

**IMPLEMENTASI *ALGORITMA CONVOLUTIONAL NEURAL NETWORK* UNTUK
IDENTIFIKASI KEMATANGAN BUAH PISANG BERDASARKAN
CITRA KULIT BUAH**

SKRIPSI

KELVIN TELAUMBANUA

191401002



PROGRAM STUDI S-1 ILMU KOMPUTER

FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI

UNIVERSITAS SUMATERA UTARA

MEDAN

2024

**IMPLEMENTASI *ALGORITMA CONVOLUTIONAL NEURAL NETWORK* UNTUK
IDENTIFIKASI KEMATANGAN BUAH PISANG BERDASARKAN
CITRA KULIT BUAH**

SKRIPSI

Diajukan untuk melengkapi tugas dan memenuhi syarat memperoleh ijazah
Sarjana Ilmu Komputer

KELVIN TELAUMBANUA

191401002



PROGRAM STUDI S-1 ILMU KOMPUTER

FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI

UNIVERSITAS SUMATERA UTARA

MEDAN

2024

PERSETUJUAN

Judul : IMPLEMENTASI *ALGORITMA CONVOLUTIONAL NEURAL NETWORK* UNTUK IDENTIFIKASI KEMATANGAN BUAH PISANG BERDASARKAN CITRA KULIT BUAH

Kategori : SKRIPSI

Nama : KELVIN TELAUMBANUA

Nomor Induk Mahasiswa : 191401002

Program Studi : SARJANA (S-1) ILMU KOMPUTER

Fakultas : ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA

Komisi Pembimbing :

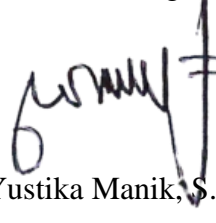
Telah diuji dan dinyatakan lulus di Medan, 24 Juni 2024

Dosen Pembimbing II




Dewi Sartika Ginting, S.Kom., M.Kom
NIP. 199005042019032023

Dosen Pembimbing I



Fuzy Yustika Manik, S.Kom., M.Kom
NIP. 198710152019032010



Diketahui/Disetujui Oleh
Ketua Program Studi S-1 Ilmu Komputer

Dj. Amalia, S.T., M.T
NIP. 19781221 201404 2 001

PERNYATAAN

IMPLEMENTASI *ALGORITMA CONVOLUTIONAL NEURAL NETWORK* UNTUK IDENTIFIKASI KEMATANGAN BUAH PISANG BERDASARKAN CITRA KULIT BUAH

SKRIPSI

Saya menyatakan bahwa skripsi ini merupakan hasil dari penelitian saya sendiri, kecuali beberapa kutipan dan ringkasan yang telah saya cantumkan sumbernya.

Medan, 24 Juni 2024

A handwritten signature in dark ink, appearing to read 'Kelvin', with a horizontal line underneath.

Kelvin Telaumbanua

191401002

PENGHARGAAN

Puji syukur kita panjatkan kehadiran Allah SWT, yang telah memberikan rahmat, hidayah, serta karunia-Nya sehingga penulis dapat menyelesaikan skripsi ini dengan judul “Implementasi Algoritma Convolutional Neural Network untuk Mengidentifikasi Kematangan Buah Pisang Berdasarkan Citra Kulit Buah”. Shalawat dan salam semoga tercurahkan kepada Nabi Muhammad SAW, keluarga, sahabat, dan pengikutnya yang setia.

Skripsi ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer pada Program Studi Ilmu Komputer, Fakultas Ilmu Komputer dan Teknologi Informasi, Universitas Sumatera Utara. Meskipun mengalami beberapa kendala selama proses penulisan, penulis berhasil mengatasi tantangan tersebut dengan sukses berkat dukungan dan panduan dari berbagai pihak.

Untuk berbagai pihak yang terlibat dalam penyelesaian skripsi ini, penulis ingin mengucapkan terima kasih yang sebesar-besarnya kepada :

1. Bapak Dr. Muryanto Amin, S.Sos., M.Si. selaku Rektor Universitas Sumatera Utara.
2. Ibu Dr. Maya Silvi Lydia, B.Sc., M.Sc. selaku Dekan Fakultas Ilmu Komputer dan Teknologi Informasi
3. Ibu Dr. Amalia, S.T., M.T. selaku Ketua Prodi S-1 Ilmu Komputer Universitas Sumatera Utara.
4. Ibu Fuzy Yustika Manik, S.Kom., M.Kom, selaku dosen pembimbing I, yang memberikan bimbingan dan arahan yang sangat berharga selama masa penyusunan skripsi.
5. Ibu Dewi Sartika Ginting, S.Kom., M.Kom, selaku dosen pembimbing II, yang memberi arahan dan saran sepanjang penulisan skripsi.
6. Ibu Anandhini Medianty Nababan S. Kom., M. T. selaku dosen pembimbing akademik yang selalu memberi solusi terkait masalah yang ada selama menjadi mahasiswa di Program Studi Ilmu Komputer.

7. Seluruh dosen dan pegawai Fakultas Ilmu Komputer dan Teknologi Informasi yang murah hati untuk berbagi ilmu dan pengetahuan selama mengemban pendidikan di kampus ini.
8. Keluarga tercinta yang sangat penulis sayangi dan banggakan, selalu memberikan doa, semangat, dan dukungan tanpa henti. Kehadiran kalian adalah sumber inspirasi dan motivasi terbesar penulis.
9. Febriando Manik selaku teman yang banyak membantu penulis dalam menyelesaikan masalah yang dihadapi selama penulisan skripsi.
10. Sahabat dan teman yang menemani masa perkuliahan yaitu Deadliner Sejati, Lapas 22, Abnormal dan Pavellas.

Skripsi ini mencoba menjawab tantangan dalam mengidentifikasi kematangan buah pisang melalui pendekatan yang inovatif menggunakan Algoritma *Convolutional Neural Network* (CNN). Melalui riset ini, diharapkan dapat memberikan kontribusi pada pengembangan teknologi di bidang pertanian, khususnya dalam mendukung proses pemantauan kualitas buah pisang secara otomatis.

Penulis sadar bahwa skripsi ini masih jauh dari kesempurnaan. Oleh karena itu, penulis sangat mengharapkan kritik dan saran yang membangun guna perbaikan di masa depan.

Semoga hasil penelitian ini dapat bermanfaat bagi pengembangan ilmu pengetahuan dan teknologi, serta memberikan inspirasi bagi penelitian-penelitian selanjutnya.

Akhir kata, penulis berharap skripsi ini dapat menjadi sumbangan kecil dalam memajukan ilmu pengetahuan dan teknologi di Indonesia.

Medan, 24 Juni 2024



Penulis

Kelvin Telaumbanua

191401002

IMPLEMENTASI *ALGORITMA CONVOLUTIONAL NEURAL NETWORK* UNTUK IDENTIFIKASI KEMATANGAN BUAH PISANG BERDASARKAN CITRA KULIT BUAH

ABSTRAK

Indonesia, dengan iklim tropisnya, menyediakan kondisi ideal untuk pertumbuhan berbagai jenis tanaman, termasuk pisang yang merupakan salah satu komoditas buah utama. Produksi pisang di Indonesia mencapai 25,96 juta ton pada tahun 2021, meningkat 5,4% dari tahun sebelumnya. Pisang, dengan beragam tahap kematangan mentah, setengah matang, matang, dan terlalu matang menawarkan manfaat kesehatan yang berbeda pada setiap tahapnya. Pemilihan tingkat kematangan yang tepat sangat penting untuk kesehatan dan penyimpanan. Saat ini, identifikasi kematangan pisang dilakukan secara manual melalui pengamatan visual, yang dapat menyebabkan ketidakkonsistenan karena subjektivitas. Oleh karena itu, penelitian ini bertujuan mengembangkan sistem klasifikasi kematangan pisang menggunakan algoritma *Convolutional Neural Network* (CNN) yang menganalisis perubahan warna kulit pisang. Berdasarkan penelitian sebelumnya yang menunjukkan efektivitas CNN dalam klasifikasi objek, model VGG16 dipilih untuk penelitian ini. Hasil penelitian menunjukkan bahwa CNN adalah pendekatan yang efektif untuk identifikasi kematangan pisang, dengan model VGG16 mencapai akurasi, precision, recall, dan F1-score masing-masing sebesar 100%. Kesimpulan ini menegaskan bahwa metode berbasis CNN dapat menyediakan cara objektif dan konsisten untuk mengidentifikasi kematangan pisang, membantu meningkatkan kualitas dan efisiensi dalam pemrosesan dan penyimpanan pisang. Implementasi sistem ini diharapkan dapat mengurangi ketergantungan pada penilaian manual, meningkatkan ketepatan klasifikasi kematangan, serta mendukung industri pisang di Indonesia dalam menghasilkan produk berkualitas tinggi.

Kata Kunci: *Convolutional Neural Network*, Indonesia, Kematangan pisang, klasifikasi, Model VGG16

Implementation of Convolutional Neural Network Algorithm for Identification of Banana Maturity Based on Fruit Skin Image

ABSTRACT

Indonesia, with its tropical climate, provides ideal conditions for the growth of various types of plants, including bananas, which are one of the main fruit commodities. Banana production in Indonesia reached 25.96 million tons in 2021, an increase of 5.4% from the previous year. Bananas, with their various ripening stages—unripe, semi-ripe, and ripe—offer different health benefits at each stage. Selecting the appropriate ripeness level is crucial for health and storage purposes. Currently, banana ripeness identification is performed manually through visual observation, which can lead to inconsistencies due to subjectivity. Therefore, this study aims to develop a banana ripeness classification system using a Convolutional Neural Network (CNN) algorithm that analyzes changes in the banana peel color. Based on previous research demonstrating the effectiveness of CNN in object classification, the VGG16 model was chosen for this study. The results indicate that CNN is an effective approach for identifying banana ripeness, with the VGG16 model achieving 100% accuracy, precision, recall, and F1-score. This conclusion affirms that a CNN-based method can provide an objective and consistent way to identify banana ripeness, helping to improve the quality and efficiency in banana processing and storage. The implementation of this system is expected to reduce reliance on manual assessment, enhance the accuracy of ripeness classification, and support the banana industry in Indonesia in producing high-quality products.

Keywords: Bananas Ripeness, Convolutional Neural Network, Classification, Indonesia, VGG16 Model.

DAFTAR ISI

PERSETUJUAN	iii
PERNYATAAN	iv
PENGHARGAAN	v
ABSTRAK	vii
ABSTRACT	viii
DAFTAR ISI	ix
DAFTAR GAMBAR	xii
DAFTAR TABEL	xiii
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Masalah	4
1.4 Tujuan Penelitian	4
1.5 Manfaat Penelitian	5
1.6 Metodologi Penelitian	5
1. Studi Pustaka	5
2. Perancangan Sistem	5
3. Implementasi Sistem	5
4. Pengujian Sistem	6
5. Dokumentasi	6
1.7 Penelitian Relevan	6
1.8 Sistematika Penulisan	7
BAB 1 PENDAHULUAN	7
BAB 2 LANDASAN TEORI	7
BAB 3 ANALISIS DAN PERANCANGAN SISTEM	7
BAB 4 IMPLEMENTASI DAN PENGUJIAN	7
BAB 5 KESIMPULAN DAN SARAN	7
BAB 2 TINJAUAN PUSTAKA	8
2.1 Pisang	8
2.2 Machine Learning	8
2.3 Deep Learning	9
2.4 Convolutional Neural Network	10
2.4.1 Convolutional Layer	11

2.4.2	Pooling Layer.....	14
2.4.3	ReLu.....	15
2.4.4	Fully Connected Layer.....	15
2.4.5	Softmax	16
2.5	Arsitektur VGG 16.....	16
BAB 3	ANALISIS DAN PERANCANGAN	19
3.1	Analisis Sistem.....	19
3.1.1	Analisis Masalah.....	19
3.1.2	Analisis Kebutuhan.....	20
3.1.3	Analisis Proses.....	21
3.1.3	Arsitektur Umum	24
3.2	Pemodelan Sistem	25
3.2.1	Use Case Diagram.....	25
3.2.2	Activity Diagram	26
3.2.3	Sequence Diagram	26
3.3	Flowchart.....	27
3.4	Perancangan Antarmuka Sistem	28
3.4.1	Halaman Pertama	28
3.4.2	Halaman Hasil Uji Data	28
BAB 4	IMPLEMENTASI DAN PENGUJIAN.....	30
4.1	Implementasi Sistem.....	30
4.2	Pengumpulan Dataset.....	30
4.3	Pelabelan Dataset.....	30
4.4	Implementasi Tahapan Antarmuka	31
4.5	Perancangan Model	33
4.5.1	Model CNN	34
4.5.2	Model VGG16	35
4.6	Penentuan Parameter Model	37
4.6.1	Pengaruh Banyaknya Epoch.....	37
4.7	Pengujian Sistem.....	38
4.7.1	Hasil Proses Training.....	38
4.7.2	Hasil Proses Testing.....	40
BAB 5	KESIMPULAN DAN SARAN.....	48
5.1	Kesimpulan.....	48
5.2	Saran	48

DAFTAR PUSTAKA.....	49
---------------------	----

DAFTAR GAMBAR

Gambar 2.1	Flowchart Algoritma CNN	10
Gambar 2.2	Arsitektur Pelatihan CNN (Yamashita et al., 2018).....	11
Gambar 2.3	Perhitungan pada Convolutional Layer (Taye, 2023).....	12
Gambar 2.4	Cara Kerja Stride	13
Gambar 2.5	Zero Padding.....	14
Gambar 2.6	Pooling Layer	15
Gambar 2.7	ReLu Function	15
Gambar 2.8	Fully Connected Layer	16
Gambar 2.9	Arsitektur VGG16	17
Gambar 3.1	Diagram Ishikawa.....	19
Gambar 3.2	Pisang Mentah Hari Pertama	21
Gambar 3.3	Pisang Mentah Hari Keempat.....	21
Gambar 3.4	Pisang Mentah Hari Kelima	22
Gambar 3.5	Pisang Setengah Matang Hari Kedelapan	22
Gambar 3.6	Pisang Matang Hari Kesembilan	23
Gambar 3.7	Pisang Terlalu Matang Hari Keduabelas	23
Gambar 3.8	Arsitektur umum	24
Gambar 3.9	Use Case Diagram Sistem	25
Gambar 3.10	Activity Diagram	26
Gambar 3.11	Sequence Diagram	26
Gambar 3.12	Flowchart Sistem	27
Gambar 3.13	Rancangan Halaman Pertama Sistem	28
Gambar 3.14	Rancangan Halaman Hasil Uji Data Sistem	29
Gambar 4.1	Perbandingan warna pada setiap tingkat kematangan pisang.....	31
Gambar 4.2	Tampilan Antarmuka Sistem.....	33
Gambar 4.3	Tampilan Halaman Beranda	33
Gambar 4.4	Tampilan Awal Halaman Uji Data	33
Gambar 4.5	Implementasi Model CNN.....	34
Gambar 4.6	Perancangan Model VGG16.....	35
Gambar 4.7	Hasil Prediksi Proses Training.....	39
Gambar 4.8	Hasil Akurasi Proses Training	39
Gambar 4.9	Grafik accuracy dan loss.....	40

DAFTAR TABEL

Tabel 3.1 Tabel dataset	24
Tabel 4.1 Tabel Banyaknya Epoch	38
Tabel 4.2 Tabel Pengujian Model	40
Tabel 4.3 Tabel Confusion Matrixs	45
Tabel 4.4 Tabel Precision	46
Tabel 4.5 Tabel Recall	46

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Indonesia terletak di wilayah tropis dengan berbagai jenis iklim dan tanah yang berbeda-beda. Hal ini menciptakan kondisi yang ideal untuk pertumbuhan beragam jenis tanaman dan tumbuhan, mulai dari hutan hujan tropis di Kalimantan dan Sumatera hingga dataran tinggi di Jawa dan Bali yang cocok untuk pertanian. Menurut Kementerian Koordinator Bidang Perekonomian (Kemenko Perekonomian) pada siaran pers tahun 2022 (Kemenko Perekonomian, 2022), tahun 2021 produksi pisang mencapai 25,96 juta ton, mengalami peningkatan sebesar 5,4% dibandingkan produksi tahun 2020 yang sebanyak 24,63 juta ton. Komoditas dengan jumlah produksi terbesar adalah pisang (8,74 juta ton atau 33,67%), diikuti oleh nanas (2,89 juta ton atau 11,13%), mangga (2,84 juta ton atau 10,94%), jeruk siam (2,4 juta ton atau 9,24%), dan durian (1,35 juta ton atau 5,2%).

Pisang menjadi salah satu komoditas buah terbanyak di Indonesia. Namun, Pisang melewati beberapa tahap kematangan yang dapat memengaruhi cita rasa dan manfaatnya. Tahap-tahap tersebut meliputi pisang yang belum matang (hijau), pisang yang setengah matang (hijau kekuningan), dan pisang yang sudah matang (kuning). Memilih pisang dengan tingkat kematangan yang sesuai sangat penting bagi kesehatan tubuh. Selain itu, tingkat kematangan pisang juga menyediakan informasi mengenai lamanya buah pisang dapat disimpan.

Manfaat buah pisang bervariasi pada tiap tingkat kematangannya. Pisang mentah mengandung serat yang bermanfaat untuk mendukung diet, mengontrol suhu tubuh, dan membantu menghilangkan pengaruh nikotin. Pisang setengah matang mengandung pectin yang dapat mengatur kadar gula darah dan menjaga kesehatan jantung. Pisang matang mengandung nutrisi tinggi, termasuk vitamin C dan antioksidan, yang baik untuk kesehatan tubuh. Sementara pisang yang terlalu matang memiliki tekstur lebih lembut daripada tingkat kematangan lainnya, namun mengandung kadar gula yang lebih tinggi.

Selain memberikan manfaat bagi tubuh, tingkat kematangan buah pisang juga memberikan indikasi mengenai lamanya buah tersebut dapat disimpan sebelum mencapai

tahap matang (berwarna kuning). Pisang mentah biasanya memiliki umur simpan yang lebih panjang, sekitar 5-7 hari, sementara pisang setengah matang cenderung memiliki umur simpan yang lebih singkat, sekitar 2-3 hari.

Pemahaman akan manfaat dan lamanya penyimpanan pisang sangat penting, terutama bagi konsumen yang ingin memaksimalkan nilai gizi dari buah ini. Dengan memilih tingkat kematangan yang sesuai dengan kebutuhan, kita dapat menikmati rasa yang optimal serta mendapatkan manfaat kesehatan yang maksimal. Pisang juga sangat fleksibel dalam penggunaannya, baik sebagai camilan sehat maupun bahan utama dalam berbagai resep kuliner, sehingga menjadi pilihan yang populer di berbagai kalangan.

Pada saat ini, melakukan identifikasi kematangan buah pisang masih bergantung dengan metode manual yang mengandalkan pengamatan visual sebagai alat untuk mendeteksi kematangan pada buah pisang. Meskipun begitu, pendekatan ini berpotensi mengalami kesalahan karena hal tersebut sangat bergantung pada penilaian subjektif dari pelaku pemilahan kematangan buah pisang ini. Hal ini berpotensi mengakibatkan ketidaksesuaian dalam proses identifikasi, terutama ketika pemilah memiliki beberapa penilaian yang berbeda.

Mengembangkan metode identifikasi buah pisang yang lebih objektif dan konsisten akan menjadi perhatian utama dalam solusi pemilahan dan pemrosesan identifikasi buah pisang.

Beberapa penelitian yang mengeksplorasi penerapan Algoritma *Convolutional Neural Network* (CNN) dalam untuk klasifikasi buah pepaya jika sudah matang atau matang sebagian atau belum matang. Model terlatih mencapai akurasi 100% pada serangkaian pengujian yang diadakan, yang menunjukkan kelayakan model klasifikasi VGG16 mencapai akurasi 100% dan waktu latihan 112 detik (Al-Masawabe M. et al., 2021).

Berdasarkan penelitian (R. et al., 2023) pengklasifikasian empat jenis kelas ikan, yaitu *Bangus*, *Glass Prechlet*, *Gold Fish*, dan *Gourami*, dengan menggunakan model VGG-16 pada *Convolutional Neural Network* (CNN), berhasil mencapai tingkat akurasi sebesar 96,2% pada proses pelatihan dan mencapai 99,5% pada proses pengujian menggunakan data uji.

Berdasarkan penelitian (Abu-Jamie & Abu-Naser, 2022) dalam upaya mengkategorikan bahasa isyarat menggunakan 29 label kelas gambar (A-Z) untuk meningkatkan komunikasi dengan masyarakat tunarungu, penggunaan *Convolutional Neural Network* (CNN) dengan model VGG-16 telah berhasil mencapai tingkat akurasi 100% selama pengujian 20 *epoch*.

Berdasarkan konteks latar belakang dan penelitian sebelumnya, fokus utama dari penelitian ini akan diarahkan kepada pengembangan sistem klasifikasi kematangan buah pisang. Pendekatan yang digunakan adalah dengan menganalisis perubahan warna pada kulit buah menggunakan Algoritma *Convolutional Neural Network* (CNN). Tujuan utama dari penelitian ini adalah untuk mengidentifikasi buah pisang yang telah mencapai tingkat kematangan tertentu dengan memanfaatkan informasi warna yang terdapat pada kulit buah pisang. Selain itu, penelitian ini juga akan menyajikan informasi terkait lamanya masa simpan buah pisang pada berbagai tahap kematangan dan mengungkap manfaat kesehatan yang dapat diperoleh dari buah pisang pada tahap kematangan tertentu.

1.2 Rumusan Masalah

Pentingnya memilih pisang dengan tingkat kematangan yang tepat untuk kesehatan tubuh menjadi sorotan, karena setiap tahap kematangan memberikan manfaat kesehatan yang berbeda. Namun, pada saat ini, identifikasi kematangan buah pisang masih dilakukan secara manual dengan mengandalkan pengamatan visual, yang berpotensi mengakibatkan ketidaksesuaian dalam proses identifikasi.

Untuk meningkatkan efisiensi dalam pemrosesan identifikasi buah pisang, penelitian ini bertujuan utama untuk mengembangkan sistem klasifikasi kematangan buah pisang. Pendekatan yang digunakan melibatkan analisis perubahan warna pada kulit buah menggunakan Algoritma *Convolutional Neural Network* (CNN). Dalam konteks ini, penelitian juga akan memberikan informasi lamanya masa simpan buah pisang pada berbagai tahap kematangan dan mengungkap manfaat kesehatan yang dapat diperoleh pada tingkat kematangan tertentu.

1.3 Batasan Masalah

Beberapa batasan masalah dalam penelitian ini sebagai berikut.

1. Menggunakan algoritma *Convolutional Neural Network* (CNN) dan model VGG-16
2. Penelitian ini bertujuan untuk mendeteksi tingkat kematangan buah pisang, khususnya untuk jenis pisang barangan.
3. Sistem mendeteksi gambar berupa satu sisir buah pisang.
4. Output yang dihasilkan dari sistem adalah hasil identifikasi buah pisang mentah, setengah matang, matang, atau terlalu matang sesuai dengan indikator warna kulit buah. Penelitian ini juga menyajikan lama umur simpan dan manfaat buah pisang dari tingkat kematangannya.

Indikator yang digunakan dalam pengukuran identifikasi tingkat kematangan buah pisang sebagai berikut.

1. Buah pisang mentah dengan warna hijau
 2. Buah pisang setengah matang dengan warna hijau kekuningan
 3. Buah pisang matang dengan warna kuning
 4. Buah pisang terlalu matang dengan warna kuning kecoklatan
5. Sistem yang dibangun menggunakan bahasa pemrograman *Python* yang dirancang berbasis website.

1.4 Tujuan Penelitian

Penelitian ini bertujuan untuk mengembangkan sebuah website klasifikasi kematangan buah pisang dengan menggunakan pendekatan analisis perubahan warna pada kulit buah menggunakan Algoritma *Convolutional Neural Network* (CNN). Fokus utama adalah mengidentifikasi buah pisang yang telah mencapai tingkat kematangan tertentu dengan memanfaatkan informasi warna yang terdapat pada kulit buah. Selain itu, penelitian ini juga bertujuan untuk memberikan informasi terkait lamanya masa simpan buah pisang pada berbagai tahap kematangan dan juga menyediakan wawasan yang berharga mengenai manfaat kesehatan yang dapat diperoleh dari buah pisang pada tingkat kematangan tertentu.

1.5 Manfaat Penelitian

Manfaat dari penelitian ini yaitu sebagai berikut.

1. Memberikan sebuah sistem berbasis website yang dapat mengklasifikasi tingkat kematangan buah pisang dalam pemilahan dan pemasaran buah pisang.
2. Memberikan informasi mengenai lamanya masa simpan buah pisang pada berbagai tahap kematangan.
3. Memberikan pengetahuan manfaat buah pisang pada tingkat kematangannya yang dapat membantu individu dalam memilih buah pisang sesuai dengan kebutuhan nutrisinya.

1.6 Metodologi Penelitian

Beberapa metode yang diterapkan pada penelitian ini sebagai berikut.

1. Studi Pustaka

Pada tahap ini, penelitian dimulai dengan menghimpun referensi dan melakukan tinjauan literatur termasuk buku, jurnal, makalah, serta penelitian terkait pengujian klasifikasi tingkat kematangan buah dengan metode *Convolutional Neural Network* (CNN) menggunakan model VGG-16.

2. Perancangan Sistem

Pada tahap ini, dilakukan evaluasi keperluan sistem penelitian yang selanjutnya akan dirancang dalam bentuk diagram alir (*flowchart*), *use case diagram*, *activity diagram*, dan tampilan antarmuka sistem (*interface*).

3. Implementasi Sistem

Pada tahap ini, dilakukan pembuatan sebuah website yang sesuai hasil rancangan yang telah ada. Aplikasi website akan dibangun menggunakan bahasa pemrograman *Python* yang kemudian akan diimplementasikan ke dalam website menggunakan *framework Flask*.

4. Pengujian Sistem

Pada tahap pengujian sistem ini, dilakukan perbandingan citra yang telah diambil dengan hasil yang telah diproses oleh sistem. Hal ini bertujuan untuk memverifikasi bahwa aplikasi yang telah dikembangkan beroperasi sesuai dengan rencana sebelumnya.

5. Dokumentasi

Pada tahap ini, peneliti melakukan proses dokumentasi dan penyusunan laporan berdasarkan hasil dari penelitian mengenai aplikasi yang telah dibuat.

1.7 Penelitian Relevan

Berikut ini disajikan sejumlah penelitian yang memiliki kaitan dengan topik penelitian ini.

1. Berdasarkan penelitian (Al-Masawabe M. et al., 2021) yang berjudul “*Papaya maturity Classification Using Deep Convolutional Neural Networks*” untuk klasifikasi buah pepaya jika sudah matang atau matang sebagian atau belum matang. Model terlatih mencapai akurasi 100% pada serangkaian pengujian yang diadakan, yang menunjukkan kelayakan model klasifikasi VGG16 mencapai akurasi 100% dan waktu latihan 112 detik.
2. Berdasarkan penelitian (R. et al., 2023) yang berjudul “Klasifikasi Citra Ikan Menggunakan Algoritma *Convolutional Neural Network* dengan Arsitektur VGG-16” yang bertujuan untuk mengklasifikasikan empat jenis kelas ikan, yaitu Bangus, Glass Prechlet, Gold Fish, dan Gourami, dengan menggunakan model VGG-16 pada *Convolutional Neural Network* (CNN), berhasil mencapai tingkat akurasi sebesar 96,2% pada proses pelatihan dan mencapai 99,5% pada proses pengujian menggunakan data uji.
3. Berdasarkan penelitian (Abu-Jamie & Abu-Naser, 2022) yang berjudul “*Classification of Sign-language Using VGG16*” dalam upaya mengkategorikan bahasa isyarat menggunakan 29 label kelas gambar (A-Z) untuk meningkatkan komunikasi dengan masyarakat tunarungu, penggunaan *Convolutional Neural Network* (CNN) dengan

model VGG-16 telah berhasil mencapai tingkat akurasi 100% selama pengujian 20 *epoch*.

1.8 Sistematika Penulisan

Penyusunan kerangka skripsi ini mengikuti beberapa bagian yang diatur secara berurutan, seperti yang dijabarkan di bawah ini:

BAB 1 PENDAHULUAN

Pada bagian ini, akan dijelaskan mengenai konteks awal dari masalah, pengidentifikasian masalah, batasan lingkup masalah, dampak dari hasil penelitian, langkah-langkah yang diambil dalam penelitian, penelitian sebelumnya yang relevan, dan pengaturan struktur tulisan.

BAB 2 LANDASAN TEORI

Pada bab ini, dijelaskan tentang beberapa teori mengenai deep learning, tingkat kematangan buah pisang, dan algoritma *Convolutional Neural Network* (CNN).

BAB 3 ANALISIS DAN PERANCANGAN SISTEM

Bagian ini mencakup analisis proses, perancangan sistem antarmuka dari website klasifikasi kematangan buah pisang berdasarkan warna dengan menggunakan algoritma *Convolutional Neural Network* (CNN)

BAB 4 IMPLEMENTASI DAN PENGUJIAN

Pada bagian ini, akan diuraikan mengenai pelaksanaan implementasi sistem dan hasil pengujian yang telah berhasil diselesaikan.

BAB 5 KESIMPULAN DAN SARAN

Bagian ini melibatkan rangkuman temuan dari penelitian serta rekomendasi yang diberikan oleh peneliti yang dapat memberikan kontribusi pada penelitian yang akan datang.

BAB 2

TINJAUAN PUSTAKA

2.1 Pisang

Pisang (*Musa spp.*) adalah sumber pangan vital bagi sebagian besar populasi dunia. Produksi global pisang meningkat sebesar 3,7% antara tahun 2000 dan 2015, dari 68,2 juta ton pada tahun 2000 menjadi 117,9 juta ton pada tahun 2015. Tingkat hasil pisang bervariasi tergantung pada negara produsen pisang, produksi, dan jenis varietas pisang (Olivares et al., 2020). Pisang memiliki peran penting dalam asupan makanan masyarakat di daerah tropis. Tanaman ini merupakan sumber karbohidrat yang tinggi dan mengandung sejumlah besar vitamin serta mineral seperti kalium, vitamin C, dan vitamin B6.

Selain berperan sebagai sumber nutrisi penting, pisang juga menyediakan serat yang bermanfaat bagi sistem pencernaan. Kalium yang terdapat dalam pisang memiliki peran yang sangat penting dalam menjaga keseimbangan cairan dan elektrolit di dalam tubuh, yang menjadi kunci penting untuk fungsi jantung dan otot yang sehat. Vitamin B6 yang terdapat dalam pisang membantu dalam proses metabolisme protein serta produksi neurotransmitter yang mendukung kesehatan otak. Selain itu, vitamin C berperan sebagai antioksidan pelindung sel-sel tubuh dari kerusakan yang disebabkan oleh radikal bebas, serta secara simultan meningkatkan sistem kekebalan tubuh.

2.2 Machine Learning

Machine Learning membahas cara membangun komputer yang dapat meningkat secara otomatis melalui pengalaman (Jordan & Mitchell, 2015). *Machine Learning* memiliki peran penting dalam pengelolaan dan prediksi data dengan menerapkan algoritma pembelajaran. Dengan menerapkan *Machine Learning*, komputer dapat secara otonom menjalani proses pembelajaran melalui analisis data yang diberikan. Sejalan dengan hal tersebut, menurut (Shukla, 2008) *Machine Learning* dapat digambarkan sebagai suatu paradigma di mana perangkat lunak memiliki kemampuan untuk belajar dari pengalaman sebelumnya. Program komputer diberikan keahlian untuk

mengidentifikasi suatu pola dan menerapkan pengetahuan yang diperoleh dari pengalaman masa lalu.

Machine Learning memiliki kemampuan dalam mengklasifikasi gambar buah. Dalam konteks ini, komputer diajarkan untuk mengenali berbagai jenis buah berdasarkan pola visual yang terdapat pada gambar-gambar buah yang diberikan. Proses pembelajaran ini melibatkan penyajian komputer dengan kumpulan gambar buah yang telah diklasifikasikan sebelumnya, dan melalui algoritma Machine Learning seperti jaringan saraf tiruan atau pohon keputusan, komputer belajar untuk mengidentifikasi perbedaan visual antara berbagai jenis buah.

Setelah proses pelatihan selesai, komputer dapat dengan akurat mengklasifikasikan gambar-gambar buah baru yang belum pernah dilihat sebelumnya ke dalam kategori yang sesuai. Hal ini memiliki berbagai aplikasi praktis, seperti dalam industri pertanian untuk mengklasifikasikan hasil panen, dalam perdagangan untuk memeriksa kualitas buah-buahan.

2.3 Deep Learning

Deep learning memberi kemungkinan dalam pengembangan model komputasi yang tersusun dari beberapa lapisan pemrosesan untuk memahami representasi data dengan tingkat abstraksi yang beragam. Dengan memanfaatkan algoritma *Convolutional Neural Network* (CNN), *Deep Learning* memiliki kemampuan untuk mengidentifikasi struktur kompleks dalam himpunan data besar. Algoritma ini memungkinkan mesin untuk mengatur parameter internal guna menghasilkan representasi pada tiap lapisan, yang dibentuk berdasarkan representasi lapisan sebelumnya (Lecun et al., 2015).


Cara *deep learning* beroperasi menyerupai cara otak manusia bekerja, di mana neuron-neuron (sel-sel saraf) saling terhubung dalam jaringan yang mendalam untuk memproses informasi. *Deep learning* memungkinkan komputer untuk menyelesaikan tugas-tugas yang lebih kompleks, seperti mengenali objek dalam gambar, menerjemahkan bahasa, dan bahkan mengidentifikasi suara. Kemajuan dalam deep learning telah menghasilkan perubahan signifikan dalam berbagai bidang, termasuk pengenalan wajah, kendaraan otonom, pengobatan medis, dan analisis data besar. Seiring dengan terus

berkembangnya teknologi ini, potensi deep learning untuk mengubah cara kita berinteraksi dengan teknologi dan dunia di sekitar kita secara menyeluruh semakin besar.

2.4 Convolutional Neural Network

Convolutional Neural Network menggambarkan struktur inti *Deep Learning*. Arsitektur yang dimiliki oleh CNN terbentuk oleh berbagai lapisan representasi yang memiliki fitur-fitur penting. Karakteristik ini memberikan CNN untuk secara otomatis mengidentifikasi representasi khusus dari data melalui transformasi nonlinier dan pemodelan fungsi nonlinier.

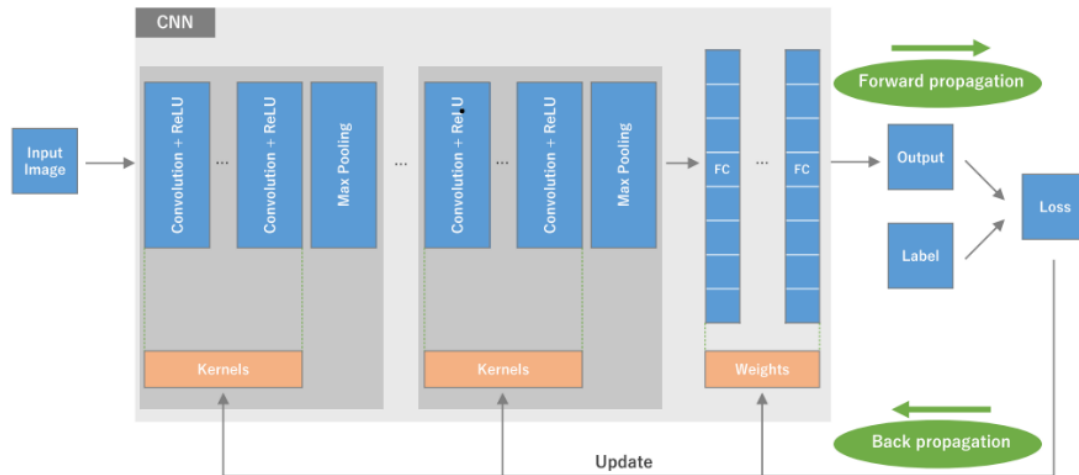
Struktur CNN terdiri dari komponen yang melibatkan ekstraksi fitur otomatis. Proses ini dimulai dengan lapisan konvolusi, yang umumnya diikuti oleh lapisan polling, dan diakhiri dengan lapisan klasifikasi softmax. Pada lapisan konvolusi, fitur-fitur diambil dari citra gambar melalui operasi konvolusi. Kemudian, pada lapisan polling, dimensi data dikurangi, mengurangi kebutuhan komputasi. Kelebihan dari arsitektur ini adalah kemampuannya untuk menciptakan regulasi internal. Fitur-fitur yang diekstraksi oleh konvolusi dan polling selanjutnya disalurkan ke dalam lapisan softmax untuk proses klasifikasi (You et al., 2017).



Gambar 2.1 Flowchart Algoritma CNN

Ada dua tahap propagasi yang terjadi dalam algoritma CNN, yakni propagasi maju (*forward propagation*) dan propagasi mundur (*back propagation*). Pada tahap propagasi maju, nilai-nilai pada citra input akan diambil atau diekstraksi pada tahap ekstraksi fitur. Setelah itu, hasil dari proses ekstraksi fitur tersebut akan membuat sebuah

model pada algoritma. Model ini akan memberi petunjuk prediksi citra dalam proses klasifikasi. Sedangkan, pada tahap propagasi mundur, algoritma akan menghitung gradien *loss* mulai dari lapisan output hingga ke lapisan input citra. Hal ini bertujuan untuk mengurangi nilai *loss* pada saat pelatihan model. Ilustrasi dari arsitektur CNN yang sesuai dengan konsep tersebut dapat dilihat pada **Gambar 2.2**.



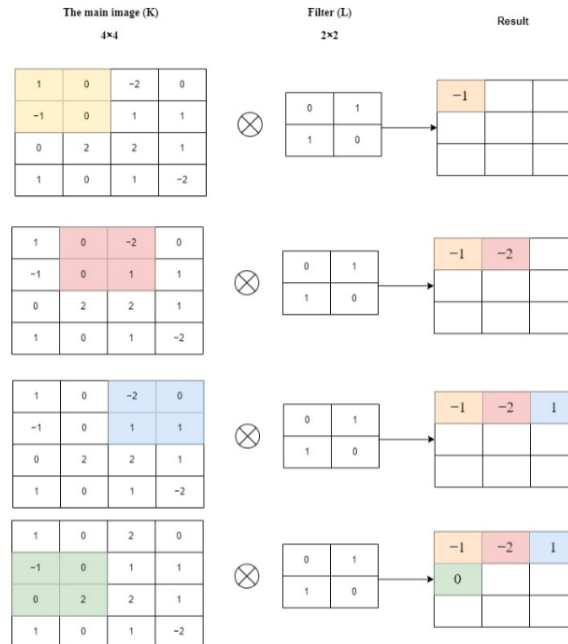
Gambar 2.2 Arsitektur Pelatihan CNN (Yamashita et al., 2018)

2.4.1 Convolutional Layer

Convolutional Layer adalah elemen pokok dalam arsitektur CNN yang bertanggung jawab untuk mengekstraksi fitur, umumnya terdiri dari gabungan operasi linier dan nonlinier, seperti operasi konvolusi dan fungsi aktivasi. Lapisan ini tersusun dari beberapa kernel (*convolutional kernels*). Kernel memiliki nilai diskrit yang dinamakan bobot kernel. Kernel ini juga bertanggung jawab atas proses ekstraksi fitur dari gambar pada saat pelatihan.

Selain berfungsi sebagai ekstraktor fitur, *Convolutional Layer* juga memainkan peran penting dalam menentukan kompleksitas dan kemampuan model untuk memahami data. Jumlah dan ukuran kernel yang dipilih dengan tepat dapat mempengaruhi seberapa baik model dapat menangkap fitur-fitur yang relevan dari gambar. Dengan mengatur bobot kernel dan melalui proses pembelajaran, lapisan konvolusi dapat mengidentifikasi pola-pola penting dalam data input, seperti tepi, sudut, atau tekstur, yang kemudian digunakan untuk

klasifikasi atau deteksi objek. Oleh karena itu, desain yang teliti dan optimasi lapisan konvolusi menjadi kunci dalam pengembangan arsitektur CNN yang efektif dan efisien.




Gambar 2.3 Perhitungan pada Convolutional Layer (Taye, 2023)

2.4.1.1 Stride

Stride merupakan parameter yang terletak pada convolutional layer yang mengatur seberapa jauh filter akan bergeser selama proses konvolusi. Selain menentukan seberapa jauh filter akan bergeser selama proses konvolusi, nilai stride dalam *convolutional layer* juga memiliki dampak yang signifikan terhadap representasi fitur yang diekstraksi. Semakin besar nilai stride, semakin sedikit informasi yang dipertahankan dalam output lapisan konvolusi karena langkah yang lebih besar menghasilkan jarak yang lebih besar antara setiap titik sampel yang diambil. Ini dapat mengurangi jumlah parameter yang diperlukan dan mempercepat waktu komputasi, tetapi juga dapat mengurangi ketepatan representasi fitur yang dihasilkan.

Pengambilan informasi dari gambar menjadi lebih terbatas karena filter "melompati" area yang lebih besar, sehingga berpotensi kehilangan

detail dan informasi penting. Oleh karena itu, pemilihan nilai stride yang sesuai menjadi penting dalam desain arsitektur CNN. Diperlukan keseimbangan antara efisiensi komputasi dan kemampuan model untuk mengekstrak fitur yang relevan dan akurat dari data input. Dengan memahami peran dan dampak stride, pengembang dapat meningkatkan kinerja dan efektivitas model convolutional neural network mereka dalam berbagai tugas pengolahan citra dan pembelajaran mesin.



Gambar 2.4 Cara Kerja Stride

2.4.1.2 Padding

Teknik yang digunakan untuk menambahkan piksel di sekitar gambar atau input data sebelum proses konvolusi disebut dengan *padding*. Teknik ini bertujuan untuk mempertahankan informasi dari tepi gambar saat melakukan proses konvolusi. Penggunaan padding akan membantu kernel untuk mengekstrak nilai-nilai pada tepi dari input gambar.

Terdapat 2 jenis padding yang umum digunakan:

1. Valid (No padding) : Tanpa penambahan piksel tambahan di sekitar gambar. Ini dapat menyebabkan hilangnya informasi tepi.
2. Same (Zero Padding) : Menambahkan piksel dengan nilai nol di sekitar gambar sehingga ukuran output setelah konvolusi tetap sama dengan ukuran input.

0	0	0	0	0	0	0	0	0
0								0
0								0
0								0
0								0
0								0
0								0
0								0
0								0
0	0	0	0	0	0	0	0	0


Gambar 2.5 Zero Padding

2.4.2 Pooling Layer

Lapisan ini memiliki fungsi untuk mengurangi dimensi spasial (panjang dan lebar) dari representasi gambar, sehingga mengurangi jumlah komputasi dalam jaringan, dan untuk mengontrol overfitting. Pada lapisan ini juga akan melakukan operasi untuk mencari nilai maksimum (*Max Pooling*) atau nilai rata-rata (*Average Pooling*) pada inputan. Selain fungsi dasarnya untuk mereduksi dimensi spasial dan mengendalikan overfitting, lapisan pooling juga memberikan manfaat tambahan dalam pengembangan *convolutional neural network* (CNN).

Proses *pooling*, seperti *max pooling* atau *average pooling*, memungkinkan jaringan untuk mendeteksi fitur-fitur penting tanpa terlalu sensitif terhadap pergeseran kecil dalam gambar. Ini membantu menciptakan invariansi translasi, di mana objek yang sama tetap dapat dikenali meskipun sedikit bergeser dalam gambar. Selain itu, *pooling* juga berperan dalam mengurangi jumlah parameter yang dibutuhkan dalam model, sehingga menghasilkan model yang lebih ringan dan efisien secara komputasi.

Namun, penting untuk diingat bahwa proses pooling juga dapat mengurangi detail spesifik dalam representasi gambar, sehingga penyesuaian parameter seperti ukuran pada *pooling* menjadi kunci untuk mempertahankan informasi penting sambil tetap mengurangi dimensi data. Dengan pemahaman yang baik tentang peran dan dampaknya, penggunaan *pooling layer* dapat dioptimalkan untuk meningkatkan kinerja dan generalisasi model CNN dalam berbagai tugas pengolahan citra.



Gambar 2.6 Pooling Layer

2.4.3 ReLu


Rectified Linear Unit (ReLU) merupakan fungsi aktivasi yang umum digunakan dalam lapisan konvolusi (CNN) dan jaringan saraf di dalam pembahasan *deep learning*. Keuntungan ReLU lebih efisien dibandingkan dengan fungsi-fungsi lainnya karena tidak semua neuron diaktifkan secara bersamaan. Sebaliknya, sejumlah neuron diaktifkan pada waktu tertentu, meningkatkan efisiensi penggunaan fungsi ini (Sharma et al., 2020).



Gambar 2.7 ReLu Function

2.4.4 Fully Connected Layer

Menurut (Alzubaidi et al., 2021), *Fully Connected Layer* merupakan lapisan yang berada pada urutan terakhir dalam arsitektur CNN. Fungsinya adalah menghubungkan setiap neuron dalam satu lapisan dengan setiap neuron dalam lapisan berikutnya, bertujuan untuk menentukan hasil output yang akan dihasilkan. Input untuk *Fully Connected Layer* diperoleh dari lapisan-lapisan sebelumnya, seperti *Pooling Layer* atau *Convolutional Layer*, dalam bentuk vektor yang terbentuk dari *feature maps* setelah melalui proses *flattening*.



Gambar 2.8 Fully Connected Layer

2.4.5 Softmax

Softmax merupakan fungsi aktivasi yang digunakan untuk dataset yang memiliki kelas yang banyak (*multiclass*). Lapisan ini biasanya ditempatkan di akhir arsitektur sebagai fungsi aktivasi output. Ini berguna ketika jaringan diterapkan untuk tugas klasifikasi, di mana algoritma ingin menentukan kategori atau kelas dari input gambar. *Softmax* memproses skor atau nilai keluaran dari layer sebelumnya dan mengonversinya menjadi distribusi probabilitas.

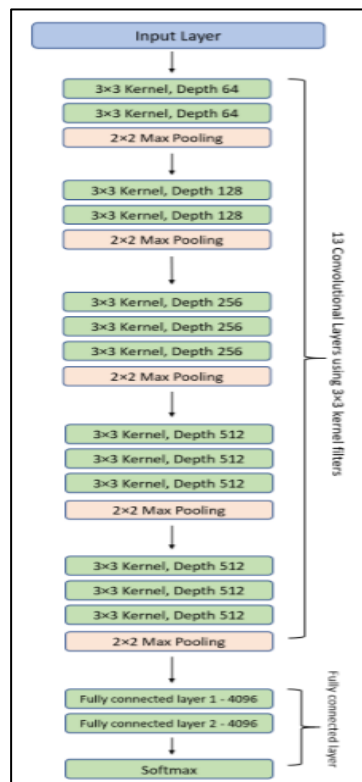
Penggunaan fungsi aktivasi softmax dalam lapisan akhir arsitektur CNN sangat penting untuk mempermudah interpretasi hasil klasifikasi. Dengan mengubah nilai output menjadi distribusi probabilitas, *softmax* memberikan pemahaman yang jelas tentang tingkat keyakinan model terhadap setiap kelas yang mungkin. Ini memungkinkan untuk menentukan kelas prediksi dengan tingkat kepercayaan tertinggi, yang sangat diperlukan dalam banyak aplikasi praktis seperti klasifikasi objek dalam gambar buah atau identifikasi wajah dalam sistem pengenalan.

2.5 Arsitektur VGG 16

VGG16 merupakan sebuah model *Convolutional Neural Network* (CNN) yang dikembangkan oleh Karen Simonyan dan Andrew Zisserman dari Universitas Oxford. Terdapat 16 lapisan pada model VGG16 yang terdiri dari gabungan antara 13 *convolutional layer*, 2 *fully connected layer*, dan 1 *softmax layer*. Model ini memiliki

convolutional layer dengan ukuran 3x3 dan lapisan *max pooling* dengan jendela 2x2 untuk memperkecil dimensi data serta menggunakan langkah (*stride*) sebesar 2. Aktivasi ReLu pada model ini diterapkan pada lapisan tersembunyi (*hidden layer*). Pada lapisan akhir, model ini memiliki 2 lapisan *fully connected* dengan masing-masing 4096 neuron pada setiap lapisannya. serta lapisan *softmax* yang berfungsi untuk mengklasifikasi.

VGG16 telah menjadi salah satu model yang sangat populer dalam pengolahan citra karena kemampuannya dalam menangkap fitur-fitur kompleks dalam gambar. Dengan kombinasi yang tepat antara lapisan konvolusi, lapisan terhubung sepenuhnya, dan lapisan *softmax*, VGG16 mampu menghasilkan prediksi yang akurat dalam berbagai tugas klasifikasi gambar. Penggunaan kernel 3x3 dan max pooling dengan ukuran 2x2 serta stride 2 membantu dalam mereduksi dimensi data tanpa mengorbankan informasi penting. Aktivasi ReLU pada lapisan tersembunyi juga berperan dalam mempercepat konvergensi dan meningkatkan kapasitas representatif model. Dengan arsitektur yang kokoh dan parameter yang terukur, VGG16 tetap menjadi pilihan utama dalam berbagai aplikasi pengolahan citra yang memerlukan tingkat akurasi yang tinggi. Ilustrasi model ini dapat dilihat pada gambar 2.9.



Gambar 2.9 Arsitektur VGG16

Berikut merupakan beberapa hyperparameter utama dari VGG16 :

1. Filter yang dimiliki berukuran 3x3 di setiap *convolutional layer*.
2. Di lapisan pertama mempunyai 64 filter, pada lapisan berikutnya 128, 256, 512 dst.
3. Memiliki *stride* yang bernilai 1 pixel

BAB 3

ANALISIS DAN PERANCANGAN

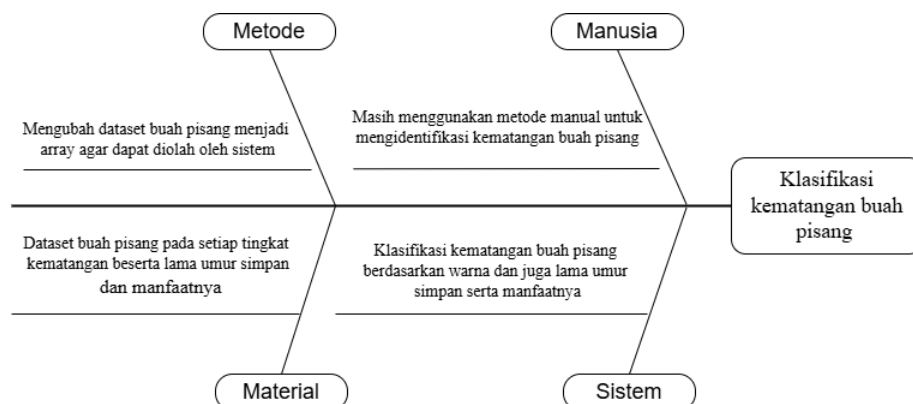
3.1 Analisis Sistem

Analisis sistem adalah suatu proses yang melibatkan penelitian dan identifikasi masalah serta kebutuhan dengan cermat. Hasil dari analisis ini nantinya akan digunakan untuk merancang suatu sistem yang efektif dan akurat, sesuai dengan tujuan pembuatan sistem tersebut.

3.1.1 Analisis Masalah

Analisis masalah adalah suatu langkah analisis yang bertujuan untuk mengidentifikasi dan memahami suatu masalah tertentu. Proses ini melibatkan pencarian dan pengumpulan data yang terkait dengan permasalahan tersebut, dengan tujuan agar masalah dapat teratasi. Dalam konteks penelitian ini, permasalahan yang diidentifikasi adalah masih dilakukannya metode manual yang mengandalkan pengamatan visual dalam identifikasi kematangan buah pisang. Hal ini berpotensi mengalami kesalahan karena hal tersebut sangat bergantung pada penilaian subjektif dari pemilah kematangan buah pisang ini.

Maka dari itu, dibutuhkannya sebuah sistem yang dapat mengidentifikasi kematangan buah pisang, yang ditampilkan ke dalam diagram Ishikawa (*Fishbone Diagram*) pada gambar 3.1.



Gambar 3.1 Diagram Ishikawa

3.1.2 Analisis Kebutuhan

Ini adalah suatu langkah yang ditujukan untuk mengidentifikasi dan memahami kebutuhan yang diperlukan untuk merancang serta membangun suatu sistem. Analisis kebutuhan bertujuan untuk memastikan bahwa solusi yang dikembangkan sesuai dengan tujuan dan harapan pengguna, serta mampu menyelesaikan permasalahan yang ada. Analisis kebutuhan umumnya dapat dibagi menjadi dua bagian utama:

1. Kebutuhan Fungsional

Persyaratan yang berhubungan dengan fungsionalitas atau tindakan yang harus dilakukan oleh sistem yang sedang dirancang disebut sebagai kebutuhan fungsional. Dalam konteks penelitian ini, kebutuhan fungsional akan menjelaskan secara rinci tindakan-tindakan yang diharapkan dilakukan oleh sistem dalam mengklasifikasikan buah pisang berdasarkan warna kulitnya. Berikut adalah beberapa contoh kebutuhan fungsional untuk penelitian ini:

- a. Sistem mampu mengklasifikasikan buah pisang ke dalam tingkat kematangan berdasarkan warna kulitnya yaitu mentah, setengah matang, matang, dan terlalu matang.
- b. Sistem menyediakan tampilan antarmuka yang memungkinkan pengguna untuk menginput citra buah pisang serta dapat melihat hasil dari klasifikasi kematangannya.

2. Kebutuhan Non-Fungsional

Aspek-aspek yang melengkapi performa dari kualitas sistem yang akan dibangun dalam penelitian dikenal sebagai kebutuhan non-fungsional. Fitur-fitur tambahan yang tidak berhubungan dengan fungsi utama sistem. Berikut adalah beberapa contoh kebutuhan non-fungsional untuk penelitian ini:

- a. Sistem diharapkan memiliki tingkat akurasi yang tinggi dalam mengklasifikasikan warna kulit buah pisang.
- b. Sistem mampu menangani gambar buah pisang yang lebih besar tanpa mengurangi kinerja atau akurasi dari sistem.
- c. Sistem mampu melakukan identifikasi dengan tepat dan cepat dengan memberikan hasil dalam waktu yang singkat.

3.1.3 Analisis Proses

Berikut ini disajikan beberapa langkah yang dilakukan pada penelitian ini untuk membangun sistem klasifikasi buah pisang berdasarkan warna kulit buah menggunakan *Convolutional Neural Network*.

1. Pengumpulan Data

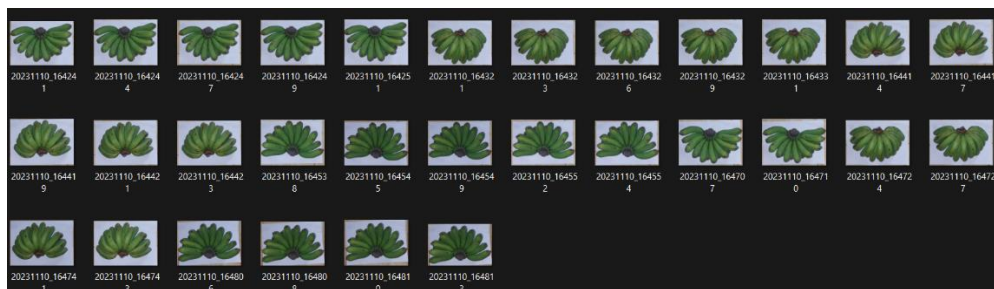
Dalam tahap penelitian ini, peneliti mengambil foto atau gambar dari buah pisang yang sesuai dengan setiap tingkat kematangannya. Pengambilan foto dilakukan pada buah pisang selama 12 hari untuk mendapatkan informasi lama umur simpan buah pisang pada setiap tingkat kematangannya. Berikut adalah contoh dari foto atau gambar buah pisang sesuai dengan tingkat kematangan selama 12 hari.

Hari ke-1 sampai hari ke-4 (Mentah) :



Gambar 3.2 Pisang Mentah Hari Pertama

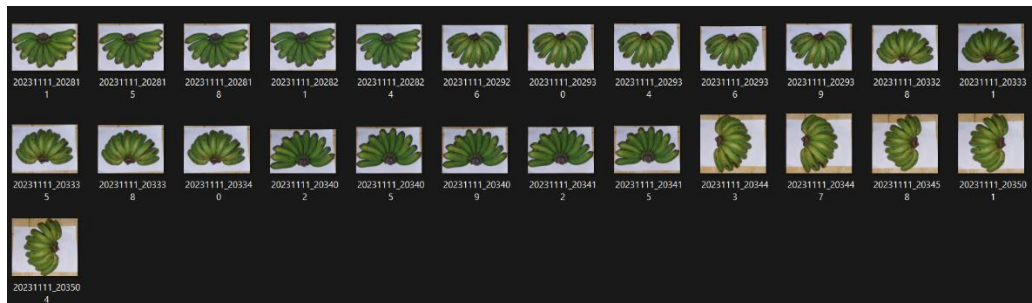
Gambar di atas menunjukkan kumpulan data buah pisang yang diambil oleh peneliti pada hari pertama. Jumlah data yang diperoleh pada hari pertama adalah 30 gambar buah pisang mentah.



Gambar 3.3 Pisang Mentah Hari Keempat

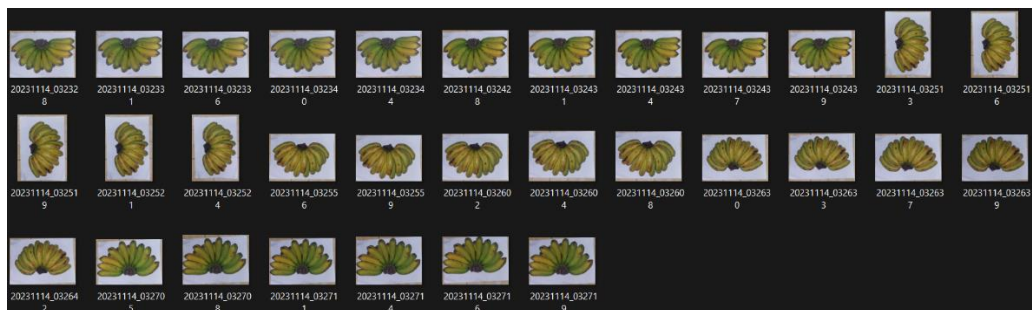
Gambar berikut menampilkan dataset buah pisang mentah yang diambil pada hari keempat. Dalam gambar tersebut, kulit pisang masih berwarna hijau, yang menunjukkan bahwa pisang tersebut masih mentah. Jumlah dataset yang diperoleh pada hari tersebut adalah 30 gambar buah pisang

Hari ke-5 sampai hari ke-8 (Mentah dan Setengah Matang) :



Gambar 3.4 Pisang Mentah Hari Kelima

Pada hari kelima, kondisi pisang masih menunjukkan warna hijau, yang menandakan bahwa buah pisang masih dalam keadaan mentah. Dataset yang diperoleh pada hari tersebut mencakup 25 gambar buah pisang.



Gambar 3.5 Pisang Setengah Matang Hari Kedelapan

Hari kedelapan, kondisi pisang sudah menunjukkan perubahan warna pada kulitnya. Kulit pisang yang terlihat berwarna hijau kekuningan yang menandakan bahwa buah pisang dalam keadaan setengah matang. Dataset yang diperoleh pada hari tersebut mencakup 31 gambar buah pisang.

Figure 1 displays a 3x12 grid of banana images, each labeled with a unique identifier (e.g., 20231116_02172_8) below it. The grid is organized into three rows of 12 images each, showing a progression of ripeness from left to right and top to bottom.

Pada hari kesembilan, kondisi pisang menunjukkan perubahan warna pada kulitnya. Kulit pisang yang terlihat berwarna kuning cerah yang menandakan bahwa buah pisang dalam keadaan matang. Dataset yang diperoleh pada hari tersebut mencakup 30 gambar buah pisang.



Pada hari kedua belas, kondisi pisang menunjukkan perubahan warna pada kulitnya. Kulit pisang terlihat berwarna coklat tua, yang menandakan bahwa buah pisang sudah terlalu matang. Dataset yang diperoleh pada hari tersebut mencakup 35 gambar buah pisang


Berdasarkan informasi telah dikumpulkan, terdapat sebanyak 586 citra dari buah pisang. Pembagian dataset terbagi atas bagian pelatihan (*training*) dan bagian pengujian (*testing*) hal ini merupakan Langkah penting dalam membuat dan menguji model *Convolutional Neural Network* (CNN).

Tabel 3.1 Tabel dataset

Tingkat Kematangan	Dataset Training	Dataset Testing	Total Dataset
Matang	132	10	142
Mentah	168	10	178
Setengah Matang	174	10	184
Terlalu Matang	140	10	150

3.1.3 Arsitektur Umum

Berikut ini merupakan ilustrasi dari arsitektur keseluruhan sistem yang diterapkan dalam penelitian ini.



Gambar 3.8 Arsitektur umum

Berikut ini adalah penjelasan alur tahapan dari rangkaian yang ada pada gambar 3.8.

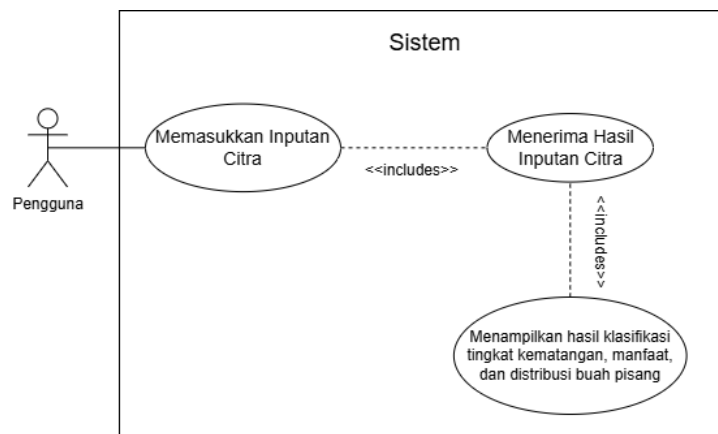
1. Pertama, pengguna menyiapkan citra buah pisang untuk diunggah pada website aplikasi klasifikasi kematangan buah pisang.
2. Gambar yang telah diunggah diproses oleh sistem dalam modul pengelola file.
3. Modul preprocessing menerima gambar dan melakukan tahap preprocessing, seperti resize.
4. Selanjutnya, data yang telah dilakukan preprocessing akan diteruskan ke modul CNN dan VGG16.
5. Modul CNN dan VGG 16 akan mengolah data dengan proses training kemudian akan menghasilkan file model h.5, file ini akan digunakan untuk proses klasifikasi kematangan buah pisang.

6. Modul pada klasifikasi akan menghasilkan prediksi tingkat kematangan yang ada pada buah pisang.
7. Hasil dari klasifikasi akan dikirim kembali ke tampilan antarmuka aplikasi agar hasil klasifikasi dapat dilihat oleh pengguna.

3.2 Pemodelan Sistem

Pemodelan sistem merupakan representasi visual dari struktur dan interaksi dalam sistem yang akan dibangun. Dalam konteks penelitian ini, bentuk pemodelan sistem akan disajikan dan dijelaskan melalui beberapa diagram, termasuk *use case diagram*, *activity diagram*, dan *sequence diagram*.

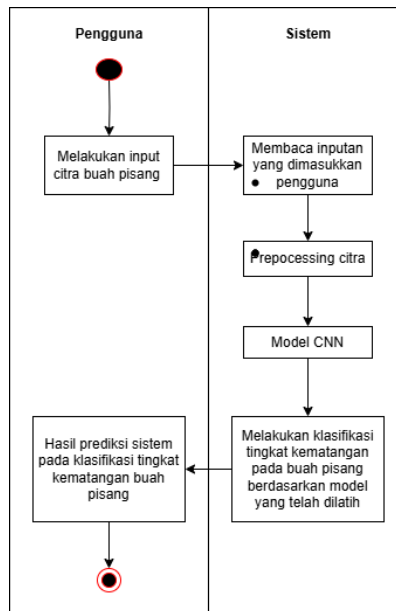
3.2.1 Use Case Diagram



Gambar 3.9 Use Case Diagram Sistem

Menurut gambar 3.9, sistem yang digunakan pengguna berbentuk website, pada halaman awal akan muncul tampilan awal dari website. Setelah itu pengguna memilih tampilan input citra untuk menginput gambar dari buah pisang yang akan diidentifikasi oleh sistem. Pengguna mengunggah gambar ke dalam website, kemudian sistem akan menampilkan hasil dari klasifikasi tingkat kematangan, manfaat serta lama waktu buah pisang akan matang untuk proses distribusi.

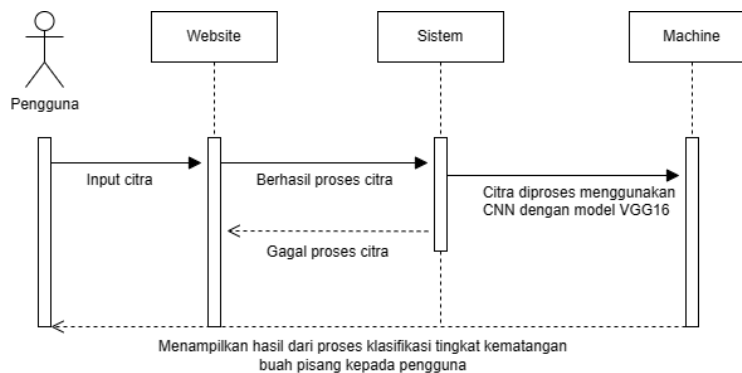
3.2.2 Activity Diagram



Gambar 3.10 Activity Diagram

Pada gambar 3.10 menjelaskan ilustrasi dari urutan alur kerja atau aktivitas pada sistem klasifikasi buah pisang berdasarkan warna pada citra kulit buah. Alur terjadi pada saat pengguna memasuki website klasifikasi buah pisang. Pertama pengguna akan melakukan input citra buah pisang, sistem akan membaca inputan dari pengguna untuk dilanjutkan ke preprocessing citra. Setelah itu, citra akan dipreprocessing dan sistem akan memprediksi citra dengan model yang telah dibangun sebelumnya pada sistem. Selanjutnya, sistem akan melakukan klasifikasi tingkat kematangan berdasarkan warna dari citra kulit buah. Terakhir, sistem akan menampilkan hasil prediksi dari model dan akan tertampil kembali website.

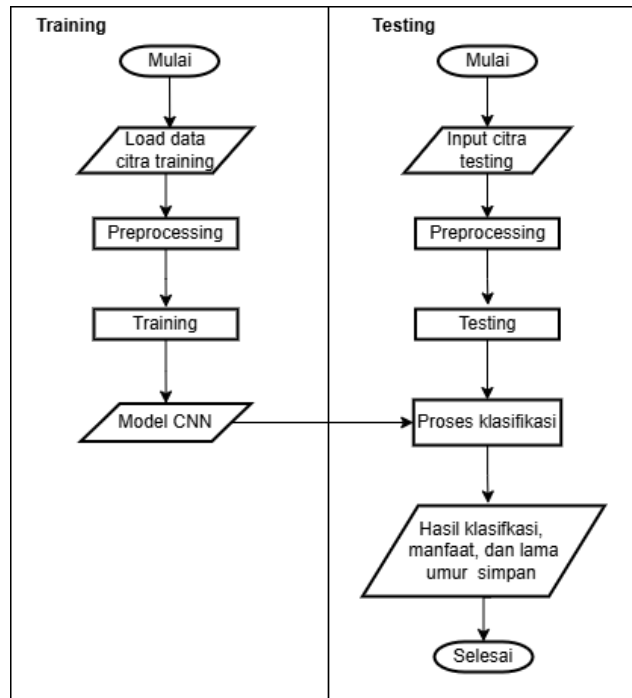
3.2.3 Sequence Diagram



Gambar 3.11 Sequence Diagram

Gambar 3.11 menunjukkan representasi visual mengenai perjalanan pesan dalam sistem, termasuk objek dan serangkaian langkah pelaksanaan dalam proses mengklasifikasikan tingkat kematangan buah pisang.

3.3 Flowchart



Gambar 3.12 Flowchart Sistem

Pada gambar 3.12 menunjukkan langkah awal dari sistem adalah memuat semua dataset dari buah pisang untuk proses *training*. Kemudian, sistem melakukan proses *preprocessing* pada citra dengan melakukan *resize* 128x128 pixel sebelum melakukan tahap *training* untuk membuat model. Untuk memproses data, data akan dibagi (*split*) menjadi data *training* dan data *testing*. Kemudian, data yang telah berhasil diolah akan menjadi sebuah model dengan bantuan dari model VGG16.

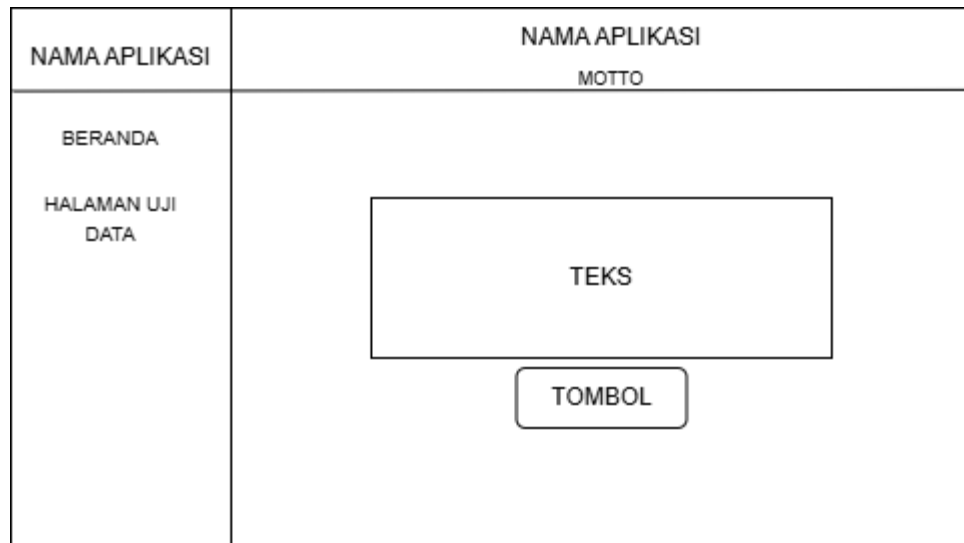
Hasil dari model berbentuk format .h5, model ini akan digunakan untuk tahap proses *testing*. Proses ini membutuhkan input citra, setelah itu citra diproccessing dan kemudian diklasifikasikan menggunakan model yang telah dibentuk sebelumnya. Ketika proses klasifikasi selesai, sistem akan menghasilkan klasifikasi tingkat kematangan, manfaat serta lama umur simpan dari buah pisang.

3.4 Perancangan Antarmuka Sistem

Pada tampilan antarmuka (*interface*) merupakan kontrol dan informasi yang dipresentasikan kepada pengguna dalam sistem yang dibangun. Rancangan tampilan antarmuka pada penelitian ini terdiri dari.

3.4.1 Halaman Pertama

Tata letak halaman pertama yang muncul saat pengguna mengakses situs web dalam penelitian ini dirancang dengan teks yang terpusat di tengah layar. Di bawah teks ini, terdapat tombol yang memungkinkan akses ke halaman uji data. Di sisi kiri halaman, terdapat panel navigasi yang menyediakan akses ke berbagai halaman yang tersedia di situs web.



Gambar 3.13 Rancangan Halaman Pertama Sistem

3.4.2 Halaman Hasil Uji Data

Halaman ini menampilkan hasil dari gambar yang telah diinput oleh pengguna. Hasil pengolahan gambar ditampilkan dalam sebuah formulir hasil uji data. Di bagian kiri formulir, terdapat gambar hasil input pengguna. Di sebelah kanan gambar, ada kolom teks yang menampilkan rincian data yang diolah oleh sistem. Rincian ini mencakup prediksi tingkat kematangan, tingkat akurasi dari prediksi

sistem, perkiraan lama distribusi buah pisang yang telah diprediksi, dan manfaat dari tingkat kematangan buah pisang yang telah diprediksi.

NAMA APLIKASI	
BERANDA	
HALAMAN UJI DATA	<div><div>FORM INPUT GAMBAR</div><div>TEKS<div>TOMBOL INPUT</div><div>TOMBOL SUBMIT</div></div><div>FORM HASIL UJI DATA</div><div>GAMBAR HASIL INPUT<div>DEKSRIpsi</div></div></div>

Gambar 3.14 Rancangan Halaman Hasil Uji Data Sistem

BAB 4

IMPLEMENTASI DAN PENGUJIAN

4.1 Implementasi Sistem

Perangkat yang disebutkan dalam penyusunan penelitian ini merupakan persyaratan minimal yang dibutuhkan sistem agar dapat beroperasi dengan baik. Berikut adalah beberapa komponen yang digunakan.

4.1.1 Perangkat Keras (*Hardware*)

1. Processor Intel Core I5 9300H
2. 8 GB DDR4 RAM

4.1.2 Perangkat Lunak (*Software*)

1. Visual Studio Code
2. Google Chrome


4.2 Pengumpulan Dataset

Tahapan pengumpulan dataset yang dilakukan dalam penelitian ini, yaitu:


1. Menggunakan fitur kamera dari *smartphone* Samsung A52S.
2. Pengambilan dataset berturut berdasarkan hari pada buah pisang selama 12 hari.

4.3 Pelabelan Dataset

Proses ini merupakan tahapan penting dalam pengolahan data pada penelitian klasifikasi tingkat kematangan buah pisang ini. Dataset yang telah terkumpul, dikelompokkan berdasarkan tingkat kematangannya yaitu mentah, setengah matang, matang, dan terlalu matang. Hal ini yang menjadi landasan dari sistem untuk melakukan proses *training* pada sistem.



(a)



(b)



Gambar 4.1 Perbandingan warna pada setiap tingkat kematangan pisang

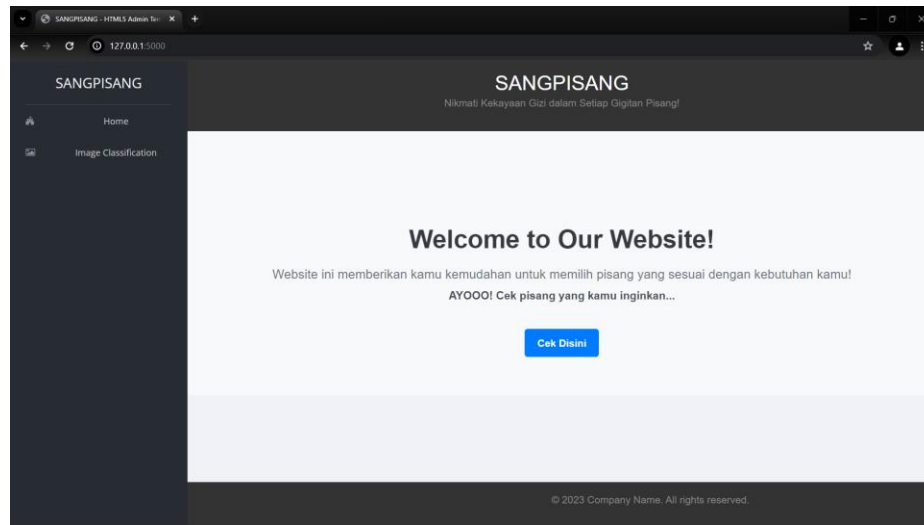
- a. **Buah Pisang Mentah** : tahap ini buah pisang memiliki warna hijau secara keseluruhan, pada tahap ini buah pisang tidak dapat dikonsumsi secara langsung. Buah pisang harus diolah terlebih dahulu sebelum dikonsumsi.
- b. **Buah Pisang Setengah Matang** : buah pisang memiliki warna hijau dengan cenderung kekuningan, buah pisang sudah dapat dikonsumsi namun memiliki rasa yang cenderung kelat dan bergetah. Sebaiknya buah pisang diolah terlebih dahulu agar rasa yang didapat lebih maksimal.
- c. **Buah Pisang Matang** : tahapan ini buah pisang matang secara optimal, dapat langsung dikonsumsi tanpa diolah terlebih dahulu. Memiliki warna kuning merata dan rasa yang dimiliki juga manis dan lembut serta manfaat dari buah ini lebih maksimal pada tingkat kematangan ini.
- d. **Buah Pisang Terlalu Matang** : buah pisang memiliki bintik coklat yang dominan, memiliki tekstur paling lembut dari semua tingkat kematangan dan memiliki rasa yang sangat manis.

4.4 Implementasi Tahapan Antarmuka

Hal ini merupakan tahapan yang muncul pada saat proses klasifikasi digunakan, dimulai dari penginputan citra buah pisang sampai menampilkan hasil prediksi serta manfaat dan lama umur simpannya. Beberapa tahapan yang muncul pada saat menggunakan sistem.

4.4.1 Tampilan Halaman Pertama (Beranda)

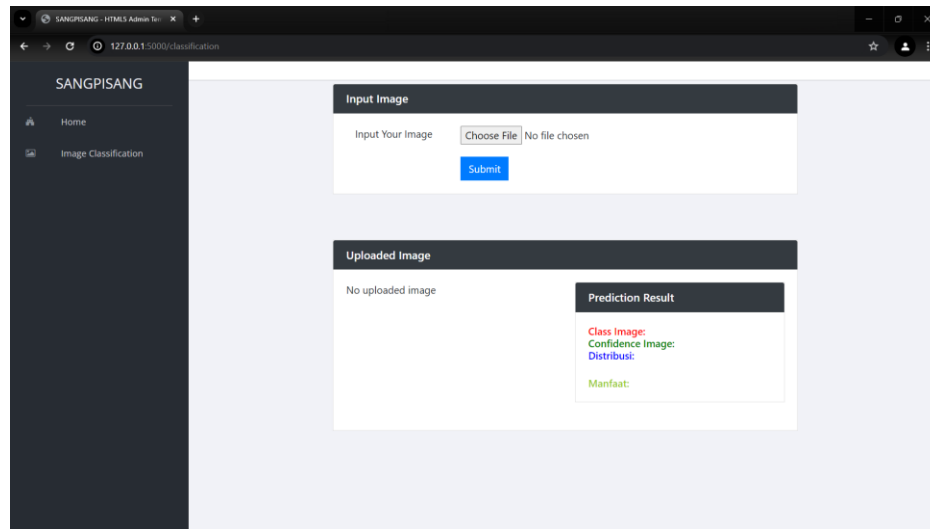
Halaman ini adalah tampilan utama aplikasi yang menjadi halaman pertama bagi pengguna. Pada halaman beranda, terdapat elemen-elemen seperti nama aplikasi, panel navigasi untuk berpindah halaman, dan beberapa teks yang menjelaskan tentang aplikasi itu sendiri.



Gambar 4.2 Tampilan Halaman Beranda

4.4.2 Tampilan Awal Halaman Uji Data

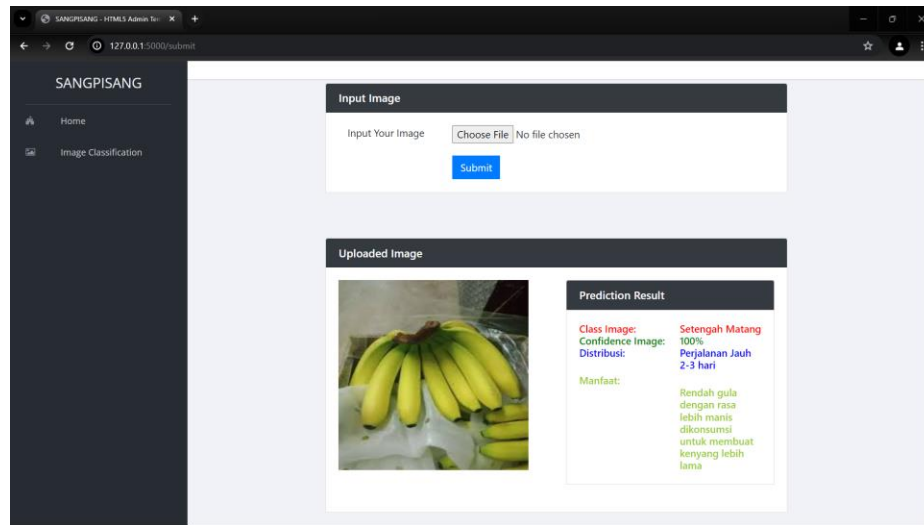
Pada halaman ini, aplikasi menampilkan awal halaman uji data ketika pengguna melakukan navigasi ke halaman uji data. Pengguna akan diminta untuk mengunggah gambar buah pisang yang ingin dideteksi tingkat kematangannya.



Gambar 4.3 Tampilan Awal Halaman Uji Data

4.4.3 Tampilan Halaman Hasil Uji Data

Setelah gambar yang diunggah diolah oleh aplikasi, hasil prediksinya ditampilkan. Rincian hasil tersebut mencakup tingkat kematangan buah pisang, akurasi prediksi aplikasi, perkiraan masa simpan untuk distribusi buah pisang, dan manfaat dari tingkat kematangan buah pisang yang diprediksi.



Gambar 4.4 Tampilan Halaman Hasil Uji Data

4.5 Perancangan Model

Setelah tahap preprocessing selesai, langkah berikutnya dalam pengembangan sistem adalah merancang model dengan menggunakan Convolutional Neural Network (CNN) dan struktur VGG16. Dengan pendekatan ini, sistem mampu mengidentifikasi dan mengekstrak fitur-fitur yang penting dari citra dengan lebih efisien. Dengan CNN dan VGG16 sebagai dasar, sistem dapat memberikan prediksi yang akurat serta memaksimalkan pemanfaatan data citra dalam berbagai aplikasi, seperti pengenalan objek.

4.5.1 Model CNN

```
# Membuat objek model Sequential
model = models.Sequential()

# Layer Convolutional pertama
model.add(layers.Conv2D(32, (3, 3), activation='relu', input_shape=(128, 128, 3)))
model.add(layers.MaxPooling2D((2, 2)))

# Layer Convolutional kedua
model.add(layers.Conv2D(64, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

# Layer Convolutional ketiga
model.add(layers.Conv2D(128, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))

# Layer Flatten untuk mengubah output menjadi vektor 1D
model.add(layers.Flatten())

# Layer Dense (fully connected)
model.add(layers.Dense(128, activation='relu'))
model.add(layers.Dense(4, activation='softmax')) # Misalnya, 4 kelas output

# Compile model
opt = Adam(learning_rate=0.001)
model.compile(optimizer=opt,
              loss='categorical_crossentropy',
              metrics=['accuracy'])

# Tampilkan ringkasan model
model.summary()
```

Gambar 4.5 Implementasi Model CNN

Model CNN yang dijelaskan dalam gambar 4.5 merupakan total 9 lapisan yang digunakan pada model, termasuk 3 *convolutional layer*, 3 *max pooling layer*, 1 *flatten layer*, dan 2 *dense layer*. Lapisan konvolusi pertama berperan ganda sebagai lapisan input citra dengan dimensi 128x128 pixel dengan 3 channel warna (RGB).

Setiap *convolutional layer* diikuti oleh *max pooling layer* dengan matriks ukuran 2x2 dan langkah (*stride*) 2 untuk mengurangi dimensi *feature map* sebelumnya. *Dense layer* hanya menerima masukan dalam bentuk vektor satu dimensi, oleh karena itu, terdapat *flatten layer* yang berfungsi mengubah output dari *convolutional layer* menjadi vektor satu dimensi.

Dense layer memiliki jumlah neuron sebanyak 128 dan 4. Jumlah neuron 128 umum digunakan dalam model CNN, sementara 4 neuron dalam lapisan terakhir

digunakan untuk output klasifikasi, dengan penggunaan fungsi *softmax* sesuai dengan jumlah kategori kelas pada dataset yang terdiri dari 4 kelas.

Untuk melatih model, digunakan fungsi kerugian *categorical_crossentropy* karena dataset memiliki 4 kelas yang berbeda. Optimizer yang digunakan adalah *Adam*, dengan *learning rate* 0,0001 yang efektif dalam menyesuaikan laju pembelajaran selama pelatihan. Performa model dievaluasi berdasarkan akurasi (*accuracy*) untuk mengukur sejauh mana model dapat mengklasifikasikan data dengan benar.

4.5.2 Model VGG16

```
def build_vgg16(input_shape=(128, 128, 3), num_classes=4):
    model = Sequential()

    # Block 1
    model.add(Conv2D(64, (3, 3), activation='relu', padding='same', input_shape=input_shape))
    model.add(Conv2D(64, (3, 3), activation='relu', padding='same'))
    model.add(MaxPooling2D((2, 2), strides=(2, 2)))

    # Block 2
    model.add(Conv2D(128, (3, 3), activation='relu', padding='same'))
    model.add(Conv2D(128, (3, 3), activation='relu', padding='same'))
    model.add(MaxPooling2D((2, 2), strides=(2, 2)))

    # Block 3
    model.add(Conv2D(256, (3, 3), activation='relu', padding='same'))
    model.add(Conv2D(256, (3, 3), activation='relu', padding='same'))
    model.add(Conv2D(256, (3, 3), activation='relu', padding='same'))
    model.add(MaxPooling2D((2, 2), strides=(2, 2)))

    # Block 4
    model.add(Conv2D(512, (3, 3), activation='relu', padding='same'))
    model.add(Conv2D(512, (3, 3), activation='relu', padding='same'))
    model.add(Conv2D(512, (3, 3), activation='relu', padding='same'))
    model.add(MaxPooling2D((2, 2), strides=(2, 2)))

    # Block 5
    model.add(Conv2D(1024, (3, 3), activation='relu', padding='same'))
    model.add(Conv2D(1024, (3, 3), activation='relu', padding='same'))
    model.add(Conv2D(1024, (3, 3), activation='relu', padding='same'))
    model.add(MaxPooling2D((2, 2), strides=(2, 2)))

    # Fully connected layers
    model.add(Flatten())
    model.add(Dense(128, activation='relu'))
    model.add(Dropout(0.5))
    model.add(Dense(128, activation='relu'))
    model.add(Dropout(0.5))
    model.add(Dense(num_classes, activation='softmax'))

    return model

# Test the model
input_shape = (224, 224, 3)
num_classes = 4
vgg16_model = build_vgg16(input_shape, num_classes)
vgg16_model.summary()
```

Gambar 4.6 Perancangan Model VGG16

Perancangan model VGG16 ini dapat dilihat pada gambar 4.6.

1. Block 1

Pada blok ini terdapat dua *convolutional layer* (Conv2D) dengan layer 64 filter, dengan masing-masing menggunakan kernel 3x3, aktivasi ReLu, serta padding *same* untuk mempertahankan gambar sesuai dengan ukuran input. Selanjutnya diikuti oleh *maxpooling layer* (MaxPooling2D) memiliki ukuran 2x2 dan *strides* 2x2 untuk mengurangi dimensi dari gambar. Dengan begitu blok ini memiliki total 3 lapisan (*layer*) dalam mengolah gambar inputan.

2. Block 2

Pada blok kedua juga terdapat dua *convolutional layer* (Conv2D) dengan layer 128 filter, menggunakan kernel 3x3, aktivasi ReLu, dan padding *same*. Selanjutnya diikuti oleh *maxpooling layer* (MaxPooling2D) memiliki ukuran 2x2 dan *strides* 2x2. Dengan total 3 *layer* dalam mengolah gambar inputan.

3. Block 3

Pada blok ketiga terdapat tiga *convolutional layer* (Conv2D) dengan layer 256 filter, menggunakan kernel 3x3, aktivasi ReLu, dan padding *same*. Selanjutnya diikuti oleh *maxpooling layer* (MaxPooling2D) memiliki ukuran 2x2 dan *strides* 2x2. Dengan total 3 *layer* dalam mengolah gambar inputan.

4. Block 4

Seperti blok ketiga, pada blok ini terdapat tiga *convolutional layer* (Conv2D) dengan filter 512, menggunakan aktivasi ReLu dan padding *same*. Memiliki *maxpooling layer* (MaxPooling2D) dengan ukuran 2x2 dan *strides* 2x2. Sehingga total *layer* pada blok ini berjumlah 4.

5. Block 5

Pada blok terakhir ini, terdiri dari tiga *convolutional layer* (Conv2D) dengan filter 1024, menggunakan aktivasi ReLu dan padding *same*. Terdapat *maxpooling layer* (MaxPooling2D) dengan ukuran 2x2 dan *strides* 2x2. Dengan demikian, jumlah total *layer* pada blok ini adalah 4.

6. Fully Connected Layer

Setelah lima blok konvolusi, langkah selanjutnya adalah pada lapisan *dense* (fully connected), yang terdiri dari tiga lapisan dengan masing-masing 128 neuron, aktivasi ReLu, dan dropout dengan tingkat 0,5

7. Output Layer

Lapisan akhir adalah lapisan *dense* yang memiliki jumlah neuron yang sama dengan jumlah kelas yang ingin diprediksi (`num_classes`), yakni 4 kelas dalam konteks ini. Lapisan ini menggunakan fungsi aktivasi softmax untuk menghasilkan probabilitas untuk setiap kelas prediksi. Penggunaan softmax sesuai dengan jumlah kategori kelas dalam dataset, yang terdiri dari 4 kelas.

Total jumlah lapisan dalam model ini adalah 4 (Blok 1) + 3 (Blok 2) + 4 (Blok 3) + 4 (Blok 4) + 4 (Blok 5) + 3 (Sepenuhnya Terhubung) + 1 (Output) = 19 lapisan. Ini merupakan sebuah implementasi yang cukup setia terhadap arsitektur VGG16 yang memiliki 16 lapisan konvolusi dan 3 lapisan fully connected, dengan tambahan penggunaan dropout untuk mengurangi kemungkinan overfitting.

4.6 Penentuan Parameter Model

Dalam usaha untuk mencari model yang optimal, adalah krusial untuk mengidentifikasi nilai-nilai parameter yang paling sesuai dalam konteks model CNN. Parameter-parameter ini mencakup jumlah epoch, dimensi gambar input, ukuran dataset pelatihan, dan tingkat pembelajaran (learning rate). Tujuannya adalah untuk menemukan kombinasi parameter model yang beragam dan menentukan model yang paling optimal dengan mempertimbangkan nilai-nilai parameter yang relevan.

4.6.1 Pengaruh Banyaknya Epoch

Epoch adalah tahap di mana seluruh dataset telah melalui proses pelatihan dalam jaringan saraf (*neural network*) hingga satu siklus pelatihan selesai (*training*). Dalam konteks jaringan saraf, satu *epoch* yang melibatkan seluruh dataset dianggap terlalu besar dan bisa memakan waktu yang lama. Karena itu, untuk mempercepat dan mempermudah proses pelatihan, dataset biasanya dibagi

menjadi batch-batch kecil. Penentuan ukuran batch ini sering bergantung pada preferensi peneliti dan jumlah sampel yang ada. Di bawah ini adalah hasil perbandingan jumlah epoch yang diperoleh dari pelatihan model.

Tabel 4.1 Tabel Banyaknya Epoch

Epoch	Accuracy Validation	Loss Validation	Time Epoch	Time
1	62%	92%	18 d	18 d
5	96%	7%	16 d	1 m 22 d
10	100%	0,0009%	18 d	2 m 47 d
15	100%	0,0003%	18 d	4 m 13 d
20	100%	0,0001%	18 d	5 m 43 d
25	100%	0,00009%	17 d	7 m 13 d
30	100%	0,00008%	18 d	8 m 41 d
35	100%	0,00007%	16 d	10m 2 d
40	100%	0,00005%	16 d	11 m 22 d


4.7 Pengujian Sistem

Hasil pengujian sistem mencakup evaluasi kinerja serta performa sistem yang telah diuji. Tujuan pengujian ini adalah untuk menentukan bagaimana sistem dapat memenuhi persyaratan yang ditetapkan, mengidentifikasi masalah atau kegagalan dalam sistem, dan memverifikasi bahwa sistem dapat beroperasi sesuai dengan rencana atau harapan yang telah disusun. Berikut beberapa hasil yang dapat timbul dari pengujian sistem:

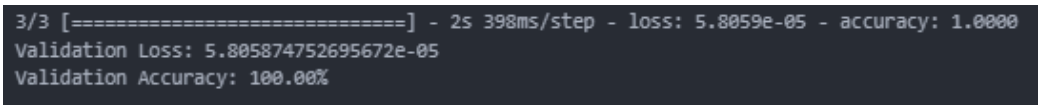
4.7.1 Hasil Proses Training

Salah satu faktor utama dalam menentukan tingkat kematangan buah pisang berdasarkan warna adalah hasil dari proses pelatihan sistem (*training*). Pelatihan ini memiliki dampak yang sangat penting terhadap hasil yang akan diperoleh saat pengujian. Parameter iterasi dalam pelatihan dilakukan sebanyak 40 epoch dengan ukuran batch sebesar 32. Oleh karena itu, proses pelatihan akan diulang sebanyak 40 kali untuk mendapatkan ekstraksi fitur yang diperlukan. Selain itu, learning rate yang digunakan dalam pelatihan adalah sebesar 0,0001. Nilai learning rate ini

digunakan untuk memperbarui bobot pada setiap tahap proses backward-pass algoritma. Gambar 4.7 menunjukkan hasil dari Confusion Matrix dari proses pelatihan.




Gambar 4.7 Hasil Prediksi Proses Training



Gambar 4.8 Hasil Akurasi Proses Training







Pada Gambar 4.8 diatas, dapat dilihat bahwa akurasi yang diperoleh dari proses pelatihan sebesar 1,0 (**100%**), dengan nilai loss sebesar 0,00058 (**0,058 %**). Grafik akurasi ini dapat dilihat dalam proses hasil pelatihan setelah mengalami 40 kali iterasi (*epoch*) dan untuk hasil grafik *accuracy* dan *loss* dapat dilihat pada gambar 4.9.
















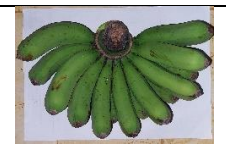


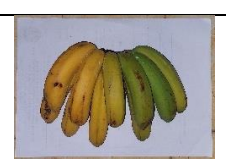

Gambar 4.9 Grafik accuracy dan loss






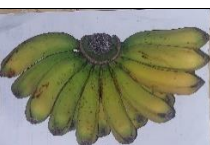



4.7.2 Hasil Proses Testing








Tabel 4.2 Tabel Pengujian Model

No	Pisang	Aktual	Prediksi
1		Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga	Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga
2		Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga	Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga
3		Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga	Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga
4		Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga	Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga
5		Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga	Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga
6		Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga	Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga

		saat olahraga	saat olahraga
7		Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga	Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga
8		Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga	Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga
9		Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga	Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga
10		Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga	Buah pisang matang, distribusi lokal, dan kadar gula meningkat dikonsumsi untuk asupan energi pada saat olahraga
11		Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes	Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes
12		Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes	Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes
13		Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes	Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes
14		Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes	Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes
15		Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes	Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes

16		Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes	Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes
17		Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes	Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes
18		Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes	Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes
19		Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes	Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes
20		Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes	Buah pisang mentah, distribusi jauh 7 hari, dan rendah gula cocok untuk dikonsumsi penderita diabetes
21		Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.	Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.
22		Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.	Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.
23		Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.	Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.
24		Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.	Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.

25		Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.	Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.
26		Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.	Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.
27		Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.	Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.
28		Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.	Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.
29		Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.	Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.
30		Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.	Buah pisang setengah matang, distribusi dekat 2-3 hari, dan rendah gula dengan rasa yang lebih manis.
31		Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi	Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi
32		Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi	Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi
33		Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi	Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi

34		Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi	Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi
35		Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi	Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi
36		Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi	Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi
37		Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi	Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi
38		Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi	Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi
39		Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi	Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi
40		Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi	Buah pisang terlalu matang, tidak dapat dikirim, dan kadar gula tinggi, antioksidan tinggi, anti inflamasi tinggi

Dari tabel diatas, disajikan hasil dari proses *testing* pada model. Tabel tersebut dapat menggambarkan nilai matriks konfusi (*confusion matrixs*) sebagai berikut:

Tabel 4.3 Tabel Confusion Matrixs

		Kelas Aktual				Total Prediksi
		Matang	Mentah	Setengah Matang	Terlalu Matang	
Kelas Prediksi	Matang	10	0	0	0	10
	Mentah	0	10	0	0	10
	Setengah Matang	0	0	10	0	10
	Terlalu Matang	0	0	0	10	10
Total Prediksi		10	10	10	10	40

a. Accuracy

Dari tabel tersebut, dapat dihitung nilai dari akurasi pada saat *testing* dengan rumus. Akurasi dapat mengidentifikaikan seberapa baik model dapat melakukan klasifikasi secara tepat.

$$Accuracy = \frac{TP+TN}{TP+FP+FN+TN} \dots (1)$$

Rumus yang digunakan untuk menghitung nilai dari akurasi menggunakan data pada tabel diatas adalah sebagai berikut:

$$\frac{10+0}{10+0+0+0} \times 100 \% = 100\%$$

Akurasi yang berhasil dicapai adalah 100%, dengan menggunakan dataset yang terdiri dari 40 data buah pisang. Dataset ini mencakup 10 data pisang matang, 10 data pisang mentah, 10 data pisang setengah matang, dan 10 data pisang terlalu matang.

b. *Precision*

Presisi (*precision*) adalah sebuah matriks yang digunakan untuk mengukur seberapa akurat model klasifikasi dalam mengidentifikasi kasus-kasus positif.

Tabel 4.4 Tabel Precision

	Matang	Mentah	Setengah Matang	Terlalu Matang
TP	10	10	10	10
FP	0	0	0	0
TP/(TP+FP)	1	1	1	1

Dari hasil perhitungan berdasarkan tabel di atas, dapat disimpulkan bahwa.

$$\begin{aligned} Precision &= \frac{TP}{TP+FP} \cdots (2) \\ &= \frac{40}{40} \times 100\% = 100\% \end{aligned}$$

c. *Recall*

Recall, juga dikenal sebagai "sensitivity" atau "true positive rate," adalah salah satu metrik evaluasi klasifikasi yang mengukur seberapa banyak dari kasus positif yang diprediksi dengan benar dibandingkan dengan total kasus positif yang sebenarnya.

Tabel 4.5 Tabel Recall

	Matang	Mentah	Setengah Matang	Terlalu Matang
TP	10	10	10	10
FP	0	0	0	0
TP/(TP+FP)	1	1	1	1

$$\begin{aligned} Recall &= \frac{TP}{TP+FP} \cdots (3) \\ &= \frac{40}{40} \times 100\% = 100\% \end{aligned}$$

d. *F1-score*

F1-score adalah ukuran gabungan dari precision dan recall yang berguna untuk mengevaluasi kinerja model klasifikasi, terutama ketika kelas-kelas tidak seimbang.

$$\begin{aligned} F1-Score &= 2 \times \frac{Precision \times Recall}{Precision + Recall} \dots (4) \\ &= 2 \times \frac{1 \times 1}{1 + 1} = 1 \times 100\% = 100\% \end{aligned}$$

BAB 5

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Dari hasil penelitian implementasi algoritma convolutional neural network untuk identifikasi kematangan buah pisang berdasarkan citra kulit buah, beberapa kesimpulan dapat ditarik, antara lain:

1. *Convolutional Neural Network* merupakan pendekatan yang efektif untuk mengidentifikasi kematangan buah pisang berdasarkan citra kulit buah. Hasil dari penelitian memberikan tingkat akurasi yang tinggi dalam proses identifikasi.
2. Penggunaan arsitektur model VGG16 dalam proses *training* dan *testing* di dalam CNN terbukti efektif menghasilkan hasil yang akurat.
3. Tingkat akurasi yang dicapai dari penelitian sebesar 100%, dengan tingkat *precision* sebesar 100%, *recall* sebesar 100%, dan nilai dari *F1-score* sebesar 100%.

5.2 Saran

Berikut ini disajikan saran-saran yang dapat dipertimbangkan dalam pengembangan sistem selanjutnya:

1. Jumlah dari dataset yang digunakan pada penelitian selanjutnya dapat ditambah dan diperbanyak.
2. Penelitian ini dapat dikembangkan dengan penggunaan variasi arsitektur model *CNN* yang lainnya.
3. Penelitian ini dapat dikembangkan dengan jenis buah serta kelas yang lebih bervariasi.
4. Penelitian ini dapat dikembangkan dengan jenis varietas buah pisang yang lainnya.

DAFTAR PUSTAKA

- Alzubaidi, L., Zhang, J., Humaidi, A. J., Al-Dujaili, A., Duan, Y., Al-Shamma, O., . . . Farhan, L. (2021). Review of deep learning: concepts, CNN architectures, challenges, applications, future directions. *Journal of Big Data*.
- Jordan, M. I., & Mitchell, T. M. (2015). Machine learning: Trends,perspectives,and prospects. *Science*, 255-260.
- Lecun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 436-444.
- M. AL-Masawabe, M., F. Samhan, L., H. Alfarra, A., E. Aslem, Y., & S. AbuNaser, S. (2021). Papaya maturity Classification Using Deep Convolutional Neural Networks. *International Journal of Engineering and Information Systems (IJEAIS)*, 60-67.
- N. Abu-Jamie, T., & S. Abu-Naser, S. (2022). Classification of Sign-language Using VGG16. *International Journal of Academic Engineering Research (IJAER)*, 36-46.
- Olivares, B. O., Araya-Alman, M., Acevedo-Opazo, C., Rey, J. C., Cañete-Salinas, P., Kurina, F. G., . . . Gómez, J. A. (2020). Relationship Between Soil Properties and Banana Productivity in the Two Main Cultivation Areas in Venezuela. *Journal of Soil Science and Plant Nutrition*, 2512-2524.
- R., I. M., Johan, T. M., & Luthfi. (2023). Klasifikasi Citra Ikan Menggunakan Algoritma Convolutional Neural Network dengan Arsitektur VGG-16. *KLIK: Kajian Ilmiah Informatika dan Komputer*, 978-985.
- Sharma, S., Sharma, S., & Athaiya, A. (2020). ACTIVATION FUNCTIONS IN NEURAL NETWORKS. *International Journal of Engineering Applied Sciences and Technology*, 310-316.
- Shukla, N. (2008). *Machine Learning eith Tensorflow*. Shelter Island, NY: Manning Publications.
- Taye, M. M. (2023). Theoretical Understanding of Convolutional Neural Network: Concepts, Architectures, Applications, Future Directions. *Computation*.
- Yamashita, R., Nishio, M., Do, R. K., & Togashi, K. (2018). Convolutional neural networks: an overview and application in radiology. *Insights into Imaging*, 611-629.
- You, W., Shen, C., Guo, X., Jiang, X., Shi, J., & Zhu, Z. (2017). A hybrid technique based on convolutional neural network and support vector regression for intelligent diagnosis of rotating machinery. *Advances in Mechanical Engineering*, 1-17.