

**IDENTIFIKASI PENYAKIT KANKER KARSINOMA  
SEL BASAL PADA CITRA DERMOSKOPI  
MENGUNAKAN EFFICIENTNETV2**

**SKRIPSI**

**BOBBY BERKAT EZRA ZEBUA**

**191402079**



**PROGRAM STUDI S1 TEKNOLOGI INFORMASI  
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI  
UNIVERSITAS SUMATERA UTARA**

**2025**

**IDENTIFIKASI PENYAKIT KANKER KARSINOMA  
SEL BASAL PADA CITRA DERMOSKOPI  
MENGUNAKAN EFFICIENTNETV2**

**SKRIPSI**

Diajukan untuk melengkapi tugas dan memenuhi syarat memperoleh  
ijazah Sarjana Teknologi Informasi

**BOBBY BERKAT EZRA ZEBUA**

**191402079**



**PROGRAM STUDI S1 TEKNOLOGI INFORMASI  
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI  
UNIVERSITAS SUMATERA UTARA**

**2025**

## PERSETUJUAN

Judul : IDENTIFIKASI PENYAKIT KANKER  
KARSINOMA SEL BASAL PADA CITRA  
DERMOSKOPI MENGGUNAKAN  
EFFICIENTNETV2

Kategori : SKRIPSI

Nama : BOBBY BERKAT EZRA ZEBUA

Nomor Induk Mahasiswa : 191402079

Program Studi : SARJANA (SI) TEKNOLOGI INFORMASI

Fakultas : ILMU KOMPUTER DAN TEKNOLOGI  
INFORMASI UNIVERSITAS SUMATERA  
UTARA

Medan , 10 Januari 2025

Komisi Pembimbing :

Pembimbing 2,



Fanindia Purnamasari, S.TI., M.IT  
NIP. 198908172019032023

Pembimbing 1



Dedy Arisandi S.T., M.Kom  
NIP. 197908312009121002

Diketahui/disetujui oleh

Program Studi Teknologi Informasi



Dedy Arisandi S.T., M.Kom.  
NIP. 197908312009121002

## **PERNYATAAN**

### **IDENTIFIKASI PENYAKIT KANKER KARSINOMA SEL BASAL PADA CITRA DERMOSKOPI MENGGUNAKAN EFFICIENTNETV2**

## **SKRIPSI**

Saya mengakui bahwa skripsi ini merupakan hasil karya saya sendiri, kecuali beberapa kutipan dan ringkasan yang masing-masing telah disebutkan sumbernya.

Medan, 10 Januari 2025



Bobby Berkat Ezra Zebua

191402079

## UCAPAN TERIMA KASIH

Puji syukur kita panjatkan kehadirat Tuhan Yang Maha Esa, yang telah memberikan rahmat, hidayah, serta karunia-Nya sehingga penulis dapat menyelesaikan skripsi ini dengan judul “Identifikasi Penyakit Kanker Karsinoma Sel Basal Pada citra Dermoskopi Menggunakan Efficientnetv2”.

Skripsi ini adalah salah satu syarat untuk mendapatkan sebuah gelar Sarjana Komputer pada Program Studi S1 Teknologi Informasi, Fakultas Ilmu Komputer dan Teknologi Informasi, Universitas Sumatera Utara. Meskipun mengalami beberapa kendala selama proses penulisan, penulis berhasil mengatasi tantangan tersebut dengan sukses berkat dukungan dan panduan dari berbagai pihak.

Untuk berbagai pihak yang terlibat dalam penyelesaian skripsi ini, penulis ingin mengucapkan terima kasih yang sebesar-besarnya kepada :

1. Keluarga penulis yang sangat penulis sayangi dan banggakan, terutama orang tua penulis Purnama Asmida Tampubolon yang telah mendidik dan membesarkan serta selalu memberikan doa, dukungan dan motivasi tanpa henti.
2. Bapak Dr. Muryanto Amin, S.Sos., M.Si. selaku Rektor Universitas Sumatera Utara.
3. Ibu Dr. Maya Silvi Lydia, B.Sc., M.Sc. selaku Dekan Fakultas Ilmu Komputer dan Teknologi Informasi
4. Bapak Dedy Arisandi S.T., M.Kom. selaku Ketua Program Studi Teknologi Informasi Universitas Sumatera Utara dan Dosen Pembimbing I saya yang sudah meluangkan waktu, pemikiran, motivasi, kritik dan memberikan saran kepada penulis dalam menyelesaikan skripsi ini
5. Ibu Fanindia Purnamasari, S.TI., M.IT, selaku Dosen Pembimbing II saya yang telah memberikan banyak waktu, pemikiran, kritik, motivasi, dan saran untuk membantu penulis dalam menyelesaikan skripsi ini.
6. Dosen Fasilkom-TI USU yang telah memberikan ilmu baik di kelas perkuliahan maupun kegiatan akademik lainnya.
7. Semua karyawan dan karyawan Fasilkom-TI USU yang telah membantu dalam mengelola berkas administrasi dan proses menyelesaikan skripsi.

Semoga Allah memberikan balasan yang berlipat ganda kepada setiap orang yang telah membantu dalam penulisan skripsi ini. Penulis berharap bahwa skripsi ini akan bermanfaat bagi mereka yang menulisnya, tetapi juga untuk orang-orang yang membacanya secara keseluruhan

Medan, Januari 2025

Penulis





## ABSTRAK

Karsinoma sel basal merupakan salah satu jenis kanker kulit yang memerlukan pemeriksaan dini karena dapat menyebar ke jaringan tubuh sekitarnya. Gejala karsinoma sel basal yang umum terjadi yaitu timbulnya benjolan kecil, berwarna merah muda dengan permukaan mengkilap pada kulit, sehingga gejalanya mirip dengan *keratosis artinik*. Deteksi dini dan diagnosis yang akurat sangat penting dalam penanganan karsinoma sel basal. Diagnosis karsinoma sel basal dilakukan dengan metode dermoskopi atau histopatologi yang memerlukan biopsi serta memakan waktu dan biaya yang cukup tinggi. Penelitian ini menggunakan arsitektur *EfficientNetV2* yang merupakan pengembangan dari arsitektur *EfficientNet* yang telah terbukti efisien dan efektif dalam pengolahan citra, khususnya klasifikasi gambar. Arsitektur ini memperkenalkan beberapa modifikasi untuk meningkatkan efisiensi model dan akurasi. Pelatihan model menggunakan *dataset HAM 10000 2020* yang berisi 3000 data, terbagi menjadi 2100 data pelatihan, 600 data validasi, dan 300 data uji. Data tersebut melalui tahapan *preprocessing* yang terdiri dari perubahan ukuran, penghapusan rambut, segmentasi, normalisasi, dan augmentasi. Setelah melalui *preprocessing*, data tersebut diteruskan ke arsitektur *EfficientNetV2* untuk dilakukan fitur ekstraksi dan pelatihan model yang menggunakan 40 *epoch* dan *batch size* sebesar 32. Hasil penggunaan arsitektur *EfficientNetV2* menunjukkan akurasi sebesar 94%. Berdasarkan hasil akurasi tersebut, dapat disimpulkan bahwa sistem sudah sangat baik dalam mengidentifikasi karsinoma sel basal melalui citra dermoskopi.

**Kata Kunci :** Karsinoma sel basal, *EfficientNetV2*, *Convolutional Neural Network*, Klasifikasi gambar.

# IDENTIFICATION OF BASAL CELL CARCINOMA USING EFFICIENTNETV2 ON DERMOSCOPY IMAGES

## ABSTRACT

Basal cell carcinoma is a type of skin cancer that requires early detection as it can spread to surrounding tissues. The common symptoms of basal cell carcinoma include the appearance of small, pinkish bumps with a shiny surface on the skin., making the symptoms similar to actinic keratosis. Early detection and accurate diagnosis are crucial in the management of basal cell carcinoma. The diagnosis of basal cell carcinoma is performed using dermoscopy or histopathology methods, which require biopsy and can be time-consuming and costly. This study utilizes the EfficientNetV2 architecture, an improvement of the EfficientNet architecture, which has been proven to be efficient and effective in image processing, particularly in image classification. This architecture introduces several modifications to enhance model efficiency and accuracy. The model training uses the HAM 10000 2020 dataset, which contains 3000 data samples, divided into 2100 training data, 600 validation data, and 300 test data. The data undergoes preprocessing steps, including resizing, hair removal, segmentation, normalization, and augmentation. After preprocessing, the data is fed into the EfficientNetV2 architecture for feature extraction and model training, which uses 40 epochs and a batch size of 32. The results of using the EfficientNetV2 architecture show an accuracy of 94%. Based on this accuracy result, it can be concluded that the system performs very well in identifying basal cell carcinoma through dermoscopic images.

**Keywords :** Basal cell carcinoma, EfficientNetV2, Convolutional Neural Network, Image classification.



## DAFTAR ISI

<b>PERSETUJUAN</b>	<b>iii</b>
<b>PERNYATAAN</b>	<b>iv</b>
<b>UCAPAN TERIMA KASIH</b>	<b>v</b>
<b>ABSTRAK</b>	<b>vii</b>
<b>ABSTRACT</b>	<b>viii</b>
<b>DAFTAR ISI</b>	<b>vii</b>
<b>DAFTAR TABEL</b>	<b>ix</b>
<b>DAFTAR GAMBAR</b>	<b>x</b>
<b>BAB 1 PENDAHULUAN</b>	<b>1</b>
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Penelitian	4
1.4 Tujuan Penelitian	4
1.5 Manfaat Penelitian	4
1.6 Metodologi Penelitian	4
<b>BAB II LANDASAN TEORI</b>	<b>6</b>
2.1 Karsinoma Sel Basal	6
2.2. Deep Learning	8
2.3 Convolutional Neural Network	8
2.4 EfficientNetV2	10
2.5 Fitur Ekstraksi	12
2.6 Citra Digital	13
2.7 Citra Dermoskopi	13
2.8 Confusion Matrix	14
2.9 Penelitian Terdahulu	16
2.10 Perbedaan Penelitian Terdahulu	18
<b>BAB 3 ANALISIS DAN PERANCANGAN SISTEM</b>	<b>18</b>
3.1 Data yang Digunakan	18
3.2 Analisis Sistem	18

3.2.1	Data Acquisition	19
3.2.2	Split data	20
3.2.3	Preprocessing	20
3.2.4	Image Classifier	24
3.2.5	Learned Model	26
3.2.6	Flask	26
3.3	Desain Antarmuka Sistem	27
3.3.1	Activity Diagram	27
3.2.2	Desain Halaman Beranda	28
3.2.3	Desain Halaman Deteksi	29
3.2.4	Desain Halaman Setelah Proses Deteksi	30
<b>BAB 4</b>	<b>IMPLEMENTASI DAN PENGUJIAN SISTEM</b>	<b>31</b>
4.1	Implementasi Sistem	31
4.1.1	Perangkat Keras dan Perangkat Lunak	31
4.1.2	Data Citra Lesi Kulit	31
4.1.3	Tahapan Pembuatan Model	32
4.2	Implementasi Tampilan Antaramuka	40
4.2.1	Tampilan Halaman Beranda	40
4.2.2	Tampilan Halaman Tentang	40
4.2.3	Tampilan Halaman Tutorial	41
4.3	Pelatihan Sistem	42
4.4	Pengujian Sistem	46
<b>BAB 5</b>	<b>KESIMPULAN DAN SARAN</b>	<b>53</b>
5.1	Kesimpulan	53
5.2	Saran	53
<b>DAFTAR PUSTAKA</b>		<b>54</b>
<b>Lampiran Hasil Pengujian Sistem</b>		<b>57</b>

## DAFTAR TABEL

Tabel 2. 1 Penelitian Terdahulu	16
Tabel 3. 1 Pembagian dataset	20
Tabel 4. 1 Data pelatihan sistem	43
Tabel 4. 2 Hasil uji coba epoch dan batch size	44
Tabel 4. 3 Hasil epoch	44
Tabel 4. 4 Contoh hasil pengujian sistem	50



## DAFTAR GAMBAR

Gambar 2. 1 Karsinoma Sel Basal (McDaniel et al., 2024)	7
Gambar 2. 2 Arsitektur CNN (Alom et al., 2019)	10
Gambar 2. 3 Struktur MBConv dan Fused-MBConv (M. Tan & Le, 2021)	11
Gambar 2. 4 Citra dermoskopi	14
Gambar 3. 1 Lesi kulit karsinoma sel basal (kiri) dan keratosis aktinik (kanan)	18
Gambar 3. 2 Arsitektur umum	19
Gambar 3. 3 Dataset HAM 10000	20
Gambar 3. 4 Hasil proses hair removal	22
Gambar 3. 5 Diagram activity	28
Gambar 3. 6 Desain halaman beranda	29
Gambar 3. 7 Tombol input gambar dan tombol deteksi	29
Gambar 3. 8 Desain halaman prediksi	30
Gambar 3. 9 Desain halaman setelah deteksi	30
Gambar 4. 1 Sebelum dan sesudah proses image resizing	33
Gambar 4. 2 Kode program dan hasil eksekusi untuk image resizing	33
Gambar 4. 3 Kode program dan hasil eksekusi untuk hair removal	34
Gambar 4. 4 Sebelum dan sesudah Image Segmentation	35
Gambar 4. 5 Kode program dan hasil eksekusi untuk image segmentation	35
Gambar 4. 6 Sebelum dan sesudah image normalization	36
Gambar 4. 7 Sebelum dan sesudah flip horizontal	37
Gambar 4. 8 Sebelum dan sesudah flip vertikal	37
Gambar 4. 9 Rotasi 90 dan -90 derajat	37
Gambar 4. 10 Kode program yang digunakan pada training dataset	38
Gambar 4. 11 Kode program pada validasi model	39
Gambar 4. 12 Tampilan halaman beranda	40
Gambar 4. 13 Tampilan halaman tentang	41
Gambar 4. 14 Tampilan halaman tutorial	41
Gambar 4. 15 Halaman deteksi	42
Gambar 4. 16 Tampilan setelah proses deteksi	42
Gambar 4. 17 Grafik tabel pelatihan sistem	46

# **BAB 1**

## **PENDAHULUAN**

### **1.1 Latar Belakang**

Kanker kulit adalah jenis kanker yang tumbuh dan menginvasi jaringan yang ada di permukaan kulit. Kondisi ini ditandai dengan perubahan pada kulit, seperti munculnya benjolan, bercak, atau tahi lalat dengan bentuk dan ukuran yang tidak normal. Berdasarkan data dari World Cancer Research Fund International, kanker kulit diperkirakan mencapai 18,1 juta kasus di dunia pada tahun 2020. Sekitar 9,3 juta kasus terjadi pada pria dan 8,8 juta kasus pada wanita. Di Indonesia, berdasarkan data dari Globocan pada tahun 2020 terdapat 18.000 kasus kanker kulit. Kanker kulit terbagi menjadi 3 jenis yaitu melanoma, karsinoma sel basal, dan karsinoma sel skuamosa. Karsinoma sel basal merupakan jenis kanker kulit yang paling banyak di derita oleh masyarakat Indonesia (ICCC, 2019). Karsinoma sel basal merupakan kanker kulit yang menyerang sel basal dan terjadi karena pengaruh lingkungan dan genetik. Sinar matahari yang mengandung gelombang UVB dapat menyebabkan mutasi pada sel basal kulit apabila terpapar dalam waktu yang lama yang menyebabkan ketidakmampuan varian kromosom, yaitu pada kromosom 1 untuk melakukan perlindungan terhadap gelombang UVB tersebut (S. T. Tan & Reginata, 2015). Selain itu, faktor lainnya seperti usia diatas 50 tahun dan riwayat keluarga juga dapat meningkatkan resiko seseorang terkena penyakit ini. Senyawa kimia juga yang dapat memicu terjadinya karsinoma sel basal, seperti hidrokarbon, coal, tar, dan obat topikal methoxipsoralen. Senyawa kimia alami arsenik yang terdapat pada daging, susu dan berbagai makanan laut juga menjadi salah faktor yang menyebabkan penyakit ini (TAN et al., 2016).

Apabila dilakukan pengamatan dan pemeriksaan langsung terhadap kulit pasien yang baru terkena penyakit karsinoma sel basal, maka akan dijumpai kesulitan dalam proses identifikasi. Hal ini dikarenakan apabila dilihat secara objektif, maka hanya dijumpai lesi yang memiliki warna suram atau sama dengan warna kulit normal. sedangkan jika dilakukan pemeriksaan secara anamnesis, pasien hanya merasakan rasa gatal atau nyeri (TAN et al., 2016). Pemeriksaan yang lebih baik mengharuskan dokter melanjutkan pemeriksaan menggunakan alat bernama dermatoskop. Dengan



dermatoskop dokter akan mencari fitur khas karsinoma sel basal. Fitur khas ini meliputi struktur berbentuk cogan dan pola struktur permukaan (Fakhrosa et al., 2018). Namun, perlu diketahui proses diagnosa karsinoma sel basal melalui gambar dermoskop memerlukan dokter dengan keahlian yang tinggi untuk mencegah kesalahan dalam diagnosa dan sering sekali dokter harus menggunakan pemeriksaan lanjutan seperti biopsi kulit untuk mengverifikasi hasil diagnosanya. Biopsi kulit merupakan sebuah pemeriksaan medis yang memerlukan bagian lesi kulit untuk dianalisis di laboratorium patologi. Dalam proses biopsi kulit terdapat beberapa langkah umum yang biasanya dilakukan, yaitu proses fiksasi, pemrosesan sampel kulit, pemotongan sampel, pewarnaan sampel, pemeriksaan mikroskopis, dan interpretasi untuk diagnosis akhir. Proses biopsi kulit memerlukan waktu yang bervariasi dari satu hari hingga beberapa minggu tergantung dengan beberapa faktor seperti metode biopsi yang digunakan, kondisi pasien, dan beban kerja laboratorium (Sitorus & Julianto, 2018).

Karsinoma sel basal pada awalnya tidak menyebar ke ke organ tubuh lainnya (metastasis). Tetapi, apabila tidak segera ditangani maka akan menyebabkan penyebaran ke berbagai jaringan tubuh disekitarnya (Pane, 2024). Deteksi dini dan diagnosis yang akurat memiliki peran krusial dalam penanganan karsinoma sel basal. Deteksi dini dapat dilakukan melalui pemeriksaan kulit secara rutin dan konsisten, serta dengan memperhatikan perubahan yang tidak biasa pada kulit. Diagnosis karsinoma sel basal memerlukan penggunaan teknologi medis seperti dermatoskopi atau histopatologi, proses ini melibatkan biopsi dan pengamatan langsung oleh ahli yang terlatih, serta memerlukan waktu yang lama dan biaya yang mahal (Fakhrosa et al., 2018). Selain itu, diagnosis karsinoma sel basal dapat memiliki tingkat ketepatan yang bervariasi antara para ahli. Faktor-faktor seperti pengalaman, pengetahuan, dan kemampuan klinis masing-masing ahli dapat memberikan hasil diagnosis yang berbeda (McDaniel et al., 2022).

Sudah terdapat beberapa penelitian mengenai identifikasi penyakit yang menggunakan CNN. CNN merupakan jaringan saraf tiruan yang digunakan untuk tugas pengenalan pola visual, seperti pengenalan gambar dan video. CNN telah menjadi sangat populer dalam pengolahan gambar, terutama dalam klasifikasi objek dan deteksi pola. Sehingga CNN terbukti memiliki efisiensi dan akurasi yang baik dalam identifikasi penyakit, termasuk untuk kasus karsinoma sel basal.



EfficientNetV2 adalah model terbaru setelah EfficientNet yang dikembangkan oleh Google Research. Diperkenalkan pada tahun 2021, arsitektur ini memiliki prinsip kerja yang sama dengan versi sebelumnya EfficientNet, tetapi memiliki peningkatan dalam hal efisiensi model dan juga akurasi. Karakteristik EfficientNetV2 terletak pada struktur yang lebih canggih dan rinci dari pendahulunya, karena menggunakan blok residu dan perubahan-perubahan dalam desain jaringan yang bertujuan untuk meningkatkan kemampuan representasi model. Karakteristik lainnya adalah pada bagian resolusinya, dimana arsitektur ini memperkenalkan resolusi yang memungkinkan model fokus pada fitur-fitur penting dalam resolusi yang lebih rendah dan meningkatkan resolusi secara bertahap (M. Tan & Le, 2021). EfficientNet-B0 hingga EfficientNet-B7 merujuk pada serangkaian varian arsitektur EfficientNet yang memiliki tingkat kompleksitas dan ukuran yang meningkat. Varian-varian ini memperkenalkan ukuran dan kompleksitas yang berbeda untuk memenuhi kebutuhan dan sumber daya yang beragam. Namun, EfficientNetV2 dirancang untuk menjadi lebih efisien daripada varian-varian EfficientNet asli (B0 hingga B7). EfficientNetV2 memperkenalkan beberapa perubahan pada skala dan arsitektur, dimana EfficientNetV2 menggunakan skala non-uniform yang mengindikasikan bahwa dimensi model ditingkatkan secara berbeda di setiap tahap, dan ini menyebabkan model menjadi lebih kecil dan efisien (M. Tan & Le, 2021). Berdasarkan latar belakang yang dipaparkan, penulis mengajukan judul penelitian yaitu “Identifikasi Penyakit Kanker Karsinoma Sel Basal Pada Citra Dermoskopi Menggunakan Efficientnetv2”.

## **1.2 Rumusan Masalah**

Diagnosa penyakit karsinoma sel basal yang memerlukan waktu lama dan alat bantu dalam mendiagnosa penyakit karsinoma sel basal. Pemeriksaan melalui citra dermoskopi dalam menemukan ciri khas dari penyakit karsinoma sel basal, meliputi pengamatan terhadap struktur berbentuk cogan dan pola struktur permukaan yang menyulitkan dokter melakukan diagnosa jika hanya mengandalkan pengamatan secara langsung. Oleh karena itu, diperlukan sebuah teknologi atau sistem pencitraan yang dapat mengidentifikasi dan membantu pemeriksaan kulit yang lebih cermat.

### 1.3 Batasan Penelitian

Dalam penelitian ini akan dibatasi oleh hal-hal pokok sebagai berikut :

1. Penelitian ini menggunakan *convolutional neural network* (CNN) berbasis arsitektur model EfficientNetV2.
2. Sistem identifikasi hanya akan menggunakan gambar dermatoskop sebagai input. Data lain seperti riwayat medis atau informasi klinis pasien tidak akan dipertimbangkan.
3. Hasil identifikasi lesi kulit adalah karsinoma sel basal atau non karsinoma sel basal.

### 1.4 Tujuan Penelitian

Adapun tujuan dari penelitian ini yaitu untuk mengidentifikasi penyakit Karsinoma sel basal dengan menggunakan algoritma Convolutional Neural Network dengan arsitektur model EfficientNetV2.

### 1.5 Manfaat Penelitian

Hasil dari penelitian ini diharapkan dapat memberikan manfaat, yaitu :

1. Membantu dalam deteksi dini Karsinoma sel basal dengan mengidentifikasikan tanda- tanda awal yang mencurigakan dalam gambar dermatoskop
2. Membantu mengurangi waktu dan usaha yang dibutuhkan dalam menganalisis gambar dermatoskop sehingga dapat meningkatkan efisiensi dan produktivitas praktisi medis.

### 1.6 Metodologi Penelitian

Terdapat Tahapan-tahapan yang akan dilakukan dalam penelitian, yaitu :

1. Studi Literatur  
Pada tahapan ini dilakukan studi literatur dengan mengumpulkan bahan referensi dari jurnal, artikel, buku, *website*, beserta sumber- sumber lainnya mengenai *efficientnetv2*, *flask*, karsinoma sel basal, lesi kulit, dan *hair removal*.
2. Analisis Permasalahan  
Pada tahapan ini dilakukan analisis terhadap tahapan yang telah dilakukan sebelumnya yaitu studi literatur untuk mendapatkan pemahaman mengenai karsinoma sel basal dan *efficientnetv2* yang akan digunakan sebagai arsitektur dalam penelitian ini.
3. Perancangan Sistem

Pada tahap ini dilakukan proses perancangan sistem berdasarkan analisis permasalahan yang telah dilakukan sebelumnya. Perancangan sistem meliputi analisis sistem dan desain antarmuka sistem yang nantinya akan diterapkan pada tahap implementasi

4. Implementasi

Pada tahapan ini dilakukan implementasi ke dalam bentuk *source code* berdasarkan analisis dan rancangan sistem untuk menghasilkan model yang memiliki akurasi yang baik dan akan dikembangkan menjadi aplikasi website.

5. Pengujian Sistem

Pada tahap ini akan dilakukan pengujian terhadap sistem untuk menilai tingkat akurasi yang bisa didapatkan dari model yang telah dilatih sebelumnya.

6. Dokumentasi dan Penyusunan Laporan

Pada tahapan ini dilakukan dokumentasi dan penyusunan laporan yang menjabarkan hasil dari penelitian yang telah dilakukan.

## 1.7 Sistematika Penulisan

Sistem penulisan skripsi ini terdiri dari lima bagian, yaitu :

### BAB I : Pendahuluan

Bab ini berisi tentang latar belakang, rumusan masalah, Batasan masalah, tujuan penelitian, manfaat penelitian, metodologi penelitian, dan sistematika penulisan.

### BAB II : Landasan Teori

Bab ini berisi tentang penjelasan dari teori-teori yang relevan dengan sistem dan permasalahan yang diangkat dalam penelitian.

### BAB III : Analisis dan Perancangan Sistem

Bab ini berisi mengenai arsitektur umum dan menerapkan metode untuk pembuatan sistem.

### BAB IV : Implementasi dan Pengujian

Bab ini berisi tentang implementasi atau penerapan sistem berdasarkan analisis dan rancangan yang telah dibuat, juga berisi mengenai tampilan sistem yang telah dibuat, lalu pengujian untuk mengetahui akurasi sistem dalam identifikasi karsinoma sel basal dan non karsinoma sel basal

## BAB V : Kesimpulan dan Saran

Bab ini berisi tentang kesimpulan dari hasil penelitian dan saran untuk penelitian-penelitian selanjutnya





## **BAB II**

### **LANDASAN TEORI**

#### **2.1 Karsinoma Sel Basal**

Karsinoma sel basal (Basal cell carcinoma atau BCC) adalah jenis kanker kulit yang paling umum terjadi, jenis kanker kulit ini menyerang jaringan epidermis kulit yang menyebabkan sel tidak dapat melakukan keratinisasi. Ketidakmampuan sel untuk melakukan keratinisasi menyebabkan kulit tidak dapat menjalankan perannya sebagai pelindung tubuh. Lapisan kulit terluar yang bersifat keras yang dikenal sebagai stratum korneum tidak terbentuk akibat dari gagalnya proses keratinisasi menyebabkan kulit rentan dengan cedera fisik, infeksi jamur, bakteri, dan virus. Pertumbuhan ksb cenderung lambat, namun dapat menyebabkan kerusakan pada jaringan kulit disekitarnya yang menyebabkan kerusakan yang signifikan dan komplikasi serius.

BCC sering terjadi di daerah kulit yang terpapar sinar matahari, seperti wajah, leher, dan tangan. Paparan sinar ultraviolet (UV) dari matahari adalah faktor risiko utama untuk perkembangan BCC. Selain itu, penggunaan pemancar radiasi tiruan dan paparan radiasi lainnya juga meningkatkan risiko. Orang dengan kulit yang lebih terang, yang mudah terbakar matahari, memiliki risiko lebih tinggi terkena BCC. Faktor risiko lainnya termasuk usia yang lebih tua, jenis kelamin (lebih umum pada pria), riwayat keluarga dengan kanker kulit, dan sistem kekebalan tubuh yang lemah (S. T. Tan & Reginata, 2015).

Secara klinis, BCC bisa muncul dalam berbagai bentuk. Bentuk yang paling umum adalah nodul atau benjolan yang kecil, berwarna daging atau merah muda, yang mungkin memiliki permukaan mengkilap atau berkilau. BCC juga bisa muncul sebagai luka terbuka yang tidak sembuh-sembuh, bercak merah, atau area kulit yang tampak bersisik. Terkadang, BCC bisa menyerupai luka yang berdarah atau berkerak.



**Gambar 2. 1** Karsinoma Sel Basal (McDaniel et al., 2024)

Untuk melakukan diagnosis KSB, dokter dapat melakukan pemeriksaan histopatologis dan dermoskopi. Namun, pemeriksaan histopatologis bersifat invasif, sehingga dokter lebih sering memilih pemeriksaan secara dermoskopi. Dermoskopi merupakan suatu pemeriksaan lesi kulit dengan menggunakan alat pembesaran optik hingga 10-20 kali untuk melihat lapisan kulit bagian epidermis. Dengan dermatoskop dokter akan mencari fitur khas karsinoma sel basal. Fitur khas ini meliputi struktur berbentuk cogan dan pola struktur permukaan (Fakhrosa et al., 2018). Berikut penjelasan mengenai struktur dan pola tersebut:

1. Struktur berbentuk cogan
  - a. Struktur berbentuk cogan adalah pola yang terlihat seperti daun dan sering ditemukan di lesi kulit, terutama dalam kasus karsinoma sel basal (BCC).
  - b. Pada dermatoskopi, mereka tampak sebagai area hiperpigmentasi yang tidak teratur dengan cabang-cabang yang menyerupai daun.
2. Pola struktur permukaan
  - a. Pola struktur permukaan mencakup berbagai bentuk dan pola yang terlihat pada permukaan lesi kulit
  - b. Pola ini bisa meliputi area bersisik, berkerak, berbintik-bintik, atau memiliki tekstur yang tidak rata



## **2.2. Deep Learning**

Deep learning merupakan bagian dari Machine Learning dan termasuk kedalam kecerdasan buatan yang meniru jaringan syaraf pada otak manusia, serta meniru cara kerja otak dalam mengolah data lalu menciptakan pola yang akan digunakan dalam pengambilan keputusan.

Salah satu keunggulan yang dimiliki oleh deep learning yaitu mampu mengenali dan memodelkan pola yang sangat kompleks dan abstrak dalam data. Hal ini membuatnya cocok untuk tugas-tugas seperti pengenalan wajah, deteksi objek, identifikasi suatu citra, pemrosesan bahasa alami, dan banyak lagi.

Deep Learning merupakan bagian daripada Machine Learning yang pada tahun 1986 diperkenalkan oleh Dechter. Deep Learning menerapkan algoritma backpropagation, dimana mesin akan terus memperbarui bobot serta bias pada layer jaringan saraf buatan berdasarkan error, sampai menemukan bobot serta bias yang optimal (Anjani, 2021).

Perbedaan deep learning dengan machine learning yaitu deep learning menggunakan rangkaian lapisan/layer unit pemrosesan nonlinier untuk ekstraksi dan transformasi fitur yang terdapat pada objek yang diteliti, contohnya dalam gambar, deep learning dapat mengekstrak fitur-fitur yang berbeda pada gambar tersebut dalam setiap hidden layer (Hao et al, 2016).

## **2.3 Convolutional Neural Network**

Convolutional Neural Network (CNN) adalah jenis jaringan saraf tiruan yang dirancang khusus untuk mengolah data grid, seperti gambar, dengan cara yang mempertahankan informasi spasial. CNN memanfaatkan operasi konvolusi sebagai blok bangunan utamanya, yang memungkinkan jaringan ini untuk secara otomatis dan adaptif belajar hierarki fitur dari data input.

CNN terdiri dari beberapa lapisan, masing-masing dengan peran spesifik. Lapisan utama dalam CNN termasuk lapisan konvolusi, lapisan pooling, dan lapisan fully connected. Lapisan konvolusi adalah inti dari CNN. Di sinilah operasi konvolusi terjadi. Operasi konvolusi melibatkan penerapan filter atau kernel (matriks kecil dengan parameter yang dapat diatur) pada data input. Filter ini secara berulang melewati data input, melakukan operasi matriks yang mengalikan nilai piksel pada data input dengan nilai dalam filter dan menjumlahkan hasilnya. Proses ini menghasilkan peta fitur atau feature map yang mencerminkan deteksi fitur-fitur lokal pada data input, seperti tepi,

tekstur, atau pola tertentu. Kekuatan CNN berasal dari kemampuan lapisan konvolusi ini untuk belajar berbagai filter yang mampu mendeteksi fitur yang semakin kompleks pada tiap lapisan yang lebih dalam.

Setelah lapisan konvolusi, lapisan pooling biasanya digunakan untuk mengurangi dimensi spasial dari peta fitur, sehingga mengurangi jumlah parameter dan komputasi dalam jaringan. Max pooling adalah teknik pooling yang paling umum digunakan, di mana nilai maksimum dalam jendela pooling dipilih sebagai nilai representatif untuk area tersebut. Pooling membantu membuat representasi fitur menjadi lebih tahan terhadap pergeseran dan distorsi kecil pada data input, serta membantu mengurangi overfitting.

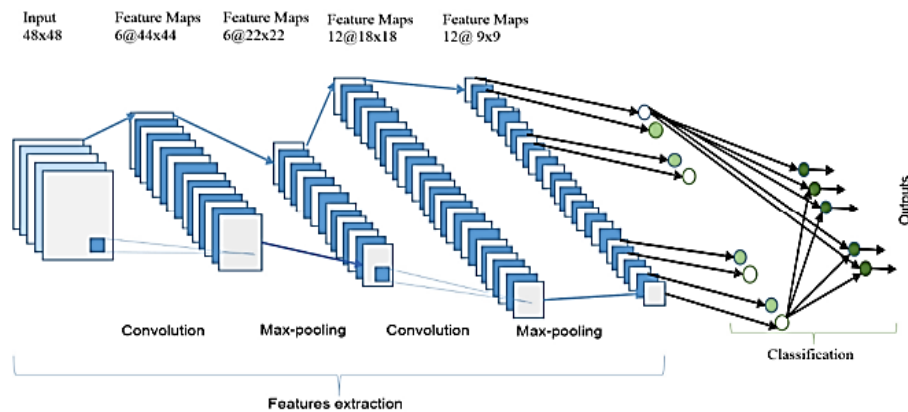
Selain itu, CNN juga sering menyertakan lapisan non-linearitas, seperti fungsi aktivasi Rectified Linear Unit (ReLU), yang diterapkan setelah operasi konvolusi. ReLU menerapkan operasi element-wise non-linearity yang mengubah semua nilai negatif menjadi nol, sehingga memperkenalkan non-linearitas ke dalam jaringan, yang penting untuk belajar representasi data yang kompleks.

Lapisan fully connected (juga dikenal sebagai dense layer) biasanya ditempatkan di bagian akhir CNN. Lapisan ini berfungsi seperti jaringan saraf tiruan tradisional, di mana setiap neuron terhubung ke semua neuron di lapisan sebelumnya. Lapisan fully connected bertugas menggabungkan fitur-fitur yang telah diekstraksi oleh lapisan konvolusi dan pooling, dan melakukan klasifikasi atau regresi pada output akhir. Neuron-neuron dalam lapisan ini mengakumulasi bukti dari berbagai fitur yang terdeteksi sebelumnya untuk membuat keputusan akhir (Li et al., 2022).

CNN dirancang untuk memanfaatkan arsitektur berlapis ini sehingga setiap lapisan dapat belajar fitur-fitur dari level rendah hingga level tinggi secara bertahap. Pada lapisan awal, CNN biasanya mendeteksi fitur-fitur dasar seperti tepi dan sudut. Pada lapisan tengah, jaringan mulai mengenali kombinasi dari fitur-fitur dasar tersebut menjadi pola yang lebih kompleks, seperti bentuk atau tekstur. Pada lapisan akhir, jaringan mampu mengenali objek atau bagian objek secara utuh.

Proses pelatihan CNN menggunakan metode backpropagation untuk mengoptimalkan parameter-parameter dalam filter konvolusi dan neuron di lapisan fully connected. Selama pelatihan, CNN meminimalkan fungsi kerugian (loss function) yang mengukur kesalahan prediksi dengan memperbarui bobot dan bias melalui algoritma

gradient descent (Zhou, 2018). Data pelatihan diberikan secara berulang (iterasi) dan jaringan belajar secara bertahap melalui epoch

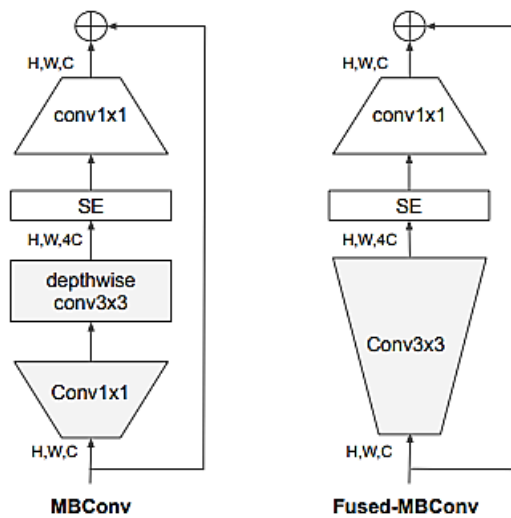


**Gambar 2. 2** Arsitektur CNN (Alom et al., 2019)

CNN telah terbukti sangat efektif untuk berbagai tugas pengenalan pola dan analisis data, terutama dalam domain visi komputer, seperti klasifikasi gambar, deteksi objek, segmentasi gambar, dan pengenalan wajah. Keunggulan CNN termasuk kemampuan untuk belajar fitur dari data tanpa perlu ekstraksi fitur manual, skalabilitas yang baik dengan data dan ukuran model yang besar, serta fleksibilitas untuk diadaptasi pada berbagai jenis data grid. Karena keunggulan-keunggulan ini, CNN menjadi salah satu arsitektur jaringan saraf yang paling populer dan banyak digunakan dalam penelitian dan aplikasi industri.

## 2.4 EfficientNetV2

EfficientNetV2 adalah arsitektur jaringan saraf konvolusional (CNN) yang dirancang untuk meningkatkan efisiensi dan performa dalam tugas-tugas visi komputer seperti klasifikasi gambar. Dikembangkan oleh para peneliti dari Google, EfficientNetV2 merupakan penerus dari model EfficientNet yang sebelumnya telah berhasil meningkatkan performa dengan efisiensi parameter yang tinggi. Pendekatan utama dalam desain EfficientNetV2 adalah kombinasi dari scaling yang tepat, penggunaan teknik baru dalam arsitektur model, dan optimisasi proses pelatihan



**Gambar 2. 3** Struktur MBConv dan Fused-MBConv (M. Tan & Le, 2021)

Salah satu inovasi utama dari EfficientNetV2 adalah konsep scaling yang lebih canggih, yang melibatkan penyesuaian dimensi kedalaman, lebar, dan resolusi input secara bersamaan untuk mencapai keseimbangan optimal antara akurasi dan efisiensi. Pada model sebelumnya, scaling dilakukan dengan cara sederhana yang hanya mengandalkan peningkatan jumlah layer, lebar, atau resolusi secara terpisah. Namun, dalam EfficientNetV2, peneliti memperkenalkan pendekatan scaling progresif yang lebih rumit namun efektif, memungkinkan model untuk memanfaatkan sumber daya komputasi dengan lebih baik sambil tetap mempertahankan atau bahkan meningkatkan akurasi.

Selain itu, EfficientNetV2 mengadopsi teknik-teknik baru dalam arsitektur model untuk meningkatkan efisiensi dan kecepatan pelatihan. Salah satu teknik penting yang digunakan adalah penggunaan Fused-MBConv, yang merupakan kombinasi dari layer konvolusi standar dan konvolusi depthwise-separable yang digunakan dalam MobileNetV2. Fused-MBConv ini dirancang untuk mengurangi overhead komputasi dan memori, sehingga memungkinkan pelatihan yang lebih cepat dan penggunaan sumber daya yang lebih efisien (M. Tan & Le, 2021). Teknik ini juga diintegrasikan dengan blok-blok yang lebih besar dan lebih dalam untuk memaksimalkan representasi fitur tanpa meningkatkan kompleksitas model secara berlebihan.

Lebih lanjut, EfficientNetV2 juga memperkenalkan pendekatan pelatihan yang lebih optimal. Salah satunya adalah penggunaan regularisasi dan augmentasi data yang lebih canggih, seperti RandAugment dan Mixup. Teknik-teknik ini membantu



meningkatkan generalisasi model dengan memperluas variasi data pelatihan dan mengurangi overfitting. Selain itu, peneliti juga mengadopsi strategi pelatihan progresif yang melibatkan perubahan skala resolusi input secara dinamis selama proses pelatihan. Dengan memulai pelatihan pada resolusi yang lebih rendah dan secara bertahap meningkatkannya, model dapat mempelajari fitur-fitur dasar terlebih dahulu sebelum beralih ke detail yang lebih halus, sehingga mempercepat konvergensi dan meningkatkan performa akhir.

Efisiensi dan performa yang dicapai oleh EfficientNetV2 juga didukung oleh penggunaan perangkat keras dan optimisasi komputasi yang cermat. Dalam eksperimen mereka, para peneliti menggunakan infrastruktur komputasi yang kuat dengan perangkat keras seperti TPU (Tensor Processing Unit) untuk mempercepat pelatihan model. Namun, arsitektur EfficientNetV2 juga dirancang agar dapat diimplementasikan pada perangkat keras yang lebih terbatas, seperti GPU konvensional dan bahkan pada perangkat edge dengan daya komputasi terbatas, menjadikannya pilihan yang fleksibel untuk berbagai aplikasi.

Secara keseluruhan, EfficientNetV2 menghadirkan peningkatan signifikan dalam hal efisiensi dan akurasi dibandingkan pendahulunya dan model-model CNN lainnya. Inovasi dalam scaling, arsitektur, dan teknik pelatihan yang diadopsi dalam EfficientNetV2 memungkinkan model ini untuk mencapai performa state-of-the-art dalam berbagai tugas visi komputer dengan penggunaan sumber daya yang lebih rendah. Sebagai hasilnya, EfficientNetV2 tidak hanya relevan dalam konteks penelitian, tetapi juga memiliki potensi besar untuk diterapkan dalam berbagai aplikasi praktis, mulai dari pengenalan gambar hingga deteksi objek dan segmentasi gambar.

## **2.5 Fitur Ekstraksi**

Pada EfficientNetV2, fitur ekstraksi adalah proses pengambilan informasi penting dari data gambar atau citra. Ciri-ciri ini digunakan untuk membangun model identifikasi yang dapat memprediksi apakah suatu lesi kulit merupakan karsinoma sel basal atau bukan. Proses ini menggunakan model Convolutional Neural Network (CNN) yang memfilter citra menggunakan kernel-kernel tertentu untuk mengekstrak ciri-ciri yang signifikan.

EfficientNetV2 melakukan fitur ekstraksi dengan menyusun beberapa blok CNN secara bertumpuk dan saling terhubung. Setiap blok CNN terdiri dari lapisan-lapisan

konvolusi, pooling, dan aktivasi. Lapisan konvolusi berfungsi untuk menyaring citra dermoskopi dan mengekstrak fitur-fitur penting dengan menggunakan sejumlah filter atau kernel, kemudian hasilnya ditambah dengan bias serta dimasukkan ke dalam fungsi aktivasi untuk menghasilkan output yang bersifat non-linear. Selanjutnya, hasil dari proses tersebut melalui lapisan pooling untuk mengurangi ukuran citra dan jumlah parameter dalam jaringan dengan cara mengambil rata-rata intensitas pixel dari suatu gambar. Hasil dari proses tersebut disebut feature map yang kemudian di-flatten untuk menjadi vektor. Feature map yang sudah menjadi vektor akan diteruskan kepada fully connected layer untuk dilakukan proses pelatihan yaitu mencari bobot dan bias yang optimal dengan cara mengkombinasikan fitur-fitur yang diekstraksi pada langkah-langkah sebelumnya. Hasilnya akan menjadi model yang dapat mengidentifikasi apakah suatu lesi kulit merupakan karsinoma sel basal atau non karsinoma sel basal.


## **2.6 Citra Digital**

Citra digital merupakan representasi visual dari objek atau adegan dalam bentuk matriks, di mana masing-masing elemen matriks mencerminkan tingkat keabuan atau intensitas cahaya pada suatu titik dalam citra. Karakteristik ini memungkinkan pengolahan komputer karena memenuhi persyaratan sebagai fungsi intensitas cahaya  $f(x, y)$ , dengan  $x$  dan  $y$  sebagai koordinat spasial. Dengan menggunakan matriks, setiap titik pada citra dapat diidentifikasi melalui elemen matriksnya, memungkinkan untuk melakukan pengolahan dan analisis citra dengan menerapkan algoritma dan teknik khusus.

## **2.7 Citra Dermoskopi**

Citra dermoskopi adalah gambar atau rekaman visual dari permukaan kulit yang dihasilkan menggunakan perangkat dermoskopi, yaitu alat optik yang memungkinkan pemeriksaan lebih detail terhadap lesi kulit. Dermoskopi digunakan dalam bidang dermatologi untuk memperoleh gambar yang lebih terperinci dari area kulit tertentu, terutama untuk evaluasi dan diagnosis lesi atau bintik-bintik yang mungkin mencurigakan. Gambar dermoskopi membantu dalam mengidentifikasi pola dan fitur khusus yang dapat menjadi petunjuk penting dalam menentukan apakah suatu lesi berpotensi menjadi kanker kulit atau tidak. Ini membantu dalam deteksi dini dan pengelolaan penyakit kulit, termasuk karsinoma sel basal dan lesi lainnya





**Gambar 2. 4** Citra dermoskopi

## 2.8 Confusion Matrix

*Confusion Matrix* adalah suatu metode yang digunakan untuk mengukur hasil klasifikasi suatu permasalahan. Metode ini membandingkan prediksi output dari model dengan nilai sebenarnya, memberikan gambaran yang rinci tentang performa model pada setiap kelas. Dengan menggunakan *Confusion Matrix*, kita dapat menilai akurasi model dan mendapatkan informasi terperinci tentang jenis kesalahan yang mungkin terjadi, diantaranya *false positive* dan *false negative*. Terdapat empat nilai dalam *confusion matrix*, antara lain:

- *True Positive (TP)*: data yang bernilai positif dan diprediksi dengan benar sebagai positif.
- *True Negative (TN)*: data yang bernilai negatif dan diprediksi dengan benar sebagai negatif.
- *False Positive (FP)*: data yang bernilai negatif, namun diprediksi dengan salah sebagai positif.
- *False Negative (FN)*: data yang bernilai positif, namun diprediksi dengan salah sebagai negatif.

Berikut merupakan beberapa metode perhitungan *confusion matrix*, diantaranya :

- *Accuracy*

Akurasi adalah nilai yang didapat dari perhitungan jumlah data bernilai positif dengan prediksi bernilai positif dan data bernilai negatif dengan prediksi yang bernilai negatif. Kemudian, nilai jumlah nilai tersebut dibagi dengan jumlah dari

seluruh data penelitian. Semakin banyak data yang memiliki prediksi yang benar, maka semakin tinggi nilai akurasi dari suatu penelitian.

$$\text{Akurasi} = \frac{\text{Jumlah data dengan prediksi benar}}{\text{Jumlah seluruh data}} \quad (2.1)$$

- *Precision*

*Precision* adalah rasio antara jumlah prediksi positif yang benar dengan total prediksi positif yang dilakukan. Dalam kata lain, *precision* mengukur sejauh mana hasil prediksi positif yang diperoleh konsisten dan akurat

$$\text{Precision} = \frac{TP}{TP+FP} \quad (2.2)$$

- *Recall*

*Recall* atau dikenal sebagai sensitivitas adalah salah satu metrik evaluasi klasifikasi yang mengukur seberapa baik model dapat mengidentifikasi dan menemukan semua *instance* yang benar positif dari kelas yang diinginkan. *Recall* menghasilkan ukuran presentase keberhasilan model dalam mendeteksi dan mengambil data positif yang relevan. Persamaan 2.3 adalah rumus mencari nilai *recall*

$$\text{Recall} = \frac{TP}{TP+FN} \quad (2.3)$$

- *F1 – Score*

*F1-score* adalah metrik yang mengintegrasikan nilai *recall* dan *precision* menjadi sebuah nilai rata-rata. *F1-score* memberikan gambaran tentang sejauh mana model dapat mencapai keseimbangan antara kemampuan untuk mengidentifikasi data yang sebenarnya positif (*recall*) dan memberikan prediksi yang benar positif (*precision*). Dengan demikian, *F1-score* dapat memberikan gambaran tentang kemampuan suatu model untuk mencapai akurasi yang seimbang antara menemukan data positif yang relevan dan memberikan prediksi yang tepat. Rumus dari *F1-score* dapat dilihat pada persamaan 2.4.

$$\text{F1-Score} = 2 \times \frac{\text{Recall} \times \text{Precision}}{\text{Recall} + \text{Precision}} \quad (2.4)$$

## 2.9 Penelitian Terdahulu

**Tabel 2. 1** Penelitian Terdahulu

No	Peneliti	Judul	Tahun	Keterangan
1	Taruno <i>et al.</i>	Monkeypox Classification based on Skin Images using CNN: EfficientNet-B0	2023	Penelitian ini bertujuan untuk membandingkan kinerja EfficientNetB0 dengan arsitektur CNN lainnya. Di antara model-model yang dievaluasi, model EfficientNet-B0 muncul sebagai pemain yang menonjol, mencapai akurasi 85,12%, melampaui akurasi model lain seperti MobileNet (63,63%) dan InceptionV3
2	Lee <i>et al.</i>	Differentiating malignant and benign eyelid lesions using deep learning (Lee <i>et al.</i> , 2023)	2023	Penelitian ini bertujuan untuk membandingkan kinerja EfficientNetB0 dengan arsitektur CNN lainnya. Di antara model-model yang dievaluasi, model EfficientNet-B0 muncul sebagai pemain yang menonjol, mencapai akurasi 85,12%, melampaui akurasi model lain seperti MobileNet (63,63%) dan InceptionV3
3	Moran <i>et al.</i>	Modelo de Red Neuronal Convolucional para la	2023	Penelitian ini menggunakan model CNN untuk mengklasifikasikan penyakit karsinoma sel basal. Dataset berasal dari Skin Cancer

	Detección de Carcinoma Basocelular		MNIST: HAM10000 dan berhasil mendapat akurasi 90,5%
4	Soegeng dkk.	Penerapan Convolutional Neural Network untuk Klasifikasi Kanker Kulit Melanoma pada Dataset Gambar Kulit	2021 Penelitian ini melakukan penggabungan arsitektur ResNet dan EfficientNet untuk mengklasifikasi melanoma. Dari hasil ensembling semua model yang telah dilatih, diperoleh akurasi prediksi AUC 93.108%
5	Papiththira & Thanika	Melanoma Skin Cancer Detection Using EfficientNet and Channel Attention Module	2021 Mengklasifikasikan melanoma dan non melanoma yang memiliki visual mirip. Model yang digunakan adalah model Efficientnet dan mendapat akurasi 84,12%
6	Burdick <i>et al.</i>	The Impact of Segmentation on the Accuracy and Sensitivity of a Melanoma Classifier Based on Skin Lesion Images	2017 Penelitian ini meneliti pengaruh segmentasi terhadap peningkatan akurasi. Hasil penelitian menunjukkan bahwa kinerja klasifikasi akan meningkat, mencapai nilai optimal.
7	Koehoorn <i>et al.</i>	Efficient and Effective Automated Digital Hair Removal From Dermoscopy Images	2016 Penelitian ini membahas penggunaan metode hair removal untuk menghapus objek rambut pada gambar dermoskopi. Penelitian ini

---



menunjukkan bahwa metode ini berhasil menangani tugas segmentasi pada dataset tumor kulit yang terdapat objek rambut

---

## **2.10 Perbedaan Penelitian Terdahulu**

Perbedaan penelitian penulis dengan penelitian yang dilakukan oleh (Moran *et al*, 2023) terletak pada arsitektur dan preprocessing yang digunakan, dimana penelitian yang dilakukan oleh Moran menggunakan arsitektur ansemble GRU dan LSTM yang menghasilkan model dengan akurasi 93,5%. Sedangkan penulis menggunakan arsitektur EfficientNetv2 untuk membangun model. Pada tahap preprocessing yang dilakukan oleh Moran tidak melalui tahap *hair removing* dan segmentasi seperti yang dilakukan oleh penulis. Penulis menggunakan tahap *hair removing* dengan tujuan untuk menghilangkan rambut dari permukaan gambar lesi kulit yang dapat menjadi elemen pengganggu dalam proses analisis. Tahap segmentasi bertujuan untuk memisahkan bagian gambar yang tidak berhubungan untuk analisis, objek yang dipisahkan akan membedakan fokus sistem dengan objek utama yang menjadi bagian dari analisis. Proses segmentasi ini juga bertujuan untuk melatih sistem dalam memahami objek yang terdapat pada gambar dan meningkatkan fokus objek pada gambar tanpa mempertimbangkan objek yang tidak penting.

## BAB 3

### ANALISIS DAN PERANCANGAN SISTEM

#### 3.1 Data yang Digunakan

Peneliti menggunakan dataset yang diambil dari HAM 10000 dataset. Dataset HAM 10000 adalah kumpulan data yang sering digunakan dalam penelitian dermatologi, khususnya dalam pengenalan dan klasifikasi citra kulit untuk mendeteksi berbagai jenis lesi kulit, termasuk kanker kulit seperti karsinoma sel basal. HAM10000 adalah singkatan dari "Human Against Machine with 10000 training images".

Penelitian ini menggunakan kumpulan gambar lesi kulit penyakit karsinoma sel basal sebagai data pelatihan sistem untuk label karsinoma sel basal dan menggunakan kumpulan gambar lesi kulit penyakit keratosis aktinik sebagai data pelatihan untuk label karsinoma sel basal. Keratosis aktinik dipilih sebagai data pelatihan untuk label non karsinoma sel basal karena memiliki kemiripan bentuk pola permukaan yang mirip dengan karsinoma sel basal. Hal ini bisa membantu model membedakan dengan lebih baik antara dua kondisi kulit tersebut.



**Gambar 3. 1** Lesi kulit karsinoma sel basal (kiri) dan keratosis aktinik (kanan)

#### 3.2 Analisis Sistem

Proses yang diterapkan dalam penelitian ini mencakup beberapa tahap, yaitu pengumpulan data citra lesi kulit, pembagian data, *data preprocessing*, *image classifier* menggunakan *efficientnetv2*, dan integrasi model ke dalam aplikasi web menggunakan *flask*







**Gambar 3. 3** Dataset HAM 10000

### 3.2.2 Split data

Penelitian ini menggunakan 3000 dataset yang terbagi menjadi 2 label yaitu karsinoma sel basal dan non karsinoma sel basal. Kedua label dibagi menjadi 3 bagian, yaitu 2100 citra atau 70% dari jumlah citra untuk data training, 600 citra atau 20% dari jumlah citra untuk data validasi, dan 300 citra atau 10% dari jumlah citra untuk data testing.

**Tabel 3. 1** Pembagian dataset

No	Data	Data Training	Data Validation	Data Testing	Jumlah
1.	Citra karsinoma sel basal	1050	300	150	1500
2.	Citra Non karsinoma sel basal	1050	300	150	1500
Total Data		2100	600	300	3000

### 3.2.3 Preprocessing

Pada tahapan ini, data dalam dataset yaitu data training, data validation, dan data testing akan diterapkan beberapa proses untuk mempersiapkan data sebelum diolah dalam arsitektur EfficientNetV2. Tujuan proses ini adalah agar data memiliki kualitas yang optimal sehingga proses identifikasi menjadi lebih baik.

#### 3.2.3.1 Image Resizing

Proses *resizing* diterapkan terhadap data citra untuk mengubah ukuran citra menjadi seragam. Model memerlukan input dengan dimensi tetap. Jika gambar dalam dataset memiliki ukuran yang berbeda-beda, proses *resizing* akan membuat semua gambar

memiliki ukuran yang sama. Resizing ke ukuran yang lebih kecil dapat mengurangi beban komputasi dan waktu pelatihan. Pada penelitian ini, ukuran dari citra akan diubah menjadi 224 x 224 piksel. Prosesnya dapat dijelaskan pada pseudocode berikut :

```
image_dir <-- 'path_to_images_directory'
output_dir <-- 'path_to_resized_images'
target_size <-- (220, 220)

for setiap image_name dalam direktori image_dir do
  image_path <-- gabungkan path image_dir dan image_name
  image <-- cv2.imread(image_path)
  resized_image <-- cv2.resize(image, target_size)
  resized_image <-- cv2.resize(image, target_size)
  output_path <-- gabungkan path output_dir dan image_name
  cv2.imwrite(output_path, resized_image)
end for
```

### 3.2.3.2 Hair Removal


*Hair removal* adalah proses penghilangan atau pengurangan rambut dari citra, terutama dalam konteks citra medis. Rambut pada citra dapat menjadi elemen gangguan yang mengakibatkan ketidakakuratan dalam tugas analisis, seperti proses identifikasi karsinoma sel basal. Hal ini dikarenakan rambut akan menjadi fitur yang tidak berhubungan dengan lesi kulit yang sedang dianalisis dan mempengaruhi proses pembelajaran model. Tahapan pertama pada proses *hair removal* adalah mengubah citra menjadi citra grayscale, kemudian citra akan diterapkan operasi morfologi yaitu manipulasi struktur bentuk objek dalam citra, seperti dilasi, erosi, *opening*, dan *closing* menggunakan suatu kernel. Setelah itu, akan diterapkan filter *blackhat*, yaitu satu jenis filter yang digunakan untuk mengekstraksi fitur yang lebih gelap dari latar belakangnya, dengan tujuan untuk menemukan kontur rambut, kemudian kontur rambut tersebut akan diperkuat dengan dengan metode *thresholding*, dengan cara merubah semua piksel dengan intensitas dibawah nilai 10 menjadi 0, dan yang di atasnya menjadi 255. Langkah terakhir dari tahapan ini yaitu menerapkan algoritma *inpainting* terhadap citra, dimana algoritma ini merupakan teknik untuk mengisi atau menggantikan bagian tertentu dari citra yang hilang atau rusak dengan informasi dari suatu *mask* yang telah dibuat sebelumnya. Dalam konteks pengolahan citra, *mask* adalah citra biner yang digunakan untuk menentukan area atau piksel tertentu yang akan diaktifkan atau dinonaktifkan dalam suatu proses pemulihan citra. Prosesnya dapat dijelaskan pada pseudocode berikut :

```

konversi grayscale
    grayImage <-- convertImageToGrayscale(image)
Apply median blur to reduce noise
    denoisedImage <-- applyMedianBlur(grayImage, kernelSize=5)
Operasi morfologi
    structuringElement <--
createStructuringElement(shape="rectangle", size=(17, 17))
    closedImage <-- applyMorphologicalClosing(denoisedImage,
operation="blackhat", element=structuringElement)
Thresholding
    thresholdedImage <-- applyThreshold(closedImage,
thresholdValue=10, maxValue=255, type="binary")

```

Proses *hair removal* ini menjadi proses penting dalam mempersiapkan dataset citra lesi kulit agar memastikan bahwa model yang nantinya dibuat dapat mendeteksi lesi dengan akurat. Citra lesi kulit sebelum dan sesudah *hair removal* dapat dilihat pada gambar berikut



**Gambar 3. 4** Hasil proses hair removal

### 3.2.3.3 Image Segmentation

Image segmentation atau segmentasi citra merupakan proses pemisahan atau pembagian sebuah gambar yang memiliki karakteristik tertentu menjadi beberapa bagian. Dengan metode ini, gambar dapat diidentifikasi dan dipisahkan menjadi objek-objek berbeda dengan tujuan untuk memahami struktur gambar dengan cara yang lebih terperinci serta meningkatkan fokus pelatihan model pada objek dalam gambar dengan cara menghilangkan elemen yang tidak relevan. Prosesnya dapat dijelaskan pada pseudocode berikut :



```
image <-- cv2.imread(image_path)
gray <-- cv2.cvtColor(image, cv2.COLOR_BGR2GRAY)
thresh <-- cv2.threshold(gray, 127, 255,
cv2.imwrite(output_path, thresh)
```

#### 3.2.3.4 Image Normalization

Proses ini merupakan proses untuk mengubah intensitas piksel dalam gambar agar memiliki distribusi yang lebih seragam dan sesuai dengan rentang tertentu, guna memastikan bahwa input ke model memiliki rata-rata dan standar deviasi yang konsisten sehingga lebih mudah dipelajari dan dibandingkan. Pada penelitian ini, intensitas piksel akan dikonversi ke rentang 0 sampai 1, dimana semakin mendekati angka 0 maka piksel tersebut akan semakin gelap, sebaliknya, semakin mendekati angka 1 maka piksel tersebut semakin terang. Proses ini dilakukan dengan cara membagi nilai tiap piksel dengan 255. Prosesnya dapat dijelaskan pada pseudocode berikut :

```
image_dir <-- 'path_to_images_directory'
output_dir <-- 'path_to_normalized_images'
for setiap image_name dalam direktori image_dir do
    image_path <-- gabungkan path image_dir dan
image_name
    img <- cv2.imread (image_path)
    normalized_img <-- img / 255.0
    normalized_img <-- (normalized_img *
255).astype (np. uint8)
    output_path <-- gabungkan path output_dir dan
image_name
    cv2.imwrite(output_path, normalized_img)
end for
```

#### 3.2.3.5 Image Augmentation

Proses mengubah atau menyesuaikan suatu gambar sehingga bentuk dan letak aslinya berubah disebut augmentasi. Augmentasi digunakan untuk memungkinkan mesin mengidentifikasi gambar dalam berbagai bentuk dan lokasi. Selain itu, augmentasi dapat menghasilkan volume data yang lebih besar untuk diproses, sehingga dapat meningkatkan variasi pola pada data dan juga menyeimbangkan *dataset* yang memiliki selisih data antar label yang dapat menyebabkan model tidak seimbang. Penelitian ini menggunakan augmentasi berupa *flip* dan *rotate*. *Flip* adalah operasi pencerminan

horizontal atau vertikal terhadap gambar, sedangkan *rotate* akan memutar gambar di sekitar pusatnya dengan sudut tertentu, dimana dalam penelitian ini menggunakan rotasi sebesar 90 derajat dan -90 derajat. Nilai -90 derajat merupakan kebalikan dari rotasi 90 derajat, yang tujuannya agar model mendapat perspektif yang lebih kaya. Prosesnya dapat dijelaskan pada pseudocode berikut :

```
for setiap image_name dalam direktori image_dir do
    image_path <-- gabungkan path image_dir dan
    image_name
    img <-- cv2.imread(image_path)
    flip_vertical <-- cv2.flip(img, 0)
    cv2.imwrite
    flip_horizontal <-- cv2.flip(img, 1)
    rotate_90 <-- cv2.rotate(img,
    cv2.ROTATE_90_CLOCKWISE)
    cv2.imwrite
    rotate_minus_90 <-- cv2.rotate(img,
    cv2.ROTATE_90_COUNTERCLOCKWISE)
    cv2.imwrite
end for
```

### 3.2.4 Image Classifier

Pada tahapan ini akan dilakukan proses terhadap data *training* menggunakan arsitektur CNN EfficientNetV2, dimana proses akan menangkap fitur-fitur pada gambar *training* dengan penerapan arsitektur EfficientNetV2, lalu fitur-fitur tersebut akan masuk ke *fully-connected layer* dimana di dalamnya akan dilakukan perbaikan bobot sehingga nantinya akan mendapatkan bobot yang optimal untuk melakukan proses identifikasi karsinomas sel basal dan non karsinoma sel basal, lalu kemudian akan menciptakan model yang terlatih. Model ini nantinya akan divalidasi menggunakan data validasi yang sudah disiapkan, agar kualitas model yang dihasilkan dapat diukur. Prosesnya dapat dijelaskan pada pseudocode berikut :

```
initialize base_model with EfficientNetV2
initialize model as Sequential
add base_model to model
add GlobalAveragePooling2D to model
add Dense layer with 128 neurons and ReLU activation to model
// Fully connected layer tambahan
add Dense layer with 1 neuron and Sigmoid activation to model
// Keluaran akhir
```

#### 3.2.4.1 Feature Extraction

Pada tahap ini gambar yang telah memasuki arsitektur *efficientnetv2* mengalami tranformasi melalui jaringan lapisan konvolusi untuk dilakukan proses pengambilan informasi. Setiap layer konvolusi memiliki filter yang bertujuan untuk mendeteksi fitur lokal seperti tepi, sudut, dan pola permukaan pada gambar.

Arsitektur *efficientnetv2* memiliki 2 jenis lapisan konvolusi, yaitu MBConv dan Fused-MBConv. Pada lapisan Fused-MBConv terdapat beberapa tahap, diantaranya adalah tahap *standart convolution (conv 3x3)*, *Squeeze dan Excitation (SE)*, dan *pointwise convolution (conv 1x1)*. Sedangkan untuk lapisan MBConv terdiri dari lapisan *pointwise convolution (conv 1x1)*, *depthwise convolution (conv 3x3)*, *Squeeze dan Excitation (SE)*, *pointwise convolution (conv 1x1)*.

Lapisan konvolusi tersebut akan menangkap fitur-fitur pada gambar karsinoma sel basal dan non karsinoma sel basal lalu dijadikan pola atau karakteristik yang dapat digunakan untuk membedakan gambar karsinoma sel basal dengan gambar non karsinoma sel basal. Pada tahapan ini akan menghasilkan *feature map* yang menjadi representasi dari karakteristik objek tersebut.

#### 3.2.4.2 Global Average Pooling 2D (GAP 2D)

Setelah proses ekstraksi fitur melalui berbagai lapisan konvolusi (termasuk MBConv dan Fused-MBConv), output yang dihasilkan adalah tensor 4D dengan dimensi (batch\_size, height, width, channels). GAP menghitung rata-rata dari nilai fitur di setiap channel. Artinya, untuk setiap channel dalam tensor output, nilai-nilai dari semua piksel (height dan width) dijumlahkan dan dibagi dengan jumlah piksel. Hasilnya adalah tensor 2D dengan dimensi (batch\_size, channels). Setiap channel akan menyimpan satu nilai rata-rata, yang mewakili fitur dari seluruh area spatial. Hasilnya adalah tensor 2D dengan dimensi (batch\_size, channels). Setiap channel akan menyimpan satu nilai rata-rata, yang mewakili fitur dari seluruh area spatial. Setelah GAP, output yang telah

diringkas ini kemudian dihubungkan ke lapisan klasifikasi, biasanya berupa *Dense layer* atau *Fully Connected layer* yang menghasilkan output akhir.

#### 3.2.4.3 Fully Connected Layer

Pada tahapan ini feature map akan diubah menjadi vektor satu dimensi, dan elemen di dalamnya akan mewakili fitur yang dimiliki oleh suatu objek. Lalu, vektor akan dijadikan masukan ke jaringan syaraf tiruan yang setiap neuron pada layer sebelumnya terhubung ke setiap neuron di layer setelahnya, atau bisa disebut fully connected layer. Setiap neuron memiliki bobot dan bias yang nantinya akan dioptimalkan seiring berjalannya proses pembelajaran. Input atau masukan tadi akan dihitung menggunakan fungsi aktivasi yang memiliki sifat non linier. Proses ini akan sampai kepada layer output, lalu kemudian akan dihitung error yang nantinya akan digunakan sebagai acuan untuk mengubah bobot pada setiap iterasi, sampai memiliki atau mendapatkan bobot yang optimal.

#### 3.2.5 Learned Model

Learned model dalam konteks perancangan model Efficientnetv2 mengacu pada model yang telah dilatih dan dioptimalkan menggunakan dataset tertentu sehingga mampu melakukan tugas spesifik, seperti klasifikasi gambar atau deteksi objek. Proses pembelajaran melibatkan beberapa tahapan kunci, mulai dari persiapan data hingga evaluasi model, dengan tujuan menghasilkan model yang memiliki generalisasi baik pada data yang belum pernah dilihat sebelumnya.

#### 3.2.6 Flask

Flask adalah salah satu framework web mikro untuk Python yang sangat populer dan digunakan untuk mengembangkan aplikasi web. Flask dikenal karena kesederhanaannya, fleksibilitasnya, dan kemudahan penggunaannya, yang membuatnya ideal untuk proyek-proyek kecil hingga menengah dan prototipe cepat. Flask adalah microframework, yang berarti hanya menyediakan komponen-komponen dasar untuk membangun aplikasi web, seperti routing dan templating. Hal ini membuatnya ringan dan mudah untuk dipelajari dan digunakan, terutama untuk proyek kecil hingga menengah. Flask tidak memaksakan struktur aplikasi tertentu, sehingga pengembang memiliki kebebasan untuk mengorganisir kode. Ini memberikan fleksibilitas yang tinggi dalam mengembangkan berbagai jenis aplikasi. Prosesnya dapat dijelaskan pada pseudocode berikut :



```
initialize app as Flask with current module name
initialize model by loading 'model.h5' using
tf.keras.models.load_model

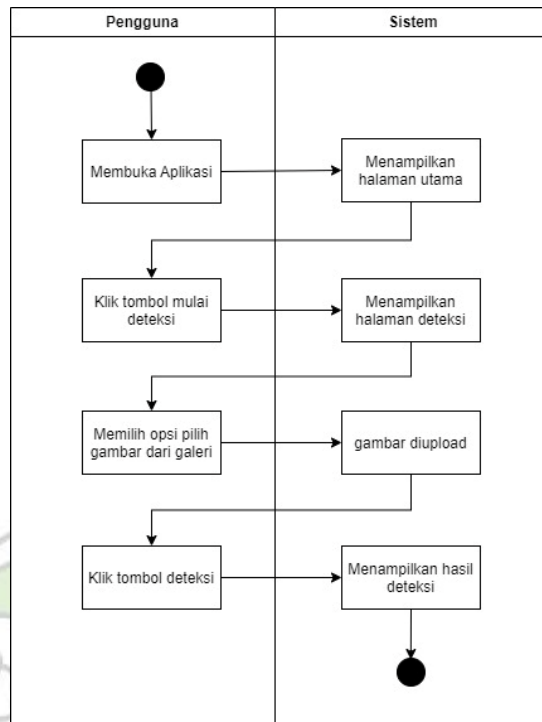
load image from filepath with target size (240, 240) into img
convert img to array and store in img_array
add a new dimension to img_array for batch size
normalize img_array by dividing by 255.0
initialize predictions by calling model.predict with img_array
as input
if predictions[0] > 0.5 then
    set predicted_class to 'A' // Label A
else
```

### 3.3 Desain Antarmuka Sistem

Dalam langkah ini, perhatian utama tertuju pada presentasi visual dari sistem aplikasi identifikasi karsinoma sel basal melalui citra dermoskopi lesi kulit. Tujuan dari tahap ini adalah menyajikan gambaran aplikasi kepada pengguna dengan tujuan memudahkan mereka dalam memahami serta menggunakan aplikasi yang dibangun. Perancangan aplikasi ini berpedoman dengan diagram aktivitas yang sudah ditentukan. Diagram aktivitas aplikasi pada penelitian ini dapat dilihat pada

#### 3.3.1 Activity Diagram

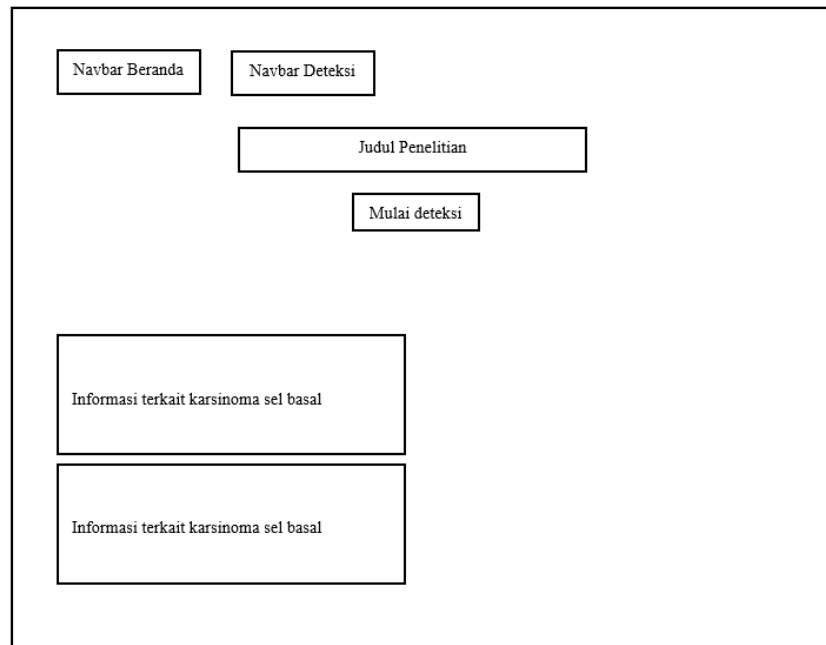
Diagram aktivitas digunakan untuk menunjukkan urutan aktivitas atau tindakan yang terjadi dari aplikasi. Diagram ini dapat menggambarkan alur kerja dari satu pekerjaan ke pekerjaan lain melalui serangkaian langkah-langkah dan apa yang terjadi pada setelahnya sehingga pengguna lebih mudah dalam memahaminya.



**Gambar 3. 5** Diagram activity

### 3.2.2 Desain Halaman Beranda


Pada halaman beranda akan memiliki dua navigasi bar, yaitu beranda dan prediksi. Navbar beranda akan mengarahkan ke halaman beranda dan navbar prediksi akan mengarahkan ke halaman untuk deteksi penyakit karsinoma sel basal dan non karsinoma sel basal. Halaman ini juga memiliki beberapa tampilan informasi terkait dengan penyakit karsinoma sel dan diagnosisnya. Judul akan berada dibagian atas dari halaman ini, dibawah judul akan terdapat tombol mulai prediksi yang akan mengarahkan ke halaman prediksi.



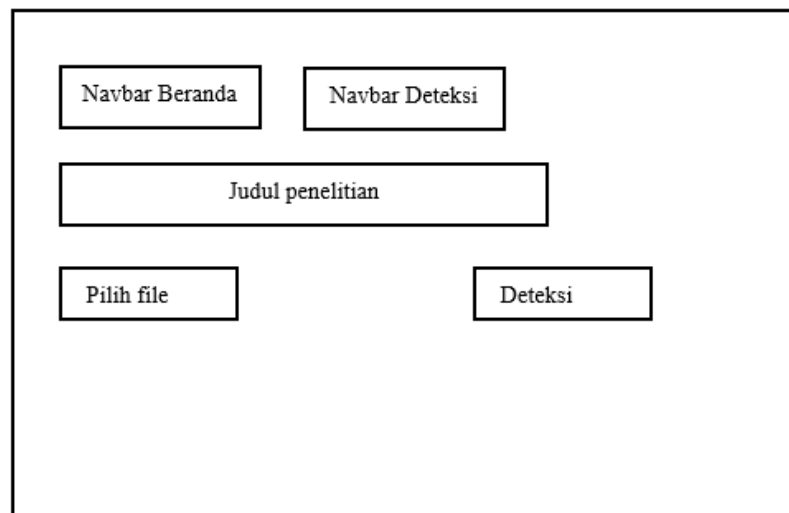
**Gambar 3. 6** Desain halaman beranda

### 3.2.3 *Desain Halaman Deteksi*

Halaman ini akan terbuka saat menekan tombol “Mulai Deteksi” atau navbar deteksi pada bagian atas halaman beranda. Pada halaman ini, pengguna diharuskan memasukkan gambar dermoskopi lesi kulit dari galeri, untuk selanjutnya akan dilakukan proses identifikasi setelah menekan tombol deteksi.



**Gambar 3. 7** Tombol input gambar dan tombol deteksi



Navbar Beranda

Navbar Deteksi

Judul penelitian

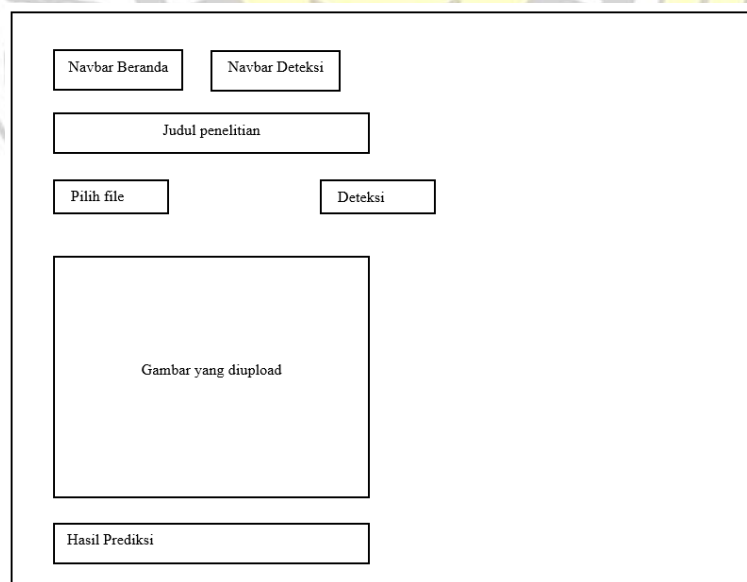
Pilih file

Deteksi

**Gambar 3. 8** Desain halaman prediksi

#### 3.2.4 *Desain Halaman Setelah Proses Deteksi*

Setelah pengguna memilih gambar yang akan di deteksi dan menekan tombol deteksi, maka aplikasi akan memproses gambar dengan model yang telah ditentukan. Hasil dari proses deteksi ini akan menampilkan gambar yang di deteksi dan hasil deteksinya. Hasil deteksi hanya memiliki dua output yaitu, karsinoma sel basal dan non karsinoma sel basal.



Navbar Beranda

Navbar Deteksi

Judul penelitian

Pilih file

Deteksi

Gambar yang diupload

Hasil Prediksi

**Gambar 3. 9** Desain halaman setelah deteksi



## BAB 4 IMPLEMENTASI DAN PENGUJIAN SISTEM

### 4.1 Implementasi Sistem

Penerapan arsitektur EfficientNetV2 yang dibangun dan diimplementasikan dalam sistem untuk mengidentifikasi gambar dermoskopi lesi kulit memerlukan perangkat dan data dukungan berikut :

#### 4.1.1 Perangkat Keras dan Perangkat Lunak

Dalam membangun sistem aplikasi ini menggunakan perangkat keras dan perangkat lunak sebagai berikut :

1. Laptop HP Laptop 14s-fq0xxx
2. *Processor AMD Ryzen 7 4700U*
3. RAM 8GB
4. Sistem operasi *Windows 11 Home 64-bit*
5. *Google Colab Pro*
6. *Jupyter Notebook*
7. *Tensorflow*
8. *Flask*
9. *Sublime Text*

#### 4.1.2 Data Citra Lesi Kulit

Penelitian ini menggunakan data citra yang terdiri dari citra lesi kulit karsinoma sel basal dan Aktinik keratosis untuk kategori non karsinoma sel basal yang diambil dari *dataset HAM 10000*. Pengambilan citra pada *dataset Ham 10000* melalui proses dermoskopi, yaitu pengambilan citra menggunakan alat bernama dermoskop. Validasi diagnosis pada *dataset* tersebut dilakukan melalui proses bernama histopatologi. Jumlah data yang digunakan sebanyak 3000 data citra dengan pembagian 1500 data citra karsinoma sel basal dan 1500 data citra non karsinoma sel basal.

#### 4.1.3 Tahapan Pembuatan Model

Pada penelitian ini terdapat tahapan-tahapan yang dilalui dalam pembuatan model untuk identifikasi karsinoma sel basal, mulai dari tahap preprocessing data, pelatihan model, validasi, hingga pengujian model. Setiap tahapan memiliki peran penting untuk memastikan model yang dibangun dapat bekerja dengan baik dan menghasilkan prediksi yang akurat.

##### 4.1.3.1 Preprocessing Data

Tahapan pertama, yaitu preprocessing, mencakup teknik-teknik yang digunakan untuk mempersiapkan dataset, yaitu :

##### 1. Image Resizing

Proses *resizing* diterapkan terhadap data citra untuk mengubah ukuran citra menjadi seragam. Pada penelitian ini, ukuran dari citra akan diubah menjadi 240 x 240 piksel. Berikan merupakan contoh dari proses *resizing* yang dilakukan pada penelitian ini :



Citra berdimensi 4x4 piksel diubah menjadi citra berdimensi 2x2 piksel dengan mengambil nilai rata-rata dari empat piksel yang berdekatan. Nilai piksel baru ini kemudian akan mewakili citra yang telah mengalami proses perubahan ukuran. Berikut perhitungannya:

$$P1 = (217+215+219+213) \div 4 = 216$$


$$P2 = (225+187+230+190) \div 4 = 208$$

$$P3 = (192+195+188+185) \div 4 = 190$$

$$P4 = (200+157+177+178) \div 4 = 178$$

216	208
190	178

Berikut merupakan contoh citra sebelum dan setelah diterapkan proses resize dan kode perprograman pada proses imaze resizing yang dapat dilihat pada gambar di bawah.



**Gambar 4. 1** Sebelum dan sesudah proses image resizing

```
train_tf_images_resized, valid_tf_images_resized, test_tf_images_resized = preprocessor.image_resizing(
    train_tf_images,
    valid_tf_images,
    test_tf_images
)
# Inspeksi data pada index tertentu
inspector.inspect(train_tf_images_resized, valid_tf_images_resized, test_tf_images_resized)
```

===== TRAIN\_DATA INFO =====

shape-image: (224, 224, 3)  
dtype-image: <dtype: 'uint8'>  
max-intensity: 255  
min-intensity: 0  
label: 1 -> bcc  
label-shape: ()  
label-type: <dtype: 'int32'>

===== VALID\_DATA INFO =====

shape-image: (224, 224, 3)  
dtype-image: <dtype: 'uint8'>  
max-intensity: 255  
min-intensity: 6  
label: 1 -> bcc  
label-shape: ()  
label-type: <dtype: 'int32'>

Train Label: bcc

Valid Label: bcc

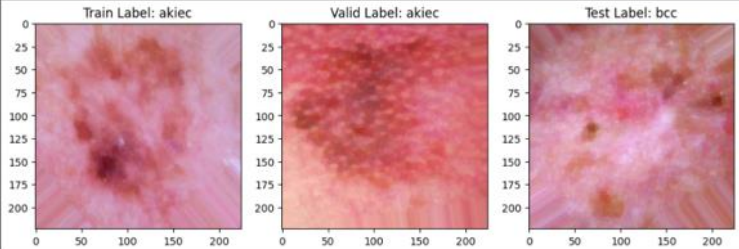
Test Label: bcc

**Gambar 4. 2** Kode program dan hasil eksekusi untuk image resizing

## 2. Hair Removal

Hair removal adalah proses penghilangan atau pengurangan rambut dari citra, terutama dalam konteks citra medis. Rambut pada citra dapat menjadi elemen gangguan yang mengakibatkan ketidakakuratan dalam tugas analisis. Hal ini dikarenakan rambut akan menjadi fitur yang tidak berhubungan dengan lesi kulit yang sedang dianalisis dan mempengaruhi proses pembelajaran model.

```
49: train_tf_images_hair_removed, valid_tf_images_hair_removed, test_tf_images_hair_removed = preprocessor.hair_removal(  
    train_tf_images_resized,  
    valid_tf_images_resized,  
    test_tf_images_resized  
)  
  
===== TRAIN_DATA INFO =====  
shape-image: (224, 224, 3)  
dtype-image: <dtype: 'uint8'>  
max-intensity: 250  
min-intensity: 15  
label: 0 -> akiec  
label-shape: ()  
label-type: <dtype: 'int32'>  
  
===== VALID_DATA INFO =====  
shape-image: (224, 224, 3)  
dtype-image: <dtype: 'uint8'>  
max-intensity: 255  
min-intensity: 32  
label: 0 -> akiec  
label-shape: ()  
label-type: <dtype: 'int32'>  
  
===== TEST_DATA INFO =====  
shape-image: (224, 224, 3)  
dtype-image: <dtype: 'uint8'>  
max-intensity: 255  
min-intensity: 11  
label: 1 -> bcc  
label-shape: ()  
  
Train Label: akiec  
Valid Label: akiec  
Test Label: bcc
```




**Gambar 4. 3** Kode program dan hasil eksekusi untuk hair removal

## 3. Image Segmentation

*Image segmentation* atau segmentasi citra merupakan proses pemisahan atau pembagian sebuah gambar yang memiliki karakteristik tertentu menjadi beberapa bagian. Dengan metode ini, gambar dapat diidentifikasi dan dipisahkan menjadi objek-objek berbeda dengan tujuan untuk memahami struktur gambar dengan cara yang lebih terperinci serta meningkatkan fokus pelatihan model pada objek dalam gambar dengan cara menghilangkan elemen yang tidak relevan





**Gambar 4. 4** Sebelum dan sesudah Image Segmentation

```
[54]: # Inspeksi data pada index tertentu
      inspector.inspect(train_tf_images_segmented, valid_tf_images_segmented, test_tf_images_segmented)

===== TRAIN_DATA INFO =====
shape-image: (224, 224, 3)
dtype-image: <dtype: 'uint8'>
max-intensity: 255
min-intensity: 0
label: 1 -> bcc
label-shape: ()
label-type: <dtype: 'int32'>

===== VALID_DATA INFO =====
shape-image: (224, 224, 3)
dtype-image: <dtype: 'uint8'>
max-intensity: 255
min-intensity: 0
label: 0 -> akiec
label-shape: ()
label-type: <dtype: 'int32'>

===== TEST_DATA INFO =====
shape-image: (224, 224, 3)
dtype-image: <dtype: 'uint8'>
max-intensity: 255
min-intensity: 0
label: 1 -> bcc
label-shape: ()
label-type: <dtype: 'int32'>
```


**Gambar 4. 5** Kode program dan hasil eksekusi untuk image segmentation

#### 4. Image Normalization

Proses ini merupakan proses untuk mengubah intensitas piksel dalam gambar agar memiliki distribusi yang lebih seragam dan sesuai dengan rentang tertentu, guna memastikan bahwa input ke model memiliki rata-rata dan standar deviasi yang konsisten sehingga lebih mudah dipelajari dan dibandingkan. Pada penelitian ini, intensitas piksel akan dikonversi ke rentang 0 sampai 1, dimana semakin mendekati angka 0 maka piksel tersebut akan semakin gelap, sebaliknya, semakin mendekati angka 1 maka piksel tersebut semakin terang. Proses ini dilakukan dengan cara membagi nilai tiap piksel dengan 255. Berikut merupakan contoh proses normalisasi citra:

217	215	225	187		0.8509	0.8431	0.8823	0.7333
219	213	230	190		0.8588	0.8382	0.9019	0.7450
192	195	200	157	→	0.7529	0.7647	0.7843	0.6156
188	185	177	178		0.7372	0.7254	0.6941	0.6980


Proses diatas merupakan contoh normalisasi intensitas setiap piksel pada gambar 4x4. Dapat dilihat bahwa intensitas setiap piksel akan dibagi dengan 255. Contohnya pada piksel pertama, dimana piksel tersebut memiliki intensitas 217, ketika dibagi dengan 255 akan menghasilkan nilai intensitas sebesar 0.8509.




**Gambar 4. 6** Sebelum dan sesudah image normalization

## 5. Augmentasi


Augmentasi digunakan untuk memungkinkan mesin mengidentifikasi gambar dalam berbagai bentuk dan lokasi. Penelitian ini menggunakan augmentasi berupa *flip* dan *rotate*. *Flip* adalah operasi pencerminan horizontal atau vertikal terhadap gambar, sedangkan *rotate* akan memutar gambar di sekitar pusatnya dengan sudut tertentu, dimana dalam penelitian ini menggunakan rotasi sebesar 90 derajat dan -90 derajat. Nilai -90 derajat merupakan kebalikan dari rotasi 90 derajat, yang tujuannya agar model mendapat perspektif yang lebih kaya.



**Gambar 4. 7** Sebelum dan sesudah flip horizontal



**Gambar 4. 8** Sebelum dan sesudah flip vertikal



**Gambar 4. 9** Rotasi 90 dan -90 derajat

#### 4.1.3.2 Training Dataset

*Training* data adalah proses dimana sistem mempelajari pola pada gambar atau citra yang menjadi *input* dan menghasilkan model dengan menggunakan arsitektur EfficientNetV2. Jumlah gambar pada data *training* lebih banyak jika dibandingkan

dengan data *testing*. Hal ini dilakukan agar pemahaman model terhadap pola gambar masing-masing *label* lebih baik dan kompleks. Pada penelitian ini, data *training* memiliki persentase sebesar 70% dari total jumlah data penelitian.

```
[36]: # Inisialisasi callback untuk logging hasil pelatihan
training_logger = TrainingLogger(
    log_file=LABEL_TRAINING_PATH, # Path untuk menyimpan log hasil pelatihan
    batch_size=BATCH_SIZE # Batch size yang digunakan
)

# Callback untuk menyimpan model terbaik berdasarkan val_loss terendah
checkpoint_callback = tf.keras.callbacks.ModelCheckpoint(
    filepath=TARGET_KERAS_MODEL_PATH, # Path untuk menyimpan model terbaik
    monitor='val_loss', # Metode evaluasi adalah val_loss
    save_best_only=True, # Hanya simpan model terbaik
    save_weights_only=False, # Simpan seluruh model, bukan hanya bobot
    mode='min', # Simpan model ketika val_loss mencapai nilai terendah
    verbose=1 # Tampilkan progress saat menyimpan model
)

# Callback untuk mengurangi learning rate jika val_loss tidak membaik setelah beberapa epoch
plateau_callback = tf.keras.callbacks.ReduceLROnPlateau(
    monitor='val_loss', # Pantau val_loss
    factor=0.5, # Kurangi learning rate dengan faktor 0.5
    patience=10, # Berapa banyak epoch yang harus ditunggu sebelum menurunkan learning rate
    verbose=1, # Tampilkan informasi saat learning rate diturunkan
    mode='auto', # Secara otomatis mendeteksi apakah harus meminimalkan atau memaksimalkan
    min_delta=0.001, # Perubahan minimal pada val_loss yang diperlukan untuk dianggap sebagai peningkatan
    cooldown=0, # Berapa lama untuk menunggu sebelum menurunkan lagi setelah perbaikan
    min_lr=0 # Learning rate minimal
)

# Callback untuk menghentikan pelatihan lebih awal jika val_loss tidak membaik
early_stopping = tf.keras.callbacks.EarlyStopping(
    monitor='val_loss', # Pantau val_loss
    patience=25, # Berhenti jika tidak ada perbaikan setelah 25 epoch
    restore_best_weights=True # Kembali ke bobot terbaik setelah selesai pelatihan
```

**Gambar 4. 10** Kode program yang digunakan pada training dataset

Pada kode program digunakan beberapa callback yang berguna selama proses pelatihan model, serta melakukan pelatihan model dengan callback yang ditentukan. Callback ini membantu memantau metrik dan menyimpan hasil model selama pelatihan.

- **TrainingLogger:** Callback ini bertugas mencatat hasil pelatihan seperti `val_accuracy` dan `val_loss` setelah setiap epoch ke dalam file CSV. Hal ini membantu dalam memantau performa model di setiap epoch tanpa harus melihat output terminal secara langsung.
- **ModelCheckpoint:** Callback ini menyimpan model setiap kali terjadi peningkatan performa berdasarkan nilai `val_loss`. Model terbaik akan disimpan di lokasi yang ditentukan dalam file `TARGET_KERAS_MODEL_PATH`.
- **ReduceLROnPlateau:** Callback ini akan mengurangi learning rate secara otomatis jika model tidak menunjukkan peningkatan setelah beberapa epoch tertentu, berdasarkan parameter `patience`. Ini membantu agar model tidak terjebak di local minima dan bisa mencapai performa lebih baik.



- **EarlyStopping:** Callback ini menghentikan pelatihan secara otomatis jika model tidak menunjukkan peningkatan setelah sejumlah epoch tertentu, dengan parameter patience. Hal ini bertujuan menghindari overfitting.

#### 4.1.3.3 Validasi Model

Setelah melalui proses pengujian, selanjutnya melalui proses evaluasi untuk mengukur kinerja model dalam mengenali pola dari gambar. Dalam proses ini, peneliti menggunakan metrik evaluasi yaitu ukuran atau nilai yang digunakan untuk mengukur kinerja model yang telah dilatih dalam melakukan tugas identifikasi. Metrik evaluasi yang digunakan diantaranya adalah *recall*, *precision*, dan F1-score. Dengan mempertimbangkan ketiga metrik ini, peneliti dapat mengevaluasi sejauh mana model efektif dalam mengenali contoh-contoh lesi kulit sebagai positif atau negatif untuk penyakit karsinoma sel basal. Selain itu, penelitian ini memungkinkan penilaian seberapa baik model mampu menghindari kesalahan klasifikasi, baik dalam hal memberikan prediksi positif palsu maupun negatif palsu.

```
def evaluate_model(
    model,
    tf_dataset,
    class_names,
    confusion_plot_path=None,
    classification_report_path=None,
    save_plot=True,
    save_report=True
):
    """
    Evaluasi model dan hasilkan confusion matrix dan classification report.

    Args:
    - model: Model yang sudah dilatih.
    - tf_dataset: Dataset untuk evaluasi.
    - class_names: Daftar nama kelas yang ada.
    - confusion_plot_path: Path untuk menyimpan confusion matrix plot.
    - classification_report_path: Path untuk menyimpan classification report.
    - save_plot: Simpan confusion matrix plot jika True.
    - save_report: Simpan classification report jika True.
    """
    # Ambil label asli dan prediksi model
    y_true = []
    y_pred = []

    for images, labels in tqdm(tf_dataset, desc='Evaluation'):
        predictions = model.predict(images, verbose=0)
        y_true.extend(tf.squeeze(labels).numpy()) # Label untuk klasifikasi biner (0 atau 1)
        y_pred.extend((predictions > 0.5).astype(int)) # Ubah prediksi menjadi biner (0 atau 1)

    y_true = np.array(y_true)
    y_pred = np.array(y_pred)
```


**Gambar 4. 11** Kode program pada validasi model

## 4.2 Implementasi Tampilan Antaramuka

Tampilan aplikasi didasarkan pada perencanaan desain yang telah dilakukan pada bab 3. Berikut merupakan implementasi dari desain aplikasi yang telah dirancang :

### 4.2.1 Tampilan Halaman Beranda

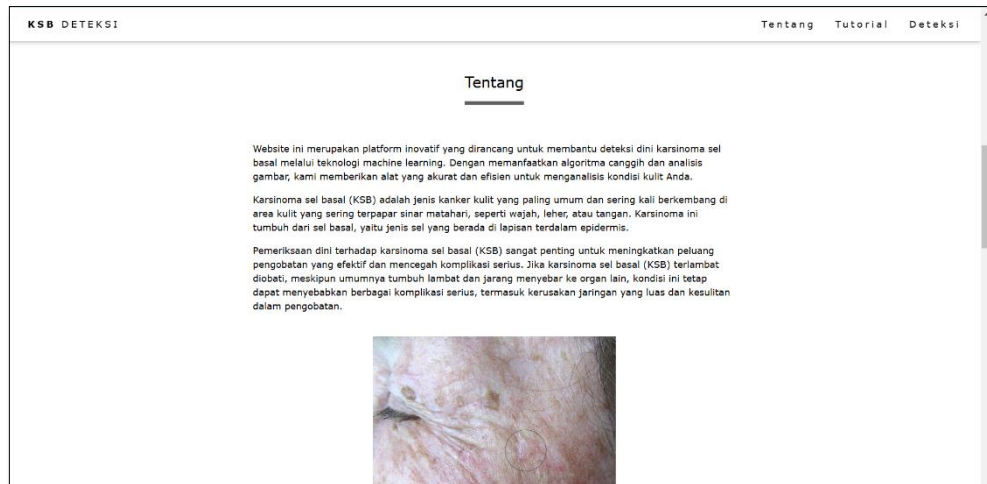
Tampilan halaman utama merupakan tampilan awal ketika aplikasi diakses. Pada halaman ini terdapat navigasi bar untuk halaman beranda dan deteksi. Halaman beranda ini menampilkan judul penelitian, tombol deteksi, dan beberapa informasi mengenai karsinoma sel basal. Menekan tombol pengguna akan mengarahkan pengguna ke halaman deteksi yang berisi fitur untuk mendeteksi penyakit karsinoma sel basal.



**Gambar 4. 12** Tampilan halaman beranda

### 4.2.2 Tampilan Halaman Tentang

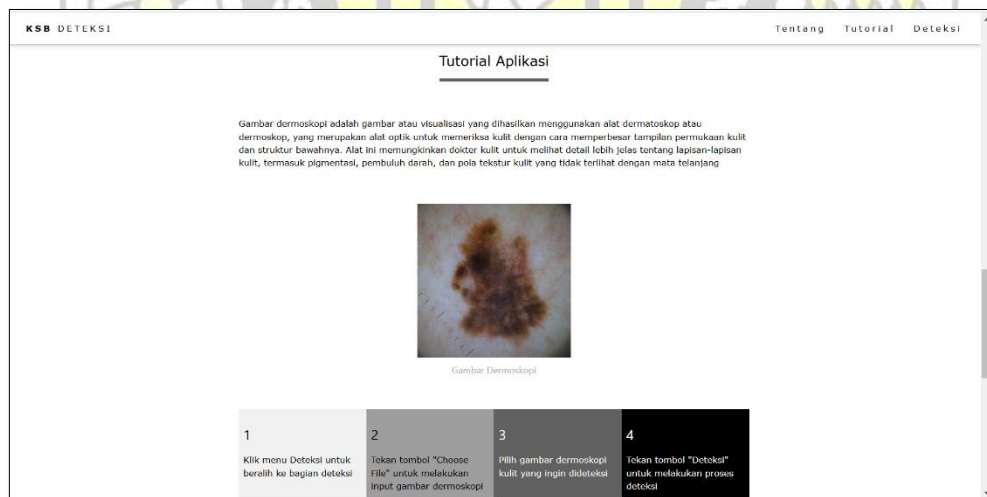
Halaman tentang berisi informasi mengenai website dan penyakit karsinoma sel basal. Melalui informasi yang ditampilkan, pengguna akan lebih mudah memahami kegunaan website, pengertian karsinoma sel basal, dan pentingnya pemeriksaan dini pada penyakit karsinoma sel basal.



**Gambar 4. 13** Tampilan halaman tentang

#### 4.2.3 Tampilan Halaman Tutorial

Pada halaman tutorial terdapat penjelasan mengenai gambar yang digunakan untuk proses deteksi, yaitu gambar dermoskopi lesi kulit karsinoma sel basal. Lalu, terdapat petunjuk penggunaan aplikasi untuk halaman deteksi yang membantu pengguna dalam penggunaan aplikasi.

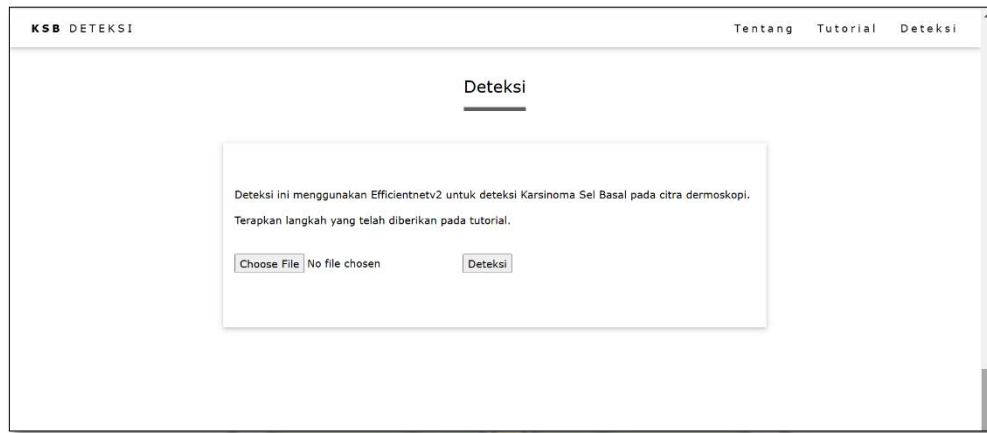


**Gambar 4. 14** Tampilan halaman tutorial

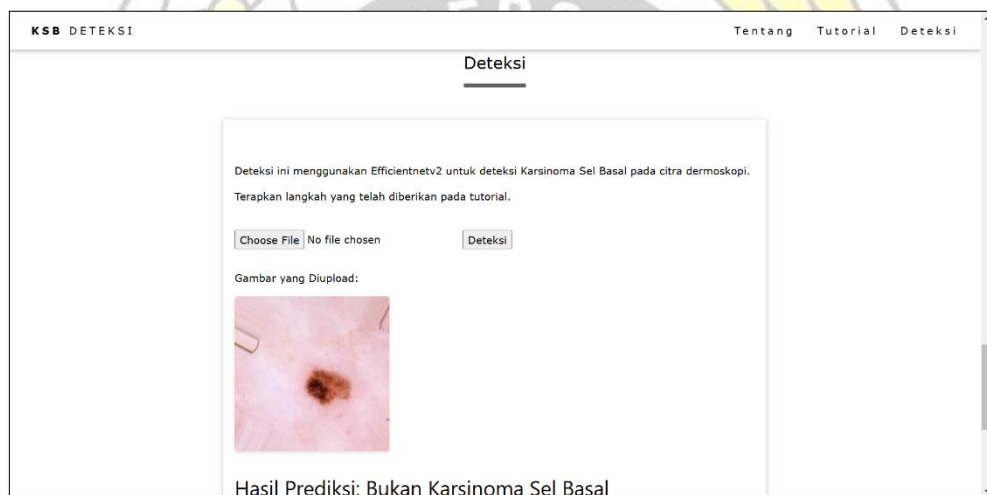
#### 4.2.4 Tampilan Halaman Deteksi

Halaman deteksi berfungsi sebagai tempat dilakukannya proses deteksi pada gambar lesi kulit. Gambar yang digunakan adalah gambar dermoskopi yang diperoleh melalui

alat yang dinamakan dermoskop. Hasil dari proses deteksi adalah karsinoma sel basal atau bukan karsinoma sel basal.



**Gambar 4. 15** Halaman deteksi



**Gambar 4. 16** Tampilan setelah proses deteksi

### 4.3 Pelatihan Sistem

Proses pelatihan sistem menerapkan arsitektur *EfficientNetV2* dan data sebanyak 11100 citra lesi kulit yang telah diaugmentasi. Banyaknya data didapatkan dari 10500 citra lesi kulit hasil augmentasi data training yang dilakukan 4 kali proses augmentasi dan 600 citra lesi kulit data validasi tanpa proses augmentasi. Sementara itu, data testing berjumlah 300 buah citra lesi kulit tidak diterapkan proses augmentasi dan tidak termasuk data untuk digunakan dalam pelatihan sistem.



**Tabel 4. 1** Data pelatihan sistem

No	Data	Data Training	Data Validation	Data Testing	Jumlah
1.	Citra Karsinoma Sel Basal	5250	300	150	5700
2.	Citra Non Karsinoma Sel Basal	5250	300	150	5700
Total Data		10500	600	300	11400

Selama proses pelatihan model, dilakukan hyperparameter tuning, dimana pada proses ini terdapat modifikasi parameter-parameter seperti jumlah epoch, ukuran batch, dan learning rate atau tingkat pembelajaran, dengan tujuan agar model pelatihan dapat mencapai tingkat optimal yang diukur berdasarkan generalisasi atau akurasi validasi dan kerugiannya, dimana semakin tinggi akurasi dan semakin rendah kerugian validasi (validation loss) maka model akan cenderung semakin baik.

Percobaan pertama menggunakan 20 epoch dengan ukuran batch sebesar 16. Pada percobaan tersebut diperoleh validation accuracy sebesar 85.24% dan validation loss sebesar 24.02%. Selanjutnya, masih dengan jumlah epoch yang sama namun dengan ukuran batch sebesar 24 didapatkan kenaikan validation accuracy menjadi 91.29% dan penurunan validation loss menjadi 20.38%. Sementara itu, dengan menggunakan epoch 20 dan ukuran batch sebesar 32, hasil yang diperoleh yaitu 85.71% untuk validation accuracy dan 24.47% untuk validation loss.

Percobaan dilanjutkan menggunakan epoch sebesar 40 serta ukuran batch sebesar 16, dimana percobaan tersebut menghasilkan validation accuracy sebesar 91.81% dan validation loss sebesar 17.61%. Percobaan kemudian dilanjutkan kembali menggunakan batch size sebesar 24 dan epoch sebesar 40, dimana percobaan ini menghasilkan validation accuracy sebesar 92.19% dan validation loss sebesar 14.23%. Percobaan terakhir menggunakan epoch sebesar 40 dan batch size sebesar 32 menghasilkan validation accuracy sebesar 94.57% dan validation loss sebesar 13.93%.

**Tabel 4. 2** Hasil uji coba epoch dan batch size

<i>Epoch</i>	<i>Batch Size</i>	<i>Vall_Acc (%)</i>	<i>Val_Loss(%)</i>
20	16	85.24	24.02
20	24	91.29	20.38
20	32	85.71	24.47
40	16	91.81	17.61
40	24	92.19	14.23
40	32	94.57	13.93

Mengacu pada eksperimen yang sudah dilakukan, didapatkan bahwa percobaan menggunakan 40 epoch dan batch size sebesar 32 memperoleh hasil yang paling optimal. Adanya keseimbangan antara validation accuracy dan validation loss menunjukkan bahwa model memiliki kemampuan yang baik dalam menggeneralisasi pola yang ada di dalam data pelatihan ke data yang belum pernah dilihat sebelumnya, yaitu data validasi. Ini berarti model tidak hanya belajar mengingat data pelatihan, namun juga mampu membuat prediksi yang akurat untuk data baru.

Penelitian ini menggunakan model hasil pelatihan sistem dengan ukuran batch sebesar 32 dan epoch sebanyak 40. Dimana setelah melakukan pelatihan dapat diambil kesimpulan bahwa epoch ke-38 memiliki nilai val\_accuracy tertinggi yaitu sebesar 0.9457.

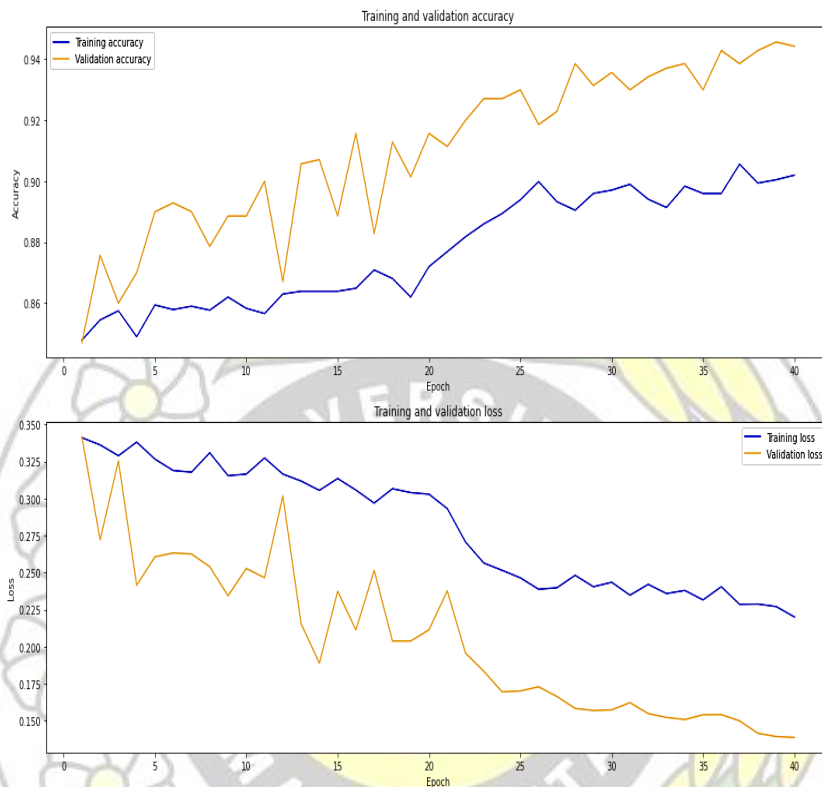
**Tabel 4. 3** Hasil epoch

<i>Epoch</i>	<i>Loss</i>	<i>Accuracy</i>	<i>Val_loss</i>	<i>Val_accuracy</i>
1.	0.3412	0.8479	0.3417	0.8471
2.	0.3363	0.8545	0.2722	0.8757
3.	0.3290	0.8575	0.3255	0.8600
4.	0.3382	0.8490	0.2415	0.8700
5.	0.3267	0.8594	0.2607	0.8900
6.	0.3190	0.8579	0.2633	0.8929
7.	0.3179	0.8590	0.2626	0.8900
8.	0.3310	0.8577	0.2540	0.8786
9.	0.3155	0.8620	0.2344	0.8886
10.	0.3166	0.8583	0.2528	0.8886
11.	0.3275	0.8566	0.2466	0.9000

12.	0.3166	0.8630	0.3018	0.8671
13.	0.3119	0.8639	0.2155	0.9057
14.	0.3056	0.8639	0.1889	0.9071
15.	0.3136	0.8639	0.2374	0.8886
16.	0.3058	0.8649	0.2113	0.9157
17.	0.2970	0.8709	0.2515	0.8829
18.	0.3067	0.8681	0.2038	0.9129
19.	0.3041	0.8620	0.2038	0.9014
20.	0.3030	0.8720	0.2114	0.9157
21.	0.2933	0.8769	0.2377	0.9114
22.	0.2707	0.8818	0.1956	0.9200
23.	0.2565	0.8860	0.1834	0.9271
24.	0.2516	0.8894	0.1695	0.9271
25.	0.2465	0.8939	0.1701	0.9300
26.	0.2388	0.8999	0.1729	0.9186
27.	0.2398	0.8933	0.1664	0.9229
28.	0.2482	0.8905	0.1583	0.9386
29.	0.2405	0.8960	0.1569	0.9314
30.	0.2435	0.8971	0.1573	0.9357
31.	0.2348	0.8990	0.1622	0.9300
32.	0.2421	0.8941	0.1548	0.9343
33.	0.2359	0.8914	0.1522	0.9371
34.	0.2380	0.8984	0.1508	0.9386
35.	0.2316	0.8960	0.1540	0.9300
36.	0.2405	0.8960	0.1541	0.9429
37.	0.2286	0.9056	0.1499	0.9386
38.	0.2271	0.9005	0.1393	0.9457
39.	0.2288	0.8994	0.1415	0.9429
40.	0.2201	0.9020	0.1387	0.9443

Setelah melalui 40 *epoch*, didapatkan akurasi validasi tertinggi terdapat pada *epoch* ke 38 yaitu sebesar 94.57%, dengan *loss validation* sebesar 13.93%. Pelatihan

model menerapkan *callback ReduceLROnPlateau*, yang bertujuan untuk memantau nilai *val\_loss* (kerugian data validasi) apakah mengalami penurunan signifikan atau tidak. Jika tidak terjadi penurunan yang signifikan selama nilai kesabaran atau *patience* yang telah ditetapkan yaitu 3 *epoch*. Pada penelitian ini, terjadi penurunan *learning rate* dari 0.0010 menjadi 0.00010 pada *epoch* ke 23



**Gambar 4. 17** Grafik tabel pelatihan sistem

#### 4.4 Pengujian Sistem

Pengujian sistem dilakukan terhadap 300 data, dapat dilihat pada lampiran penelitian ini. Pada pengujian aplikasi, terdapat 18 data yang salah diidentifikasi, yaitu 10 data pada kategori karsinoma sel basal, dan 8 data pada kategori non karsinoma sel basal. Data dengan hasil identifikasi benar sebanyak 282, 142 pada kategori karsinoma sel basal dan 140 pada kategori non karsinoma sel basal. Dengan hasil ini, dapat diketahui jumlah *true positif* (TP), *true negatif* (TN), *false positif* (FP), dan *false negatif* (FN).



		Prediksi	
		Karsinoma Sel Basal	Non Karsinoma Sel Basal
Aktual	Karsinoma Sel Basal	142	8
	Non Karsinoma Sel Basal	10	140

	TP	TN	FP	FN
karsinoma sel basal	142	0	0	8
Non karsinoma sel basal	0	140	10	0

Berdasarkan hasil pengujian tersebut, kita memiliki 282 data yang diprediksi secara tepat. Dengan nilai-nilai yang terdapat pada tabel, kita dapat melakukan perhitungan nilai Precision, Recall, dan F1-Score untuk setiap kategori.

a. Precision

Perhitungan precision dapat dihitung menggunakan rumus yang terdapat pada persamaan 2.2.

$$\text{Precision Karsinoma Sel Basal} = 142/152 \times 100 = 93.42\%$$

$$\text{Precision Non Karsinoma} = 140/150 \times 100 = 93.33\%$$

Sel Basal

b. Recall

Perhitungan recall dapat dihitung menggunakan rumus yang terdapat pada persamaan 2.3.

$$\text{Recall Karsinoma Sel Basal} = 142/150 \times 100 = 94.67\%$$

$$\text{Recall Non Karsinoma} = 140/148 \times 100 = 94.59\%$$

Sel Basal

C. F1-Score

Perhitungan F1-Score dapat dihitung menggunakan rumus yang terdapat pada persamaan 2.4.

$$\text{F1-Score Karsinoma Sel Basal} = 2 \times \frac{0.9342 \times 0.9467}{0.9342 + 0.9467} \times 100 = 94.04\%$$

$$\text{F1-Score Non Karsinoma} = 2 \times \frac{0.9333 \times 0.9459}{0.9333 + 0.9459} \times 100 = 93.96\%$$

Sel Basal

Perhitungan diatas dapat dibuat dalam bentuk tabel seperti pada tabel berikut ini:

	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>
Karsinoma Sel Basal	93.42%	94.67%	94.04%
Non Karsinoma Sel Basal	93.33%	94.59%	93.96%

Hasil pengujian mendapatkan 282 total identifikasi yang benar dari 300 data uji. Data uji tersebut terdiri dari 142 citra karsinoma sel basal dan 140 citra non karsinoma sel basal. Dari total identifikasi benar diatas, maka dapat dihitung nilai akurasi yang dapat dilihat pada persamaan 2.1.








$$\text{Akurasi} = (142+140)/300 \times 100 = 282/300 \times 100 = 94\%$$

Perhitungan di atas menunjukkan tingkat akurasi pada penelitian menggunakan arsitektur EfficientNetV2 yaitu mencapai 94%.










Dari 300 gambar yang diuji pada tahap testing, terdapat 18 gambar yang salah diprediksi dengan benar oleh model yang telah dilatih. Berdasarkan analisis dari penulis, hal ini disebabkan oleh keadaan dataset yang kurang optimal serta adanya ketidaksesuaian antara jenis preprocessing yang dilakukan dengan hasil yang diharapkan setelah proses preprocessing. Beberapa dataset gambar yang digunakan pada penelitian ini yang berasal dari HAM 10000 memiliki kualitas yang kurang baik dari segi pengambilan citra. Hal ini menyebabkan sistem kurang bisa mengidentifikasi gambar terkait. Proses preprocessing hair removal pada gambar tidak selalu memberikan hasil yang baik terhadap gambar, hal ini kemungkinan merupakan penyebab dari kesalahan prediksi atau identifikasi oleh model. Hal ini sesuai dengan kesimpulan hasil penelitian yang disampaikan oleh (soegeng, 2021) dengan judul penelitian “ *Penerapan Convolutional Neural Network untuk Klasifikasi Kanker Kulit Melanoma pada Dataset Gambar Kulit* ”. Penelitian yang dilakukan oleh (Soegeng, 2021) menggunakan gabungan dari beberapa arsitektur CNN yang digunakan untuk melakukan klasifikasi kanker kulit melanoma terhadap *dataset* ISIC 2020, didapatkan akurasi prediksi AUC sebesar 93.1%. Kekurangan dalam penelitian ini yaitu pada model yang dilatih menggunakan *dataset* yang diolah menggunakan algoritma penghapusan rambut mengalami penurunan akurasi yang disebabkan karena model mempelajari lebih banyak fitur dari kulit biasa dibanding fitur lesi kulit, sehingga diperlukan untuk menyempitkan daerah yang dipelajari.





Berikut contoh 10 gambar pertama dan 10 gambar terakhir hasil pengujian sistem :

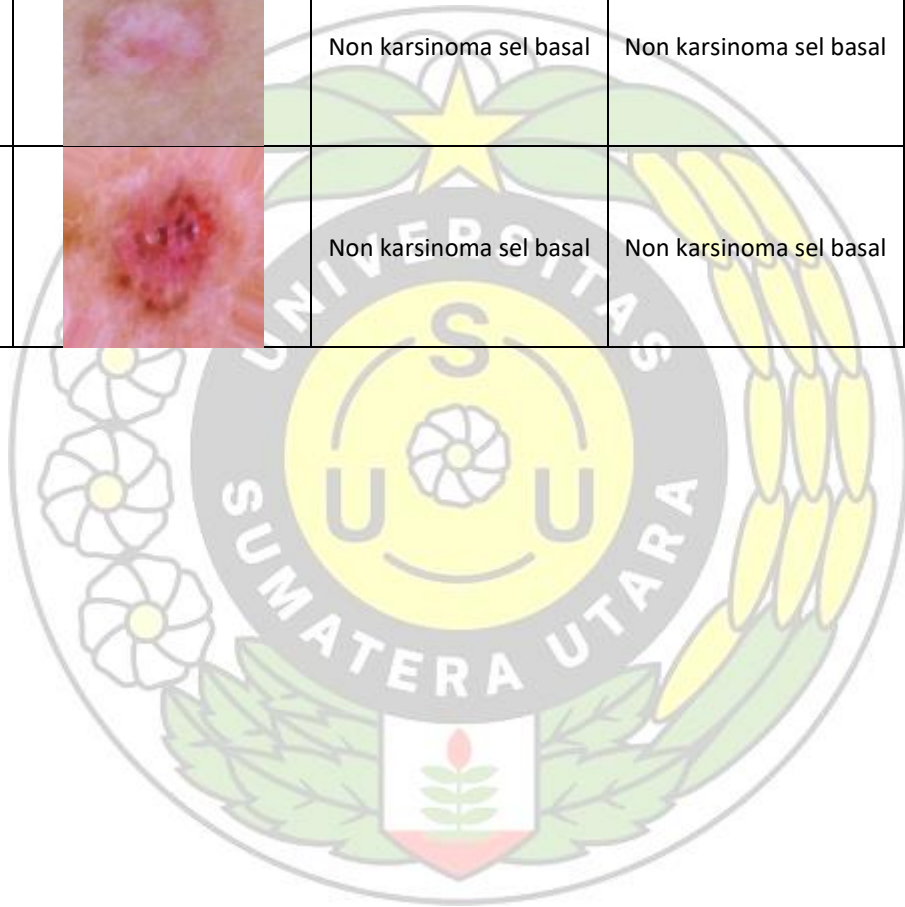
**Tabel 4. 4** Contoh hasil pengujian sistem

No	Citra	Diagnosis	Sistem	Status
1		Karsinoma sel basal	Karsinoma sel basal	Benar
2		Karsinoma sel basal	Karsinoma sel basal	Benar
3		Karsinoma sel basal	Karsinoma sel basal	Benar
4		Karsinoma sel basal	Karsinoma sel basal	Benar
5		Karsinoma sel basal	Karsinoma sel basal	Benar
6		Karsinoma sel basal	Karsinoma sel basal	Benar
7		Karsinoma sel basal	Karsinoma sel basal	Benar



8		Karsinoma sel basal	Non Karsinoma sel basal	Salah
9		Non karsinoma sel basal	Non karsinoma sel basal	Benar
10		Non karsinoma sel basal	Non karsinoma sel basal	Benar
291		Non karsinoma sel basal	Non karsinoma sel basal	Benar
292		Non karsinoma sel basal	Non karsinoma sel basal	Benar
293		Non karsinoma sel basal	Non karsinoma sel basal	Benar
294		Non karsinoma sel basal	Non karsinoma sel basal	Benar
295		Non karsinoma sel basal	Non karsinoma sel basal	Benar
296		Non karsinoma sel basal	karsinoma sel basal	Salah

297		Non karsinoma sel basal	Non karsinoma sel basal	Benar
298		Non karsinoma sel basal	Non karsinoma sel basal	Benar
299		Non karsinoma sel basal	Non karsinoma sel basal	Benar
300		Non karsinoma sel basal	Non karsinoma sel basal	Benar



## **BAB 5**

### **KESIMPULAN DAN SARAN**

#### **5.1 Kesimpulan**

Kesimpulan yang didapatkan dari penelitian ini, berdasarkan hasil dan pengujian sistem karsinoma sel basal melalui citra dermoskopi dengan arsitektur EfficientNetV2 yang telah dilakukan adalah:

1. Penerapan metode segmentasi pada dataset dapat meningkatkan hasil akurasi pada sistem.
2. Arsitektur EfficientNetV2 yang digunakan dalam ekstraksi fitur terbukti memiliki kinerja yang optimal. Hal ini ditunjukkan dengan diperolehnya akurasi sebesar 94%

#### **5.2 Saran**

Adapun terdapat beberapa saran yang dapat diterapkan untuk pengembangan penelitian selanjutnya, yaitu:

1. Penelitian selanjutnya diharapkan untuk menambah *dataset* untuk kategori non karsinoma sel basal seperti dermatofibroma, dan vascular.
2. Penelitian selanjutnya diharapkan menambahkan parameter lain seperti ketebalan lesi kulit.
3. Penelitian selanjutnya diharapkan membuat sistem untuk dapat mengklasifikasi tingkat stadium pada penyakit karsinoma sel basal.

## DAFTAR PUSTAKA

- Alom, M. Z., Taha, T. M., Yakopcic, C., Westberg, S., Sidike, P., Nasrin, M. S., Hasan, M., Van Essen, B. C., Awwal, A. A. S., & Asari, V. K. (2019). A state-of-the-art survey on deep learning theory and architectures. *Electronics (Switzerland)*, 8(3). <https://doi.org/10.3390/electronics8030292>
- Fakhrosa, I., Krishna Sutedja, E., Hadi Agusni, J., Feriza, V., Ayu Saraswati, N., Ilmu Kesehatan Kulit dan Kelamin, D., & dr Hasan sadikin, R. (2018). *Tinjauan Pustaka: Manifestasi Klinis dan Gambaran Dermoskopi pada Karsinoma Sel Basal* (Vol. 8, Issue 2).
- Friday, J., Burdick, J., Atlantic, F., Marques, O., Romero López, A., Giró-I-Nieto, X., & Hypothesis, J. W. (n.d.). *SIIM 2017 Scientific Session Analytics & Deep Learning Part 3 The Impact of Segmentation on the Accuracy and Sensitivity of a Melanoma Classifier Based on Skin Lesion Images*.
- ICCC. (2019). *Sekilas Kanker Kulit*. ICC. <https://iccc.id/sekilas-kanker-kulit>
- Koehoorn, J., Sobiecki, A., Rauber, P., Jalba, A., & Telea, A. (2016). Efficient and Effective Automated Digital Hair Removal from Dermoscopy Images. *Mathematical Morphology - Theory and Applications*, 1(1). <https://doi.org/10.1515/mathm-2016-0001>
- Kurniawan Soegeng, M., & Noertjahyana, A. (n.d.). *Penerapan Convolutional Neural Network untuk Klasifikasi Kanker Kulit Melanoma pada Dataset Gambar Kulit*.
- Lee, M. J., Yang, M. K., Khwarg, S. I., Oh, E. K., Choi, Y. J., Kim, N., Choung, H., Seo, C. W., Ha, Y. J., Cho, M. H., & Cho, B. J. (2023). Differentiating malignant and benign eyelid lesions using deep learning. *Scientific Reports*, 13(1). <https://doi.org/10.1038/s41598-023-30699-5>
- Li, Z., Liu, F., Yang, W., Peng, S., & Zhou, J. (2022). A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects. *Transactions on Neural*



*Networks and Learning Systems*, 33(12), 6999–7019.  
<https://doi.org/10.1109/TNNLS.2021.3084827>

McDaniel, B., Badri, T., & Steele, R. B. (2024). *Basal Cell Carcinoma*. National Center for Biotechnology Information.  
<https://www.ncbi.nlm.nih.gov/books/NBK482439/>

Pane, M. D. C. (2024). *Karsinoma Sel Basal*. Alodokter.  
<https://www.alodokter.com/karsinoma-sel-basal>

Papiththira, S., & Kokul, T. (2021). Melanoma Skin Cancer Detection Using EfficientNet and Channel Attention Module. *2021 16th International Conference on Industrial and Information Systems, 2021 - Proceedings*, 227–232.  
<https://doi.org/10.1109/ICIIS53135.2021.9660759>

Sitorus, E. P., & Julianto, I. (2018). Teknik–teknik Biopsi Kulit. *Cermin Dunia Kedokteran*. <https://cdkjournal.com/index.php/cdk/article/view/780>

Tan, M., & Le, Q. V. (2021). EfficientNetV2: Smaller Models and Faster Training. *Proceedings of Machine Learning Research*, 139, 10096–10106.

TAN, S. T., Ghaznawie, M., & Reginata, G. (2016). Deteksi Dini Karsinoma Sel Basal. *Indonesian Journal of Cancer*, 10(2), 61. <https://doi.org/10.33371/ijoc.v10i2.428>

Tan, S. T., & Reginata, G. (2015). Continuing Medical Education Diagnosis dan Tatalaksana Karsinoma Sel Basal. *Cdk Journal*.  
<http://www.cdkjournal.com/index.php/CDK/article/view/932/664>

Taruno, P. E. N., Nugraha, G. S., Dwiyanaputra, R., & Bimantoro, F. (2023). Monkeypox Classification based on Skin Images using CNN: EfficientNet-B0. *E3S Web of Conferences*, 465. <https://doi.org/10.1051/e3sconf/202346502031>








Zafra Moran, R. J., López Loaiza, E. F., Tumi Alarcón, N. G., & Lezama Gonzales, P. M. (2023). Modelo de Red Neuronal Convolutacional para la Detección de Carcinoma Basocelular. *Revista de Investigación de Sistemas e Informática*, 16(2), 33–41. <https://doi.org/10.15381/risi.v16i2.25773>







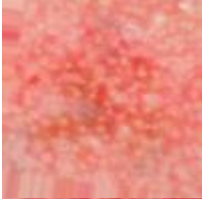












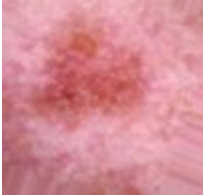
Zhou, X. (2018). Understanding the Convolutional Neural Networks with Gradient Descent and Backpropagation. *Journal of Physics: Conference Series*, 1004(1). <https://doi.org/10.1088/1742-6596/1004/1/012028>









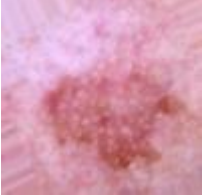


### Lampiran Hasil Pengujian Sistem



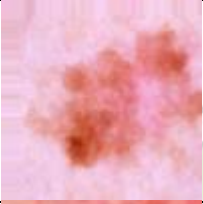




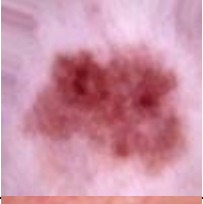
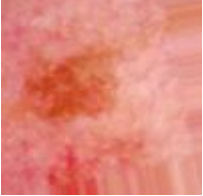
No	Citra	Diagnosis	Sistem	Status
1		Karsinoma sel basal	Karsinoma sel basal	Benar
2		Karsinoma sel basal	Karsinoma sel basal	Benar
3		Karsinoma sel basal	Karsinoma sel basal	Benar
4		Karsinoma sel basal	Karsinoma sel basal	Benar
5		Karsinoma sel basal	Karsinoma sel basal	Benar
6		Karsinoma sel basal	Karsinoma sel basal	Benar
7		Karsinoma sel basal	Karsinoma sel basal	Benar

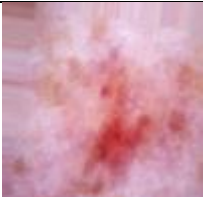








8		Karsinoma sel basal	Karsinoma sel basal	Benar
9		Karsinoma sel basal	Karsinoma sel basal	Benar
10		Karsinoma sel basal	Karsinoma sel basal	Benar
11		Karsinoma sel basal	Karsinoma sel basal	Benar
12		Karsinoma sel basal	Karsinoma sel basal	Benar
13		Karsinoma sel basal	Karsinoma sel basal	Benar
14		Karsinoma sel basal	Karsinoma sel basal	Benar
15		Karsinoma sel basal	Karsinoma sel basal	Benar
16		Karsinoma sel basal	Karsinoma sel basal	Benar










17		Karsinoma sel basal	Karsinoma sel basal	Benar
18		Karsinoma sel basal	Karsinoma sel basal	Benar
19		Karsinoma sel basal	Karsinoma sel basal	Benar
20		Karsinoma sel basal	Karsinoma sel basal	Benar
21		Karsinoma sel basal	Karsinoma sel basal	Benar
22		Karsinoma sel basal	Karsinoma sel basal	Benar
23		Karsinoma sel basal	Karsinoma sel basal	Salah
24		Karsinoma sel basal	Non Karsinoma sel basal	Salah
25		Karsinoma sel basal	Karsinoma sel basal	Benar

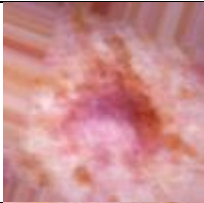








26		Karsinoma sel basal	Karsinoma sel basal	Benar
27		Karsinoma sel basal	Karsinoma sel basal	Benar
28		Karsinoma sel basal	Karsinoma sel basal	Benar
29		Karsinoma sel basal	Karsinoma sel basal	Benar
30		Karsinoma sel basal	Non Karsinoma sel basal	Salah
31		Karsinoma sel basal	Karsinoma sel basal	Benar
32		Karsinoma sel basal	Karsinoma sel basal	Benar
33		Karsinoma sel basal	Karsinoma sel basal	Benar
34		Karsinoma sel basal	Karsinoma sel basal	Benar



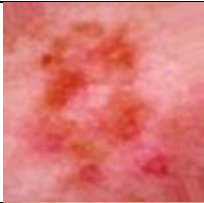
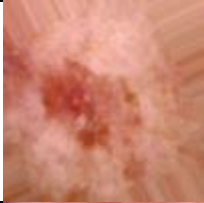







35		Karsinoma sel basal	Karsinoma sel basal	Benar
36		Karsinoma sel basal	Karsinoma sel basal	Benar
37		Karsinoma sel basal	Karsinoma sel basal	Benar
38		Karsinoma sel basal	Karsinoma sel basal	Benar
39		Karsinoma sel basal	Karsinoma sel basal	Benar
40		Karsinoma sel basal	Karsinoma sel basal	Benar
41		Karsinoma sel basal	Karsinoma sel basal	Benar
42		Karsinoma sel basal	Karsinoma sel basal	Benar
43		Karsinoma sel basal	Karsinoma sel basal	Benar

44		Karsinoma sel basal	Karsinoma sel basal	Benar
45		Karsinoma sel basal	Karsinoma sel basal	Benar
46		Karsinoma sel basal	Karsinoma sel basal	Benar
47		Karsinoma sel basal	Karsinoma sel basal	Benar
48		Karsinoma sel basal	Karsinoma sel basal	Benar
49		Karsinoma sel basal	Non Karsinoma sel basal	Salah
50		Karsinoma sel basal	Karsinoma sel basal	Benar
51		Karsinoma sel basal	Karsinoma sel basal	Benar
52		Karsinoma sel basal	Karsinoma sel basal	Benar



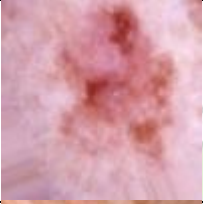



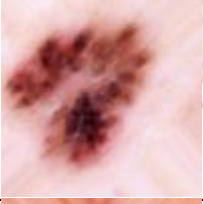


53		Karsinoma sel basal	Karsinoma sel basal	Benar
54		Karsinoma sel basal	Karsinoma sel basal	Benar
55		Karsinoma sel basal	Karsinoma sel basal	Benar
56		Karsinoma sel basal	Karsinoma sel basal	Benar
57		Karsinoma sel basal	Karsinoma sel basal	Benar
58		Karsinoma sel basal	Karsinoma sel basal	Benar
59		Karsinoma sel basal	Karsinoma sel basal	Benar
60		Karsinoma sel basal	Karsinoma sel basal	Benar
61		Karsinoma sel basal	Non Karsinoma sel basal	Salah

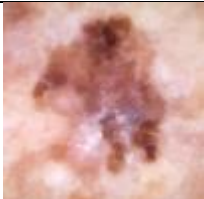

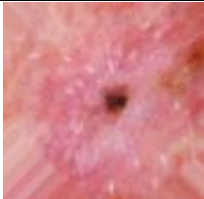





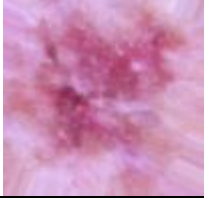
62		Karsinoma sel basal	Karsinoma sel basal	Benar
63		Karsinoma sel basal	Karsinoma sel basal	Benar
64		Karsinoma sel basal	Karsinoma sel basal	Benar
65		Karsinoma sel basal	Karsinoma sel basal	Benar
66		Karsinoma sel basal	Karsinoma sel basal	Benar
67		Karsinoma sel basal	Karsinoma sel basal	Benar
68		Karsinoma sel basal	Karsinoma sel basal	Benar
69		Karsinoma sel basal	Karsinoma sel basal	Benar
70		Karsinoma sel basal	Karsinoma sel basal	Benar

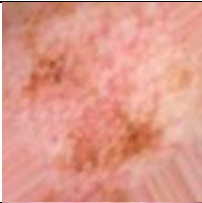



















71		Karsinoma sel basal	Karsinoma sel basal	Benar
72		Karsinoma sel basal	Karsinoma sel basal	Benar
73		Karsinoma sel basal	Non Karsinoma sel basal	Salah
74		Karsinoma sel basal	Karsinoma sel basal	Benar
75		Karsinoma sel basal	Karsinoma sel basal	Benar
76		Karsinoma sel basal	Karsinoma sel basal	Benar
77		Karsinoma sel basal	Karsinoma sel basal	Benar
78		Karsinoma sel basal	Karsinoma sel basal	Benar
79		Karsinoma sel basal	Karsinoma sel basal	Benar



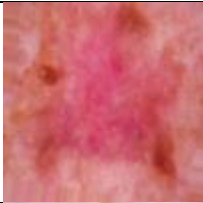








80		Karsinoma sel basal	Karsinoma sel basal	Benar
81		Karsinoma sel basal	Karsinoma sel basal	Benar
82		Karsinoma sel basal	Karsinoma sel basal	Benar
83		Karsinoma sel basal	Karsinoma sel basal	Benar
84		Karsinoma sel basal	Non Karsinoma sel basal	Salah
85		Karsinoma sel basal	Karsinoma sel basal	Benar
86		Karsinoma sel basal	Karsinoma sel basal	Benar
87		Karsinoma sel basal	Karsinoma sel basal	Benar
88		Karsinoma sel basal	Karsinoma sel basal	Benar

89		Karsinoma sel basal	Karsinoma sel basal	Benar
90		Karsinoma sel basal	Karsinoma sel basal	Benar
91		Karsinoma sel basal	Karsinoma sel basal	Benar
92		Karsinoma sel basal	Karsinoma sel basal	Benar
93		Karsinoma sel basal	Karsinoma sel basal	Benar
94		Karsinoma sel basal	Karsinoma sel basal	Benar
95		Karsinoma sel basal	Karsinoma sel basal	Benar
96		Karsinoma sel basal	Karsinoma sel basal	Benar
97		Karsinoma sel basal	Karsinoma sel basal	Benar



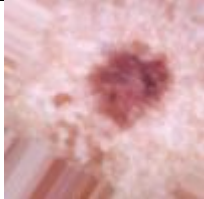






98		Karsinoma sel basal	Karsinoma sel basal	Benar
99		Karsinoma sel basal	Karsinoma sel basal	Benar
100		Karsinoma sel basal	Karsinoma sel basal	Benar
101		Karsinoma sel basal	Karsinoma sel basal	Benar
102		Karsinoma sel basal	Karsinoma sel basal	Benar
103		Karsinoma sel basal	Karsinoma sel basal	Benar
104		Karsinoma sel basal	Karsinoma sel basal	Benar
105		Karsinoma sel basal	Karsinoma sel basal	Benar
106		Karsinoma sel basal	Karsinoma sel basal	Benar






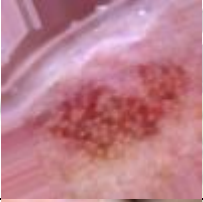

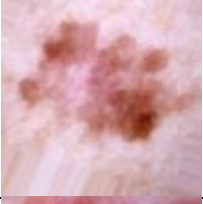

107		Karsinoma sel basal	Karsinoma sel basal	Benar
108		Karsinoma sel basal	Karsinoma sel basal	Benar
109		Karsinoma sel basal	Karsinoma sel basal	Benar
110		Karsinoma sel basal	Karsinoma sel basal	Benar
111		Karsinoma sel basal	Non Karsinoma sel basal	Salah
112		Karsinoma sel basal	Karsinoma sel basal	Benar
113		Karsinoma sel basal	Karsinoma sel basal	Benar
114		Karsinoma sel basal	Karsinoma sel basal	Benar
115		Karsinoma sel basal	Karsinoma sel basal	Benar









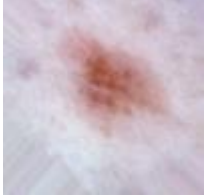


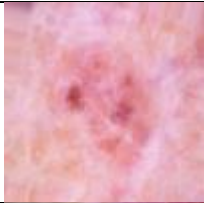








116		Karsinoma sel basal	Karsinoma sel basal	Benar
117		Karsinoma sel basal	Karsinoma sel basal	Benar
118		Karsinoma sel basal	Karsinoma sel basal	Benar
119		Karsinoma sel basal	Karsinoma sel basal	Benar
120		Karsinoma sel basal	Karsinoma sel basal	Benar
121		Karsinoma sel basal	Karsinoma sel basal	Benar
122		Karsinoma sel basal	Karsinoma sel basal	Benar
123		Karsinoma sel basal	Karsinoma sel basal	Benar
124		Karsinoma sel basal	Karsinoma sel basal	Benar



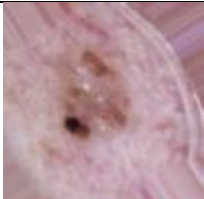



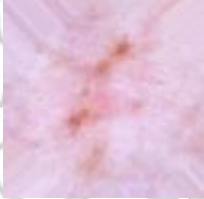

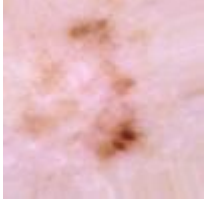


125		Karsinoma sel basal	Karsinoma sel basal	Benar
126		Karsinoma sel basal	Karsinoma sel basal	Benar
127		Karsinoma sel basal	Karsinoma sel basal	Benar
128		Karsinoma sel basal	Karsinoma sel basal	Benar
129		Karsinoma sel basal	Karsinoma sel basal	Benar
130		Karsinoma sel basal	Karsinoma sel basal	Benar
131		Karsinoma sel basal	Non Karsinoma sel basal	Salah
132		Karsinoma sel basal	Karsinoma sel basal	Benar
133		Karsinoma sel basal	Karsinoma sel basal	Benar

134		Karsinoma sel basal	Karsinoma sel basal	Benar
135		Karsinoma sel basal	Karsinoma sel basal	Benar
136		Karsinoma sel basal	Karsinoma sel basal	Benar
137		Karsinoma sel basal	Karsinoma sel basal	Benar
138		Karsinoma sel basal	Karsinoma sel basal	Benar
139		Karsinoma sel basal	Karsinoma sel basal	Benar
140		Karsinoma sel basal	Karsinoma sel basal	Benar
141		Karsinoma sel basal	Karsinoma sel basal	Benar
142		Karsinoma sel basal	Karsinoma sel basal	Benar



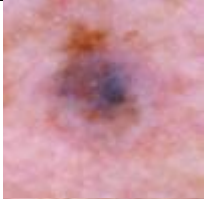






143		Karsinoma sel basal	Karsinoma sel basal	Benar
144		Karsinoma sel basal	Karsinoma sel basal	Benar
145		Karsinoma sel basal	Karsinoma sel basal	Benar
146		Karsinoma sel basal	Karsinoma sel basal	Benar
147		Karsinoma sel basal	Karsinoma sel basal	Benar
148		Karsinoma sel basal	Karsinoma sel basal	Benar
149		Karsinoma sel basal	Karsinoma sel basal	Benar
150		Karsinoma sel basal	Karsinoma sel basal	Benar
151		Non karsinoma sel basal	Non karsinoma sel basal	Benar





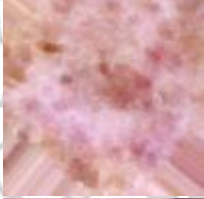




152		Non karsinoma sel basal	Non karsinoma sel basal	Benar
153		Non karsinoma sel basal	Non karsinoma sel basal	Benar
154		Non karsinoma sel basal	Non karsinoma sel basal	Benar
155		Non karsinoma sel basal	Non karsinoma sel basal	Benar
156		Non karsinoma sel basal	Non karsinoma sel basal	Benar
157		Non karsinoma sel basal	Non karsinoma sel basal	Benar
158		Non karsinoma sel basal	Non karsinoma sel basal	Benar
159		Non karsinoma sel basal	Non karsinoma sel basal	Benar
160		Non karsinoma sel basal	Non karsinoma sel basal	Benar

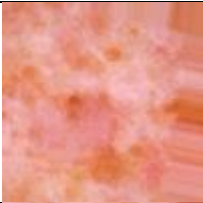














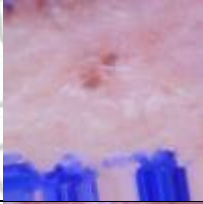


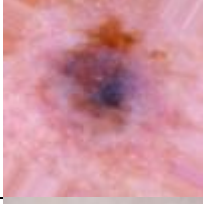

161		Non karsinoma sel basal	Non karsinoma sel basal	Benar
162		Non karsinoma sel basal	Non karsinoma sel basal	Benar
163		Non karsinoma sel basal	Non karsinoma sel basal	Benar
164		Non karsinoma sel basal	Non karsinoma sel basal	Benar
165		Non karsinoma sel basal	Non karsinoma sel basal	Benar
166		Non karsinoma sel basal	Non karsinoma sel basal	Benar
167		Non karsinoma sel basal	Non karsinoma sel basal	Benar
168		Non karsinoma sel basal	karsinoma sel basal	Salah
169		Non karsinoma sel basal	Non karsinoma sel basal	Benar












170			Non karsinoma sel basal	Non karsinoma sel basal	Benar
171			Non karsinoma sel basal	Non karsinoma sel basal	Benar
172			Non karsinoma sel basal	Non karsinoma sel basal	Benar
173			Non karsinoma sel basal	Non karsinoma sel basal	Benar
174			Non karsinoma sel basal	Non karsinoma sel basal	Benar
175			Non karsinoma sel basal	Non karsinoma sel basal	Benar
176			Non karsinoma sel basal	Non karsinoma sel basal	Benar
177			Non karsinoma sel basal	Non karsinoma sel basal	Benar
178			Non karsinoma sel basal	Non karsinoma sel basal	Benar

179		Non karsinoma sel basal	Non karsinoma sel basal	Benar
180		Non karsinoma sel basal	Non karsinoma sel basal	Benar
181		Non karsinoma sel basal	Non karsinoma sel basal	Benar
182		Non karsinoma sel basal	Non karsinoma sel basal	Benar
183		Non karsinoma sel basal	Non karsinoma sel basal	Benar
184		Non karsinoma sel basal	Non karsinoma sel basal	Benar
185		Non karsinoma sel basal	karsinoma sel basal	Salah
186		Non karsinoma sel basal	Non karsinoma sel basal	Benar
187		Non karsinoma sel basal	Non karsinoma sel basal	Benar







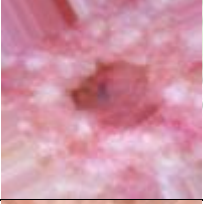


188		Non karsinoma sel basal	Non karsinoma sel basal	Benar
189		Non karsinoma sel basal	Non karsinoma sel basal	Benar
190		Non karsinoma sel basal	Non karsinoma sel basal	Benar
191		Non karsinoma sel basal	karsinoma sel basal	Salah
192		Non karsinoma sel basal	Non karsinoma sel basal	Benar
193		Non karsinoma sel basal	Non karsinoma sel basal	Benar
194		Non karsinoma sel basal	Non karsinoma sel basal	Benar
195		Non karsinoma sel basal	Non karsinoma sel basal	Benar
196		Non karsinoma sel basal	Non karsinoma sel basal	Benar










197		Non karsinoma sel basal	karsinoma sel basal	Salah
198		Non karsinoma sel basal	Non karsinoma sel basal	Benar
199		Non karsinoma sel basal	Non karsinoma sel basal	Benar
200		Non karsinoma sel basal	Non karsinoma sel basal	Benar
201		Non karsinoma sel basal	Non karsinoma sel basal	Benar
202		Non karsinoma sel basal	Non karsinoma sel basal	Benar
203		Non karsinoma sel basal	Non karsinoma sel basal	Benar
204		Non karsinoma sel basal	Non karsinoma sel basal	Benar
205		Non karsinoma sel basal	Non karsinoma sel basal	Benar












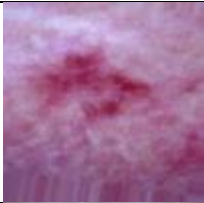








206		Non karsinoma sel basal	Non karsinoma sel basal	Benar
207		Non karsinoma sel basal	Non karsinoma sel basal	Benar
208		Non karsinoma sel basal	Non karsinoma sel basal	Benar
209		Non karsinoma sel basal	Non karsinoma sel basal	Benar
210		Non karsinoma sel basal	Non karsinoma sel basal	Benar
211		Non karsinoma sel basal	Non karsinoma sel basal	Benar
212		Non karsinoma sel basal	Non karsinoma sel basal	Benar
213		Non karsinoma sel basal	Non karsinoma sel basal	Benar
214		Non karsinoma sel basal	Non karsinoma sel basal	Benar



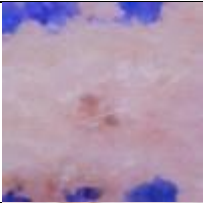








215		Non karsinoma sel basal	Non karsinoma sel basal	Benar
216		Non karsinoma sel basal	Non karsinoma sel basal	Benar
217		Non karsinoma sel basal	Non karsinoma sel basal	Benar
218		Non karsinoma sel basal	Non karsinoma sel basal	Benar
219		Non karsinoma sel basal	Non karsinoma sel basal	Benar
220		Non karsinoma sel basal	Non karsinoma sel basal	Benar
221		Non karsinoma sel basal	karsinoma sel basal	Salah
222		Non karsinoma sel basal	Non karsinoma sel basal	Benar
223		Non karsinoma sel basal	Non karsinoma sel basal	Benar








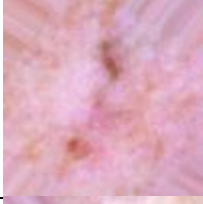

224		Non karsinoma sel basal	Non karsinoma sel basal	Benar
225		Non karsinoma sel basal	Non karsinoma sel basal	Benar
226		Non karsinoma sel basal	Non karsinoma sel basal	Benar
227		Non karsinoma sel basal	Non karsinoma sel basal	Benar
228		Non karsinoma sel basal	Non karsinoma sel basal	Benar
229		Non karsinoma sel basal	Non karsinoma sel basal	Benar
230		Non karsinoma sel basal	Non karsinoma sel basal	Benar
231		Non karsinoma sel basal	Non karsinoma sel basal	Benar
232		Non karsinoma sel basal	Non karsinoma sel basal	Benar








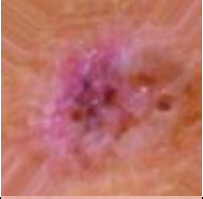

233		Non karsinoma sel basal	Non karsinoma sel basal	Benar
234		Non karsinoma sel basal	Non karsinoma sel basal	Benar
235		Non karsinoma sel basal	karsinoma sel basal	Salah
236		Non karsinoma sel basal	Non karsinoma sel basal	Benar
237		Non karsinoma sel basal	Non karsinoma sel basal	Benar
238		Non karsinoma sel basal	Non karsinoma sel basal	Benar
239		Non karsinoma sel basal	Non karsinoma sel basal	Benar
240		Non karsinoma sel basal	Non karsinoma sel basal	Benar
241		Non karsinoma sel basal	Non karsinoma sel basal	Benar










242			Non karsinoma sel basal	Non karsinoma sel basal	Benar
243			Non karsinoma sel basal	Non karsinoma sel basal	Benar
244			Non karsinoma sel basal	Non karsinoma sel basal	Benar
245			Non karsinoma sel basal	Non karsinoma sel basal	Benar
246			Non karsinoma sel basal	Non karsinoma sel basal	Benar
247			Non karsinoma sel basal	Non karsinoma sel basal	Benar
248			Non karsinoma sel basal	Non karsinoma sel basal	Benar
249			Non karsinoma sel basal	Non karsinoma sel basal	Benar
250			Non karsinoma sel basal	Non karsinoma sel basal	Benar



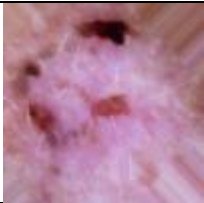
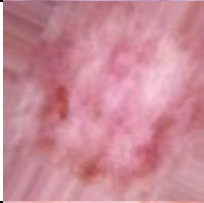



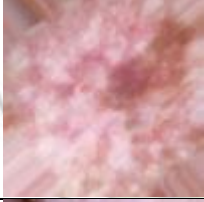



251		Non karsinoma sel basal	Non karsinoma sel basal	Benar
252		Non karsinoma sel basal	Non karsinoma sel basal	Benar
253		Non karsinoma sel basal	Non karsinoma sel basal	Benar
254		Non karsinoma sel basal	Non karsinoma sel basal	Benar
255		Non karsinoma sel basal	Non karsinoma sel basal	Benar
256		Non karsinoma sel basal	Non karsinoma sel basal	Benar
257		Non karsinoma sel basal	Non karsinoma sel basal	Benar
258		Non karsinoma sel basal	Non karsinoma sel basal	Benar
259		Non karsinoma sel basal	Non karsinoma sel basal	Benar

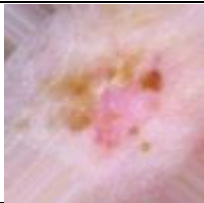
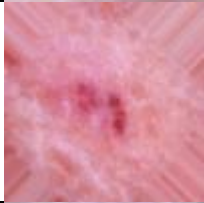
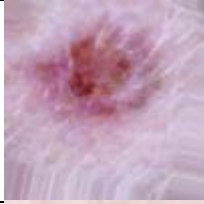


260		Non karsinoma sel basal	Non karsinoma sel basal	Benar
261		Non karsinoma sel basal	Non karsinoma sel basal	Benar
262		Non karsinoma sel basal	Non karsinoma sel basal	Benar
263		Non karsinoma sel basal	Non karsinoma sel basal	Benar
264		Non karsinoma sel basal	Non karsinoma sel basal	Benar
265		Non karsinoma sel basal	Non karsinoma sel basal	Benar
266		Non karsinoma sel basal	Non karsinoma sel basal	Benar
267		Non karsinoma sel basal	Non karsinoma sel basal	Benar
268		Non karsinoma sel basal	Non karsinoma sel basal	Benar

269		Non karsinoma sel basal	Non karsinoma sel basal	Benar
270		Non karsinoma sel basal	Non karsinoma sel basal	Benar
271		Non karsinoma sel basal	Non karsinoma sel basal	Benar
272		Non karsinoma sel basal	Non karsinoma sel basal	Benar
273		Non karsinoma sel basal	Non karsinoma sel basal	Benar
274		Non karsinoma sel basal	Non karsinoma sel basal	Benar
275		Non karsinoma sel basal	Non karsinoma sel basal	Benar
276		Non karsinoma sel basal	karsinoma sel basal	Salah
277		Non karsinoma sel basal	Non karsinoma sel basal	Benar

278		Non karsinoma sel basal	Non karsinoma sel basal	Benar
279		Non karsinoma sel basal	Non karsinoma sel basal	Benar
280		Non karsinoma sel basal	Non karsinoma sel basal	Benar
281		Non karsinoma sel basal	Non karsinoma sel basal	Benar
282		Non karsinoma sel basal	Non karsinoma sel basal	Benar
283		Non karsinoma sel basal	Non karsinoma sel basal	Benar
284		Non karsinoma sel basal	Non karsinoma sel basal	Benar
285		Non karsinoma sel basal	Non karsinoma sel basal	Benar
286		Non karsinoma sel basal	Non karsinoma sel basal	Benar



287		Non karsinoma sel basal	Non karsinoma sel basal	Benar
288		Non karsinoma sel basal	Non karsinoma sel basal	Benar
289		Non karsinoma sel basal	Non karsinoma sel basal	Benar
290		Non karsinoma sel basal	Non karsinoma sel basal	Benar
291		Non karsinoma sel basal	karsinoma sel basal	Salah
292		Non karsinoma sel basal	Non karsinoma sel basal	Benar
293		Non karsinoma sel basal	Non karsinoma sel basal	Benar
294		Non karsinoma sel basal	Non karsinoma sel basal	Benar
295		Non karsinoma sel basal	Non karsinoma sel basal	Benar

296		Non karsinoma sel basal	Non karsinoma sel basal	Benar
297		Non karsinoma sel basal	Non karsinoma sel basal	Benar
298		Non karsinoma sel basal	karsinoma sel basal	Salah
299		Non karsinoma sel basal	Non karsinoma sel basal	Benar
300		Non karsinoma sel basal	karsinoma sel basal	Salah

