

**KLASIFIKASI JENIS TANAMAN SAYURAN SELADA
MENGGUNAKAN METODE *TRANSFER LEARNING***

SKRIPSI

VINCENT SIRAIT

191402081



**PROGRAM STUDI S1 TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA
MEDAN
2024**

**KLASIFIKASI JENIS TANAMAN SAYURAN SELADA MENGGUNAKAN
METODE TRANSFER LEARNING**

SKRIPSI

**Diajukan untuk melengkapi tugas dan memenuhi syarat memperoleh ijazah
Sarjana Teknologi Informasi**

VINCENT SIRAIT

191402081



**PROGRAM STUDI S1 TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA
MEDAN
2024**

PERSETUJUAN

Judul : KLASIFIKASI JENIS TANAMAN SAYURAN
SELADA MENGGUNAKAN METODE
TRANSFER LEARNING

Kategori : SKRIPPSI

Nama Mahasiswa : VINCENT SIRAIT

Nomor Induk Mahasiswa : 191402081

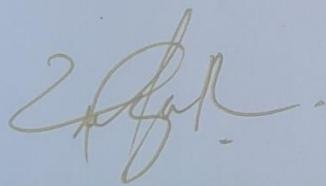
Program Studi : SARJANA (S-1) TEKNOLOGI INFORMASI

Fakultas : ILMU KOMPUTER DAN TEKNOLOGI
INFORMASI

Medan, 21 Mei 2024

Komisi Pembimbing:

Pembimbing 2



Umaya Ramadhani Putri Nasution
S.TI., M.Kom.
NIP. 199104112021022001

Pembimbing 1,



Mohammad Fadly Syah Putra
M.Sc.
NIP. 198301292009121003

Diketahui/disetujui oleh
Program Studi S1 Teknologi Informasi
Ketua,



Dedy Arisandi, S.Kom, M.Kom
NIP. 197908312009121002

PERNYATAAN**KLASIFIKASI JENIS TANAMAN SAYURAN SELADA MENGGUNAKAN
METODE *TRANSFER LEARNING*****SKRIPSI**

Saya mengakui bahwa skripsi ini adalah hasil karya saya sendiri, kecuali beberapa kutipan dan ringkasan yang masing-masing telah disebutkan sumbernya.

Medan, 21 Mei 2024



Vincent Sirait

191402081

UCAPAN TERIMAKASIH

Puji dan Syukur kepada Tuhan Yang Maha Esa, yang senantiasa memberikan berkat, rahmat, dan karunia-Nya, sehingga penulis dapat menyelesaikan skripsi ini sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer dari Program Studi S1 Teknologi Informasi, Fakultas Ilmu Komputer dan Teknologi Informasi, Universitas Sumatera Utara.

Dalam proses menyelesaikan penulisan tugas akhir ini, penulis telah menerima banyak bimbingan, dukungan, bantuan, serta doa dari berbagai pihak. Pada kesempatan ini, penulis ingin mengucapkan terima kasih kepada:

1. Ibu Dr. Maya Silvi Lydia, B.Sc., M.Sc. selaku Dekan Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Sumatera Utara.
2. Bapak Dedy Arisandi ST., M.Kom. selaku Ketua Program Studi S1 Teknologi Informasi Universitas Sumatera Utara.
3. Bapak Mohammad Fadly Syah Putra M.Sc selaku Dosen Pembimbing 1 yang telah banyak membimbing dan mengarahkan , serta memberikan saran pada penulis dalam proses penggerjaan skripsi ini.
4. Ibu Umaya Ramadhani Putri Nasution S.TI., M.Kom. selaku Dosen Pembimbing 2 yang juga sangat banyak membantu penulis dalam membimbing serta memberi saran dan arahan dalam proses penggerjaan skripsi.
5. Seluruh Dosen Program Studi S1 Teknologi Informasi Sumatera Utara yang telah mengajar dan memberikan ilmu yang berguna selama masa perkuliahan penulis.
6. Keluarga penulis, Bapak Rudol dan Ibu Morta Manullang selaku orang tua penulis yang telah mendidik dan membesarakan penulis, selalu memberikan semangat dan doa terbaik untuk penulis.
7. Seluruh Staff dan Pegawai Fasilkom-TI Universitas Sumatera Utara yang telah membantu segala urusan administrasi selama masa perkuliahan dan menyelesaikan skripsi penulis.
8. Teman-teman penulis yang turut langsung membantu penulis dalam menyelesaikan tugas akhir yaitu Christoper Manurung, Jhuan Sitorus, Daniel Situmeang, Anri Marpaung, Nananda Ambiya, Monang Limbong, Ricky Purba, Grace Ogestin, dan masih banyak lagi yang tidak bisa penulis sebutkan satu persatu.

9. Kepada Grup Kemana Lagi Enaknya, Anggi, Anri, Brian, Christopher, Daniel, Gmilang, Geyl, Jhuan, Monang, Ricky, Samuel Sebastian, Tomy yang menemani penulis dari awal perkuliahan serta menjadi tempat belajar dan bermain bersama untuk menyelesaikan per tiap semester perkuliahan.
10. Teman-teman Teknologi Informasi angkatan 19, yang telah membersamai penulis selama masa perkuliahan.
11. Kepada Bang Hanafi yang selalu membantu saya dalam setiap penulisan pada skripsi saya.
12. Teman-teman MBKM Bangkit Academy dan Kakak Pembimbing *Android Mobile Development* yang berperan dalam memberi ilmu serta memberikan kesempatan kepada penulis untuk belajar bekerja secara langsung dalam beberapa kesempatan.
13. Kepada Senior, Junior, Kerabat, Teman – teman dan pihak lainnya yang juga berperan dalam memberikan semangat dan dukungan serta doa selama masa perkuliahan dan dalam menyelesaikan penulisan skripsi.

Medan, 21 Mei 2024



Vincent Sirait

191402081

KLASIFIKASI JENIS TANAMAN SAYURAN SELADA MENGGUNAKAN METODE TRANSFER LEARNING

ABSTRAK

Kurangnya gizi di Indonesia salah satu penyebabnya adalah kurangnya konsumsi sayur di masyarakat. Tugas dari salah satu bidang Kesehatan dan Gizi adalah melakukan penelitian terkait penanggulangan kurang gizi di Indonesia. Salah satu sayuran yang saat ini sayuran yang cukup sering di teliti salah satunya adalah selta. Untuk melakukan analisis gizi yang lebih tepat dan informatif, selada dapat digunakan sebagai salah satu contoh sayuran yang mudah didapatkan di Indonesia. Pada penelitian ini digunakan metode *Transfer Learning* untuk melakukan klasifikasi jenis tanaman sayuran selada yang mana terdiri dari 6 jenis yaitu Selada Butterhead, Selada *Green Romanie*, Selada Hijau *New Grand Rapid*, Selada Keriting *Oakleaf Green*, Selada Merah *Red Rapid*, dan Selada *Red Romaine*. Dataset yang digunakan sebanyak 1242 data yang terdiri 993 sebagai data *training* sebanyak 249 sebagai data validasi. Data testing yang digunakan sebanyak 72 data yang diambil menggunakan *smartphone*. Penggunaan metode *Transfer Learning* dalam mengklasifikasikan jenis tanaman sayuran selada menghasilkan akurasi sebesar 93%. Hasil tersebut menunjukkan bahwa sistem yang dibuat menggunakan metode *Transfer Learning* telah berhasil dengan baik dalam mengklasifikasi jenis tanaman sayuran selada.

Kata Kunci: Tanaman Sayuran Selada, *Transfer Learning*, Klasifikasi, Deteksi Objek

Classification of Lettuce Vegetable Plant Types Using Transfer Learning Method

ABSTRACT

One of the causes of malnutrition in Indonesia is the lack of vegetable consumption among the population. One of the tasks of the Health and Nutrition sector is to conduct research related to addressing malnutrition in Indonesia. One of the vegetables that is frequently studied is lettuce. To perform more accurate and informative nutritional analysis, lettuce can be used as an example of a readily available vegetable in Indonesia. In this research, Transfer Learning method is used to classify different types of lettuce, including Butterhead Lettuce, Green Romaine Lettuce, Green New Grand Rapid Lettuce, Oakleaf Green Lettuce, Red Rapid Lettuce, and Red Romaine Lettuce. The dataset comprises 1,242 data points, with 993 for training and 249 for validation. Additionally, 72 testing data points were captured using a smartphone. The utilization of Transfer Learning in classifying lettuce types resulted in an accuracy rate of 93%. These results demonstrate that the system developed using Transfer Learning has effectively classified various types of lettuce plants.

Keywords: ***Lettuce Vegetable Plants, Transfer Learning, Classification, Object Detection***

DAFTAR ISI

PERSETUJUAN	i
PERNYATAAN	ii
UCAPAN TERIMAKASIH	iii
ABSTRAK	v
ABSTRACT	vi
DAFTAR ISI	vii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Penelitian	3
1.4 Tujuan Penelitian	4
1.5 Manfaat Penelitian	4
1.6 Metodologi Penilitian	4
1.7 Sistematika Penulisan	5
BAB II LANDASAN TEORI	6
2.1 Tanaman Selada	6
2.1.1 Selada <i>Butterhead</i>	7
2.1.2 <i>Green Romaine</i>	7
2.1.3 <i>New Grand Rapid</i>	8
2.1.4 <i>Oakleaf Green</i>	9
2.1.5 <i>Red Rapid</i>	10
2.1.6 <i>Red Romaine</i>	11
2.2 Pengolahan Citra Digital	12
2.2.1 Citra Berwarna	12
2.2.2 Citra <i>Biner</i>	13
2.2.3 Citra <i>Grayscale</i>	14
2.3 <i>Transfer Learning</i>	14
2.4 Pendekatan <i>Transfer Learning</i>	15
2.5 <i>Image Net</i>	18
2.5.1 <i>Resnet-15v2</i>	19
2.5.2 <i>DenseNet-121</i>	20

2.5.3 <i>Inception V3</i>	20
2.5.4 <i>VGG-19</i>	21
2.6 <i>Confusion Matrix</i>	22
2.6.1 <i>Accuracy</i>	23
2.6.2 <i>Precision</i>	23
2.6.3 <i>Recall</i>	23
2.6.4 <i>F1-Score</i>	24
2.7 Penelitian Terdahulu	24
2.8 Perbedaan Penelitian Terdahulu	30
BAB III ANALISIS DAN PERANCANGAN SISTEM	33
3.1 Dataset	33
3.2 Arsitektur Umum	36
3.2.1 <i>Image Acquisition</i>	37
3.2.2 <i>Image Pre-Processing</i>	37
3.2.2.1 <i>Resize</i>	37
3.2.2.2 <i>Labeling</i>	38
3.2.2.3 <i>Augmentation</i>	38
3.2.3 <i>Image Classification</i>	39
3.2.3.1 <i>Load Pretrain Network</i>	39
3.2.3.2 <i>Replace Final Layer</i>	40
3.2.3.3 <i>Train Clasifier</i>	40
3.2.3.4 <i>Evaluated Model</i>	40
3.2.4 <i>Learned Model</i>	40
3.2.5 <i>Validation</i>	40
3.2.6 <i>TFLite Model</i>	41
3.2.7 <i>Output</i>	41
3.3 Perancangan Antar Muka Sistem	41
3.3.1 <i>Splash Screen</i>	42
3.3.2 Tampilan <i>Home Screen</i>	42
3.3.3 Tampilan Halaman Deteksi Tanaman Selada	43
3.3.4 Tampilan Hasil Deteksi	44
BAB IV IMPLEMENTASI DAN PENGUJIAN SISTEM	45
4.1 Implementasi Sistem	45

4.1.1	Perangkat Keras dan Perangkat Lunak	45
4.2	Implementasi Data	46
4.3	Pelatihan Sistem	48
4.4	Implementasi Perancangan <i>Interface</i>	51
4.4.1	Tampilan Halaman <i>Home Screen</i>	52
4.4.2	Tampilan Halaman Artikel	52
4.4.3	Tampilan Halaman Deteksi	53
4.4.4	Halaman Klasifikasi	54
4.5	Pengujian Sistem	55
4.6	Pengujian Jarak	66
BAB V KESIMPULAN DAN SARAN		69
DAFTAR PUSTAKA		70

DAFTAR TABEL

Tabel 2.1 <i>Transfer Learning Approach</i>	16
Tabel 2.2 Parameter Arsitektur <i>ILSVRC</i>	19
Tabel 2.3 <i>Confusion Matrix</i>	22
Tabel 2.4 Penelitian Terdahulu	28
Tabel 3.1 Contoh Jenis Data Selada	33
Tabel 3.2 Jumlah Pembagian Kelas Pada Setiap Data	35
Tabel 4.1 Hasil <i>Training</i> Setiap <i>Premodel</i>	49
Tabel 4.2 Tabel Grafik <i>Loss</i> dan <i>Accuracy</i>	50
Tabel 4.3 Pengujian Sistem	56
Tabel 4.4 <i>Confusion Matrix</i>	64
Tabel 4.5 Hasil Pengujian	64
Tabel 4.6 Hasil Setiap Kelas	66
Tabel 4.7 Pengujian Jarak	67

DAFTAR GAMBAR

Gambar 2.1 Selada <i>butterhead</i>	7
Gambar 2.2 Selada <i>Green Romanie</i>	8
Gambar 2.3 Selada <i>Grand Rapid</i>	9
Gambar 2.4 Selada <i>Oakleaf Green</i>	10
Gambar 2.5 Selada <i>Red Rapid</i>	11
Gambar 2.6 Selada <i>Red Romaine</i>	12
Gambar 2.7 Citra <i>Berwana</i>	13
Gambar 2.8 Citra <i>Biner</i>	13
Gambar 2.9 Citra <i>Grayscale</i>	14
Gambar 2.10 <i>Traditional ML vs Transfer Learning</i>	15
Gambar 2.11 <i>Transfer Learning Scenario</i>	18
Gambar 2.12 Arsitektur <i>Resnet15V2</i>	19
Gambar 2.13 Arsitektur <i>DenseNet 121</i>	20
Gambar 2.14 Arsitektur <i>Inception V3</i>	21
Gambar 2.15 Arsitektur <i>VGG-19</i>	22
Gambar 3.1 Arsitektur Umum	36
Gambar 3.2 Pemberian Label Pada Objek	38
Gambar 3.3 Proses Augmentasi	39
Gambar 3.4 Rancangan Tampilan <i>Splash Screen</i>	42
Gambar 3.5 Rancangan Tampilan <i>Home Screen</i>	43
Gambar 3.6 Kamera Deteksi Foto	44
Gambar 3.7 Halaman Hasil Deteksi Foto	44
Gambar 4.1 Selada <i>Butterhead</i>	46
Gambar 4.2 Selada <i>Green Romanie</i>	46
Gambar 4.3 Selada <i>New Grand Rapid</i>	47
Gambar 4.4 Selada Keritiing <i>Oakleaf Green</i>	47
Gambar 4.5 Selada <i>Red Rapid</i>	48
Gambar 4.6 Selada <i>Red Romaine</i>	48
Gambar 4.7 Splash Screen dan Home Screen	52
Gambar 4.8 Halaman Artikel	53
Gambar 4.9 Halaman Identifikasi	54

Gambar 4.10 Halaman Klasifikasi

55

BAB I

PENDAHULUAN

1.1 Latar Belakang

Sayuran merupakan bahan pangan yang berasal dari tumbuhan yang mana memiliki nutrisi serta vitamin yang baik untuk dikonsumsi oleh manusia. Namun Riset Kesehatan Dasar (Riskesdas) menunjukkan, tidak lebih dari 10% orang Indonesia yang mengkonsumsi sayuran cukup. Artinya, 90% penduduk lainnya kurang mengonsumsi sayuran. Mineral dan vitamin pada sayuran tidak dapat diperoleh secara cukup hanya dari makanan pokok. WHO dan Food and Agriculture Organisation (FAO) menyebutkan, kekurangan asupan sayur dapat menyebabkan risiko kematian maupun gizi buruk.

Salah satu sayuran yang mana paling sering dikonsumsi oleh manusia dan merupakan salah satu sayuran yang dianjurkan untuk dikonsumsi adalah selada. Selada merupakan jenis tanaman sayuran yang mana sering dikonsumsi daunnya oleh masyarakat (Samadi, 2018). Selada sendiri juga merupakan sayuran yang memiliki prospek yang cukup baik dalam menangkal gizi buruk. Daun selada sendiri adalah sumber vitamin dan gizi yang sangat baik untuk tubuh dikarenakan memiliki Kalsium, Fosfor, Besi, vitamin A dan juga vitamin K yang sangat tinggi (Hesti Dwi Setyaningrum & Cahyo Saparinto, 2011).

Salah satu bidang yang mempelajari gizi di Indonesia adalah Laboratorium Kesehatan dan Gizi yang mana mengemban tugas untuk mempelajari bagaimana zat gizi dicerna, diserap, digunakan, disimpan, dan dikeluarkan oleh tubuh, seorang ahli gizi juga mempelajari tentang hubungan antara makanan dan zat gizi dengan kesehatan serta berbagai penyakit terkait gizi, baik akut maupun kronis.

Beberapa penelitian mengenai sayuran selada sebelumnya sudah pernah dilakukan, seperti halnya penelitian mengenai Deteksi Kondisi Tanaman selada menggunakan *Convolutional Neural Network (CNN)*. Pada penelitian ini memanfaatkan gambar tanaman Selada sebanyak 300 dengan pembagian kelas kondisi tidak baik dengan kelas kondisi baik yang sama rata dengan jumlah 150 gambar tanaman Selada. Pengujian partisi data memanfaatkan nilai default atau bawaan dari sistem yaitu learning rate pada nilai 0.001, jumlah *epoch* 100, dan batch

size 10 Penelitian ini menghasilkan akurasi sebesar 99.2% dan didukung dengan nilai *confusion matrix* yang tinggi (Reza Megantara et al., 2020).

Penelitian mengenai selada selanjutnya yaitu tentang klasifikasi tanaman selada menggunakan *Convolutional Neural Network* yang mana dari penelitian ini dihasilkan selada memiliki prediksi yang benar lebih dari 290 dari 300 lembar daun dan dua jenis lainnya diprediksi dengan benar di atas 282 dari 300 lembar daun dari gambar pengujian setelah ukuran mini-batch dikurangi menjadi 32. Dari matriks konfusi, masing-masing varietas mendapatkan akurasi lebih dari 95% dengan akurasi rata-rata untuk model adalah 97,8% (Hassim & Chuah, 2020).

Dalam bidang *machine learning* sendiri pada saat ini sudah banyak yang menggunakan selada sebagai bahan penelitiannya salah satunya menggunakan *Deep Learning* yaitu untuk menilai mana selada yang sehat dan tidak sehat menggunakan metode *Convolutional Neural Network* yang berbasis menggunakan *Faster R-CNN* dan menghasilkan akurasi sebesar 97% dengan bantuan *R-CNN* sebagai base modelnya (Yudha et al., 2020).

Saat ini sudah banyak penelitian yang menggunakan *Transfer Learning* sebagai metode penelitiannya. Berikut merupakan beberapa penelitian-penelitian yang menggunakan metode *Transfer Learning* seperti penelitian yang dilakukan Mendeteksi gangguan pada tanaman dengan memanfaatkan metode *Transfer Learning*. Hasil penelitian menunjukkan tingkat ketepatan data pelatihan yang mencapai 99% dan test akurasi sebesar 98.99% yang mana dengan metode tersebut didapat juga model complexity sebesar 0.23 (Ahmad et al., 2021). Penelitian lainnya yang menggunakan metode *Transfer Learning* adalah penelitian yang dilakukan mengenai pengecekan kepastian diagnosis *X-ray* dari penyakit *covid-19*. Dalam penelitian ini didapat akurasi sebesar 98% yang mana dalam media transfer learning menggunakan *DenseNet121*, *RestNet50*, dan *VGG16*. Dengan mengkombinasikan metode tersebut ke dalam *transfer learning* maka didapat hasil akurasi yang cukup baik (Shamsi et al., 2021).

Berdasarkan informasi yang ditemukan dalam penelitian-penelitian sebelumnya, penulis merasa tertarik untuk melaksanakan penelitian ini dalam penyelesaian Tugas Akhir dengan judul “*Klasifikasi Jenis Tanaman Sayuran Selada Menggunakan Metode Transfer Learning*” yang mana dengan penelitian ini diharapkan dapat membantu setiap peneliti yang ada di laboratorium Kesehatan dan

Gizi terutama yang masih baru sebagai peneliti maupun mahasiswa magang baik itu sebagai alat pembelajaran ataupun untuk dapat mengetahui jenis selada yang ada itu cukup beragam dan memiliki tingkat vitamin serta mineral yang berbeda-beda, pemanfaatan yang berbeda serta pengolahan yang berbeda juga semua itu dapat membantu kebutuhan gizi setiap orang.

1.2 Rumusan Masalah

Kurangnya gizi di Indonesia salah satu penyebabnya dikarenakan kurangnya konsumsi sayur di Masyarakat. Tugas dari salah satu bidang Kesehatan dan Gizi adalah untuk melakukan penelitian terkait penanggulangan kurang gizi di Indonesia.

Dalam melakukan analisis gizi yang lebih tepat dan informatif dapat dilakukan dengan menggunakan sayur selada sebagai salah satu contoh sayuran yang mudah didapatkan di Indonesia. Namun penelitian yang tergolong masih mudah terkadang masih sulit membedakannya, dimana sayur selada memiliki jenis yang berbeda sehingga kandungan gizi yang terdapat pada setiap jenis selada juga berbeda. Oleh karena itu, dibutuhkan sistem yang dapat mempercepat riset bagi orang yang baru masuk sebagai ahli gizi maupun yang sedang magang di Laboratorium Penelitian Kesehatan dan Gizi. Sistem ini dapat berfungsi sebagai bahan pembelajaran pertama maupun referensi yang dapat digunakan untuk membedakan setiap jenis selada, serta membedakan selada dengan jenis sayuran lainnya.

1.3 Batasan Penelitian

Untuk memastikan pemahaman yang tepat mengenai maksud dan tujuan penelitian, serta memastikan sistem yang optimal dan sesuai dengan tujuan penelitian, penelitian ini akan diarahkan oleh sejumlah batasan, yang mencakup:

1. Dataset jenis tanaman selada yang dapat diklasifikasikan oleh model yang akan di terapkan pada *Deep Learning* itu hanya terdapat enam jenis selada yang berbeda yaitu selada *Butterhead, Green Romaine, New Grand Rapid, Oakleaf Green, Red Rapid, Red Romanie*.
2. Data yang digunakan sebagai penelitian berekstensi .jpg/jpeg
3. Pengklasifikasian hanya dapat dilakukan dengan satu objek saja.
4. Pengambilan gambar sebaiknya diambil dari sisi atas pada saat menggunakan aplikasi.

1.4 Tujuan Penelitian

Mengklasifikasikan berbagai jenis tanaman Selada, sehingga dapat secara akurat membedakan keenam jenis tanaman tersebut berdasarkan yang telah ditentukan serta menganalisis dan menguji tingkat kinerja model yang telah di dapat.

1.5 Manfaat Penelitian

Manfaat penelitian ini dilakukan untuk membantu dalam menentukan jenis tanaman selada guna dalam meningkatkan wawasan serta pemanfaatan tanaman selada dalam konsumsi hidup sehari-hari.

1.6 Metodologi Penelitian

Langkah-langkah yang akan dijalani dalam penelitian ini adalah sebagai berikut:

1. Studi Literatur

Pada tahap ini dilakukan studi literatur dengan mengumpulkan dan mempelajari bahan yang dijadikan referensi baik itu dari jurnal, buku, artikel, website, maupun sumber lainnya yang berkaitan dengan *image processing* dan metode *Transfer Learning*.

2. Analisis Permasalahan

Pada tahap ini dilakukan analisis mengenai setiap studi literatur yang telah dikumpulkan pada tahapan sebelumnya untuk mendapatkan pemahaman yang mendalam mengenai metode yang akan diterapkan dalam penelitian ini agar dapat membangun suatu aplikasi yang dapat mengklasifikasikan jenis tanaman selada menggunakan *Transfer Learning*.

3. Perancangan Sistem

Pada tahap ini dilakukan proses perancangan sistem berdasarkan analisis permasalahan yang telah dilakukan pada tahapan sebelumnya. Dalam perancangan sistem ini dilakukan suatu perancangan arsitektur sistem, desain antarmuka, pengumpulan data dan membagi data *training* serta data *testing*.

4. Implementasi

Pada tahap ini dilakukan implementasi dari analisis yang telah dilakukan serta rancangan sistem yang akan dibuat ke dalam bentuk *source code* agar dapat menghasilkan suatu aplikasi untuk mengklasifikasikan jenis tanaman selada.

5. Pengujian Sistem

Pada tahap ini, pengujian sistem yang telah dikembangkan dilakukan untuk mengevaluasi tingkat akurasi yang diperoleh dari penerapan metode *Transfer Learning* dalam suatu sistem yang dapat mengklasifikasikan jenis tanaman selada.

6. Dokumentasi dan Penyusunan Laporan

Pada tahap ini dilakukan dokumentasi dan penyusunan laporan yang menjabarkan hasil dari keseluruhan penelitian yang telah dilakukan.

1.7 Sistematika Penulisan

Sistematika penulisan pada skripsi ini terdiri dari lima bab yang mana masing-masing dari bab akan dijabarkan secara singkat seperti berikut :

BAB I : PENDAHULUAN

Bab ini berisi tentang latar belakang, rumusan masalah, Batasan masalah, tujuan penelitian, manfaat penelitian, metodologi penelitian, dan sistematika penulisan.

BAB II : LANDASAN TEORI

Bab ini berisi teori-teori yang menjelaskan mengenai tanaman selada dan *transfer learning* serta beberapa teori lainnya yang terkait dengan penelitian yang akan dilakukan.

BAB III : ANALISIS DAN RANCANGAN SISTEM

Bab ini berisi mengenai arsitektur umum dari metode yang diterapkan dan juga langkah-langkah yang dilakukan dalam merancang sistem dalam penelitian ini.

BAB IV : IMPLEMENTASI DAN PENGUJIAN SISTEM

Bab ini berisi tentang implementasi sistem berdasarkan analisis dan rancangan yang telah dibuat pada bab sebelumnya. Pada bab ini juga akan dijabarkan hasil dari pengujian sistem untuk dapat mengetahui tingkat akurasi dari sistem yang telah dibuat.

BAB V : KESIMPULAN DAN SARAN

Bab ini berisi mengenai kesimpulan dari keseluruhan penelitian yang dilakukan dan saran untuk mengembangkan penelitian selanjutnya.

BAB II

LANDASAN TEORI

2.1 Tanaman Selada

Tanaman Selada adalah sayuran daun yang tumbuh di wilayah beriklim sedang. Pada zaman dahulu tanaman selada sudah dibudidayakan kurang lebih 2.500 tahun yang lalu, tanaman selada telah tumbuh di Amerika. Buktinya, Christoper Columbus mencatat hal ini pada tahun 1493 yang mana ia menemukan tanaman selada di wilayah Hemisphere barat, terutama di Bahama. Selada adalah salah satu jenis sayuran yang memiliki nilai ekonomi yang tinggi. Tanaman selada sering dibudidayakan untuk diambil daunnya lalu dimanfaatkan untuk menjadi lalapan, pelengkap sajian masakan dan memercantik hidangan. Selada sendiri juga merupakan sayuran yang memiliki prospek yang cukup baik serta memiliki peminat yang sangat banyak. Daun selada sendiri adalah sumber vitamain dan gizi yang sangat baik untuk tubuh dikarenakan memiliki kandungan Kalsium, Fosfor, Besi, vitamin A dan juga vitamin K yang sangat tinggi (Setyaningrum & Saparinto, 2011).

Dengan begitu banyaknya peminat ini menuntut peningkatan terhadap produksi selada itu sendiri. Saat ini, selada banyak dikonsumsi dan telah menjadi elemen vital dalam pola konsumsi manusia. Selada merupakan salah satu sayuran yang lebih sehat dan memiliki nilai pasar di mana beberapa varietas hanya bisa diperoleh dari hipermarket. Pemeliharaan kualitas produk, pemantauan tanaman yang tepat selama pertumbuhan untuk mendapatkan hasil yang tinggi, menjadi sangat penting.

Namun, sebelum mengembangkan aplikasi untuk pemantauan tanaman atau mendapatkan informasi lain terkait varietas selada, proses pengenalan dengan nama yang benar adalah bagian penting dari aplikasi tersebut. Merancang sistem yang mampu mengenali varietas selada diperlukan untuk memfasilitasi klasifikasi selada dengan cepat dan memungkinkan dengan metode yang tepat untuk mengelolanya (Hassim & Chuah, 2020).

Berikut beberapa jenis tanaman selada yang akan diklasifikasikan :

2.1.1 Selada *Butterhead*

Selada *butterhead*, yang juga dikenal sebagai selada butter, memiliki daun yang membentuk kepala dengan kekenyalan yang menghasilkan tekstur gurih. Ketika dimakan, selada *butterhead* memberikan sensasi lembut yang memiliki sentuhan manis dan rasa gurih seperti mentega. Selada *butterhead* sering digunakan sebagai wadah ideal untuk hidangan seperti hidangan ayam atau udang yang digiling karena daunnya lebar dan fleksibel (Perwita et al., 2023).

Selada *butterhead* mengandung berbagai fitokimia dan antioksidan yang dapat bermanfaat bagi kesehatan. Vitamin A dan K yang tinggi dalam selada ini berperan penting dalam kesehatan mata, kulit, dan tulang, serta membantu dalam proses pembekuan darah. Kandungan folatnya penting untuk fungsi sel dan pertumbuhan jaringan, membuatnya sangat baik bagi wanita hamil.



Gambar 2.1 Selada *Butterhead* (Sumber : www.bibitbunga.com)

2.1.2 *Green Romaine*

Selada *Green Romaine* adalah varietas sayuran yang termasuk dalam keluarga Asteraceae dan asalnya berasal dari Timur Tengah, khususnya Turki. Ini merupakan varietas *cos lettuce* yang memiliki ciri khas berbentuk lonjong dan tumbuh dengan sikap yang mirip perisai. Tinggi tanaman selada *Green Romaine* dapat mencapai 25-40 cm. Daunnya lebih tegak jika dibandingkan dengan selada biasa yang daunnya

cenderung menjuntai. Bagian luar daunnya berwarna hijau gelap dan lembut, sedangkan daun di bagian dalam atau cropnya memiliki warna hijau keputihan. Selada jenis ini tumbuh lebih lambat dibandingkan dengan varietas selada lainnya dan siap panen sekitar 30-45 hari setelah penanaman. Dari segi gizi, Selada *Green Romaine* dianggap sangat bergizi dengan kandungan energi sekitar 72 KJ, karbohidrat sekitar 3.3 gr, serat sekitar 2.1 gr, protein sekitar 1.2 gr, kalsium sekitar 33 mg, lemak sekitar 0.3 gr, air sekitar 95 gr, zat besi sekitar 0.97 mg, kalium sekitar 247 mg, fosfor sekitar 30 mg, dan vitamin C sekitar 24 mg (Fitrian et al., 2023).



Gambar 2.2 Selada *Green Romanie* (Sumber : www.bibitbunga.com)

2.1.3 *New Grand Rapid*

Selada *Grand Rapid* adalah salah satu varietas selada yang sangat umum dan memiliki kemampuan adaptasi yang baik terhadap lingkungan di Indonesia. Tanaman ini dapat tumbuh dengan baik di berbagai ketinggian, mulai dari dataran rendah hingga dataran tinggi (antara 100 hingga 1.200 meter di atas permukaan laut), dan tetap menghasilkan panen yang berkualitas. Ciri khasnya adalah tumbuhan ini memiliki daun-daun yang berkumpul dalam bentuk roset yang padat, dengan daun yang lembut dan renyah. Daun-daun selada ini memiliki permukaan yang bergerigi atau bergelombang.

Selada Grand Rapids mengandung karbohidrat sekitar 2-3 gram per 100 gram, yang sebagian besar berasal dari serat, menjadikannya baik untuk pencernaan. Protein dalam selada ini relatif rendah, sekitar 1-1.5 gram per 100 gram, sementara kandungan lemaknya sangat rendah, kurang dari 0.3 gram Mineral yang terkandung

dalam selada Grand Rapids termasuk kalsium, magnesium, kalium, dan zat besi dalam jumlah moderat. Kalsium dan magnesium penting untuk kesehatan tulang dan otot, sementara kalium membantu dalam menjaga tekanan darah yang sehat dan fungsi saraf. Secara keseluruhan, selada Grand Rapids adalah tambahan yang bergizi dan sehat untuk diet, memberikan berbagai vitamin, mineral, dan serat yang penting untuk kesehatan umum.(Nurza & Venesia, 2020).

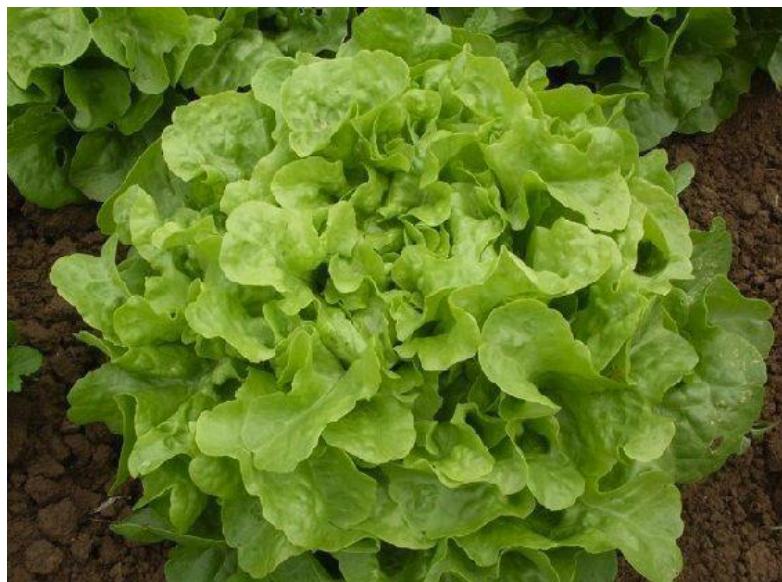


Gambar 2.3 Selada *Grand Rapid* (Sumber :www.Blibli.com)

2.1.4 *Oakleaf Green*

Green oakleaf merupakan selada yang termasuk ke dalam jenis L. Sativa Var. Crispata atau selada lembaran. Pada bagian luarnya, selada ini memiliki warna hijau seperti yang tampak pada Gambar. Konon, selada ini dikenal sejak abad ke-19 di wilayah Mediterania timur dan Asia barat. Tradisionalnya, selada ini sering dijadikan lalapan. Selain digunakan sebagai makanan, selada *Oakleaf Green* juga memiliki sifat obat yang dapat membantu dalam pencegahan dan pengobatan berbagai penyakit. Kandungan senyawa aktif yang ada pada setiap lembarannya, mencapai sekitar 70 jenis, memberikan manfaat kesehatan bagi manusia (Chen et al., 2014).

Selada Oakleaf hijau memiliki profil gizi yang kaya dan seimbang, menjadikannya pilihan yang sehat dalam pola makan. Selada ini sebagian besar terdiri dari air, sekitar 95-96%, yang membantu menjaga tubuh tetap terhidrasi dengan baik. Dengan kalori yang sangat rendah, sekitar 13-17 kalori per 100 gram, selada ini sangat cocok untuk mereka yang ingin menjaga asupan kalori tetap rendah tanpa mengorbankan asupan nutrisi.



Gambar 2.4 Selada *Oakleaf Green* (Sumber :www.Blibli.com)

2.1.5 *Red Rapid*

Selada merah (*lactuca sativa Var. Red rapid*) adalah selada berjenis leaf lettuce. Secara karakteristik, berbeda dengan varietas selada hijau, varietas selada merah mempunyai daun berwarna merah, lebar, tipis, dan bergerombol, serta tampak kering seperti yang tampak pada Gambar 1. Umumnya, selada merah memiliki ukuran daun sepanjang 20 cm hingga 50 cm dengan lebar mencapai 15 cm.

Dalam hal rasa, daun selada merah memiliki sifat yang lunak dan renyah dengan rasa sedikit manis. Kandungan vitamin yang ada pada selada ini di antaranya adalah vitamin A, vitamin B, dan vitamin C. Selada ini juga diklaim mempunyai kandungan antioksidan yang lebih tinggi dibanding selada hijau. Kandungan vitamin pada selada merah tidak hanya bermanfaat untuk memenuhi kebutuhan nutrisi harian, tetapi juga baik untuk menjaga kesehatan mata. Selada merah juga bisa dikonsumsi sebagai salah satu cara untuk melindungi tubuh dari radang gejala infeksi (Haryanti et al., 2003).

Dengan kandungan vitamin dan antioksidan yang tinggi, selada merah banyak digunakan untuk keperluan kecantikan. Selada ini dipercaya dapat dapat menurunkan kadar lemak di bagian tubuh. *U.S. Food and Drug Administration* (USDA) menunjukkan bahwa selada *red rapid* biasanya memenuhi syarat sebagai makanan tanpa kalori. Tanaman ini juga tanpa lemak dan pada dasarnya terdiri dari air.



Gambar 2.5 Selada Red Romaine (Sumber :www.BukaLapak.com)

2.1.6 *Red Romaine*

Selada merah, juga dikenal sebagai *Lactuca sativa*, memiliki kedekatan genetik dengan selada hijau. Dalam hal nutrisi dan citarasa, selada merah tidak kalah dengan saudara hijaunya. Selada merah memiliki sedikit kalori dan lemak, namun kaya akan beragam vitamin dan mineral yang penting bagi kesehatan tubuh kita. Mengkonsumsi selada merah dapat membantu dalam penurunan berat badan, menjaga kesehatan jantung, dan menjaga tekanan darah tetap stabil. Karena itu, selada merah dikenal sebagai salah satu sayuran yang sangat baik untuk kesehatan (Rosdiana et al., 2023).

Kandungan nutrisi dalam selada merah serupa dengan sayuran berdaun hijau lainnya, dengan kandungan vitamin K yang cukup tinggi. Selada merah juga mengandung sejumlah besar air, yang mendominasi hampir 96 persennya. Ini membuat selada merah menjadi makanan yang memberikan rasa kenyang lebih lama.

Tak hanya itu, selada merah juga mengandung antosianin, senyawa yang memiliki sifat antiinflamasi dan bermanfaat bagi kesehatan jantung. Terlebih lagi, sayuran yang ideal untuk hidangan salad ini juga mengandung vitamin C, sebuah antioksidan yang sangat efektif dalam mencegah berbagai penyakit, termasuk penyakit jantung dan kanker (Haryanti et al., 2003).



Gambar 2.6 Selada *Red Romaine* (Sumber :www.Tokopedia.com)

2.2 Pengolahan Citra Digital

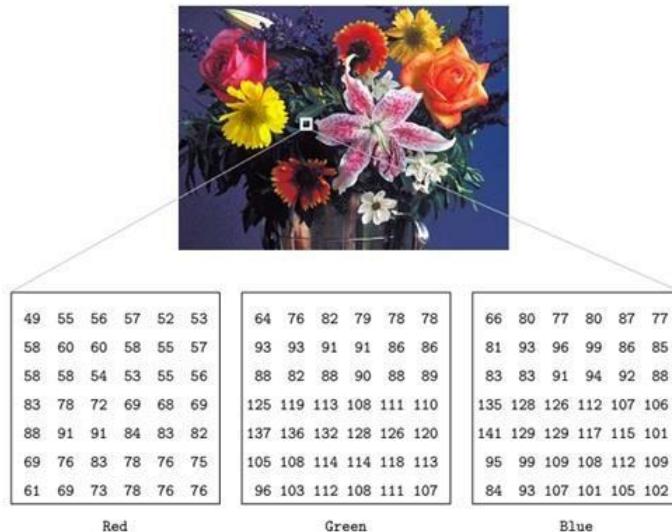
Citra merupakan gambaran objek dua dimensi yang ada di dunia ini yang menyangkut beragam disiplin ilmu seperti seni, astronomi, human vision, Teknik dan banyak ilmu lainnya. Citra sendiri adalah suatu kumpulan piksel atau titik yang membentuk gambar memiliki warna dan bentuk dalam dua dimensi. (Jumadi et al., 2021). Citra dalam perwujudannya dapat berbentuk macam-macam, mulai dari gambar putih dalam sebuah foto sampai dengan gambar yang memiliki warna yang bergerak pada suatu media.

Pengolahan citra adalah teknik yang sering digunakan dalam pemrosesan suatu data dalam bentuk gambar yang ditujukan untuk mendapatkan suatu informasi mengenai objek pada gambar yang sedang diamati. Pengolahan citra dapat diterapkan pada setiap elemen piksel gambar, yang paling tidaknya menyimpan informasi mengenai posisi warna. Dengan melakukan pengolahan citra, kita dapat mendapatkan informasi mengenai keberadaan suatu objek melalui deteksi perubahan atau gerakan dalam citra tertentu.(Putri, 2016).

2.2.1 Citra Berwarna

Citra berwarna yang biasanya juga dikenal sebagai citra RGB merupakan citra yang mengandung piksel dengan warna-warna tertentu, warna tersebut ialah R (merah), G (hijau) dan B (biru). Setiap warna tersebut menggunakan 8 bit yang mana nilainya memiliki range 0 – 255. Dengan demikian total warna yang didapat dari citra ini

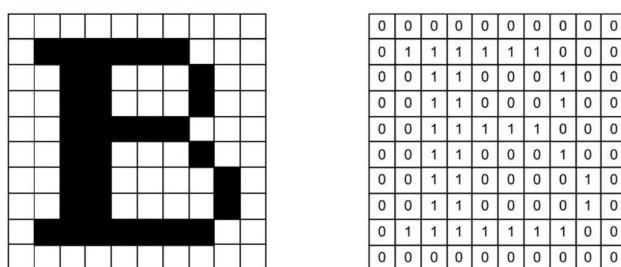
adalah sebanyak $255^3 = 16.581.375$ variasi warna pada suatu gambar (Kusumanto & Tompunu, 2011).



Gambar 2.7 Citra Berwarna (Hendrawaty et al., 2021)

2.2.2 Citra *Biner*

Citra *biner* merupakan citra yang mempunyai dua warna yaitu hitam dan putih oleh karena itu hanya terdapat 1 bit per piksel yaitu 0 dan 1. Piksel – piksel dari suatu objek bernilai 1 dan piksel untuk latar belakang bernilai 0. Gambar yang paling cocok menggunakan citra ini itu seperti teks tulisan tangan, sidik jari ataupun gambar yang terdapat arsitektur. Contohnya ada pada gambar 2.8 yang mana menampilkan gambar 1 dan 0 yang mana merupakan hasil dari citra *biner* (Wahyudi et al., 2015).



Gambar 2.8 Citra *Biner* (Munir, 2004)

2.2.3 Citra *Grayscale*

Citra *grayscale* merupakan citra yang setiap pikselnya mengandung nilai warna gradasi mulai dari warna putih ke hitam. Dengan gradasi warna tersebut didapat nilai intensitas paling besar yaitu 8 bit yang mana 255 berwarna putih hingga warna hitam dengan nilai intensitasnya paling kecil sebesar 0. Rentang warna ini sangatlah cocok untuk digunakan pada pengolahan gambar dan paling sering digunakan dalam kedokteran untuk X-ray (Kusumanto & Tompunu, 2011).



Gambar 2.9 Citra *Grayscale* (Saputra et al., n.d.)

2.3 Transfer Learning

Transfer Learning adalah salah satu metode yang sering digunakan dalam mengklasifikasikan suatu gambar, cara kerja dari *transfer learning* itu sendiri yaitu dengan menggunakan pengetahuan yang diperoleh dari tugas dan kumpulan data lain (bahkan yang tidak terkait sekalipun dengan tugas sumber atau kumpulan data) untuk membantu meningkatkan akurasi atau mengurangi waktu pelatihan (Kermanshahani & Hamidi, 2023).

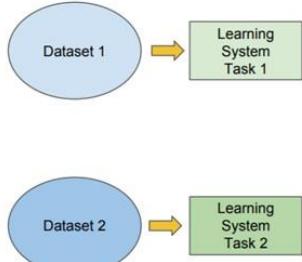
Dalam *Transfer Learning* model pra-pelatihan telah mempelajari fitur tingkat rendah yang dapat digeneralisasikan untuk tugas lain. Dengan menggunakan kembali fitur yang dipelajari ini sebagai titik awal, model dapat berfokus untuk mempelajari fitur khusus tugas dari data domain target. Pendekatan ini dapat menghemat waktu dan sumber daya komputasi secara signifikan dibandingkan dengan melatih model dari awal, terutama saat bekerja dengan data yang terbatas.

Pembelajaran transfer dapat diterapkan ke berbagai tugas pembelajaran mesin, seperti pengenalan gambar, deteksi objek, analisis sentimen, terjemahan bahasa, dan banyak lagi. Dalam *transfer learning* sendiri melatih kembali suatu model jaringan dengan target yang baru tanpa mengalami *overfitting* juga cukup besar, selama tugas yang diberikan pada target yang kedua mempunyai suatu kecocokan dan

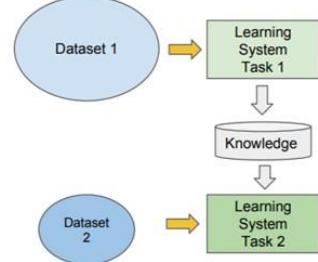
karakteristik fitur yang sama satu sama lain dengan tugas yang pertama (Rochman & Junaedi, 2020).

Traditional ML vs Transfer Learning

- Isolated, single task learning:
 - Knowledge is not retained or accumulated. Learning is performed w.o. considering past learned knowledge in other tasks



- Learning of a new tasks relies on the previous learned tasks:
 - Learning process can be faster, more accurate and/or need less training data



Gambar 2.10 Traditional ML vs Transfer Learning (Afif et al., 2020)

Gambar diatas menjelaskan peningkatan yang dibawa dengan menggunakan strategi *transfer learning*. Dengan *transfer learning* meningkatkan pembelajaran dengan menciptakan hubungan antara tugas sebelumnya dan tugas target, memberikan solusi yang logis, lebih cepat, dan lebih baik. *Transfer learning* mencoba untuk menyediakan cara pembelajaran dan komunikasi yang efisien antara tugas sumber dan tugas target. Selain itu, *transfer learning* paling dapat diterapkan ketika pasokan data pelatihan target terbatas (Ribani & Marengoni, 2019).

2.4 Pendekatan Transfer Learning

Ada tiga strategi utama dalam metode *transfer learning*, sesuai dengan (Elgendi, 2019):

1. Ekstraksi Fitur dari *Model Pre-trained*: Dalam metode ini, data di domain sumber mirip dengan yang ada di domain target. Model dilatih dengan data yang lebih besar seperti *ImageNet*, dan kemudian, bobot dan arsitektur model ini disesuaikan ulang dengan membekukan ekstraksi fiturnya. Lapisan klasifikasi model asli dihapus, dan lapisan klasifikasi baru ditambahkan untuk mencocokkan gambar di domain target.
2. *Model Pre-trained* sebagai Pengklasifikasi: Dalam skenario ini, domain sumber dan target memiliki kemiripan yang cukup tinggi. Model *pre-trained* digunakan

secara langsung untuk mengklasifikasikan data target tanpa perlu pelatihan tambahan. Model yang telah dilatih sebelumnya digunakan untuk memprediksi gambar tanpa modifikasi lebih lanjut.

3. Pemantapan Lanjutan: Pendekatan ini digunakan ketika data di domain sumber dan target sangat berbeda. Ini melibatkan pengambilan fitur-fitur yang relevan dari model domain sumber dan menyesuaikannya untuk sesuai dengan domain target yang berbeda.

Pada dasarnya *convolutional layer* pada *lower/initial layer* merupakan proses ekstraksi ciri umum. Semakin dalam jaringan, semakin detail ekstraksi fiturnya. Dua faktor penting yang harus diperhatikan dalam melaksanakan *transfer learning* menurut (Elgendi, 2019) antara lain:

1. Ukuran dataset target (sedikit atau banyak).
2. Kesamaan domain dataset antara sumber dan target.

Dari dua faktor yang dijelaskan diatas, dapat disimpulkan dan diilustrasikan untuk aturan umum pendekatan *transfer learning* pada tabel 2.1 yang ada dibawah ini :

Tabel 2.1 Transfer Learning Approach

Skenario	Ukuran Data Target	Perbedaan domain antara dataset asli dan baru	Pendekatan
1.	Kecil	Serupa	<i>Pre-trained as a feature extractor</i>
2.	Besar	Serupa	<i>Fine tune through the full network</i>
3.	Kecil	Sangat Berbeda	<i>Fine tune from activations earlier in the network</i>
4.	Besar	Sangat Berbeda	<i>Fine tune through the entire network</i>

Berikut merupakan penjelasan mengenai skenario pendekatan *transfer learning* :

- Skenario 1: Kumpulan data target berukuran kecil dan sangat mirip dengan kumpulan data sumber

Dikarenakan dataset target memiliki kemiripan yang signifikan dengan dataset sumber, maka disarankan untuk menerapkan *transfer learning* dengan fokus pada pelatihan layer klasifikasi atau *classifier* saja. Tidak baik melakukan pelatihan pada layer ekstraksi fitur, karena jumlah data yang terbatas tidak dapat memberikan informasi fitur yang mencukupi untuk menggeneralisasikan data, maka ini dapat menyebabkan *overfitting*.

- Skenario 2: Kumpulan data target berukuran besar dan mirip dengan data sumber

Seperti pada skenario 1, tetapi karena memiliki kumpulan data yang besar, latih ulang lapisan fitur yang mewakili fitur tertentu, yaitu lapisan atas. Bekukan sekitar 60-80% dari jaringan yang telah dilatih sebelumnya dan menggunakan lapisan yang tersisa untuk melatih kumpulan data baru.

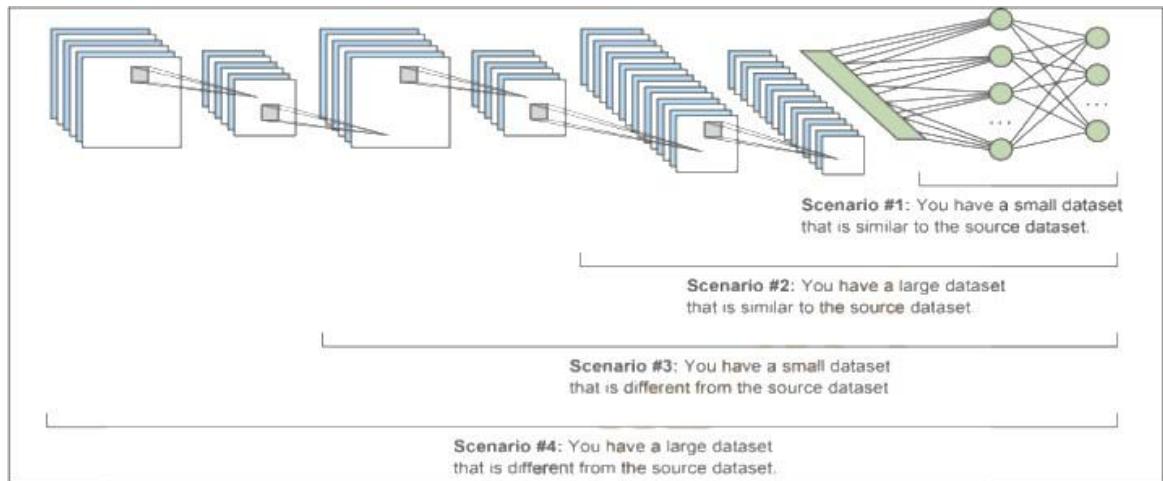
- Skenario 3: Dataset target memiliki ukuran yang terbatas dan berbeda secara signifikan dari dataset sumber.

Solusi untuk masalah ini adalah membekukan sepertiga atau setengah pertama dari jaringan pretrained. Lapisan awal mencerminkan peta fitur yang sangat generik dan bermanfaat untuk dataset target yang memiliki ukuran kecil.

- Skenario 4: Dataset target besar dan berbeda dari dataset sumber

Solusi untuk skenario ini adalah menginstruksikan seluruh jaringan untuk pelatihan dari awal, tanpa memanfaatkan *transfer learning*. Tetapi, keuntungan utama dari penggunaan *transfer learning* adalah mempercepat proses konvergensi model.

Kesimpulan dari keempat skenario di atas diilustrasikan pada gambar yang ada di bawah ini :



Gambar 2.11 Transfer Learning Scenario (Nana et al., 2021)

2.5 Image Net

Penelitian ini menggunakan model *pre-training* dari Keras yang dilatih pada dataset citra berukuran besar, yaitu *ImageNet*. *ImageNet* merupakan dataset citra yang disusun berdasarkan hirarki untuk setiap node hirarki yang terdiri dari ratusan hingga ribuan citra (Pangestu & Bunyamin, 2018).

ImageNet banyak digunakan oleh para peneliti sebagai bagian dari *pre-training* untuk menyesuaikan fitur-fiturnya dengan tugas-tugas baru dan telah menjadi standar *de facto* untuk menyelesaikan berbagai masalah dalam *computer vision* (Isola et al., 2017).

ImageNet adalah basis data lebih dari 15 juta gambar beresolusi tinggi yang diberi label di 22.000 kategori. Gambar-gambar ini dikumpulkan dari web dan diberi label menggunakan alat *crowd-sourcing* mekanis *amazon* oleh pelabel manusia (Krizhevsky & Hinton, 2012). Dalam bidang visi komputer, dataset ini merupakan bagian dari kompetisi tahunan *ImageNet Large Scale Recognition VisualRecognition Challenge* (ILSVRC), yang merupakan kompetisi penting dalam pengenalan dan klasifikasi gambar. Kompetisi ini pertama kali diselenggarakan sebagai bagian dari *Pascal Visual Object Challenge* pada tahun 2010. Secara keseluruhan, ILSVRC menggunakan subset *ImageNet* yang terdiri dari 1,4 juta gambar dan mencakup 1000 kelas objek. Hasil dari kompetisi ini biasanya diukur dengan dua metrik kesalahan, yaitu top-1 dan top-5.

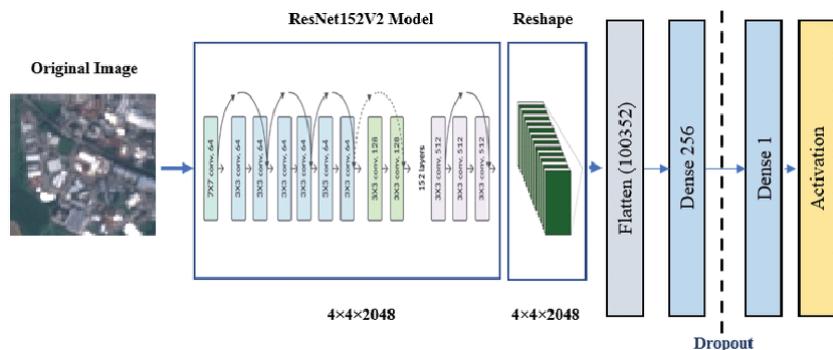
Tabel 2.2 Parameter Arsitektur ILSVRC

Arsitektur CNN	<i>Top-5 error rates</i> (%)	Tahun	Oleh	Jumlah Parameter
LeNet	28.2	1998	Yann LeCun et al.	600.000
AlexNet	16.4	2012	Alex Krizhevsky et al.	62.3 juta
VGG	7.30	2014	Simonyan, Zisserman	138 juta
GoogleNet	6.70	2014	Google Inc	4 juta
ResNet	3.57	2015	Kaiming He	25 juta

2.5.1 Resnet-15v2

ResNet adalah singkatan dari "Residual Network," yang diperkenalkan oleh Kaiming He dan tim penelitiannya pada tahun 2015. Versi "15v2" mengacu pada varian model *ResNet* yang memiliki 15 lapisan (*depth*) dan telah mengalami optimisasi. Ciri utama dari *ResNet* adalah penggunaan "*residual blocks*" atau blok residu, yang memungkinkan pelatihan jaringan yang sangat dalam secara lebih efisien dan mengatasi masalah "*vanishing gradient*," yang sering muncul dalam jaringan saraf dalam yang sangat dalam.

ResNet telah menjadi sangat populer dalam berbagai tugas pengenalan gambar dan pengolahan citra. Model-model *ResNet* telah digunakan dalam berbagai kompetisi dan proyek yang melibatkan analisis visual dan pengenalan objek dalam gambar. Keunggulan utamanya adalah kemampuan untuk melatih jaringan yang lebih dalam dengan lebih sedikit masalah pelatihan, yang membuatnya menjadi pilihan yang kuat dalam banyak aplikasi berbasis gambar.

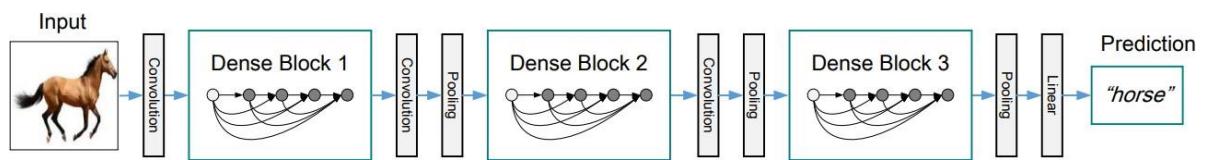
**Gambar 2.12** Arsitektur Resnet15V2 (Kanna et al., 2023)

2.5.2 DenseNet-121

DenseNet, atau "*Densely Connected Convolutional Networks*," adalah jenis jaringan saraf konvolusi (CNN) yang diperkenalkan oleh Gao Huang, Zhuang Liu, dan Laurens van der Maaten pada tahun 2016. Angka "121" dalam "*DenseNet-121*" merujuk pada jumlah lapisan yang ada dalam model *DenseNet* tersebut.

Fitur utama dari *DenseNet* adalah adanya koneksi yang kuat antara lapisan-lapisannya. Pada *DenseNet*, setiap lapisan menerima input dari semua lapisan sebelumnya dalam jaringan. Ini menciptakan aliran informasi yang sangat efisien melalui jaringan, karena setiap lapisan memiliki akses langsung ke informasi dari seluruh jaringan. Hal ini juga mengatasi masalah yang biasa terjadi dalam jaringan yang sangat dalam, yaitu hilangnya informasi (*vanishing gradient*), karena setiap lapisan memiliki jalur langsung ke lapisan-lapisan berikutnya.

DenseNet telah terbukti sangat efektif dalam tugas klasifikasi gambar dan segmentasi gambar. Karena koneksi yang kuat antara lapisan-lapisannya, model *DenseNet* cenderung membutuhkan lebih sedikit parameter daripada jaringan yang serupa, yang dapat membuat pelatihan lebih cepat dan membutuhkan lebih sedikit data pelatihan.



Gambar 2.13 Arsitektur *DenseNet 121* (Sumber : <https://datascience.eu>)

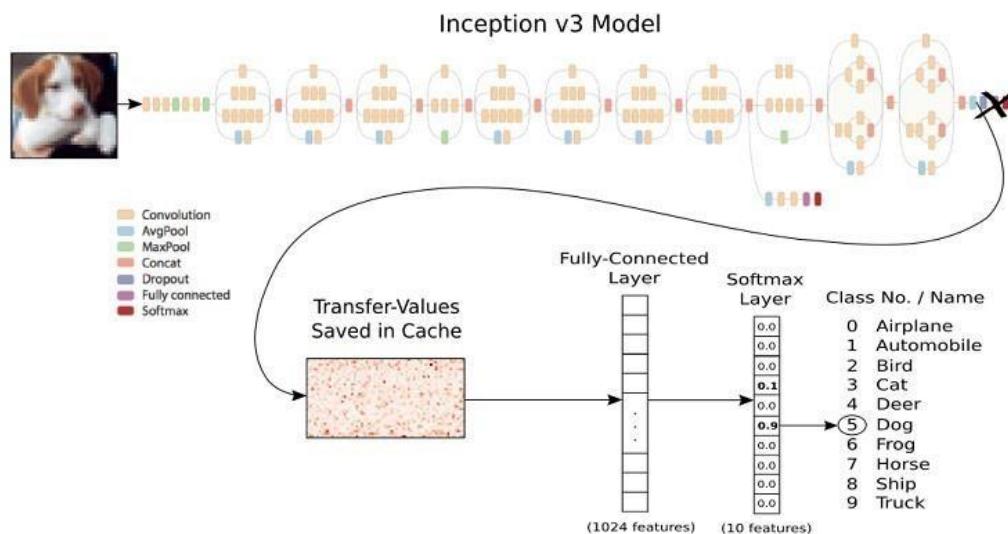
2.5.3 Inception V3

Inception V3 adalah sebuah model jaringan saraf konvolusi yang dikembangkan oleh *Google* sebagai kelanjutan dari arsitektur *Inception*, yang juga dikenal dengan nama *GoogLeNet*. Model ini terkenal karena penggunaan modul "*Inception*" yang kompleks, yang mencakup berbagai ukuran kernel konvolusi dan dilasi.

Arsitektur *Inception V3* sangat dalam dan efisien dalam tugas-tugas seperti klasifikasi gambar, deteksi objek, dan pemahaman gambar. Salah satu keunggulan utamanya adalah penggunaan "*factorization*" atau faktorisasi, yang membantu mengurangi jumlah parameter dalam jaringan tanpa mengorbankan performa.

Faktorisasi ini memungkinkan jaringan untuk menjadi lebih efisien secara komputasi dan memungkinkan pelatihan model dengan dataset yang lebih kecil.

Inception V3 telah digunakan secara luas dalam berbagai aplikasi berbasis gambar dan telah menjadi salah satu model yang sangat terkenal dalam komunitas pengolahan citra dan pembelajaran mendalam.

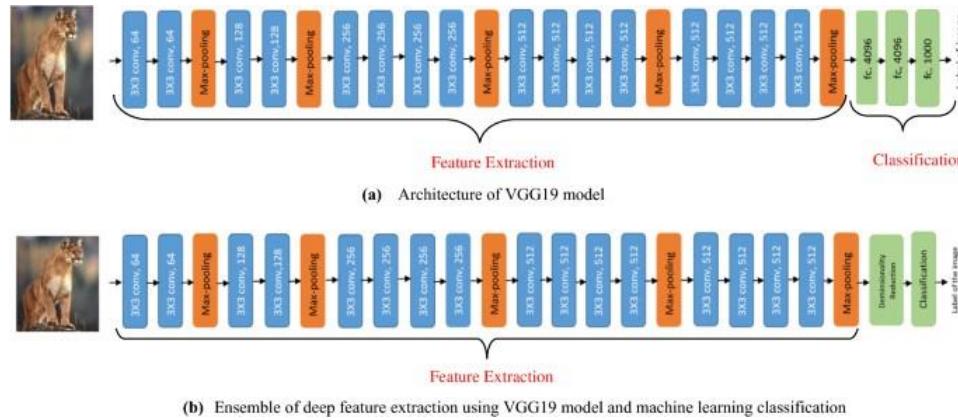


Gambar 2.14 Arsitektur *Inception V3* (Sumber : www.intel.com)

2.5.4 VGG-19

VGG-19 adalah salah satu arsitektur jaringan saraf konvolusi (CNN) yang dikembangkan oleh *Visual Geometry Group* (VGG) di Universitas Oxford. *VGG-19* adalah varian dari keluarga arsitektur VGG, yang terkenal karena kemampuannya dalam tugas-tugas pengenalan gambar dan pemrosesan citra. "19" dalam *VGG-19* merujuk pada jumlah lapisan (*depth*) dalam arsitektur ini.

VGG-19 telah digunakan secara luas dalam berbagai kompetisi dan proyek pengolahan citra sejak diperkenalkan. Meskipun demikian, karena ukurannya yang besar, *VGG-19* mungkin kurang efisien dalam aplikasi yang memerlukan model yang lebih kecil dan lebih cepat, seperti aplikasi di perangkat mobile atau *edge computing*. Dalam kasus tersebut, model-model yang lebih ringkas mungkin lebih sesuai.



Gambar 2.15 Arsitektur *VGG-19* (Bansal et al., 2021)

2.6 Confusion Matrix

Confusion Matrix adalah sebuah matriks atau tabel yang digunakan untuk mengevaluasi kinerja suatu model klasifikasi dengan membandingkan prediksi yang dibuat oleh model dengan nilai sebenarnya dari data yang telah diketahui sebelumnya. Dalam *Confusion Matrix*, terdapat empat istilah utama yang digunakan untuk menggambarkan hasil proses klasifikasi seperti tabel 2.3 dibawah ini :

Tabel 2.3 *Confusion Matrix*

		Aktual	
		Positif	Negatif
Prediksi	Positif	TP	FP
	Negatif	FN	TN

Terdapat empat istilah utama yang digunakan untuk menggambarkan tabel diatas :

- 1) *True Positive* (TP): Ini adalah situasi ketika model dengan benar memprediksi bahwa suatu instance atau sampel data termasuk dalam suatu kelas tertentu, dan kenyataannya data tersebut memang termasuk dalam kelas tersebut.
- 2) *True Negative* (TN): Ini adalah situasi ketika model dengan benar memprediksi bahwa suatu instance atau sampel data bukan termasuk dalam suatu kelas tertentu, dan kenyataannya data tersebut memang bukan termasuk dalam kelas tersebut.
- 3) *False Positive* (FP): Ini adalah situasi ketika model salah memprediksi bahwa suatu instance atau sampel data termasuk dalam suatu kelas tertentu, tetapi

kenyataannya data tersebut seharusnya tidak termasuk dalam kelas tersebut. Ini juga dikenal sebagai *error Type I*.

- 4) *False Negative* (FN): Ini adalah situasi ketika model salah memprediksi bahwa suatu instance atau sampel data bukan termasuk dalam suatu kelas tertentu, padahal kenyataannya data tersebut seharusnya termasuk dalam kelas tersebut. Ini juga dikenal sebagai *error Type II*.

Dengan menggunakan empat istilah di atas, kita dapat mengukur berbagai metrik evaluasi kinerja model seperti akurasi (*accuracy*), presisi (*precision*), *recall* (*sensitivity*), *F1-score*, dan lainnya seperti yang terdapat di bawah ini :

2.6.1 Accuracy

Accuracy merupakan tingkat tolak ukur sejauh mana model berhasil dalam memprediksi kelas dengan benar. Akurasi dihitung sebagai jumlah prediksi yang benar (*True Positive* dan *True Negative*) dibagi dengan jumlah total sampel. Cara untuk dapat mengukur tingkat akurasi dapat ditentukan dengan cara seperti berikut:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \times 100\% \quad (1)$$

2.6.2 Precision

Precision adalah cara untuk mengukur sejauh mana prediksi positif model yang dinyatakan benar. Presisi dihitung sebagai jumlah *True Positive* dibagi dengan jumlah *True Positive* dan *False Positive*. Cara untuk dapat mengukur tingkat *precision* dapat ditentukan dengan cara seperti berikut :

$$Precision = \frac{TP}{TP + FP} \quad (2)$$

2.6.3 Recall

Recall adalah cara untuk mengukur sejauh mana model dapat mendeteksi semua kasus positif yang sebenarnya. *Recall* dihitung sebagai jumlah *True Positive* dibagi dengan jumlah *True Positive* dan *False Negative*. *Recall* berguna ketika ingin meminimalkan jumlah kasus positif yang sebenarnya yang terlewat oleh model. Cara untuk dapat mengukur tingkat *recall* dapat ditentukan dengan cara seperti berikut :

$$Recall = \frac{TP}{TP + FN}$$

(3)

2.6.4 *F1-Score*

F1-Score adalah metrik yang menggabungkan presisi dan *recall* menjadi satu skor tunggal. Ini adalah harmonic mean dari presisi dan *recall*, sehingga memberikan bobot yang seimbang pada keduanya. *F1-Score* berguna ketika perlu mencari keseimbangan antara meminimalkan *false positive* dan *false negative*. Cara untuk dapat mengukur tingkat *F1-Score* dapat ditentukan dengan cara seperti berikut :

$$F1 - Score = 2 \times \frac{Recall \times Precision}{Recall + Precision} \quad (4)$$

2.7 Penelitian Terdahulu

Beberapa penelitian mengenai sayuran selada sebelumnya sudah pernah dilakukan, seperti halnya penelitian yang dilakukan oleh (Megantara, et al, 2020). Pada penelitian ini akan dirancang sistem vision untuk mengklasifikasikan kondisi tanaman selada menggunakan algoritma *Convolutional Neural Network (CNN)* melalui citra yang telah ditangkap oleh kamera. Dengan memanfaatkan dataset berisi 300 citra tanaman selada, yang dibagi menjadi dua bagian, yakni 90% untuk data latih dan 10% untuk data uji, sistem klasifikasi kondisi tanaman Selada ini beroperasi secara efektif. Sistem ini memiliki dua kelas, yang mencakup kondisi kurang baik dan kondisi baik. Melalui penerapan algoritma *Convolutional Neural Network (CNN)*, hasil terbaik diperoleh dengan membagi data menjadi 90% untuk data latih dan 10% untuk data uji, serta dengan pengaturan learning rate sebesar 0,0001, melakukan pelatihan selama 250 *epoch*, dan menggunakan batch size sebesar 15, yang menghasilkan akurasi tinggi mencapai 99,2%. Hal ini juga dikuatkan oleh nilai *confusion matrix* yang sangat baik.

Penelitian lainnya mengenai tanaman selada yang dilakukan oleh (Alejandrino, et al, 2020). Tujuan utama dari penelitian ini adalah untuk mencapai model pembelajaran mesin yang optimal untuk mengelompokkan sampel gambar selada menjadi tiga tahap pertumbuhan (vegetatif, perkembangan kepala, dan panen) di antara algoritma *unsupervised machine learning* : *Self Organizing Map (SOM)*, *Hierarchical Clustering (HC)* dan *K – means Clustering (K-means)*. Dalam

penelitian ini di dapat *K-means* model sebagai model yang paling akurat dalam *holdout* dan *k-folds* dengan 96,75% dan 91,0% klasifikasi tahap pertumbuhan selada yang benar masing-masing. Sehingga menjadikannya sebagai model *machine learning* teroptimasi terbaik dalam artian model ini konsisten dalam memberikan klasifikasi yang benar didukung dengan performa dan akurasinya.

Penelitian mengenai selada selanjutnya yang dilakukan oleh (Hassim & Chuah, 2020). Dari penelitian ini diperoleh dapat dipastikan bahwa *CNN* mampu menentukan dan memperoleh prediksi persentase akurasi yang tinggi dari citra selada pada jendela simulasi *MATLAB*. Berdasarkan citra daun, model mampu membedakan tujuh varietas selada yang berbeda dengan persentase akurasi yang tinggi. Jumlah total prediksi yang benar dan salah masing-masing diwakili oleh kotak hijau dan merah. Jumlah prediksi yang benar meningkat dengan lima varietas selada memiliki prediksi yang benar di lebih dari 290 dari 300 daun dan dua jenis lainnya memprediksi dengan benar di lebih dari 282 dari 300 daun gambar uji setelah ukuran mini-batch. dikurangi menjadi 32. Dari matriks konfusi, masing-masing varietas diperoleh akurasi lebih dari 95% dengan akurasi model rata-rata 97,8%.

Penelitian selada selanjutnya yang ditulis oleh (Pratama, et al, 2021). Dalam penelitian ini, Algoritma *Faster RCNN Inception V2* dan *YOLO* diidentifikasi sebagai algoritma yang cocok untuk penggunaan pembelajaran mendalam, dan keduanya dilatih menggunakan kumpulan data yang berisi gambar terkait penyakit yang ditemukan di Selada. Algoritma tersebut telah dilatih dengan dataset sebanyak 412 citra selada berpenyakit yang kemudian disortir untuk dianalisis akurasi, presisi, *recall*, dan nilai F1 dari 53 citra uji atau 13% dari total dataset. Setelah menganalisis dan membandingkan citra latih dan rasio validasi yang dibagi menjadi 3 kategori, diketahui bahwa algoritma *YOLO* dengan model B memiliki performa yang sangat baik dalam akurasi, presisi dan skor F1, sedangkan algoritma *V2 inception Faster R-CNN* dengan Model C memiliki kinerja terendah jika dibandingkan dengan algoritma dan model lain. Secara khusus algoritma *Faster R-CNN Inception V2* memiliki performa yang baik menggunakan model A dengan akurasi 70%, presisi 97%, *recall* 68%, dan skor F1 80%, sedangkan hasil terendah adalah untuk model C dengan kisaran 34% untuk skor akurasi, presisi, dan F1 100% *recall*.

Penelitian yang dijadikan acuan berikutnya ditulis oleh (De Jesus et al., 2023). Penelitian ini menggunakan model klasifikasi berbasis *Convolutional Neural Network (CNN)* menggunakan *TensorFlow* untuk mendeteksi kondisi daun selada. Dataset model ini dibagi menjadi 80% set pelatihan, 10% set pengujian, dan 10% set validasi. Kondisi kesehatan daun diklasifikasikan menjadi empat kategori: Sehat, Hawar Septoria, Jamur Tepung, dan Bintik Bakteri. Hasil penelitian ini menunjukkan bahwa model yang diusulkan mencapai akurasi yang tinggi, dengan akurasi pelatihan sebesar 98,50%, akurasi pengujian sebesar 87,50%, dan akurasi validasi sebesar 97,50%. Temuan ini menunjukkan bahwa pendekatan yang diusulkan memiliki potensi untuk meningkatkan deteksi penyakit daun selada secara signifikan dan meningkatkan kualitas praktik pemantauan dan pengelolaan tanaman.

Penelitian yang dijadikan acuan untuk memahami *Transfer Learning* sebagai metode penelitiannya adalah penelitian yang dilakukan oleh (Ahmad et al., 2021). Model yang diusulkan dilatih menggunakan tiga konfigurasi yang berbeda. Pertama, model dilatih dari awal, yaitu tanpa *transfer learning*. Kemudian model dilatih dengan pembelajaran transfer sederhana dan terakhir, model dilatih dalam konfigurasi *transfer learning configuration*. Hasil ini menunjukkan kinerja yang sangat baik pada dataset, arsitektur dasar yang dipilih adalah *MobileNet V3 small* yang mana menghasilkan akurasi data *training* sebesar 99% dan test akurasi sebesar 97.84% yang mana dengan metode tersebut didapat juga model complexity sebesar 0.23.

Penelitian selanjutnya yang dijadikan acuan dalam menggunakan metode *Transfer Learning* adalah penelitian yang dilakukan oleh (Celik & Bilgin, 2021). Diagnosis kanker ini biasanya ditegakkan berdasarkan gambaran *histopatologi*. Dalam penelitian ini, empat kelas citra kanker payudara (normal, regional, jinak, dan invasif) dideteksi dengan menggunakan pendekatan *transfer learning*. Kumpulan data *BACH* digunakan dalam penelitian ini merupakan kumpulan data gambar yang dibagi menjadi potongan-potongan kecil berukuran 256×256 , 128×128 , dan 75×75 dari tempat yang kepadatannya tinggi. Hasilnya, keberhasilan sistem mendapatkan akurasi 99% pada ukuran patch 256×256 dan bervariasi sesuai dengan ukuran patch gambar.

Penelitian lainnya yang menggunakan metode *Transfer Learning* adalah penelitian yang dilakukan oleh (Shamsi, et al, 2021). Memanfaatkan kerangka *transfer learning*, penelitian ini menerapkan empat pretrained model *CNN* (*VGG16*, *ResNet15V2*, *DenseNet121*, dan *Inception V3*) untuk secara efektif mengekstrak fitur informatif dan diskriminatif dari gambar rontgen dada dan CT. Mengambil 25 gambar *COVID-19*. Kemudian menambahkan 75 kasus *non-Covid* dari gambar rontgen dada. Kumpulan data CT memiliki 349 gambar *Covid* dan 397 gambar *non-Covid*. Dalam penelitian ini didapat akurasi sebesar 98% yang mana dalam media *transfer learning* menggunakan *DenseNet121*, *RestNet50*, dan *VGG16*. Dengan mengkombinasikan metode tersebut ke dalam *transfer learning* maka didapatkan hasil akurasi yang cukup baik.

Berdasarkan dari penelitian-penelitian yang ada sebelumnya maka, penulis tertarik untuk melakukan penelitian untuk menyelesaikan Tugas Akhir dengan judul “Klasifikasi Jenis Tanaman Sayuran Selada Menggunakan Metode *Transfer Learning*” yang mana dengan penelitian ini akan dibuat suatu sistem yang dapat mengklasifikasikan jenis setiap tanaman selada melalui tahapan *image processing* yang akan dikombinasikan dengan metode *Transfer Learning* melalui penelitian ini diharapkan dapat mendapatkan akurasi yang baik dan dapat digunakan serta dimanfaatkan oleh banyak orang.

Ringkasan dari penelitian-penelitian terdahulu dapat dilihat pada Tabel 2.4 berikut ini :

Tabel 2.4 Penelitian Terdahulu

No.	Peneliti	Tahun	Metode	Keterangan
1.	Fachrie, et al.	2020	<i>CNN</i>	Penelitian ini membahas tentang kondisi tanaman selada berdasarkan citra. Melalui penelitian ini berdasarkan pengujian jumlah <i>epoch</i> didapatkan tingkat akurasi dengan pembagian <i>epoch</i> sebesar 250 dengan nilai akurasi 99.3%. Nilai <i>confusion matrix</i> yang tinggi serta nilai learning rate sebesar 0.0001.
2.	Alejandrino, Jonnel, et al.	2020	<i>Self Organizing Map (SOM), Hierarchical Clustering (HC) dan K – means Clustering (K- means)</i>	Penelitian ini membahas tentang klasifikasi tahap pertumbuhan selada. Dari penelitian ini dihasilkan akurasi sebesar 87% dalam panen, 90% dalam Pengembangan Kepala, 98% dalam Vegetatif. Sedangkan 86% pada panen, 91% pada <i>Head Development</i> , 97% untuk <i>positive predictive value</i> .

Tabel 2.4 Penelitian Terdahulu (Lanjutan)

No.	Peneliti	Tahun	Metode	Keterangan
3.	Hassim & Chuah	2020	CNN	Penelitian ini membahas tentang klasifikasi selada. Dari penelitian ini dihasilkan 282 dari 300 lembar daun dari gambar pengujian. Dari matriks konfusi, masing-masing varietas mendapatkan akurasi lebih dari 95% dengan akurasi rata-rata untuk model adalah 97,8%.
4.	Yudha Pratama et al.	2021	<i>Faster R-CNN with Inception V2</i>	Penelitian ini membahas tentang menilai mana selada yang baik dan tidak. Penelitian ini menghasilkan akurasi sebesar 70%, presisi 97%, <i>recall</i> sebesar 68% dan 80% F1 skor.
5.	Ahmad et al.	2021	<i>CNN dan Transfer Learning</i>	Penelitian ini membahas tentang deteksi penyakit pada tanaman. Penelitian ini menghasilkan akurasi data <i>training</i> sebesar 99% dan test akurasi sebesar 97.84% yang mana dengan metode tersebut didapat juga <i>model complexity</i> sebesar 0.23.

Tabel 2.4 Penelitian Terdahulu (Lanjutan)

No.	Peneliti	Tahun	Metode	Keterangan
6.	Shamsi et al.	2021	<i>Transfer Learning</i>	Penelitian ini membahas tentang diagnosa terhadap penyakit Covid19. Dalam penelitian ini didapat akurasi sebesar 98% yang mana dalam media <i>transfer learning</i> menggunakan <i>DenseNet121</i> , <i>RestNet50</i> , dan <i>VGG16</i> .
7.	Celik & Bilgin	2021	<i>Transfer Learning</i>	Penelitian ini membahas tentang klasifikasi jenis kanker payudara menggunakan patching size yang berbeda-beda dan mendapatkan akurasi sebesar 99% menggunakan ukuran gambar 256 x 256.
8.	De Jesus et al.	2023	<i>CNN</i>	Penelitian ini membahas pendektsian penyakit yang ada pada selada. Pada penelitian ini menunjukkan bahwa model yang diusulkan mencapai akurasi yang tinggi, dengan akurasi pelatihan sebesar 98,50%, akurasi pengujian sebesar 87,50%, dan akurasi validasi sebesar 97,50%

2.8 Perbedaan Penelitian Terdahulu

Ada beberapa perbedaan dalam penelitian sebelumnya yang mencakup objek penelitian, waktu dan tempat pelaksanaan penelitian, serta batasan yang digunakan selama penelitian. Dalam penelitian ini, penulis menggunakan metode *Transfer Learning* untuk mengklasifikasi jenis sayuran selada. Jenis selada yang diteliti meliput Selada *Butterhead*, Selada *Green Romanie*, Selada Hijau *New Grand Rapid*, Selada Keriting *Oakleaf Green*, Selada *Red Rapid*, dan Selada *Red Romaine* yang memiliki kemiripan dalam jenis daunnya, yang dimana pada penelitian oleh (Hassim & Chuah, 2020) menggunakan metode *Convolutional Neural Network* untuk mengklasifikasi jenis tanaman selada serta mengklasifikasi jenis tanaman sayuran selada yang lumayan berbeda dengan penulis. Selain itu, penulis telah mengembangkan sebuah aplikasi berbasis *Android* untuk mempermudah pengguna dalam menggunakan sistem dalam penelitian ini. Dengan adanya aplikasi ini, pengguna dapat dengan lebih mudah dan praktis menggunakan sistem dalam waktunya.

Selanjutnya, perbedaan dari penelitian (Reza et al., 2020) dan juga (De Jesus et al., 2023) terletak pada tujuan penelitian dan metode penelitian. Peneliti terdahulu oleh (Reza et al., 2020) dan juga (De Jesus et al., 2023) menggunakan CNN sebagai metode penelitian yang digunakan yang mana (Reza et al., 2020) bertujuan untuk mendeteksi kondisi tanaman selada berdasarkan citra menggunakan metode CNN dan untuk (De Jesus et al., 2023) melakukan pendekripsi penyakit yang ada pada selada menggunakan CNN.

Perbedaan penelitian selanjutnya yang dilakukan oleh (Yudha et al., 2020) terletak pada metode serta tujuan penelitiannya yaitu menentukan mana selada yang baik dan tidak menggunakan metode *Faster R-CNN* dan juga *Inception V2*. Penelitian berikutnya yang dilakukan oleh (Alejandrino et al., 2020) terletak pada metode yang digunakan dan tujuannya yaitu menggunakan metode *SOM*, *HC* dan *K-Means* untuk mengklasifikasikan tingkat pertumbuhan pada tanaman selada.

Perbedaan penelitian berikutnya yaitu dilakukan oleh (Ahmad et al., 2021) yang mana menggunakan *CNN* dan juga *Transfer learning* sebagai metode dalam mendekripsi penyakit pada tanaman. Berikutnya adalah penelitian dari (Shamsi et al., 2021) dan (Celik & Bilgin, 2021) yang mana keduanya sama-sama menggunakan metode *Transfer Learning* dalam menentukan suatu penyakit

perbedaanya terletak pada tujuannya yang mana (Shamsi et al., 2021) dalam menentukan diagnosis terhadap penyakit *Covid-19* dan (Celik & Bilgin, 2021) dalam mengklasifikasikan jenis-jenis kanker payudara yang ada pada manusia berdasarkan patching sizenya.

Perbedaan secara keseluruhan antara penelitian ini dan studi sebelumnya terletak pada beberapa aspek. Penelitian ini memfokuskan pada tanaman sayuran selada, mengklasifikasikan enam jenis selada yang berbeda, yaitu Selada *Butterhead*, Selada *Green Romanie*, Selada Hijau *New Grand Rapid*, Selada Keriting *Oakleaf Green*, Selada Merah *Red Rapid*, dan Selada *Red Romaine*. Perbedaan ini signifikan dibandingkan dengan penelitian sebelumnya yang mungkin hanya mempertimbangkan jenis tanaman selada tertentu atau bahkan jenis tanaman yang berbeda.

Selain itu, perbedaan terdapat pada metodologi penelitian yang menerapkan *Transfer Learning*, suatu pendekatan yang belum pernah digunakan oleh peneliti sebelumnya. Tidak hanya itu, perbedaan lainnya mencakup implementasi aplikasi, di mana penelitian ini menciptakan aplikasi berbasis *Android*, yang merupakan inovasi tambahan yang belum pernah diterapkan dalam penelitian sebelumnya.

BAB III

ANALISIS DAN PERANCANGAN SISTEM

Bab ini akan menguraikan analisis dan perancangan sistem terkait dengan langkah-langkah penelitian dan pengembangan aplikasi *Android* menggunakan metode *Transfer Learning*. Metode ini bertujuan untuk mengenali dan mengklasifikasikan berbagai jenis selada. Proses tersebut melibatkan tahapan pengumpulan data, input data, *pre-processing*, *training* dan *testing* data, serta *output* dari proses deteksi menggunakan *pre-model Transfer Learning*.

3.1 Dataset

Data yang akan digunakan dalam penelitian ini berupa data *image*. Data *image* tanaman selada yang akan digunakan sebagai dataset didapat dari beberapa lahan pertanian selada yang ada di jl.Karya Bersama No.28 kota Medan , Sumatera Utara. Data yang dikumpulkan diambil langsung menggunakan kamera *smartphone* dan data yang dikumpulkan akan berekstensi JPG.

Tabel 3.1 Contoh Jenis Data Selada

No.	Gambar	Jenis Selada
1.		Selada <i>Butterhead</i>
2.		Selada <i>Green Romanie</i>

3.		Selada Hijau <i>New Grand Rapid</i>
4.		Selada Keriting <i>Oaleaf Green</i>
5.		Selada Red <i>Rapid</i>
6.		Selada Red <i>Romaine</i>

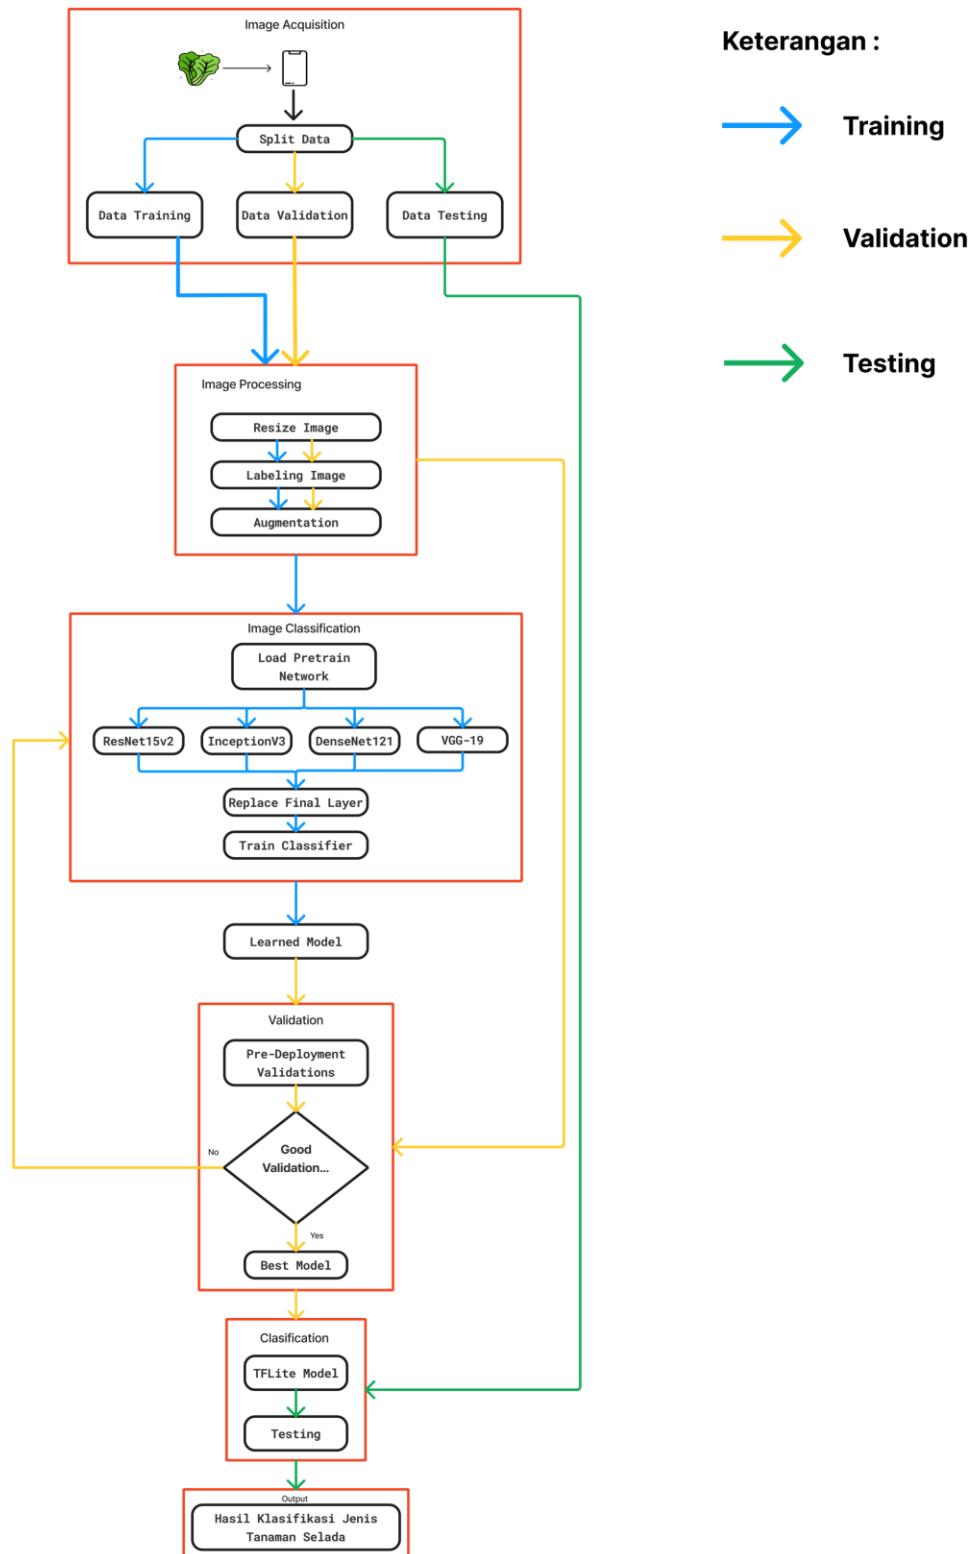
Data mengenai jenis selada dalam penelitian ini mencakup enam variasi, yakni Selada *Butterhead*, Selada *Green Romanie*, Selada Hijau *New Grand Rapid*, Selada Keriting *oakleaf green*, Selada *Red Rapid*, dan Selada *Red Romaine*. Dataset ini terbagi menjadi dua kelompok utama: data latihan (*training*) dan data validasi. Kedua kelompok ini akan digunakan dalam proses pelatihan model. Data uji (*testing*) yang akan diaplikasikan dalam penelitian ini akan diperoleh dari petani selada di wilayah Kota Medan. Data tersebut akan diuji dalam sistem untuk menilai keberhasilan sistem dalam mendeteksi objek. Tabel 3.2 akan menampilkan rincian jumlah data untuk setiap jenis selada.

Tabel 3.2 Jumlah Pembagian Kelas Pada Setiap Data

Jenis Penyakit	Selada <i>Butterhead</i>	Selada <i>Green Romanie</i>	Selada Hijau <i>New Grand Rapid</i>	Selada <i>Oakleaf Green</i>	Selada <i>Red Rapid</i>	Selada <i>Red Romaine</i>
Jumlah	102	100	104	101	108	106

Jumlah keseluruhan dari 621 data citra akan dibagi menjadi dua kelompok, yaitu data pelatihan (*training*) dan data validasi. Dalam pembagian ini, 80% dari data akan dialokasikan untuk pelatihan dan sisanya, 20%, akan digunakan sebagai data validasi. Pendekatan ini bertujuan untuk melatih algoritma agar dapat mengidentifikasi setiap jenis data yang ada dalam kelompok data *training* dan *validation*.

3.2 Arsitektur Umum



Gambar 3.1 Arsitektur Umum

Metode yang digunakan dalam penelitian ini terdiri dari beberapa tahap. Tahap pertama yaitu melakukan pengumpulan data gambar dari setiap jenis tanaman selada yang akan diklasifikasikan pada penelitian ini.

Tahap berikutnya adalah tahap *image processing* antara lain, *resize* image untuk merubah ukuran pixel setiap gambar tanaman selada, *labeling* untuk memberikan penamaan pada setiap gambar selada. Setelah gambar melewati proses *labeling* data akan di augmentasi untuk dapat memperbanyak jumlah data.

Tahap terakhir merupakan tahap pengklasifikasian gambar, penelitian ini menggunakan metode *transfer learning* yang mana dalam setiap proses klasifikasi akan dilatih dengan beberapa *premodel* yang telah dikonfigurasikan dengan *transfer learning*. Setelah itu akan keluar model dengan akurasi yang paling tinggi yang mana akan digunakan untuk menentukan hasil dari klasifikasi jenis tanaman selada. Seluruh tahap penelitian ini dapat dilihat dalam arsitektur umum pada Gambar 3.1.

Berikut ini merupakan penjelasan terkait proses arsitektur pada Gambar 3.1

3.2.1 *Image Acquisition*

Pada tahapan ini dilakukan pengumpulan data tanaman selada setelah itu data yang telah terkumpul akan dibagi menjadi data *training* dan data *testing*. Ada 6 jenis tanaman selada dan penelitian ini akan berfokus untuk dapat mengidentifikasi ketujuh jenis tanaman selada tersebut.

3.2.2 *Image Pre-Processing*

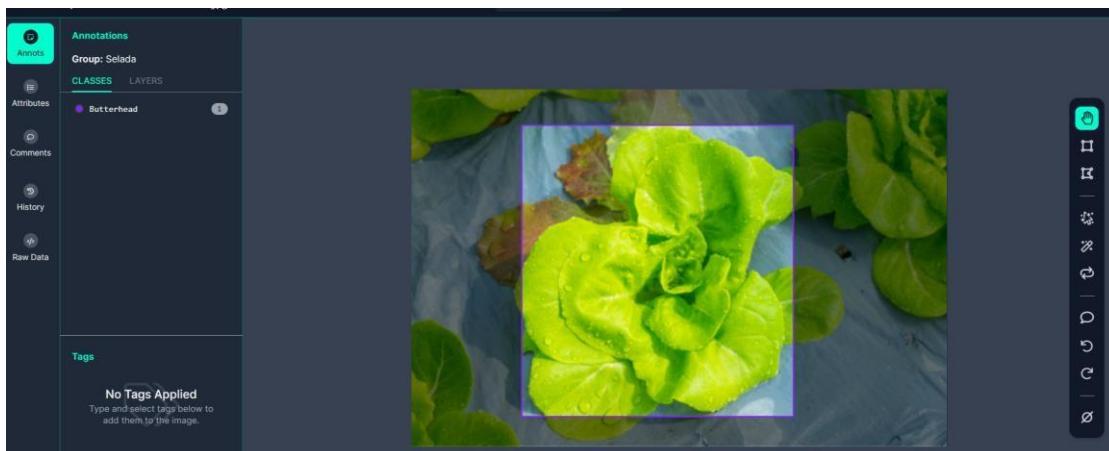
Pada tahapan preprocessing ini merupakan proses pengelolaan gambar selada agar dalam lebih baik dalam tahapan selanjutnya. Pada tahap ini dilakukan beberapa tahapan yaitu :

3.2.2.1 *Resize*

Resize image yang mana tahapan ini bertujuan untuk melakukan pengubahan terhadap ukuran dari setiap gambar, data gambar yang telah terkumpul akan diubah ukurannya menjadi 150x150. Hasil dari proses ini mengakibatkan perlunya penyesuaian data sebelum dapat diimplementasikan sebagai model *TF-Lite*. Proses ini juga berfungsi untuk dapat meringankan kinerja dari sistem.

3.2.2.2 Labeling

Selanjutnya itu adalah *labeling images* yang mana bertujuan untuk melakukan *labeling* terhadap setiap gambar untuk dapat membuat suatu objek yang unik dan dapat dibaca oleh *system*. Data citra akan diberi label dengan memberikan klasifikasi atau anotasi pada setiap citra, terdiri dari enam kelas yang mencakup Selada *Butterhead*, Selada *Green Romanie*, Selada Hijau *New Grand Rapid*, Selada Keriting *oakleaf green*, Selada Merah *Red Rapid*, dan Selada *Red Romaine*. Setelah proses pelabelan, hasilnya akan disimpan dalam bentuk folder yang nantinya digunakan dalam tahap pelatihan data.



Gambar 3.2 Pemberian Label Pada Objek

3.2.2.3 Augmentation

Pada tahap augmentasi yang mana setiap data yang telah diberikan label sebelumnya pada tahap ini kemudian akan dilakukan proses augmentasi yang mana berguna untuk menambah data dengan cara melakukan *flip* dan horizontal pada setiap gambar. Hal ini bertujuan untuk dapat menambah kuantitas data pada data sehingga data yang digunakan dapat jadi jauh lebih banyak yang mana pada awalnya berjumlah 621 citra gambar menjadi 1.242 citra gambar. Proses ini berguna untuk dapat meningkatkan akurasi pada saat proses *training* data. Proses augmentasi ini dilakukan menggunakan web *roboflow*. Adapun pseudocode augmentasi sebagai berikut :

```
def augment_data(image):
    image <--- random_flip_horizontal(image)
    image <--- random_flip_vertical(image)
    image <--- normalize_image(image)
    return image
```

```

def random_flip_horizontal(image):
    return flipped_image

def random_flip_vertical(image):
    return flipped_image

def normalize_image(image):
    return normalized_image

image <--- load_image(image_path)
augmented_image <--- augment_data(image)

```



Gambar 3.3 Proses Augmentasi

3.2.3 *Image Classification*

Pada tahapan *classification* ini akan dilakukan menggunakan metode *Transfer Learning* berikut adalah tahapannya :

3.2.3.1 *Load Pre-train Network*

Pertama-tama akan dilakukan tahapan *load pretrained network* dimana pada tahapan ini peneliti akan mengambil model yang sudah terlatih untuk melakukan klasifikasi berbagai jenis gambar menggunakan *Resnet15v2*, *DenseNet121*, *Inception V3*, dan *VGG19*.

3.2.3.2 Replace Final Layer

Setelahnya dilakukan tahapan *replace final layer* yang untuk tahapan ini peneliti akan melakukan modifikasi pada layer terakhir pada setiap model sebelumnya untuk dapat membuat suatu layer baru yang lebih spesifik dalam melakukan klasifikasi jenis tanaman selada.

3.2.3.3 Train Classifier

Tahapan berikutnya itu melakukan *train classifier* pada tahapan ini dilakukan *training images* menggunakan metode *Resnet15v2*, *DenseNet121*, *Inception V3*, dan *VGG19* yang telah dilakukan pengubahan tadi sampai mendapatkan hasil klasifikasi yang tepat. Gambar di bawah ini merupakan *pretrain model* yang akan di *train* dalam melakukan pengujian terhadap dataset selada.

3.2.3.4 Evaluated Model

Pada tahapan selanjutnya akan dilakukan evaluasi terhadap model yang telah berhasil sebelumnya dengan menguji cobanya menggunakan gambar yang peneliti masukkan apakah model tersebut dapat mengenali gambar yang di *input* atau tidak. Jika bisa maka model sudah masuk kedalam tahapan berhasil. Setiap model tersebut selanjutnya akan dilakukan semacam seleksi dalam menentukan mana model yang paling baik dalam melakukan klasifikasi pada penelitian ini.

3.2.4 Learned Model

Setelah berhasil dalam tahapan *evaluated model*, selanjutnya model yang berhasil tadi akan masuk kedalam tahapan *learned model* yang mana model tersebut sudah bisa memberikan prediksi gambar yang diinput dengan hasil akurasi yang cukup baik dan akan ditetapkan sebagai model yang akan dipakai dalam melakukan klasifikasi terhadap selada

3.2.5 Validation

Tahap validasi merupakan langkah pengujian yang bertujuan untuk memverifikasi mutu sistem di luar situasi uji langsung. Proses ini mencakup pengukuran dan penjaminan bahwa metode atau algoritma yang diterapkan dalam analisis gambar mampu menghasilkan *output* yang tepat, konsisten, dan dapat diandalkan. Validasi menjadi

esensial untuk memastikan bahwa hasil dari pengolahan gambar sesuai dengan harapan dan sesuai dengan tujuan yang telah ditetapkan. Evaluasi ini perlu dilakukan sebagai langkah verifikasi kualitas sistem sebelum diperkenalkan dalam suatu aplikasi.

Pada tahap ini, model-model yang telah terbentuk selama tahap pelatihan akan diuji dengan melakukan evaluasi terhadap kinerja model, dengan fokus pada aspek nilai *loss* yang dihasilkan selama pelatihan model. Proses validasi ini juga dapat membandingkan model dengan model lain yang telah dibentuk untuk memastikan bahwa model yang dipilih adalah yang terbaik. Hasil dari model ini dapat bervariasi berdasarkan kombinasi parameter antara *batch size* dan langkah-langkah (*steps*) yang digunakan dalam pelatihan.

3.2.6 *TFLite Model*

Pada tahap sebelumnya, *output* dari pelatihan menghasilkan *saved model* dengan ekstensi .pb. Pada tahap ini, file tersebut akan diubah menjadi format *Tensorflow Lite (TFLite)*. Proses konversi ini diperlukan karena sistem yang sedang dikembangkan akan diimplementasikan pada platform *Android*. *Tensorflow Lite* menyediakan dasar untuk model *Tensorflow* yang telah dilatih sepenuhnya, yang dapat dikompres dan digunakan pada perangkat seluler. Melalui konversi ke format *TFLite*, ukuran *file* akan berkurang dalam bentuk *biner*, menjadikannya lebih efisien dan sesuai untuk penggunaan pada perangkat *mobile*.

3.2.7 *Output*

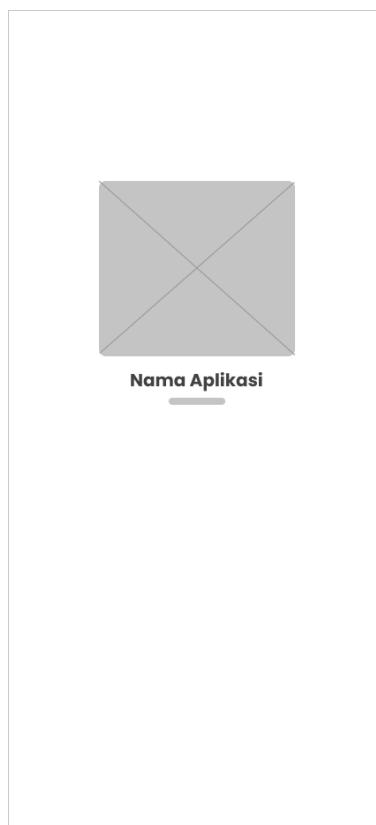
Ini merupakan tahapan terakhir dari system ini yang mana merupakan hasil dari setiap proses yang telah dilakukan. Tahapan ini akan memperlihatkan akurasi dari objek yang diinput dan mampu melakukan klasifikasi setiap jenis tanaman selada.

3.3 Perancangan Antar Muka Sistem

Pada tahap ini, dilakukan perancangan antarmuka untuk aplikasi klasifikasi jenis tanaman selada yang diberi nama "Hyponic". Perancangan ini bertujuan untuk menggambarkan secara visual bagaimana sistem yang akan dibangun direncanakan akan berfungsi. Sistem ini akan diimplementasikan dalam bentuk aplikasi berbasis mobile. Berikut adalah gambaran dari beberapa tampilan yang telah direncanakan :

3.3.1 *Splash Screen*

Splash screen adalah tampilan awal yang muncul ketika pengguna membuka sebuah aplikasi *Android* sebelum aplikasi tersebut sepenuhnya dimuat dan tampil di layar perangkat. Biasanya, *splash screen Android* berisi logo atau elemen grafis merek dari aplikasi, dan tujuannya adalah memberikan pengalaman awal kepada pengguna sambil memberi waktu kepada aplikasi untuk memuat sumber daya dan data yang diperlukan. *Splash screen* ini bertindak sebagai antarmuka pengguna pertama yang memperkenalkan aplikasi kepada pengguna sebelum mereka masuk ke tampilan utama atau aktivitas dalam aplikasi tersebut



Gambar 3.4 Rancangan Tampilan *Splash Screen*

3.3.2 Tampilan *Home Screen*

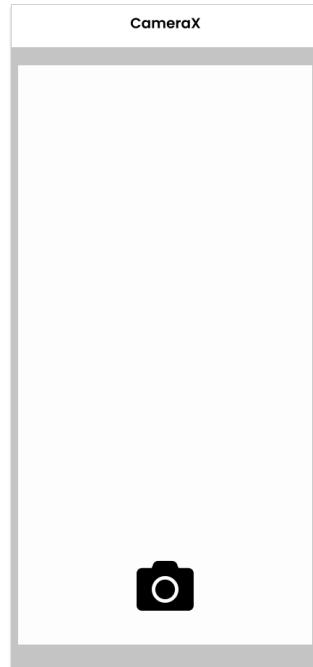
Tampilan ini adalah halaman home yang mana merupakan pratinjau dari aplikasi yang sedang berjalan, yang memuat artikel-artikel bermanfaat, serta tiga pilihan yang terdapat pada navbar aplikasi yang terdiri dari tombol-tombol yang mengarahkan pengguna ke halaman-halaman yang sesuai dengan setiap menu.



Gambar 3.5 Rancangan Tampilan *Home Screen*

3.3.3 Tampilan Halaman Deteksi Tanaman Selada

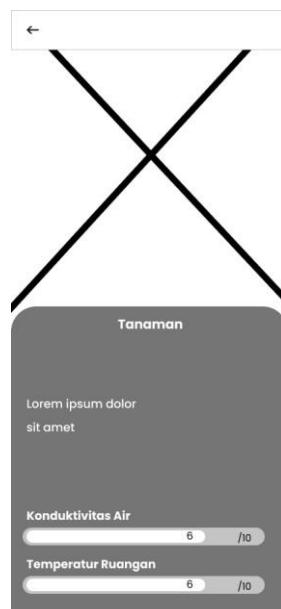
Pada halaman ini, terdapat fitur yang memungkinkan pengguna untuk mendekripsi gambar selada dengan menggunakan kamera foto mereka. Halaman ini akan menyediakan tombol-tombol yang dirancang dengan sangat intuitif agar pengguna dapat dengan mudah memahaminya.



Gambar 3.6 Kamera Deteksi Foto

3.3.4 Tampilan Hasil Deteksi

Halaman ini berfungsi untuk menampilkan hasil dari proses deteksi foto selada. Pada halaman hasil deteksi ini akan menemukan foto selada beserta informasi mengenai tingkat keasaman selada, padatan terlarut, tingkat air, dan suhu yang ideal untuk menyimpan selada.



Gambar 3.7 Halaman Hasil Deteksi Foto

BAB IV

IMPLEMENTASI DAN PENGUJIAN SISTEM

Dalam bab ini, akan dibahas mengenai proses implementasi klasifikasi jenis tanaman selada menggunakan metode *Transfer Learning* berdasarkan rancangan yang telah dipersiapkan sebelumnya. Selain itu, pada bab ini akan dilakukan analisis dan pemaparan hasil dari pengujian sistem.

4.1 Implementasi Sistem

Pada tahap ini, akan diterapkan metode *Transfer Learning* untuk mengklasifikasi jenis tanaman selada dengan menggunakan perangkat *Android*. Untuk melaksanakan ini, diperlukan sistem perangkat keras dan perangkat lunak yang mendukung, yakni sebagai berikut:

4.1.1 Perangkat Keras dan Perangkat Lunak

Penelitian ini mengimplementasikan model sebagai sebuah aplikasi yang mana Untuk membangun sistem pendekripsi ini dibutuhkan perangkat keras dan perangkat lunak. Di bawah ini akan dijelaskan perangkat keras dan perangkat lunak yang digunakan :

- Spesifikasi Hardware dan Software pada laptop :
 1. Laptop Acer Nitro 5
 2. *Processor Intel Core I5-11300H 3,10 GHz*
 3. GPU Nvidia Geforce GTX 3050
 4. RAM 8 GB
 5. Penyimpanan SSD 512GB
 6. *Android Studio*
 7. *Google Colab*
- Spesifikasi Hardware dan Software pada handphone :
 1. *Samsung Galaxy A series*
 2. Ram 8 GB
 3. Resolusi Layar 1080 x 2400.
 4. Penyimpanan 128GB

4.2 Implementasi Data

Data gambar yang digunakan dalam penelitian ini adalah gambar tanaman selada, yang terdiri dari enam jenis, yaitu Selada *Butterhead*, Selada *Green Romanie*, Selada Hijau *New Grand Rapid*, Selada Keriting *Oakleaf Green*, Selada Merah *Red Rapid*, dan Selada *Red Romaine*. Data ini diperoleh dari beberapa petani selada di Medan dan juga menggunakan dataset yang tersedia di *Kaggle*, dengan total sebanyak 621 gambar, 80% dari data akan dialokasikan untuk pelatihan dan sisanya, 20%, akan digunakan sebagai data validasi. Contoh-contoh citra gambar yang digunakan dapat dilihat pada gambar-gambar di bawah ini :



Gambar 4.1 Selada Butterhead



Gambar 4.2 Selada Green Romanie



Gambar 4.3 Selada New Grand Rapid



Gambar 4.4 Selada Keriting Oakleaf Green



Gambar 4.5 Selada Red Rapid



Gambar 4.6 Selada Red Romaine

4.3 Pelatihan Sistem

Setelah data melalui tahap preprocessing selanjutnya akan dibuat suatu model yang akan dilatih untuk memahami ciri-ciri pada setiap objek menggunakan beberapa *premodel*. Pada penelitian kali ini data akan di *training* menggunakan empat *premodel* yaitu *RestNet152V2*, *DenseNet121*, *Inception v3*, dan *VGG19*. Pada *training* setiap *premodel* digunakan *early stopping* yang merupakan teknik yang digunakan dalam machine learning untuk menghentikan pelatihan model secara otomatis ketika kinerja model pada dataset validasi tidak lagi mengalami peningkatan yang signifikan. Tujuan utama dari *early stopping* adalah untuk menghindari *overfitting*, yaitu ketika model terlalu "menghafal" data pelatihan sehingga tidak dapat menggeneralisasi dengan baik

pada data yang belum pernah dilihat sebelumnya. Dengan *early stopping*, pelatihan akan berhenti saat model mencapai tingkat kinerja terbaiknya pada data validasi, sehingga menghasilkan model yang lebih baik dan mencegah *overfitting*. Kemudian, akan dipilih *pre-model* yang memberikan hasil terbaik untuk digunakan dalam mengklasifikasikan tanaman selada. Seluruh proses ini dilakukan di platform *Google Collab*. Berikut tabel hasil *training* setiap *pre-model* yang telah dilakukan :

Tabel 4.1 Hasil Training Setiap Pre-model

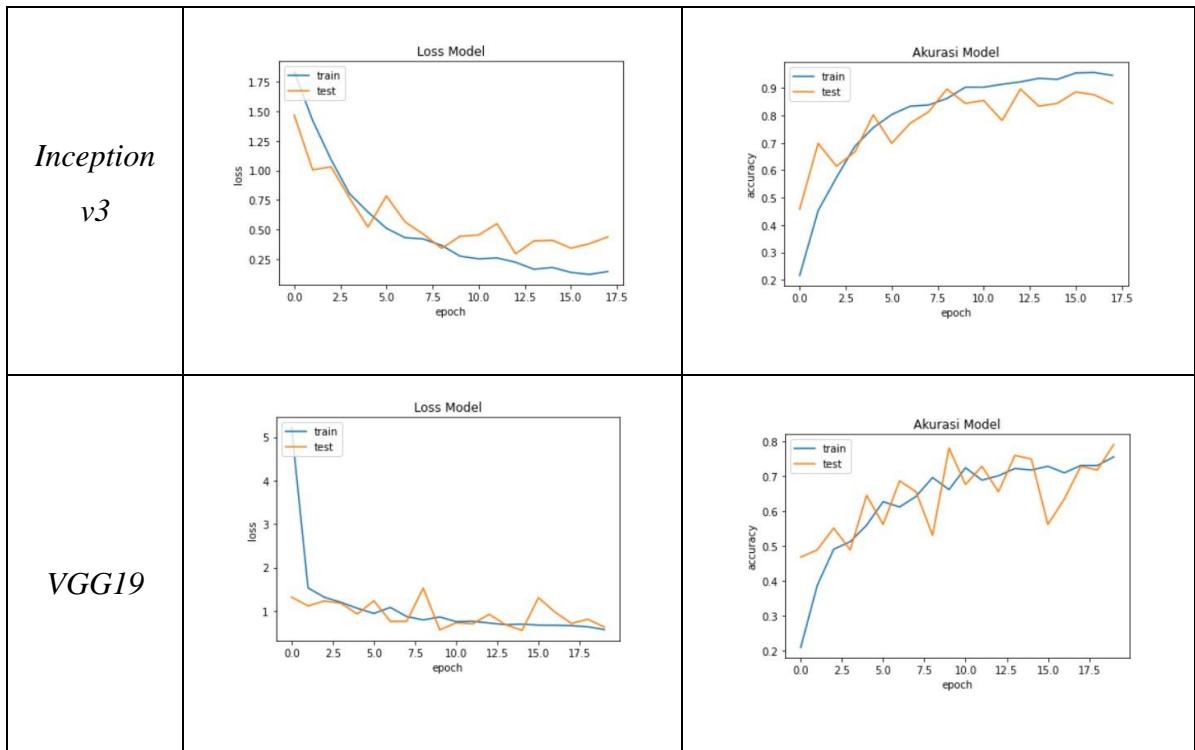
Pre-model	Epoch	Loss	Train Accuracy	Val Loss	Val Accuracy
<i>RestNet152V2</i>	10	2.0839	0.6255	1.4129	0.6979
	20	1.2886	0.7056	1.0429	0.7500
	30	1.1399	0.7229	0.8610	0.7604
	40	0.5689	0.8333	1.0981	0.7708
	50	0.7893	0.8052	0.9013	0.77083
<i>DenseNet121</i>	10	0.7386	0.7078	0.3999	0.8125
	20	0.4259	0.8571	0.2977	0.8958
	30	0.3468	0.8810	0.4305	0.8438
	42	0.2232	0.9156	0.2589	0.9375
	50	0.1918	0.9307	0.7115	0.9375
<i>Inception v3</i>	10	1.4229	0.4524	1.0038	0.6979
	20	0.6466	0.7554	0.5185	0.8021
	30	0.4180	0.8377	0.4590	0.8125
	48	0.3636	0.8615	0.3386	0.8958
	50	0.1421	0.9459	0.4356	0.8438
<i>VGG19</i>	10	1.5287	0.3874	1.1153	0.4896
	20	1.0595	0.5606	0.9286	0.6458
	30	1.0805	0.6126	0.7589	0.6875
	40	0.8605	0.6623	0.5640	0.7812
	50	0.5716	0.7563	0.6279	0.7917

Percobaan dilakukan dengan menggunakan *batch size* sebesar 32 dan *epoch* 50. Dari percobaan ini dapat dilihat dari Tabel 4.1 bahwa DenseNet121 dan *Inception V3*

merupakan *pre-model* yang memiliki akurasi *training* terbaik dari ke 4 *pre-model* lainnya oleh karena itu perlu dilakukan pengecekan pada grafiknya yang mana hal ini juga didukung dengan grafik yang tersedia dalam Tabel 4.2 mencerminkan perubahan dalam *loss* dan akurasi model sepanjang proses pelatihan. Grafik *loss* menggambarkan sejauh mana model mampu mengurangi kesalahan prediksi seiring waktu, sementara grafik akurasi mengindikasikan tingkat kemampuan model dalam mengklasifikasikan data dengan benar. Memeriksa grafik-grafik ini memberikan pemahaman visual mengenai perilaku model selama pelatihan, membantu dalam menilai kompleksitas model dan model mana yang mengindikasikan *overfitting*. Berikut grafik dari setiap *pre-model* yang di *training*:

Tabel 4.2 Tabel Grafik *Loss* dan *Accuracy*

Premodel	Grafik Loss	Grafik Accuracy																																																																																																												
<i>ResNet 152V2</i>	<p>Training loss and validation loss</p> <table border="1"> <caption>Data for Training and Validation Loss (ResNet 152V2)</caption> <thead> <tr> <th>Epoch</th> <th>Training Loss</th> <th>Validation Loss</th> </tr> </thead> <tbody> <tr><td>0</td><td>~22</td><td>~2</td></tr> <tr><td>1</td><td>~10</td><td>~2</td></tr> <tr><td>2</td><td>~2</td><td>~2</td></tr> <tr><td>4</td><td>~1</td><td>~2</td></tr> <tr><td>6</td><td>~1</td><td>~2</td></tr> <tr><td>8</td><td>~1</td><td>~2</td></tr> <tr><td>10</td><td>~1</td><td>~2</td></tr> </tbody> </table>	Epoch	Training Loss	Validation Loss	0	~22	~2	1	~10	~2	2	~2	~2	4	~1	~2	6	~1	~2	8	~1	~2	10	~1	~2	<p>Training and validation accuracy</p> <table border="1"> <caption>Data for Training and Validation Accuracy (ResNet 152V2)</caption> <thead> <tr> <th>Epoch</th> <th>Training Accuracy</th> <th>Validation Accuracy</th> </tr> </thead> <tbody> <tr><td>0</td><td>~0.45</td><td>~0.68</td></tr> <tr><td>1</td><td>~0.58</td><td>~0.68</td></tr> <tr><td>2</td><td>~0.62</td><td>~0.68</td></tr> <tr><td>3</td><td>~0.72</td><td>~0.75</td></tr> <tr><td>4</td><td>~0.75</td><td>~0.62</td></tr> <tr><td>5</td><td>~0.78</td><td>~0.78</td></tr> <tr><td>6</td><td>~0.75</td><td>~0.78</td></tr> <tr><td>7</td><td>~0.78</td><td>~0.75</td></tr> <tr><td>8</td><td>~0.78</td><td>~0.75</td></tr> <tr><td>9</td><td>~0.80</td><td>~0.75</td></tr> <tr><td>10</td><td>~0.82</td><td>~0.75</td></tr> <tr><td>11</td><td>~0.85</td><td>~0.78</td></tr> </tbody> </table>	Epoch	Training Accuracy	Validation Accuracy	0	~0.45	~0.68	1	~0.58	~0.68	2	~0.62	~0.68	3	~0.72	~0.75	4	~0.75	~0.62	5	~0.78	~0.78	6	~0.75	~0.78	7	~0.78	~0.75	8	~0.78	~0.75	9	~0.80	~0.75	10	~0.82	~0.75	11	~0.85	~0.78																																													
Epoch	Training Loss	Validation Loss																																																																																																												
0	~22	~2																																																																																																												
1	~10	~2																																																																																																												
2	~2	~2																																																																																																												
4	~1	~2																																																																																																												
6	~1	~2																																																																																																												
8	~1	~2																																																																																																												
10	~1	~2																																																																																																												
Epoch	Training Accuracy	Validation Accuracy																																																																																																												
0	~0.45	~0.68																																																																																																												
1	~0.58	~0.68																																																																																																												
2	~0.62	~0.68																																																																																																												
3	~0.72	~0.75																																																																																																												
4	~0.75	~0.62																																																																																																												
5	~0.78	~0.78																																																																																																												
6	~0.75	~0.78																																																																																																												
7	~0.78	~0.75																																																																																																												
8	~0.78	~0.75																																																																																																												
9	~0.80	~0.75																																																																																																												
10	~0.82	~0.75																																																																																																												
11	~0.85	~0.78																																																																																																												
<i>DenseNet 121</i>	<p>Loss Model</p> <table border="1"> <caption>Data for Loss Model (DenseNet 121)</caption> <thead> <tr> <th>Epoch</th> <th>Train Loss</th> <th>Test Loss</th> </tr> </thead> <tbody> <tr><td>0</td><td>~2.2</td><td>~1.5</td></tr> <tr><td>1</td><td>~1.4</td><td>~0.9</td></tr> <tr><td>2</td><td>~1.1</td><td>~0.8</td></tr> <tr><td>3</td><td>~0.9</td><td>~0.6</td></tr> <tr><td>4</td><td>~0.7</td><td>~0.5</td></tr> <tr><td>5</td><td>~0.6</td><td>~0.6</td></tr> <tr><td>6</td><td>~0.5</td><td>~0.7</td></tr> <tr><td>7</td><td>~0.4</td><td>~0.5</td></tr> <tr><td>8</td><td>~0.35</td><td>~0.6</td></tr> <tr><td>9</td><td>~0.35</td><td>~0.4</td></tr> <tr><td>10</td><td>~0.35</td><td>~0.3</td></tr> <tr><td>11</td><td>~0.35</td><td>~0.4</td></tr> <tr><td>12</td><td>~0.38</td><td>~0.4</td></tr> <tr><td>13</td><td>~0.35</td><td>~0.4</td></tr> <tr><td>14</td><td>~0.35</td><td>~0.4</td></tr> <tr><td>15</td><td>~0.35</td><td>~0.5</td></tr> <tr><td>16</td><td>~0.32</td><td>~0.6</td></tr> </tbody> </table>	Epoch	Train Loss	Test Loss	0	~2.2	~1.5	1	~1.4	~0.9	2	~1.1	~0.8	3	~0.9	~0.6	4	~0.7	~0.5	5	~0.6	~0.6	6	~0.5	~0.7	7	~0.4	~0.5	8	~0.35	~0.6	9	~0.35	~0.4	10	~0.35	~0.3	11	~0.35	~0.4	12	~0.38	~0.4	13	~0.35	~0.4	14	~0.35	~0.4	15	~0.35	~0.5	16	~0.32	~0.6	<p>Model Accuracy</p> <table border="1"> <caption>Data for Model Accuracy (DenseNet 121)</caption> <thead> <tr> <th>Epoch</th> <th>Train Accuracy</th> <th>Test Accuracy</th> </tr> </thead> <tbody> <tr><td>0</td><td>~0.25</td><td>~0.42</td></tr> <tr><td>1</td><td>~0.45</td><td>~0.55</td></tr> <tr><td>2</td><td>~0.65</td><td>~0.72</td></tr> <tr><td>3</td><td>~0.75</td><td>~0.82</td></tr> <tr><td>4</td><td>~0.82</td><td>~0.88</td></tr> <tr><td>5</td><td>~0.85</td><td>~0.90</td></tr> <tr><td>6</td><td>~0.82</td><td>~0.88</td></tr> <tr><td>7</td><td>~0.85</td><td>~0.90</td></tr> <tr><td>8</td><td>~0.88</td><td>~0.92</td></tr> <tr><td>9</td><td>~0.85</td><td>~0.90</td></tr> <tr><td>10</td><td>~0.88</td><td>~0.92</td></tr> <tr><td>11</td><td>~0.85</td><td>~0.90</td></tr> <tr><td>12</td><td>~0.88</td><td>~0.92</td></tr> <tr><td>13</td><td>~0.85</td><td>~0.90</td></tr> <tr><td>14</td><td>~0.88</td><td>~0.92</td></tr> <tr><td>15</td><td>~0.85</td><td>~0.90</td></tr> <tr><td>16</td><td>~0.88</td><td>~0.92</td></tr> </tbody> </table>	Epoch	Train Accuracy	Test Accuracy	0	~0.25	~0.42	1	~0.45	~0.55	2	~0.65	~0.72	3	~0.75	~0.82	4	~0.82	~0.88	5	~0.85	~0.90	6	~0.82	~0.88	7	~0.85	~0.90	8	~0.88	~0.92	9	~0.85	~0.90	10	~0.88	~0.92	11	~0.85	~0.90	12	~0.88	~0.92	13	~0.85	~0.90	14	~0.88	~0.92	15	~0.85	~0.90	16	~0.88	~0.92
Epoch	Train Loss	Test Loss																																																																																																												
0	~2.2	~1.5																																																																																																												
1	~1.4	~0.9																																																																																																												
2	~1.1	~0.8																																																																																																												
3	~0.9	~0.6																																																																																																												
4	~0.7	~0.5																																																																																																												
5	~0.6	~0.6																																																																																																												
6	~0.5	~0.7																																																																																																												
7	~0.4	~0.5																																																																																																												
8	~0.35	~0.6																																																																																																												
9	~0.35	~0.4																																																																																																												
10	~0.35	~0.3																																																																																																												
11	~0.35	~0.4																																																																																																												
12	~0.38	~0.4																																																																																																												
13	~0.35	~0.4																																																																																																												
14	~0.35	~0.4																																																																																																												
15	~0.35	~0.5																																																																																																												
16	~0.32	~0.6																																																																																																												
Epoch	Train Accuracy	Test Accuracy																																																																																																												
0	~0.25	~0.42																																																																																																												
1	~0.45	~0.55																																																																																																												
2	~0.65	~0.72																																																																																																												
3	~0.75	~0.82																																																																																																												
4	~0.82	~0.88																																																																																																												
5	~0.85	~0.90																																																																																																												
6	~0.82	~0.88																																																																																																												
7	~0.85	~0.90																																																																																																												
8	~0.88	~0.92																																																																																																												
9	~0.85	~0.90																																																																																																												
10	~0.88	~0.92																																																																																																												
11	~0.85	~0.90																																																																																																												
12	~0.88	~0.92																																																																																																												
13	~0.85	~0.90																																																																																																												
14	~0.88	~0.92																																																																																																												
15	~0.85	~0.90																																																																																																												
16	~0.88	~0.92																																																																																																												

Tabel 4.2 Tabel Grafik Loss dan Accuracy

Berdasarkan Tabel 4.2, dapat disimpulkan bahwa di antara keempat *pre-model* yang digunakan, *DenseNet121* adalah yang paling optimal. Kesimpulan ini dapat ditarik dengan memeriksa grafik *loss* dan grafik akurasi secara visual. Identifikasi titik di mana *loss* mulai stabil atau meningkat dan akurasi mencapai puncaknya adalah penting.

Dalam grafik *loss*, perhatikan kemungkinan adanya *overfitting*, yang terjadi ketika *loss* pada data validasi mulai meningkat sementara *loss* pada data pelatihan tetap menurun. Pada grafik akurasi, perhatikan bahwa garis-garis yang mewakili akurasi pada data pelatihan dan data validasi mulai bergerak menjauh satu sama lain. Ini merupakan indikasi yang lebih kuat tentang adanya *overfitting*, dan semakin besar perbedaan antara keduanya, semakin signifikan *overfitting*-nya.

4.4 Implementasi Perancangan Interface

Dengan mengacu pada rancangan yang telah disusun di Bab Tiga, implementasi dari antarmuka tersebut dapat diuraikan sebagai berikut:

4.4.1 Tampilan Halaman *Home Screen*

Pada halaman ini, pengguna akan mengalami tampilan awal aplikasi (*splash screen*) diikuti oleh layar utama (*home screen*). Layar utama ini akan menampilkan logo "HyPonics" dan selanjutnya mengarahkan pengguna ke beranda (*home page*). Di beranda, terdapat berbagai artikel yang dapat dibaca oleh pengguna. Selanjutnya, terdapat dua tombol navigasi yang memungkinkan pengguna untuk berpindah antara halaman beranda dan tombol identifikasi. Tombol identifikasi akan membawa pengguna ke halaman klasifikasi ketika ditekan.



Gambar 4.7 Splash Screen dan Home Screen

4.4.2 Tampilan Halaman Artikel

Pada halaman artikel, pengguna dapat mengakses dan membaca berbagai artikel terkait selada yang telah disediakan. Setiap artikel berisi informasi yang bermanfaat tentang selada, dan tujuan utama dari artikel-artikel ini adalah untuk memberikan wawasan yang lebih mendalam kepada pengguna mengenai pemanfaatan dan pengolahan selada yang tepat dan benar. Dengan demikian, pengguna diharapkan akan memperoleh

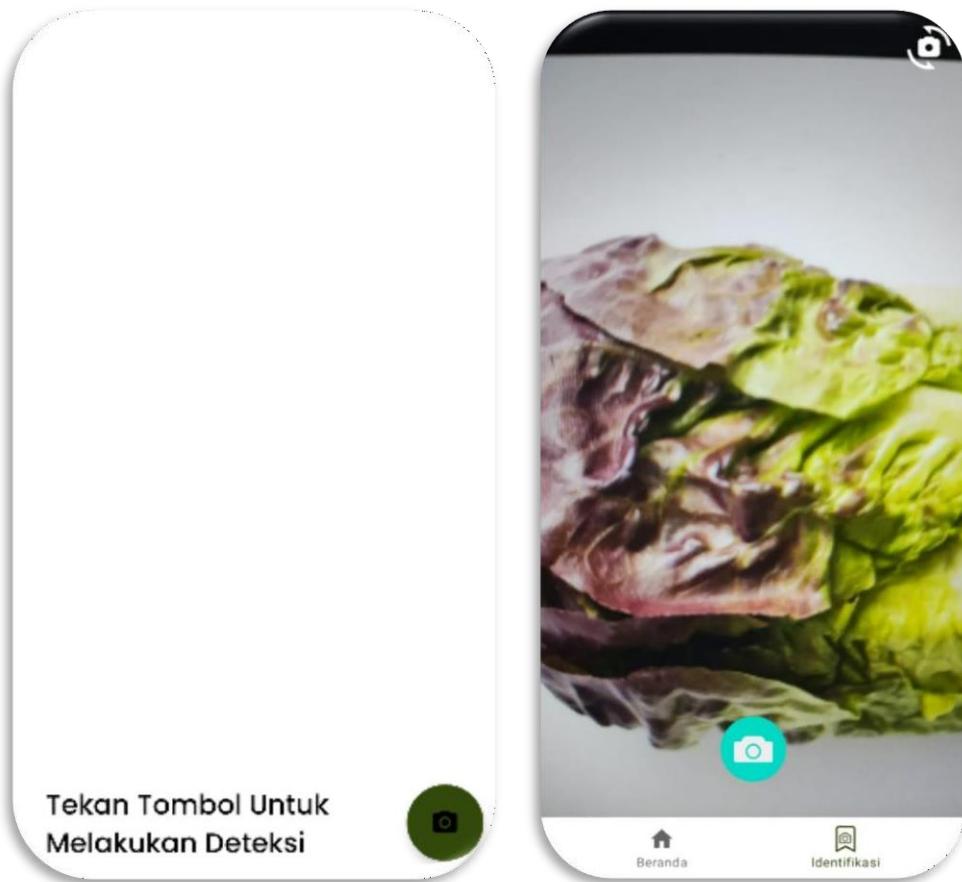
pemahaman yang lebih baik tentang cara yang baik dan benar dalam memanfaatkan selada.



Gambar 4.8 Halaman Artikel

4.4.3 Tampilan Halaman Deteksi

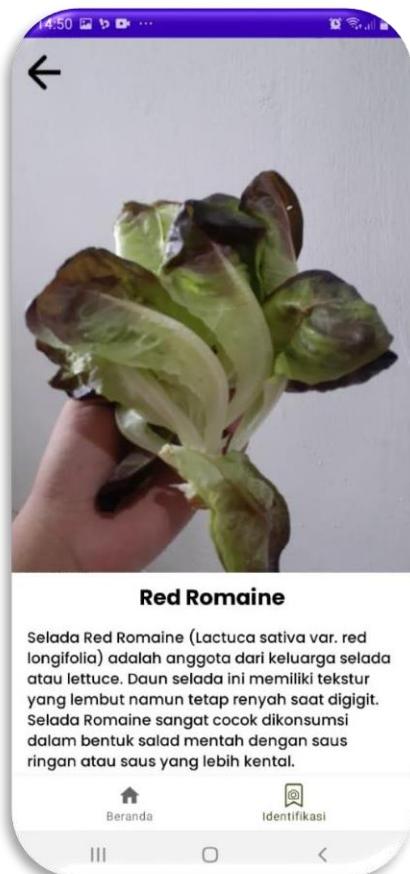
Pada halaman deteksi, pengguna akan diminta untuk menekan tombol yang menandakan kamera untuk mengakses kamera pada perangkat mereka. Sebelum dapat mengakses kamera, pengguna akan diminta memberikan persetujuan agar aplikasi dapat menggunakan kamera pada perangkat mereka. Setelah izin diberikan, pengguna akan diminta untuk mengambil foto dari selada yang akan dideteksi, sehingga aplikasi dapat mendeteksi jenis selada tersebut.



Gambar 4.9 Halaman Identifikasi

4.4.4 Halaman Klasifikasi

Setelah pengguna melalui halaman deteksi, hasil dari proses klasifikasi akan ditampilkan pada halaman klasifikasi. Di halaman ini, pengguna akan dapat melihat jenis selada yang telah difoto sebelumnya, serta informasi singkat mengenai selada tersebut.



Gambar 4.10 Halaman Klasifikasi

4.5 Pengujian Sistem

Tahapan ini adalah tahap di mana dilakukan pengujian pada sistem yang menggunakan model hasil pelatihan dari tahap sebelumnya. Pengujian ini bertujuan untuk mengukur kemampuan model dalam mendeteksi jenis tanaman selada. Pengujian dilakukan dengan menggunakan kamera pada *smartphone* yang telah diinstal aplikasi yang menggunakan model tersebut.

Tabel 4.3 Pengujian Sistem

No.	Citra	Aktual	Prediksi	Status
1.		<i>New Grand Rapid</i>	<i>New Grand Rapid</i>	Benar
2.		<i>New Grand Rapid</i>	<i>New Grand Rapid</i>	Benar
3.		<i>New Grand Rapid</i>	<i>New Grand Rapid</i>	Benar
4.		<i>New Grand Rapid</i>	<i>New Grand Rapid</i>	Benar

5.	 <p>New Grand Rapid</p> <p>Selada Grand Rapid (Lactuca sativa var. sativa) atau Grand Rapid ini memiliki bentuk oval dengan permukaan yang lentang, dan memiliki warna hijau segar yang menarik. Selada ini memiliki tekstur yang lembut namun tetap renyah saat digigit. Selada Grand Rapid sangat cocok dikonsumsi dalam bentuk salad mentah.</p> <p>Ponselku untuk Selada Beranda Identifikasi</p>	<i>New Grand Rapid</i>	<i>New Grand Rapid</i>	Benar
6.	 <p>Green Romaine</p> <p>Selada Green Romaine (Lactuca sativa var. longifolia) adalah sayuran dari keluarga selada atau lettuce. Daun selada ini memiliki tekstur yang lembut namun tetap renyah saat digigit. Selada Romaine sangat cocok dikonsumsi dalam bentuk salad mentah.</p> <p>Ponselku untuk Selada Beranda Identifikasi</p>	<i>Green Romaine</i>	<i>Green Romaine</i>	Benar
7.	 <p>Green Romaine</p> <p>Selada Green Romaine (Lactuca sativa var. longifolia) adalah sayuran dari keluarga selada atau lettuce. Daun selada ini memiliki tekstur yang lembut namun tetap renyah saat digigit. Selada Romaine sangat cocok dikonsumsi dalam bentuk salad mentah.</p> <p>Ponselku untuk Selada Beranda Identifikasi</p>	<i>Green Romaine</i>	<i>Green Romaine</i>	Benar
8.	 <p>Green Romaine</p> <p>Selada Green Romaine (Lactuca sativa var. longifolia) adalah sayuran dari keluarga selada atau lettuce. Daun selada ini memiliki tekstur yang lembut namun tetap renyah saat digigit. Selada Romaine sangat cocok dikonsumsi dalam bentuk salad mentah.</p> <p>Ponselku untuk Selada Beranda Identifikasi</p>	<i>Green Romaine</i>	<i>Green Romaine</i>	Benar

9.	 <p>Red Romaine</p> <p>Selada Red Romaine (Lactuca sativa var. longifolia) adalah sayuran daun keluaran selada atau lettuce. Daun selada ini memiliki tekstur yang lembut namun tetap renyah saat digigit. Selada ini biasanya dimakan mentah sebagai topping dalam membuat salad makanan dingin atau souce yang lebih kental.</p> <p>Home Identifikasi</p>	<i>Green Romaine</i>	<i>Red Romaine</i>	Salah
10.	 <p>Green Romaine</p> <p>Selada Green Romaine (Lactuca sativa var. longifolia) adalah sayuran daun keluaran selada atau lettuce. Daun selada ini memiliki tekstur yang lembut namun tetap renyah saat digigit. Selada Romaine sangat cocok dikonsumsi dalam bentuk salad mentah.</p> <p>Home Identifikasi</p>	<i>Green Romaine</i>	<i>Green Romaine</i>	Benar
11.	 <p>Butterhead</p> <p>Selada Butterhead (L. sativa var. capitata) adalah salah satu jenis selada yang sangat populer. Jenis selada ini disukai oleh banyak orang karena memiliki bentuk yang unik dan daun-daunnya yang lembut. Dilengkapi dengan jalinan selada yang kuat, selada Butterhead cenderung lebih lembut, memilki bentuk yang</p> <p>Home Identifikasi</p>	<i>Butterhead</i>	<i>Butterhead</i>	Benar
12.	 <p>Butterhead</p> <p>Selada Butterhead (L. sativa var. capitata) adalah salah satu jenis selada yang sangat populer. Jenis selada ini disukai oleh banyak orang karena memiliki bentuk yang unik dan daun-daunnya yang lembut. Dilengkapi dengan jalinan selada yang kuat, selada Butterhead cenderung lebih lembut, memilki bentuk yang</p> <p>Home Identifikasi</p>	<i>Butterhead</i>	<i>Butterhead</i>	Benar

13.	 <p>Butterhead</p> <p>Selada Butterhead (<i>L. sativa var. capitata</i>) adalah selada satu jenis selada yang sangat populer. Jenis selada ini ditakdir oleh banyak orang karena memiliki aroma yang khas dan daun-daunnya yang amukat. Dibandingkan dengan jenis selada lainnya, Selada Butterhead mengandung lebih banyak vitamin yang baik.</p>		<i>Butterhead</i>	<i>Butterhead</i>	Benar
14.	 <p>Butterhead</p> <p>Selada Butterhead (<i>L. sativa var. capitata</i>) adalah selada satu jenis selada yang sangat populer. Jenis selada ini ditakdir oleh banyak orang karena memiliki aroma yang khas dan daun-daunnya yang amukat. Dibandingkan dengan jenis selada lainnya, Selada Butterhead mengandung lebih banyak vitamin yang baik.</p>		<i>Butterhead</i>	<i>Butterhead</i>	Benar
15.	 <p>Butterhead</p> <p>Selada Butterhead (<i>L. sativa var. capitata</i>) adalah selada satu jenis selada yang sangat populer. Jenis selada ini ditakdir oleh banyak orang karena memiliki aroma yang khas dan daun-daunnya yang amukat. Dibandingkan dengan jenis selada lainnya, Selada Butterhead mengandung lebih banyak vitamin yang baik.</p>		<i>Butterhead</i>	<i>Butterhead</i>	Benar
16.	 <p>Oakleaf</p> <p>Selada Oakleaf adalah jenis selada keriting yang memiliki penampilan yang sangat menarik, dengan daun yang berlapis hijau dan terdapat garis-garis putih di bagian dalam menyirip di sekitar puncak (oak), sehingga dikenal "Oakleaf" atau "Selada oak". Keritisan dan bentuknya yang unik membuat selada Oakleaf menjadi pilihan yang populer dalam hidangan salad dan memberikan sentuhan estetika yang menarik pada sajian.</p>		<i>Oakleaf</i>	<i>Oakleaf</i>	Benar

17.	 <p>Oakleaf</p> <p>Selada Oakleaf adalah jenis selada keriting yang memiliki penampakan yang sangat merakir, dengan daun yang berwarna hijau dan mengkilap. Bentuk daunnya bulat dan menyerupai daun pohon ek (oak), sehingga dinamai "Oakleaf" atau "selai oak". Keindahan dan bentuknya yang unik membuat selada</p> <p>Bantah Identifikasi</p>	<i>Oakleaf</i>	<i>Oakleaf</i>	Benar
18.	 <p>Oakleaf</p> <p>Selada Oakleaf adalah jenis selada keriting yang memiliki penampakan yang sangat merakir, dengan daun yang berwarna hijau dan mengkilap. Bentuk daunnya bulat dan menyerupai daun pohon ek (oak), sehingga dinamai "Oakleaf" atau "selai oak". Keindahan dan bentuknya yang unik membuat selada</p> <p>Bantah Identifikasi</p>	<i>Oakleaf</i>	<i>Oakleaf</i>	Benar
19.	 <p>Oakleaf</p> <p>Selada Oakleaf cocok jadi sela-sela keriting yang memiliki penampakan yang sangat merakir, dengan daun yang berwarna hijau dan mengkilap. Bentuk daunnya bulat dan menyerupai daun pohon ek (oak), sehingga dinamai "Oakleaf" atau "selai oak". Keindahan dan bentuknya yang unik membuat selada</p> <p>Bantah Identifikasi</p>	<i>Oakleaf</i>	<i>Oakleaf</i>	Benar
20.	 <p>Green Romaine</p> <p>Selada romaine cocok jadi sela-sela keriting yang memiliki penampakan yang sangat merakir, dengan daun yang berwarna hijau dan mengkilap. Bentuk daunnya bulat dan menyerupai daun pohon ek (oak), sehingga dinamai "Oakleaf" atau "selai oak". Keindahan dan bentuknya yang unik membuat selada</p> <p>Bantah Identifikasi</p>	<i>Green Romaine</i>	<i>Green Romaine</i>	Benar

21.	 <p>Oakleaf</p> <p>Selada Oakleaf mirip seperti romaine tetapi dengan bentuk daun yang berwarna hijau yang menarik, dengan daun yang berwarna hijau dan mengkilap, bentuk daunnya bulat dan menyerupai daun pohon oak. Daunnya juga dinamai "Oakleaf" atau "salad oak". Kendohnya dan bentuknya yang unik membuat Selada Oakleaf ini menjadi salah satu jenis selada yang banyak diminati.</p>	<i>Green Romaine</i>	<i>Green Romaine</i>	Benar
22.	 <p>Red Rapid</p> <p>Selada Red Rapid mirip seperti grand rapid mempunyai daun yang berbentuk keriting dan yang membedakannya adalah warnanya merah tua. Daunnya berbentuk oval dengan permukaan yang keriting, dan memiliki warna hijau segar yang merah. Selada Grand Rapid dapat tumbuh baik di musim hujan maupun panas.</p>	<i>Red Rapid</i>	<i>Red Rapid</i>	Benar
23.	 <p>Red Rapid</p> <p>Selada Red Rapid mirip seperti grand rapid mempunyai daun yang berbentuk keriting dan yang membedakannya adalah warnanya merah tua. Daunnya berbentuk oval dengan permukaan yang keriting, dan memiliki warna hijau segar yang merah. Selada Grand Rapid dapat tumbuh baik di musim hujan maupun panas.</p>	<i>Red Rapid</i>	<i>Red Rapid</i>	Benar
24.	 <p>Red Romaine</p> <p>Selada Red Romaine mirip seperti romaine var. red (merah) tetapi dengan bentuk daunnya yang berbentuk keriting atau lettuce. Daun selada ini memiliki tekstur yang lembut namun tetap kuat saat sedang dipotong. Selada Romaine sering kali dicampur dengan daging bahan salad membuatnya dengan rasa ringan atau sosis yang lembut ketika dimakan.</p>	<i>Red Rapid</i>	<i>Red Romaine</i>	Salah

25.	 <p>Red Rapid</p> <p>Selada Red Rapid atau grand rapid merupakan daun yang berukuran sedang dan yang membedakannya adalah bentuk bulat dan berbentuk oval dengan permukaan yang kering dan memiliki tekstur yang manis. Selada Grand Rapid ini dapat tumbuh baik pada musim hujan maupun</p> <p>Beranda Identifikasi</p>	<i>Red Rapid</i>	<i>Red Rapid</i>	Benar
26.	 <p>Red Rapid</p> <p>Selada Red Rapid mirip seperti grand rapid tetapi ukurannya lebih besar dan berbentuk bulat. Daunnya berbentuk oval dengan permukaan yang kering dan memiliki warna hijau seger yang manis. Selada Grand Rapid ini dapat tumbuh baik pada musim hujan maupun</p> <p>Beranda Identifikasi</p>	<i>Red Rapid</i>	<i>Red Rapid</i>	Benar
27.	 <p>Red Romaine</p> <p>Selada Red Romaine (Lactuca sativa var. red longifolia) adalah anggota dari keluarga selada atau lettuce. Daun selada ini memiliki tekstur yang lembut namun tetap memiliki sedikit kekentalan. Selada Romaine sangat cocok dikonsumsi dalam bentuk salad mentah dengan saus rujak atau saus yang lembut.</p> <p>Beranda Identifikasi</p>	<i>Red Romaine</i>	<i>Red Romaine</i>	Benar
28.	 <p>Red Romaine</p> <p>Selada Romaine (Lactuca sativa var. red longifolia) adalah anggota dari keluarga selada atau lettuce. Daun selada ini memiliki tekstur yang lembut namun tetap memiliki sedikit kekentalan. Selada Romaine sangat cocok dikonsumsi dalam bentuk salad mentah dengan saus rujak atau saus yang lembut.</p> <p>Beranda Identifikasi</p>	<i>Red Romaine</i>	<i>Red Romaine</i>	Benar

29.			<i>Red Romaine</i>	<i>Red Romaine</i>	Benar
30.			<i>Red Romaine</i>	<i>Red Romaine</i>	Benar
31.			<i>Red Romaine</i>	<i>Red Romaine</i>	Benar

Pengujian yang telah dilakukan melibatkan 72 data uji untuk setiap kelas dan dilakukan secara *real-time*. Hasil dari pengujian tersebut direpresentasikan dalam bentuk *Confusion Matrix* yang dapat ditemukan pada Tabel 4.4.

Tabel 4.4 Confusion Matrix

		Aktual						Total
		New Grand Rapid	Green Romaine	Butterhead	Oakleaf	Red Rapid	Red Romaine	
Prediksi	New Grand Rapid	12	0	0	0	0	0	12
	Green Romaine	0	11	2	0	0	0	13
	Butterhead	0	0	10	0	0	0	10
	Oakleaf	0	0	0	12	0	0	12
	Red Rapid	0	0	0	0	11	1	12
	Red Romaine	0	1	0	0	1	11	13
Total		12	12	12	12	12	12	72

Dalam pengujian yang telah dilakukan, juga terdapat sejumlah kesalahan dalam hasil deteksi. Ini terjadi karena adanya kemiripan antara enam kelas dan pada sudut tertentu selama proses pendekripsi. Hasil dari pengujian ini dipaparkan dalam Tabel 4.5.

Tabel 4.5 Hasil Pengujian

	TP	FP	FN
New Grand Rapid	12	0	0
Green Romaine	11	2	1
Butterhead	10	0	2
Oakleaf	12	0	0
Red Rapid	11	1	1
Red Romaine	11	2	1
Total	67	5	5

Berikut adalah perhitungan yang digunakan untuk menghitung nilai Akurasi, Presisi, *Recall*, dan F-1 Score:

a. *Precision*

Rumus perhitungan *Precision* pada persamaan (2)

$$\text{New Grand Rapid} = \frac{12}{12+0} \times 100\% = 100\%$$

$$\text{Green Romaine} = \frac{11}{11+2} \times 100\% = 84,6\%$$

$$\text{Butterhead} = \frac{10}{10+0} \times 100\% = 100\%$$

$$\text{Oakleaf} = \frac{12}{12+0} \times 100\% = 100\%$$

$$\text{Red Rapid} = \frac{11}{11+1} \times 100\% = 91,6\%$$

$$\text{Red Romaine} = \frac{11}{11+2} \times 100\% = 84,6\%$$

b. *Recall*

Rumus perhitungan *Recall* pada persamaan (3)

$$\text{New Grand Rapid} = \frac{12}{12+0} \times 100\% = 100\%$$

$$\text{Green Romaine} = \frac{11}{11+1} \times 100\% = 91,6\%$$

$$\text{Butterhead} = \frac{10}{10+2} \times 100\% = 83,3\%$$

$$\text{Oakleaf} = \frac{12}{12+0} \times 100\% = 100\%$$

$$\text{Red Rapid} = \frac{11}{11+1} \times 100\% = 91,6\%$$

$$\text{Red Romaine} = \frac{11}{11+1} \times 100\% = 91,6\%$$

c. *F1-Score*

Rumus perhitungan *F1-Score* pada persamaan (4)

$$\text{New Grand Rapid} = 2 \times \frac{(100\% \times 100\%)}{(100\% + 100\%)} = 100\%$$

$$\text{Green Romaine} = 2 \times \frac{(91,6\% \times 84,6\%)}{(91,6\% + 84,6\%)} = 86,8\%$$

$$\text{Butterhead} = 2 \times \frac{(83,3\% \times 100\%)}{(83,3\% + 100\%)} = 88\%$$

$$\text{Oakleaf} = 2 \times \frac{(100\% \times 100\%)}{(100\% + 100\%)} = 100\%$$

$$\text{Red Rapid} = 2 \times \frac{(91,6\% \times 91,6\%)}{(91,6\% + 91,6\%)} = 91,6\%$$

$$\text{Red Romaine} = 2 \times \frac{(91\% \times 84,6\%)}{(91\% + 84,6\%)} = 87,68\%$$

d. Accuracy

Rumus perhitungan *Accuracy* pada persamaan (1)

$$\text{Accuracy} = \frac{67}{72} \times 100\% = 93\%$$

Hasil dari setiap kelas dapat dilihat pada Tabel 4.6 berikut ini :

Tabel 4.6 Hasil Setiap Kelas

	Precision	Recall	F1- Score
New Grand Rapid	100%	100%	100%
Green Romaine	84,6%	91,6%	86,8%
Butterhead	100%	83,3%	88%
Oakleaf	100%	100%	100%
Red Rapid	91,6%	91,6%	91,6%
Red Romaine	84,6%	91,6%	87,68%

Dari hasil perhitungan dan temuan di atas, penelitian mengenai Klasifikasi Jenis Tanaman Selada telah mampu mengklasifikasi objek selada dengan tingkat akurasi mencapai 93%. Terdapat juga kesalahan sebesar 7% yang mana dikarenakan adanya kesalahan dalam pengambilan gambar selama dilakukannya tahapan *testing* dan juga penyebab kurang banyaknya data yang dikumpulkan dalam pembuatan model untuk aplikasi ini. Sistem ini juga telah diujikan dalam aplikasi *Android* dan dapat digunakan secara langsung. Meskipun terdapat beberapa kesalahan dalam proses pendekripsi objek, sistem ini masih dapat efektif dalam mengklasifikasikan beberapa jenis selada.

4.6 Pengujian Jarak

Pengujian dengan pendekatan jarak merujuk mengacu pada proses pengujian perangkat atau sistem dengan mengukur jarak atau perbedaan antara hasil yang dihasilkan oleh sistem dan nilai-nilai yang diharapkan atau dianggap benar. Pendekatan ini sering digunakan untuk menguji kualitas atau akurasi sistem dalam menghasilkan *output*.

Tabel 4.7 Pengujian Jarak

Jarak	Gambar	Hasil
10 cm		Terdeteksi dan Hasil Benar
20 cm		Terdeteksi dan Hasil Benar
30 cm		Terdeteksi dan Hasil Benar

Jarak	Gambar	Hasil
40 cm		Terdeteksi dan Hasil Benar
50 cm		Tidak Terdeteksi

Dalam Tabel 4.7, dijelaskan bagaimana pengujian dilakukan pada berbagai jarak, mulai dari 0 hingga 50cm. Dari hasil pengujian dapat dilihat bahwa pada jarak sekitar ± 10 cm dari kamera, sistem mampu mengklasifikasi selada dengan baik. Hal yang sama berlaku pada jarak sekitar ± 20 cm, ± 30 cm dan ± 40 cm. Namun, ketika pengujian dilakukan pada jarak sekitar ± 50 cm, sistem tidak dapat mengenali jenis selada yang telah dilatih sebelumnya. Jarak yang dianggap optimal untuk melakukan klasifikasi dalam sistem ini adalah antara 5cm hingga 40cm. Jika jarak terlalu dekat sekitar kurang dari 5cm atau terlalu jauh yaitu lebih dari 40cm maka sistem kemungkinan akan menghasilkan klasifikasi selada yang salah ataupun tidak dapat mengenali objek selada.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Beberapa kesimpulan yang dapat ditarik dari hasil pengujian dalam penelitian mengenai pembuatan sistem klasifikasi selada menggunakan metode *Transfer Learning* sebagai pendekripsi jenis selada adalah sebagai berikut:

1. Metode *Transfer Learning* terbukti efektif dalam mengklasifikasi 6 jenis selada dengan tingkat akurasi mencapai 93% dari total 72 data yang diuji.
2. Dari hasil pengujian *premodel* dalam penelitian ini, terbukti bahwa *DenseNet121* merupakan *premodel* yang paling efektif dalam menerapkan metode *Transfer Learning* untuk mengklasifikasikan jenis tanaman sayuran selada.
3. Penyetelan (*tuning*) dalam model memiliki signifikansi yang besar dalam penelitian. Model penelitian ini menggunakan tuning dengan *learning rate* 0,002 dan *momentum* sebesar 0,9. Oleh karena itu penyetelan tuning memungkinkan untuk mengatur parameter-parameter seperti *learning rate* agar proses pelatihan dapat mencapai akurasi tertinggi yang optimal dalam sistem.

5.2 Saran

Berikut beberapa saran yang dapat digunakan sebagai pedoman dan referensi untuk pengembangan penelitian selanjutnya dengan tema yang sama, yaitu:

1. Harapannya, penelitian selanjutnya dapat meningkatkan proses pelatihan dan memperbanyak lagi jumlah data untuk setiap jenis selada.
2. Pada penelitian selanjutnya diharapkan dapat memperbanyak lagi jenis-jenis selada yang dapat diklasifikasikan.
3. Pada penelitian selanjutnya diharapkan dapat mencoba atau memperbanyak jumlah *pre-model* yang diuji guna mengevaluasi dan mengetahui hasil percobaan menggunakan *pre-model* yang lainnya.
4. Pada penelitian selanjutnya, diharapkan dapat mengimplementasikan pengklasifikasi jenis selada secara waktu nyata (*real-time*).

DAFTAR PUSTAKA

- Afif, M., Fawwaz, A., Ramadhani, K. N., & Sthevanie, F. (2020). *Klasifikasi Ras pada Kucing menggunakan Algoritma Convolutional Neural Network(CNN)*.
- Ahmad, M., Abdullah, M., Moon, H., & Han, D. (2021). Plant Disease Detection in Imbalanced Datasets Using Efficient Convolutional Neural Networks With Stepwise Transfer Learning. *IEEE Access*, 9, 140565–140580. <https://doi.org/10.1109/ACCESS.2021.3119655>
- Alejandrino, J., Concepcion, R., Lauguico, S., Tobias, R. R., Almero, V. J., Puno, J. C., Bandala, A., Dadios, E., & Flores, R. (2020). Visual Classification of Lettuce Growth Stage based on Morphological Attributes using Unsupervised Machine Learning models. *2020 IEEE REGION 10 CONFERENCE (TENCON)*, 438–443. <https://doi.org/10.1109/TENCON50793.2020.9293854>
- Bansal, M., Kumar, M., Sachdeva, M., & Mittal, A. (2021). Transfer learning for image classification using VGG19: Caltech-101 image data set. *Journal of Ambient Intelligence and Humanized Computing*, 14, 3609–3620.
- Celik, E., & Bilgin, G. (2021). Classification of Breast Cancer Images by Transfer Learning Approach Using Different Patching Sizes. *2021 Medical Technologies Congress (TIPTEKNO)*, 1–4. <https://doi.org/10.1109/TIPTEKNO53239.2021.9632923>
- Chen, X., Guo, W., Xue, X., Wang, L., & Qiao, X. (2014). Growth and quality responses of ‘Green Oak Leaf’ lettuce as affected by monochromic or mixed radiation provided by fluorescent lamp (FL) and light-emitting diode (LED). *Scientia Horticulturae*, 172, 168–175. <https://doi.org/10.1016/j.scienta.2014.04.009>
- De Jesus, L. C. M., Ruth P. Pastera, N., Samaniego, L. A., Joy V. Mendoza, M., Laureta, J. P., Santos, M. S. M., Joson, J. B., Brucal, S. G. E., Villarroel, J. M. H., Peruda, S. R., Yong, E. D., & Cosio, P. (2023). A Convolutional Neural Network-based Approach for Lettuce Leaf Disease Classification. *2023 IEEE 12th Global Conference on Consumer Electronics (GCCE)*, 394–395. <https://doi.org/10.1109/GCCE59613.2023.10315544>
- Elgendi, M. (2019). *Deep Learning for Vision Systems (MEAP Editi)* (1st ed.). Manning Publications.

- Fitrian, A., Bafdal, N., & Dwiratna, N. P. S. (2023). Respon Pertumbuhan dan Hasil Tanaman Selada Romaine (*Lactuca Sativa L. Var. Longifolia*) Terhadap Perbedaan Jarak Tanam Pada Smart Watering System SWU 02. *Berkala Ilmiah Pertanian*, 6(1), 1. <https://doi.org/10.19184/bip.v6i1.37120>
- Haryanti, E., Suhartini, T., & Rahayu, E. (2003). *Sawi dan selada* (9th ed.). Penebar swadaya.
- Hassim, S. A., & Chuah, J. H. (2020). Lettuce classification using convolutional neural network. *Food Research*, 4(S6), 118–123. [https://doi.org/10.26656/fr.2017.4\(S6\).029](https://doi.org/10.26656/fr.2017.4(S6).029)
- Hendrawaty, Toni, & Azhar. (2021). *RANCANG BANGUN APLIKASI KRIPTOGRAFI UNTUK PENGAMANAN CITRA RGB 24 BIT MENGGUNAKAN ALGORITMA ELGAMAL*. 2, 109–114.
- Isola, P., Zhu, J.-Y., Zhou, T., & Efros, A. A. (2017). Image-to-Image Translation with Conditional Adversarial Networks. *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 5967–5976. <https://doi.org/10.1109/CVPR.2017.632>
- Jumadi, J., Yupianti, Y., & Sartika, D. (2021). PENGOLAHAN CITRA DIGITAL UNTUK IDENTIFIKASI OBJEK MENGGUNAKAN METODE HIERARCHICAL AGGLOMERATIVE CLUSTERING. *JST (Jurnal Sains Dan Teknologi)*, 10(2), 148–156. <https://doi.org/10.23887/jstundiksha.v10i2.33636>
- Kanna, G. P., Kumar, S. J. K. J., Kumar, Y., Changela, A., Woźniak, M., Shafi, J., & Ijaz, M. F. (2023). Advanced deep learning techniques for early disease prediction in cauliflower plants. *Scientific Reports*, 13(1), 20701. <https://doi.org/10.1038/s41598-023-47732-2>
- Kermanshahani, S., & Hamidi, H. R. (2023). Flexible Data Refreshing Architecture for Health Information System Integration. *SPEKTA (Jurnal Pengabdian Kepada Masyarakat : Teknologi Dan Aplikasi)*, 4(1). <https://doi.org/10.12928/spekta.v4i1.7845>
- Kusumanto, R. D., & Tompunu, A. N. (2011). PENGOLAHAN CITRA DIGITAL UNTUK MENDETEKSI OBYEK MENGGUNAKAN PENGOLAHAN WARNA MODEL NORMALISASI RGB. In *Seminar Nasional Teknologi Informasi & Komunikasi Terapan*.
- Munir, R. (2004). *Pengolahan citra digital* (1st ed.).

- Nana, H. A., Rosmala, D., & Gustiana, H. M. (2021). Transfer Learning for Classification of Fruit Ripeness Using VGG16. *2021 The 4th International Conference on Computers in Management and Business*, 139–146. <https://doi.org/10.1145/3450588.3450943>
- Nurza, I. S. A., & Venesia, D. (2020). Penggunaan AB Mix dan Media Tanam terhadap Viabilitas Tanaman Selada (*Lactuca sativa L. Var. New Grand Rapids*) dalam Hydroponic Wick System. *Risenologi*, 5(1), 14–19. <https://doi.org/10.47028/j.risenologi.2020.51.68>
- Pangestu, M. A., & Bunyamin, H. (2018). *Analisis Performa dan Pengembangan Sistem Deteksi Ras Anjing pada Gambar dengan Menggunakan Pre-Trained CNN Model*. 4, 2443–2229. <https://doi.org/10.28932/jutisi.v4i2.828>
- Perwita, A. W., Setyawati, R., & Syah, R. F. (2023). RESPON TANAMAN SELADA BUTTERHEAD (*Lactuca sativa var.capitata*) TERHADAP BERBAGAI MACAM MEDIA TANAM HIDROPONIK DAN DOSIS PUPUK AB MIX RESPONSE OF BUTTERHEAD CULTIVATE CULTURE (*Lactuca sativa var.capitata*) TO VARIOUS KIND OF HYDROPONIC GROWING MEDIA AND AB MIX FERTILIZER DOSAGE. *Jurnal Pertanian Agros*, 25(2), 1683–1690.
- Putri, A. R. (2016). PENGOLAHAN CITRA DENGAN MENGGUNAKAN WEB CAM PADA KENDARAAN BERGERAK DI JALAN RAYA. *JIPI (Jurnal Ilmiah Penelitian Dan Pembelajaran Informatika)*, 1(01). <https://doi.org/10.29100/jipi.v1i01.18>
- Reza, M. F., Purwanto, Y., & Setianingsih, C. (2020). DETEKSI KONDISI TANAMAN SELADA BERDASARKAN CITRA MENGGUNAKAN METODE CONVOLUTIONAL NEURAL NETWORK (CNN) LETTUCE PLANT CONDITION DETECTION BASED ON IMAGE USING CONVOLUTIONAL NEURAL NETWORK (CNN) METHOD. *Proceeding of Engineering Journal*, 7, 9330–9338.
- Ribani, R., & Marengoni, M. (2019). A Survey of Transfer Learning for Convolutional Neural Networks. *2019 32nd SIBGRAPI Conference on Graphics, Patterns and Images Tutorials (SIBGRAPI-T)*, 47–57. <https://doi.org/10.1109/SIBGRAPI-T.2019.00010>

- Rochman, F., & Junaedi, H. (2020). IMPLEMENTASI TRANSFER LEARNING UNTUK IDENTIFIKASI ORDO TUMBUHAN MELALUI DAUN . *Jurnal Syntax Admiration* , 1, 672–679.
- Rosdiana, Sigit, A., & Regita Cindy, P. (2023). *PENGARUH KOMPOSISI MEDIA TANAM TERHADAP PERTUMBUHAN DAN PRODUKSI SELADA (Lactuca sativa L.) SECARA VERTIKULTUR*. 1, 8–14.
- Saputra, I., Astuti, H. N., & Rahim, R. (n.d.). *Vigenere Cipher Algorithm with Grayscale Image Key Generator for Secure Text File*. www.ijert.org
- Setyaningrum, H. D., & Saparinto, C. (2011). *Panen Sayur secara Rutin di Lahan Sempit* (Desi S., Ed.; Vol. 1). Penebar Swadaya.
- Shamsi, A., Asgharnezhad, H., Jokandan, S. S., Khosravi, A., Kebria, P. M., Nahavandi, D., Nahavandi, S., & Srinivasan, D. (2021). An Uncertainty-Aware Transfer Learning-Based Framework for COVID-19 Diagnosis. *IEEE Transactions on Neural Networks and Learning Systems*, 32(4), 1408–1417. <https://doi.org/10.1109/TNNLS.2021.3054306>
- Wahyudi, Triyanto, D., & Ruslianto, I. (2015). IDENTIFIKASI TEKS DOKUMEN MENGGUNAKAN METODE PROFILE PROJECTION DAN TEMPLATE MATCHING. *Jurnal Coding*, 3, 1–10.
- Yudha, P. I., Wahab, A., & Alaydrus, M. (2020). Deep Learning for Assessing Unhealthy Lettuce Hydroponic Using Convolutional Neural Network based on Faster R-CNN with Inception V2. *2020 Fifth International Conference on Informatics and Computing (ICIC)*, 1–6. <https://doi.org/10.1109/ICIC50835.2020.9288554>