

**IMPLEMENTASI EFFICIENTNETV2 UNTUK IDENTIFIKASI
MELANOMA MELALUI CITRA DERMOSKOPI**

SKRIPSI

ERIKSON ANDRE SUMANGAP

191402100



**PROGRAM STUDI S1 TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA
MEDAN
2023**

**IMPLEMENTASI EFFICIENTNETV2 UNTUK IDENTIFIKASI
MELANOMA MELALUI CITRA DERMOSKOPI**

Diajukan untuk melengkapi tugas dan memenuhi syarat memperoleh ijazah
Sarjana Teknologi Informasi

ERIKSON ANDRE SUMANGAP

191402100



**PROGRAM STUDI S1 TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA
MEDAN
2023**

PERSETUJUAN

PERSETUJUAN

Judul : IMPLEMENTASI EFFICIENTNETV2 UNTUK
 IDENTIFIKASI MELANOMA MELALUI CITRA
 DERMOSKOPI
 Kategori : Skripsi
 Nama Mahasiswa : ERIKSON ANDRE SUMANGAP
 Nomor Induk Mahasiswa : 191402100
 Program Studi : Sarjana (S-1) Teknologi Informasi
 Fakultas : Ilmu Komputer dan Teknologi Informasi
 Universitas Sumatera Utara

Medan, 14 Juni 2024

Komisi Pembimbing:

Pembimbing 2,



Rossy Nurhasanah S.Kom., M.Kom.
NIP. 198707012019032016

Pembimbing 1,



Ivan Jaya S.Si., M.Kom
NIP. 198407072015041001

Diketahui/disetujui oleh
Program Studi S-1 Teknologi Informasi

Ketua,



Dedy Arisandi, S.T., M.Kom.
NIP. 197908312009121002

PERNYATAAN

IMPLEMENTASI EFFICIENTNETV2 UNTUK IDENTIFIKASI MELANOMA MELALUI CITRA DERMOSKOPI

SKRIPSI

Saya menyatakan bahwa skripsi ini adalah hasil karya saya sendiri, kecuali beberapa kutipan dan ringkasan yang masing-masing telah disebutkan sumbernya.

Medan, Maret 2024



Erikson Andre Sumangap

191402100

UCAPAN TERIMAKASIH

Segala puji dan syukur penulis sampaikan ke hadirat Tuhan Yesus Kristus yang senantiasa menjadi penopang dan teman terbaik penulis sepanjang hidupnya, sekaligus jadi Bapa terbaik untuk penulis yang senantiasa sabar dan selalu mengampuni kesalahan penulis. Oleh karena Kasih-Nya penulis dapat berhasil menyelesaikan penelitian ini.

Penulis juga mengucapkan terimakasih sebesar-besarnya kepada semua pihak yang memberikan dukungan serta doa kepada penulis dalam menyelesaikan skripsi ini. Pada kesempatan yang baik ini, penulis ingin mengucapkan rasa terimakasih kepada:

1. Keluarga besar dan orang tua penulis, Ibu Elfrida Simanjuntak dan Ayah Fredryk M Pieter yang selalu memberikan doa dan dukungan kepada penulis dalam menyelesaikan skripsi ini.
2. Abang Harry Sianturi yang menjadi salah satu guru terbaik dan sangat berjasa dalam hidup penulis.
3. Kekasih sekaligus sahabat penulis, Salsa Zanedfi, yang dengan sepenuh hati menemani, menyemangati, menenangkan, dan memberikan solusi pada setiap keluh kesah yang penulis lalui.
4. Bapak Ivan Jaya, S.Si., M.Kom dan Ibu Rossy Nurhasanah, S. Kom., M. Kom. Selaku dosen pembimbing 1 dan 2 terbaik yang telah memberikan saran, kritik, dan motivasi kepada penulis.
5. Ibu Sarah Purnamawati, S. T., M.Sc dan Ibu Annisa Fadhillah Pulungan, S. Kom., M. Kom. Selaku dosen pembanding 1 dan 2 yang telah memberikan saran dan kritik yang membangun kepada penulis.
6. Bapak Dedy Arisandi ST., M. Kom, selaku ketua Program Studi S1 Teknologi Informasi Universitas Sumatera Utara.
7. Seluruh dosen prodi S1 Teknologi Informasi yang telah memberikan ilmu, pengalaman, dan menjadi inspirasi penulis selama masa perkuliahan.
8. Seluruh staff dan pegawai Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Sumatera Utara, khususnya Bang Fadly dan Kak Maia yang membantu segala urusan administrasi selama masa perkuliahan penulis.

9. Teman dekat sekaligus teman nongkrong penulis di USU, yaitu Bobby Zheb, Taufiq, dan Joshua Pandiangan yang selalu menjadi teman diskusi penulis apapun pembahasannya.
10. Teman dekat penulis yaitu Karvin Halim, Alwi, Iqbal, Sayid Farhan, Riyadh, Ruchyat dan Rafif Pratama.
11. Sahabat dari SMP yaitu Kris, Daniel, Angga, dan Lewi yang jadi teman ngobrol penulis dari dulu.
12. Teman-teman di UKM Kristen yang sudah menjadi teman-teman pertama bagi penulis di USU.
13. Teman-teman angkatan 2019, senior, dan junior yang sudah melewati masa-masa perkuliahan bersama-sama.
14. Gatsu, Cengeng, Doge, dan Kusut yang selalu menjadi teman yang lucu bagi penulis.
15. Semua pihak yang berjasa membantu penulis, namun belum bisa penulis tulis satu per satu.

Penulis menyadari bahwa penulisan skripsi ini masih terdapat banyak kekurangan. Oleh karena itu, penulis mengharapkan kritik dan saran yang membangun dalam penyempurnaan skripsi ini.

Jakarta, Maret 2024



Penulis

ABSTRAK

Melanoma merupakan salah satu jenis kanker kulit yang paling mematikan karena dapat menyebar ke seluruh tubuh melalui sistem pembuluh darah dan getah bening. Gejala melanoma yang umum terjadi yaitu timbulnya bintik hitam, coklat, atau merah pada kulit, sehingga gejalanya mirip *nevus* atau tahi lalat. Deteksi dini dan diagnosis yang akurat sangat penting dalam penanganan melanoma. Diagnosis melanoma dilakukan dengan metode dermoskopi atau histopatologi yang memerlukan biopsi serta memakan waktu dan biaya yang cukup tinggi. Penelitian ini menggunakan arsitektur *EfficientNetV2* yang merupakan pengembangan dari arsitektur *EfficientNet* yang telah terbukti efisien dan efektif dalam pengolahan citra, khususnya klasifikasi gambar. Arsitektur ini memperkenalkan beberapa modifikasi untuk meningkatkan efisiensi model dan akurasi. Pelatihan model menggunakan *dataset* ISIC 2020 yang berisi 2100 data, terbagi menjadi 1470 data pelatihan, 420 data validasi, dan 210 data uji. Data tersebut melalui tahapan *preprocessing* yang terdiri dari perubahan ukuran, penghapusan rambut, segmentasi, normalisasi, dan augmentasi. Setelah melalui *preprocessing*, data tersebut diteruskan ke arsitektur *EfficientNetV2* untuk dilakukan fitur ekstraksi dan pelatihan model yang menggunakan 40 *epoch* dan *batch size* sebesar 20. Hasil penggunaan arsitektur *EfficientNetV2* menunjukkan akurasi sebesar 93.33%. Berdasarkan hasil akurasi tersebut, dapat disimpulkan bahwa sistem sudah sangat baik dalam mengidentifikasi melanoma melalui citra dermoskopi.

Kata Kunci: Melanoma, *EfficientNetV2*, *Convolutional Neural Network*, Klasifikasi gambar.

IMPLEMENTATION OF EFFICIENTNETV2 FOR MELANOMA IDENTIFICATION VIA DERMOSCOPIC IMAGES

ABSTRACT

Melanoma is one of the deadliest types of skin cancer because it can spread throughout the body through the blood vessel and lymph system. A common symptom of melanoma is the appearance of black, brown or red spots on the skin, so the symptoms resemble a nevus or mole. Early detection and accurate diagnosis are very important in treating melanoma. Melanoma diagnosis is carried out using dermoscopy or histopathology methods which require biopsy and are quite time consuming and expensive. This research uses the EfficientNetV2 architecture which is a development of the EfficientNet architecture which has been proven to be efficient and effective in image processing, especially image classification. This architecture introduces several modifications to improve model efficiency and accuracy. Model training uses the ISIC 2020 dataset which contains 2100 data, divided into 1470 training data, 420 validation data, and 210 test data. The data goes through preprocessing stages which consist of resizing, hair removal, segmentation, normalization and augmentation. After going through preprocessing, the data is forwarded to the EfficientNetV2 architecture for feature extraction and model training using 40 epochs and a batch size of 20. The results of using the EfficientNetV2 architecture show an accuracy of 93.33%. Based on these accuracy results, it can be concluded that the system is very good at identifying melanoma through dermoscopic images.

Keywords: Melanoma, EfficientNetV2, Convolutional Neural Network, Image Classification.

DAFTAR ISI

PERSETUJUAN	ii
PERNYATAAN	iii
UCAPAN TERIMAKASIH	iv
ABSTRAK	vi
ABSTRACT	vii
DAFTAR ISI	viii
DAFTAR TABEL	xi
DAFTAR GAMBAR	xii
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian	4
1.4 Batasan Masalah	4
1.5 Manfaat Penelitian	5
1.6 Metodologi Penelitian	5
1.6.1 Studi Literatur	5
1.6.2 Analisis Permasalahan	5
1.6.3 Perancangan Sistem	6
1.6.4 Implementasi	6
1.6.5 Pengujian Sistem	6
1.6.6 Penyusunan Laporan	6
1.7 Sistematika Penulisan	6
BAB 2 LANDASAN TEORI	8
2.1 Kulit	8
2.2 Melanoma	8
2.3 Karakteristik Melanoma	10
2.4 <i>Deep Learning</i>	10
2.5 <i>Convolutional Neural Network</i>	11

2.6	EfficientNetV2	12
2.7	Fitur Ekstraksi	14
2.8	Pengolahan Citra Digital	15
2.9	Citra Digital	15
2.10	Citra Dermoskopi	15
2.11	Augmentasi	16
2.12	Hair Removal	16
2.13	<i>Flask</i>	17
2.14	<i>Confusion Matrix</i>	17
2.15	Penelitian Terdahulu	19
2.15.1	Perbedaan Penelitian	23
BAB 3 ANALISIS DAN PERANCANGAN SISTEM		25
3.1	Data yang digunakan	25
3.2	Analisis Sistem	26
3.2.1	<i>Data Acquisition</i>	28
3.2.2	<i>Splitting Data</i>	29
3.2.3	<i>Preprocessing</i>	29
3.2.3.1	Image Resizing	29
3.2.3.2	Hair Removal	30
3.2.3.3	Image Segmentation	31
3.2.3.4	Image Normalization	33
3.2.3.5	Augmentasi	34
3.2.3.6	Labelling	37
3.2.4	<i>Image Classifier</i>	37
3.2.4.1	Convolutional Layer	37
3.2.4.2	Feature Map	40
3.2.4.3	Global Average Pooling 2D (GAP)	41
3.2.4.4	Fully Connected Layer	43
3.2.5	<i>Learned Model</i>	45
3.2.6	<i>Flask</i>	45
3.2.7	<i>Training Data</i>	45
3.2.8	<i>Testing Data</i>	47
3.2.9	Evaluasi Model	47

3.3 Perancangan Antarmuka Sistem	48
3.3.1 Rancangan Tampilan Halaman Utama	49
3.3.2 Rancangan Tampilan Halaman Identifikasi	50
3.3.3 Rancangan Tampilan Halaman Hasil Identifikasi	50
3.3.4 Rancangan Tampilan Halaman Tutorial	51
3.3.5 Rancangan Tampilan Halaman Informasi	51
BAB 4 IMPLEMENTASI DAN PENGUJIAN SISTEM	53
4.1 Data yang digunakan	53
4.1.1 Perangkat Keras dan Perangkat Lunak	53
4.1.2 Implementasi Data	53
4.1.3 Implementasi Desain Antarmuka Aplikasi (<i>Interface</i>)	54
4.2 Prosedur Operasional	62
4.3 Pelatihan Sistem	63
4.4 Pengujian Sistem	67
BAB 5 KESIMPULAN DAN SARAN	79
5.1 Kesimpulan	79
5.2 Saran	79
DAFTAR PUSTAKA	81
Lampiran 1. Tabel Hasil Pengujian Sistem	84

DAFTAR TABEL

Tabel 2.1 Penelitian Terdahulu	20
Tabel 3.1 Pembagian Data <i>Training</i> , <i>Data Validation</i> , dan <i>Data Testing</i>	26
Tabel 4.1 Pembagian Data <i>Training</i> , <i>Data Validation</i> , <i>Data Testing</i> Setelah	63
Tabel 4.2 Tabel Pelatihan	64
Tabel 4.3 Tabel <i>Epoch</i>	65
Tabel 4.4 Hasil Pengujian Identifikasi Melanoma	68
Tabel 4.5 <i>Confusion Matrix</i>	73
Tabel 4.6 Nilai TP, TN, FP, dan FN	73
Tabel 4.7 Nilai <i>Precision</i> , <i>Recall</i> , dan <i>F1-Score</i>	75

DAFTAR GAMBAR

Gambar 2.1 Kanker Kulit Melanoma	9
Gambar 2.2 Karakteristik Melanoma	10
Gambar 2.3 Arsitektur CNN (Alom et al, 2019)	12
Gambar 2.4 Struktur MBConv dan Fused-MBConv (Tan & Le, 2021)	13
Gambar 2.5 Arsitektur Umum EfficientNetV2 (Albattah et al, 2022)	14
Gambar 2.6 Citra Dermoskopi	16
Gambar 2.7 Penghapusan Rambut pada Citra Digital	16
Gambar 3.1 Citra Melanoma dan Citra Non Melanoma (<i>nevus</i>)	25
Gambar 3.2 Arsitektur Umum	28
Gambar 3.3 Nilai Matriks Setelah Proses <i>Resize</i>	30
Gambar 3.4 Citra Lesi Kulit Sebelum dan Sesudah <i>resizing</i>	30
Gambar 3.5 Citra Sebelum dan Sesudah <i>hair removal</i>	31
Gambar 3.6 Arsitektur U-Net (Ronneberger, 2015)	32
Gambar 3.7 Citra Sebelum dan Sesudah <i>segmentation</i>	33
Gambar 3.8 Sebelum dan Sesudah <i>normalization</i>	34
Gambar 3.9 Sebelum dan Sesudah <i>flip</i> horizontal	35
Gambar 3.10 Sebelum dan Sesudah <i>flip</i> vertikal	35
Gambar 3.11 Rotasi 90 derajat dan -90 derajat	35
Gambar 3.12 <i>Labelling</i> Data	37
Gambar 3.13 Contoh Perhitungan <i>Filter Convolutional Layer</i>	38
Gambar 3.14 Posisi <i>filter</i> pada Proses Konvolusi	39
Gambar 3.15 <i>Feature Map</i>	41
Gambar 3.16 Diagram Aktivitas	49
Gambar 3.17 Rancangan Halaman Utama	50
Gambar 3.18 Rancangan Halaman Identifikasi	50
Gambar 3.19 Rancangan Halaman Hasil Identifikasi	51
Gambar 3.20 Rancangan Halaman Tutorial Aplikasi	51
Gambar 3.21 Rancangan Halaman Informasi	52
Gambar 4.1 Data Citra Melanoma	54
Gambar 4.2 Data Citra Non Melanoma	54
Gambar 4.3 Tampilan Halaman Utama	55
Gambar 4.4 Tampilan Halaman Identifikasi	56
Gambar 4.5 Tampilan Halaman Yang Telah Diinput Citra	57
Gambar 4.6 Tampilan Hasil Identifikasi Melanoma	58
Gambar 4.7 Tampilan Hasil Identifikasi Non Melanoma	58
Gambar 4.8 Citra Sebelum Segmentasi	59

Gambar 4.9 Citra Sesudah Segmentasi	60
Gambar 4.10 Tampilan Halaman Informasi	61
Gambar 4.11 Tampilan Halaman Tutorial	62
Gambar 4.12 Grafik <i>accuracy</i> dan <i>loss</i>	67
Gambar 4.13 Gambar Melanoma Setelah Segmentasi Lebih Lanjut	76
Gambar 4.14 Hasil Identifikasi Setelah Proses Segmentasi	76
Gambar 4.15 Gambar Non Melanoma Setelah <i>Crop Centered</i>	77
Gambar 4.16 Hasil Identifikasi Setelah Proses <i>Crop Centered</i>	78

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Kanker kulit termasuk salah satu jenis kanker yang paling banyak terjadi di seluruh dunia. Salah satu jenis kanker kulit yang paling mematikan dan secara signifikan meningkatkan risiko kematian bagi penderitanya adalah melanoma. Hal ini disebabkan oleh kemampuan melanoma untuk menyebar ke seluruh tubuh melalui sistem pembuluh darah dan getah bening, sehingga sulit untuk dikontrol dan diobati. Deteksi dan pengobatan dengan tepat waktu dapat meningkatkan kemungkinan penderita melanoma untuk disembuhkan (Siloam Hospitals, 2023).

Menurut data statistik GLOBOCAN oleh International Agency for Research on Cancer (IARC) pada tahun 2020, melanoma berada pada posisi ke-17 teratas sebagai kanker yang umum terjadi pada manusia, dengan jumlah kasus sebanyak 324.635 kasus, dan jumlah kematian sebanyak 57.043 kasus. Sementara itu, masih berdasarkan data dari sumber yang sama, melanoma di Indonesia berada pada peringkat ke-23 dalam daftar kanker yang sering terjadi, dengan jumlah kasus mencapai 1.609 kasus, dan tingkat kematiannya mencapai 699 kasus.

Gejala yang umum terjadi pada penderita melanoma diantaranya adalah bintik hitam atau coklat pada kulit, namun dapat juga muncul dalam bentuk bintik merah atau merah muda. Tanda-tanda melanoma yang harus diwaspadai adalah perubahan ukuran, bentuk, atau warna tanda atau bintik yang ada pada kulit, serta munculnya benjolan atau perubahan pada kulit yang terlihat tidak wajar (Alodokter, 2021). Melanoma juga memiliki kemiripan dengan tanda kulit yang dimiliki oleh semua orang yaitu tahi lalat yang umumnya bersifat jinak. Namun, tahi lalat yang bersifat jinak ini dapat berubah sifat menjadi ganas dan menjadi kanker kulit. Tahi lalat yang tidak wajar memiliki bentuk dan batas yang tidak

beraturan serta mengalami perubahan warna yang merupakan karakteristik dari melanoma. Sementara itu tahi lalat yang berukuran lebih besar dari 20 milimeter juga beresiko tinggi berkembang menjadi kanker (Hendaria et al., 2013).

Deteksi dini dan diagnosis yang akurat sangat penting dalam menangani melanoma. Deteksi dini dapat dilakukan dengan pemeriksaan kulit secara berkala dan konsisten, serta dengan memperhatikan perubahan pada kulit yang terlihat tidak wajar. Diagnosis melanoma dilakukan dengan menggunakan teknologi medis seperti dermoskopi atau histopatologi, namun diagnosis ini memerlukan biopsi dan pengamatan langsung oleh ahli yang terlatih, serta memakan waktu dan biaya yang cukup tinggi. Di samping itu, tingkat ketepatan dalam mendiagnosa dapat bervariasi di antara para ahli.

Dalam beberapa tahun terakhir, metode identifikasi melanoma dengan menggunakan teknologi *deep learning* dan *convolutional neural network* (CNN) mulai dikembangkan. CNN adalah salah satu jenis jaringan saraf tiruan yang digunakan untuk memproses data dengan bentuk yang kompleks, seperti gambar dan video. Metode ini telah terbukti mampu memberikan kinerja yang sangat baik dalam tugas-tugas identifikasi gambar, termasuk identifikasi melanoma.

Pada penelitian sebelumnya yang dilakukan oleh (Soegeng, 2021) menggunakan gabungan dari beberapa arsitektur CNN yang digunakan untuk melakukan klasifikasi kanker kulit melanoma terhadap *dataset* ISIC 2020, didapatkan akurasi prediksi AUC sebesar 93.1%. Arsitektur CNN yang diterapkan pada penelitian tersebut diantaranya adalah EfficientNet dan ResNet-50-v2 yang digunakan untuk mengklasifikasikan lesi kulit ke dalam dua kategori yaitu melanoma dan non-melanoma. Penelitian ini melakukan pelatihan model terhadap *dataset* asli dan *dataset* yang telah diolah menggunakan algoritma penghapusan rambut. Hasil dari penelitian ini menunjukkan bahwa analisis citra lesi kulit menggunakan metode *deep learning* dapat menjadi metode non-invasif serta efektif dalam mendeteksi melanoma. Namun, ada kekurangan dalam penelitian ini yaitu pada model yang dilatih menggunakan *dataset* yang diolah menggunakan algoritma penghapusan rambut mengalami penurunan akurasi yang disebabkan karena model mempelajari lebih banyak fitur dari kulit biasa dibanding fitur lesi kulit, sehingga diperlukan untuk menyempitkan daerah yang dipelajari.

Pada klasifikasi gambar menggunakan metode deep learning, seringkali terjadi beberapa tantangan seperti overfitting, underfitting, dan penggunaan sumber daya yang besar. Salah satu metode dalam ranah *deep learning* adalah *EfficientNet* yang diperkenalkan oleh (Tan & Le, 2019) dan merupakan model yang menggabungkan teknik scaling cerdas dengan tujuan untuk memperkuat arsitektur dan meningkatkan performa klasifikasi gambar. Namun terdapat beberapa kekurangan pada EfficientNet diantaranya yaitu pelatihan dengan ukuran gambar yang sangat besar lambat, konvolusi kedalaman (*depthwise convolutions*) lambat di lapisan awal, dan penskalaan setiap tahap secara merata tidak optimal. Selain itu, EfficientNet secara agresif meningkatkan ukuran gambar, yang kemudian mengakibatkan konsumsi memori yang besar dan pelatihan yang lambat. Berdasarkan hal tersebut, peneliti merancang ruang pencarian yang diperkaya dengan metode tambahan seperti Fused-MBConv, serta menerapkan pencarian arsitektur saraf yang memiliki kesadaran terhadap proses pelatihan dan penskalaan, dengan tujuan utama yaitu untuk mengoptimalkan akurasi model, kecepatan pelatihan, dan ukuran parameter (GOA Institute of Management, 2021). Sehingga pada penelitian oleh (Tan & Le, 2021) diperkenalkan EfficientNetV2 yang merupakan penerus dari EfficientNet.

EfficientNetV2 merupakan arsitektur jaringan saraf konvolusional yang dirancang untuk meningkatkan efisiensi dan akurasi model. Arsitektur ini menggunakan prinsip-prinsip yang sama seperti EfficientNet terdahulu, namun dengan beberapa modifikasi yang meningkatkan efisiensi model dan akurasi (Tan & Le, 2021). EfficientNetV2 mampu melakukan proses secara lebih efisien jika dibandingkan dengan pendahulunya yaitu EfficientNet, hal ini dikarenakan EfficientNetV2 dioptimalkan dengan menggunakan teknik baru yang disebut Fused-MBConv. Selain itu perbedaan antara EfficientNet dengan EfficientNetV2 adalah pada skala dan arsitektur, dimana EfficientNetV2 menggunakan skala non-uniform yang mengindikasikan bahwa dimensi model ditingkatkan secara berbeda di setiap tahap, dan ini menyebabkan model menjadi lebih kecil dan efisien (Tan & Le, 2021).

Pembuatan aplikasi untuk mengidentifikasi melanoma melalui citra lesi kulit hasil dermoskopi memiliki urgensi karena melanoma merupakan salah satu jenis

kanker kulit yang sangat mematikan jika terlambat diobati. Dalam hal ini, aplikasi dengan teknologi *deep learning* dapat membantu mengidentifikasi ciri-ciri khusus pada lesi kulit yang mengindikasikan melanoma secara akurat dan cepat. Berdasarkan latar belakang yang dipaparkan, penulis melakukan penelitian dengan judul “IMPLEMENTASI EFFICIENTNETV2 UNTUK IDENTIFIKASI MELANOMA MELALUI CITRA DERMOSKOPI”.

1.2 Rumusan Masalah

Melanoma merupakan salah satu jenis kanker kulit paling mematikan yang memiliki potensi untuk menyebar ke area tubuh lain dan dapat berkembang menjadi kanker yang sulit diobati jika tidak diatasi dengan tepat waktu. Deteksi dini dan diagnosis melanoma seringkali melibatkan waktu dan biaya yang tinggi. Oleh karena itu, diperlukan sistem deteksi gejala melanoma melalui citra lesi kulit hasil dermoskopi dengan menggunakan algoritma yang efektif.

1.3 Tujuan Penelitian

Adapun tujuan dari penelitian ini yaitu untuk mengidentifikasi penyakit melanoma dengan menggunakan algoritma *Convolutional Neural Network* dengan arsitektur model EfficientNetV2.

1.4 Batasan Masalah

Dalam penelitian ini akan dibatasi oleh hal-hal pokok sebagai berikut:

1. Penelitian ini difokuskan pada identifikasi melanoma berdasarkan gambar hasil dermoskopi kulit menggunakan metode *convolutional neural network* (CNN) berbasis arsitektur model EfficientNetV2.
2. Sistem identifikasi hanya akan menggunakan gambar dermoskop sebagai input. Data lain seperti riwayat medis atau informasi klinis pasien tidak akan dipertimbangkan.
3. Data gambar untuk *dataset* non melanoma yang digunakan dalam penelitian ini hanya terdiri dari jenis lesi kulit nevus (tahi lalat). Nevus dipilih sebagai representasi non melanoma karena merupakan jenis lesi

kulit yang umum dan sering dikaitkan dengan perubahan melanin, seperti halnya pada melanoma.

4. Luaran yang dihasilkan adalah hasil identifikasi suatu tanda pada kulit berupa melanoma atau non melanoma

1.5 Manfaat Penelitian

Hasil dari penelitian ini diharapkan dapat memberikan manfaat, yaitu:

1. Membantu dalam deteksi dini melanoma dengan mengidentifikasi tanda-tanda awal yang mencurigakan dalam gambar dermoskop.
2. Membantu mengurangi waktu dan usaha yang dibutuhkan dalam menganalisis gambar dermoskop sehingga dapat meningkatkan efisiensi dan produktivitas praktisi medis.
3. Menambah referensi penelitian mengenai identifikasi menggunakan metode *convolutional neural network* khususnya menggunakan arsitektur EfficientNetV2.

1.6 Metodologi Penelitian

Berikut adalah tahapan-tahapan yang ditempuh dalam melaksanakan penelitian ini:

1.6.1 Studi Literatur

Menghimpun referensi dari berbagai sumber seperti buku, jurnal, makalah, dan berbagai literatur yang relevan dengan penelitian penulis. Termasuk di antaranya adalah penelitian yang berkaitan dengan melanoma, identifikasi gejala melanoma melalui citra dermoskopi, teknik pengolahan citra, serta metode dan algoritma yang terkait dengan EfficientNetV2.

1.6.2 Analisis Permasalahan

Tahapan ini melibatkan analisis terhadap referensi dan informasi yang telah dikumpulkan sebelumnya. Tujuannya adalah untuk memperoleh pemahaman mendalam tentang arsitektur EfficientNetV2. Informasi ini

akan menjadi dasar untuk penggunaan EfficientNetV2 dalam penelitian, khususnya untuk tujuan mengidentifikasi citra lesi kulit.

1.6.3 Perancangan Sistem

Berdasarkan evaluasi tahapan sebelumnya, disusun rancangan sistem yang mencakup perencanaan arsitektur umum dan penetapan pembagian data untuk tahap pelatihan, validasi, dan pengujian.

1.6.4 Implementasi

Sistem yang direncanakan sebelumnya kemudian dijalankan, menghasilkan implementasi yang sesuai dengan tujuan penelitian.

1.6.5 Pengujian Sistem

Dalam tahapan ini, sistem yang telah dikembangkan diuji untuk memastikan kegunaannya dan untuk mengukur tingkat akurasi penerapan arsitektur EfficientNetV2 dalam proses identifikasi melanoma berdasarkan citra lesi kulit.

1.6.6 Penyusunan Laporan

Dalam tahapan ini, disusun laporan yang menyajikan hasil dari penelitian yang telah dilaksanakan.

1.7 Sistematika Penulisan

Struktur penulisan skripsi ini terbagi menjadi lima bab, yang mencakup:

BAB 1: PENDAHULUAN

Bab satu berisi beberapa bagian penting dalam penelitian, diantaranya adalah latar belakang, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, metodologi penelitian, dan sistematika penulisan dari penelitian ini.

BAB 2: LANDASAN TEORI

Bab dua berisi teori-teori yang relevan dengan penelitian dan berkaitan dengan permasalahan yang dihadapi. Beberapa teori yang dibahas meliputi teori yang berkaitan dengan kulit, melanoma, pengolahan citra digital, EfficientNetV2, *Convolutional Neural Network (CNN)*, dan *Deep Learning*.

BAB 3: ANALISIS DAN PERANCANGAN

Bab tiga berisi analisis data, perancangan arsitektur umum, dan penjelasan mengenai tahapan-tahapan yang terdapat dalam perancangan arsitektur umum penelitian. Selain itu, juga dilakukan perancangan pada sistem yang akan dibangun.

BAB 4: IMPLEMENTASI DAN PENGUJIAN SISTEM

Bab empat berisi pembahasan tentang pengimplementasian dari perancangan yang telah dijelaskan di bab sebelumnya. Tahapan ini juga membahas hasil pengujian dari sistem yang telah dibangun.

BAB 5: KESIMPULAN DAN SARAN

Bab lima berisi penjelasan tentang kesimpulan dari penelitian yang telah dilakukan dan memberikan saran untuk penelitian selanjutnya.

BAB 2

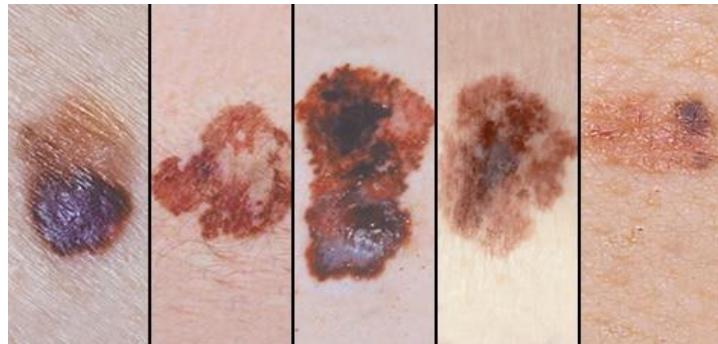
LANDASAN TEORI

2.1 Kulit

Kulit merupakan organ vital sekaligus terbesar di tubuh manusia. Ini merupakan antarmuka langsung antara manusia dan lingkungannya. Lapisan kulit secara terus-menerus mengalami perubahan dan berisi banyak jenis sel serta struktur yang memiliki peranan khusus. Peran utama kulit adalah melindungi bagian dalam tubuh, termasuk otot, tulang, sendi, saraf, serta jaringan ikat tubuh (Hendaria et al., 2013). Organ kulit juga berperan dalam mengendalikan suhu tubuh, mengumpulkan informasi sensorik dari sekitar, dan berpartisipasi aktif dalam sistem kekebalan untuk menjaga tubuh dari penyakit. Kulit manusia terdiri dari tiga lapisan utama yaitu epidermis, dermis, dan hypodermis (Halodoc, 2021).

2.2 Melanoma

Melanoma merupakan salah satu jenis kanker kulit ganas yang diakibatkan oleh pertumbuhan sel melanosit secara tidak normal (Ariesta, 2018). Kanker ini dapat menyebar dengan cepat ke organ tubuh lain, seperti otak, mata, hidung, hingga paru-paru jika tidak segera ditangani. Umumnya kemunculan melanoma dapat diidentifikasi saat muncul tahi lalat baru di kulit atau perubahan bentuk, ukuran, dan warna pada tahi lalat. Terdapat empat jenis melanoma diantaranya *superficial spreading melanoma*, *nodular melanoma*, *lentigo maligna melanoma*, dan *acral lentiginous melanoma*. Keempat jenis melanoma tersebut kerap diabaikan karena mirip dengan tahi lalat biasa. (Halodoc, 2019).



Gambar 2.1 Kanker Kulit Melanoma

Penyebab melanoma belum sepenuhnya dipahami, namun salah satu faktor yang dicurigai yaitu terpapar sinar UV secara langsung. Melanoma muncul akibat kerusakan DNA lalu memicu pertumbuhan sel-sel kulit yang tidak terkendali, serta menghasilkan sel yang bersifat kanker. Ada beberapa faktor yang mampu meningkatkan risiko orang terkena melanoma yaitu kulit putih, jumlah tahi lalat yang banyak, memiliki sistem imun yang lemah, dan sering terpapar sinar matahari secara langsung (Halodoc, 2022).

Melanoma sering kali timbul sebagai tanda atau bintik berwarna hitam atau coklat pada permukaan kulit, meskipun terkadang dapat muncul dalam bentuk bintik merah atau merah muda. Tanda-tanda melanoma yang perlu diawasi adalah perubahan dalam ukuran, bentuk, atau warna tanda atau bintik yang sudah ada di kulit, serta kemunculan benjolan atau perubahan kulit yang terlihat tidak biasa. Dalam melihat perubahan-perubahan pada tanda-tanda tersebut, dokter dapat melakukan dermoskopi atau dermatoskopi. Dermoskopi yaitu pemeriksaan kulit untuk membantu diagnosis penyakit kanker kulit menggunakan alat bernama dermoskop (Kato, 2019).

2.3 Karakteristik Melanoma



Gambar 2.2 Karakteristik Melanoma

Melanoma merupakan jenis kanker kulit yang berasal dari sel melanosit, sel yang menghasilkan pigmen melanin. Karakteristik melanoma dapat ditelisik menggunakan rumus “ABCDE” seperti pada Gambar 2.2, dimana setiap huruf mewakili kata yang merupakan ciri dari melanoma diantaranya adalah A (*Asymmetry*), B (*Border irregularity*), C (*Colour*), D (*Diameter*), dan E (*Evolution*). Beberapa karakteristik melanoma yang perlu diperhatikan antara lain perubahan warna dan bentuk lesi yang tepinya tidak teratur atau bergantian antara area gelap dan terang, lesi asimetri dimana setengah bagian lesi tidak cocok dengan setengah bagian lainnya, memiliki batas yang tidak jelas atau tidak teratur, pertumbuhan atau peningkatan diameter lesi yang signifikan, gatal atau nyeri, dan perubahan tekstur pada area tersebut.

2.4 Deep Learning

Deep learning merupakan bagian dari *Machine Learning* dan termasuk kedalam kecerdasan buatan yang meniru jaringan syaraf pada otak manusia, serta meniru cara kerja otak dalam mengolah data lalu menciptakan pola yang akan digunakan dalam pengambilan keputusan.

Salah satu keunggulan yang dimiliki oleh *deep learning* yaitu mampu mengenali dan memodelkan pola yang sangat kompleks dan abstrak dalam data.

Hal ini membuatnya cocok untuk tugas-tugas seperti pengenalan wajah, deteksi objek, identifikasi suatu citra, pemrosesan bahasa alami, dan banyak lagi.

Deep Learning merupakan bagian daripada *Machine Learning* yang pada tahun 1986 diperkenalkan oleh Dechter. *Deep Learning* menerapkan algoritma *backpropagation*, dimana mesin akan terus memperbarui bobot serta bias pada layer jaringan saraf buatan berdasarkan error, sampai menemukan bobot serta bias yang optimal (Anjani, 2021).

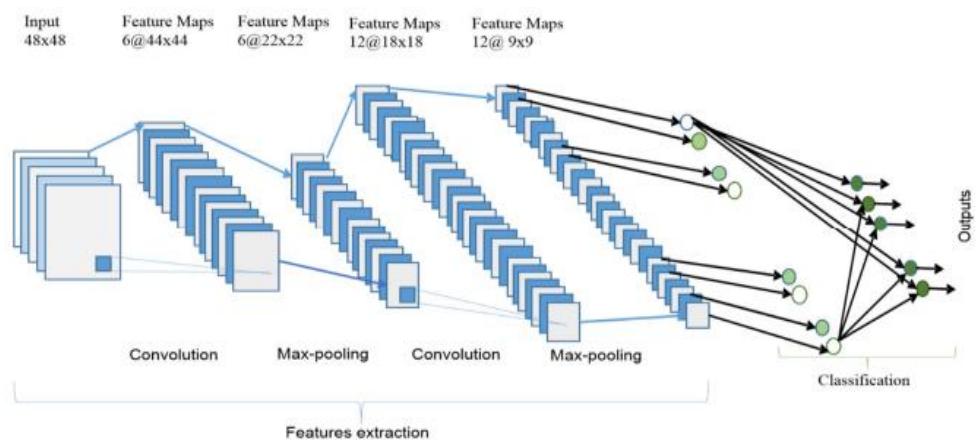
Perbedaan *deep learning* dengan *machine learning* yaitu *deep learning* menggunakan rangkaian lapisan/*layer unit* pemrosesan *nonlinier* untuk ekstraksi dan transformasi fitur yang terdapat pada objek yang diteliti, contohnya dalam gambar, *deep learning* dapat mengekstrak fitur-fitur yang berbeda pada gambar tersebut dalam setiap *hidden layer* (Hao et al, 2016).

2.5 Convolutional Neural Network

Convolutional neural network (CNN) merupakan jenis arsitektur dalam bidang kecerdasan buatan yang digunakan untuk pemrosesan data terutama data yang memiliki struktur grid seperti gambar dan video. Arsitektur ini termasuk ke dalam *Deep Neural Network* karena memiliki kedalaman arsitektur/jaringan yang tinggi (E.P & Soelaiman, 2016). CNN didasarkan pada konsep konvolusi, yang mirip dengan cara manusia mengenali pola visual melalui *filter receptive field*, dimana dalam konteks jaringan saraf tiruan, *filter receptive field* mengacu pada area atau wilayah di dalam input data yang diproses oleh filter konvolusi. *Receptive field* memiliki peran penting dalam menentukan sejauh mana setiap neuron atau unit dalam lapisan konvolusi dapat merespons terhadap informasi dalam input.

Arsitektur CNN terdiri dari beberapa lapisan yaitu lapisan konvolusi, lapisan pooling, lapisan aktivasi, dan lapisan *fully connected*. Lapisan konvolusi memiliki peran penting dalam mengekstraksi ciri-ciri dari citra, sementara lapisan pooling berperan dalam mengurangi dimensi atau ukuran citra yang telah melalui proses ekstraksi, kemudian lapisan aktivasi berfungsi untuk mengenali pola-pola non-linear dalam data yang telah diekstraksi oleh lapisan konvolusi. Dengan

menerapkan fungsi aktivasi pada keluaran dari lapisan konvolusi, model dapat mempelajari representasi ciri yang lebih kompleks dan abstrak dari citra. Selanjutnya, hasil dari ketiga lapisan tersebut akan diteruskan ke lapisan-lapisan yang sepenuhnya terhubung (*fully connected*) untuk menghasilkan output yang diinginkan, seperti dalam tugas klasifikasi atau segmentasi citra. (Hijazi & Rowen, 2015).



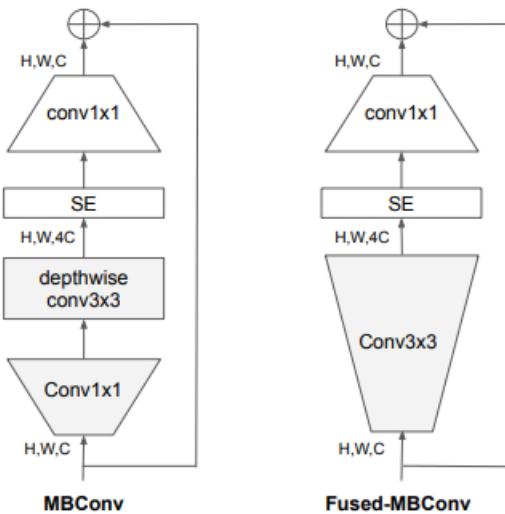
Gambar 2.3 Arsitektur CNN (Alom et al, 2019)

2.6 EfficientNetV2

EfficientNetV2 adalah arsitektur yang diperkenalkan pada tahun 2021 dan merupakan pengembangan lanjutan dari model EfficientNet yang dikenal efisien dalam penggunaan sumber daya komputasi. Arsitektur ini menggabungkan skala, kedalaman, dan resolusi yang optimal untuk menghasilkan performa yang baik dalam pengenalan pola visual. EfficientNetV2 adalah model arsitektur canggih yang dapat digunakan dalam tugas pengenalan pola, termasuk identifikasi melanoma.

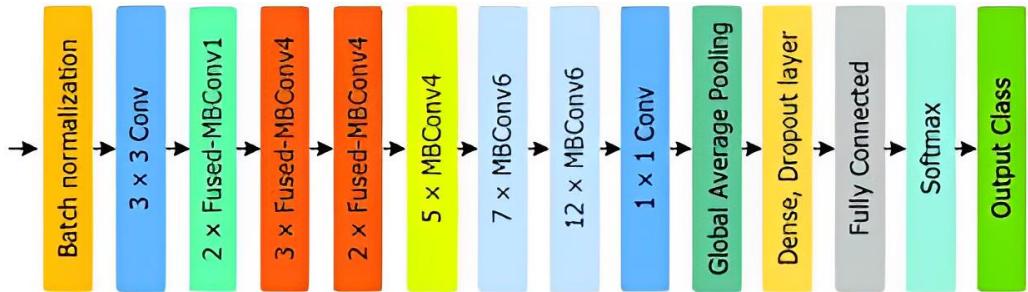
Perbedaan utama antara Efficientnet dan EfficientnetV2 adalah penggunaan faktor skala. Faktor skala adalah parameter yang menentukan ukuran dan kedalaman model. EfficientNet menggunakan faktor skala yang konstan untuk semua lapisan, sedangkan EfficientNetV2 menggunakan faktor skala yang berbeda untuk setiap lapisan (Tan & Le, 2021). Terdapat juga teknik baru yang diterapkan pada EfficientnetV2 untuk meningkatkan efisiensi model yaitu Fused MBConv.

Teknik ini melibatkan penggabungan operasi konvolusi, pooling, dan aktivasi menjadi satu operasi. Fused MBConv menggunakan operasi konvolusi yang lebih kecil dan lebih efisien, yang dapat mengurangi jumlah parameter dan operasi model (Tan & Le, 2021).



Gambar 2.4 Struktur MBConv dan Fused-MBConv (Tan & Le, 2021)

Pada Gambar 2.4 menunjukkan diagram dua jenis konvolusi yang digunakan dalam EfficientNetV2, yaitu *Mobile inverted bottleneck convolution* (MBConv) dan Fused-MBConv. MBConv terdiri dari empat tahap, diantaranya adalah konvolusi 1x1 untuk meningkatkan dimensi input, konvolusi mendalam (*depthwise convolution*) dengan ukuran kernel 3x3, *Squeeze-and-Excitation* (SE), dan konvolusi 1x1 untuk mengurangi dimensi output. Sementara itu, Fused-MBConv menggabungkan dua tahap pertama dari MBConv menjadi satu tahap, yaitu konvolusi 3x3 dengan ukuran output yang sama dengan konvolusi 1x1 pada tahap pertama MBConv. Penggunaan konvolusi mendalam pada MBConv dapat meningkatkan akurasi, tetapi juga dapat meningkatkan kompleksitas dan konsumsi daya. Fused-MBConv memberikan solusi yang lebih sederhana dan efisien, dengan akurasi yang setara dengan MBConv. Dengan demikian, EfficientNetV2 mampu mencapai akurasi yang lebih tinggi dengan menggunakan sumber daya komputasi yang lebih efisien dibandingkan dengan EfficientNet terdahulu.



Gambar 2.5 Arsitektur Umum EfficientNetV2 (Albattah et al, 2022)

2.7 Fitur Ekstraksi

Pada EfficientNetV2, fitur ekstraksi adalah proses pengambilan informasi penting dari data gambar atau citra. Ciri-ciri ini digunakan untuk membangun model identifikasi yang dapat memprediksi apakah suatu lesi kulit merupakan melanoma atau bukan. Proses ini menggunakan model *Convolutional Neural Network* (CNN) yang memfilter citra menggunakan kernel-kernel tertentu untuk mengekstrak ciri-ciri yang signifikan.

EfficientNetV2 melakukan fitur ekstraksi dengan menyusun beberapa blok CNN secara bertumpuk dan saling terhubung. Setiap blok CNN terdiri dari lapisan-lapisan konvolusi, pooling, dan aktivasi. Lapisan konvolusi berfungsi untuk menyaring citra dermoskopi dan mengekstrak fitur-fitur penting dengan menggunakan sejumlah filter atau kernel, kemudian hasilnya ditambah dengan bias serta dimasukkan ke dalam fungsi aktivasi untuk menghasilkan *output* yang bersifat non-linear. Selanjutnya, hasil dari proses tersebut melalui lapisan *pooling* untuk mengurangi ukuran citra dan jumlah parameter dalam jaringan dengan cara mengambil rata-rata intensitas *pixel* dari suatu gambar. Hasil dari proses tersebut disebut *feature map* yang kemudian di-*flatten* untuk menjadi vektor. *Feature map* yang sudah menjadi vektor akan diteruskan kepada *fully connected* layer untuk dilakukan proses pelatihan yaitu mencari bobot dan bias yang optimal dengan cara mengkombinasikan fitur-fitur yang diekstraksi pada langkah-langkah sebelumnya. Hasilnya akan menjadi model yang dapat mengidentifikasi apakah suatu lesi kulit merupakan melanoma atau non-melanoma.

2.8 Pengolahan Citra Digital

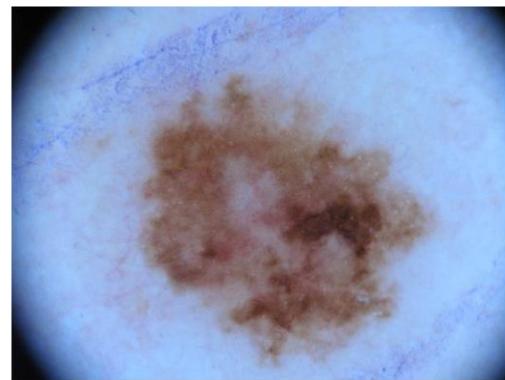
Pengolahan citra digital merujuk pada salah satu bidang ilmu komputer yang menerapkan teknik khusus untuk melakukan transformasi pada citra digital.

2.9 Citra Digital

Citra digital merupakan representasi visual dari objek atau adegan dalam bentuk matriks, di mana masing-masing elemen matriks mencerminkan tingkat keabuan atau intensitas cahaya pada suatu titik dalam citra. Karakteristik ini memungkinkan pengolahan komputer karena memenuhi persyaratan sebagai fungsi intensitas cahaya $f(x, y)$, dengan x dan y sebagai koordinat spasial. Dengan menggunakan matriks, setiap titik pada citra dapat diidentifikasi melalui elemen matriksnya, memungkinkan untuk melakukan pengolahan dan analisis citra dengan menerapkan algoritma dan teknik khusus.

2.10 Citra Dermoskopi

Citra dermoskopi adalah gambar atau rekaman visual dari permukaan kulit yang dihasilkan menggunakan perangkat dermoskopi, yaitu alat optik yang memungkinkan pemeriksaan lebih detail terhadap lesi kulit. Dermoskopi digunakan dalam bidang dermatologi untuk memperoleh gambar yang lebih terperinci dari area kulit tertentu, terutama untuk evaluasi dan diagnosis lesi atau bintik-bintik yang mungkin mencurigakan. Gambar dermoskopi membantu dalam mengidentifikasi pola dan fitur khusus yang dapat menjadi petunjuk penting dalam menentukan apakah suatu lesi berpotensi menjadi kanker kulit atau tidak. Ini membantu dalam deteksi dini dan pengelolaan penyakit kulit, termasuk melanoma dan lesi lainnya.



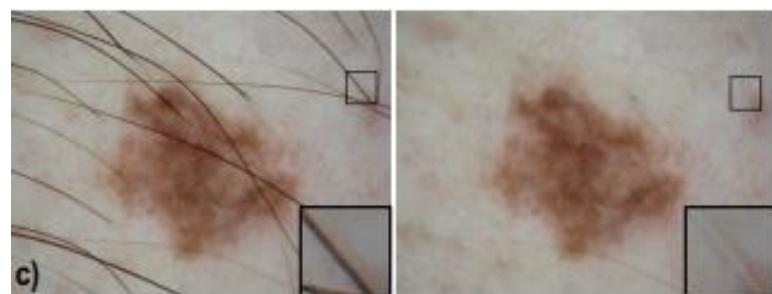
Gambar 2.6 Citra Dermoskopi

2.11 Augmentasi

Augmentasi merupakan teknik yang digunakan untuk memanipulasi atau mengubah citra sehingga citra aslinya mengalami variasi bentuk dan posisi. Tujuan dari augmentasi adalah memastikan bahwa mesin dapat mengenali objek dalam citra meskipun berada dalam bentuk dan posisi yang beragam. Selain itu, augmentasi juga berfungsi untuk meningkatkan jumlah data yang dapat diproses.

2.12 Hair Removal

Hair removal pada pengolahan citra digital merupakan proses penghapusan atau pengurangan jejak rambut sekitar lesi kulit pada gambar untuk meningkatkan kualitas citra dan mengurangi *noise* yang dapat membuat model sulit untuk mempelajari fitur dari suatu gambar. Dalam melakukan proses ini, digunakan algoritma oleh (Koehoorn et al, 2016).



Gambar 2.7 Penghapusan Rambut pada Citra Digital

2.13 *Flask*

Flask adalah *framework* web mikro yang ditulis menggunakan bahasa pemrograman Python. *Framework* ini dirancang untuk menjadi sederhana dan mudah dipahami serta menyediakan alat yang efisien untuk membangun aplikasi web dengan cepat. Flask memiliki focus yang terbatas dan kerangka kerja yang ringan, dan memungkinkan pengembang memilih dan mengintegrasikan komponen lain sesuai kebutuhan.

Flask memiliki beberapa kelebihan dan fitur utama, yaitu:

1. Flask memiliki sintaks yang sederhana dan mudah dipahami.
2. Flask dapat menghasilkan aplikasi web yang responsif dan efisien.
3. Flask merupakan *framework* yang fleksibel sehingga dapat disesuaikan dengan berbagai kebutuhan aplikasi web.
4. Flask adalah *framework* yang ringan dan sederhana sehingga mempermudah pengintegrasian model *machine learning* dan menjalankan API.

2.14 *Confusion Matrix*

Confusion Matrix adalah suatu metode yang digunakan untuk mengukur hasil klasifikasi suatu permasalahan. Metode ini membandingkan prediksi output dari model dengan nilai sebenarnya, memberikan gambaran yang rinci tentang performa model pada setiap kelas. Dengan menggunakan *Confusion Matrix*, kita dapat menilai akurasi model dan mendapatkan informasi terperinci tentang jenis kesalahan yang mungkin terjadi, diantaranya *false positive* dan *false negative*.

Terdapat empat nilai dalam *confusion matrix*, antara lain:

- *True Positive (TP)*: data yang bernilai positif dan diprediksi dengan benar sebagai positif.
- *True Negative (TN)*: data yang bernilai negatif dan diprediksi dengan benar sebagai negatif.
- *False Positive (FP)*: data yang bernilai negatif, namun diprediksi positif.
- *False Negative (FN)*: data yang bernilai positif, namun diprediksi negatif.

Berikut merupakan beberapa metode perhitungan *confusion matrix*, diantaranya:

1) Accuracy

Akurasi adalah nilai yang didapat dari perhitungan jumlah data bernilai positif dengan prediksi bernilai positif dan data bernilai negatif dengan prediksi yang bernilai negatif. Kemudian, nilai jumlah nilai tersebut dibagi dengan jumlah dari seluruh data penelitian. Semakin banyak data yang memiliki prediksi yang benar, maka semakin tinggi nilai akurasi dari suatu penelitian.

$$\text{Akurasi} = \frac{\text{Jumlah data dengan prediksi benar}}{\text{Jumlah seluruh data}} \quad (2.1)$$

2) Precision

Precision adalah rasio antara jumlah prediksi positif yang benar dengan total prediksi positif yang dilakukan. Dalam kata lain, *precision* mengukur sejauh mana hasil prediksi positif yang diperoleh konsisten dan akurat.

$$\text{Precision} = \frac{TP}{TP+FP} \quad (2.2)$$

3) Recall

Recall atau dikenal sebagai sensitivitas adalah salah satu metrik evaluasi klasifikasi yang mengukur seberapa baik model dapat mengidentifikasi dan menemukan semua *instance* yang benar positif dari kelas yang diinginkan. *Recall* menghasilkan ukuran persentase keberhasilan model dalam mendeteksi dan mengambil data positif yang relevan. Persamaan 2.3 adalah rumus mencari nilai *recall*.

$$\text{Recall} = \frac{TP}{TP+FN} \quad (2.3)$$

4) F1-Score

F1-score adalah metrik yang mengintegrasikan nilai recall dan precision menjadi sebuah nilai rata-rata. *F1-score* memberikan gambaran tentang sejauh mana model dapat mencapai keseimbangan antara kemampuan untuk mengidentifikasi data yang sebenarnya positif (*recall*) dan memberikan prediksi yang benar positif

(*precision*). Dengan demikian, *F1-score* dapat memberikan gambaran tentang kemampuan suatu model untuk mencapai akurasi yang seimbang antara menemukan data positif yang relevan dan memberikan prediksi yang tepat. Rumus dari *F1-score* dapat dilihat pada persamaan 2.4.

$$F1\text{-Score} = 2 \times \frac{Recall \times Precision}{Recall + Precision} \quad (2.4)$$

2.15 Penelitian Terdahulu

Penelitian terdahulu yang dilakukan oleh (Tan & Le, 2021) , mengusulkan sebuah model jaringan saraf tiruan dengan nama EfficientNetV2. Arsitektur tersebut merupakan pengembangan lebih lanjut dari arsitektur EfficientNet yang sebelumnya sudah diusulkan oleh mereka pada tahun 2019. EfficientNetV2 menggabungkan beberapa teknik baru untuk meningkatkan kinerja dan efisiensi model diantaranya adalah AutoML untuk menemukan konfigurasi model terbaik secara otomatis, scaling untuk meningkatkan kinerja model tanpa meningkatkan jumlah parameter, Fused-MBConv, dan MixNet untuk meningkatkan efisiensi model. Hasil dari penelitian ini menunjukkan bahwa EfficientNetV2 mencapai akurasi yang lebih tinggi daripada model-model terdahulu termasuk EfficientNet, dengan ukuran model yang lebih kecil dan waktu pelatihan lebih cepat.

Kemudian terdapat penelitian terdahulu lainnya yang dilakukan oleh (Soegeng, 2021) mengenai penerapan CNN untuk mengklasifikasi kanker kulit melanoma menggunakan dataset ISIC 2020. Penelitian ini menggunakan *Ensembling Bagging Method*, yaitu menggabungkan beberapa model yang telah dilatih menjadi satu meta-model yang menghasilkan akurasi yang lebih tinggi dibandingkan apabila masing-masing model melakukan prediksi terhadap dataset yang sama secara terpisah. Penelitian ini menerapkan *preprocessing hair removal*, dimana metode ini malah mengurangi akurasi pada model, sehingga peneliti tersebut menyarankan untuk menyempitkan daerah yang akan dipelajari setelah melakukan *hair removal*. Adapun arsitektur yang digunakan pada penelitian ini diantaranya adalah ResNet-50-v2, EfficientNet-B0, EfficientNet-B1, EfficientNet-B3, EfficientNet-B4, EfficientNet-B5, EfficientNet-B6, dan EfficientNet-B7, dimana model yang memiliki tingkat akurasi pada proses prediksi terpisah dan

tidak menerapkan *preprocessing hair removal* terbesar adalah EfficientNet-B6 dengan akurasi 92,813%, dan model yang memiliki tingkat akurasi pada proses prediksi terpisah serta menerapkan *preprocessing hair removal* terbesar adalah EfficientNet-B4 dengan akurasi 92,03%. Adapun hasil prediksi test menggunakan *Ensemble* dengan kombinasi berbagai model memiliki akurasi terbesar yaitu 93,108% pada sepuluh rata-rata model terbaik, dan memiliki peningkatan 0.295% dari akurasi individu model tertinggi.

Penelitian selanjutnya yang dilakukan oleh (Pardede dan Putra, 2020) melakukan implementasi DenseNet untuk mengidentifikasi kanker kulit melanoma. Penelitian ini menggunakan dataset citra kanker kulit melanoma yang didapat dari Alexander Scarlat, dimana terdapat dua kelas pada dataset tersebut yaitu kelas melanoma dan kelas bukan melanoma. Penelitian ini melakukan proses *training* dengan menggunakan 300 *epoch*, *optimizer stochastic gradient descent*, *learning rates* 0,1 dan 32 *batch size* dengan menggunakan arsitektur DenseNet121. Hasil dari penelitian ini adalah arsitektur DenseNet121 mampu melakukan klasifikasi kanker kulit melanoma dengan nilai rata-rata akurasi, *precision*, *recall*, dan F-Measure masing-masing yaitu 0,94, 0,95, 0,92, dan 0,94.

Tabel 2.1 Penelitian Terdahulu

No.	Penulis	Judul	Tahun	Keterangan
1.	Tan M, Le Q	EfficientNetV2: Smaller Models and Faster Training	2021	Penelitian ini membahas tentang pengembangan arsitektur EfficientNet dengan menggabungkan beberapa teknik baru untuk meningkatkan kinerja dan efisiensi model. Hasil dari penelitian ini menunjukkan bahwa EfficientNetV2 mencapai akurasi yang lebih tinggi daripada model-model terdahulu termasuk EfficientNet, dengan ukuran model yang lebih kecil dan waktu pelatihan lebih cepat.
2.	Michael Kurniawan, Soegeng, Liliana, Agustinus	Penerapan Convolutional Neural Network untuk Klasifikasi Kanker Kulit	2021	Penelitian ini melakukan penggabungan arsitektur ResNet dan EfficientNet untuk mengklasifikasi melanoma. Dari hasil ensembling semua model

	Noertjahyana	Melanoma pada Dataset Gambar Kulit	yang telah dilatih, diperoleh akurasi prediksi AUC 93.108%
3.	Jasman Pardede, Dwi Adi Lenggana Putra	Implementasi DenseNet Untuk Mengidentifikasi Kanker Kulit Melanoma	2020 Menggunakan arsitektur DenseNet untuk mengidentifikasi melanoma. Penelitian ini mengimplementasi arsitektur CNN yaitu DenseNet121 dan mendapatkan nilai rata-rata akurasi 94%
4.	Huang, Liao	Stacking Ensemble and ECAEfficientNet V2 Convolutional Neural Networks on Classification of Multiple Chest	2022 Pada penelitian ini melakukan klasifikasi beberapa penyakit dada termasuk COVID-19 dengan menggunakan gabungan beberapa model termasuk EfficientNetV2 dan ECA-EfficientNetV2. Penelitian ini mendapatkan akurasi tertinggi pada 99,81%
5.	Danilo Barros Mendes, Nilton Correia da Silva	Skin Lesions Classification Using Convolutional Neural Networks in Clinical Images	2018 Menggunakan arsitektur ResNet-152, dan melakukan pelatihan pada 3.797 data gambar. Penelitian ini melakukan klasifikasi lesi kulit termasuk melanoma dan menghasilkan 0.96 AUC untuk melanoma, dan 0.91 untuk Basal Cell Carcinoma
6.	Jasmine Athira Azzahra	Identifikasi Kanker Kulit (Melanoma) Pada Citra Menggunakan Algoritma Machine Learning K-Nearest Neighbor (K-NN) Classifier	2023 Penelitian ini mengajukan penggunaan machine learning untuk deteksi melanoma dengan menerapkan metode K-NN dengan K = 7, dengan fokus pada fitur tekstur citra yang diekstraksi menggunakan Local Binary Pattern. Metode ini juga melibatkan proses cross-validation sebanyak 5 fold, dan hasilnya menunjukkan rata-rata akurasi sebesar 90% dengan penggunaan K-Fold.
7.	Joost Koehoorn, André Sobiecki, Paulo Rauber, Andrei Jalba,	Efficient and Effective Automated Digital Hair Removal from Dermoscopy	2016 Penelitian mengusulkan sebuah metode untuk penghapusan rambut digital pada citra dermoskopi. Metode ini didasarkan pada model pengaturan ambang tertentu.

	Alexandru Telea	Images	Untuk setiap ambang tertentu, mereka menggunakan algoritma deteksi celah terbaru untuk menemukan rambut, dan hasilnya digabungkan dalam sebuah citra biner. Proses selanjutnya melibatkan pencarian rambut menggunakan filter morfologis dan deskriptor medial. Penelitian ini menunjukkan bahwa metodenya secara efektif menangani tugas segmentasi tumor kulit otomatis untuk gambar yang terdapat rambut.
8.	Mohammed A. Al-masni, Dong-Hyun Kim, Tae-Seong Kim	Multiple Skin Lesions Diagnostics via integrated deep convolutional networks for segmentation and classification	2020 Penelitian ini menggunakan gabungan beberapa arsitektur diantaranya Inception-v3, ResNet-50, Inception-ResNet-v2, dan DenseNet-201 untuk mengklasifikasi lesi kulit yang telah dilakukan segmentasi sebelumnya menggunakan <i>deep learning full resolution convolutional network</i> (FrCN), dan mendapatkan akurasi tertinggi sebesar 89.28% untuk dataset ISIC 2018.
9.	Duwi Purnama Sidik, Fitri Utaminingrum, Lailil Muflikhah	Penggunaan Variasi Model pada Arsitektur EfficientNetV2 untuk Prediksi Sel Kanker Serviks	2023 Penelitian ini menggunakan arsitektur EfficientNetV2 untuk mendeteksi gambar dengan sel kanker serviks dengan kinerja dan efektivitas yang tinggi dan mendapat akurasi sebesar tertinggi 99%.
10.	Hasib Zunair, A. Ben Hamza	Melanoma Detection using Adversarial Training and Deep Transfer Learning	2020 Penelitian membahas masalah ketidakseimbangan kelas pada dataset lesi kulit, di mana sebagian besar sampel adalah normal dan hanya sebagian kecil yang abnormal. Selain itu, gambar lesi kulit cenderung mirip secara keseluruhan karena variasi antar kelas yang rendah. Untuk mengatasi masalah ini, penelitian mengusulkan kerangka kerja dua tahap untuk

klasifikasi otomatis gambar lesi kulit menggunakan pelatihan adveersarian dan transfer learning untuk mendeteksi melanoma. Tahap pertama adalah sintesis gambar, dimana penelitian memanfaatkan variasi antar kelas dalam distribusi data dengan melakukan sintesis gambar kondisional dan dengan menggunakan teknik translasi gambar ke gambar tanpa pasangan, tahap kedua adalah klasifikasi. Penelitian ini menunjukkan bahwa metodenya menghasilkan penilaian lesi berbasis konteks yang dapat mencapai tingkat ahli dermatolog.

2.15.1 Perbedaan Penelitian

Terdapat perbedaan penelitian penulis dengan penelitian oleh (Soegeng, 2021), dimana pada penelitian yang dilakukan oleh Soegeng menggabungkan beberapa arsitektur RestNet dan EfficientNet untuk mengklasifikasikan penyakit kanker kulit melanoma, sementara itu, penelitian ini mengimplementasikan arsitektur EfficientNetV2 untuk mengidentifikasi penyakit melanoma berdasarkan citra dermoskopi. Penelitian yang dilakukan Soegeng juga menerapkan *preprocessing hair removal* terhadap dataset gambar dengan tujuan untuk mengurangi *noise* yang disebabkan oleh rambut pada kulit, namun hal tersebut menyebabkan akurasi berkurang dikarenakan model mempelajari fitur dari kulit biasa sehingga mengganggu dalam proses klasifikasi, sehingga pada penelitian ini akan menerapkan *preprocessing hair removal*, namun ditambah dengan metode segmentasi untuk memisahkan objek dengan latar belakang, dengan harapan model dapat lebih fokus terhadap tanda pada kulit yang diteliti.

Lalu perbedaan penelitian penulis dengan penelitian (Pardede, 2020) yang sama-sama mengidentifikasi melanoma yaitu terletak pada arsitektur yang digunakan. Penelitian oleh Pardede menggunakan arsitektur DenseNet121,

sementara penulis menggunakan arsitektur EfficientNetV2. Begitu juga dengan penelitian oleh (Mohmmmed A., 2020), dimana penelitiannya berfokus pada diagnosis beberapa lesi kulit menggunakan beberapa arsitektur diantaranya yaitu Inception-v3, ResNet-50, Inception-ResNet-v2, dan DenseNet-201 untuk mengklasifikasi beberapa dataset lesi kulit diantaranya adalah ISIC 2016, 2017, dan 2019 dimana terdapat gambar tujuh jenis lesi kulit yang sudah diterapkan proses segmentasi. Perbedaan penelitian ini dengan penelitian tersebut terletak pada penggunaan arsitektur yang berbeda dan dataset yang digunakan, dimana pada penelitian ini menggunakan dataset ISIC 2020.

BAB 3

ANALISIS DAN PERANCANGAN SISTEM

3.1 Data yang digunakan

Penelitian ini menggunakan data gambar yang diambil dari ISIC *dataset*. ISIC atau *International Skin Imaging Collaboration* merupakan organisasi nirlaba yang berfokus pada pengembangan dan distribusi *dataset* citra kulit untuk mendukung penelitian dalam bidang pengenalan dan deteksi penyakit kulit dengan menggunakan teknologi citra medis. Dataset ISIC diambil dan dikumpulkan oleh para peneliti dengan berbagai perangkat, termasuk dermoskop. Dataset ini juga digunakan dalam proyek-proyek penelitian dan pengembangan untuk mengembangkan algoritma dan model kecerdasan buatan yang dapat membantu dalam diagnosis penyakit kulit, termasuk deteksi kanker kulit. Total jumlah data yang digunakan adalah 2100 data diantaranya terdapat 1050 gambar melanoma dan 1050 gambar *nevus* atau tahi lalat untuk kategori non melanoma. Berikut merupakan contoh data penelitian yang dapat dilihat pada gambar 3.1.



Gambar 3.1 Citra Melanoma dan Citra Non Melanoma (*nevus*)

Kedua jenis klasifikasi citra diatas kemudian akan dibagi menjadi tiga bagian, yaitu 1470 citra atau 70% dari jumlah citra untuk data *training*, 420 citra atau 20% dari jumlah citra untuk data *validation*, dan 210 citra atau 10% dari jumlah citra untuk data *testing*. Rincian mengenai pembagian data terdapat pada tabel 3.1.

Tabel 3.1 Pembagian Data *Training*, Data *Validation*, dan Data *Testing*

No	Data	Data Training	Data Validation	Data Testing	Jumlah
1.	Citra Melanoma	735	210	105	1050
2.	Citra Non-Melanoma	735	210	105	1050
Total Data		1470	420	210	2100

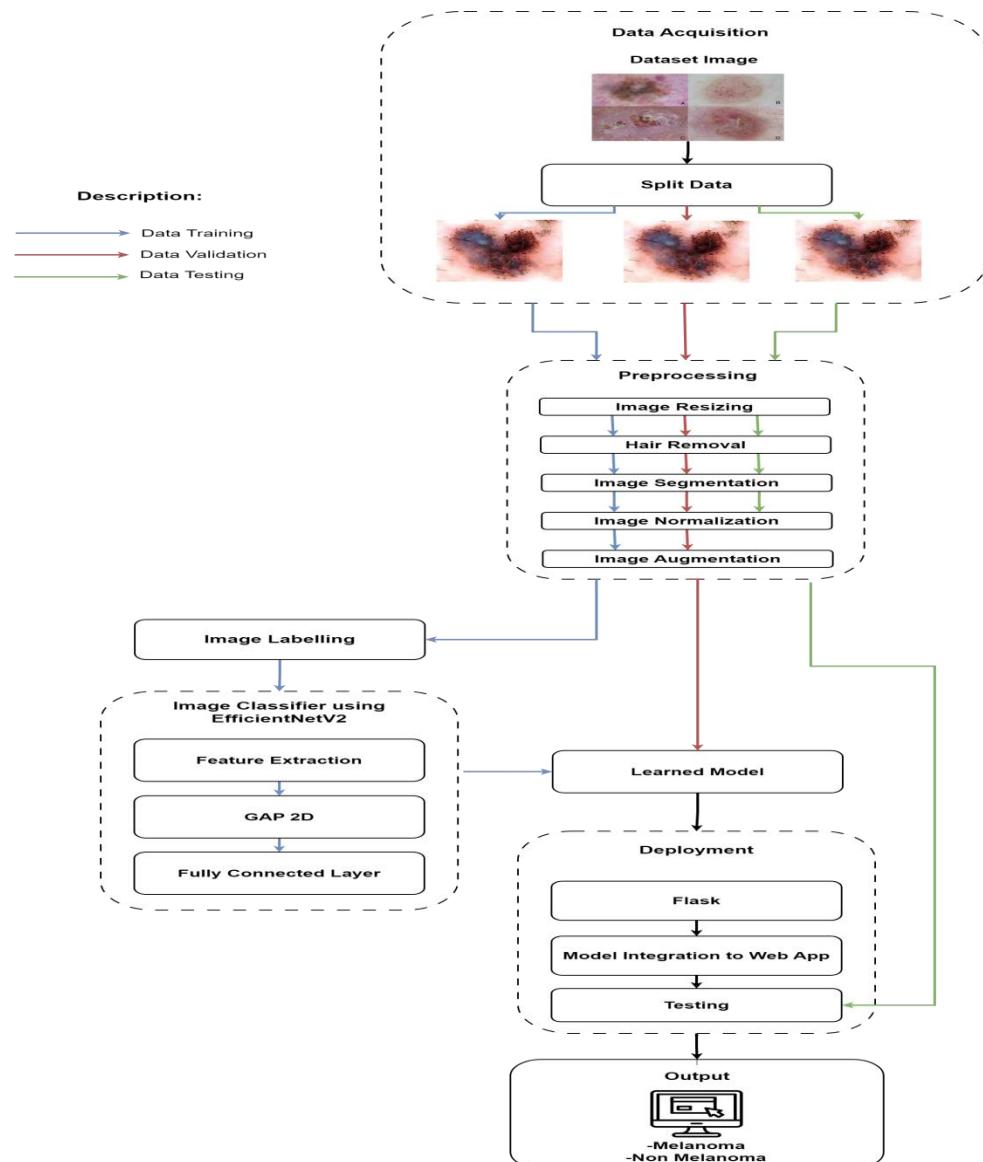
3.2 Analisis Sistem

Proses yang diterapkan dalam penelitian ini mencakup beberapa tahap. Tahap pertama yaitu pengumpulan data citra lesi kulit, dimana data tersebut berisi citra lesi kulit melanoma dan non melanoma. Data tersebut merupakan citra lesi kulit yang diambil dengan menggunakan alat medis bernama dermoskop, kemudian disimpan di dalam satu *database* oleh ISIC dalam format JPEG dan PNG.

Tahap kedua merupakan tahap *preprocessing* yang melibatkan proses pelabelan untuk memberi nama pada masing-masing citra lidah, proses pelabelan ini hanya diterapkan untuk data *training* saja, lalu setelah itu terdapat tahap *resizing* untuk mengubah ukuran piksel menjadi seragam yaitu menjadi 240×240 piksel. Pemilihan ukuran piksel tersebut karena EfficientNetV2 tidak meminta ukuran gambar atau citra secara spesifik, namun untuk ukuran citra minimum adalah 128 piksel, dengan ukuran maksimum 300 piksel untuk model varian kecil seperti B0 hingga S dan 380 piksel untuk model varian besar seperti M dan L. Pemilihan ukuran yang tidak terlalu besar dengan tujuan agar proses komputasi berjalan lebih cepat, sementara pemilihan ukuran yang tidak terlalu kecil memiliki tujuan yaitu agar model tidak kehilangan kualitas dari fitur-fitur yang diekstraksi dari suatu citra karena citra yang terlalu kecil. Alasan lain ukuran tersebut dipilih karena pada penelitian ini menggunakan EfficientNetV2 varian B3. Setelah itu, terdapat proses *hair removal* dimana pada proses ini, rambut di sekitar lesi kulit akan dihilangkan. Langkah selanjutnya adalah *segmentation*, proses ini akan menyempitkan ruang atau daerah yang akan dipelajari. Kemudian, citra tersebut akan melalui proses *normalization* yaitu untuk memastikan skala intensitas piksel

setiap gambar sama, sehingga dapat dibandingkan dengan mudah, lalu terdapat proses *augmentation*, yaitu untuk menciptakan variasi data dengan cara menerapkan transformasi atau modifikasi tertentu dengan tujuan untuk meningkatkan performa serta generalisasi model. Pada proses *augmentation* ini, akan melalui beberapa proses yaitu pembalikan (*flipping*), rotasi secara vertikal dan horizontal, serta rotasi sebesar 45 derajat.

Tahap terakhir yaitu tahap pengklasifikasian citra menggunakan metode fitur ekstraksi yang terdapat pada algoritma CNN dengan arsitektur EfficientNetV2. Tahap klasifikasi ini akan menghasilkan output berupa lesi kulit yang teridentifikasi sebagai melanoma atau non melanoma. Keseluruhan tahapan penelitian ini dapat dilihat pada arsitektur umum dalam gambar 3.2.



Gambar 3.2 Arsitektur Umum

3.2.1 Data Acquisition

Tahap ini merupakan tahap pengumpulan data citra dermoskopi kulit. Citra tersebut terdiri dari dua kategori, yaitu melanoma dan non melanoma, dimana untuk kategori non melanoma, citra yang digunakan merupakan citra *nevus*. Data citra tersebut berasal dari *dataset* ISIC, yang merupakan organisasi nirlaba yang dibentuk untuk berbagai tujuan termasuk pengembangan dan validasi model kecerdasan buatan untuk deteksi melanoma atau kondisi kulit lainnya. Data yang dikumpulkan memiliki ekstensi JPEG/JPG dan PNG.

3.2.2 *Splitting Data*

Setelah tahap pengumpulan data, data citra dermoskopi kulit tersebut selanjutnya dibagi menjadi tiga kategori, yaitu data *training*, data *validation*, dan data *testing*. Data *training* digunakan dalam proses pelatihan model, sementara itu data *validation* digunakan untuk mengevaluasi kinerja atau akurasi model selama proses pelatihan berlangsung. Kemudian, data *testing* merupakan data yang digunakan untuk menguji kinerja model yang sudah selesai melakukan proses pelatihan.

3.2.3 *Preprocessing*

Tahapan ini terdiri dari serangkaian langkah atau teknik yang diterapkan pada citra sebelum analisis atau pembelajaran mesin. Tujuan utama dari *preprocessing* adalah untuk meningkatkan kualitas informasi dalam citra, serta memfasilitasi ekstraksi fitur atau tugas klasifikasi yang lebih baik. Pada penelitian ini, tahapan *preprocessing* yang akan dilakukan diantaranya adalah *Labelling*, *Resizing*, *Hair Removal*, *Segmentation*, *Normalization*, dan *Augmentation*.

3.2.3.1 *Image Resizing*

Proses *resizing* diterapkan terhadap data citra untuk mengubah ukuran citra menjadi seragam. Pada penelitian ini, ukuran dari citra akan diubah menjadi 240 x 240 piksel. Berikan merupakan contoh dari proses *resizing* yang dilakukan pada penelitian ini:



Citra berdimensi 4x4 piksel diubah menjadi citra berdimensi 2x2 piksel dengan mengambil nilai rata-rata dari empat piksel yang berdekatan. Nilai piksel baru ini

kemudian akan mewakili citra yang telah mengalami proses perubahan ukuran.

Berikut perhitungannya:

$$P1 = (217+215+219+213) \div 4 = 216$$

$$P2 = (225+187+230+190) \div 4 = 208$$

$$P3 = (192+195+188+185) \div 4 = 190$$

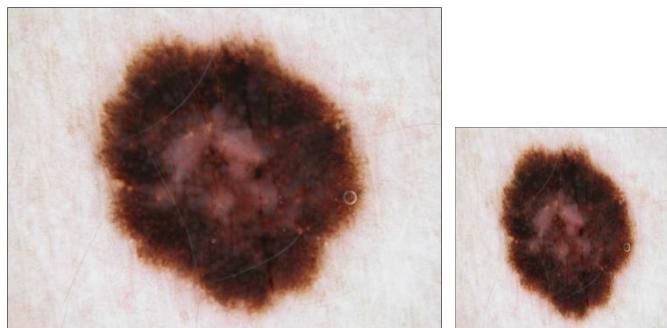
$$P4 = (200+157+177+178) \div 4 = 178$$

Nilai intensitas piksel dari citra hasil proses *resizing* dengan matriks diatas terdapat pada gambar 3.3.

216	208
190	178

Gambar 3.3 Nilai Matriks Setelah Proses *Resize*

Berikut merupakan contoh citra sebelum dan setelah diterapkan proses *resize* yang dapat dilihat pada gambar 3.4 di bawah.

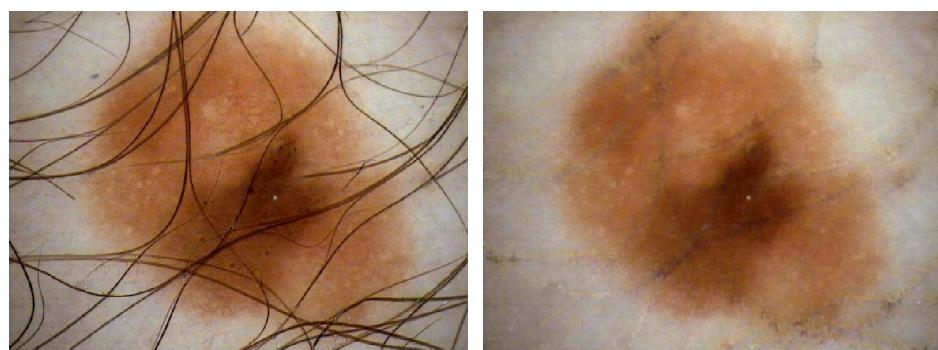


Gambar 3.4 Citra Lesi Kulit Sebelum dan Sesudah *resizing*

3.2.3.2 Hair Removal

Hair removal adalah proses penghilangan atau pengurangan rambut dari citra, terutama dalam konteks citra medis. Rambut pada citra dapat menjadi elemen gangguan yang mengakibatkan ketidakakuratan dalam tugas analisis, seperti proses identifikasi melanoma. Hal ini dikarenakan rambut akan menjadi fitur yang tidak berhubungan dengan lesi kulit yang sedang dianalisis dan mempengaruhi proses pembelajaran model. Tahapan pertama pada proses hair removal adalah mengubah citra menjadi citra grayscale, kemudian citra akan diterapkan operasi

morfologi yaitu manipulasi struktur bentuk objek dalam citra, seperti dilasi, erosi, *opening*, dan *closing* menggunakan suatu kernel. Setelah itu, akan diterapkan filter *blackhat*, yaitu satu jenis filter yang digunakan untuk mengekstraksi fitur yang lebih gelap dari latar belakangnya, dengan tujuan untuk menemukan kontur rambut, kemudian kontur rambut tersebut akan diperkuat dengan dengan metode *thresholding*, dengan cara merubah semua piksel dengan intensitas dibawah nilai 10 menjadi 0, dan yang di atasnya menjadi 255. Langkah terakhir dari tahapan ini yaitu menerapkan algoritma *inpainting* terhadap citra, dimana algoritma ini merupakan teknik untuk mengisi atau menggantikan bagian tertentu dari citra yang hilang atau rusak dengan informasi dari suatu *mask* yang telah dibuat sebelumnya. Dalam konteks pengolahan citra, *mask* adalah citra biner yang digunakan untuk menentukan area atau piksel tertentu yang akan diaktifkan atau dinonaktifkan dalam suatu proses pemulihan citra. Citra lesi kulit sebelum dan sesudah diterapkan hair removal dapat dilihat pada gambar 3.5.

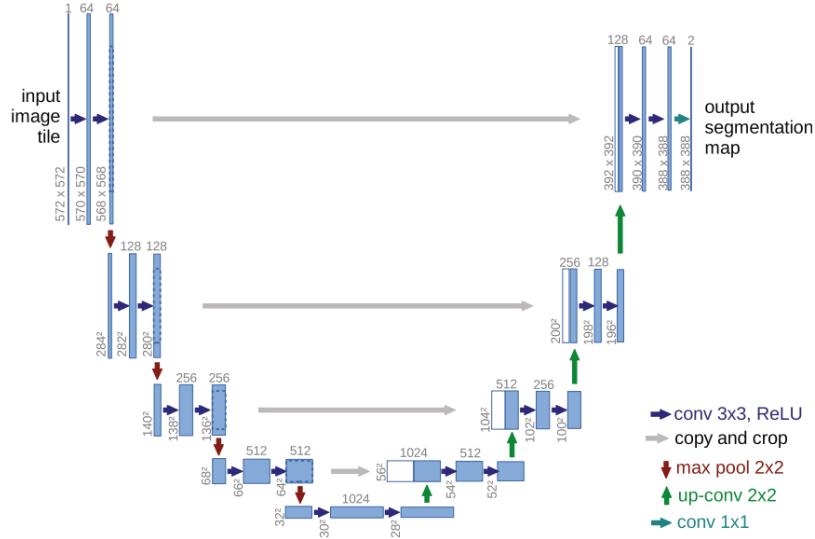


Gambar 3.5 Citra Sebelum dan Sesudah *hair removal*

3.2.3.3 *Image Segmentation*

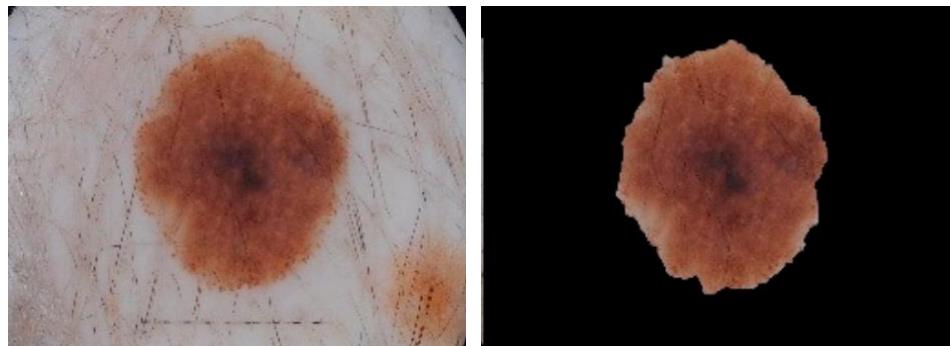
Image segmentation atau segmentasi citra merupakan proses pemisahan atau pembagian sebuah gambar yang memiliki karakteristik tertentu menjadi beberapa bagian. Dengan metode ini, gambar dapat diidentifikasi dan dipisahkan menjadi objek-objek berbeda dengan tujuan untuk memahami struktur gambar dengan cara yang lebih terperinci serta meningkatkan fokus pelatihan model pada objek dalam gambar dengan cara menghilangkan elemen yang tidak relevan. Dalam tahapan ini, digunakan arsitektur bernama U-Net yang dirancang oleh O. Ronneberger et al

dari Universitas Freiburg yang khusus digunakan untuk memecahkan masalah segmentasi citra biomedis.



Gambar 3.6 Arsitektur U-Net (Ronneberger, 2015)

Pada gambar 3.6, bagian sebelah kiri merupakan bagian *contracting path*, sementara itu bagian sebelah kanan merupakan *expanding path* untuk mencapai segmentasi semantik. Jaringan konvolusi ini terdiri dari proses yang berulang yaitu dua operasi konvolusi 3x3 diikuti oleh fungsi aktivasi ReLU dan terdapat proses downsampling melalui operasi max pooling 2x2 dengan stride 2. Sedangkan pada sisi dekonvolusional terdapat operasi upsampling dari *feature map* yang diperoleh selama berjalannya *contracting path*. Sebagai persyaratan, *feature map* yang diperoleh selama proses *contracting path* perlu diikuti dengan konvolusi 3x3 dan diikuti oleh lapisan ReLU (Ciptaningrum, 2021). Input pada arsitektur ini adalah citra RGB dan *mask* biner yang sesuai, sementara itu pelatihannya dilakukan dengan mengoptimalkan bobot menggunakan *stochastic gradient descent* (SGD). Contoh citra sebelum dan sesudah diterapkan proses *segmentation* dapat dilihat pada gambar 3.7 berikut.



Gambar 3.7 Citra Sebelum dan Sesudah *segmentation*

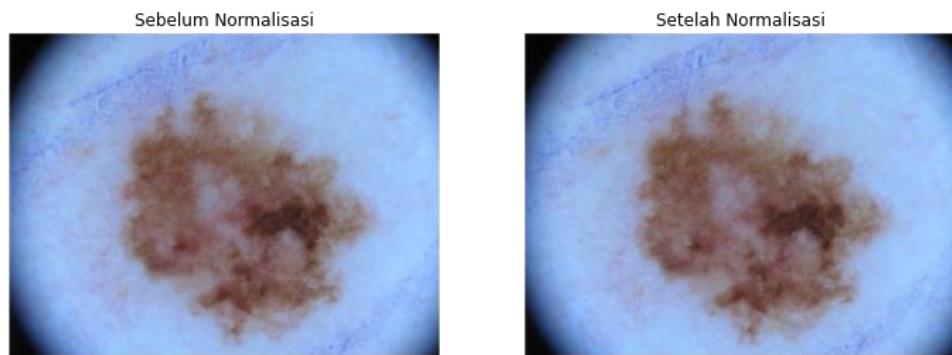
3.2.3.4 *Image Normalization*

Proses ini merupakan proses untuk mengubah intensitas piksel dalam gambar agar memiliki distribusi yang lebih seragam dan sesuai dengan rentang tertentu, guna memastikan bahwa input ke model memiliki rata-rata dan standar deviasi yang konsisten sehingga lebih mudah dipelajari dan dibandingkan. Pada penelitian ini, intensitas piksel akan dikonversi ke rentang 0 sampai 1, dimana semakin mendekati angka 0 maka piksel tersebut akan semakin gelap, sebaliknya, semakin mendekati angka 1 maka piksel tersebut semakin terang. Proses ini dilakukan dengan cara membagi nilai tiap piksel dengan 255. Berikut merupakan contoh proses normalisasi citra:

217	215	225	187	→	0.8509	0.8431	0.8823	0.7333
219	213	230	190		0.8588	0.8382	0.9019	0.7450
192	195	200	157		0.7529	0.7647	0.7843	0.6156
188	185	177	178		0.7372	0.7254	0.6941	0.6980

Proses diatas merupakan contoh normalisasi intensitas setiap piksel pada gambar 4x4. Dapat dilihat bahwa intensitas setiap piksel akan dibagi dengan 255. Contohnya pada piksel pertama, dimana piksel tersebut memiliki intensitas 217, ketika dibagi dengan 255 akan menghasilkan nilai intensitas sebesar 0.8509.

Contoh gambar atau citra sebelum dan sesudah diterapkan proses *normalization* terdapat pada gambar 3.8.

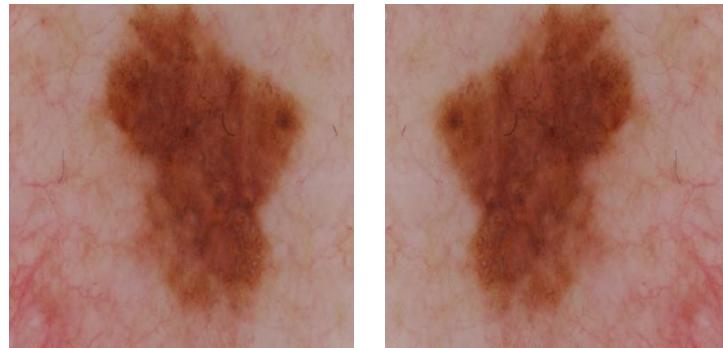


Gambar 3.8 Sebelum dan Sesudah *normalization*

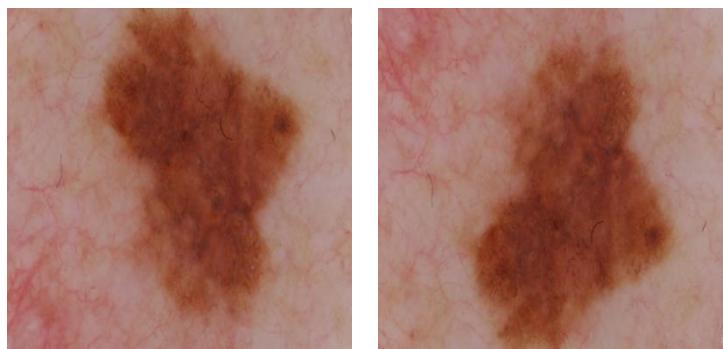
3.2.3.5 Augmentasi

Proses mengubah atau menyesuaikan suatu gambar sehingga bentuk dan letak aslinya berubah disebut augmentasi. Augmentasi digunakan untuk memungkinkan mesin mengidentifikasi gambar dalam berbagai bentuk dan lokasi. Selain itu, augmentasi dapat menghasilkan volume data yang lebih besar untuk diproses, sehingga dapat meningkatkan variasi pola pada data dan juga menyeimbangkan *dataset* yang memiliki selisih data antar label yang dapat menyebabkan model tidak seimbang. Penelitian ini menggunakan augmentasi berupa *flip* dan *rotate*. *Flip* adalah operasi pencerminan horizontal atau vertikal terhadap gambar, sedangkan *rotate* akan memutar gambar di sekitar pusatnya dengan sudut tertentu, dimana dalam penelitian ini menggunakan rotasi sebesar 90 derajat dan -90 derajat. Nilai -90 derajat merupakan kebalikan dari rotasi 90 derajat, yang tujuannya agar model mendapat perspektif yang lebih kaya.

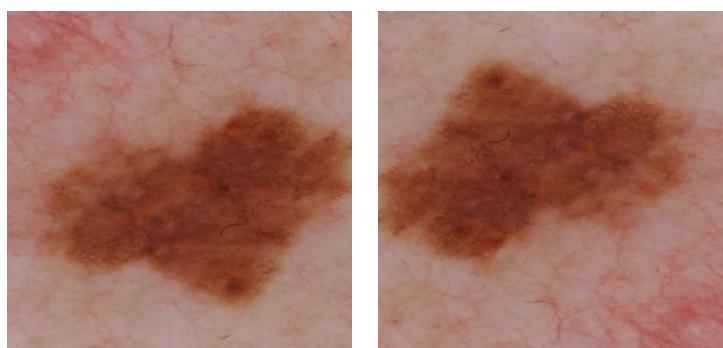
Gambar atau citra lesi kulit sebelum dan sesudah diterapkan proses augmentasi terdapat pada gambar 3.9, 3.10, dan 3.11.



Gambar 3.9 Sebelum dan Sesudah *flip* horizontal



Gambar 3.10 Sebelum dan Sesudah *flip* vertikal



Gambar 3.11 Rotasi 90 derajat dan -90 derajat

Berikut merupakan contoh *pseudocode* dari proses augmentasi diatas:

```

IMPORT libraries

FUNCTION create_folder_if_not_exist(folder):
    If folder not exists:
        Create folder

    Input_folder = "Folder-sebelum-augmentasi"
    Output_folder = "Folder-setelah-augmentasi"
    Augmentations = ["90", "hf", "vf"]

FOR augmentation in Augmentations:
    FOR class_folder in list_folders_in(Input_folder):
        Create_folder_if_not_exist(join(output_folder, class_folder))

        FOR image_file in list_files_in(class_folder):
            Image = read_image(image_file)

            If augmentation == "90":
                Augmented_image = rotate_image_90(image)

            Else if augmentation == "hf":
                Augmented_image = flip_image_horizontally(image)

            Else if augmentation == "vf":
                Augmented_image = flip_image_vertically(image)

            Img_name, ext = split_file_name_and_extension(image)
            Output_file = output_folder/class_folder/img_name.ext
            SAVE_IMAGE(Augmented_image, Output_file)

PRINT("Augmentation done")

```

3.2.3.6 *Labelling*

Proses ini dilakukan untuk menamai atau menetapkan label tertentu kepada dataset pelatihan untuk membimbing model dalam memahami pola atau hubungan antara *input* dan *output* yang diinginkan. Proses pelabelan gambar dilakukan dengan mengelompokkan gambar ke dalam folder yang masing-masing telah diberikan nama label sesuai klasifikasinya, yaitu melanoma dan non melanoma. Gambar yang telah berada pada folder-folder tersebut kemudian dimuat oleh sistem seusai labelnya. Proses *labeling* terdapat pada gambar 3.12 dibawah ini.

Drive Saya > Dataset-Final > dataset_train				✓	☰	grid	info
Jenis	Orang	Dimodifikasi					
			Nama	Terakhir			
			melanoma	saya 12.00			
			non_melanoma	saya 12.00			

Gambar 3.12 *Labelling* Data

3.2.4 *Image Classifier*

Dalam penelitian ini, proses klasifikasi menerapkan algoritma *Convolutional Neural Network* (CNN) menggunakan *Google Colab* dan *TensorFlow* sebagai alat bantu. Pembagian klasifikasi terdiri dari beberapa tahap yaitu tahap pelatihan, validasi, dan pengujian. Berikut merupakan tahapan dari klasifikasi gambar menggunakan *EfficientNetV2*:

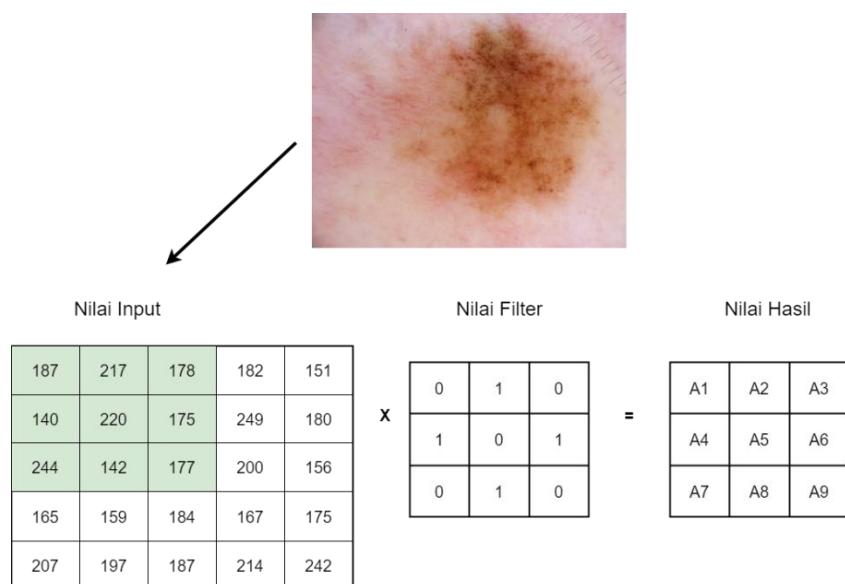
3.2.4.1 *Convolutional Layer*

Convolutional layer menerapkan filter untuk mengenali dan mengekstrak fitur visual dari objek lesi kulit yang sedang diidentifikasi. Filter pada lapisan ini terdiri dari sejumlah neuron yang disusun dalam sebuah matriks yang memiliki tinggi dan lebar tertentu (dalam piksel). Proses konvolusi melibatkan ekstraksi informasi yang signifikan dari input melalui perkalian bobot pada setiap piksel, diikuti dengan penjumlahan hasilnya. Hasil dari proses konvolusi ini kemudian diarahkan ke lapisan berikutnya untuk mengalami tahapan pemrosesan lebih lanjut.

EfficientNetV2 memiliki filter-filter yang dirancang khusus untuk mencapai tingkat efisiensi dan kinerja yang optimal dalam pemrosesan gambar atau citra. Dengan memindahkan atau menggeser filter secara menyeluruh pada seluruh gambar, terbentuk peta aktivasi yang memvisualisasikan lokasi fitur-fitur penting dalam gambar. Lapisan konvolusi berfungsi untuk menjalankan operasi konvolusi pada citra, menghasilkan *feature map* yang menyoroti pola-pola penting terkait dengan lesi kulit dalam citra tersebut. Berikut merupakan contoh matriks gambar *input* pada penelitian ini:

$$\begin{bmatrix} 187 & 217 & 178 & 182 & 151 \\ 140 & 220 & 175 & 249 & 180 \\ 244 & 142 & 177 & 200 & 156 \\ 165 & 159 & 184 & 167 & 175 \\ 207 & 197 & 187 & 214 & 242 \end{bmatrix}$$

Matriks yang berisi intensitas piksel dari gambar dihitung menggunakan filter yang terdapat pada lapisan konvolusi. *Activation map* dibentuk melalui pengulangan proses ini untuk setiap elemen dalam gambar *input*, di mana *filter* digeser melalui seluruh area gambar untuk menghasilkan respons atau aktivasi pada setiap langkah perhitungan. Adapun salah satu contoh perhitungan menggunakan *filter* pada matriks gambar penelitian dapat dilihat pada Gambar 3.13.



Gambar 3.13 Contoh Perhitungan *Filter Convolutional Layer*

Pada Gambar 3.13 terdapat langkah perhitungan konvolusi yang dilakukan pada lapisan konvolusi dengan menggunakan *filter* atau kernel berukuran 3×3 dengan *stride* atau langkah sebesar 1. *Stride* menggambarkan seberapa jauh *filter* akan digeser pada matriks *input* setiap langkahnya. Gambar 3.14 menunjukkan proses pergeseran *filter* dengan *stride* 1.

187	217	178	182	151
140	220	175	249	180
244	142	177	200	156
165	159	184	167	175
207	197	187	214	242

187	217	178	182	151
140	220	175	249	180
244	142	177	200	156
165	159	184	167	175
207	197	187	214	242

187	217	178	182	151
140	220	175	249	180
244	142	177	200	156
165	159	184	167	175
207	197	187	214	242

187	217	178	182	151
140	220	175	249	180
244	142	177	200	156
165	159	184	167	175
207	197	187	214	242

187	217	178	182	151
140	220	175	249	180
244	142	177	200	156
165	159	184	167	175
207	197	187	214	242

187	217	178	182	151
140	220	175	249	180
244	142	177	200	156
165	159	184	167	175
207	197	187	214	242

Gambar 3.14 Posisi *filter* pada Proses Konvolusi

Pada Gambar 3.13, terlihat proses perhitungan *dot product*, dimana hasil dari perkalian matriks *input* dengan matriks *filter* menjadi nilai dari *feature map*. Berikut adalah perhitungan lapisan konvolusi pada penelitian ini:

$$\begin{aligned} A1 &= (187 \times 0) + (217 \times 1) + (178 \times 0) + (140 \times 1) + (220 \times 0) + (175 \times 1) + (244 \times 0) \\ &\quad + (142 \times 1) + (177 \times 0) = 217 + 140 + 175 + 142 = 674 \end{aligned}$$

$$\begin{aligned} A2 &= (217 \times 0) + (178 \times 1) + (182 \times 0) + (220 \times 1) + (175 \times 0) + (249 \times 1) + (142 \times 0) \\ &\quad + (177 \times 1) + (200 \times 0) = 178 + 220 + 249 + 177 = 824 \end{aligned}$$

$$\begin{aligned} A3 &= (178 \times 0) + (182 \times 1) + (151 \times 0) + (175 \times 1) + (249 \times 0) + (180 \times 1) + (177 \times 0) \\ &\quad + (200 \times 1) + (156 \times 0) = 182 + 175 + 180 + 200 = 737 \end{aligned}$$

$$A4 = (140 \times 0) + (220 \times 1) + (175 \times 0) + (244 \times 1) + (142 \times 0) + (177 \times 1) + (165 \times 0) \\ + (159 \times 1) + (184 \times 0) = 220 + 244 + 177 + 159 = 800$$

$$A5 = (220 \times 0) + (175 \times 1) + (249 \times 0) + (142 \times 1) + (177 \times 0) + (200 \times 1) + (159 \times 0) \\ + (184 \times 1) + (167 \times 0) = 175 + 142 + 200 + 184 = 701$$

$$A6 = (175 \times 0) + (249 \times 1) + (180 \times 0) + (177 \times 1) + (200 \times 0) + (156 \times 1) + (184 \times 0) \\ + (167 \times 1) + (175 \times 0) = 249 + 177 + 156 + 167 = 749$$

$$A7 = (244 \times 0) + (142 \times 1) + (177 \times 0) + (165 \times 1) + (159 \times 0) + (184 \times 1) + (207 \times 0) \\ + (197 \times 1) + (187 \times 0) = 142 + 165 + 184 + 197 = 688$$

$$A8 = (142 \times 0) + (177 \times 1) + (200 \times 0) + (159 \times 1) + (184 \times 0) + (167 \times 1) + (197 \times 0) \\ + (187 \times 1) + (214 \times 0) = 177 + 159 + 167 + 187 = 690$$

$$A9 = (177 \times 0) + (200 \times 1) + (156 \times 0) + (184 \times 1) + (167 \times 0) + (175 \times 1) + (187 \times 0) \\ + (214 \times 1) + (242 \times 0) = 200 + 184 + 175 + 214 = 773$$

Dari perhitungan diatas, didapatkan contoh hasil perhitungan matriks pada penelitian ini yang terjadi di lapisan konvolusi yaitu sebagai berikut:

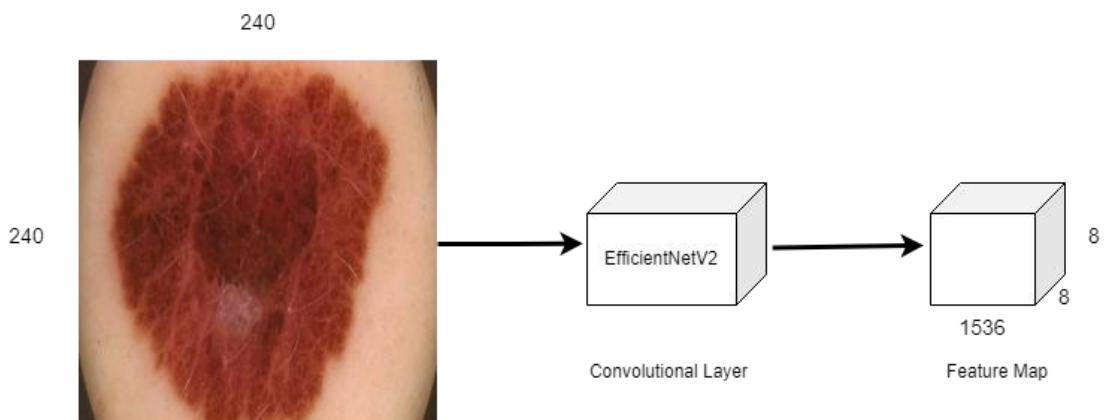
674	824	737
800	701	749
688	690	773

3.2.4.2 Feature Map

Feature map adalah hasil atau representasi dari input data yang telah melalui proses ekstraksi fitur dalam suatu model atau algoritma pembelajaran mesin. Dalam konteks pemrosesan citra, *feature map* umumnya diperoleh melalui konvolusi data input dengan filter atau kernel. Setiap filter menghasilkan *feature map* yang menyoroti bagian penting dari suatu gambar yang relevan dengan pola yang sedang diidentifikasi. Filter pada proses konvolusi memiliki bobot yang dapat dioptimalkan atau disesuaikan selama pelatihan model berlangsung. *Feature map* yang dihasilkan berukuran lebih kecil, namun memiliki kedalaman yang lebih besar. Tiap lapisan konvolusi bertugas untuk mengekstraksi dan meningkatkan

fitur-fitur penting dari suatu gambar, seperti garis tepi, tekstur, dan pola visual lainnya.

EfficientNetV2 menerapkan pendekatan *compound scaling*, dimana metode ini menggabungkan *scaling factor* dari beberapa dimensi, yaitu *width*, *depth*, dan *resolution*, untuk mendapatkan hasil yang lebih optimal. EfficientNetV2 juga menggunakan metode baru untuk mengurangi *overfitting*, yaitu *regularization by pruning*. Metode tersebut menggunakan teknik pemangkasan untuk mengurangi jumlah parameter model secara dinamis selama pelatihan. Kedua pendekatan tersebut membantu menciptakan *feature map* yang efisien dan berkualitas tinggi. Dimensi awal gambar dalam *feature map* adalah $240 \times 240 \times 3$, kemudian berubah menjadi $8 \times 8 \times 1536$ pada model yang telah dilatih menggunakan EfficientNetV2. Gambar 3.15 merupakan visualisasi dari *feature map*.



Gambar 3.15 Feature Map

3.2.4.3 Global Average Pooling 2D (GAP)

Global Average Pooling 2D (GAP2D) adalah operasi *pooling* yang digunakan pada lapisan konvolusi dalam jaringan saraf tiruan. Tujuan utama dari metode ini yaitu untuk mengurangi dimensi spasial dari fitur yang dihasilkan oleh lapisan konvolusi dengan cara mengambil nilai rata-rata dari setiap saluran atau *channel* di seluruh area spasial. Pada model EfficientNetV2, *feature map* yang dihasilkan pada model tersebut memiliki dimensi yang cukup besar, yaitu $8 \times 8 \times 1536$. Metode GAP kemudian akan mentransformasi *feature map* tersebut menjadi representasi yang lebih sederhana yaitu $1 \times 1 \times 1536$.

Proses GAP melakukan perhitungan nilai rata-rata dari setiap *channel* pada *feature map* secara terpisah. Misalnya, untuk setiap *channel*, GAP akan menjumlahkan nilai piksel yang berada dalam *channel* tersebut, lalu membagi hasilnya dengan total jumlah piksel tersebut. Hasil akhir dari proses ini adalah nilai rata-rata dari masing-masing *channel*. Saluran atau *channel* merujuk kepada dimensi atau lapisan data dalam suatu gambar dan *feature map*. Sebagai contoh, pada gambar berwarna yang memiliki format RGB, setiap *channel* mewakili informasi intensitas warna yang berbeda. Oleh sebab itu, gambar RGB memiliki tiga *channel* yang berbeda. Dalam proses pengolahan gambar menggunakan CNN, tiap lapisan konvolusi menghasilkan beberapa *channel* yang merepresentasikan fitur-fitur yang berbeda dengan tingkatan yang semakin kompleks. Misalnya, pada lapisan awal konvolusi, fitur-fitur yang direpresentasikan seperti tepi atau garis, sementara itu pada lapisan selanjutnya, *channel* akan mewakili fitur yang lebih kompleks seperti bentuk objek dan tekstur.

Penerapan metode GAP membuat informasi atau fitur-fitur penting yang terkandung dalam *feature map* tetap dipertahankan, namun dalam representasi yang lebih sederhana. Hasilnya yaitu *feature map* dengan dimensi spasial yang berkurang menjadi 1×1 , yang dapat dianggap sebagai ringkasan global dari fitur-fitur lokal yang terdapat pada *feature map* sebelumnya. Berikut merupakan contoh *feature map* 5×5 yang akan dilakukan proses GAP:

$$\begin{bmatrix} 187 & 217 & 178 & 182 & 151 \\ 140 & 220 & 175 & 249 & 180 \\ 244 & 142 & 177 & 200 & 156 \\ 165 & 159 & 184 & 167 & 175 \\ 207 & 197 & 187 & 214 & 242 \end{bmatrix}$$

Untuk menerapkan proses GAP pada *feature map* tersebut dilakukanlah penjumlahan nilai terhadap seluruh elemen pada *channel* yang menerapkan metode ini. Berikut adalah contoh perhitungan dari proses GAP tersebut:

$$\text{Total} = 187 + 217 + 178 + 182 + 151 + 140 + 220 + 175 + 249 + 180 + 244 + 142 + 177 + 200 + 156 + 165 + 159 + 184 + 167 + 175 + 207 + 197 + 187 + 214 + 242 = 4695$$

$$\text{Rata-rata} = 4695 \div 25 = 187.8$$

Jadi, setelah menggunakan atau menerapkan *Global Average Pooling*, didapatkan nilai sebesar 187.8 yang akan mewakili nilai pada satu *channel*. Proses tersebut terus dilakukan sampai semua *channel* mendapatkan nilai yang dapat mewakili keseluruhan masing-masing *channel*. Hal ini membuat ukuran dimensi suatu *feature map* menjadi lebih kecil, sehingga proses komputasi berjalan lebih efisien.

Dengan mengambil rata-rata sebagai representasi fitur, informasi posisi piksel tidak lagi relevan, sehingga *feature map* menjadi lebih invariant terhadap transformasi spasial. Sementara itu berkurangnya jumlah parameter yang perlu dilatih meningkatkan kecepatan dan efisiensi dari proses komputasi, serta juga mengurangi kemungkinan model akan *overfitting*. Dalam konteks EfficientNetV2, metode GAP digunakan setelah *convolution layer* untuk menghasilkan *feature map* yang lebih ringkas sebelum dilanjutkan ke lapisan-lapisan berikutnya.

3.2.4.4 Fully Connected Layer

Fully connected layer, juga dikenal sebagai *Dense Layer*, merupakan jenis lapisan dalam sebuah jaringan saraf tiruan yang paling umum dan sering digunakan. Lapisan ini menghubungkan setiap *neuron* dalam lapisan tersebut ke setiap *neuron* di lapisan berikutnya, sehingga setiap *neuron* menerima input dari semua *neuron* dalam lapisan sebelumnya.

Dalam *fully connected layer*, setiap koneksi antar *neuron* memiliki bobot yang dapat dioptimalkan selama proses pelatihan model. Bobot ini digunakan untuk mengatur seberapa besar pengaruh input dari satu *neuron* terhadap output dari *neuron* yang terhubung dengannya. Misalnya, jika terdapat lapisan dengan jumlah *neuron* sebanyak n, maka setiap *neuron* dalam lapisan tersebut akan terhubung ke semua *neuron* dalam lapisan berikutnya. Jika lapisan selanjutnya memiliki sebanyak m *neuron*, maka jumlah total bobot yang harus diatur adalah n × m.

Proses pada lapisan ini dimulai dengan mengubah *feature map* hasil dari langkah sebelumnya menjadi vektor satu dimensi atau biasa disebut dengan proses

flattening. Setiap elemen dalam vektor ini adalah representasi dari fitur-fitur yang telah diekstraksi sebelumnya. Vektor ini kemudian diteruskan ke lapisan yang terdiri dari *neuron-neuron* yang sepenuhnya terhubung, dimana setiap *neuron* memiliki bobot dan bias yang unik. Setiap *neuron* mengambil fitur dari vektor input, kemudian melakukan perhitungan aktifasi menggunakan fungsi aktifasi *Rectified Linear Unit* (ReLU). Fungsi aktifasi ReLU ini diterapkan karena memiliki sifat non-linear yang memungkinkan aktifasi terjadi hanya jika nilai input positif, sementara jika nilai input negatif, maka nilai tersebut akan dijadikan nol. Dengan menghilangkan nilai negatif, dapat membantu mempercepat komputasi dan mengurangi kompleksitas model. Fungsi ReLU juga membantu menonaktifkan *neuron* yang tidak aktif dan memungkinkan hanya fitur penting dari gambar lesi kulit yang diaktifkan, sehingga kemampuan model dalam mengambil fitur yang relevan akhirnya meningkatkan akurasi klasifikasi.

Proses pada *fully connected layer* dilakukan secara berulang, dan output dari setiap *neuron* dihitung. Pada tahap terakhir, hasil perhitungan dari *neuron-neuron* ini dialirkan ke lapisan output, dan dilakukan perhitungan dengan menggunakan fungsi aktifasi yang sesuai pada penelitian ini, yaitu fungsi aktifasi *sigmoid* untuk tugas klasifikasi biner atau klasifikasi dua kelas. Fungsi aktifasi *sigmoid* ini digunakan pada lapisan output untuk memberikan probabilitas prediksi pada kelas yang sesuai, seperti melanoma atau non melanoma. *Sigmoid* merubah *output* ke dalam rentang 0 hingga 1, yang dapat diinterpretasikan sebagai probabilitas. Nilai yang mendekati 1 menunjukkan probabilitas yang tinggi untuk kelas melanoma, sementara itu untuk nilai yang mendekati 0 menunjukkan probabilitas yang mengarah ke kelas non melanoma. Hal ini membuat pengambilan keputusan lebih akurat karena menggunakan probabilitas, serta mempermudah penggunaan *threshold* dalam klasifikasi biner.

Pelatihan pada lapisan ini menggunakan algoritma *Adaptive Moment Estimation* (Adam) untuk mengoptimalkan nilai bobot dan bias pada semua *neuron* yang terhubung. Metode optimasi ini menggabungkan adaptasi gradient dan momentum yang membantu konvergensi menjadi lebih cepat dan efisien. Adaptasi gradient bertujuan untuk menyesuaikan *learning rate* secara dinamis

selama pelatihan model, dan momentum bertujuan untuk mengatasi masalah lambat konvergensi di daerah datar atau di sekitar minimum lokal. Sementara itu, konvergensi dalam konteks optimisasi ini merujuk pada proses di mana model menuju ke solusi atau keadaan yang stabil dan optimal, sehingga memungkinkan model untuk mempelajari pola kompleks antar fitur yang diekstraksi, dan menghasilkan *output* yang sesuai.

3.2.5 Learned Model

Proses pelatihan pada *fully connected layer* menghasilkan sebuah model yang telah belajar atau bisa disebut model yang memiliki bobot dan bias yang sudah optimal, dan dapat digunakan dalam aplikasi. *Learned model* berisi definisi grafik serta bobot hasil *data training* yang di dalamnya terdapat 2 klasifikasi citra lesi kulit yaitu melanoma dan non melanoma. Selanjutnya, *learned model* ini diintegrasikan dengan aplikasi web menggunakan *framework Flask*.

3.2.6 Flask

Integrasi model hasil pelatihan dengan aplikasi web menggunakan framework Flask melibatkan beberapa langkah. *Learned model* yang telah terbentuk, diubah menjadi format serialisasi seperti JSON agar dapat diproses oleh web atau Pickle agar lebih efisien, karena Pickle merupakan salah satu format biner khusus. Selanjutnya aplikasi web yang dibentuk memiliki rute khusus untuk memproses input dari pengguna dan menggunakan model untuk mengklasifikasi prediksi. Aplikasi web nantinya akan mengirim data ke model, dan hasil prediksi akan dikirim kembali ke pengguna melalui antarmuka web.

3.2.7 Training Data

Training data adalah proses dimana sistem mempelajari pola pada gambar atau citra yang menjadi *input* dan menghasilkan model dengan menggunakan algoritma CNN dengan arsitektur EfficientNetV2. Jumlah gambar pada data *training* lebih banyak jika dibandingkan dengan data *testing*. Hal ini dilakukan agar pemahaman model terhadap pola gambar masing-masing *label* lebih baik dan kompleks. Pada penelitian ini, data *training* memiliki persentase sebesar 70% dari total jumlah data

penelitian yaitu sebesar 1470 data. Pengolahan pada proses pelatihan dilakukan dengan 40 iterasi (*epoch*) dan nilai batch sebesar 20. Setelah proses *training* selesai, proses ini akan menghasilkan model yang akan digunakan pada proses *testing*. Berikut merupakan *pseudocode* yang menggambarkan proses *training* data.

```

IMPORT libraries

DEFINE train_data_augmentation as ImageDataGenerator with rescaling, rotation, shearing,
shifting, zoom, and flipping augmentation parameters

DEFINE valid_data_augmentation as ImageDataGenerator with rescaling augmentation
parameter

CREATE train_datagen by apply train_data_augmentation to training data directory

CREATE valid_datagen by apply valid_data_augmentation to validation data directory

DEFINE checkpointfilepath as the path to save checkpoints with the epoch placeholder

DEFINE checkpointcallback using ModelCheckpoint with checkpointfilepath, monitoring
validation loss, verbosity, and mode

DEFINE reduce_lr_callback using ReduceLROnPlateau with the validation loss monitoring,
factor, patience, verbosity, and mode

DEFINE early_stopping using EarlyStopping with validation loss monitoring, patience,
verbosity, and mode

LOAD pre-trained EfficientNetV2B3 model with ‘imagenet’ weights, then define input shape

PRINT number of layer in the base model

DEFINE number of layers to fine-tune

FREEZE the layers in the base model unless enhancements are specified

CREATE model by adding layers sequentially: base model, GAP2D, dense, dropout, dense

COMPILE model using Adam optimizer, binary cross-entropy loss, accuracy metric

PRINT model summary

SET number of epochs, train and valid steps per epoch

TRAIN model using fit method, specifying traing generator, validation data, and callbacks

```

3.2.8 *Testing Data*

Testing data merupakan proses dimana model yang sudah terbentuk pada proses pelatihan akan diuji. Proses ini memiliki tujuan yaitu untuk mengetahui apakah sistem dapat mengidentifikasi melanoma dengan input gambar lesi kulit hasil proses dermoskopi. Pada proses ini dapat dilihat seberapa baik pemahaman model dalam mengidentifikasi pola data yang diinput dengan cara melihat akurasi dari proses *pengujian*.

3.2.9 Evaluasi Model

Setelah melalui proses pengujian, selanjutnya melalui proses evaluasi untuk mengukur kinerja model dalam mengenali pola dari gambar. Dalam proses ini, peneliti menggunakan metrik evaluasi yaitu ukuran atau nilai yang digunakan untuk mengukur kinerja model yang telah dilatih dalam melakukan tugas identifikasi penyakit melanoma melalui citra dermoskopi lesi kulit dengan model EfficientNetV2-B3. Metrik evaluasi yang digunakan diantaranya adalah *recall*, *precision*, dan F1-score.

Recall adalah metrik yang mengukur seberapa baik model dapat mendeteksi dan mengidentifikasi seluruh contoh positif yang benar dalam suatu kumpulan data. Dalam penelitian ini, recall memberikan gambaran tentang sejauh mana kemampuan model dalam mendeteksi dan mengidentifikasi citra lesi kulit yang sesungguhnya merupakan tanda penyakit melanoma. Semakin tinggi nilai *recall*, semakin sedikit kasus positif yang tidak terdeteksi oleh model.

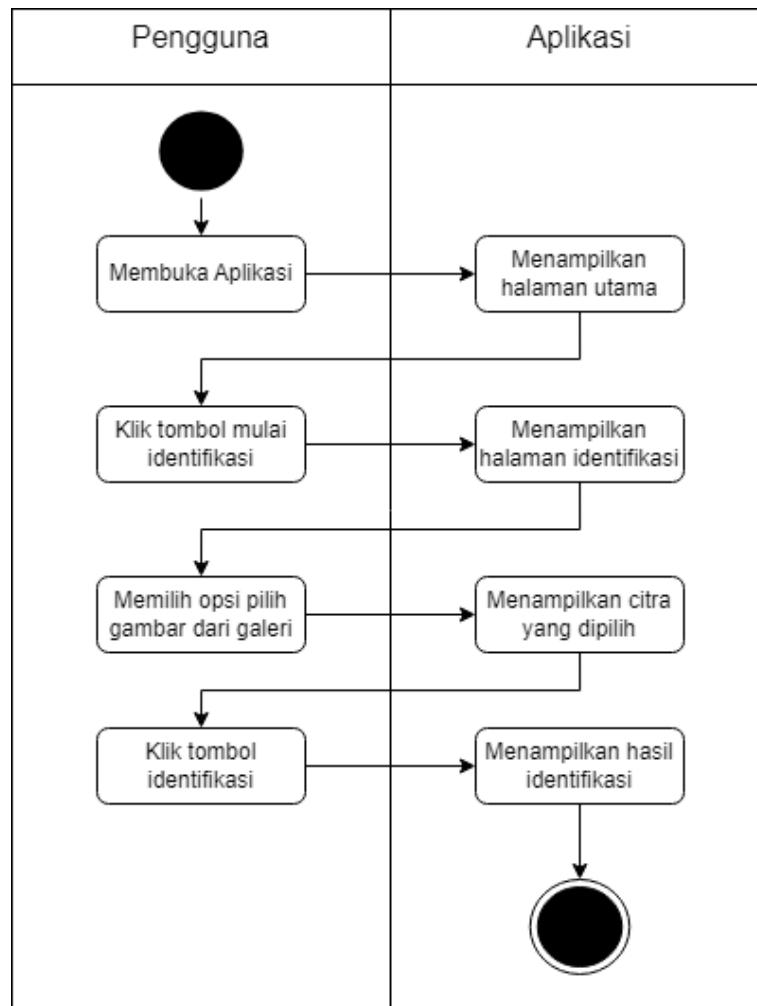
Precision merupakan parameter yang menilai sejauh mana model memberikan prediksi yang akurat untuk contoh-contoh positif. Dalam konteks ini, precision memberikan informasi tentang seberapa tepat model dalam mengidentifikasikan contoh gambar sebagai kasus penyakit melanoma. Tingginya nilai *precision* menandakan bahwa model cenderung memberikan prediksi positif dengan akurasi tinggi dan mengurangi kesalahan dalam mengklasifikasikan contoh negatif sebagai positif.

F1-score adalah metrik yang menggabungkan *recall* dan *precision* dengan menghitung rata-rata harmonik antara keduanya. Metrik ini memberikan gambaran menyeluruh tentang kinerja model dengan mempertimbangkan keseimbangan antara *recall* dan *precision*. F1-score sering digunakan sebagai metrik evaluasi yang efektif, terutama dalam situasi di mana kelas memiliki ketidakseimbangan, karena menghasilkan nilai yang seimbang antara kemampuan model untuk mendeteksi semua contoh positif dan untuk menghindari memberikan prediksi positif yang salah.

Dengan mempertimbangkan ketiga metrik ini, peneliti dapat mengevaluasi sejauh mana model efektif dalam mengenali contoh-contoh lesi kulit sebagai positif atau negatif untuk penyakit melanoma. Selain itu, penelitian ini memungkinkan penilaian seberapa baik model mampu menghindari kesalahan klasifikasi, baik dalam hal memberikan prediksi positif palsu maupun negatif palsu.

3.3 Perancangan Antarmuka Sistem

Dalam langkah ini, perhatian utama tertuju pada presentasi visual dari sistem aplikasi identifikasi melanoma melalui citra dermoskopi lesi kulit. Tujuan dari tahap ini adalah menyajikan gambaran aplikasi kepada pengguna dengan tujuan memudahkan mereka dalam memahami serta menggunakan aplikasi yang dibangun. Perancangan aplikasi ini berpedoman dengan diagram aktivitas yang sudah ditentukan. Diagram aktivitas aplikasi pada penelitian ini dapat dilihat pada Gambar 3.16.



Gambar 3.16 Diagram Aktivitas

3.3.1 Rancangan Tampilan Halaman Utama

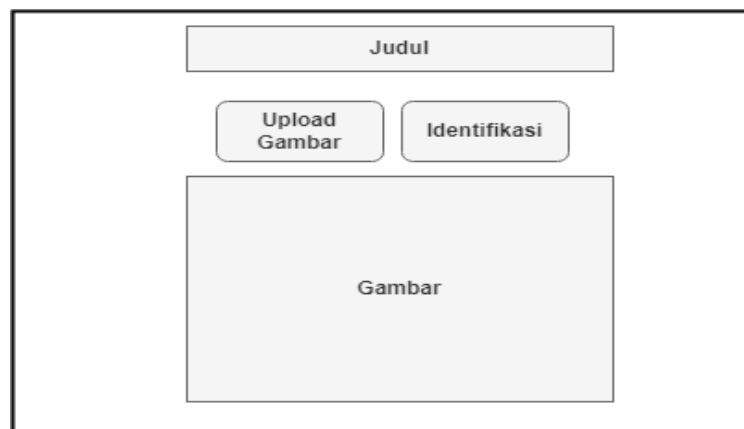
Pada halaman utama terdapat *header* yang menampilkan judul penelitian. Di bagian sebelah kanan atas terdapat *icon* menu yang jika dipilih akan menampilkan beberapa menu lainnya, seperti menu panduan aplikasi dan menu yang berisi informasi tentang melanoma. Kemudian, di bagian tengah terdapat tombol “Mulai Identifikasi” yang jika dipilih akan mengarahkan pengguna ke halaman identifikasi. Pada bagian *footer*, tepatnya di bawah tombol “Mulai Identifikasi”, terdapat keterangan peneliti berupa NIM dan nama, serta program studi dan universitas peneliti. Adapun, rancangan halaman utama terdapat pada Gambar 3.17.



Gambar 3.17 Rancangan Halaman Utama

3.3.2 Rancangan Tampilan Halaman Identifikasi

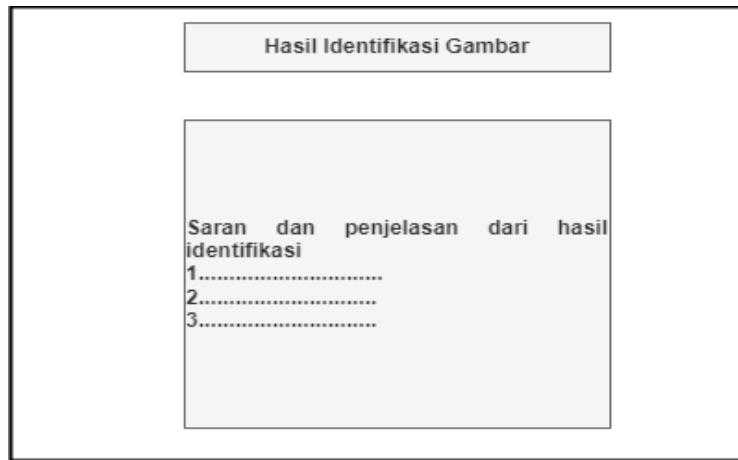
Halaman ini akan terbuka saat tombol “Mulai Identifikasi” dipilih pada halaman utama. Pada halaman ini, pengguna diharuskan memilih gambar dermoskopi lesi kulit dari galeri, untuk selanjutnya akan dilakukan proses identifikasi. Rancangan halaman ini terdapat pada Gambar 3.18.



Gambar 3.18 Rancangan Halaman Identifikasi

3.3.3 Rancangan Tampilan Halaman Hasil Identifikasi

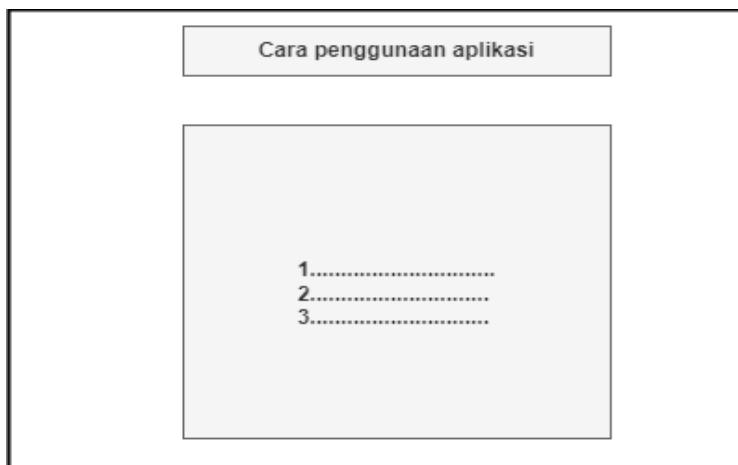
Setelah menekan tombol “Identifikasi”, maka halaman hasil identifikasi akan terbuka dan menampilkan hasil identifikasi dari gambar yang sebelumnya dijadikan *input* oleh pengguna. Rancangan halaman hasil identifikasi terdapat pada Gambar 3.19.



Gambar 3.19 Rancangan Halaman Hasil Identifikasi

3.3.4 Rancangan Tampilan Halaman Tutorial

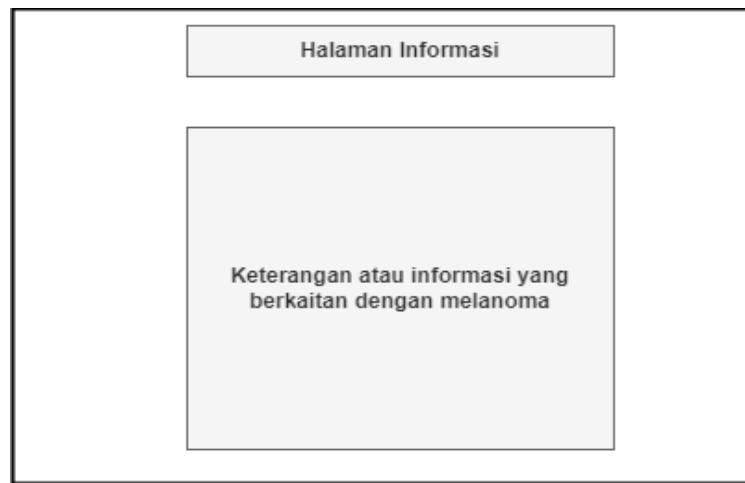
Halaman ini berisi pedoman penggunaan aplikasi yang ditulis ke dalam kalimat. Pada Gambar 3.20 dapat dilihat rancangan dari halaman pedoman aplikasi pada penelitian kali ini.



Gambar 3.20 Rancangan Halaman Tutorial Aplikasi

3.3.5 Rancangan Tampilan Halaman Informasi

Halaman ini berisi tentang informasi mengenai lesi kulit sampai dengan kanker kulit melanoma, serta memuat juga tentang ciri-ciri melanoma dan penanganannya. Gambaran dari halaman informasi dapat dilihat pada Gambar 3.21.



Gambar 3.21 Rancangan Halaman Informasi

BAB 4

IMPLEMENTASI DAN PENGUJIAN SISTEM

4.1 Data yang digunakan

Identifikasi citra dermoskopi lesi kulit dengan menerapkan arsitektur *EfficientNetV2* yang dibangun dan diimplementasikan ke dalam suatu sistem, memerlukan perangkat keras, perangkat lunak, serta sumber daya yang mendukung, yaitu:

4.1.1 Perangkat Keras dan Perangkat Lunak

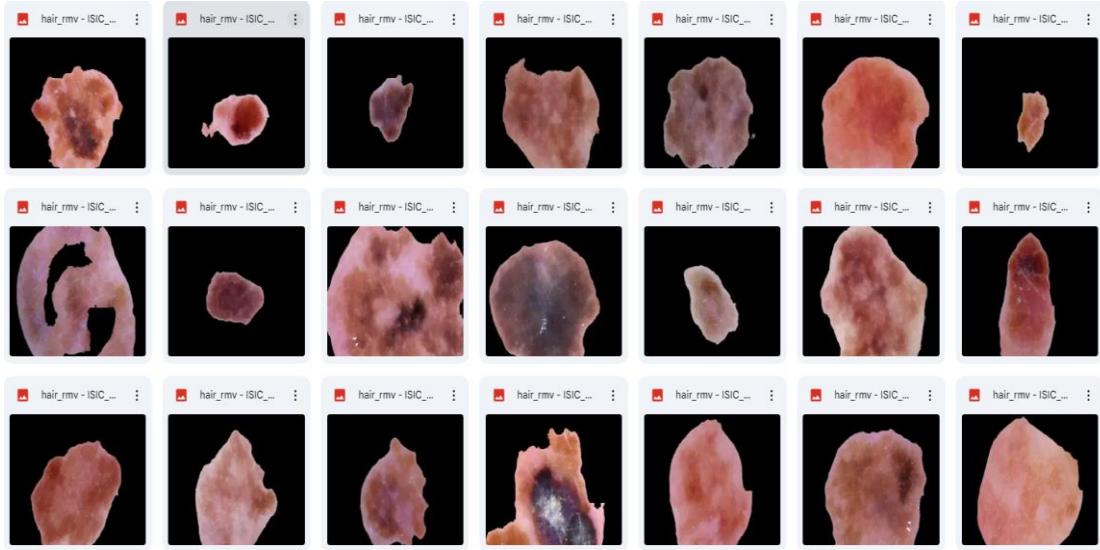
Perangkat keras dan perangkat lunak yang digunakan dalam membangun sistem aplikasi ini memiliki spesifikasi sebagai berikut:

1. Laptop *Asus Strix 15 GL503GE*
2. Processor *Intel Core™ i7 Gen 8th*
3. Storage SSD 1TB dan HDD 1TB
4. RAM 8GB
5. Sistem operasi *Windows 11 Home 64-bit*
6. *Google Colab Pro*
7. *Jupyter Notebook*
8. *Tensorflow*
9. *Flask*
10. *Sublime Text*

4.1.2 Implementasi Data

Penelitian ini menggunakan data citra yang terdiri dari citra lesi kulit melanoma dan *nevus* untuk kategori non melanoma yang diambil dari *Dataset ISIC 2020*. Pengambilan citra pada *dataset* ISIC melalui proses dermoskopi, yaitu

pengambilan citra menggunakan alat bernama dermoskop. Validasi diagnosis pada dataset tersebut dilakukan melalui proses bernama histopatologi. Jumlah data yang digunakan sebanyak 2100 data citra dengan pembagian 1050 data citra melanoma dan 1050 data citra non melanoma. Adapun beberapa contoh data pada masing-masing label, dapat dilihat pada gambar 4.1 dan 4.2.



Gambar 4.1 Data Citra Melanoma



Gambar 4.2 Data Citra Non Melanoma

4.1.3 Implementasi Desain Antarmuka Aplikasi (*Interface*)

Antarmuka aplikasi didasarkan pada perencanaan desain yang telah dilakukan pada bab sebelumnya. Pada setiap halaman terdapat beberapa elemen yang sama

diantaranya adalah, logo Universitas Sumatera Utara di bagian kiri atas aplikasi, tombol menu pada bagian kanan atas aplikasi, dan *footer* yang berisi tulisan "Tugas Akhir" serta biodata penulis yang mencakup nama, NIM, dan fakultas. Berikut merupakan implementasi dari desain aplikasi yang telah dirancang pada bab sebelumnya:

1. Tampilan Halaman Utama

Tampilan halaman utama merupakan tampilan awal ketika aplikasi diakses. Pada halaman ini terdapat judul penelitian dan tombol "Mulai Identifikasi" yang ketika diklik akan mengarahkan pengguna ke halaman identifikasi. Tampilan halaman utama dapat dilihat pada gambar 4.3.

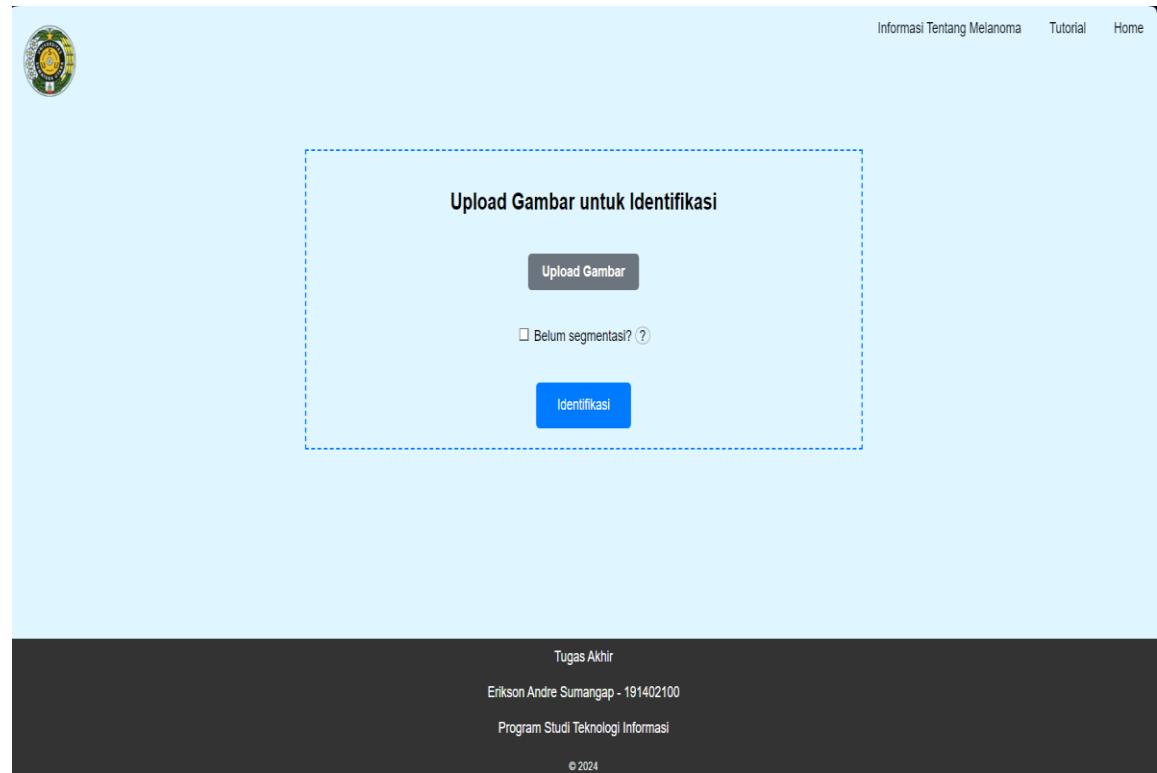


Gambar 4.3 Tampilan Halaman Utama

2. Tampilan Halaman Identifikasi

Pada halaman ini terdapat kotak yang berisi judul bertuliskan "Upload Gambar untuk Identifikasi", tombol "Upload Gambar" untuk mengunggah gambar lesi kulit yang ingin diidentifikasi, *checkbox* "Belum segmentasi?" yang ketika dicentang maka gambar yang belum disegmentasi akan disegmentasi secara

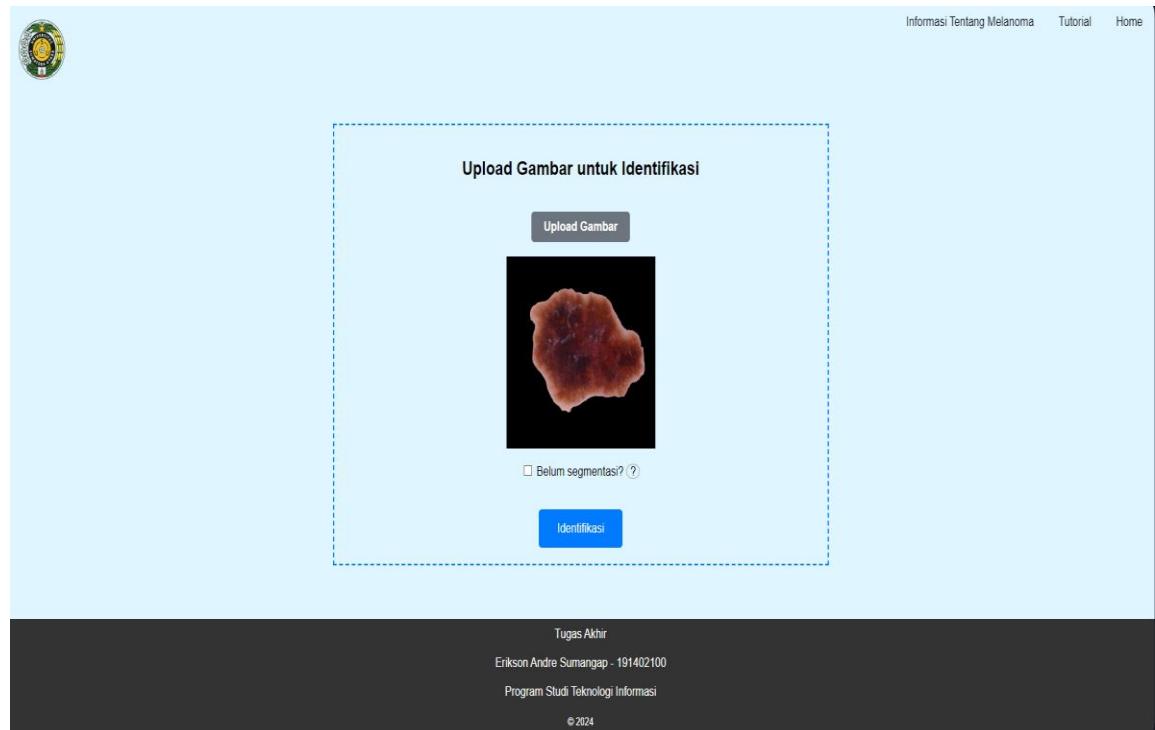
otomatis, serta tombol “Identifikasi” untuk mulai melakukan identifikasi terhadap gambar yang diunggah. Halaman identifikasi dapat dilihat pada gambar 4.4.



Gambar 4.4 Tampilan Halaman Identifikasi

3. Tampilan Halaman Identifikasi Setelah Memasukkan Citra

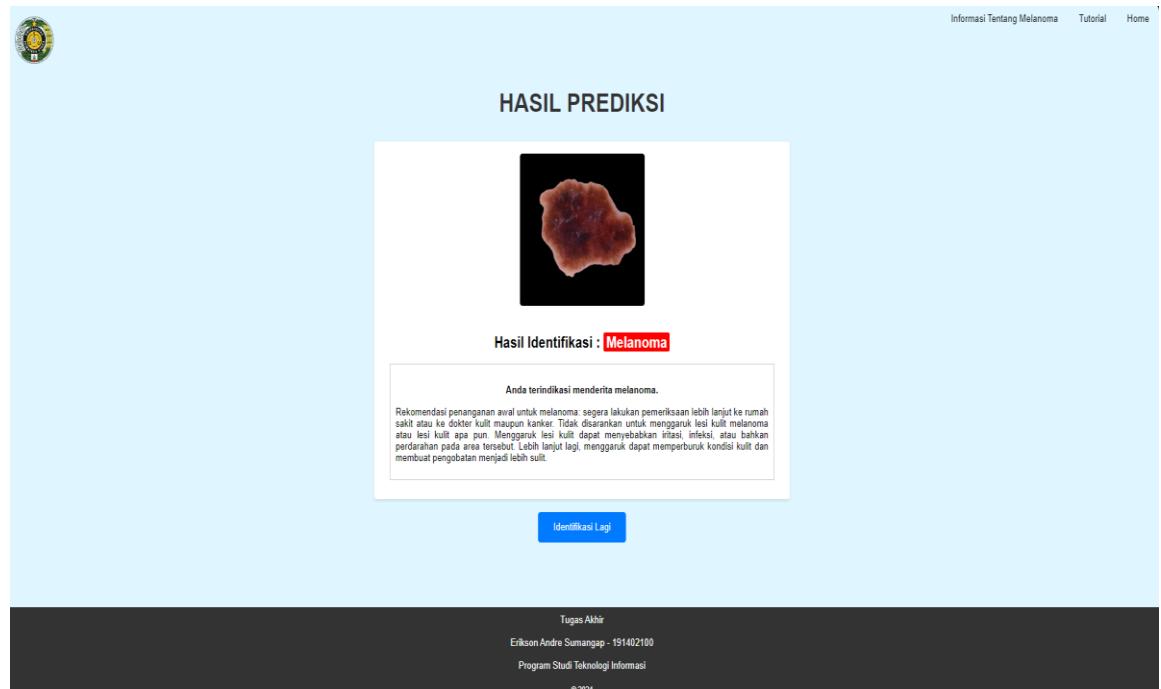
Halaman ini berisi citra lesi kulit yang sebelumnya telah diunggah oleh pengguna pada halaman identifikasi. Adapun tampilan halaman ini dapat dilihat pada gambar 4.5 berikut.



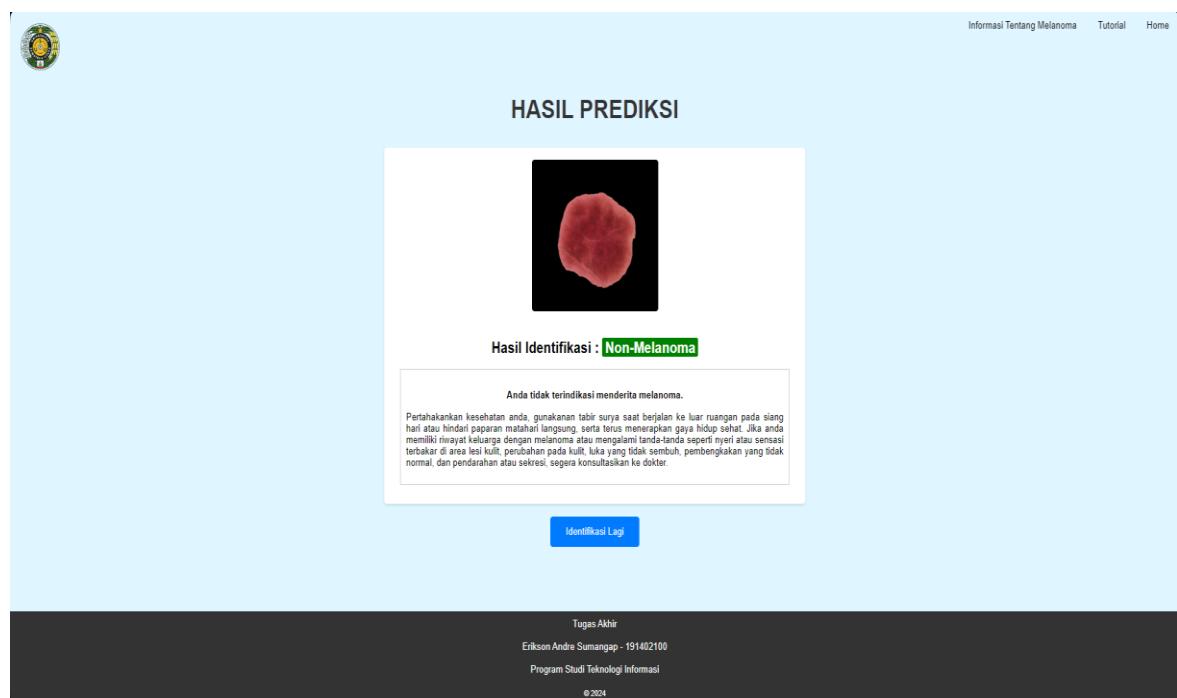
Gambar 4.5 Tampilan Halaman Yang Telah Diinput Citra

4. Tampilan Halaman Hasil Identifikasi

Pada halaman ini berisi hasil identifikasi dari lesi kulit tersebut, yaitu melanoma atau non melanoma. Tampilan halaman hasil dapat dilihat pada gambar 4.6 dan gambar 4.7.



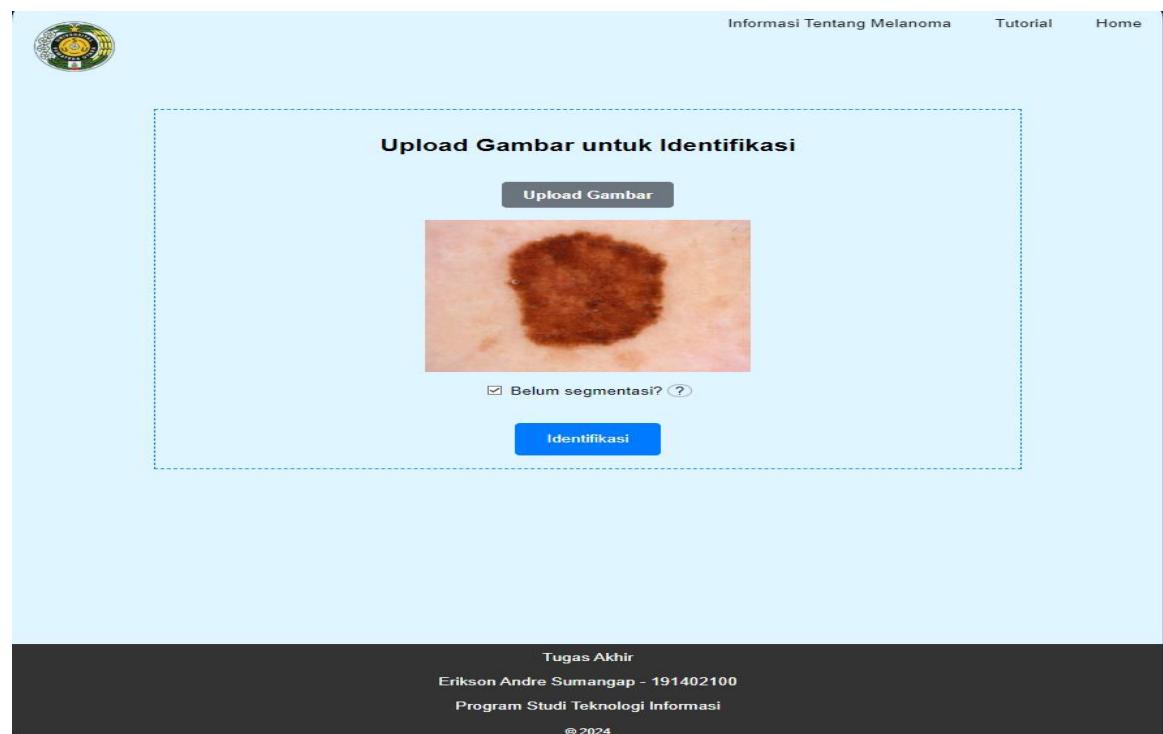
Gambar 4.6 Tampilan Hasil Identifikasi Melanoma



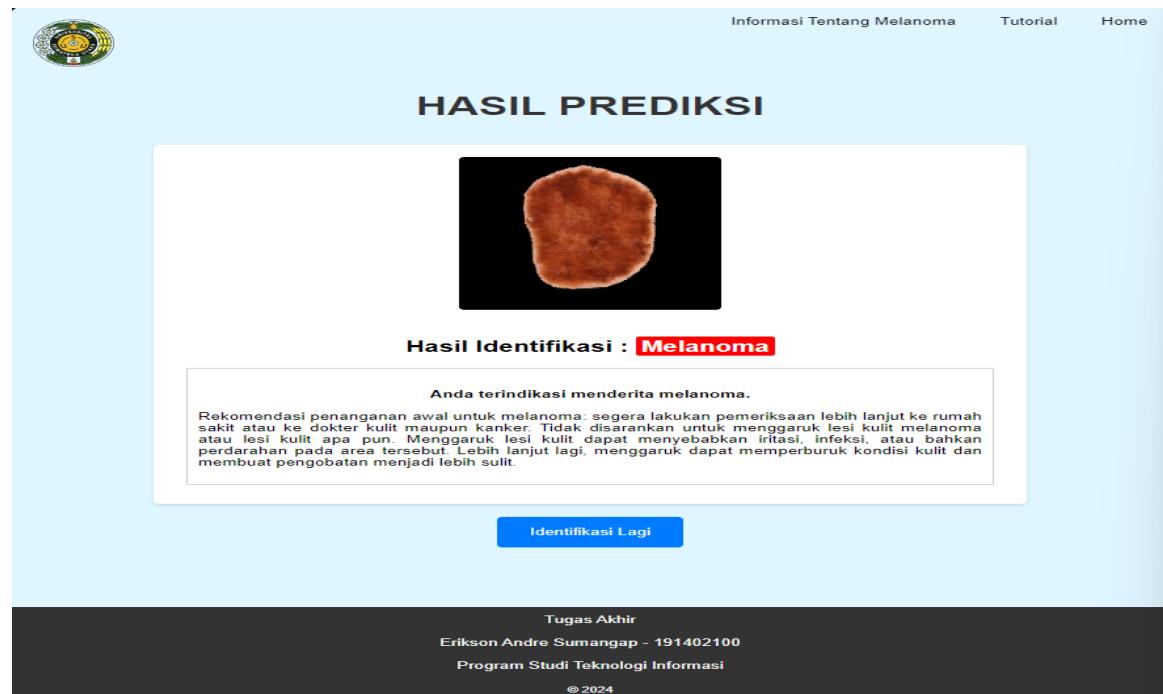
Gambar 4.7 Tampilan Hasil Identifikasi Non Melanoma

5. Tampilan Halaman Hasil Segmentasi

Pada halaman ini berisi hasil citra yang melalui proses segmentasi. Dapat dilihat pada gambar 4.8 bahwa citra sebelumnya belum tersegmentasi, lalu pada gambar 4.9 citra telah tersegmentasi secara otomatis oleh sistem.



Gambar 4.8 Citra Sebelum Segmentasi



Gambar 4.9 Citra Sesudah Segmentasi

6. Tampilan Halaman Informasi

Halaman informasi adalah halaman yang berisi informasi seputaran melanoma dan *nevus* atau tahi lalat yang dikategorikan sebagai non melanoma. Halaman ini dapat diakses dengan menekan menu “Informasi Tentang Melanoma”. Tampilan halaman informasi dapat dilihat pada gambar 4.10.

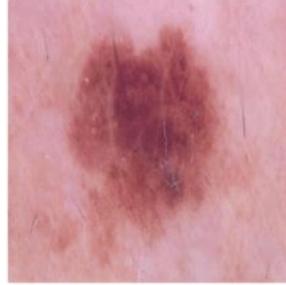


Informasi Tentang Melanoma Tutorial Home

INFORMASI MENGENAI MELANOMA

Melanoma adalah jenis kanker kulit yang berkembang dari melanosit, sel yang menghasilkan pigmen kulit (melanin), serta sering kali muncul sebagai bintik atau bintik hitam yang tidak biasa pada kulit. Melanoma menjadi kanker kulit paling mematikan karena kemampuannya untuk tumbuh dan menyebar dengan cepat ke bagian tubuh lainnya jika tidak dideteksi dan diobati secara dini.

Beberapa faktor yang meningkatkan resiko orang terkena melanoma yaitu paparan sinar ultraviolet, pemakaian alat solarium yang memancarkan sinar UV, faktor genetik, kulit yang sangat putih, orang yang memiliki kekebalan tubuh yang lemah, dan orang yang terkena paparan bahan kimia tertentu.

Malignant Melanoma 	Melanocytic nevi 
--	---

Orang sering keliru mengenali melanoma dan nevus karena keduaanya bisa memiliki penampilan yang mirip pada awalnya. Nevus, atau tahi lalat, adalah pertumbuhan kulit yang normal yang terdiri dari melanosit. Sebagian besar nevus tidak berbahaya dan biasanya memiliki warna coklat atau hitam yang seragam, serta batas yang terdefinisi dengan jelas. Namun, nevus yang berubah warna, ukuran, atau bentuknya bisa menjadi tanda melanoma.

Karena nevus dan melanoma bisa memiliki penampilan yang mirip, penting untuk memeriksa kulit secara teratur dan memperhatikan perubahan apa pun pada nevus atau munculnya lesi kulit baru. Jika Anda memiliki kekhawatiran tentang tahi lalat atau lesi kulit Anda, segera konsultasikan dengan dokter atau dokter kulit untuk evaluasi lebih lanjut. Deteksi dini melanoma dapat meningkatkan peluang kesembuhan.

Gambar 4.10 Tampilan Halaman Informasi

7. Tampilan Halaman Tutorial

Halaman tutorial merupakan halaman yang berisi mengenai pedoman atau tata cara penggunaan aplikasi. Halaman ini diakses dengan cara menekan tombol “Tutorial” yang terdapat pada bagian kanan atas aplikasi web. Tampilan halaman tutorial dapat dilihat pada gambar 4.11.



Gambar 4.11 Tampilan Halaman Tutorial

4.2 Prosedur Operasional

Sistem yang dikembangkan terdiri dari beberapa halaman diantaranya yaitu halaman utama, halaman identifikasi, halaman hasil identifikasi, halaman tutorial, dan halaman informasi tentang melanoma.

Saat pengguna pertama kali mengakses aplikasi, pengguna akan langsung diarahkan ke halaman utama. Pada halaman utama, pengguna dapat menekan tombol untuk masuk ke halaman identifikasi. Setelah diarahkan ke halaman identifikasi, pengguna dapat mengunggah citra lesi kulit yang ingin diidentifikasi, jika citra yang diunggah belum diterapkan metode segmentasi, pengguna dapat mencentang *checkbox* “Belum segmentasi?”, kemudian menekan tombol “Identifikasi” untuk melihat apakah lesi kulit tersebut merupakan melanoma atau non melanoma.

Pengguna dapat melihat informasi seputaran melanoma dan non melanoma pada halaman informasi. Untuk masuk ke halaman tersebut, pengguna dapat memilih

menu “Informasi Tentang Melanoma” yang terdapat pada bagian atas kanan aplikasi. Sementara itu, jika pengguna ingin melihat tata cara penggunaan aplikasi, pengguna dapat memilih menu “Tutorial” yang terdapat pada bagian atas kanan aplikasi.

4.3 Pelatihan Sistem

Proses pelatihan sistem menerapkan algoritma CNN dengan arsitektur *EfficientNetV2* dan data sebanyak 11340 citra lesi kulit yang telah diaugmentasi. Banyaknya data didapatkan dari 1890 citra lesi kulit yang merupakan 90% total data penelitian yang dilakukan 6 kali proses augmentasi. Sementara itu, data uji berjumlah 210 buah citra lesi kulit dan tidak diterapkan proses augmentasi, serta akan dijadikan data uji untuk menguji model yang telah terlatih. Pembagian data pelatihan sistem dapat dilihat pada tabel 4.1.

Tabel 4.1 Pembagian Data *Training*, Data *Validation*, Data *Testing* Setelah
Augmentasi

No	Data	Data Training	Data Validation	Data Testing	Jumlah
1.	Citra Melanoma	4410	1260	105	5775
2.	Citra Non-Melanoma	4410	1260	105	5775
Total Data		8820	2520	210	11550

Selama proses pelatihan model, dilakukan *hyperparameter tuning*, dimana pada proses ini terdapat modifikasi parameter-parameter seperti jumlah *epoch*, ukuran *batch*, dan *learning rate* atau tingkat pembelajaran, dengan tujuan agar model pelatihan dapat mencapai tingkat optimal yang diukur berdasarkan generalisasi atau akurasi validasi dan kerugiannya, dimana semakin tinggi akurasi dan semakin rendah kerugian validasi (*validation loss*) maka model akan cenderung semakin baik.

Percobaan pertama menggunakan 20 *epoch* dengan ukuran *batch* sebesar 10. Pada percobaan tersebut diperoleh *validation accuracy* sebesar 85.24% dan *validation loss* sebesar 24.02%. Selanjutnya, masih dengan jumlah *epoch* yang

sama namun dengan ukuran *batch* sebesar 20 didapatkan kenaikan *validation accuracy* menjadi 91.29% dan penurunan *validation loss* menjadi 20.38%. Sementara itu, dengan menggunakan *epoch* 20 dan ukuran *batch* sebesar 30, hasil yang diperoleh yaitu 85.71% untuk *validation accuracy* dan 24.47% untuk *validation loss*.

Percobaan dilanjutkan menggunakan *epoch* sebesar 40 serta ukuran *batch* sebesar 10, dimana percobaan tersebut menghasilkan *validation accuracy* sebesar 91.81% dan *validation loss* sebesar 17.61%. Percobaan kemudian dilanjutkan kembali menggunakan *batch size* sebesar 20 dan *epoch* sebesar 40, dimana percobaan ini menghasilkan *validation accuracy* sebesar 94.57% dan *validation loss* sebesar 13.93%. Percobaan terakhir menggunakan *epoch* sebesar 40 dan *batch size* sebesar 30 menghasilkan *validation accuracy* sebesar 92.15% dan *validation loss* sebesar 14.23%.

Tabel 4.2 Tabel Pelatihan

Epoch	Batch Size	Vall_Acc (%)	Val_Loss(%)
20	10	85.24	24.02
20	20	91.29	20.38
20	30	85.71	24.47
40	10	91.81	17.61
40	20	94.57	13.93
40	30	92.15	14.23

Mengacu pada eksperimen yang sudah dilakukan, didapatkan bahwa percobaan menggunakan 40 *epoch* dan *batch size* sebesar 20 memperoleh hasil yang paling optimal. Adanya keseimbangan antara *validation accuracy* dan *validation loss* menunjukkan bahwa model memiliki kemampuan yang baik dalam menggeneralisasi pola yang ada di dalam data pelatihan ke data yang belum pernah dilihat sebelumnya, yaitu data validasi. Ini berarti model tidak hanya belajar mengingat data pelatihan, namun juga mampu membuat prediksi yang akurat untuk data baru.

Penelitian ini menggunakan model hasil pelatihan sistem dengan ukuran *batch* sebesar 20 dan *epoch* sebanyak 40. Dimana setelah melakukan pelatihan dapat diambil kesimpulan bahwa *epoch* ke-39 memiliki nilai *val_accuracy* tertinggi yaitu sebesar 0.94571. Informasi setiap *epoch* dapat dilihat pada tabel 4.3.

Tabel 4.3 Tabel *Epoch*

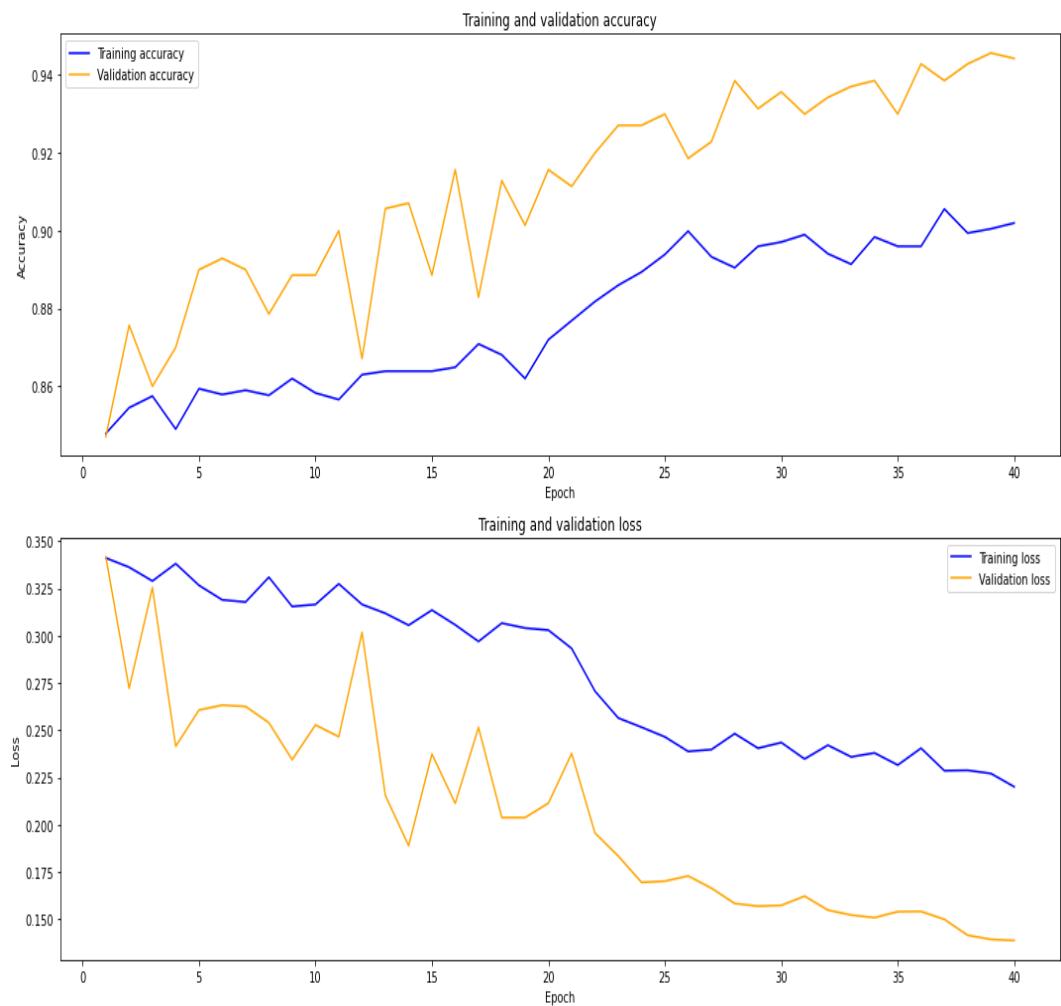
<i>Epoch</i>	<i>Loss</i>	<i>Accuracy</i>	<i>Val_loss</i>	<i>Val_accuracy</i>
1.	0.3412	0.8479	0.3417	0.8471
2.	0.3363	0.8545	0.2722	0.8757
3.	0.3290	0.8575	0.3255	0.8600
4.	0.3382	0.8490	0.2415	0.8700
5.	0.3267	0.8594	0.2607	0.8900
6.	0.3190	0.8579	0.2633	0.8929
7.	0.3179	0.8590	0.2626	0.8900
8.	0.3310	0.8577	0.2540	0.8786
9.	0.3155	0.8620	0.2344	0.8886
10.	0.3166	0.8583	0.2528	0.8886
11.	0.3275	0.8566	0.2466	0.9000
12.	0.3166	0.8630	0.3018	0.8671
13.	0.3119	0.8639	0.2155	0.9057
14.	0.3056	0.8639	0.1889	0.9071
15.	0.3136	0.8639	0.2374	0.8886
16.	0.3058	0.8649	0.2113	0.9157
17.	0.2970	0.8709	0.2515	0.8829
18.	0.3067	0.8681	0.2038	0.9129
19.	0.3041	0.8620	0.2038	0.9014
20.	0.3030	0.8720	0.2114	0.9157
21.	0.2933	0.8769	0.2377	0.9114
22.	0.2707	0.8818	0.1956	0.9200
23.	0.2565	0.8860	0.1834	0.9271
24.	0.2516	0.8894	0.1695	0.9271

25.	0.2465	0.8939	0.1701	0.9300
26.	0.2388	0.8999	0.1729	0.9186
27.	0.2398	0.8933	0.1664	0.9229
28.	0.2482	0.8905	0.1583	0.9386
29.	0.2405	0.8960	0.1569	0.9314
30.	0.2435	0.8971	0.1573	0.9357
31.	0.2348	0.8990	0.1622	0.9300
32.	0.2421	0.8941	0.1548	0.9343
33.	0.2359	0.8914	0.1522	0.9371
34.	0.2380	0.8984	0.1508	0.9386
35.	0.2316	0.8960	0.1540	0.9300
36.	0.2405	0.8960	0.1541	0.9429
37.	0.2286	0.9056	0.1499	0.9386
38.	0.2288	0.8994	0.1415	0.9429
39.	0.2271	0.9005	0.1393	0.9457
40.	0.2201	0.9020	0.1387	0.9443

Setelah melalui 40 *epoch*, didapatkan akurasi validasi tertinggi terdapat pada *epoch* ke 39 yaitu sebesar 94.57%, dengan *loss validation* sebesar 13.93%. Pelatihan model menerapkan *callback ReduceLROnPlateau*, yang bertujuan untuk memantau nilai *val_loss* (kerugian data validasi) apakah mengalami penurunan signifikan atau tidak. Jika tidak terjadi penurunan yang signifikan selama nilai kesabaran atau *patience* yang telah ditetapkan yaitu 3 *epoch*, maka *learning rate* akan disesuaikan menjadi lebih rendah, dengan tujuan untuk membantu model mencapai konvergensi yang lebih baik.

Dalam penelitian ini, terjadi penurunan *learning rate* dari 0.0010 menjadi 0.0001000000474974513 pada *epoch* ke 23. Hal ini disebabkan karena selama 3 *epoch* terakhir tidak terdapat penurunan *validation loss* yang signifikan. Proses tersebut terjadi secara otomatis oleh *callback ReduceLROnPlateau* berdasarkan nilai *val_loss* yang diawasi. Penurunan *learning rate* pada penelitian ini hanya terjadi satu kali selama 40 *epoch* pelatihan.

Metode menurunkan *learning rate* bertujuan untuk mengatur langkah pembelajaran model, sehingga model dapat mencoba untuk menemukan nilai yang optimal dengan mengurangi risiko melewatkkan bobot optimal karena langkah yang terlalu besar. Selain itu, metode ini juga memungkinkan model untuk lebih teliti menyesuaikan bobotnya untuk mencapai kinerja yang lebih baik. Adapun gambar grafik akurasi dan *loss* dapat dilihat pada gambar 4.12 berikut.



Gambar 4.12 Grafik *accuracy* dan *loss*

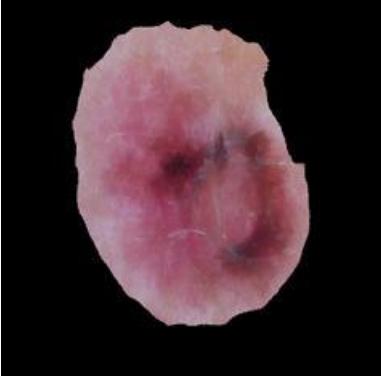
4.4 Pengujian Sistem

Sistem diuji menggunakan 10% data penelitian yakni sebanyak 210 citra lesi kulit yang tidak diaugmentasi. Sistem akan mengidentifikasi citra lesi kulit ke dalam 2 kategori yaitu melanoma dan non melanoma. Tabel 4.4 merupakan contoh hasil pengujian sistem.

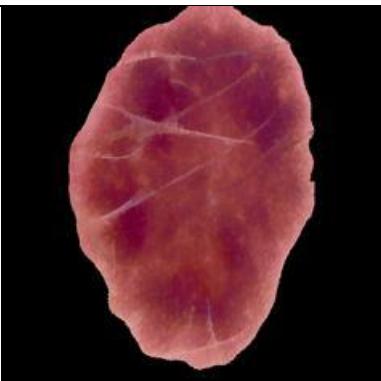
Tabel 4.4 Hasil Pengujian Identifikasi Melanoma

No.	Citra	Diagnosis	Sistem	Status
1.		Melanoma	Melanoma	Benar
2.		Melanoma	Melanoma	Benar
3.		Melanoma	Non-Melanoma	Salah
4.		Melanoma	Melanoma	Benar

5.		Melanoma	Melanoma	Benar
6.		Melanoma	Melanoma	Benar
7.		Melanoma	Melanoma	Benar
8.		Melanoma	Melanoma	Benar

9.		Melanoma	Melanoma	Benar
10.		Melanoma	Melanoma	Benar
11.		Non-Melanoma	Non-Melanoma	Benar
12.		Non-Melanoma	Non-Melanoma	Benar

13.		Non-Melanoma	Non-Melanoma	Benar
14.		Non-Melanoma	Non-Melanoma	Benar
15.		Non-Melanoma	Melanoma	Salah
16.		Non-Melanoma	Non-Melanoma	Benar

17.		Non-Melanoma	Non-Melanoma	Benar
18.		Non-Melanoma	Melanoma	Salah
19.		Non-Melanoma	Non-Melanoma	Benar
20.		Non-Melanoma	Non-Melanoma	Benar

Tabel di atas menampilkan sample pengujian aplikasi yang dilakukan menggunakan 10 data citra melanoma dan 10 data citra non melanoma yang mewakili keseluruhan data uji. Untuk pengujian secara lengkap terhadap 210 data, dapat dilihat pada lampiran penelitian ini. Pada pengujian aplikasi, terdapat 14 data yang salah diidentifikasi, yaitu 6 data pada kategori melanoma, dan 8 data pada kategori non melanoma. Berikut *confusion matrix* pada penelitian ini yang dapat dilihat pada tabel 4.5.

Tabel 4.5 Confusion Matrix

		Prediksi	
		Melanoma	Non Melanoma
Aktual	Melanoma	99	6
	Non Melanoma	8	97

Terlihat pada tabel 4.4 diatas bahwa terdapat 6 data melanoma dan 8 data non melanoma yang salah diidentifikasi. Berdasarkan data tersebut, bisa dihitung jumlah *true positive* (TP), *true negative* (TN), *false positive* (FP), dan *false negative* (FN) yang dapat dilihat pada tabel 4.6.

Tabel 4.6 Nilai TP, TN, FP, dan FN

	TP	TN	FP	FN
Melanoma	99	0	0	6
Non Melanoma	0	97	8	0

Berdasarkan hasil pengujian tersebut, kita memiliki 196 data yang diprediksi secara tepat. Dengan nilai-nilai yang terdapat pada tabel 4.6, kita dapat melakukan perhitungan nilai *Precision*, *Recall*, dan *F1-Score* untuk setiap kategori.

a. *Precision*

Perhitungan *precision* dapat dihitung menggunakan rumus yang terdapat pada persamaan 2.2.

$$\text{Precision Melanoma} = \frac{99}{107} \times 100 = 92.52\%$$

$$\text{Precision Non Melanoma} = \frac{97}{103} \times 100 = 94.17\%$$

b. *Recall*

Perhitungan *recall* dapat dihitung menggunakan rumus yang terdapat pada persamaan 2.3.

$$\text{Recall Melanoma} = \frac{99}{105} \times 100 = 94.28\%$$

$$\text{Recall Non Melanoma} = \frac{97}{105} \times 100 = 92.38\%$$

c. *F1-Score*

Perhitungan *F1-Score* dapat dihitung menggunakan rumus yang terdapat pada persamaan 2.4.

$$\text{F1-Score Melanoma} = 2 \times \frac{0.9252 \times 0.9428}{0.9252+0.9428} \times 100 = 93.39\%$$

$$\text{F1-Score Non Melanoma} = 2 \times \frac{0.9417 \times 0.9238}{0.9417+0.9238} \times 100 = 93.26\%$$

Perhitungan diatas dapat dibuat dalam bentuk tabel seperti pada tabel 4.7 berikut ini:

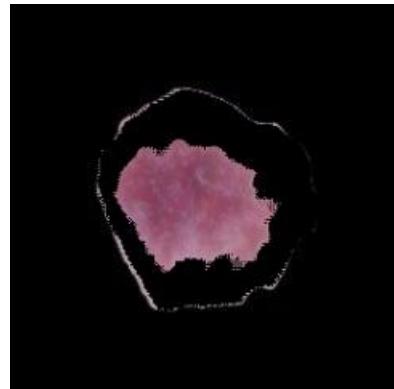
Tabel 4.7 Nilai *Precision*, *Recall*, dan *F1-Score*

	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>
Melanoma	92.52%	94.28%	93.39%
Non Melanoma	94.17%	92.38%	93.26%

Hasil pengujian mendapatkan 196 total identifikasi yang benar dari 210 data uji. Data uji tersebut terdiri dari 105 citra melanoma dan 105 citra non melanoma. Dari total identifikasi benar diatas, maka dapat dihitung nilai akurasi yang dapat dilihat pada persamaan 2.1.

$$\text{Akurasi} = \frac{99+97}{210} \times 100 = \frac{196}{210} \times 100 = 93.33\%$$

Perhitungan di atas menunjukkan tingkat akurasi pada penelitian menggunakan arsitektur *EfficientNetV2* yaitu mencapai 93.33%. Kesalahan identifikasi pada sistem dapat disebabkan oleh data segmentasi yang tidak sempurna atau ukuran lesi kulit yang telah tersegmentasi berukuran terlalu kecil, sehingga warna latar belakang mendominasi perhitungan pada *fully connected layer*. Untuk mengatasi proses segmentasi yang tidak sempurna, pelatihan model segmentasi harus dilatih menggunakan data yang lebih beragam, termasuk mencakup data yang memiliki perbedaan tipis pada warna kulit normal dan warna lesi kulit, sehingga ketika gambar yang ingin disegmentasi memiliki perbedaan warna yang tidak terlalu mencolok, model masih bisa untuk mensegmentasi dengan akurat. Selain itu penggunaan metode *hair removal* juga menyebabkan kualitas beberapa gambar yang diterapkannya berkurang karena metode ini menyebabkan perubahan yang tidak alami pada gambar, sehingga mempengaruhi pelatihan model. Sebagai pembuktian mengenai kesalahan identifikasi dapat dipengaruhi oleh proses segmentasi yang tidak sempurna, berikut peneliti melakukan proses segmentasi lebih lanjut pada gambar nomor 3 di tabel 4.4 yang hasilnya dapat dilihat pada gambar 4.13.



Gambar 4.13 Gambar Melanoma Setelah Segmentasi Lebih Lanjut

Setelah melalui proses segmentasi lebih lanjut, hasil yang didapatkan sesuai dengan kategori atau label aktual, yaitu melanoma. Hal tersebut dapat dilihat pada gambar 4.14 berikut.

[Informasi Tentang Melanoma](#) [Tutorial](#) [Home](#)

HASIL PREDIKSI

Hasil Identifikasi : Melanoma

Anda terindikasi menderita melanoma.

Rekomendasi penanganan awal untuk melanoma: segera lakukan pemeriksaan lebih lanjut ke rumah sakit atau ke dokter kulit maupun kanker. Tidak disarankan untuk menggaruk lesi kulit melanoma atau lesi kulit apa pun. Menggaruk lesi kulit dapat menyebabkan iritasi, infeksi, atau bahkan perdarahan pada area tersebut. Lebih lanjut lagi, menggaruk dapat memperburuk kondisi kulit dan membuat pengobatan menjadi lebih sulit.

[Identifikasi Lagi](#)

Gambar 4.14 Hasil Identifikasi Setelah Proses Segmentasi

Selain itu, untuk mengatasi ukuran lesi kulit yang terlalu kecil seperti pada gambar nomor 15 di tabel 4.3 yang menyebabkan latar belakang mendominasi perhitungan pada *fully connected layer*, peneliti melakukan proses untuk memfokuskan gambar pada lesi kulit dengan cara memindahkan posisi lesi kulit ke tengah dan kemudian melakukan *crop centered*, yaitu metode untuk memotong gambar dengan cara memastikan bahwa bagian tengah gambar menjadi fokus utama setelah pemotongan. Hasil dari proses tersebut dapat dilihat pada gambar 4.15.



Gambar 4.15 Gambar Non Melanoma Setelah *Crop Centered*

Hasil identifikasi lesi kulit yang didapat setelah proses diatas diterapkan pada gambar, menunjukkan hasil yang sesuai dengan kategori yang aktual. Hasil identifikasi dapat dilihat pada gambar 4.16.

 Informasi Tentang Melanoma Tutorial Home

HASIL PREDIKSI



Hasil Identifikasi : Non-Melanoma

Anda tidak terindikasi menderita melanoma.

Pertahankan kesehatan anda, gunakan tabir surya saat berjalan ke luar ruangan pada siang hari atau hindari paparan matahari langsung, serta terus menerapkan gaya hidup sehat. Jika anda memiliki riwayat keluarga dengan melanoma atau mengalami tanda-tanda seperti nyeri atau sensasi terbakar di area lesi kulit, perubahan pada kulit, luka yang tidak sembuh, pembengkakan yang tidak normal, dan pendarahan atau sekresi, segera konsultasikan ke dokter.

[Identifikasi Lagi](#)

Gambar 4.16 Hasil Identifikasi Setelah Proses *Crop Centered*

BAB 5

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Kesimpulan yang didapatkan dari penelitian ini, berdasarkan hasil dan pengujian sistem identifikasi melanoma melalui citra dermoskopi dengan arsitektur *EfficientNetV2* yang telah dilakukan adalah:

1. Pemanfaatan algoritma *Convolutional Neural Network* (CNN) dengan penerapan arsitektur *EfficientNetV2* mampu mengidentifikasi melanoma dan non melanoma yang direpresentasikan dengan data citra tahi lalat, mencapai nilai akurasi sebesar 93.33%.
2. Penerapan metode segmentasi pada *dataset* dapat meningkatkan hasil akurasi pada sistem.
3. Arsitektur *EfficientNetV2* yang digunakan dalam ekstraksi fitur terbukti memiliki kinerja yang optimal. Dengan pelatihan sebanyak 40 *epoch* dan ukuran *batch* sebesar 20, model mampu mencapai *validation accuracy* sebesar 94.57%.

5.2 Saran

Adapun terdapat beberapa saran yang dapat diterapkan untuk pengembangan penelitian selanjutnya, yaitu:

1. Penelitian selanjutnya diharapkan untuk menambah *dataset* untuk kategori non melanoma seperti keratosis, dermatofibroma, vascular, dan karsinoma.
2. Penelitian selanjutnya diharapkan menambahkan parameter lain seperti ketebalan lesi kulit.

3. Penelitian selanjutnya diharapkan membuat sistem untuk dapat mengklasifikasi tingkat stadium pada penyakit melanoma.
4. Penelitian selanjutnya diharapkan untuk menerapkan metode klasifikasi lain, untuk kemudian dibandingkan dengan hasil yang telah didapat pada penelitian ini.

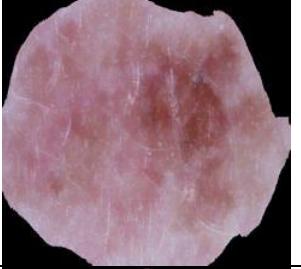
DAFTAR PUSTAKA

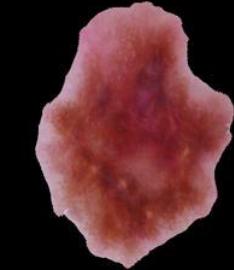
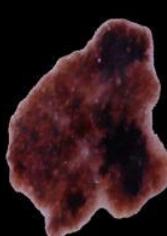
- Albattah, W., Javed, A., Nawaz, M., Masood, M., & Albahli, S. (2022). Artificial Intelligence-Based Drone System for Multiclass Plant Disease Detection Using an Improved Efficient Convolutional Neural Network. *Frontiers in Plant Science*, 13(June), 1–16. <https://doi.org/10.3389/fpls.2022.808380>
- Al-masni, M. A., Kim, D. H., & Kim, T. S. (2020). Multiple skin lesions diagnostics via integrated deep convolutional networks for segmentation and classification. *Computer Methods and Programs in Biomedicine*, 190, 105351. <https://doi.org/10.1016/j.cmpb.2020.105351>
- Alodokter. (2021, September 13). Kanker Kulit Melanoma. Diakses pada 7 September 2023, dari <https://www.alodokter.com/kanker-kulit-melanoma/gejala>
- Alom, M. Z., Taha, T. M., Yakopcic, C., Westberg, S., Sidike, P., Nasrin, M. S., Hasan, M., Van Essen, B. C., Awwal, A. A. S., & Asari, V. K. (2019). A state-of-the-art survey on deep learning theory and architectures. *Electronics (Switzerland)*, 8(3), 1–67. <https://doi.org/10.3390/electronics8030292>
- Anjani, I. A., Pratiwi, Y. R., & Norfa Bagas Nurhuda, S. (2021). Implementation of Deep Learning Using Convolutional Neural Network Algorithm for Classification Rose Flower. *Journal of Physics: Conference Series*, 1842(1). <https://doi.org/10.1088/1742-6596/1842/1/012002>
- Ariesta, N., Musa, Z., & Septadina, I. S. (2018). Karakteristik Histopatologi Melanoma Maligna di Bagian Patologi Anatomi RSUP Dr. Moh. Hoesin Palembang Tahun 2009-2013. *Biomedical Journal of Indonesia: Jurnal Biomedik Fakultas Kedokteran Universitas Sriwijaya*, 4(1), 26–31. <https://doi.org/10.32539/bji.v5i1.7955>
- Azzahra, J. A. (2023). *Identifikasi Kanker Kulit (Melanoma) Pada Citra Menggunakan Algoritma Machine Learning K-Nearest Neighbor (K-NN) Classifier*. 1–14. <https://www.ncbi.nlm.nih.gov/books/NBK558907/>
- Ciptaningrum, A. (2021). Segmentasi lesi kulit pada citra dermoskopi menggunakan CNN. In *Magister Teknik ITS*.

- E.P, I. W., Wijaya, A. Y., & Soelaiman, R. (2016). Klasifikasi Citra Menggunakan Convolutional Neural Network (Cnn) pada Caltech 101. JURNAL TEKNIK ITS, A65-A69.
- GOA Institute of Management. (2021, April 19). *Tech Behind Google's New CNN, EfficientNetV2*. (n.d.). Diakses pada 31 Desember 2023, dari <https://analyticsindiamag.com/tech-behind-googles-new-cnn-efficientnetv2/>
- Halodoc. (2019, Agustus 29). Kenali 4 Jenis Melanoma yang Dapat Terjadi. Diakses pada 31 Desember 2023, dari <https://www.halodoc.com/artikel/kenali-4-jenis-melanoma-yang-dapat-terjadi>
- Halodoc. (2019, Juli 9). Bercak pada Kulit Bisa Jadi Tanda Awal Melanoma. Diakses pada 31 Desember 2023, dari <https://www.halodoc.com/artikel/bercak-pada-kulit-bisa-jadi-tanda-awal-melanoma>
- Halodoc. (2021, November 29). Anatomi Lapisan Kulit dan Fungsinya Bagi Tubuh Manusia. Diakses pada 7 September 2023, dari <https://www.halodoc.com/artikel/anatomi-lapisan-kulit-dan-fungsinya-bagi-tubuh-manusia>
- Halodoc. (2022, Mei 31). Melanoma. Diakses pada 7 September 2023, dari <https://www.halodoc.com/kesehatan/melanoma>
- Hao, X., Zhang, G., & Ma, S. (2016). Deep Learning. *International Journal of Semantic Computing*, 10(3), 417–439. <https://doi.org/10.1142/S1793351X16500045>
- Hendaria, M. P., Maliawan, S., Pusat, U., Denpasar, S., & Skuamosa, K. S. (2013). Kanker kulit. *Kanker Kulit*, 1–17.
- Hijazi, S., Kumar, R., & Rowen, C. (2015). Using convolutional neural networks for image recognition. Cadence Design Systems Inc.: San Jose, CA, USA.
- Huang, M. L., & Liao, Y. C. (2022). Stacking Ensemble and ECA-EfficientNetV2 Convolutional Neural Networks on Classification of Multiple Chest Diseases Including COVID-19. *Academic Radiology*, 4, 1–21. <https://doi.org/10.1016/j.acra.2022.11.027>
- Kato, J., Horimoto, K., Sato, S., Minowa, T., & Uhara, H. (2019). Dermoscopy of Melanoma and Non-melanoma Skin Cancers. *Frontiers in Medicine*, 6(August), 1–7. <https://doi.org/10.3389/fmed.2019.00180>
- Koehoorn, J., Sobiecki, A., Rauber, P., Jalba, A., & Telea, A. (2016). Efficient and Effective Automated Digital Hair Removal from Dermoscopy Images. *Mathematical Morphology - Theory and Applications*, 1(1), 1–17. <https://doi.org/10.1515/mathm-2016-0001>

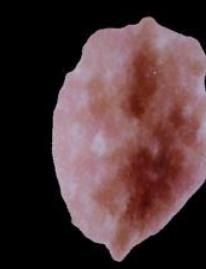
- KOUWENAAR, W. (2020). On cancer incidence in Indonesia. *Acta - Unio Internationalis Contra Cancrum*, 7(1 Spec. No.), 61–71.
- Mendes, D. B., & da Silva, N. C. (2018). *Skin Lesions Classification Using Convolutional Neural Networks in Clinical Images*. <http://arxiv.org/abs/1812.02316>
- Pardede, J., & Putra, D. A. L. (2020). Implementasi DenseNet Untuk Mengidentifikasi Kanker Kulit Melanoma. *Jurnal Teknik Informatika Dan Sistem Informasi*, 6(3), 10–27. <http://dx.doi.org/10.28932/jutisi.v6i3.2814>
- Population, I., Population, M., & Sum, P. (2021). International Agency for Research on Cancer. *WHO Chronicle*, 23(7), 323–326.
- Ronneberger, Navab, N., Hornegger, J., Wells, W. M., & Frangi, A. F. (2015). Medical Image Computing and Computer-Assisted Intervention - MICCAI 2015: 18th International Conference Munich, Germany, October 5-9, 2015 proceedings, part III. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 9351(Cvd), 12–20. <https://doi.org/10.1007/978-3-319-24574-4>
- Sidik, D. P., Utaminingrum, F., & Muflikhah, L. (2023). Penggunaan Variasi Model pada Arsitektur EfficientNetV2 untuk Prediksi Sel Kanker Serviks. *Teknologi Informasi Dan Ilmu ...*, 7(5), 2116–2121. <https://j-ptiik.ub.ac.id/index.php/j-ptiik/article/view/12656>
- Siloam Hospitals. (2023, Maret 29). Kanker Kulit Melanoma – Penyebab, Gejala, dan Pengobatannya. Diakses pada 7 September 2023, dari <https://www.siloamhospitals.com/informasi-siloam/artikel/apa-itu-melanoma>
- Soegeng, M. K., Liliana, L., & Noertjahyana, A. (2021). Penerapan Convolutional Neural Network untuk Klasifikasi Kanker Kulit Melanoma pada Dataset Gambar Kulit. *Jurnal Infra*, 9(1), 47–51. <https://publication.petra.ac.id/index.php/teknik-informatika/article/view/10945>
- Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *36th International Conference on Machine Learning, ICML 2019, 2019-June*, 10691–10700.
- Tan, M., & Le, Q. V. (2021). EfficientNetV2: Smaller Models and Faster Training. *Proceedings of Machine Learning Research*, 139, 10096–10106.
- Zunair, H., & Hamza, A. Ben. (2020). *Melanoma detection using adversarial training and deep transfer learning*. 22(1), 16–20. <https://doi.org/10.1088/1361-6560/ab86d3>

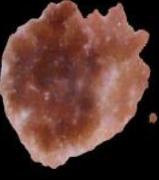
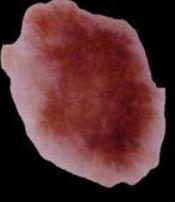
Lampiran 1. Tabel Hasil Pengujian Sistem

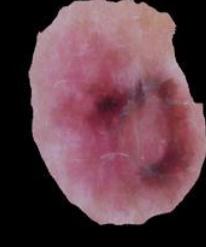
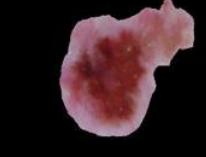
No.	Citra	Diagnosis	Sistem	Status
1		Melanoma	Melanoma	Benar
2		Melanoma	Melanoma	Benar
3		Melanoma	Melanoma	Benar
4		Melanoma	Melanoma	Benar
5		Melanoma	Melanoma	Benar

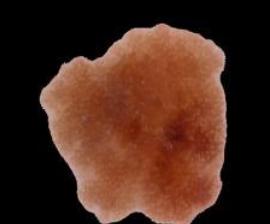
6		Melanoma	Melanoma	Benar
7		Melanoma	Melanoma	Benar
8		Melanoma	Melanoma	Benar
9		Melanoma	Non-Melanoma	Salah
10		Melanoma	Melanoma	Benar
11		Melanoma	Melanoma	Benar

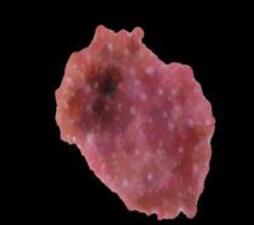
12		Melanoma	Melanoma	Benar
13		Melanoma	Melanoma	Benar
14		Melanoma	Melanoma	Benar
15		Melanoma	Melanoma	Benar
16		Melanoma	Melanoma	Benar
17		Melanoma	Melanoma	Benar

18		Melanoma	Melanoma	Benar
19		Melanoma	Melanoma	Benar
20		Melanoma	Melanoma	Benar
21		Melanoma	Melanoma	Benar
22		Melanoma	Melanoma	Benar
23		Melanoma	Melanoma	Benar

24		Melanoma	Melanoma	Benar
25		Melanoma	Melanoma	Benar
26		Melanoma	Melanoma	Benar
27		Melanoma	Melanoma	Benar
28		Melanoma	Melanoma	Benar
29		Melanoma	Melanoma	Benar

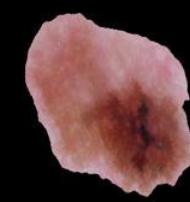
30		Melanoma	Melanoma	Benar
31		Melanoma	Melanoma	Benar
32		Melanoma	Melanoma	Benar
33		Melanoma	Melanoma	Benar
34		Melanoma	Melanoma	Benar
35		Melanoma	Melanoma	Benar

36		Melanoma	Melanoma	Benar
37		Melanoma	Melanoma	Benar
38		Melanoma	Non-Melanoma	Salah
39		Melanoma	Non-Melanoma	Salah
40		Melanoma	Non-Melanoma	Salah
41		Melanoma	Melanoma	Benar

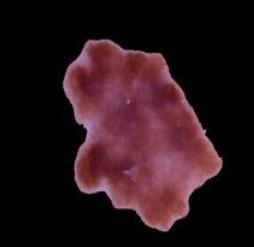
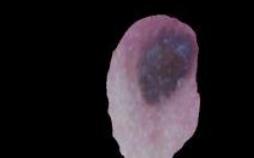
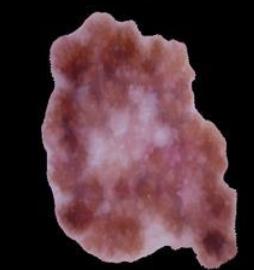
42		Melanoma	Melanoma	Benar
43		Melanoma	Melanoma	Benar
44		Melanoma	Melanoma	Benar
45		Melanoma	Melanoma	Benar
46		Melanoma	Melanoma	Benar
47		Melanoma	Melanoma	Benar

48		Melanoma	Melanoma	Benar
49		Melanoma	Melanoma	Benar
50		Melanoma	Melanoma	Benar
51		Melanoma	Melanoma	Benar
52		Melanoma	Melanoma	Benar
53		Melanoma	Melanoma	Benar

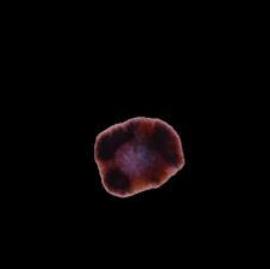
54		Melanoma	Non-Melanoma	Salah
55		Melanoma	Melanoma	Benar
56		Melanoma	Melanoma	Benar
57		Melanoma	Melanoma	Benar
58		Melanoma	Melanoma	Benar
59		Melanoma	Melanoma	Benar

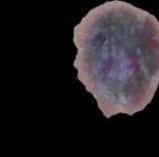
60		Melanoma	Melanoma	Benar
61		Melanoma	Melanoma	Benar
62		Melanoma	Melanoma	Benar
63		Melanoma	Melanoma	Benar
64		Melanoma	Melanoma	Benar
65		Melanoma	Melanoma	Benar

66		Melanoma	Melanoma	Benar
67		Melanoma	Melanoma	Benar
68		Melanoma	Melanoma	Benar
69		Melanoma	Melanoma	Benar
70		Melanoma	Melanoma	Benar
71		Melanoma	Melanoma	Benar

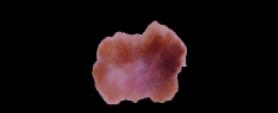
72		Melanoma	Melanoma	Benar
73		Melanoma	Melanoma	Benar
74		Melanoma	Melanoma	Benar
75		Melanoma	Melanoma	Benar
76		Melanoma	Melanoma	Benar
77		Melanoma	Melanoma	Benar

78		Melanoma	Melanoma	Benar
79		Melanoma	Melanoma	Benar
80		Melanoma	Melanoma	Benar
81		Melanoma	Melanoma	Benar
82		Melanoma	Melanoma	Benar
83		Melanoma	Melanoma	Benar

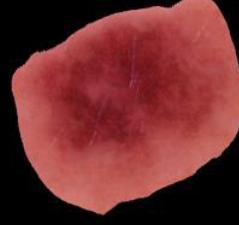
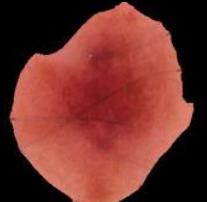
84		Melanoma	Melanoma	Benar
85		Melanoma	Melanoma	Benar
86		Melanoma	Melanoma	Benar
87		Melanoma	Melanoma	Benar
88		Melanoma	Melanoma	Benar
89		Melanoma	Melanoma	Benar

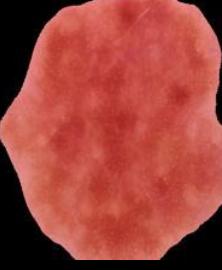
90		Melanoma	Melanoma	Benar
91		Melanoma	Melanoma	Benar
92		Melanoma	Melanoma	Benar
93		Melanoma	Melanoma	Benar
94		Melanoma	Non-Melanoma	Salah
95		Melanoma	Melanoma	Benar

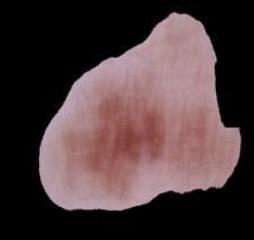
96		Melanoma	Melanoma	Benar
97		Melanoma	Melanoma	Benar
98		Melanoma	Melanoma	Benar
99		Melanoma	Melanoma	Benar
100		Melanoma	Melanoma	Benar
101		Melanoma	Melanoma	Benar

102		Melanoma	Melanoma	Benar
103		Melanoma	Melanoma	Benar
104		Melanoma	Melanoma	Benar
105		Melanoma	Melanoma	Benar
106		Non-Melanoma	Non-Melanoma	Benar
107		Non-Melanoma	Melanoma	Salah

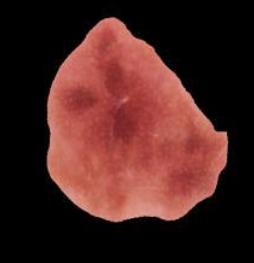
108		Non-Melanoma	Non-Melanoma	Benar
109		Non-Melanoma	Non-Melanoma	Benar
110		Non-Melanoma	Melanoma	Salah
111		Non-Melanoma	Non-Melanoma	Benar
112		Non-Melanoma	Non-Melanoma	Benar
113		Non-Melanoma	Non-Melanoma	Benar

114		Non-Melanoma	Non-Melanoma	Benar
115		Non-Melanoma	Non-Melanoma	Benar
116		Non-Melanoma	Non-Melanoma	Benar
117		Non-Melanoma	Non-Melanoma	Benar
118		Non-Melanoma	Non-Melanoma	Benar
119		Non-Melanoma	Non-Melanoma	Benar

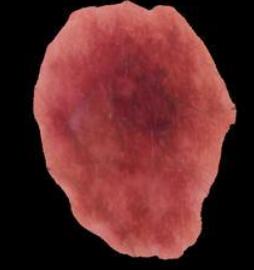
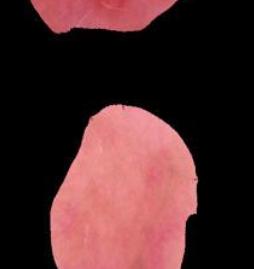
120		Non-Melanoma	Non-Melanoma	Benar
121		Non-Melanoma	Non-Melanoma	Benar
122		Non-Melanoma	Non-Melanoma	Benar
123		Non-Melanoma	Non-Melanoma	Benar
124		Non-Melanoma	Non-Melanoma	Benar
125		Non-Melanoma	Non-Melanoma	Benar

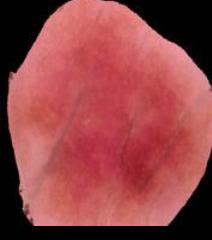
126		Non-Melanoma	Non-Melanoma	Benar
127		Non-Melanoma	Non-Melanoma	Benar
128		Non-Melanoma	Non-Melanoma	Benar
129		Non-Melanoma	Melanoma	Salah
130		Non-Melanoma	Melanoma	Salah
131		Non-Melanoma	Non-Melanoma	Benar

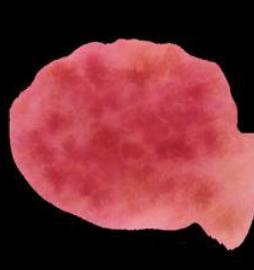
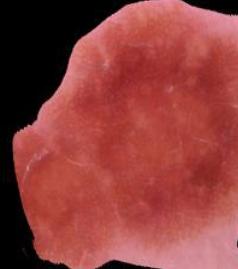
132		Non-Melanoma	Non-Melanoma	Benar
133		Non-Melanoma	Non-Melanoma	Benar
134		Non-Melanoma	Non-Melanoma	Benar
135		Non-Melanoma	Melanoma	Salah
136		Non-Melanoma	Non-Melanoma	Benar
137		Non-Melanoma	Non-Melanoma	Benar

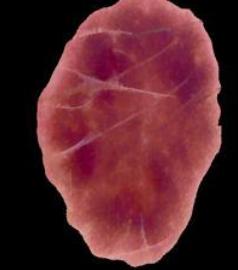
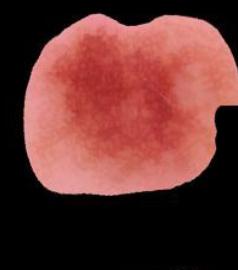
138		Non-Melanoma	Melanoma	Salah
139		Non-Melanoma	Non-Melanoma	Benar
140		Non-Melanoma	Non-Melanoma	Benar
141		Non-Melanoma	Non-Melanoma	Benar
142		Non-Melanoma	Non-Melanoma	Benar
143		Non-Melanoma	Non-Melanoma	Benar

144		Non-Melanoma	Non-Melanoma	Benar
145		Non-Melanoma	Non-Melanoma	Benar
146		Non-Melanoma	Non-Melanoma	Benar
147		Non-Melanoma	Melanoma	Salah
148		Non-Melanoma	Non-Melanoma	Benar
149		Non-Melanoma	Non-Melanoma	Benar

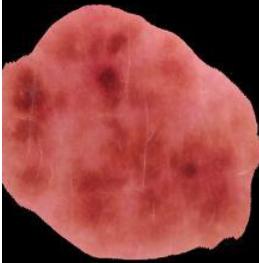
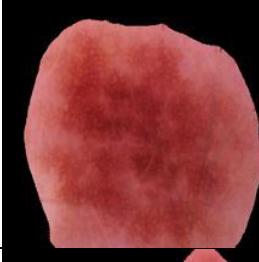
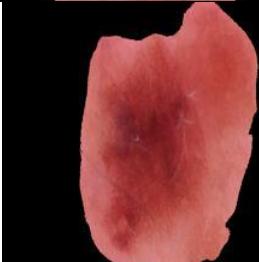
150		Non-Melanoma	Non-Melanoma	Benar
151		Non-Melanoma	Non-Melanoma	Benar
152		Non-Melanoma	Non-Melanoma	Benar
153		Non-Melanoma	Non-Melanoma	Benar
154		Non-Melanoma	Non-Melanoma	Benar
155		Non-Melanoma	Non-Melanoma	Benar

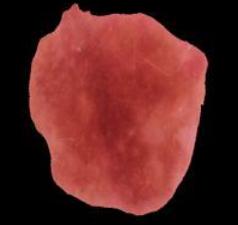
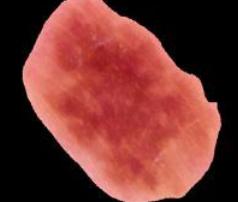
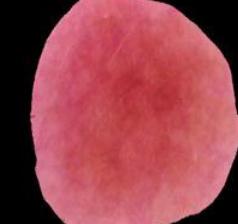
156		Non-Melanoma	Non-Melanoma	Benar
157		Non-Melanoma	Non-Melanoma	Benar
158		Non-Melanoma	Non-Melanoma	Benar
159		Non-Melanoma	Non-Melanoma	Benar
160		Non-Melanoma	Non-Melanoma	Benar
161		Non-Melanoma	Non-Melanoma	Benar

162		Non-Melanoma	Non-Melanoma	Benar
163		Non-Melanoma	Non-Melanoma	Benar
164		Non-Melanoma	Non-Melanoma	Benar
165		Non-Melanoma	Non-Melanoma	Benar
166		Non-Melanoma	Non-Melanoma	Benar
167		Non-Melanoma	Melanoma	Salah

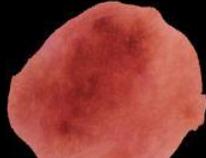
168		Non-Melanoma	Non-Melanoma	Benar
169		Non-Melanoma	Non-Melanoma	Benar
170		Non-Melanoma	Non-Melanoma	Benar
171		Non-Melanoma	Non-Melanoma	Benar
172		Non-Melanoma	Non-Melanoma	Benar
173		Non-Melanoma	Non-Melanoma	Benar

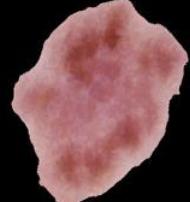
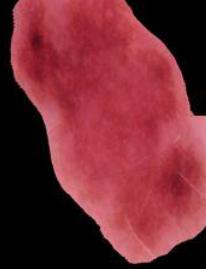
174		Non-Melanoma	Non-Melanoma	Benar
175		Non-Melanoma	Non-Melanoma	Benar
176		Non-Melanoma	Non-Melanoma	Benar
177		Non-Melanoma	Non-Melanoma	Benar
178		Non-Melanoma	Non-Melanoma	Benar
179		Non-Melanoma	Non-Melanoma	Benar

180		Non-Melanoma	Non-Melanoma	Benar
181		Non-Melanoma	Non-Melanoma	Benar
182		Non-Melanoma	Non-Melanoma	Benar
183		Non-Melanoma	Non-Melanoma	Benar
184		Non-Melanoma	Non-Melanoma	Benar
185		Non-Melanoma	Non-Melanoma	Benar

186		Non-Melanoma	Non-Melanoma	Benar
187		Non-Melanoma	Non-Melanoma	Benar
188		Non-Melanoma	Non-Melanoma	Benar
189		Non-Melanoma	Non-Melanoma	Benar
190		Non-Melanoma	Non-Melanoma	Benar
191		Non-Melanoma	Non-Melanoma	Benar

192		Non-Melanoma	Non-Melanoma	Benar
193		Non-Melanoma	Non-Melanoma	Benar
194		Non-Melanoma	Non-Melanoma	Benar
195		Non-Melanoma	Non-Melanoma	Benar
196		Non-Melanoma	Non-Melanoma	Benar
197		Non-Melanoma	Non-Melanoma	Benar

198		Non-Melanoma	Non-Melanoma	Benar
199		Non-Melanoma	Non-Melanoma	Benar
200		Non-Melanoma	Non-Melanoma	Benar
201		Non-Melanoma	Non-Melanoma	Benar
202		Non-Melanoma	Non-Melanoma	Benar
203		Non-Melanoma	Non-Melanoma	Benar

204		Non-Melanoma	Non-Melanoma	Benar
205		Non-Melanoma	Non-Melanoma	Benar
206		Non-Melanoma	Non-Melanoma	Benar
207		Non-Melanoma	Non-Melanoma	Benar
208		Non-Melanoma	Non-Melanoma	Benar
209		Non-Melanoma	Non-Melanoma	Benar

210		Non-Melanoma	Non-Melanoma	Benar
-----	---	--------------	--------------	-------



**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN,
RISET, DAN TEKNOLOGI**
UNIVERSITAS SUMATERA UTARA
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI

Jalan Universitas No. 9A Gedung A, Kampus USU Medan 20155, Telepon: (061) 821007
Laman: <http://Fasilkomti.usu.ac.id>

**KEPUTUSAN
DEKAN FAKULTAS ILMU KOMPUTER
DAN TEKNOLOGI INFORMASI
NOMOR : 1935/UN5.2.14.D/SK/SPB/2024**

**DEKAN FAKULTAS ILMU KOMPUTER
DAN TEKNOLOGI INFORMASI UNIVERSITAS SUMATERA UTARA**

- | | |
|--------------------|--|
| Membaca | : Surat Permohonan Mahasiswa Fasilkom-TI USU tanggal 13 Juni 2024 perihal permohonan ujian skripsi |
| | Nama : ERIKSON ANDRE SUMANGAP |
| | NIM : 191402100 |
| | Program Studi : Sarjana (S-1) Teknologi Informasi |
| | Judul Skripsi : Implementasi Efficientnetv2 Untuk Identifikasi Melanoma Melalui Citra Dermoskopii |
| Memperhatikan | : Bahwa Mahasiswa tersebut telah memenuhi kewajiban untuk ikut dalam pelaksanaan Meja Hijau Skripsi Mahasiswa pada Program Studi Sarjana (S-1) Teknologi Informasi Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Sumatera Utara TA 2023/2024. |
| Menimbang | : Bahwa permohonan tersebut diatas dapat disetujui dan perlu ditetapkan dengan surat keputusan |
| Mengingat | :
1. Undang-undang Nomor 20 Tahun 2003 tentang Sistem Pendidikan Nasional.
2. Peraturan Pemerintah Nomor 17 tahun 2010 tentang pengelolaan dan penyelenggara pendidikan.
3. Keputusan Rektor USU Nomor 03/UN5.1.R/SK/SPB/2021 tentang Peraturan Akademik Program Sarjana Universitas Sumatera Utara.
4. Surat Keputusan Rektor USU Nomor 1876/UN5.1.R/SK/SDM/2021 tentang pengangkatan Dekan Fasilkom-TI USU Periode 2021-2026 |
| MEMUTUSKAN | |
| Menetapkan Pertama | :
Membentuk dan mengangkat Tim Penguji Skripsi mahasiswa sebagai berikut: |
| | Ketua : Sarah Purnamawati ST., MSc.
NIP: 198302262010122003 |
| | Sekretaris : Annisa Fadillah Pukungan S.Kom, M.Kom
NIP: 199308092020012001 |
| | Anggota Penguji : Ivan Jaya S.Si, M.Kom.
NIP: 198407072015041001 |
| | Anggota Penguji : Rossy Nurhasanah S.Kom., M.Kom
NIP: 198707012019032016 |
| | Moderator : - |
| | Panitera : - |
| Kedua | : Segala biaya yang diperlukan untuk pelaksanaan kegiatan ini dibebankan pada Dana Penerimaan Bukan Pajak (PNPB) Fasilkom-TI USU Tahun 2024. |
| Ketiga | : Keputusan ini berlaku sejak tanggal ditetapkan dengan ketentuan bahwa segala sesuatunya akan diperbaiki sebagaimana mestinya apabila dikemudian hari terdapat kekeliruan dalam surat keputusan ini. |

Tembusan :

1. Ketua Program Studi Sarjana (S-1) Teknologi Informasi
2. Yang bersangkutan
3. Arsip

Medan, 14 Juni 2024

Ditandatangani secara elektronik oleh:
Dekan



Maya Silvi Lydia
NIP 197401272002122001