

**KLASIFIKASI KADAR KOLESTEROL TOTAL MELALUI  
CITRA IRIS MATA MENGGUNAKAN  
ALGORITMA ALEXNET**

**SKRIPSI**

**MUHAMMAD IQBAL MANALU**

**201402011**



**PROGRAM STUDI S1 TEKNOLOGI INFORMASI  
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI  
UNIVERSITAS SUMATERA UTARA  
MEDAN  
2024**

**KLASIFIKASI KADAR KOLESTEROL TOTAL MELALUI  
CITRA IRIS MATA MENGGUNAKAN  
ALGORITMA ALEXNET**

**SKRIPSI**

Diajukan untuk melengkapi tugas dan memenuhi syarat memperoleh ijazah  
Sarjana Teknologi Informasi

**MUHAMMAD IQBAL MANALU  
201402011**



**PROGRAM STUDI S1 TEKNOLOGI INFORMASI  
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI  
UNIVERSITAS SUMATERA UTARA  
MEDAN  
2024**

**PERSETUJUAN**

**Judul** : KLASIFIKASI KADAR KOLESTEROL TOTAL  
MELALUI CITRA IRIS MATA MENGGUNAKAN  
ALGORITMA ALEXNET

**Kategori** : SKRIPSI

**Nama** : MUHAMMAD IQBAL MANALU

**Nomor Induk Mahasiswa** : 201402011

**Program Studi** : SARJANA (S1) TEKNOLOGI INFORMASI

**Fakultas** : ILMU KOMPUTER DAN TEKNOLOGI INFORMASI  
UNIVERSITAS SUMATERA UTARA

Medan, 16 Oktober 2024

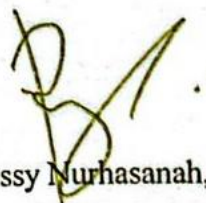
Komisi Pembimbing :

Pembimbing 2

Pembimbing 1



Ivan Jaya S.Si., M. Kom.  
NIP. 198407072015041001



Rossy Nurhasanah, S.Kom., M.Kom.  
NIP. 198707012019032016

Diketahui/disetujui oleh  
Program Studi S-1 Teknologi Informasi  
Ketua,



Dedy Arisandi, S.T., M.Kom.  
NIP. 197908312009121002

**PERNYATAAN****KLASIFIKASI KADAR KOLESTEROL TOTAL MELALUI  
CITRA IRIS MATA MENGGUNAKAN  
ALGORITMA ALEXNET****SKRIPSI**

Saya mengakui bahwa skripsi ini adalah hasil karya saya sendiri, kecuali beberapa kutipan dan ringkasan yang masing-masing telah disebutkan sumbernya.

Medan, 16 Oktober 2024



Muhammad Iqbal Manalu

201402011

## UCAPAN TERIMA KASIH

Puji dan syukur penulis sampaikan atas kehadiran Allah SWT, yang selalu memberi berkat dan rahmat sehingga penulis dapat menyelesaikan skripsi ini, yang merupakan salah satu syarat lulus dan mendapatkan gelar Sarjana Komputer, Pada Program Studi S1 Teknologi Informasi Universitas Sumatera Utara. Penulis mendapat banyak doa, dukungan, bimbingan, dan arahan dari berbagai orang secara langsung dan tidak langsung selama proses menyelesaikan tugas akhir ini. Oleh karena itu, penulis ingin mengucapkan terima kasih yang tulus kepada:

1. Kepada Alm. Ayah Hamrun Manalu, banyak hal yang saya alami tanpa kehadiran ayah selama dua tahun terakhir. Saya menghadapi tantangan yang kadang-kadang tidak sesuai dengan kenyataan. Rasa iri dan rindu membuat saya mengabaikan kenyataan. Tapi tidak mengurangi rasa bangga dan terima kasih atas kehidupan yang ayah berikan, terima kasih telah membawa saya ketempat ini meskipun pada akhirnya saya harus melewati perjalanan ini tanpa ayah lagi
2. Kepada umakku, pintu surgaku ibu Suharni rambe, beliau sangat berperan penting dalam menyelesaikan program studi penulis. beliau tidak sempat merasakan bangku perkuliahan, namu rasa kasih sayang dan doanya hingga penulis dapat menyelesaikan studinya.
3. Bapak Dr. Muryanto Amin, S.Sos., M.Si., selaku Rektor Universitas Sumatera Utara.
4. Ibu Dr. Maya Silvi Lydia, B.Sc., M.Sc., selaku Dekan Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Sumatera Utara.
5. Bapak Dedy Arisandi, S.T., M.Kom., selaku Ketua Program Studi S1 Teknologi Informasi Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Sumatera Utara
6. Ibu Rossy Nurhasanah, S.Kom., M.Kom., dan Bapak Ivan Jaya S.Si., M.Kom., selaku Dosen Pembimbing tugas akhir yang telah meluangkan waktu dan pikirannya untuk memberikan dukungan dan arahan kepada penulis.
7. Dosen penguji yang telah memberikan komentar dan masukan untuk menyempurnakan isi tugas akhir ini.

8. Bapak dan Ibu Dosen di lingkungan Program Studi S1 Teknologi Informasi, atas ilmu dan wawasan yang diberikan selama perkuliahan.
9. Seluruh staff Fakultas Ilmu Komputer dan Teknologi Informasi yang telah membantu segala urusan administrasi selama perkuliahan.
10. Terima kasih kepada sahabat capek pc, Ivan Tandella yang selalu membantu penulis semasa perkulihan sampai sekarang, Ullayya Zhafirah, Tsabitah Muflihza, Vanissya Arbashika Putri, Nayla Rahmi Nasution, Wahyu Sony Pratama, Muhammad Hatta Abdillah, yang selalu memberikan semangat dan hiburan, serta selalu menemani semasa perkuliahan
11. Teman- teman penulis, Ridha Arrahmi, Fildza Zata Amani, Mhd Afifan Aly Rahman Saragih, Teruna Tegar Matondang, M Zidane Rizky Lubis
12. Sahabat penulis, Ummy Warissa Pasaribu, Sulis Hafizah Pasaribu, Anwar Sadad Sibagariang, Jaihan Alkhair Pasaribu
13. Teman-teman Wacana grup, Hizkia winter Simaka Purba, Farhan Yehanda, Muhammad Ridwan Rizki, Reinhart Domingo Sahatmartua, Franda Christianto Siahaan, Raihan alifya lubis, yang selalu menemani penulis di kelas semasa perkuliahan
14. Teman-teman seperjuangan Teknologi Informasi Angkatan 2020 yang tidak dapat disebutkan satu persatu
15. Dan terakhir kepada diri saya sendiri Muhammad Iqbal Manalu, terima kasih sudah berjuang dan bertahan sampai sejauh ini, dan mampu mengatasi tekanan luar biasa dan tidak pernah memutuskan untuk menyerah pada kesulitan apapun dalam proses penyusunan skripsi ini dan menyelesaikannya dengan sempurna.

Medan, 16 Oktober 2024



Muhammad Iqbal Manalu

# **KLASIFIKASI KADAR KOLESTEROL TOTAL MELALUI CITRA IRIS MATA MENGGUNAKAN ALGORITMA ALEXNET**

## **ABSTRAK**

Badan Kesehatan Dunia (WHO) mencatat angka kematian yang disebabkan oleh penyakit kardiovaskular (termasuk penyakit jantung koroner, hipertensi, dan stroke) mencapai 7,9% di seluruh dunia pada tahun 2022. Salah satu penyebab terjadinya penyakit kardiovaskular adalah kadar kolesterol berlebih yang berada di dalam darah. Dilansir dari pernyataan Kementerian Kesehatan Direktorat Jenderal Pelayanan Kesehatan pada 2022, penderita kolesterol di Indonesia mencapai 28% dari total jumlah penduduk. sehingga diperlukan tindakan untuk mengetahui kadar kolesterol sedini mungkin agar dapat mencegah terserangnya penyakit kardiovaskular. Namun pemeriksaan kolesterol saat ini masih banyak dilakukan dengan pengambilan darah yang sehingga menyebabkan rasa nyeri tertusuk jarum dan keterbatasan alat, serta tidak semua memiliki alat dan tahu cara menggunakannya. Penelitian ini mengimplementasikan model AlexNet untuk mengembangkan metode non-invasive dalam mengklasifikasi kadar kolesterol total dengan cepat dan akurat berdasarkan cabang ilmu iridologi. Data yang digunakan merupakan data citra iris mata dari Telkom University Dataverse dan hasil pengumpulan mandiri di Puskesmas Barus. Model terbaik diperoleh dengan kombinasi hyperparameter antara lain epoch 50, batch size 16 dan learning rate 0,00001 dengan waktu pelatihan rata-rata 10 detik per epoch. Hasil pelatihan model diimplementasikan ke dalam aplikasi mobile dengan hasil akurasi mencapai 93% pada data uji. Sistem tersebut dapat dijadikan alat bantu atau dapat digunakan masyarakat luas sebagai metode pendeteksian dini yang mudah dan cepat.

Kata kunci: Kolesterol, Mata, Iridologi, CNN, AlexNet

**CLASSIFICATION OF TOTAL CHOLESTEROL LEVELS  
THROUGH IRIS IMAGES USING  
ALEXNET ALGORITHM**

**ABSTRACT**

*The World Health Organization (WHO) noted that the death rate caused by cardiovascular disease (including coronary heart disease, hypertension, and stroke) reached 7.9% worldwide in 2022. One of the causes of cardiovascular disease is excess cholesterol levels in the blood. Reported from the statement of the Ministry of Health, Directorate General of Health Services in 2022, cholesterol sufferers in Indonesia reached 28% of the total population. so that action is needed to find out cholesterol levels as early as possible in order to prevent cardiovascular disease. However, cholesterol checks are currently still widely carried out by taking blood which causes pain from needle pricks and limited equipment, and not everyone has the equipment and knows how to use it. This study implements the AlexNet model to develop a non-invasive method for classifying total cholesterol levels quickly and accurately based on the branch of iridology. The data used are iris image data from Telkom University Dataverse and the results of independent collection at the Barus Health Center. The best model was obtained with a combination of hyperparameters including epoch 50, batch size 16 and learning rate 0.00001 with an average training time of 10 seconds per epoch. The results of the model training were implemented into a mobile application with an accuracy of 93% on the test data. The system can be used as a tool or can be used by the wider community as an easy and fast early detection method.*

*Keywords: Cholesterol, Eyes, Iridology, CNN, AlexNet*



## DAFTAR ISI

<b>PERSETUJUAN</b>	<b>iii</b>
<b>PERNYATAAN</b>	<b>iv</b>
<b>UCAPAN TERIMA KASIH</b>	<b>v</b>
<b>ABSTRAK</b>	<b>vii</b>
<b><i>ABSTRACT</i></b>	<b>viii</b>
<b>DAFTAR ISI</b>	<b>ix</b>
<b>DAFTAR TABEL</b>	<b>xii</b>
<b>DAFTAR GAMBAR</b>	<b>xiii</b>
<b>BAB 1 PENDAHULUAN</b>	<b>1</b>
1.1. Latar Belakang	1
1.2. Rumusan Masalah	4
1.3. Tujuan Penelitian	4
1.4. Batasan Masalah	4
1.5. Manfaat Penelitian	4
1.6. Metodologi Penelitian	5
1.7. Sistematika Penulisan	5
<b>BAB 2 LANDASAN TEORI</b>	<b>7</b>
2.1. Iridologi	7
2.2. Kolesterol	7
2.3. Indikator Kolesterol Pada Iris Mata	8
2.4. Deep Learning	8
2.5. Convolutional Neural Network (CNN)	8
2.6. AlexNet	9
2.6.1. Feature extraction	9
2.6.2. Classification	10
2.6.3. Hyperparameter AlexNet	10
2.7. Metrik Evaluasi	11
2.7.1. Confusion Matrix	11
2.7.2. Precision	11

2.7.3. Recall	11
2.7.4. F1-Score	11
2.7.5. Accuracy	12
2.8. Penelitian Terdahulu	12
2.9. Perbedaan Penelitian	17
<b>BAB 3 ANALISIS DAN PERANCANGAN SISTEM</b>	<b>18</b>
3.1. Dataset	18
3.2. Analisis Sistem	18
3.3. Akusisi Data	19
3.4. Data Preprocessing	21
3.4.1. Labeling	21
3.4.2. Crop & resize	21
3.4.3. Normalisasi	23
3.4.4. Augmentasi	23
3.5. Pelatihan Model	24
3.5.1. Convolution layer	24
3.5.2. Pooling layer	25
3.5.3. Fully connected layer	26
3.6. Learned Model	26
3.7. Deployment	26
3.7.1. TF Lite model	26
3.7.2. Testing	26
3.8 Output	26
3.5. Perancangan Antarmuka Sistem	27
3.5.1. Rancangan halaman home	27
3.5.2. Rancangan halaman deteksi	28
3.5.3. Rancangan halaman informasi	28
3.5.4. Rancangan halaman tips	29
<b>BAB 4 IMPLEMENTASI DAN PENGUJIAN</b>	<b>31</b>
4.1. Implementasi Sistem	31
4.1.1. Perangkat keras	31
4.1.2. Perangkat lunak	31
4.2. Implementasi Data	32

4.3. Implementasi Model	33
4.4. Implementasi Antarmuka Aplikasi	38
4.4.1. Antarmuka halaman home	38
4.4.2. Antarmuka halaman deteksi	39
4.4.3. Antarmuka halaman informasi	40
4.4.4. Antarmuka halaman tips	41
4.5. Pengujian Sistem	42
<b>BAB 5 KESIMPULAN DAN SARAN</b>	<b>57</b>
5.1. Kesimpulan	57
5.2. Saran	57
<b>DAFTAR PUSTAKA</b>	<b>58</b>
<b>LAMPIRAN</b>	<b>62</b>

**DAFTAR TABEL**

<b>Tabel 2. 1</b> Penelitian Terdahulu	14
<b>Tabel 4. 1</b> Perbandingan Data Setiap Kelas	32
<b>Tabel 4. 2</b> Skenario Pelatihan Model	35
<b>Tabel 4. 3</b> Pengujian Sistem	43
<b>Tabel 4. 4</b> Confusion Matrix	54
<b>Tabel 4. 5</b> Nilai Precision, Recall, dan F1-score	55

## DAFTAR GAMBAR

<b>Gambar 2. 1</b> Bagian-bagian pada mata	8
<b>Gambar 2. 2</b> Arsitektur CNN	9
<b>Gambar 2. 3</b> Arsitektur AlexNet	9
<b>Gambar 3. 1</b> Citra mata (a) normal ( $< 200$ mg/dL), (b) beresiko kolesterol (200-239 mg/dL), (c) kolesterol tinggi ( $> 240$ mg/dl)	18
<b>Gambar 3. 2</b> Arsitektur Umum	19
<b>Gambar 3. 3</b> Contoh Citra Mata dari Telkom University Dataverse	20
<b>Gambar 3. 4</b> Dokumentasi Pengumpulan Data di Puskesmas Barus	20
<b>Gambar 3. 5</b> Contoh Citra Mata Hasil Pengumpulan Mandiri	21
<b>Gambar 3. 6</b> Proses resize (a) sebelum resize $785 \times 649$ piksel, (b) sesudah resize $224 \times 224$ piksel	23
<b>Gambar 3. 7</b> Proses augmentasi (a) asli, (b) flip, (c) rotate, (d) brightness	24
<b>Gambar 3. 8</b> Contoh Proses Perhitungan Filter $3 \times 3$ Lapisan Convolusi	25
<b>Gambar 3. 9</b> Contoh Proses Pergeseran Stride 1	25
<b>Gambar 3. 10</b> Rancangan Halaman Home	27
<b>Gambar 3. 11</b> Rancangan Halaman Deteksi	28
<b>Gambar 3. 12</b> Rancangan Halaman Informasi	29
<b>Gambar 3. 13</b> Rancangan Halaman Tips	30
<b>Gambar 4. 1</b> Citra Iris Mata Normal	32
<b>Gambar 4. 2</b> Citra Iris Mata Beresiko Kolesterol	33
<b>Gambar 4. 3</b> Citra Iris Mata Kolesterol Tinggi	33
<b>Gambar 4. 4</b> Visual Studio Code	34
<b>Gambar 4. 5</b> Grafik Akurasi	36
<b>Gambar 4. 6</b> Grafik Loss	37
<b>Gambar 4. 7</b> Antarmuka Halaman Home	39
<b>Gambar 4. 8</b> Antarmuka Halaman Deteksi	40
<b>Gambar 4. 9</b> Antarmuka Halaman Informasi	41
<b>Gambar 4. 10</b> Antarmuka Halaman Tips	42

## **BAB 1**

### **PENDAHULUAN**

#### **1.1. Latar Belakang**

Penyakit kardiovaskular merupakan salah satu penyakit sebagai penyebab angka kematian utama setiap tahunnya (Putri & Anita, 2020). Badan Kesehatan Dunia (WHO) mencatat angka kematian yang disebabkan oleh penyakit kardiovaskular (termasuk penyakit jantung koroner, hipertensi, dan stroke) mencapai 7,9% di seluruh dunia pada tahun 2022. Salah satu penyebab terjadinya penyakit kardiovaskular adalah kadar kolesterol berlebih yang berada di dalam darah (Siddik *et al.*, 2019).

Kolesterol adalah lemak dalam aliran darah yang diperlukan untuk produksi hormon dan sel baru (Elisabet *et al.*, 2020). Dalam kondisi di mana kadar kolesterol dalam darah lebih tinggi dari normal, dinding pembuluh darah dapat mengalami endapan yang membuat pembuluh darah lebih kecil dan tersumbat (Putri & Anita, 2020).

Pada manusia terdapat kolesterol total yang merupakan kadar gabungan antara jumlah kolesterol baik, kolesterol jahat, dan trigliserida dalam setiap desiliter darah. Kadar kolesterol total manusia normalnya di bawah 200 mg/dL, jika mencapai antara 200 dan 239 mg/dL maka dianggap ABA (Ambang Batas Atas), dan dianggap tinggi jika mencapai lebih dari 240 mg/dL (Susanti & Ikhwan, 2022). Dilansir dari pernyataan Kementerian Kesehatan Direktorat Jenderal Pelayanan Kesehatan pada 2022, penderita kolesterol di Indonesia mencapai 28% dari total jumlah penduduk. Untuk mencegah semakin tingginya presentase dari faktor tersebut maka diperlukan sebuah tindakan mengetahui kadar kolesterol sedini mungkin dan berkala dalam mencegah penyakit kardiovaskular (Waluya *et al.*, 2019).

Pada umumnya, proses pengecekan kadar kolesterol masih dilakukan dengan teknik mengambil sampel darah pasien. Pada proses tersebut terdapat kekurangan yaitu menyebabkan luka dan rasa nyeri pada bagian tubuh pasien yang tertusuk jarum (Nurhusni *et al.*, 2021). Seiring dengan perkembangan zaman, dalam bidang kesehatan terdapat salah satu cara alternatif untuk mendeteksi kolesterol total yaitu dengan mengamati pola yang terbentuk pada iris mata atau yang dikenal dengan iridologi. Untuk menghindari subjektivitas dalam melakukan diagnosa dengan teknik iridologi, dapat memanfaatkan pemrosesan citra pada iris mata menggunakan perangkat lunak untuk mendeteksi secara cepat, efisien, dan akurat (Saputra *et al.*, 2017). Citra iris mata dapat diperoleh melalui pemotretan, kemudian hasilnya diolah menggunakan teknik machine learning untuk menghasilkan polanya (Hasanah, 2022). Salah satu algoritma yang populer untuk klasifikasi citra saat ini adalah Convolutional Neural Network (CNN). CNN memiliki tahapan untuk melakukan ekstraksi pada citra secara otomatis (Naufal *et al.*, 2021).

Beberapa penelitian sebelumnya telah menunjukkan bahwa berbagai algoritma pembelajaran mesin dapat digunakan untuk mengklasifikasikan kadar kolesterol berdasarkan citra iris mata, dengan tingkat akurasi yang cukup baik. Bonowati *et al.* (2019) pernah menggunakan CNN untuk melakukan identifikasi kolesterol. Penelitian ini menggunakan model terlatih Inception V3 dengan hasil akurasi penelitian tersebut adalah sebesar 97,45%. Namun penelitian tersebut hanya menunjukkan apakah memiliki kolesterol normal atau tinggi.

Pada tahun 2019, Siddik *et al.* mengembangkan sistem yang dapat mengidentifikasi kadar kolesterol dalam gambar mata individu dengan menggunakan metode iridologi dan pemrosesan gambar. Histogram Gradients Oriented (HOG) dan Artificial Neural Network (ANN) digunakan untuk metode feature extraction dan klasifikasi. Dengan akurasi 93%, sistem ini dapat mendeteksi kadar kolesterol dalam tiga kategori yaitu normal, berisiko tinggi, dan kolesterol tinggi. Waktu komputasi adalah 0,0862 detik.

Pada tahun 2021, Hapsari *et al.* mengusulkan sistem untuk mengidentifikasi dua kelainan penyakit sekaligus dengan algoritma 3D-GLCM yang outputnya berupa identifikasi deteksi dini pada salah satu dari empat kemungkinan cluster yaitu DM (Diabetes Mellitus), HC (hypercholesterolemia), DM dan HC, atau normal. Dan telah dilakukan identifikasi dengan 3D-GLCM dengan membandingkan tingkat keabuan

16, 32, 64, dan 256. Hasil pengujian menunjukkan bahwa semakin banyak tingkat keabuan yang terdapat pada citra maka nilai sensitivitas dan akurasinya semakin tinggi. Penelitian ini terbatas pada jumlah dataset yang tersedia. Salah satu kelemahan dari citramata yang diambil adalah bahwa kelopak mata responden menutupi iris mata jika bentuk mata responden kecil atau sipit.

Salah satu model arsitektur CNN yang dapat digunakan untuk citra mata adalah AlexNet. Model tersebut pernah digunakan oleh Cahya *et al.* (2021) untuk klasifikasi penyakit mata yaitu katarak, glaukoma dan *retina disease*. Hasil penelitian klasifikasi penyakit mata yang menggunakan CNN adalah akurasi 98.37%.

Balashanmugam *et al.* (2022) juga pernah menggunakan Alexnet untuk pengenalan dan klasifikasi iris mata. Penelitian yang diusulkan mengklasifikasikan iris dengan akurasi 99,1% dengan skor F1 0,995. penelitian Amini & Ameri (2020) mengusulkan penggunaan arsitektur Alexnet untuk deteksi Arcus Senilis (AS) yang merupakan gejala kolesterol. Peneliti juga membandingkan dengan CNN dan VGG16. Hasilnya Alexnet unggul dengan akurasi 100%.

Alaslani & Elrefaei (2018) juga melakukan penelitian menggunakan AlexNet dan memadukan dengan SVM untuk mengenal citra iris mata, Peneliti melakukan uji coba pada beberapa dataset public, seperti dataset IITD, data CASIA-Iris-V1, CASIAIris-thousand, dan CASIA-Iris-V3 Interval. Hasil uji coba penelitian ini menghasilkan rata-rata akurasi yang sangat baik, yaitu diatas 95%.

Pada tahun 2020, Omran *et al.* juga menggunakan AlexNet untuk pengenalan citra iris mata. Tujuan penelitian tersebut adalah untuk membandingkan kemampuan tiga model deep learning, antara lain: AlexNet, VGG16, dan VGG19, dalam mengenali citra iris mata yang telah diberikan noise. Hasilnya menunjukkan AlexNet unggul dengan akurasi 100% dibandingkan VGG16 dan VGG19 yang masing-masing memperoleh akurasi 97,88% dan 97,5%.

Berdasarkan penelitian terdahulu yang telah dibahas di atas, maka penulis mengangkat penelitian dengan judul **KLASIFIKASI KADAR KOLESTEROL TOTAL MELALUI CITRA IRIS MATA DENGAN MENGGUNAKAN ALGORITMA ALEXNET.**



## **1.2. Rumusan Masalah**

Persentase penderita kolesterol di Indonesia cukuplah besar mencapai 28% dari jumlah penduduk sehingga diperlukan tindakan untuk mengetahui kadar kolesterol sedini mungkin agar dapat mencegah terserangnya penyakit kardiovaskular. Namun pemeriksaan kolesterol saat ini masih banyak dilakukan dengan pengambilan darah yang sehingga menyebabkan rasa nyeri tertusuk jarum dan keterbatasan alat, serta tidak semua memiliki alat dan tahu cara menggunakannya. Oleh karena itu, penelitian ini bertujuan untuk mengembangkan metode non-invasive (tanpa menembus kulit atau masuk secara fisik kedalam tubuh) dalam mengklasifikasi kadar kolesterol dengan cepat dan akurat.

## **1.3. Tujuan Penelitian**

Tujuan studi penelitian ini adalah untuk menerapkan model AlexNet dan menganalisis kinerjanya untuk klasifikasi kadar kolesterol total menggunakan citra iris mata.

## **1.4. Batasan Masalah**

Terdapat batasan dalam penelitian ini agar tidak menyimpang dari tujuan awalnya, antara lain:

- 1) Data yang dikumpulkan berupa citra iris mata.
- 2) Data yang digunakan untuk training berupa citra dengan ekstensi file jpg.
- 3) Kadar kolesterol yang diklasifikasikan merupakan kadar kolesterol total.
- 4) Luaran aplikasi berupa kadar kolesterol total dengan klasifikasi normal, beresiko kolesterol, kolesterol tinggi.

## **1.5. Manfaat Penelitian**

Beberapa manfaat yang diharapkan dari dilakukannya penelitian ini, yaitu

- 1) Mengetahui performa AlexNet dalam melakukan klasifikasi penyakit kolesterol total pada citra iris mata.
- 2) Menjadi sumber rujukan untuk perkembangan terkait sistem klasifikasi kadar kolesterol total pada citra mata dan implementasi AlexNet.
- 3) Hasil penelitian diharapkan dapat membantu tim kesehatan dan masyarakat dalam mengidentifikasi kadar kolesterol.

## **1.6. Metodologi Penelitian**

Proses penelitian yang akan dilakukan adalah sebagai berikut

### **1. Studi Literatur**

Pada tahap ini, penulis mencari dan mengumpulkan informasi tentang Alexnet, kadar kolesterol, dan iridologi.

### **2. Analisis Permasalahan**

Penulis melakukan analisis untuk memahami penggunaan AlexNet untuk klasifikasi kolestrol total pada gambar iris mata setelah mengumpulkan data.

### **3. Perancangan sistem**

Perancangan sistem akan dilakukan pada tahap berikutnya, meliputi perancangan arsitektur umum, pengumpulan data, pelatihan model, dan implementasi pada aplikasi mobile.

### **4. Implementasi Sistem**

Sebuah sistem yang sesuai dengan tujuan penelitian akan dibuat dengan menerapkan desain sistem yang telah dibuat.

### **5. Pengujian Sistem**

Tahap ini akan menguji sistem yang telah digunakan sebelumnya untuk memastikan bahwa sistem yang dirancang dapat digunakan dengan baik untuk klasifikasi kadar kolesterol total pada citra iris mata.

### **6. Penyusunan Laporan**

Pada tahap ini, peneliti membuat laporan dan mencatat proses penelitian untuk menunjukkan hasil temuan.

## **1.7. Sistematika Penulisan**

Terdapat lima bagian dalam penulisan skripsi, yaitu sebagai berikut.

### **BAB 1: PENDAHULUAN**

Bagian ini menjelaskan latar belakang penelitian, rumusan masalah, tujuan dilakukan penelitian, manfaat penelitian, batasan masalah, tahapan metodologi penelitian, dan sistematika penulisan.

**BAB 2: LANDASAN TEORI**

Teori-teori yang berkaitan dengan algoritma yang digunakan dalam penelitian ini dibahas dalam bagian ini meliputi iridologi, kolesterol, indikator kolesterol pada mata, CNN, dan AlexNet.

**BAB 3: ANALISIS DAN PERANCANGAN SISTEM**

Dalam bagian ini, arsitektur umum penelitian dijelaskan, termasuk pengumpulan, pembagian, preprocessing, pelatihan, pengujian, dan output, serta perancangan antarmuka sistem.

**BAB 4: IMPLEMENTASI DAN PENGUJIAN**

Bagian ini memuat proses implementasi dan pengujian perancangan sistem yang telah dijelaskan pada bab sebelumnya untuk menunjukkan apakah tujuan penelitian telah dicapai.

**BAB 5: KESIMPULAN DAN SARAN**

Bagian ini mencakup hasil dari penelitian yang telah dilakukan serta saran untuk cara meningkatkan penelitian di masa depan.

## **BAB 2**

### **LANDASAN TEORI**

#### **2.1. Iridologi**

Iridologi adalah suatu metode untuk memprediksi kondisi kesehatan manusia menggunakan diagnosa iris mata. Metode ini melihat tanda-tanda pada struktur iris mata sebagai representasi berbagai sistem dan organ dalam tubuh.

Iridologi adalah ilmu yang mempelajari iris mata karena etimologinya berasal dari kata "iri", yang berarti iris mata, dan "logos", yang berarti ilmu. Secara khusus, iridologi adalah suatu kaidah (cara) menganalisa penyakit melalui perubahan warna, rupa, bentuk, dan simbol-simbol yang terdapat pada iris mata. Iris mata manusia dapat menunjukkan sistem tubuh, kekuatan dan kelemahan, tahap kesehatan (level kesehatan), dan perkembangan (Anugrah, 2020).


#### **2.2. Kolesterol**

Kolesterol merupakan jenis lipid yang dapat ditemukan dalam plasma darah. Kandungan kolesterol darah dinyatakan normal jika berada pada 200-240 mg/dl (1dl = 100ml) serum darah.

*Low Density Lipoprotein* (LDL) juga dikenal sebagai Kolesterol jahat adalah kolesterol yang lengket, berdensitas rendah, dan berpotensi menggumpal di pembuluh darah. LDL memiliki kemampuan yang dapat mempersempit pembuluh darah dengan membentuk plak aterosklerosis sehingga dianggap sebagai kolesterol jahat.

*High Density Lipoprotein* (HDL) adalah kolesterol berdensitas tinggi yang tidak menggumpal yang memiliki kemampuan untuk membersihkan kolesterol jahat dalam darah sehingga dianggap sebagai kolesterol baik. LDL dan HDL dikatakan normal bila masing-masing ada dalam darah sebesar 40mg/dl (Fairudz & Nisa, 2015).

### 2.3. Indikator Kolesterol Pada Iris Mata



**Gambar 2. 1** Bagian-bagian pada mata

Terdapat ribuan saraf di seluruh tubuh melalui iris mata manusia. Kolesterol adalah lemak yang ada dalam darah dan mampu dilihat dengan cincin putih pada iris mata. Seperti pada Gambar 2.1. Cincin putih tebal menunjukkan bahwa kadar kolesterol seseorang lebih tinggi (Kumar *et al.*, 2016).


### 2.4. Deep Learning

Algoritma pembelajaran mendalam bertujuan untuk menemukan berbagai tingkat representasi terdistribusi, adalah bagian dari algoritma pembelajaran mesin. Banyak algoritma pembelajaran mendalam telah diusulkan baru-baru ini sebagai solusi untuk masalah kecerdasan buatan tradisional (Guo *et al.*, 2016).

### 2.5. Convolutional Neural Network (CNN)

Untuk memproses data dua dimensi, Convolutional Neural Network adalah pengembangan multi-layer perceptron (MLP). CNN adalah jenis *deep neural network* yang umum digunakan dalam gambar berjejaring tinggi dan banyak digunakan dalam penelitian citra. CNN terdiri dari lapisan input, lapisan keluaran dan lapisan tersembunyi.


Lapisan tersembunyi terdiri dari lapisan *convolutional* yang mengekstrak fitur dari gambar, lapisan *pooling* yang bertugas mengurangi ukuran fitur konvolusi, agar mengurangi jumlah sumber daya komputasi yang digunakan pada saat mengolah gambar, dan lapisan terhubung penuh yang mengubah data yang dapat dikategorikan secara linier (Alwanda *et al.*, 2020).



**Gambar 2. 2** Arsitektur CNN

## 2.6. AlexNet

AlexNet adalah arsitektur CNN yang dikembangkan oleh Alex Krizhevsky dengan memenangkan kompetisi ImageNet Large Scale Visual Recognition Challenge (ILSVRC) pada tahun 2012. Arsitektur AlexNet terdiri dari delapan lapisan, yang terdiri dari lima lapisan *convolution* untuk mengekstrak fitur dan tiga lapisan yang terhubung penuh (*fully-connected*) untuk proses klasifikasi (Zhang *et al.*, 2018). Arsitektur AlexNet dapat dilihat pada Gambar 2.4.



**Gambar 2. 3** Arsitektur AlexNet

### 2.6.1. Feature extraction

*Feature extraction* merupakan bagian pertama dari arsitektur ini, di mana mesin akan menghasilkan output model matrik yang lebih kecil. Bagian *feature extraction* terdiri dari kombinasi proses konvolusi, *batch processing*, dan *maxpooling*. Lapisan input pada AlexNet menerima gambar berukuran 224x224 piksel dengan 3 channel warna (RGB). Lapisan konvolusi pertama memiliki 96 filter dengan ukuran 11x11. Lapisan

ini menghasilkan keluaran berukuran  $55 \times 55 \times 96$ . Tujuan utama dari lapisan ini adalah mengekstrak fitur dasar dari gambar seperti tepi dan tekstur. Lapisan kedua menggunakan 256 filter dengan ukuran  $5 \times 5$  dan stride 1. Lapisan ini menghasilkan keluaran berukuran  $27 \times 27 \times 256$ . Lapisan ini membantu untuk mengekstraksi fitur yang lebih kompleks dari gambar. Lapisan ketiga, keempat, dan kelima menggunakan filter dengan ukuran  $3 \times 3$  dan stride 1. Masing-masing lapisan menghasilkan keluaran berukuran  $13 \times 13$  dengan jumlah filter berturut-turut 384 untuk lapisan ketiga dan keempat, dan 256 untuk lapisan kelima (Krizhevsky *et al.*, 2012).

Proses konvolusi ini menghasilkan matrik yang lebih kecil. Kemudian difilter menggunakan fungsi aktivasi ReLu (*Rectified linear unit*) yang mengubah nilai negatif menjadi nilai 0. Setelah lima lapisan konvolusi dilalui, lapisan *flatten* akan mengubah matrik menjadi vektor. Untuk membuat matrik lebih kecil, proses *dense*. *Output* dari proses *feature extraction* akan dimasukkan ke bagian kedua, yaitu proses klasifikasi.

#### 2.6.2. Classification

Bagian kedua dari arsitektur ini adalah proses klasifikasi menggunakan *fully-connected network*. Jaringan ini terdiri dari tiga layer yang terhubung sepenuhnya dengan jumlah neuron masing-masing 4096, 4096, dan 1000 (Krizhevsky *et al.*, 2012). Jaringan tersebut akan mengolah hasil dari proses ekstraksi fitur untuk memperoleh hasil klasifikasi dari input data yang diberikan.

#### 2.6.3. Hyperparameter AlexNet

Terdapat beberapa hyperparameter penting yang memiliki pengaruh signifikan terhadap performa model. Cepat atau lambat proses pembelajaran model terhadap data, ditentukan oleh learning rate. Penggunaan learning rate yang optimal sangat memengaruhi konvergensi model dan akurasi akhir. Ukuran batch menentukan berapa banyak sampel yang diproses sekaligus sebelum pembaruan bobot dilakukan. Jumlah epoch atau iterasi penuh di mana model melewati dataset memainkan peran penting dalam menentukan kapan model mencapai titik konvergensi. Untuk mencegah overfitting, augmentasi dan dropout diterapkan pada lapisan fully connected. AlexNet menggunakan dropout rate sebesar 0.5 yang efektif dalam meningkatkan generalisasi dengan menonaktifkan neuron secara acak selama pelatihan (Krizhevsky *et al.*, 2012).

## 2.7. Metrik Evaluasi

### 2.7.1. Confusion Matrix

Salah satu metode untuk mengevaluasi efektivitas model pembelajaran mesin adalah *Confusion Matrix*. Data kelas sebenarnya dan prediksi dimasukkan ke dalam matriks konfusi. Confusion matrix terdiri dari empat kombinasi: true positive, true negative, false positive, dan false negative (Prakosa *et al.*, 2023).

1. True positive (TP) adalah ketika data yang diprediksi oleh model positif dan sebenarnya positif.
2. False positive (FP) adalah ketika data yang diprediksi oleh model positif tetapi sebenarnya negatif.
3. True negative (TN) adalah ketika data yang diprediksi oleh model negatif tetapi sebenarnya negatif.
4. False negative (FN) adalah ketika data yang diprediksi oleh model negatif tetapi sebenarnya positif.

### 2.7.2. Precision

*Precision* adalah kemampuan model untuk mengidentifikasi objek yang sesuai. Metrik ini menunjukkan persentase prediksi positif yang benar (Padilla *et al.*, 2021).

$$Precision = \frac{TP}{TP + FP} \quad (2.1)$$

### 2.7.3. Recall

*Recall* menunjukkan bagaimana model dapat mengidentifikasi semua kasus yang relevan. Metrik tersebut menunjukkan persentase prediksi yang benar dari semua data benar yang tersedia (Padilla *et al.*, 2021).

$$Recall = \frac{TP}{TP + FN} \quad (2.2)$$

### 2.7.4. F1-Score

Skor F1 menunjukkan keseimbangan antara *precision* dan *recall*. Nilai ini menunjukkan seberapa baik model kita menggabungkan kemampuan *precision* dan *recall*, yang membantu kita memahami seberapa efektif model kita dalam melakukan klasifikasi yang akurat (Clara *et al.*, 2021).



$$F1\ Score = 2 \times \frac{Recall \times Precision}{Recall + Precision} \quad (2.3)$$

#### 2.7.5. Accuracy

Akurasi adalah metrik evaluasi yang mengukur sebaik apa suatu model melakukan prediksi yang benar dari total jumlah prediksi. Seberapa sering suatu model memprediksi kelas yang benar, baik positif maupun negatif, dalam hal klasifikasi (Khasanah *et al.*, 2022).

$$Accuracy = \frac{Jumlah\ Prediksi\ Benar}{Total\ Data} \times 100\% \quad (2.4)$$

### 2.8. Penelitian Terdahulu

Beberapa penelitian sebelumnya telah menunjukkan bahwa berbagai algoritma pembelajaran mesin dapat digunakan untuk mengklasifikasikan kadar kolesterol berdasarkan citra iris mata, dengan tingkat akurasi yang cukup baik. Bonowati *et al.* (2019) pernah menggunakan CNN untuk melakukan identifikasi kolesterol. Penelitian ini menggunakan model terlatih Inception V3 dengan hasil akurasi penelitian tersebut adalah sebesar 97,45%. Namun penelitian tersebut hanya menunjukkan apakah memiliki kolesterol normal atau tinggi.

Siddik *et al.* (2019) menggunakan teknik iridologi dan pemrosesan gambar untuk mengembangkan sistem yang dapat mengidentifikasi kadar kolesterol pada gambar iris mata. Histogram Gradients Oriented (HOG) dan Artificial Neural Network (ANN) digunakan untuk metode ekstraksi ciri dan klasifikasi. Dengan akurasi 93% dan waktu komputasi 0,0862 detik, Kadar kolesterol dapat diklasifikasikan menjadi tiga kategori: normal, berisiko tinggi, dan tinggi.

Pada tahun 2021, Hapsari *et al.* mengusulkan sistem untuk mengidentifikasi dua kelainan penyakit sekaligus dengan algoritma 3D-GLCM yang outputnya berupa identifikasi deteksi dini pada salah satu dari empat kemungkinan cluster yaitu DM (Diabetes Mellitus), HC (hypercholesterolemia), DM dan HC, atau normal. Dan telah dilakukan identifikasi dengan 3D-GLCM dengan membandingkan tingkat keabuan 16, 32, 64, dan 256. Hasil pengujian menunjukkan bahwa semakin banyak tingkat keabuan yang terdapat pada citra maka nilai sensitivitas dan akurasinya semakin tinggi. Penelitian ini terbatas pada jumlah dataset yang tersedia. Salah satu kelemahan

dari citramata yang diambil adalah bahwa kelopak mata responden menutupi iris mata jika bentuk mata responden kecil atau sipit.

Salah satu model arsitektur CNN yang dapat digunakan untuk citra mata adalah AlexNet. Model tersebut pernah digunakan oleh Cahya *et al.* (2021) untuk klasifikasi penyakit mata yaitu katarak, glaukoma dan retina disease. Hasil penelitian klasifikasi penyakit mata yang menggunakan CNN adalah akurasi 98.37%.

Balashanmugam *et al.* (2022) juga pernah menggunakan Alexnet untuk pengenalan dan klasifikasi iris mata. Penelitian yang diusulkan mengklasifikasikan iris dengan akurasi 99,1% dengan skor F1 0,995. Penelitian Amini & Ameri (2020) mengusulkan penggunaan arsitektur Alexnet untuk deteksi Arcus Senilis (AS) yang merupakan gejala kolesterol. Peneliti juga membandingkan dengan CNN dan VGG16. Hasilnya Alexnet unggul dengan akurasi 100%.

Alaslani & Elrefaei (2018) juga melakukan penelitian menggunakan AlexNet dan memadukan dengan SVM untuk mengenal citra iris mata, Peneliti melakukan uji coba pada beberapa dataset public, seperti dataset IITD, data CASIA-Iris-V1, CASIAIris-thousand, dan CASIA-Iris-V3 Interval. Hasil uji coba penelitian ini menghasilkan rata-rata akurasi yang sangat baik, yaitu diatas 95%.

Pada tahun 2020, Omran *et al.* juga menggunakan AlexNet untuk pengenalan citra iris mata. Tujuan penelitian tersebut adalah untuk membandingkan kemampuan tiga model deep learning, antara lain: AlexNet, VGG16, dan VGG19, dalam mengenali citra iris mata yang telah diberikan noise. Hasilnya menunjukkan AlexNet unggul dengan akurasi 100% dibandingkan VGG16 dan VGG19 yang masing-masing memperoleh akurasi 97,88% dan 97,5%.

**Tabel 2. 1** Penelitian Terdahulu

<b>No.</b>	<b>Penulis</b>	<b>Judul</b>	<b>Tahun</b>	<b>Keterangan</b>
1	Citra Banowati, Astri Novianty, Casi Setianingsih	<i>Cholesterol Level Detection Based on Iris Recognition Using Convolutional Neural Network Method</i>	2019	Penelitian ini menggunakan model terlatih Inception V3 dengan hasil akurasi penelitian adalah sebesar 97,45%. Namun penelitian tersebut hanya menunjukkan apakah memiliki kolesterol normal atau tinggi
2	Muhammad Arsyad Siddik, Ledy Novamizanti, I Nyoman Apraz Ramatryana	Deteksi Level Kolesterol melalui Citra Mata Berbasis HOG dan ANN	2019	Penelitian ini menggunakan Histogram of Oriented Gradients (HOG) dan Artificial Neural Network (ANN). Dengan akurasi 93% dan waktu komputasi 0,0862 detik, sistem dapat mendeteksi kadar kolesterol dalam tiga kategori, yaitu normal, berisiko tinggi, dan kolesterol tinggi.

**Tabel 2. 1** Penelitian Terdahulu

No.	Penulis	Judul	Tahun	Keterangan
3	Rinci Kembang Hapsari, Miswanto Miswanto , Riries Rulaningtyas, Herry Suprajitno	<i>Identification of DiabetesMellitus and High Cholesterol Based on IrisImage</i>	2021	Penelitian ini bertujuan untuk mengidentifikasi dua kelainan penyakit sekaligus dengan algoritma 3D-GLCM yang outputnya berupa identifikasi deteksi dini pada salah satu dari empat kemungkinan cluster yaitu DM (Diabetes Mellitus), HC(hypercholesterolemia) , DM dan HC, atau normal. Salah satu kelemahan dari gambar iris mata yang diambil adalah bahwa kelopak mata responden menutupi iris mata jika bentuk mata responden kecil atau sipit.
4	Fani Nurona Cahya, Nila Hardi, Dwiza Riana, Sri Hadiani	Klasifikasi Penyakit Mata Menggunakan Convolutional Neural Network ( CNN)	2021	Penelitian ini bertujuan untuk klasifikasi penyakit mata yaitu katarak, glaukoma dan retina disease. Hasil penelitian klasifikasi penyakit mata yang menggunakan CNN adalah akurasi 98.37%.
5	Thiyaneswaran Balashanmugam, Kumarganesh Sengottaiyan, Martin Sagayam Kulandairaj, HienDang	<i>An Effective Model For The Iris Regional Characteristics And Classification Using Deep Learning Alex Network</i>	2022	Penelitian ini menggunakanarsitektur AlexNet untuk pengenalan dan klasifikasi iris mata. Penelitian ini memperoleh akurasi 99,1% dengan skor F1 sebesar 0,995.

**Tabel 2. 1** Penelitian Terdahulu

No.	Penulis	Judul	Tahun	Keterangan
6	Amini, Ameri	<i>A Deep Learning Approach to Automatic Recognition of Arcus Senilis</i>	2020	Penelitian ini mengusulkan penggunaan arsitektur Alexnet untuk deteksi Arcus Senilis (AS) yang merupakan gejala kolesterol. Peneliti juga membandingkan dengan CNN dan VGG16. Hasilnya Alexnet unggul dengan akurasi 100%.
7	Maram G. Alaslani & Lamiaa A. Elrefaei	<i>Convolutional Neural Network Based Feature Extraction For Iris Recognition</i>	2018	Penelitian ini menggunakan AlexNet dan memadukan dengan SVM untuk mengenal citra iris mata. Hasil uji coba penelitian ini menghasilkan rata-rata akurasi yang sangat baik, yaitu diatas 95%.
8	Eman M. Omran, Randa F. Soliman, Maryam Mostafa Salah, Sameh A. Napoleon, El-Sayed M. El-Rabaie, Mustafa M. AbdeElnaby, Nabil A. Ismail, Ayman A. Eisa, & Fathi abd El-samie	<i>Noisy Iris Recognition Based on Deep Neural Network</i>	2020	Penelitian ini juga menggunakan AlexNet untuk pengenalan citra iris mata. Tujuan penelitian tersebut adalah untuk membandingkan kemampuan tiga model <i>deep learning</i> , antara lain: AlexNet, VGG16, dan VGG19, dalam mengenali citra iris mata yang telah diberikan <i>noise</i> . Hasilnya menunjukkan AlexNet unggul dengan akurasi 100% dibandingkan VGG16 dan VGG19

## 2.9. Perbedaan Penelitian

Perbedaan dengan penelitian terdahulu yang telah dibahas diatas, yaitu pada penelitian ini akan menggunakan model AlexNet untuk melakukan klasifikasi. Berbeda dengan penelitian Ameni & Ameri (2020) dan Bonowati *et al.* (2019) yang hanya menunjukkan normal atau kolesterol, output penelitian ini akan menunjukkan kadar kolesterol total dengan 3 *class* klasifikasi, yaitu normal, beresiko kolesterol, dan kolesterol tinggi.

Selanjutnya pada penelitian Siddik *et al.* (2019) menggunakan teknik HOG untuk ekstraksi fitur, sedangkan pada penelitian ini proses ekstraksi fitur akan dilakukan melalui jaringan konvolusi pada AlexNet. Hasil juga akan diimplementasikan ke dalam aplikasi mobile sehingga dapat digunakan oleh masyarakat luas.


## BAB 3

### ANALISIS DAN PERANCANGAN SISTEM

Bab ini membahas dan menjelaskan analisis dan perencanaan sistem untuk klasifikasi kadar kolesterol total. Ini membahas sumber data yang digunakan, proses input, pra-pemrosesan data, pelatihan dan pengujian, dan output yang dihasilkan.

#### 3.1. Dataset

Data untuk penelitian ini dikumpulkan dari Dataverse Universitas Telkom dan Puskesmas Barus Kabupaten Tapanuli Tengah. Dari seluruh data yang dikumpulkan terdapat sebanyak 113 data untuk jenis kolesterol tinggi, 102 data untuk jenis beresiko kolesterol dan sebanyak 145 data untuk jenis normal.

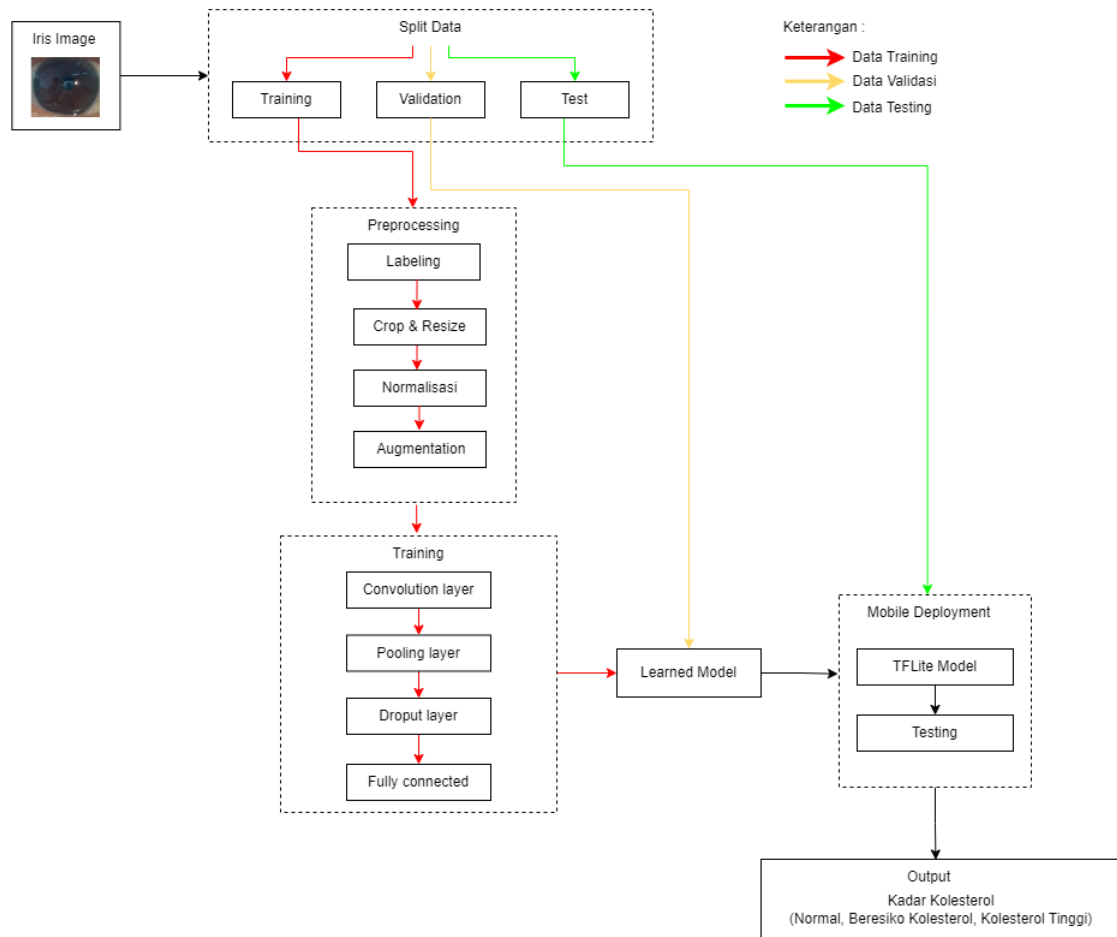


**Gambar 3. 1** Citra mata (a) normal ( $< 200$  mg/dL), (b) beresiko kolesterol (200-239 mg/dL), (c) kolesterol tinggi ( $> 240$  mg/dl)

#### 3.2. Analisis Sistem

Data citra iris mata dikumpulkan dalam bentuk gambar dan kemudian dibagi menjadi data pelatihan, validasi, dan pengujian. Proses penelitian ini terdiri dari beberapa tahapan. Pra-proses akan dilakukan pada gambar yang telah dikumpulkan, seperti melakukan pelabelan data, *crop* dan *resize*, normalisasi citra, dan augmentasi.

Kemudian dilakukan pelatihan model menggunakan AlexNet yang akan menghasilkan learned model. Lalu model akan diubah menjadi format tflite dan diimplementasikan ke aplikasi mobile. Gambar 3.2 menunjukkan rancangan arsitektur umum.



**Gambar 3. 2** Arsitektur Umum

### 3.3. Akusisi Data

Tahap awal adalah tahap pengumpulan data untuk penelitian yang dikumpulkan dari Database Universitas Telkom oleh Novamizanti (2022). Data tersebut berupa gambar mata yang diambil menggunakan kamera digital. Contoh data yang diambil dari Telkom University Dataverse dapat dilihat pada Gambar 3.3.






**Gambar 3. 3** Contoh Citra Mata dari Telkom University Dataverse

Penulis juga melakukan pengumpulan data secara mandiri di Puskesmas Barus Kabupaten Tapanuli Tengah. Pengambilan data dibantu oleh Ibu Devi Masjida, A.Md.Keb yang merupakan seorang bidan di puskesmas tersebut. Subjek akan dilakukan pengecekan kolesterol dengan mengambil sampel darah di ujung jari menggunakan jarum, lalu kadar kolesterol akan diukur menggunakan alat kolesterol meter. Selanjutnya gambar mata dari subjek akan diambil. Foto dokumentasi pengumpulan data di Puskesmas Barus dapat dilihat pada Gambar 3.4.



**Gambar 3. 4** Dokumentasi Pengumpulan Data di Puskesmas Barus



**Gambar 3. 5** Contoh Citra Mata Hasil Pengumpulan Mandiri

Pada Gambar 3.5 menunjukkan hasil pengumpulan mandiri yang dilakukan di Puskesmas Barus. Data pelatihan, validasi, dan pengujian akan dibagi dari semua data yang telah dikumpulkan sebelumnya.

### **3.4. Data Preprocessing**

Pada tahap ini, data gambar akan melalui beberapa prosedur untuk mendapatkan hasil yang lebih baik. Proses *preprocessing* meliputi *crop* dan *resize*, *labeling*, normalisasi dan augmentasi.

#### **3.4.1. Labeling**

*Labeling* adalah proses yang digunakan untuk memberikan label atau penanda pada citra untuk membantu mengidentifikasi atau mengkategorikan data sehingga dapat mempermudah model dalam mempelajari data yang diberikan. Label akan diberikan sesuai dengan folder tempat penyimpanan data masing-masing jenis.

#### **3.4.2. Crop & resize**

Pemotongan area gambar, juga dikenal sebagai *image cropping* adalah teknik yang digunakan untuk menentukan bagian mana dari gambar yang mengandung area objek yang akan diolah. Proses tersebut memungkinkan untuk memotong dan memisahkan area gambar yang tidak dibutuhkan untuk pengolahan lebih lanjut. Sedangkan *resize* adalah proses mengubah dimensi gambar dari ukuran aslinya menjadi ukuran yang diinginkan. Pada tahap ini, gambar diubah ukurannya menjadi 224×224 piksel agar sesuai dengan input yang dibutuhkan oleh AlexNet. Pemotongan dan *resize* yang sesuai dengan kebutuhan model dapat mengurangi waktu pemrosesan sehingga pelatihan dapat berjalan lebih cepat (Das *et al.*, 2020). Berikut ini adalah *pseudocode* untuk proses *resize*.

```

DEFINE target_width
DEFINE target_height

// Mengambil ukuran asli
SET original_width = Image.width
SET original_height = Image.height

// Menghitung faktor skala
SET x_scale = target_width / original_width
SET y_scale = target_height / original_height

// Menentukan ukuran baru
SET new_width = original_width * x_scale
SET new_height = original_height * y_scale

```

Berikut adalah proses perhitungan pada proses *resizing*.

- a. Mengambil ukuran asli citra

$$w_{original} = 785 \text{ piksel}$$

$$h_{original} = 649 \text{ piksel}$$

- b. Menghitung faktor skala

$$scale_x = \frac{w_{target}}{w_{original}} = \frac{224}{785} = 0,285350318$$


$$scale_y = \frac{h_{target}}{h_{original}} = \frac{224}{649} = 0,345146379$$

- c. Menghitung ukuran citra baru

$$w_{new} = w_{original} \times scale_x = 785 \times 0,285350318 = 224$$

$$h_{new} = h_{original} \times scale_y = 649 \times 0,345146379 = 224$$

Contoh hasil resize dapat dilihat pada Gambar 3.6



**Gambar 3. 6** Proses resize (a) sebelum resize 785×649 piksel, (b) sesudah resize 224×224 piksel

#### 3.4.3. Normalisasi

Untuk mengubah nilai fitur data ke dalam skala yang seragam tanpa mengubah distribusi relatifnya, proses pembelajaran mesin yang penting dikenal sebagai normalisasi. Untuk menyamakan skala fitur, mempercepat konvergensi algoritma, meningkatkan akurasi model, dan mengurangi risiko overfitting, normalisasi sangat penting.

Normalisasi dilakukan dengan metode min-max normalization. Metode ini mengubah nilai piksel gambar dari rentang awal 0-255 menjadi rentang 0-1. Metode tersebut sering digunakan dalam pemrosesan gambar dan pembelajaran mesin untuk mempercepat konvergensi algoritma serta membantu stabilitas perhitungan.

Berikut adalah contoh piksel gambar sebelum dilakukan normalisasi.

```
[114  81  64]
[113  80  63]
[112  79  62]
```


Dan berikut adalah contoh piksel gambar setelah dilakukan normalisasi.

```
[0.44705882 0.31764706 0.25098039]
[0.44313725 0.31372549 0.24705882]
[0.43921569 0.30980392 0.24313725]
```

#### 3.4.4. Augmentasi

Augmentasi data dapat digunakan untuk meningkatkan jumlah dan keragaman data. Augmentasi adalah teknik yang dapat digunakan untuk membuat dataset menjadi lebih besar dan lebih beragam tanpa mengumpulkan data tambahan melalui manipulasi data

yang sudah ada. Proses augmentasi yang dilakukan meliputi *flip*, *rotate*, dan penyesuaian kecerahan.



**Gambar 3. 7** Proses augmentasi (a) asli, (b) flip, (c) rotate, (d) brightness

### 3.5. Pelatihan Model

Tahap ini merupakan tahap membangun arsitektur model menggunakan AlexNet dan melatih model dengan data *training*.

#### 3.5.1. Convolution layer

*Convolution layer* merupakan blok pertama dalam proses (CNN) yang didalamnya terdapat beragam filter yang diinisialisasikan secara acak untuk melakukan *convolution* yang berfungsi sebagai ekstraksi fitur yang digunakan untuk mempelajari representasi fitur dari suatu citra. Lapisan ini berfungsi untuk mengekstraksi fitur dasar dari gambar seperti tepi dan tekstur.

Lapisan konvolusi pertama menggunakan 96 filter berukuran  $11 \times 11$  dengan stride 4, menghasilkan output berukuran  $55 \times 55 \times 96$ . Lapisan kedua memiliki 256 filter berukuran  $5 \times 5$  dengan stride 1, menghasilkan output berukuran  $27 \times 27 \times 256$ , yang berguna untuk mendeteksi fitur gambar yang lebih kompleks. Sementara itu, lapisan ketiga, keempat, dan kelima menggunakan filter berukuran  $3 \times 3$  dengan stride 1.

Ukuran output dari ketiga lapisan ini adalah  $13 \times 13$ , dengan 384 filter untuk lapisan ketiga dan keempat, serta 256 filter pada lapisan kelima.

Nilai Input					Nilai Filter			Nilai Hasil				
114	81	64	111	115	x	0	1	0	=	C1	C2	C3
113	80	63	112	121		1	0	1		C4	C5	C6
112	79	62	96	98		0	1	0				
125	77	79	111	112								

**Gambar 3. 8** Contoh Proses Perhitungan Filter 3x3 Lapisan Convolusi

114 81 64 111 115	114 81 64 111 115	114 81 64 111 115
113 80 63 112 121	113 80 63 112 121	113 80 63 112 121
112 79 62 96 98	112 79 62 96 98	112 79 62 96 98
125 77 79 111 112	125 77 79 111 112	125 77 79 111 112

114 81 64 111 115	114 81 64 111 115	114 81 64 111 115
113 80 63 112 121	113 80 63 112 121	113 80 63 112 121
112 79 62 96 98	112 79 62 96 98	112 79 62 96 98
125 77 79 111 112	125 77 79 111 112	125 77 79 111 112

**Gambar 3. 9** Contoh Proses Pergeseran Stride 1

### 3.5.2. Pooling layer

*Pooling layer* digunakan untuk mereduksi dimensi spasial (lebar dan tinggi) dari fitur-fitur yang dihasilkan oleh lapisan konvolusi, namun tetap mempertahankan informasi penting. Fungsi ini membantu mengurangi jumlah parameter dan komputasi, serta mencegah *overfitting*.

AlexNet menggunakan MaxPooling yang memilih nilai tertinggi dari setiap wilayah kecil dari output fitur konvolusi. Misalnya, jika digunakan ukuran jendela pooling  $2 \times 2$ , dari setiap blok  $2 \times 2$  piksel dalam peta fitur, nilai tertinggi akan diambil

sebagai hasil pooling. Ukuran kernel yang digunakan berukuran  $3 \times 3$ , yang bergerak dengan stride 2. Hal ini berarti jendela pooling berpindah dua piksel dalam satu waktu.

### 3.5.3. *Fully connected layer*

Dalam AlexNet terdapat tiga lapisan terhubung penuh dengan neuron masing-masing 4069, 4096, dan 1000. Lapisan ini bertujuan untuk melakukan transformasi pada dimensi data agar data dapat diklasifikasikan secara linear. Setiap neuron di lapisan *convolution* harus diubah menjadi data satu dimensi sebelum dapat dimasukkan ke dalam lapisan yang penuh terhubung. Pada lapisan akhir merupakan lapisan output dengan 3 neuron sesuai dengan jumlah class yang diklasifikasikan.

## 3.6. *Learned Model*

Model yang telah dilatih akan dievaluasi menggunakan data validasi yang belum pernah digunakan saat pelatihan.

## 3.7. *Deployment*

Model yang disimpan akan dikonversi menjadi TensorFlow Lite dan diimplementasikan ke dalam aplikasi Mobile. Kemudian hasil akan diuji menggunakan data *testing*.

### 3.7.1. *TF Lite model*

TFLite adalah *library* pembelajaran mesin yang dimaksudkan untuk digunakan dengan perangkat Android untuk mengembangkan model pembelajaran mesin dengan binari yang sederhana dan latensi yang rendah.

### 3.7.2. *Testing*

Tahap ini merupakan tahap pengujian sistem dengan menggunakan data test yang telah dikumpulkan sebelumnya.

## 3.8 *Output*

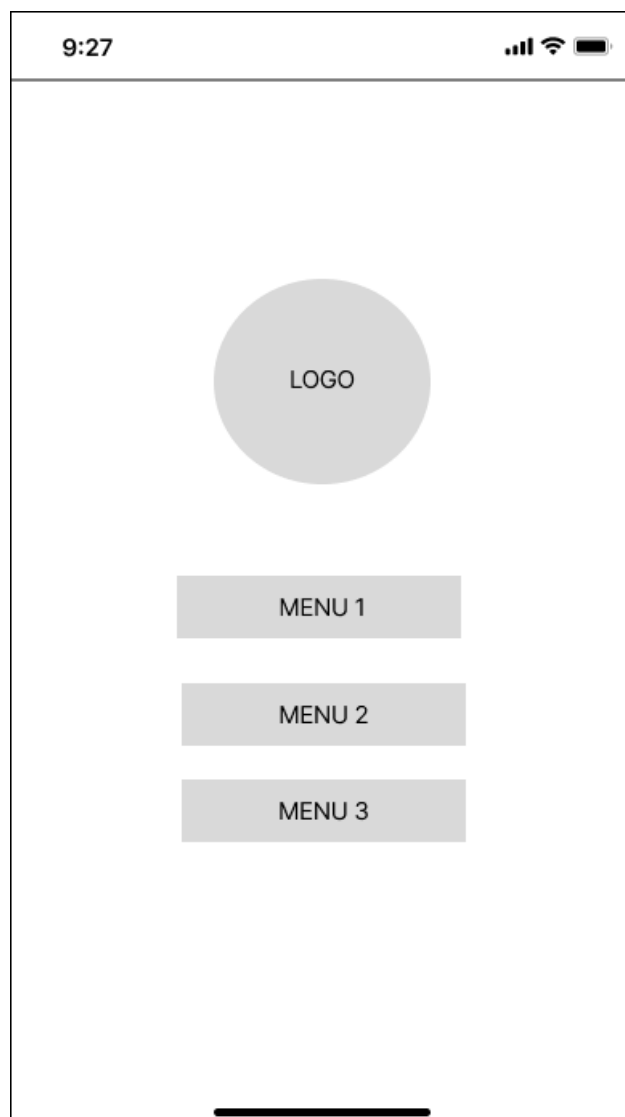
Tahap akhir dari serangkaian proses sebelumnya akan menghasilkan keluaran berupa klasifikasi kadar kolesterol normal, beresiko kolesterol, atau kolesterol tinggi.

### 3.5. Perancangan Antarmuka Sistem

Tahapan selanjutnya adalah membuat rancangan antarmuka pengguna aplikasi. Tujuan dari perancangan ini adalah untuk memberikan contoh sistem yang akan dibangun. Halaman utama, halaman deteksi, halaman keterangan, dan halaman tips adalah semua halaman yang dirancang.

#### 3.5.1. Rancangan halaman home

Saat aplikasi dibuka, halaman ini adalah halaman utama. Di halaman ini terdapat logo aplikasi, yang diikuti oleh tiga tombol yang akan mengarahkan pengguna ke halaman masing-masing. Menu-menu ini adalah menu deteksi, menu keterangan, dan menu tips.




**Gambar 3. 10** Rancangan Halaman Home



### 3.5.2. Rancangan halaman deteksi

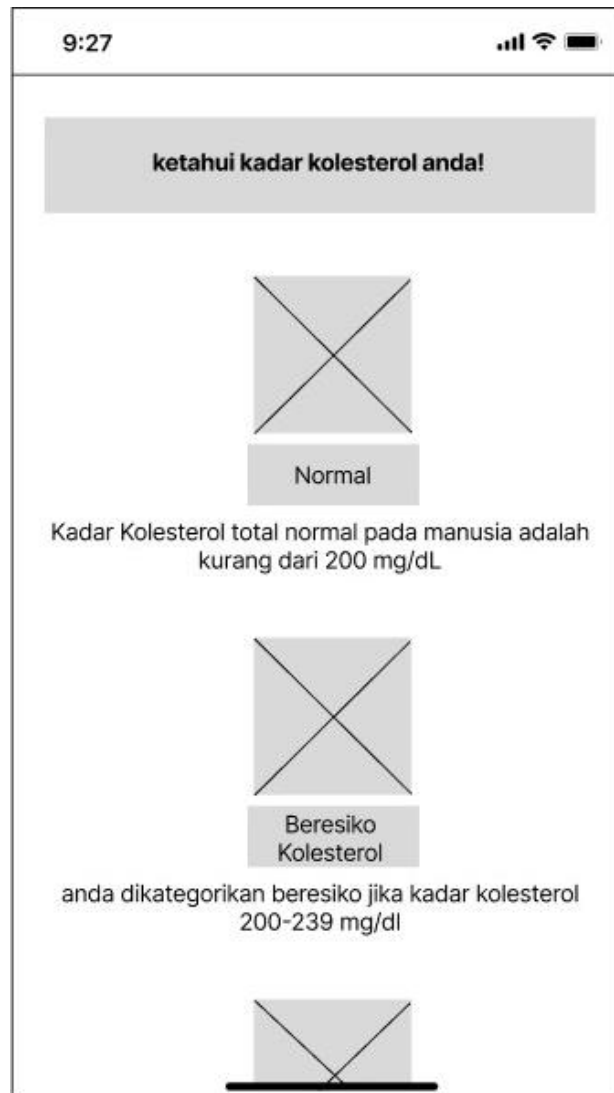
Halaman ini akan terbuka ketika pengguna menekan tombol deteksi, halaman ini merupakan fitur utama dari aplikasi tersebut. Apabila menekan tombol pilih maka pengguna akan diarahkan ke galeri tempat menyimpan gambar yang akan dideteksi, setelah itu pengguna dapat menekan tombol predict untuk mengetahui hasil deteksi dari gambar yang dipilih.



**Gambar 3. 11** Rancangan Halaman Deteksi

### 3.5.3. Rancangan halaman informasi

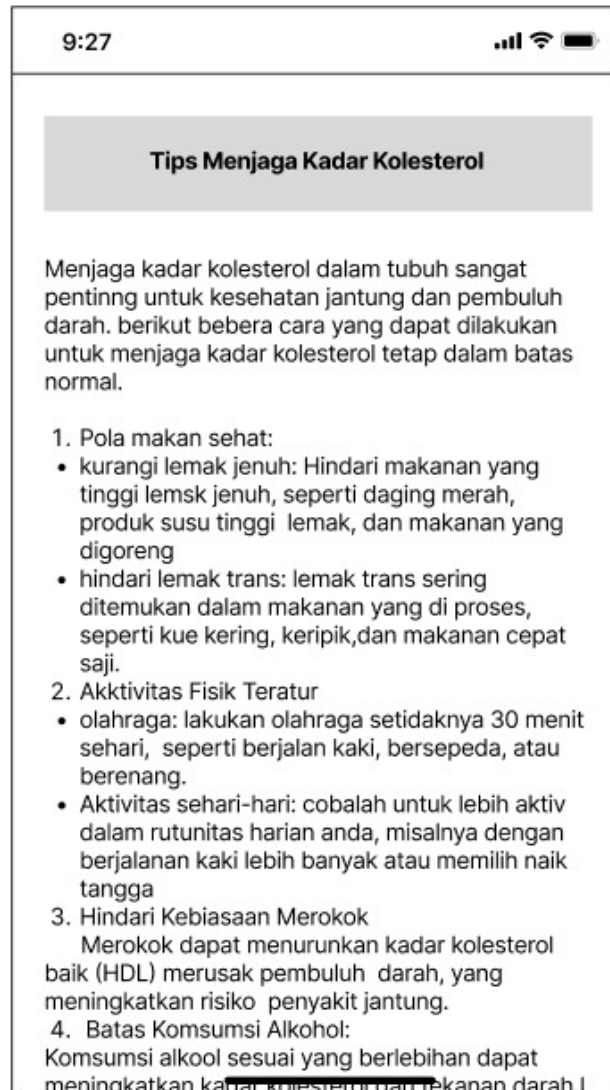
Halaman ini menunjukkan informasi tentang kadar kolesterol total, termasuk normal, beresiko, dan kolesterol tinggi. Ini adalah informasi penting bagi pengguna aplikasi. Pengguna dapat mengetahui kisaran kadar kolesterol yang ada dalam darah berdasarkan hasil klasifikasi pada menu deteksi.



**Gambar 3. 12** Rancangan Halaman Informasi

#### *3.5.4. Rancangan halaman tips*

Menu tips memberikan panduan singkat tentang pola makan sehat, aktivitas teratur, menghindari merokok, mengurangi konsumsi alkohol, menjaga berat badan sehat, dan rutin memeriksa kesehatan. Menu ini dirancang untuk membantu pengguna mengelola kolesterol mereka dengan mudah dalam kehidupan sehari-hari.



**Gambar 3. 13** Rancangan Halaman Tips

## **BAB 4**

### **IMPLEMENTASI DAN PENGUJIAN**

Bab ini membahas proses implementasi algoritma AlexNet untuk mengklasifikasikan kadar kolesterol melalui citra iris mata, hingga tahap pengujian.

#### **4.1. Implementasi Sistem**

Implementasi algoritma AlexNet akan dilakukan pada tahap ini untuk klasifikasi kadar kolesterol melalui citra iris mata.

##### *4.1.1. Perangkat keras*

Perangkat yang digunakan untuk membuat sistem ini adalah PC MSI MAG Infinite S3 13th, yang memiliki spesifikasi berikut.

- 1) CPU: Intel Core i7-13700F
- 2) RAM: 32 GB
- 3) Storage: 1 TB
- 4) GPU: Nvidia GeForce RTX 4070
- 5) OS: Windows 11 Home Single Language 64-bit

##### *4.1.2. Perangkat lunak*

Berikut merupakan perangkat lunak dan library yang digunakan untuk membangun sistem tersebut.


- 1) Visual Studio Code 1.89.0
- 2) Bahasa pemrograman Python 3.11.7
- 3) TensorFlow 2.10
- 4) TensorFlow Lite
- 5) Android Studio Iguana 2023.2.1

## 4.2. Implementasi Data


Data yang digunakan adalah gambar iris mata dari tiga kategori, yaitu normal, beresiko kolesterol, dan kolesterol tinggi. Data ini dikumpulkan dari Universitas Telkom dan Puskesmas Barus. Jumlah data yang digunakan sebagai data training sebanyak 1072, data validasi sebanyak 90, dan data testing sebanyak 45. Perbandingan jumlah data ditunjukkan pada Tabel 4.1, dan contoh masing-masing kelas dapat dilihat pada Gambar 4.1, Gambar 4.2, dan Gambar 4.3.

**Tabel 4. 1** Perbandingan Data Setiap Kelas


	Train	Validasi	Testing
Beresiko	360	30	15
Kolesterol	369	30	15
Normal	343	30	15



**Gambar 4. 1** Citra Iris Mata Normal



**Gambar 4. 2** Citra Iris Mata Beresiko Kolesterol

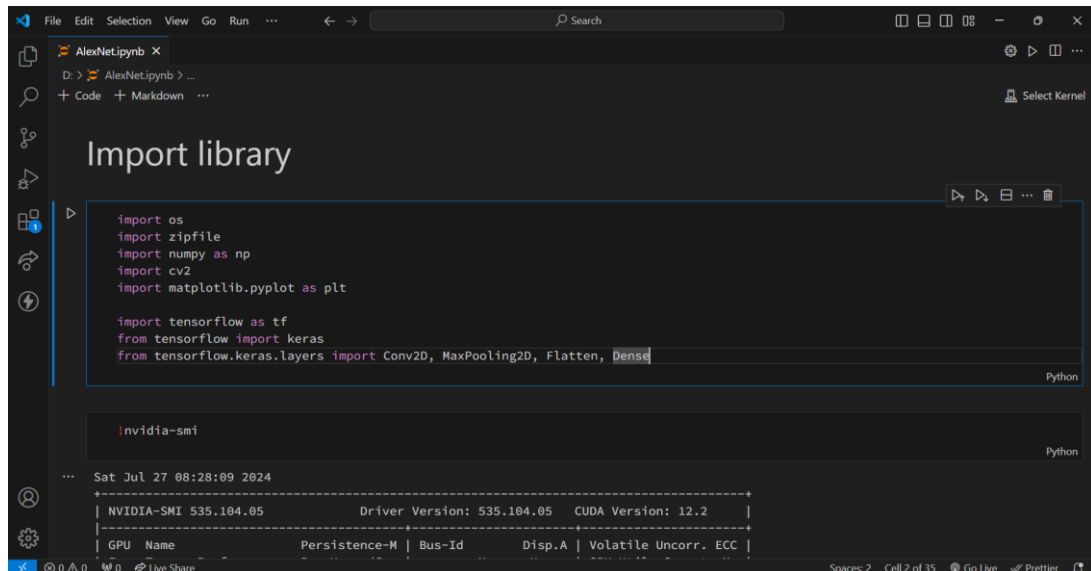


**Gambar 4. 3** Citra Iris Mata Kolesterol Tinggi

#### 4.3. Implementasi Model

Untuk mengimplementasikan model, penulis menggunakan program Visual Studio Code, juga dikenal sebagai VS Code, yang merupakan IDE (Integrated Development

Environment) yang sangat populer dan mudah digunakan. VS Code memiliki kemampuan untuk menjalankan file notebook, mirip dengan Google Colab, tetapi dengan konfigurasi lokal.



**Gambar 4. 4** Visual Studio Code

Pelatihan sistem dilakukan dengan menggunakan model neural network AlexNet. Model AlexNet pernah digunakan dalam penelitian Amini & Ameri (2020) untuk deteksi Arcus Senilis (AS) pada mata yang merupakan gejala kolesterol. Lapisan input pada AlexNet menerima gambar berukuran 224×224 piksel dengan 3 channel warna (RGB). Selanjutnya gambar akan melewati 5 lapisan konvolusi. Lapisan konvolusi pertama memiliki 96 filter dengan ukuran 11×11 dan stride 4. Lapisan ini menghasilkan keluaran berukuran 55×55×96. Tujuan utama dari lapisan ini adalah mengekstrak fitur dasar dari gambar seperti tepi dan tekstur. Lapisan kedua menggunakan 256 filter dengan ukuran 5×5 dan stride 1. Lapisan ini menghasilkan keluaran berukuran 27×27×256. Lapisan ini membantu untuk mengekstraksi fitur yang lebih kompleks dari gambar. Lapisan ketiga, keempat, dan kelima menggunakan filter dengan ukuran 3×3 dan stride 1. Masing-masing lapisan menghasilkan keluaran berukuran 13×13 dengan jumlah filter berturut-turut 384 untuk lapisan ketiga dan keempat, dan 256 untuk lapisan kelima. Lapisan-lapisan ini semakin memperdalam pemahaman model terhadap fitur gambar dengan mengekstraksi informasi yang lebih abstrak.

Setelah lapisan konvolusi, terdapat tiga lapisan terhubung penuh dengan jumlah neuron berturut-turut 4096, 4096, dan 1000. Lapisan-lapisan ini bertugas untuk

memproses fitur yang telah diekstraksi oleh lapisan konvolusi dan akhirnya memetakan ke kelas yang berbeda untuk klasifikasi. Lapisan terakhir (output) adalah lapisan dengan 3 neuron yang menggunakan fungsi aktivasi softmax yang memberikan probabilitas untuk setiap dari 3 kelas, yang kemudian digunakan untuk menentukan kelas yang benar dari input gambar.

Dalam pelatihan model, terdapat beberapa hyperparameter yang berpengaruh terhadap performa model. Learning rate memiliki peran kunci dalam mengatur kecepatan model dalam mempelajari data. Memilih learning rate yang tepat sangat berdampak pada kecepatan konvergensi dan hasil akhir akurasi model. Sementara itu, ukuran batch mengontrol jumlah sampel yang diproses secara bersamaan sebelum bobot diperbarui. Menggunakan ukuran batch yang terlalu kecil atau terlalu besar dapat memengaruhi waktu komputasi dan kemungkinan terjadinya *overfitting* model. Jumlah epoch berperan penting dalam menentukan kapan model mencapai konvergensi (Rochmawati *et al.*, 2021).


Tabel 4.1 merupakan beberapa skenario pelatihan yang dilakukan untuk memperoleh model terbaik.

**Tabel 4. 2** Skenario Pelatihan Model

Epoch	Batch Size	Learning Rate	Accuracy	Loss
10	16	0.0001	0.9333	0.2708
10	32	0.0001	0.9333	0.3510
25	16	0.00001	0.8937	0.4380
25	32	0.00001	0.8153	0.6285
<b>50</b>	<b>16</b>	<b>0.00001</b>	<b>0.9556</b>	<b>0.2571</b>
50	16	0.000001	0.7556	0.7606
50	32	0.00001	0.8778	0.4121
50	32	0.000001	0.6889	0.8612

Hasil model terbaik diperoleh dengan hyperparameter epoch 50, batch size 16, learning rate 0,00001 dengan akurasi sebesar 96% seperti yang dapat dilihat pada Gambar 4.5 dan loss sebesar 0,2 seperti yang ditunjukkan pada Gambar 4.6. Peningkatan epoch dapat memberikan hasil yang lebih baik karena model akan belajar lebih banyak dari data. Pemilihan batch size yang tepat juga akan berpengaruh sesuai dengan jumlah data yang digunakan untuk mendapatkan hasil yang baik.






**Gambar 4. 5** Grafik Akurasi

Gambar 4.5 menunjukkan grafik akurasi selama proses pelatihan model. Pada grafik ini, sumbu X menunjukkan jumlah epoch, sedangkan sumbu Y menunjukkan nilai akurasi yang mengukur seberapa baik model dalam memprediksi label yang benar. Garis berwarna biru menunjukkan akurasi model pada data pelatihan. Kurva ini menunjukkan seberapa baik model belajar dari data yang tersedia. Sedangkan garis berwarna merah menunjukkan akurasi model pada data validasi. Kurva ini menunjukkan kinerja model pada data yang tidak digunakan selama pelatihan, memberikan gambaran tentang bagaimana model akan bekerja pada data yang belum pernah dilihat sebelumnya.

Pada awal pelatihan sekitar 10 epoch pertama, baik akurasi pelatihan maupun validasi meningkat dengan cepat. Hal ini menunjukkan bahwa model sedang belajar pola-pola dari data dengan cukup efektif. Setelah epoch ke-10, kurva mulai mendatar, menandakan bahwa peningkatan akurasi menjadi lebih lambat, yang merupakan indikasi bahwa model mendekati konvergensi.

Secara keseluruhan, kurva pelatihan dan validasi bergerak beriringan, dengan fluktuasi kecil pada kurva validasi. Fluktuasi ini bisa menunjukkan adanya variasi

dalam data validasi. Pada akhir pelatihan, akurasi pada data pelatihan dan validasi tercatat diatas 0,9 atau 90%. Hal ini menunjukkan bahwa model memiliki kinerja yang baik pada data pelatihan maupun validasi.



**Gambar 4. 6** Grafik Loss

Gambar 4.6 menunjukkan grafik nilai loss selama proses pelatihan model. Pada grafik ini, sumbu X menunjukkan jumlah epoch, sementara sumbu Y menunjukkan nilai loss, yang mencerminkan seberapa baik atau buruk model memprediksi. Garis biru menunjukkan nilai loss yang dari data pelatihan. Kurva ini menunjukkan seberapa baik model belajar dari data yang tersedia. Garis merah menunjukkan nilai loss dari data validasi. Kurva ini menunjukkan kinerja model pada data yang tidak digunakan selama pelatihan, yang memberikan gambaran bagaimana model akan bekerja pada data yang belum pernah dilihat sebelumnya.

Pada awal pelatihan sebelum epoch ke-10, loss pada data pelatihan dan validasi menurun dengan cepat, yang menunjukkan bahwa model sedang belajar dan kinerjanya membaik. Setelah beberapa epoch, kurva mulai mendatar, menunjukkan bahwa laju penurunan loss melambat. Ini biasanya terjadi karena model mendekati kondisi konvergensi, di mana pelatihan tidak memberikan banyak peningkatan. Menjelang

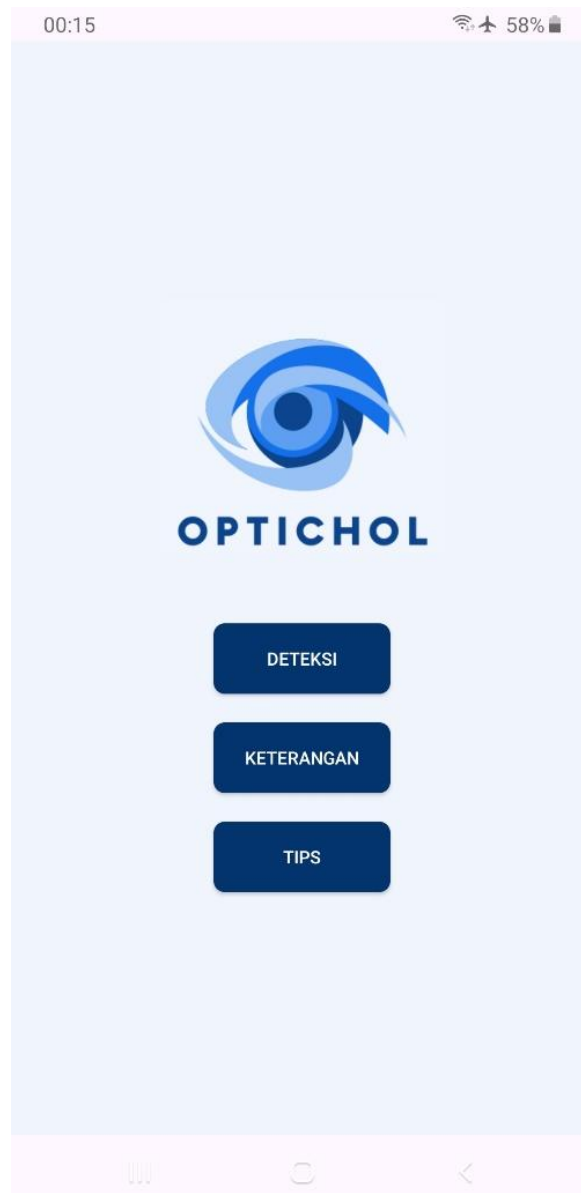
epoch ke-30 hingga ke-50, kurva pelatihan dan validasi hampir paralel, tetapi ada sedikit fluktuasi pada kurva validasi, yang bisa disebabkan oleh variasi dalam data validasi.

Secara keseluruhan, grafik ini menunjukkan bahwa model memiliki kinerja yang stabil dan akurasi yang baik. Tidak ada tanda-tanda overfitting yang signifikan, karena kurva tetap berdekatan. Pelatihan sebanyak 50 epoch selesai dengan waktu rata-rata 10 detik per epoch.

#### **4.4. Implementasi Antarmuka Aplikasi**

##### *4.4.1. Antarmuka halaman home*

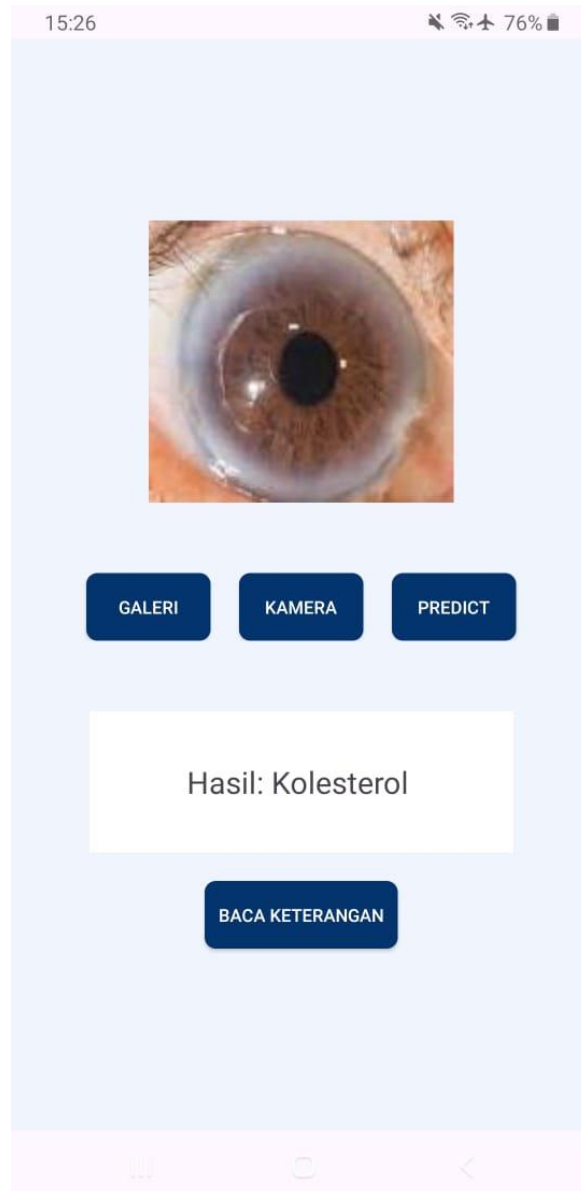
Saat aplikasi dibuka, halaman ini adalah halaman utama. Di halaman ini terdapat logo aplikasi, yang diikuti oleh tiga tombol yang akan mengarahkan pengguna ke halaman masing-masing. Menu-menu ini adalah menu deteksi, menu keterangan, dan menu tips.



**Gambar 4. 7** Antarmuka Halaman Home

#### *4.4.2. Antarmuka halaman deteksi*

Halaman ini akan terbuka ketika pengguna menekan tombol deteksi, halaman ini merupakan fitur utama dari aplikasi tersebut. Apabila menekan tombol pilih maka pengguna akan diarahkan ke galeri tempat pengguna menyimpan gambar yang akan dideteksi, setelah itu pengguna dapat menekan tombol predict untuk mengetahui hasil gambar yang dipilih.



**Gambar 4. 8** Antarmuka Halaman Deteksi

#### *4.4.3. Antarmuka halaman informasi*

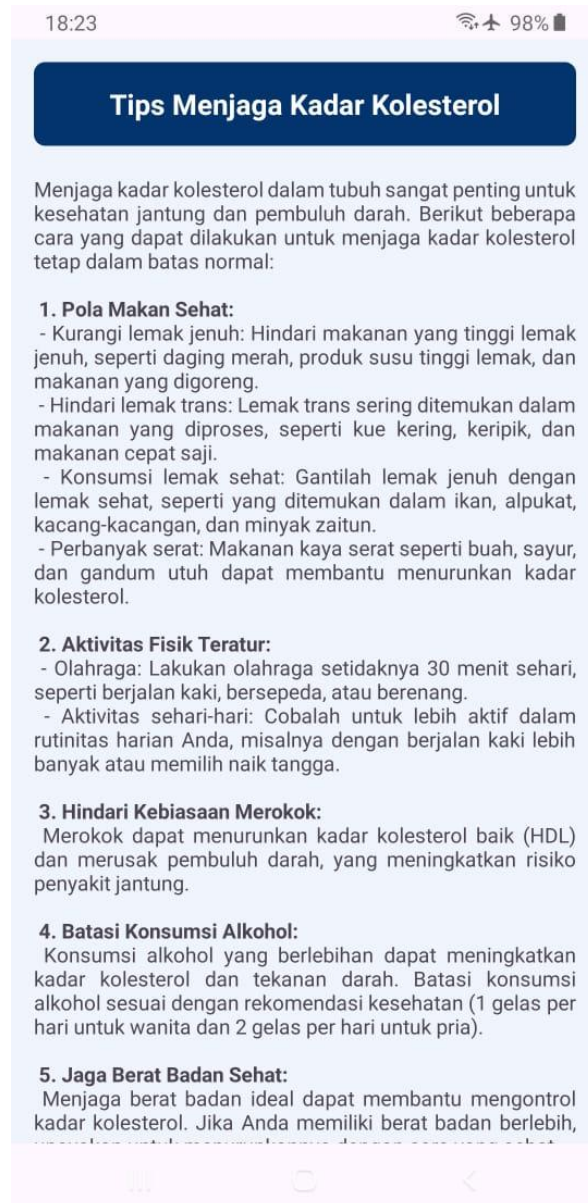
Halaman ini menunjukkan informasi tentang kadar kolesterol total, termasuk normal, beresiko, dan kolesterol tinggi. Ini adalah informasi penting bagi pengguna aplikasi. Pengguna dapat mengetahui kisaran kadar kolesterol yang ada dalam darah berdasarkan hasil klasifikasi pada menu deteksi.



**Gambar 4. 9** Antarmuka Halaman Informasi

#### *4.4.4. Antarmuka halaman tips*

Menu tips in memberikan panduan singkat tentang pola makan sehat, aktivitas teratur, menghindari merokok, mengurangi konsumsi alkohol, menjaga berat badan sehat, dan rutin memeriksa kesehatan. Menu ini dirancang untuk membantu pengguna mengelola kolesterol mereka dengan mudah dalam kehidupan sehari-hari.



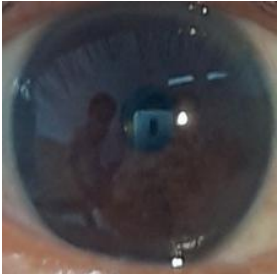



**Gambar 4. 10** Antarmuka Halaman Tips

#### 4.5. Pengujian Sistem

Pada tahap ini, pengujian sistem dilakukan pada model hasil pelatihan dari proses sebelumnya untuk mengetahui apakah model dapat mengklasifikasi kolesterol pada citra iris mata. Pengujian ini dilakukan menggunakan kamera hp beresolusi 24 MP.

**Tabel 4. 3** Pengujian Sistem




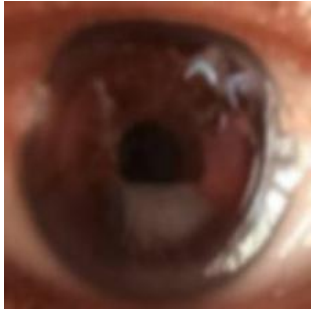
No.	Citra	Aktual	Prediksi	Keterangan
1		Beresiko	Beresiko	Benar
2		Beresiko	Beresiko	Benar
3		Beresiko	Beresiko	Benar
4		Beresiko	Beresiko	Benar




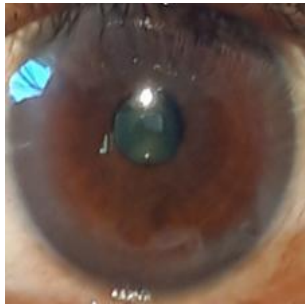


Tabel 4. 3 Pengujian Sistem

No.	Citra	Aktual	Prediksi	Keterangan
5		Beresiko	Beresiko	Benar
6		Beresiko	Kolesterol	Salah
7		Beresiko	Beresiko	Benar
8		Beresiko	Beresiko	Benar


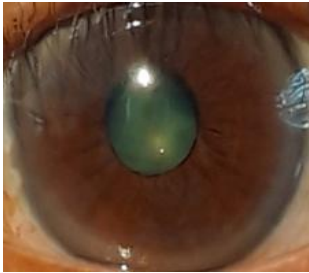
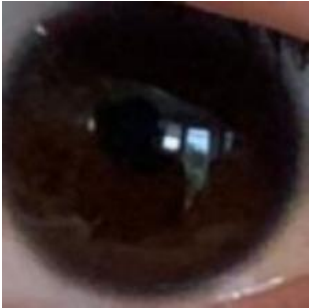

**Tabel 4. 3** Pengujian Sistem

No.	Citra	Aktual	Prediksi	Keterangan
9		Beresiko	Beresiko	Benar
10		Beresiko	Beresiko	Benar
11		Beresiko	Beresiko	Benar
12		Beresiko	Beresiko	Benar





**Tabel 4. 3** Pengujian Sistem

<b>No.</b>	<b>Citra</b>	<b>Aktual</b>	<b>Prediksi</b>	<b>Keterangan</b>
13		Beresiko	Beresiko	Benar
14		Beresiko	Beresiko	Benar
15		Beresiko	Beresiko	Benar
16		Kolesterol	Kolesterol	Benar

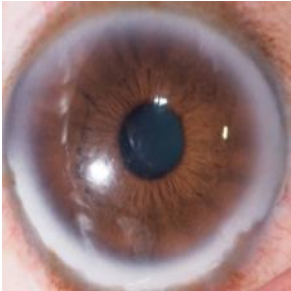



**Tabel 4. 3** Pengujian Sistem

<b>No.</b>	<b>Citra</b>	<b>Aktual</b>	<b>Prediksi</b>	<b>Keterangan</b>
17		Kolesterol	Kolesterol	Benar
18		Kolesterol	Kolesterol	Benar
19		Kolesterol	Kolesterol	Benar
20		Kolesterol	Kolesterol	Benar

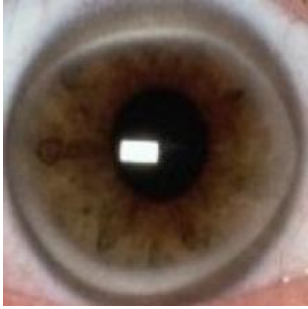



**Tabel 4. 3** Pengujian Sistem

No.	Citra	Aktual	Prediksi	Keterangan
21		Kolesterol	Kolesterol	Benar
22		Kolesterol	Kolesterol	Benar
23		Kolesterol	Beresiko	Salah
24		Kolesterol	Kolesterol	Benar





**Tabel 4. 3** Pengujian Sistem

No.	Citra	Aktual	Prediksi	Keterangan
25		Kolesterol	Kolesterol	Benar
26		Kolesterol	Kolesterol	Benar
27		Kolesterol	Kolesterol	Benar
28		Kolesterol	Kolesterol	Benar

**Tabel 4. 3** Pengujian Sistem





<b>No.</b>	<b>Citra</b>	<b>Aktual</b>	<b>Prediksi</b>	<b>Keterangan</b>
29		Kolesterol	Kolesterol	Benar
30		Kolesterol	Kolesterol	Benar
31		Normal	Beresiko	Salah
32		Normal	Normal	Benar

**Tabel 4. 3** Pengujian Sistem





<b>No.</b>	<b>Citra</b>	<b>Aktual</b>	<b>Prediksi</b>	<b>Keterangan</b>
33		Normal	Normal	Benar
34		Normal	Normal	Benar
35		Normal	Normal	Benar
36		Normal	Normal	Benar




**Tabel 4. 3** Pengujian Sistem

<b>No.</b>	<b>Citra</b>	<b>Aktual</b>	<b>Prediksi</b>	<b>Keterangan</b>
37		Normal	Normal	Benar
38		Normal	Normal	Benar
39		Normal	Normal	Benar
40		Normal	Normal	Benar

**Tabel 4. 3** Pengujian Sistem

<b>No.</b>	<b>Citra</b>	<b>Aktual</b>	<b>Prediksi</b>	<b>Keterangan</b>
41		Normal	Normal	Benar
42		Normal	Normal	Benar
43		Normal	Normal	Benar
44		Normal	Normal	Benar

**Tabel 4. 3** Pengujian Sistem

No.	Citra	Aktual	Prediksi	Keterangan
45		Normal	Normal	Benar

Tabel 4.2 menunjukkan hasil pengujian sistem klasifikasi kadar kolesterol melalui citra mata. Berdasarkan hasil pengujian sebanyak 45 data testing, ditemukan sebanyak 3 kesalahan klasifikasi. Kesalahan tersebut dapat terjadi karena adanya kemiripan citra antar mata, dimana cincin putih pada iris mata yang terlihat tipis sehingga sistem dapat mengklasifikasikannya ke dalam kategori lainnya. Perhitungan *confusion matrix* dapat dilihat pada Tabel 4.3.

**Tabel 4. 4** *Confusion Matrix*

<div>Aktual Prediksi</div>	Beresiko	Kolesterol	Normal	Total
Beresiko	14	1	1	16
Kolesterol	1	14	0	15
Normal	0	0	14	14
Total	15	15	15	45

Adapun perhitungan nilai *precision*, *recall*, *f1-score* adalah sebagai berikut.

a. *Precision*

Perhitungan *precision* dilakukan berdasarkan persamaan (2.1)

$$\text{Beresiko} = \frac{14}{14+1} = 0,93$$

$$\text{Kolesterol} = \frac{14}{14+1} = 0,93$$

$$\text{Normal} = \frac{14}{14+1} = 0,93$$

b. *Recall*

Perhitungan *recall* dilakukan berdasarkan persamaan (2.2)

$$\text{Beresiko} = \frac{14}{14+2} = 0,87$$

$$\text{Kolesterol} = \frac{14}{14+1} = 0,93$$

$$\text{Normal} = \frac{14}{14+0} = 1,0$$

c. *F1-score*

Perhitungan *f1-score* dilakukan berdasarkan persamaan (2.3)

$$\text{Beresiko} = 2 \times \frac{0,87 \times 0,93}{0,87 + 0,93} = 0,89$$

$$\text{Kolesterol} = 2 \times \frac{0,93 \times 0,93}{0,93 + 0,93} = 0,93$$

$$\text{Normal} = 2 \times \frac{1,0 \times 0,93}{1,0 + 0,93} = 0,96$$

**Tabel 4. 5** Nilai *Precision*, *Recall*, dan *F1-score*

Kelas \ Metrik	<i>Precision</i>	<i>Recall</i>	<i>F1-score</i>
Beresiko	0,93	0,87	0,89
Kolesterol	0,93	0,93	0,93
Normal	0,93	1,0	0,96

Tabel 4.4 merupakan rekap hasil perhitungan nilai metrik precision, recall, f1-score. Nilai precision menunjukkan persentase prediksi positif yang benar dari semua prediksi positif. Nilai *precision* sistem ini diperoleh sebesar 93%. Nilai recall menunjukkan perhitungan persentase kasus positif yang benar-benar terdeteksi dari seluruh kasus positif sebenarnya. Sistem ini memperoleh nilai recall sebesar 93%. Sedangkan nilai f1 menunjukkan perhitungan rata-rata harmonik dari nilai precision dan nilai recall. F1-score adalah metrik yang berguna ketika ada ketidakseimbangan antara precision dan recall. Nilai f1-score diperoleh sebesar 92%.

Dalam sebuah sistem klasifikasi, akurasi juga merupakan suatu metrik evaluasi yang sangat penting dalam mengukur kemampuan sebuah model pembelajaran mesin. Berikut adalah perhitungan akurasi yang dilakukan berdasarkan persamaan (2.4).

$$\text{Akurasi} = \frac{42}{45} = 0,93$$

Sistem ini memperoleh akurasi sebesar 93%. Nilai akurasi menghitung persentase prediksi yang benar dari total data keseluruhan. Nilai akurasi yang diperoleh sudah dapat dikategorikan sebagai model yang memiliki performa yang baik. Meskipun demikian, masih dapat terjadi kesalahan dalam proses klasifikasi yang dapat disebabkan karena adanya kemiripan citra antar jenis. Hasil dari sistem tersebut tentunya tidak dapat dinyatakan mutlak untuk menentukan kadar kolesterol seseorang. Sistem tersebut dapat dijadikan alat bantu atau dapat digunakan masyarakat luas sebagai metode pendeteksian dini yang mudah dan cepat.

## **BAB 5**

### **KESIMPULAN DAN SARAN**

#### **5.1. Kesimpulan**

Adapun kesimpulan dari penelitian yang dilakukan, yaitu sebagai berikut.

- 1) Penggunaan model AlexNet untuk klasifikasi kadar kolesterol total melalui citra iris mata memperoleh hasil akurasi 93%.
- 2) Model terbaik diperoleh dengan kombinasi epoch 50, batch size 16 dan learning rate 0,00001 dengan waktu pelatihan rata-rata 10 detik per epoch.
- 3) Sistem mampu melakukan klasifikasi melalui perangkat mobile berbasis Android.
- 4) Sistem tersebut dapat dijadikan alat bantu atau dapat digunakan masyarakat luas sebagai metode pendeteksian dini yang mudah dan cepat.

#### **5.2. Saran**

Adapun saran yang dapat diterapkan pada penelitian-penelitian kedepannya, yaitu sebagai berikut.

- 1) Penelitian berikutnya dapat menggunakan metode yang berbeda agar dapat menjadi perbandingan.
- 2) Penelitian berikutnya dapat mengembangkan sistem yang dapat menunjukkan kadar kolesterol dengan lebih spesifik, dibandingkan hanya dalam kategori.
- 3) Penelitian berikutnya dapat merancang pendeteksian gejala penyakit lainnya melalui citra mata.

## DAFTAR PUSTAKA

- Alaslani, M. G., & Elrefaei, L. A. (2018). *Convolutional Neural Network Based Feature Extraction For Iris Recognition*. International Journal of Computer Science & Information Technology (IJCSIT), 10(2), 65-78, doi: 10.5121/ijcsit.2018.10206
- Alwanda, M. R., Ramadhan, R. P. K., & Alamsyah, D. (2020). Implementasi Metode Convolutional Neural Network Menggunakan Arsitektur LeNet-5 untuk Pengenalan Doodle. Jurnal Algoritme, 1(1), 45–56.
- Amini N., & Ameri A., (2020) *A Deep Learning Approach to Automatic Recognition of Arcus Senilis*. Journal of Biomedical Physics and Engineering, 10(4), 507- 512, doi:10.31661/jbpe.v0i0.2003-1080
- Anugrah, R. (2020). Sistem Pendukung Diagnosa Iridologi Dengan Menggunakan Pengolahan Citra Digital Metode Segmentasi Berbasis Region. Insan Pembangunan Sistem Informasi dan Komputer (IPSIKOM), 8(2), 10.58217/ipsikom.v8i2.175.
- Balashanmugam, T., Sengottaiyan, K., Kulandairaj, M. S., & Dang, H. (2022). *An Effective Model For The Iris Regional Characteristics And Classification Using Deep Learning Alex Network*. IET Image Processing, 17(1), 227-238, <https://doi.org/10.1049/ipr2.12630>
- Banowati, C., Novianty, A., & Setianingsih, C. (2019). *Cholesterol Level Detection Based on Iris Recognition Using Convolutional Neural Network Method*. 2019 IEEE Conference on Sustainable Utilization and Development in Engineering and Technologies (CSUDET), 116-121, <https://doi.org/10.1109/CSUDET47057.2019.9214690>
- Cahya, F. N., Hardi, N., Riana, D., & Hadiani, S. (2021). Klasifikasi Penyakit Mata Menggunakan Convolutional Neural Network (CNN). SISTEMASI: Jurnal Sistem Informasi, 10(3), 618-626, doi:10.32520/stmsi.v10i3.1248
- Clara, S., Prianto, D. L., Habsi, R. A., Lumbantobing, E. F., Chamidah, N. (2021). Implementasi Seleksi Fitur Pada Algoritma Klasifikasi Machine Learning Untuk Prediksi Penghasilan Pada Adult Income Dataset. Seminar Nasional Mahasiswa Ilmu Komputer Dan Aplikasinya (SENAMIKA), 741–747.

- Das, S., Roy, D., & Das, P. (2020). *Disease Feature Extraction and Disease Detection from Paddy Crops Using Image Processing and Deep Learning Technique*. In Computational Intelligence in Pattern Recognition: Proceedings of CIPR 2020 443-449.
- Fairudz, A. & Nisa, K. (2015). Pengaruh Serat Pangan terhadap Kadar Kolesterol Penderita Overweight. *Majority*, 4(8), 121-126.
- Hapsari, R. K., Miswanto, M., Rulaningtyas, R., & Suprajitno, H. (2021). *Identification of Diabetes Mellitus and High Cholesterol Based on Iris Image*. *Journal of Hunan University Natural Sciences*, 48(10), 151-160
- Hasanah, R. L. (2022). Deteksi Hiperkolesterolemia Melalui Iris Mata Menggunakan Image Processing dengan Metode K-Means Clustering dan Gray Level CoOccurrence Matrix (GLCM). *PRISMA FISIKA*, 10(3), 332-337.
- Khasanah, N., Salim, A., Afni, N., Komarudin, R., & Maulana, Y. I. (2022). Prediksi Kelulusan Mahasiswa dengan Metode Naive Bayes. *Technologia*, 13(3), 207–214.
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). *ImageNet Classification with Deep Convolutional Neural Networks*. *Advances in Neural Information Processing Systems 25 (NIPS 2012)*, 25.
- Kumar, S. V. M., Gunasundari, R., & Ezhilvathani, N. (2016). *Non-Invasive Measurement of Cholesterol Levels Using Eye Image Analysis Regression analysis*. *International Conference on Advances in Computational Intelligence and Communication (CIC 2016)*, 33 - 42.
- Naufal, M. F., Huda, S., Budilaksono, A., Yustisia, W. A., Arius, A. A., Miranti, F. A., & Prayoga, F. A. T. (2021). Klasifikasi Citra Game Batu Kertas Gunting Menggunakan Convolutional Neural Network. *Techno.Com: Jurnal Teknologi Informasi*, 20(1), 166–174. <https://doi.org/10.33633/tc.v20i1.4273>
- Novamizanti, Ledy. (2022). Cholesterol Image. *Telkom University Dataverse*, V3. <https://doi.org/10.34820/FK2/RYPQ5EN>
- Nurhusni, S. A., Adam, R. I., & Carudin. 2021. Klasifikasi Kadar Kolesterol Menggunakan Ekstraksi Ciri Moment Invariant dan Algoritma K-Nearest Neighbor (KNN). *Journal of Applied Informatics and Computing (JAIC)*, 5(02), 169-175.
- Omran, E. M., Soliman, R. F., Salah, M. M., Napoleon, S. A., El-Rabaie, E. M.,



- AbdeElnaby, M. M., Ismail, N. A., Eisa, A. A., & El-samie, F. A. (2020). *Noisy Iris Recognition Based on Deep Neural Network*. Menoufia J. of Electronic Engineering Research (MJEER), 29(2), 64-69.
- Padilla, R., Passos, W. L., Dias, T. L. B., Netto, S. L., & Da Silva, E. A. B. (2021). A Comparative Analysis of Object Detection Metrics with a Companion Open-Source Toolkit. *Electronics*, 10(3), 1–28. <https://doi.org/10.3390/electronics10030279>
- Prakosa, A. B., Hendry, & Tanone, R. (2023). Implementasi Model Deep Learning Convolutional Neural Network (CNN) Pada Citra Penyakit Daun Jagung Untuk Klasifikasi Penyakit Tanaman. *Jurnal Pendidikan Teknologi Informasi (JUKANTI)*, 6(1), 107-116.
- Putri, M. S., & Anita, D. C. (2020). Literature Review Kadar Kolesterol dan Kadar Gula Darah dengan Kejadian Penyakit Jantung Koroner. Universitas ‘Aisyiyah.
- Rochmawati, N., Hidayati, H. B., Yamasari, Y., Peni, H., Tjahyaningtjas, A., Yustanti, W., & Prihanto, A. (2021). Analisa Learning rate dan Batch size Pada Klasifikasi Covid Menggunakan Deep learning dengan Optimizer Adam. *Journal Information Engineering and Educational Technology*.
- Saputra, A., Broto, W., & Budi, R. L., (2017). Deteksi Kadar Kolesterol Melalui Iris Mata Menggunakan Image Processing Dengan Metode Jaringan Syaraf Tiruan Dan Gray Level Co-Occurrence Matrix (GLCM). *Prosiding Seminar Nasional Fisika (E-Journal)*, 6, doi: 10.21009/03.SNF2017.02.CIP.09
- Siddik, M. A., Novamizanti, L., & Ramatryana, I. N. A. (2019). Deteksi Level Kolesterol melalui Citra Mata Berbasis HOG dan ANN. *ELKOMIKA*, 7(2), 284- 296
- Susanti, N., & Ikhwan (2022). Deteksi Dini Kadar Gula Darah Sewaktu, Kolesterol Total dan Asam Urat pada Masyarakat Kecamatan Deli Tua. *Shihatuna: Jurnal Pengabdian Kesehatan Masyarakat*, 2(1), 12-22
- Waluya, D. P., Suhartono, E., & Safitri, I. (2019). Deteksi Kolesterol Menggunakan Citra Mata Berbasis Local Binary Pattern (LBP) Dan Support Vector Machine (SVM). *e-Proceeding of Engineering*, 6(2), 3814-3821
- Zhang, X., Pan, W., & Xiao, P. (2018). *In-Vivo Skin Capacitive Image Classification Using AlexNet Convolution Neural Network*. 2018 IEEE 3rd International Conference on Image, Vision and Computing (ICIVC).

doi:10.1109/icivc.2018.8492860

## LAMPIRAN

### Lampiran 1. Dokumentasi Pengumpulan Data

