

**KLASIFIKASI ZONA TANAM MANGROVE DESA PULAU
SEMBILAN MENGGUNAKAN GAUSSIAN PROCESS
REGRESSION FOR CLASSIFICATION (GPRC)**

SKRIPSI

HERZINANDA PUTRA

201402043



**PROGRAM STUDI TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA
MEDAN
2024**

**KLASIFIKASI ZONA TANAM MANGROVE DESA PULAU SEMBILAN
MENGGUNAKAN GAUSSIAN PROCESS REGRESSION FOR
CLASSIFICATION (GPRC)**

SKRIPSI

Diajukan untuk melengkapi tugas dan memenuhi syarat memperoleh ijazah Sarjana
Teknologi Informasi

**HERZINANDA PUTRA
201402043**



**PROGRAM STUDI S1 TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA
MEDAN
2024**

PERSETUJUAN

Judul : KLASIFIKASI ZONA TANAM MANGROVE DESA
 PULAU SEMBILAN MENGGUNAKAN GAUSSIAN
 PROCESS REGRESSION FOR CLASSIFICATION
 (GPRC)
 Kategori : SKRIPSI
 Nama Mahasiswa : HERZINANDA PUTRA
 Nomor Induk Mahasiswa : 201402043
 Program Studi : SARJANA (S1) TEKNOLOGI INFORMASI
 Fakultas : ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
 UNIVERSITAS SUMATERA UTARA

Medan, 4 Juli 2024

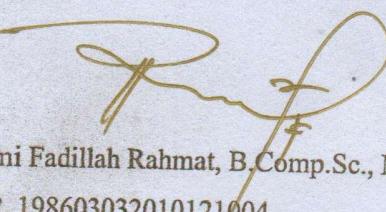
Komisi Pembimbing:

Pembimbing 2,

Pembimbing 1,



Umaya Ramadhani P. Nst, S.TI, M.Kom. Romi Fadillah Rahmat, B.Comp.Sc., M.Sc.
 NIP. 199104112021022001 NIP. 198603032010121004



Diketahui/disetujui oleh

Program Studi S1 Teknologi Informasi

Ketua,



Dedy Arisandi S.T., M.Kom.
 NIP. 197908312009121002

PERNYATAAN

KLASIFIKASI ZONA TANAM MANGROVE DESA PULAU SEMBILAN
MENGGUNAKAN GAUSSIAN PROCESS REGRESSION FOR
CLASSIFICATION (GPRC)

SKRIPSI

Saya mengakui bahwa skripsi ini merupakan hasil karya saya sendiri, kecuali beberapa kutipan dan ringkasan yang masing-masing telah disebutkan sumbernya.

Medan, 4 Juli 2024



Herzinanda Putra
201402043

UCAPAN TERIMA KASIH

Dengan mengucapkan puji dan syukur kepada Allah Yang Maha Pengasih lagi Penyayang atas segala rahmat dan karunia-Nya yang telah melimpahkan, penulis ingin menyampaikan terima kasih atas dukungan dan bantuan yang diberikan dalam menyelesaikan tugas akhir ini sebagai syarat kelulusan dan perolehan gelar Sarjana Komputer di Program Studi S1 Teknologi Informasi, Universitas Sumatera Utara. Selama proses penulisan, penulis merasa terbantu oleh berbagai pihak baik secara langsung maupun tidak langsung. Oleh karena itu, penulis ingin mengucapkan terima kasih kepada:

1. Keluarga tercinta, khususnya Ibu saya, Hazirni, serta Ayah saya, Alm. Herman Rasul, yang telah memberikan dukungan, semangat, dan cinta tanpa henti selama proses penyelesaian tugas akhir ini.
2. Diri sendiri yang telah gigih dan tidak mengenal lelah dalam menghadapi tantangan dan menyelesaikan tugas akhir ini.
3. Bapak Dr. Muryanto Amin, S.Sos, M.Si. yang merupakan Rektor Universitas Sumatera Utara.
4. Ibu Dr. Maya Silvi Lydia B.Sc., M.Sc. selaku Dekan Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Sumatera Utara.
5. Bapak Dedy Arisandi ST., M.Kom. selaku Ketua Prodi S1 Teknologi Informasi Universitas Sumatera Utara dan Dosen Penguji I.
6. Bapak Ivan Jaya S.Si., M.Kom. selaku Sekretaris Prodi S1 Teknologi Informasi Universitas Sumatera Utara dan Dosen Penguji II.
7. Bapak Romi Fadillah Rahmat, B.Comp.Sc., M.Sc. selaku Dosen Pembimbing I dan Ibu Umaya Ramadhani Putri Nasution, S.TI., M.Kom., selaku Dosen Pembimbing II yang telah meluangkan waktu untuk membimbing, memberikan kitikan, masukan, dan saran kepada penulis selama proses penggeraan skripsi ini yang tidak dapat dinilai harganya.
8. Bapak dan Ibu Dosen di Program Studi S1 Teknologi Informasi, Universitas Sumatera Utara, yang telah memberikan ilmu dan pengalaman yang berharga bagi penulis.

9. Bang Rhama Permadi Ahmad, Bang Ahmad Fadhil, dan Bang Riyandi Syahputra, Bang Farhan Alzuhri Nst yang telah banyak membantu penulis tumbuh dan berkembang selama berkuliah di Fasilkom-TI USU.
10. Bang Iqbal Fakhriya yang telah banyak membantu penulis baik dalam melakukan penelitian maupun dalam hal lain yang tidak bisa penulis sebutkan satu persatu.
11. Christine Amanda, Lulu Syifa Kamilah, Adinda Khairani, Bang Geylfedra yang telah banyak memberikan masukan dan saran tentang penulisan skripsi kepada penulis
12. Teman-teman GDSC USU, yang telah memberikan pengalaman baru yang berharga dalam peningkatan keahlian penulis.
13. Teman-teman seerbimbingan, M. Arief Fadhlwan, Diah Paramitha, Cynthia Yapiter, Levina Gunawan, Davita Candra, Felix Kurnia Salim yang telah berjuang bersama dalam menyelesaikan tugas akhirnya.
14. Teman-teman Modentca, Nuraini Aqikah Putri, Andrian Putra Ramadan, Miftahul Muthmainnah Rizani, dan Athaya Sabina, yang telah memberikan kesempatan penulis untuk mengaplikasikan pengetahuan yang didapatkan ketika perkuliahan.

Penulis menyadari bahwa penelitian ini belum mencapai kesempurnaan dan masih memiliki ruang untuk peningkatan di masa mendatang. Oleh karena itu, penulis mengundang kritik dan saran konstruktif untuk meningkatkan kualitas penelitian ini. Penulis berharap hasil dari penelitian ini dapat memberikan manfaat yang signifikan bagi pembaca dan semua pihak yang terlibat.

Medan, 4 Juli 2024



Herzinanda Putra

ABSTRAK

Dalam 20 tahun terakhir, hutan mangrove terus mengalami deforestasi yang cukup signifikan. Provinsi Sumatera Utara, salah satu provinsi yang memiliki luas hutan mangrove terbesar di Indonesia, mencapai 57.490 hektar, yang tersebar di Kawasan Pantai Timur Sumatera. Desa Pulau Sembilan, di Kecamatan Pangkalan Susu, Kabupaten Langkat, Sumatera Utara, merupakan salah satu kawasan dengan mangrove yang melimpah, dengan ketebalan bervariasi dari 100m – 1700m. Namun, tekanan dari aktivitas manusia seperti penebangan liar dan akumulasi limbah, serta perubahan iklim global, mengancam kualitas dan keberlanjutan ekosistem ini. Oleh karena itu, diterapkan metode *Gaussian Process Regression for Classification (GPRC)* guna mengklasifikasikan zona tanam mangrove di Desa Pulau Sembilan, Kabupaten Langkat, Sumatera Utara. Menggunakan data kandungan air dengan berbagai fitur lingkungan, model GPRC dilatih dengan tiga kernel berbeda, yaitu *Radial Basis Function (RBF)*, *Matern*, dan *Rational Quadratic*. Proses pelatihan dilakukan melalui 25 iterasi untuk setiap kernel, dan hasil dievaluasi menggunakan metrik akurasi, F1-Score, precision, dan recall. Hasilnya menunjukkan bahwa *kernel Rational Quadratic* mencapai akurasi tertinggi sebesar 98,29%, diikuti *kernel Matern* sebesar 98%, dan *kernel RBF* sebesar 96,58%. Pada pengujian, kernel *Rational Quadratic* juga menunjukkan performa terbaik dengan akurasi 98,15%. Metode GPRC efektif untuk klasifikasi zona tanam mangrove dengan kernel *Rational Quadratic* memberikan hasil paling optimal. Penelitian ini memberikan kontribusi dalam pengelolaan zona tanam mangrove dan dapat menjadi referensi untuk penelitian lanjutan dalam klasifikasi menggunakan metode GPRC.

Kata kunci : *Gaussian Process Regression for Classification*, zona tanam mangrove, *Radial Basis Function*, *Matern*, *Rational Quadratic*

**CLASSIFICATION OF MANGROVE PLANTING ZONES IN PULAU
SEMBILAN VILLAGE USING GAUSSIAN PROCESS REGRESSION FOR
CLASSIFICATION (GPRC)**

ABSTRACT

Over the past two decades, mangrove forests have undergone substantial deforestation. North Sumatra Province, as one of Indonesia's largest repository of mangrove forests, covering approximately 57,490 hectares, primarily situated along the East Coast of Sumatra. Notably, Pulau Sembilan Village, nestled within Pangkalan Susu District, Langkat Regency, North Sumatra, emerges as a notable hub of mangrove growth, featuring a thickness range spanning from 100m to 1700m. Despite its considerable expanse, this ecosystem faces imminent threats posed by human-induced activities such as illicit logging, waste accumulation, and the overarching impacts of global climate change. Consequently, this study employs the Gaussian Process Regression for Classification (GPRC) methodology to delineate mangrove planting zones within Pulau Sembilan Village, Langkat Regency, North Sumatra. Leveraging water content data alongside diverse environmental features, the GPRC model undergoes training employing three distinct kernels: Radial Basis Function (RBF), Matern, and Rational Quadratic. The training regimen entails 25 iterations per kernel, with performance assessments conducted via accuracy, F1-Score, precision, and recall metrics. Outcomes indicate the Rational Quadratic kernel yielding the highest accuracy at 98.29%, followed by the Matern kernel at 98%, and the RBF kernel at 96.58%. Subsequent testing underscores the superiority of the Rational Quadratic kernel, attaining an accuracy rate of 98.15%. These findings underscore the efficacy of GPRC in classifying mangrove planting zones, with the Rational Quadratic kernel emerging as particularly adept. Ultimately, this research contributes valuable insights towards mangrove planting zone management and offers a robust foundation for future investigations into GPRC-based classification methodologies.

Keyword : Gaussian Process Regression for Classification, mangrove planting zone, Radial Basis Function, Matern, Rational Quadratic

DAFTAR ISI

PERSETUJUAN	iii
PERNYATAAN	iv
UCAPAN TERIMA KASIH	v
ABSTRAK	vii
<i>ABSTRACT</i>	viii
DAFTAR ISI	ix
DAFTAR TABEL	xi
DAFTAR GAMBAR	xii
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian	4
1.4 Batasan Masalah	4
1.5 Manfaat Penelitian	5
1.6 Metodologi Penelitian	5
1.7 Sistematika Penulisan	6
BAB 2 LANDASAN TEORI	8
2.1 Ekosistem Mangrove	8
2.2 Zona Tanam Mangrove	9
2.3 Kandungan Air	10
2.4 Gaussian Process	12
2.5 Gaussian Process Regression	12
2.6 Gaussian Process Regression for Classification (GPRC)	13

2.7	Fungsi Kernel	14
2.8	Metrik Evaluasi	16
2.9	Penelitian Terdahulu	19
BAB 3 ANALISIS DAN PERANCANGAN SISTEM		25
3.1	Data	25
3.2	Analisis Sistem	26
3.3	Perancangan Antarmuka Sistem	35
BAB 4 IMPLEMENTASI DAN PENGUJIAN SISTEM		42
4.1	Implementasi Sistem	42
4.2	Pengujian Sistem	54
4.3	Implementasi Tampilan Antarmuka	59
BAB 5 KESIMPULAN DAN SARAN		60
5.1	Kesimpulan	60
5.2	Saran	60
DAFTAR PUSTAKA		62

DAFTAR TABEL

Tabel 2.1 <i>Confusion Matrix</i> untuk Klasifikasi Tiga Kelas	17
Tabel 4.2 Penelitian Terdahulu	20
Tabel 4.1 Hasil <i>training</i> dengan kernel RBF	48
Tabel 4.2 Hasil <i>training</i> dengan kernel Matern	50
Tabel 4.3 Hasil <i>training</i> dengan kernel Rational Quadratic	52
Tabel 4.4 Perbandingan Hasil <i>training</i> kernel RBF, Matern, dan Rational Quadratic	54
Tabel 4.5 Perbandingan nilai actual dan predicted dari masing-masing kernel	55
Tabel 4.6 Akumulasi nilai <i>actual</i> dan <i>predicted</i> dengan tiga kernel	56
Tabel 4.7 Hasil pengujian model GPRC dengan 3 kernel berbeda	56

DAFTAR GAMBAR

Gambar 2.1	Visualisasi Zona Tanam Mangrove (Waycott et al., 2011).....	10
Gambar 2.2	Model Grafis <i>Gaussian Process Regression</i>	13
Gambar 3.1	Arstektur Umum Model Klasifikasi GPRC.....	27
Gambar 3.2	<i>Pseudocode</i> Proses <i>Data Cleaning</i>	29
Gambar 3.3	Proses <i>Data Splitting</i> Menjadi Data Latih dan Data Uji	31
Gambar 3.4	<i>Pseudocode</i> Inisialisasi Kernel	312
Gambar 3.5	<i>Pseudocode</i> training model sebanyak 25 kali iterasi.....	31
Gambar 3.6	Rancangan tampilan antarmuka halaman home	36
Gambar 3.7	Rancangan tampilan antarmuka halaman input dataset training	36
Gambar 3.8	Rancangan tampilan antarmuka halaman loading training	36
Gambar 3.9	Rancangan tampilan antarmuka halaman hasil training	36
Gambar 3.10	Rancangan Tampilan Antarmuka Halaman Input File Testing.....	36
Gambar 4.1	Tampilan Aplikasi Postman Saat Menguji <i>Endpoint API</i>	44
Gambar 4.2	Tampilan Antarmuka Halaman <i>Home</i>	44
Gambar 4.3	Tampilan Antarmuka Halaman Input <i>File Training</i>	45
Gambar 4.4	Tampilan Antarmuka Halaman Tabel Hasil <i>Training</i>	46
Gambar 4.5	Tampilan Antarmuka Grafik Hasil <i>Training</i>	46
Gambar 4.6	Tampilan Antarmuka Halaman <i>Input File Testing</i>	47
Gambar 4.7	Tampilan Antarmuka Halaman Hasil <i>Testing</i>	47
Gambar 4.8	Grafik Hasil <i>Training</i> model GPRC dengan <i>Kernel RBF</i>	49
Gambar 4.9	Grafik Hasil <i>Training</i> Model GPRC dengan <i>Kernel Matern</i>	51
Gambar 4.10	Grafik Hasil <i>Training</i> Model GPRC dengan <i>Kernel RQ</i>	53
Gambar 4.11	<i>Confusion Matrix</i> Hasil Pengujian dengan <i>Kernel RBF</i>	57
Gambar 4.12	<i>Confusion Matrix</i> Hasil Pengujian dengan <i>Kernel Matern</i>	58
Gambar 4.13	<i>Confusion Matrix</i> Hasil Pengujian dengan <i>Kernel RQ</i>	59

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Hutan mangrove merupakan sekumpulan pohon dan semak tropis yang berada di zona pasang surut di sekitar pantai pada wilayah tropis dan subtropis (Jia et al., 2019; Mori et al., 2015). Hutan mangrove memiliki fungsi sebagai habitat pembibitan bagi ikan-ikan muda dan memiliki pengaruh yang signifikan terhadap struktur komunitas ikan di terumbu karang yang berdekatan (Mumby et al., 2004).

Ekosistem mangrove memiliki peranan penting baik secara ekonomis dan ekologis. Ekosistem mangrove berperan sebagai tempat utama untuk perkembangbiakan ikan, sumber kayu yang dapat diperbarui, serta penghalang alami terhadap erosi pantai, badai, dan bencana alam (Alongi, 2002; Mahmuda et al., 2023). Hutan mangrove berperan signifikan sebagai penyimpan karbon dalam jumlah besar untuk periode yang panjang, sehingga berkontribusi pada pengurangan emisi gas rumah kaca serta mendukung inisiatif mitigasi perubahan iklim (Adame et al., 2021).

Dalam 20 tahun terakhir, hutan mangrove terus mengalami deforestasi yang cukup signifikan. Indonesia, sebagai negara dengan luas hutan mangrove terbesar di dunia, dengan luasan sekitar 26% hingga 29% dari total luas hutan mangrove global, mengalami tingkat deforestasi bersikar antara 0,26% hingga 0,66% per tahun (Hamilton & Casey, 2016). Angka deforestasi ini lebih tinggi dibandingkan dengan rata-rata deforestasi di wilayah Asia Tenggara dari tahun 2000 hingga 2012, yakni sebesar 0,18% per tahun (Richards & Friess, 2016). Ini menandakan bahwa hutan mangrove di Indonesia dihadapkan pada risiko penuruan kualitas dan keberlangsungan ekosistem mangrove yang perlu diperhatikan.

Provinsi Sumatera Utara adalah salah satu provinsi dengan luas hutan mangrove terbesar di Indonesia. Menurut data dari Direktorat Konservasi Tanah dan Air (2021), luas hutan mangrove di Provinsi Sumatera Utara mencapai 57.490 hektar. Mangrove tersebut tersebar di daerah Kawasan Pantai Timur Sumatera. Salah satu kawasan yang banyak ditumbuhi oleh mangrove adalah Desa Pulau Sembilan, yang

terletak di Kecamatan Pangkalan Susu, Kabupaten Langkat, Provinsi Sumatera Utara. Di Desa Pulau Sembilan, hampir seluruh garis pantai ditumbuhi mangrove dengan ketebalan yang bervariasi antara 100 hingga 1700 meter (Muhtadi et al., 2016). Namun, meskipun Desa Pulau Sembilan memiliki luas hutan mangrove yang substansial, tekanan dari aktivitas manusia seperti penebangan liar dan akumulasi limbah, bersamaan dengan perubahan iklim global, dapat menyebabkan penurunan kualitas dan keberlanjutan ekosistem ini (Dinas Kelautan dan Perikanan (DKP) Provinsi Sumatera Utara, 2014).

Sebanyak 70% dari kerusakan hutan mangrove yang dilaporkan disebabkan oleh peristiwa alam yang jarang terjadi namun memiliki intensitas yang tinggi, seperti siklon tropis dan ekstrem iklim (Sippo et al., 2018). Aktivitas manusia seperti perubahan penggunaan lahan mangrove menjadi budidaya perikanan dan pertanian menjadi penyebab kerusakan 62% total hutan mangrove secara global antara tahun 2000 dan 2016 (Goldberg et al., 2020). Tingginya angka kerusakan mangrove secara global ini menunjukkan pentingnya upaya pelestarian dan pengelolaan yang efektif untuk memastikan keberlangsungan hidup hutan mangrove dan menjaga keberlanjutan ekosistem pesisir.

Untuk mengatasi tantangan dalam pelestarian hutan mangrove, khususnya di Desa Pulau Sembilan, salah satu solusi yang dapat diimplementasikan adalah dengan mengklasifikasikan zona tanam tumbuhan mangrove. Klasifikasi zona tanam mangrove di Desa Pulau Sembilan menjadi langkah awal yang sangat penting dalam upaya pelestarian hutan mangrove. Dengan informasi yang diperoleh dari klasifikasi ini, petani mangrove dan pelestari hutan mangrove dapat menanam mangrove secara lebih efektif sesuai dengan zona yang tepat.

Berbagai macam metode dalam lingkup *machine learning* telah berhasil melakukan pengklasifikasian secara akurat. Salah satunya adalah metode *Gaussian Process Regression for Classification (GPRC)*. GPRC atau yang biasa disebut dengan Gaussian Process Classifier (GPCs) adalah model klasifikasi kernel yang menggunakan pendekatan probabilistik Bayesian untuk mempelajari fungsi laten dan *hyperparameter* dari data, dengan menggunakan *Gaussian process prior* (Hyun-Chul Kim & Ghahramani, 2006). Salah satu keunggulan dari metode GPRC adalah dapat menangani dataset besar secara efisien dengan melakukan proyeksi linear terhadap semua titik data (Banerjee et al., 2013). GPRC juga efektif untuk dataset kecil karena kemampuannya

dalam memprediksi kelas secara efisien menggunakan pendekatan Bayesian dan integrasi terhadap ketidakpastian dalam *prior* (Williams & Barber, 1998). Dengan memanfaatkan keunggulan ini, GPRC diharapkan mampu menangani kompleksitas data mangrove dan menghasilkan klasifikasi yang akurat.

Beragam penelitian telah dilakukan untuk mendalami ekologi dan konservasi hutan mangrove, sekaligus mengeksplorasi penggunaan teknologi dan metode analisis seperti GPRC. Pada tahun 2021, dilakukan penelitian untuk mengembangkan perangkat monitoring zona tanam mangrove berbasis arduino. Lubis (2021) berhasil mengembangkan suatu perangkat pemantauan zona tanam mangrove di Desa Pulau Sembilan berbasis arduino yang terintegrasi dengan layanan berbasis web. Perangkat ini dirancang untuk memantau parameter kandungan air, meliputi kadar pH, oksigen terlarut, suhu udara, suhu air, ketinggian air, dan potensial oksidasi-reduksi (ORP), yang dipasang di dalam zona mangrove. Penelitian ini berhasil mengumpulkan sebanyak 2.342 data kandungan air di Desa Pulau Sembilan dalam format Comma Separated Value (CSV). Data yang terkumpul ini akan menjadi *dataset* utama yang akan digunakan dalam penelitian ini.

Selain penggunaan perangkat teknologi arduino, penggunaan *machine learning* dalam masalah ekologi dan konservasi hutan mangrove telah menjadi solusi yang efektif dan efisien. Maulana (2021) menggunakan algoritma *Long Short Term Memory (LSTM)* untuk mengidentifikasi tingkat kelayakan hidup tanaman mangrove berdasarkan data kandungan air di Desa Pulau Sembilan. Berdasarkan hasil yang dicapai pada penelitian ini, algoritma LSTM mampu mengidentifikasi tingkat kelayakan hidup tanaman mangrove dengan tingkat akurasi mencapai 99%. Hasil ini menunjukkan potensi besar pendekatan *machine learning* dalam studi ekologi mangrove ini.

Dengan landasan tersebut dan penelitian-penelitian terdahulu, penulis melakukan penelitian untuk menghasilkan sebuah aplikasi berbasis website dengan metode klasifikasi *Gaussian Process Regression for Classification (GPRC)* untuk membantu petani mangrove dan masyarakat sekitar dalam menanam mangrove sesuai dengan zona tanamnya. Penelitian ini diberi judul, “**KLASIFIKASI ZONA TANAM MANGROVE DESA PULAU SEMBILAN MENGGUNAKAN GAUSSIAN PROCESS REGRESSION FOR CLASSIFICATION (GPRC).**”

1.2 Rumusan Masalah

Deforestasi hutan mangrove di Indonesia, khususnya di Desa Pulau Sembilan, Sumatera Utara, telah menyebabkan penurunan kualitas ekosistem yang vital bagi kehidupan pesisir. Ancaman dari aktivitas manusia dan perubahan iklim semakin memperburuk kondisi ini, mengakibatkan berkurangnya habitat penting bagi berbagai spesies dan fungsi ekosistem lainnya. Pengelolaan zona tanam mangrove yang tepat menjadi krusial untuk konservasi dan pemanfaatan berkelanjutan. Proses manual untuk mengklasifikasikan zona tanam seringkali memakan waktu dan kurang konsisten. Oleh karena itu, diperlukan metode yang efektif dan efisien seperti *Gaussian Process Regression for Classification (GPRC)* untuk mengidentifikasi dan mengklasifikasikan zona tanam mangrove secara akurat. Penelitian ini berfokus pada penerapan berbagai kernel dalam metode GPRC untuk menentukan *kernel* yang paling efektif dalam klasifikasi zona tanam mangrove, guna mendukung upaya pelestarian hutan mangrove di Desa Pulau Sembilan.

1.3 Tujuan Penelitian

Tujuan penelitian ini adalah untuk menerapkan teknik *Gaussian Process Regression for Classification (GPRC)* dalam klasifikasi zona tanam tumbuhan mangrove di Desa Pulau Sembilan, Kecamatan Pangkalan Susu, Kabupaten Langkat, Sumatera Utara.

1.4 Batasan Masalah

Batasan Masalah ditentukan untuk menghindari pembahasan yang terlalu meluas dalam penelitian. Berikut merupakan Batasan masalah untuk penelitian ini:

1. Penelitian ini mengklasifikasikan zona tanam mangrove berdasarkan data kandungan air di Desa Pulau Sembilan, Kabupaten Langkat, Sumatera Utara.
2. Penelitian ini menerapkan metode *Gaussian Process Regression for Classification (GPRC)*.
3. Data yang dipergunakan untuk pelatihan dan pengujian menggunakan format file csv.

4. Fitur yang terdapat dalam dataset meliputi ketinggian air, suhu udara, suhu air, kelembapan udara, pH, total dissolved solids (TDS), oksidasi-reduksi potensial (ORP), tingkat oksigen terlarut (DO), dan lokasi.
5. Hasil klasifikasi akan membagi data menjadi tiga kelas, yaitu *seaward zone*, *mid zone*, dan *landward zone*.

1.5 Manfaat Penelitian

Dampak positif yang dapat dihasilkan dari penelitian ini meliputi:

1. Memberikan panduan bagi petani mangrove dan masyarakat dalam menetapkan lokasi yang optimal untuk penanaman tumbuhan mangrove.
2. Mengimplementasikan klasifikasi jenis mangrove berdasarkan zonasi alami mangrove menggunakan metode *Gaussian Process Regression for Classification (GPRC)*.
3. Menambah pemahaman penulis tentang penerapan metode *Gaussian Process Regression for Classification (GPRC)*.
4. Menjadi referensi penelitian – penelitian berikutnya dalam melakukan klasifikasi khususnya dengan metode *Gaussian Process Regression for Classification (GPRC)*.

1.6 Metodologi Penelitian

Berikut adalah tahapan-tahapan yang terdapat dalam penelitian ini.

2.3.1 Studi Literatur

Tahap studi literatur ini dilaksanakan dengan mengumpulkan referensi-referensi yang relevan dari penelitian sebelumnya yang membahas tentang klasifikasi zona tanam mangrove dan penggunaan metode *Gaussian Process Regression for Classification (GPRC)*. Rujukan penelitian bersumber dari literatur akademis, jurnal ilmiah, artikel riset, skripsi, dan sumber-sumber terpercaya lainnya.

2.3.2 Analisis Permasalahan

Setelah melakukan studi literatur, ditemukan berbagai tantangan dan hambatan yang muncul baik pada tingkat topik maupun dalam pelaksanaan penelitian-penelitian

sebelumnya. Dari hasil studi tersebut, dapat diidentifikasi permasalahan yang perludiselesaikan melalui penelitian ini.

2.3.3 Perancangan Sistem

Dengan merujuk pada studi literatur dan menganalisis masalah, dirumuskan rancangan sistem dalam bentuk arsitektur umum untuk model klasifikasi yang akan dikembangkan dalam penelitian ini.

2.3.4 Implementasi

Setelah merumuskan rancangan sistem yang sesuai untuk penelitian ini, langkah selanjutnya adalah mengimplementasikan rancangan sistem yang telah disusun pada tahap sebelumnya.

2.3.5 Pengujian Sistem

Pada fase ini, dilakukan pengujian dan evaluasi terhadap sistem yang telah dibuat, dengan membandingkan hasil yang diperoleh dengan standar yang diharapkan. Tahap ini bertujuan untuk memastikan bahwa sistem yang dikembangkan menggunakan metode GPRC dapat beroperasi dengan baik dan sesuai dengan ekspektasi yang telah ditetapkan.

2.3.6 Dokumentasi dan Penyusunan Laporan

Langkah terakhir adalah melakukan dokumentasi dan menyusun laporan. Pada tahap ini, dilakukan penyusunan laporan lengkap beserta dokumentasi dari awal hingga akhir proses penelitian.

1.7 Sistematika Penulisan

Penelitian ini disusun dalam lima bab dengan penjelasan sebagai berikut:

BAB 1 : PENDAHULUAN

Bab satu memuat penjelasan tentang latar belakang penelitian, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, metodologi penelitian, dan sistematika penulisan.

BAB 2 : LANDASAN TEORI

Di bab dua, akan dijelaskan mengenai teori-teori yang terkait dengan penelitian ini, termasuk penjelasan tentang ekosistem mangrove, pembagian zona tanam mangrove, serta penjelasan tentang metode GPRC.

BAB 3 : ANALISIS DAN PERANCANGAN SISTEM

Bab tiga berisi penjelasan tentang proses analisis dan perancangan sistem klasifikasi zona tanam mangrove dengan metode GPRC. Penjelasan ini termasuk tentang tahap-tahap analisis data, perancangan model, serta perancangan sistem web klasifikasi zona tanam mangrove.

BAB 4 : IMPLEMENTASI DAN PENGUJIAN SISTEM

Bab ini memuat penjelasan tentang penerapan hasil analisis dan rancangan sistem yang telah dibahas pada bab 3. Bab ini juga akan menjelaskan hasil klasifikasi zona tanam mangrove dengan metode GPRC.

BAB 5 : KESIMPULAN DAN SARAN

Bab lima merangkum dan menyajikan kesimpulan dari hasil seluruh proses penelitian yang telah dilakukan, serta memberikan saran untuk pengembangan penelitian di masa mendatang agar dapat ditingkatkan lebih lanjut.

BAB 2

LANDASAN TEORI

2.1 Ekosistem Mangrove

Ekosistem mangrove dianggap sebagai salah satu ekosistem yang paling produktif di Bumi, yang menyediakan jasa lingkungan, manfaat ekologi, dan sumber penghidupan (Ho & Mukul, 2021). Tingkat produksi ekosistem mangrove sebanding dengan hutan hujan tropis basah dan terumbu karang yang menyumbang 10-15% terhadap penyimpanan karbon sedimen pasir (Alongi, 2014). Mangrove memiliki adaptasi khusus dan fleksibilitas yang tinggi, memungkinkan mereka bertahan dalam kondisi salinitas yang bervariasi, banjir berkala, dan perubahan ketersediaan nutrisi, sehingga dapat tumbuh dan berkembang di lingkungan pesisir yang dinamis (Feller et al., 2010).

Ekosistem mangrove berperan penting dalam aspek ekologis terhadap makhluk hidup di sekitarnya. Sebagai tempat pembibitan, mangrove merupakan lokasi penting bagi ikan dan udang-udangan, dari fase pasca-larva hingga fase juvenil dan dewasa kecil (Robertson & Duke, 1987). Selain berperan sebagai habitat pembibitan, mangrove juga memberikan dampak yang signifikan terhadap struktur komunitas ikan di lingkungan sekitarnya, termasuk terumbu karang yang berdekatan (Mumby et al., 2004). Selain itu, habitat mangrove juga memberikan kesempatan penting bagi berbagai spesies, termasuk ikan, udang-udangan, burung, reptil, dan mamalia untuk mencari makan dan berkembang biak (Malik et al., 2015). Oleh karena itu, melalui berbagai peran ekologisnya, mangrove tidak hanya menjadi elemen penting dalam menjaga keanekaragaman hayati, tetapi juga dalam mempertahankan keseimbangan ekosistem pesisir secara keseluruhan.

Hutan mangrove juga telah menjadi sumber daya ekonomis yang berharga, memberikan manfaat yang penting bagi masyarakat dan lingkungan. Mangrove memberikan tempat bagi pembibitan dan perkembangbiakan, menyediakan kayu yang dapat diperbarui, serta memberikan perlindungan terhadap erosi pantai (Alongi, 2002). Secara ekonomis mangrove telah memberikan dampak yang cukup signifikan bagi masyarakat di sekitarnya. Di Kabupaten Takalar, Sulawesi Selatan, mangrove telah

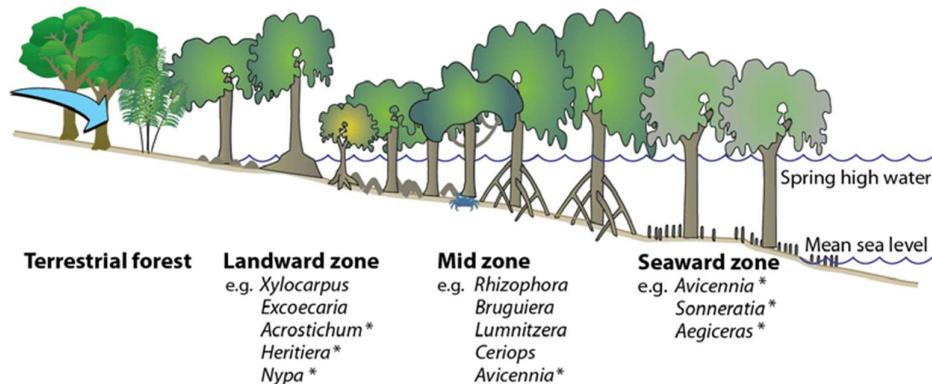
menjadi produk dan layanan ekosistem yang mendukung penghidupan masyarakat lokal, dengan nilai ekonomi tahunan berkisar antara US\$4.370 hingga US\$10.597 (Malik et al., 2015). Di Galapagos, mangrove memberikan manfaat berupa penyimpanan karbon, dukungan bagi perikanan skala kecil, dan mendukung sektor pariwisata, dengan nilai ekonomi yang tinggi, mencapai US\$16.958 per hektar (Tanner et al., 2019).

Walaupun hutan mangrove memiliki manfaat yang melimpah, namun menghadapi ancaman serius dari deforestasi yang disebabkan oleh aktivitas manusia dan perubahan lingkungan. Eksplorasi hutan mangrove oleh manusia dan proyeksi kenaikan permukaan laut di masa depan menjadi faktor utama yang mengancam kelangsungan hidup mereka (Sarker et al., 2016). Perubahan dalam salinitas air, aktivitas penebangan berlebihan, dan praktik perikanan ilegal juga merupakan ancaman signifikan terhadap layanan ekosistem mangrove (Gnansounou et al., 2022). Oleh karena itu, perlunya tindakan segera untuk melindungi ekosistem mangrove dari degradasi lebih lanjut, mengingat peran penting mangrove dalam penyerapan karbon, siklus nutrisi, dan sebagai habitat bagi berbagai spesies.

2.2 Zona Tanam Mangrove

Zona tanam mangrove diklasifikasikan menjadi *seaward zone*, *mid zone*, dan *landward zone*, berdasarkan lokasi mereka terhadap posisi pasang surut (Waycott et al., 2011). *Seaward zone* adalah bagian terluar dari hutan mangrove yang terpapar sepenuhnya oleh pasang surut dan sering kali terendam banjir. Tanah di zona ini umumnya berupa lumpur lunak yang berasal dari endapan sedimen. Mangrove yang tumbuh di zona ini biasanya memiliki akar udara yang mengait dan menopang tanaman tersebut. *Mid zone* adalah bagian yang terpengaruh lebih sedikit oleh pasang surut air laut dibandingkan dengan *seaward zone*. Tanah di zona ini juga berupa sedimen, namun lebih padat dibandingkan dengan *seaward zone*. *Landward zone* biasanya hanya terendam saat pasang surut mencapai puncaknya, dan sering menerima air tawar dari tanah atau aliran dari daratan. Di sini, tumbuh berbagai jenis tanaman, seperti semak, tanaman merambat, herba, dan epifit, yang biasanya ditemukan di belakang hutan mangrove. *Landward zone* umumnya merupakan area sempit yang ditumbuhi oleh berbagai jenis vegetasi dan dapat berubah menjadi hutan daratan. Keanekaragaman spesies mangrove di tiga zona

habitat ini bisa berbeda-beda, terutama dipengaruhi oleh perubahan kadar garam air laut. Gambar 2.1 menunjukkan zonasi habitat mangrove.



Gambar 2.1 Visualisasi Zona Tanam Mangrove (Waycott et al., 2011)

2.3 Kandungan Air

Air merupakan zat kimia yang paling penting di planet kita, karena memengaruhi hampir semua bidang penting dalam kehidupan, baik itu dalam hal biokimia, kimia, maupun fisika (Henderson, 2002). Sekarang ini, kita menyadari bahwa air bukan hanya sekadar pelarut biasa, tetapi juga komponen aktif dalam sel. Sifat uniknya sebagai pelarut, kemampuannya untuk membentuk ikatan hidrogen, dan sifat amfoteriknya, semuanya memainkan peran penting dalam proses biologi sel (Ball, 2008). Terdapat berbagai variasi air, seperti air laut, air danau, air sungai, dan air hujan, dan lain sebagainya. Umumnya, air terdiri dari unsur hidrogen dan oksigen, meskipun dalam situasi tertentu, komposisinya dapat bervariasi tergantung pada jenis airnya.

Penelitian ini menganalisis kandungan air seperti pH (derajat keasaman), suhu air, dan *dissolved oxygen* (oksigen terlarut/DO) sebagai parameter dalam klasifikasi zona taman mangrove di Desa Pulau Sembilan.

2.3.1 pH Air

Air laut memiliki nilai pH antara 7.983 sampai 8.202 (Rivaro et al., 2021), menandakan sifat basa secara umum, meskipun dalam kondisi tertentu nilai tersebut dapat turun di bawah 7 yang mengindikasikan sifat asam. Kebanyakan organisme di air sensitif terhadap perubahan tingkat keasaman air, yang biasanya harus berada di kisaran antara 7 hingga 8,5 agar bisa hidup dengan baik. Ketika tingkat keasaman turun sangat rendah,

di bawah 4, sebagian besar tanaman air akan mati karena tidak bisa bertahan dalam kondisi air yang asam (Susana, 2009).

2.3.2 *Suhu Air*

Suhu air memiliki pengaruh yang signifikan terhadap kehidupan tumbuhan, pertumbuhan, reproduksi, dan dinamika komunitas dalam ekosistem tumbuhan air. Bornette & Puijalon (2011) menyimpulkan dalam tinjauan mereka bahwa tumbuhan air merespons dengan sensitif terhadap faktor-faktor abiotik, termasuk suhu air. Selain itu, suhu air juga memengaruhi distribusi dan kelimpahan tumbuhan air di ekosistem air tawar, seperti yang disarankan Lacoul & Freedman (2006).

Sementara itu, dalam konteks mangrove, Ximenes et al. (2018) menunjukkan bahwa peristiwa penurunan suhu permukaan laut dapat membatasi zona-zona pertumbuhan mangrove dalam batas-batas aktualnya. Studi ini memberikan wawasan bahwa perubahan suhu air laut dapat mempengaruhi penyebaran dan perluasan mangrove di wilayah-wilayah tertentu. Pengetahuan tentang pengaruh suhu air dapat membantu dalam manajemen dan pelestarian ekosistem mangrove, khususnya dalam konteks perubahan iklim dan suhu global yang sedang terjadi.

2.3.3 *Dissolved Oxygen (DO)*

Oksigen terlarut (DO) adalah indikator penting kesehatan ekosistem akuatik yang mempengaruhi tingkat metabolisme dan pertukaran gas, yang dipengaruhi oleh beban nutrien dan faktor lingkungan (Venkiteswaran et al., 2007). Ketersediaan oksigen terlarut dalam air menjamin pertumbuhan yang sehat bagi produk akuatik dan penting untuk regulasi dan kontrol yang tepat terhadap kualitas air dalam budidaya tambak (Cao et al., 2020).

Selain itu, DO juga terkait dengan kualitas air dan habitat biologis di lingkungan akuatik, dan keakuratannya penting untuk mengevaluasi kualitas air di ekosistem akuatik (Markfort & Hondzo, 2009). Konsentrasi oksigen terlarut dalam sistem aquatik membantu mengatur keanekaragaman hayati, biogeokimia nutrien, emisi gas rumah kaca, dan kualitas air minum (Jane et al., 2021).

Dalam konteks mangrove, konsentrasi oksigen terlarut juga memiliki pengaruh yang signifikan. A. Faust & A. Gulledge (1996) menemukan bahwa konsentrasi DO berkorelasi signifikan dengan kepadatan mikroalga pada detritus mangrove yang

mengapung. Selain itu, konsentrasi oksigen terlarut juga mempengaruhi laju pertumbuhan maksimum reaksi nitrifikasi, dengan tingkat yang bervariasi tergantung pada konsentrasi yang berbeda (Stenstrom & Poduska, 1980).

2.4 Gaussian Process

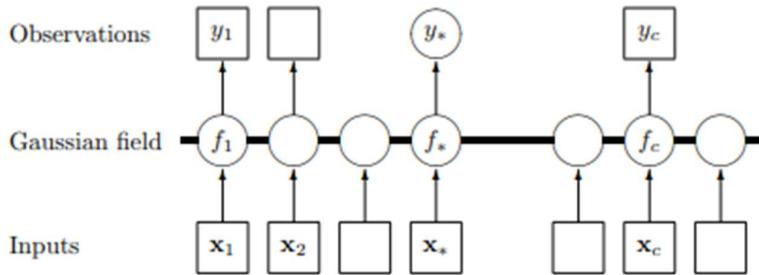
Gaussian Processes (GP) adalah generalisasi dari distribusi probabilitas Gaussian. Jika sebuah distribusi probabilitas menjelaskan variabel acak yang berupa skalar atau vektor (untuk distribusi multivariat), suatu proses stokastik mengatur sifat-sifat dari fungsi-fungsi (Rasmussen & Williams, 2005). GP merupakan pendekatan yang efektif dalam melakukan prediksi *supervised learning*, namun dapat mengalami ketidakstabilan numerik dalam beberapa implementasi (Foster et al., 2009). GP banyak digunakan dalam *nonparametric regression*, *classification*, dan *spatiotemporal modeling*, namun dihadapi batasan komputasi karena inversi matriks yang mahal secara komputasional (Banerjee et al., 2013).

GP memiliki beragam keunggulan dan tantangan dalam penerapannya. GP memiliki keunggulan dalam menangani ketidakpastian pada data dengan efektif, menyediakan representasi multi-resolusi dari ruang, dan mengatasi kekurangan informasi sensorik (Vasudevan et al., 2009). Namun, tantangan utama dalam penggunaan GP adalah biaya komputasi yang tinggi terkait dengan pengolahan matriks, terutama ketika bekerja dengan dataset yang besar (Moore et al., 2016).

2.5 Gaussian Process Regression

Gaussian Processes Regression (GPR) adalah metode probabilistik yang sepenuhnya digunakan untuk regresi non-linear, dengan memanfaatkan distribusi *heavy-tailed* untuk memodelkan *noise* generalisasi dari distribusi probabilitas Gaussian (Ranjan et al., 2016). Dalam *supervised machine learning*, GPR digunakan untuk menggambarkan ketidakpastian dalam estimasi fungsi dan semakin sering digunakan untuk memodelkan sistem dinamis non-linear dari data (Hewing et al., 2020). GPR banyak diterapkan dalam statistik, teknik, dan berbagai bidang lainnya karena kinerjanya yang baik dan sifat analitis yang menguntungkan (Shi et al., 2005). Selain itu, GPR digunakan dalam regresi nonparametrik, klasifikasi, dan pemodelan spasial-temporal. Namun, metode ini

menghadapi batasan komputasi yang signifikan karena inversi matriks yang mahal (Banerjee et al., 2013).



Gambar 2.2 Model Grafis *Gaussian Process Regression* (Rasmussen & Williams, 2005)

2.6 Gaussian Process Regression for Classification (GPRC)

Gaussian Processes Regression for Classification (GPRC), yang lebih dikenal sebagai *Gaussian Process Classification (GPC)*, adalah model klasifikasi probabilistik yang sangat fleksibel karena menggunakan prior proses Gaussian (Kuss & Rasmussen, 2005). GPC mampu menangkap korelasi antar label kelas dengan efektif melalui penggunaan sejumlah kecil fungsi laten proses Gaussian (Panos et al., 2021). Dalam konteks klasifikasi multi-label, GPC menunjukkan kemampuan luar biasa dengan menangkap korelasi antar label kelas dan mengelola data dalam jumlah besar menggunakan teknik inferensi variansional ganda stokastik dan optimasi stokastik (Xiang & Gu, 2022). Lebih dari itu, GPC dapat memprediksi beberapa label secara simultan dengan mempertimbangkan ketergantungan antar label yang berdekatan, yang pada gilirannya meningkatkan kinerjanya dalam anotasi dan segmentasi urutan observasi (Altun et al., 2004). GPC sering kali menghasilkan model prediktif yang lebih unggul dibandingkan dengan metode lain seperti hutan acak atau mesin vektor dukung, terutama dalam masalah pemodelan hubungan struktur-aktivitas kuantitatif (Obrezanova & Segall, 2010).

Langkah-langkah umum dalam mengimplementasikan GPC adalah sebagai berikut (Rasmussen & Williams, 2005):

1. Pemilihan *Kernel*: Memilih fungsi *kernel* yang sesuai untuk mengukur kemiripan antara titik-titik data input. *Kernel* Gaussian sering digunakan karena sifatnya

yang *smooth* dan kemampuannya untuk menangkap struktur kompleks dalam data.

2. Estimasi Parameter: Mengestimasi parameter-parameter dari kernel Gaussian, seperti panjang skala (*length scale*) dan parameter *noise*, menggunakan data latih.
3. Perhitungan *Posterior*: Berdasarkan data latih dan fungsi *kernel* yang dipilih, menghitung *posterior* distribusi probabilitas untuk setiap kelas untuk setiap titik data input.
4. Prediksi Kelas: Untuk setiap titik data baru, menghitung probabilitas dari masing-masing kelas berdasarkan posterior distribusi probabilitas yang telah dihitung sebelumnya.

2.7 Fungsi Kernel

Fungsi *Kernel* merupakan komponen penting dalam GP terutama dalam konteks regresi dan klasifikasi. Fungsi *kernel* dalam GP berperan sebagai model *threshold* yang menggeneralisasi fungsi *probit*. Fungsi *probit* adalah jenis fungsi distribusi kumulatif normal yang sering digunakan sebagai fungsi *likelihood* dalam regresi ordinal (Chu & Ghahramani, 2005). Fungsi *kernel* memainkan peran krusial dalam menentukan bagaimana kemiripan antara titik-titik data diukur, yang pada gilirannya mempengaruhi kemampuan model dalam melakukan prediksi. Salah satu fungsi kernel yang paling umum digunakan adalah *Radial Basis Function (RBF) kernel*, terutama ketika tidak ada pengetahuan khusus mengenai pola data yang sedang dianalisis (Liu et al., 2022).

Selain *kernel RBF*, terdapat beberapa kernel lain yang umum digunakan, antara lain *dot product kernel*, *Matern kernel*, *white kernel*, *squared exponential kernel*, dan *rational quadratic kernel* (Rasmussen & Williams, 2005). Dalam penelitian ini, akan digunakan *kernel RBF*, *Matern*, dan *rational quadratic*.

2.7.1 Radial Basis Function (RBF) Kernel

RBF *kernel*, juga dikenal sebagai *Gaussian kernel*, adalah pilihan default dalam banyak aplikasi Proses Gaussian karena sifatnya yang serbaguna dan kemampuannya untuk menangkap pola-pola dalam data tanpa memerlukan asumsi khusus tentang distribusi data tersebut (Rasmussen & Williams, 2005). *RBF kernel* mendefinisikan kemiripan antara dua titik data x dan x' sebagai berikut:

$$k(x, x') = \exp\left(-\frac{\|x - x'\|}{2\sigma^2}\right) \quad (2.1)$$

Dengan σ adalah parameter skala yang mengontrol seberapa cepat korelasi antara titik data menurun seiring dengan meningkatnya jarak antara titik-titik tersebut.

2.7.2 Matern Kernel

Salah satu fungsi kernel yang populer dan fleksibel adalah *Matern kernel*. *Kernel* ini dikenal karena kemampuannya untuk menangkap berbagai karakteristik data melalui pengaturan parameter yang dapat disesuaikan. *Matern kernel* menawarkan fleksibilitas lebih besar dibandingkan dengan *Radial Basis Function (RBF) kernel*, terutama dalam mengontrol kehalusan fungsi yang dihasilkan.

Matérn kernel diindikasikan oleh dua parameter: ν (nu), yang mengontrol kehalusan fungsi, dan ℓ (*length scale*), yang mengontrol jarak di mana dua titik data masih dianggap berkorelasi. Secara matematis, *Matérn kernel* $k_{\nu,\ell}(x, x')$ antara dua titik data x dan x' didefinisikan sebagai:

$$k_{\nu,\ell}(x, x') = \frac{1}{\Gamma(\nu)2^{\nu-1}} \left(\frac{\sqrt{2\nu} \|x - x'\|}{\ell} \right)^{\nu} K_{\nu} \left(\frac{\sqrt{2\nu} \|x - x'\|}{\ell} \right) \quad (2.2)$$

Keterangan:

$\Gamma(\nu)$: adalah fungsi Gamma.

K_{ν} : adalah fungsi Bessel yang dimodifikasi dari orde kedua.

2.7.3 Rational Quadratic Kernel

Rational Quadratic kernel adalah fungsi kernel yang dapat dilihat sebagai kumpulan dari banyak *Radial Basis Function (RBF) kernel* dengan berbagai skala panjang. *Kernel* ini sangat berguna karena kemampuannya untuk menangkap variasi pada berbagai skala panjang (*length scales*) dan fleksibilitasnya dalam menghadapi data yang memiliki karakteristik kompleks. Secara matematis, *Rational Quadratic kernel* $k_{RQ}(x, x')$ antara dua titik data x dan x' didefinisikan sebagai:

$$k(x, x') = \left(1 + \frac{\|x - x'\|^2}{2\alpha\ell^2} \right)^{-\alpha} \quad (2.3)$$

Keterangan :

- ℓ : a parameter skala panjang (*length scale*).
- α : parameter yang mengontrol bentuk distribusi dan tingkat kehalusan kernel.

2.8 Metrik Evaluasi

Penelitian ini memanfaatkan beberapa metrik evaluasi untuk menguji model pelatihan yang dikembangkan. Metrik evaluasi yang digunakan dalam penelitian ini mencakup *confusion matrix*, akurasi, presisi, *recall*, dan *F1-Score*. Berikut adalah penjelasan singkat mengenai masing-masing metrik evaluasi tersebut.

2.8.1 Confusion Matrix

Confusion matrix merupakan sebuah metrik evaluasi yang umum digunakan dalam konteks masalah klasifikasi, baik yang bersifat biner maupun multi-kelas, guna menilai kinerja algoritma pembelajaran (Ting, 2017). Sebuah *confusion matrix* menggambarkan informasi tentang klasifikasi yang sebenarnya dan hasil prediksi yang dihasilkan oleh suatu sistem klasifikasi tertentu. Matriks ini bertindak sebagai instrumen evaluasi untuk mengevaluasi performa sistem tersebut (Tharwat, 2021).

Dalam bentuk dasarnya, matriks ini terdiri dari empat komponen utama untuk masalah klasifikasi biner:

- a) *True Positif* (TP) : Total kasus positif yang berhasil diprediksi dengan tepat oleh model.
- b) *True Negatives* (TN): Total kasus negatif yang berhasil diprediksi dengan tepat oleh model.
- c) *False Positives* (FP): Total kasus negatif yang salah diprediksi sebagai positif oleh model.
- d) *False Negatives* (FN): Total kasus positif yang salah diprediksi sebagai negatif oleh model.

Untuk masalah klasifikasi dengan tiga kelas, *confusion matrix* diperluas menjadi matriks berukuran 3×3 , setiap baris mewakili kelas aktual dan setiap kolom mewakili kelas prediksi.

Tabel 2.1 memberikan gambaran umum tentang *confusion matrix* dalam konteks klasifikasi tiga kelas (seperti kelas A, B, dan C).

Tabel 2.1 *Confusion Matrix* untuk Klasifikasi Tiga Kelas

	Prediksi A	Prediksi B	Prediksi C
Aktual A	<i>True Positive A</i> (TP_A)	<i>False Negatif A as B</i> ($FN_{A \rightarrow B}$)	<i>False Negatif A as C</i> ($FN_{A \rightarrow C}$)
Aktual B	<i>False Positif B as A</i> ($FP_{B \rightarrow A}$)	<i>True Positif B</i> (TP_B)	<i>False Negatif B as C</i> ($FN_{B \rightarrow C}$)
Aktual C	<i>False Positif C as A</i> ($FP_{C \rightarrow A}$)	<i>False Positif C as B</i> ($FP_{C \rightarrow B}$)	<i>True Positif C</i> (TP_C)

Pada tabel di atas, *True Positive* (TP) untuk kelas A, B, dan C adalah jumlah observasi yang diprediksi dengan benar untuk masing-masing kelas. *False Positive* (FP) adalah jumlah observasi yang diprediksi sebagai suatu kelas, padahal aktualnya berasal dari kelas lain. Sementara itu, *False Negative* (FN) adalah jumlah observasi dari suatu kelas yang salah diprediksi sebagai kelas lain.

2.8.2 Akurasi

Dalam bidang pembelajaran mesin dan statistik, evaluasi kinerja model klasifikasi merupakan aspek yang krusial. Salah satu metrik evaluasi yang sering digunakan adalah tingkat akurasi. Akurasi memberikan gambaran mengenai seberapa sering model klasifikasi memberikan prediksi yang benar dibandingkan dengan keseluruhan prediksi yang dibuat. Meskipun sederhana, akurasi memiliki keterbatasan tertentu yang perlu dipertimbangkan dalam analisis yang lebih mendalam.

Akurasi merupakan rasio antara jumlah prediksi yang tepat dengan total jumlah prediksi. Dalam konteks klasifikasi multi-kelas, akurasi merujuk pada perbandingan antara jumlah prediksi yang tepat untuk setiap kelas dengan total jumlah observasi. Secara matematis, untuk masalah dengan K kelas, akurasi dirumuskan sebagai:

$$Akurasi = \frac{\sum_{i=1}^K TP_i}{\sum_{i=1}^K \sum_{j=1}^K C_{ij}} \quad (2.4)$$

Keterangan :

TP_i : jumlah prediksi benar untuk kelas i ,

C_{ij} : elemen dari *confusion matrix* yang menunjukkan jumlah observasi yang diketahui berada di kelas i dan diprediksi sebagai kelas j .

2.8.3 Precision

Presisi adalah ukuran yang dinyatakan sebagai rasio antara jumlah prediksi positif yang tepat (*true positives*) dengan total jumlah prediksi positif yang dihasilkan oleh model. Presisi menggambarkan seberapa akurat model dalam mengidentifikasi semua prediksi positif secara tepat.

Dalam klasifikasi multi-kelas, presisi dapat dihitung untuk masing-masing kelas secara individual. Untuk kelas i , presisi dirumuskan sebagai:

$$Presisi_i = \frac{TP_i}{TP_i + FP_i} \quad (2.5)$$

Keterangan :

TP_i : jumlah prediksi benar untuk kelas i

FP_i : jumlah kasus dari kelas lain yang diprediksi sebagai kelas i

2.8.4 Recall

Recall, atau yang juga dikenal sebagai sensitivitas, didefinisikan sebagai perbandingan antara jumlah prediksi positif yang benar (*true positives*) dengan jumlah total kasus positif yang sebenarnya dalam *dataset*. *Recall* merupakan indikator yang mengukur seberapa efektif model dalam menemukan seluruh kejadian yang sesungguhnya positif.

Dalam klasifikasi multi-kelas, *recall* dapat dihitung untuk masing-masing kelas secara individual. Untuk kelas i , *recall* dirumuskan sebagai:

$$Recall_i = \frac{TP_i}{TP_i + FN_i} \quad (2.5)$$

Keterangan :

TP_i : jumlah prediksi benar untuk kelas i

FN_i : jumlah kasus dari kelas lain yang diprediksi sebagai kelas lain

2.8.5 *F1-Score*

F1-Score didefinisikan sebagai rata-rata harmonis dari presisi dan *recall*. Dengan menggabungkan kedua metrik ini, *F1-Score* memberikan keseimbangan antara kemampuan model untuk mendeteksi *instance* positif (*recall*) dan ketepatan prediksi positif (presisi).

Secara matematis, *F1-Score* dirumuskan sebagai berikut:

$$F1 - Score = 2 \times \frac{\text{Presisi} \times \text{Recall}}{\text{Presisi} + \text{Recall}} \quad (2.6)$$

2.9 Penelitian Terdahulu

Penelitian-penelitian terdahulu yang berhubungan dengan klasifikasi zona tanam mangrove dan GPRC telah banyak dilakukan. Dalam penelitian oleh Lubis (2021) yang berjudul "Klasifikasi Zona Tanam Mangrove Berbasis Data *Monitoring Wireless Sensor*," penulis berhasil mengembangkan metode *real-time monitoring* untuk mengumpulkan data kandungan air zona-zona mangrove. Penelitian ini mengambil data kandungan air di Desa Pulau Sembilan, dan mendapatkan sebanyak 2.342 data dari 19 titik pengambilan sampel. Perbedaan penelitian ini adalah, Lubis hanya memonitor dan mengumpulkan data kandungan air dari zona-zona mangrove dan menyimpannya dalam format CSV. Sebaliknya, penelitian ini menggunakan metode *Gaussian Process Regression for Classification (GPRC)* untuk tidak hanya mengumpulkan, tetapi juga mengklasifikasikan data secara lebih mendalam, sehingga memberikan hasil yang lebih analitis dan prediktif terhadap zona tanam mangrove.

Penelitian selanjutnya adalah dari Maulana (2021) tentang indentifikasi tingkat kelayakan hidup mangrove di Desa Pulau Sembilan. Pada penelitian ini, Maulana juga menggunakan dataset kandungan air dari penelitian Lubis (2021). Perbedaan antara penelitian ini dengan penelitian yang akan dilakukan adalah bahwa penelitian yang dilakukan oleh Maulana menggunakan algoritma LSTM untuk mengidentifikasi tingkat kelayakan hidup mangrove di Desa Pulau Sembilan. Hasil dari penelitian ini

menunjukkan tingkat akurasi mencapai 99%, menggambarkan potensi besar pendekatan *machine learning* dalam studi ini.

Dalam konteks penggunaan metode GPRC, telah dilakukan beberapa penelitian sebelumnya. Tabel 2.2 menyajikan penelitian-penelitian terdahulu yang terkait dengan zona tanam mangrove dan penggunaan GPRC.

Tabel 2.2 Penelitian Terdahulu

No	Penulis	Tahun	Metode	Keterangan
1.	Muhammad Ibrahim Lubis	2021	<i>Real-Time Monitoring System</i>	<i>Realtime monitoring systems</i> untuk mengumpulkan data kandungan air zona – zona mangrove dan melakukan klasifikasi terhadap zona-zona yang sudah dikumpulkan datanya apakah zona tersebut cocok untuk ditanami jenis – jenis mangrove tertentu. Penelitian ini berhasil mengumpulkan lebih dari 2.300 data kandungan air zona mangrove di Paua Sembilan, Langkat, Sumatera Utara.
2.	Arif Maulana	2021	<i>Long Short-Term Memory (LSTM)</i>	Penelitian ini memanfaatkan dataset kandungan air Desa Pulau Sembilan yang sebelumnya telah dikumpulkan oleh Lubis (2021). Hasil dari penelitian ini menunjukkan bahwa akurasi sistem mencapai 99% dengan menerapkan

				kombinasi dari <i>optimizer Adamax</i> dan fungsi <i>softmax</i> .
3.	Klyuchnikov & Burnaev	2020	<i>Gaussian Process Classification (GPC)</i>	Penelitian yang berjudul “ <i>Gaussian process classification for variable fidelity data</i> ” ini menggunakan tiga dataset, yaitu dataset artifisial, dataset benchmark nyata untuk label dengan ketelitian rendah, dan dataset nyata dengan <i>noise</i> yang sebenarnya. Hasil yang didapatkan adalah metode GPC dapat berkinerja baik dalam berbagai kondisi, termasuk ketika <i>noise</i> ada dalam label rendah.
4.	He, et. al	2020	<i>Hyperspectral Data and 3-D Siamese Residual Network</i>	Penelitian ini bertujuan untuk membedakan tingkat spesies dalam konservasi dan restorasi pesisir. Dataset yang digunakan pada penelitian ini berupa 2012×570 pixels gambar, dan 125 spectral reflectance bands cover the wavelength range of 450–950 nm
5.	Kemler et. al	2013	<i>Gaussian Processes</i>	Penelitian ini menggunakan dataset dari ImageNet yang memiliki 1.000 kategori dengan 100.000 gambar untuk pembelajaran dan 50.000 gambar untuk <i>testing</i> .

					Hasil yang didapatkan pada penelitian ini adalah secara signifikan mengungguli <i>Support Vector Data Description</i> dalam klasifikasi satu kelas untuk pengenalan objek visual, yang mengindikasikan potensi tinggi untuk bidang penelitian ini.
6.	Obrezanova & Segall	2021	<i>Gaussian Process for Classification</i>		Tujuan dari penelitian yang berjudul " <i>Gaussian Processes for Classification: QSAR Modeling of ADMET and Target Activity</i> " ini adalah untuk memperluas penerapan teknik <i>Gaussian processes</i> dalam pemodelan hubungan struktur-aktivitas kuantitatif untuk klasifikasi. Hasil yang didapatkan dari penelitian ini adalah <i>Gaussian Process Classifier</i> seringkali menghasilkan model yang lebih prediktif untuk pemodelan QSAR ADMET dan data aktivitas target dibandingkan dengan <i>random forest</i> atau <i>support vector machine</i>
7.	Villacampa-Calvo et al.	2021	<i>Gaussian Process Classification</i>		Penelitian yang berjudul " <i>Multi-class Gaussian Process Classification with</i>

				Noisy <i>Inputs</i> ” ini mengembangkan beberapa <i>multi-class GPC</i> yang dapat memperhitungkan <i>noise</i> pada input. Penelitian ini melakukan serangkaian eksperimen menggunakan data sintetis dan nyata, yaitu beberapa <i>dataset</i> dari repositori UCI, dataset MNIST, dan <i>dataset</i> dari bidang astrofisika. Hasil penelitian menunjukkan bahwa meskipun kesalahan klasifikasi serupa di antara metode-metode tersebut, distribusi prediksi dari metode-metode yang diusulkan lebih baik dalam hal <i>log-likelihood</i> uji daripada distribusi prediksi dari <i>classifier</i> berbasis GP yang mengabaikan <i>noise</i> input
--	--	--	--	--

Terdapat beberapa penelitian yang berhubungan dengan konsep GPRC. Penelitian pertama dilakukan oleh Klyuchnikov & Burnaev (2020). Klyuchnikov menerapkan *Gaussian Process Classification* (GPC) dengan menggunakan tiga dataset berbeda, dataset yang dihasilkan secara buatan dengan asumsi model, dataset *benchmark* nyata dengan *noise* yang disimulasikan untuk label dengan ketelitian rendah, yang diambil dari dataset repositori Penn Machine Learning Benchmark (Olson et al., 2017), serta dataset nyata dengan *noise* yang sebenarnya yang menggunakan dataset music_genre (mscg) dan sentiment_polarity (snlp) dari Rodrigues et al. (2014).

Penelitian ini mengembangkan metode inferensi Laplace untuk klasifikasi berbasis *Gaussian Process* (GP) agar dapat digunakan dengan data *multi-fidelity*.

Penelitian selanjutnya oleh (Villacampa-Calvo et al., 2021) membahas keberadaan *noise* pada masukan dalam klasifikasi multi-kelas menggunakan *Gaussian processes*. Dengan mengembangkan *Multi-class Gaussian Process Classifier* yang memperhitungkan input *noise*, penelitian ini memberikan sumbangan pada pemahaman tentang peran ketidakpastian dalam estimasi distribusi prediksi. Hasil eksperimen menunjukkan bahwa mengabaikan keberadaan *noise* pada masukan dapat mengurangi kualitas distribusi prediktif, sementara klasifier yang memperhitungkan *noise* dapat meningkatkan performa distribusi prediktif.

Dalam konteks penelitian tentang mangrove dan pembelajaran mesin terdapat beberapa penelitian yang telah berhasil melakukannya, salah satunya penelitian oleh Pham et al. (2019) yang berjudul “*Remote Sensing Approaches for Monitoring Mangrove Species, Structure, and Biomass: Opportunities and Challenges*”. Penelitian ini membahas penggunaan teknik penginderaan jauh dalam pemetaan spesies mangrove, biomassa, dan stok karbon. Penelitian ini menyoroti peran penting ekosistem mangrove dalam siklus karbon global serta upaya mitigasi dan adaptasi terhadap perubahan iklim. Namun, kehilangan habitat mangrove secara global telah menyebabkan kerugian stok karbon yang signifikan. Penelitian tersebut menggarisbawahi tantangan praktis dalam mengukur dan memonitor biomassa mangrove serta stok karbon mereka. Tanpa metode kuantitatif yang efektif untuk memantau parameter biofisik dan stok karbon di mangrove, pembuatan kebijakan dan tindakan yang berkelanjutan untuk melestarikan mangrove dalam konteks mitigasi dan adaptasi terhadap perubahan iklim menjadi lebih sulit. Meskipun berbeda dalam pendekatan dan fokus, keduanya menunjukkan pentingnya teknologi dan metodologi inovatif untuk memahami dan melestarikan ekosistem mangrove secara global. Dengan demikian, kedua penelitian ini memberikan kontribusi yang berharga dalam upaya pemantauan dan pelestarian mangrove yang berkelanjutan.

BAB 3

ANALISIS DAN PERANCANGAN SISTEM

Bab ini menjelaskan secara mendetail proses analisis dan perancangan sistem klasifikasi zona tanam mangrove menggunakan metode *Gaussian Process Regression for Classification (GPRC)*. Proses ini mencakup tahapan pengumpulan data, pemrosesan data, pembuatan model, hingga model tersebut siap digunakan. Selain itu, bab ini juga membahas integrasi model klasifikasi dengan sistem web yang akan dikembangkan untuk mempermudah pengguna dalam mengakses dan memanfaatkan informasi yang dihasilkan. Dengan demikian, bab ini memberikan gambaran komprehensif tentang bagaimana sistem klasifikasi zona tanam mangrove dirancang dan diimplementasikan menggunakan pendekatan GPRC, serta bagaimana model tersebut diintegrasikan ke dalam platform web untuk mendukung pengambilan keputusan dan manajemen lingkungan secara efektif.

3.1 Data

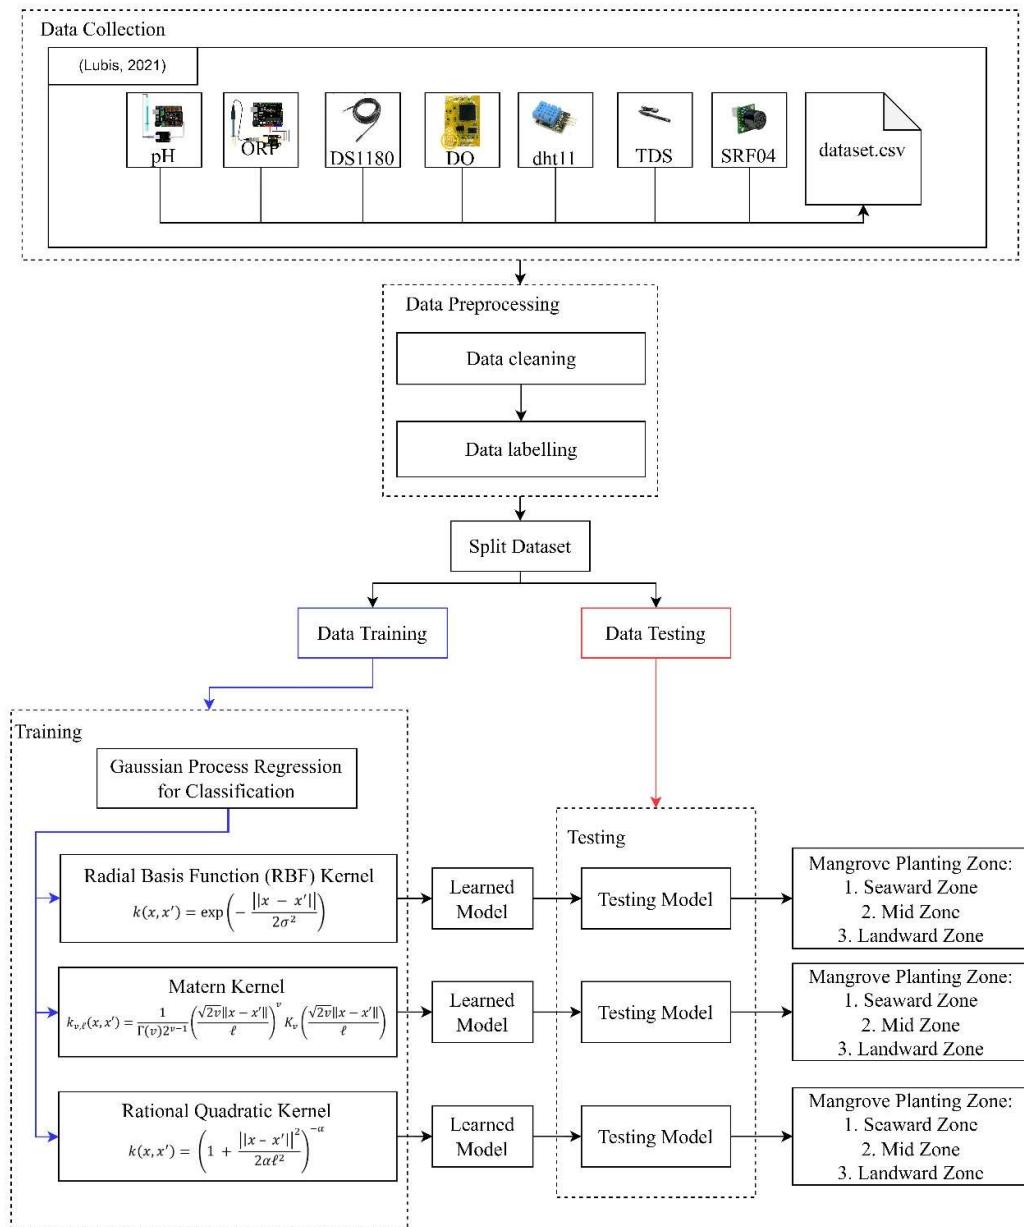
Sumber data yang dimanfaatkan dalam penelitian ini berasal dari penelitian sebelumnya yang telah dilakukan oleh (Lubis, 2021), yang menyoroti pemantauan zona tanam mangrove secara *real-time* di Desa Pulau Sembilan. Dataset ini berbentuk *Comma Separated Value* (CSV) yang terdiri dari 2.342 baris data, dengan setiap baris memiliki 8 parameter dan 1 label. Parameter-parameter yang terdapat dalam dataset mencakup suhu air, kelembapak udara, ketinggian air, suhu udara, pH, *Total Dissolved Solids* (TDS), *Oxidation-Reduction Potential* (ORP), *Dissolved Oxygen* (DO), dengan entitas lokasi sebagai label. Data ini mulai pada tanggal 15 April 2021, di Desa Pulau Sembilan, selama 15 hari berturut-turut

Tabel 3.1 Dataset penelitian monitoring zona tanam mangrove di Desa Pulau Sembilan (Lubis, 2021)

no	idPerangkat	ketinggianAir	suhuAir	suhuUdara	kelembapanUdara	tds	orp	do	ph	dateTime	label	lokasi
1	ID001	111	29.94	27.00	43.00	715.80	320.18	29.32	8.83	14/03/2021 11:20	1	3
2	ID001	115	29.34	27.24	43.06	716.21	322.32	29.13	8.65	14/03/2021 11:23	1	3
3	ID001	120	29.12	27.57	43.17	717.57	321.76	28.98	8.21	14/03/2021 11:26	1	3
4	ID001	119	29.27	27.62	43.21	716.47	319.63	28.48	7.94	14/03/2021 11:29	1	3
5	ID001	123	29.24	27.78	43.28	717.00	318.82	29.84	7.67	14/03/2021 11:32	1	3
6	ID001	122	29.18	28.02	43.32	718.10	319.84	28.83	8.23	14/03/2021 11:35	1	3
7	ID001	125	29.06	28.13	43.42	718.35	320.52	29.39	7.84	14/03/2021 11:38	1	3
8	ID001	124	28.94	28.19	43.49	718.32	321.93	29.85	8.43	14/03/2021 11:41	1	3
9	ID001	127	28.94	28.36	43.31	719.24	322.52	29.99	9.01	14/03/2021 11:44	1	3
10	ID001	130	28.95	28.42	43.24	718.10	323.23	30.21	8.87	14/03/2021 11:47	1	3
11	ID001	132	28.89	28.31	43.15	718.23	324.29	29.79	8.18	14/03/2021 11:50	1	3
12	ID001	136	29.00	28.23	43.06	718.28	322.83	28.42	7.69	14/03/2021 11:53	1	3
13	ID001	132	29.09	28.14	42.97	718.36	322.23	28.12	8.12	14/03/2021 11:56	1	3
14	ID001	129	29.09	28.03	42.86	718.25	323.63	27.87	8.35	14/03/2021 11:59	1	3
15	ID001	132	28.98	27.95	42.74	717.58	321.43	27.42	8.63	14/03/2021 12:02	1	3
16	ID001	135	29.10	27.85	42.62	717.24	320.74	27.89	8.96	14/03/2021 12:05	1	3
17	ID001	138	29.20	27.74	42.79	717.18	320.32	28.42	9.34	14/03/2021 12:08	1	3
18	ID001	137	29.27	27.65	42.86	717.63	319.85	28.79	9.12	14/03/2021 11:11	1	3
19	ID001	140	29.24	27.53	42.99	717.83	329.12	29.32	8.85	14/03/2021 12:14	1	3
20	ID001	139	29.28	27.41	43.05	717.32	319.45	28.75	8.65	14/03/2021 12:17	1	3
21	ID001	127	30.12	29.00	40.00	516.75	294.46	22.41	6.02	14/03/2021 12:47	2	2
22	ID001	134	30.19	29.05	40.05	516.87	294.57	22.56	6.09	14/03/2021 12:50	2	2
23	ID001	142	30.23	29.13	40.17	516.93	294.62	22.67	6.13	14/03/2021 12:53	2	2
24	ID001	151	30.28	29.19	40.23	517.03	294.78	22.78	6.17	14/03/2021 12:56	2	2
25	ID001	147	30.37	29.24	40.29	517.11	294.83	22.94	6.26	14/03/2021 12:59	2	2

3.2 Analisis Sistem

Penelitian ini melibatkan serangkaian tahapan untuk mengembangkan sistem klasifikasi zona tanam mangrove menggunakan metode *Gaussian Process Regression for Classification (GPRC)*. Tahap awal dimulai dengan pengumpulan data, yang mencakup parameter seperti ketinggian air, suhu air, suhu udara, kelembapan udara, TDS, ORP, DO, dan pH. Selanjutnya, data akan diproses melalui tahap *pre-processing* agar dataset dapat dimanfaatkan secara optimal. Setelah dataset siap, dilakukan pembangunan model klasifikasi zona tanam mangrove menggunakan metode GPRC. Proses selanjutnya melibatkan *tahap training* dan *testing* untuk menghasilkan *output* model yang optimal. Gambar 3.1 menampilkan arsitektur umum dari sistem klasifikasi zona tanam mangrove dengan GPRC.



Gambar 3.1 Arsteuktur Umum Model Klasifikasi Zona Tanam Mangrove Desa Pulau Sembilan Menggunakan *Gaussian Process Regression for Classification (GPRC)*

3.2.1 Data Collection

Langkah awal adalah tahap pengumpulan data. *Dataset* yang dipakai dalam penelitian ini tersaji dalam format file CSV (*Comma Separated Value*) dengan jumlah total data mencapai 2.342 baris, yang memuat 10 atribut termasuk ketinggian air, suhu air, suhu udara, kelembapan udara, TDS, ORP, DO, pH, *datetime*, dan lokasi. Data ini berasal dari penelitian sebelumnya oleh (Lubis, 2021) yang memfokuskan pada pemantauan kandungan air di zona mangrove Desa Pulau Sembilan.

3.2.2 Data Pre-processing

Tahap *pre-processing* data bertujuan untuk memastikan bahwa data yang akan digunakan untuk model klasifikasi memiliki kualitas yang baik dan bebas dari kesalahan. Terdapat dua tahap utama yang akan dilakukan pada tahap *pre-processing* ini, yakni pembersihan data (*data cleaning*) dan penentuan label data (*data labelling*).

a) Data cleaning

Proses *data cleaning* (pembersihan data) bertujuan untuk menjamin akurasi dan konsistensi *dataset*. Pada tahap ini, dilakukan seleksi serta penghapusan data yang redundant, dan perbaikan pada *instance* atau fitur yang mungkin tidak tepat pada *dataset*. Gambar 3.2 Menampilkan *pseudocode* dalam proses *data cleaning* pada dataset zona tanam mangrove ini. Pseudocode ini dimulai dengan memuat dan membaca dataset, kemudian iterasi dilakukan pada setiap titik data. Jika suatu data bernilai null, data tersebut diubah menjadi nol. Jika data bukan tipe float, baris data tersebut dihapus. Proses ini berlanjut hingga semua data dalam dataset telah diperiksa. Setelah iterasi selesai, dataset yang telah diproses disimpan kembali.

```

BEGIN
    LOAD dataset
    READ dataset
    FOR each data point IN dataset
        IF data point IS NULL THEN
            ASSIGN data point TO 0
        ELSE IF data point IS NOT FLOAT THEN
            DELETE line containing data point
        END IF
    END FOR
    SAVE dataset
END

```

Gambar 3.2 Pseudocode Proses Data Cleaning

b) *Data labelling*

Langkah berikutnya dalam *data pre-processing* adalah pelabelan data. Dalam penelitian ini, data telah dilabelkan oleh penelitian sebelumnya. Proses pelabelan ini bertujuan untuk memastikan bahwa dataset yang digunakan dalam penelitian memiliki kualitas yang tinggi sebelum memasuki tahap pelatihan model. Label yang digunakan adalah parameter lokasi dengan nilai 1 (satu) menunjukkan *seaward zone*, 2 (dua) menunjukkan *mid zone*, dan 3 (tiga) menunjukkan *landward zone*. Dengan demikian, data telah disiapkan dalam format yang sesuai untuk konteks klasifikasi zona tanam mangrove, menjamin kesesuaian dan relevansi data untuk analisis lebih lanjut.

Tabel 3.2 menunjukkan data yang telah melalui tahap pre-processing. Data ini terdiri dari 9 kolom, yaitu suhu air, kelembapan udara, ketinggian air, suhu udara, pH, *Total Dissolved Solids* (TDS), *Oxidation-Reduction Potential* (ORP), *Dissolved Oxygen* (DO), dan Lokasi.

Tabel 3.2 Dataset setelah tahap *pre-processing*

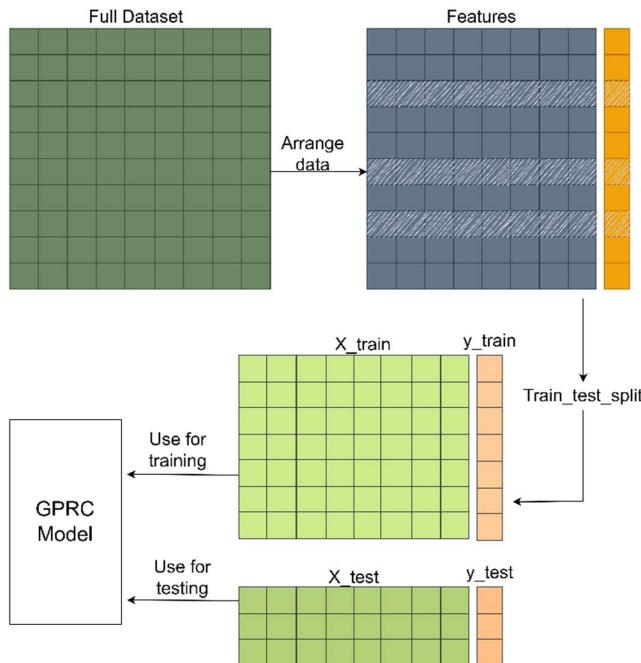
Ketinggian Air	Suhu Air	Suhu Udara	Kelembapan Udara	tds	orp	do	ph	lokasi
111	29.94	27	43	715.8	320.18	29.32	8.83	3

115	29.34	27.24	43.06	716.21	322.32	29.13	8.65	3
120	29.12	27.57	43.17	717.57	321.76	28.98	8.21	3
119	29.27	27.62	43.21	716.47	319.63	28.48	7.94	3
123	29.24	27.78	43.28	717	318.82	29.84	7.67	3
122	29.18	28.02	43.32	718.1	319.84	28.83	8.23	3
125	29.06	28.13	43.42	718.35	320.52	29.39	7.84	3
124	28.94	28.19	43.49	718.32	321.93	29.85	8.43	3
127	28.94	28.36	43.31	719.24	322.52	29.99	9.01	3
130	28.95	28.42	43.24	718.1	323.23	30.21	8.87	3
132	28.89	28.31	43.15	718.23	324.29	29.79	8.18	3
136	29	28.23	43.06	718.28	322.83	28.42	7.69	3
:	:	:	:	:	:	:	:	:
88	22.5	22.89	49.85	421.73	119.19	19.07	9.77	19
85	23.02	21.96	48.52	439.25	114.89	18.65	8.24	19
71	23.07	20.97	49.58	431.08	119.72	19.83	8.83	19
71	22.25	22.42	47.87	427.18	113.84	19.22	9.58	19
82	22.39	22	50.37	434.93	119.36	19.91	9.82	19
90	22.19	22.06	49.62	443.28	114.53	19.52	9.79	19
86	23.34	21.93	52.7	440.27	115.55	18.32	8.33	19
78	23.26	21.31	53.01	438.11	113.23	19.88	8.69	19
65	23.76	22.1	48.65	425.06	119.66	19.75	9.58	19
66	22.73	21.96	49.04	442.57	117.64	20	8.24	19
88	22.31	21.72	45.92	427.62	119.65	18.3	9.44	19

Setelah memastikan data yang digunakan berkualitas baik, file akan disimpan ke dalam format CSV agar dapat digunakan sebagai dataset pada pelatihan model.

3.2.3 Data Splitting

Data splitting merupakan proses membagi dataset menjadi dua atau lebih subset yang berbeda untuk digunakan dalam tahap-tahap tertentu dari analisis data atau Pembangunan model. Tujuan dari *data splitting* adalah untuk menghasilkan subset yang dapat digunakan untuk melatih model (*training set*) dan subset lainnya untuk menguji model (*testing set*). Untuk membagi data tersebut, digunakan *method train_test_split* pada library *scikit-learn* agar data dapat dibagi menjadi dua subset dengan data yang acak. Gambar 3.3 menampilkan proses *data splitting* menjadi data latih dan data uji.



Gambar 3.3 Proses *Data Splitting* Menjadi Data Latih dan Data Uji

Selanjutnya, data dalam format CSV dengan total 2.342 baris akan dibagi menjadi dua subset. Dalam penelitian ini, pembagian dilakukan dengan proporsi 70% untuk *training set* dan 30% untuk *testing set*. Tabel 3.3 menunjukkan rincian pembagian dataset menjadi *training set* dan *testing set*.

Tabel 3.3 Detail pembagian dataset

No	Subset	Jumlah
1.	Training set	1.639 baris
2.	Testing set	703 baris

3.2.4 Model Training

Pada fase pelatihan model, algoritma GPRC akan mengeksplorasi pola dan korelasi dalam data guna membangun model yang mampu melakukan prediksi. Subset data yang digunakan pada tahap ini dikenal sebagai *training set*. Langkah awal dalam penerapan GPRC adalah merumuskan *Gaussian Process* yang digunakan untuk menggambarkan hubungan antara *input* dan *output*. Proses Gaussian didefinisikan sebagai distribusi probabilistik atas fungsi-fungsi, dengan *mean function* $m(x)$, dan *covariance function*

atau *kernel function* $k(x, x')$ yang menentukan korelasi antara titik-titik dalam ruang input.

Berikutnya, seleksi fungsi kernel memiliki signifikansi penting karena memengaruhi kapabilitas model dalam menangkap pola dalam data. Beberapa kernel yang diterapkan dalam penelitian ini mencakup *Radial Basis Function (RBF)*, *Matern*, dan *White Kernel*. *Kernel* ini membantu dalam mengukur kemiripan antara dua titik dalam ruang fitur, yang kemudian digunakan untuk membuat prediksi. Gambar 3.3 menampilkan *pseudocode* inisialisasi kernel yang digunakan.

```
// Initialize the kernels
INITIALIZE rbfKernel AS new instance of RBF
INITIALIZE maternKernel AS new instance of Matern
INITIALIZE rqKernel AS new instance of RationalQuadratic
```

Gambar 3.4 *Pseudocode* Inisialisasi Kernel

Setelah mendefinisikan kernel, langkah berikutnya adalah melakukan *training* model klasifikasi. Implementasi GPRC dilakukan dengan menggunakan library *scikit-learn* di Python dengan *method GaussianProcessClassifier*. Kernel yang digunakan didefinisikan pada parameter *method GaussianProcessClassifier*. Setelahnya dilakukan pelatihan pada model selama 25 kali iterasi agar model dapat mempelajari *dataset* yang digunakan. Gambar 3.5

```
for x in range(1, 26):
    gpc = GaussianProcessClassifier(kernel=kernel, max_iter_predict=x).fit(X_train,
y_train)
    accuracy = gpc.score(X_test, y_test)
    y_pred = gpc.predict(X_test)
```

Gambar 3.5 *Pseudocode* training model sebanyak 25 kali iterasi

Dengan mengadopsi GPRC dan melakukan optimasi *kernel*, diharapkan model dapat memberikan hasil klasifikasi yang optimal dengan kemampuan yang baik dalam

menangkap kompleksitas variasi spasial dan ketidakpastian pada data. Pendekatan ini bertujuan untuk meningkatkan performa model dan memberikan keakuratan yang maksimal dalam mengidentifikasi zona tanam mangrove di wilayah tersebut.

3.2.5 Model Testing

Model Testing adalah proses evaluasi kinerja model *machine learning* setelah proses *training* selesai. Pada tahap ini, model GPRC yang telah dilatih diuji menggunakan *testing set* yang berisi data yang tidak pernah digunakan selama *training*. Tujuan utama dari proses ini adalah untuk menilai kualitas model dan membuat klasifikasi yang akurat dengan data yang belum pernah digunakan selama *training*.

Pada tahap *model testing* ini model akan diuji dengan menggunakan berbagai metrik evaluasi untuk menilai kinerja model. Beberapa metrik evaluasi yang digunakan antara lain adalah akurasi, *precision*, *recall*, dan *F1-Score*.

Pengujian model dilaksanakan dengan tujuan memverifikasi bahwa model yang telah dilatih mampu memberikan klasifikasi yang tepat dan stabil. Metrik evaluasi yang diterapkan memberikan gambaran menyeluruh tentang keefektifan model, memungkinkan untuk mengidentifikasi aspek yang kuat dan lemah dari model yang telah dikembangkan.

3.2.6 Output

Hasil output dari model klasifikasi menggunakan GPRC akan mencakup klasifikasi zona tanam mangrove di Desa Pulau Sembilan menjadi tiga kategori utama, yaitu *Seaward Zone*, *Mid Zone*, dan *Landward Zone* (Waycott et al., 2011). Kategori-kategori ini mencerminkan penentuan zona-zona berdasarkan karakteristik spasial dan lingkungan yang dapat diidentifikasi oleh model. Berikut ini adalah penjelasan tentang ketiga zona tersebut:

- a) *Seaward Zone*: Zona ini mencakup area-area mangrove yang terletak lebih dekat dengan garis pantai atau zona laut. *Seaward Zone* seringkali memiliki karakteristik yang lebih terpengaruh oleh pasang surut dan memiliki kondisi ekologis yang berbeda dibandingkan dengan zona-zona lainnya.
- b) *Mid Zone*: *Mid Zone* merujuk pada zona mangrove yang terletak di antara *Seaward Zone* dan *Landward Zone*. Zona ini seringkali menunjukkan

karakteristik transisi antara zona pesisir dan daratan, dan dapat memiliki dinamika ekologis yang unik.

- c) *Landward Zone*: Zona ini mencakup area mangrove yang terletak lebih jauh dari garis pantai, lebih mendekati daratan. *Landward Zone* umumnya memiliki kondisi ekologis yang berbeda, yang dapat dipengaruhi oleh faktor-faktor seperti salinitas, kelembaban tanah, dan interaksi dengan lingkungan daratan.

Output klasifikasi ini memiliki tujuan untuk memberikan informasi yang jelas dan kategorikal mengenai zona tanam mangrove di Desa Pulau Sembilan. Oleh karena itu, hasil klasifikasi ini dapat digunakan oleh pihak yang berkepentingan, peneliti, dan pengelola untuk mengambil keputusan yang lebih informasional terkait pelestarian, pengelolaan, dan pemantauan ekosistem mangrove di wilayah tersebut..

3.2.7 Implementasi Rancangan Antarmuka

Pada tahap ini dilakukan pengimplementasian rancangan tampilan antarmuka sistem web klasifikasi zona tanam mangrove yang telah dilakukan sebelumnya. Implementasi ini dilakukan dengan dua bagian, *backend* dan *frontend*. Bagian *backend* dibangun dengan *framework Flask*, sebuah yang ditulis dalam bahasa pemrograman Python. Sementara itu, bagian *frontend* akan dikembangkan dengan Next JS, sebuah *framework React* yang memungkinkan pengembangan aplikasi web yang responsif dan cepat.

Pemilihan Flask untuk bagian *backend* didasarkan pada kemampuannya untuk membuat dan membaca model *machine learning*. Flask menyediakan fleksibilitas yang diperlukan dalam mengintegrasikan model machine learning ke dalam aplikasi web, serta kemudahan dalam menangani HTTP *request*. Selain itu, Flask juga mendukung penggunaan *library Python* untuk *machine learning* seperti *scikit-learn*, *numpy*, dan *pandas*, yang digunakan untuk membangun, menyimpan, dan memuat model *machine learning*.

Integrasi bagian *frontend* dan *backend* dilakukan melalui REST API, yang merupakan singkatan dari *Representational State Transfer Application Programming Interfaces* (Baniaş et al., 2021). REST API adalah *web application programming interface* yang memungkinkan pengguna mengakses data melalui protokol yang telah terdefinisi dengan baik, sehingga memungkinkan kolaborasi dalam penelitian desain dan pengembangan material komputasional (Taylor et al., 2014). REST API akan

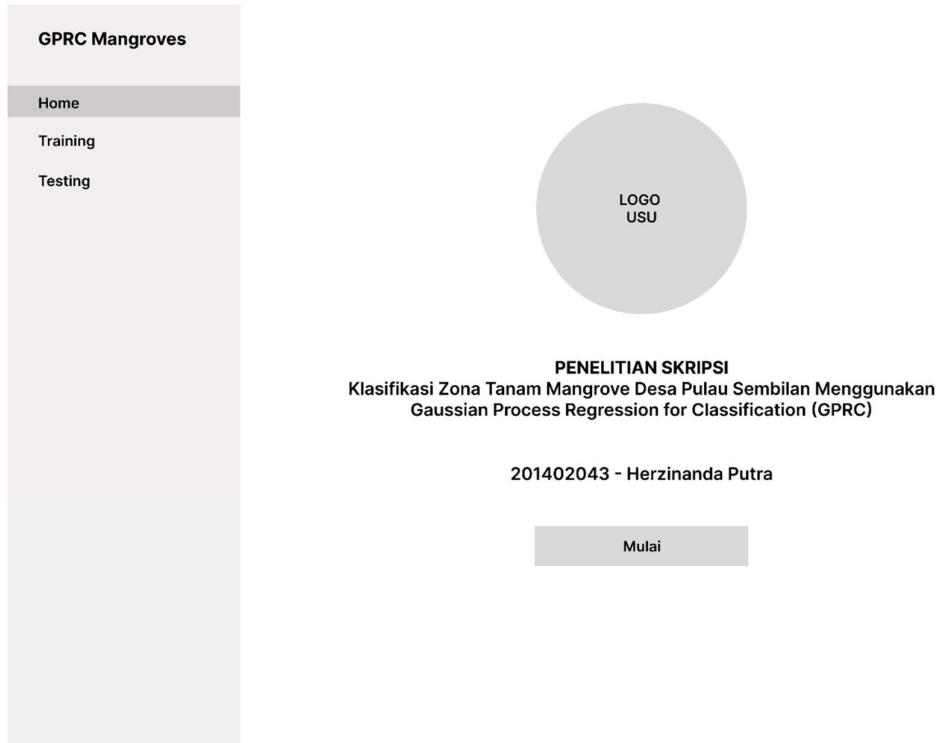
berperan sebagai jembatan komunikasi antara kedua bagian sistem, memungkinkan *frontend* untuk mengirim HTTP *request* ke *backend* dan menerima respons dalam format yang terstruktur seperti JSON atau XML. Hal ini akan memungkinkan aplikasi *frontend* untuk berinteraksi dengan *backend* secara efisien dan mengakses data yang diperlukan untuk ditampilkan dalam antarmuka pengguna.

3.3 Perancangan Antarmuka Sistem

Langkah-langkah dalam desain antarmuka sistem bertujuan untuk memverifikasi bahwa interaksi antara pengguna dan sistem berlangsung dengan lancar dan mudah dimengerti. Bagian ini akan menguraikan proses perancangan antarmuka untuk sistem web klasifikasi zona tanam mangrove di Desa Pulau Sembilan. Perancangan ini disusun untuk memberikan gambaran yang mengenai sistem yang akan dibangun. Halaman-halaman yang akan dirancang dalam sistem web ini meliputi halaman *training*, halaman *testing*, dan halaman *home*.

3.3.1 Halaman Home

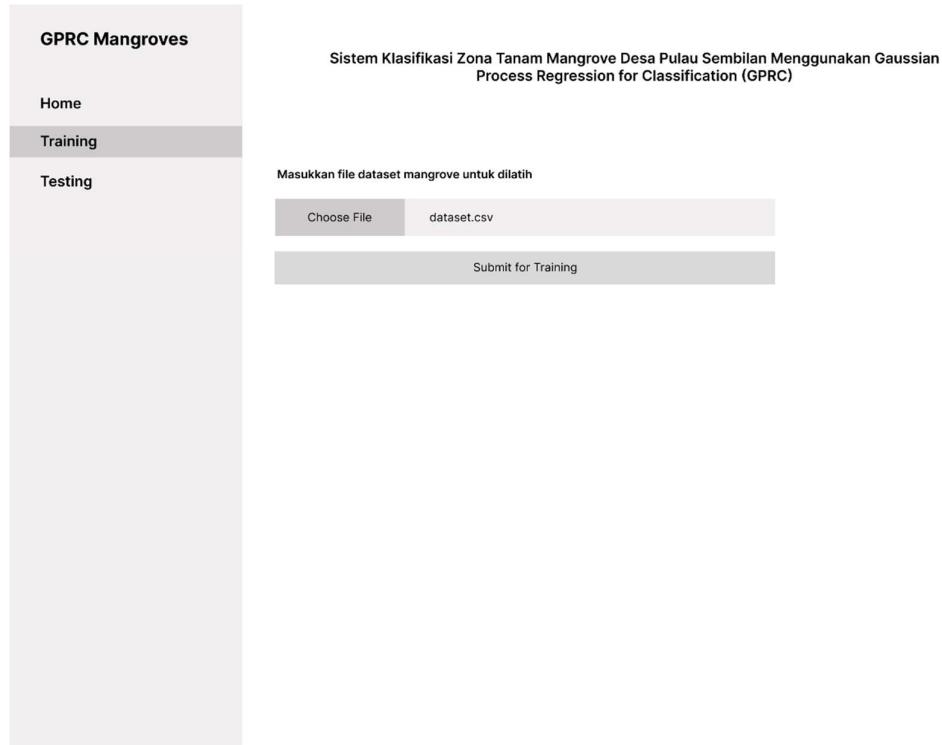
Halaman ini menyediakan informasi tentang aplikasi, termasuk informasi penulis, serta penjelasan mengenai tentang metode yang digunakan. Halaman ini bertujuan untuk sebagai halaman awal ketika pengguna pertama kali mengakses web ini. Gambar 3.6 menampilkan rancangan antarmuka untuk halaman *Home*. Dapat dilihat pada gambar bahwasannya untuk halaman Home akan tersedia informasi seperti Lambang USU, judul penelitian, penulis, serta sebuah tombol “Mulai” yang akan langsung mengarahkan ke halaman *training* ketika ditekan. Dapat dilihat juga bahwa terdapat sebuah sidebar dengan 3 macam menu, menu Home, menu Training, dan menu Testing.



Gambar 3.4 Rancangan tampilan antarmuka halaman *home*

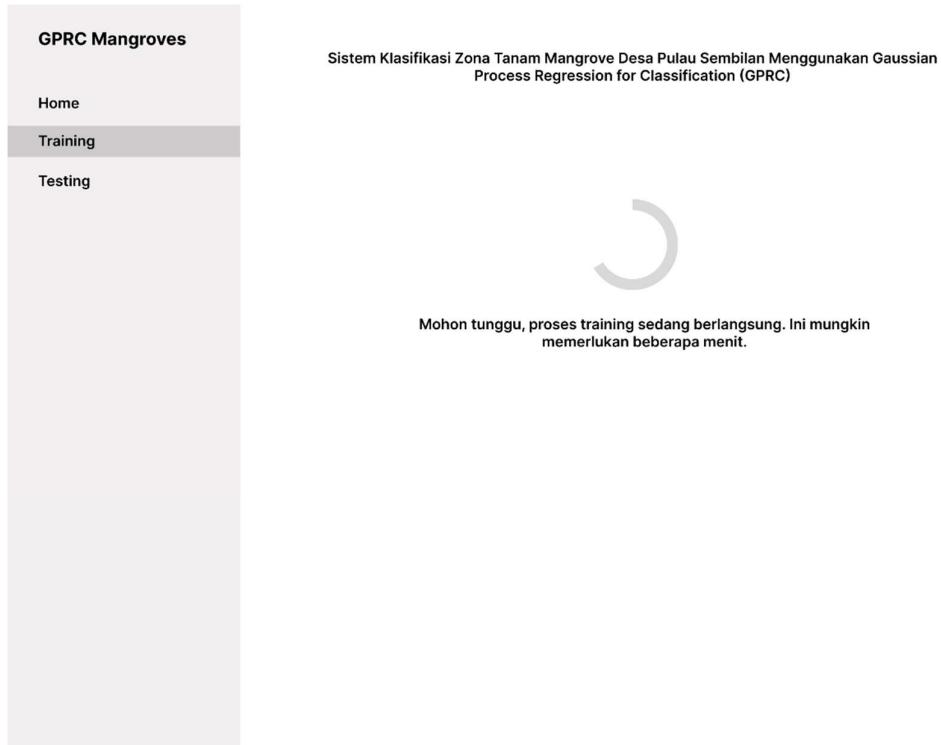
3.3.2 Halaman Training

Halaman *training* disusun untuk membolehkan pengguna melatih model klasifikasi dengan data yang sudah ada. Di laman ini, pengguna bisa mengunggah dataset baru dan mengawasi proses pelatihan model. Di samping itu, grafik yang menggambarkan hasil kinerja model selama proses pelatihan juga disajikan. Gambar 3.7 menampilkan rancangan tampilan antarmuka untuk halaman awal training. Pada halaman ini akan menampilkan sebuah form untuk memasukkan berkas dengan ekstensi CSV untuk dilakukan pelatihan.



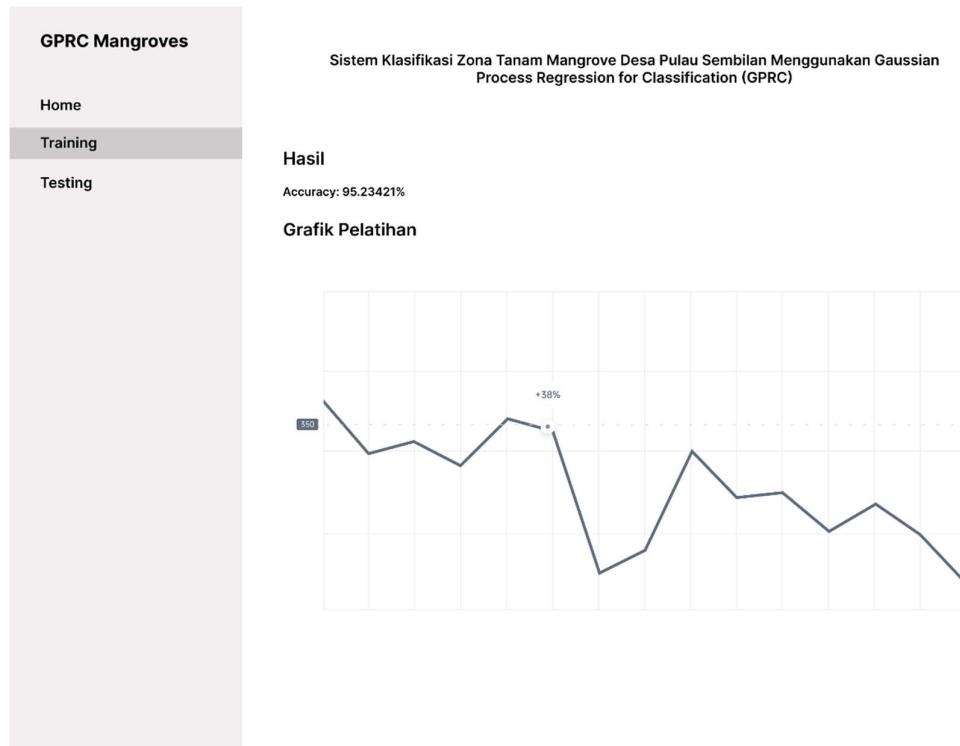
Gambar 3.7 Rancangan tampilan antarmuka halaman input dataset training

Gambar 3.8 menampilkan rancangan tampilan antarmuka halaman *loading* pada saat menunggu hasil *training*.



Gambar 3.8 Rancangan tampilan antrrmuka hlaaman loading training

Gambar 3.9 menampilkan rancangan tampilan antarmuka halaman hasil *training*. Pada halaman ini terdapat hasil akurasi dari proses *training* yang berlangsung, dan grafik dari hasil *training* tersebut.

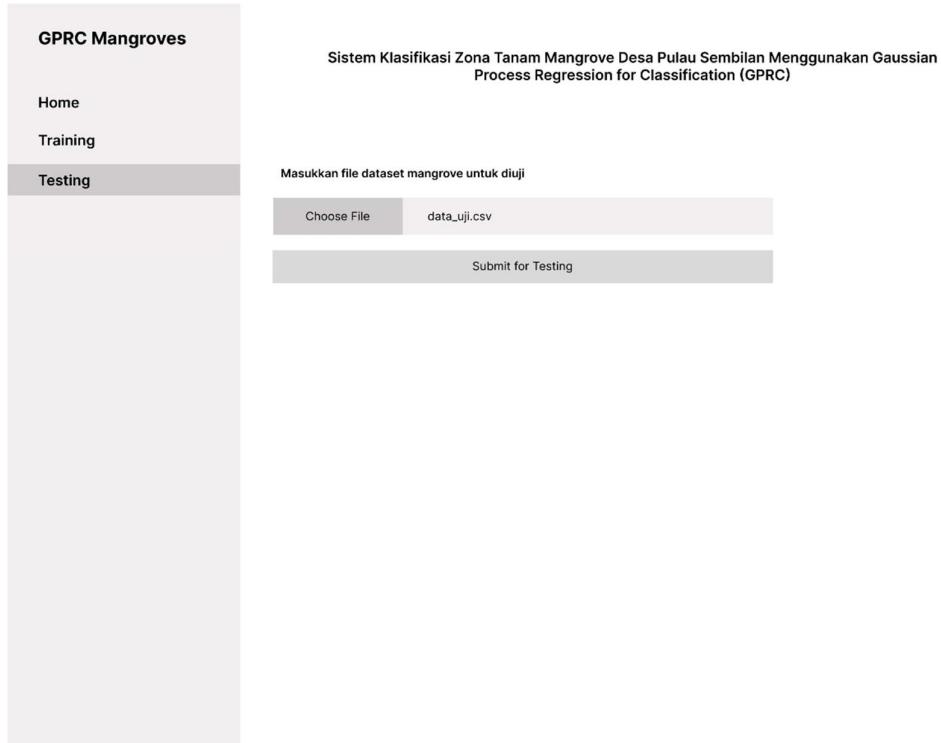


Gambar 3.9 Rancangan tampilan antarmuka halaman hasil training

3.3.3 Halaman Testing

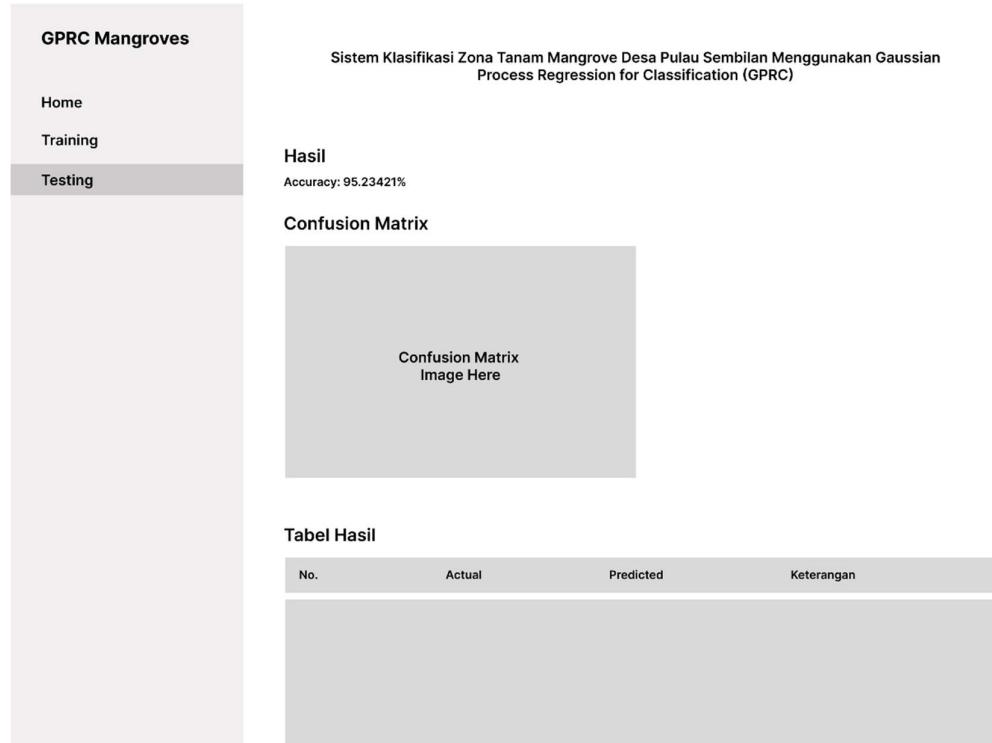
Setelah model selesai dilatih, halaman pengujian menyediakan fasilitas bagi pengguna untuk menguji model dengan dataset yang berbeda atau data uji baru yang diunggah. Pengguna dapat melihat hasil klasifikasi dan evaluasi kinerja model, termasuk metrik akurasi, presisi, dan recall. Halaman ini juga menyediakan fitur untuk membandingkan hasil dari berbagai model atau parameter pelatihan yang berbeda, sehingga pengguna dapat melakukan evaluasi komprehensif. Pada halaman ini juga akan ditampilkan hasil data *actual* dan hasil data *predicted* dengan keterangan data tersebut sesuai atau tidak.

Gambar 3.10 menampilkan rancangan tampilan antarmuka halaman untuk memasukkan berkas testing dalam format CSV. Pada halaman ini juga terdapat sebuah *button* untuk memproses berkas agar bisa dilakukan pengujian.



Gambar 3.10 Rancangan Tampilan Antarmuka Halaman *Input File Testing*

Gambar 3.11 menampilkan rancangan tampilan antarmuka halaman hasil *testing*. Pada halaman ini terdapat hasil dari proses pengujian berupa *accuracy*, tabel *confusion matrix*, dan tabel perbandingan nilai *actual* dan nilai *predicted* dari pengujian.



Gambar 3.11 Rancangan Tampilan Antarmuka Halaman Hasil *Testing*

BAB 4

IMPLEMENTASI DAN PENGUJIAN SISTEM

Pada bab ini akan dibahas proses implementasi metode *Gaussian Process Regression for Classification (GPRC)* terhadap klasifikasi zona tanam mangrove di Desa Pulau Sembilan. Langkah-langkah implementasi metode ini, termasuk tahap implementasi sistem, persiapan data, proses pelatihan, proses pengujian, serta proses integrasi dengan sistem berbasis web akan dijelaskan pada bagian ini.

4.1 Implementasi Sistem

GPRC akan diimplementasikan untuk mengklasifikasikan zona tanam mangrove di Desa Pulau Sembilan. Oleh karena itu, pada bagian ini akan diberikan penjelasan mengenai penerapan sistem yang telah direncanakan dalam bab sebelumnya. Bagian ini mencakup uraian tentang perangkat keras dan perangkat lunak yang digunakan, penerapan data, penerapan pelatihan dan pengujian, serta penerapan antarmuka yang telah dirancang dalam bab sebelumnya.

4.1.1. Perangkat keras dan perangkat lunak

Berikut adalah komponen perangkat keras dan perangkat lunak yang digunakan dalam pembangunan sistem ini.

1. Processor AMD Ryzen 7 5700U dengan AMD Radeon Integrated Graphics
2. RAM dengan kapasitas sebesar 16 GB
3. Penyimpanan dengan kapasitas sebesar 512GB SSD
4. OS Windows 11 Home 64-bit
5. Google Collab dengan A100 GPU
6. Visual Studio
7. Postman

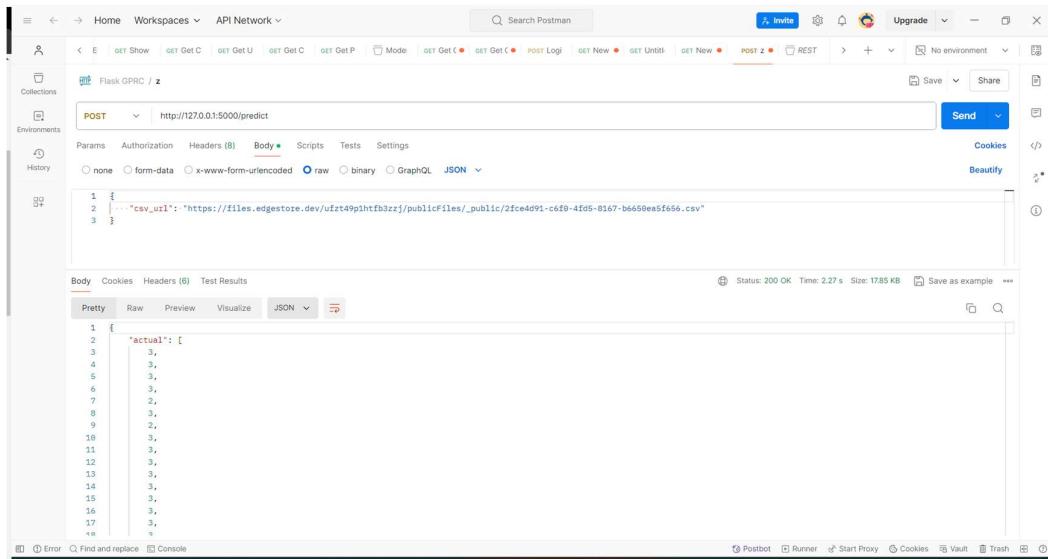
4.1.2. Implementasi Tampilan Antarmuka

Bagian ini akan menjelaskan implementasi tampilan antarmuka pengguna untuk sistem klasifikasi zona tanam mangrove menggunakan metode GPRC. Implementasi antarmuka pengguna bertujuan untuk memastikan bahwa interaksi antara pengguna dan sistem berjalan secara efisien dan intuitif. Dengan menggunakan framework Flask untuk backend dan Next.js untuk frontend, aplikasi ini dirancang untuk memberikan pengalaman pengguna yang optimal. Pada subbab ini, akan diuraikan langkah-langkah pengembangan dan integrasi antarmuka, serta bagaimana tampilan tersebut berkontribusi terhadap keseluruhan fungsi sistem. Frontend dan backend aplikasi akan dihubungkan melalui REST API, memungkinkan komunikasi yang lancar antara komponen-komponen sistem.

4.1.2.1. Implementasi Bagian Backend

Bagian *backend* pada sistem ini merupakan bagian yang bertanggung jawab dalam menangani logika dan pemrosesan data yang diperlukan untuk melakukan klasifikasi zona tanam mangrove menggunakan metode GPRC. *Backend* ini dibangun menggunakan *framework* Flask, yang dipilih karena kemampuannya dalam memfasilitasi pembuatan, pelatihan, dan penggunaan model machine learning secara efisien.

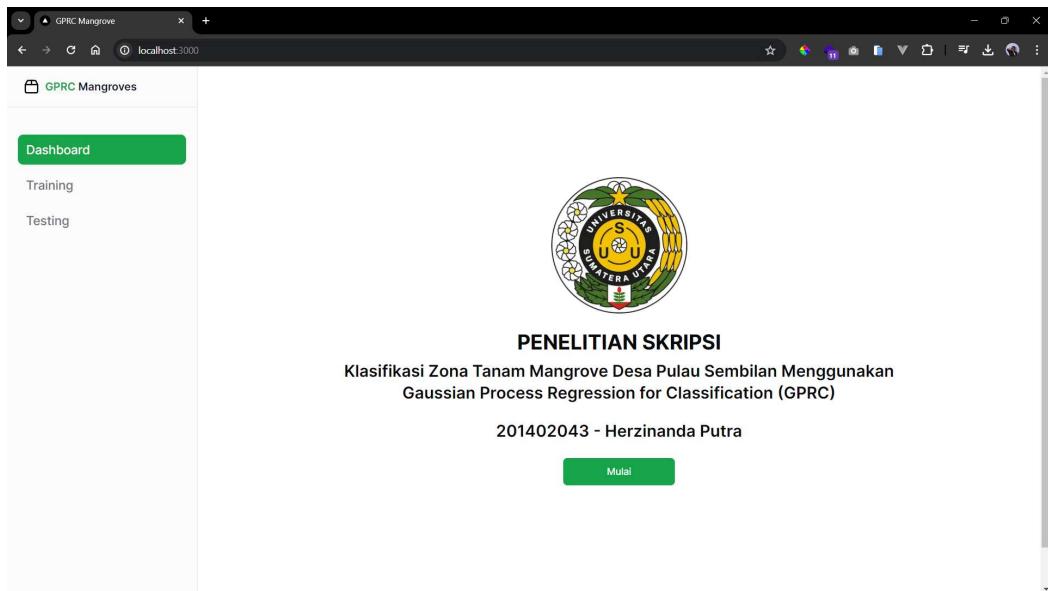
Flask menyediakan beragam fitur dan alat yang memungkinkan penggunaan model *machine learning* dengan mudah, termasuk pembuatan *endpoint* API untuk berkomunikasi dengan *frontend*, pengaturan *routing*, dan manajemen data. Gambar 4.1 menampilkan tampilan dari aplikasi Postman yang sedang menguji mengirim HTTP *request* ke *endpoint* API dan menerima respons.



Gambar 4.1 Tampilan Aplikasi Postman Saat Sedang Menguji *Endpoint API* dan Menerima Respons

4.1.2.2. Implementasi Halaman Beranda

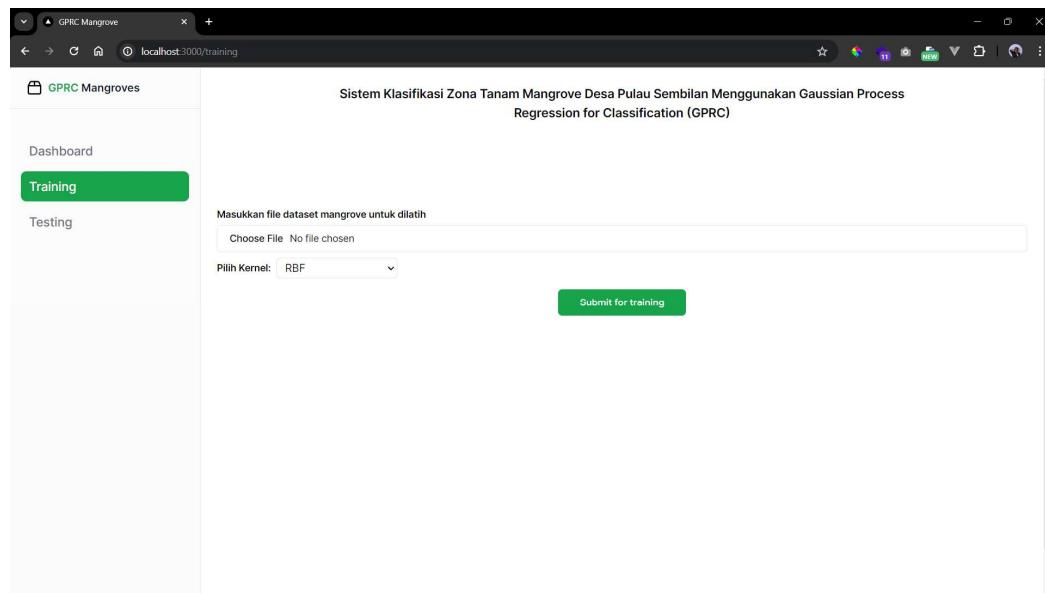
Setelah mengembangkan bagian *backend*, selanjutnya adalah mengembangkan bagian *frontend*. Gambar 4.2 menampilkan halaman beranda pada sistem web Klasifikasi Zona Tanam Mangrove ini. Pada halaman ini terdapat lambang Universitas Sumatera Utara, judul penelitian, dan informasi penulis.



Gambar 4.2 Tampilan Antarmuka Halaman *Home*

4.1.2.3. Implementasi Halaman Training

Setelah pengguna mengeklik tombol “mulai” pada halaman *Home*. Selanjutnya pengguna diarahkan ke halaman *training*. Halaman ini bertujuan untuk melatih model klasifikasi zona tanam mangrove dengan metode GPRC dengan *dataset* yang diinginkan. Gambar 4.3 menampilkan tampilan awal dari halaman *training*. Terdapat satu form input file, dan sebuah kolom untuk input pilihan *kernel* agar pengguna dapat memasukkan dataset beserta *kernel* yang ingin dilatih.



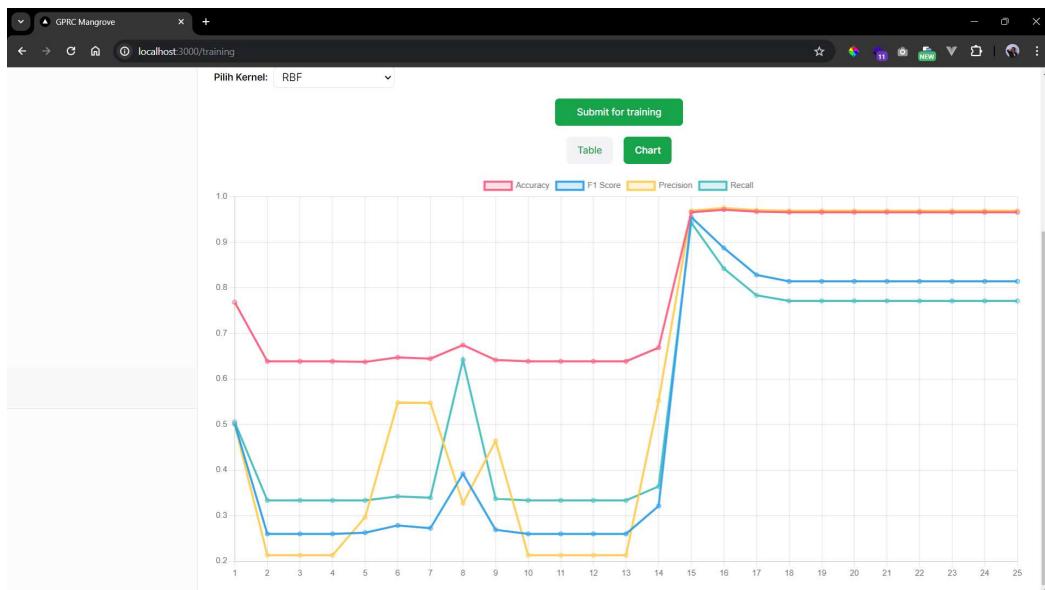
Gambar 4.3 Tampilan Antarmuka Halaman Input File *Training*

Gambar 4.4 merupakan tampilan antarmuka halaman hasil *training* dalam bentuk tabel. Pada halaman ini terdapat informasi hasil dari *training* dengan *dataset* yang dimasukkan dalam bentuk tabel dengan 25 kali iterasi. Tabel memuat metrik akurasi, *F1-Score*, *precision*, dan *recall*.

Iteration	Accuracy	F1-Score	Precision	Recall
1	0.768136558	0.50144338	0.500453202	0.505440381
2	0.638691323	0.259837963	0.212897108	0.333333333
3	0.638691323	0.259837963	0.212897108	0.333333333
4	0.638691323	0.259837963	0.212897108	0.333333333
5	0.637268848	0.262467884	0.296494993	0.333316981
6	0.647226174	0.278365753	0.548063128	0.342143906
7	0.644381223	0.272287333	0.547448736	0.339207048
8	0.674253201	0.391610156	0.327032454	0.641975309
9	0.641536273	0.26882061	0.463638531	0.336996229
10	0.638691323	0.259837963	0.212897108	0.333333333
11	0.638691323	0.259837963	0.212897108	0.333333333
12	0.638691323	0.259837963	0.212897108	0.333333333
13	0.638691323	0.259837963	0.212897108	0.333333333
14	0.638691323	0.259837963	0.212897108	0.333333333
15	0.950001223	0.950001223	0.950001223	0.950001223

Gambar 4.4 Tampilan Antarmuka Halaman Tabel Hasil *Training*

Gambar 4.5 menunjukkan tampilan antarmuka halaman hasil *training* dalam bentuk grafik.



Gambar 4.5 Tampilan Antarmuka Grafik Hasil *Training*

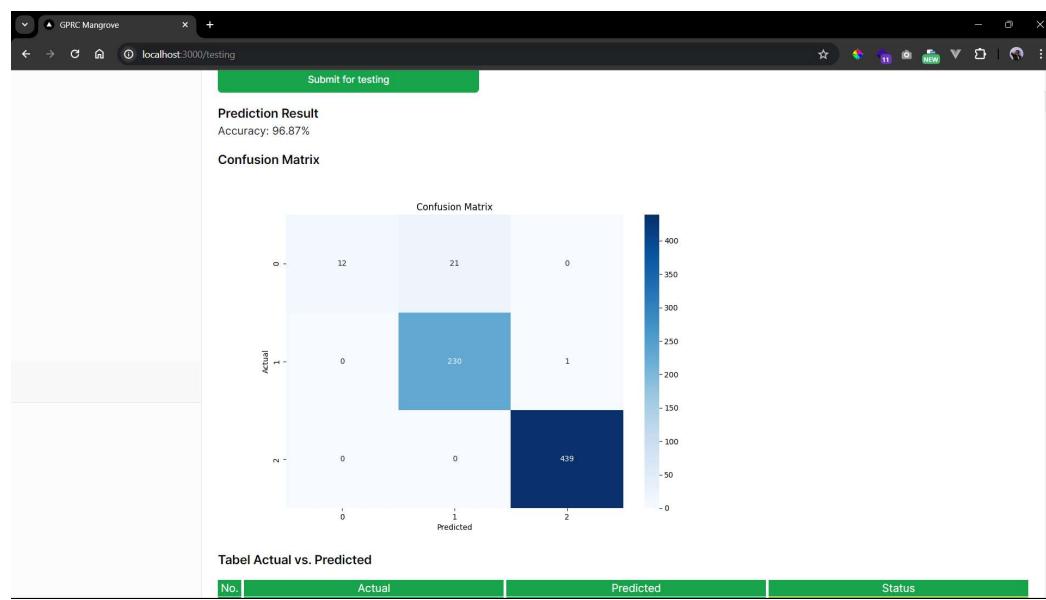
4.1.2.4. Implementasi Halaman *Testing*

Halaman selanjutnya adalah halaman *testing*. Halaman ini bertujuan untuk menguji model klasifikasi dengan dataset yang diinginkan. Gambar 4.6 menunjukkan tampilan

awal dari halaman *testing*. Terdapat sebuah *form input file* dan kolom untuk memilih kernel yang ingin digunakan untuk dilakukan pengujian.

Gambar 4.6 Tampilan Antarmuka Halaman *Input File Testing*

Setelah dataset pengujian dimasukkan, selanjutnya akan ditampilkan hasil klasifikasi berupa akurasi, *confusion matrix*, serta perbandingan tabel *actual* dan *predicted* dari data. Gambar 4.7 menunjukkan tampilan web sistem klasifikasi zona tanam mangrove dengan metode GPRC untuk halaman hasil *testing*.



Gambar 4.7 Tampilan Antarmuka Halaman Hasil *Testing*

4.2 Model Training

Proses model training dilakukan dengan menggunakan method *GaussianProcessClassifier* yang terdapat pada library *scikit-learn*. Model *GaussianProcessClassifier* akan diinisialisasi dengan melibatkan berbagai kernel seperti RBF kernel, Matern kernel, dan rational quadratic kernel. Pada tahap inisialisasi, masing-masing model diinisialisasi dengan kernel yang sesuai menggunakan scikit-learn dengan parameter default digunakan sebagai titik awal.

4.2.1. Training Model dengan RBF Kernel

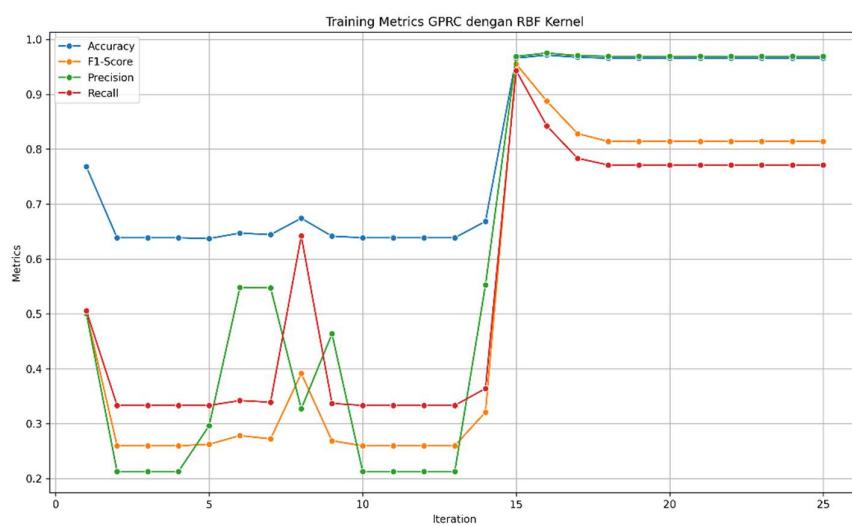
Pada proses pelatihan dengan *RBF kernel*, dilakukan iterasi sebanyak 25 kali untuk melihat akurasi optimal dari model. Tabel 4.1 menampilkan hasil pelatihan GPRC dengan kernel RBF. Dapat dilihat pada tabel bahwa pada iterasi pertama, nilai akurasi sebesar 76%, *F1-Score* sebesar 50%, *precision* sebesar 50%, dan *recall* sebesar 50%. Nilai ini kemudian turun mulai dari iterasi ke-2 hingga iterasi ke-14, dan mencapai nilai akurasi tertinggi pada iterasi ke-17, yakni sebesar 97,15%. Namun, tingginya nilai akurasi ini tidak diikuti dengan metrik evaluasi yang lain. Nilai *F1-Score* dan *recall* tertinggi terjadi pada iterasi ke-15, sedangkan nilai *precision* tertinggi terjadi pada iterasi ke-16. Nilai-nilai ini kemudian stabil mulai dari iterasi ke-18 hingga iterasi ke-25.

Tabel 4.1 Hasil *training* dengan kernel RBF

Iterasi	Accuracy	F1-Score	Precision	Recall
1	0.768136558	0.50144338	0.500453202	0.505440381
2	0.638691323	0.259837963	0.212897108	0.333333333
3	0.638691323	0.259837963	0.212897108	0.333333333
4	0.638691323	0.259837963	0.212897108	0.333333333
5	0.637268848	0.262467884	0.296494993	0.333316981
6	0.647226174	0.278365753	0.548063128	0.342143906
7	0.644381223	0.272287333	0.547448736	0.339207048
8	0.674253201	0.391610156	0.327032454	0.641975309
9	0.641536273	0.26882061	0.463638531	0.336996229
10	0.638691323	0.259837963	0.212897108	0.333333333
11	0.638691323	0.259837963	0.212897108	0.333333333

12	0.638691323	0.259837963	0.212897108	0.333333333
13	0.638691323	0.259837963	0.212897108	0.333333333
14	0.6685633	0.321114153	0.552785924	0.364170338
15	0.965860597	0.955081921	0.969065258	0.943003209
16	0.971550498	0.887431126	0.975207462	0.842282536
17	0.967283073	0.828342251	0.970450424	0.783490999
18	0.965860597	0.814157009	0.9692014	0.77114532
19	0.965860597	0.814157009	0.9692014	0.77114532
20	0.965860597	0.814157009	0.9692014	0.77114532
21	0.965860597	0.814157009	0.9692014	0.77114532
22	0.965860597	0.814157009	0.9692014	0.77114532
23	0.965860597	0.814157009	0.9692014	0.77114532
24	0.965860597	0.814157009	0.9692014	0.77114532
25	0.965860597	0.814157009	0.9692014	0.77114532

Gambar 4.8 menampilkan visualisasi grafik hasil pelatihan dengan menggunakan *kernel RBF*. Gambar menunjukkan bahwa terjadi fluktuasi nilai khususnya pada metrik evaluasi *F1-Score*, *precision*, dan *recall* di iterasi ke-2 hingga iterasi ke-13. Kemudian grafik cenderung menaik pada iterasi ke-14 hingga iterasi ke-15, dan stabil mulai dari iterasi ke-18 hingga iterasi ke-25.



Gambar 4.8 Grafik Hasil Training model GPRC dengan *Kernel RBF*

Nilai akhir akurasi pada pelatihan model GPRC dengan *kernel RBF* adalah 96,586%, dengan nilai *F1-Score* sebesar 81,415%, *precision* sebesar 96,92%, dan *recall* sebesar 77,114%.

4.2.2. Training Model dengan Matern Kernel

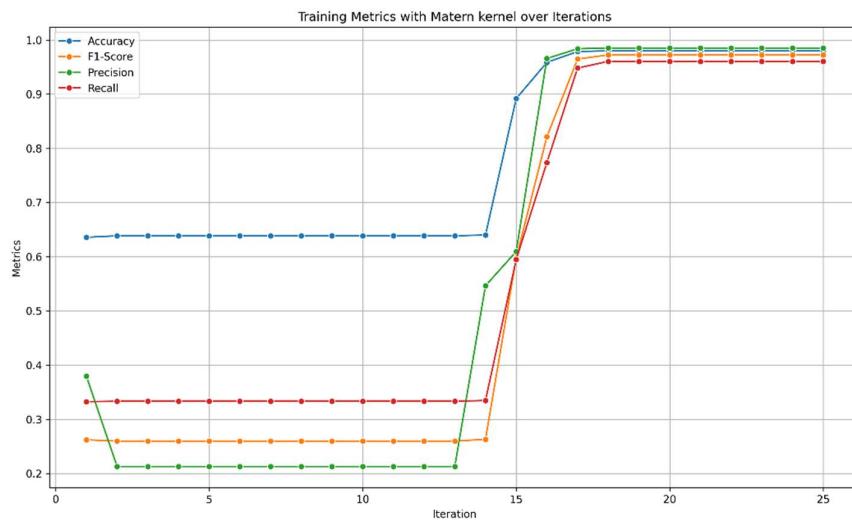
Proses selanjutnya adalah melatih model dengan *kernel Matern*. Pada proses ini dilakukan iterasi sebanyak 25 kali, untuk melatih model dengan optimal. Tabel 4.2 menampilkan hasil pelatihan GPRC dengan *kernel Matern*. Pada iterasi pertama, didapat nilai akurasi sebesar 63,58%, *F1-Score* sebesar 26,21%, *precision* sebesar 37,96%, dan *recall* sebesar 33,25%. Pada iterasi ke-2, terjadi penurunan nilai *precision* yang cukup signifikan menjadi 21,28%. Nilai-nilai ini kemudian cenderung stabil pada iterasi ke-2 hingga iterasi ke-13. Pada iterasi ke-14 hingga iterasi ke-18, terjadi peningkatan nilai pada semua metrik. Pada iterasi ke-18, nilai akurasi sebesar 98,00%, nilai *F1-Score* sebesar 97,24%, *precision* sebesar 98,52%, dan *recall* sebesar 96,05%. Nilai-nilai ini stabil hingga iterasi ke-25.

Tabel 4.2 Hasil training dengan kernel Matern

Iterasi	Accuracy	F1-Score	Precision	Recall
1	0.635846373	0.262138177	0.37965616	0.332574591
2	0.638691323	0.259837963	0.212897108	0.333333333
3	0.638691323	0.259837963	0.212897108	0.333333333
4	0.638691323	0.259837963	0.212897108	0.333333333
5	0.638691323	0.259837963	0.212897108	0.333333333
6	0.638691323	0.259837963	0.212897108	0.333333333
7	0.638691323	0.259837963	0.212897108	0.333333333
8	0.638691323	0.259837963	0.212897108	0.333333333
9	0.638691323	0.259837963	0.212897108	0.333333333
10	0.638691323	0.259837963	0.212897108	0.333333333
11	0.638691323	0.259837963	0.212897108	0.333333333
12	0.638691323	0.259837963	0.212897108	0.333333333
13	0.638691323	0.259837963	0.212897108	0.333333333
14	0.640113798	0.262987689	0.546533713	0.334801762

15	0.891891892	0.597574322	0.60965251	0.594713656
16	0.958748222	0.821553506	0.965869896	0.773954388
17	0.978662873	0.964920039	0.983788835	0.948245971
18	0.980085349	0.972420414	0.98522443	0.96059165
19	0.980085349	0.972420414	0.98522443	0.96059165
20	0.980085349	0.972420414	0.98522443	0.96059165
21	0.980085349	0.972420414	0.98522443	0.96059165
22	0.980085349	0.972420414	0.98522443	0.96059165
23	0.980085349	0.972420414	0.98522443	0.96059165
24	0.980085349	0.972420414	0.98522443	0.96059165
25	0.980085349	0.972420414	0.98522443	0.96059165

Gambar 4.9 menampilkan grafik hasil *training* dengan kernel Matern. Dapat dilihat pada gambar bahwa metrik pelatihan cenderung stabil pada iterasi ke-1 hingga iterasi ke-13, kecuali untuk *precision* yang terjadi penurunan nilai di iterasi ke-2. Pada iterasi ke 14 hingga iterasi ke-18 seluruh metrik mengalami kenaikan nilai dan mencapai nilai tertinggi pada iterasi ke-19. Selanjutnya, nilai-nilai ini stabil sampai iterasi ke-25.



Gambar 4.9 Grafik Hasil *Training* Model GPRC dengan Kernel Matern

Nilai akhir akurasi pada pelatihan model GPRC dengan kernel Matern adalah 98,008%, dengan nilai *F1-Score* sebesar 97,242%, *precision* sebesar 98,522%, dan *recall* sebesar 96,059%.

4.2.3. Training Model dengan Rational Quadratic Kernel

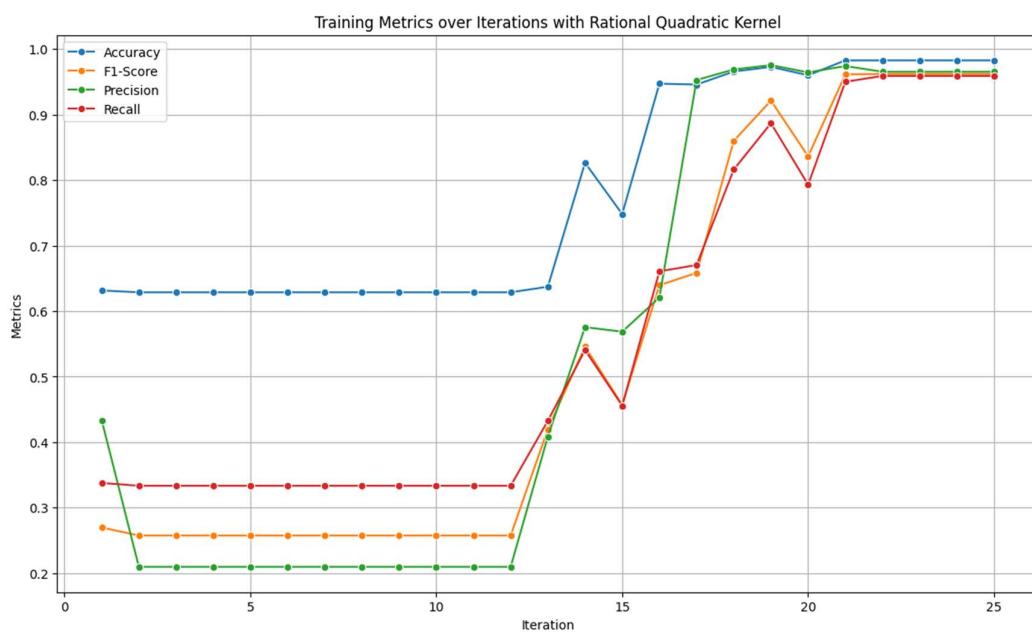
Kernel ketiga yang akan digunakan adalah kernl *Rational Quadratic*. Proses pelatihan model GPRC dengan *kernel rational quadratic* dilakukan dengan 25 kali iterasi. Tabel 4.3 menampilkan hasil pelatihan model GPRC dengan *kernel rational quadratic*. Pada iterasi ke-1, nilai akurasi *F1-Score*, *precision*, dan *recall* berturut-turut sebesar 63,15%, 26,95%, 43,33%, dan 33,76%. Pada iterasi ke-2, keempat metrik ini menunjukkan penurunan nilai, yakni akurasi sebesar 62,87%, *F1-Score* sebesar 25,73%, *precision* sebesar 20,95%, dan *recall* sebesar 33,335. Nilai ini stabil sampai ke iterasi ke-12. Pada iterasi ke-13 sampai iterasi ke-22 nilai metrik mengalami fluktuasi namun trennya menaik. Pada iterasi ke-23 hingga iterasi ke-25, nilai metrik menunjukkan nilai tertinggi dengan rincian akurasi sebesar 98,29%, *F1-Score* sebesar 96,22%, *precision* sebesar 96,55%, dan *recall* sebesar 95,51%.

Tabel 4.3 Hasil *training* dengan *kernel Rational Quadratic*

Iterasi	Accuracy	F1-Score	Precision	Recall
1	0.631578947	0.26956348	0.433557477	0.337647454
2	0.628733997	0.257350801	0.209577999	0.333333333
3	0.628733997	0.257350801	0.209577999	0.333333333
4	0.628733997	0.257350801	0.209577999	0.333333333
5	0.628733997	0.257350801	0.209577999	0.333333333
6	0.628733997	0.257350801	0.209577999	0.333333333
7	0.628733997	0.257350801	0.209577999	0.333333333
8	0.628733997	0.257350801	0.209577999	0.333333333
9	0.628733997	0.257350801	0.209577999	0.333333333
10	0.628733997	0.257350801	0.209577999	0.333333333
11	0.628733997	0.257350801	0.209577999	0.333333333
12	0.628733997	0.257350801	0.209577999	0.333333333
13	0.637268848	0.419676993	0.408658503	0.432554816
14	0.826458037	0.545681162	0.575546534	0.540572494

15	0.748221906	0.456856866	0.568589254	0.455604076
16	0.947368421	0.639561887	0.620819587	0.660791559
17	0.945945946	0.658474924	0.952854021	0.670401386
18	0.965860597	0.860047717	0.969030259	0.816234719
19	0.972972973	0.921419816	0.975683528	0.886941634
20	0.960170697	0.836409593	0.964521564	0.793191634
21	0.982930299	0.9614084	0.974221187	0.950195782
22	0.982930299	0.962238459	0.965531099	0.959156845
23	0.982930299	0.962238459	0.965531099	0.959156845
24	0.982930299	0.962238459	0.965531099	0.959156845
25	0.982930299	0.962238459	0.965531099	0.959156845

Gambar 4.10 menunjukkan grafik hasil *training* model GPRC dengan *kernel rational quadratic*. Dapat dilihat bahwa semua metrik mengalami penurunan nilai pada iterasi ke-2. Kemudian nilai ini cenderung stabil dari iterasi ke-2 hingga iterasi ke-12. Dari iterasi ke-13 sampai iterasi ke-22, grafik menunjukkan peningkatan secara fluktuatif, dan mencapai nilai puncak pada iterasi ke-23 hingga iterasi ke-25.



Gambar 4.10 Grafik Hasil *Training* Model GPRC dengan *Kernel Rational Quadratic*

Nilai akhir akurasi pada pelatihan model GPRC dengan *kernel rational quadratic* adalah 98,293%, dengan nilai *F1-Score* sebesar 96,223%, *precision* sebesar 96,553%, dan *recall* sebesar 95,915%.

4.2.4. Kesimpulan Training Model

Setelah melakukan *training* model, hasil metrik pelatihan dari masing-masing *kernel* dianalisis dan dibandingkan. Tabel 4.4 menampilkan perbandingan hasil metrik pelatihan dari ketiga *kernel* yang digunakan. Dapat dilihat pada tabel bahwa *kernel rational quadratic* berhasil mendapatkan akurasi tertinggi sebesar 98,293%, diikuti *kernel Matern* sebesar 98%, dan *kernel RBF* sebesar 96,58%. Untuk metrik pelatihan *F1-Score*, *precision*, dan *recall*, nilai tertinggi didapatkan oleh *kernel Matern* dengan nilai berturut-turut sebesar 97,242%, 98,522%, dan 96,059%.

Tabel 4.4 Perbandingan Hasil *training kernel RBF, Matern*, dan Rational Quadratic

Kernel	Accuracy	F1-Score	Precision	Recall
RBF	0.965860597	0.814157009	0.9692014	0.77114532
Matern	0.980085349	0.972420414	0.98522443	0.96059165
Rational Quadratic	0.982930299	0.962238459	0.965531099	0.959156845

4.3 Model Testing

Pada bagian ini, akan dijabarkan pengujian yang diterapkan untuk mengevaluasi efektivitas model GPRC yang telah dipelajari dengan tiga kernel yang berbeda, *Radial Basis Function (RBF)*, *Matern*, dan *Rational Quadratic*. Setelah model dilatih, dilakukan pengujian pada data pengujian menggunakan ketiga kernel. Proses pengujian dilakukan dengan menghitung *confusion matrix*, akurasi, *F1-Score*, *precision*, dan *recall* untuk setiap *kernel* berdasarkan hasil prediksi dan nilai aktual.

Tabel 4.5 berisikan 703 data pengujian yang menunjukkan perbandingan antara nilai *actual* dan *predicted* berserta status kebenarannya. Tabel ini memberikan gambaran detail mengenai seberapa baik masing-masing model dalam memprediksi nilai kelas dari data pengujian. Kolom “Actual” adalah nilai kelas sebenarnya dari data pengujian. Kolom “Predicted” berisi prediksi kelas yang dihasilkan oleh *kernel RBF*, *Matern*, dan *Rational Quadratic*. Kolom “Status” berisi indikator apakah prediksi oleh

masing-masing kernel benar (TRUE) atau salah (FALSE). *Seaward zone* diwakili oleh kelas 1, *mid zone* diwakili oleh kelas 2, dan *landward zone* diwakili oleh kelas 3.

Tabel 4.5 Perbandingan nilai actual dan predicted dari masing-masing kernel

No.	Actual	Predicted			Status		
		RBF	Matern	Rational Quadratic	RBF	Matern	Rational Quadratic
1	3	3	3	3	TRUE	TRUE	TRUE
2	3	3	3	3	TRUE	TRUE	TRUE
3	2	2	2	2	TRUE	TRUE	TRUE
4	3	3	3	3	TRUE	TRUE	TRUE
5	1	2	2	2	FALSE	FALSE	FALSE
6	2	2	2	2	TRUE	TRUE	TRUE
7	2	2	2	2	TRUE	TRUE	TRUE
:	:	:	:	:	:	:	:
697	1	1	1	1	TRUE	TRUE	TRUE
698	3	3	3	3	TRUE	TRUE	TRUE
699	3	3	3	3	TRUE	TRUE	TRUE
700	3	3	3	3	TRUE	TRUE	TRUE
701	3	3	3	3	TRUE	TRUE	TRUE
702	2	2	2	2	TRUE	TRUE	TRUE
703	3	3	3	3	TRUE	TRUE	TRUE

Tabel 4.6 menampilkan akumulasi nilai prediksi yang tepat dalam konteks klasifikasi. Terlihat dari data aktual bahwa terdapat 30 entitas dalam kelas 1, 220 entitas dalam kelas 2, dan 453 entitas dalam kelas 3, dengan jumlah total entitas aktual sebanyak 703. Pada metode *kernel RBF*, jumlah entitas yang diprediksi dengan benar dalam kelas 1, 2, dan 3 adalah masing-masing sebanyak 13, 217, dan 448, dengan total prediksi yang tepat mencapai 678 entitas. Sedangkan pada metode *kernel Matern*, total entitas yang diprediksi dengan benar adalah 682, terdiri dari 13 entitas dalam kelas 1, 225 entitas dalam kelas 2, dan 444 entitas dalam kelas 3. Sementara pada metode *kernel Rational Quadratic*, jumlah entitas yang diprediksi dengan benar dalam kelas 1, 2, dan

3 berturut-turut sebanyak 24, 219, dan 447 entitas, dengan total 690 entitas yang diprediksi secara tepat.

Tabel 4.6 Akumulasi nilai *actual* dan *predicted* dengan tiga kernel

Kelas	Actual	Predicted		
		RBF	Matern	RQ
1 (<i>seaward zone</i>)	30	13	13	24
2 (<i>mid zone</i>)	220	217	225	219
3 (<i>landward zone</i>)	453	448	444	447
Total	703	678	682	690

Setelah mendapatkan nilai *actual* dan *predicted* dari data pengujian, langkah selanjutnya adalah melakukan perhitungan terhadap metrik evaluasi yang meliputi akurasi, *F1-Score*, *precision*, dan *recall*. Tabel 4.7 memperlihatkan hasil perhitungan nilai metrik evaluasi untuk model GPRC dengan tiga kernel yang berbeda.

Tabel 4.7 Hasil pengujian model GPRC dengan 3 kernel berbeda

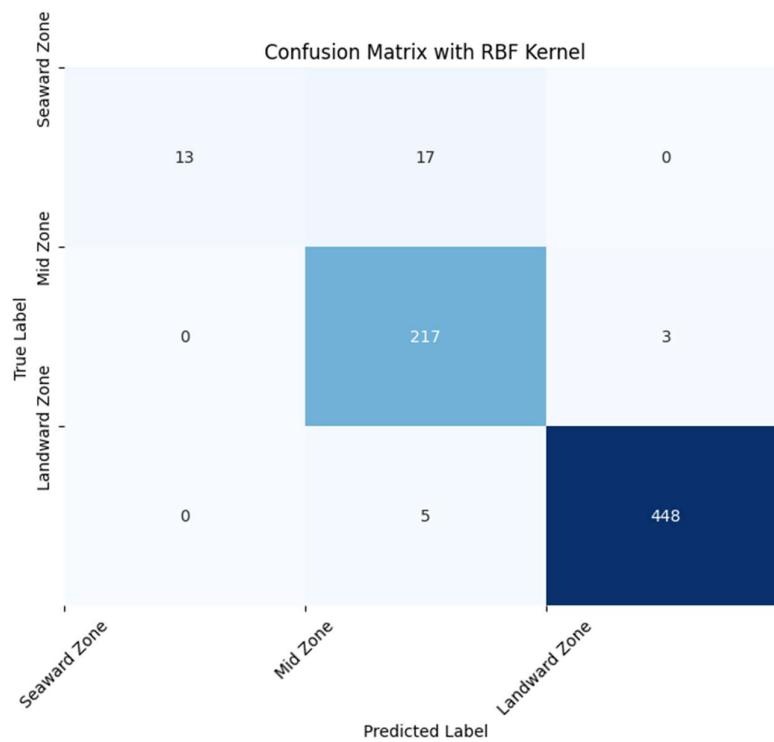
Kernel	Accuracy	F1-Score	Precision	Recall
RBF	0.964438122	0.847111791	0.967099302	0.802886481
Matern	0.970128023	0.93675356	0.961674074	0.916840591
Rational Quadratic	0.981507824	0.957052859	0.983098417	0.936219814

Tabel tersebut menggambarkan hasil evaluasi kinerja model GPRC dengan ketiga kernel yang berbeda, yaitu RBF, *Matern*, dan *Rational Quadratic*, yang diukur berdasarkan metrik akurasi, *F1-Score*, *precision*, dan *recall*.

Berikutnya, dilakukan pembuatan *confusion matrix* untuk mengidentifikasi serta mengevaluasi performa model dalam memprediksi kelas-kelas data uji. *Confusion matrix* menyajikan gambaran yang komprehensif tentang jumlah prediksi yang tepat dan tidak tepat untuk setiap kelas, memungkinkan analisis mendalam terhadap akurasi dan kesalahan model.

Gambar 4.11 menampilkan gambar *confusion matrix* dari hasil pengujian dengan *kernel RBF*. Dari gambar ini, terlihat bahwa model mampu memprediksi

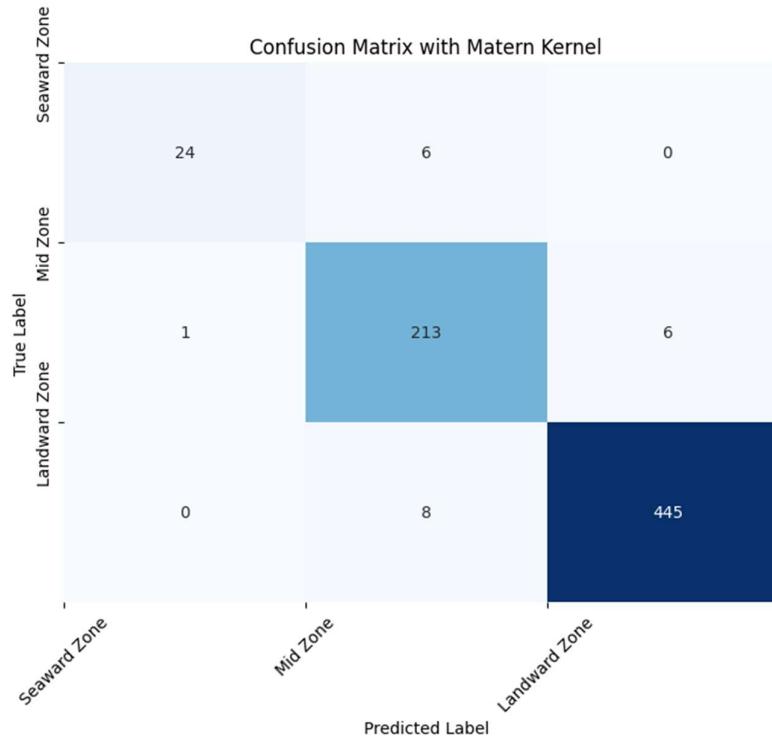
dengan benar 13 entitas sebagai *Seaward Zone*, namun salah memprediksi 17 entitas sebagai *Mid Zone*, dan tidak ada yang salah diprediksi sebagai *Landward Zone*. Untuk kategori *Mid Zone*, model menunjukkan kinerja yang lebih baik dengan memprediksi 217 entitas dengan benar, tetapi masih ada 3 entitas yang salah diprediksi sebagai *Landward Zone*. Sementara itu, kategori *Landward Zone* menunjukkan performa yang paling tinggi dengan 448 entitas diprediksi dengan benar dan hanya 5 entitas yang salah diprediksi sebagai *Mid Zone*.



Gambar 4.11 Confusion Matrix Hasil Pengujian dengan Kernel RBF

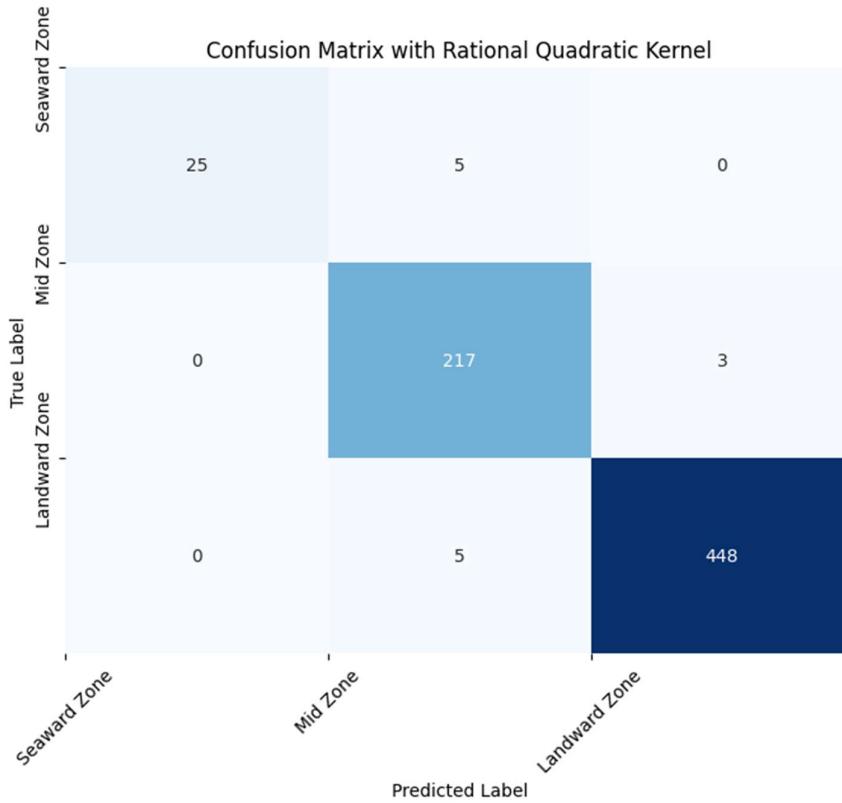
Selanjutnya, Gambar 4.12 menampilkan gambar *confusion matrix* dari hasil pengujian dengan *kernel Matern*. Dalam kategori *Seaward Zone*, model berhasil memprediksi 24 entitas dengan benar, sementara terdapat 6 entitas yang salah diprediksi sebagai *Mid Zone*, dan tidak ada entitas yang salah diprediksi sebagai *Landward Zone*. Untuk kategori *Mid Zone*, model menunjukkan akurasi yang cukup tinggi dengan 213 entitas diprediksi dengan benar. Namun, terdapat 1 entitas yang salah diprediksi sebagai *Seaward Zone* dan 6 entitas lainnya salah diprediksi sebagai *Landward Zone*. Pada kategori *Landward Zone*, model menunjukkan performa yang sangat baik dengan 445

entitas diprediksi dengan benar dan hanya 8 entitas yang salah diprediksi sebagai *Mid Zone*, tanpa ada kesalahan prediksi sebagai *Seaward Zone*.



Gambar 4.12 Confusion Matrix Hasil Pengujian dengan Kernel Matern

Terakhir, Gambar 4.13 menunjukkan gambar *confusion matrix* dari hasil pengujian dengan kernel *Rational Quadratic*. Dari gambar ini, dapat dilihat bahwa untuk kategori *Seaward Zone*, model memprediksi dengan benar 25 entitas, namun salah memprediksi 5 entitas sebagai *Mid Zone*. Tidak ada kesalahan prediksi ke *Landward Zone* dalam kategori ini. Untuk kategori *Mid Zone*, model menunjukkan kinerja yang baik dengan 217 entitas diprediksi dengan benar, namun terdapat 3 kesalahan prediksi ke *Landward Zone*. Tidak ada kesalahan prediksi ke *Seaward Zone*. Pada kategori *Landward Zone*, model menunjukkan performa yang sangat baik dengan 448 entitas diprediksi dengan benar, meskipun ada 5 kesalahan prediksi ke *Mid Zone*, dan tidak ada kesalahan prediksi ke *Seaward Zone*.



Gambar 4.13 Confusion Matrix Hasil Pengujian dengan Kernel Rational Quadratic

Ketiga visualisasi *confusion matrix* yang disajikan menggambarkan performa model klasifikasi yang menggunakan kernel RBF, Matern, dan Rational Quadratic dalam mengelompokkan data ke dalam kategori *seaward zone*, *mid zone*, dan *landward zone*. Secara keseluruhan, semua model menunjukkan kinerja yang memuaskan, terutama dalam pengelompokan Mid Zone dan Landward Zone. Model dengan *kernel Rational Quadratic* menunjukkan akurasi tertinggi, dengan kesalahan prediksi yang minimal di semua kategori. Model dengan *kernel Matérn* juga menunjukkan kinerja yang baik, namun sedikit lebih banyak kesalahan prediksi dibandingkan *Rational Quadratic*. Model dengan *kernel RBF* memiliki kinerja yang paling kurang optimal, terutama dalam mengklasifikasikan *Seaward Zone* dengan jumlah kesalahan prediksi yang lebih tinggi. Secara keseluruhan, model dengan *kernel Rational Quadratic* paling unggul dalam hal akurasi dan reliabilitas, diikuti oleh *Matérn*, dan terakhir *RBF*. Hasil ini memberikan wawasan penting untuk memilih kernel yang optimal dalam tugas klasifikasi dan menjadi dasar untuk pengembangan model lebih lanjut.

BAB 5

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan penelitian yang dilakukan mengenai klasifikasi zona tanam mangrove di Desa Pulau Sembilan menggunakan Gaussian Process Regression for Classification (GPRC) dengan tiga kernel berbeda (RBF, Matern, dan Rational Quadratic), dapat disimpulkan sebagai berikut:

1. Pemilihan kernel sangat mempengaruhi performa model GPRC dalam klasifikasi zona tanam mangrove. Hasil penelitian menunjukkan variasi signifikan dalam akurasi dan metrik evaluasi lainnya tergantung pada kernel yang digunakan.
2. Kernel Rational Quadratic menunjukkan performa terbaik dengan akurasi pelatihan sebesar 98,293% dan akurasi pengujian 98,15%. Kernel ini juga memiliki F1-Score 95,71%, precision 98,31%, dan recall 93,62%, menjadikannya pilihan yang direkomendasikan untuk klasifikasi zona tanam mangrove.
3. Analisis confusion matrix mengungkapkan bahwa penggunaan kernel yang tepat dapat mengurangi tingkat kesalahan klasifikasi antara zona tanam yang berbeda. Kernel Rational Quadratic memiliki kesalahan klasifikasi paling sedikit dibandingkan dengan kernel lainnya.
4. Penelitian ini menunjukkan bahwa metode GPRC dengan pemilihan kernel yang sesuai dapat menjadi alat yang efektif untuk membantu petani dan masyarakat setempat dalam menentukan zona tanam mangrove yang optimal

5.2 Saran

Dari hasil penelitian yang telah dilaksanakan, berikut beberapa saran yang dapat diajukan untuk mengatasi kelemahan yang ada, melakukan perbaikan, dan memberikan arahan untuk penelitian berikutnya.

1. Salah satu kelemahan utama penelitian ini adalah jumlah data yang terbatas, terutama untuk *seaward zone*. Untuk memperoleh hasil yang lebih representatif dan meningkatkan akurasi klasifikasi, perlu dilakukan pengumpulan data tambahan khususnya untuk *seaward zone*. Hal ini dapat membantu model dalam mengenali pola yang lebih kompleks dan meningkatkan performa klasifikasi secara keseluruhan.
2. Selain mengembangkan *dataset* dari sumber yang ada, sebaiknya dilakukan diversifikasi sumber data dengan melibatkan lebih banyak lokasi di Desa Pulau Sembilan atau wilayah lain di sekitar Kabupaten Langkat. Dengan demikian, model akan lebih robust dan mampu menangani variasi yang lebih luas dari kondisi lingkungan.
3. Penelitian ini hanya menggunakan tiga jenis *kernel* (*RBF, Matern, dan Rational Quadratic*). Penelitian selanjutnya dapat mengeksplorasi *kernel*-*kernel* lain yang mungkin memberikan performa yang lebih baik atau sesuai dengan karakteristik data yang berbeda.
4. Penggunaan parameter *default* dalam model pelatihan bisa jadi belum optimal. Penelitian selanjutnya sebaiknya melakukan *hyperparameter tuning* untuk menemukan kombinasi parameter yang paling optimal untuk setiap *kernel*.
5. Untuk pengembangan selanjutnya, model klasifikasi GPRC dapat dijadikan prototipe model untuk alat klasifikasi zona tanam mangrove yang dapat mengambil data kandungan air dan mengklasifikasikannya dalam waktu yang bersamaan.

DAFTAR PUSTAKA

- A. Faust, M., & A. Gulledge, R. (1996). Associations of microalgae and meiofauna in floating detritus at a mangrove island, Twin Cays, Belize. *Journal of Experimental Marine Biology and Ecology*, 197(2), 159–175. [https://doi.org/10.1016/0022-0981\(95\)00159-X](https://doi.org/10.1016/0022-0981(95)00159-X)
- Adame, M. F., Connolly, R. M., Turschwell, M. P., Lovelock, C. E., Fatoyinbo, T., Lagomasino, D., Goldberg, L. A., Holdorf, J., Friess, D. A., Sasmito, S. D., Sanderman, J., Sievers, M., Buelow, C., Kauffman, J. B., Bryan-Brown, D., & Brown, C. J. (2021). Future carbon emissions from global mangrove forest loss. *Global Change Biology*, 27(12), 2856–2866. <https://doi.org/10.1111/gcb.15571>
- Alongi, D. M. (2002a). Present state and future of the world's mangrove forests. *Environmental Conservation*, 29(3), 331–349. <https://doi.org/10.1017/S0376892902000231>
- Alongi, D. M. (2002b). Present state and future of the world's mangrove forests. *Environmental Conservation*, 29(3), 331–349. <https://doi.org/10.1017/S0376892902000231>
- Alongi, D. M. (2014). Carbon Cycling and Storage in Mangrove Forests. *Annual Review of Marine Science*, 6(1), 195–219. <https://doi.org/10.1146/annurev-marine-010213-135020>
- Altun, Y., Hofmann, T., & Smola, A. J. (2004). Gaussian process classification for segmenting and annotating sequences. *Twenty-First International Conference on Machine Learning - ICML '04*, 4. <https://doi.org/10.1145/1015330.1015433>
- Ball, P. (2008). Water as an Active Constituent in Cell Biology. *Chemical Reviews*, 108(1), 74–108. <https://doi.org/10.1021/cr068037a>
- Banerjee, A., Dunson, D. B., & Tokdar, S. T. (2013). Efficient Gaussian process regression for large datasets. *Biometrika*, 100(1), 75–89. <https://doi.org/10.1093/biomet/ass068>
- Baniaş, O., Florea, D., Gyalai, R., & Curiac, D.-I. (2021). Automated Specification-Based Testing of REST APIs. *Sensors*, 21(16), 5375. <https://doi.org/10.3390/s21165375>

- Bornette, G., & Puijalon, S. (2011). Response of aquatic plants to abiotic factors: a review. *Aquatic Sciences*, 73(1), 1–14. <https://doi.org/10.1007/s00027-010-0162-7>
- Cao, X., Liu, Y., Wang, J., Liu, C., & Duan, Q. (2020). Prediction of dissolved oxygen in pond culture water based on K-means clustering and gated recurrent unit neural network. *Aquacultural Engineering*, 91, 102122. <https://doi.org/10.1016/j.aquaeng.2020.102122>
- Chu, W., & Ghahramani, Z. (2005). Gaussian Processes for Ordinal Regression. *Journal of Machine Learning Research*, 6, 1019–1041.
- Dinas Kelautan dan Perikanan (DKP) Provinsi Sumatera Utara. (2014). *Laporan Tahunan Dinas Kelautan dan Perikanan Provinsi Sumatera Utara*.
- Direktorat Konservasi Tanah dan Air, D. P. (2021). *Peta Mengrove Nasional Tahun 2021*.
- Feller, I. C., Lovelock, C. E., Berger, U., McKee, K. L., Joye, S. B., & Ball, M. C. (2010). Biocomplexity in Mangrove Ecosystems. *Annual Review of Marine Science*, 2(1), 395–417. <https://doi.org/10.1146/annurev.marine.010908.163809>
- Foster, L., Waagen, A., Aijaz, N., Hurley, M., Luis, A., Rinsky, J., Satyavolu, C., Way, M. J., Gazis, P., & Srivastava, A. (2009). Stable and efficient Gaussian process calculations. *Journal of Machine Learning Research*, 10, 857–882.
- Gnansounou, S. C., Salako, K. V., Sagoe, A. A., Mattah, P. A. D., Aheto, D. W., & Glèlè Kakaï, R. (2022). Mangrove Ecosystem Services, Associated Threats and Implications for Wellbeing in the Mono Transboundary Biosphere Reserve (Togo-Benin), West-Africa. *Sustainability*, 14(4), 2438. <https://doi.org/10.3390/su14042438>
- Goldberg, L., Lagomasino, D., Thomas, N., & Fatoyinbo, T. (2020). Global declines in human-driven mangrove loss. *Global Change Biology*, 26(10), 5844–5855. <https://doi.org/10.1111/gcb.15275>
- Hamilton, S. E., & Casey, D. (2016). Creation of a high spatio-temporal resolution global database of continuous mangrove forest cover for the 21st century (CGMFC-21). *Global Ecology and Biogeography*, 25(6), 729–738. <https://doi.org/10.1111/geb.12449>

- Henderson, M. (2002). The interaction of water with solid surfaces: fundamental aspects revisited. *Surface Science Reports*, 46(1–8), 1–308. [https://doi.org/10.1016/S0167-5729\(01\)00020-6](https://doi.org/10.1016/S0167-5729(01)00020-6)
- Hewing, L., Kabzan, J., & Zeilinger, M. N. (2020). Cautious Model Predictive Control Using Gaussian Process Regression. *IEEE Transactions on Control Systems Technology*, 28(6), 2736–2743. <https://doi.org/10.1109/TCST.2019.2949757>
- Ho, Y.-S., & Mukul, S. A. (2021). Publication Performance and Trends in Mangrove Forests: A Bibliometric Analysis. *Sustainability*, 13(22), 12532. <https://doi.org/10.3390/su132212532>
- Hyun-Chul Kim, & Ghahramani, Z. (2006). Bayesian Gaussian Process Classification with the EM-EP Algorithm. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 28(12), 1948–1959. <https://doi.org/10.1109/TPAMI.2006.238>
- Jane, S. F., Hansen, G. J. A., Kraemer, B. M., Leavitt, P. R., Mincer, J. L., North, R. L., Pilla, R. M., Stetler, J. T., Williamson, C. E., Woolway, R. I., Arvola, L., Chandra, S., DeGasperi, C. L., Diemer, L., Dunalska, J., Erina, O., Flaim, G., Grossart, H.-P., Hambright, K. D., ... Rose, K. C. (2021). Widespread deoxygenation of temperate lakes. *Nature*, 594(7861), 66–70. <https://doi.org/10.1038/s41586-021-03550-y>
- Jensen, R. D., & Taylor, S. A. (1961). Effect of temperature on water transport through plants. *Plant Physiology*, 36(5), 639–642. <https://doi.org/10.1104/pp.36.5.639>
- Jia, Wang, Wang, Mao, & Zhang. (2019). A New Vegetation Index to Detect Periodically Submerged Mangrove Forest Using Single-Tide Sentinel-2 Imagery. *Remote Sensing*, 11(17), 2043. <https://doi.org/10.3390/rs11172043>
- Klyuchnikov, N., & Burnaev, E. (2020). Gaussian process classification for variable fidelity data. *Neurocomputing*, 397, 345–355. <https://doi.org/10.1016/j.neucom.2019.10.111>
- Kuss, M., & Rasmussen, C. (2005). Assessing Approximate Inference for Binary Gaussian Process Classification. *J. Mach. Learn. Res.*, 6, 1679–1704.
- Lacoul, P., & Freedman, B. (2006). Environmental influences on aquatic plants in freshwater ecosystems. *Environmental Reviews*, 14(2), 89–136. <https://doi.org/10.1139/a06-001>
- Liu, Z., Lyu, C., Huo, J., Wang, S., & Chen, J. (2022). Gaussian Process Regression for Transportation System Estimation and Prediction Problems: The Deformation and

- a Hat Kernel. *IEEE Transactions on Intelligent Transportation Systems*, 23(11), 22331–22342. <https://doi.org/10.1109/TITS.2022.3155527>
- Lubis, M. I. (2021). *Klasifikasi Zona Tanam Mangrove Berbasis Data Monitoring Wireless Sensor* [Skripsi]. Universitas Sumatera Utara.
- Mahmuda, R., Aritonang, D., & Harefa, M. S. (2023). Mengatasi dalam Rehabilitasi di Kawasan Mangrove di Paluh Merbau, Tanjung Rejo, Kabupaten Deli Serdang. *Humantech: Jurnal Ilmiah Multi Disiplin Indonesia*, 2(3).
- Malik, A., Fensholt, R., & Mertz, O. (2015). Economic Valuation of Mangroves for Comparison with Commercial Aquaculture in South Sulawesi, Indonesia. *Forests*, 6(12), 3028–3044. <https://doi.org/10.3390/f6093028>
- Markfort, C. D., & Hondzo, M. (2009). Dissolved Oxygen Measurements in Aquatic Environments: The Effects of Changing Temperature and Pressure on Three Sensor Technologies. *Journal of Environmental Quality*, 38(4), 1766–1774. <https://doi.org/10.2134/jeq2008.0197>
- Maulana, A. (2021). *Identifikasi Tingkat Kelayakan Hidup Jenis Mangrove Desa Pulau Sembilan Berdasarkan Kandungan Air Menggunakan Long Short Term Memory* [Skripsi Sarjana]. Universitas Sumatera Utara.
- Moore, C. J., Chua, A. J. K., Berry, C. P. L., & Gair, J. R. (2016). Fast methods for training Gaussian processes on large datasets. *Royal Society Open Science*, 3(5), 160125. <https://doi.org/10.1098/rsos.160125>
- Mori, G. M., Zucchi, M. I., & Souza, A. P. (2015). Multiple-Geographic-Scale Genetic Structure of Two Mangrove Tree Species: The Roles of Mating System, Hybridization, Limited Dispersal and Extrinsic Factors. *PLOS ONE*, 10(2), e0118710. <https://doi.org/10.1371/journal.pone.0118710>
- Muhtadi, A., Siregar, R. H., Leidonald, R., & Harahap, Z. A. (2016). Status ekologis mangrove Pulau Sembilan, Kabupaten Langkat Provinsi Sumatera Utara (Ecological status of mangrove of Sembilan Island, Langkat Regency, North Sumatra Province). *Depik*, 5(3). <https://doi.org/10.13170/depik.5.3.5656>
- Mumby, P. J., Edwards, A. J., Ernesto Arias-González, J., Lindeman, K. C., Blackwell, P. G., Gall, A., Gorczynska, M. I., Harborne, A. R., Pescod, C. L., Renken, H., C. C. Wabnitz, C., & Llewellyn, G. (2004a). Mangroves enhance the biomass of coral reef fish communities in the Caribbean. *Nature*, 427(6974), 533–536. <https://doi.org/10.1038/nature02286>

- Mumby, P. J., Edwards, A. J., Ernesto Arias-González, J., Lindeman, K. C., Blackwell, P. G., Gall, A., Gorczynska, M. I., Harborne, A. R., Pescod, C. L., Renken, H., C. C. Wabnitz, C., & Llewellyn, G. (2004b). Mangroves enhance the biomass of coral reef fish communities in the Caribbean. *Nature*, 427(6974), 533–536. <https://doi.org/10.1038/nature02286>
- Obrezanova, O., & Segall, M. D. (2010). Gaussian Processes for Classification: QSAR Modeling of ADMET and Target Activity. *Journal of Chemical Information and Modeling*, 50(6), 1053–1061. <https://doi.org/10.1021/ci900406x>
- Olson, R. S., La Cava, W., Orzechowski, P., Urbanowicz, R. J., & Moore, J. H. (2017). PMLB: a large benchmark suite for machine learning evaluation and comparison. *BioData Mining*, 10(1), 36. <https://doi.org/10.1186/s13040-017-0154-4>
- Panos, A., Dellaportas, P., & Titsias, M. K. (2021). Large scale multi-label learning using Gaussian processes. *Machine Learning*, 110(5), 965–987. <https://doi.org/10.1007/s10994-021-05952-5>
- Pham, T., Yokoya, N., Bui, D., Yoshino, K., & Friess, D. (2019). Remote Sensing Approaches for Monitoring Mangrove Species, Structure, and Biomass: Opportunities and Challenges. *Remote Sensing*, 11(3), 230. <https://doi.org/10.3390/rs11030230>
- Ranjan, R., Huang, B., & Fatehi, A. (2016). Robust Gaussian process modeling using EM algorithm. *Journal of Process Control*, 42, 125–136. <https://doi.org/10.1016/j.jprocont.2016.04.003>
- Rasmussen, C. E., & Williams, C. K. I. (2005). *Gaussian Processes for Machine Learning*. The MIT Press. <https://doi.org/10.7551/mitpress/3206.001.0001>
- Richards, D. R., & Friess, D. A. (2016). Rates and drivers of mangrove deforestation in Southeast Asia, 2000–2012. *Proceedings of the National Academy of Sciences*, 113(2), 344–349. <https://doi.org/10.1073/pnas.1510272113>
- Rivaro, P., Vivado, D., Falco, P., & Ianni, C. (2021). HPLC-DAD Purification and Characterization of Meta-Cresol-Purple for Spectrophotometric Seawater pH Measurements. *Water*, 13(21), 3030. <https://doi.org/10.3390/w13213030>
- Robertson, A. I., & Duke, N. C. (1987). Mangroves as nursery sites: comparisons of the abundance and species composition of fish and crustaceans in mangroves and other nearshore habitats in tropical Australia. *Marine Biology*, 96(2), 193–205. <https://doi.org/10.1007/BF00427019>

- Rodrigues, F., Pereira, F., & Ribeiro, B. (2014). Gaussian Process Classification and Active Learning with Multiple Annotators. In E. P. Xing & T. Jebara (Eds.), *Proceedings of the 31st International Conference on Machine Learning* (Vol. 32, Issue 2, pp. 433–441). PMLR. <https://proceedings.mlr.press/v32/rodrigues14.html>
- Sarker, S. K., Reeve, R., Thompson, J., Paul, N. K., & Matthiopoulos, J. (2016). Are we failing to protect threatened mangroves in the Sundarbans world heritage ecosystem? *Scientific Reports*, 6(1), 21234. <https://doi.org/10.1038/srep21234>
- Shi, J. Q., Murray-Smith, R., & Titterington, D. M. (2005). Hierarchical Gaussian process mixtures for regression. *Statistics and Computing*, 15(1), 31–41. <https://doi.org/10.1007/s11222-005-4787-7>
- Sippo, J. Z., Lovelock, C. E., Santos, I. R., Sanders, C. J., & Maher, D. T. (2018). Mangrove mortality in a changing climate: An overview. *Estuarine, Coastal and Shelf Science*, 215, 241–249. <https://doi.org/10.1016/j.ecss.2018.10.011>
- Stenstrom, M. K., & Poduska, R. A. (1980). The effect of dissolved oxygen concentration on nitrification. *Water Research*, 14(6), 643–649. [https://doi.org/10.1016/0043-1354\(80\)90122-0](https://doi.org/10.1016/0043-1354(80)90122-0)
- Susana, T. (2009). TINGKAT KEASAMAN (pH) DAN OKSIGEN TERLARUT SEBAGAI INDIKATOR KUALITAS PERAIRAN SEKITAR MUARA SUNGAI CISADANE. *INDONESIAN JOURNAL OF URBAN AND ENVIRONMENTAL TECHNOLOGY*, 5(2), 33. <https://doi.org/10.25105/urbanenviotech.v5i2.675>
- Tanner, M. K., Moity, N., Costa, M. T., Marin Jarrin, J. R., Aburto-Oropeza, O., & Salinas-de-León, P. (2019). Mangroves in the Galapagos: Ecosystem services and their valuation. *Ecological Economics*, 160, 12–24. <https://doi.org/10.1016/j.ecolecon.2019.01.024>
- Taylor, R. H., Rose, F., Toher, C., Levy, O., Yang, K., Buongiorno Nardelli, M., & Curtarolo, S. (2014). A RESTful API for exchanging materials data in the AFLOWLIB.org consortium. *Computational Materials Science*, 93, 178–192. <https://doi.org/10.1016/j.commatsci.2014.05.014>
- Tharwat, A. (2021). Classification assessment methods. *Applied Computing and Informatics*, 17(1), 168–192. <https://doi.org/10.1016/j.aci.2018.08.003>

- Ting, K. M. (2017). Confusion Matrix. In *Encyclopedia of Machine Learning and Data Mining* (pp. 260–260). Springer US. https://doi.org/10.1007/978-1-4899-7687-1_50
- Vasudevan, S., Ramos, F., Nettleton, E., & Durrant-Whyte, H. (2009). Gaussian process modeling of large-scale terrain. *Journal of Field Robotics*, 26(10), 812–840. <https://doi.org/10.1002/rob.20309>
- Venkiteswaran, J. J., Wassenaar, L. I., & Schiff, S. L. (2007). Dynamics of dissolved oxygen isotopic ratios: a transient model to quantify primary production, community respiration, and air–water exchange in aquatic ecosystems. *Oecologia*, 153(2), 385–398. <https://doi.org/10.1007/s00442-007-0744-9>
- Villacampa-Calvo, C., Zaldívar, B., Garrido-Merchán, E. C., & Hernández-Lobato, D. (2021). Multi-class Gaussian Process Classification with Noisy Inputs. In *Journal of Machine Learning Research* (Vol. 22). <http://jmlr.org/papers/v22/20-107.html>.
- Waycott, M., McKenzie, L., Mellors, J., Ellison, J., Sheaves, M., Collier, C., Schwarz, A.-M., Webb, A., Johnson, J., & Payri, C. (2011). Vulnerability of mangroves, seagrasses and intertidal flats in the tropical Pacific to climate change. In *Vulnerability of Fisheries and Aquaculture in the Pacific to Climate Change* (pp. 97–168).
- Williams, C. K. I., & Barber, D. (1998). Bayesian classification with Gaussian processes. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 20(12), 1342–1351. <https://doi.org/10.1109/34.735807>
- Xiang, H., & Gu, S. (2022). Gaussian process multi-label classification based on multi-view similarity fusion. *Proceedings of the 2022 4th International Conference on Robotics, Intelligent Control and Artificial Intelligence*, 1032–1036. <https://doi.org/10.1145/3584376.3584560>
- Ximenes, A., Ponsoni, L., Lira, C., Koedam, N., & Dahdouh-Guebas, F. (2018). Does Sea Surface Temperature Contribute to Determining Range Limits and Expansion of Mangroves in Eastern South America (Brazil)? *Remote Sensing*, 10(11), 1787. <https://doi.org/10.3390/rs10111787>



**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN,
RISET, DAN TEKNOLOGI**
UNIVERSITAS SUMATERA UTARA
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI

Jalan Universitas No. 9A Gedung A, Kampus USU Medan 20155, Telepon: (061) 821007
Laman: <http://Fasilkomti.usu.ac.id>

**KEPUTUSAN
DEKAN FAKULTAS ILMU KOMPUTER
DAN TEKNOLOGI INFORMASI
NOMOR : 2375/UN5.2.14.D/SK/SPB/2024**

**DEKAN FAKULTAS ILMU KOMPUTER
DAN TEKNOLOGI INFORMASI UNIVERSITAS SUMATERA UTARA**

- Membaca : Surat Permohonan Mahasiswa Fasilkom-TI USU tanggal 3 Juli 2024 perihal permohonan ujian skripsi:
Nama : HERZINANDA PUTRA
NIM : 201402043
Program Studi : Sarjana (S-1) Teknologi Informasi
Judul Skripsi : Klasifikasi Zona Tanam Mangrove Desa Pulau Sembilan Menggunakan Gaussian Process Regression For Classification (GPRC)
- Memperhatikan : Bawa Mahasiswa tersebut telah memenuhi kewajiban untuk ikut dalam pelaksanaan Meja Hijau Skripsi Mahasiswa pada Program Studi Sarjana (S-1) Teknologi Informasi Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Sumatera Utara TA 2023/2024.
- Menimbang : Bawa permohonan tersebut diatas dapat disetujui dan perlu ditetapkan dengan surat keputusan
- Mengingat : 1. Undang-undang Nomor 20 Tahun 2003 tentang Sistem Pendidikan Nasional.
2. Peraturan Pemerintah Nomor 17 tahun 2010 tentang pengelolaan dan penyelenggara pendidikan.
3. Keputusan Rektor USU Nomor 03/UN5.1.R/SK/SPB/2021 tentang Peraturan Akademik Program Sarjana Universitas Sumatera Utara.
4. Surat Keputusan Rektor USU Nomor 1876/UN5.1.R/SK/SDM/2021 tentang pengangkatan Dekan Fasilkom-TI USU Periode 2021-2026
- MEMUTUSKAN**
- Menetapkan Pertama :
: Membentuk dan mengangkat Tim Penguji Skripsi mahasiswa sebagai berikut:
- | | |
|-----------------|--|
| Ketua | : Dedy Arisandi ST., M.Kom.
NIP: 197908312009121002 |
| Sekretaris | : Ivan Jaya S.Si., M.Kom.
NIP: 198407072015041001 |
| Anggota Penguji | : Dr. Romi Fadillah Rahmat, B.Comp.Sc., M.Sc.
NIP: 198603032010121004 |
| Anggota Penguji | : Umaya Ramadhani Putri Nasution S.TI, M.Kom.
NIP: 199104112021022001 |
| Moderator | : - |
| Panitera | : - |
- Kedua : Segala biaya yang diperlukan untuk pelaksanaan kegiatan ini dibebankan pada Dana Penerimaan Bukan Pajak (PNPB) Fasilkom-TI USU Tahun 2024.
- Ketiga : Keputusan ini berlaku sejak tanggal ditetapkan dengan ketentuan bahwa segala sesuatunya akan diperbaiki sebagaimana mestinya apabila dikemudian hari terdapat kekeliruan dalam surat keputusan ini.

Tembusan :

1. Ketua Program Studi Sarjana (S-1) Teknologi Informasi
2. Yang bersangkutan
3. Arsip

Medan, 04 Juli 2024
Ditandatangani secara elektronik oleh:
Dekan



Maya Silvi Lydia
NIP 197401272002122001