

**PREDIKSI RADIASI SINAR MATAHARI MENGGUNAKAN
METODE *DEEP AUTOREGRESSIVE***

SKRIPSI

MUHAMMAD ARIEF FADHLAN

201402054



**PROGRAM STUDI S1 TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA
MEDAN
2024**

**PREDIKSI RADIASI SINAR MATAHARI MENGGUNAKAN
METODE *DEEP AUTOREGRESSIVE***

SKRIPSI

Diajukan untuk melengkapi tugas dan memenuhi syarat memperoleh ijazah
Sarjana Teknologi Informasi

MUHAMMAD ARIEF FADHLAN

201402054



PROGRAM STUDI S1 TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA

MEDAN

2024

PERSETUJUAN

Judul : PREDIKSI RADIASI SINAR MATAHARI
MENGGUNAKAN METODE DEEP
AUTOREGRESSIVE
Kategori : SKRIPSI
Nama : MUHAMMAD ARIEF FADHLAN
Nomor Induk Mahasiswa : 201402054
Program Studi : SARJANA (S-1) TEKNOLOGI INFORMASI
Fakultas : ILMU KOMPUTER DAN TEKNOLOGI
INFORMASI UNIVERSITAS SUMATERA
UTARA

Medan, 16 Oktober 2024

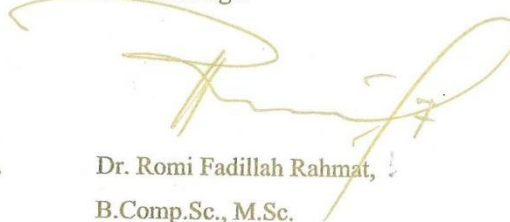
Komisi Pembimbing

Pembimbing 2



Umayya Ramadhani Putri Nasution,
S.TI., M.Kom.
NIP. 199104112021022001

Pembimbing 1



Dr. Romi Fadillah Rahmat,
B.Comp.Sc., M.Sc.
NIP. 198603032010121004

Diketahui/disetujui oleh

Program Studi S1 Teknologi Informasi

Ketua,




Dedy Arisandi, S.T., M.Kom.
NIP. 197908312009121002

PERNYATAAN**PREDIKSI RADIASI SINAR MATAHARI MENGGUNAKAN
METODE DEEP AUTOREGRESSIVE****SKRIPSI**

Saya mengakui bahwa skripsi ini merupakan hasil karya saya sendiri, kecuali beberapa kutipan dan ringkasan yang masing-masing telah disebutkan sumbernya.

Medan, 16 Oktober 2024

A handwritten signature in black ink, appearing to be 'Muhammad Arief Fadhlán', with a stylized, cursive script.

Muhammad Arief Fadhlán
201402054

UCAPAN TERIMA KASIH

Penulis ingin menyampaikan rasa syukur dan terima kasih kepada Allah SWT atas anugerah dan karunia-Nya sehingga penulis dapat menyelesaikan skripsi ini sebagai salah satu syarat kelulusan untuk memperoleh gelar Sarjana Komputer pada Program Studi S1 Teknologi Informasi di Universitas Sumatera Utara. Penulisan skripsi ini dapat diselesaikan dengan baik berkat dukungan moral dan materi dari berbagai pihak. Sebagai ungkapan rasa syukur dan terima kasih atas doa, motivasi, dan bantuan yang diberikan oleh berbagai pihak selama proses penyusunan skripsi ini, penulis mengucapkan terima kasih sebesar-besarnya kepada:

1. Allah SWT atas anugerah dan karunia-Nya yang senantiasa memberikan penulis kemudahan, kekuatan, dan kesabaran dalam menjalani setiap proses penyelesaian skripsi ini.
2. Seluruh keluarga penulis yang selalu memberikan doa, semangat, dan dukungan kepada penulis untuk menyelesaikan skripsi ini.
3. Dosen Pembimbing pertama dan kedua penulis, Bapak Dr. Romi Fadillah Rahmat B.Comp.Sc., M.Sc. dan Ibu Umayra Ramadhani Putri Nasution S.TI., M.Kom. yang telah memberikan bimbingan dan arahan selama proses penyelesaian skripsi ini.
4. Dekan Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Sumatera Utara, Ibu Dr. Maya Silvi Lydia, B.Sc., M.Sc.
5. Ketua dan Sekretaris Program Studi S1 Teknologi Informasi Universitas Sumatera Utara, Bapak Dedy Arisandi, S.T., M.Kom. dan Bapak Ivan Jaya, S.Si., M.Kom.
6. Seluruh dosen Program Studi S1 Teknologi Informasi yang telah memberikan ilmu, wawasan, dan pengalaman yang berharga kepada penulis.
7. Seluruh pegawai Fakultas Ilmu Komputer dan Teknologi Informasi yang telah membantu penulis dalam mengurus segala urusan administrasi perkuliahan.
8. Seluruh teman-teman Angkatan 2020 yang telah berjuang bersama selama masa perkuliahan.
9. Teman-teman perkuliahan, Albert, Yeftha, Vicky, Felix, Kevin Bangun, Kevin Tulus, Kelvin, Syavira, Fildzah, Monica, Rere, Jane, dan Hara yang selalu memberikan motivasi dan saran kepada penulis.

10. Teman-teman seperbimbingan, Adinda Khairani, Diah Paramitha, Herzinanda Putra, Levina Gunawan, Davita Chandra, Felix Kurnia Salim, dan Cynthia Yapiter yang saling membantu dalam menyelesaikan skripsi ini
11. Abang, Kakak, dan Teman-teman Direktorat Digitalisasi dan Integrasi Sistem Universitas Sumatera Utara, Iqbal Fakhriza, Jason Surya Faylim, Rasyid Hafiz Fenny Julistine, dan teman-teman lain yang tidak dapat dituliskan satu per satu.
12. Seluruh pihak yang secara langsung maupun tidak langsung turut membantu penulis dalam menyelesaikan skripsi ini.

Medan, 16 Oktober 2024

Penulis,



Muhammad Arief Fadhlan

201402054

ABSTRAK

Energi surya merupakan salah satu sumber energi terbarukan yang berkembang dengan sangat pesat dalam pemanfaatannya. Melalui Pembangkit Listrik Tenaga Surya (PLTS), radiasi matahari dapat diubah menjadi energi listrik menggunakan sel surya yang memanfaatkan teknologi *photovoltaic* (PV). Namun, kinerja pada sistem PV dapat dipengaruhi oleh berbagai faktor lingkungan, seperti suhu, kelembapan, kecepatan angin, dan intensitas cahaya. Selain itu, pengoperasian sistem tenaga surya dengan penetrasi tinggi dapat menimbulkan fluktuasi tegangan dan produksi listrik tenaga surya menjadi tidak stabil sehingga menyebabkan ketidakseimbangan antara permintaan dan pasokan energi. Dalam hal ini, prediksi radiasi sinar matahari yang akurat sangat penting untuk membuat perencanaan yang baik dalam mengelola dan mengoperasikan sistem tenaga surya sehingga dapat memproduksi energi dengan optimal dan menjaga keseimbangan pasokan dan permintaan energi. Pada penelitian ini, metode *Deep Autoregressive* (DeepAR) diterapkan untuk melatih model dalam memprediksi radiasi sinar matahari. Hasil penelitian ini menunjukkan bahwa *model* yang dilatih dengan metode DeepAR memiliki kinerja yang baik dalam memprediksi radiasi sinar matahari dengan nilai metrik evaluasi terbaik tercapai pada rentang waktu prediksi 7 hari dengan nilai R^2 sebesar 0.956675, MAE sebesar 7.835733, MSE sebesar 97.33104, dan RMSE sebesar 9.86565.

Kata Kunci: Prediksi, Radiasi Sinar Matahari, *Deep Autoregressive* (DeepAR).

**PREDICTION OF SOLAR RADIATION USING
DEEP AUTOREGRESSIVE METHOD**

ABSTRACT

Solar energy is one of the renewable energy sources that is growing very rapidly in its utilization. Through solar power plants (PLTS), solar radiation can be converted into electrical energy using solar cells that utilize photovoltaic (PV) technology. However, the performance of PV systems can be affected by various environmental factors, such as temperature, humidity, wind speed, and light intensity. In addition, the operation of solar power systems with high penetration can lead to voltage fluctuations and unstable solar electricity production, causing an imbalance between energy demand and supply. In this case, accurate prediction of solar radiation is essential to make good planning in managing and operating solar power systems so that it can produce energy optimally and maintain the balance of energy supply and demand. In this study, the Deep Autoregressive (DeepAR) method is applied to train a model to predict solar radiation. The results of this study show that the model trained with the DeepAR method has good performance in predicting solar radiation with the best evaluation metric value achieved in the prediction time span of 7 days with an R^2 value of 0.956675, MAE of 7.835733, MSE of 97.33104, and RMSE of 9.86565.

Keywords: Prediction, Sunlight Radiation, Deep Autoregressive (DeepAR).

DAFTAR ISI

PERSETUJUAN	iii
PERNYATAAN	iv
UCAPAN TERIMA KASIH	v
ABSTRAK	vii
<i>ABSTRACT</i>	viii
DAFTAR ISI	ix
DAFTAR TABEL	xi
DAFTAR GAMBAR	xii
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	4
1.4 Batasan Masalah	4
1.5 Manfaat Penelitian	4
1.6 Metodologi Penelitian	4
1.7 Sistematika Penulisan	5
BAB 2 LANDASAN TEORI	2
2.1 Sumber Energi Terbarukan	2
2.2 Sumber Energi Tenaga Surya	8
2.3 Radiasi Matahari	8
2.4 Jangka Waktu Prediksi Radiasi Matahari	9
2.5 Parameter Prediksi Radiasi Matahari	9
2.6 <i>Deep Learning</i>	10
2.7 <i>Recurrent Neural Network (RNN)</i>	10
2.8 <i>Long Short-Term Memory (LSTM)</i>	11
2.9 <i>Deep Autoregressive (DeepAR)</i>	13
2.10 Metrik Evaluasi	15
2.10.1 <i>Coefficient of Determination (R^2)</i>	15
2.10.2 <i>Mean Absolute Error (MAE)</i>	16
2.10.3 <i>Mean Square Error (MSE)</i>	16
2.10.4 <i>Root Mean Square Error (RMSE)</i>	16

2.11 Penelitian Terdahulu	16
2.12 Perbedaan Penelitian	23
BAB 3 ANALISIS DAN PERANCANGAN SISTEM	8
3.1 Sumber Data	8
3.2 Arsitektur Umum	27
3.2.1 <i>Data Collection</i>	28
3.2.2 <i>Data Preprocessing</i>	28
3.2.3 <i>Data Splitting</i>	33
3.2.4 <i>Pelatihan Model</i>	33
3.2.5 <i>Pengujian Model</i>	34
3.2.6 <i>Output</i>	35
3.3 Perancangan Antarmuka Sistem	35
3.3.1 Rancangan Halaman Beranda	35
3.3.2 Rancangan Halaman Pelatihan	36
3.3.3 Rancangan Halaman Pengujian	37
3.3.4 Rancangan Halaman Prediksi	39
BAB 4 IMPLEMENTASI DAN PENGUJIAN SISTEM	27
4.1 Implementasi Sistem	27
4.1.1 Spesifikasi Perangkat Keras dan Perangkat Lunak	27
4.1.2 Implementasi Antarmuka Sistem	27
4.2 <i>Pelatihan Model</i>	48
4.3 <i>Pengujian Model</i>	51
4.4 <i>Validasi Model</i>	65
4.5 Diskusi	67
BAB 5 KESIMPULAN DAN SARAN	43
5.1 Kesimpulan	43
5.2 Saran	43
DAFTAR PUSTAKA	43

DAFTAR TABEL

Tabel 2. 1 Penelitian Terdahulu	20
Tabel 3. 1 Rincian Data	27
Tabel 3. 2 Statistik Data Sebelum Proses Pembersihan	30
Tabel 3. 3 Daftar <i>Hyperparameter</i> DeepAR	34
Tabel 4. 1 Hasil Pelatihan Model Pada Rentang Waktu Prediksi 7 Hari	48
Tabel 4. 2 Hasil Pelatihan Model Pada Rentang Waktu Prediksi 30 Hari	48
Tabel 4. 3 Hasil Pelatihan Model Pada Rentang Waktu Prediksi 60 Hari	49
Tabel 4. 4 Hasil Pelatihan Model Pada Rentang Waktu Prediksi 90 Hari	50
Tabel 4. 5 Hasil Pelatihan Model Pada Rentang Waktu Prediksi 120 Hari	51
Tabel 4. 6 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 7 Hari	52
Tabel 4. 7 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 30 Hari	53
Tabel 4. 8 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 60 Hari	54
Tabel 4. 9 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 90 Hari	57
Tabel 4. 10 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 120 Hari	60
Tabel 4. 11 Hasil Pengujian Model Pada Setiap Rentang Waktu Prediksi	65
Tabel 4. 12 Perbandingan Hasil Evaluasi Model Menggunakan Validasi Dengan Tanpa Validasi Pada Semua Rentang Waktu Prediksi	66

DAFTAR GAMBAR

Gambar 2. 1 Berbagai Jenis Sumber Energi Terbarukan (Farghali et al., 2023)	8
Gambar 2. 2 Perbedaan Tahapan Metode <i>Machine Learning</i> dan <i>Deep Learning</i>	10
Gambar 2. 3 Arsitektur RNN (Ye & Yang, 2021)	11
Gambar 2. 4 Arsitektur LSTM (Pellegrino et al., 2024)	12
Gambar 2. 5 Arsitektur DeepAR (Salinas et al., 2020)	14
Gambar 3. 1 Alat Pengukur Radiasi Matahari (Ambarita, 2017)	8
Gambar 3. 2 Arsitektur Umum	27
Gambar 3. 3 Grafik Distribusi Data Sebelum Proses Pembersihan	30
Gambar 3. 4 Distribusi Data Setelah Proses Pembersihan	31
Gambar 3. 5 <i>Correlation Heatmap</i>	32
Gambar 3. 6 Rancangan Halaman Beranda	35
Gambar 3. 7 Rancangan Halaman Pelatihan	36
Gambar 3. 8 Rancangan Halaman Hasil Pelatihan	37
Gambar 3. 9 Rancangan Halaman Pengujian	38
Gambar 3. 10 Rancangan Halaman Hasil Pengujian	39
Gambar 3. 11 Rancangan Halaman Prediksi	40
Gambar 3. 12 Rancangan Halaman Hasil Prediksi	41
Gambar 4. 1 Tampilan Halaman Beranda	43
Gambar 4. 2 Tampilan Halaman Pelatihan	43
Gambar 4. 3 Tabel Hasil Pelatihan	44
Gambar 4. 4 Grafik Hasil Pelatihan	44
Gambar 4. 5 Tampilan Halaman Pengujian	45
Gambar 4. 6 Tabel Hasil Pengujian	45
Gambar 4. 7 Grafik Hasil Pengujian	46
Gambar 4. 8 Tampilan Halaman Prediksi	46
Gambar 4. 9 Tabel Hasil Prediksi	47
Gambar 4. 10 Grafik Hasil Prediksi	47
Gambar 4. 11 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 7 Hari	52
Gambar 4. 12 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 30 Hari	54
Gambar 4. 13 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 60 Hari	56
Gambar 4. 14 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 90 Hari	60

Gambar 4. 15 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 120 Hari	64
Gambar 4. 16 Perbandingan Hasil Evaluasi Model Menggunakan Validasi Dengan Tanpa Validasi Pada Semua Rentang Waktu Prediksi	66

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Energi memiliki peran penting dalam masyarakat sebagai penggerak sektor ekonomi, sistem transportasi, dan aktivitas dalam kehidupan sehari-hari. Selama bertahun-tahun, seluruh dunia telah mengandalkan berbagai sumber energi, seperti batu bara, minyak, dan gas alam. Namun, seiring pertumbuhan populasi yang terus bertambah, membuat permintaan energi semakin meningkat sehingga mengakibatkan krisis energi yang berdampak signifikan pada lingkungan, ekonomi, dan struktur sosial (Farghali *et al.*, 2023). Hal ini membuat krisis energi menjadi masalah serius yang harus dihadapi dunia saat ini.

Menurut laporan *World Energy Outlook* pada tahun 2019 dari International Energy Agency (IEA), sekitar 81% dari seluruh sumber utama energi di seluruh dunia berasal dari bahan bakar fosil (IEA, 2019). Ketergantungan pada bahan bakar fosil yang merupakan sumber daya terbatas menimbulkan dampak negatif terhadap lingkungan. Misalnya, pembakaran bahan bakar fosil dapat meningkatkan emisi karbon dioksida (CO₂) yang menjadi pemicu utama perubahan iklim. Selain itu, ekstraksi dan konsumsi bahan bakar fosil dapat menimbulkan polusi, merusak keanekaragaman hayati, dan menyebabkan ketidakseimbangan ekosistem (Hassan *et al.*, 2024). Situasi ini mendorong berbagai negara dan perusahaan untuk melakukan transisi ke sumber energi terbarukan yang ramah lingkungan sebagai alternatif pengganti bahan bakar fosil.

Di antara berbagai sumber energi terbarukan yang telah dikembangkan, energi surya menunjukkan perkembangan yang sangat pesat dalam pemanfaatannya dengan kapasitas terpasang mencapai 1053 GW pada tahun 2022 (IRENA, 2023). Energi surya dapat dimanfaatkan dengan menggunakan Pembangkit Listrik Tenaga Surya (PLTS). Sumber energi dari PLTS diambil melalui sel surya yang menggunakan teknologi *photovoltaic* (PV) untuk mengubah radiasi matahari menjadi energi listrik (Muhammad & Purwahyudi, 2021). Akan tetapi, kinerja pada sistem PV dapat dipengaruhi oleh berbagai faktor, seperti suhu panel surya, kelembapan, kecepatan angin, jumlah cahaya, ketinggian, dan tekanan barometrik (Jathar *et al.*, 2023).

Selain itu, pengoperasian sistem tenaga surya dengan penetrasi tinggi dapat menimbulkan dampak negatif, seperti kehilangan daya, aliran daya balik, fluktuasi tegangan, ketidakseimbangan tegangan, dan masalah kualitas tegangan di jaringan listrik (Uzum *et al.*, 2021). Hal ini menyebabkan produksi listrik tenaga surya menjadi fluktuatif sehingga menciptakan inversi aliran daya dan ketidakseimbangan antara permintaan dan pasokan energi (Solano *et al.*, 2022). Untuk itu, prediksi radiasi matahari yang akurat sangat penting untuk menjaga efisiensi dalam mengoperasikan sistem pembangkit listrik tenaga surya.

Untuk memprediksi tingkat radiasi sinar matahari di masa depan secara akurat, pengembangan metode prediksi berbasis data meteorologi umum sangat diperlukan. Pengembangan ini tidak hanya mendorong pertumbuhan industri energi surya, tetapi juga berkontribusi dalam meningkatkan pemanfaatan energi yang berkelanjutan (Lyu *et al.*, 2023). Berbagai metode prediksi yang telah diusulkan berfokus pada jangka waktu prediksi yang berbeda, seperti prediksi jangka sangat pendek (hitungan jam), pendek (1 hari atau 1 hari ke depan), menengah (1 bulan), dan jangka panjang (1 tahun) dengan masing-masing prediksi digunakan untuk aplikasi yang berbeda (Liu *et al.*, 2022). Dalam hal ini, berbagai metode *machine learning* telah diterapkan secara luas karena kemampuannya yang dapat mempelajari dan memproses data dalam jumlah yang besar dan meningkatkan akurasi prediksi (Lyu *et al.*, 2023).

Penelitian mengenai prediksi radiasi matahari dengan menggunakan metode *machine learning* telah banyak dilakukan. Pada tahun 2020, Zeng *et al.* (2020) melakukan penelitian untuk memprediksi radiasi matahari harian dalam kondisi iklim dan geografis yang berbeda di Cina. Penelitian ini menerapkan metode *Random Forest* dan menggunakan data radiasi matahari dan meteorologi. Hasil dari penelitian ini menunjukkan bahwa durasi sinar matahari, suhu permukaan, dan hari dalam setahun memiliki peran penting dalam menentukan radiasi matahari harian di seluruh Cina.

Pada tahun 2021, Ağbulut *et al.* (2021) melakukan penelitian untuk membandingkan metode *Artificial Neural Network*, *K-Nearest Neighbor*, *Support Vector Machine*, dan *Deep Learning* dalam memprediksi radiasi matahari harian di 4 wilayah (Kırklareli, Tokat, Nevşehir, dan Karaman) yang memiliki distribusi radiasi matahari yang berbeda di Turki. Hasil dari penelitian ini menunjukkan bahwa belum ada metode yang memberikan hasil terbaik untuk semua tempat.

Penelitian mengenai prediksi radiasi matahari juga telah dilakukan oleh Nematchoua *et al.* (2022) untuk memprediksi radiasi sinar matahari harian dan suhu udara di 27 negara Eropa dengan menggunakan berbagai metode, seperti *Linear Model*, *Decision Tree*, *Support Vector Machine*, *Deep Learning*, *Random Forrest*, dan *Gradient Boosted Tree*. Penelitian ini menggunakan data yang berasal dari 27 stasiun meteorologi dan diukur pada ketinggian 100 meter. Hasil dari penelitian ini menunjukkan bahwa di antara beberapa metode yang digunakan, metode *Support Vector Machine* memberikan hasil terbaik dengan nilai RMSE sebesar 0,189 MJ/m². Sebaliknya, metode *Decision Tree* memberikan hasil terburuk dengan nilai RMSE sebesar 0,405 MJ/m².

Dalam penelitian ini, metode yang diusulkan adalah *Deep Autoregressive* (DeepAR). DeepAR dapat menghasilkan prakiraan probabilistik berdasarkan pelatihan *model* dengan *autoregressive recurrent network* pada sejumlah besar deret waktu. DeepAR dapat menangani skala yang bervariasi dan mempelajari pola yang rumit (Salinas *et al.*, 2020). Fleksibilitas DeepAR dalam menangani karakteristik data yang beragam menjadikannya sebagai alat yang serbaguna dalam meningkatkan akurasi dan keandalan prediksi (Ramos & Oliveira, 2023). Dengan demikian, penulis mengajukan penelitian berjudul “Prediksi Radiasi Sinar Matahari Menggunakan Metode *Deep Autoregressive*.”

1.2 Rumusan Masalah

Sebagai upaya mengurangi ketergantungan terhadap bahan bakar fosil, penggunaan sumber energi terbarukan diprioritaskan sebagai alternatif yang ramah lingkungan. Dalam hal ini, sumber energi tenaga surya merupakan salah satu sumber energi terbarukan yang berkembang dengan sangat pesat dalam pemanfaatannya. Pemanfaatan energi surya dilakukan melalui sel surya yang menggunakan teknologi *photovoltaic* (PV). Namun, terdapat faktor yang mempengaruhi kinerja pada sistem PV, misalnya pengoperasian sistem tenaga surya dengan penetrasi tinggi yang dapat menimbulkan fluktuasi tegangan sehingga produksi listrik tenaga surya menjadi tidak teratur. Hal ini dapat menyebabkan ketidakseimbangan antara permintaan dan pasokan energi. Oleh karena itu, diperlukan prediksi radiasi sinar matahari yang akurat sebagai salah satu solusi untuk merencanakan produksi energi secara optimal serta menyeimbangkan pasokan dan permintaan energi.

1.3 Tujuan Penelitian

Penelitian ini bertujuan untuk memprediksi besaran radiasi sinar matahari dengan menggunakan metode *Deep Autoregressive* (DeepAR).

1.4 Batasan Masalah

Dalam penelitian ini, ditentukan batasan masalah agar penelitian terfokus pada ruang lingkup permasalahan. Adapun batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Data yang digunakan adalah data cuaca dan radiasi matahari selama tahun 2017 hingga 2022 dengan format .csv.
2. Rentang waktu prediksi yang digunakan adalah 7 hari, 30 hari, 60 hari, 90 hari, dan 120 hari.
3. Parameter yang digunakan adalah suhu dan kelembapan udara.

1.5 Manfaat Penelitian

Manfaat yang dapat diperoleh dari penelitian ini adalah sebagai berikut:

1. Membantu pengelola PLTS dan pengguna panel surya dalam meningkatkan efisiensi pengoperasian pembangkit listrik tenaga surya, merencanakan produksi energi secara optimal, dan mengurangi ketidakseimbangan antara pasokan dan permintaan energi.
2. Mengetahui kinerja metode *Deep Autoregressive* (DeepAR) dalam memprediksi besaran radiasi sinar matahari.
3. Menjadi sumber rujukan bagi penelitian berikutnya dalam menggunakan metode *Deep Autoregressive* (DeepAR).

1.6 Metodologi Penelitian

Serangkaian tahapan yang dilakukan pada penelitian ini meliputi:

1. Studi Literatur

Pada tahap ini dilakukan studi literatur dengan mengumpulkan informasi dan referensi berupa jurnal, artikel, buku, laporan, skripsi, dan sumber lainnya yang berkaitan dengan prediksi radiasi sinar matahari, *time series analysis*, dan metode *Deep Autoregressive*.

2. Analisis Permasalahan

Pada tahap ini dilakukan analisis terhadap informasi dan referensi yang telah dikumpulkan pada tahap studi literatur untuk mendapatkan pemahaman terkait konsep penggunaan metode *Deep Autoregressive* (DeepAR) yang akan diterapkan untuk melakukan prediksi radiasi sinar matahari.

3. Perancangan Sistem

Pada tahap ini dilakukan perancangan sistem berupa arsitektur umum untuk memprediksi radiasi sinar matahari yang disesuaikan dengan hasil analisis permasalahan yang telah dilakukan.

4. Implementasi

Pada tahap ini dilakukan implementasi sistem berdasarkan perancangan sistem yang telah dilakukan untuk menciptakan sebuah sistem yang sesuai dengan tujuan penelitian.

5. Pengujian Sistem

Pada tahap ini dilakukan pengujian terhadap sistem yang telah dibuat dan pemeriksaan terhadap hasil yang diperoleh dari penerapan metode DeepAR dalam memprediksi radiasi sinar matahari.

6. Dokumentasi dan Penyusunan Laporan

Pada tahap ini dilakukan dokumentasi dan penyusunan laporan yang memuat seluruh proses penelitian dari awal hingga akhir.

1.7 Sistematika Penulisan

Sistematika penulisan pada skripsi ini dibagi menjadi lima bagian, antara lain:

Bab 1: Pendahuluan

Bagian ini menjelaskan mengenai dorongan dan alasan dilakukannya penelitian ini. Setiap penjelasan dibagi menjadi beberapa bagian, meliputi latar belakang penelitian, rumusan masalah, tujuan penelitian, batasan masalah yang menjelaskan ruang lingkup masalah yang diteliti, manfaat penelitian, metode penelitian, dan sistematika penelitian.

Bab 2: Landasan Teori

Bagian ini menjelaskan mengenai konsep dan teori yang digunakan dalam analisis permasalahan penelitian ini, meliputi sumber energi terbarukan, sumber energi tenaga surya, radiasi matahari, jangka waktu prediksi radiasi matahari, parameter prediksi radiasi matahari, *deep learning*, *Recurrent Neural Network* (RNN), *Long Short-Term Memory* (LSTM), dan *Deep Autoregressive* (DeepAR). Selain itu, terdapat penjelasan mengenai penelitian terdahulu yang relevan dengan topik dan metode serupa dan perbedaan penelitian yang dilakukan dengan penelitian sebelumnya

Bab 3: Analisis dan Perancangan

Bagian ini menjelaskan mengenai analisis dan perancangan mengenai sumber data yang digunakan, arsitektur umum, dan perancangan antarmuka sistem.

Bab 4: Implementasi dan Pengujian Sistem

Bagian ini menjelaskan mengenai penerapan metode DeepAR pada pelatihan dan pengujian *model* serta implementasi antarmuka sistem.

Bab 5: Kesimpulan dan Saran

Bagian kesimpulan dan saran menjelaskan rangkuman dari hasil dan temuan penelitian yang telah dilakukan serta memberikan rekomendasi untuk penelitian selanjutnya berdasarkan kekurangan atau kelemahan yang ditemukan dalam penelitian ini.

BAB 2

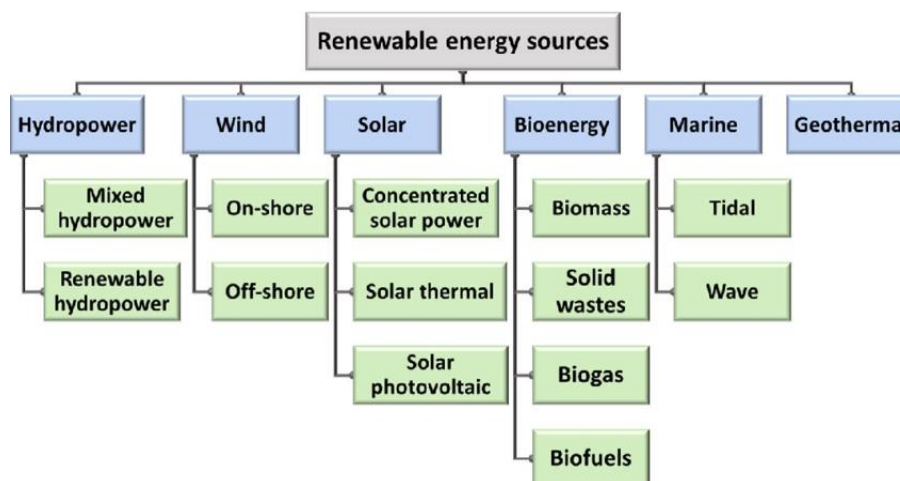
LANDASAN TEORI

2.1 Sumber Energi Terbarukan

Perubahan iklim telah menjadi ancaman bagi kehidupan manusia dan struktur ekonomi di dunia. Penyebab utama perubahan iklim adalah peningkatan suhu atau pemanasan global yang disebabkan oleh gas rumah kaca yang berasal dari penggunaan bahan bakar fosil untuk menghasilkan energi sehingga meningkatkan emisi karbon dioksida (CO₂) (Farghali *et al.*, 2022; Lau *et al.*, 2023). Selama beberapa dekade terakhir, penggunaan bahan bakar fosil telah memberikan dampak buruk terhadap iklim dan peningkatan intensitas peristiwa cuaca yang ekstrem (Shang *et al.*, 2023). Hal ini memberikan argumen yang kuat untuk mengurangi ketergantungan terhadap bahan bakar fosil yang menjadi penyebab utama peningkatan emisi gas rumah kaca (Farghali *et al.*, 2023).

Selama beberapa tahun terakhir, permintaan energi telah meningkat sehingga perlu untuk memeriksa penggunaan bahan bakar fosil dan meningkatkan penggunaan sumber energi terbarukan untuk mencegah konsekuensi jangka panjang (Arora & Mishra, 2022). Selain itu, ancaman perubahan iklim yang terus meningkat telah mendesak pemerintah dan berbagai organisasi untuk mengurangi emisi gas rumah kaca dan mendorong penggunaan sumber energi terbarukan (Rashid *et al.*, 2020; Yoro & Daramola, 2020). Sebagai upaya untuk mencapai pembangunan berkelanjutan, Perserikatan Bangsa-Bangsa (PBB) meresmikan Sustainable Development Goals (SDGs) pada tahun 2015. Salah satu dari 17 tujuan Sustainable Development Goals, yakni tujuan ke-7 memiliki fokus utama untuk memastikan akses terhadap energi yang terjangkau, andal, dan modern untuk semua orang pada tahun 2030.

Sumber energi terbarukan merupakan kunci dari pembangunan berkelanjutan yang berperan penting dalam mitigasi perubahan iklim dengan mengurangi karbon dari sektor energi dan membatasi emisi gas rumah kaca (Chen & Lin, 2024). Peran sumber energi terbarukan dalam mencapai pembangunan berkelanjutan telah diakui dengan baik (Wang, 2024). Apabila dibandingkan dengan sumber energi fosil tradisional, sumber energi terbarukan memiliki karakteristik yang lebih bersih dan tidak terbatas (Bilgili *et al.*, 2022). Hal ini dikarenakan sumber energi terbarukan berasal dari sumber yang terus diperbarui sehingga dapat diperoleh kembali secara alami dalam waktu yang singkat (Zohuri & McDaniel, 2021).



Gambar 2. 1 Berbagai Jenis Sumber Energi Terbarukan (Farghali *et al.*, 2023)

Dengan karakteristik yang bersih dan tidak terbatas, sumber energi terbarukan dianggap sebagai salah satu pilihan yang menjanjikan untuk mengatasi pemanasan global dan mengubah struktur energi global (Smil, 2020).

2.2 Sumber Energi Tenaga Surya

Energi surya atau energi matahari merupakan sumber energi yang berlimpah untuk perekonomian yang bebas karbon (Dalapati *et al.*, 2023). Secara keseluruhan, telah terjadi pertumbuhan dalam pemanfaatan energi surya karena dapat digunakan untuk menghasilkan listrik, desalinasi air, dan menghasilkan panas (Maka & Alabid, 2022). Energi surya dianggap sebagai sumber energi terbarukan yang menjanjikan karena tidak memiliki kendala pasokan dan produk sampingan fisik yang menyebabkan bahaya lingkungan (Hossain *et al.*, 2023).

2.3 Radiasi Matahari

Radiasi matahari merupakan sumber energi yang bersih dan terbarukan (Ehteram *et al.*, 2024). Apabila dibandingkan dengan dengan bahan bakar fosil, radiasi matahari tidak menghasilkan emisi gas rumah kaca dan polutan udara (Goliatt & Yaseen, 2023). Hal ini menjadikan radiasi matahari dianggap sebagai salah satu sumber energi terpenting di bumi (Nematchoua *et al.*, 2022).

Ketika mendesain sistem energi, data radiasi matahari dapat digunakan untuk mengoptimalkan sistem energi surya pada lingkungan tertentu (Küçüktopçu *et al.*, 2024). Namun, radiasi matahari tidak jatuh pada jumlah yang sama di semua tempat

sehingga sangat penting untuk mengetahui dan memprediksi di mana, kapan, dan berapa banyak radiasi matahari jatuh. (Gürel *et al.*, 2020). Pengukuran radiasi matahari sering kali tidak memungkinkan karena biaya yang mahal dan memakan waktu. Oleh karena itu, Prediksi radiasi sinar matahari yang tepat sangat relevan baik dalam penelitian iklim maupun industri tenaga surya (Nematchoua *et al.*, 2022).

2.4 Jangka Waktu Prediksi Radiasi Matahari

Pengembangan model prediksi perlu memperhatikan dan mempertimbangkan jangka waktu yang diinginkan (El Bakali *et al.*, 2023). Hal ini dikarenakan pola radiasi matahari dapat bervariasi secara signifikan sepanjang hari (Ehteram *et al.*, 2024). Beberapa *model* prediksi dapat menargetkan jangka waktu prediksi yang berbeda, seperti prediksi jangka sangat pendek (hitungan jam), pendek (1 hari atau 1 hari ke depan), menengah (1 bulan), dan jangka panjang (1 tahun) (Liu *et al.*, 2022).

Setiap rentang waktu prediksi digunakan untuk aplikasi yang berbeda. Prediksi jangka pendek dapat membantu operator jaringan untuk menyeimbangkan pasokan dan permintaan listrik secara *real-time* (Matrenin *et al.*, 2023), sedangkan prediksi jangka menengah dan panjang dapat digunakan untuk keperluan pemeliharaan dan pasar energi (Solano *et al.*, 2022).


2.5 Parameter Prediksi Radiasi Matahari

Radiasi matahari dipengaruhi oleh berbagai faktor, seperti kondisi cuaca, waktu, dan lokasi geografis (Ehteram *et al.*, 2024). Hal ini dikarenakan sumber energi matahari bersifat tidak teratur sehingga bergantung pada radiasi, suhu, dan parameter atmosfer lainnya (Behera *et al.*, 2018). Untuk itu, penting untuk memprediksi radiasi matahari menggunakan parameter iklim, seperti durasi penyinaran matahari, ketinggian, garis bujur, indeks kejernihan, dan lain-lain (Gürel *et al.*, 2020).

Efisiensi radiasi matahari juga dapat berubah-ubah tergantung pada parameter meteorologi dan kondisi langit (Kumari & Toshniwal, 2021). Oleh karena itu, terdapat kebutuhan untuk memprediksi radiasi matahari menggunakan data meteorologi, seperti radiasi matahari, suhu, arah angin, kecepatan dan tekanan angin, kelembapan, dan tutupan awan (Ozgoren *et al.*, 2012; Chand *et al.*, 2023; Krishnan *et al.*, 2023).

2.6 Deep Learning

Deep learning merupakan bagian dari *machine learning* yang terinspirasi dari pola pemrosesan informasi yang ditemukan di otak manusia. *Deep learning* tidak memerlukan aturan yang dirancang manusia untuk beroperasi, tetapi menggunakan sejumlah besar data untuk memetakan *input* yang diberikan ke label tertentu (Alzubaidi *et al.*, 2021). Metode *deep learning* memanfaatkan *neural network* untuk memecahkan masalah yang rumit (Sharifani & Amini, 2023). *Deep learning* menggunakan beberapa lapisan neuron yang saling berhubungan sehingga memungkinkan untuk menganalisis data yang besar, tidak terstruktur, dan kompleks (Choudhary *et al.*, 2022; Kufel *et al.*, 2023).




Gambar 2. 2 Perbedaan Tahapan Metode *Machine Learning* dan *Deep Learning*
(Valente *et al.*, 2023)

Deep Learning unggul dalam tugas yang rumit dan melibatkan data berdimensi tinggi (Theodosiou & Read, 2023). *Deep learning* memungkinkan model komputasi yang terdiri dari beberapa lapisan pemrosesan untuk mempelajari representasi data dengan berbagai tingkat abstraksi (LeCun *et al.*, 2015). Metode *deep learning* disusun ke dalam beberapa lapisan neuron buatan yang saling berhubungan. Setiap lapisan menerima *input* dari lapisan sebelumnya dan melakukan komputasi untuk mengubah data. Lapisan terakhir menghasilkan *output* atau prediksi yang bergantung pada tugas tertentu (Pham *et al.*, 2024).

2.7 Recurrent Neural Network (RNN)

RNN merupakan arsitektur jaringan yang dapat menangani data sensor mentah atau ekstraksi fitur minimum dan memodelkan data temporal dengan pemrosesan berurutan (Paraschiakos *et al.*, 2022). RNN bermanfaat untuk data yang berurutan atau bergantung pada waktu (Manalu & Rifai, 2024). Model RNN dapat mengenali karakteristik berurutan dalam data dan membantu memprediksi kemungkinan titik data berikutnya

dalam urutan data. Arsitektur RNN berupa jaringan syaraf (*neural network*) dengan keadaan tersembunyi (*hidden state*) yang menggunakan perulangan umpan balik untuk memproses urutan data (Das *et al.*, 2023).

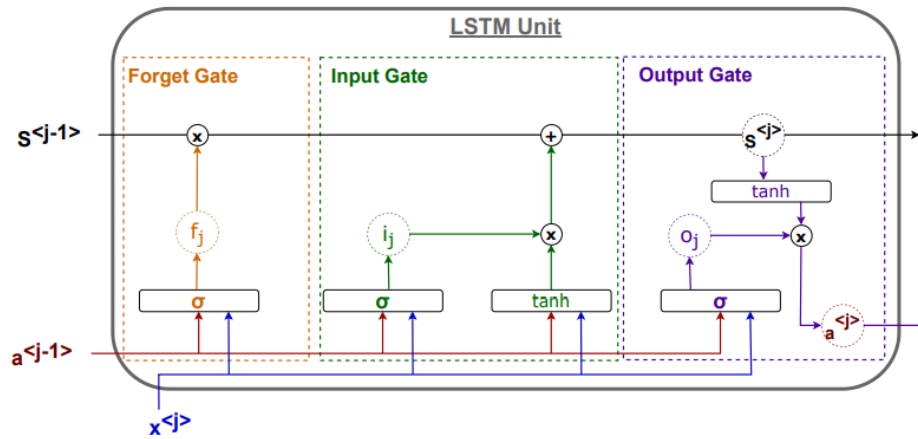


Gambar 2. 3 Arsitektur RNN (Ye & Yang, 2021)

Berdasarkan arsitektur RNN yang ditunjukkan pada Gambar 2.3, dapat dilihat bahwa untuk setiap waktu (t), terdapat x_t sebagai *input*, y_t sebagai *output*, dan kotak yang berada di tengah sebagai keadaan tersembunyi (*hidden state*). Setiap simpul (*node*) menerima *input* dari *node* sebelumnya, kemudian menggunakan mekanisme perulangan umpan balik. Setiap *node* akan menghasilkan *hidden state* dan *output* melalui *input* saat ini dan *hidden state* sebelumnya (Ye & Yang, 2021).

2.8 Long Short-Term Memory (LSTM)

LSTM merupakan pembaruan dari RNN yang diperkenalkan oleh Sepp Hochreiter dan Jürgen Schmidhuber pada tahun 1997 (Hochreiter & Schmidhuber, 1997). LSTM bertujuan untuk mengatasi masalah *vanishing gradient* dan ketergantungan jangka panjang dalam data yang berurutan (Diarra *et al.*, 2023; Yadav & Thakkar, 2024). LSTM memungkinkan RNN untuk melakukan prediksi berurutan jangka panjang (Xie *et al.*, 2020). Model LSTM dapat memperluas memori RNN sehingga dapat menyimpan waktu yang lama dengan kemampuan membaca, menulis, dan menghapus data dari sel memorinya (Ekinci, 2024).



Gambar 2. 4 Arsitektur LSTM (Pellegrino *et al.*, 2024)

Berdasarkan arsitektur LSTM yang diilustrasikan pada Gambar 2.4, dapat dilihat bahwa LSTM memiliki 3 *gates* yang berlokasi di dalam setiap sel memori, yaitu *input gate* (i_t), *forget gate* (f_t), dan *output gate* (o_t). Setiap *gates* saling berkolaborasi untuk memperbarui dan menyesuaikan *cell state* (c_t). *Input gate* berfungsi untuk mengatur aliran dari data *input* ke dalam *cell state* dengan menentukan informasi yang harus diperbarui. *Forget gate* berfungsi untuk membuang informasi yang tidak perlu dari langkah sebelumnya dan memperbarui status *cell state*. *Output gate* berfungsi untuk menentukan *output* yang akan diteruskan ke *hidden unit* berikutnya. Perhitungan matematis yang mengatur setiap *gates* di dalam LSTM dapat dilihat pada persamaan 2.1, 2.2, dan 2.3.

$$i_t = \sigma(w_i[h_{t-1}, x_t] + b_i) \quad (2.1)$$

$$f_t = \sigma(w_f[h_{t-1}, x_t] + b_f) \quad (2.2)$$

$$o_t = \sigma(w_o[h_{t-1}, x_t] + b_o) \quad (2.3)$$

Keterangan:

i_t = *input gate*

f_t = *forget gate*

o_t = *output gate*

w_x = *weight*

b_x = *bias*

σ = fungsi aktivasi sigmoid

h_{t-1} = *hidden state* sebelumnya

Fungsi aktivasi sigmoid digunakan untuk menghitung nilai *gate* sebagai *binary output*. Nilai yang mendekati 0 menandakan bahwa informasi masa lalu dilupakan, sedangkan nilai yang mendekati 1 menandakan bahwa informasi tersebut disimpan untuk digunakan di masa depan. Perhitungan matematis *cell state* dan *candidate cell state* diuraikan pada persamaan 2.4, 2.5, dan 2.6.

$$\tilde{c}_t = \tanh(w_c[h_{t-1}, x_t] + b_c) \quad (2.4)$$

$$c_t = i_t * \tilde{c}_t + f_t * c_{t-1} \quad (2.5)$$

$$h_t = o_t * \tanh c_t \quad (2.6)$$

Keterangan:

\tilde{c}_t = *candidate cell state*

c_t = *cell state*

h_t = *hidden state*

tahn = fungsi aktivasi tahn

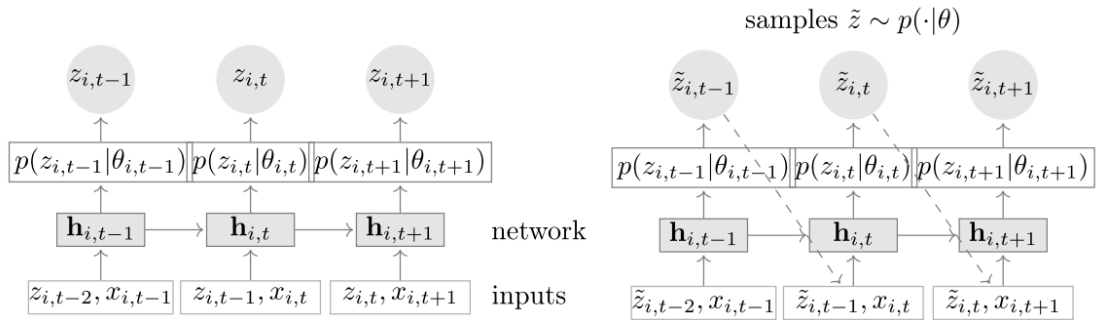
Melalui ketiga *gates* yang melindungi dan mengontrol *cell state* (Zhou *et al.*, 2024), LSTM dapat menangkap dan menyimpan informasi yang relevan sambil membuang data yang tidak perlu atau berlebihan (Syed & Ahmed, 2023). Dalam banyak kasus, LSTM mengungguli RNN karena kemampuannya dalam menghafal pola dalam jangka waktu yang lama (Kumar, C. & Kumar, M., 2024).

2.9 Deep Autoregressive (DeepAR)

Deep Autoregressive (DeepAR) merupakan metode prediksi deret waktu non-linear yang menggunakan *autoregressive recurrent neural network* untuk mempelajari *model* dari data historis semua deret waktu (*time series*) dalam *dataset* (Chang & Jia, 2023; Salinas *et al.*, 2020). DeepAR menerapkan metode LSTM dan *fully connected layer* untuk menangkap pola dan hubungan waktu yang mendasari data deret waktu (Singh *et*

al., 2024). DeepAR menggunakan nilai dan fitur dari rentang waktu dari masa lalu untuk memprediksi nilai dari suatu rentang waktu di masa depan (Niu *et al.*, 2023).

DeepAR melatih dan memprediksi satu titik data setiap saat sehingga metode ini dikenal sebagai *autoregressive* (Singh *et al.*, 2024). Dalam DeepAR, terdapat rentang pengkondisian (*conditioning range*) berupa langkah-langkah waktu dari awal hingga sebelum waktu prediksi dan rentang prediksi (*prediction range*) berupa langkah-langkah waktu dari waktu prediksi hingga akhir urutan.



Gambar 2. 5 Arsitektur DeepAR (Salinas *et al.*, 2020)

Berdasarkan arsitektur DeepAR yang diilustrasikan pada Gambar 2.5, bagian sebelah kiri menunjukkan proses pelatihan dan bagian sebelah kanan menunjukkan proses prediksi. Pada proses pelatihan, LSTM digunakan untuk memproses data deret waktu secara *autoregressive*. Setiap langkah waktu (t) pada deret waktu (i), sel LSTM menerima *input* berupa kovariat ($x_{i,t}$) dari langkah waktu saat ini dan nilai target ($z_{i,t-1}$) serta *hidden state* ($h_{i,t-1}$) dari langkah waktu sebelumnya ($t - 1$). Setelah itu, sel LSTM memproses *input* tersebut untuk menghasilkan *hidden state* baru ($h_{i,t}$) yang berisi ringkasan informasi dari langkah waktu sebelumnya dan informasi yang baru diproses pada langkah waktu saat ini (t).

Selanjutnya, *hidden state* ($h_{i,t}$) yang baru digunakan untuk menghitung nilai parameter distribusi (misalnya, rata-rata (μ) dan standar deviasi (σ) dalam distribusi Gaussian). Nilai parameter tersebut akan membentuk distribusi probabilitas yang akan digunakan untuk membuat fungsi kemungkinan (*likelihood function*). Fungsi ini digunakan untuk mengukur seberapa besar kemungkinan nilai target sebenarnya ($Z_{i,t}$) yang muncul dari distribusi probabilitas. Semakin dekat nilai target dengan nilai rata-rata dari distribusi probabilitas, maka semakin tinggi kemungkinannya. Jika nilai target

semakin jauh, maka kemungkinannya semakin rendah sehingga *model* akan diperbaiki untuk menghasilkan prediksi yang lebih akurat. Pada akhir langkah waktu (t), nilai target ($z_{i,t}$) dan *hidden state* baru ($h_{i,t}$) diteruskan ke langkah waktu berikutnya ($t + 1$). Proses ini berlanjut untuk setiap langkah waktu.

Model yang sudah dilatih akan digunakan untuk melakukan proses prediksi (*inference*). Saat melakukan prediksi, tahapannya hampir sama dengan proses pelatihan. Untuk menghitung nilai prediksi pada langkah waktu berikutnya ($z_{i,t+1}$), *model* membuat distribusi probabilitas dengan menggunakan nilai parameter dari distribusi tersebut (misalnya, rata-rata (μ) dan standar deviasi (σ) dalam distribusi Gaussian). Setelah distribusi terbentuk, *model* mengambil sampel dari distribusi tersebut untuk menghasilkan prediksi nilai target ($z_{i,t}$). Hasil prediksi ini diteruskan sebagai *input* pada langkah waktu berikutnya bersamaan dengan *hidden state* ($h_{i,t}$) yang telah diperbarui. Proses ini terus berlanjut hingga seluruh langkah waktu dalam deret waktu selesai diprediksi.

Sebagai tambahan, distribusi probabilitas tidak hanya terbatas pada distribusi Gaussian saja. Distribusi lainnya, seperti Negative Binomial, Poisson, dan Student's-T dapat digunakan bergantung pada jenis data yang digunakan.

2.10 Metrik Evaluasi

Untuk mengevaluasi hasil kinerja model DeepAR yang telah dilatih, penelitian ini menggunakan empat metrik evaluasi, yaitu *Coefficient of Determination* (R^2), *Mean Absolute Error* (MAE), *Mean Squared Error* (MSE), dan *Root Mean Squared Error* (RMSE).

2.10.1 *Coefficient of Determination* (R^2)

R^2 digunakan untuk mengukur kesesuaian hasil prediksi dengan data aktual. Nilai R^2 yang semakin tinggi dan mendekati angka 1 menunjukkan bahwa *model* mampu menjelaskan sebagian besar variasi data. Rumus perhitungan nilai R^2 ditunjukkan pada persamaan 2.11.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (2.11)$$

2.10.2 Mean Absolute Error (MAE)

MAE merupakan rata-rata dari selisih absolut antara nilai yang diprediksi prediksi (\hat{y}_i) dengan nilai aktual (y_i). Nilai MAE yang semakin kecil menunjukkan bahwa *model* mampu memprediksi radiasi sinar matahari dengan akurat. Rumus perhitungan MAE ditunjukkan pada persamaan 2.12.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.12)$$

2.10.3 Mean Square Error (MSE)

MSE merupakan rata-rata dari kuadrat selisih antara nilai yang diprediksi (\hat{y}_i) dengan nilai aktual (y_i). Nilai MSE yang semakin kecil menunjukkan bahwa *model* memiliki kesalahan prediksi yang lebih kecil secara keseluruhan. Rumus perhitungan MSE ditunjukkan pada persamaan 2.13.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2.13)$$

2.10.4 Root Mean Square Error (RMSE)

RMSE merupakan akar kuadrat dari MSE. Nilai RMSE yang semakin kecil menunjukkan bahwa *model* menghasilkan prediksi yang mendekati nilai aktual. Rumus perhitungan RMSE diuraikan pada persamaan 2.14.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2.14)$$

2.11 Penelitian Terdahulu

Penelitian terkait prediksi radiasi matahari telah banyak dilakukan. Pada tahun 2020, terdapat penelitian yang dilakukan untuk memprediksi radiasi matahari harian pada kondisi iklim dan geografis yang berbeda di Cina (Zeng *et al.*, 2020). Penelitian ini menerapkan metode *Random Forrest* dengan menggunakan data radiasi matahari yang

berasal dari National Meteorological Information Center, China Meteorological Administration. Penelitian ini juga menggunakan data meteorologi. Hasil penelitian ini menunjukkan bahwa estimasi radiasi matahari harian memiliki kesesuaian yang baik dengan pengamatan lokasi di seluruh cina dengan nilai koefisien korelasi (R) sebesar 0.95, RMSE sebesar 2.34 MJ/m^2 , dan bias rata-rata sebesar -0.04 MJ/m^2 . Selain itu, durasi sinar matahari harian, suhu permukaan tanah maksimum harian, dan hari dalam setahun memiliki peran penting dalam menentukan radiasi matahari harian di seluruh Cina.

Pada tahun 2021, terdapat penelitian yang dilakukan untuk memprediksi radiasi matahari di Provinsi Ghardaia yang terletak di wilayah padang pasir Aljazair dengan ketinggian 450 m (Ferkous *et al.*, 2021). Penelitian ini menggunakan dua metode, yakni *Wavelet-Coupled Gaussian Process Regression* (W-GPR) dan *Gaussian Process Regression* (GPR). Penelitian ini menggunakan data yang diperoleh dari Applied Research Unit for Renewable Energy (URAER), mencakup suhu udara minimum, suhu udara maksimum, suhu udara rata-rata, kelembapan relatif maksimum, kelembapan relatif maksimum, kelembapan relatif rata-rata, dan total radiasi matahari harian. Data yang digunakan diukur dan dicatat selama empat tahun dari 1 Januari 2013 hingga 31 Desember 2016. Hasil dari penelitian ini menunjukkan keefektifan metode W-GPR dibandingkan dengan metode GPR klasik dengan nilai R^2 sebesar 0.923, MAE sebesar 1.625 MJ/m^2 , dan RMSE sebesar 2.4191 MJ/m^2 .

Pada tahun 2022, terdapat penelitian yang dilakukan untuk memprediksi radiasi matahari harian dari 27 kota yang terletak di 27 negara yang sebagian besar memiliki distribusi radiasi matahari yang berbeda di Eropa (Nematchoua *et al.*, 2022). Penelitian ini menggunakan beberapa metode, seperti *Linear Model*, *Decision Tree*, *Support Vector Machine*, *Deep Learning*, *Random Forrest*, dan *Gradient Boosted Tree*. Penelitian ini menggunakan data yang berasal dari 27 stasiun meteorologi yang terletak di 27 negara yang diteliti, kemudian diukur pada ketinggian 100 m. Parameter yang digunakan dalam penelitian ini, meliputi suhu udara, kecepatan angin, kelembapan relatif, dan radiasi matahari. Hasil penelitian ini menunjukkan bahwa metode *Support Vector Machine* memberikan hasil terbaik dengan nilai RMSE sebesar $0,189 \text{ MJ/m}^2$ dan metode *Decision Tree* memberikan hasil terburuk dengan nilai RMSE sebesar $0,405 \text{ MJ/m}^2$.

Penelitian terkait prediksi radiasi matahari di enam pembangkit listrik tenaga surya di Queensland, Australia dilakukan oleh Ghimire *et al.* (2022). Penelitian ini menggunakan metode CSVR yang merupakan integrasi antara metode *Convolutional Neural Network* (CNN) dengan metode *Support Vector Regression* (SVR). Metode CNN digunakan untuk melakukan *feature selection*, kemudian diintegrasikan dengan metode SVR untuk mendapatkan hasil prediksi radiasi matahari. Variabel prediksi atau *input* yang digunakan pada penelitian ini diperoleh dari variabel meteorologi yang dihasilkan oleh *Global Climate Model* (GCM), mencakup parameter awan, parameter kelembapan, curah hujan, kecepatan angin, dan sebagainya. Sebagai tambahan, variabel prediksi diperkaya dengan *ground-based observation data* yang berasal dari repositori Scientific Information for Landowners (SILO), mencakup penguapan, tekanan uap, curah hujan, dan sebagainya. Hasil penelitian ini menunjukkan bahwa metode CSVR unggul dibandingkan dengan beberapa metode *deep learning* yang berbeda, meliputi *Long Short-Term Memory*, *Deep Belief Network*, *Radial Basis Function Network*, *Boosting Random Forest Regression*, *Multivariate Adaptive Regression Splines*, *Weighted K-Nearest Neighbor*, *Gaussian Processes for Machine Learning*, dan *M5 Regression Tree* (M5TREE). Secara khusus, metode CSVR mencatat nilai RMSE/MAE yang berkisar antara $\approx 2.172 - 3.305/1,624 - 2.370 \text{ MJ/m}^2$ pada enam pembangkit listrik tenaga surya yang diuji, sedangkan metode *deep learning* yang berbeda menghasilkan nilai yang berkisar antara $\approx 2.514 - 3.879/1.939 - 2.866 \text{ MJ/m}^2$.

Pada tahun 2023, terdapat penelitian yang dilakukan untuk memprediksi radiasi matahari setiap jam di Distrik Baru Lanzhou yang terletak di Provinsi Gansu, Cina (Yang *et al.*, 2023). Penelitian ini menggunakan metode *Back-Propagation Network*, *Support Vector Machine*, dan *Light Gradient Boosting Machine* (LightGBM) yang digunakan untuk membangun model prediksi dan *Shapley Additive Explanations* (SHAP) yang digunakan untuk menyederhanakan struktur *model* prediksi dengan menganalisis hubungan antara variabel *input* dengan hasil prediksi. Penelitian ini menggunakan data meteorologi aktual daerah tersebut yang berasal dari National Meteorological Information Center of China. Parameter yang digunakan dalam penelitian ini, mencakup radiasi matahari luar angkasa, jenis cuaca, tutupan awan, suhu udara, kelembapan relatif, dan waktu. Hasil penelitian ini menunjukkan bahwa metode LightGBM memiliki performa terbaik dengan nilai RMSE sebesar 126.1 MJ/m^2 . Selain itu, hasil analisis *Shapley Additive Explanations* mengungkapkan bahwa jenis cuaca

bukan merupakan faktor utama yang mempengaruhi hasil prediksi metode LightGBM sehingga ketika parameter jenis cuaca dikeluarkan, akurasi metode LightGBM tidak berubah secara signifikan dengan nilai RMSE diperbarui menjadi 135.2 MJ/m².

Penelitian yang menggunakan DeepAR dilakukan oleh (Zhu & Huang, 2021). Penelitian ini dilakukan untuk memprediksi konsumsi listrik perusahaan dalam jangka pendek. Penelitian ini menggunakan metode DeepAR dan WaveNet sebagai representasi metode *deep generative*. Penelitian ini menggunakan data, mencakup konsumsi listrik harian, suhu, kecepatan angin, tekanan, kelembapan, dan variabel lain yang dapat mempengaruhi penggunaan listrik. Hasil dari penelitian ini menunjukkan bahwa metode DeepAR dan WaveNet memiliki kinerja yang sama baiknya dibandingkan dengan metode lainnya, termasuk *machine learning*, ARIMA, dan LSTM. DeepAR memiliki performa terbaik kecuali dalam rentang waktu 2 hari, sedangkan WaveNet memiliki performa terbaik kecuali dalam rentang waktu 4 hari. Sebagai tambahan, kekurangan dari penelitian ini adalah akurasi prediksinya tidak sebaik hasil prediksi deret waktu lainnya dikarenakan terdapat kemungkinan memiliki masalah kualitas pada data yang digunakan.

Penelitian terkait prediksi permintaan sepeda di layanan sepeda bersama atau *bike-sharing service* (BSS) yang terletak di Korea dilakukan oleh (Lim *et al.*, 2022). Penelitian ini menerapkan metode DeepAR untuk memprediksi permintaan sepeda berdasarkan stasiun menggunakan data BSS yang berasal dari Kota Metropolitan Seoul. Selain itu, metode statistik, seperti ARIMA, ARIMAX, dan *Holt-Winters* akan digunakan sebagai tolok ukur. Hasil dari penelitian ini menunjukkan bahwa DeepAR merupakan metode yang tepat untuk menyediakan distribusi probabilitas sebagai hasil prediksi dengan mengungguli metode statistik lainnya dengan lebih dari 16% hingga 61% dalam *error reductions*.

Penelitian yang menggunakan metode DeepAR juga dilakukan oleh (Ramos & Oliveira, 2023). Penelitian ini bertujuan untuk menguji keakuratan metode prediksi yang dipengaruhi oleh berbagai kovariat permintaan dengan mempertimbangkan potensi dari dampaknya terhadap pengambilan keputusan operasional. Penelitian ini menerapkan metode DeepAR dan menggunakan data kompetisi M5 berupa kumpulan data penjualan unit hierarki dari Walmart yang kredibel dan banyak digunakan untuk penelitian peramalan. *Model* DeepAR dilatih menggunakan kumpulan data M5 sejumlah 30.490 penjualan produk di sepuluh toko. Hasil penelitian ini menunjukkan

bahwa metode DeepAR memiliki kinerja yang lebih unggul dibandingkan dengan tolok ukur *seasonal naïve* dengan RMSSE sebesar 1,8% dan peningkatan MASE sebesar 6,5%. Selain itu, penyertaan fitur terkait waktu, peristiwa, dan ID secara konsisten meningkatkan keakuratan model DeepAR yang tidak memiliki kovariat tambahan.

Tabel 2. 1 Penelitian Terdahulu

No	Peneliti	Judul	Metode	Keterangan
1	Zeng <i>et al.</i> (2020)	<i>Daily Global Solar Radiation in China Estimated from High-Density Meteorological</i>	<i>Random Forrest</i>	Penelitian ini bertujuan untuk memprediksi radiasi matahari harian pada kondisi iklim dan geografis yang berbeda di Cina. Hasil dari penelitian ini menunjukkan estimasi radiasi matahari harian memiliki kesesuaian yang baik.
2	Ferkous <i>et al.</i> (2021)	<i>Wavelet-gaussian Process Regression Model for Forecasting Daily Solar Radiation in the Saharan Climate</i>	<i>Wavelet-Coupled Gaussian Process Regression (W-GPR) dan Gaussian Process Regression (GPR).</i>	Penelitian ini bertujuan untuk memprediksi radiasi matahari di Provinsi Ghardaia yang terletak di wilayah padang pasir Aljazair. Hasil dari penelitian ini menunjukkan keefektifan metode W-GPR dibandingkan dengan metode GPR klasik dengan nilai R^2 sebesar 0.923, MAE sebesar 1.625 MJ/m ² , dan RMSE sebesar 2.4191 MJ/m ² .

No	Peneliti	Judul	Metode	Keterangan
3	Nematchoua <i>et al.</i> (2022)	<i>Prediction of Daily Global Solar Radiation and Air Temperature Using Six Machine Learning Algorithms; case of 27 European countries</i>	<i>Linear Model, Decision Tree, Support Vector Machine, Deep Learning, Random Forrest, dan Gradient Boosted Tree.</i>	Penelitian ini bertujuan untuk memprediksi radiasi matahari harian dari 27 kota yang terletak di 27 negara Eropa dengan menggunakan beberapa metode <i>machine learning</i> . Hasil penelitian ini menunjukkan bahwa metode <i>Support Vector Machine</i> memberikan hasil terbaik dengan nilai RMSE sebesar 0,189 MJ/m ² .
4	Ghimire <i>et al.</i> (2022)	<i>Hybrid Deep CNN-SVR Algorithm for Solar Radiation Prediction Problems in Queensland, Australia</i>	<i>Convolutional Neural Network - Support Vector Regression (CSVR).</i>	Penelitian ini bertujuan untuk memprediksi radiasi matahari di enam pembangkit listrik tenaga surya di Queensland, Australia. Hasil penelitian ini menunjukkan bahwa CSVR lebih unggul dibandingkan dengan beberapa metode <i>deep learning</i> yang berbeda.

No	Peneliti	Judul	Metode	Keterangan
5	Yang <i>et al.</i> (2023)	<i>Simplified Method for Predicting Hourly Global Solar Radiation Using Extraterrestrial Radiation and Limited Weather Forecast Parameters</i>	<i>Back-Propagation Network, Support Vector Machine, Light Gradient Boosting Machine</i> (LightGBM), dan <i>Shapley Additive Explanations</i> (SHAP)	Penelitian ini bertujuan untuk memprediksi radiasi matahari setiap jam di Distrik Baru Lanzhou yang terletak di Provinsi Gansu, Cina. Hasil penelitian ini menunjukkan bahwa metode LightGBM memiliki performa terbaik dengan nilai RMSE sebesar 126.1 MJ/m ² dan hasil analisis SHAP mengungkapkan bahwa jenis cuaca bukan merupakan faktor utama yang mempengaruhi hasil prediksi metode LightGBM.
6	Zhu & Huang (2021)	<i>Research on Deep Generative Model Application for Short-term Load Forecasting of Enterprise Electricity</i>	DeepAR dan WaveNet	Penelitian ini bertujuan untuk memprediksi konsumsi listrik perusahaan dalam jangka pendek. Hasil penelitian ini menunjukkan bahwa metode DeepAR dan WaveNet memiliki kinerja yang baik dibandingkan dengan metode lainnya, termasuk <i>machine learning</i> , ARIMA, dan LSTM.

No	Peneliti	Judul	Metode	Keterangan
7	Lim <i>et al.</i> (2022)	<i>Probabilistic Forecasting for Demand of a Bike-Sharing Service Using a Deep-Learning Approach</i>	DeepAR	Penelitian ini bertujuan untuk memprediksi permintaan sepeda di layanan sepeda bersama atau <i>bike-sharing service</i> (BSS) yang terletak di Korea. Hasil penelitian ini menunjukkan bahwa metode DeepAR lebih unggul dibandingkan metode statistik lainnya dengan lebih dari 16% hingga 61% dalam <i>error reductions</i> .
8	Ramos & Oliveira (2023)	<i>Robust Sales forecasting Using Deep Learning with Static and Dynamic Covariates</i>	DeepAR	Penelitian ini bertujuan untuk menguji keakuratan metode prediksi yang dipengaruhi oleh berbagai kovariat permintaan. Hasil penelitian ini menunjukkan bahwa metode DeepAR memiliki kinerja yang baik dengan peningkatan RMSSE sebesar 1,8% dan peningkatan MASE sebesar 6,5%.

2.12 Perbedaan Penelitian

Penelitian terkait prediksi radiasi matahari telah banyak dilakukan dengan beragam *metode* dan *dataset*. Perbedaan penelitian yang dilakukan oleh Zeng *et al.* (2020) terletak pada metode dan data yang digunakan. Penelitian ini menggunakan metode

Random Forrest serta data radiasi matahari dan meteorologi, mencakup tekanan barometrik rata-rata harian, kelembapan relatif rata-rata harian, durasi sinar matahari harian, suhu udara rata-rata harian, kecepatan angin rata-rata harian, suhu udara permukaan maksimum dan minimum harian, kapasitas penguapan harian, dan curah hujan.

Penelitian yang dilakukan oleh Ferkous et al. (2021) menggunakan dua metode, yakni *Wavelet-Coupled Gaussian Process Regression* (W-GPR) dan *Gaussian Process Regression* (GPR). *Dataset* yang digunakan dalam penelitian ini, mencakup suhu udara minimum, suhu udara maksimum, suhu udara rata-rata, kelembapan relatif maksimum, kelembapan relatif maksimum, kelembapan relatif rata-rata, dan total radiasi matahari harian. Data yang digunakan diukur dan dicatat selama empat tahun dari 1 Januari 2013 hingga 31 Desember 2016. Tiga tahun pertama dari data (2013 — 2015) digunakan sebagai data latih, sedangkan data tahun terakhir (2016) digunakan untuk menguji model yang berbeda.

Perbedaan dalam penelitian oleh Nematchoua et al. (2022) terletak pada metode, pengambilan data, dan parameter pelatihan. Penelitian ini menggunakan beberapa metode, seperti *Linear Model*, *Decision Tree*, *Support Vector Machine*, *Deep Learning*, *Random Forrest*, dan *Gradient Boosted Tree*. Penelitian ini menggunakan *dataset* yang berasal dari 27 stasiun meteorologi yang diukur pada ketinggian 100. Parameter yang digunakan dalam penelitian ini, meliputi suhu udara, kecepatan angin, kelembapan relatif, dan radiasi matahari.

Penelitian yang dilakukan oleh Ghimire *et al.* (2022) menggunakan metode CSVR yang merupakan integrasi antara metode *Convolutional Neural Network* (CNN) dengan metode *Support Vector Regression* (SVR). Variabel prediksi atau input pada penelitian ini menggunakan data meteorologi dan *ground-based observation data*, mencakup parameter awan, parameter kelembapan, curah hujan, kecepatan angin, penguapan, tekanan uap, curah hujan, dan sebagainya.

Penelitian yang dilakukan oleh Yang *et al.*, (2023) menggunakan metode *Back-Propagation Network*, *Support Vector Machine*, dan *Light Gradient Boosting Machine* (LightGBM). Penelitian ini juga menggunakan *Shapley Additive Explanations* (SHAP) yang digunakan untuk menganalisis hubungan antara variabel *input* dengan hasil prediksi. Parameter yang digunakan dalam penelitian ini, mencakup radiasi matahari luar angkasa, jenis cuaca, tutupan awan, suhu udara, kelembapan relatif, dan waktu.

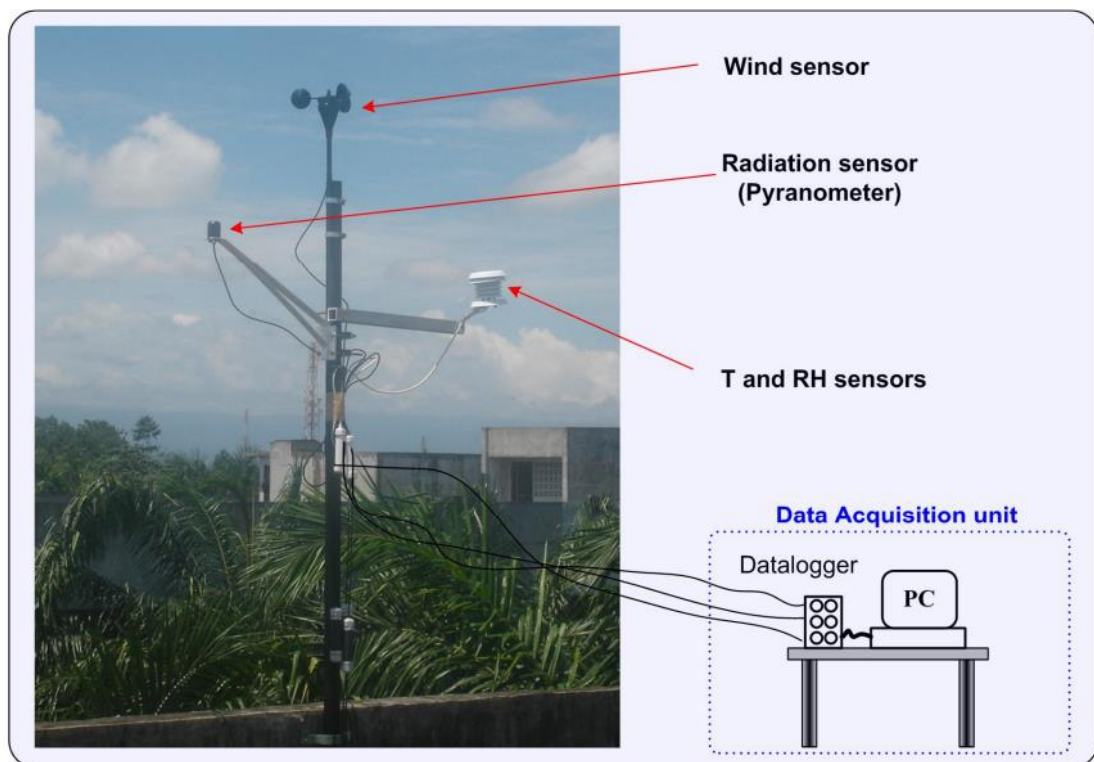
Berdasarkan perbandingan penelitian yang telah dijelaskan, penelitian ini memiliki perbedaan dengan penelitian yang telah dilakukan sebelumnya. Perbedaan penelitian ini terletak pada metode, pengambilan data penelitian, data penelitian, wilayah penelitian, dan parameter yang digunakan dalam proses prediksi. Penelitian ini menggunakan metode *Deep Autoregressive* (DeepAR). Data yang digunakan dalam penelitian ini berupa data cuaca dan radiasi matahari yang berasal dari penelitian yang dilakukan oleh Ambarita (2017), mencakup suhu udara, kelembapan udara, radiasi matahari, dan titik embun. Data tersebut diambil menggunakan alat pengukur radiasi matahari yang dilengkapi sensor kecepatan angin, sensor radiasi (*pyranometer*), serta sensor suhu dan kelembapan udara.

BAB 3

ANALISIS DAN PERANCANGAN SISTEM

3.1 Sumber Data

Penelitian ini menggunakan sumber data yang berasal dari penelitian sebelumnya yang dilakukan oleh Ambarita (2017). Dalam penelitian tersebut, data diambil dengan menggunakan alat pengukur radiasi matahari yang dilengkapi sensor kecepatan angin, sensor radiasi matahari, serta sensor suhu dan kelembapan udara dengan rentang pengukuran setiap sensor adalah 0 — 76 m/s, 0 — 1280 W/m², dan - 40° C — 75° C. Pengukuran dilakukan dengan interval setiap 2 menit dan berlokasi di atas atap Gedung S2 Teknik Mesin Universitas Sumatera Utara. Alat pengukur radiasi matahari yang digunakan dalam penelitian tersebut dapat dilihat pada Gambar 3.1.



Gambar 3. 1 Alat Pengukur Radiasi Matahari (Ambarita, 2017)

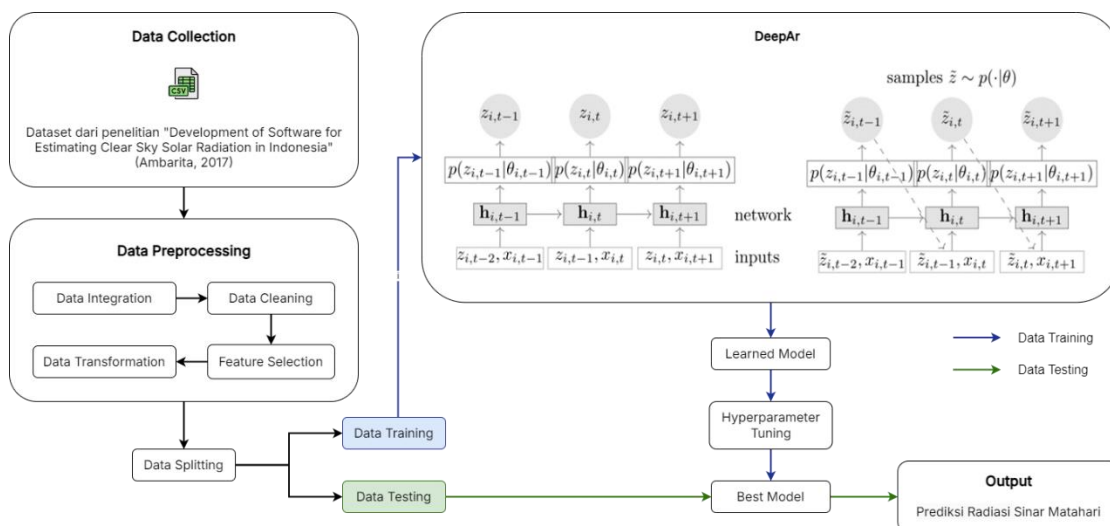
Data yang diperoleh dari penelitian tersebut berupa 63 dokumen Excel dengan format .xlsx yang dikumpulkan dari Oktober 2017 hingga Desember 2022. Rincian data yang digunakan dapat dilihat pada Tabel 3.1.

Tabel 3. 1 Rincian Data

Periode	Jumlah Dokumen
Oktober 2017 — Desember 2017	3
Januari 2018 — Desember 2018	12
Januari 2019 — Desember 2019	12
Januari 2020 — Desember 2020	12
Januari 2021 — Desember 2021	12
Januari 2022 — Desember 2022	12
Total	63

3.2 Arsitektur Umum

Dalam pengembangan sistem prediksi radiasi matahari menggunakan metode *Deep Autoregressive* (DeepAR), terdapat serangkaian tahapan yang harus dilakukan. Tahap awal dimulai dengan mengumpulkan sumber data. Data yang telah dikumpulkan akan melalui tahap prapemrosesan untuk memastikan bahwa data yang digunakan memiliki kualitas yang baik. Data yang telah diproses akan dipisahkan menjadi dua bagian, yakni data *training* dan data *testing*. Model DeepAR akan dilatih menggunakan data *training*. Setelah itu, *model* yang telah dilatih akan diuji menggunakan data *testing*. Arsitektur umum penelitian ini dapat dilihat pada Gambar 3.2.



Gambar 3. 2 Arsitektur Umum

3.2.1 Data Collection

Penelitian ini menggunakan sumber data yang berasal dari penelitian yang dilakukan oleh Ambarita (2017). Data yang diperoleh dari penelitian tersebut berupa kumpulan dokumen Excel sebanyak 63 dokumen dengan rincian data yang dapat dilihat pada Tabel 3.1. Setiap dokumen berisi data cuaca dan radiasi matahari, meliputi suhu udara (*Temperature*), kelembapan udara (*Relative Humidity*), kecepatan angin (*Wind Speed*), kecepatan embusan (*Gust Speed*), titik embun (*Dew Point*), dan radiasi matahari (*Solar Radiation*).

3.2.2 Data Preprocessing

Tahap prapemrosesan dilakukan untuk memilih dan menyaring data sehingga data yang digunakan memiliki kualitas yang baik, terstruktur, dan sesuai dengan kebutuhan penelitian. Pada penelitian ini, terdapat empat tahap prapemrosesan data yang akan dilakukan, yaitu *data integration*, *data cleaning*, *feature selection*, dan *data transformation*.

3.2.2.1 Data Integration

Data yang diperoleh berisi kumpulan folder yang dikelompokkan berdasarkan tahun. Setiap folder berisi kumpulan dokumen Excel yang dikelompokkan berdasarkan bulan. Dalam setiap dokumen, terdapat lembar kerja Excel (*worksheet*) yang dikelompokkan berdasarkan hari. Namun, data yang terdapat di dalam setiap *worksheet* memiliki kolom yang tidak seragam sehingga menyebabkan data sulit untuk diproses dan dianalisis.

Pada tahap ini, data akan digabungkan menjadi satu dokumen utuh dengan format .csv. Setelah itu, kolom pada dokumen akan disesuaikan agar seluruh data memiliki kolom yang seragam. Proses integrasi data ditunjukkan pada *pseudocode* di bawah ini.

```

DEFINE COLUMNS_NAME AND COLUMN_RENAME_MAP
FUNCTION preprocess_data(data):
    SET column names from first row
    REMOVE first row
    RENAME columns using COLUMN_RENAME_MAP
    RETURN preprocessed data

```

```

FUNCTION integrate_data(directory):
    INITIALIZE file_locations
    INITIALIZE data_list

    FOR each folder in directory:
        FOR each file in folder:
            IF file is .xlsx AND not temporary:
                ADD file to file_locations

    FOR each file in file_locations:
        FOR each sheet in file:
            preprocess data using preprocess_data()
            APPEND preprocessed data to data_list

    CONCATENATE all data
    REMOVE columns not in COLUMNS_NAME
    REMOVE duplicates rows
    RETURN integrated data

CALL integrate_data() with directory path
CONVERT integrated data to CSV format with UTF-8 encoding

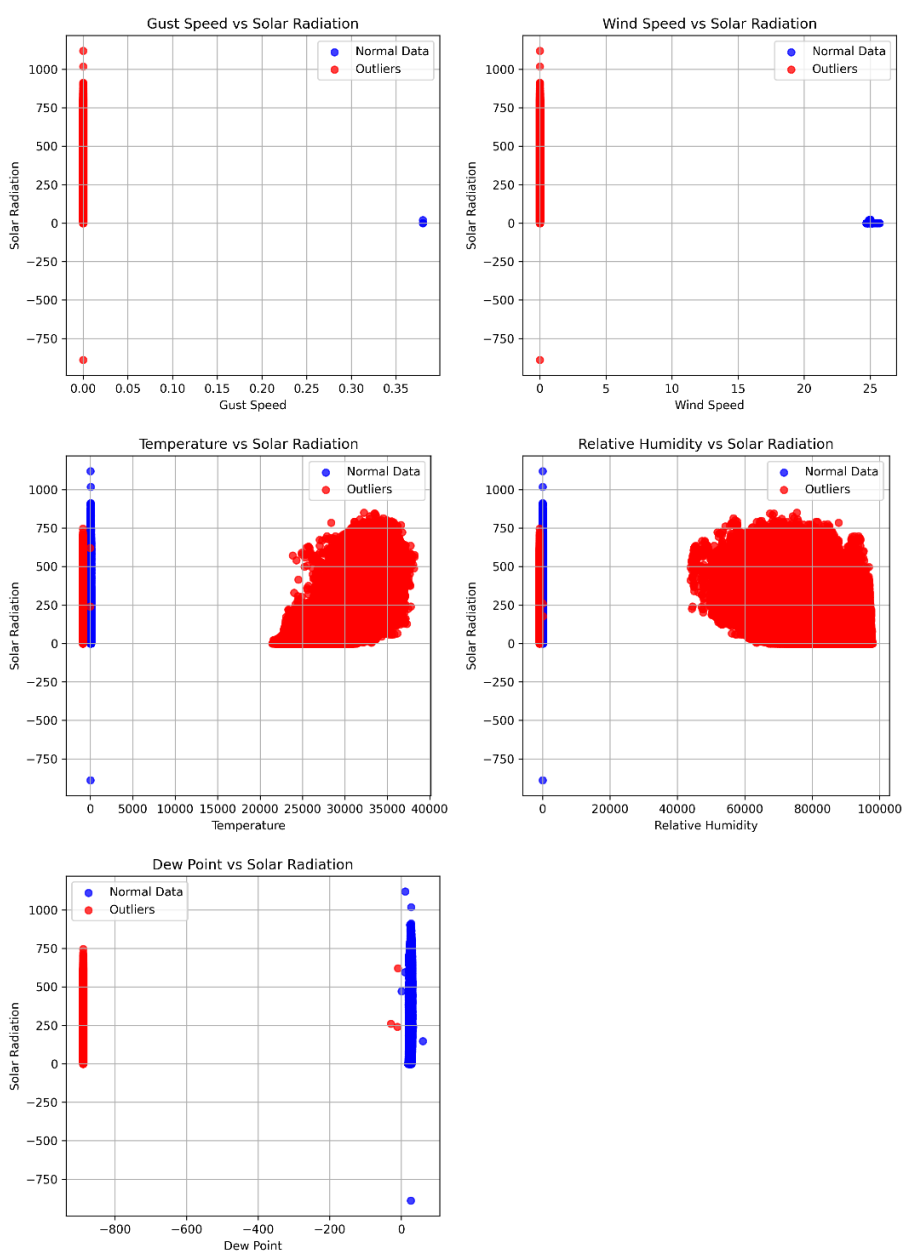
```

3.2.2.2 Data Cleaning

Setelah penggabungan data selesai, total keseluruhan data mencapai 2.536.567 data. Data yang telah digabungkan harus melalui tahap pembersihan. Hal ini dilakukan karena terdapat kemungkinan adanya *outliers* dan *missing value* pada distribusi data yang menyebabkan data menjadi tidak konsisten. Pembersihan data bertujuan untuk menghilangkan *outliers* dan menyesuaikan data dengan kebutuhan penelitian. Statistik dan distribusi data sebelum melalui proses pembersihan dapat dilihat pada Tabel 3.2 dan Gambar 3.3.

Tabel 3. 2 Statistik Data Sebelum Proses Pembersihan

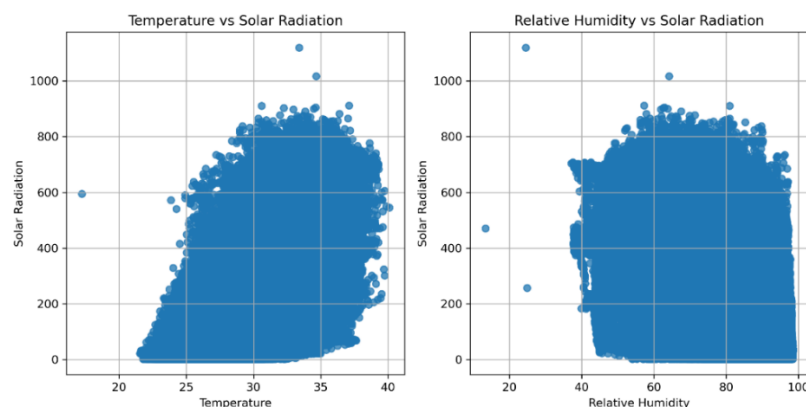
Data	Minimum	Maksimum	Missing Value
<i>Gust Speed</i>	0	25,1	1.873
<i>Wind Speed</i>	0	0,38	1.427
<i>Temperature</i>	-888,88	38.198	509
<i>Relative Humidity</i>	-888,88	97.800	509
<i>Dew Point</i>	-888,9	59,8	236.550
<i>Solar Radiation</i>	-888,9	1119.4	0

**Gambar 3. 3** Grafik Distribusi Data Sebelum Proses Pembersihan

Dalam proses pembersihan, data akan disaring berdasarkan waktu penyinaran yang ditentukan mulai dari saat terjadi peningkatan radiasi matahari sebesar 1 W/m^2 atau lebih. Setelah itu, data kecepatan angin (*Wind Speed*), kecepatan embusan (*Gust Speed*), dan titik embun (*Dew Point*) akan dihapus karena memiliki *missing value* yang cukup banyak dan sebagian besar nilainya berkumpul pada angka 0 sebagaimana yang ditunjukkan pada Tabel 3.2 dan Gambar 3.3. Selain itu, data suhu (*Temperature*) dan kelembapan udara (*Relative Humidity*) akan disesuaikan dan disaring karena terdapat nilai di atas 50°C untuk suhu dan 100% untuk kelembapan udara yang tidak sesuai dengan suhu dan kelembapan udara normal di Indonesia. Setelah proses penyaringan selesai, *missing value* dalam data akan diisi dengan nilai rata-rata pada kolom tersebut. Proses pembersihan data ditunjukkan pada *pseudocode* di bawah ini.

```
IF RH >= 100 THEN RH = RH / 1000
IF Temp >= 100 THEN Temp = Temp / 1000
FILTER rows WHERE Solar Radiation >= 1
FILTER rows WHERE Temp >= 50 AND RH >= 100
DROP Wind Speed, Gust Speed, AND Dew Point
FILL outliers with NaN
FILL NaN and missing values with average values
```

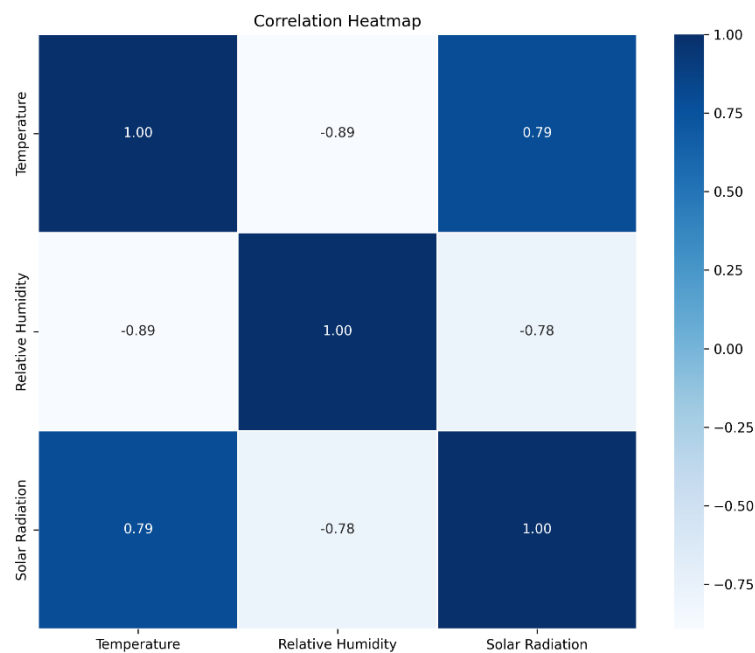
Setelah proses pembersihan data selesai, total keseluruhan data mencapai 1.752 data. Selanjutnya, data akan disederhanakan dengan menghitung rata-rata nilai untuk setiap kolom, kemudian data tersebut dikelompokkan berdasarkan hari. Distribusi data setelah melalui proses pembersihan dapat dilihat pada Gambar 3.4.



Gambar 3. 4 Distribusi Data Setelah Proses Pembersihan

3.2.2.3 Feature Selection

Pada tahap ini, akan dilakukan pemilihan fitur yang akan digunakan pada pelatihan *model*. Pemilihan fitur bertujuan untuk meningkatkan efisiensi dan kualitas *model*. Penggunaan fitur yang tepat dapat mengurangi risiko *overfitting* karena *model* menjadi lebih sederhana. Korelasi seluruh fitur digambarkan dalam bentuk *correlation heatmap* yang dapat dilihat pada Gambar 3.5.



Gambar 3. 5 *Correlation Heatmap*

Berdasarkan Gambar 3.5, suhu udara (*Temperature*) dan kelembapan udara (*Relative Humidity*) dipilih sebagai fitur pada pelatihan *model* karena memiliki korelasi yang cukup tinggi dengan nilai 0.79 dan -0.78.

3.2.2.4 Data Transformation

Pada tahap ini, data akan ditransformasi menggunakan *MinMaxScaler* dari *library* *scikit-learn* untuk menyesuaikan nilai fitur dalam rentang 0 hingga 1. Proses transformasi data ditunjukkan pada *pseudocode* di bawah ini.

```
scaler = MinMaxScaler()
scaled = scaler.fit_transform(features)
```

3.2.3 Data Splitting

Pada tahap ini, data akan dipisahkan menjadi dua bagian, yakni data *training* dan data *testing*. Data *training* akan digunakan untuk melatih *model*, sedangkan data *testing* akan digunakan untuk menguji *model* yang telah dilatih. Data *training* yang akan digunakan sebanyak total data dikurangi rentang waktu prediksi yang telah ditentukan.

Sementara itu, data *testing* akan dipisahkan menjadi dua bagian, yakni *test input* dan *test label*. *Test input* merupakan data historis yang diberikan ke *predictor* sebagai *input* untuk menghasilkan prediksi, sedangkan *test label* merupakan data masa depan yang digunakan untuk menguji dan mengevaluasi hasil prediksi *model*. *Test input* yang akan digunakan sebanyak total data dikurangi rentang waktu prediksi yang telah ditentukan, sedangkan *test label* yang akan digunakan sebanyak rentang waktu prediksi yang telah ditentukan.

3.2.4 Pelatihan Model

Pada tahap ini, *model* DeepAR dilatih menggunakan data *training* untuk memahami pola pada data historis. Implementasi *model* DeepAR dilakukan dengan menggunakan *class* *DeepAREstimator* dari *library* GluonTS. *DeepAREstimator* memiliki parameter yang dapat ditentukan dan disesuaikan dengan kebutuhan pelatihan *model*, seperti *freq*, *trainer*, *num_cells*, *num_layers*, *batch_size*, *distr_output*, *prediction_length*, dan *context_length*. Dalam pelatihan *model*, parameter *context_length* digunakan untuk menentukan jumlah titik waktu yang dapat dilihat *model* sebelum melakukan prediksi, sedangkan *prediction_length* digunakan untuk menentukan jumlah langkah waktu yang diprediksi oleh *model*. Untuk melatih *model*, *context_length* akan menggunakan nilai yang sama dengan *prediction_length* karena memungkinkan *model* memahami pola yang berulang dengan lebih baik.

Pelatihan *model* dilakukan dengan menggunakan *method train* dari *class* *DeepAREstimator*. Selama proses pelatihan, metode *early stopping* akan diterapkan untuk mengurangi risiko *overfitting* dengan menghentikan pelatihan *model* lebih awal apabila tidak ada peningkatan kinerja dan performa. Proses pelatihan *model* ditunjukkan pada *pseudocode* di bawah ini.

```

DEFINE model_path
INITIALIZE estimator with parameters
INITIALIZE callbacks for early stopping
SET epochs AND callbacks to estimator.trainer

TRAIN model with data_train
SAVE trained model to model_path

```

Setelah pelatihan *model* selesai, *hyperparameter tuning* dilakukan untuk menemukan parameter dengan kinerja dan performa paling optimal selama proses pelatihan *model*. Parameter yang digunakan untuk melakukan *hyperparameter tuning* dapat dilihat pada Tabel 3.3.

Tabel 3. 3 Daftar Hyperparameter DeepAR

Parameter	Nilai
<i>freq</i>	D
<i>num_layers</i>	1, 2, 3
<i>num_cells</i>	30, 40, 50
<i>batch_size</i>	16, 32, 64, 128
<i>distr_output</i>	StudentTOutput
<i>learning_rate</i>	0.001
<i>context_length</i>	7, 30, 60, 90, 120
<i>prediction_length</i>	7, 30, 60, 90, 120
<i>use_feat_dynamic_real</i>	true

3.2.5 Pengujian Model

Pada tahap ini, *model* DeepAR yang telah dilatih akan diuji menggunakan data *testing* untuk menilai kinerjanya dalam memprediksi radiasi matahari. Pengujian dilakukan dengan memberikan *test input* ke *predictor* untuk menghasilkan prediksi, kemudian hasil prediksi akan dibandingkan dengan *test label* atau data aktual untuk mengevaluasi kinerja *model*. Dalam proses evaluasi kinerja *model*, terdapat empat metrik evaluasi yang akan digunakan, yaitu MAE, MSE, RMSE, dan R^2 .

3.2.6 Output

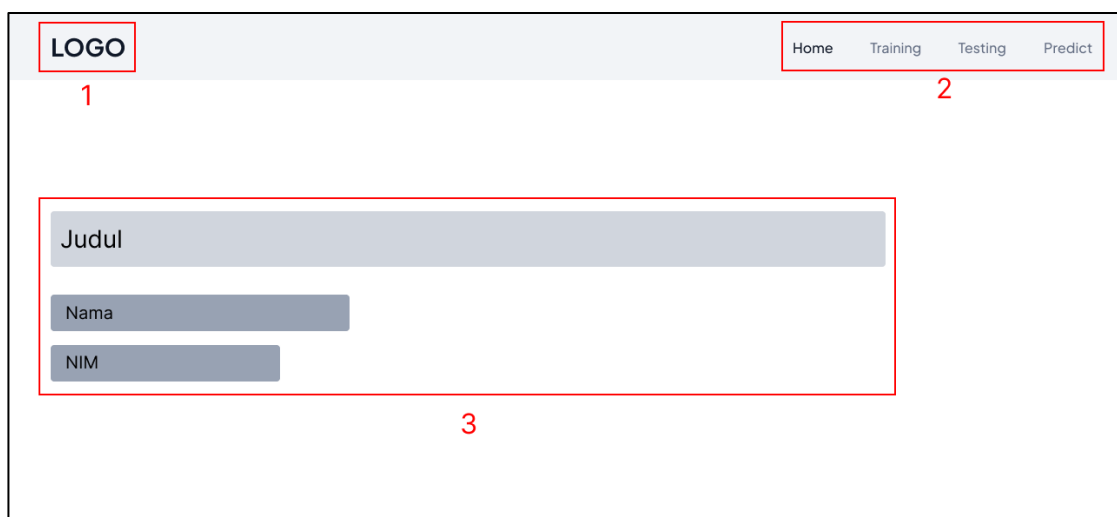
Hasil akhir dari *model* setelah melalui tahap pelatihan dan pengujian adalah prediksi radiasi matahari untuk rentang waktu yang telah ditentukan.

3.3 Perancangan Antarmuka Sistem

Bagian ini akan menjelaskan proses perancangan antarmuka pada sistem prediksi radiasi matahari yang akan dikembangkan dalam bentuk aplikasi berbasis *website*. Perancangan antarmuka ini bertujuan untuk mendapatkan gambaran mengenai sistem yang akan dikembangkan dan menjadi panduan dalam pengembangan sistem. Halaman yang akan dirancang dalam *website* ini, terdiri atas halaman beranda, halaman pelatihan, halaman pengujian, dan halaman prediksi.

3.3.1 Rancangan Halaman Beranda

Halaman beranda merupakan halaman awal yang akan diperlihatkan kepada pengguna ketika pertama kali mengakses *website*. Halaman ini menampilkan informasi mengenai logo universitas, judul penelitian, identitas penulis, dan *link* yang akan digunakan untuk mengarahkan pengguna ke halaman yang dituju. Rancangan halaman beranda dapat dilihat pada Gambar 3.6.



Gambar 3. 6 Rancangan Halaman Beranda

Keterangan:

- Label 1** menunjukkan logo universitas.
- Label 2** menunjukkan *link* yang akan digunakan untuk mengarahkan pengguna ke halaman yang dituju.
- Label 3** menunjukkan identitas penulis.

3.3.2 Rancangan Halaman Pelatihan

Halaman pelatihan merupakan halaman yang akan digunakan oleh pengguna untuk melatih *model*. Halaman ini menyediakan fasilitas kepada pengguna untuk memilih rentang waktu prediksi, mengunggah *dataset* dengan format .csv yang akan digunakan dalam proses pelatihan, dan tombol ‘Train’ yang akan digunakan untuk memulai pelatihan *model*. Rancangan halaman pelatihan dapat dilihat pada Gambar 3.7.

The image shows a web interface for a training page. At the top, there is a header with a 'LOGO' on the left and navigation links 'Home', 'Training', 'Testing', and 'Predict' on the right. Below the header, the main section is titled 'Training'. Inside this section, there are four elements highlighted with red boxes and numbered labels:

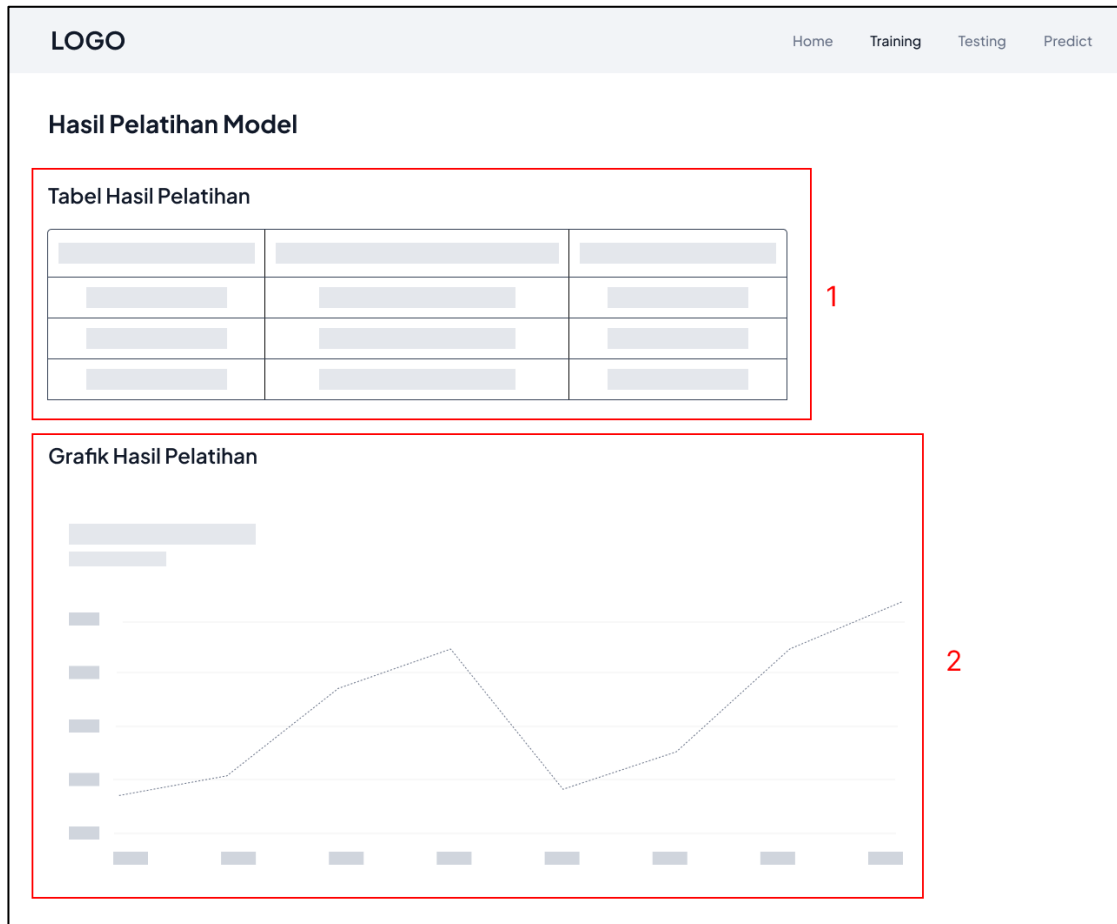
- Label 1:** A box containing the text 'Metode:' followed by a dropdown menu currently showing 'DeepAR'.
- Label 2:** A box containing the text 'Jangka waktu prediksi:' followed by five buttons: '7 Hari', '30 Hari', '60 Hari', '90 Hari', and '120 Hari'.
- Label 3:** A large dashed box containing the text 'Upload Data Training (.csv):' and a file upload area with a folder icon and the text 'Browse file to upload'.
- Label 4:** A button labeled 'Train'.

Gambar 3. 7 Rancangan Halaman Pelatihan

Keterangan:

- Label 1** menunjukkan metode yang digunakan untuk melatih *model*.
- Label 2** menunjukkan rentang waktu prediksi yang dapat dipilih pengguna.
- Label 3** menunjukkan *input* atau wadah untuk mengunggah *dataset* pelatihan.
- Label 4** menunjukkan tombol yang digunakan untuk memulai proses pelatihan.

Setelah pelatihan *model* selesai, sistem akan menampilkan hasil pelatihan dalam bentuk tabel dan grafik yang dapat digunakan untuk melihat hasil kinerja *model* selama proses pelatihan. Rancangan halaman hasil pelatihan dapat dilihat pada Gambar 3.8.



Gambar 3. 8 Rancangan Halaman Hasil Pelatihan

Keterangan:

- Label 1** menunjukkan tabel hasil pelatihan *model*.
- Label 2** menunjukkan grafik hasil pelatihan *model*.

3.3.3 Rancangan Halaman Pengujian

Halaman pengujian merupakan halaman yang akan digunakan oleh pengguna untuk melakukan uji coba terhadap *model* yang telah dilatih. Halaman ini menyediakan fasilitas kepada pengguna untuk memilih rentang waktu prediksi, mengunggah *dataset* dengan format .csv yang akan digunakan dalam proses pengujian, dan tombol ‘Test’

yang akan digunakan untuk memulai pengujian *model*. Rancangan halaman pengujian dapat dilihat pada Gambar 3.9.

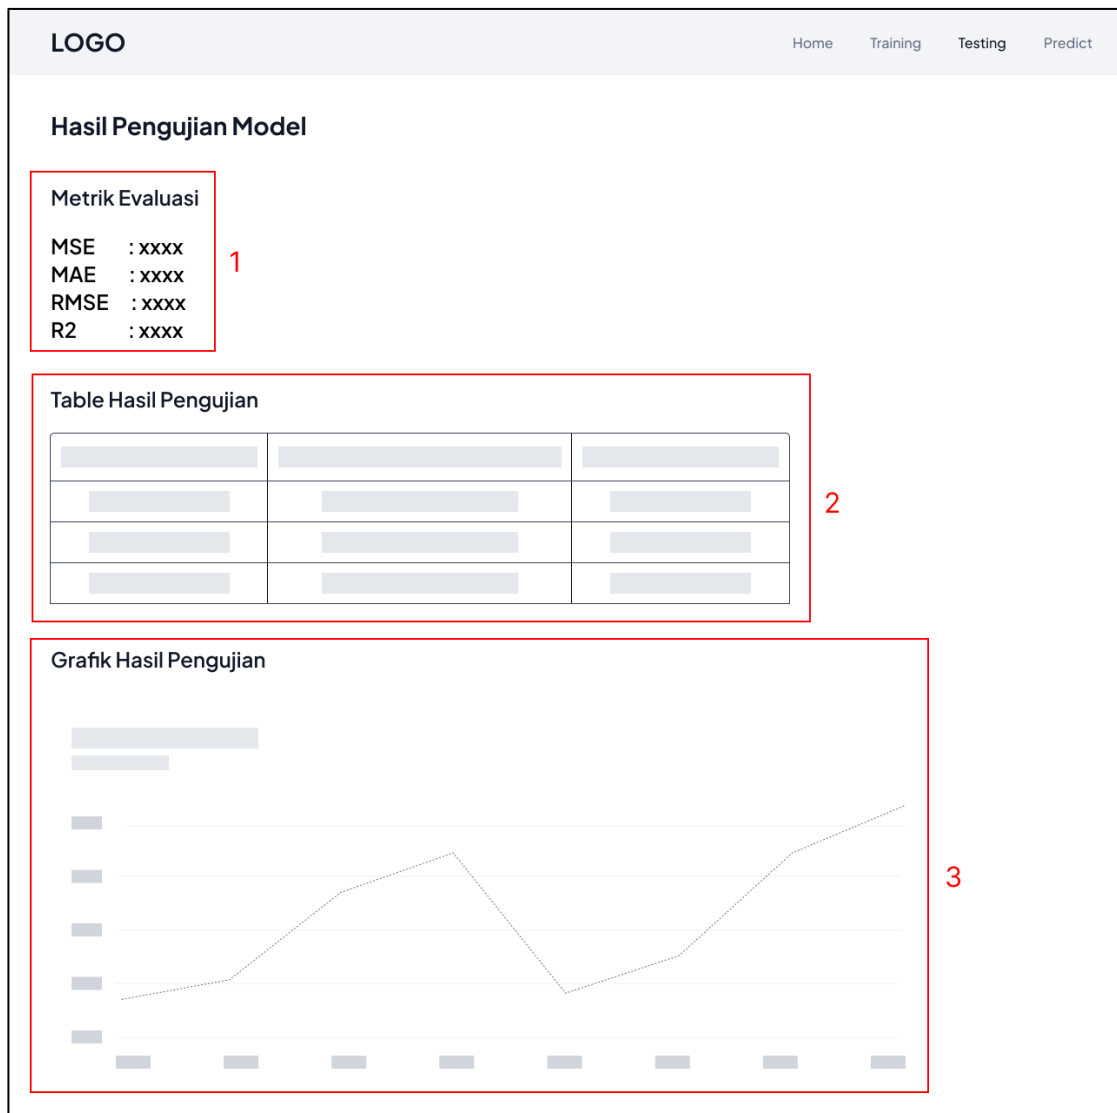
The image shows a web interface for the 'Testing' section. At the top, there is a navigation bar with 'LOGO' on the left and 'Home', 'Training', 'Testing', and 'Predict' on the right. Below the navigation bar, the title 'Testing' is displayed. The main content area includes a section for 'Jangka waktu prediksi:' with five buttons: '7 Hari', '30 Hari', '60 Hari', '90 Hari', and '120 Hari'. This section is highlighted with a red box and labeled '1'. Below this is a section for 'Upload Data Testing (.csv):' which contains a large dashed box for file upload. Inside this box is a folder icon with an upward arrow and the text 'Browse file to upload'. This area is highlighted with a red box and labeled '2'. At the bottom of the form is a 'Test' button, which is highlighted with a red box and labeled '3'.

Gambar 3. 9 Rancangan Halaman Pengujian

Keterangan:

- Label 1** menunjukkan rentang waktu prediksi yang dapat dipilih pengguna.
- Label 2** menunjukkan *input* atau wadah untuk mengunggah *dataset* pengujian.
- Label 3** menunjukkan tombol yang digunakan untuk memulai proses pengujian.

Setelah pengujian *model* selesai, sistem akan menampilkan hasil pengujian dalam bentuk tabel dan grafik yang menampilkan perbandingan antara nilai radiasi matahari pada data aktual dengan data hasil prediksi. Selain itu, terdapat metrik evaluasi yang menunjukkan seberapa baik *model* dalam memprediksi besaran radiasi matahari. Rancangan halaman hasil pengujian dapat dilihat pada Gambar 3.10.



Gambar 3. 10 Rancangan Halaman Hasil Pengujian

Keterangan:

- Label 1** menunjukkan nilai metrik evaluasi dari hasil pengujian *model*.
- Label 2** menunjukkan tabel hasil pengujian *model*.
- Label 3** menunjukkan grafik hasil pengujian *model*.

3.3.4 Rancangan Halaman Prediksi

Halaman prediksi merupakan halaman yang akan digunakan untuk memprediksi radiasi matahari menggunakan model yang telah dilatih dan diuji. Halaman ini menyediakan fasilitas kepada pengguna untuk memilih rentang waktu prediksi, mengunggah *dataset* dengan format .csv yang akan digunakan dalam proses prediksi, dan tombol 'Predict'

yang akan digunakan untuk memulai proses prediksi. Rancangan halaman prediksi dapat dilihat pada Gambar 3.11.

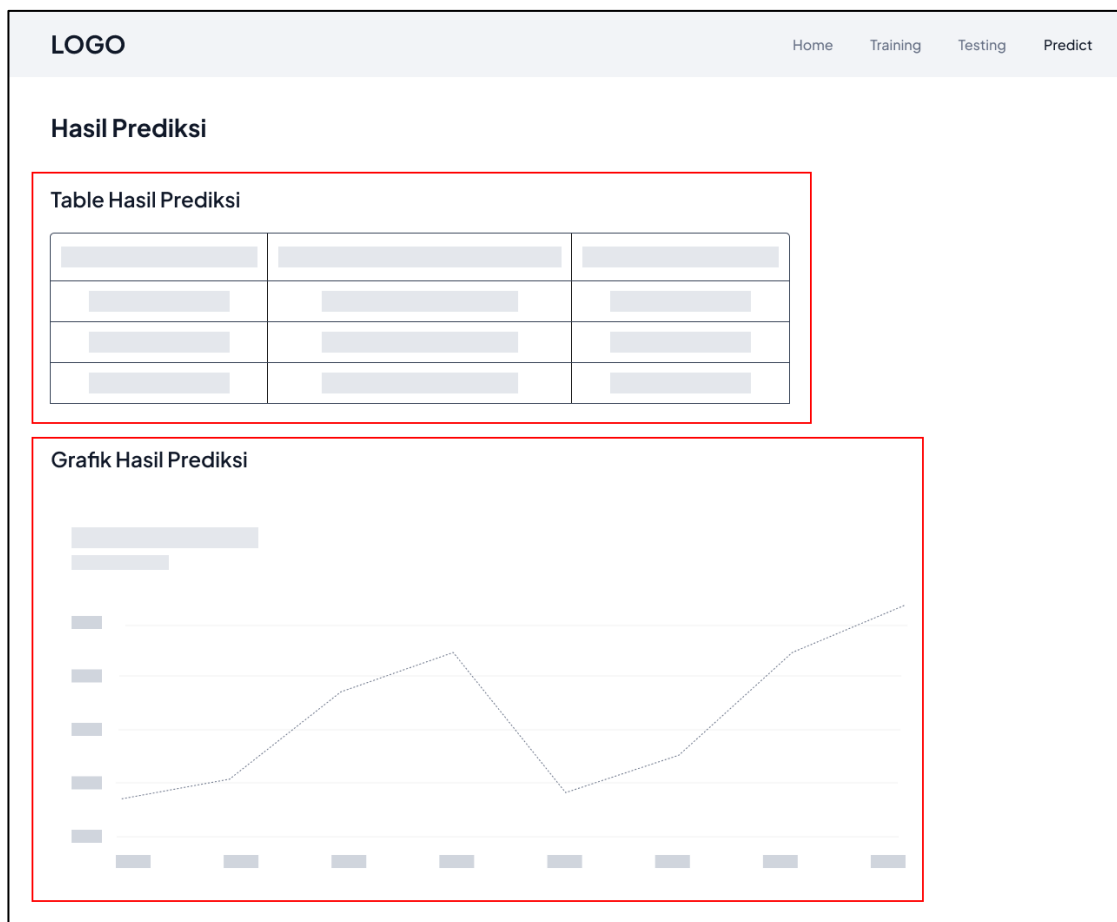
The image shows a web interface for a prediction system. At the top, there is a navigation bar with a 'LOGO' on the left and links for 'Home', 'Training', 'Testing', and 'Predict' on the right. Below the navigation bar, the main heading is 'Prediction'. Under this heading, there is a section for 'Jangka waktu prediksi:' (Prediction time range) with five buttons: '7 Hari', '30 Hari', '60 Hari', '90 Hari', and '120 Hari'. A red box labeled '1' highlights these buttons. Below this, there is a section for 'Upload Data Predict (.csv):' with a large dashed rectangular area for file upload. Inside this area, there is a folder icon with an upward arrow and the text 'Browse file to upload'. A red box labeled '2' highlights the entire upload area. At the bottom of the form, there is a 'Predict' button, which is highlighted by a red box labeled '3'.

Gambar 3. 11 Rancangan Halaman Prediksi

Keterangan:

- Label 1** menunjukkan rentang waktu prediksi yang dapat dipilih pengguna.
- Label 2** menunjukkan *input* atau wadah untuk mengunggah *dataset* prediksi.
- Label 3** menunjukkan tombol yang digunakan untuk memulai proses prediksi.

Setelah proses prediksi selesai, sistem akan menampilkan nilai radiasi matahari berdasarkan hasil prediksi dalam bentuk tabel dan grafik. Rancangan halaman hasil prediksi dapat dilihat pada Gambar 3.12.



Gambar 3. 12 Rancangan Halaman Hasil Prediksi

Keterangan:

- Label 1** menunjukkan tabel hasil prediksi *model*.
- Label 2** menunjukkan grafik hasil prediksi *model*.

BAB 4

IMPLEMENTASI DAN PENGUJIAN SISTEM

4.1 Implementasi Sistem

Pada tahap ini, metode *Deep Autoregressive* (DeepAR) diterapkan untuk memprediksi radiasi matahari. Selain itu, integrasi sistem dengan antarmuka pengguna dilakukan agar sistem dapat diakses oleh pengguna. Bagian ini akan menjelaskan mengenai perangkat yang digunakan, implementasi antarmuka sistem, serta proses pelatihan dan pengujian *model*.

4.1.1 Spesifikasi Perangkat Keras dan Perangkat Lunak

Adapun spesifikasi perangkat keras yang digunakan dalam implementasi sistem diuraikan sebagai berikut:

1. Laptop Lenovo Yoga C640-13IML
2. Prosesor Intel (R) Core (TM) i5-10210U @ 1.60 GHz (8 CPU), ~ 2.1 GHz
3. *Solid State Drive* (SSD) dengan kapasitas 512 GB
4. *Random Access Memory* (RAM) dengan kapasitas 8 GB

Adapun spesifikasi perangkat lunak yang digunakan dalam implementasi sistem diuraikan sebagai berikut:

1. Sistem Operasi Windows 10 Home Single Language 64-bit
2. Google Colab Pro High-RAM
3. Jupyter Notebook
4. Anaconda
5. Bahasa Pemrograman Python versi 3.10.12 dengan *library* pendukung, seperti Flask versi 2.0.3, MXNet versi 1.8.0, NumPy versi 1.23.1, pandas versi 2.2.2, seaborn versi 0.11.2, GluonTS versi 0.15.1, Matplotlib versi 3.5.3, SciPy versi 1.10.1, dan scikit-learn versi 1.5.1.

4.1.2 Implementasi Antarmuka Sistem

Bagian ini akan menjelaskan implementasi tampilan antarmuka sistem prediksi radiasi matahari berdasarkan rancangan antarmuka sistem yang telah dijelaskan pada bab sebelumnya.

4.1.2.1 Tampilan Halaman Beranda

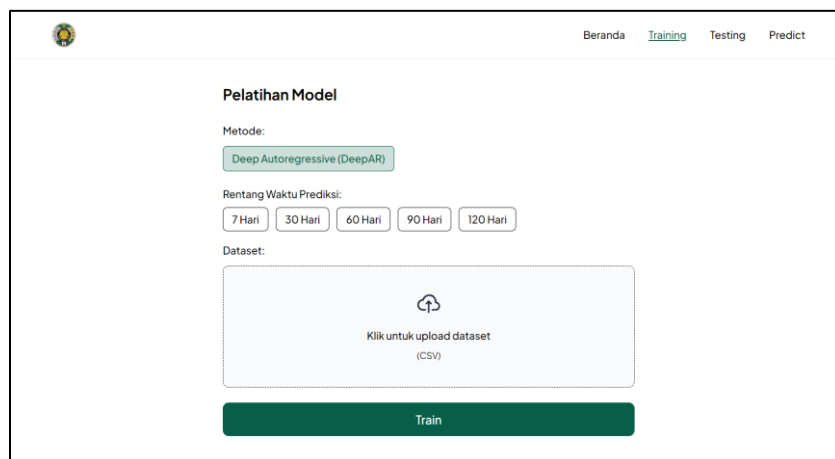
Halaman beranda merupakan halaman awal yang ditampilkan ketika pengguna mengakses *website*. Halaman ini menampilkan informasi mengenai logo universitas, judul penelitian, dan identitas penulis. Selain itu, terdapat *link* yang akan mengarahkan pengguna ke halaman yang dituju. Tampilan halaman beranda dapat dilihat pada Gambar 4.1.



Gambar 4. 1 Tampilan Halaman Beranda

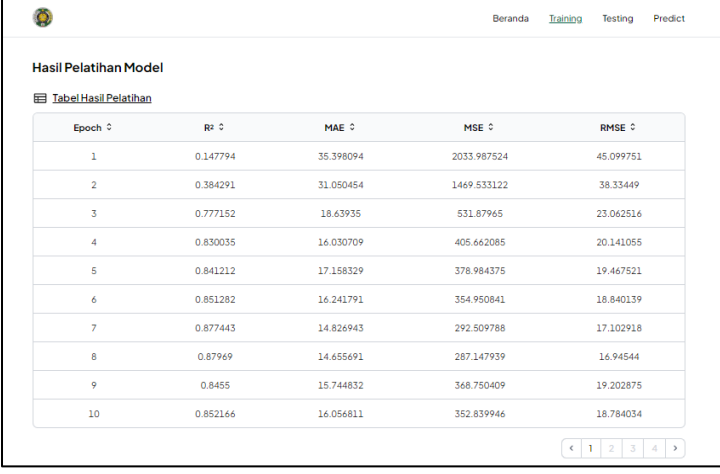
4.1.2.2 Tampilan Halaman Pelatihan

Halaman pelatihan merupakan halaman yang digunakan oleh pengguna untuk melatih *model*. Pada halaman ini, pengguna memilih rentang waktu prediksi, kemudian mengunggah *dataset* dengan format .csv yang akan digunakan dalam proses pelatihan. Setelah itu, pengguna dapat menekan tombol ‘Train’ untuk memulai pelatihan *model*. Tampilan halaman pelatihan dapat dilihat pada Gambar 4.2



Gambar 4. 2 Tampilan Halaman Pelatihan

Setelah *model* selesai dilatih, sistem akan menampilkan hasil pelatihan dalam bentuk tabel yang berisi informasi mengenai *epoch* dan metrik evaluasi, yaitu MAE, MSE, RMSE, dan R^2 . Tabel ini dapat digunakan untuk melihat pada *epoch* seberapa *model* mencapai performa terbaik. Selain itu, pengguna dapat melihat apakah performa *model* mengalami peningkatan atau penurunan selama proses pelatihan. Tabel hasil pelatihan dapat dilihat pada Gambar 4.3.




Hasil Pelatihan Model

Tabel Hasil Pelatihan

Epoch	R^2	MAE	MSE	RMSE
1	0.147794	35.398094	2033.987524	45.099751
2	0.384291	31.050454	1469.533122	38.33449
3	0.777152	18.63935	531.87965	23.062516
4	0.830035	16.030709	405.662085	20.141055
5	0.841212	17.158329	378.984375	19.467521
6	0.851282	16.241791	354.950841	18.840139
7	0.877443	14.826943	292.509788	17.102918
8	0.87969	14.655691	287.147939	16.94544
9	0.8455	15.744832	368.750409	19.202875
10	0.852166	16.056811	352.839946	18.784034

Gambar 4. 3 Tabel Hasil Pelatihan

Di samping itu, sistem juga menampilkan grafik yang memvisualisasikan pergerakan nilai metrik evaluasi selama proses pelatihan. Grafik ini dapat digunakan untuk melihat lebih jelas terkait peningkatan dan penurunan *error* yang dialami *model* selama proses pelatihan. Grafik hasil pelatihan dapat dilihat pada Gambar 4.4.



Gambar 4. 4 Grafik Hasil Pelatihan

4.1.2.3 Tampilan Halaman Pengujian

Halaman pengujian merupakan halaman yang digunakan oleh pengguna untuk menguji coba *model* yang telah dilatih. Pada halaman ini, pengguna memilih rentang waktu prediksi, kemudian mengunggah *dataset* dengan format .csv yang akan digunakan dalam proses pengujian. Setelah itu, pengguna dapat menekan tombol ‘Test’ untuk memulai pengujian *model*. Tampilan halaman pengujian dapat dilihat pada Gambar 4.5.

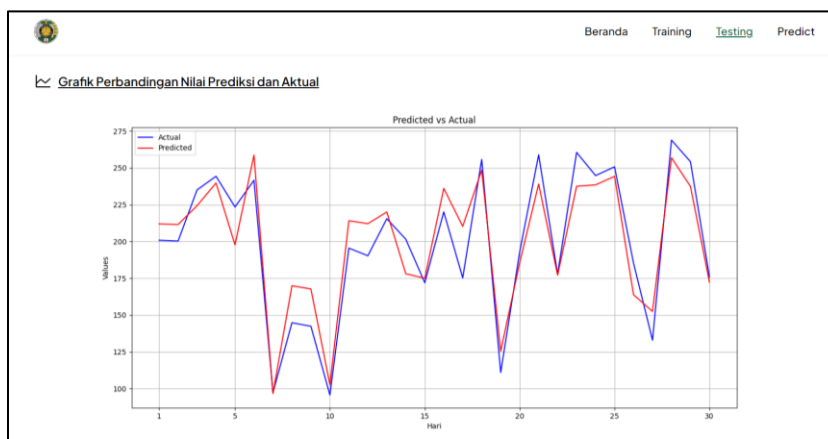
Gambar 4. 5 Tampilan Halaman Pengujian

Setelah pengujian *model* selesai, sistem akan menampilkan hasil pengujian berupa metrik evaluasi, yaitu MAE, MSE, RMSE, dan R^2 . Berdasarkan metrik tersebut, pengguna dapat menilai seberapa baik *model* dalam memprediksi besaran radiasi matahari. Selain itu, terdapat tabel yang menampilkan perbandingan antara nilai radiasi matahari dari hasil prediksi dengan nilai aktual. Tabel hasil pengujian dapat dilihat pada Gambar 4.6.

Hari	Prediksi	Aktual
1	211.940292	200.82507
2	211.500687	200.261648
3	224.312271	235.035944
4	239.737442	244.284388

Gambar 4. 6 Tabel Hasil Pengujian

Di samping itu, sistem juga menampilkan grafik yang memvisualisasikan perbandingan antara nilai radiasi matahari dari hasil prediksi dengan nilai aktual. Grafik ini dapat digunakan untuk melihat apakah *model* mampu memprediksi arah kenaikan atau penurunan nilai radiasi matahari di setiap harinya. Selain itu, grafik tersebut dapat membantu pengguna untuk mengevaluasi sejauh mana hasil prediksi *model* mendekati nilai aktual. Grafik hasil pengujian dapat dilihat pada Gambar 4.7.



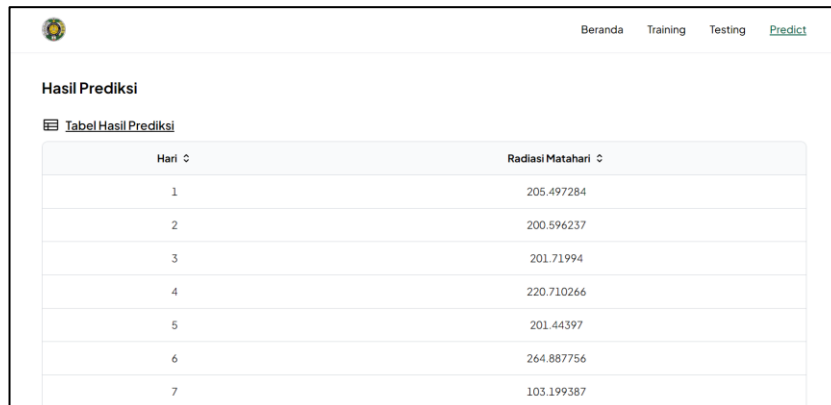
Gambar 4. 7 Grafik Hasil Pengujian

4.1.2.4 Tampilan Halaman Prediksi

Halaman prediksi merupakan halaman yang digunakan oleh pengguna untuk memprediksi radiasi matahari menggunakan *model* yang telah dilatih dan diuji. Pada halaman ini, pengguna memilih rentang waktu prediksi, kemudian mengunggah *dataset* dengan format .csv yang akan digunakan dalam proses prediksi. Setelah itu, pengguna dapat menekan tombol 'Predict' untuk memulai proses prediksi. Tampilan halaman prediksi dapat dilihat pada Gambar 4.8.

Gambar 4. 8 Tampilan Halaman Prediksi

Setelah proses prediksi selesai, sistem akan menampilkan hasil prediksi dalam bentuk tabel yang akan menampilkan nilai radiasi matahari yang diprediksi oleh *model*. Dari tabel tersebut, pengguna dapat melihat pada hari seberapa radiasi matahari mencapai nilai tertinggi dan terendah. Tabel hasil prediksi dapat dilihat pada Gambar 4.9.

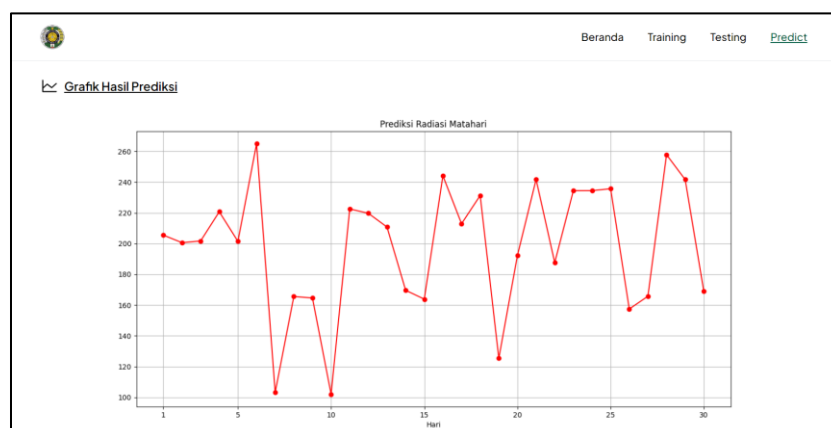


The screenshot shows a web interface with a navigation bar at the top containing 'Beranda', 'Training', 'Testing', and 'Predict'. The 'Predict' tab is active. Below the navigation bar, the title 'Hasil Prediksi' is displayed. Underneath, there is a toggle switch for 'Tabel Hasil Prediksi', which is currently turned on. The table below shows the predicted solar radiation values for 7 days.

Hari	Radiasi Matahari
1	205.497284
2	200.596237
3	201.71994
4	220.710266
5	201.44397
6	264.887756
7	103.199387

Gambar 4. 9 Tabel Hasil Prediksi

Di samping itu, sistem juga menampilkan grafik yang memvisualisasikan besaran radiasi matahari untuk rentang waktu prediksi yang telah dipilih. Grafik ini dapat digunakan untuk mengetahui pola radiasi matahari serta melihat peningkatan dan penurunan radiasi matahari pada hari-hari tertentu. Grafik hasil prediksi dapat dilihat pada Gambar Gambar 4.10.



Gambar 4. 10 Grafik Hasil Prediksi

4.2 Pelatihan Model

Untuk menemukan parameter yang optimal selama pelatihan *model*, penulis melakukan eskplorasi dan *hyperparameter tuning* dengan mengombinasikan berbagai parameter yang terdapat pada Tabel 3.3. Setelah *hyperparameter tuning* selesai, kinerja *model* selama pelatihan dievaluasi menggunakan metrik R^2 , MAE, MSE, dan RMSE. Berdasarkan keempat metrik evaluasi, ditemukan kombinasi parameter dengan kinerja dan performa terbaik untuk setiap rentang waktu prediksi. Tabel 4.1 menunjukkan hasil pelatihan *model* pada rentang waktu prediksi 7 hari.

Tabel 4. 1 Hasil Pelatihan Model Pada Rentang Waktu Prediksi 7 Hari

No	Num Layers	Num Cells	Batch Size	R^2	MAE	MSE	RMSE
1	1	30	16	0.906554	10.696021	209.929844	14.488956
2	1	30	32	0.956891	8.20003	96.846075	9.841040
3	1	40	16	0.916462	9.913087	187.670918	13.699304
4	1	40	32	0.949224	8.268083	114.069247	10.680321
5	1	50	32	0.941601	9.17191	131.195702	11.454069
6	2	30	32	0.906806	12.090712	209.364352	14.469428
7	2	40	32	0.91335	10.865257	194.663038	13.952170
8	3	30	32	0.907099	12.234299	208.705739	14.446651
9	3	40	32	0.914844	10.603562	191.305477	13.831322
10	3	50	32	0.917345	10.000219	185.68624	13.626674

Berdasarkan Tabel 4.1, dapat dilihat bahwa ekplorasi ke-2 memberikan hasil terbaik dengan kombinasi parameter *num_layers* 1, *num_cells* 30, dan *batch_size* 32. Kombinasi parameter tersebut memiliki kinerja yang optimal dengan nilai R^2 , MAE, MSE, dan RMSE sebesar 0.956891, 8.20003, 96.846075, dan 9.841040.

Tabel 4. 2 Hasil Pelatihan Model Pada Rentang Waktu Prediksi 30 Hari

No	Num Layers	Num Cells	Batch Size	R^2	MAE	MSE	RMSE
1	1	30	16	0.888765	13.804974	265.488719	16.293825
2	1	40	16	0.884898	13.649586	274.718108	16.574622

No	Num Layers	Num Cells	Batch Size	R ²	MAE	MSE	RMSE
3	1	50	16	0.875892	13.712318	296.212086	17.210813
4	1	50	32	0.8895	13.199789	263.733585	16.239876
5	2	30	16	0.86384	14.286094	324.977012	18.027119
6	2	40	32	0.871162	15.003565	307.502316	17.535744
7	2	50	16	0.886269	12.491139	271.446086	16.475621
8	3	30	16	0.885587	13.27675	273.072423	16.524903
9	3	40	16	0.894023	13.041774	252.939147	15.904061
10	3	40	32	0.876137	14.625439	295.628997	17.193865

Berdasarkan hasil pelatihan *model* dengan rentang waktu prediksi 30 hari yang ditunjukkan pada Tabel 4.2, terjadi penurunan kinerja *model* berdasarkan nilai keempat metrik evaluasi. Sementara itu, hasil terbaik ditemukan pada eksplorasi ke-9 dengan kombinasi parameter *num_layers* 3, *num_cells* 40, dan *batch_size* 16. Kombinasi parameter tersebut memiliki kinerja yang optimal dengan nilai R², MAE, MSE, dan RMSE sebesar 0.894023, 13.041774, 252.939147, dan 15.904061.

Tabel 4. 3 Hasil Pelatihan *Model* Pada Rentang Waktu Prediksi 60 Hari

No	Num Layers	Num Cells	Batch Size	R ²	MAE	MSE	RMSE
1	1	30	16	0.729378	20.255747	656.465821	25.621589
2	1	30	32	0.732666	20.37699	648.49148	25.465496
3	1	50	16	0.775309	18.053349	545.048751	23.346279
4	1	50	32	0.728831	20.511976	657.793319	25.647482
5	2	30	16	0.75566	19.286838	592.713774	24.345714
6	2	40	16	0.7608	19.328431	580.245392	24.088283
7	2	40	32	0.741423	20.117261	627.248908	25.044938
8	3	30	16	0.744539	19.557216	619.688597	24.893545
9	3	40	16	0.75186	19.673432	601.931579	24.534294
10	3	50	16	0.734411	19.961341	644.258151	25.382241

Berdasarkan hasil pelatihan *model* dengan rentang waktu prediksi 60 hari yang ditunjukkan pada Tabel 4.3, penurunan kinerja *model* kembali terjadi. Sementara itu, hasil terbaik ditemukan pada eksplorasi ke-3 dengan kombinasi parameter *num_layers* 1, *num_cells* 50, dan *batch_size* 16. Kombinasi parameter tersebut memiliki kinerja yang optimal dengan nilai R^2 , MAE, MSE, dan RMSE sebesar 0.775309, 18.053349, 545.048751, dan 23.346279.

Tabel 4. 4 Hasil Pelatihan *Model* Pada Rentang Waktu Prediksi 90 Hari

No	Num Layers	Num Cells	Batch Size	R^2	MAE	MSE	RMSE
1	1	30	16	0.671756	21.240816	672.863178	25.939606
2	1	30	64	0.696234	20.557808	622.685317	24.953663
3	1	40	32	0.652243	21.712842	712.861715	26.69947
4	1	50	16	0.668254	21.174397	680.041505	26.077605
5	1	50	64	0.673166	21.364923	669.97359	25.883848
6	2	40	16	0.666498	21.459829	683.642267	26.146554
7	2	40	64	0.669432	21.294333	677.626357	26.031257
8	2	50	64	0.668977	22.080626	678.559576	26.049176
9	3	40	32	0.68098	21.396109	653.954262	25.572529
10	3	50	32	0.686813	20.849491	641.997782	25.337675

Berdasarkan hasil pelatihan *model* dengan rentang waktu prediksi 90 hari yang ditunjukkan pada Tabel 4.4, penurunan kinerja *model* kembali terjadi meskipun perbedaan nilai metrik evaluasinya cukup kecil apabila dibandingkan dengan metrik evaluasi pada hasil pelatihan *model* dengan rentang waktu prediksi 30 dan 60 hari. Sementara itu, hasil terbaik ditemukan pada eksplorasi ke-2 dengan kombinasi parameter *num_layers* 1, *num_cells* 30, dan *batch_size* 64. Kombinasi parameter tersebut memiliki kinerja yang optimal dengan nilai R^2 , MAE, MSE, dan RMSE sebesar 0.696234, 20.557808, 622.685317, dan 24.953663.

Tabel 4. 5 Hasil Pelatihan *Model* Pada Rentang Waktu Prediksi 120 Hari

No	Num Layers	Num Cells	Batch Size	R ²	MAE	MSE	RMSE
1	1	30	16	0.697017	20.985506	667.73038	25.840479
2	1	30	64	0.688482	20.66651	686.540456	26.201917
3	1	40	16	0.696919	21.217937	667.945188	25.844636
4	1	40	32	0.698487	20.829634	664.491362	25.77773
5	1	50	64	0.697662	21.299903	666.309344	25.812969
6	2	30	16	0.688285	21.428709	686.973436	26.210178
7	2	30	64	0.690198	21.2294	682.758559	26.129649
8	2	40	16	0.690247	21.704271	682.651117	26.127593
9	3	40	32	0.691721	21.070469	679.40049	26.065312
10	3	50	32	0.689316	21.225886	684.701354	26.166799

Berdasarkan hasil pelatihan *model* dengan rentang waktu prediksi 120 hari yang ditunjukkan pada Tabel 4.5, penurunan kinerja *model* kembali terjadi. Meskipun begitu, *model* dapat mempertahankan nilai keempat metrik evaluasi dengan perbedaan yang cukup kecil. Sementara itu, hasil terbaik ditemukan pada eksplorasi ke-4 dengan kombinasi parameter *num_layers* 1, *num_cells* 40, dan *batch_size* 32. Kombinasi parameter tersebut memiliki kinerja yang optimal dengan nilai R², MAE, MSE, dan RMSE sebesar 0.698487, 20.829634, 664.491362, dan 25.77773.

Berdasarkan hasil pelatihan *model* pada setiap rentang waktu prediksi, dapat dilihat bahwa kinerja *model* mengalami penurunan seiring bertambahnya rentang waktu prediksi. Hal ini dikarenakan rentang waktu yang semakin panjang menyebabkan pola pada data yang dipelajari *model* akan menjadi lebih kompleks.


4.3 Pengujian *Model*

Setelah pelatihan *model* selesai dilakukan, *model* terbaik yang sudah dilatih akan diuji untuk menilai kemampuan *model* dalam memprediksi radiasi matahari. Pengujian dilakukan dengan membandingkan hasil prediksi dengan data aktual, kemudian kinerja *model* akan dinilai menggunakan empat metrik evaluasi, yaitu R², MAE, MSE, dan RMSE. Nilai MAE, MSE, dan RMSE yang rendah menunjukkan bahwa *model* memiliki performa yang baik dalam melakukan prediksi. Di sisi lain, nilai R² yang

tinggi dan mendekati angka satu menunjukkan bahwa *model* memiliki performa yang baik dalam melakukan prediksi.

Tabel 4. 6 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 7 Hari

Hari	Prediksi	Aktual	$ y_i - \hat{y}_i $
1	240.300735	244.761072	4.460337
2	248.040710	250.711543	2.670833
3	167.018615	185.292556	18.273941
4	148.640914	132.953856	15.687058
5	274.578735	268.859801	5.718934
6	248.012512	254.182541	6.170029
7	174.105468	175.974468	1.869000




Gambar 4. 11 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 7 Hari

Berdasarkan hasil pengujian *model* dengan rentang waktu prediksi 7 hari yang ditunjukkan pada Tabel 4.6, dapat dilihat bahwa *model* DeepAR mampu memprediksi radiasi matahari dengan cukup baik. Nilai yang diprediksi oleh *model* cukup mendekati nilai aktual dengan perbedaan yang tidak terlalu signifikan meskipun pada hari ke-3 dan ke-4 terdapat perbedaan nilai yang cukup besar. Selain itu, *model* mampu memprediksi arah kenaikan dan penurunan radiasi matahari sebagaimana yang ditunjukkan pada Gambar 4.11.

Tabel 4. 7 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 30 Hari

Hari	Prediksi	Aktual	$y_i - \hat{y}_i$
1	212.329040	200.825070	11.503970
2	210.126449	200.261647	9.864802
3	225.101257	235.035944	9.934687
4	238.560638	244.284388	5.723750
5	197.362701	223.444381	26.081680
6	257.883148	241.617318	16.265830
7	97.065582	97.306956	0.241374
8	165.339660	144.807525	20.532135
9	164.392425	142.423031	21.969394
10	98.850158	95.757057	3.093101
11	208.017456	195.492665	12.524791
12	204.932251	190.308707	14.623544
13	213.856033	215.470096	1.614063
14	179.064529	201.529517	22.464988
15	168.812698	171.996792	3.184094
16	235.143264	220.120844	15.022420
17	212.506332	175.261969	37.244363
18	253.262344	255.746913	2.484569
19	126.253913	111.015020	15.238893
20	186.674392	192.862586	6.188194
21	238.640777	258.912834	20.272057
22	178.197357	177.848179	0.349178
23	240.106796	260.498482	20.391686
24	235.731872	244.761072	9.029200
25	244.032486	250.711543	6.679057
26	156.750854	185.292556	28.541702
27	151.161254	132.953856	18.207398
28	257.176147	268.859801	11.683654
29	233.904998	254.182541	20.277543
30	171.261932	175.974468	4.712536



Gambar 4. 12 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 30 Hari


Berdasarkan hasil pengujian *model* dengan rentang waktu prediksi 30 hari yang ditunjukkan pada Tabel 4.7 dan Gambar 4.12, terdapat perbedaan nilai yang cukup signifikan di beberapa hari dengan perbedaan tertinggi terjadi pada hari ke-17 sebesar 37.244363. Meskipun begitu, *model* masih mampu memprediksi arah kenaikan dan penurunan radiasi matahari walaupun terdapat beberapa hari di mana arah yang diprediksi lebih tinggi atau lebih rendah daripada yang seharusnya, seperti hari ke-5, ke-6, ke-8, ke-9, ke-14, ke-17, ke-21, ke-23, ke-26, dan ke-29.

Tabel 4. 8 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 60 Hari

Hari	Prediksi	Aktual	$ y_i - \hat{y}_i $
1	161.873413	175.204795	13.331382
2	177.488235	160.981293	16.506942
3	268.245758	225.077040	43.168718
4	223.455474	215.905829	7.549645
5	142.669830	134.469080	8.200750
6	266.570556	261.914701	4.655855
7	129.497177	103.680056	25.817121
8	231.689254	212.987430	18.701824
9	195.850494	178.277115	17.573379
10	210.497299	239.091415	28.594116
11	175.995269	205.912290	29.917021
12	175.939147	241.343954	65.404807

Hari	Prediksi	Aktual	$ y_i - \hat{y}_i $
13	200.049682	225.245137	25.195455
14	185.180969	242.986008	57.805039
15	208.691528	235.787826	27.096298
16	193.401992	181.119747	12.282245
17	151.392349	159.212809	7.820460
18	122.452873	120.250286	2.202587
19	96.665901	95.645677	1.020224
20	179.489608	210.072727	30.583119
21	279.099060	262.755890	16.343170
22	246.468460	280.003561	33.535101
23	135.742279	112.620956	23.121323
24	254.191192	183.718630	70.472562
25	248.222869	275.900136	27.677267
26	223.991836	201.195700	22.796136
27	181.935821	186.280443	4.344622
28	167.513824	149.958392	17.555432
29	180.449691	184.960404	4.510713
30	168.447967	193.754716	25.306749
31	219.919418	200.825070	19.094348
32	223.453247	200.261647	23.191600
33	242.781097	235.035944	7.745153
34	254.791656	244.284388	10.507268
35	191.929748	223.444381	31.514633
36	242.849426	241.617318	1.232108
37	95.672874	97.306956	1.634082
38	160.996215	144.807525	16.188690
39	164.357605	142.423031	21.934574
40	91.639373	95.757057	4.117684
41	215.098815	195.492665	19.606150
42	204.235366	190.308707	13.926659
43	221.032241	215.470096	5.562145
44	187.053146	201.529517	14.476371

Hari	Prediksi	Aktual	$ y_i - \hat{y}_i $
45	165.657867	171.996792	6.338925
46	214.671463	220.120844	5.449381
47	216.348297	175.261969	41.086328
48	242.346694	255.746913	13.400219
49	129.381668	111.015020	18.366648
50	182.488952	192.862586	10.373634
51	242.562896	258.912834	16.349938
52	179.877304	177.848179	2.029125
53	236.948669	260.498482	23.549813
54	238.160110	244.761072	6.600962
55	247.073165	250.711543	3.638378
56	164.695953	185.292556	20.596603
57	157.661880	132.953856	24.708024
58	264.916687	268.859801	3.943114
59	252.097045	254.182541	2.085496
60	171.786117	175.974468	4.188351



Gambar 4. 13 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 60 Hari


Berdasarkan hasil pengujian *model* dengan rentang waktu prediksi 60 hari yang ditunjukkan pada Tabel 4.8 dan Gambar 4.13, terdapat perbedaan nilai yang cukup signifikan di beberapa hari dengan perbedaan tertinggi terjadi pada hari ke-24 sebesar 70.472562. Selain itu, terdapat kesalahan *model* dalam memprediksi arah perubahan radiasi matahari pada hari ke-2, ke-32, ke-47, dan ke-54, di mana *model* memprediksi peningkatan nilai radiasi matahari yang seharusnya mengalami penurunan. Sebaliknya, pada hari ke-12, ke-14, ke-22, ke-25, dan ke-30, *model* memprediksi penurunan nilai radiasi matahari yang seharusnya mengalami peningkatan.

Tabel 4. 9 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 90 Hari

Hari	Prediksi	Aktual	$y_i - \hat{y}_i$
1	179.869140	159.087482	20.781658
2	211.649276	191.793444	19.855832
3	224.055130	256.818922	32.763792
4	200.294220	216.404936	16.110716
5	205.925170	222.276797	16.351627
6	110.046806	130.459071	20.412265
7	239.914856	231.011397	8.903459
8	209.518356	161.348689	48.169667
9	186.151916	213.714804	27.562888
10	222.759231	240.503586	17.744355
11	132.703872	149.865642	17.161770
12	192.561401	222.585948	30.024547
13	201.748840	186.472752	15.276088
14	217.522766	207.795277	9.727489
15	157.043640	157.183795	0.140155
16	162.058563	186.580161	24.521598
17	186.092636	218.552896	32.460260
18	186.148101	197.811424	11.663323
19	214.568100	214.831412	0.263312
20	159.616958	175.385899	15.768941
21	197.945541	197.791498	0.154043
22	229.277816	246.928702	17.650886
23	193.108810	202.992876	9.884066
24	163.345932	136.293681	27.052251
25	220.252487	176.072380	44.180107
26	291.953582	250.575240	41.378342
27	240.195037	248.993188	8.798151
28	206.806243	247.712907	40.906664
29	146.599899	167.338276	20.738377
30	183.284317	150.428511	32.855806
31	147.828491	175.204795	27.376304

Hari	Prediksi	Aktual	$ y_i - \hat{y}_i $
32	178.015899	160.981293	17.034606
33	266.487121	225.077040	41.410081
34	225.602462	215.905829	9.696633
35	137.054260	134.469080	2.585180
36	253.968536	261.914701	7.946165
37	144.675231	103.680056	40.995175
38	243.120620	212.987430	30.133190
39	186.404602	178.277115	8.127487
40	211.212585	239.091415	27.878830
41	181.255996	205.912290	24.656294
42	180.451782	241.343954	60.892172
43	203.400405	225.245137	21.844732
44	192.416595	242.986008	50.569413
45	198.392868	235.787826	37.394958
46	203.663970	181.119747	22.544223
47	160.513977	159.212809	1.301168
48	148.154235	120.250286	27.903949
49	114.673904	95.645677	19.028227
50	197.808303	210.072727	12.264424
51	268.008697	262.755890	5.252807
52	245.008667	280.003561	34.994894
53	144.883194	112.620956	32.262238
54	258.314666	183.718630	74.596036
55	246.484100	275.900136	29.416036
56	223.602600	201.195700	22.406900
57	172.393280	186.280443	13.887163
58	180.057128	149.958392	30.098736
59	178.668792	184.960404	6.291612
60	163.231353	193.754716	30.523363
61	213.785598	200.825070	12.960528
62	222.266693	200.261647	22.005046
63	239.393692	235.035944	4.357748

Hari	Prediksi	Aktual	$y_i - \hat{y}_i$
64	239.865570	244.284388	4.418818
65	190.589904	223.444381	32.854477
66	250.753341	241.617318	9.136023
67	84.331199	97.306956	12.975757
68	167.644348	144.807525	22.836823
69	152.831268	142.423031	10.408237
70	108.331481	95.757057	12.574424
71	223.146957	195.492665	27.654292
72	205.435195	190.308707	15.126488
73	218.633148	215.470096	3.163052
74	174.890319	201.529517	26.639198
75	158.450241	171.996792	13.546551
76	235.827484	220.120844	15.706640
77	224.568924	175.261969	49.306955
78	245.505569	255.746913	10.241344
79	119.812461	111.015020	8.797441
80	188.321334	192.862586	4.541252
81	242.635116	258.912834	16.277718
82	189.292663	177.848179	11.444484
83	252.186874	260.498482	8.311608
84	226.534683	244.761072	18.226389
85	248.717651	250.711543	1.993892
86	162.031021	185.292556	23.261535
87	157.515090	132.953856	24.561234
88	254.267440	268.859801	14.592361
89	228.750534	254.182541	25.432007
90	173.250579	175.974468	2.723889



Gambar 4. 14 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 90 Hari

Berdasarkan hasil pengujian *model* dengan rentang waktu prediksi 90 hari yang ditunjukkan pada Tabel 4.9 dan Gambar 4.14, terdapat perbedaan nilai yang cukup signifikan di beberapa hari dengan perbedaan tertinggi terjadi pada hari ke-54 sebesar 74.596036. Selain itu, terdapat kesalahan *model* dalam memprediksi arah perubahan radiasi matahari pada hari ke-30, ke-32, ke-43, ke-45, ke-46, ke-58, dan ke-62, di mana *model* memprediksi peningkatan nilai radiasi matahari yang seharusnya mengalami penurunan. Sebaliknya, pada hari ke-9, ke-13, ke-18, ke-31, ke-42, ke-44, ke-55, ke-59, dan ke-60, *model* memprediksi penurunan nilai radiasi matahari yang seharusnya mengalami peningkatan.

Tabel 4. 10 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 120 Hari


Hari	Prediksi	Aktual	$ y_i - \hat{y}_i $
1	140.228164	146.294452	6.066288
2	214.027267	181.048913	32.978354
3	238.897415	220.838440	18.058975
4	227.871292	244.628240	16.756948
5	167.607620	206.073569	38.465949
6	224.279876	222.294528	1.985348
7	259.220520	228.404183	30.816337
8	147.600616	101.760952	45.839664
9	239.827301	275.527496	35.700195
10	220.113616	226.103429	5.989813
11	121.021530	98.787774	22.233756
12	184.022537	169.171994	14.850543
13	145.796997	153.342206	7.545209

Hari	Prediksi	Aktual	$ y_i - \hat{y}_i $
14	160.014251	156.859675	3.154576
15	203.018737	203.110109	0.091372
16	199.263534	234.633239	35.369705
17	216.865951	211.106602	5.759349
18	225.806243	271.014035	45.207792
19	234.678512	228.130232	6.548280
20	242.367248	273.077902	30.710654
21	167.517578	178.713617	11.196039
22	145.206558	140.511516	4.695042
23	189.471984	214.108391	24.636407
24	222.936218	264.486311	41.550093
25	204.977005	192.189944	12.787061
26	204.448577	184.343902	20.104675
27	268.353118	280.750135	12.397017
28	264.277099	304.254993	39.977894
29	181.180481	148.422607	32.757874
30	171.410415	198.112359	26.701944
31	182.231735	159.087482	23.144253
32	225.892486	191.793444	34.099042
33	240.824127	256.818922	15.994795
34	200.041427	216.404936	16.363509
35	208.852813	222.276797	13.423984
36	114.398849	130.459071	16.060222
37	234.826187	231.011397	3.814790
38	210.122695	161.348689	48.774006
39	185.362854	213.714804	28.351950
40	211.339508	240.503586	29.164078
41	125.706062	149.865642	24.159580
42	186.405426	222.585948	36.180522
43	192.466430	186.472752	5.993678
44	223.365799	207.795277	15.570522
45	160.636779	157.183795	3.452984

Hari	Prediksi	Aktual	$ y_i - \hat{y}_i $
46	171.983337	186.580161	14.596824
47	178.127792	218.552896	40.425104
48	190.306213	197.811424	7.505211
49	202.821502	214.831412	12.009910
50	155.741439	175.385899	19.644460
51	191.598403	197.791498	6.193095
52	227.361511	246.928702	19.567191
53	196.915802	202.992876	6.077074
54	171.059661	136.293681	34.765980
55	219.021057	176.072380	42.948677
56	300.133178	250.575240	49.557938
57	244.447174	248.993188	4.546014
58	208.864593	247.712907	38.848314
59	170.073791	167.338276	2.735515
60	188.590423	150.428511	38.161912
61	154.736908	175.204795	20.467887
62	175.575729	160.981293	14.594436
63	260.204925	225.077040	35.127885
64	208.022811	215.905829	7.883018
65	137.419601	134.469080	2.950521
66	258.972747	261.914701	2.941954
67	150.180221	103.680056	46.500165
68	251.264862	212.987430	38.277432
69	182.777877	178.277115	4.500762
70	208.468978	239.091415	30.622437
71	168.074127	205.912290	37.838163
72	177.985717	241.343954	63.358237
73	210.386428	225.245137	14.858709
74	194.825561	242.986008	48.160447
75	191.299301	235.787826	44.488525
76	197.168945	181.119747	16.049198
77	154.822876	159.212809	4.389933

Hari	Prediksi	Aktual	$ y_i - \hat{y}_i $
78	127.028183	120.250286	6.777897
79	103.920677	95.645677	8.275000
80	192.989120	210.072727	17.083607
81	263.413696	262.755890	0.657806
82	239.844650	280.003561	40.158911
83	155.420639	112.620956	42.799683
84	263.125885	183.718630	79.407255
85	249.124160	275.900136	26.775976
86	226.295272	201.195700	25.099572
87	169.643783	186.280443	16.636660
88	166.855728	149.958392	16.897336
89	177.872482	184.960404	7.087922
90	158.974121	193.754716	34.780595
91	210.833709	200.825070	10.008639
92	223.944549	200.261647	23.682902
93	220.337417	235.035944	14.698527
94	241.673812	244.284388	2.610576
95	201.878128	223.444381	21.566253
96	258.511566	241.617318	16.894248
97	102.300178	97.306956	4.993222
98	177.500412	144.807525	32.692887
99	148.225448	142.423031	5.802417
100	95.3350067	95.757057	0.422050
101	220.765701	195.492665	25.273036
102	208.314453	190.308707	18.005746
103	218.308395	215.470096	2.838299
104	167.470443	201.529517	34.059074
105	150.228469	171.996792	21.768323
106	223.510803	220.120844	3.389959
107	209.804916	175.261969	34.542947
108	250.953476	255.746913	4.793437
109	135.205261	111.015020	24.190241

Hari	Prediksi	Aktual	$ y_i - \hat{y}_i $
110	188.516265	192.862586	4.346321
111	228.695220	258.912834	30.217614
112	172.431015	177.848179	5.417164
113	240.288986	260.498482	20.209496
114	229.740417	244.761072	15.020655
115	265.331176	250.711543	14.619633
116	168.195373	185.292556	17.097183
117	166.132629	132.953856	33.178773
118	273.097534	268.859801	4.237733
119	241.121002	254.182541	13.061539
120	176.676208	175.974468	0.701740



Gambar 4. 15 Perbandingan Prediksi dan Aktual Pada Rentang Waktu 120 Hari

Berdasarkan hasil pengujian *model* dengan rentang waktu prediksi 90 hari yang ditunjukkan pada Tabel 4.10 dan Gambar 4.15, terdapat perbedaan nilai yang cukup signifikan di beberapa hari dengan perbedaan tertinggi terjadi pada hari ke-72 sebesar 63.358237. Selain itu, terdapat kesalahan *model* dalam memprediksi arah perubahan radiasi matahari pada hari ke-17, ke-19, ke-31, ke-43, ke-48, ke-60, ke-62, ke-73, ke-76, dan ke-92, di mana *model* memprediksi peningkatan nilai radiasi matahari yang seharusnya mengalami penurunan. Sebaliknya, pada hari ke-4, ke-16, ke-28, ke-30, ke-39, ke-61, ke-74, ke-82, ke-85, dan ke-90, *model* memprediksi penurunan nilai radiasi matahari yang seharusnya mengalami peningkatan.

Setelah melakukan perbandingan antara data hasil prediksi dengan data aktual, *model* pada setiap rentang waktu prediksi akan dievaluasi dan dinilai menggunakan empat metrik evaluasi, yakni R^2 , MAE, MSE, dan RMSE. Hasil pengujian *model* pada setiap rentang waktu prediksi ditunjukkan pada Tabel 4.11.

Tabel 4. 11 Hasil Pengujian Model Pada Setiap Rentang Waktu Prediksi

Rentang Waktu	R²	MAE	MSE	RMSE
7 hari	0.956675	7.835733	97.33104	9.86565
30 hari	0.892929	13.198155	255.550221	15.985938
60 hari	0.774698	18.042108	546.529698	23.377975
90 hari	0.693524	20.740574	628.240771	25.064732
120 hari	0.696689	20.823774	668.451923	25.854437

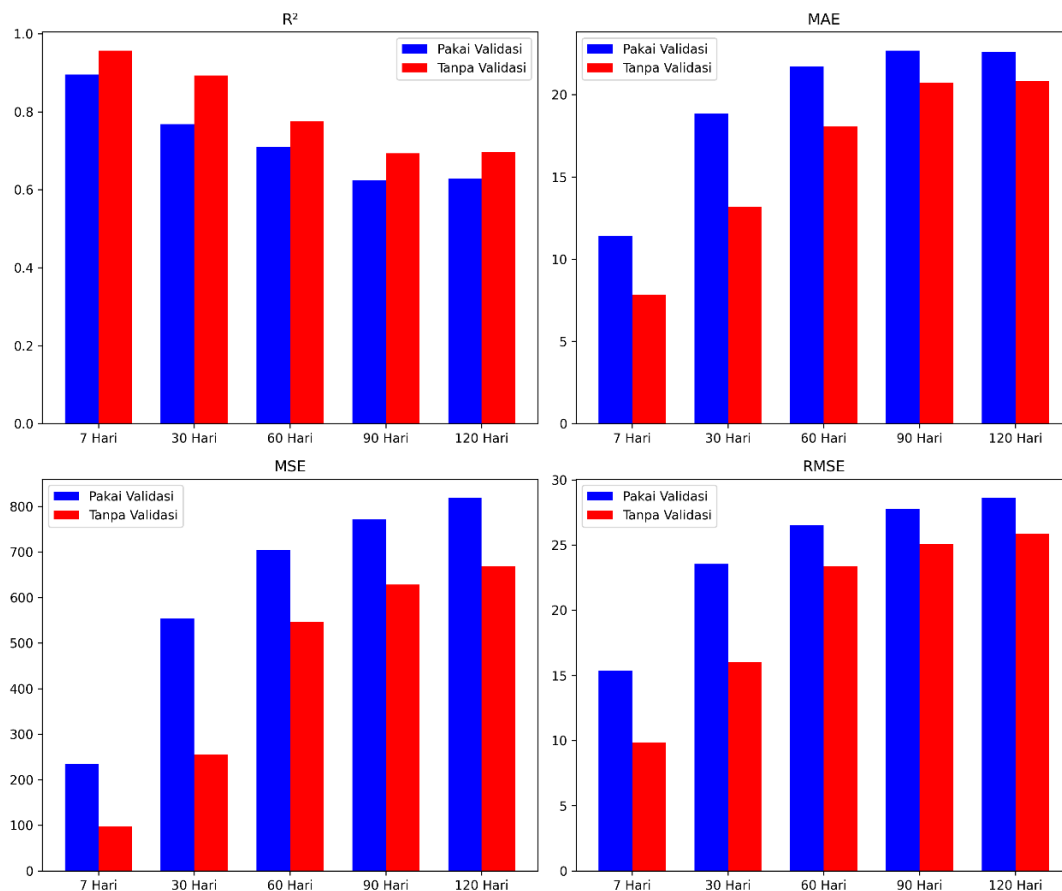
Berdasarkan Tabel 4.11, dapat dilihat bahwa *model* menunjukkan kinerja yang sangat baik pada rentang waktu prediksi 7 hari dengan nilai RMSE sebesar 9.86565. Namun, kinerja *model* semakin menurun seiring dengan bertambahnya rentang waktu prediksi dengan nilai RMSE mencapai 25.854437 pada rentang waktu 120 hari. Penurunan kinerja ini terjadi karena pola dan variasi dalam data menjadi semakin kompleks seiring bertambahnya waktu sehingga *model* lebih rentan terhadap kesalahan dalam melakukan prediksi, terutama dalam memprediksi arah kenaikan dan penurunan nilai radiasi matahari yang berdampak langsung pada nilai metrik evaluasi. Meskipun begitu, *model* masih mampu mempertahankan nilai metrik evaluasi dengan cukup baik dengan perbedaan nilai yang cukup kecil antara rentang waktu 90 hari dan 120 hari.

4.4 Validasi Model

Dalam penelitian ini, penulis tidak menerapkan proses validasi karena hasil evaluasi *model* tanpa menggunakan validasi menunjukkan kinerja yang lebih baik untuk setiap rentang waktu prediksi. Dengan menggunakan kombinasi parameter terbaik untuk masing-masing rentang waktu, hasil evaluasi *model* tanpa validasi secara konsisten menunjukkan kinerja yang lebih unggul. Tabel 4.12 dan Gambar 4.16 menunjukkan perbandingan antara hasil evaluasi *model* menggunakan validasi dengan hasil evaluasi *model* tanpa menggunakan validasi untuk semua rentang waktu prediksi.

Tabel 4. 12 Perbandingan Hasil Evaluasi Model Menggunakan Validasi Dengan Tanpa Validasi Pada Semua Rentang Waktu Prediksi

Waktu	Metode	R ²	MAE	MSE	RMSE
7 Hari	Nonvalidasi	0.956675	7.835733	97.33104	9.86565
	Validasi	0.895376	11.389452	235.040844	15.331042
30 Hari	Nonvalidasi	0.892929	13.198155	255.550221	15.985938
	Validasi	0.767794	18.843255	554.212674	23.541722
60 Hari	Nonvalidasi	0.774698	18.042108	546.529698	23.377975
	Validasi	0.709647	21.702425	704.329083	26.539199
90 Hari	Nonvalidasi	0.693524	20.740574	628.240771	25.064732
	Validasi	0.623675	22.670911	771.423954	27.774520
120 Hari	Nonvalidasi	0.696689	20.823774	668.451923	25.854437
	Validasi	0.628354	22.587808	819.052468	28.619093



Gambar 4. 16 Perbandingan Hasil Evaluasi Model Menggunakan Validasi Dengan Tanpa Validasi Pada Semua Rentang Waktu Prediksi

Berdasarkan Tabel 4.12 dan Gambar 4.16, dapat dilihat bahwa untuk semua rentang waktu prediksi, hasil evaluasi *model* tanpa menggunakan validasi menunjukkan performa yang lebih unggul dibandingkan dengan hasil evaluasi *model* dengan proses validasi. Keunggulan ini dapat dipengaruhi oleh penggunaan metode DeepAR yang dirancang untuk menangani prediksi deret waktu dengan memanfaatkan informasi masa lalu untuk menghasilkan prediksi masa depan yang akurat. Dalam pendekatan tanpa validasi, *model* dapat mempelajari informasi masa lalu dari titik waktu yang lebih jauh sehingga memungkinkan *model* untuk menangkap pola dan hubungan yang lebih kompleks dalam data. Ketika menggunakan validasi, *model* mungkin kehilangan informasi penting yang diperlukan untuk menangkap pola dan variasi dalam data.

Meskipun begitu, perbedaan nilai metrik evaluasi antara penggunaan *model* tanpa validasi dengan *model* yang menggunakan proses validasi tidak terlalu signifikan. Hal ini menunjukkan bahwa *model* dengan proses validasi tetap dapat menghasilkan prediksi yang relevan. Dengan menggunakan validasi, *Model* tidak hanya dapat mengoptimalkan kinerja pada data pelatihan, tetapi juga memastikan bahwa prediksi yang dihasilkan tetap akurat ketika diterapkan pada data baru yang belum pernah dilihat sebelumnya.

4.5 Diskusi

Penelitian ini menerapkan metode *Deep Autoregressive* (DeepAR) untuk memprediksi besaran radiasi sinar matahari. Data yang digunakan pada penelitian ini berasal dari penelitian sebelumnya yang dilakukan oleh (Ambarita, 2017). Data yang diperoleh dari penelitian tersebut terpisah ke dalam beberapa dokumen Excel sehingga diperlukan proses integrasi data untuk menggabungkan seluruh data menjadi satu dokumen utuh dengan kolom yang seragam.

Berdasarkan statistik dan distribusi data yang diperoleh setelah melalui proses integrasi, ditemukan banyak data yang tidak tercatat dan nilainya berkumpul pada angka 0, seperti data kecepatan angin, kecepatan embusan, dan titik embun sehingga data tersebut perlu dihapus karena dapat mempengaruhi kinerja dan akurasi *model* apabila tetap digunakan. Selain itu, data suhu dan kelembapan udara memiliki nilai yang tidak relevan dan sangat tinggi karena tidak sesuai dengan rata-rata suhu dan kelembapan udara normal di Indonesia. Semua data tersebut akan dibersihkan dan disesuaikan dengan kebutuhan penelitian sehingga pada proses pembentukan dan pelatihan *model*,

data yang digunakan memiliki kualitas yang baik. Setelah itu, *correlation heatmap* digunakan untuk melihat hubungan antara fitur dengan variabel target dalam data. Hasil visualisasi menunjukkan korelasi yang cukup relevan dengan nilai 0.79 untuk suhu dan -0.78 untuk kelembapan udara.

Berbagai parameter diterapkan pada *model* DeepAR untuk mendapatkan kombinasi parameter dengan kinerja dan performa yang paling optimal. Untuk rentang waktu 7 hari diperoleh kombinasi parameter terbaik pada *num_layers* 1, *num_cells* 30, dan *batch_size* 32. Untuk 30 hari diperoleh kombinasi parameter terbaik pada *num_layers* 3, *num_cells* 40, dan *batch_size* 16. Untuk 60 hari diperoleh kombinasi parameter terbaik pada *num_layers* 1, *num_cells* 50, dan *batch_size* 16. Untuk 90 hari diperoleh kombinasi parameter terbaik pada *num_layers* 1, *num_cells* 30, dan *batch_size* 64. Untuk 120 hari diperoleh kombinasi parameter terbaik pada *num_layers* 1, *num_cells* 40, dan *batch_size* 32.

Kinerja *model* dievaluasi menggunakan empat metrik, yaitu R^2 , MAE, MSE, dan RMSE. Berdasarkan pengujian *model* dengan menggunakan kombinasi parameter terbaik untuk masing-masing rentang waktu prediksi, hasil terbaik dicapai pada rentang waktu 7 hari dengan nilai R^2 sebesar 0.956675, MAE sebesar 7.835733, MSE sebesar 97.33104, dan RMSE sebesar 9.86565. Berdasarkan hasil pengujian ini, dapat disimpulkan bahwa kinerja model semakin menurun seiring bertambahnya rentang waktu prediksi. Penurunan kinerja ini disebabkan oleh semakin kompleksnya pola dan variasi dalam data sehingga *model* lebih rentan terhadap kesalahan prediksi.

Dalam penelitian ini, penulis tidak menerapkan proses validasi karena hasil evaluasi *model* tanpa validasi menunjukkan kinerja yang lebih baik untuk semua rentang waktu prediksi. Keputusan untuk tidak menggunakan validasi dalam penelitian ini memungkinkan *model* untuk memanfaatkan seluruh data pelatihan yang tersedia sehingga *model* mampu menangkap pola dan variasi data yang lebih kompleks pada titik waktu yang lebih jauh. Meskipun pendekatan ini dapat meningkatkan risiko *overfitting*, hasil pengujian menunjukkan bahwa *model* tanpa validasi memberikan hasil yang lebih baik dengan kesalahan prediksi yang lebih rendah.

BAB 5

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Setelah melakukan serangkaian tahapan penelitian untuk memprediksi radiasi sinar matahari dengan menggunakan metode *Deep Autoregressive* (DeepAR), diperoleh kesimpulan sebagai berikut:

1. Metode DeepAR menunjukkan kinerja yang baik dalam memprediksi radiasi sinar matahari dengan hasil terbaik tercapai pada rentang waktu prediksi 7 hari dengan nilai R^2 sebesar 0.956675, MAE sebesar 7.835733, MSE sebesar 97.33104, dan RMSE sebesar 9.86565.
2. Rentang waktu yang digunakan memiliki pengaruh yang signifikan pada performa *model* dan hasil metrik evaluasi. Hal ini dikarenakan rentang waktu yang semakin panjang menyebabkan pola pada data yang dipelajari *model* akan menjadi lebih kompleks.
3. Variabel suhu dan kelembapan udara memiliki pengaruh yang signifikan terhadap nilai radiasi sinar matahari. Hal ini menunjukkan bahwa peningkatan suhu cenderung diikuti oleh peningkatan radiasi sinar matahari, sedangkan peningkatan kelembapan udara cenderung diikuti oleh penurunan radiasi sinar matahari.
4. Hasil evaluasi *model* tanpa validasi menunjukkan performa yang lebih unggul dibandingkan dengan hasil evaluasi *model* dengan menggunakan validasi untuk semua rentang waktu prediksi.

5.2 Saran

Adapun saran yang dapat dipertimbangkan untuk pengembangan penelitian selanjutnya adalah sebagai berikut:

1. Menggunakan data yang lengkap dan lebih banyak agar *model* dapat menangkap dan mempelajari pola pada data dengan titik waktu yang lebih jauh sehingga dapat membantu meningkatkan akurasi dan meminimalisir *error* untuk setiap rentang waktu prediksi yang digunakan.
2. Menggunakan fitur lainnya yang berkaitan dengan radiasi sinar matahari, seperti musim dan intensitas sinar matahari untuk membantu *model* dalam memahami pola pada data.

3. Menggunakan kombinasi parameter pelatihan yang lebih beragam untuk mendapatkan *model* dengan kinerja yang lebih baik dalam melakukan prediksi radiasi matahari.
4. Mengeksplorasi metode validasi lainnya, seperti *K-Fold Cross-Validation* atau *Time Series Cross-Validation* yang mungkin dapat meningkatkan kinerja *model* dan memberikan hasil prediksi yang lebih baik.

DAFTAR PUSTAKA

- Ağbulut, Ü., Gürel, A. E., & Biçen, Y. (2021). Prediction of daily global solar radiation using different machine learning algorithms: Evaluation and comparison. *Renewable and Sustainable Energy Reviews*, 135(July 2020). <https://doi.org/10.1016/j.rser.2020.110114>
- Alzubaidi, L., Zhang, J., Humaidi, A. J., Al-Dujaili, A., Duan, Y., Al-Shamma, O., Santamaría, J., Fadhel, M. A., Al-Amidie, M., & Farhan, L. (2021). Review of deep learning: concepts, CNN architectures, challenges, applications, future directions. In *Journal of Big Data* (Vol. 8, Issue 1). Springer International Publishing. <https://doi.org/10.1186/s40537-021-00444-8>
- Ambarita, H. (2017). Development of software for estimating clear sky solar radiation in Indonesia. *Journal of Physics: Conference Series*, 755(1). <https://doi.org/10.1088/1742-6596/755/1/011001>
- Arora, N. K., & Mishra, I. (2022). Progress of sustainable development goal 7: clean and green energy for all as the biggest challenge to combat climate crisis. *Environmental Sustainability*, 5(4), 395–399. <https://doi.org/10.1007/s42398-022-00257-2>
- Behera, M. K., Majumder, I., & Nayak, N. (2018). Solar photovoltaic power forecasting using optimized modified extreme learning machine technique. *Engineering Science and Technology, an International Journal*, 21(3), 428–438. <https://doi.org/10.1016/j.jestch.2018.04.013>
- Bilgili, F., Zarali, F., Ilgün, M. F., Dumrul, C., & Dumrul, Y. (2022). The evaluation of renewable energy alternatives for sustainable development in Turkey using intuitionistic fuzzy-TOPSIS method. *Renewable Energy*, 189, 1443–1458. <https://doi.org/10.1016/j.renene.2022.03.058>
- Chand, S., Krishnan, N., & K, R. K. (2023). Medium-Term Forecasting of Solar Radiation Using Hybrid Modelling. *Peer Review Journal of Solar & Photoenergy Systems*, 2(2), 1–9.
- Chang, X., & Jia, X. (2023). A DeepAR based hybrid probabilistic prediction model for production bottleneck of flexible shop-floor in Industry 4.0. *Computers and Industrial Engineering*, 185(September). <https://doi.org/10.1016/j.cie.2023.109644>

- Chen, S., & Lin, T. (2024). *Monetary policy and renewable energy production*. 132(February).
- Choudhary, K., DeCost, B., Chen, C., Jain, A., Tavazza, F., Cohn, R., Park, C. W., Choudhary, A., Agrawal, A., Billinge, S. J. L., Holm, E., Ong, S. P., & Wolverton, C. (2022). Recent advances and applications of deep learning methods in materials science. *Npj Computational Materials*, 8(1). <https://doi.org/10.1038/s41524-022-00734-6>
- Das, S., Tariq, A., Santos, T., Kantareddy, S. S., & Banerjee Imon. (2023). *Machine Learning for Brain Disorders* (Vol. 197, p. 1058). <https://link.springer.com/10.1007/978-1-0716-3195-9>
- Diarra, M. K., Maniar, A., Masson, J. B., Marhic, B., & Delahoche, L. (2023). Occupancy State Prediction by Recurrent Neural Network (LSTM): Multi-Room Context. *Sensors*, 23(23). <https://doi.org/10.3390/s23239603>
- Ehteram, M., Afshari Nia, M., Panahi, F., & Farrokhi, A. (2024). Read-First LSTM model: A new variant of long short term memory neural network for predicting solar radiation data. *Energy Conversion and Management*, 305(February). <https://doi.org/10.1016/j.enconman.2024.118267>
- Ekinici, E. (2024). A comparative study of LSTM-ED architectures in forecasting day-ahead solar photovoltaic energy using Weather Data. *Computing*, 0123456789. <https://doi.org/10.1007/s00607-024-01266-1>
- El Bakali, S., Hamid, O., & Gheouany, S. (2023). Day-ahead seasonal solar radiation prediction, combining VMD and STACK algorithms. *Clean Energy*, 7(4), 911–925. <https://doi.org/10.1093/ce/zkad025>
- Farghali, M., Osman, A. I., Chen, Z., Abdelhaleem, A., Ihara, I., Mohamed, I. M. A., Yap, P. S., & Rooney, D. W. (2023). Social, environmental, and economic consequences of integrating renewable energies in the electricity sector: a review. In *Environmental Chemistry Letters* (Vol. 21, Issue 3). Springer International Publishing. <https://doi.org/10.1007/s10311-023-01587-1>
- Farghali, M., Osman, A. I., Mohamed, I. M. A., Chen, Z., Chen, L., Ihara, I., Yap, P. S., & Rooney, D. W. (2023). Strategies to save energy in the context of the energy crisis: a review. In *Environmental Chemistry Letters* (Vol. 21, Issue 4). Springer International Publishing. <https://doi.org/10.1007/s10311-023-01591-5>

- Farghali, M., Osman, A. I., Umetsu, K., & Rooney, D. W. (2022). Integration of biogas systems into a carbon zero and hydrogen economy: a review. In *Environmental Chemistry Letters* (Vol. 20, Issue 5). Springer International Publishing. <https://doi.org/10.1007/s10311-022-01468-z>
- Ferkous, K., Chellali, F., Kouzou, A., & Bekkar, B. (2021). Wavelet-Gaussian process regression model for forecasting daily solar radiation in the Saharan climate. *Clean Energy*, 5(2), 316–328. <https://doi.org/10.1093/ce/zkab012>
- Ghimire, S., Bhandari, B., Casillas-Pérez, D., Deo, R. C., & Salcedo-Sanz, S. (2022). Hybrid deep CNN-SVR algorithm for solar radiation prediction problems in Queensland, Australia. *Engineering Applications of Artificial Intelligence*, 112(March). <https://doi.org/10.1016/j.engappai.2022.104860>
- Goliatt, L., & Yaseen, Z. M. (2023). Development of a hybrid computational intelligent model for daily global solar radiation prediction. *Expert Systems with Applications*, 212(April 2021). <https://doi.org/10.1016/j.eswa.2022.118295>
- Gürel, A. E., Ağbulut, Ü., & Biçen, Y. (2020). Assessment of machine learning, time series, response surface methodology and empirical models in prediction of global solar radiation. *Journal of Cleaner Production*, 277. <https://doi.org/10.1016/j.jclepro.2020.122353>
- Hassan, Q., Viktor, P., J. Al-Musawi, T., Mahmood Ali, B., Algburi, S., Alzoubi, H. M., Khudhair Al-Jiboory, A., Zuhair Sameen, A., Salman, H. M., & Jaszczur, M. (2024). The renewable energy role in the global energy Transformations. *Renewable Energy Focus*, 48(August 2023). <https://doi.org/10.1016/j.ref.2024.100545>
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Hossain, M. S., Abboodi Madloul, N., Al-Fatlawi, A. W., & El Haj Assad, M. (2023). High Penetration of Solar Photovoltaic Structure on the Grid System Disruption: An Overview of Technology Advancement. *Sustainability (Switzerland)*, 15(2). <https://doi.org/10.3390/su15021174>
- IEA. (2019). *World Energy Outlook 2019*. World Energy Outlook 2019. <https://www.iea.org/reports/world-energy-outlook-2019>
- IRENA. (2023). *Renewable Capacity Statistics 2023*. www.irena.org/publications

- Jathar, L. D., Ganesan, S., Awasarmol, U., Nikam, K., Shahapurkar, K., Soudagar, M. E. M., Fayaz, H., El-Shafay, A. S., Kalam, M. A., Bouadila, S., Baddadi, S., Tirth, V., Nizami, A. S., Lam, S. S., & Rehan, M. (2023). Comprehensive review of environmental factors influencing the performance of photovoltaic panels: Concern over emissions at various phases throughout the lifecycle. *Environmental Pollution*, 326(March). <https://doi.org/10.1016/j.envpol.2023.121474>
- Krishnan, N., Kumar, K. R., & Inda, C. S. (2023). How solar radiation forecasting impacts the utilization of solar energy: A critical review. *Journal of Cleaner Production*, 388(December 2022), 135860. <https://doi.org/10.1016/j.jclepro.2023.135860>
- Küçüktopçu, E., Cemek, B., & Simsek, H. (2024). Comparative analysis of single and hybrid machine learning models for daily solar radiation. *Energy Reports*, 11(February), 3256–3266. <https://doi.org/10.1016/j.egyr.2024.03.012>
- Kufel, J., Bargieł-Łączek, K., Kocot, S., Koźlik, M., Bartnikowska, W., Janik, M., Czogalik, Ł., Dudek, P., Magiera, M., Lis, A., Paszkiewicz, I., Nawrat, Z., Cebula, M., & Gruszczyńska, K. (2023). What Is Machine Learning, Artificial Neural Networks and Deep Learning?—Examples of Practical Applications in Medicine. *Diagnostics*, 13(15). <https://doi.org/10.3390/diagnostics13152582>
- Kumar, C., & Kumar, M. (2024). Session-based recommendations with sequential context using attention-driven LSTM. *Computers and Electrical Engineering*, 115(February). <https://doi.org/10.1016/j.compeleceng.2024.109138>
- Kumar Dalapati, G., Ghosh, S., Sherin P A, T., Ramasubramanian, B., Samanta, A., Rathour, A., Kin Shun Wong, T., Chakraborty, S., Ramakrishna, S., & Kumar, A. (2023). Maximizing solar energy production in ASEAN region: Opportunity and challenges. *Results in Engineering*, 20(June). <https://doi.org/10.1016/j.rineng.2023.101525>
- Kumari, P., & Toshniwal, D. (2021). Long short term memory–convolutional neural network based deep hybrid approach for solar irradiance forecasting. *Applied Energy*, 295(April). <https://doi.org/10.1016/j.apenergy.2021.117061>
- Lau, C. K., Gozgor, G., Mahalik, M. K., Patel, G., & Li, J. (2023). Introducing a new measure of energy transition: Green quality of energy mix and its impact on CO2 emissions. *Energy Economics*, 122(May), 1–7. <https://doi.org/10.1016/j.eneco.2023.106702>

- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- Lim, H., Chung, K., & Lee, S. (2022). Probabilistic Forecasting for Demand of a Bike-Sharing Service Using a Deep-Learning Approach. *Sustainability (Switzerland)*, 14(23), 1–18. <https://doi.org/10.3390/su142315889>
- Liu, C., Li, M., Yu, Y., Wu, Z., Gong, H., & Cheng, F. (2022). A Review of Multitemporal and Multispatial Scales Photovoltaic Forecasting Methods. *IEEE Access*, 10, 35073–35093. <https://doi.org/10.1109/ACCESS.2022.3162206>
- Lyu, Z., Shen, Y., Zhao, Y., & Hu, T. (2023). Solar Radiation Prediction Based on Conformer-GLaplace-SDAR Model. *Sustainability*, 15(20), 15050. <https://doi.org/10.3390/su152015050>
- Maka, A. O. M., & Alabid, J. M. (2022). Solar energy technology and its roles in sustainable development. *Clean Energy*, 6(3), 476–483. <https://doi.org/10.1093/ce/zkac023>
- Manalu, H. V., & Rifai, A. P. (2024). Detection of human emotions through facial expressions using hybrid convolutional neural network-recurrent neural network algorithm. *Intelligent Systems with Applications*, 21(February). <https://doi.org/10.1016/j.iswa.2024.200339>
- Matrenin, P., Manusov, V., Nazarov, M., Safaraliev, M., Kokin, S., Zicmane, I., & Beryozkina, S. (2023). *Power Systems Using Neural Networks*.
- Muhammad, U. S., & Purwahyudi, B. (2021). Design of Solar Power Plant for Electricity Source of The Drying Machine. *JEECS (Journal of Electrical Engineering and Computer Sciences)*, 6(2), 1081–1086. <https://doi.org/10.54732/jeeecs.v6i2.202>
- Nematchoua, M. K., Orosa, J. A., & Afaifia, M. (2022). Prediction of daily global solar radiation and air temperature using six machine learning algorithms; a case of 27 European countries. *Ecological Informatics*, 69(March). <https://doi.org/10.1016/j.ecoinf.2022.101643>
- Niu, W., Lu, J., Zhang, X., Sun, Y., Zhang, J., Cao, X., Li, Q., & Wu, B. (2023). Time series modeling for production prediction of shale gas wells. *Geoenergy Science and Engineering*, 231(October). <https://doi.org/10.1016/j.geoen.2023.212406>

- Ozgoren, M., Bilgili, M., & Sahin, B. (2012). Estimation of global solar radiation using ANN over Turkey. *Expert Systems with Applications*, 39(5), 5043–5051. <https://doi.org/10.1016/j.eswa.2011.11.036>
- Paraschiakos, S., de Sá, C. R., Okai, J., Slagboom, P. E., Beekman, M., & Knobbe, A. (2022). A recurrent neural network architecture to model physical activity energy expenditure in older people. *Data Mining and Knowledge Discovery*, 36(1), 477–512. <https://doi.org/10.1007/s10618-021-00817-w>
- Pellegrino, M., Lombardo, G., Adosoglou, G., Cagnoni, S., Pardalos, P. M., & Poggi, A. (2024). A Multi-Head LSTM Architecture for Bankruptcy Prediction with Time Series Accounting Data. *Future Internet*, 16(3), 1–20. <https://doi.org/10.3390/fi16030079>
- Pham, T. H., Acharya, P., Bachina, S., Osterloh, K., & Nguyen, K. D. (2024). Deep-learning framework for optimal selection of soil sampling sites. *Computers and Electronics in Agriculture*, 217(December 2023), 108650. <https://doi.org/10.1016/j.compag.2024.108650>
- Ramos, P., & Oliveira, J. M. (2023). Robust Sales forecasting Using Deep Learning with Static and Dynamic Covariates. *Applied System Innovation*, 6(5). <https://doi.org/10.3390/asi6050085>
- Rashid, M. I., Benhelal, E., & Rafiq, S. (2020). Reduction of Greenhouse Gas Emissions from Gas, Oil, and Coal Power Plants in Pakistan by Carbon Capture and Storage (CCS): A Review. *Chemical Engineering and Technology*, 43(11), 2140–2148. <https://doi.org/10.1002/ceat.201900297>
- Salinas, D., Flunkert, V., Gasthaus, J., & Januschowski, T. (2020). DeepAR: Probabilistic forecasting with autoregressive recurrent networks. *International Journal of Forecasting*, 36(3), 1181–1191. <https://doi.org/10.1016/j.ijforecast.2019.07.001>
- Shang, Y., Sang, S., Tiwari, K. A., Khan, S., & Zhao, S. (2023). Impacts of renewable energy on climate risk: A global perspective for energy transition in a climate adaptation framework. *Science of the Total Environment*, 859(February). <https://doi.org/10.1016/j.scitotenv.2022.160175>
- Sharifani, K., & Amini, M. (2023). Machine Learning and Deep Learning: A Review of Methods and Applications. *World Information Technology and Engineering Journal*, 10(07), 3897–3904.

- Singh, R. B., Patra, K. C., Pradhan, B., & Samantra, A. (2024). HDTO-DeepAR: A novel hybrid approach to forecast surface water quality indicators. *Journal of Environmental Management*, 352(December 2023). <https://doi.org/10.1016/j.jenvman.2024.120091>
- Smil, V. (2020). Energy Transitions: Fundamentals in Six Points. *Funcas*, 11–20.
- Solano, E. S., Dehghanian, P., & Affonso, C. M. (2022). Solar Radiation Forecasting Using Machine Learning and Ensemble Feature Selection. *Energies*, 15(19). <https://doi.org/10.3390/en15197049>
- Syed, M. A. Bin, & Ahmed, I. (2023). A CNN-LSTM Architecture for Marine Vessel Track Association Using Automatic Identification System (AIS) Data. *Sensors*, 23(14). <https://doi.org/10.3390/s23146400>
- Theodosiou, A. A., & Read, R. C. (2023). Resources for the Infection Clinician. *Journal of Infection*, 87(4), 287–294. <https://doi.org/10.1016/j.jinf.2023.07.006>
- Uzum, B., Onen, A., Hasanien, H. M., & Muyeen, S. M. (2021). Rooftop solar pv penetration impacts on distribution network and further growth factors—a comprehensive review. *Electronics (Switzerland)*, 10(1), 1–31. <https://doi.org/10.3390/electronics10010055>
- Valente, J., António, J., Mora, C., & Jardim, S. (2023). Developments in Image Processing Using Deep Learning and Reinforcement Learning. *Journal of Imaging*, 9(10). <https://doi.org/10.3390/jimaging9100207>
- Wang, J. (2024). Renewable energy, inequality and environmental degradation. *Journal of Environmental Management*, 356(February). <https://doi.org/10.1016/j.jenvman.2024.120563>
- Xie, G., Shangguan, A., Fei, R., Ji, W., Ma, W., & Hei, X. (2020). Motion trajectory prediction based on a CNN-LSTM sequential model. *Science China Information Sciences*, 63(11), 1–21. <https://doi.org/10.1007/s11432-019-2761-y>
- Yadav, H., & Thakkar, A. (2024). NOA-LSTM: An efficient LSTM cell architecture for time series forecasting. *Expert Systems with Applications*, 238(July 2023). <https://doi.org/10.1016/j.eswa.2023.122333>
- Yang, X., Ji, Y., Wang, X., Niu, M., Long, S., Xie, J., & Sun, Y. (2023). Simplified Method for Predicting Hourly Global Solar Radiation Using Extraterrestrial Radiation and Limited Weather Forecast Parameters. *Energies*, 16(7). <https://doi.org/10.3390/en16073215>

- Ye, F., & Yang, J. (2021). Applied Sciences. *Early Writings on India*, 124–134. <https://doi.org/10.4324/9781315232140-14>
- Yoro, K. O., & Daramola, M. O. (2020). Gases , and the Global Warming Effect. *Advances in Carbon Capture*, 3–28. <http://dx.doi.org/10.1016/B978-0-12-819657-1.00001-3>
- Zeng, Z., Wang, Z., Gui, K., Yan, X., Gao, M., Luo, M., Geng, H., Liao, T., Li, X., An, J., Lio, H., He, C., Ning, G., & Yang, Y. (2020). 2020 - Zeng - *Daily Global Solar Radiation in China Estimated From High-Density Meteorological.pdf*.
- Zhou, K., Oh, S.-K., Pedrycz, W., Qiu, J., & Seo, K. (2024). A Self-organizing Deep Network Architecture Designed Based on LSTM Network via Elitism-driven Roulette-Wheel Selection for Time-Series Forecasting. *Knowledge-Based Systems*, 289(February), 111481. <https://doi.org/10.1016/j.knosys.2024.111481>
- Zhu, L., & Huang, Y. (2021). Research on Deep Generative Model Application for Shortterm Load Forecasting of Enterprise Electricity. *IOP Conference Series: Earth and Environmental Science*, 687(1). <https://doi.org/10.1088/1755-1315/687/1/012113>
- Zohuri, B., & McDaniel, P. (2021). Introduction to Energy Essentials. In *Introduction to Energy Essentials* (Issue January 2021). <https://doi.org/10.1016/c2020-0-03623-6>