

**KLASIFIKASI PENYAKIT GINJAL BERDASARKAN GAMBAR
CT SCAN MENGGUNAKAN DEEP LEARNING**

TRIFALIYOKA GUSRUL MR

201402115



**PROGRAM STUDI TEKNOLOGI INFORMASI FAKULTAS
ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA**

2025

**KLASIFIKASI PENYAKIT GINJAL BERDASARKAN GAMBAR
CT SCAN MENGGUNAKAN DEEP LEARNING**

SKRIPSI

Diajukan untuk melengkapi tugas dan memenuhi syarat memperoleh
ijazah Sarjana Teknologi Informasi

TRIFALIYOKA GUSRUL MR

201402115



**PROGRAM STUDI TEKNOLOGI INFORMASI FAKULTAS
ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA**

2025

SURAT PERNYATAAN

KLASIFIKASI PENYAKIT GINJAL BERDASARKAN GAMBAR CT SCAN MENGGUNAKAN DEEP LEARNING

SKRIPSI

Saya mengakui bahwa skripsi ini adalah hasil karya saya sendiri, kecuali beberapa kutipan dan ringkasan yang masing-masing telah disebutkan sumbernya.

Medan , 25 Desember 2024

Trifaliyoka Gusrul M.R

201402115

KATA PENGANTAR

Puji dan Syukur kepada Allah SWT, yang senantiasa memberikan berkat, rahmat, dan karunia-Nya, sehingga penulis dapat menyelesaikan skripsi ini sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer dari Program Studi S1 Teknologi Informasi, Fakultas Ilmu Komputer dan Teknologi Informasi, Universitas Sumatera Utara. Dalam proses menyelesaikan penulisan tugas akhir ini, penulis telah menerima banyak bimbingan, dukungan, bantuan, serta doa dari berbagai pihak. Pada kesempatan ini, penulis ingin mengucapkan terima kasih kepada:

1. Kedua orang tua penulis, Bapak Ringgo dan Ibu Adriani Dinar dan saudara penulis, Abang Irsyadi Fauzul Aziem, kakak Yolla Prisiskalya Apriani Ringgo, Abang Syahfadel Gusrul Muhammad Ringgo, dan Abang Aprilio Gusrul Muhammad Ringgo atas doa, kasih sayang, serta dukungan kepada penulis dari mulai awal pendidikan hingga penulis dapat menyelesaikan tugas akhir ini.
2. Ibu Dr. Maya Silvi Lydia B.Sc, M.Sc. selaku Dekan Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Sumatera Utara..
3. Bapak Fahrurrozi Lubis B.IT., M.Sc.IT. selaku Dosen Pembimbing I dan Mohammad Fadly Syah Putra M.Sc selaku Dosen Pembimbing II yang telah membimbing peneliti dalam penelitian dan penulisan skripsi ini.
4. Ketua Program Studi Teknologi Informasi Bapak Dedy Arisandi ST., M.Kom. Selaku Ketua Program Studi Teknologi Informasi.
5. Dosen Program Studi Teknologi Informasi yang telah memberikan ilmu saat penulis menjalani masa perkuliahan.
6. Staff dan pegawai Fasilkom-TI Universitas Sumatera Utara yang membantu segala urusan administrasi selama perkuliahan.
7. Teman yang membantu peneliti Berliana, Ravi, Raul, Daffa, Lingga, Ghautsan, Fariz, dan Gibran, yang selalu menemani dan mendukung penulis dalam penelitian dan penulisan hingga akhir.
8. Warga Andimed yang membantu peneliti, Logi, Ridho, Rio, Jethro, Anri, Zikri, Christoper, Daniel, Anggi, Brian, Sam, Tomi, Monang, Timo, Vincent, dan Geyl yang selalu menemani dan mendukung penulis dalam penelitian dan penulisan hingga akhir.
9. Tim Sepak Bola Manchester United yang telah mengajari arti dari kesabaran

dan perjuangan kepada penulis

10. Teman-teman Teknologi Informasi USU terkhusus Stambuk 2020 Semua pihak yang terlibat langsung ataupun tidak langsung yang tidak dapat penulis ucapkan satu persatu yang telah membantu penyelesaian skripsi ini

Medan, 25 Desember 2024

Penulis,

Trifaliyoka Gusrul M.R

201402115

KLASIFIKASI PENYAKIT GINJAL BERDASARKAN GAMBAR CT SCAN MENGGUNAKAN DEEP LEARNING

ABSTRAK

Ginjal adalah organ vital dalam sistem ekskresi manusia yang memiliki peran penting dalam menyaring darah dan mengeluarkan limbah. Ginjal merupakan masalah serius untuk manusia apabila tidak ditangani ataupun ditangani dengan cara yang salah, misinterpretasi mengenai penyakit juga akan berdampak fatal pada pasien, oleh karena itu, diperlukan sistem yang dapat membantu tenaga ahli Kesehatan yang dapat mengklasifikasikan jenis kondisi ginjal yang tepat. Penelitian ini mengimplementasikan You Only Look Once version 9 (YOLO v9) untuk mengklasifikasikan 4 jenis kondisi ginjal yaitu batu ginjal, kista, normal, dan tumor dengan jumlah data yang digunakan sebanyak 3600 data yang terdiri dari 2880 data sebagai data *training*, 360 data sebagai data validation, dan 360 data sebagai data testing. Hasil menunjukkan bahwa algoritma YOLOv9 mampu untuk mengklasifikasikan kondisi ginjal dengan nilai accuracy 89.90%, precision 88,67%, recall 86,30%, dan f1-score 87,42%. Model ini mampu melakukan pengklasifikasian jenis kondisi ginjal secara bersamaan sebanyak 40 gambar. Dari hasil tersebut menunjukkan bahwa sistem yang dibuat menggunakan algoritma YOLO v9 telah berhasil melakukan pengklasifikasian jenis kondisi pada ginjal.

Kata Kunci: Penyakit Ginjal, YOLOv9, Deteksi Objek, Citra Digital

CLASSIFICATION OF KIDNEY DISEASE BASED ON CT SCAN IMAGES USING DEEP LEARNING

ABSTRACT

Kidney is a vital organ in the human excretory system that has an important role in filtering blood and removing waste. Kidney is a serious problem for humans if not treated or treated in the wrong way, misinterpretation of the disease will also have a fatal impact on the patient, therefore, a system is needed that can help health professionals who can classify the right type of kidney condition. This research implements You Only Look Once version 9 (YOLOv9) to classify 4 types of kidney conditions namely kidney stones, cysts, normal, and tumors with the amount of data used as much as 3600 data consisting of 2880 data as training data, 360 data as validation data, and 360 data as testing data. The results show that the YOLOv9 algorithm is less able to classify kidney conditions with an accuracy value of 89.90%, precision 88.67%, recall 86.30%, and f1-score 87.42%. This model is able to classify the type of kidney condition simultaneously with as many as 40 images. These results show that the system created using the YOLOv9 algorithm has successfully classified the types of conditions in the kidneys.

Keywords: Kidney Disease, YOLOv9, Object Detection, Digital Image

DAFTAR ISI

SURAT PERNYATAAN	i
KATA PENGANTAR.....	ii
ABSTRAK	iv
ABSTRACT	v
DAFTAR ISI.....	vi
DAFTAR TABEL	ix
BAB 1 PENDAHULUAN	1
1.1 Latar belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian.....	3
1.4 Batasan Masalah	4
1.5 Manfaat Penelitian.....	4
1.6 Sistematika Penulisan	5
BAB 2 LANDASAN TEORI	6
2.1 Ginjal.....	6
2.2 Batu Ginjal	6
2.3 Kista	7
2.3.1 Kelas 1	7
2.3.2 Kelas 2	8
2.3.3 Kelas 2F	8
2.3.4 Kelas 3	9
2.3.5 Kelas 4	9
2.4 Tumor.....	10
2.5 CT Scan.....	10
2.6 Deep Learning	10
2.7 Computer Vision	11
2.8 Citra Digital	12
2.8.1 Citra Biner	12
2.8.2 Citra Hitam Putih	12
2.9 Object Detection.....	12

2.10 CNN	13
2.11 You Only Look Once (YOLO)	13
2.12 You Only Look Once V8 (YOLOV8)	14
2.13 You Only Look Once V9 (YOLOv9)	15
2.14 Perbedaan YOLOv8 dan YOLOv9	16
2.15 Confusion Matrix	17
2.16 Penelitian Terdahulu	18
BAB 3 ANALISIS DAN PERANCANGAN SISTEM	24
3.1 Dataset.....	24
3.2 Analisis Sistem.....	25
3.2.1 Data Acquisition	25
3.2.2 Image Pre-Processing.....	26
3.2.3 Image Classification	28
3.3 Perancangan Antarmuka Sistem.....	30
3.3.1 Tampilan Halaman Home	30
3.3.2 Tampilan Halaman About.....	31
3.3.3 Tampilan Halaman Predict.....	31
3.3.4 Tampilan Halaman Hasil.....	32
BAB 4 IMPLEMENTASI DAN PENGUJIAN.....	33
4.1 Implementasi Sistem	33
4.2 Implementasi Data	33
4.3 Implementasi Perancangan Antarmuka.....	34
4.3.1 Tampilan Halaman Home	34
4.3.2 Tampilan Halaman About.....	34
4.3.3 Tampilan Halaman Predict.....	35
4.3.4 Tampilan Halaman Hasil.....	35
4.4 Pelatihan Sistem	36
4.5 Pengujian Sistem.....	39
4.5.1 Pengujian Akurasi.....	39
BAB 5 KESIMPULAN DAN SARAN	48
5.1 Kesimpulan.....	48
5.2 Saran	48

DAFTAR GAMBAR

Gambar 2. 1 Kista Kelas 1 Pada CT Scan	8
Gambar 2. 2 Kista Kelas 2 Pada CT Scan	8
Gambar 2. 3 Kista Kelas 2F pada CT Scan	9
Gambar 2. 4 Kista Kelas 3 pada CT Scan	9
Gambar 2. 5 Kista Kelas 4 pada CT Scan	9
Gambar 2. 6 Ilustrasi Ginjal yang sehat dan Ginjal yang terkena tumor	10
Gambar 2. 7 Perbandingan Machine Learning dan Deep Learning	11
Gambar 2. 8 Arsitektur Umum CNN	13
Gambar 2. 9 Arsitektur Umum You Only Look Once (YOLO)	14
Gambar 2. 10 Arsitektur Umum You Only Look Once Version 8	15
Gambar 2. 11 Arsitektur Umum Programmable Gradient Information (PGI)	16
Gambar 2. 12 Arsitektur Umum GELAN	16
Gambar 3. 1 Contoh dataset yang akan digunakan	24
Gambar 3. 2 Arsitektur Umum	25
Gambar 3. 3 Pemberian Label dan Bounding Box pada citra	26
Gambar 3. 4 Tahap Resizing	27
Gambar 3. 5 Contoh data citra sebelum dan sesudah resize	27
Gambar 3. 6 Tahap Augmentasi	28
Gambar 3. 7 Contoh data citra sebelum dan setelah Augmentasi	28
Gambar 3. 8 Tampilan Halaman Home	31
Gambar 3. 9 Tampilan Halaman About	31
Gambar 3. 10 Tampilan Halaman Predict	32
Gambar 3. 11 Tampilan Halaman Hasil	32
Gambar 4. 1 Tampilan Halaman Home	34
Gambar 4. 2 Tampilan Halaman about	35
Gambar 4. 3 Tampilan Halaman Predict	35
Gambar 4. 4 Tampilan Halaman Hasil	36
Gambar 4. 5 Kaggle	36
Gambar 4. 6 Jenis GPU dan Jumlah VRAM yang digunakan	37
Gambar 4. 7 Grafik Pelatihan	38

DAFTAR TABEL

Tabel 2. 1 Penelitian Terdahulu	20
Tabel 3. 1 Data Split.....	24
Tabel 4. 1 Hasil Percobaan Training	37
Tabel 4. 2 Hasil Uji Sistem	39
Tabel 4. 3 Confusion Matrix	44
Tabel 4. 4 Nilai Pengujian TP, FP, FN.....	44
Tabel 4. 5 Nilai Precision, Recall, dan F1-Score	46

BAB 1

PENDAHULUAN

1.1 Latar belakang

Ginjal adalah organ vital dalam sistem ekskresi manusia yang memiliki peran penting dalam menyaring darah, mengeluarkan limbah, mengatur keseimbangan elektrolit, dan menjaga keseimbangan cairan tubuh. Setiap hari, ginjal memproses sekitar 120-150 liter darah untuk menghasilkan 1-2 liter urin, yang terdiri dari limbah dan cairan berlebih (M. Koeppen & Stanton, 2013). Gangguan pada fungsi ginjal dapat menyebabkan akumulasi limbah berbahaya dalam tubuh dan berujung pada kondisi medis serius, salah satunya adalah pembentukan batu ginjal, tumor, dan kista.

Batu ginjal merupakan salah satu masalah kesehatan yang signifikan dan sering ditemukan dalam praktik klinis. Kondisi ini terjadi ketika mineral dan garam dalam urin mengendap dan membentuk kristal yang kemudian berkembang menjadi batu keras. Batu ginjal dapat menyebabkan nyeri hebat, infeksi, dan komplikasi serius lainnya jika tidak ditangani dengan tepat.

Tumor ginjal adalah pertumbuhan abnormal yang terjadi pada organ ginjal. Tumor ini dapat bersifat jinak atau ganas (kanker). Tumor ginjal jinak umumnya tidak membahayakan dan tidak menyebar ke bagian lain tubuh. Pertumbuhannya biasanya lambat dan dapat diangkat dengan operasi (Vogelzang J & Stadler M, 1998).

Sedangkan tumor ginjal ganas (kanker ginjal) memiliki potensi untuk menyerang dan merusak jaringan ginjal di sekitarnya, serta menyebar ke bagian tubuh lain (metastasis). Kanker ginjal adalah salah satu jenis kanker yang umum dan dapat menyerang orang-orang dari berbagai usia (Vogelzang J & Stadler M, 1998).

Gejala tumor ginjal dapat bervariasi tergantung pada jenis, ukuran, dan lokasi tumornya. Beberapa gejala umum tumor ginjal meliputi darah dalam urin, nyeri punggung atau perut, benjolan di perut, kelelahan, dan penurunan berat badan.

Kista ginjal adalah kantong berisi cairan yang terbentuk di dalam ginjal. Kista ini dapat ditemukan di bagian luar (korteks) atau bagian dalam (medulla) ginjal dan dapat bervariasi dalam ukuran, dari kecil seperti kacang hingga besar seperti

bola tenis. Oleh karena itu, deteksi dini dan diagnosis yang akurat sangat penting untuk mengurangi risiko komplikasi dan memastikan penanganan yang tepat waktu (Schieda et al., 2021).

Berdasarkan (Kementerian Kesehatan RI, 2023) data survei kesehatan Indonesia tahun 2023, didapatkan angka 638.178 kasus penyakit ginjal kronis. Angka ini menunjukkan beban yang cukup besar bagi sistem kesehatan Indonesia, mengingat tingginya biaya pengobatan dan dampaknya terhadap kualitas hidup penderita.

Pencitraan medis seperti CT (*Computer Tomography*) scan, MRI (*Magnetic Resonance Imaging*), dan *ultrasound* telah menjadi alat utama dalam mendiagnosis batu ginjal. Meskipun teknologi ini memungkinkan visualisasi yang baik dari ginjal dan batu yang terbentuk, interpretasi hasil pencitraan masih memerlukan keahlian khusus dari radiologis. Proses ini sering kali memakan waktu dan bergantung pada penilaian subjektif, yang dapat menyebabkan variabilitas dalam diagnosis.

Penilaian subyektif yang dapat menyebabkan variabilitas dalam diagnosis telah dibuktikan pada artikel dari (Lee et al., 2021) yang didapatkan 16 kasus misinterpretasi mengenai penyakit pada ginjal dari 381 kasus, angka ini menunjukkan adanya penilaian yang keliru yang disebabkan oleh penilaian yang subyektif.

Perkembangan teknologi yang semakin pesat dan canggih di masa kini telah banyak membantu pekerjaan manusia. Hal ini dibuktikan dengan adanya pengolahan citra digital untuk mendeteksi batu ginjal yang dilakukan oleh (Soni Scholar, 2020) yang berjudul “Kidney Stone Recognition and Extraction using Directional Emboss & SVM from Computed Tomography Images” yang menggunakan data CT *scan* yang difoto dari atas berhasil menggunakan menggunakan filter emboss untuk menemukan batu ginjal dengan cara gambar akan timbul ditunjukkan oleh gambar datar dan kemiringan di sekitarnya. Kemudian gambar yang berhasil diemboss akan disegmentasi dan dideteksi menggunakan algoritma SVM, hasil penelitian ini menunjukkan akurasi 98,71%, mendapatkan hasil sensitivitas 100% dan spesifisitas 97,5%.

Kemudian penelitian selanjutnya yang dilakukan oleh (Yildirim et al., 2021a) yang berjudul “*Deep learning model for automated kidney stone detection using coronal CT images*” menggunakan gambar *ct scan* yang diambil dari depan berhasil mengimplementasikan algoritma Xresnet-50. Dengan algoritma Xresnet-50 didapatkan akurasi sebesar 96,81% dan F1 Score sebesar 97%.

Kemudian penelitian yang dilakukan oleh (Thein et al., 2018) yang berjudul “*An Image Preprocessing Method for Kidney Stone Segmentation in CT scan images*” mengambil gambar data *ct scan* dari atas dan melakukan penekanan pada proses segmentasi untuk melakukan proses pemisahan antara organ dan tulang, kemudian hasil penelitian diuji coba kepada 30 pasien dan didapatkan hasil 60 True Positive dan 3 false Negative.

Kemudian penelitian yang dilakukan oleh (Sowjanya et al., 2023) yang berjudul “*DeepKidney: Multiclass Classification of Kidney Stones, Cysts, Tumors, and Normal Cases Using Convolutional Neural Networks*” berhasil mengklasifikasikan antara batu ginjal, kista, tumor, dan ginjal yang sehat menggunakan algoritma CNN, kemudian penelitian ini mendapatkan akurasi sebesar 98,91%

1.2 Rumusan Masalah

Walaupun angka dalam kasus misinterpretasi diagnosa pada ginjal memiliki angka yang kecil, tetapi kesalahan dalam dunia medis memiliki dampak yang besar atas keberlangsungan hidup pasien, oleh karena itu diharapkan sistem pada penelitian ini dapat mengurangi kasus misinterpretasi diagnosa pada ginjal.

Kemudian pada penggunaan *ct scan*, gambar yang dihasilkan bisa sampai puluhan gambar yang terdiri dari irisan gambar ginjal, oleh karena itu diharapkan hasil penelitian ini dapat meningkatkan efisiensi pengguna dalam mendeteksi penyakit batu ginjal

1.3 Tujuan Penelitian

Penelitian ini bertujuan untuk mengetahui kinerja, kecepatan, dan efisiensi algoritma dan untuk mengevaluasi dampak peningkatan teknologi pada YOLO v9, memberikan rekomendasi penggunaan algoritma yang lebih sesuai dalam praktik klinis, dan mengkaji potensi peningkatan diagnosis klinis melalui penggunaan algoritma yang

lebih akurat dan efisien. Dengan demikian, hasil penelitian diharapkan dapat memberikan kontribusi signifikan dalam pengembangan teknologi deteksi batu ginjal yang lebih canggih dan mendukung praktisi medis dalam memilih alat bantu diagnosis yang tepat.

1.4 Batasan Masalah

Penelitian tersebut memiliki beberapa batasan masalah agar penelitian tidak menyimpang dari tujuan yang akan dicapai. Batasan-batasan yang disebut adalah:

1. Data yang digunakan berekstensi JPG
2. Penelitian ini dibatasi dengan menggunakan algoritma YoloV9.
3. Penelitian Mengklasifikasikan Data yang terkena batu ginjal, tumor, dan kista
4. Penggunaan pada hasil penelitian ini berfokus pada dokter, residen, dan koas
5. Sistem akan mengeluarkan 1 jenis penyakit dengan *confidence* tertinggi
6. Sistem tidak dapat mengukur besaran dari suatu penyakit

1.5 Manfaat Penelitian

Manfaat dari penelitian tersebut ialah:

1. Meningkatkan kualitas pelayanan kesehatan dengan deteksi yang canggih, peningkatan pelayanan kesehatan kepada pasien dalam hal kecepatan dan ketepatan diagnosa.
2. Mengetahui bagaimana kinerja algoritma YOLO v9 untuk mengklasifikasikan penyakit ginjal pada gambar *CT Scan*
3. Dengan adanya pendeteksian algoritma yang cepat dan akurat, diharapkan dapat mengurangi waktu dan biaya yang diperlukan untuk proses diagnostik dalam konteks klinis maupun laboratorium

1.6 Sistematika Penulisan

Sistematika penulisan skripsi ini terdiri dari 5 bab yaitu pendahuluan, landasan teori, analisis dan perancangan sistem, implementasi dan pengujian sistem, kesimpulan dan saran.

BAB 1: PENDAHULUAN

Bab satu memuat penjelasan mengenai latar belakang penelitian, perumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, metodologi penelitian, dan sistematika penulisan.

BAB 2: LANDASAN TEORI

Bab dua terdiri dari teori yang berhubungan dengan ginjal, penyakit pada ginjal, *ct scan*, pengolahan citra digital, dan arsitektur YOLO v9 yang digunakan pada penelitian ini.

BAB 3: ANALISIS DAN PERANCANGAN SISTEM

Bab tiga mencakup arsitektur umum dari penelitian yang dilakukan yang terdiri dari pengambilan data gambar, langkah-langkah pada tahap *pre-processing*, proses *training* beberapa model YOLO v9, evaluasi model, *testing*, dan perancangan antarmuka sistem.

BAB 4: IMPLEMENTASI DAN PENGUJIAN SISTEM

Pada bab empat, dijelaskan tentang pelaksanaan analisis dan perancangan sistem yang telah dijelaskan pada bab sebelumnya, serta menunjukkan hasil dari pengujian sistem yang telah dibangun.

BAB 5: KESIMPULAN DAN SARAN

Bab lima berisi tentang kesimpulan dan saran dari hasil penelitian yang telah dilakukan guna pengembangan pada penelitian selanjutnya.

BAB 2

LANDASAN TEORI

2.1 Ginjal

Ginjal adalah organ berpasangan yang terletak di bagian belakang dinding perut di belakang peritoneum di kedua sisi sisi kolom vertebral. Pada manusia dewasa, masing-masing ginjal memiliki berat antara 115 dan 170 g dan berukuran sekitar panjangnya sekitar 11 cm, lebar 6 cm, dan tebal 3 cm (M. Koeppen & Stanton, 2013). Ginjal memiliki peran vital dalam sistem ekskresi manusia yang memiliki peran penting dalam membersihkan darah, mengatur pembuangan limbah, mengurus keseimbangan elektrolit, dan menjaga keseimbangan cairan tubuh. Setiap hari, ginjal memproses sekitar 120 hingga 150 liter darah untuk menghasilkan 1 hingga 2 liter urin, yang terdiri dari limbah dan cairan berlebih (M. Koeppen & Stanton, 2013). Gangguan pada fungsi ginjal dapat menyebabkan akumulasi limbah berbahaya dalam tubuh dan berujung pada kondisi medis serius, salah satunya adalah pembentukan batu ginjal.

2.2 Batu Ginjal

Batu Ginjal merupakan suatu kondisi dimana di dalam ginjal terdapat satu atau lebih batu di dalam pelvis atau *calyces* dari ginjal tersebut (Indridason et al., 2006), penyebab utama terbentuk batu ginjal dapat disebabkan oleh dehidrasi, pola makan yang tinggi protein dan garam, obesitas, serta kondisi medis tertentu. Pembentukan batu ginjal dapat terjadi ureter tetapi biasa terjadi di ginjal khususnya bagian pelvis *renalis*. Batu ginjal terbentuk dari kombinasi fosfat, kalsium, atau asam urat dan biasanya larut dalam urin (Sun et al., 2010).

Gejala umum dari batu ginjal meliputi nyeri hebat di punggung bawah atau sisi perut, yang dapat menyebar ke bagian bawah perut dan pangkal paha. Rasa sakit ini sering kali datang secara tiba-tiba dan dalam gelombang. Gejala lainnya bisa termasuk darah dalam urin (hematuria), mual dan muntah, sering buang air kecil, merasakan sakit saat buang air kecil, dan urin berbau atau keruh.

Diagnosis batu ginjal biasanya melibatkan pemeriksaan riwayat medis dan gejala pasien, serta pemeriksaan fisik. Tes diagnostik yang umum dilakukan meliputi analisis urin, tes darah untuk memeriksa kadar kalsium dan asam urat, serta pencitraan seperti *CT scan*, ultrasound, atau sinar-X untuk mendeteksi batu ginjal dan menentukan ukuran serta lokasi batu.

2.3 Kista

Kista adalah kantong berisi cairan, zat padat, atau udara yang dapat terbentuk di berbagai bagian tubuh. Ukurannya bisa bervariasi dari kecil seperti kacang hingga besar seperti bola basket. Kista umumnya jinak, namun dalam beberapa kasus yang jarang, bisa bersifat ganas. Gejala kista tergantung pada lokasi dan ukurannya. Kista kecil mungkin tidak menimbulkan gejala, sedangkan kista besar dapat menyebabkan rasa sakit, pembengkakan, atau gangguan fungsi organ (Schieda et al., 2021). Pengobatan kista tergantung pada jenis, lokasi, dan ukurannya. Kista kecil tanpa gejala mungkin tidak memerlukan pengobatan, sedangkan kista besar atau yang menimbulkan gejala mungkin memerlukan drainase, operasi pengangkatan, atau terapi lain.

Berdasarkan pada penelitian yang ditulis oleh (Schieda et al., 2021) yang berjudul “*Bosniak Classification of Cystic Renal Masses, Version 2019: A Pictorial Guide to Clinical Use*” kista pada gambar *CT scan* dikategorikan menjadi 5 kelas yaitu :

2.3.1 Kelas 1


Kelas 1 memiliki dinding halus yang dapat didefinisikan dengan baik dan memiliki ketebalan tipis (dibawah 2mm), memiliki cairan sederhana homo-geneous (-9 hingga 20 HU) dan tidak ada kalsifikasi septaor.



Gambar 2. 1 Kista Kelas 1 Pada CT Scan (Schieda et al., 2021)

2.3.2 Kelas 2


Massa kistik dengan dinding penambah yang halus dan minimal setebal dinding penambah yang halus (3 mm), atau halus penebalan minimal (3 mm) dari satu atau lebih meningkatkan septa, atau banyak (≥ 4) tipis halus (≤ 2 mm) septa penambah.



Gambar 2. 2 Kista Kelas 2 Pada CT Scan (Schieda et al., 2021)

2.3.3 Kelas 2F


Massa kistik dengan dinding penambah yang halus dan minimal setebal dinding penambah yang halus (3 mm), atau halus penebalan minimal (3 mm) dari satu atau lebih meningkatkan septa, atau banyak (≥ 4) tipis halus (≤ 2 mm) septa penambah



Gambar 2. 3 Kista Kelas 2F pada CT Scan (Schieda et al., 2021)

2.3.4 Kelas 3


Satu atau lebih penambah tebal (lebar ≥ 4 mm) atau meningkatkan tidak teratur (menampilkan ≤ 3 mm secara tumpul tonjolan cembung yang terpotong) dinding atau septa



Gambar 2. 4 Kista Kelas 3 pada CT Scan (Schieda et al., 2021)

2.3.5 Kelas 4

Satu atau lebih nodul penambah (≥ 4 mm cembung tonjolan dengan margin tumpul, atau tonjolan cembung trusi cembung dengan berbagai ukuran yang memiliki tepi tajam)



Gambar 2. 5 Kista Kelas 4 pada CT Scan (Schieda et al., 2021)

2.4 Tumor

Tumor pada ginjal merupakan pertumbuhan jaringan yang terjadi secara abnormal pada ginjal, tumor pada ginjal dapat terjadi pada salah satu atau pada kedua ginjal, jenis tumor pada ginjal adalah jinak dan ganas (Vogelzang J & Stadler M, 1998). Tumor ginjal menunjukkan tanda munculnya tumor dengan dimulainya perubahan yang terjadi pada DNA beberapa sel ginjal, dimana DNA yang berisi petunjuk bagi sel dan sel tersebut dapat membelah dan berpindah ke bagian tubuh yang lain (Linehan, 2012), Gejala pada tumor pada ginjal dapat berbeda beda tergantung pasien, tetapi umumnya gejala pasien yang terkena tumor ginjal adalah nyeri panggul, punggung, kelelahan, anemia, hematuria, dan penurunan berat badan (Vogelzang J & Stadler M, 1998)



Gambar 2. 6 Ilustrasi Ginjal yang sehat dan Ginjal yang terkena tumor (*Vogelzang J & Stadler M, 1998*)

2.5 CT Scan


CT Scan (Computed Tomography) adalah teknik pencitraan medis yang menggunakan Kombinasi data yang diolah oleh komputer dari berbagai pengukuran sinar-X yang diambil dari sudut berbeda untuk menghasilkan sebuah gambar penampang tubuh. Gambar-gambar ini memberikan informasi terperinci tentang struktur internal tubuh, memungkinkan diagnosis dan pemantauan berbagai kondisi medis (Sarma et al., 2012) . Contoh gambar penerapan *CT scan* dapat dilihat pada Gambar 2.1.

2.6 Deep Learning

Deep Learning Merupakan cabang machine learning yang menitikberatkan pada penggunaan jaringan saraf tiruan bertingkat (*deep neural networks*) untuk menganalisis dan memahami data. Metode ini memungkinkan pemrosesan melalui

beberapa lapisan untuk mempelajari dan merepresentasikan data dengan berbagai tingkat abstraksi, meniru cara kerja otak dalam memahami informasi multimodal. (Voulodimos et al., 2018). Oleh karena itu, *deep learning* memungkinkan untuk belajar dan beradaptasi terhadap data dalam jumlah besar dan mampu menyelesaikan masalah yang sulit yang dihadapi oleh algoritma pembelajaran mesin. (*machine learning*).

Perbandingan *Machine learning* dan *deep learning* dapat dilihat pada gambar 2.7 di bawah ini :



Gambar 2. 7 Perbandingan *Machine Learning* dan *Deep Learning*

Sumber : Researchgate.net

2.7 Computer Vision

Computer vision merupakan proses komputer untuk memproses data visual seperti gambar dan video. *Computer vision* memiliki tujuan untuk meniru kemampuan yang dimiliki manusia yaitu penglihatan, sehingga komputer memiliki kemampuan untuk menginterpretasikan dan membuat keputusan berdasarkan input visual. proses tersebut melibatkan algoritma untuk dapat mendeteksi, mengenali dan menganalisis objek dari input visual dengan maksud untuk memahami konteks visual yang lebih luas (Voulodimos et al., 2018).

2.8 Citra Digital

Citra digital adalah kombinasi dari citra, yang mencakup gambar diam atau gambar bergerak (video) dari kamera, dan digital, yang mengacu pada pengolahan citra atau gambar secara digital menggunakan komputer. (Kusumanto & Tompunu, 2011) Agar sebuah gambar dapat diolah secara digital, maka suatu citra harus dipresentasikan secara numerik dengan nilai-nilai diskrit (Kusumanto & Tompunu, 2011) Citra digital direpresentasikan sebagai matriks dua dimensi $f(x,y)$ yang terdiri dari M kolom dan N baris. Setiap perpotongan antara baris dan kolom disebut piksel, yang merupakan elemen terkecil dari sebuah citra.

2.8.1 Citra Biner

Citra biner adalah jenis citra yang hanya memiliki dua warna, yaitu hitam dan putih. Karena hanya terdiri dari dua warna, setiap piksel pada citra biner direpresentasikan dengan 1 bit, yaitu 0 atau 1, atau dalam format 8-bit dengan nilai 0 dan 255. Hal ini membuat citra biner sangat efisien dalam hal penyimpanan data.

2.8.2 Citra Hitam Putih

Citra digital hitam putih adalah citra di mana setiap pikselnya memiliki gradasi warna dari putih hingga hitam. Gradasi ini memungkinkan setiap piksel direpresentasikan dengan 8 bit atau 1 byte. Rentang warna hitam putih sangat efektif untuk berbagai aplikasi pengolahan gambar, termasuk penggunaannya dalam bidang kedokteran, seperti pada pencitraan sinar-X (*X-ray*).

2.9 Object Detection

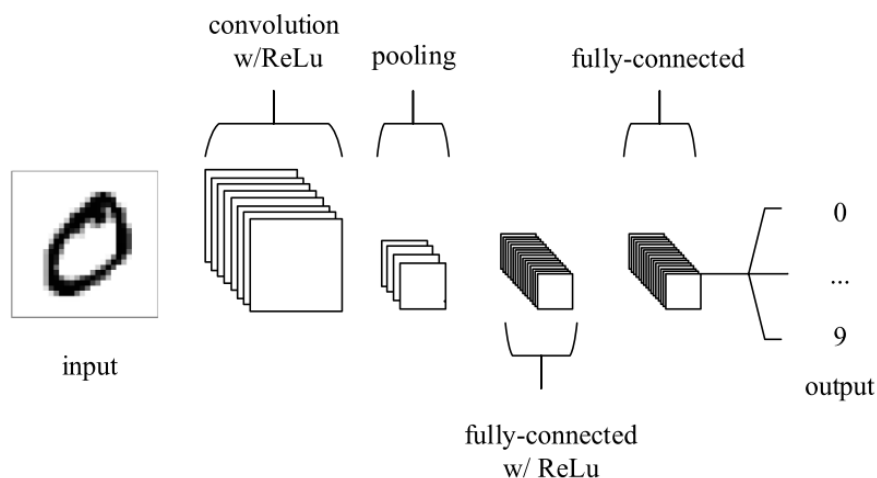
Object Detection merupakan cabang dari *computer vision* yang memiliki kemampuan untuk mendeteksi objek tertentu dari sebuah gambar atau video. Dengan melakukan pendeteksian objek pada sebuah gambar, *object detection* mampu untuk menandai objek-objek yang berbeda dan memberikan kotak pembatas (*bounding box*) yang bermanfaat untuk memberikan posisi dan ukuran dari suatu objek tersebut dalam sebuah gambar atau video (Zhao et al., 2019).

Dengan melakukan identifikasi dan mengenali objek dalam sebuah gambar atau video. *Object detection* memungkinkan untuk melakukan pengenalan objek dalam

sebuah gambar atau video, objek yang dapat dikenali juga beragam dari yang besar seperti kendaraan dan hewan hingga yang kecil seperti batu ginjal.

2.10 CNN

Convolutional Neural network (CNN) adalah salah satu metode *neural network* yang memiliki kemampuan untuk mendeteksi objek, ekstraksi objek, dan mengenali objek, CNN juga dapat diterapkan pada data citra yang memiliki resolusi tinggi. CNN terdiri dari beberapa lapisan, termasuk lapisan konvolusi, lapisan pooling, dan lapisan *fully connected* (O'Shea & Nash, 2015). Lapisan konvolusi bertanggung jawab untuk ekstraksi fitur, di mana filter atau kernel diterapkan pada gambar input untuk menghasilkan peta fitur. Proses ini membantu mengidentifikasi pola dasar seperti tepi, tekstur, dan bentuk pada gambar. Lapisan *pooling* kemudian digunakan untuk mengurangi dimensi data, menjaga fitur penting sambil mengurangi kompleksitas komputasi dan risiko *overfitting*.

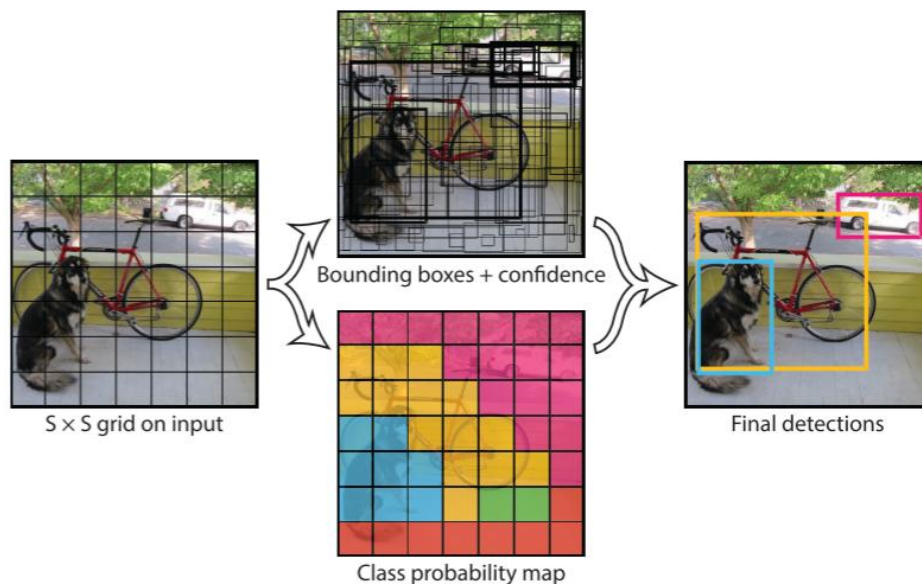


Gambar 2. 8 Arsitektur Umum CNN (O'Shea & Nash, 2015)

2.11 You Only Look Once (YOLO)

Algoritma *You only look once* (YOLO) merupakan metode yang digunakan untuk mendeteksi objek dalam bidang pengolahan citra yang dibuat untuk mendeteksi objek dalam gambar atau video secara *real-time*. Berbeda dengan metode seperti R-CNN (*Region based convolutional Neural Networks*) yang menggunakan pendekatan *Region Proposal* yang digunakan untuk mengidentifikasi dan menghasilkan area dalam gambar yang kemungkinan adalah objek sehingga akan memproses gambar dalam beberapa

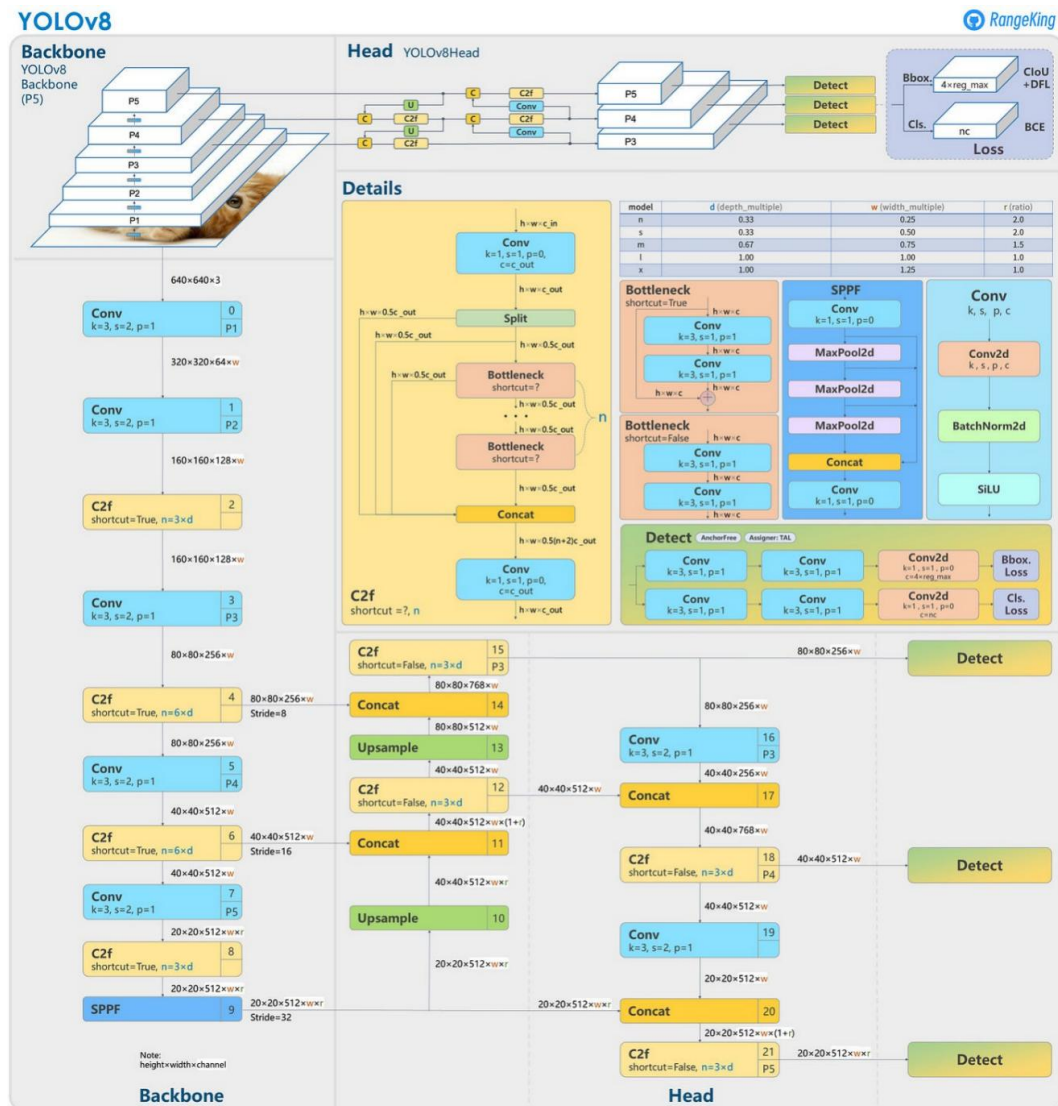
tahap (Redmon et al., 2015). YOLO melakukan deteksi objek hanya dengan sekali lihat pada gambar. Algoritma YOLO akan membagi gambar yang diinput menjadi grid dan untuk setiap sel grid, kemudian YOLO akan memprediksi *bounding box* beserta dengan *confidence score* dan *class probabilities* (Redmon et al., 2015) Cara ini memungkinkan untuk YOLO mampu mendeteksi objek dalam satu kali pemrosesan pada gambar, sehingga mencapai kecepatan yang tinggi tanpa mengurangi akurasi secara signifikan.



Gambar 2. 9 Arsitektur Umum *You Only Look Once* (YOLO) (Redmon et al., 2015)

2.12 You Only Look Once V8 (YOLOV8)

Algoritma YOLOV8 merupakan pengembangan dari metode YOLO yang sudah mengalami peningkatan secara komprehensif dan memiliki banyak hal kemampuan bagi pengguna (Hussain, 2024). Contoh perubahan yang dialami oleh YOLOV8 salah satunya adalah arsitektur *backbone* yang mengalami penyesuaian pada bagian CSPlayer menjadi modul C2F yang membantu menjaga performa *real-time* sambil meningkatkan kualitas deteksi sehingga memiliki manfaat mengalami peningkatan pada performa *real-time*, pengoptimalan sumber daya dan meningkatkan kualitas hasil deteksi.



Gambar 2. 10 Arsitektur Umum You Only Look Once Version 8 (J Solawetz, 2023)

2.13 You Only Look Once V9 (YOLOv9)

Algoritma YOLO v9 merupakan pengembangan dalam pendeteksian objek secara *real-time*, pengembangan dari YoloV9 adalah adanya pengembangan fitur yaitu *Programmable gradient Information* (PGI) dan *Generalized Efficient Layer Aggregation Network* (GELAN). PGI merupakan sebuah inovasi untuk masalah propagasi gradien yang dilakukan layer by layer yang dapat menyebabkan hilangnya informasi penting selama proses propagasi, dengan adanya PGI akan meminimalisir hilangnya informasi selama proses propagasi dikarenakan PGI menggunakan Cabang *Auxiliary Reversible* yang berfungsi untuk jalur alternatif untuk propagasi gradien yang memungkinkan untuk meminimalisir informasi penting hilang dan *Auxiliary Multi level*

information yang memiliki fungsi untuk menggabungkan informasi gradien dari *layer* yang berbeda pada beberapa level sehingga menghasilkan representasi yang informatif (C.-Y. Wang et al., 2024).

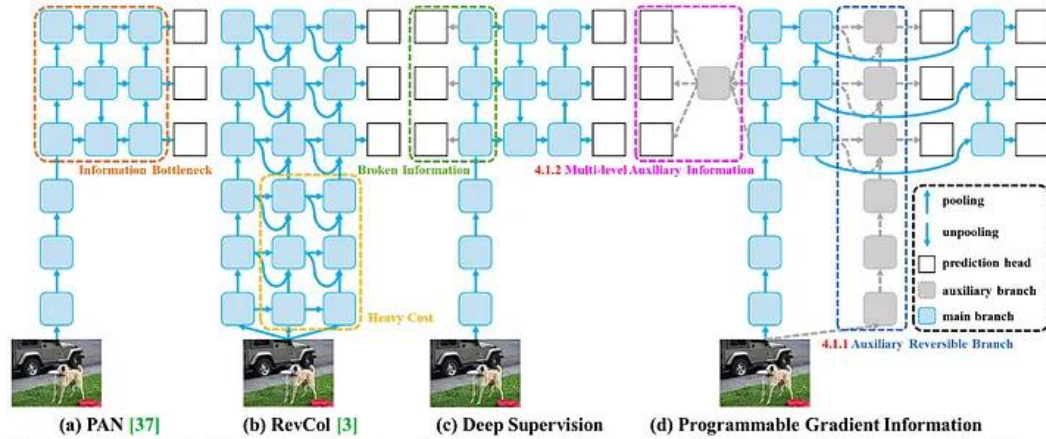


Figure 3. PGI and related network architectures and methods. (a) Path Aggregation Network (PAN)) [37], (b) Reversible Columns (RevCol) [3], (c) conventional deep supervision, and (d) our proposed Programmable Gradient Information (PGI). PGI is mainly composed of three components: (1) main branch: architecture used for inference, (2) auxiliary reversible branch: generate reliable gradients to supply main branch for backward transmission, and (3) multi-level auxiliary information: control main branch learning plannable multi-level of semantic information.

Gambar 2. 11 Arsitektur Umum *Programmable Gradient Information* (PGI) (C.-Y. Wang et al., 2024)

GELAN merupakan sebuah arsitektur inovasi dari yolov9 yang merupakan gabungan dari arsitektur CSPNet dan ELAN (C.-Y. Wang et al., 2024) GELAN memiliki cara kerja dengan cara agregasi fitur langsung yang dimana GELAN tidak lagi bergantung pada propagasi gradien lapis demi lapis. Sebaliknya, GELAN langsung menggabungkan informasi fitur dari berbagai lapisan model secara efisien. Ini memungkinkan informasi penting untuk mencapai lapisan akhir tanpa terdegradasi.

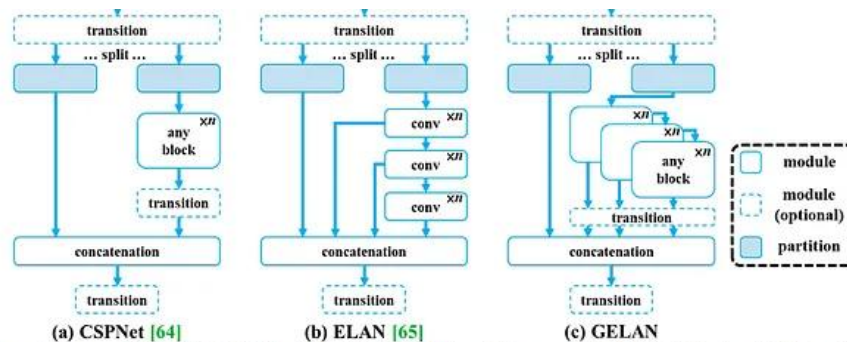


Figure 4. The architecture of GELAN: (a) CSPNet [64], (b) ELAN [65], and (c) proposed GELAN. We imitate CSPNet and extend ELAN into GELAN that can support any computational blocks.

Gambar 2. 12 Arsitektur Umum GELAN (C.-Y. Wang et al., 2024)

2.14 Perbedaan YOLOv8 dan YOLOv9

YoloV8 dan YoloV9 merupakan arsitektur *neural network* yang memiliki tugas yang sama yaitu melakukan pendeteksian objek, Karena YOLOv8 dan YOLOv9

merupakan versi yang dirilis dalam jangka waktu yang berdekatan, kedua versi tersebut hanya memiliki sedikit perbedaan yaitu :

YOLOv8 :

- Pada arsitektur, yoloV8 menggunakan arsitektur *backbone* C2F yang dimana menggunakan 2 cabang berbeda yaitu cabang resolusi tinggi dan cabang resolusi rendah, yang dimana cabang resolusi tinggi berfungsi untuk memproses informasi dan memperhatikan detail spasial yang halus dan cabang resolusi rendah berfungsi untuk mengekstrak fitur semantik tingkat tinggi tentang objek dalam gambar sehingga output dari 2 cabang tersebut akan menghasilkan fitur yang lebih informatik dan fitur gabungan tersebut akan menjadi output dari modul c2f

YOLOv9 :

- Pada arsitektur, yolov9 menggunakan gabungan dari arsitektur CSPnet dan ELAN yang mengambil fitur CSP yang berfungsi untuk membagi blok konvolusi menjadi 2 yaitu jalur reguler dan jalur *shortcut* dan digabungkan kembali yang berfungsi untuk mengurangi jumlah operasi dan meningkatkan efisiensi dan dan fitur EAM (*Efficient Attention Mechanism*) yang berfungsi untuk penggunaan mekanisme yang hemat komputasi untuk fokus pada bagian gambar yang paling relevan dengan deteksi objek sehingga gabungan fitur tersebut akan menghasilkan keseimbangan yang optimal antara efisiensi dan akurasi.

2.15 Confusion Matrix

Algoritma *Confusion Matrix* digunakan untuk memprediksi hasil klasifikasi dengan menghasilkan nilai awal dengan nilai keluaran yang diinginkan guna mengukur kinerja model klasifikasi. Berikut nilai-nilai berikut terbentuk dalam confusion matrix :

- *True Positive* (TP), yaitu Data dengan nilai positif kemudian hasil prediksi bernilai positif
- *True Negative* (TN), yaitu Data dengan nilai negatif kemudian hasil prediksi bernilai negative
- *False Positive* (FP), yaitu Data dengan nilai negatif kemudian hasil prediksi bernilai positif

- *False Negative* (FN), yaitu Data dengan nilai positif kemudian hasil prediksi bernilai negatif

Berikut metode yang digunakan untuk menghitung *confusion matrix* yaitu :

1. Accuracy

Accuracy merupakan evaluasi yang digunakan untuk mengukur kinerja dari model klasifikasi, nilai yang dihasilkan dari jumlah data yang nilai positif dan nilai negatif juga disebut nilai akurasi. Nilai-nilai yang telah keluar ini kemudian akan dibagi dengan jumlah total data yang digunakan pada penelitian.

$$\text{Akurasi} = \frac{\text{Jumlah data yang diprediksi benar}}{\text{Jumlah Keseluruhan data}}$$

2. Precision

Precision merupakan nilai peluang yang diprediksi positif dibandingkan dengan nilai keseluruhan hasil yang diprediksi positif.

$$\text{Precision} = \frac{TP}{TP + FP}$$

3. Recall

Recall merupakan nilai presentase keberhasilan model dalam mengumpulkan informasi yang diinginkan. *Recall* dapat dihitung dengan cara nilai true positive dibagi dengan jumlah *true positive* ditambah dengan *false negative*

$$\text{Recall} = \frac{TP}{TP + FN}$$

4. F1-Score

F1-Score merupakan perbandingan mean dari *precision* dan *recall*.

$$\text{F1 - Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

2.16 Penelitian Terdahulu

Terdapat penelitian terdahulu yang membahas tentang pendeteksian batu ginjal, salah satunya adalah penelitian yang telah dilakukan oleh (Viswanath K & Gunasundari R, 2014) yang bertujuan untuk melakukan pendeteksian batu ginjal pada gambar ultrasound, langkah awal yang dilakukan adalah melakukan segmentasi pada gambar data yang bertujuan untuk mengidentifikasi objek dan penelitian mendapatkan hasil akhir dengan akurasi sebesar 98,8%.

Penelitian selanjutnya yang dilakukan (Thein et al., 2018) yang berjudul “An Image Preprocessing Method for Kidney Stone Segmentation in CT *Scan* Images” melakukan pengujian menggunakan data CT *scan* yang diambil dari atas, kemudian penelitian ini memfokuskan penelitian pada bagian segmentasi menggunakan metode *threshold* yang bertujuan untuk memisahkan struktur organ, tulang, dan bagian pembuluh darah yang dibagi menjadi 3 proses yang bertujuan agar proses menemukan data CT *scan* yang terdapat batu ginjal. Penelitian ini telah melakukan ujicoba pada 30 pasien yang menghasilkan 500 sampai dengan 600 gambar. Pada gambar yang telah dikumpulkan terdapat 500 ribu label, dengan menggunakan algoritma yang telah disiapkan sebelumnya, pada tahap pertama algoritma mampu memisahkan bagian organ tertentu dengan rata-rata mencapai 4300 label, kemudian pada tahap kedua dengan memisahkan bagian tulang hingga menyisakan rata-rata 400 label, sehingga pada tahap terakhir algoritma dapat memisahkan bagian yang tidak diperlukan dan dapat meningkatkan output pada tahap preprocessing. Pada tahap terakhir ini algoritma dapat mengeluarkan gambar yang tidak diperlukan hingga bersisa 25 label pada setiap gambar. Hasil akhir algoritma diujikan terhadap 30 pasien dengan hasil 60 *true positive* dan 3 *false negative*, oleh karena itu didapatkan hasil sensitivitas sebesar 95,24%. Kesimpulan yang didapatkan dari penelitian ini adalah metode segmentasi *threshold* terbukti bagus untuk menghasilkan gambar yang berfokus pada penyakit sehingga hasil yang keluar lebih baik.

Penelitian yang dilakukan oleh (Scholar S, 2020) yang menggunakan dataset gambar CT *scan* yang diambil dari atas melakukan pendeteksian batu ginjal menggunakan metode segmentasi *embossing* dan pengklasifikasian menggunakan SVM. Segmentasi menggunakan *embossing* dilakukan dengan tujuan untuk meningkatkan visibilitas batu ginjal dengan cara meningkatkan kontras antara tepi objek dan latar belakang. Kemudian dataset yang telah disegmentasi akan diklasifikasikan menggunakan algoritma SVM. Penelitian ini menggunakan data *training* dengan menggunakan 156 gambar ct *scan* yang terdiri dari 78 gambar yang terkena batu ginjal dan 78 gambar yang sehat, kemudian pada 156 data tersebut didapatkan hasil akurasi 98,71% dengan total 76 *true positive*, 78 *true negative*, 2 *false positive*, dan 0 *false negative*.

Penelitian yang dilakukan oleh (Yildirim et al., 2021) yang berjudul “Deep Learning Model for Automated Kidney Stone Detection Using Coronal CT Images” menggunakan dataset berupa gambar CT *scan* yang diambil dari depan. Data yang dikumpulkan didapatkan dari pasien rumah sakit di turki, penelitian ini menekankan dalam implementasi algoritma Xresnet-50 untuk melakukan pendeteksian pada batu ginjal. Hasil dari penelitian adalah yang diujicoba pada 346 didapatkan hasil akurasi 96.82%

Kemudian penelitian oleh (Aulia et al., 2022) yang berjudul “Implementasi Algoritma Convolutional Neural Network Untuk Mendeteksi Penyakit Ginjal” menggunakan dataset CT *scan* yang diambil dari atas menggunakan algoritma CNN untuk melakukan pengklasifikasian terhadap penyakit ginjal yaitu ginjal yang terkena kista, terkena batu ginjal, terkena tumor, dan ginjal yang normal, hasil penelitian yang dilakukan didapatkan hasil *f1 score* sebesar 68%

Kemudian penelitian yang dilakukan oleh (F. Wang et al., 2023) dengan judul “Lightweight Framework for Automated Kidney Stone Detection Using Coronal CT Images” melakukan pendeteksian terhadap penyakit batu ginjal menggunakan data CT *scan* yang diambil dari depan menggunakan gabungan dari algoritma yolov8 dan mobilenet untuk melakukan pendeteksian dan pengklasifikasian, hasil dari penelitian didapatkan hasil F1 Score sebesar 95,94%

Tabel 2. 1 Penelitian Terdahulu

No	Penulis (Tahun)	Metode	Judul	Hasil
1	(Viswanath K & Gunasundari R, 2014)	ANN	<i>Design and analysis performance of Kidney Stone Detection from Ultrasound Image by Level Set Segmentation and ANN Classification</i>	Melakukan pendeteksian batu ginjal dari gambar usg dan mendapatkan hasil 98,8%.

No	Penulis (Tahun)	Metode	Judul	Hasil
2	(Thein et al., 2018)	<i>Pre-Processing Threshold</i>	<i>An image preprocessing method for kidney stone Segmentation in CT scan images</i>	Membagi dan memisahkan antara organ dan tulang agar pendeteksian batu ginjal dapat mudah dilakukan, hasil didapatkan tingkat sensitivitas mencapai 95,24%
3	(Sowjanya et al., 2023)	CNN	<i>DeepKidney: Multiclass Classification of Kidney Stones, Cyst Tumors, and Normal Cases Using Convolutional Neural Networks</i>	Mengklasifikasikan Ginjal yang sehat, terkena tumor, batu ginjal, dan terkena kista menggunakan algoritma CNN, Hasil yang didapatkan pada penelitian ini adalah akurasi sebesar 98,91%
4	(Soni Scholar, 2020)	SVM	<i>Kidney Stone Recognition and Extraction using Directional Emboss & SVM from Computed Tomography Images</i>	berhasil menggunakan filter emboss untuk menemukan batu ginjal dengan cara gambar akan timbul ditunjukkan oleh gambar datar dan kemiringan di sekitarnya. Kemudian gambar yang berhasil diemboss akan disegmentasi dan dideteksi menggunakan algoritma SVM, hasil penelitian ini menunjukkan akurasi 98,71%, mendapatkan hasil sensitivitas 100% dan spesifisitas 97,5%.

No	Penulis (Tahun)	Metode	Judul	Hasil
5	(Yildirim et al., 2021a)	Xresnet-50	<i>Deep learning model for automated kidney stone detection using coronal CT images</i>	Penelitian ini menggunakan gambar ct scans yang diambil dari depan berhasil mengimplementasikan algoritma Xresnet-50. Dengan algoritma Xresnet- 50 didapatkan akurasi sebesar 96,81% dan F1 Score sebesar 97%
6	(Aulia et al., 2022)	CNN	<i>Implementasi Algoritma Convolutional Neural Network Untuk Mendeteksi Penyakit Ginjal</i>	Penelitian Melakukan segmentasi thresholding dan Menggunakan algoritma CNN untuk melakukan pengklasifikasian dan mendapatkan akurasi sebesar 75,17%
7	(F. Wang et al., 2023)	YoloV8	<i>LIGHT WEIGHT FRAMEWORK OR AUTOMATED KI DNEY STONE DETECTION USING CORONAL CT IMAGES</i>	Menggunakan YoloV8 untuk melakukan deteksi dan mobilnet untuk pengklasifikasian untuk data Coronal CT Image yang dibagi menjadi 3 yaitu data <i>training</i> (1163 gambar), data <i>validation</i> (290 Gambar), dan data testing (346 Gambar). Hasil didapatkan F1 Score sebesar 95,94%.

Adapun perbedaan penelitian ini dengan penelitian sebelumnya seperti (Aulia et al., 2022) yang melakukan pengklasifikasian penyakit ginjal berupa kista, tumor, batu ginjal, dan normal dengan menggunakan pendekatan *Convolutional Neural Network* (CNN) . Kemudian penelitian yang dilakukan oleh (F. Wang et al., 2023b) melakukan


pengklasifikasian penyakit ginjal berupa batu ginjal dan normal menggunakan pendekatan YOLO v8. Sedangkan penelitian ini melakukan pengklasifikasian penyakit ginjal berupa kista, tumor, batu ginjal, dan normal dengan menggunakan pendekatan YOLO v9.

BAB 3

ANALISIS DAN PERANCANGAN SISTEM

3.1 Dataset

Data input yang digunakan adalah data yang berupa citra ginjal dari hasil CT *Scan* yang terkena penyakit Kista, Tumor, dan batu ginjal serta ginjal yang sehat. Pengumpulan data dilakukan dengan mengambil dari Kaggle dan Rumah sakit Putri Bidadari. Seluruh data yang dikumpulkan berekstensi JPG. Contoh data citra dapat dilihat pada gambar 3.1



Gambar 3. 1 Contoh dataset yang akan digunakan

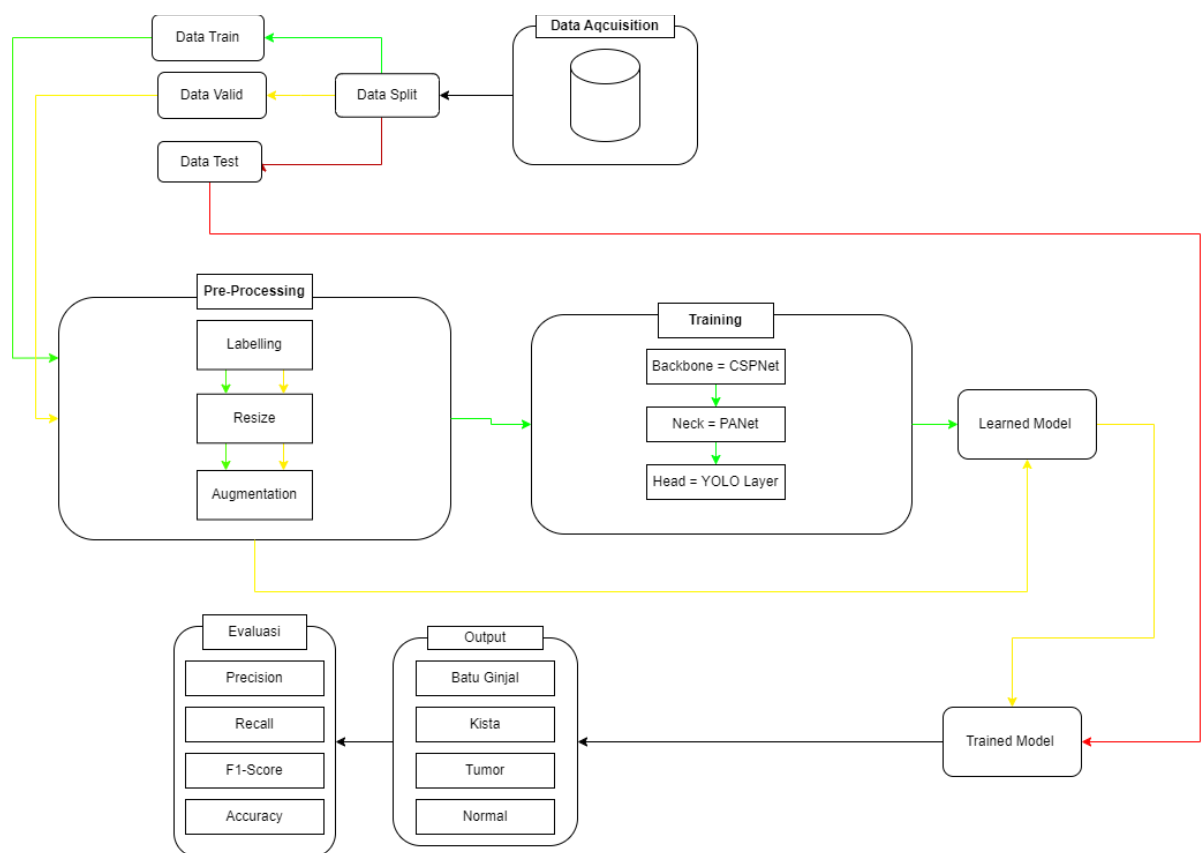
Pada Penelitian ini, peneliti menggunakan empat jenis penyakit pada ginjal, yaitu batu ginjal, tumor, normal, dan kista. Terdiri dari 3600 data gambar. Dari total 3600 data gambar, data tersebut kemudian dibagi menggunakan rasio 80/10/10 yang memiliki rasio data split dengan performa terbaik (Golchubian et al., 2021), menjadi 2880 untuk data *training*, 360 untuk data *validation*, dan 360 untuk data *testing*.

Tabel 3. 1 Data Split

	Train	Validation	Test	Total
Batu Ginjal	776	97	97	970
Tumor	672	84	84	840
Normal	768	96	96	960
Kista	674	83	83	830
TOTAL	2880	360	360	3600

3.2 Analisis Sistem

Dalam penelitian ini, dataset yang diperoleh akan dibagi menjadi tiga bagian: data *training*, data *validation*, dan data *testing*. Data *training* dan data *validation* digunakan selama proses pelatihan model, sedangkan data *testing* hanya digunakan pada tahap pengujian untuk mengevaluasi kinerja model.



Gambar 3. 2 Arsitektur Umum

3.2.1 Data Acquisition

Berdasarkan analisis yang sudah dilakukan sebelumnya, dilakukan pengambilan data yang kemudian dilakukan data yang diambil akan dikelompokkan menjadi data *training*, data *validation*, dan data *testing*. Data *training* akan digunakan untuk melatih data agar dapat digunakan untuk melakukan pengujian, kemudian data validasi digunakan untuk memastikan bahwa data *training* yang digunakan sudah

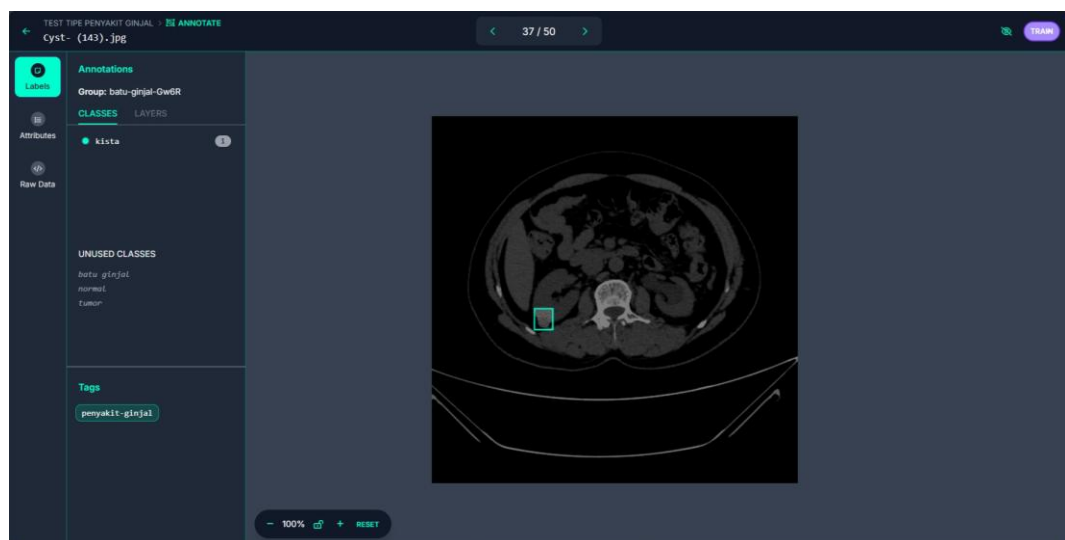
benar, dan data testing digunakan untuk menguji data *training* menggunakan data yang belum pernah diuji oleh model sebelumnya. Data ini akan digunakan untuk mengukur seberapa baik kinerja model tersebut.

3.2.2 Image *Pre-Processing*

Pada tahap *pre-processing*, dataset yang telah diambil akan dilakukan perubahan kualitas dan perubahan pada bentuk data agar algoritma dapat mudah mempelajari data, *Pre-processing* yang dilakukan oleh peneliti adalah meliputi :

a) Labelling

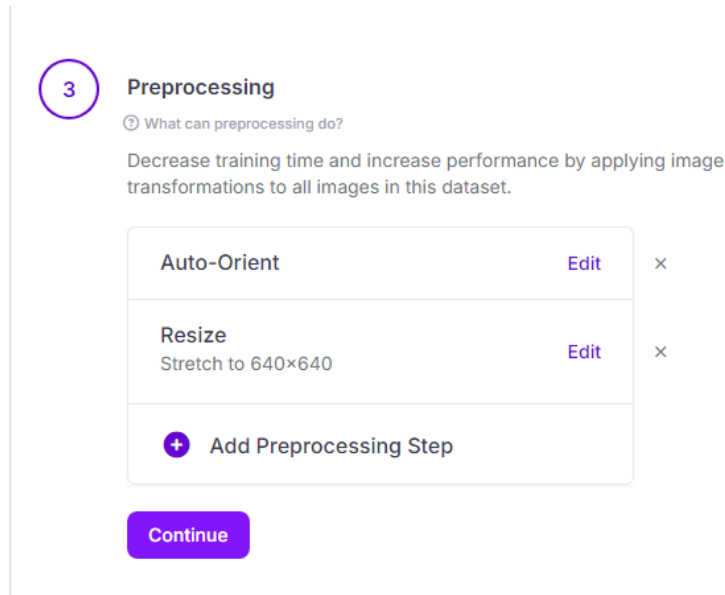
Labelling merupakan proses memberikan label kepada data. Proses *labelling* dilakukan dengan tujuan untuk memberikan konteks pada data mentah. Dengan adanya pemberian konteks pada data mentah, *labelling* bermanfaat untuk membantu model untuk memahami data dan mempermudah untuk proses *training*. Pada penelitian ini, pelabelan data dilakukan dengan menggunakan aplikasi ‘Labelme’. Pada umumnya, anotasi yang telah dilakukan akan disimpan sebagai file XML dalam format PASCAL VOC. Pelabelan dilakukan dengan cara memberikan *bounding box* data gambar CT scan dengan label penyakit yang ada. Pemberian *bounding box* dilakukan pada area yang memiliki informasi penting mengenai penyakit ginjal.




Gambar 3. 3 Pemberian Label dan *Bounding Box* pada citra

b) Resizing

Resizing merupakan salah satu dari metode *pre-processing* yang akan digunakan pada penelitian ini. Tahap *Resizing* akan mengubah ukuran data citra sesuai dengan kebutuhan penelitian, pada penelitian ini ukuran yang akan digunakan adalah 640x640 piksel



Gambar 3. 4 Tahap *Resizing*



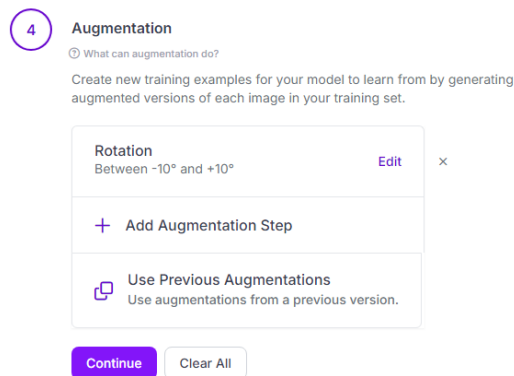
Gambar 3. 5 Contoh data citra sebelum dan sesudah *resize*

c) Augmentation


Augmentation merupakan proses *pre-processing* yang digunakan untuk menambahkan jumlah data dan meningkatkan variasi data latih dengan membuat modifikasi pada data yang ada. Tujuan dilakukan *augmentation* adalah untuk memperluas informasi terkait data latih dengan cara yang realistis sehingga model yang dilatih menjadi lebih umum, lebih terbiasa terhadap variasi, dan lebih baik

menggeneralisasi pada data baru nanti.

Teknik augmentasi yang digunakan pada penelitian ini adalah *rotate*. Augmentasi *rotate* adalah teknik augmentasi data yang melibatkan perputaran gambar dalam berbagai sudut. Pada penelitian ini, sudut yang digunakan adalah 10 dan -10.



Gambar 3. 6 Tahap Augmentasi



Gambar 3. 7 Contoh data citra sebelum dan setelah Augmentasi

3.2.3 Image Classification

Kemudian setelah tahap *pre-processing* dilakukan, tahap ini akan dilakukan pengklasifikasian pada kelasnya menggunakan algoritma YoloV9, Adapun proses yang ada pada tahapan ini adalah :

A. *Backbone* (CSPNet)

CSPNet (*Cross Stage Partial Network*) adalah arsitektur jaringan saraf dalam yang inovatif yang dirancang untuk meningkatkan efisiensi dan akurasi deteksi objek. Pertama kali diperkenalkan dalam paper "YOLOv9: A *High-Performance Detector with Cross-Stage Partial Network*" pada tahun 2024.

CSPNet bekerja dengan membagi feature map dari layer awal menjadi dua jalur. Jalur pertama diproses melalui blok Dense parsial dan lapisan transisi, sementara jalur kedua langsung digabungkan dengan feature map yang diteruskan ke tahap selanjutnya. Dalam konteks klasifikasi penyakit ginjal, pendekatan ini memungkinkan CSPNet untuk secara efisien mengintegrasikan informasi dari berbagai tahap pemrosesan, sehingga model dapat mengenali pola-pola penting dalam gambar CT *scan* ginjal, seperti tekstur atau bentuk yang khas dari batu ginjal, kista, tumor, atau ginjal normal, dengan representasi fitur yang lebih kaya dan akurat.

Dalam CSPNet, GELAN (*Generalized Efficient Layer Aggregation Network*) berfungsi sebagai komponen inti yang mendukung peningkatan efisiensi dan akurasi dalam deteksi objek pada YOLOv9. GELAN mengintegrasikan berbagai blok komputasi, seperti convolutional layers, pooling layers, dan activation functions, dengan cara yang fleksibel dan efisien.

Pada kasus klasifikasi penyakit ginjal, kemampuan GELAN untuk memilih blok komputasi yang optimal dan menggabungkan informasi dari berbagai lapisan jaringan membantu model mengenali detail penting dalam gambar CT scan, seperti tekstur, pola, atau bentuk khas dari batu ginjal, kista, tumor, atau ginjal normal. Dengan keseimbangan antara akurasi dan kecepatan yang dioptimalkan, GELAN memungkinkan deteksi yang lebih efektif, meningkatkan performa model dalam membedakan berbagai kondisi ginjal.

B.Neck

Pada YOLOv9, *neck* terinspirasi oleh arsitektur PANet dan dirancang menggunakan struktur PAN-FPN (Path Aggregation Network with Feature Pyramid Network), mirip dengan yang digunakan pada YOLOv8. Struktur PAN-FPN ini mengintegrasikan pendekatan top-down dan bottom-up untuk menggabungkan informasi dari fitur dangkal, seperti detail posisi, dengan informasi semantik mendalam. Proses ini menghasilkan fitur yang lebih kaya dan bervariasi. Dalam klasifikasi penyakit ginjal berbasis gambar CT *scan*, peran *neck* memungkinkan sistem untuk lebih akurat memprediksi kondisi ginjal, termasuk area kecil seperti batas kista atau detail pada batu ginjal. Penambahan layer dalam neck juga membentuk pyramid feature yang dirancang untuk meningkatkan kemampuan deteksi pada piksel kecil, yang sangat penting untuk segmentasi gambar medis.

Dibandingkan dengan neck pada YOLOv5 dan YOLOv7, YOLOv8 telah menghapus operasi konvolusi setelah pengambilan sampel dalam struktur PAN, membuat model lebih ringan tanpa mengorbankan performa. Modifikasi ini dilanjutkan pada YOLOv9 untuk memperbaiki akurasi, sehingga sistem dapat mendeteksi dan mengklasifikasikan penyakit ginjal dengan lebih efisien dan akurat.

C.Head


Pada tahap ini, proses menghasilkan kotak deteksi dilakukan untuk menentukan koordinat *bounding box* pada objek yang terdeteksi dan menghitung *confidence score* untuk setiap kelas. Dalam konteks klasifikasi penyakit ginjal berdasarkan gambar CT scan, *bounding box* akan digunakan untuk menyoroti area spesifik pada ginjal, seperti lokasi batu ginjal, kista, atau tumor. Setiap kotak deteksi direpresentasikan oleh tujuh vektor, di mana setiap vektor menunjukkan koordinat atau atribut tertentu dari bounding box. Selain itu, fungsi IOU (*Intersection Over Union*) diterapkan untuk mengevaluasi tumpang tindih antar kotak dan memastikan deteksi hanya pada area yang relevan. Fungsi *non-max suppression* juga digunakan untuk menghindari keberadaan kotak deteksi yang berlebihan dan tumpang tindih, sehingga hanya kotak dengan confidence score tertinggi yang dipertahankan. Pendekatan ini membantu model memberikan hasil deteksi yang lebih akurat dan terorganisir, yang sangat penting dalam identifikasi detail penyakit ginjal pada citra medis.

3.3 Perancangan Antarmuka Sistem

Pada tahap ini, peneliti melakukan perancangan untuk antarmuka dari website pengklasifikasian penyakit ginjal yang akan diberi nama CTScanAI. Rancangan ini bertujuan sebagai gambaran dari website yang akan dibangun. Aplikasi ini dirancang oleh peneliti dengan tampilan halaman home, halaman about, halaman predict, dan halaman hasil

3.3.1 Tampilan Halaman Home

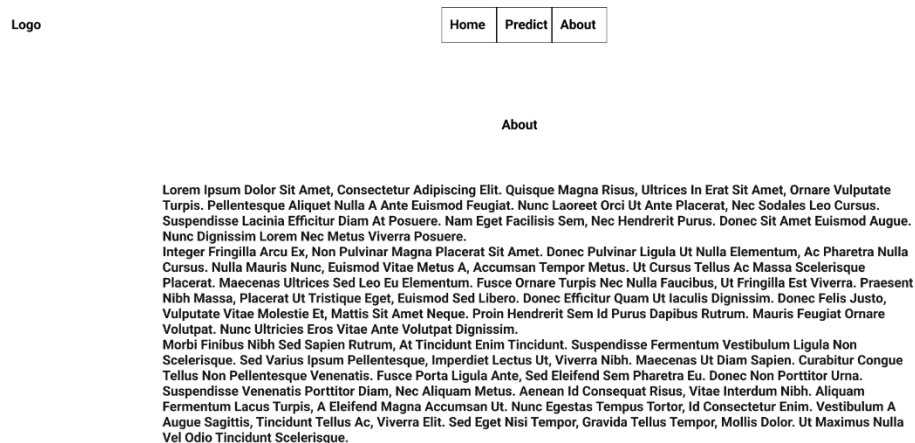
Tampilan Halaman Home adalah halaman utama dari website CTScanAI. Halaman ini berisikan navbar yang tersambung ke halaman About dan halaman predict.



Gambar 3. 8 Tampilan Halaman Home

3.3.2 Tampilan Halaman About

Tampilan Halaman About adalah tampilan halaman yang berisi tentang informasi website dan terdapat pembelajaran cara menggunakan website sehingga pengguna tidak kesulitan dan dapat memahami cara kerja dari website tersebut.

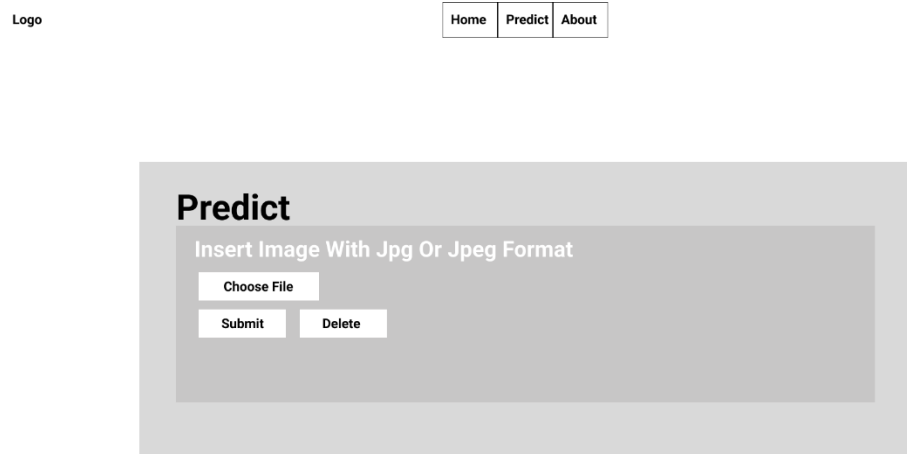


Gambar 3. 9 Tampilan Halaman About

3.3.3 Tampilan Halaman Predict

Pada Tampilan ini, pengguna dapat memasukkan gambar untuk dilakukan


pengklasifikasian, pada tampilan ini terdapat tombol *choose file* untuk memilih gambar yang akan dipilih, kemudian terdapat tombol submit apabila gambar akan diklasifikasi dan tombol *reset* apabila gambar tidak jadi untuk diklasifikasikan.



Gambar 3. 10 Tampilan Halaman *Predict*

3.3.4 Tampilan Halaman Hasil

Pada tampilan halaman hasil, gambar yang telah dipredict akan muncul di halaman ini dengan tampilan gambar yang telah diklasifikasi, terdapat *button download* untuk mengunduh gambar yang telah diklasifikasikan untuk diteliti lebih lanjut.



Gambar 3. 11 Tampilan Halaman Hasil

BAB 4

IMPLEMENTASI DAN PENGUJIAN

Pada bab ini, akan dibahas implementasi arsitektur YOLOv9 dalam proses klasifikasi penyakit ginjal menggunakan data citra CT *scan*. Selain itu, juga disajikan hasil pengujian sistem yang telah dirancang pada Bab 3 untuk mengevaluasi performa model dalam mendeteksi dan mengklasifikasikan penyakit ginjal berdasarkan data yang digunakan.

4.1 Implementasi Sistem

Pada Tahap Implementasi Sistem, Sistem akan digunakan untuk menentukan jenis penyakit ginjal yang dimiliki pasien, implementasi dilakukan dengan menggunakan Bahasa pemrograman Python dan output akan berbentuk website dengan menggunakan framework Flask. Berikut Hardware dan software yang peneliti gunakan dalam penelitian ini :

1. Laptop
2. Processor : Intel® Core™ i7-6700 HQ 2.6Ghz
3. GPU : Nvidia GeForce GTX 960m
4. Storage : 1 Tb SSD
5. Ram : 16 Gb
6. OS : Windows 10
7. Kaggle
8. Visual Studio Code

4.2 Implementasi Data


Data yang digunakan dalam penelitian ini diperoleh dari *platform Kaggle*. Data citra yang digunakan merupakan citra CT *Scan* pada ginjal yang normal dan ginjal yang terkena tumor, terkena kista, dan terkena batu ginjal. Seluruh

gambar yang digunakan berformat .jpg dengan total keseluruhan gambar 3600 gambar dengan gambar per kelas berjumlah 900 gambar.

4.3 Implementasi Perancangan Antarmuka

4.3.1 Tampilan Halaman Home

Tampilan Halaman Home merupakan tampilan utama dari aplikasi. Tampilan home berisikan informasi singkat mengenai aplikasi dan terdapat navbar yang akan mengarah ke halaman home, halaman predict, dan halaman about.



Gambar 4. 1 Tampilan Halaman Home

4.3.2 Tampilan Halaman About

Tampilan Halaman About adalah tampilan halaman yang berisi tentang informasi website dan terdapat pembelajaran cara menggunakan website sehingga pengguna tidak kesulitan dan dapat memahami cara kerja dari website secara bertahap dari website tersebut.



Gambar 4. 2 Tampilan Halaman about

4.3.3 Tampilan Halaman Predict

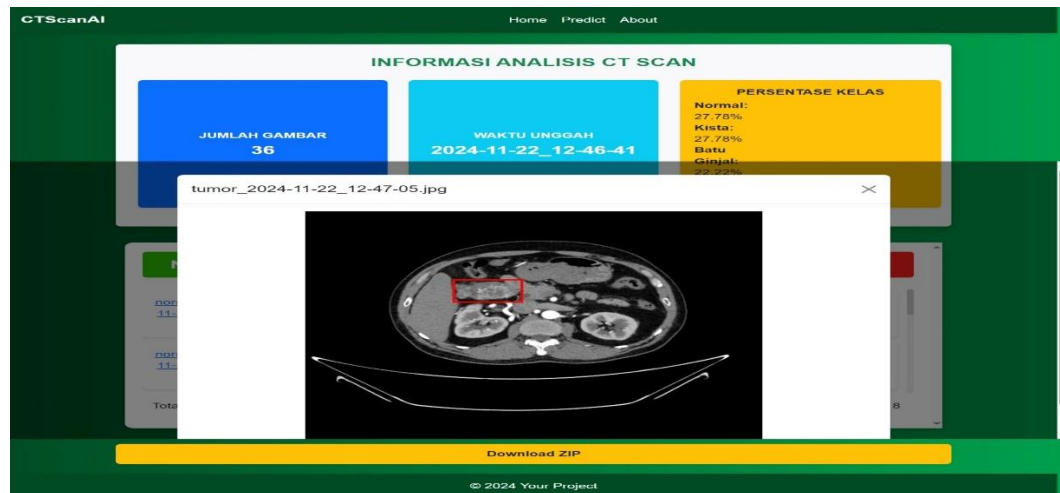
Pada tampilan halaman predict berisikan tempat untuk meletakkan gambar *ct scan* yang nantinya akan diproses dan hasilnya akan keluar di halaman hasil yang dapat dilihat pada gambar 4.4



Gambar 4. 3 Tampilan Halaman Predict

4.3.4 Tampilan Halaman Hasil

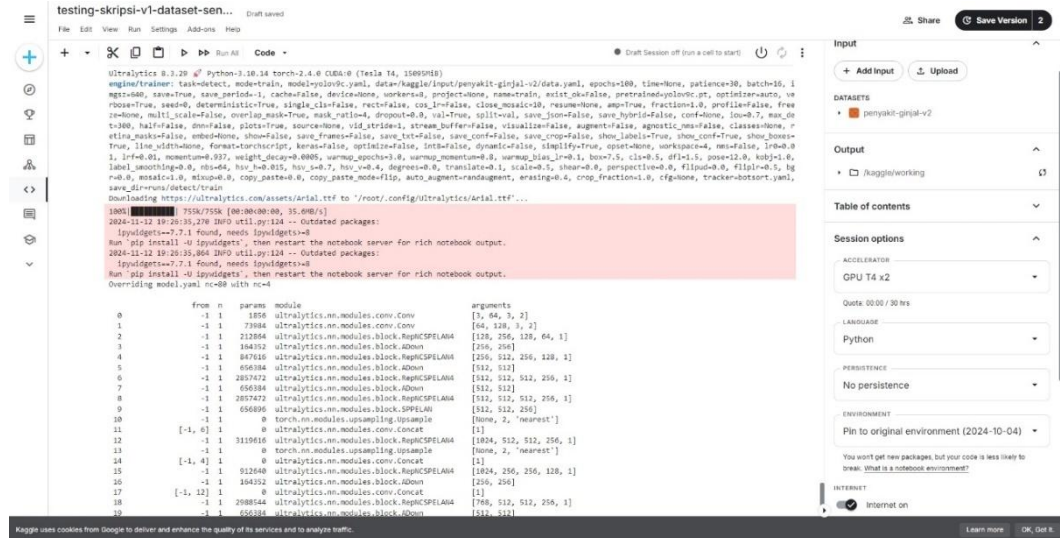
Pada tampilan halaman hasil memuat informasi mengenai analisis *ct scan* yang berisikan jumlah gambar, waktu unggah, dan persentase kelas dari gambar yang diinput. Kemudian gambar yang telah diklasifikasi dapat dilihat pada card yang telah diberi kelas masing-masing yang Ketika ditekan akan muncul seperti pada gambar 4.5



Gambar 4. 4 Tampilan Halaman Hasil

4.4 Pelatihan Sistem

Pelatihan Sistem merupakan Langkah dalam pelatihan model agar model dapat mengenali objek. Sebelum melalui tahap pelatihan sistem, data yang digunakan sudah melalui tahap *pre-processing*. Pelatihan sistem ini dilakukan menggunakan Kaggle sebagai alat bantu dan model pre-trained yoloV9c.pt, Yang merupakan model dari YOLOv9



Gambar 4. 5 Kaggle

Kaggle menyediakan Framework Pytorch dan runtime GPU NVIDIA dengan dukungan CUDA secara gratis, dengan batas waktu penggunaan 9 jam per sesi, Kaggle juga menyediakan T4 Runtime type secara gratis dengan batas waktu penggunaan 30 jam perminggu.

Proses pelatihan dilakukan sebanyak Sembilan kali dengan konfigurasi nilai epoch dan batch size yang berbeda untuk mendapatkan nilai akurasi yang optimal, nilai epoch yang digunakan adalah 30,50, dan 100 dengan setiap epoch menggunakan batch size sebesar 8,16, dan 32. Hasil percobaan dapat dilihat pada table 4.1

Tabel 4. 1 Hasil Percobaan *Training*


<i>Epoch</i>	<i>Batch Size</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>
30	8	0.9424	0.95139	0.94687
50	8	0.94106	0.9641	0.9524
100	8	0.95748	0.95654	0.95701
30	16	0.95624	0.9594	0.9578
50	16	0.94612	0.9646	0.955290
100	16	0.96795	0.956	0.96151
30	32	0.94215	0.95035	0.94624.
50	32	0.9568	0.95624	0.95652.
100	32	0.94288	0.94118	0.94203.

Setelah melalui seluruh proses pelatihan yang terlihat pada tabel 4.1 maka didapatkan model terbaik dari berbagai *batch* dan *epoch* dengan Batch size sebesar 16 dengan jumlah *epoch* sebesar 100 dengan hasil nilai mAP 0.95329, nilai mAP50 – 95 0.6923, nilai precision 0.96795, dan nilai recall 0.956. proses pelatihan memakan waktu selama 3 jam 30 menit dengan penggunaan *GPU* menggunakan T4 dan memakan *VRAM* sebanyak 15gb. Model dengan hasil terbaik akan disimpan model yang dinamakan best.pt grafik dari hasil proses pelatihan dapat dilihat pada gambar 4.7

```
100 epochs completed in 3.507 hours.
Optimizer stripped from runs/detect/train/weights/last.pt, 51.6MB
Optimizer stripped from runs/detect/train/weights/best.pt, 51.6MB

Validating runs/detect/train/weights/best.pt...
WARNING ⚠ validating an untrained model YAML will result in 0 mAP.
Ultralytics 8.3.21 🚀 Python-3.10.14 torch-2.4.0 CUDA:0 (Tesla T4, 15095MiB)
YOLOv9c summary (fused): 384 layers, 25,322,332 parameters, 0 gradients, 102.3 GFLOPs
```

Gambar 4. 6 Jenis *GPU* dan Jumlah *VRAM* yang digunakan



Gambar 4. 7 Grafik Pelatihan

Pada Gambar 4.5 di atas, terlihat bahwa grafik precision dan recall menggambarkan peningkatan akurasi model yang berlangsung dengan cepat pada tahap awal pelatihan, kemudian stabil. Hal ini menunjukkan bahwa model mampu mendeteksi sebagian besar instance positif dalam dataset. Grafik mAP50 juga menunjukkan peningkatan signifikan selama iterasi awal pelatihan, lalu stabil pada nilai tinggi, yang mengindikasikan performa deteksi model yang baik pada ambang batas IoU (Intersection over Union) sebesar 0.50.

Selain itu, pada grafik mAP50-95 terlihat adanya peningkatan yang konsisten, yang mengindikasikan kemampuan model dalam mendeteksi dengan baik pada berbagai ambang batas IoU. Secara keseluruhan, grafik pada Gambar 4.5 menunjukkan tren peningkatan yang stabil di awal pelatihan, lalu menjadi konstan seiring bertambahnya iterasi.

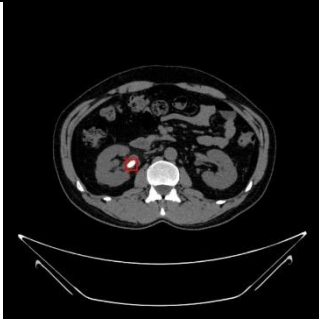
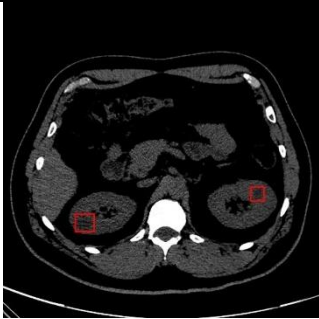
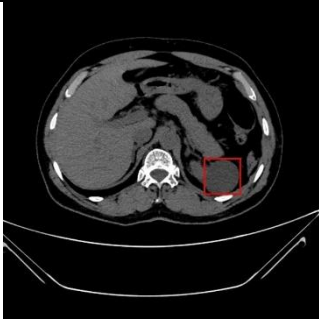
Pada tahap awal pelatihan, terdapat fluktuasi yang cukup signifikan pada nilai metrik, karena model masih berada dalam tahap awal pembelajaran dan mencoba menyesuaikan parameter-parameter. Setelah melalui beberapa iterasi, metrik-metrik tersebut mencapai nilai maksimum dan menjadi stabil, menandakan bahwa model telah mencapai kemampuan optimalnya dalam mendeteksi sesuai dengan dataset yang diberikan.

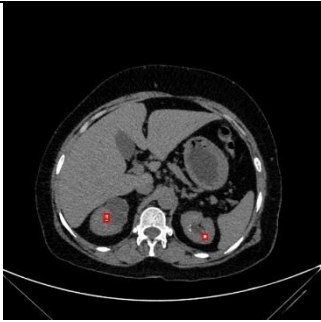

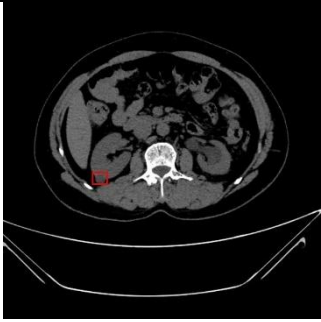


4.5 Pengujian Sistem

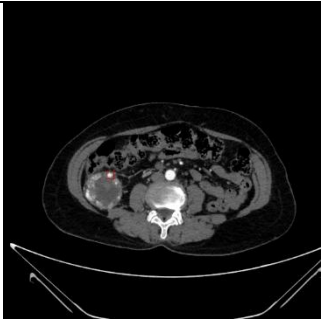

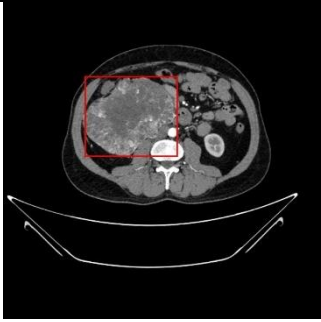
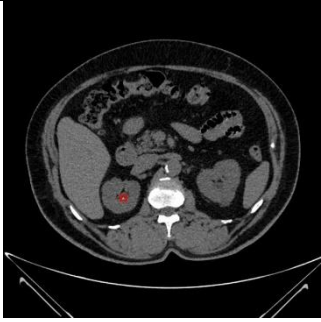

Pada Tahap Pengujian Sistem, model terbaik selama tahap pelatihan system akan digunakan untuk mengukur kemampuan system dalam mengklasifikasi 4 jenis penyakit yang menjangkit ginjal berdasarkan gambar *CT Scan* yaitu tumor, kista, batu ginjal, atau normal .

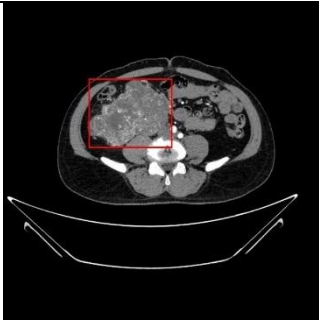
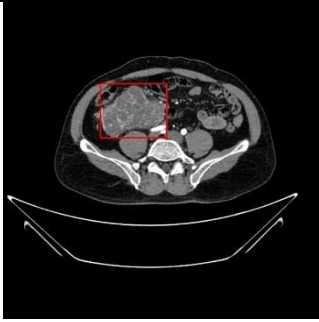

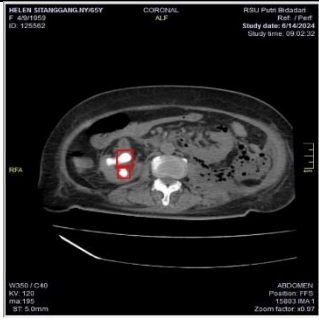
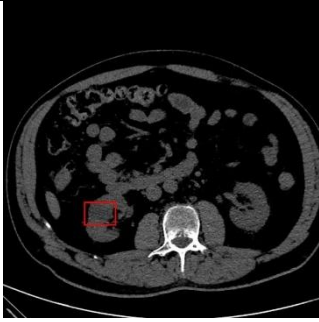
4.5.1 Pengujian Akurasi

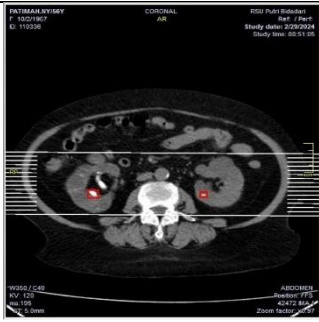

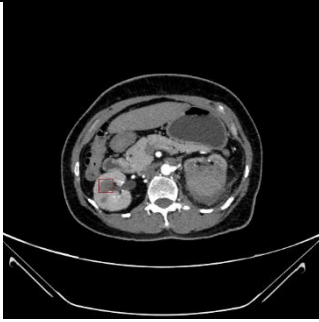
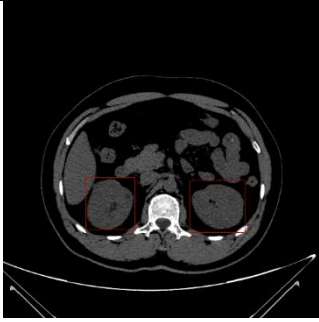
Tabel 4. 2 Hasil Uji Sistem

No	Data	Aktual	Prediksi	Status
1		Batu Ginjal	Batu Ginjal	Benar
2		Kista	Kista	Benar
3		Kista	Kista	Benar

4		Batu Ginjal	Batu Ginjal	Benar
5		Normal	Batu Ginjal	Salah
6		Kista	Kista	Benar
7		Normal	Normal	Benar
8		Batu Ginjal	Batu Ginjal	Benar

9		Tumor	Batu Ginjal	Salah
10		Tumor	Tumor	Benar
11		Tumor	Tumor	Benar
12		Batu Ginjal	Batu Ginjal	Benar
13		Normal	Normal	Benar

14		Tumor	Tumor	Benar
15		Tumor	Tumor	Benar
16		Normal	Normal	Benar
17		Batu Ginjal	Batu Ginjal	Benar
18		Kista	Kista	Benar

19		Batu Ginjal	Batu Ginjal	Benar
20		Batu Ginjal	Batu Ginjal	Benar
21		Tumor	Kista	Salah
22		Kista	Normal	Salah

Tabel 4. 3 *Confusion Matrix*

		Aktual				Total
		Batu Ginjal	Kista	Normal	Tumor	
Prediksi	Batu Ginjal	89	6	3	2	100
	Kista	6	67	1	7	81
	Normal	1	10	89	0	100
	Tumor	1	0	3	75	79
Total		97	83	96	84	360

Pada *Confusion matrix* yang telah diuji yang dapat dilihat pada table 4.3, tercatat ada beberapa kesalahan dalam mengklasifikasi penyakit pada ginjal, dari total 360, terdapat beberapa kesalahan terutama dalam mendeteksi batu ginjal dikarenakan adanya kesamaan antara penyakit dan *background*, dan beberapa kesalahan pada penyakit lain dikarenakan adanya kemiripan antara warna penyakit dan warna pada ginjal, hal tersebut menyebabkan *confidence score* yang rendah sehingga menyebabkan adanya kesalahan dalam pemberian *bounding box*

Tabel 4. 4 Nilai Pengujian TP, FP, FN

	TP	FP	FN
Batu Ginjal	89	8	11
Kista	67	16	14
Tumor	89	7	13
Normal	75	9	12
Total	320	40	50

Berdasarkan tabel 4.4 dapat dilihat bahwa 320 data tergolong sebagai *True Positive* yang berarti data prediksi sesuai dengan data hasilnya, dan sebanyak 40 data bernilai *False Positive* yang Dimana data yang bernilai negatif

dikenali bernilai positif oleh sistem, dan 50 data yang bernilai *False Negative* yang Dimana data yang seharusnya bernilai positif diberi nilai negatif oleh sistem. Dari nilai yang telah didapatkan dapat diperoleh nilai precision, recall, dan *F1-Score* melalui perhitungan berikut.

1. Precision

$$Precision = \frac{TP}{TP+FP}$$

$$Precision \text{ Batu Ginjal} = \frac{89}{97} \times 100\% = 91.75\%$$

$$Precision \text{ Kista} = \frac{67}{83} \times 100\% = 80.72\%$$

$$Precision \text{ Tumor} = \frac{75}{84} \times 100\% = 89.29\%$$

$$Precision \text{ Normal} = \frac{89}{96} \times 100\% = 92.71\%$$

2. Recall

$$Recall = \frac{TP}{TP+FN}$$

$$Recall \text{ Batu ginjal} = \frac{89}{100} \times 100\% = 89\%$$

$$Recall \text{ kista} = \frac{67}{81} \times 100\% = 82.72\%$$

$$Recall \text{ Tumor} = \frac{75}{87} \times 100\% = 86.21\%$$

$$Recall \text{ Normal} = \frac{89}{102} \times 100\% = 87.25\%$$

3. F1-Score

$$F1 - Score = 2 \times \frac{Recall \times Precision}{Recall+Precision}$$

$$F1 - Score \text{ Batu ginjal} = \left(2 \times \frac{0.9175 \times 0.89}{0.9175 + 0.89} \right) \times 100\% = 90.35\%$$

$$F1 - Score \text{ Kista} = \left(2 \times \frac{0.8072 \times 0.8272}{0.8072 + 0.8272} \right) \times 100\% = 81.71\%$$

$$F1 - Score \text{ Tumor} = \left(2 \times \frac{0.8929 \times 0.8621}{0.8929 + 0.8621} \right) \times 100\% = 87.72\%$$

$$F1 - Score \text{ Normal} = \left(2 \times \frac{0.9271 \times 0.8725}{0.9271 + 0.8725} \right) \times 100\% = 89.90\%$$

Dari seluruh perhitungan yang sudah dilakukan, maka nilai nilai tersebut dapat dirangkum pada tabel 4.5

Tabel 4. 5 Nilai *Precision*, *Recall*, dan *F1-Score*

	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>
Batu Ginjal	91.75%	89%	90.35%
Kista	80.72%	82.72%	81.71%
Tumor	89.29%	86.21%	87.72%
Normal	92.71%	87.25%	89.90%

Tujuan mengetahui recall adalah untuk mengukur kemampuan model dalam mendeteksi seluruh kasus positif yang sebenarnya. Nilai *recall* yang tinggi menunjukkan bahwa model mampu mengenali sebagian besar data positif yang ada. Kemudian tujuan mengetahui *precision* adalah untuk mengukur ketepatan model dalam mengklasifikasikan data sebagai positif. Nilai *precision* yang tinggi menunjukkan bahwa sebagian besar prediksi yang dilakukan oleh model benar-benar positif. Dan *f1-score* untuk memberikan gambaran tentang keseimbangan antara keduanya. Nilai *F1-score* yang tinggi mencerminkan bahwa model memiliki kemampuan deteksi yang baik (*recall*) tanpa mengorbankan ketepatan prediksi (*precision*), sehingga menjadi metrik yang sangat berguna ketika menghadapi data yang tidak seimbang antara kelas positif dan negatif.

Berdasarkan uji coba yang telah dilakukan pada model klasifikasi penyakit ginjal menggunakan YOLO v9 maka didapatkan akurasi sebesar 88.89% berdasarkan perhitungan berikut :

$$Akurasi = \frac{\text{Jumlah data yang diprediksi benar}}{\text{jumlah keseluruhan data}}$$

$$Akurasi = \frac{320}{360} \times 100\% = 88.89\%$$

Dengan nilai akurasi yang didapatkan sebesar 88.89%, maka dapat dikatakan bahwa sistem mampu untuk mengklasifikasikan penyakit ginjal tetapi memiliki kekurangan dikarenakan sistem menghasilkan beberapa kesalahan ketika melakukan pengklasifikasian menunjukkan bahwa sistem berjalan dengan baik tetapi memiliki kekurangan dalam mengklasifikasikan penyakit. Kesalahan tersebut dikarenakan

terdapat kemiripan antar penyakit dan kurangnya variasi data sehingga menyebabkan sistem kebingungan dan sulit untuk melakukan pengklasifikasian

BAB 5

KESIMPULAN DAN SARAN

Pada bab ini akan membahas mengenai hasil penelitian klasifikasi penyakit ginjal berdasarkan gambar CT *Scan* menggunakan YOLOv9 untuk menentukan penyakit yang menjangkit ginjal dengan memanfaatkan aplikasi *website*. Selain itu, juga diberikan saran – saran dan referensi pengembangan penelitian selanjutnya.

5.1 Kesimpulan

Dari keseluruhan penelitian terkait penggunaan algoritma YOLOv9 dengan hasil akhir yang didapatkan pada pengujian sistem maka dapat disimpulkan:

1. Penggunaan algoritma You Only Look Once version 9 (YOLOv9) mampu mengklasifikasi 4 jenis kondisi pada ginjal menggunakan citra CT *Scan* yaitu Batu Ginjal, kistal, tumor, dan normal
2. Pengklasifikasian menggunakan You Only Look Once version 9 (YOLOv9) mendapatkan hasil akurasi yang sebesar 88.89% dengan nilai rata-rata *precision* sebesar 88,67%, Nilai rata-rata *recall* sebesar 86,30%, dan nilai rata-rata *F1-Score* sebesar 87,42%
3. Kegagalan dalam pengklasifikasian disebabkan karena adanya kemiripan antara penyakit ginjal dan kemiripan dengan bentuk organ di luar ginjal

5.2 Saran

Adapun saran untuk pengembangan penelitian selanjutnya adalah:

1. Diharapkan Pada penelitian selanjutnya menggunakan data yang lebih variatif dengan tampilan data yang lebih banyak
2. Untuk Penelitian selanjutnya diharapkan Implementasi Algoritma tambahan untuk melakukan pengklasifikasian, sedangkan YOLO v9 khusus untuk mendeteksi keberadaan objek tertentu
3. Penelitian Selanjutnya diharapkan melakukan percobaan *batch size* yang lebih tinggi dan *epoch* yang lebih variatif apabila menggunakan spesifikasi *software* dan *hardware* yang tinggi

DAFTAR PUSTAKA

- Aulia, F., Harahap, A., Mardianson Sinaga, R., Arifin, K., Saputra, K., Prodi, J., Komputer, I., Ilmu, F., & Alam, P. (2022). *IMPLEMENTASI ALGORITMA CONVOLUTIONAL NEURAL NETWORK UNTUK MENDETEKSI PENYAKIT GINJAL IMPLEMENTATION OF CONVOLUTIONAL NEURAL NETWORK FOR DETECTING KIDNEY DISEASE*.
<http://jtika.if.unram.ac.id/index.php/JTIKA/>
- Golchubian, A., Marques, O., & Nojournian, M. (2021). Photo quality classification using deep learning. *Multimedia Tools and Applications*, 80(14), 22193–22208.
<https://doi.org/10.1007/s11042-021-10766-7>
- Hussain, M. (2024). YOLOv1 to v8: Unveiling Each Variant-A Comprehensive Review of YOLO. *IEEE Access*, 12, 42816–42833.
<https://doi.org/10.1109/ACCESS.2024.3378568>
- Indridason, O. S., Birgisson, S., Edvardsson, V. O., Sigvaldason, H., Sigfusson, N., & Palsson, R. (2006). Epidemiology of kidney stones in Iceland: A population-based study. *Scandinavian Journal of Urology and Nephrology*, 40(3), 215–220.
<https://doi.org/10.1080/00365590600589898>
- J Solawetz. (2023). *What is yolov8? the ultimate guide*.
- Kementerian Kesehatan RI. (2023). *DALAM ANGKA TIM PENYUSUN SKI 2023 DALAM ANGKA KEMENTERIAN KESEHATAN REPUBLIK INDONESIA*.
- Kusumanto, R. D., & Tompunu, A. N. (2011). PENGOLAHAN CITRA DIGITAL UNTUK MENDETEKSI OBYEK MENGGUNAKAN PENGOLAHAN WARNA MODEL NORMALISASI RGB. In *Seminar Nasional Teknologi Informasi & Komunikasi Terapan*.
- Lee, S. G., Cho, H., Kim, J. Y., Song, J., & Park, J. H. (2021). Factors affecting incorrect interpretation of abdominal computed tomography in non-traumatic patients by novice emergency physicians. *Clinical and Experimental Emergency Medicine*, 8(3), 207–215. <https://doi.org/10.15441/ceem.20.118>
- Linehan, W. M. (2012). Genetic basis of kidney cancer: Role of genomics for the development of disease-based therapeutics. In *Genome Research* (Vol. 22, Issue 11, pp. 2089–2100). <https://doi.org/10.1101/gr.131110.111>
- M. Koeppen, & Stanton. (2013). *Renal Physiology*.

- O'Shea, K., & Nash, R. (2015). *An Introduction to Convolutional Neural Networks*. <http://arxiv.org/abs/1511.08458>
- Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2015). *You Only Look Once: Unified, Real-Time Object Detection*. <http://arxiv.org/abs/1506.02640>
- Sarma, A., Heilbrun, M. E., Conner, K. E., Stevens, S. M., Woller, S. C., & Elliott, C. G. (2012). Radiation and chest CT scan examinations: What do we know? *Chest*, 142(3), 750–760. <https://doi.org/10.1378/chest.11-2863>
- Schieda, N., Davenport, M. S., Krishna, S., Edney, E. A., Pedrosa, I., Hindman, N., Baroni, R. H., Curci, N. E., Shinagare, A., & Silverman, S. G. (2021). Bosniak classification of cystic renal masses, version 2019: A pictorial guide to clinical use. *Radiographics*, 41(3), 814–828. <https://doi.org/10.1148/rg.2021200160>
- Scholar S, A. (2020). *Kidney Stone Recognition and Extraction using Directional Emboss & SVM from Computed Tomography Images*. [https://doi.org/10.1109/MPCIT51588.2020.9350388/20/\\$31.00](https://doi.org/10.1109/MPCIT51588.2020.9350388/20/$31.00)
- Soni Scholar, A. (2020). Kidney Stone Recognition and Extraction using Directional Emboss & SVM from Computed Tomography Images. *2020 Third International Conference on Multimedia Processing, Communication & Information Technology (MPCIT)*. [https://doi.org/10.1109/MPCIT51588.2020.9350388/20/\\$31.00](https://doi.org/10.1109/MPCIT51588.2020.9350388/20/$31.00)
- Sowjanya, K., Bindu Madavi, K. P., Patwari, N., & Shobharani, D. A. (2023). DeepKidney: Multiclass Classification of Kidney Stones, Cysts, Tumors, and Normal Cases Using Convolutional Neural Networks. *4th International Conference on Communication, Computing and Industry 6.0, C216 2023*. <https://doi.org/10.1109/C2I659362.2023.10431043>
- Sun, Q., Shen, Y., Sun, N., Zhang, G. J., Chen, Z., Fan, J. F., Jia, L. Q., Xiao, H. Z., Li, X. R., & Puschner, B. (2010). Diagnosis, treatment and follow-up of 25 patients with melamine-induced kidney stones complicated by acute obstructive renal failure in Beijing Children's Hospital. *European Journal of Pediatrics*, 169(4), 483–489. <https://doi.org/10.1007/s00431-009-1093-y>
- Thein, N., Adi Nugroho, H., Hamamoto, K., & Bharata Adj, T. (2018). *An image preprocessing method for kidney stone segmentation in CT scan images*.

- Viswanath K, & Gunasundari R. (2014). *Proceedings of the 2014 International Conference on Advances in Computing, Communications and Informatics (ICACCI) : 24-27 September 2014, Delhi, India.*
- Vogelzang J, & Stadler M. (1998). *Kidney cancer.*
- Voulodimos, A., Doulamis, N., Doulamis, A., & Protopapadakis, E. (2018). Deep Learning for Computer Vision: A Brief Review. In *Computational Intelligence and Neuroscience* (Vol. 2018). Hindawi Limited. <https://doi.org/10.1155/2018/7068349>
- Wang, C.-Y., Yeh, I.-H., & Liao, H.-Y. M. (2024). *YOLOv9: Learning What You Want to Learn Using Programmable Gradient Information.* <http://arxiv.org/abs/2402.13616>
- Wang, F., Silvestre, G., & Curran, K. M. (2023a). *Lightweight Framework for Automated Kidney Stone Detection using coronal CT images.* <http://arxiv.org/abs/2311.14488>
- Wang, F., Silvestre, G., & Curran, K. M. (2023b). *Lightweight Framework for Automated Kidney Stone Detection using coronal CT images.* <http://arxiv.org/abs/2311.14488>
- Yildirim, K., Bozdag, P. G., Talo, M., Yildirim, O., Karabatak, M., & Acharya, U. R. (2021a). Deep learning model for automated kidney stone detection using coronal CT images. *Computers in Biology and Medicine*, 135. <https://doi.org/10.1016/j.compbimed.2021.104569>
- Yildirim, K., Bozdag, P. G., Talo, M., Yildirim, O., Karabatak, M., & Acharya, U. R. (2021b). Deep learning model for automated kidney stone detection using coronal CT images. *Computers in Biology and Medicine*, 135. <https://doi.org/10.1016/j.compbimed.2021.104569>
- Zhao, Z. Q., Zheng, P., Xu, S. T., & Wu, X. (2019). Object Detection with Deep Learning: A Review. In *IEEE Transactions on Neural Networks and Learning Systems* (Vol. 30, Issue 11, pp. 3212–3232). Institute of Electrical and Electronics Engineers Inc. <https://doi.org/10.1109/TNNLS.2018.2876865>