

**ANALISIS PREVALENSI STUNTING BERDASARKAN INDEKS KHUSUS  
PENANGANAN STUNTING DI INDONESIA MENGGUNAKAN  
HIERARCHICAL DENSITY-BASED SPATIAL CLUSTERING  
OF APPLICATIONS WITH NOISE (HDBSCAN)**

**SKRIPSI**

**NURHALIMAH**

**211401009**



**PROGRAM STUDI S-1 ILMU KOMPUTER  
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI  
UNIVERSITAS SUMATERA UTARA  
MEDAN  
2025**

**ANALISIS PREVALENSI STUNTING BERDASARKAN INDEKS KHUSUS  
PENANGANAN STUNTING DI INDONESIA MENGGUNAKAN  
HIERARCHICAL DENSITY-BASED SPATIAL CLUSTERING  
OF APPLICATIONS WITH NOISE (HDBSCAN)**

**SKRIPSI**

**Diajukan untuk melengkapi tugas dan memenuhi syarat memperoleh ijazah  
Sarjana (S-1) Ilmu Komputer**

**NURHALIMAH**

**211401009**



**PROGRAM STUDI S-1 ILMU KOMPUTER  
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI  
UNIVERSITAS SUMATERA UTARA  
MEDAN  
2025**

## PERSETUJUAN

Judul : ANALISIS PREVALENSI STUNTING  
BERDASARKAN INDEKS KHUSUS  
PENANGANAN STUNTING DI INDONESIA  
MENGGUNAKAN *HIERARCHICAL DENSITY*  
*-BASED SPATIAL CLUSTERING OF*  
*APPLICATIONS WITH NOISE (HDBSCAN)*

Kategori : SKRIPSI

Nama : NURHALIMAH

Nomor Induk Mahasiswa : 211401009

Program Studi : SARJANA (S-1) ILMU KOMPUTER

Fakultas : ILMU KOMPUTER DAN TEKNOLOGI  
INFORMASI UNIVERSITAS SUMATERA  
UTARA

Tanggal Sidang : 04 MARET 2025

Komisi Pembimbing :  
Pembimbing I :  
Pembimbing II :

Anandhini Medianty Nababan, S.Kom, M.T  
NIP. 199304132024062001

Pembimbing I :  
Hayatunnufus, S.Kom, M.Cs  
NIP. 199207192024062001

Diketahui/Disetujui Oleh  
Program Studi Ilmu Komputer  
Ketua

  
Dr. Amalia, S.T. M.T

NIP. 197812212014042001

## **PERNYATAAN**

### **ANALISIS PREVALENSI STUNTING BERDASARKAN INDEKS KHUSUS PENANGANAN STUNTING DI INDONESIA MENGGUNAKAN *HIERARCHICAL DENSITY-BASED SPATIAL CLUSTERING OF APPLICATIONS WITH NOISE (HDBSCAN)***

**SKRIPSI**

Saya menyatakan bahwa skripsi ini merupakan hasil penelitian saya sendiri, dengan pengecualian pada beberapa kutipan dan ringkasan yang sumbernya telah dicantumkan.

Medan, 17 Januari 2025



Nurhalimah  
211401009

## **PENGHARGAAN**

*Bismillahirrahmanirrahim* dengan penuh rasa syukur, penulis mengucapkan puji dan terima kasih kepada Allah SWT atas segala rahmat, hidayah dan karunia-Nya yang tiada terhingga, yang memungkinkan penulis menyelesaikan tugas akhir ini sebagai bagian dari syarat kelulusan pada Program Studi Ilmu Komputer, Fakultas Ilmu Komputer dan Teknologi Informasi, Universitas Sumatera Utara.

Penulis menyadari bahwa dalam proses pemikiran panjang, perancangan, implementasi, suka dan duka dalam penelitian ini tidak terlepas dari dukungan, doa, dan bantuan dari berbagai pihak. Oleh karena itu, penulis ingin menyampaikan rasa terima kasih dan sayang yang sebesar-besarnya kepada:

1. Bapak Dr. Muryanto Amin, S.Sos., M.Si., selaku Rektor Universitas Sumatera Utara.
2. Ibu Dr. Maya Silvi Lydia B.Sc., M.Sc., selaku Dekan Fakultas Ilmu Komputer dan Teknologi Informasi, Universitas Sumatera Utara.
3. Ibu Dr. Amalia S.T., M.T., selaku Ketua Program Studi S-1 Ilmu Komputer, Universitas Sumatera Utara.
4. Ibu Hayatunnufus, S.Kom., M.Cs., selaku Dosen Pembimbing I saya, yang telah meluangkan banyak waktu dengan penuh kesabaran memberikan banyak bimbingan, arahan, dan saran berharga selama proses penulisan skripsi ini.
5. Ibu Anandhini Medianty Nababan, S.Kom, M.T selaku Dosen Pembimbing II saya, yang juga telah memberikan waktunya untuk saya, bimbingan, saran dan masukan dalam penyusunan skripsi ini.
6. Bapak Dr. Mohammad Andri Budiman S.T., M.Comp.Sc., M.E.M. selaku Dosen Penasihat Akademik saya selama kuliah, yang selalu saya beri kabar terkait proses perkuliahan, senantiasa memberikan dukungan, nasihat akademis, dan motivasi yang sangat berarti bagi penulis selama masa perkuliahan dan penyusunan tugas akhir ini.
7. Ibu Dr. Amalia S.T., M.T., selaku dosen pembimbing yang membawa saya dan tim dalam kejuaraan pada KTI RXPO 2024 serta membawa saya

dengan terhormat dalam ajang USU Awards Penganugerahan Mahasiswa Berprestasi 2024.

8. Kepada seluruh Bapak/Ibu dosen Fasilkom-TI USU yang telah mengajar dan membimbing saya selama berkuliah.
9. Kepada Bapak/Ibu Kemendikbudristek dan DITMAWALUMNI USU yang telah memberikan beasiswa penuh sampai saya dapat berkuliah hingga akhir.
10. Yang tercinta, kedua orangtua, kakak dan adik tersayang saya, Mamak Erna, Bapak Muliadi, Kakak Siti Khadijah dan Adik Intan Nurhasanah yang tak pernah putus mendoakan, memberikan dukungan, Mamak yang selalu melapangkan waktu saya dalam penggeraan skripsi ini, Bapak yang selalu memberikan semangat hangat, terima kasih atas hal kecil yang selalu menjadi alasan untuk terus bangkit.
11. Kepada yang tersayang ‘Pren’, Sandra, Meysha, Dea, Almarhumah Upi dan Aurick yang telah banyak sekali menemani, mewarnai, mengiringi, mendengarkan keluh kesah dan memberikan dukungan tanpa lelah selama perkuliahan dan dalam penyusunan skripsi ini.
12. Teman-teman seperjuangan selama perkuliahan, KOM C “Exolence”, KOM C Girls yang selalu memberikan dukungan dan semangat serta terima kasih telah bersamai suka maupun duka selama berkuliah di kelas.
13. Teman-teman Stambuk 2021, yang bersama semenjak CSA 20, terima kasih telah bersamai.
14. *And last but not least*, kepada seluruh teman-teman, abang kakak dan seluruh pihak yang tidak dapat saya sebutkan satu per satu.

Medan, 17 Januari 2025

Penulis,



Nurhalimah

## ABSTRAK

*Stunting* merupakan masalah kesehatan serius yang dapat memengaruhi pertumbuhan fisik dan perkembangan kognitif anak. Penelitian ini bertujuan untuk mengklasifikasikan wilayah kabupaten/kota di Indonesia berdasarkan indikator penanganan *stunting* menggunakan algoritma HDBSCAN. Data yang digunakan meliputi prevalensi *stunting* dan Indeks Khusus Penanganan *Stunting* (IKPS) selama tiga tahun, yaitu Tahun 2020 (190 Kab/kota), Tahun 2021 (315 kabupaten/kota) dan Tahun 2022 (469 Kab/kota). Hasil klasterisasi menunjukkan bahwa setiap tahun terbentuk 3 klaster dengan karakteristik yang berbeda. Tahun 2020, Klaster 1 berjumlah 5 Kab/kota (Prevalensi Baik, IKPS Optimal), Klaster 0 berjumlah 73 Kab/kota (Prevalensi Menengah, IKPS Stabil) dan Klaster 2 berjumlah 112 Kab/kota (Prevalensi Buruk, IKPS Rendah). Tahun 2021, Klaster 1 ada 61 Kab/kota (Prevalensi Menengah, IKPS Optimal), Klaster 2 ada 246 Kab/kota (Prevalensi Buruk, IKPS Stabil), Klaster 0 ada 8 Kab/kota (Prevalensi Baik, IKPS Rendah). Tahun 2022, Klaster 0 berjumlah 198 Kab/kota (Prevalensi Menengah, IKPS Optimal), Klaster 2 berjumlah 264 Kab/kota (prevalensi buruk, IKPS stabil), Klaster 1 berjumlah 7 Kab/kota (Prevalensi Baik, IKPS Rendah). Evaluasi klaster menggunakan *Davies-Bouldin Index* (DBI) menunjukkan bahwa kualitas klasterisasi cukup baik dengan nilai DBI sebesar 0.5827 pada tahun 2020, 0.6639 pada tahun 2021, dan 0.5710 pada tahun 2022. Hasil pengujian eksternal tahun prioritas mendominasi oleh Klaster 2 untuk setiap tahunnya dan sesuai secara keseluruhan. *Dasbor* interaktif yang dikembangkan dalam penelitian ini menvisualisasikan hasil klasterisasi, mencakup pemetaan wilayah, perbandingan prevalensi dan IKPS, serta perangkingan wilayah prioritas. Visualisasi ini diharapkan dapat memberikan gambaran mengenai wilayah dengan prevalensi *stunting* serta indikator yang perlu ditingkatkan.

**Kata Kunci:** Prevalensi *Stunting*, IKPS, *Clustering*, *HDBSCAN*.

***ANALYSIS OF STUNTING PREVALENCE BASED ON THE SPECIAL  
STUNTING HANDLING INDEX IN INDONESIA USING  
HIERARCHICAL DENSITY-BASED SPATIAL CLUSTERING  
OF APPLICATIONS WITH NOISE (HDBSCAN)***

***ABSTRACT***

*Stunting is a serious health problem that can affect children's physical growth and cognitive development. This study aims to classify districts/cities in Indonesia based on stunting indicators using the HDBSCAN algorithm. The data used includes stunting prevalence and the Special Stunting Handling Index (IKPS) for three years, namely 2020 (190 districts/cities), 2021 (315 districts/cities) and 2022 (469 districts/cities). The clustering results show that each year 3 clusters are formed with different characteristics. In 2020, Cluster 1 had 5 districts/municipalities (Good Prevalence, Optimal IKPS), Cluster 0 had 73 districts/municipalities (Medium Prevalence, Stable IKPS) and Cluster 2 had 112 districts/municipalities (Poor Prevalence, Low IKPS). In 2021, Cluster 1 had 61 districts/cities (Intermediate Prevalence, Optimal IKPS), Cluster 2 had 246 districts/cities (Poor Prevalence, Stable IKPS), Cluster 0 had 8 districts/cities (Good Prevalence, Low IKPS). In 2022, Cluster 0 had 198 districts/municipalities (Intermediate Prevalence, Optimal IKPS), Cluster 2 had 264 districts/municipalities (Poor Prevalence, Stable IKPS), Cluster 1 had 7 districts/municipalities (Good Prevalence, Low IKPS). Cluster evaluation using the Davies-Bouldin Index (DBI) showed that the quality of clustering was good with DBI values of 0.5827 in 2020, 0.6639 in 2021, and 0.5710 in 2022. Priority year external testing results are dominated by Cluster 2 for each year and are appropriate overall. The interactive dasbor developed in this study visualizes the clustering results, including area mapping, comparison of prevalence and IKPS, and ranking of priority areas. This visualization is expected to provide a picture of areas with stunting prevalence and indicators that need to be improved.*

***Keywords:*** Stunting prevalence, IKPS, Clustering, HDBSCAN.

## DAFTAR ISI

<b>PERSETUJUAN .....</b>	<b>ii</b>
<b>PERNYATAAN.....</b>	<b>iii</b>
<b>PENGHARGAAN.....</b>	<b>iv</b>
<b>ABSTRAK .....</b>	<b>vi</b>
<b>ABSTRACT .....</b>	<b>vii</b>
<b>DAFTAR ISI.....</b>	<b>viii</b>
<b>DAFTAR GAMBAR.....</b>	<b>xi</b>
<b>DAFTAR TABEL .....</b>	<b>xiii</b>
<b>BAB 1 PENDAHULUAN .....</b>	<b>1</b>
1.1. Latar Belakang .....	1
1.2. Rumusan Masalah .....	3
1.3. Batasan Masalah .....	3
1.4. Tujuan Penelitian .....	4
1.5. Manfaat Penelitian .....	4
1.6. Metodologi Penelitian .....	4
1.7. Penelitian Relevan .....	7
1.8. Sistematika Penulisan .....	9
<b>BAB 2 TINJAUAN PUSTAKA.....</b>	<b>10</b>
2.1. <i>Stunting</i> .....	10
2.2. Prevalensi <i>Stunting</i> .....	10
2.3. Indeks Khusus Penanganan <i>Stunting</i> (IKPS) .....	11
2.4. <i>Data Mining</i> .....	14
2.5. <i>Clustering</i> .....	16
2.6. Algoritma <i>Hierarchical Density-Based Spatial Clustering of Applications with Noise</i> (HDBSCAN) .....	19
<b>BAB 3 ANALISIS DAN PERANCANGAN SISTEM .....</b>	<b>24</b>
3.1. Analisis Sistem.....	24
3.1.1. Analisis Masalah .....	24
3.1.2. Analisis Kebutuhan .....	25
3.1.2.1. Analisis Kebutuhan Fungsional .....	25
3.1.2.2. Analisis Kebutuhan Non Fungsional.....	25

3.1.3. Analisis Proses.....	26
3.1.4. Analisis Data .....	29
3.2. <i>Clustering</i> menggunakan HDBSCAN .....	41
3.2.1. Inisialisasi Parameter.....	42
3.2.2. Menghitung Jarak Inti ( <i>Core Distance</i> ).....	43
3.2.3. Menghitung Jarak <i>Mutual Reachability Distance</i> .....	45
3.2.4. Membuat <i>Minimum Spanning Tree</i> (MST) .....	46
3.2.5. Menentukan <i>Cluster</i> Berdasarkan Densitas.....	48
3.2.6. Ekstrak Hasil Klasterisasi.....	49
3.3. Arsitektur Umum Sistem .....	52
3.4. Pemodelan Sistem .....	52
3.4.1. <i>Use Case Diagram</i> .....	53
3.4.2. <i>Activity Diagram</i> .....	53
3.4.3. <i>Sequence Diagram</i> .....	54
3.5. <i>Flowchart</i> .....	55
3.5.1. <i>Flowchart</i> Sistem.....	55
3.5.2. <i>Flowchart</i> Algoritma HDBSCAN .....	56
3.6. Perancangan <i>Interface</i> .....	57
3.6.1. Halaman Dasbor .....	57
3.6.2. Tampilan Data Tabel .....	58
3.6.3. Tampilan Informasi.....	59
3.6.4. Tampilan Pemetaan Klaster dan Perangkingan Wilayah .....	59
3.6.5. Tampilan Grafik, Diagram dan Hasil Analisis .....	60
<b>BAB 4 IMPLEMENTASI DAN PENGUJIAN.....</b>	<b>61</b>
4.1. Implementasi Sistem .....	61
4.1.1. Halaman Dasbor .....	61
4.1.2. Tampilan Data Tabel .....	63
4.1.3. Tampilan Informasi.....	64
4.1.3. Tampilan Pemetaan Klaster dan Perangkingan Wilayah .....	64
4.1.3. Tampilan Grafik, Diagram dan Hasil Analisis .....	66
4.2. Implementasi Analisis Hasil Klaster.....	67
4.2.1. Analisis Karakteristik Klaster.....	67
4.2.2. Hasil Analisis Klaster .....	73
4.3. Analisis Prevalensi <i>Stunting</i> Berdasarkan IKPS di Indonesia .....	81

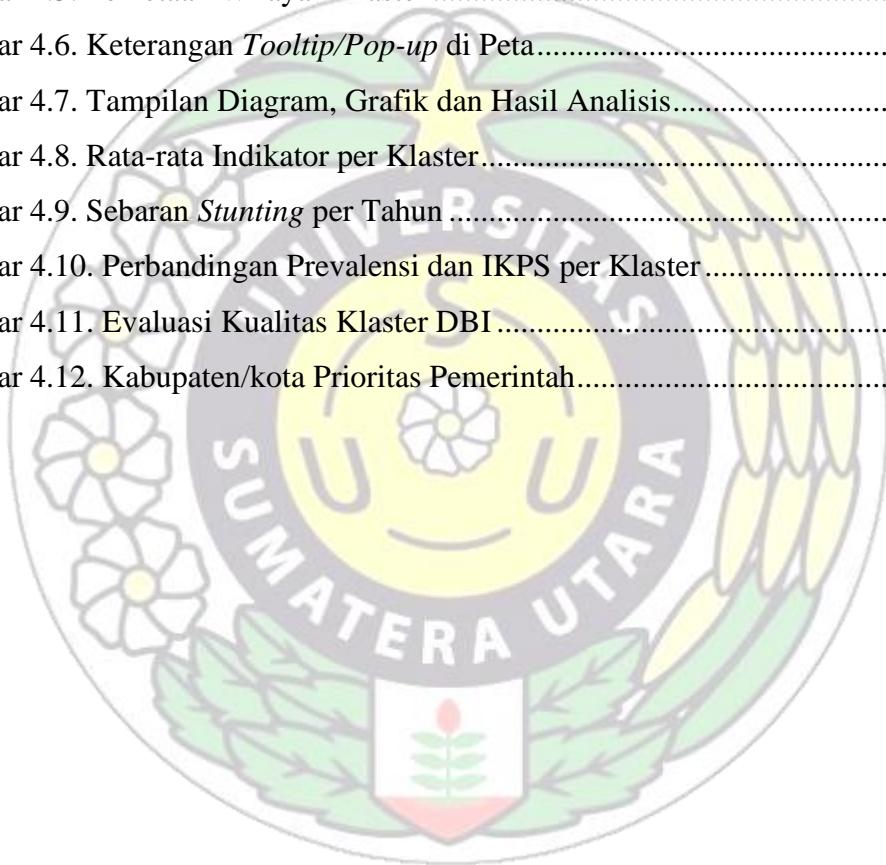
4.3.1. Hubungan IKPS dengan Prevalensi <i>Stunting</i> .....	81
4.3.2. Analisis Balita Tertangani dan Belum Tertangani Berdasarkan IKPS .....	83
4.3.3. Identifikasi Wilayah Prioritas.....	89
4.4. Pengujian.....	91
4.4.1. Evaluasi Kualitas Klasterisasi .....	91
4.4.2. Validasi Eksternal .....	93
<b>BAB 5 KESIMPULAN DAN SARAN.....</b>	<b>97</b>
5.1. Kesimpulan .....	97
5.2. Saran .....	98
<b>DAFTAR PUSTAKA .....</b>	<b>99</b>



## DAFTAR GAMBAR

Gambar 1.1. Metodologi Penelitian .....	6
Gambar 2.1. <i>Core Task of Data Mining</i> .....	14
Gambar 2.2. Proses <i>Data Mining</i> .....	15
Gambar 2.3. Visualisasi <i>Clustering</i> .....	16
Gambar 2.4. Visualisasi <i>Principal Component Analysis (PCA)</i> .....	18
Gambar 2.5. Perbedaan <i>Cluster DBSCAN</i> dan <i>HDBSCAN</i> .....	19
Gambar 2.6. Flow Algoritma <i>HDBSCAN</i> pada <i>Recursive Sampling</i> .....	20
Gambar 2.7. <i>Minimum Spanning Tree HDBSCAN</i> .....	22
Gambar 2.8. Dendogram <i>HDBSCAN</i> .....	22
Gambar 2.9. Hasil Klaster <i>HDBSCAN</i> .....	23
Gambar 3.1. Diagram Ishikawa/ <i>fishbone</i> .....	24
Gambar 3.2. Inisialisasi Parameter .....	42
Gambar 3.3. Kolom Hasil Reduksi PCA .....	43
Gambar 3.4. <i>Minimum Spanning Tree Tahun 2020</i> .....	46
Gambar 3.5. <i>Minimum Spanning Tree Tahun 2021</i> .....	47
Gambar 3.6. <i>Minimum Spanning Tree Tahun 2022</i> .....	47
Gambar 3.7. Dendogram <i>HDBSCAN</i> Tahun 2020.....	48
Gambar 3.8. Dendogram <i>HDBSCAN</i> Tahun 2021.....	48
Gambar 3.9. Dendogram <i>HDBSCAN</i> Tahun 2022.....	49
Gambar 3.10. Hasil Klasterisasi.....	50
Gambar 3.11. Visualisasi Klaster Tahun 2020 dengan PCA .....	50
Gambar 3.12. Visualisasi Klaster Tahun 2021 dengan PCA .....	51
Gambar 3.13. Visualisasi Klaster Tahun 2022 dengan PCA .....	51
Gambar 3.14. Arsitektur Umum Sistem .....	52
Gambar 3.15. <i>Use Case Diagram</i> .....	53
Gambar 3.16. <i>Activity Diagram</i> .....	54
Gambar 3.17. <i>Sequence Diagram</i> .....	55
Gambar 3.18. <i>Flowchart</i> Sistem .....	55
Gambar 3.19. <i>Flowchart</i> Algoritma <i>HDBSCAN</i> .....	56
Gambar 3.20. Halaman <i>Dasbor</i> .....	57

Gambar 3.21. Tampilan Data Tabel.....	58
Gambar 3.22. Tampilan Halaman Informasi .....	59
Gambar 3.23. Tampilan Pemetaan Klaster dan Perangkingan Wilayah .....	59
Gambar 3.24. Tampilan Diagram, Grafik dan Hasil Analisis.....	60
Gambar 4.1. Halaman <i>Dasbor</i> .....	61
Gambar 4.2. Tampilan Data Tabel.....	63
Gambar 4.3. Tampilan Informasi .....	64
Gambar 4.4. Tampilan Pemetaan Klaster dan Perangkingan Wilayah .....	64
Gambar 4.5. Pemetaan Wilayah Klaster .....	65
Gambar 4.6. Keterangan <i>Tooltip/Pop-up</i> di Peta.....	66
Gambar 4.7. Tampilan Diagram, Grafik dan Hasil Analisis.....	66
Gambar 4.8. Rata-rata Indikator per Klaster.....	69
Gambar 4.9. Sebaran <i>Stunting</i> per Tahun .....	80
Gambar 4.10. Perbandingan Prevalensi dan IKPS per Klaster.....	82
Gambar 4.11. Evaluasi Kualitas Klaster DBI .....	92
Gambar 4.12. Kabupaten/kota Prioritas Pemerintah.....	94



## DAFTAR TABEL

Tabel 3.1. Atribut dan Deskripsi Data .....	30
Tabel 3.2. Data Prevalensi dan IKPS (Atribut Provinsi s/d Prevalensi) .....	31
Tabel 3.3. Data Prevalensi dan IKPS (Atribut Imunisasi s/d Air Minum Layak) .....	31
Tabel 3.4. Data Prevalensi dan IKPS (Atribut Sanitasi Layak s/d Penerima Bantuan Pangan) .....	32
Tabel 3.5. Data Prevalensi dan IKPS (Atribut Dimensi Kesehatan s/d IKPS) .....	32
Tabel 3.6. Hasil <i>Feature Selection</i> (Atribut Tahun s/d ASI Eksklusif) .....	33
Tabel 3.7. Hasil <i>Feature Selection</i> (Atribut MP ASI s/d Penerima Bantuan Pangan) .....	34
Tabel 3.8. Deskripsi Statistik Data.....	34
Tabel 3.9. Perbandingan Atribut ‘Prevalensi’ setelah <i>Reverse Scalling</i> .....	35
Tabel 3.10. Deskripsi Statistik Per Tahun .....	36
Tabel 3.11. Hasil <i>Data Preprocessing</i> Tahun 2020 (Prevalensi s/d MP ASI) .....	37
Tabel 3.12. Hasil <i>Data Preprocessing</i> Tahun 2020 (Atribut Air Minum Layak s/d Penerima Bantuan Pangan).....	38
Tabel 3.13. Hasil <i>Data Preprocessing</i> Tahun 2021 (Atribut Prevalensi s/d MP ASI) .....	38
Tabel 3.14. Hasil <i>Data Preprocessing</i> Tahun 2021 (Air Minum Layak s/d Penerima Bantuan Pangan).....	39
Tabel 3.15. Hasil <i>Data Preprocessing</i> Tahun 2022 (Atribut Prevalensi s/d MP ASI) .....	39
Tabel 3.16. Hasil <i>Data Preprocessing</i> Tahun 2022 (Atribut Air Minum Layak s/d Penerima Bantuan Pangan).....	40
Tabel 3.17. Deskripsi Statistik setelah <i>Preprocessing</i> .....	40
Tabel 4.1. Rata-rata Klaster .....	68
Tabel 4.2. Rata-rata Prevalensi dan IKPS per Klaster .....	70
Tabel 4.3. Karakteristik Klaster .....	71
Tabel 4.4. Wilayah Hasil Klaster .....	73
Tabel 4.5. Jumlah Balita Tertangani dan Belum Tahun 2020 .....	83
Tabel 4.6. Jumlah Balita Tertangani dan Belum Tahun 2021 .....	85

Tabel 4.7. Jumlah Balita Tertangani dan Belum Tahun 2022 .....	86
Tabel 4.8. Wilayah Prioritas Tahun 2020 .....	89
Tabel 4.9. Wilayah Prioritas Tahun 2021 .....	90
Tabel 4.10. Wilayah Prioritas Tahun 2022 .....	90
Tabel 4.11. Evaluasi Kualitas Klaster.....	92
Tabel 4.12. Validasi Wilayah Prioritas Tahun 2020.....	94
Tabel 4.13. Validasi Wilayah Prioritas Tahun 2020.....	94
Tabel 4.14. Validasi Wilayah Prioritas Tahun 2020.....	95



## BAB 1

### PENDAHULUAN

#### 1.1. Latar Belakang

*Stunting* merupakan salah satu permasalahan gizi kronis yang masih menjadi tantangan kesehatan masyarakat di Indonesia. *Stunting* didefinisikan sebagai kondisi kekurangan gizi pada balita yang menyebabkan anak tumbuh terlalu pendek pada usianya (Yulia et al., 2021). Dampak dari *stunting* tidak hanya terlihat dari pertumbuhan fisik anak yang terhambat, tetapi juga berdampak pada perkembangan kognitif dan kesehatan jangka panjang. Dengan dampak yang ada, maka perlu adanya tindakan untuk mengetahui perkembangan *stunting* di tiap daerah menggunakan prevalensi. Prevalensi *stunting* adalah persentase anak-anak di bawah usia lima tahun yang memiliki tinggi badan lebih rendah dari standar yang sesuai dengan usia mereka yang ada di suatu daerah berdasarkan data yang telah ada. Laporan *Global Nutrition Report* tahun 2022, menyebutkan bahwa prevalensi *stunting* digunakan untuk menilai kemajuan suatu negara atau wilayah dalam mencapai target gizi global, dengan tujuan utama menurunkan angka ini untuk mencegah dampak jangka panjang yang negatif pada kesehatan dan kesejahteraan masyarakat.

Menurut laporan *World Health Organization* (WHO) pada tahun 2022, sekitar 148,1 juta anak di bawah usia lima tahun di dunia mengalami *stunting*. Di Asia Tenggara, prevalensi *stunting* mencapai 27,4%, yang masih menjadi salah satu yang tertinggi di dunia, meskipun ada sedikit kemajuan menuju target global (*Global Nutrition Report.*, 2022). Di Indonesia, prevalensi *stunting* juga masih berada pada tingkat yang mengkhawatirkan, pada tahun 2021 angka *stunting* sebesar 24,4%, angka ini hanya turun sedikit, dibuktikan dengan pada tahun 2022 angka *stunting* sebesar 21,6% (Kementerian Kesehatan., 2023). Angka ini menunjukkan bahwa hampir satu dari empat anak balita di Indonesia mengalami *stunting*, yang jauh di atas batas maksimal yang direkomendasikan WHO, yakni 20%.

Untuk mencapai target *Sustainable Development Goals* (SDGs), khususnya tujuan kedua yang bertujuan mengakhiri kelaparan, mencapai

ketahanan pangan, meningkatkan gizi, serta mendukung pertanian berkelanjutan, Indonesia harus mengambil langkah konkret dalam menurunkan prevalensi *stunting*. Pemerintah menargetkan prevalensi anak balita *stunting* di Indonesia sebesar 14% pada tahun 2024 (Kementerian Kesehatan., 2023). Ini adalah bagian dari upaya yang ditekankan dalam Peraturan Presiden Nomor 72 Tahun 2021 tentang Percepatan Penurunan *Stunting*. Guna mencapai target ini, dibutuhkan pendekatan yang lebih komprehensif dan berbasis data guna mendukung perencanaan kebijakan yang lebih tepat sasaran.

Indeks Khusus Penanganan *Stunting* (IKPS) adalah salah satu upaya strategis yang dikembangkan untuk memantau dan mengevaluasi berbagai indikator terkait penanganan *stunting* di Indonesia. IKPS mencakup berbagai variabel penting seperti akses terhadap imunisasi, sanitasi layak, layanan kesehatan, pendidikan, serta gizi. Data Prevalensi *stunting* dan Data IKPS yang mencakup data provinsi, kabupaten, dan kota di Indonesia untuk periode 2020-2022, dengan total 19.746 data, akan digunakan untuk membangun dasbor visualisasi prevalensi *stunting*. Dasbor ini akan mengintegrasikan teknologi pendekatan *Big Data* dalam menganalisis wilayah klaster. Dengan menggunakan algoritma HDBSCAN, wilayah-wilayah akan dikelompokkan berdasarkan berbagai indikator penanganan *stunting*, sehingga memungkinkan identifikasi terhadap daerah yang paling prioritas yang membutuhkan perhatian lebih dalam penanganan *stunting* di wilayah tersebut.

Algoritma *Hierarchical Density-Based Spatial Clustering of Applications with Noise* yang selanjutnya disebut HDBSCAN merupakan salah satu teknik *clustering* berbasis kepadatan yang efektif untuk mengelompokkan wilayah berdasarkan kesamaan karakteristik terkait indikator *stunting*. Keunggulan utama HDBSCAN terletak pada kemampuannya untuk secara otomatis mendeteksi dan mengabaikan *outlier*, serta mengidentifikasi *cluster* dengan kepadatan yang bervariasi. Algoritma ini memungkinkan pengenalan pola-pola kepadatan di antara wilayah-wilayah dalam hal prevalensi *stunting* dan berbagai faktor penanganan, seperti akses terhadap sanitasi, layanan kesehatan, dan gizi.

## 1.2. Rumusan Masalah

*Stunting* adalah masalah gizi kronis yang serius di Indonesia, dengan prevalensi yang masih mengkhawatirkan dan berdampak signifikan pada kesehatan jangka panjang anak. Penanganan *stunting* memerlukan pendekatan berbasis data untuk merencanakan kebijakan yang efektif. Namun, dengan kompleksitas data yang melibatkan berbagai indikator dan wilayah, seperti akses layanan kesehatan, sanitasi, gizi, serta program sosial yang bervariasi antar wilayah, diperlukan metode analisis yang dapat mengelompokkan wilayah dengan karakteristik serupa. Maka dari itu, penelitian ini bermaksud untuk mengklasterisasi wilayah kabupaten/kota di Indonesia menggunakan metode HDBSCAN berdasarkan indikator penanganan *stunting* dan mengimplementasikan hasil klasterisasi dalam dasbor.

## 1.3. Batasan Masalah

Dalam melakukan penelitian ini, penulis membatasi ruang masalah yang diteliti. Beberapa batasan masalah dalam penelitian ini adalah,

1. Data diambil dari dua sumber *website* yaitu Publikasi Kementerian Dalam Negeri melalui Ditjen Bina Pembangunan Daerah dan Publikasi Tim Percepatan Penanganan *Stunting* melalui buku Indeks Khusus Penanganan *Stunting* (IKPS).
2. Penelitian ini berfokus pada analisis klaster wilayah prevalensi *stunting* per tahun berdasarkan imunisasi, penolong persalinan oleh tenaga kesehatan di fasilitas kesehatan, KB modern, ASI eksklusif, MP ASI, air minum layak, sanitasi layak, PAUD, kepemilikan JKN/Jamkesda, dan penerima bantuan pangan.
3. Proses analisis tidak mencakup seluruh wilayah Indonesia, hanya dilakukan pada 34 provinsi, 190 kabupaten/kota untuk tahun 2020, 315 kabupaten/kota tahun 2021 dan 469 kabupaten/kota di tahun 2022.
4. Proses klasterisasi menggunakan *Visual Studio Code* dengan bahasa pemrograman *Python* menggunakan algoritma *Hierarchical Density-Based Spatial Clustering of Applications with Noise* (HDBSCAN).
5. Hasil penelitian berupa analisis pengelompokan wilayah kabupaten/kota

di Indonesia berdasarkan tingkat prevalensi penanganan *stunting*.

6. Dasbor hasil analisis dirancang berbasis *Website* menggunakan *Streamlit*.

#### **1.4. Tujuan Penelitian**

Penelitian ini bertujuan untuk mengelompokkan dan menganalisis prevalensi *stunting* di Indonesia berdasarkan data Indeks Khusus Penanganan *Stunting* (IKPS) melalui metode pengelompokan (*clustering*) menggunakan algoritma HDBSCAN. Hasil dari metode ini diharapkan dapat memberikan rekomendasi kebijakan untuk mengetahui kondisi prevalensi *stunting* dengan penanganannya secara lebih efektif.

#### **1.5. Manfaat Penelitian**

Adapun beberapa manfaat yang diharapkan dari penelitian ini adalah sebagai berikut,

1. Implementasi algoritma HDBSCAN pada pengelompokan (*clustering*) data prevalensi *stunting* berdasarkan indikator penanganan di Indonesia.
2. Pemetaan wilayah kabupaten/kota terkait daerah rentan *stunting* berdasarkan indikator penanganan *stunting*.
3. Dapat dijadikan sebagai referensi dalam pengembangan pengolahan data dan analisis klasterisasi wilayah terkait penanganan *stunting*.

#### **1.6. Metodologi Penelitian**

Metode penelitian yang dilakukan dalam penelitian ini adalah,

##### **1. Studi Pustaka**

Tahap awal penelitian adalah melakukan studi pustaka untuk memahami konsep-konsep yang relevan dengan topik penelitian, seperti *stunting*, indikator penanganan *stunting*, prevalensi *stunting* dan Algoritma HDBSCAN. Penelitian-penelitian terdahulu seperti jurnal, buku dan penelitian sebelumnya yang membahas pendekatan serupa dalam penanganan *stunting*.

##### **2. Pengumpulan Data**

Pengumpulan data dilakukan dengan memperoleh data dari Publikasi Kementerian Dalam Negeri melalui Ditjen Bina Pembangunan Daerah dan

Publikasi Tim Percepatan Penanganan *Stunting* melalui buku Indeks Khusus Penanganan *Stunting* (IKPS) yang meliputi 34 provinsi, 476 kabupaten/kota di Indonesia selama periode 2020-2022, dengan total 19.746 data (sebelum di *preprocessing*) dan 13.188 data (setelah di *preprocessing*).

### 3. *Preprocessing* Data

Sebelum ke tahap pemodelan, dilakukan *preprocessing* data untuk mempersiapkan dataset sebelum dilakukan analisis lebih lanjut. Proses ini bertujuan untuk memastikan bahwa data bersih, konsisten dan sesuai untuk digunakan dalam model analisis.

### 4. Pemodelan Sistem

Pada tahap pemodelan sistem, desain rancangan analisis data akan dilakukan dengan merancang *fish bone*, *use case* diagram, *sequence* diagram, *activity* diagram, dan *flowchart* yang menggambarkan alur penelitian secara sistematis. *Use case* diagram akan menunjukkan interaksi antara pengguna dengan sistem yang dibangun, sementara *sequence* diagram dan *flowchart* akan merinci urutan langkah-langkah dalam pengolahan data, klustering dan analisis.

### 5. Implementasi Sistem

Pada tahap ini adalah proses implementasi sistem (*coding*) dengan penerapan metode HDBSCAN pada dataset yang telah dikumpulkan dan melakukan analisis terhadap hasil klaster yang dihasilkan.

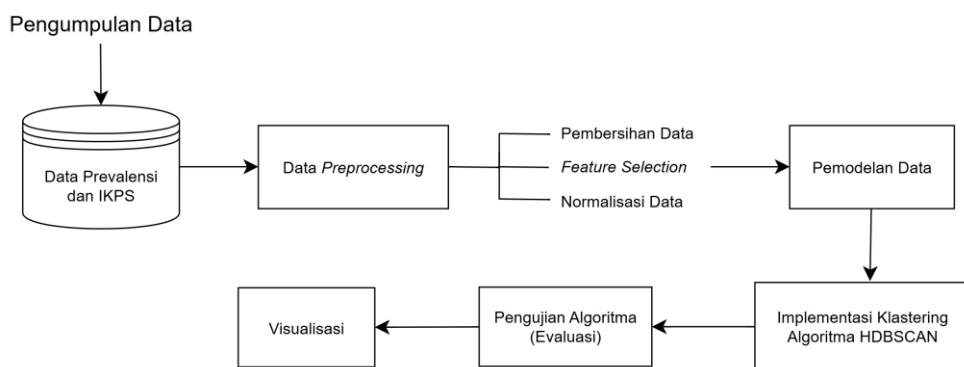
### 6. Pengujian Sistem

Pada tahap ini, hasil analisis akan didokumentasikan dalam bentuk visualisasi seperti grafik, diagram klaster, *heatmap*, dan peta yang menggambarkan hasil klustering. Dokumentasi ini akan disertakan dalam laporan skripsi, yang mencakup proses analisis, hasil, dan rekomendasi kebijakan berbasis data untuk penanganan *stunting* di Indonesia.

### 7. Visualisasi dan Dokumentasi

Pada tahap ini, hasil analisis akan didokumentasikan dalam bentuk visualisasi seperti grafik, diagram klaster, *heatmap* dan peta yang

menggambarkan hasil klastering. Dokumentasi ini akan disertakan dalam laporan skripsi, yang mencakup proses analisis dan hasil untuk penanganan *stunting* di Indonesia.



**Gambar 1.1. Metodologi Penelitian**

Proses metode penelitian dimulai dengan pengumpulan data, yang mencakup data prevalensi *stunting* serta data Indeks Khusus Penanganan *Stunting* (IKPS) dari seluruh wilayah Indonesia. Setelah data terkumpul, dilakukan penggabungan data dan *data preprocessing* yang melibatkan beberapa langkah penting seperti pembersihan data yaitu penghapusan *missing values*, menghapus kolom yang duplikat dan memastikan tipe data sesuai. Selanjutnya dilakukan *feature selection* (pemilihan fitur) yaitu pemilihan kolom yang relevan untuk dilakukan pemodelan, dan menghapus kolom yang tidak diperlukan. Kemudian, dilakukan normalisasi data untuk menyeimbangkan skala antar variabel.

Setelah data dipreparasi, masuk ke tahap pemodelan data di mana algoritma HDBSCAN (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*) digunakan untuk mengelompokkan wilayah berdasarkan prevalensi *stunting* dan indikator penanganan *stunting*. Pada tahap implementasi klastering, algoritma HDBSCAN diterapkan untuk menghasilkan klaster yang menunjukkan kesamaan karakteristik wilayah terkait prevalensi dan penanganan *stunting*. Setelah klaster terbentuk, dilakukan pengujian algoritma untuk mengevaluasi kinerja HDBSCAN dan memastikan klasterisasi yang dihasilkan sesuai. Langkah terakhir adalah visualisasi, dimana hasil klasterisasi divisualisasikan berupa pemetaan

wilayah dan diagram agar mudah dipahami, menunjukkan prevalensi *stunting* antar wilayah dan indikator penanangannya.

### 1.7. Penelitian Relevan

Beberapa penelitian terdahulu dan relevan dengan penelitian ini adalah,

1. Penelitian oleh (Jannah et al., 2024) dengan judul “Penerapan *Density-Based Spatial Clustering Of Application With Noise* (DBSCAN) Untuk Mengelompokkan Kecamatan Di Kabupaten Blitar Berdasarkan Prevalensi *Stunting* Pada Anak” membahas penerapan algoritma DBSCAN untuk mengelompokkan kecamatan di Kabupaten Blitar berdasarkan prevalensi *stunting* pada anak. Variabel yang digunakan dalam penelitian ini meliputi banyaknya bayi dengan Berat Badan Lahir Rendah (BBLR), bayi yang mendapatkan Inisiasi Menyusu Dini (IMD), Asi Eksklusif, MPASI sesuai standar, Pemberian Makanan Tambahan (PMT), serta pemberian vitamin A. Hasil dari penelitian ini menunjukkan bahwa DBSCAN berhasil membentuk tiga klaster dengan *cluster* 1 terdiri dari 8 kecamatan, *cluster* 2 terdiri dari 5 kecamatan, dan *cluster* 3 terdiri dari 3 kecamatan, serta terdapat 6 titik yang diidentifikasi sebagai *noise*.
2. Penelitian yang dilakukan oleh (Zarlis et al., 2023) dengan judul “*Minimizing the number of Stunting prevalence using the Euclid algorithm clustering approach*”. Penelitian ini membagi data menjadi 4 klaster: sangat sedikit (79%), sedikit (67%), banyak (51%), dan sangat banyak (21%). Hasil klasifikasi dan klasterisasi prevalensi *stunting* terbaik di klaster pertama dengan jumlah yang sangat sedikit, dapat digunakan sebagai sumber informasi yang akurat oleh pemerintah dalam upaya mengoptimalkan penanganan *stunting* di setiap kabupaten/kota.
3. Penelitian yang dilakukan oleh (Faujia et al., 2022) dengan judul Analisis Klaster K-Means dan *Agglomerative Nesting* pada Indikator *Stunting* Balita di Indonesia diperoleh hasil analisis mengidentifikasi 2 klaster optimum: Klaster 2, termasuk Provinsi Papua, menunjukkan prevalensi *stunting* tinggi dengan indikator imunisasi dan akses sanitasi yang rendah, sementara 33 provinsi lainnya masuk Klaster 1 dengan indikator lebih baik.

4. Penelitian oleh (Fadilah et al., 2022). Dengan judul “Pengelompokan Kabupaten/Kota Di Indonesia Berdasarkan Faktor Penyebab *Stunting* Pada Balita Menggunakan Algoritma K-Means” membahas penerapan algoritma K-Means untuk mengelompokkan kabupaten/kota di Indonesia berdasarkan faktor penyebab *Stunting* pada balita. Hasil penelitian menunjukkan bahwa dengan metode *Elbow*, didapatkan dua klaster terbaik, yaitu *cluster 1* dengan faktor penyebab *stunting* tinggi yang terdiri dari 324 kabupaten/kota, dan *cluster 2* dengan faktor penyebab *stunting* rendah yang terdiri dari 49 kabupaten/kota. Total nilai selisih *Sum of Square Error* (SSE) adalah 1401,5156.
5. Penelitian oleh (Gare et al., 2022) berjudul "Analytics Pipeline for Visualization of Single Cell RNA Sequencing Data from Bronchoalveolar Fluid in COVID-19 Patients: Assessment of Neuro Fuzzy-CMeans and HDBSCAN" bahwa metode Neuro-fuzzy dan HDBSCAN dapat menggambarkan perbedaan antara kondisi sedang dan parah untuk kasus pasien COVID-19.
6. Penelitian yang dilakukan oleh (Wahyuni et al., 2021) yang berjudul “Metode Hierarchical Density-Based Spatial Clustering of Application with Noise (HDBSCAN) Pada Wilayah Desa/Kelurahan Tertinggal di Kabupaten Kutai Kartanegara” membahas penerapan metode HDBSCAN untuk mengelompokkan desa/kelurahan tertinggal di Kabupaten Kutai Kartanegara berdasarkan data hasil Pendataan Potensi Desa (PODES) tahun 2018. Penelitian ini menemukan bahwa terdapat dua *cluster* yang terbentuk, di mana *cluster 1* terdiri dari 4 desa/kelurahan, sedangkan *cluster 2* terdiri dari 61 desa/kelurahan. Selain itu, hasil pengelompokan menunjukkan bahwa rata-rata jumlah keluarga yang menggunakan listrik PLN di *cluster 1* jauh lebih sedikit dibandingkan dengan *cluster 2*, dengan masing-masing rata-rata pengguna listrik PLN sebanyak 25 keluarga di *cluster 1* dan 250 keluarga di *cluster 2*. Penelitian ini merekomendasikan agar desa/kelurahan *cluster 1* menjadi sasaran utama pemerintah dalam memberikan bantuan dan pembangunan sarana/prasarana daerah.

## 1.8. Sistematika Penulisan

Berikut ini merupakan sistematika dari penulisan skripsi ini yang terdiri dari beberapa bagian.

### **BAB I PENDAHULUAN**

Bab ini menjelaskan tentang latar belakang masalah, rumusan masalah, batasan masalah, tujuan dan manfaat penelitian, metodologi penelitian, serta sistematika penelitian dari skripsi ini.

### **BAB II LANDASAN TEORI**

Pada bab ini, dijelaskan tentang beberapa teori mengenai *Stunting*, Prevalensi *Stunting*, Indeks Khusus Penanganan *Stunting*, *Data Mining*, *Clustering* dan algoritma HDBSCAN (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*).

### **BAB III ANALISIS DAN PERANCANGAN SISTEM**

Bab ini berisi tentang analisis dari proses, perancangan sistem dan antarmuka dari sistem analisis prevalensi *stunting* berdasarkan indeks khusus penanganan *stunting* di Indonesia menggunakan HDBSCAN (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*).

### **BAB IV IMPLEMENTASI DAN PENGUJIAN**

Pada bab ini, berisikan penjelasan tentang implementasi sistem, implementasi analisis dan hasil pengujian terhadap sistem yang telah dibuat.

### **BAB V KESIMPULAN DAN SARAN**

Bab ini mencakup kesimpulan yang didapatkan dari penelitian dan saran dari peneliti yang dapat membantu penelitian sebelumnya.

## BAB 2

### TINJAUAN PUSTAKA

#### 2.1. *Stunting*

*Stunting* adalah kondisi dimana anak balita mengalami pertumbuhan yang terhambat akibat kekurangan gizi kronis dan infeksi yang terjadi secara berulang, terutama dalam periode 1.000 Hari Pertama Kehidupan (HPK), yang dimulai sejak masa janin hingga usia 23 bulan. *Stunting* tidak hanya berdampak pada pertumbuhan fisik anak, tetapi juga mempengaruhi fungsi tubuh lainnya seperti perkembangan otak dan sistem kekebalan. Anak-anak yang *stunting* cenderung memiliki kecerdasan yang buruk, lebih rentan terhadap penyakit, dan berisiko menurunkan produktivitas di masa depan. Oleh karena itu, pemerintah memprioritaskan program percepatan penurunan *stunting* sebagai salah satu agenda nasional yang penting (BPS., 2020). *Stunting* dapat disebabkan oleh berbagai faktor seperti asupan gizi yang tidak memadai, infeksi berulang, serta praktik perawatan kesehatan yang kurang baik (World Health Organization., 2022). Dampak *stunting* tidak hanya pada fisik, tetapi juga perkembangan kognitif anak, yang kemudian mempengaruhi kualitas hidup serta produktivitas di masa depan (Global Nutrition Report., 2022). Proses pencegahan *stunting* memerlukan intervensi gizi dan kesehatan sejak dini untuk menghindari efek jangka panjang yang merugikan perkembangan anak.

#### 2.2. Prevalensi *Stunting*

Prevalensi *Stunting* merupakan indikator penting yang menggambarkan persentase anak-anak di bawah usia lima tahun dengan tinggi badan lebih rendah dari standar yang ditetapkan sesuai dengan usia mereka. Prevalensi ini mencerminkan tingkat kesehatan dan gizi di suatu wilayah dan menjadi parameter penting dalam menilai kemajuan negara atau daerah dalam mencapai target gizi global (Global Nutrition Report, 2022). Berdasarkan laporan *World Health Organization* (WHO) pada tahun 2022, diperkirakan sekitar 148,1 juta anak balita di dunia mengalami *stunting*. Di kawasan Asia

Tenggara, prevalensi *stunting* masih sangat tinggi, mencapai 27,4%, yang menunjukkan tantangan besar meskipun ada sedikit kemajuan menuju target global (WHO., 2022). Di Indonesia sendiri, prevalensi *stunting* juga masih menjadi isu serius, dengan angka mencapai 24,4% pada tahun 2021, dan sedikit penurunan menjadi 21,6% pada tahun 2022 (Kementerian Kesehatan., 2023). Angka ini jauh di atas batas maksimal yang direkomendasikan WHO, yaitu 20%, yang menunjukkan bahwa hampir satu dari empat balita di Indonesia mengalami *stunting*. Dalam upaya mencapai target *Sustainable Development Goals* (SDGs), khususnya pada aspek peningkatan gizi dan ketahanan pangan, pemerintah Indonesia menargetkan penurunan prevalensi *stunting* hingga 14% pada tahun 2024 (Kementerian Kesehatan., 2023). Pencapaian target ini memerlukan strategi yang komprehensif dan berbasis data, dengan kebijakan yang dirancang untuk mendukung percepatan penurunan angka *stunting* secara lebih efektif. Rumus prevalensi *stunting* digunakan untuk menghitung persentase anak balita yang mengalami *stunting* dalam suatu populasi. Rumusnya adalah:

$$\text{Prevalensi Stunting} = \left( \frac{\text{Jumlah Balita Stunting}}{\text{Jumlah Total Balita}} \times 100 \right)$$

Keterangan:

- Jumlah Balita *Stunting*: Jumlah anak balita (di bawah 5 tahun) yang memiliki tinggi badan lebih rendah dari standar tinggi badan berdasarkan usia.
- Jumlah Total Balita: Jumlah keseluruhan anak balita di wilayah atau kelompok yang diukur.

### **2.3. Indeks Khusus Penanganan *Stunting* (IKPS)**

Indeks Khusus Penanganan *Stunting* (IKPS) adalah salah satu alat evaluasi yang dirancang untuk mengukur kinerja upaya tim percepatan penurunan *stunting*. Indeks Khusus Penanganan *Stunting* (IKPS) memfasilitasi perbandingan perkembangan cakupan intervensi pada rumah tangga sasaran di tingkat nasional, provinsi, hingga kabupaten/kota. Pada penelitian ini, rentang

tahun yang digunakan yaitu tahun 2020-2022, untuk menyediakan data yang diperlukan pemerintah dalam memantau kinerja program penanganan *stunting* di Indonesia.

Selain menjadi instrumen untuk menilai efektivitas program, penyusunan IKPS juga bertujuan untuk memenuhi persyaratan *Disbursement Linked Indicators* (DLI) 8 dari Program *Investing in Nutrition and Early Years* (INEY), yang merupakan kerja sama antara Pemerintah Indonesia dan Bank Dunia. Sejak pertama kali diperkenalkan pada tahun 2018, IKPS telah mengalami beberapa kali revisi dengan melibatkan masukan dari kementerian, lembaga, dan pakar dari berbagai sektor. IKPS dihitung menggunakan data dari Survei Sosial Ekonomi Nasional (Susenas), sebuah survei rumah tangga yang dilakukan oleh BPS untuk menyediakan data sosial ekonomi. Data Susenas yang digunakan dalam penyusunan IKPS berasal dari survei yang dilaksanakan pada Maret setiap tahunnya, dengan sekitar 345.000 rumah tangga sebagai sampel (BPS, 2023). Setelah beberapa revisi dan penyempurnaan indikator, kini IKPS terdiri dari lima dimensi, yaitu dimensi kesehatan, dimensi gizi, dimensi perumahan, dimensi pendidikan dan dimensi perlindungan sosial. Berikut adalah penjelasan mengenai setiap indikator penyusun Indek Khusus Penanganan *Stunting* (IKPS) menurut Badan Pusat Statistik (BPS) Tahun 2023:

a. Dimensi Kesehatan

Dimensi ini mencakup tiga indikator, yaitu imunisasi, penolong persalinan oleh tenaga kesehatan di fasilitas kesehatan, dan penggunaan alat kontrasepsi modern (Keluarga Berencana/KB).

- 1) Imunisasi: Indikator ini mengacu pada persentase anak usia 12-23 bulan yang telah mendapatkan imunisasi dasar lengkap, meliputi satu dosis BCG, tiga dosis DPT, tiga dosis polio, satu dosis campak, dan tiga dosis hepatitis. Persentasenya dihitung dari perbandingan jumlah anak usia 12-23 bulan yang mendapatkan imunisasi dasar lengkap dengan jumlah total anak usia tersebut.

- 2) Penolong Persalinan oleh Tenaga Kesehatan di Fasilitas Kesehatan: Indikator ini mengukur persentase perempuan usia 15-49 tahun yang melahirkan dengan bantuan tenaga kesehatan di fasilitas kesehatan, seperti rumah sakit, puskesmas, atau praktik tenaga kesehatan. Tenaga kesehatan meliputi dokter, bidan dan perawat.
- 3) Keluarga Berencana (KB) Modern: Indikator ini menunjukkan persentase perempuan usia 15-49 tahun atau pasangannya yang menggunakan metode kontrasepsi modern untuk menunda atau mencegah kehamilan. Metode kontrasepsi modern mencakup sterilisasi, IUD, suntikan, implan, pil, dan metode kontrasepsi lainnya.

b. Dimensi Gizi

Dimensi ini meliputi dua indikator, yaitu pemberian ASI eksklusif dan makanan pendamping ASI (MP ASI).

- 4) ASI Eksklusif: Indikator ini mengukur persentase bayi berusia di bawah enam bulan yang hanya menerima ASI eksklusif, tanpa tambahan makanan atau minuman lain.
- 5) Makanan Pendamping (MP) ASI: Indikator ini merujuk pada persentase anak usia 6-23 bulan yang menerima makanan atau minuman bergizi selain ASI dalam 24 jam terakhir.

c. Dimensi Perumahan

- 6) Air Minum Layak: Indikator ini mengukur persentase rumah tangga yang memiliki akses ke sumber air minum yang memenuhi standar kelayakan, seperti sumur terlindung atau air hujan.
- 7) Sanitasi Layak: Indikator ini adalah persentase rumah tangga yang memiliki fasilitas sanitasi yang aman dan berkelanjutan, seperti kloset dengan pembuangan limbah yang sesuai standar.

d. Dimensi Pendidikan

- 8) PAUD: Dimensi pendidikan dinilai berdasarkan indikator angka partisipasi kasar (APK) PAUD untuk anak usia 3-6 tahun, yang membandingkan jumlah anak yang terdaftar di PAUD dengan total populasi anak dalam rentang usia tersebut.

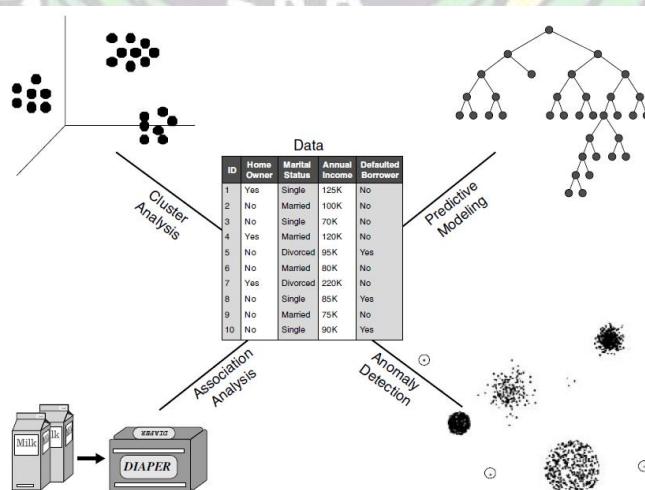
e. Dimensi Perlindungan Sosial

- 9) Kepemilikan JKN/Jamkesda: Indikator ini menghitung persentase penduduk yang memiliki jaminan kesehatan nasional (JKN) atau jaminan kesehatan daerah (jamkesda).
- 10) Penerima KPS/KKS atau Bantuan Pangan: Indikator ini mengacu pada persentase rumah tangga yang menerima kartu perlindungan sosial, kartu keluarga sejahtera, atau bantuan pangan seperti Raskin, Bansos Rastra, atau BPNT dalam kurun waktu empat bulan terakhir.

Seluruh indikator-indikator diatas telah ditetapkan sebelumnya oleh Badan Pusat Statistik (BPS) dengan berdasarkan RPJMN 2020-2024, rancangan perpres dan kesepakatan pakar. Dengan indikator yang telah ditetapkan, maka cakupan indikator dapat digunakan sebagai aspek penanganan *stunting* dalam penelitian ini.

#### 2.4. Data Mining

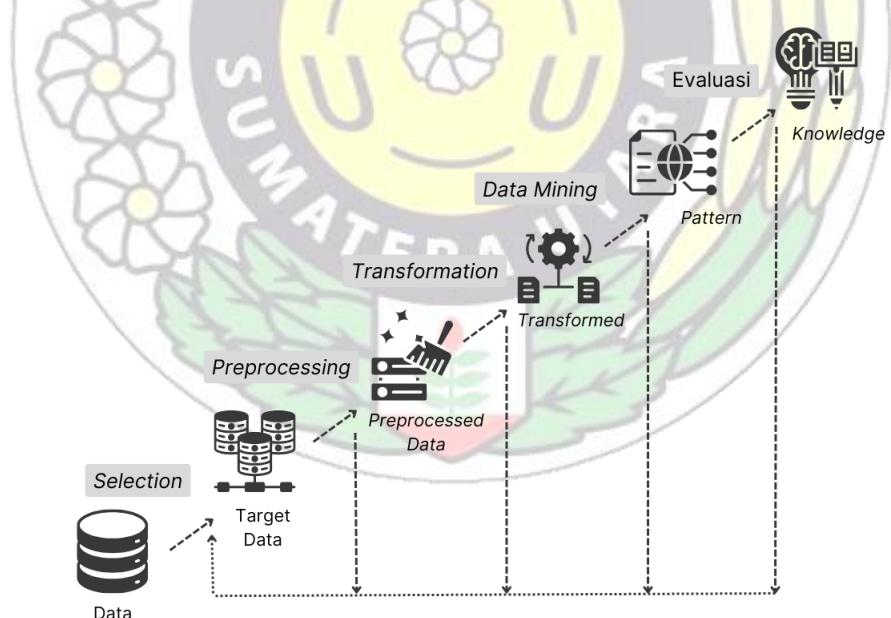
*Data mining* adalah proses mengekstraksi informasi berharga dari dataset besar yang kompleks. Metode ini menggunakan teknik analisis statistik, kecerdasan buatan, dan *machine learning* untuk menemukan pola-pola tersembunyi, hubungan, atau tren dalam data yang tidak mudah terlihat dengan analisis tradisional.



**Gambar 2.1. Core Task of Data Mining**

Sumber: Pearson Education (2nd ed.)

Gambar tersebut menunjukkan inti dari *data mining* yang mencakup empat teknik utama untuk mengekstrak informasi dari data: *cluster analysis*, *predictive modeling*, *association analysis*, dan *anomaly detection*. *Cluster analysis* bertujuan mengelompokkan data berdasarkan kesamaan sehingga data dalam satu kelompok lebih mirip dibandingkan dengan kelompok lain, seperti identifikasi segmen pelanggan. *Predictive modeling* memanfaatkan pola dalam data untuk memprediksi hasil masa depan, contohnya memprediksi status peminjam bermasalah dengan menggunakan pohon keputusan. *Association analysis* menemukan pola yang sering muncul bersamaan dalam data, seperti hubungan antara produk dalam analisis keranjang belanja. Sementara itu, *anomaly detection* berfokus pada mendeteksi data yang menyimpang dari pola umum, misalnya, untuk mendeteksi penipuan pada transaksi kartu kredit. Keseluruhan teknik ini saling melengkapi untuk menganalisis data, mengidentifikasi pola, dan menghasilkan wawasan yang dapat digunakan dalam pengambilan keputusan yang lebih baik.



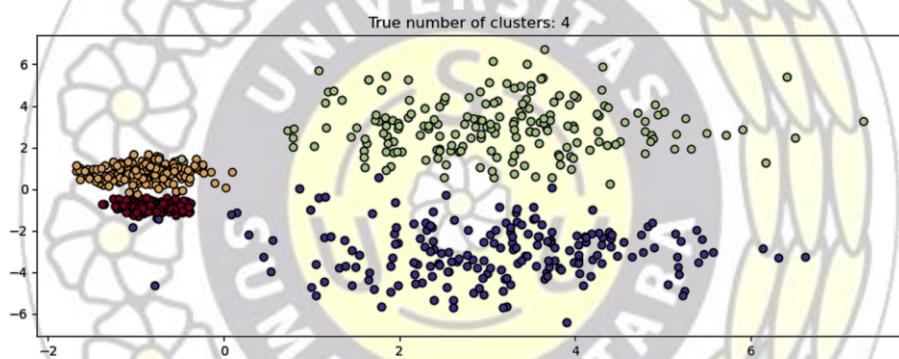
**Gambar 2.2.** Proses *Data Mining*

Proses *data mining* melibatkan beberapa tahapan utama untuk mendapatkan *insight* dari data. Tahap pertama adalah *selection* dimana data yang relevan dipilih dari berbagai sumber untuk dianalisis lebih lanjut. Setelah itu, dilakukan *preprocessing*, yaitu pembersihan data dari ketidakkonsistenan,

duplicasi, atau nilai yang hilang, serta persiapan data agar siap digunakan. Data yang telah diproses kemudian melalui tahap *transformation*, di mana data diubah ke dalam format yang sesuai untuk algoritma data mining, seperti normalisasi atau pembuatan fitur baru.

Tahap inti adalah *data mining*, di mana algoritma digunakan untuk menemukan pola, hubungan, atau informasi tersembunyi sesuai tujuan analisis, seperti *clustering* atau klasifikasi. Terakhir, hasil dari *data mining* dievaluasi pada tahap *evaluation* untuk memastikan kualitas dan relevansinya, sehingga dapat memberikan *insight* yang berguna bagi pengambilan keputusan. Proses ini bersifat iteratif, memungkinkan setiap tahap disesuaikan berdasarkan kebutuhan untuk hasil yang optimal.

## 2.5. Clustering



Gambar 2.3. Visualisasi Clustering

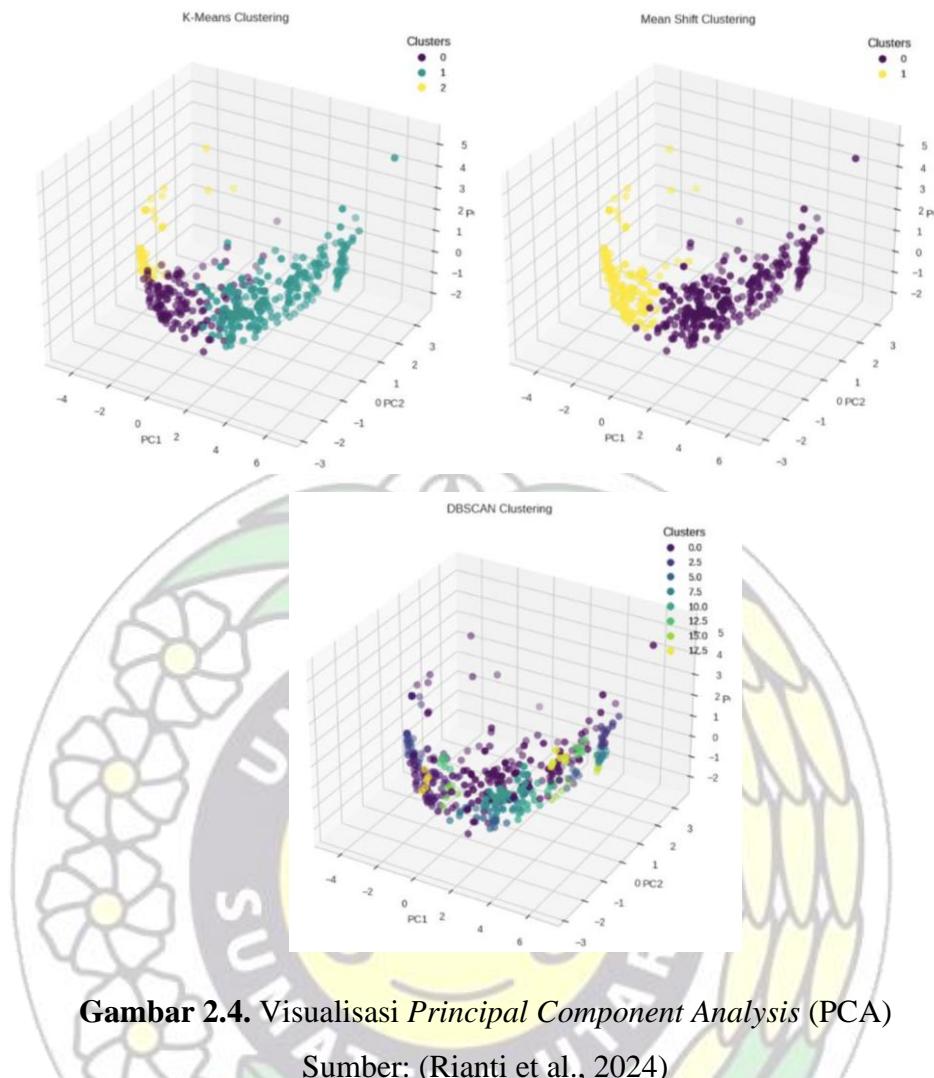
Sumber: ([scikit-learn.org/clustering.html](https://scikit-learn.org/clustering.html))

Menurut (Anggraeni et al., 2023) *clustering* adalah teknik yang digunakan untuk mengelompokkan data dengan tujuan mengidentifikasi kelompok-kelompok atau *cluster* berdasarkan kesamaan antar elemen yang lebih kecil. *Clustering* berdasarkan kategori kemiripan dapat dibagi menjadi dua metode utama, yaitu metode hierarki dan metode non-hierarki. Metode hierarki secara umum menghasilkan diagram pohon (*tree diagram*) dan dendogram yang menggambarkan pengelompokan objek berdasarkan jarak antar objek. Sementara itu, metode non-hierarki, juga dikenal sebagai metode partisi, membagi objek menjadi beberapa *cluster* tanpa membentuk hierarki. Setiap objek dikelompokkan berdasarkan kemiripan atau jarak antar objek yang didefinisikan sebelumnya (Wahyuni et al., 2021).

Selain itu, *clustering* merupakan salah satu metode yang sering diterapkan dalam *data mining* (Faujia et al., 2022). *Clustering* melibatkan proses pemartisian suatu kumpulan objek data menjadi sub-kumpulan yang dikenal sebagai *cluster*. Metode ini berfungsi untuk mengidentifikasi kelompok-kelompok tersembunyi dalam data. Dalam bidang *business intelligence*, *clustering* dimanfaatkan untuk mengelompokkan pelanggan ke dalam berbagai kategori berdasarkan karakteristik yang serupa. Proses ini sering disebut sebagai segmentasi data, karena *clustering* membagi dataset menjadi beberapa grup yang memiliki kemiripan (Fadilah et al., 2022).

Selain teknik klasterisasi, analisis utama dapat diperkuat dengan *Principal Component Analysis* (PCA), adalah teknik statistik yang digunakan untuk mereduksi dimensi data dengan tetap mempertahankan informasi yang signifikan. Analisis Komponen Utama PCA adalah teknik statistik yang digunakan untuk mereduksi dimensi data dengan mengubah sejumlah variabel yang saling berkorelasi menjadi sejumlah kecil variabel baru yang tidak berkorelasi, yang disebut komponen utama. Dalam penelitian ini, PCA diterapkan setelah klasterisasi untuk memproyeksikan hasil klaster ke dalam dimensi yang lebih rendah, sehingga memudahkan interpretasi dan visualisasi pola tiap kelompok. PCA juga membantu mengidentifikasi kontribusi masing-masing indikator dalam membentuk klaster serta karakteristik utama yang membedakan setiap wilayah dalam penanganan *stunting*.

Pada penelitian (Rianti et al., 2024) menunjukkan bahwa penerapan PCA sebelum klasterisasi dapat meningkatkan akurasi dalam pengelompokan data mutu perguruan tinggi. Dalam penelitian ini, digunakan tiga algoritma clustering—K-Means, Mean Shift, dan DBSCAN—with Mean Shift memberikan hasil terbaik berdasarkan tiga metrik evaluasi (*Silhouette Score*, *Davies-Bouldin Index*, dan *Calinski-Harabasz Index*). PCA membantu mengurangi kompleksitas data tanpa kehilangan informasi penting, sehingga memperbaiki performa algoritma *clustering* dalam mengelompokkan perguruan tinggi berdasarkan indikator mutu.



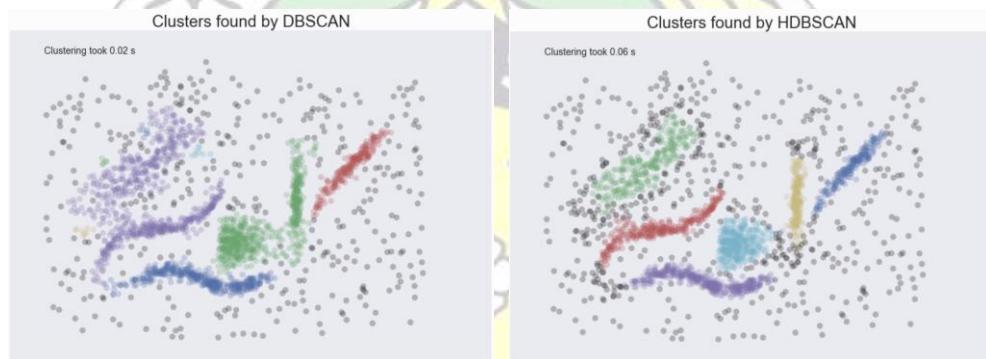
**Gambar 2.4.** Visualisasi *Principal Component Analysis* (PCA)

Sumber: (Ranti et al., 2024)

Visualisasi PCA menunjukkan perbedaan pola clustering pada setiap algoritma. K-Means membentuk tiga *cluster* yang cukup jelas namun masih memiliki sedikit tumpang tindih antar kelompok. Mean Shift menghasilkan *cluster* yang lebih fleksibel dalam bentuk dan ukuran, dengan pemisahan yang lebih optimal berdasarkan metrik evaluasi. Sementara itu, DBSCAN mampu mendeteksi *outlier* dan membentuk *cluster* yang tidak beraturan, namun performanya lebih rendah karena bergantung pada pemilihan parameter. Dari ketiga algoritma, Mean Shift memberikan hasil terbaik dengan pemisahan *cluster* yang lebih jelas dan kompak. Dengan demikian, penerapan PCA dalam penelitian ini diharapkan dapat memperjelas klasterisasi dengan mereduksi dimensi, sehingga pola pengelompokan lebih terlihat.

## 2.6. Algoritma *Hierarchical Density-Based Spatial Clustering of Applications with Noise* (HDBSCAN)

*Hierarchical Density-Based Spatial Clustering of Applications with Noise* (HDBSCAN) adalah algoritma klasterisasi yang populer karena kemampuannya untuk mengelola data dengan keberadaan *noise* secara efisien. Algoritma ini unggul dalam mengidentifikasi klaster dalam dataset yang bervariasi tanpa memerlukan definisi awal jumlah klaster, serta memberikan ketahanan terhadap *noise* pada data (Ghamarian et al., 2019). HDBSCAN bekerja dengan cara membentuk klaster dari data yang memiliki kepadatan tinggi, sehingga memungkinkan pengelompokan yang lebih akurat dan fleksibel dibandingkan algoritma tradisional seperti DBSCAN.

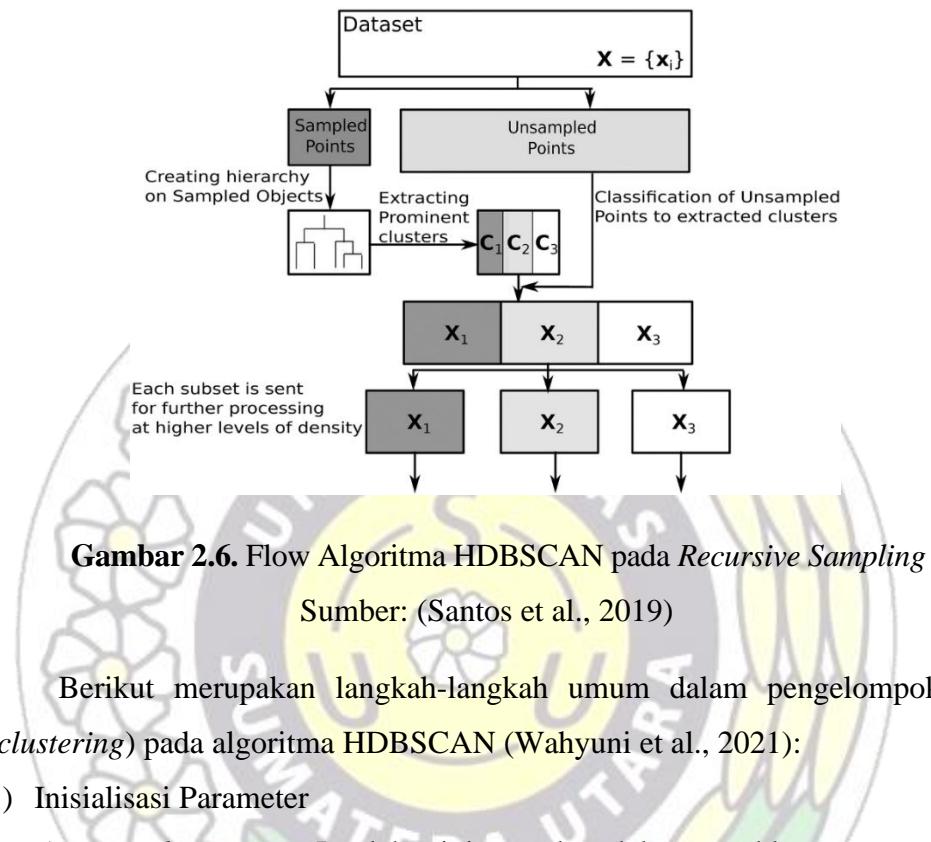


**Gambar 2.5.** Perbedaan Cluster DBSCAN dan HDBSCAN

Sumber: <https://hdbscan.readthedocs.io/>

Selain itu, algoritma ini tidak memerlukan input jumlah klaster di awal, melainkan secara otomatis membentuk klaster berdasarkan struktur data yang ada. Dengan pendekatan hierarkisnya, HDBSCAN dapat menemukan klaster di berbagai tingkat kepadatan, yang sangat berguna untuk data dengan variasi densitas. Algoritma ini sering digunakan dalam analisis data geografis, jaringan sosial, dan dataset kompleks lainnya karena kemampuannya dalam menangani *outlier* dan variabilitas data yang tinggi (Wahyuni et al., 2021). Dalam penelitian yang dilakukan oleh (Santos et al., 2019) mengusulkan pendekatan *Recursive Sampling* dalam klasterisasi data yang tidak dapat diproses sepenuhnya dalam satu node. Ide utama dari pendekatan ini adalah menggunakan sampel yang menangkap klaster paling menonjol sebagai

representasi kasar dari struktur dataset secara keseluruhan. Klaster-klaster ini membentuk tingkat atas hierarki klaster. Penelitian ini menggunakan algoritma HDBSCAN untuk mengklasterkan sampel dan mengekstrak klaster utama menggunakan kerangka FOSC (Santos et al., 2019).



Berikut merupakan langkah-langkah umum dalam pengelompokan (*clustering*) pada algoritma HDBSCAN (Wahyuni et al., 2021):

1) Inisialisasi Parameter

- min\_cluster\_size*: Jumlah minimum data dalam satu klaster.
  - 2020 = 6
  - 2021 = 5
  - 2022 = 7
- min\_samples*: Minimum sampel untuk menentukan *core point* (titik inti klaster). Semua tahun = 3.
- cluster\_selection\_epsilon*: Radius yang memberikan fleksibilitas pada seleksi klaster dalam hierarki.
  - 2020, 2021 = 0.2
  - 2022 = 0.3
- metric*: Menggunakan jarak *Euclidean* untuk menghitung jarak antar titik.

$$d_{(p,q)} = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

Keterangan:

- $d_{(p,q)}$  : Jarak *Euclidean* antara dua titik p dan q
  - $n$  : Dimensi ruang data
  - $p_i$  : Komponen ke-i dari titik p
  - $q_i$  : Komponen ke-i dari titik q.
- e)  $\text{gen\_min\_span\_tree}$  = Membuat *Minimum Spanning Tree* (MST) untuk menghitung stabilitas.

## 2) Menentukan Titik *Core Point*

- a) Gunakan parameter *min\_samples* (misal: 3) untuk menghitung jarak inti (*core distance*) dari setiap titik  $x_p$  menggunakan persamaan:

$$d_{\text{core}}(x_p) = k - \text{distance}(x_p)$$

Keterangan:

- $k$  :  $\text{min\_samples} - 1$ , jika  $\text{min\_samples} = 3$ , maka  $k = 3 - 1 = 2$ .
- $k - \text{distance}(x_p)$  : Jarak antara titik  $x_p$  dan titik  $k$ -terdekatnya, dihitung menggunakan jarak *Euclidean*:

$$d_{(p,q)} = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

- b) Sebuah titik menjadi *core point* jika jumlah titik yang berada dalam radius *cluster\_selection\_epsilon* lebih besar atau sama dengan *min\_samples*.

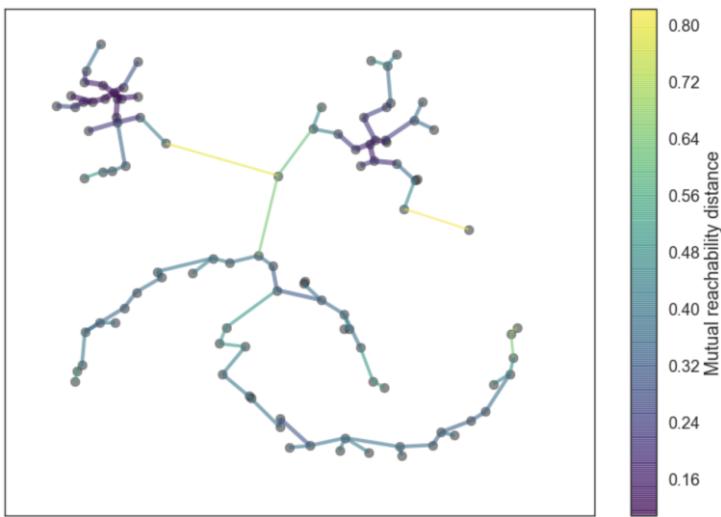
## 3) Menghitung Jarak *Mutual Reachability*

Menggunakan *metric\_euclidean*, untuk hitung jarak mutual reachability untuk setiap pasangan titik:

$$d_{\text{reachability}}(p, q) = \max(d_{\text{core}}(p), d_{\text{core}}(q), d(p, q))$$

## 4) Membuat *Minimum Spanning Tree* (MST)

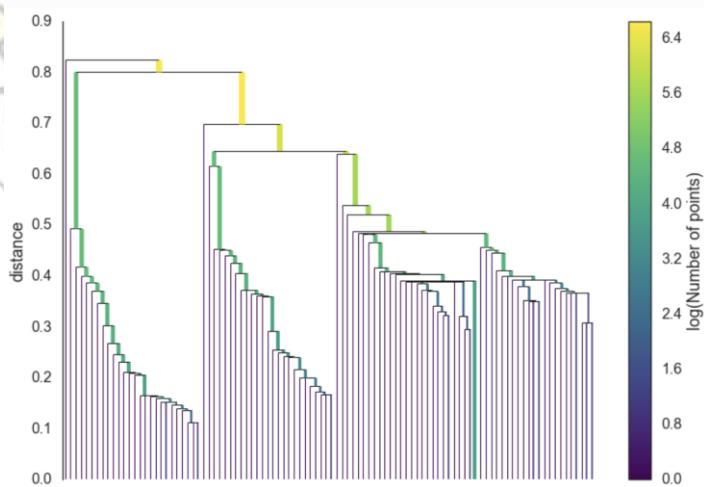
Dengan menggunakan jarak *mutual reachability*, bangun *Minimum Spanning Tree* (MST) untuk menentukan hierarki klaster berdasarkan kestabilan klaster.



**Gambar 2.7. Minimum Spanning Tree HDBSCAN**

Sumber: <https://hdbscan.readthedocs.io/>

- 5) Menentukan *Cluster* Berdasarkan Densitas
- Gunakan parameter *min\_cluster\_size* untuk menentukan klaster.
  - Titik yang memenuhi kriteria berikut akan dimasukkan ke dalam klaster. *Density-reachable*: terhubung secara langsung atau tidak langsung dengan *core point* radius  $\epsilon$ . Titik yang bukan *noise* harus memiliki cukup tetangga dalam radius  $\epsilon$ .



**Gambar 2.8. Dendrogram HDBSCAN**

Sumber: <https://hdbscan.readthedocs.io/>

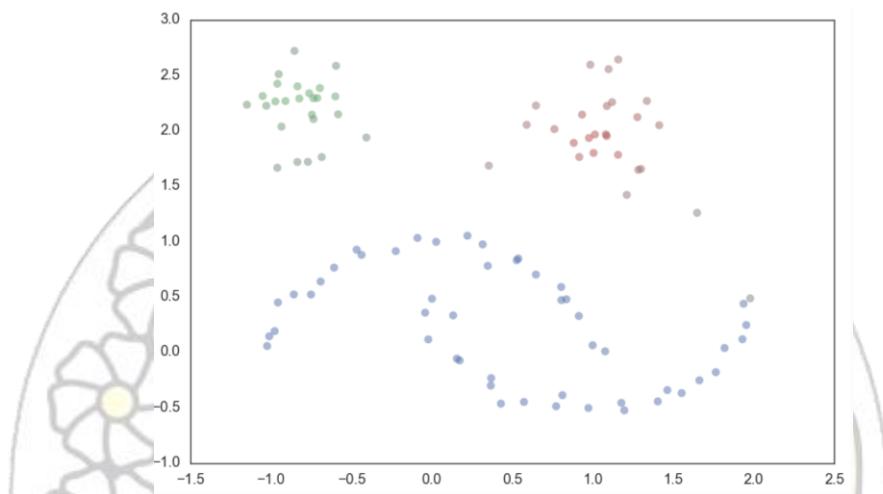
- 6) Mengevaluasi Stabilitas *Cluster*
- Evaluasi stabilitas klaster menggunakan *gen\_min\_span\_tree=True*

untuk menghasilkan stabilitas *cluster* berdasarkan dendogram.

$$S(C) = \sum_{i \in C} (\lambda_{start}(i) - \lambda_{end}(i))$$

#### 7) Ekstrak Hasil Akhir Klasterisasi

Klaster final diperoleh dari hierarki yang dihasilkan yaitu *Border points* (titik batas) dimasukkan ke dalam klaster terdekat. Titik-titik yang tidak termasuk dalam klaster dianggap sebagai *noise*.



**Gambar 2.9.** Hasil Klaster HDBSCAN

Sumber: <https://hdbscan.readthedocs.io/>

## BAB 3

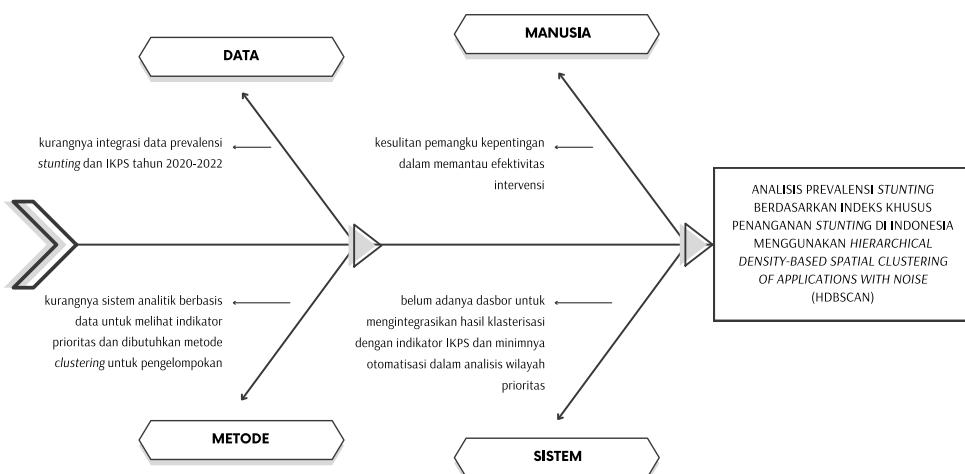
### ANALISIS DAN PERANCANGAN SISTEM

#### 3.1. Analisis Sistem

Analisis sistem dilakukan untuk memastikan semua fungsi berjalan sesuai tujuan serta meminimalkan kemungkinan kesalahan dalam perancangan sistem. Analisis ini mencakup:

##### 3.1.1. Analisis Masalah

Permasalahan utama yang diidentifikasi adalah belum adanya dasbor yang menampilkan pemetaan klasterisasi prevalensi *stunting* sekaligus Indeks Khusus Penanganan *Stunting* (IKPS) untuk tahun 2020-2022. Akibatnya, sulit untuk menentukan indikator mana yang memerlukan perhatian lebih dalam penanganannya, sehingga intervensi yang dilakukan belum maksimal. Oleh karena itu, dirancang sebuah sistem klasterisasi untuk mengelompokkan wilayah kabupaten/kota berdasarkan indikator penanganan *stunting*. Sistem ini bertujuan untuk memberikan hasil analisis yang divisualisasikan melalui dasbor, untuk mengetahui lebih detail, dapat dilihat pada diagram Ishikawa atau *Fishbone* pada gambar berikut.



**Gambar 3.1.** Diagram Ishikawa/*fishbone*

Pada Gambar 3.1., setiap kategori permasalahan divisualisasikan dalam diagram Ishikawa untuk membantu menjelaskan akar penyebab dari permasalahan dan keterkaitan antar faktor. Solusi dari permasalahannya yaitu melakukan klasterisasi terlebih dahulu kemudian membangun dasbor untuk menganalisis prevalensi *stunting* berdasarkan indikator penanganan di Indonesia.

### **3.1.2. Analisis Kebutuhan**

Pada bagian analisis kebutuhan merupakan bagian yang berfokus pada identifikasi kebutuhan sistem yang akan dirancang, mencakup aspek fungsional dan non-fungsional.

#### **3.1.2.1. Analisis Kebutuhan Fungsional**

Adapun beberapa hal yang dibutuhkan secara fungsional pada penelitian ini, yaitu:

1. Sistem memberikan informasi klasterisasi wilayah berdasarkan indikator penanganan *stunting* yang divisualisasikan dalam bentuk peta interaktif. Titik-titik lokasi kabupaten/kota ditampilkan menggunakan pemetaan *folium (leaflet)*, dengan metode klaster menggunakan HDBSCAN untuk mengelompokkan wilayah dengan kondisi prevalensi *stunting* dan indikator penanganannya.
2. Sistem memberikan analisis prevalensi *stunting* berdasarkan indikator seperti gizi, sanitasi, imunisasi, dan air minum layak, yang diolah dari data Indeks Khusus Penanganan *Stunting* (IKPS). Hasil analisis membantu mengidentifikasi indikator penanganan yang perlu ditingkatkan di setiap wilayah.

#### **2.1.2.2. Analisis Kebutuhan Non Fungsional**

Adapun beberapa hal yang dibutuhkan secara non fungsional pada penelitian ini yaitu:

1. Sistem *interface* dirancang sederhana dan mudah digunakan oleh pengguna tanpa memerlukan perangkat prasyarat apapun.
2. Sistem memerlukan koneksi internet agar dapat diakses pengguna.

### 3.1.3. Analisis Proses

Dalam penelitian ini, sistem yang diterapkan adalah dasbor untuk memetakan prevalensi *stunting* di Indonesia. Data prevalensi *Stunting* akan klasterisasi terlebih dahulu menggunakan algoritma HDBSCAN berdasarkan indikator-indikator khusus penanganan *stunting*, kemudian membangun dasbor untuk menghasilkan pemetaan wilayah berdasarkan klaster tertentu. Proses kerja sistem ini mencakup:

#### 1. Pengumpulan dan *Data Preprocessing*

##### a. Pengumpulan Data

Penelitian ini menggunakan dua jenis sumber data, yaitu data prevalensi *stunting* dan data Indeks Khusus Penanganan *Stunting* (IKPS). Data prevalensi *stunting* dengan total 3.796 data yang mencakup informasi tahun, provinsi, Kab/kota, jumlah balita, jumlah *stunting* dan prevalensi *stunting*. Dan untuk IKPS dengan total 15.950 data meliputi tahun, provinsi, Kab/kota, imunisasi, penolong persalinan oleh tenaga kesehatan di fasilitas kesehatan, KB modern, ASI eksklusif, MPASI, air minum layak, sanitasi layak, PAUD, kepemilikan jkn/jamkesda, penerima bantuan pangan.

##### b. *Data Preprocessing*

- 1) Penggabungan Data: Menggabungkan dataset prevalensi dan data IKPS untuk menganalisis secara menyeluruh.
- 2) Pembersihan Data: Menghapus kolom yang sama (duplikat) dan baris yang bernilai kosong (*NaN*).
- 3) Pengecekan Tipe Data: Memeriksa tipe data (*integer*, *float*, *string*) untuk memastikan setiap kolom sesuai.
- 4) *Feature Selection* (Pemilihan Fitur): Memilih kolom atau atribut yang relevan dan berkontribusi terhadap analisis atau pemodelan.
- 5) Transformasi Data: Merubah skala pengukuran data asli

menjadi bentuk yang berbeda. *Reverse scaling* (perbalikan skala) pada kolom ‘Prevalensi’ yang memiliki skala yang berbeda (prevalensi buruk jika nilai tinggi), maka dilakukan transformasi agar skala nilainya sebanding yaitu dengan rumus ( $x_{baru} = Nilai\ Max - x$ ).

- 6) Pemisahan Data berdasarkan Tahun: Pemisahan data dilakukan untuk pengelompokan dan klasterisasi per tahun (2020, 2021 dan 2022).
- 7) Normalisasi Data: Mengubah data menjadi skala nilai antara 0 sampai 1 menggunakan metode *Min-Max Scaling*:

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

## 2. Penerapan Klasterisasi HDBSCAN

- a. Setelah dilakukan *preprocessing*, maka data siap untuk dilakukan klasterisasi. Klasterisasi dilakukan dengan menggunakan algoritma HDBSCAN (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*). Algoritma *clustering* berbasis kepadatan untuk menghasilkan klaster yang hierarkis dan mendeteksi *outlier*.
- b. Parameter penting yang digunakan dalam klasterisasi HDBSCAN adalah sebagai berikut:
  - 1) *Min\_cluster\_size*: nilai minimum jumlah data dalam satu klaster.
  - 2) *Min\_samples*: nilai minimum sampel untuk menemukan inti klaster.
  - 3) *Cluster\_selection\_epsilon*: radius untuk fleksibilitas klaster.
  - 4) *Metric Euclidean*: metrik yang digunakan jarak *Euclidean*.
  - 5) *Gen\_min\_span\_tree*: membuat pohon minimum untuk menghitung stabilitas klaster.

3. Integrasi kedalam Sistem Dasbor Visualisasi
  - a. Dasbor Visualisasi *Framework Streamlit*: Data hasil klasterisasi menggunakan HDBSCAN diintegrasikan ke dalam dasbor visualisasi berbasis *Streamlit*. Sistem ini menghubungkan analisis data dengan antarmuka pengguna berbasis *website* untuk visualisasi interaktif.
  - b. Inputan: Pengguna memasukkan Provinsi, Kabupaten/kota dan Tahun melalui antarmuka *Streamlit*.
  - c. Pemrosesan Sistem: Sistem *Streamlit* akan me-*running* ulang berdasarkan inputan yang dimasukkan pengguna.
  - d. *Output*: Hasilnya ditampilkan di halaman web *Streamlit* meliputi pemetaan wilayah klasterisasi yang menunjukan klaster setiap indikator berdasarkan inputan Provinsi, Kabupaten/kota dan Tahun, perangkingan wilayah prioritas, tampilan diagram indikator, grafik perbandingan prevalensi dengan IKPS dan kesimpulan hasil analisis keseluruhan.
4. Tampilan Hasil di Dasbor
  - a. *User Interface/Tampilan Antarmuka*
    - 1) Desain antarmuka berbasis *web* yang sederhana dan mudah dipahami pengguna menggunakan *Streamlit*.
    - 2) Bagian atas halaman menampilkan judul seperti "*Dashboard Prevalensi Stunting berdasarkan Indeks Khusus Penanganan Stunting di Indonesia*".
    - 3) Input berupa *dropdown* atau filter untuk memilih tahun, provinsi dan kabupaten/kota yang terletak di sisi kiri halaman.
  - b. Input Pengguna
    - 1) *Dropdown* Tahun: Berisi opsi tahun (2020, 2021, 2022).
    - 2) *Dropdown* Provinsi: Memuat daftar provinsi di Indonesia.
    - 3) *Dropdown* Kabupaten/kota: Memuat kabupaten/kota di provinsi yang telah dipilih sebelumnya.

- c. Visualisasi Peta Wilayah Klasterisasi
  - 1) *Expander* Informasi: Tampilan untuk informasi terkait klasterisasi tiap tahunnya.
  - 2) *Expander* Tabel: Fitur ini jika pengguna ingin melihat data secara keseluruhan yang dapat dipilih berdasarkan kolom.
  - 3) Peta Interaktif: Menampilkan peta wilayah Indonesia dengan penanda *cluster* di kabupaten/kota yang diberi warna berdasarkan hasil klasterisasi. Legenda klaster yang menjelaskan arti dari warna atau label klaster dan *Tooltip* Interaktif untuk menampilkan infomasi tambahan (nama Kab/kota, prevalensi *stunting* dan nilai IKPS) ketika kursor diarahkan ke wilayah tertentu.
- d. Tabel Perangkingan Wilayah Prioritas: Tampilan perangkingan akan muncul berdasarkan inputan dipilih. Wilayah teratas adalah wilayah yang klaster yang memiliki prevalensi tertinggi dan IKPS rendah.
- e. Analisis Indikator Wilayah
  - 1) Diagram Batang: Menampilkan perbandingan indikator wilayah input (Kabupaten/kota) dengan rata-rata provinsi dengan rata-rata nasional.
  - 2) *Line Chart*: Menampilkan grafik garis perbandingan persentase prevalensi dengan IKPS berdasarkan tahun.
  - 3) Kesimpulan Hasil Analisis: Menampilkan hasil analisis wilayah prevalensi *stunting* dan indikator yang masih kurang maksimal.

#### **3.1.4. Analisis Data**

Data yang digunakan diperoleh dari Publikasi Kementerian Dalam Negeri melalui Ditjen Bina Pembangunan Daerah dan Publikasi Tim Percepatan Penanganan *Stunting* melalui buku Indeks Khusus Penanganan *Stunting* (IKPS) yang meliputi 34 provinsi, 476 kabupaten/kota di Indonesia selama periode 2020-2022, dengan total

19.746 data (sebelum di *preprocessing*) dan 13.188 data (setelah di *preprocessing*). Berikut merupakan proses analisis data yang dilakukan:

**Tabel 3.1.** Atribut dan Deskripsi Data

No	Atribut	Deskripsi
1	Provinsi	Nama provinsi di Indonesia.
2	Kab/Kota	Nama kabupaten/kota di Indonesia.
3	Tahun	Tahun analisa yaitu 2020, 2021 dan 2022.
4	Jumlah Balita	Jumlah balita di wilayah per Kab/kota tertentu.
5	Jumlah <i>Stunting</i>	Jumlah balita yang terkena <i>stunting</i> di wilayah per Kab/kota tertentu.
6	Prevalensi	Persentase balita yang terkena <i>stunting</i> di wilayah tertentu.
7	Imunisasi	Persentase anak berusia 12-23 bulan yang mendapatkan imunisasi dasar lengkap.
8	Penolong persalinan oleh tenaga kesehatan di fasilitas kesehatan	Persentase perempuan pernah kawin (PPK) usia 15-49 tahun yang proses persalinan terakhirnya dibantu oleh tenaga kesehatan terlatih di fasilitas kesehatan.
9	KB modern	Proporsi perempuan usia 15-49 tahun atau pasangannya yang aktif secara seksual, ingin menunda atau tidak menambah anak, dan menggunakan kontrasepsi modern.
10	ASI eksklusif	Persentase bayi di bawah enam bulan yang menerima ASI eksklusif.
11	MP ASI	Persentase anak usia 6-23 bulan yang menerima makanan pendamping ASI.
12	Air minum layak	Persentase rumah tangga yang memiliki akses ke layanan air minum layak.
13	Sanitasi layak	Persentase rumah tangga yang memiliki akses ke layanan sanitasi layak dan berkelanjutan.
14	PAUD	Angka Partisipasi Kasar (APK) PAUD untuk anak usia 3-6 tahun.
15	Kepemilikan JKN/jamkesda	Persentase penduduk yang mendapatkan JKN/jamkesda.
16	Penerima bantuan pangan	Persentase rumah tangga yang menerima KPS/KKS atau bantuan pangan.
17	Dimensi Kesehatan	Persentase rata-rata yang termasuk dimensi kesehatan (imunisasi, penolong persalinan oleh tenaga kesehatan di fasilitas kesehatan dan KB modern).
18	Dimensi Gizi	Persentase rata-rata yang termasuk dimensi gizi (ASI eksklusif dan MP ASI).
19	Dimensi Perumahan	Persentase rata-rata yang termasuk dimensi perumahan (air minum layak dan sanitasi layak).
20	Dimensi Pendidikan	Persentase rata-rata yang termasuk dimensi

		pendidikan (PAUD).
21	Dimensi Perlindungan Sosial	Persentase rata-rata yang termasuk dimensi perlindungan sosial (kepemilikan JKN/jamkesda).
22	IKPS	Persentase rata-rata seluruh indikator penanganan <i>stunting</i> per dimensi.

**Tabel 3.2.** Data Prevalensi dan IKPS (Atribut Provinsi s/d Prevalensi)

Provinsi	Kab/Kota	Tahun	Jumlah Balita	Jumlah Stunting	Prevalensi
Aceh	Aceh Tenggara	2020	15947	1711	10.7
Aceh	Aceh Timur	2020	31161	9269	29.7
Aceh	Aceh Tengah	2020	17373	1609	9.3
Aceh	Pidie	2020	1598	142	8.9
Aceh	Bireuen	2020	44230	879	2
Aceh	Gayo Lues	2020	8506	643	7.6
Aceh	Nagan Raya	2020	13621	2345	17.2
Aceh	Bener Meriah	2020	9720	1679	17.3
Aceh	Kota Subulussalam	2020	10983	1718	15.6
Sumatera Utara	Nias	2020	4699	1200	25.5
...	...	...	...	...	...
Maluku Utara	Kota Tidore Kepulauan	2022	4700	350	7.4
Papua Barat	Fakfak	2022	6832	1590	23.3
Papua Barat	Kaimana	2022	6162	577	9.4
Papua Barat	Teluk Wondama	2022	3907	190	4.9
Papua Barat	Teluk Bintuni	2022	2455	408	16.6
Papua Barat	Manokwari	2022	13487	1400	10.4
Papua Barat	Manokwari Selatan	2022	2708	73	2.7

**Tabel 3.3.** Data Prevalensi dan IKPS (Atribut Imunisasi s/d Air Minum Layak)

Imunisasi	Penolong Persalinan oleh Tenaga Kesehatan di Fasilitas Kesehatan	KB Modern	ASI Eksklusif	MP ASI	Air Minum Layak
10.7	59.6	57.7	81.9	81.2	90.9
12	86.6	64.2	42.8	49.3	74.7
48.9	86.3	86	73.3	98.3	89.4
13.4	96	46.9	94	99.3	90.3
25.8	96.4	40.3	100	100	91.3
7.6	52.2	83.7	100	87	71.8
25.3	92.8	66.7	94.8	59.5	93.3
42.3	95.9	87.4	78.2	93.6	89.5

11.3	73.6	51	100	83.5	64.3
23.2	44.3	55.4	84.5	43.8	49.5
...	...	...	...	...	...
68.4	94.4	56.8	100	88.4	97.7
70.9	76.7	45	78.8	80.8	98.5
77.6	51.4	27.9	62	65.4	85.9
44.2	45.5	27.9	63.4	64.9	24
68.2	71.3	42.8	100	75.8	87.5
62.9	88.7	49.3	77.1	76.8	81.1
70.9	79	39.9	80.3	58.1	89.3

**Tabel 3.4.** Data Prevalensi dan IKPS (Atribut Sanitasi Layak s/d Penerima Bantuan Pangan)

Sanitasi Layak	PAUD	Kepemilikan JKN/jamkesda	Penerima Bantuan Pangan
54	26.2	92.2	35
74.7	23.4	97.6	46.7
81.3	37	97.5	32.4
63.5	23.7	96.5	80.3
84.2	26.5	97.4	65.5
43.3	19.9	99.6	47.8
80.4	30	96.5	34.3
84.1	22.1	99.1	42
73.5	33.1	95.3	37.8
17.8	11.5	62.5	37.8
...	...	...	...
89.6	41.6	62.3	9.4
69.2	35.3	74	41.8
76.5	23.9	62.4	29.7
53	35.8	82.1	38.1
78.6	25.8	99.9	24.4
82.6	29.8	60	15.9
88.4	39.4	73.4	25.4

**Tabel 3.5.** Data Prevalensi dan IKPS (Atribut Dimensi Kesehatan s/d IKPS)

Dimensi Kesehatan	Dimensi Gizi	Dimensi Perumahan	Dimensi Pendidikan	Dimensi Perlindungan Sosial	IKPS
42.7	81.6	72.5	26.2	63.6	57.3
54.3	46.1	74.7	23.4	72.2	54.1
73.7	85.8	85.4	37	65	69.4
52.1	96.7	76.9	23.7	88.4	67.6
54.2	100	87.8	26.5	81.5	70
47.8	93.5	57.6	19.9	73.7	58.5
61.6	77.2	86.9	30	65.4	64.2

75.2	85.9	86.8	22.1	70.6	68.1
45.3	91.8	68.9	33.1	66.6	61.1
41	64.2	33.7	11.5	50.2	40.1
...	...	...	...	...	...
73.2	94.2	93.7	41.6	35.9	67.7
64.2	79.8	83.9	35.3	57.9	64.2
52.3	63.7	81.2	23.9	46.1	53.4
39.2	64.2	38.5	35.8	60.1	47.6
60.8	87.9	83.1	25.8	62.2	63.9
67	77	81.9	29.8	38	58.7
63.3	69.2	88.9	39.4	49.4	62

Data diatas merupakan data yang telah digabungkan (data prevalensi dan data indikator penanganan). Dan telah dilakukan pembersihan data yang duplikat serta penghapusan data yang kosong (*Nan*). Selanjutnya dilakukan pengecekan tipe data, untuk memastikan bahwa seluruh data sudah sesuai. Setelah tipe data sudah sesuai, maka dilakukan *feature selection* (pemilihan fitur) yang relevan yang benar-benar berkontribusi untuk dilakukan pemodelan pengelompokan data.

**Tabel 3.6.** Hasil *Feature Selection* (Atribut Tahun s/d ASI Eksklusif)

Tahun	Prevalensi	Imunisasi	Penolong Persalinan oleh Tenaga Kesehatan di Fasilitas Kesehatan	KB Modern	ASI Eksklusif
2020	10.7	10.7	59.6	57.7	81.9
2020	29.7	12	86.6	64.2	42.8
2020	9.3	48.9	86.3	86	73.3
2020	8.9	13.4	96	46.9	94
2020	2	25.8	96.4	40.3	100
2020	7.6	7.6	52.2	83.7	100
2020	17.2	25.3	92.8	66.7	94.8
2020	17.3	42.3	95.9	87.4	78.2
2020	15.6	11.3	73.6	51	100
2020	25.5	23.2	44.3	55.4	84.5
...	...	...	...	...	...
2022	7.4	68.4	94.4	56.8	100
2022	23.3	70.9	76.7	45	78.8
2022	9.4	77.6	51.4	27.9	62
2022	4.9	44.2	45.5	27.9	63.4
2022	16.6	68.2	71.3	42.8	100
2022	10.4	62.9	88.7	49.3	77.1
2022	2.7	70.9	79	39.9	80.3

**Tabel 3.7.** Hasil *Feature Selection* (Atribut MP ASI s/d Penerima Bantuan Pangan)

MP ASI	Air Minum Layak	Sanitasi Layak	PAUD	Kepemilikan JKN/jamkesda	Penerima Bantuan Pangan
81.2	90.9	54	26.2	92.2	35
49.3	74.7	74.7	23.4	97.6	46.7
98.3	89.4	81.3	37	97.5	32.4
99.3	90.3	63.5	23.7	96.5	80.3
100	91.3	84.2	26.5	97.4	65.5
87	71.8	43.3	19.9	99.6	47.8
59.5	93.3	80.4	30	96.5	34.3
93.6	89.5	84.1	22.1	99.1	42
83.5	64.3	73.5	33.1	95.3	37.8
43.8	49.5	17.8	11.5	62.5	37.8
...	...	...	...	...	...
88.4	97.7	89.6	41.6	62.3	9.4
80.8	98.5	69.2	35.3	74	41.8
65.4	85.9	76.5	23.9	62.4	29.7
64.9	24	53	35.8	82.1	38.1
75.8	87.5	78.6	25.8	99.9	24.4
76.8	81.1	82.6	29.8	60	15.9
58.1	89.3	88.4	39.4	73.4	25.4

**Tabel 3.8.** Deskripsi Statistik Data

	count	mean	std	min	25%	50%	75%	max
Tahun	974.0	2021.286448	0.771460	2020.0	2021.000	2021.00	2022.000	2022.0
Prevalensi	974.0	11.204928	7.793463	0.0	5.400	9.50	15.300	48.5
Imunisasi	974.0	67.157803	22.590337	3.4	51.600	71.55	84.775	100.0
Penolong Persalinan..	974.0	86.013552	16.087896	9.0	79.975	91.95	97.500	100.0
KB Modern	974.0	64.850205	15.821607	3.2	53.250	66.70	77.375	97.1
ASI Eksklusif	974.0	84.966632	18.248126	0.0	76.025	90.60	100.000	100.0
MP ASI	974.0	83.450924	13.477077	8.0	74.425	85.30	93.900	100.0
Air Minum Layak	974.0	86.962115	12.768511	10.6	81.700	91.10	96.400	100.0
Sanitasi Layak	974.0	78.716735	14.630735	12.2	71.100	81.80	89.700	100.0
PAUD	974.0	40.163142	14.399836	3.2	29.300	37.85	49.400	93.0
Kepemilikan JKN/jamkesda	974.0	68.954312	17.441397	16.5	55.825	67.85	82.375	100.0
Penerima Bantuan Pangan	974.0	41.615811	17.534258	3.1	28.000	40.85	53.400	96.3

Setelah fitur dipilih dan statistik deskriptif dihitung dan ditampilkan, dapat dilihat bahwa terdapat satu atribut yang memiliki skala berbeda yaitu atribut ‘Prevalensi’. Jika nilai angka artibut tersebut lebih tinggi menandakan bahwa atribut tersebut buruk, sedangkan

atribut lainnya jika memiliki nilai angka tinggi maka baik. Jadi dilakukan transformasi data yaitu *reverse scaling* untuk menyamakan seluruh nilai atribut sesuai dan seragam. Dengan perhitungan sebagai berikut.

$$(x_{baru} = \text{Nilai Max} - x)$$

$$Prevalensi_{b1} = 48.5 - 10.7 = 37.8$$

$$Prevalensi_{b2} = 48.5 - 29.7 = 18.8$$

$$Prevalensi_{b3} = 48.5 - 9.3 = 39.2$$

$$Prevalensi_{b4} = 48.5 - 8.9 = 57.4$$

$$Prevalensi_{b5} = 48.5 - 2.0 = 46.5$$

$$Prevalensi_{b6} = 48.5 - 7.6 = 40.9$$

$$Prevalensi_{b7} = 48.5 - 17.2 = 31.3$$

$$Prevalensi_{b8} = 48.5 - 17.3 = 31.2$$

$$Prevalensi_{b9} = 48.5 - 15.6 = 32.9$$

...

$$Prevalensi_{b973} = 48.5 - 10.4 = 38.1$$

$$Prevalensi_{b974} = 48.5 - 2.7 = 45.8$$

**Tabel 3.9.** Perbandingan Atribut ‘Prevalensi’ setelah *Reverse Scalling*

Tahun	Prevalensi	Prevalensi <sub>b</sub>
2020	10.7	37.8
2020	29.7	18.8
2020	9.3	39.2
2020	8.9	57.4
2020	2	46.5
2020	7.6	40.9
2020	17.2	31.3
2020	17.3	31.2
2020	15.6	32.9
2020	25.5	23
...	...	...
2022	7.4	41.1
2022	23.3	25.2
2022	9.4	39.1
2022	4.9	43.6
2022	16.6	31.9

2022	10.4	38.1
2022	2.7	45.8

Tabel diatas dapat terlihat bahwa skala di *reverse* (dibalik) agar ketika proses pengelompokan klaster skalanya tidak berbeda. Ketika diimplementasikan ke visualisasi dasbor dengan nilai asli, hasil klaster sesuai. Terkait hal tersebut seperti nilai prevalensi 40% (buruk) dengan indikator imunisasi 12% (rendah). Setelah skala sudah sesuai, maka selanjutnya dilakukan pemisahan data berdasarkan tahun untuk klasterisasi. Data disimpan dalam format .csv dengan menghasilkan tiga file yaitu *dataStunting2020.csv*, *dataStunting2021.csv* dan *dataStunting2022.csv*.

**Tabel 3.10.** Deskripsi Statistik Per Tahun

	count	mean	std	min	25%	50%	75%	max
<b>Tahun 2020</b>								
Prevalensi	190.0	14.238947	9.202654	0.0	7.300	12.90	19.425	48.5
Imunisasi	190.0	61.714211	22.261730	6.8	46.250	64.70	78.275	100.0
Penolong Persalinan oleh TenagaKesehatan di Fasilitas Kesehatan	190.0	81.655789	18.308215	13.6	71.975	87.70	96.150	100.0
KB Modern	190.0	64.626842	16.055247	8.4	53.375	67.20	77.325	97.1
ASI Eksklusif	190.0	85.471579	16.406159	21.0	78.350	88.65	100.000	100.0
MP ASI	190.0	81.776842	14.347741	40.7	72.450	84.75	92.625	100.0
Air Minum Layak	190.0	84.438947	14.266049	10.6	79.125	89.45	94.500	100.0
Sanitasi Layak	190.0	75.223158	16.006308	17.8	66.250	78.65	87.275	98.0
PAUD	190.0	41.463684	14.217066	11.5	29.800	40.40	49.775	81.5
Kepemilikan JKN/jamkesda	190.0	67.982105	17.154517	33.4	54.775	66.30	78.450	100.0
Penerima Bantuan Pangan	190.0	41.311579	16.266741	7.4	30.525	40.25	50.475	93.4
<b>Tahun 2021</b>								
Prevalensi	315.0	11.447619	7.448410	0.5	5.95	9.7	15.35	43.9
Imunisasi	315.0	68.329841	22.222892	6.1	53.90	72.3	85.80	100.0
Penolong Persalinan oleh TenagaKesehatan di Fasilitas Kesehatan	315.0	86.298730	16.201824	9.0	80.15	92.2	97.85	100.0
KB Modern	315.0	63.872063	16.383553	3.2	52.10	65.6	76.90	95.5
ASI Eksklusif	315.0	86.898413	15.646416	28.3	78.05	92.3	100.00	100.0
MP ASI	315.0	81.977460	13.726249	38.8	73.00	82.7	93.25	100.0

Air Minum Layak	315.0	87.237143	12.610906	19.8	81.90	91.5	96.50	100.0
Sanitasi Layak	315.0	78.619365	14.821586	13.1	70.35	81.8	89.70	100.0
PAUD	315.0	40.011429	14.683319	3.2	28.85	38.0	49.35	93.0
Kepemilikan JKN/jamkesda	315.0	67.676190	17.390571	21.9	55.25	65.7	80.50	99.9
Penerima Bantuan Pangan	315.0	41.653016	16.725944	3.4	28.60	42.3	53.05	89.3
<b>Tahun 2022</b>								
Prevalensi	469.0	9.812793	7.009625	0.1	4.5	8.2	13.9	44.3
Imunisasi	469.0	68.575906	22.683344	3.4	53.0	72.4	86.6	100.0
Penolong Persalinan oleh Tenaga Kesehatan di Fasilitas Kesehatan	469.0	87.587420	14.709509	16.0	82.6	93.0	98.0	100.0
KB Modern	469.0	65.597655	15.330322	18.6	54.4	67.3	77.5	96.5
ASI Eksklusif	469.0	83.464606	20.358912	0.0	73.4	90.4	100.0	100.0
MP ASI	469.0	85.118763	12.754985	8.0	77.4	86.9	95.4	100.0
Air Minum Layak	469.0	87.799574	12.113096	24.0	82.6	91.6	96.8	100.0
Sanitasi Layak	469.0	80.197441	13.675661	12.2	73.2	83.4	90.6	100.0
PAUD	469.0	39.738166	14.280716	9.3	29.2	37.2	48.8	93.0
Kepemilikan JKN/jamkesda	469.0	70.206610	17.539766	16.5	57.0	69.1	85.1	100.0
Penerima Bantuan Pangan	469.0	41.714072	18.563362	3.1	27.5	40.1	54.8	96.3

Tahap terakhir dalam *preprocessing* yaitu normalisasi ketiga file sekaligus untuk menyamaratakan seluruh data menjadi rentang nilai 0 sampai 1 menggunakan metode *Min-Max Scaling* dengan perhitungan sebagai berikut.

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

**Tabel 3.11.** Hasil *Data Preprocessing* Tahun 2020 (Prevalensi s/d MP ASI)

Prevalensi	Imunisasi	Penolong Persalinan..	KB Modern	ASI Eksklusif	MP ASI
0.779381	0.041845	0.532407	0.555806	0.770886	0.682968
0.387629	0.055794	0.844907	0.629087	0.275949	0.145025
0.808247	0.451717	0.841435	0.874859	0.662025	0.971332
0.816495	0.070815	0.953704	0.434047	0.924051	0.988196
0.958763	0.203863	0.958333	0.359639	1	1
0.843299	0.008584	0.446759	0.848929	1	0.780776
0.645361	0.198498	0.916667	0.657272	0.934177	0.317032
0.643299	0.380901	0.952546	0.890643	0.724051	0.892074
0.678351	0.048283	0.694444	0.480271	1	0.721754

0.474227	0.175966	0.355324	0.529876	0.803797	0.052277
...	...	...	...	...	...
0.62268	0.693133	0.762731	0.43292	0.792405	0.306914
0.637113	0.628755	0.893519	0.438557	0.4	0.541315
0.830928	0.100858	0.564815	0.418264	0.667089	0.182125
0.964948	0	0.136574	0	1	0.82968
0.641237	0.417382	0.866898	0.251409	0.348101	0
0.964948	0.320815	0.796296	0.38106	0.822785	0.558179
0.797938	0.624464	0.909722	0.334837	0.701266	0.17032

**Tabel 3.12.** Hasil *Data Preprocessing* Tahun 2020 (Atribut Air Minum Layak s/d Penerima Bantuan Pangan)

Air Minum Layak	Sanitasi Layak	PAUD	Kepemilikan JKN/jamkesda	Penerima Bantuan Pangan
0.89821	0.451372	0.21	0.882883	0.32093
0.717002	0.709476	0.17	0.963964	0.456977
0.881432	0.791771	0.364286	0.962462	0.290698
0.891499	0.569825	0.174286	0.947447	0.847674
0.902685	0.82793	0.214286	0.960961	0.675581
0.684564	0.317955	0.12	0.993994	0.469767
0.925056	0.780549	0.264286	0.947447	0.312791
0.88255	0.826683	0.151429	0.986486	0.402326
0.600671	0.694514	0.308571	0.929429	0.353488
0.435123	0	0	0.436937	0.353488
...	...	...	...	...
0.831096	0.749377	0.391429	0.861862	0.175581
0.87472	0.908978	0.211429	0.493994	0.369767
0.701342	0.856608	0.365714	0.599099	0.265116
0.612975	0.317955	0.11	0.512012	0.090698
0.763982	0.69202	0.334286	0.515015	0.201163
0.940716	0.825436	0.24	0.683183	0.145349
0.964206	0.794264	0.29	0.642643	0.096512

**Tabel 3.13.** Hasil *Data Preprocessing* Tahun 2021 (Atribut Prevalensi s/d MP ASI)

Prevalensi	Imunisasi	Penolong Persalinan..	KB Modern	ASI Eksklusif	MP ASI
0.576037	0.505857	0.96044	0.503792	1	0.816993
0.576037	0.097977	0.818681	0.52546	0.740586	0.316993
0.490783	0.101171	0.91978	0.640303	0.357043	0.429739
0.808756	0.312034	0.913187	0.840737	0.827057	0.617647
0.68894	0.15016	0.951648	0.468039	1	0.836601
0.847926	0.107561	0.948352	0.409534	0.492329	0.550654
0.859447	0.097977	0.898901	0.424702	0.775453	1
0.679724	0.038339	0.83956	0.541712	0.62622	0.449346
0.900922	0.356763	0.453846	0.907909	0.497908	0.843137

0.857143	0.8541	0.972527	0.687974	0.838215	0.511438
...	...	...	...	...	...
0.596774	0.592119	0.816484	0.511376	0	0.555556
0.857143	0.043663	0.718681	0.396533	0.972106	0.78268
0.958525	0	0	0	1	0.710784
0.682028	0.499468	0.824176	0.224269	0.691771	0.076797
0.665899	0.652822	0.861538	0.485374	1	0.294118
0.665899	0.372737	0.374725	0.258938	0.988842	0.658497
0.663594	0.595314	0.881319	0.440953	0.2106	0

**Tabel 3.14.** Hasil *Data Preprocessing* Tahun 2021 (Air Minum Layak s/d Penerima Bantuan Pangan)

Air Minum Layak	Sanitasi Layak	PAUD	Kepemilikan JKN/jamkesda	Penerima Bantuan Pangan
0.842893	0.673188	0.356347	0.989744	0.549476
0.834165	0.570771	0.209354	0.902564	0.220023
0.790524	0.616801	0.198218	0.967949	0.407451
0.876559	0.89183	0.246102	0.95	0.454016
0.780549	0.855006	0.36637	0.965385	0.605355
0.865337	0.471807	0.312918	0.94359	0.80326
0.918953	0.791715	0.396437	0.985897	0.647264
0.889027	0.76985	0.297327	0.924359	0.526193
0.809227	0.397008	0.371938	0.973077	0.476135
0.789277	0.856157	0.35412	0.925641	0.591385
...	...	...	...	...
0.82793	0.849252	0.152561	0.555128	0.280559
0.760599	0.902186	0.302895	0.70641	0.619325
0.781796	0.36939	0	0.635897	0.307334
0.687032	0.668585	0.167038	0.639744	0.300349
0.695761	0.546605	0.252784	0.610256	0.313155
0.321696	0.773303	0.368597	0.941026	0.189756
0.96384	0.83084	0.250557	0.724359	0.138533

**Tabel 3.15.** Hasil *Data Preprocessing* Tahun 2022 (Atribut Prevalensi s/d MP ASI)

Prevalensi	Imunisasi	Penolong Persalinan..	KB Modern	ASI Eksklusif	MP ASI
0.776018	0.407867	0.792857	0.441592	1	0
0.737557	0.450311	0.905952	0.510911	0.808	1
0.721719	0.654244	0.691667	0.459564	0.509	0.932609
0.846154	0.039337	0.895238	0.587933	0.933	0.966304
0.80543	0.371636	0.964286	0.682927	0.705	0.990217
0.88009	0.186335	1	0.473684	0.801	1
0.735294	0.041408	0.982143	0.36457	0.779	0.911957
0.893665	0.158385	0.945238	0.265725	0.74	1
0.920814	0.018634	0.960714	0.349166	0.743	0.88913

0.875566	0	0.829762	0.44801	1	0.873913
...	...	...	...	...	...
0.834842	0.672878	0.933333	0.490372	1	0.873913
0.475113	0.698758	0.722619	0.338896	0.788	0.791304
0.789593	0.768116	0.421429	0.119384	0.62	0.623913
0.891403	0.42236	0.35119	0.119384	0.634	0.618478
0.626697	0.670807	0.658333	0.310655	1	0.736957
0.766968	0.615942	0.865476	0.394095	0.771	0.747826
0.941176	0.698758	0.75	0.273427	0.803	0.544565

**Tabel 3.16.** Hasil *Data Preprocessing* Tahun 2022 (Atribut Air Minum Layak s/d Penerima Bantuan Pangan)

Air Minum Layak	Sanitasi Layak	PAUD	Kepemilikan JKN/jamkesda	Penerima Bantuan Pangan
0.794737	0.759681	0.379928	0.931737	0.740343
0.703947	0.667426	0.761051	0.949701	0.5397
0.918421	0.577449	0	0.973653	0.106223
0.773684	0.648064	0.137395	0.978443	0.370172
0.961842	0.882688	0.173238	0.955689	0.281116
0.940789	0.867882	0.454002	0.982036	0.304721
0.873684	0.812073	0.405018	0.960479	0.592275
0.857895	0.484055	0.199522	0.967665	0.776824
0.931579	0.833713	0.387097	0.980838	0.637339
0.885526	0.759681	0.200717	0.978443	0.530043
...	...	...	...	...
0.969737	0.881549	0.385902	0.548503	0.067597
0.980263	0.649203	0.310633	0.688623	0.415236
0.814474	0.732346	0.174432	0.549701	0.285408
0	0.464692	0.316607	0.785629	0.375536
0.835526	0.756264	0.197133	0.998802	0.228541
0.751316	0.801822	0.244922	0.520958	0.137339
0.859211	0.867882	0.359618	0.681437	0.23927

**Tabel 3.17.** Deskripsi Statistik setelah *Preprocessing*

	count	mean	std	min	25%	50%	75%	max
<b>Tahun 2020</b>								
Prevalensi	190.0	0.706413	0.189745	0.0	0.599485	0.734021	0.849485	1.0
Imunisasi	190.0	0.589208	0.238860	0.0	0.423283	0.621245	0.766899	1.0
Penolong Persalinan..	190.0	0.787683	0.211901	0.0	0.675637	0.857639	0.955440	1.0
KB Modern	190.0	0.633899	0.181006	0.0	0.507046	0.662909	0.777057	1.0
ASI Eksklusif	190.0	0.816096	0.207673	0.0	0.725949	0.856329	1.000000	1.0
MP ASI	190.0	0.692695	0.241952	0.0	0.535413	0.742833	0.875632	1.0
Air Minum Layak	190.0	0.825939	0.159575	0.0	0.766499	0.881991	0.938479	1.0
Sanitasi Layak	190.0	0.715999	0.199580	0.0	0.604115	0.758728	0.866272	1.0
PAUD	190.0	0.428053	0.203101	0.0	0.261429	0.412857	0.546786	1.0
Kepemilikan	190.0	0.519251	0.257575	0.0	0.320946	0.493994	0.676426	1.0

JKN/jamkesda								
Penerima Bantuan Pangan	190.0	0.394321	0.189148	0.0	0.268895	0.381977	0.500872	1.0
<b>Tahun 2021</b>								
Prevalensi	315.0	0.747751	0.171622	0.0	0.657834	0.788018	0.874424	1.0
Imunisasi	315.0	0.662725	0.236666	0.0	0.509052	0.705005	0.848775	1.0
Penolong Persalinan oleh TenagaKesehatan..	315.0	0.849437	0.178042	0.0	0.781868	0.914286	0.976374	1.0
KB Modern	315.0	0.657335	0.177503	0.0	0.529794	0.676056	0.798483	1.0
ASI Eksklusif	315.0	0.817272	0.218221	0.0	0.693863	0.892608	1.000000	1.0
MP ASI	315.0	0.705514	0.224285	0.0	0.558824	0.717320	0.889706	1.0
Air Minum Layak	315.0	0.840862	0.157243	0.0	0.774314	0.894015	0.956359	1.0
Sanitasi Layak	315.0	0.753963	0.170559	0.0	0.658803	0.790564	0.881473	1.0
PAUD	315.0	0.409927	0.163511	0.0	0.285635	0.387528	0.513920	1.0
Kepemilikan JKN/jamkesda	315.0	0.586874	0.222956	0.0	0.427564	0.561538	0.751282	1.0
Penerima Bantuan Pangan	315.0	0.445320	0.194714	0.0	0.293364	0.452852	0.577998	1.0
<b>Tahun 2022</b>								
Prevalensi	469.0	0.780254	0.158589	0.0	0.687783	0.816742	0.900452	1.0
Imunisasi	469.0	0.674699	0.234817	0.0	0.513458	0.714286	0.861284	1.0
Penolong Persalinan oleh TenagaKesehatan di Fasilitas Kesehatan	469.0	0.852231	0.175113	0.0	0.792857	0.916667	0.976190	1.0
KB Modern	469.0	0.603308	0.196795	0.0	0.459564	0.625160	0.756098	1.0
ASI Eksklusif	469.0	0.834646	0.203589	0.0	0.734000	0.904000	1.000000	1.0
MP ASI	469.0	0.838247	0.138641	0.0	0.754348	0.857609	0.950000	1.0
Air Minum Layak	469.0	0.839468	0.159383	0.0	0.771053	0.889474	0.957895	1.0
Sanitasi Layak	469.0	0.774458	0.155759	0.0	0.694761	0.810934	0.892938	1.0
PAUD	469.0	0.363658	0.170618	0.0	0.237754	0.333333	0.471924	1.0
Kepemilikan JKN/jamkesda	469.0	0.643193	0.210057	0.0	0.485030	0.629940	0.821557	1.0
Penerima Bantuan Pangan	469.0	0.414314	0.199178	0.0	0.261803	0.396996	0.554721	1.0

Setelah seluruh tahapan *preprocessing data* telah dilakukan, maka data sudah layak untuk dilakukan pemodelan. Pemodelan dilakukan dengan metode *clustering* (pengelompokan) berdasarkan data yang telah dipilih fitur sebelumnya. Analisis data ini berguna untuk melayakkkan data agar dapat digunakan dalam analisis proses pada metode selanjutnya.

### 3.2. Clustering menggunakan HDBSCAN

Setelah dilakukan tahapan *preprocessing data*, maka selanjutnya data siap untuk dilakukan pengelompokan (*clustering*) menggunakan HDBSCAN sebelum data diintegrasikan ke visualisasi dasbor.

### 3.2.1. Inisialisasi Parameter

Parameter pada penerapan *clustering* algoritma HDBSCAN seperti yang telah dijelaskan pada tinjauan pustaka, yaitu *min\_cluster\_size*, *min\_samples*, *cluster\_selection\_epsilon*, *metric*, *gen\_min\_span\_tree*.

```
import hdbscan

clusterer_2020 = hdbscan.HDBSCAN(
    min_cluster_size=3,      # Minimum jumlah data dalam satu klaster
    min_samples=3,           # Minimum sampel untuk menentukan inti klaster
    cluster_selection_epsilon=0.2, # Radius untuk fleksibilitas klaster
    metric='euclidean',       # Gunakan jarak Euclidean
    gen_min_span_tree=True   # Membuat pohon minimum untuk menghitung stabilitas
)

clusterer_2021 = hdbscan.HDBSCAN(
    min_cluster_size=5,
    min_samples=4,
    cluster_selection_epsilon=0.2,
    metric='euclidean',
    gen_min_span_tree=True
)

clusterer_2022 = hdbscan.HDBSCAN(
    min_cluster_size=6,
    min_samples=3,
    cluster_selection_epsilon=0.2,
    metric='euclidean',
    gen_min_span_tree=True
)
```

**Gambar 3.2.** Inisialisasi Parameter

- 1) Tahun 2020
  - a. *min\_cluster\_size*: 3
  - b. *min\_samples*: 3
  - c. *cluster\_selection\_epsilon*: 0.2
  - d. *metric*: ‘euclidean’
  - e. *gen\_min\_span\_tree*: *True*
- 2) Tahun 2021
  - a. *min\_cluster\_size*: 5
  - b. *min\_samples*: 4
  - c. *cluster\_selection\_epsilon*: 0.2
  - d. *metric*: ‘euclidean’
  - e. *gen\_min\_span\_tree*: *True*
- 3) Tahun 2022
  - a. *min\_cluster\_size*: 6

- b. *min\_samples*: 3
- c. *cluster\_selection\_epsilon*: 0.2
- d. *metric*: ‘euclidean’
- e. *gen\_min\_span\_tree*: True

### 3.2.2. Menghitung Jarak Inti (*Core Distance*)

*Core Distance* mengukur jarak minimum dari sebuah titik ke tetangganya agar memenuhi syarat *minPts* atau *min\_samples* = 3 (jumlah minimum tetangga dalam radius tertentu) menggunakan metrik jarak *Euclidean*.

$D$  = jarak *Euclidean* antara dua titik dalam ruang n-dimensi.

$$D_{(p,q)} = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

$$D_{(p,q)} = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Disini,  $p = (x_1, y_1)$  dan  $q = (x_2, y_2)$

Nilai x dan y diperoleh dari data yang telah dinormalisasi, kemudian dilakukan reduksi dimensi menggunakan PCA, dengan tampilan kolom seperti dibawah ini.

A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	Prevalensi	Imunisasi	Penolong Persalin KB Modern	ASI Eksklusif	MP ASI	Air Minum	Sanitasi Layak	PAUD	Kependidikan	Penerima	Cluster Tahun 2020	x	y
2	0.779381	0.041845	0.532407407	0.55580609	0.7708861	0.682968	0.89821	0.451371571	0.21	0.88288288	0.32093	2	0.896708 -0.30057
3	0.387629	0.55794	0.844907407	0.62908681	0.2759494	0.145025	0.717002	0.709476309	0.17	0.96396396	0.456977	2	0.965718 -0.05184
4	0.808247	0.451717	0.841435185	0.87485908	0.6620253	0.971332	0.881432	0.791770574	0.364286	0.96246246	0.290698	2	0.769557 0.219446
5	0.816495	0.070815	0.953703703	0.434045735	0.9240505	0.988196	0.891499	0.569825436	0.174286	0.94744745	0.847674	2	0.806467 0.065785
6	0.958763	0.203863	0.958333333	0.35963923	1	1	0.902685	0.827930175	0.214286	0.96096096	0.765581	2	0.766956 0.160737
7	0.843299	0.008584	0.446759259	0.84892897	1	0.780776	0.684564	0.317955112	0.12	0.99399399	0.469767	2	0.89715 -0.34997
8	0.645361	0.198498	0.916666667	0.6572717	0.9341772	0.317032	0.925056	0.780548628	0.264286	0.94744745	0.312791	2	0.849429 0.078359
9	0.643299	0.380901	0.952546296	0.89064262	0.7240506	0.892074	0.88255	0.826683292	0.151429	0.98648649	0.402326	2	0.786939 0.236609
10	0.678351	0.048283	0.694444444	0.48027057	1	0.72154	0.600671	0.694513716	0.308571	0.92942943	0.353488	2	0.873899 -0.08615
11	0.4744227	0.175966	0.355324074	0.52987599	0.8037975	0.052277	0.435123	0	0	0.43693694	0.353488	2	1.024327 -0.73506
12	0.872165	0.193133	0.665509259	0.32581736	0.9886070	0.785835	0.642058	0.199501247	0.19	0.27027027	0.403488	2	0.848157 -0.56403
13	0.752577	0.246781	0.703703704	0.47012401	0.7658228	0.381113	0.784113	0.412718204	0.207143	0.35735736	0.474419	2	0.87029 -0.40916
14	0.952577	0.627682	0.658564815	0.53438557	0.3721519	0.284992	0.989933	0.912718204	0.2	0.42642643	0.281395	2	0.819651 -0.17257
15	0.56701	0.533262	0.770833333	0.30101466	0.7126582	0.50253	0.863535	0.882793017	0.075714	0.34234234	0.227907	2	0.82934 -0.13567
16	0.849485	0.281116	0.950231481	0.46786922	0.1886076	0.67285	0.95032	0.971321696	0.261429	0.21471471	0.98837	2	0.792464 -0.30177
17	0.62268	0.243562	0.929398184	0.67418264	0.8227848	0.575042	0.91387	0.87032419	0.197143	0.37537538	0.436047	0	-1.15977 -0.33853
18	0.814433	0.657725	0.967592593	0.41939121	0.3594937	1	0.522371	0.922693267	0.461429	0.83933934	0.456977	2	0.777022 0.364097

Gambar 3.3. Kolom Hasil Reduksi PCA

- Titik P1 (0.8967, -0.3006)

$$D_{(P1,P2)} = \sqrt{(0.9657 - 0.8967)^2 + (-0.0518 - (-0.3006))^2}$$

$$= \sqrt{0.0048 + 0.619} = 0.258 \text{ (Core Distance P1)}$$

$$D_{(P1,P6)} = \sqrt{(0.8971 - 0.8967)^2 + (-0.3500 - (-0.3006))^2}$$

$$= \sqrt{0.0000 + 0.0024} = 0.050$$

$$D_{(P1,P9)} = \sqrt{(0.8739 - 0.8967)^2 + (-0.0861 - (-0.3006))^2}$$

$$= \sqrt{0.0005 + 0.0460} = 0.214$$

- Titik P2 (0.9657, -0.0518)

$$\begin{aligned} D_{(P2,P1)} &= \sqrt{(0.9657 - 0.8967)^2 + (-0.0518 - (-0.3006))^2} \\ &= \sqrt{0.0048 + 0.619} = 0.258 \text{ (Core Distance P2)} \end{aligned}$$

$$\begin{aligned} D_{(P2,P9)} &= \sqrt{(0.8739 - 0.9657)^2 + (-0.861 - (-0.0518))^2} \\ &= \sqrt{0.0084 + 0.0012} = 0.098 \\ D_{(P2,P4)} &= \sqrt{(0.8065 - 0.9657)^2 + (0.0658 - (-0.0518))^2} \\ &= \sqrt{0.0254 + 0.0138} = 0.197 \end{aligned}$$

- Titik P3 (0.7696, 0.2194)

$$\begin{aligned} D_{(P3,P4)} &= \sqrt{(0.8065 - 0.7696)^2 + (0.0658 - 0.2194)^2} \\ &= \sqrt{0.0014 + 0.0236} = 0.158 \text{ (Core Distance P3)} \\ D_{(P3,P5)} &= \sqrt{(0.7670 - 0.7696)^2 + (0.1607 - 0.2194)^2} \\ &= \sqrt{0.0000 + 0.0034} = 0.058 \\ D_{(P3,P8)} &= \sqrt{(0.7869 - 0.7696)^2 + (0.2366 - 0.2194)^2} \\ &= \sqrt{0.0000 + 0.0034} = 0.026 \end{aligned}$$

- Titik P4 (0.8065, 0.0658)

$$\begin{aligned} D_{(P4,P3)} &= \sqrt{(0.8065 - 0.7696)^2 + (0.0658 - 0.2194)^2} \\ &= \sqrt{0.0014 + 0.0236} = 0.158 \\ D_{(P4,P5)} &= \sqrt{(0.8065 - 0.7670)^2 + (0.0658 - 0.1607)^2} \\ &= \sqrt{0.0016 + 0.0090} = 0.103 \\ D_{(P4,P8)} &= \sqrt{(0.8065 - 0.7869)^2 + (0.0658 - 0.2366)^2} \\ &= \sqrt{0.0004 + 0.0292} = 0.172 \text{ (Core Distance P4)} \end{aligned}$$

- Titik P5 (0.7670, 0.1607)

$$\begin{aligned} D_{(P5,P3)} &= \sqrt{(0.7670 - 0.7696)^2 + (0.1607 - 0.2194)^2} \\ &= \sqrt{0.0000 + 0.0034} = 0.058 \end{aligned}$$

$$D_{(P5,P4)} = \sqrt{(0.7670 - 0.8065)^2 + (0.1607 - 0.0658)^2} \\ = \sqrt{0.0016 + 0.0090} = 0.103 \text{ (Core Distance P5)}$$

$$D_{(P5,P8)} = \sqrt{(0.7670 - 0.7869)^2 + (0.1607 - 0.2366)^2} \\ = \sqrt{0.0004 + 0.0058} = 0.079$$

....

- Titik P974 (0.8465, -0.0742)

(perhitungan yang sama dilakukan berulang sampai P ke-974)

### 3.2.3. Menghitung Jarak *Mutual Reachability Distance*

Setelah dihitung *core distance*, maka dihitung jarak *mutual reachability distance* untuk setiap pasangan titik:

$$d_{reachability}(p, q) = \max(d_{core}(p), d_{core}(q), d(p, q))$$

$$d_{reachability}(P1, P2) = \max(d_{core}(P1), d_{core}(P2), d(P1, P2)) \\ = \max(0.086, 0.249, 0.258) = 0.258$$

$$d_{reachability}(P1, P3) = \max(d_{core}(P1), d_{core}(P3), d(P1, P3)) \\ = \max(0.086, 0.172, 0.380) = 0.380$$

$$d_{reachability}(P1, P4) = \max(d_{core}(P1), d_{core}(P4), d(P1, P4)) \\ = \max(0.086, 0.172, 0.366) = 0.366$$

$$d_{reachability}(P2, P3) = \max(d_{core}(P2), d_{core}(P3), d(P2, P3)) \\ = \max(0.249, 0.172, 0.298) = 0.298$$

$$d_{reachability}(P2, P4) = \max(d_{core}(P2), d_{core}(P4), d(P2, P4)) \\ = \max(0.249, 0.172, 0.269) = 0.269$$

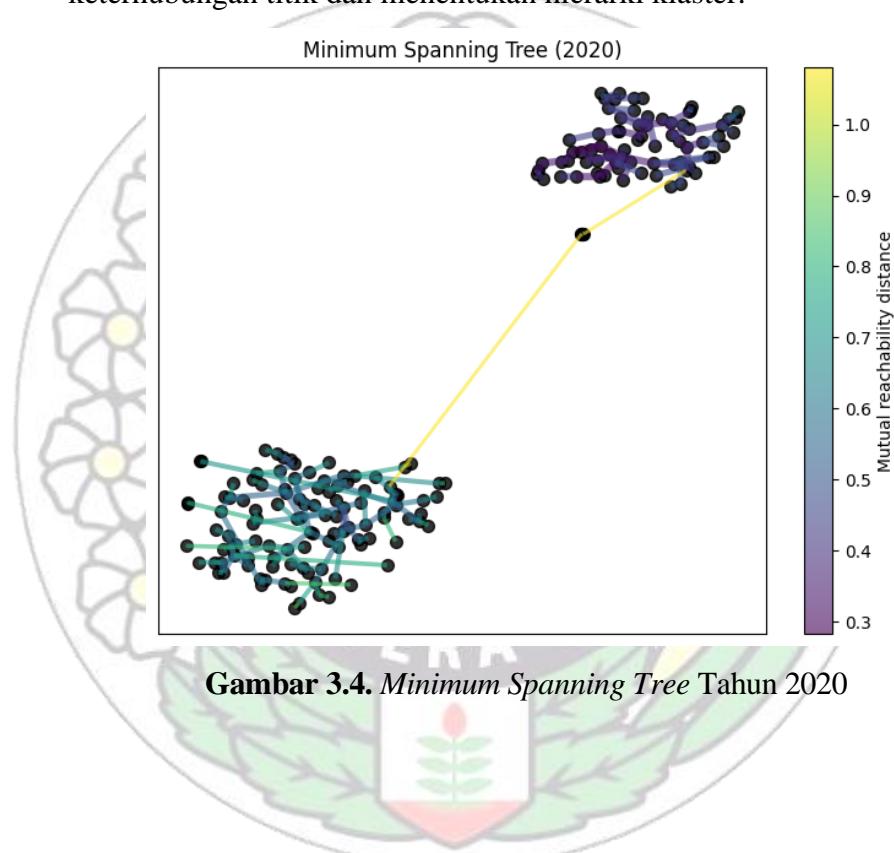
$$d_{reachability}(P3, P4) = \max(d_{core}(P3), d_{core}(P4), d(P3, P4)) \\ = \max(0.249, 0.172, 0.298) = 0.172$$

....

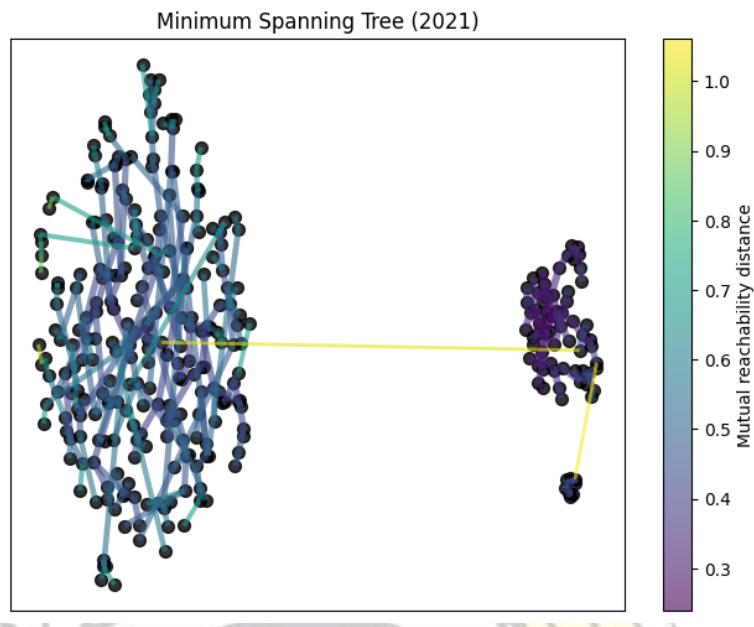
$$\begin{aligned}
 d_{reachability}(P974, P973) \\
 &= \max(d_{core}(P974), d_{core}(P973), d(P974, P973)) \\
 &= \max(0.086, 0.249, 1.9739) = 1.9739
 \end{aligned}$$

### 3.2.4. Membuat *Minimum Spanning Tree* (MST)

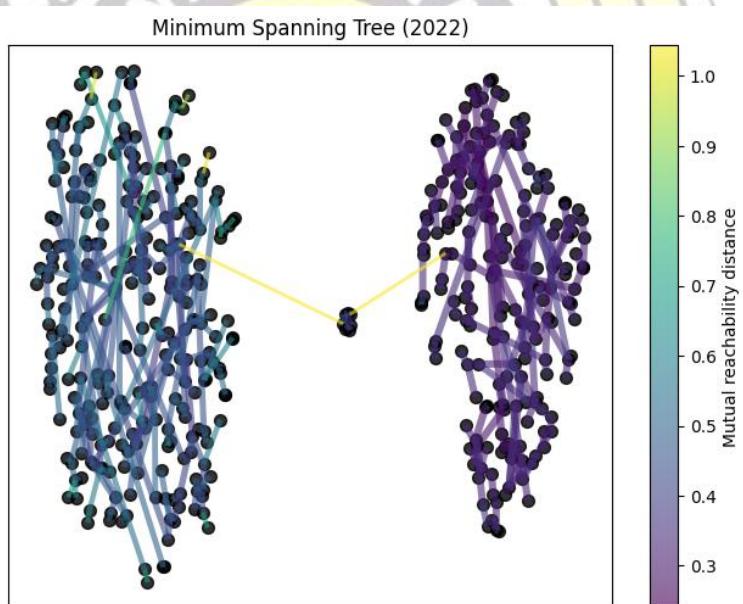
Selanjutnya, dibangun *Minimum Spanning Tree* (MST) dari titik-titik yang terbentuk oleh *Mutual Reachability Distance* untuk melihat keterhubungan titik dan menentukan hierarki klaster.



**Gambar 3.4.** *Minimum Spanning Tree* Tahun 2020



Gambar 3.5. Minimum Spanning Tree Tahun 2021

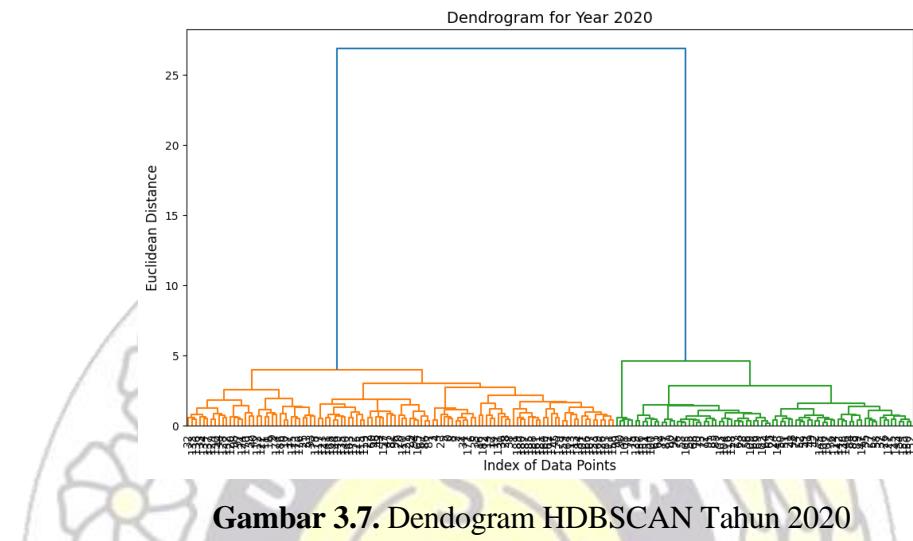


Gambar 3.6. Minimum Spanning Tree Tahun 2022

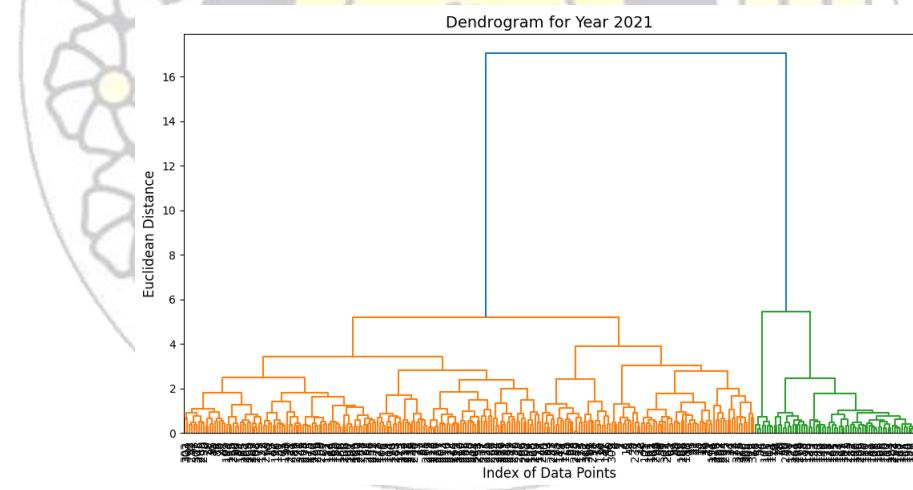
Ketiga gambar diatas memperlihatkan titik-titik *Mutual Reachability Distance* yang saling terhubung dan berdekatan dengan membentuk klaster. Tahun 2020-2022 terdapat 3 titik yang berkumpul.

### 3.2.5. Menentukan *Cluster* Berdasarkan Densitas

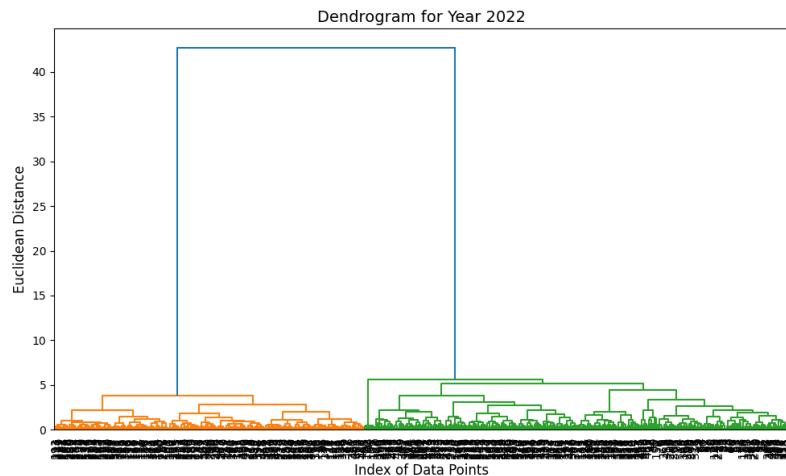
Menentukan klaster berdasarkan jarak terdekat menggunakan parameter *min\_cluster\_size* dan *Euclidean distance*. Titik yang terhubung secara langsung atau tidak langsung dengan *core point* radius  $\epsilon$  akan termasuk dalam klaster.



Gambar 3.7. Dendogram HDBSCAN Tahun 2020



Gambar 3.8. Dendogram HDBSCAN Tahun 2021



**Gambar 3.9.** Dendrogram HDBSCAN Tahun 2022

Dendrogram menunjukkan pengelompokan data untuk tahun 2020, 2021, dan 2022 berdasarkan jarak *Euclidean*. Pada tahun 2020, terlihat dua *cluster* utama dengan jarak penggabungan yang cukup besar, menunjukkan variasi data yang tinggi. Tahun 2021 memiliki jarak antar *cluster* yang lebih kecil, menandakan data lebih homogen dibandingkan tahun sebelumnya. Sementara itu, tahun 2022 kembali menunjukkan pola mirip 2020 dengan jarak antar *cluster* yang lebih besar, mencerminkan perbedaan indikator atau dinamika yang lebih signifikan. Secara keseluruhan, dendrogram ini dapat digunakan untuk memahami pola pengelompokan antar tahun dan mengidentifikasi perubahan signifikan dalam indikator yang dianalisis.

### 3.2.6. Ekstrak Hasil Akhir Klasterisasi

```

cluster_labels2020 = clusterer_2020.fit_predict(datastunting2020)
cluster_labels2021 = clusterer_2021.fit_predict(datastunting2021)
cluster_labels2022 = clusterer_2022.fit_predict(datastunting2022)

datastunting2020['Cluster Tahun 2020'] = cluster_labels2020
datastunting2021['Cluster Tahun 2021'] = cluster_labels2021
datastunting2022['Cluster Tahun 2022'] = cluster_labels2022

print(datastunting2020['Cluster Tahun 2020'].value_counts())
print(datastunting2021['Cluster Tahun 2021'].value_counts())
print(datastunting2022['Cluster Tahun 2022'].value_counts())

```

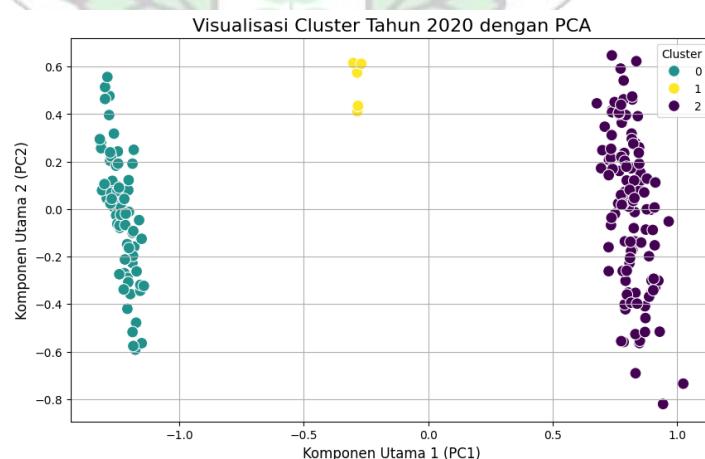
```

Cluster Tahun 2020
2    112
0     73
1      5
Name: count, dtype: int64
Cluster Tahun 2021
2    246
1     61
0      8
Name: count, dtype: int64
Cluster Tahun 2022
2    264
0    198
1      7
Name: count, dtype: int64

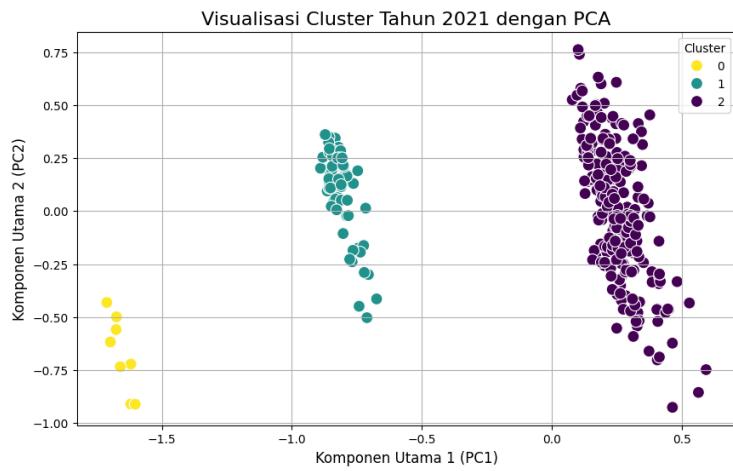
```

**Gambar 3.10.** Hasil Klasterisasi

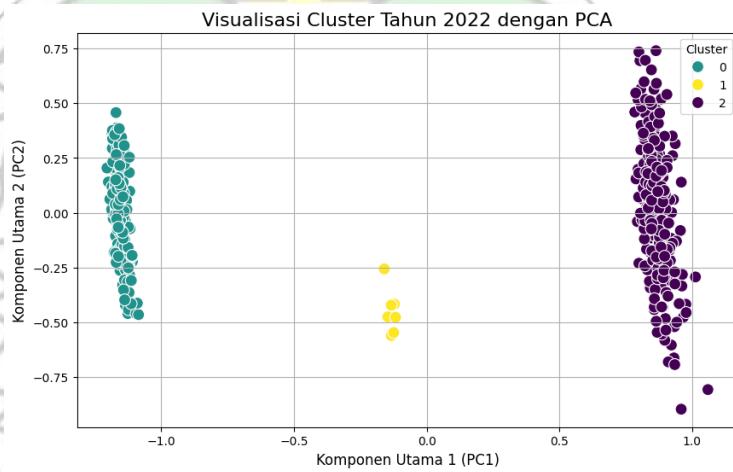
Setelah proses diatas selesai dilakukan, data tahun 2020, 2021, dan 2022 dikelompokkan dan divisualisasikan melalui diagram PCA. PCA digunakan untuk mereduksi dimensi data ke dua komponen utama (*Principal Components*). Dalam PCA, komponen 1 (PC1) dan komponen 2 (PC2) adalah dua sumbu utama yang menangkap variasi terbesar dalam data. PC1 mewakili dimensi dengan variansi terbesar, sedangkan PC2 menangkap variasi terbesar kedua yang tidak berkorelasi dengan PC1. Kedua komponen ini merupakan kombinasi linier dari fitur asli dan digunakan untuk mereduksi dimensi data tanpa kehilangan terlalu banyak informasi. Hal ini guna mempermudah interpretasi distribusi *cluster* dalam ruang berdimensi rendah seperti gambar berikut:



**Gambar 3.11.** Visualisasi Klaster Tahun 2020 dengan PCA



**Gambar 3.12.** Visualisasi Klaster Tahun 2021 dengan PCA



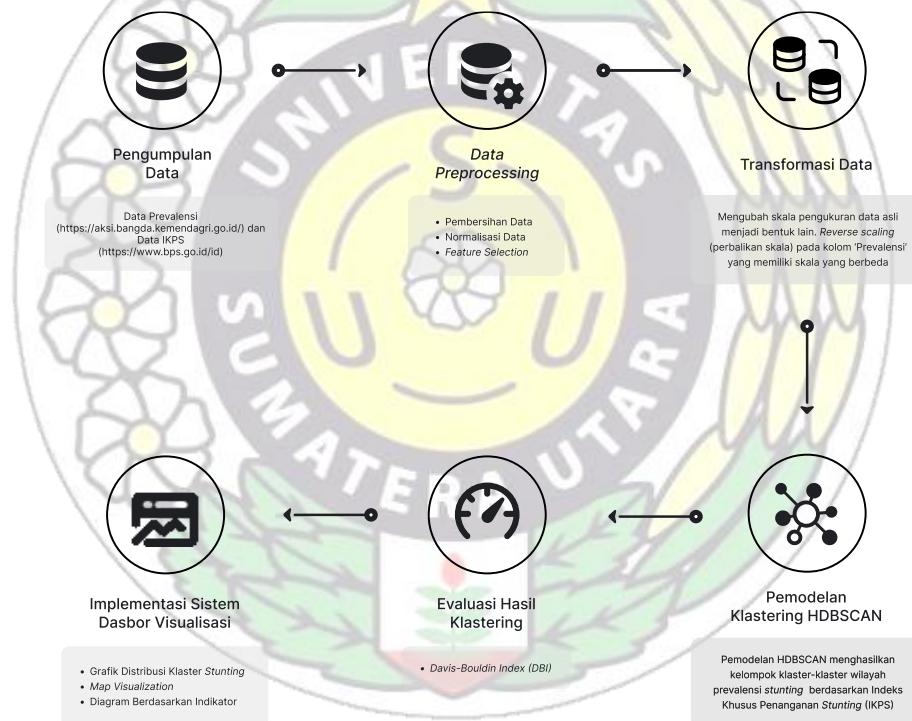
**Gambar 3.13.** Visualisasi Klaster Tahun 2022 dengan PCA

- 1) Tahun 2020 menghasilkan 3 *cluster*:
  - a. *Cluster* 2 berisi 112 wilayah, menjadi kelompok terbesar.
  - b. *Cluster* 0 mencakup 73 wilayah.
  - c. *Cluster* 1 terdiri dari 5 wilayah, menandakan kelompok dengan kepadatan paling rendah.
- 2) Tahun 2021 menghasilkan 3 *cluster*:
  - a. *Cluster* 2 tetap menjadi yang terbesar dengan 246 wilayah.
  - b. *Cluster* 1 mencakup 61 wilayah.
  - c. *Cluster* 0 hanya terdiri dari 8 wilayah, menunjukkan kelompok dengan karakteristik berbeda yang mungkin lebih jarang.

- 3) Tahun 2022 menghasilkan 3 *cluster*:
- Cluster* 2 mencakup 264 wilayah, menunjukkan konsistensi sebagai kelompok terbesar.
  - Cluster* 0 memiliki peningkatan signifikan menjadi 198 wilayah.
  - Cluster* 1 tetap kecil dengan hanya 7 wilayah, mencerminkan wilayah dengan kepadatan densitas rendah.

### 3.3. Arsitektur Umum Sistem

Diagram umum sistem merupakan gambaran visual dari struktur keseluruhan atau alur sistem yang diterapkan dalam penelitian ini. Berikut merupakan komponen alur yang tercakup dalam diagram umum sistem:



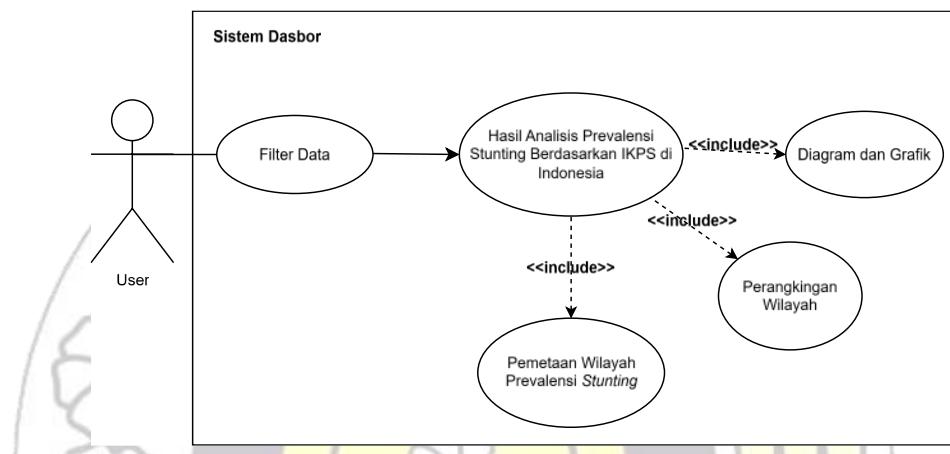
**Gambar 3.14. Arsitektur Umum Sistem**

### 3.4. Pemodelan Sistem

Tahapan berikutnya adalah pemodelan sistem, yang bertujuan untuk menggambarkan interaksi antara sistem dan pengguna melalui proses yang terstruktur. Pemodelan ini diwakili dengan menggunakan *Use Case Diagram*, *Activity Diagram*, *Sequence Diagram*, dan *Flowchart*.

### 3.4.1. Use Case Diagram

*Use Case Diagram* digunakan untuk representasi visual yang menggambarkan hubungan antara pengguna (aktor) dan sistem dalam sebuah proses atau aplikasi. Diagram ini digunakan untuk menunjukkan bagaimana aktor berinteraksi dengan fungsi-fungsi utama (*use case*) dalam sistem yang sedang dikembangkan. Berikut adalah *Use Case Diagram*:

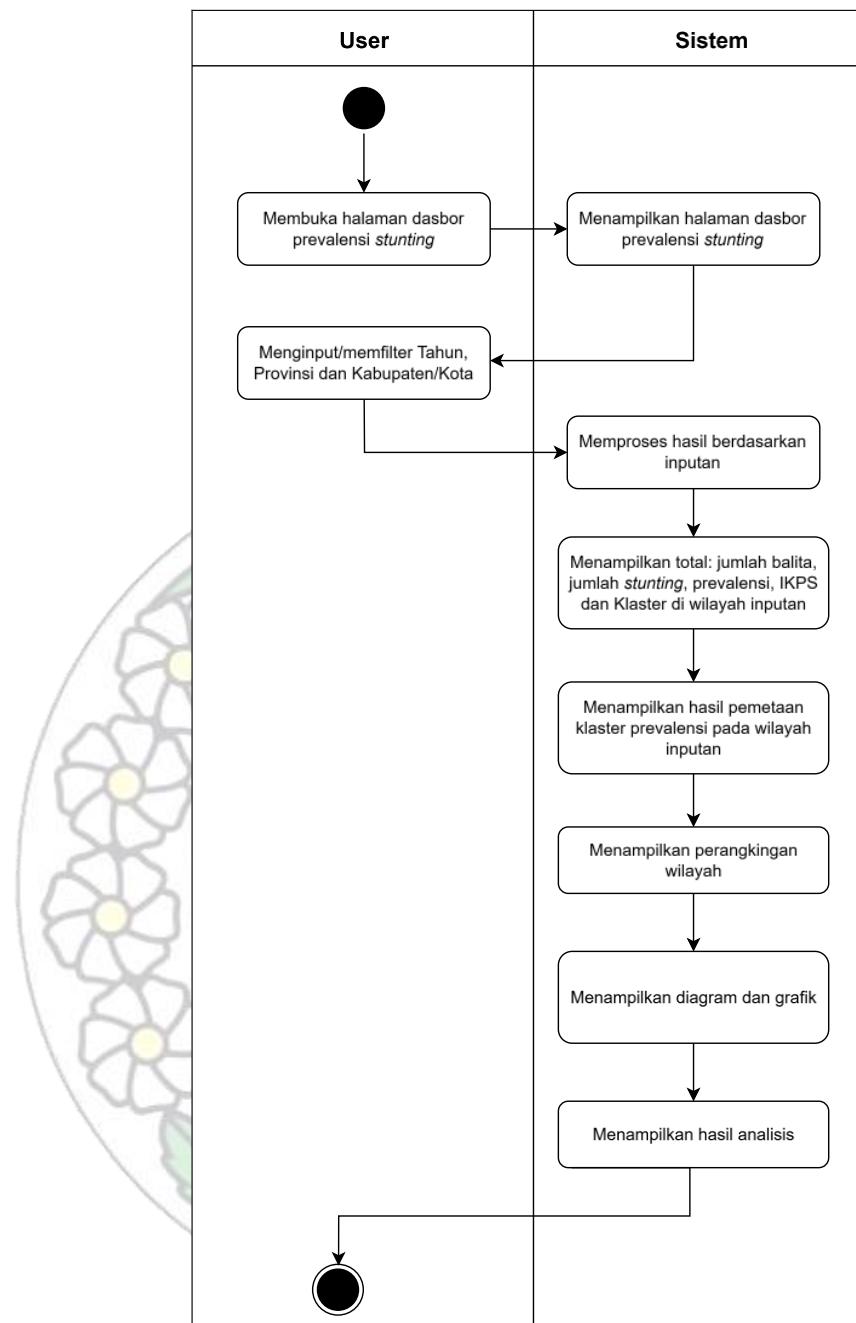


Gambar 3.15. *Use Case Diagram*

Pada *use case* diagram di atas, pengguna mengakses dasbor prevalensi *stunting* di Indonesia dan melakukan filter data berupa tahun, provinsi, serta kabupaten/kota. Hubungan *<<include>>* menunjukkan bahwa setiap proses bergantung pada proses sebelumnya. Setelah data dimasukkan, sistem akan memproses input tersebut dan menampilkan hasil berupa pemetaan wilayah klaster, peringkat wilayah prioritas, visualisasi diagram indikator penanganan, serta kesimpulan hasil analisis klaster berdasarkan wilayah yang dipilih oleh pengguna.

### 3.4.2. Activity Diagram

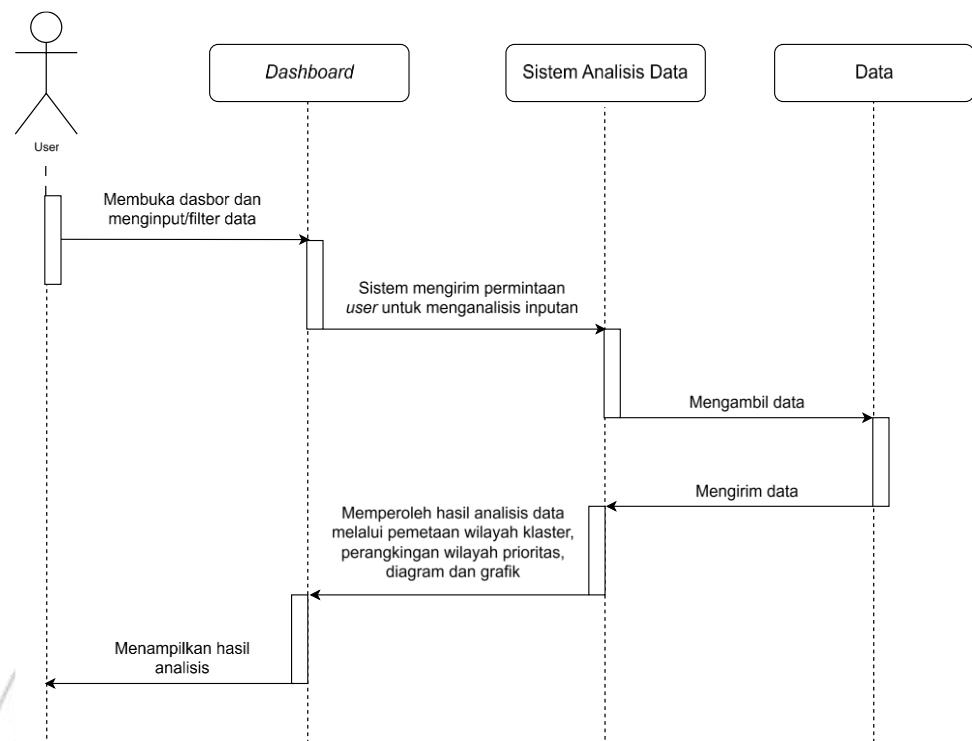
*Activity Diagram* digunakan untuk menggambarkan alur aktivitas sistem dengan *user* dalam menampilkan data prevalensi *stunting* dan memberikan representasi visual yang terstruktur terhadap alur kerja sistem, seperti yang ditunjukkan pada gambar 3.16.



**Gambar 3.16. Activity Diagram**

### 3.4.3. Sequence Diagram

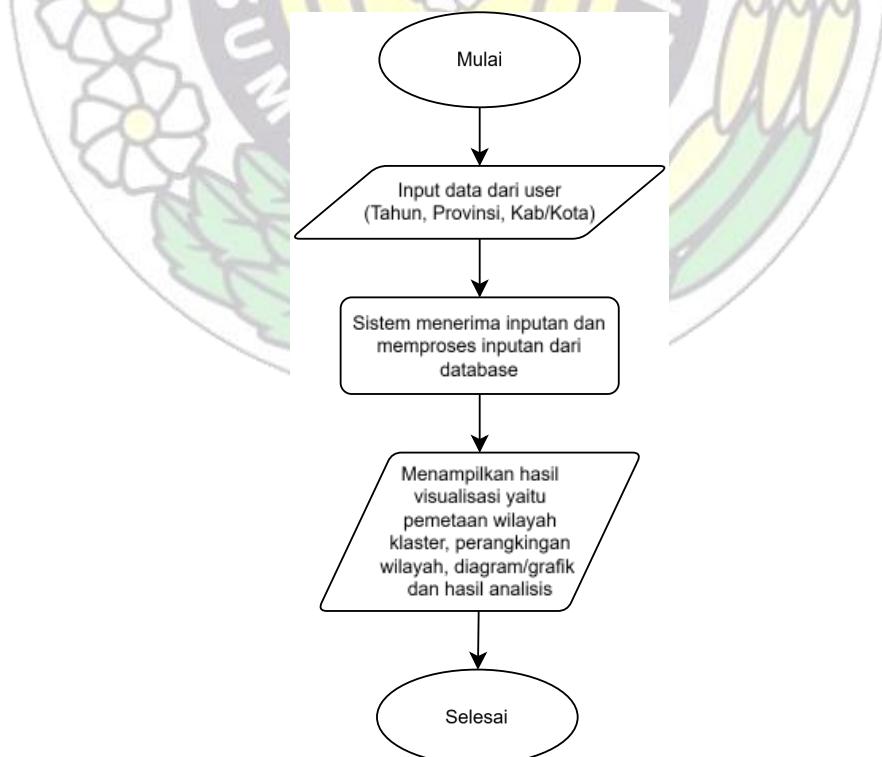
*Sequence diagram* untuk analisis prevalensi *Stunting* menggambarkan alur interaksi antara komponen utama dalam sistem. Diagram ini menunjukkan alur komunikasi yang terstruktur antara *User*, *Dasbor*, Sistem Analisis Data, dan Data, yang memungkinkan analisis data prevalensi *stunting* seperti ditunjukkan pada gambar 3.17.



**Gambar 3.17. Sequence Diagram**

### 3.5. Flowchart

#### 3.5.1. Flowchart Sistem

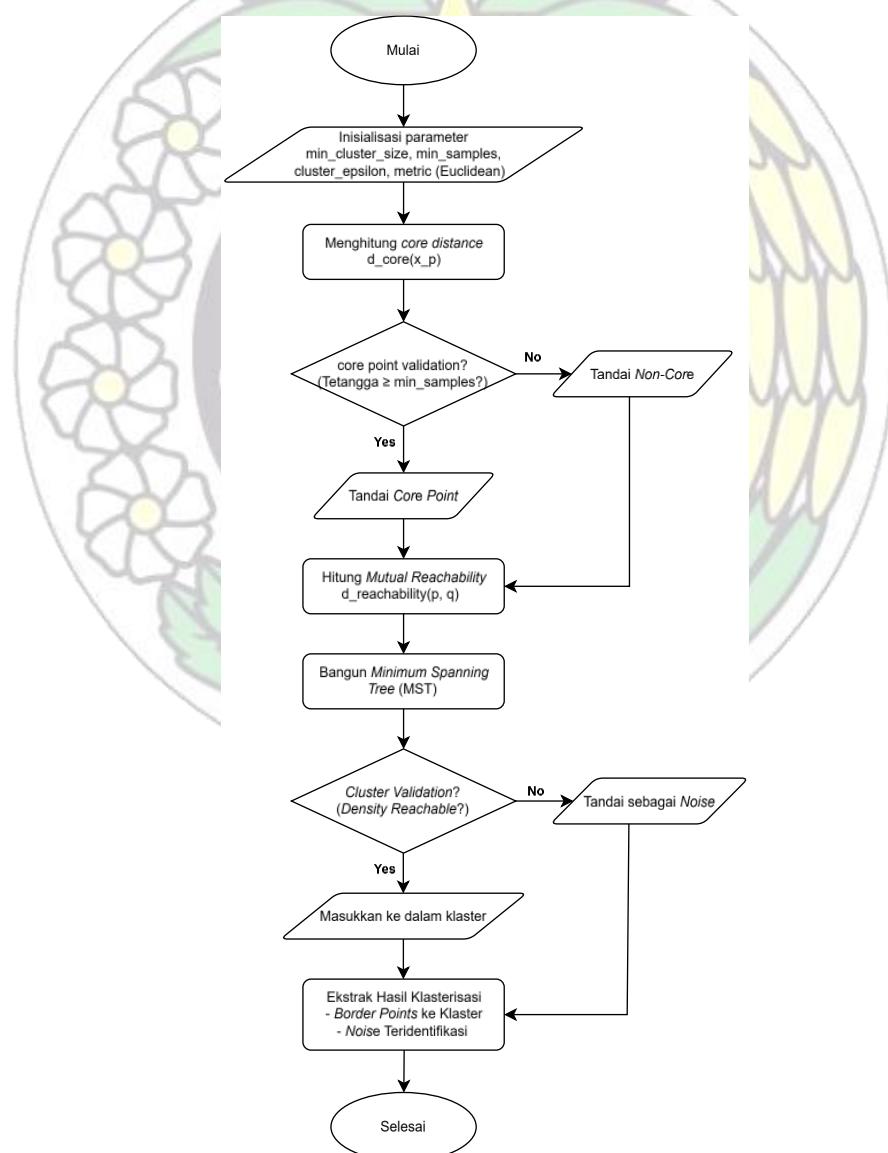


**Gambar 3.18. Flowchart Sistem**

Penjelasan:

- Masukkan inputan *user* yaitu tahun, provinsi dan kabupaten/kota yang akan dianalisis wilayahnya (bisa lebih dari satu wilayah).
- Sistem menerima inputan dan memproses data untuk dilakukan analisis berdasarkan data yang sudah di kelompokkan.
- Sistem menampilkan hasil dari proses analisis yaitu berupa pemetaan wilayah klaster, perangkingan wilayah prioritas inputan, grafik/diagram indikator dan hasil analisis keseluruhan.

### 3.5.2. Flowchart Algoritma HDBSCAN



**Gambar 3.19. Flowchart Algoritma HDBSCAN**

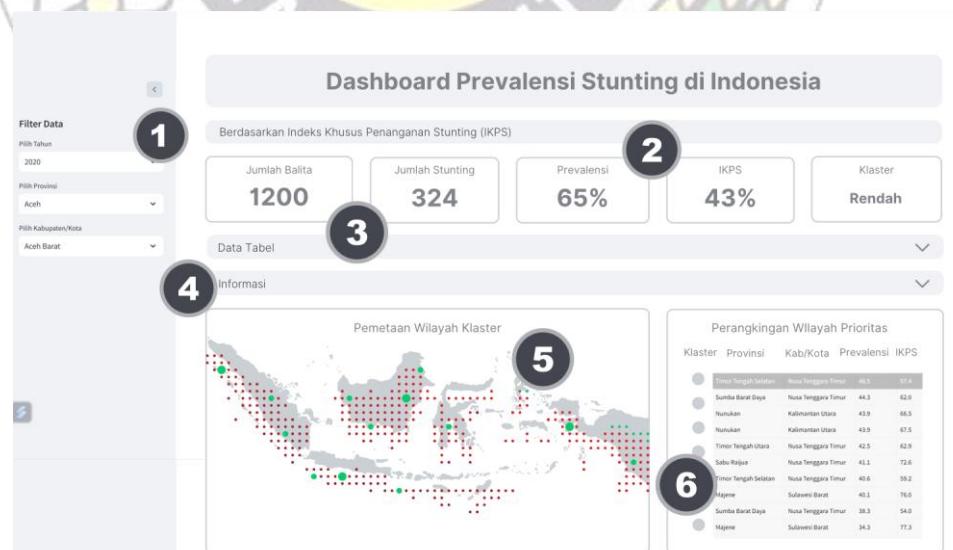
Penjelasan:

- Input parameter awal seperti *min\_cluster\_size*, *min\_samples*, *cluster\_selection\_epsilon*, dan jarak *Euclidean*.
- Menghitung jarak inti tiap titik berdasarkan tetangga terdekat.
- Menentukan titik sebagai *core* jika memenuhi syarat jumlah tetangga.
- Menghitung jarak *mutual reachability* antar titik.
- Membuat *Minimum Spanning Tree* (MST) untuk hierarki klaster.
- Menentukan klaster berdasarkan kepadatan (*density-reachable*). Titik yang tidak memenuhi syarat ditandai *noise*.
- Menentukan hasil akhir klasterisasi, termasuk *border points* dan *noise*.
- Menampilkan hasil analisis dalam bentuk klaster dan visualisasi.

### 3.6. Perancangan Interface

Perancangan *interface* bertujuan untuk mendesain tampilan antarmuka yang *user-friendly* dan fungsional, sehingga memudahkan pengguna dalam mengakses serta memahami hasil analisis. Berikut elemen perancangan *interface*:

#### 3.6.1. Halaman Dasbor

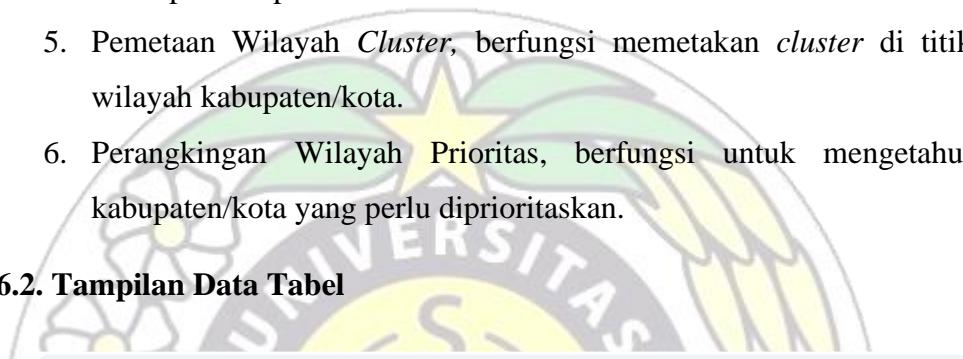


Gambar 3.20. Halaman Dasbor

Keterangan:

1. Filter Data, berfungsi untuk input/filter data.
2. *Display Count*, berfungsi untuk menghitung beberapa data yang menampilkan jumlah berdasarkan inputan.
3. *Expander Tabel*, berfungsi menampilkan seluruh data yang ada di dataset.
4. *Expander Informasi*, berfungsi memberikan informasi berupa deskripsi setiap klaster.
5. Pemetaan Wilayah *Cluster*, berfungsi memetakan *cluster* di titik wilayah kabupaten/kota.
6. Perangkingan Wilayah Prioritas, berfungsi untuk mengetahui kabupaten/kota yang perlu diprioritaskan.

### 3.6.2. Tampilan Data Tabel



**Dashboard Prevalensi Stunting di Indonesia**

Berdasarkan Indeks Khusus Penanganan Stunting (IKPS)

Data Tabel

1

Kolom yang Ingin Ditampilkan:

Choose an option

	Provinsi	Kab/Kota	Latitude	Longitude	Tahun	Jumlah Balita	Jumlah Stunting	Prevalensi	Imunisasi	Penolong Persalinan oleh Tenaga Kesehatan di Fasilitas Kesehatan
0	Aceh	Aceh Tenggara	3.3667	97.7	2,020	15,947	1,711	10.7	10.7	59.6
1	Aceh	Aceh Timur	4.6333	97.6333	2,020	31,161	9,269	29.7	12	86.6
2	Aceh	Aceh Tengah	4.51	96.855	2,020	17,373	1,609	9.3	48.9	86.3
3	Aceh	Pidie	5.08	96.11	2,020	1,598	142	8.9	13.4	96
4	Aceh	Bireuen	5.0833	96.5833	2,020	44,230	879	2	25.8	96.4
5	Aceh	Gayo Lues	3.95	97.39	2,020	8,506	643	7.6	7.6	52.2
6	Aceh	Nagan Raya	4.1667	96.5167	2,020	13,621	2,345	17.2	25.3	92.8
7	Aceh	Bener Meriah	4.7302	96.8616	2,020	9,720	1,679	17.3	42.3	95.9
8	Aceh	Kota Subulussalam	2.75	97.9333	2,020	10,983	1,718	15.6	11.3	73.6
9	Sumatera Utara	Nias	1.0333	97.7667	2,020	4,699	1,200	25.5	23.2	44.3

**Gambar 3.21.** Tampilan Data Tabel

Keterangan:

1. *Expander Tabel*, yang berisikan seluruh tabel dataset yang ingin dilihat untuk memastikan bahwa data yang digunakan benar.

### 3.6.3. Tampilan Informasi

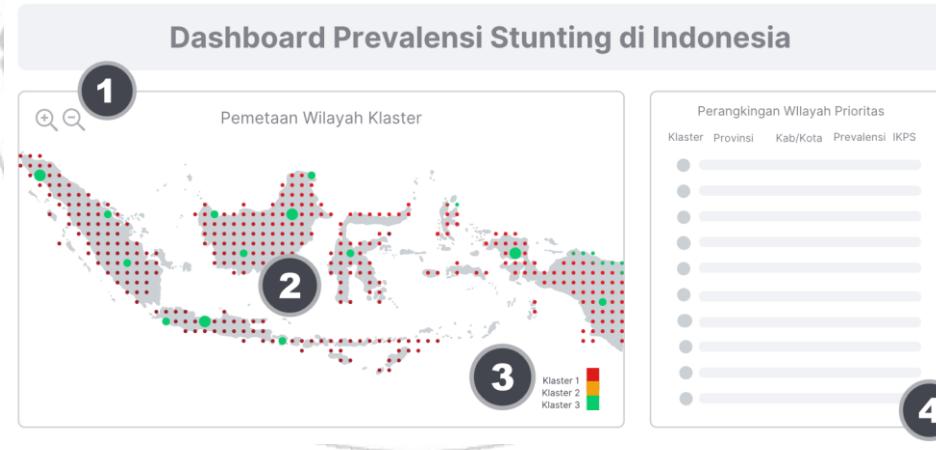


**Gambar 3.22.** Tampilan Halaman Informasi

Keterangan:

1. *Expander* Informasi, berisikan info label klaster.

### 3.6.4. Tampilan Pemetaan Klaster dan Perangkingan Wilayah



**Gambar 3.23.** Tampilan Pemetaan Klaster dan Perangkingan Wilayah

Keterangan:

1. *Zoom In* dan *Zoom Out*, untuk menampilkan peta dalam ukuran yang kecil/besar agar lebih kelihatan.
2. Titik point klaster di berbagai titik, dimana jika di klik akan muncul beberapa keterangan mengenai wilayah klaster.
3. Tampilan legenda untuk keterangan tiap klaster.
4. Tampilan perangkingan wilayah prioritas.

### 3.6.5. Tampilan Grafik, Diagram dan Hasil Analisis



**Gambar 3.24.** Tampilan Diagram, Grafik dan Hasil Analisis

Keterangan:

1. Diagram Indikator Penanganan.
2. Grafik Perbandingan Prevalensi dan IKPS per Tahun.
3. Hasil Analisis Prevalensi berdasarkan Indikator Penanganan.

## BAB 4

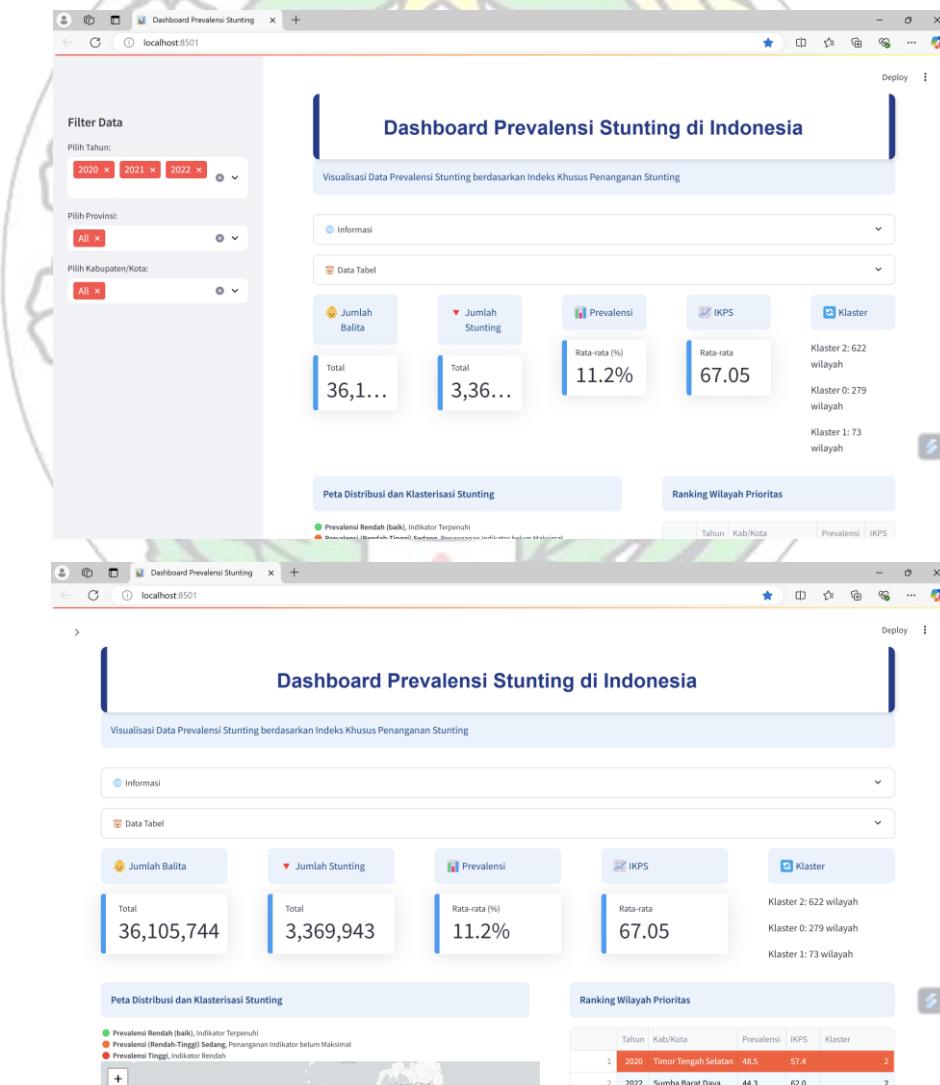
### IMPLEMENTASI DAN PENGUJIAN

#### 4.1. Implementasi Sistem

Implementasi sistem dari penelitian ini adalah membuat dasbor interaktif untuk menampilkan hasil klasterisasi data. Dasbor ini bertujuan mempermudah pengguna dalam melihat pengelompokan wilayah berdasarkan indikator penanganan *stunting*. Dibangun menggunakan *Streamlit* dengan bahasa pemrograman *Python*.

Laman website: <https://dashboard-sebaran-stunting.streamlit.app/>

##### 4.1.1. Halaman Dasbor



Gambar 4.1. Halaman Dasbor

Keterangan:

- a. Filter Data, pada bagian ini, input filter memungkinkan pengguna memilih data berdasarkan tahun, provinsi, dan kabupaten/kota. Data yang diambil dari file CSV akan difilter sesuai input pengguna, kemudian ditampilkan di dasbor. Proses ini dilakukan menggunakan *Streamlit*.
- b. *Display Count*, ringkasan otomatis ditampilkan menggunakan fungsi agregasi data. Dasbor menghitung jumlah balita, jumlah *stunting*, prevalensi, nilai IKPS, dan jumlah klaster berdasarkan data yang difilter.
- c. *Expander Tabel*, bagian ini dirancang untuk menampilkan tabel data lengkap dari dataset. Pengguna bisa membuka atau menutup tabel sesuai kebutuhan. Data dalam tabel sudah diurutkan berdasarkan filter yang dipilih.
- d. *Expander Informasi*, berisikan informasi terkait klaster dihasilkan dari hasil klasterisasi menggunakan algoritma HDBSCAN. Detail seperti deskripsi setiap klaster dan karakteristik wilayah disajikan di dalam *expander* ini.
- e. Pemetaan Wilayah *Cluster*, Visualisasi peta dibuat untuk menampilkan wilayah berdasarkan hasil klasterisasi. Peta ini menyesuaikan input tahun dan wilayah yang dipilih, dengan penanda warna yang mewakili masing-masing klaster.
- f. Perangkingan Wilayah Prioritas, sistem menghitung perangkingan wilayah berdasarkan prevalensi tinggi dan indikator penanganan rendah.

#### 4.1.2. Tampilan Data Tabel

The screenshot displays two instances of a data table interface from a web application. The top instance shows a full table with 10 rows of data, while the bottom instance shows a collapsed state with only the first row visible.

**Data Tabel (Top View):**

	Provinsi	Kab/Kota	Latitude	Longitude	Tahun	Jumlah Balita	Jumlah Stunting	Prevalensi	Imunisasi	Penolong Persalinan..	KB Modern	ASI Eksklusif	MP ASI	Air Minum Layak
0	Aceh	Aceh Tengg.	3.3667	97.7	2,020	15,947	1,711	10.7	10.7	59.6	57.7	81.9	81.2	90.9
1	Aceh	Aceh Timu	4.6333	97.6333	2,020	31,161	9,269	29.7	12	86.6	64.2	42.8	49.3	74.7
2	Aceh	Aceh Tengg.	4.51	96.855	2,020	17,373	1,609	9.3	48.9	86.3	86	73.3	98.3	89.4
3	Aceh	Pidie	5.08	96.11	2,020	1,598	142	8.9	13.4	96	46.9	94	99.3	90.3
4	Aceh	Bireuen	5.0833	96.5833	2,020	44,230	879	2	25.8	96.4	40.3	100	100	91.3
5	Aceh	Gayo Lues	3.95	97.39	2,020	8,506	643	7.6	7.6	52.2	83.7	100	87	71.8
6	Aceh	Nagan Ray	4.1667	96.5167	2,020	13,621	2,345	17.2	25.3	92.8	66.7	94.8	59.5	93.3
7	Aceh	Bener Meri	4.7302	96.8616	2,020	9,720	1,679	17.3	42.3	95.9	87.4	78.2	93.6	89.5
8	Aceh	Kota Subul	2.75	97.9333	2,020	10,983	1,718	15.6	11.3	73.6	51	100	83.5	64.3
9	Sumatera Nias		1.0333	97.7667	2,020	4,699	1,200	25.5	23.2	44.3	55.4	84.5	43.8	49.5

**Data Tabel (Bottom View):**

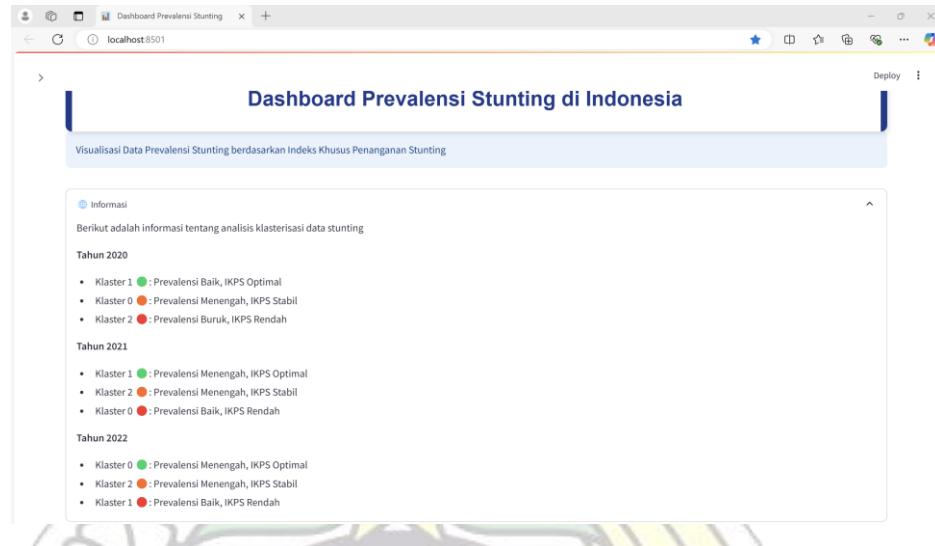
	Provinsi	Kab/Kota	Latitude	Longitude	Tahun	Jumlah Balita	Jumlah Stunting	Prevalensi	Imunisasi	Penolong Persalinan..	KB Modern	ASI Eksklusif	MP ASI	Air Minum Layak
7	Aceh	Bener Meri	4.7302	96.8616	2,020	9,720	1,679	17.3	42.3	95.9	87.4	78.2	93.6	89.5
8	Aceh	Kota Subul	2.75	97.9333	2,020	10,983	1,718	15.6	11.3	73.6	51	100	83.5	64.3
9	Sumatera Nias		1.0333	97.7667	2,020	4,699	1,200	25.5	23.2	44.3	55.4	84.5	43.8	49.5

Gambar 4.2. Tampilan Data Tabel

Keterangan:

- Expander Tabel*, pengguna dapat melihat seluruh data di data tabel.
- Input Kolom, untuk memilih kolom yang ingin dilihat atau ditampilkan. Kolom yang tersedia yaitu Provinsi, Kab/Kota, Latitude, Longitude, Tahun, Jumlah Balita, Jumlah Stunting, Prevalensi, Imunisasi, Penolong Persalinan.., KB Modern, ASI Eksklusif, MP ASI, Air Minum Layak, Sanitasi Layak, PAUD, Kepemilikan JKN/jamkesda, Penerima Bantuan Pangan, Dimensi Kesehatan, Dimensi Gizi, Dimensi Perumahan, Dimensi Pendidikan, Dimensi Perlindungan Sosial, IKPS dan Klaster.

### 4.1.3. Tampilan Informasi

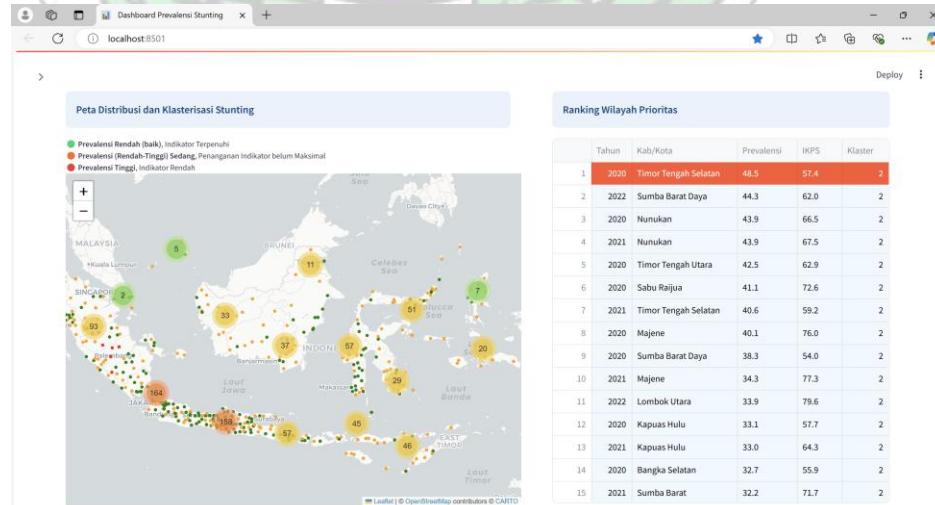


Gambar 4.3. Tampilan Informasi

Keterangan:

- Expander* Informasi, berisikan informasi terkait klaster dimana setiap tahun memiliki klaster yang berbeda-beda. Informasi ini berguna agar pengguna dapat memahami pelabelan dari pemetaan di peta walaupun sudah disediakan legenda, informasi ini merupakan deskripsi detail terkait klaster.

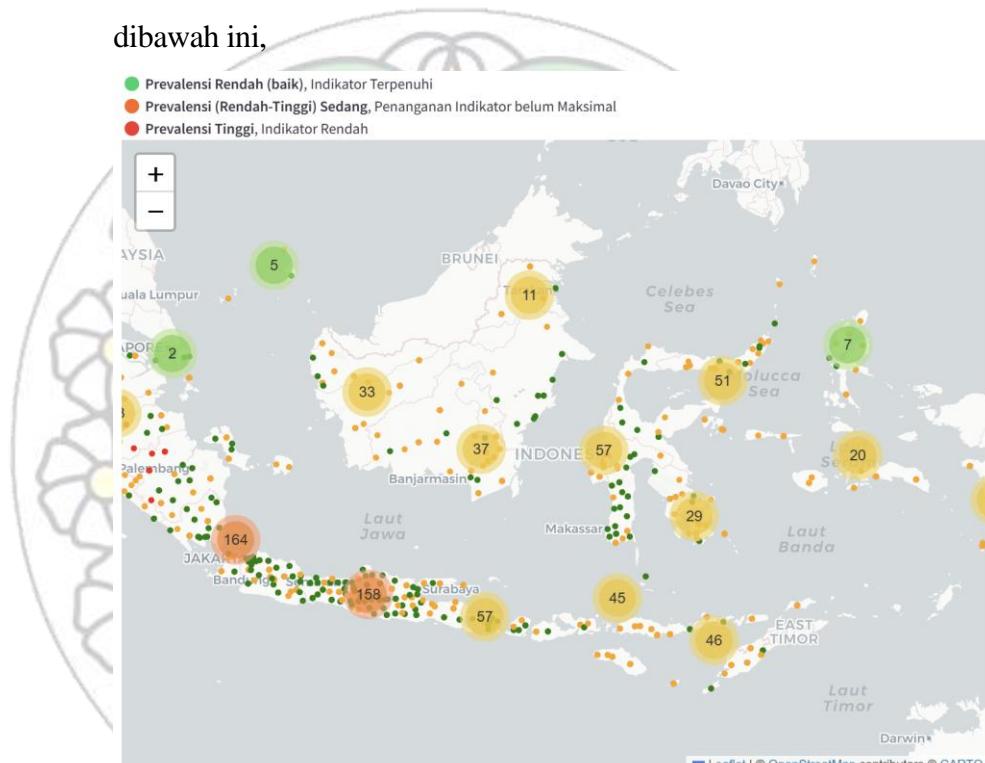
### 4.1.4. Tampilan Pemetaan Klaster dan Perangkingan Wilayah



Gambar 4.4. Tampilan Pemetaan Klaster dan Perangkingan Wilayah

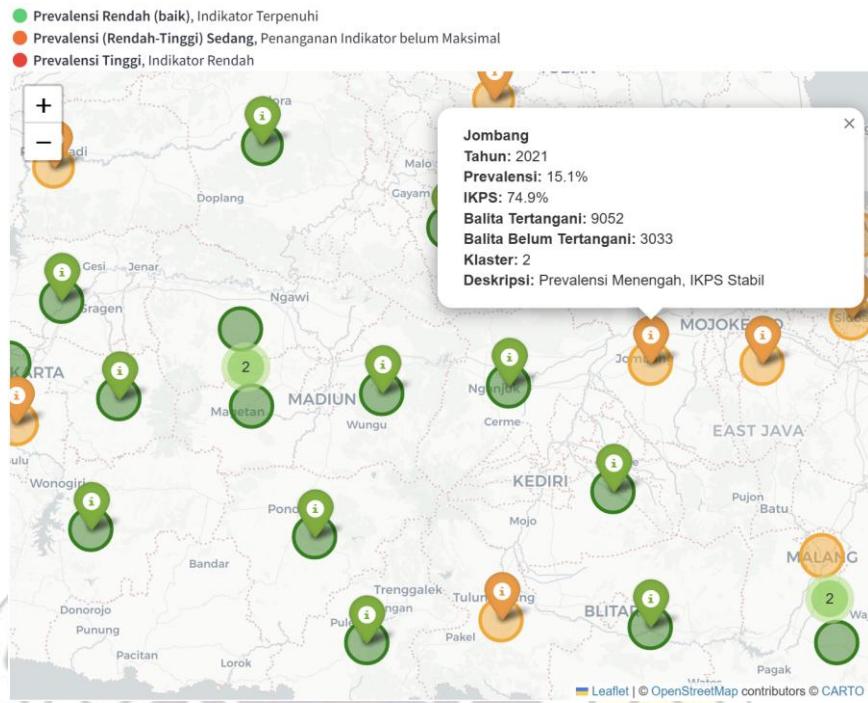
Keterangan:

- Pemetaan Klaster, menampilkan visualisasi peta interaktif yang memetakan wilayah berdasarkan hasil klasterisasi. Setiap klaster ditampilkan dengan warna yang berbeda untuk memudahkan pengguna dalam memahami pengelompokan wilayah. Peta ini dihasilkan dengan memanfaatkan data hasil klasterisasi algoritma HDBSCAN, yang telah diproses sebelumnya. Data peta divisualisasikan menggunakan *folium (leaflet)* seperti gambar 4.5 dibawah ini,



**Gambar 4.5.** Pemetaan Wilayah Klaster

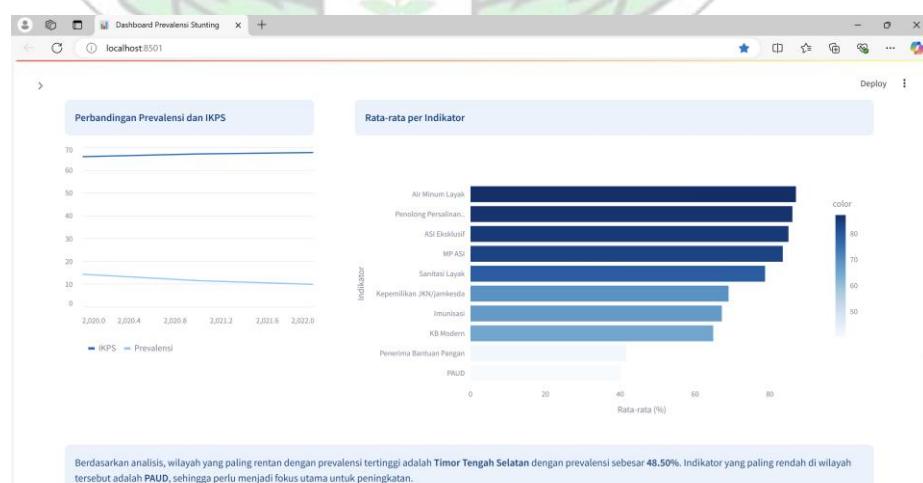
- Legenda, memberikan informasi terkait warna *cluster* yang terdapat di peta. Dimana warna hijau ●, menandakan Prevalensi Rendah (baik), Indikator Terpenuhi, warna orange ●, menandakan Prevalensi (Rendah-Tinggi) Sedang, Penanganan Indikator belum Maksimal dan warna merah ●, berarti Prevalensi Tinggi, Indikator Rendah.
- Tooltip* atau *Pop-up*, ketika salah satu titik di klik, maka akan muncul informasi wilayah seperti gambar 4.6. dibawah ini,



**Gambar 4.6.** Keterangan Tooltip/Pop-up di Peta

- d. Perangkingan Wilayah, menampilkan daftar Kabupaten/kota yang berada di klaster yang rentan *stunting* dengan prevalensi *stunting* tinggi dan nilai IKPS rendah. Kabupaten/kota teratas menandakan bahwa wilayah tersebut paling tinggi *stuntingnya* dan penanganan *stunting* masih perlu diprioritaskan.

#### 4.1.5. Tampilan Grafik, Diagram dan Hasil Analisis



**Gambar 4.7.** Tampilan Diagram, Grafik dan Hasil Analisis

Keterangan:

- a. Grafik Perbandingan Prevalensi dan IKPS, menampilkan grafik yang membandingkan prevalensi *stunting* dengan nilai IKPS selama tiga tahun (2020–2022). Grafik ini dirancang untuk menunjukkan tren perkembangan upaya penanganan *stunting* berdasarkan indeks IKPS, apakah berhasil menurunkan prevalensi atau tidak. Pengguna dapat memilih filter tahun dan wilayah untuk menampilkan grafik yang sesuai.
- b. Diagram Rata-rata per Indikator, diagram ini menunjukkan rata-rata nilai setiap indikator penanganan *stunting* di wilayah tertentu. Indikator-indikator ini mencakup imunisasi, ASI eksklusif, air minum layak, sanitasi, dan lainnya. Visualisasi ini membantu pengguna memahami indikator mana yang memiliki nilai rendah dan perlu ditingkatkan. Data indikator dihitung berdasarkan nilai rata-rata per klaster atau wilayah tertentu, kemudian divisualisasikan dalam bentuk diagram batang.
- c. Hasil Analisis, bagian ini menyajikan ringkasan hasil analisis berdasarkan data yang telah diklasterisasi. Informasi yang ditampilkan mencakup wilayah kabupaten/kota dengan prevalensi *stunting* dan nilai IKPS, rekomendasi kebijakan untuk wilayah dengan nilai indikator rendah. Hasil analisis dirancang agar mudah dipahami, baik untuk pengambil kebijakan maupun pengguna umum.

## 4.2. Implementasi Analisis Hasil Klaster

Pada bagian ini, menyajikan *output* hasil klasterisasi secara lebih rinci dan disertai analisis terhadap pola setiap klasternya.

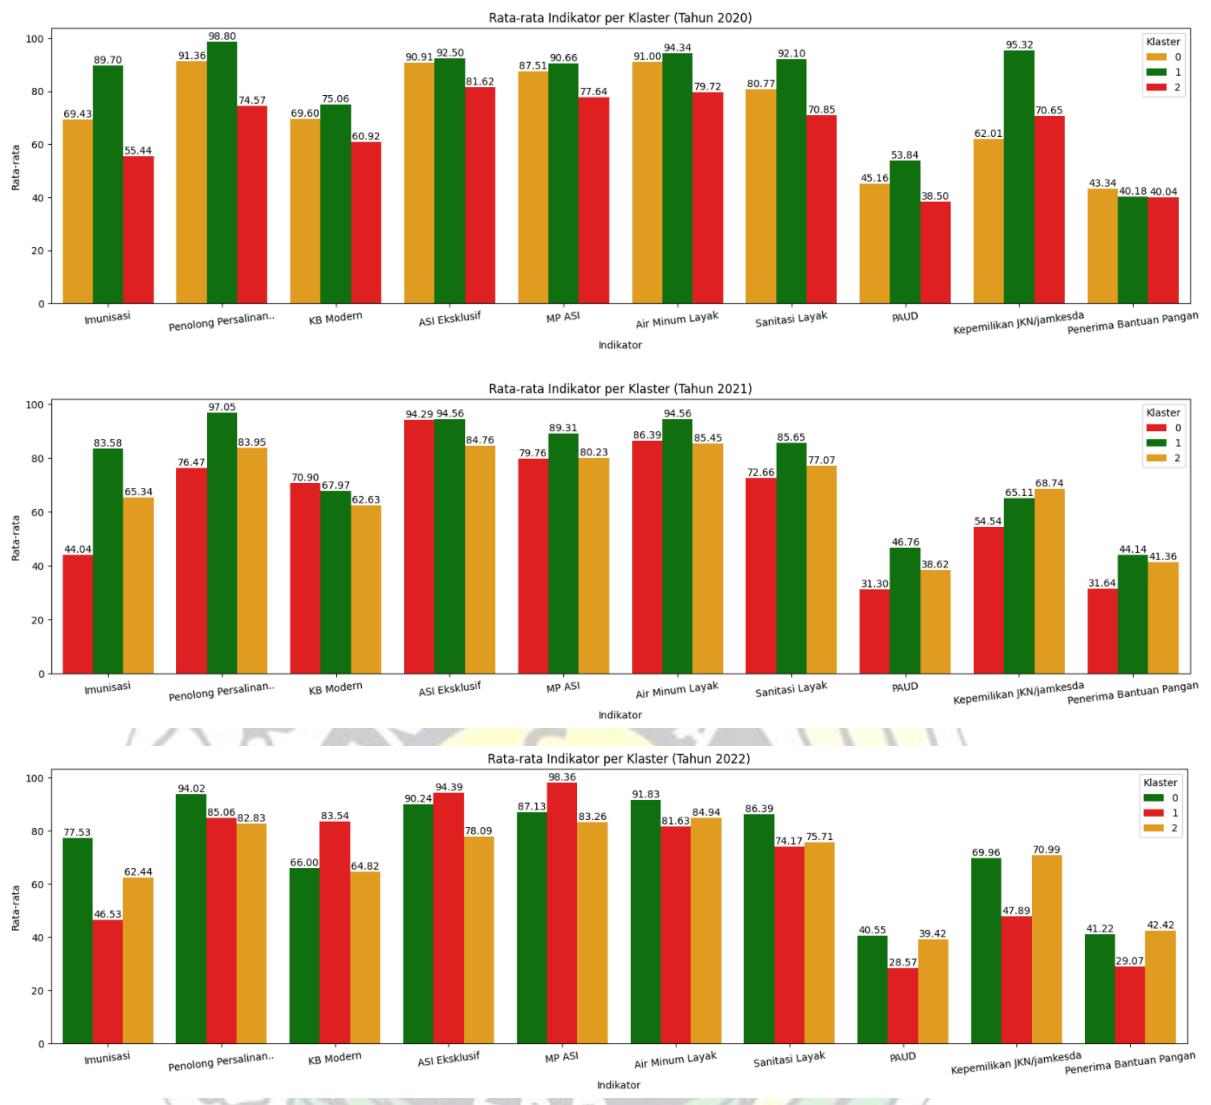
### 4.2.1. Analisis Karakteristik Klaster

Analisis karakteristik klaster diperlukan untuk mengetahui tingkat klaster yang dihasilkan, untuk mengidentifikasi klaster dan membantu memberikan label yang tepat. Langkah awal untuk mengidentifikasi karakteristik klaster yaitu dengan melihat rata-rata pada setiap prevalensi dan indikator seperti terlihat pada tabel 4.1

**Tabel 4.1.** Rata-rata Klaster

Atribut	Klaster 0	Klaster 1	Klaster 2
<b>Tahun 2020</b>			
Prevalensi	12.3603	7.86	15.7482
Imunisasi	69.4288	89.70	55.4367
Penolong Persalinan oleh Tenaga Kesehatan di Fasilitas Kesehatan	91.3575	98.80	74.5667
KB Modern	69.5973	75.06	60.9214
ASI Eksklusif	90.9055	92.50	81.6161
MP ASI	87.5137	90.66	77.6411
Air Minum Layak	90.9986	94.34	79.7214
Sanitasi Layak	80.7712	92.10	70.8536
PAUD	45.1630	53.84	38.5
Kepemilikan JKN/Jamkesda	62.0096	95.32	70.6544
Penerima Bantuan Pangan	43.3397	40.18	40.0402
<b>Tahun 2021</b>			
Prevalensi	4.6625	10.1689	11.9854
Imunisasi	44.0375	83.5770	65.3390
Penolong Persalinan oleh Tenaga Kesehatan di Fasilitas Kesehatan	76.4750	97.0492	83.9524
KB Modern	70.9	67.9738	62.6264
ASI Eksklusif	94.2875	94.5607	84.7581
MP ASI	79.7625	89.3066	80.2321
Air Minum Layak	86.3875	94.5623	85.4484
Sanitasi Layak	72.6625	85.6508	77.0695
PAUD	31.3	46.7639	38.6203
Kepemilikan JKN/Jamkesda	54.5375	65.1131	68.7390
Penerima Bantuan Pangan	31.6375	44.1410	41.3618
<b>Tahun 2022</b>			
Prevalensi	8.2677	3.0143	11.1519
Imunisasi	77.5333	46.5286	62.4424
Penolong Persalinan oleh Tenaga Kesehatan di Fasilitas Kesehatan	94.0187	85.0571	82.8311
KB Modern	65.9970	83.5429	64.8223
ASI Eksklusif	90.2450	94.3858	78.0898
MP ASI	87.1303	98.3571	83.2591
Air Minum Layak	91.8338	81.6286	84.9375
Sanitasi Layak	86.3934	74.1714	75.7102
PAUD	40.5520	28.5714	39.4239
Kepemilikan JKN/Jamkesda	69.9571	47.8858	70.9857
Penerima Bantuan Pangan	41.2167	29.0714	42.4223

Tabel diatas dapat dilihat lebih detail perbedaan setiap indikator dengan menggunakan diagram batang seperti pada gambar 4.8 berikut,



**Gambar 4.8. Rata-rata Indikator per Klaster**

Grafik di atas menunjukkan rata-rata indikator per klaster untuk tahun 2020, 2021, dan 2022. Pada tahun 2020, Klaster 0 memiliki rata-rata indikator yang tinggi, terutama pada ASI Eksklusif, Penolong Persalinan, dan Air Minum Layak, meskipun indikator Penerima Bantuan Pangan dan PAUD masih relatif rendah. Klaster 1 menunjukkan stabilitas pada indikator seperti ASI Eksklusif dan MP ASI, namun menghadapi tantangan pada Sanitasi Layak dan PAUD. Sebaliknya, Klaster 2 menunjukkan kinerja terendah di hampir semua kategori, terutama pada PAUD dan Sanitasi Layak.

Pada tahun 2021, pola serupa terlihat dengan Klaster 0 tetap unggul pada indikator seperti ASI Eksklusif, MP ASI, dan Sanitasi Layak, meskipun PAUD masih menjadi tantangan. Klaster 1 mempertahankan kinerja stabil di beberapa indikator, namun PAUD dan Penerima Bantuan Pangan tetap rendah. Klaster 2 masih menjadi klaster dengan indikator rata-rata terendah, termasuk PAUD, Sanitasi Layak, dan Penerima Bantuan Pangan.

Pada tahun 2022, Klaster 0 kembali unggul, terutama pada ASI Eksklusif dan MP ASI, meski PAUD dan Penerima Bantuan Pangan menunjukkan nilai yang lebih rendah. Klaster 1 memiliki kinerja yang cukup stabil pada MP ASI dan ASI Eksklusif, namun menghadapi kendala pada PAUD dan Penerima Bantuan Pangan. Klaster 2 tetap memiliki indikator yang paling rendah di hampir semua kategori, dengan tantangan terbesar pada PAUD dan Penerima Bantuan Pangan. Secara keseluruhan, indikator seperti ASI Eksklusif dan Penolong Persalinan konsisten menunjukkan nilai yang baik, terutama di Klaster 0. Namun, indikator PAUD dan Penerima Bantuan Pangan menjadi tantangan besar di semua klaster, terutama Klaster 2, yang menunjukkan kinerja terendah secara konsisten.

Berdasarkan Indeks Khusus Penanganan *Stunting* (IKPS), yang menjadi patokan dari penentuan indikator penanganan, yang terdiri dari Imunisasi, Penolong Persalinan oleh Tenaga Kesehatan di Fasilitas Kesehatan, KB Modern, ASI Eksklusif, MP ASI, Air Minum Layak, Sanitasi Layak, PAUD, Kepemilikan JKN/Jamkesda dan Penerima Bantuan Pangan. Indikator-indikator tersebut dijumlahkan seluruhnya kemudian ditampilkan rata-rata seperti terlihat pada Tabel 4.2. dibawah ini,

**Tabel 4.2.** Rata-rata Prevalensi dan IKPS per Klaster

Tahun	Klaster	Prevalensi	IKPS	Keterangan
2020	0	12.36	69.95	Prevalensi Menengah, IKPS Stabil
	1	7.86	78.82	Prevalensi Baik, IKPS Optimal

	2	15.75	62.49	Prevalensi Buruk, IKPS Rendah
2021	0	4.66	60.95	Prevalensi Baik, IKPS Rendah
	1	10.17	73.26	Prevalensi Menengah, IKPS Optimal
	2	11.99	65.62	Prevalensi Buruk, IKPS Stabil
2022	0	8.27	70.63	Prevalensi Menengah, IKPS Optimal
	1	3.01	62.60	Prevalensi Baik, IKPS Rendah
	2	11.15	65.47	Prevalensi Buruk, IKPS Stabil

Berdasarkan tabel rata-rata klaster dan rata-rata prevalensi dan IKPS per klasernya seperti tabel diatas, karakteristik setiap klaster dan setiap tahunnya memiliki pola prevalensi dan indikator yang berbeda dan signifikan. Berikut uraian terkait karakteristik setiap klaster:

**Tabel 4.3.** Karakteristik Klaster

Tahun	Klaster	Karakteristik Rata-rata	Label
2020	1	<ul style="list-style-type: none"> <li>• Prevalensi rendah (7.86)</li> <li>• Indikator baik: Imunisasi (89.70), Penolong persalinan (98.80), ASI Eksklusif (92.50), MP ASI (90.66)</li> <li>• Kekurangan: PAUD (53.84)</li> </ul>	Prevalensi Baik, IKPS Optimal
	0	<ul style="list-style-type: none"> <li>• Prevalensi sedang (12.36)</li> <li>• Indikator baik: Penolong persalinan (91.36), ASI eksklusif (90.91), MP ASI (87.51), Air minum layak (90.99)</li> <li>• Kekurangan: PAUD (45.16), Kepemilikan JKN/jamkesda (62.01), Bantuan pangan (43.34)</li> </ul>	Prevalensi Menengah, IKPS Stabil
	2	<ul style="list-style-type: none"> <li>• Prevalensi tinggi (15.75)</li> <li>• Indikator baik: ASI eksklusif (81.62), Air minum layak (79.72)</li> <li>• Kekurangan: Imunisasi (55.44), KB modern (60.92), PAUD</li> </ul>	Prevalensi Buruk, IKPS Rendah

		(38.5), Penerima bantuan pangan (40.04)	
2021	1	<ul style="list-style-type: none"> <li>Prevalensi sedang (10.17)</li> <li>Indikator baik: Imunisasi (83.58), Penolong persalinan (97.05), ASI eksklusif (94.56), MP ASI (89.3), Air minum layak (94.56), Sanitasi layak (85.65)</li> <li>Kekurangan: PAUD (46.76), Penerima bantuan pangan (44.14)</li> </ul>	Prevalensi Menengah, IKPS Optimal
	2	<ul style="list-style-type: none"> <li>Prevalensi sedang (11.99)</li> <li>Indikator baik: Penolong persalinan (83.95), ASI eksklusif (84.76), MP ASI (80.23), Air minum layak (85.45)</li> <li>Kekurangan: PAUD (38.62), Imunisasi (65.34), Penerima bantuan pangan (41.36)</li> </ul>	Prevalensi Buruk, IKPS Stabil
	0	<ul style="list-style-type: none"> <li>Prevalensi rendah (4.66)</li> <li>Indikator baik: ASI eksklusif (94.29), Air minum layak (86.39), MP ASI (79.76)</li> <li>Kekurangan: Imunisasi (44.03), PAUD (31.3), Kepemilikan JKN/jamkesda (54.54), Penerima bantuan pangan (31.64)</li> </ul>	Prevalensi Baik, IKPS Rendah
2022	0	<ul style="list-style-type: none"> <li>Prevalensi sedang (8.27)</li> <li>Indikator baik: Penolong persalinan (94.02), ASI eksklusif (90.24), MP ASI (87.13), Air minum layak (91.83), Sanitasi layak (86.39)</li> <li>Kekurangan: KB modern (65.99), PAUD (40.55), Penerima bantuan pangan (41.22)</li> </ul>	Prevalensi Menengah, IKPS Optimal
	2	<ul style="list-style-type: none"> <li>Prevalensi tinggi (11.15)</li> <li>Indikator baik: Penolong</li> </ul>	Prevalensi Buruk, IKPS Stabil

		<p>persalinan (82.83), MP ASI (83.25), Air minum layak (84.94)</p> <ul style="list-style-type: none"> <li>• Kekurangan: Imunisasi (62.44), KB modern (64.82) PAUD (39.42), Penerima bantuan pangan (42.42)</li> </ul>	
1		<ul style="list-style-type: none"> <li>• Prevalensi rendah (3.01)</li> <li>• Indikator baik: Penolong persalinan (85.06), ASI ekslusif (94.39), MP ASI (98.36)</li> <li>• Kekurangan: Imunisasi (46.53), PAUD (28.57), JKN/Jamkesda (47.88), Bantuan pangan (29.07)</li> </ul>	Prevalensi Baik, IKPS Rendah

#### 4.2.2. Hasil Analisis Klaster

Proses klasterisasi telah dilakukan untuk mengelompokkan wilayah di Indonesia berdasarkan indikator Indeks Khusus Penanganan *Stunting* (IKPS). Analisis karakteristik dan pemberian label juga sudah dilakukan, selanjutnya adalah menampilkan hasil klasterisasi wilayah pada tabel 4.4 dibawah ini,

**Tabel 4.4.** Wilayah Hasil Klaster

Tahun	Klaster	Kab/Kota	Jumlah Kab/Kota
2020	1 (Prevalensi Baik, IKPS Optimal)	Grobogan, Demak, Nganjuk, Gianyar, Sumbawa Barat.	5
	0 (Prevalensi Menengah, IKPS Stabil)	Langkat, Solok, Pasaman Barat, Kampar, Rokan Hulu, Ogan Ilir, Kota Palembang, Lampung Tengah, Pesawaran, Bogor, Sukabumi, Cianjur, Garut, Ciamis, Kuningan, Cirebon, Majalengka, Sumedang, Indramayu, Subang, Bandung Barat, Kota Bekasi, Kota Depok, Cilacap, Banyumas, Purwalingga, Kebumen, Magelang, Klaten, Sragen, Blora, Pati, Jepara, Pekalongan, Pemalang, Brebes, Kulon Progo, Bantul, Gunung Kidul, Kediri, Malang, Jember, Pasuruan, Sidoarjo, Ngawi, Lamongan, Sumenep, Bangli, Lombok Barat, Lombok Tengah, Lombok Timur, Sumbawa, Dompu, Bima, Lombok Utara, Belu, Sikka, Ngada, Sambas, Kutai Barat, Malinau,	73

		Bolaang Mongondow, Minahasa Utara, Bolaang Mongondow Selatan, Banggai, Morowali, Sigi, Jeneponto, Takalar, Gowa, Bone, Pinrang, Enrekang.	
	2 (Prevalensi Buruk, IKPS Rendah)	Aceh Tenggara, Aceh Timur, Aceh Tengah, Pidie, Bireuen, Gayo Lues, Nagan Raya, Bener Meriah, Kota Subulussalam, Nias, Mandailing Natal, Tapanuli Tengah, Simalungun, Dairi, Deli Serdang, Pakpak Bharat, Padang Lawas, Nias Barat, Kota Medan, Kota Gunungsitoli, Lima Puluh Kota, Pasaman, Pelalawan, Rokan Hilir, Kepulauan Meranti, Kerinci, Merangin, Tanjung Jabung Timur, Ogan Komering Ilir, Muara Enim, Lahat, Bengkulu Utara, Seluma, Tanggamus, Bangka, Bangka Selatan, Natuna, Lingga, Kota Jakarta Timur, Kota Bandung, Wonosobo, Trenggalek, Bondowoso, Probolinggo, Bangkalan, Pamekasan, Kota Surabaya, Pandeglang, Lebak, Buleleng, Sumba Timur, Kupang, Timor Tengah Selatan, Timor Tengah Utara, Alor, Ende, Rote Ndao, Manggarai Barat, Sumba Tengah, Sumba Barat Daya, Nagekeo, Manggarai Timur, Sabu Raijua, Malaka, Ketapang, Sintang, Kapuas Hulu, Kotawaringin Timur, Gunung Mas, Barito Timur, Tapin, Hulu Sungai Utara, Tabalong, Tanah Bumbu, Bulungan, Nunukan, Bolaang Mongondow Utara, Kepulauan Selayar, Sinjai, Tana Toraja, Toraja Utara, Buton, Muna, Kolaka, Wakatobi, Kolaka Timur, Buton Selatan, Boalemo, Gorontalo, Bone Bolango, Majene, Polewali Mandar, Mamasa, Mamuju, Maluku Tenggara, Maluku Tengah, Kepulauan Aru, Seram Bagian Barat, Seram Bagian Timur, Maluku Barat Daya, Kepulauan Sula, Halmahera Selatan, Fakfak, Kaimana, Teluk Wondama, Teluk Bintuni, Manokwari, Manokwari Selatan, Pegunungan Arfak, Jayapura, Biak Numfor, Kota Jayapura.	112
2021	1 (Prevalensi Menengah, IKPS Optimal)	Asahan, Simalungun, Dairi, Humbang Hasundutan, Siak, Bengkalis, Lampung Tengah, Pringsewu, Kota Batam, Kota Jakarta Pusat, Ciamis, Kuningan, Majalengka, Sumedang, Kota Bogor, Kota Depok, Kota Cimahi, Cilacap, Purbalingga, Kebumen, Magelang, Boyolali, Klaten, Wonogiri, Karanganyar, Sragen, Blora, Rembang, Pati, Jepara, Demak, Semarang, Temanggung, Kendal, Batang, Pekalongan, Tegal, Brebes, Kota Surakarta, Kota Tegal, Sleman, Ponorogo, Trenggalek, Blitar, Kediri, Malang,	61

		Banyuwangi, Nganjuk, Madiun, Magetan, Ngawi, Bojonegoro, Kota Tangerang, Bangli, Lombok Barat, Lombok Timur, Sumbawa, Belu, Kota Samarinda, Gowa, Wajo.	
	2 (Prevalensi Buruk, IKPS Stabil)	Simeuleu, Aceh Tenggara, Aceh Timur, Aceh Tengah, Aceh Besar, Pidie, Bireuen, Aceh Utara, Gayo Lues, Aceh Tamiang, Nagan Raya, Bener Meriah, Kota Subulussalam, Nias, Mandailing Natal, Tapanuli Tengah, Tapanuli Utara, Labuhan Batu, Karo, Deli Serdang, Langkat, Nias Selatan, Pakpak Bharat, Serdang Bedagai, Batu Bara, Padang Lawas Utara, Padang Lawas, Labuhan Batu Selatan, Nias Utara, Nias Barat, Kota Medan, Kota Padangsidimpuan, Kota Gunungsitoli, Pesisir Selatan, Solok, Sijunjung, Padang Pariaman, Agam, Lima Puluh Kota, Pasaman, Pasaman Barat, Kota Padang, Indragiri Hulu, Indragiri Hilir, Pelalawan, Kampar, Rokan Hulu, Kepulauan Meranti, Kota Pekanbaru, Kerinci, Merangin, Tanjung Jabung Timur, Tanjung Jabung Barat, Tebo, Kota Jambi, Ogan Komering Ulu, Ogan Komering Ilir, Muara Enim, Lahat, Musi Rawas, Banyu Asin, Ogan Komering Ulu Timur, Ogan Ilir, Penukal Abab Lematang Ilir, Kota Palembang, Bengkulu Selatan, Bengkulu Utara, Seluma, Tanggamus, Lampung Selatan, Lampung Timur, Lampung Utara, Way Kanan, Tulangbawang, Pesawaran, Kota Bandar Lampung, Bangka, Bangka Barat, Bangka Selatan, Karimun, Natuna, Lingga, Kepulauan Seribu, Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Barat, Kota Jakarta Utara, Cianjur, Bandung, Garut, Tasikmalaya, Cirebon, Indramayu, Subang, Bekasi, Bandung Barat, Kota Bandung, Kota Bekasi, Kota Tasikmalaya, Banyumas, BanjarNEGARA, Wonosobo, Sukoharjo, Grobogan, Kudus, Pemalang, Kota Magelang, Kota Salatiga, Kota Semarang, Kota Pekalongan, Kulon Progo, Bantul, Gunung Kidul, Kota Yogyakarta, Tulungagung, Lumajang, Jember, Bondowoso, Situbondo, Probolinggo, Pasuruan, Sidoarjo, Mojokerto, Jombang, Tuban, Lamongan, Gresik, Bangkalan, Pamekasan, Kota Malang, Kota Surabaya, Pandeglang, Lebak, Tangerang, Serang, Kota Serang, Kota Tangerang Selatan, Gianyar, Buleleng, Kota Denpasar, Lombok Tengah, Dompu, Bima, Sumbawa Barat, Kota Mataram, Sumba Barat, Sumba Timur, Kupang, Timor Tengah Selatan, Timor Tengah Utara, Alor,	246

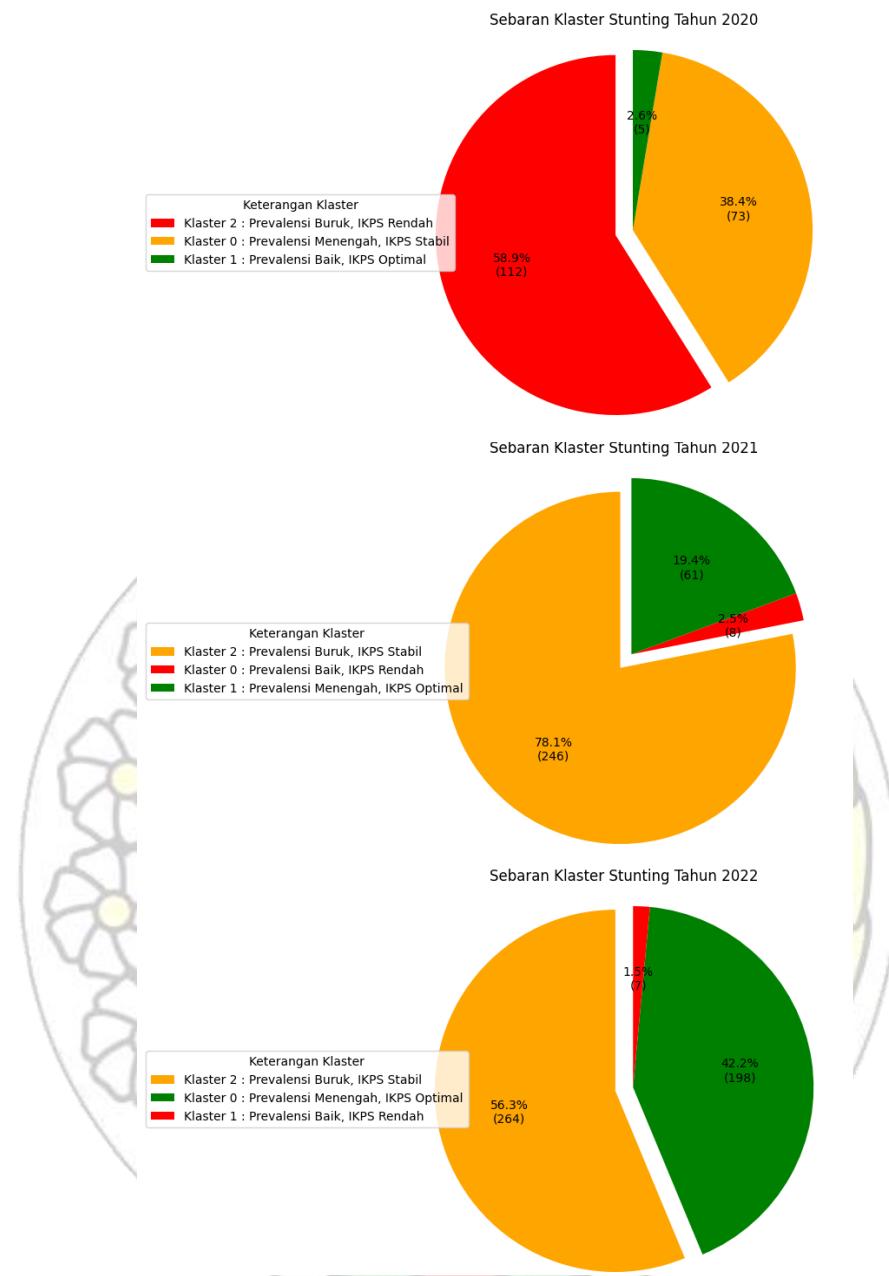
		Lembata, Flores Timur, Sikka, Ende, Ngada, Manggarai, Rote Ndao, Manggarai Barat, Sumba Tengah, Sumba Barat Daya, Nagekeo, Manggarai Timur, Sabu Raijua, Malaka, Sambas, Landak, Sanggau, Ketapang, Sintang, Kapuas Hulu, Kubu Raya, Kota Pontianak, Tanah Laut, Barito Kuala, Tapin, Hulu Sungai Tengah, Hulu Sungai Utara, Tanah Bumbu, Kota Banjarmasin, Kota Banjar Baru, Kutai Barat, Kutai Kartanegara, Kutai Timur, Kota Balikpapan, Malinau, Bulungan, Nunukan, Bolaang Mongondow, Minahasa Utara, Bolaang Mongondow Utara, Banggai Kepulauan, Banggai Kepulauan, Morowali, Parigi Moutong, Kepulauan Selayar, Bulukumba, Jeneponto, Takalar, Sinjai, Maros, Bone, Pinrang, Enrekang, Luwu, Luwu Utara, Toraja Utara, Buton, Muna, Kolaka, Wakatobi, Kolaka Timur, Konawe Kepulauan, Buton Selatan, Boalemo, Gorontalo, Bone Bolango, Majene, Polewali Mandar, Mamasa, Mamuju, Mamuju Tengah, Maluku Tenggara, Maluku Tengah, Buru, Seram Bagian Barat, Seram Bagian Timur, Maluku Barat Daya, Buru Selatan, Kota Ambon, Kota Tual, Halmahera Tengah, Kepulauan Sula, Halmahera Selatan, Halmahera Timur, Fakfak, Kaimana, Teluk Wondama, Teluk Bintuni, Manokwari, Manokwari Selatan, Pegunungan Arfak, Jayapura, Keerom, Supiori, Kota Jayapura.	
	0 (Prevalensi Baik, IKPS Rendah)	Labuhan Batu Utara, Rokan Hilir, Musi Banyuasin, Kaur, Bogor, Sukabumi, Purwakarta, Karawang.	8
2022	0 (Prevalensi Menengah, IKPS Stabil)	Aceh Tamiang, Kota Langsa, Tapanuli Utara, Asahan, Simalungun, Karo, Deli Serdang, Langkat, Humbang Hasundutan, Pakpak Bharat, Serdang Bedagai, Kota Binjai, Sijunjung, Agam, Kota Solok, Kota Padang Panjang, Kota Bukittinggi, Kota Payakumbuh, Kota Pariaman, Siak, Kampar, Bengkalis, Batang Hari, Tanjung Jabung Barat, Kota Jambi, Ogan Komering Ulu, Lahat, Banyu Asin, Ogan Ilir, Kota Palembang, Kota Prabumulih, Bengkulu Utara, Kaur, Seluma, Mukomuko, Lampung Selatan, Lampung Timur, Lampung Utara, Way Kanan, Tulangbawang, Pesawaran, Pringsewu, Mesuji, Pesisir Barat, Kota Bandar Lampung, Kota Metro, Bangka Barat, Bangka Tengah, Kota Pangkal Pinang, Karimun, Bintan, Kota Batam, Kota Tanjung Pinang, Kota Jakarta Selatan, Kota Jakarta Timur, Kota Jakarta Pusat, Kota Jakarta Barat, Kota Jakarta Utara,	198

	Sukabumi, Cianjur, Bandung, Garut, Kuningan, Cirebon, Majalengka, Indramayu, Subang, Karawang, Bekasi, Pangandaran, Kota Bogor, Kota Bekasi, Kota Depok, Kota Cimahi, Kota Banjar, Cilacap, Banyumas, Purbalingga, Kebumen, Purworejo, Magelang, Boyolali, Klaten, Sukoharjo, Wonogiri, Karanganyar, Sragen, Grobogan, Blora, Rembang, Pati, Kudus, Jepara, Semarang, Temanggung, Kendal, Batang, Pekalongan, Tegal, Brebes, Kota Salatiga, Kota Semarang, Kota Tegal, Sleman, Kota Yogyakarta, Pacitan, Ponorogo, Trenggalek, Tulungagung, Blitar, Kediri, Malang, Jember, Banyuwangi, Pasuruan, Sidoarjo, Nganjuk, Madiun, Magetan, Ngawi, Tuban, Gresik, Sampang, Kota Malang, Kota Mojokerto, Kota Madiun, Kota Surabaya, Lebak, Kota Tangerang, Kota Cilegon, Kota Tangerang Selatan, Jembrana, Badung, Gianyar, Bangli, Karang Asem, Buleleng, Kota Denpasar, Lombok Barat, Lombok Tengah, Lombok Timur, Sumbawa, Bima, Belu, Lembata, Sikka, Rote Ndao, Mempawah, Kota Pontianak, Kota Singkawang, Kotawaringin Barat, Barito Timur, Kota Palangka Raya, Kota Banjarmasin, Kota Banjar Baru, Paser, Kutai Barat, Kutai Kartanegara, Kutai Timur, Penajam Paser Utara, Kota Balikpapan, Kota Samarinda, Kota Bontang, Kota Tarakan, Minahasa, Bolaang Mongondow Utara, Siau Tagulandang Biaro, Bolaang Mongondow Selatan, Kota Tomohon, Kota Kotamobagu, Morowali, Poso, Buol, Sigi, Kota Palu, Kepulauan Selayar, Bulukumba, Takalar, Gowa, Maros, Barru, Bone, Soppeng, Wajo, Sidenreng Rappang, Pinrang, Enrekang, Luwu Utara, Luwu Timur, Kota Makassar, Kota Palopo, Konawe Selatan, Kolaka Utara, Buton Selatan, Kota Kendari, Kota Ternate, Kota Tidore Kepulauan, Manokwari.	
2 (Prevalensi Buruk, IKPS Stabil)	Aceh Singkil, Aceh Selatan, Aceh Tenggara, Aceh Timur, Aceh Tengah, Aceh Barat, Aceh Besar, Pidie, Bireuen, Aceh Utara, Aceh Barat Daya, Gayo Lues, Nagan Raya, Aceh Jaya, Bener Meriah, Pidie Jaya, Kota Banda Aceh, Kota Sabang, Kota Lhokseumawe, Kota Subulussalam, Nias, Mandailing Natal, Tapanuli Selatan, Tapanuli Tengah, Toba Samosir, Labuhan Batu, Dairi, Nias Selatan, Samosir, Batu Bara, Padang Lawas Utara, Padang Lawas, Labuhan Batu Selatan, Labuhan Batu Utara, Nias Utara, Nias	264

		Barat, Kota Sibolga, Kota Tanjung Balai, Kota Pematang Siantar, Kota Tebing Tinggi, Kota Medan, Kota Padangsidimpuan, Kota Gunungsitoli, Kepulauan Mentawai, Pesisir Selatan, Solok, Tanah Datar, Padang Pariaman, Lima Puluh Kota, Pasaman, Solok Selatan, Dharmasraya, Pasaman Barat, Kota Padang, Kota Sawah Lunto, Kuantan Singingi, Indragiri Hulu, Indragiri Hilir, Pelalawan, Rokan Hulu, Rokan Hilir, Kepulauan Meranti, Kota Pekanbaru, Kota Dumai, Kerinci, Merangin, Muaro Jambi, Tanjung Jabung Timur, Kota Sungai Penuh, Ogan Komering Ilir, Muara Enim, Ogan Komering Ulu Selatan, Ogan Komering Ulu Timur, Empat Lawang, Penukal Abab Lematang Ilir, Kota Lubuklinggau, Bengkulu Selatan, Rejang Lebong, Lebong, Kepahiang, Bengkulu Tengah, Kota Bengkulu, Lampung Barat, Tanggamus, Lampung Tengah, Tulang Bawang Barat, Bangka, Belitung, Bangka Selatan, Belitung Timur, Natuna, Lingga, Kepulauan Anambas, Kepulauan Seribu, Bogor, Tasikmalaya, Ciamis, Sumedang, Purwakarta, Bandung Barat, Kota Sukabumi, Kota Bandung, Kota Cirebon, Kota Tasikmalaya, Banjarnegara, Wonosobo, Demak, Pemalang, Kota Magelang, Kota Surakarta, Kota Pekalongan, Kulon Progo, Bantul, Gunung Kidul, Lumajang, Bondowoso, Situbondo, Probolinggo, Mojokerto, Jombang, Bojonegoro, Lamongan, Bangkalan, Pamekasan, Sumenep, Kota Kediri, Kota Blitar, Kota Probolinggo, Kota Pasuruan, Kota Batu, Pandeglang, Tangerang, Serang, Kota Serang, Tabanan, Klungkung, Dompu, Sumbawa Barat, Lombok Utara, Kota Mataram, Kota Bima, Sumba Barat, Sumba Timur, Kupang, Timor Tengah Selatan, Timor Tengah Utara, Alor, Flores Timur, Ende, Ngada, Manggarai, Manggarai Barat, Sumba Tengah, Sumba Barat Daya, Nagekeo, Manggarai Timur, Sabu Raijua, Malaka, Kota Kupang, Sambas, Bengkayang, Landak, Sanggau, Ketapang, Sintang, Kapuas Hulu, Sekadau, Melawi, Kayong Utara, Kubu Raya, Kotawaringin Timur, Barito Selatan, Barito Utara, Sukamara, Lamandau, Seruyan, Katingan, Pulang Pisau, Gunung Mas, Murung Raya, Tanah Laut, Barito Kuala, Tapin, Hulu Sungai Selatan, Hulu Sungai Tengah, Hulu Sungai Utara, Tabalong, Tanah Bumbu, Balangan, Berau, Mahakam Hulu, Malinau, Bulungan, Nunukan, Bolaang	
--	--	--	--

	Mongondow, Kepulauan Sangihe, Kepulauan Talaud, Minahasa Selatan, Minahasa Utara, Minahasa Tenggara, Bolaang Mongondow Timur, Kota Manado, Kota Bitung, Banggai Kepulauan, Banggai, Donggala, Toli-Toli, Parigi Moutong, Tojo Una-Una, Banggai Laut, Morowali Utara, Bantaeng, Jeneponto, Sinjai, Luwu, Tana Toraja, Toraja Utara, Kota Parepare, Buton, Muna, Konawe, Kolaka, Bombana, Wakatobi, Buton Utara, Konawe Utara, Kolaka Timur, Konawe Kepulauan, Muna Barat, Buton Tengah, Kota Baubau, Boalemo, Gorontalo, Bone Bolango, Gorontalo Utara, Kota Gorontalo, Majene, Polewali Mandar, Mamasa, Mamuju, Mamuju Tengah, Maluku Tenggara, Maluku Tengah, Buru, Kepulauan Aru, Seram Bagian Barat, Seram Bagian Timur, Maluku Barat Daya, Buru Selatan, Kota Ambon, Kota Tual, Halmahera Barat, Halmahera Tengah, Kepulauan Sula, Halmahera Selatan, Halmahera Utara, Halmahera Timur, Pulau Morotai, Pulau Taliabu, Fakfak, Kaimana, Teluk Wondama, Teluk Bintuni, Manokwari Selatan.	
1 (Prevalensi Baik, IKPS Rendah)	Sarolangun, Tebo, Bungo, Musi Rawas, Musi Banyuasin, Musi Rawas Utara, Kota Pagar Alam.	7

Berdasarkan tabel diatas, dapat divisualisasikan untuk hasil analisis persebaran klaster per tahunnya menggunakan diagram *Pie Chart* pada Gambar 4.9 berikut,



**Gambar 4.9.** Sebaran *Stunting* per Tahun

Pada tahun 2020, mayoritas wilayah (56,3%) berada dalam klaster dengan prevalensi buruk meskipun IKPS stabil, menunjukkan tantangan signifikan dalam pengelolaan *stunting*. Sebanyak 42,2% wilayah masuk dalam kategori prevalensi menengah dengan IKPS optimal, sedangkan hanya 1,5% wilayah yang tergolong prevalensi baik. Hal ini mengindikasikan perlunya intervensi besar-besaran untuk memperbaiki kondisi gizi dan kesehatan di sebagian besar wilayah.

Pada tahun 2021, kondisi semakin memburuk dengan dominasi klaster prevalensi buruk yang meningkat menjadi 78,1%, menunjukkan penurunan yang signifikan dibandingkan tahun sebelumnya. Wilayah dengan prevalensi menengah turun menjadi 19,4%, dan klaster prevalensi baik tetap sangat kecil (2,5%). Hal ini menunjukkan bahwa langkah-langkah intervensi yang dilakukan belum cukup efektif untuk menekan angka *stunting* di wilayah yang paling rentan.

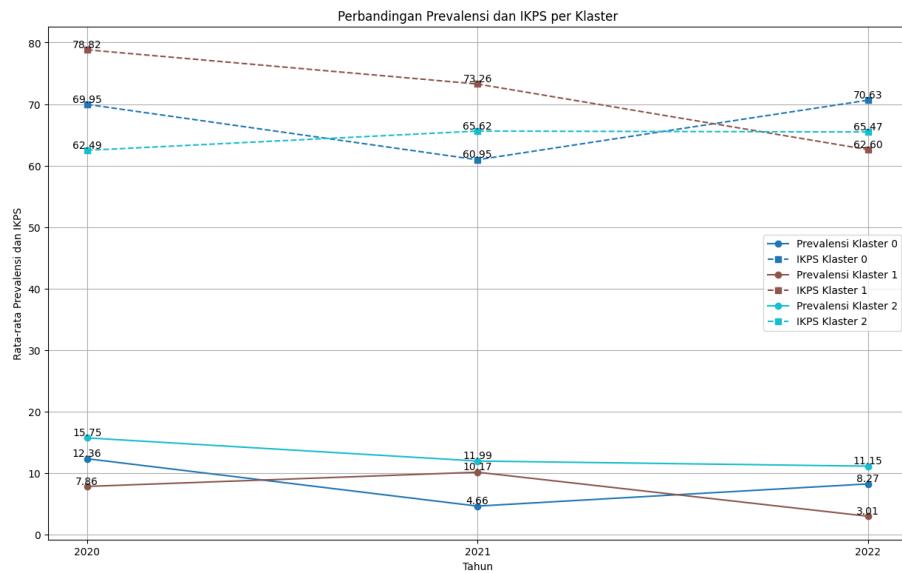
Pada tahun 2022, klaster prevalensi buruk mendominasi dengan 56,3%, sementara klaster prevalensi menengah mencapai 42,2%. Meskipun demikian, klaster prevalensi baik tetap sangat kecil, hanya sebesar 1,5%. Perubahan ini menunjukkan adanya indikasi awal keberhasilan intervensi di beberapa wilayah, namun perlu upaya lebih besar untuk mengurangi wilayah dengan prevalensi buruk dan meningkatkan jumlah wilayah yang masuk kategori prevalensi menengah dan baik.

### **4.3. Analisis Prevalensi *Stunting* Berdasarkan IKPS di Indonesia**

Analisis prevalensi *Stunting* di Indonesia didasarkan pada Indeks Khusus Penanganan *Stunting* (IKPS), yang merupakan hasil evaluasi kinerja kabupaten/kota dalam melaksanakan percepatan pencegahan *stunting*. IKPS merupakan ukuran yang disusun oleh Sekretariat Wakil Presiden (Setwapres) bersama Badan Pusat Statistik (BPS) untuk menilai efektivitas program-program pencegahan *stunting* di setiap wilayah.

#### **4.3.1. Hubungan IKPS dengan Prevalensi *Stunting***

Dalam analisis ini, IKPS digunakan untuk memetakan wilayah berdasarkan tingkat kinerjanya terhadap prevalensi *stunting*. Wilayah yang memiliki nilai IKPS tinggi diharapkan memiliki prevalensi *stunting* yang lebih rendah, karena menunjukkan keberhasilan implementasi program pencegahan. Sebaliknya, wilayah dengan nilai IKPS rendah mungkin memerlukan perhatian lebih dalam intervensi.



**Gambar 4.10.** Perbandingan Prevalensi dan IKPS per Klaster

Grafik diatas menunjukkan perbandingan rata-rata prevalensi *stunting* dan Indeks Khusus Penanganan *Stunting* (IKPS) di tiap klaster selama periode 2020–2022. Secara umum, prevalensi *stunting* di semua klaster mengalami penurunan. Klaster 0 memiliki prevalensi tertinggi, yakni 15,75% pada 2020, yang menurun secara konsisten hingga 11,15% pada 2022. Klaster 1 juga menunjukkan tren serupa, dengan prevalensi *stunting* turun dari 12,36% pada 2020 menjadi 8,27% pada 2022. Sementara itu, Klaster 2 memiliki prevalensi terendah, dari 7,86% pada 2020 turun menjadi 3,01% pada 2022, meskipun sempat mengalami sedikit kenaikan pada 2022.

Namun, tren IKPS di tiap klaster menunjukkan pola yang berbeda. Klaster 0 memiliki IKPS tertinggi di seluruh periode, tetapi cenderung fluktuatif, turun dari 78,22 pada 2020 menjadi 73,26 pada 2021, lalu meningkat kembali menjadi 70,63 pada 2022. Klaster 1 juga mengalami penurunan IKPS dari 69,95 pada 2020 menjadi 65,47 pada 2022, sementara Klaster 2 menunjukkan sedikit peningkatan dari 62,49 pada 2020 menjadi 62,60 pada 2022. Secara keseluruhan, klaster dengan IKPS lebih tinggi (Klaster 0 dan 1) cenderung memiliki prevalensi *stunting* yang lebih tinggi dibandingkan Klaster 2. Penurunan prevalensi *stunting* tidak selalu berbanding lurus dengan

peningkatan IKPS, seperti terlihat pada Klaster 2 yang memiliki penurunan prevalensi signifikan meskipun peningkatan IKPS tidak terlalu besar. Hal ini menunjukkan perlunya strategi berbeda untuk meningkatkan IKPS di Klaster 0 dan 1, sembari mengambil pembelajaran dari keberhasilan Klaster 2.

#### **4.3.2. Analisis Balita Tertangani dan Belum Tertangani Berdasarkan IKPS**

Analisis jumlah balita tertangani dan belum tertangani berdasarkan IKPS bertujuan untuk mengukur efektivitas program intervensi di setiap wilayah. Data ini memberikan gambaran kuantitatif tentang tingkat keberhasilan penanganan *stunting*.

##### a. Jumlah Balita Tertangani per Wilayah

$$\text{Balita Tertangani} = \left( \frac{\text{IKPS} \times \text{Jumlah Stunting}}{100} \right)$$

##### b. Jumlah Balita Belum Tertangani per Wilayah

$$\text{Balita Belum Tertangani} = \text{Jumlah Stunting} - \text{Balita Tertangani}$$

**Tabel 4.5. Jumlah Balita Tertangani dan Belum Tahun 2020**

Provinsi	Kab/Kota	Jumlah Stunting	Prevalensi	IKPS	Balita Tertangani	Balita Belum Tertangani	Label Klaster
Aceh	Aceh Tenggara	1711	10.7	57.3	980	730	Prevalensi Buruk, IKPS Rendah
Aceh	Aceh Timur	9269	29.7	54.1	5014	4254	Prevalensi Buruk, IKPS Rendah
Aceh	Aceh Tengah	1609	9.3	69.4	1116	492	Prevalensi Buruk, IKPS Rendah
Aceh	Pidie	142	8.9	67.6	95	46	Prevalensi Buruk, IKPS Rendah
Aceh	Bireuen	879	2	70	615	263	Prevalensi Buruk, IKPS Rendah
Aceh	Gayo Lues	643	7.6	58.5	376	266	Prevalensi Buruk, IKPS Rendah
Aceh	Nagan Raya	2345	17.2	64.2	1505	839	Prevalensi Buruk, IKPS Rendah
Aceh	Bener Meriah	1679	17.3	68.1	1143	535	Prevalensi Buruk, IKPS

							Rendah
Aceh	Kota Subulussalam	1718	15.6	61.1	1049	668	Prevalensi Buruk, IKPS Rendah
Sumatera Utara	Nias	1200	25.5	40.1	481	718	Prevalensi Buruk, IKPS Rendah
Sumatera Utara	Mandailing Natal	2201	6.2	52	1144	1056	Prevalensi Buruk, IKPS Rendah
Sumatera Utara	Tapanuli Tengah	1682	12	53.7	903	778	Prevalensi Buruk, IKPS Rendah
Sumatera Utara	Simalungun	1216	2.3	57	693	522	Prevalensi Buruk, IKPS Rendah
Sumatera Utara	Dairi	5745	21	55.6	3194	2550	Prevalensi Buruk, IKPS Rendah
Sumatera Utara	Deli Serdang	8027	7.3	55	4414	3612	Prevalensi Buruk, IKPS Rendah
...	...	...	...	...	...	...	...
Maluku	Seram Bagian Barat	894	4.2	55.6	497	396	Prevalensi Buruk, IKPS Rendah
Maluku	Seram Bagian Timur	1162	10.8	55.9	649	512	Prevalensi Buruk, IKPS Rendah
Maluku	Maluku Barat Daya	386	4.7	66	254	131	Prevalensi Buruk, IKPS Rendah
Maluku Utara	Kepulauan Sula	228	3.1	53.5	121	106	Prevalensi Buruk, IKPS Rendah
Maluku Utara	Halmahera Selatan	1966	12.2	61.6	1211	754	Prevalensi Buruk, IKPS Rendah
Papua Barat	Fakfak	1271	14.6	54.8	696	574	Prevalensi Buruk, IKPS Rendah
Papua Barat	Kaimana	440	6.6	57.6	253	186	Prevalensi Buruk, IKPS Rendah
Papua Barat	Teluk Wondama	353	15.4	52.6	185	167	Prevalensi Buruk, IKPS Rendah
Papua Barat	Teluk Bintuni	244	18.3	62.8	153	90	Prevalensi Buruk, IKPS Rendah
Papua Barat	Manokwari	1580	17.6	59.9	946	633	Prevalensi Buruk, IKPS Rendah
Papua Barat	Manokwari Selatan	172	8.2	54.5	93	78	Prevalensi Buruk, IKPS Rendah
Papua Barat	Pegunungan Arfak	76	1.7	44.7	33	42	Prevalensi Buruk, IKPS Rendah
Papua	Jayapura	1249	17.4	51.4	641	607	Prevalensi Buruk, IKPS Rendah

Papua	Biak Numfor	870	1.7	60.1	522	347	Prevalensi Buruk, IKPS Rendah
Papua	Kota Jayapura	1494	9.8	59.1	882	611	Prevalensi Buruk, IKPS Rendah

**Tabel 4.6.** Jumlah Balita Tertangani dan Belum Tahun 2021

Provinsi	Kab/Kota	Jumlah Stunting	Prevalensi	IKPS	Balita Tertangani	Balita Belum Tertangani	Label Klaster
Aceh	Simeuleu	1460	18.9	70.1	1023	436	Prevalensi Buruk, IKPS Stabil
Aceh	Aceh Tenggara	2988	18.9	54.8	1637	1350	Prevalensi Buruk, IKPS Stabil
Aceh	Aceh Timur	5982	22.6	56	3349	2632	Prevalensi Buruk, IKPS Stabil
Aceh	Aceh Tengah	1601	8.8	67.3	1077	523	Prevalensi Buruk, IKPS Stabil
Aceh	Aceh Besar	4220	14	69.3	2924	1295	Prevalensi Buruk, IKPS Stabil
Aceh	Pidie	2574	7.1	61.2	1575	998	Prevalensi Buruk, IKPS Stabil
Aceh	Bireuen	2563	6.6	69.4	1778	784	Prevalensi Buruk, IKPS Stabil
Aceh	Aceh Utara	5287	14.4	61.2	3235	2051	Prevalensi Buruk, IKPS Stabil
Aceh	Gayo Lues	413	4.8	62	256	156	Prevalensi Buruk, IKPS Stabil
Aceh	Aceh Tamiang	1509	6.7	71.4	1077	431	Prevalensi Buruk, IKPS Stabil
Aceh	Nagan Raya	1138	8.6	64.3	731	406	Prevalensi Buruk, IKPS Stabil
Aceh	Bener Meriah	2086	21.5	71.1	1483	602	Prevalensi Buruk, IKPS Stabil
Aceh	Kota Subulussalam	1196	12.2	60.1	718	477	Prevalensi Buruk, IKPS Stabil
Sumatera Utara	Nias	1116	17.3	41.3	460	655	Prevalensi Buruk, IKPS Stabil
Sumatera Utara	Mandailing Natal	1682	4.4	47.5	798	883	Prevalensi Buruk, IKPS Stabil
...	...	...	...	...	...	...	...
Maluku Utara	Halmahera Tengah	817	19.2	65.1	531	285	Prevalensi Buruk, IKPS Stabil

Maluku Utara	Kepulauan Sula	228	3.1	55.6	126	101	Prevalensi Buruk, IKPS Stabil
Maluku Utara	Halmahera Selatan	1966	12.2	64.1	1260	705	Prevalensi Buruk, IKPS Stabil
Maluku Utara	Halmahera Timur	1421	22.7	67.7	962	458	Prevalensi Buruk, IKPS Stabil
Papua Barat	Fakfak	1469	27.4	67.6	993	475	Prevalensi Buruk, IKPS Stabil
Papua Barat	Kaimana	226	4.2	59.3	134	91	Prevalensi Buruk, IKPS Stabil
Papua Barat	Teluk Wondama	515	14.5	50.5	260	254	Prevalensi Buruk, IKPS Stabil
Papua Barat	Teluk Bintuni	145	3.3	65.3	94	50	Prevalensi Buruk, IKPS Stabil
Papua Barat	Manokwari	1659	18	53.1	880	778	Prevalensi Buruk, IKPS Stabil
Papua Barat	Manokwari Selatan	89	6.7	63.4	56	32	Prevalensi Buruk, IKPS Stabil
Papua Barat	Pegunungan Arfak	82	2.3	43	35	46	Prevalensi Buruk, IKPS Stabil
Papua	Jayapura	904	14.3	51.2	462	441	Prevalensi Buruk, IKPS Stabil
Papua	Keerom	596	15	58	345	250	Prevalensi Buruk, IKPS Stabil
Papua	Supiori	381	15	56.6	215	165	Prevalensi Buruk, IKPS Stabil
Papua	Kota Jayapura	986	15.1	54	532	453	Prevalensi Buruk, IKPS Stabil

**Tabel 4.7.** Jumlah Balita Tertangani dan Belum Tahun 2022

Provinsi	Kab/Kota	Jumlah Stunting	Prevalensi	IKPS	Balita Tertangani	Balita Belum Tertangani	Label Klaster
Aceh	Aceh Singkil	1112	10	73.1	812	299	Prevalensi Buruk, IKPS Stabil
Aceh	Aceh Selatan	1712	11.7	75.6	1294	417	Prevalensi Buruk, IKPS Stabil
Aceh	Aceh Tenggara	2332	12.4	56.1	1308	1023	Prevalensi Buruk, IKPS Stabil
Aceh	Aceh Timur	2864	6.9	62.8	1798	1065	Prevalensi Buruk, IKPS Stabil
Aceh	Aceh Tengah	1576	8.7	66.8	1052	523	Prevalensi

							Buruk, IKPS Stabil
Aceh	Aceh Barat	796	5.4	70.7	562	233	Prevalensi Buruk, IKPS Stabil
Aceh	Aceh Besar	4193	11.8	68.7	2880	1312	Prevalensi Buruk, IKPS Stabil
Aceh	Pidie	1564	4.8	64.5	1008	555	Prevalensi Buruk, IKPS Stabil
Aceh	Bireuen	1274	3.6	68.7	875	398	Prevalensi Buruk, IKPS Stabil
Aceh	Aceh Utara	2271	5.6	65.7	1492	778	Prevalensi Buruk, IKPS Stabil
Aceh	Aceh Barat Daya	1328	10.6	74.8	993	334	Prevalensi Buruk, IKPS Stabil
Aceh	Gayo Lues	402	5	61.6	247	154	Prevalensi Buruk, IKPS Stabil
Aceh	Aceh Tamiang	1175	5.4	67.2	789	385	Prevalensi Menengah, IKPS Optimal
Aceh	Nagan Raya	1556	13.3	64.3	1000	555	Prevalensi Buruk, IKPS Stabil
Aceh	Acéh Jaya	1171	21.4	65.7	769	401	Prevalensi Buruk, IKPS Stabil
...	...	...	...	...	...	...	...
Maluku Utara	Halmahera Tengah	568	18.6	62.8	356	211	Prevalensi Buruk, IKPS Stabil
Maluku Utara	Kepulauan Sula	329	9.1	50.2	165	163	Prevalensi Buruk, IKPS Stabil
Maluku Utara	Halmahera Selatan	1348	12.1	69.6	938	409	Prevalensi Buruk, IKPS Stabil
Maluku Utara	Halmahera Utara	1542	20.5	55.7	858	683	Prevalensi Buruk, IKPS Stabil
Maluku Utara	Halmahera Timur	1288	17	63.7	820	467	Prevalensi Buruk, IKPS Stabil
Maluku Utara	Pulau Morotai	380	5.5	64	243	136	Prevalensi Buruk, IKPS Stabil
Maluku Utara	Pulau Taliabu	73	2.8	47.6	34	38	Prevalensi Buruk, IKPS Stabil
Maluku Utara	Kota Ternate	209	3.8	63.8	133	75	Prevalensi Menengah, IKPS Optimal
Maluku Utara	Kota Tidore Kepulauan	350	7.4	67.7	236	113	Prevalensi Menengah, IKPS

							Optimal
Papua Barat	Fakfak	1590	23.3	64.2	1020	569	Prevalensi Buruk, IKPS Stabil
Papua Barat	Kaimana	577	9.4	53.4	308	268	Prevalensi Buruk, IKPS Stabil
Papua Barat	Teluk Wondama	190	4.9	47.6	90	99	Prevalensi Buruk, IKPS Stabil
Papua Barat	Teluk Bintuni	408	16.6	63.9	260	147	Prevalensi Buruk, IKPS Stabil
Papua Barat	Manokwari	1400	10.4	58.7	821	578	Prevalensi Menengah, IKPS Optimal
Papua Barat	Manokwari Selatan	73	2.7	62	45	27	Prevalensi Buruk, IKPS Stabil

Analisis jumlah balita tertangani dan belum tertangani memberikan gambaran sejauh mana program intervensi di masing-masing wilayah telah berjalan efektif. Wilayah dengan jumlah balita tertangani yang tinggi mencerminkan keberhasilan program penanganan *stunting*, seperti akses layanan kesehatan, gizi, atau sanitasi yang memadai. Sebaliknya, tingginya jumlah balita belum tertangani di beberapa wilayah menunjukkan perlunya perhatian lebih dalam penyediaan layanan intervensi. Analisis ini juga menunjukkan hubungan erat dengan Indeks Khusus Penanganan *Stunting* (IKPS), di mana wilayah dengan IKPS tinggi cenderung memiliki jumlah balita tertangani yang lebih banyak, sedangkan wilayah dengan IKPS rendah menunjukkan jumlah balita belum tertangani yang lebih tinggi, mengindikasikan tantangan dalam implementasi program.

Beberapa faktor yang berkontribusi pada tingginya jumlah balita belum tertangani mencakup keterbatasan aksesibilitas, kurangnya sumber daya kesehatan, dan rendahnya kesadaran masyarakat terhadap program intervensi. Wilayah dengan jumlah balita belum tertangani yang tinggi harus menjadi prioritas pemerintah untuk meningkatkan layanan kesehatan, akses gizi, dan dukungan sosial.

### 4.3.2. Identifikasi Wilayah Prioritas

Identifikasi Wilayah Prioritas adalah langkah penting dalam analisis *stunting* untuk menentukan wilayah yang membutuhkan perhatian dan intervensi lebih besar. Wilayah prioritas diidentifikasi berdasarkan kombinasi prevalensi *stunting* yang tinggi dan nilai IKPS yang rendah, yang menunjukkan bahwa wilayah tersebut memiliki beban masalah *stunting* yang berat dan belum mendapatkan intervensi yang memadai.

**Tabel 4.8.** Wilayah Prioritas Tahun 2020

No	Provinsi	Kab/Kota	Jumlah Balita	Jumlah Stunting	Prevalensi	IKPS	Balita Tertangani	Balita Belum Tertangani	Label Klaster
1	Nusa Tenggara Timur	Timor Tengah Selatan	28552	13859	48.5	57.4	7955	5903	Prevalensi Buruk, IKPS Rendah
2	Kalimantan Utara	Nunukan	4217	1851	43.9	66.5	1230	620	Prevalensi Buruk, IKPS Rendah
3	Nusa Tenggara Timur	Timor Tengah Utara	17163	7293	42.5	62.9	4587	2705	Prevalensi Buruk, IKPS Rendah
4	Nusa Tenggara Timur	Sabu Raijua	6602	2716	41.1	72.6	1971	744	Prevalensi Buruk, IKPS Rendah
5	Sulawesi Barat	Majene	11843	4754	40.1	76.0	3613	1140	Prevalensi Buruk, IKPS Rendah
6	Nusa Tenggara Timur	Sumba Barat Daya	15836	6066	38.3	54.0	3275	2790	Prevalensi Buruk, IKPS Rendah
7	Kalimantan Barat	Kapuas Hulu	16108	5326	33.1	57.7	3073	2252	Prevalensi Buruk, IKPS Rendah
8	Kepulauan Bangka Belitung	Bangka Selatan	618	202	32.7	55.9	112	89	Prevalensi Buruk, IKPS Rendah
9	Kalimantan Barat	Sintang	14322	4504	31.4	54.8	2468	2035	Prevalensi Buruk, IKPS Rendah
10	Aceh	Aceh Timur	31161	9269	29.7	54.1	5014	4254	Prevalensi Buruk, IKPS Rendah

**Tabel 4.9.** Wilayah Prioritas Tahun 2021

No	Provinsi	Kab/Kota	Jumlah Balita	Jumlah Stunting	Prevalensi	IKPS	Balita Tertangani	Balita Belum Tertangani	Label Klaster
1	Kalimantan Utara	Nunukan	4217	1851	43.9	67.5	1249	601	Prevalensi Buruk, IKPS Stabil
2	Nusa Tenggara Timur	Timor Tengah Selatan	41592	16904	40.6	59.2	10007	6896	Prevalensi Buruk, IKPS Stabil
3	Sulawesi Barat	Majene	13321	4564	34.3	77.3	3527	1036	Prevalensi Buruk, IKPS Stabil
4	Kalimantan Barat	Kapuas Hulu	16027	5290	33.0	64.3	3401	1888	Prevalensi Buruk, IKPS Stabil
5	Nusa Tenggara Timur	Sumba Barat	8592	2763	32.2	71.7	1981	781	Prevalensi Buruk, IKPS Stabil
6	Nusa Tenggara Timur	Sabu Raijua	7192	2258	31.4	68.8	1553	704	Prevalensi Buruk, IKPS Stabil
7	Kalimantan Barat	Sintang	14677	4567	31.1	57.2	2612	1954	Prevalensi Buruk, IKPS Stabil
8	Nusa Tenggara Timur	Timor Tengah Utara	20173	5836	28.9	70.6	10007	6896	Prevalensi Buruk, IKPS Stabil
9	Kalimantan Utara	Bulungan	4267	1223	28.7	65.8	804	418	Prevalensi Buruk, IKPS Stabil
10	Sulawesi Tenggara	Buton Selatan	6015	1724	28.7	73.9	1274	449	Prevalensi Buruk, IKPS Stabil

**Tabel 4.10.** Wilayah Prioritas Tahun 2022

No	Provinsi	Kab/Kota	Jumlah Balita	Jumlah Stunting	Prevalensi	IKPS	Balita Tertangani	Balita Belum Tertangani	Label Klaster
1	Nusa Tenggara Timur	Sumba Barat Daya	29700	13150	44.3	62.0	8153	4997	Prevalensi Buruk, IKPS Stabil
2	Nusa Tenggara Barat	Lombok Utara	18608	6302	33.9	79.6	5016	1285	Prevalensi Buruk, IKPS Stabil
3	Sulawesi Barat	Majene	13339	4300	32.2	74.4	3199	1100	Prevalensi Buruk, IKPS Stabil
4	Nusa Tenggara Timur	Timor Tengah Selatan	41026	13133	32.0	60.1	7892	5240	Prevalensi Buruk, IKPS Stabil
5	Kalimantan Barat	Kapuas Hulu	16133	5026	31.2	56.9	2859	2166	Prevalensi Buruk, IKPS Stabil

6	Nusa Tenggara Timur	Timor Tengah Utara	17728	5524	31.2	71.8	3966	1557	Prevalensi Buruk, IKPS Stabil
7	Kalimantan Barat	Melawi	8756	2642	30.2	58.2	1537	1104	Prevalensi Buruk, IKPS Stabil
8	Maluku	Kota Ambon	5054	1501	29.7	56.5	848	652	Prevalensi Buruk, IKPS Stabil
9	Kalimantan Barat	Sintang	15679	4482	28.6	59.0	2644	1837	Prevalensi Buruk, IKPS Stabil
10	Kalimantan Barat	Bengkayang	15609	4353	27.9	64.8	2820	1532	Prevalensi Buruk, IKPS Stabil

#### 4.4. Pengujian

##### 4.4.1. Evaluasi Kualitas Klasterisasi

Evaluasi hasil klasterisasi dilakukan menggunakan *Davies-Bouldin Index* (DBI). DBI merupakan metrik yang mengukur validitas *cluster* berdasarkan rata-rata jarak antar *cluster* dibandingkan dengan ukuran *cluster* itu sendiri. Rumus DBI:

$$DBI = \frac{1}{N} \sum_{i=1}^N \max_{j \neq i} \left( \frac{S_i + S_j}{D_{i,j}} \right)$$

Keterangan:

$N$  = Jumlah klaster

$S_i$  = Rata-rata jarak semua titik dalam klaster  $i$  ke centroid klaster  $i$

$D_{i,j}$  = Jarak antara centroid klaster  $i$  dan klaster  $j$

$\max_{j \neq i}$  = Untuk per klaster  $i$ , klaster  $j$  yang memiliki *overlap* tertinggi

Untuk rentang kualitas klaster *Davies-Bouldin Index* (DBI), Interpretasinya sebagai berikut.

- DBI mendekati 0: Kualitas klasterisasi sangat baik. *Cluster* lebih kompak (dalam *cluster*) dan lebih terpisah (antar *cluster*).
- DBI yang lebih tinggi ( $>1$ ): Menunjukkan kualitas klasterisasi yang kurang baik, di mana *cluster* saling tumpang tindih atau kurang terdefinisi dengan baik.

### Evaluasi Kualitas Klaster:

```

from sklearn.metrics import davies_bouldin_score

# Menghitung DBI untuk setiap tahun
dbi_2020 = davies_bouldin_score(datastunting2020, cluster_labels2020)
dbi_2021 = davies_bouldin_score(datastunting2021, cluster_labels2021)
dbi_2022 = davies_bouldin_score(datastunting2022, cluster_labels2022)

# Menampilkan hasil DBI
print("Davies-Bouldin Index (DBI) Tahun 2020:", dbi_2020)
print("Davies-Bouldin Index (DBI) Tahun 2021:", dbi_2021)
print("Davies-Bouldin Index (DBI) Tahun 2022:", dbi_2022)

```

Davies-Bouldin Index (DBI) Tahun 2020: 0.5827384236776317  
Davies-Bouldin Index (DBI) Tahun 2021: 0.6639081031810748  
Davies-Bouldin Index (DBI) Tahun 2022: 0.5709594855567454

**Gambar 4.11.** Evaluasi Kualitas Klaster DBI

Dari hasil evaluasi klaster yang ditunjukkan pada Gambar 4.11., maka dapat dilihat pada Tabel 4.11. dibawah ini,

**Tabel 4.11.** Evaluasi Kualitas Klaster

Tahun	Nilai DBI	Keterangan
2020	0.5827	Kualitas klasterisasi cukup baik; <i>cluster</i> terdefinisi dengan baik.
2021	0.6639	Kualitas klasterisasi sedikit lebih rendah; ada sedikit tumpang tindih <i>cluster</i> .
2022	0.5710	Kualitas klasterisasi lebih baik; <i>cluster</i> terpisah dengan baik.

Tabel 4.11 menunjukkan evaluasi hasil klasterisasi menggunakan nilai *Davies-Bouldin Index* (DBI) untuk tahun 2020, 2021, dan 2022. Nilai DBI digunakan untuk mengukur kualitas klasterisasi, dengan aturan bahwa semakin kecil nilai DBI, semakin baik kualitas klaster yang dihasilkan.

1. Tahun 2020 (DBI = 0.5827): Hasil klasterisasi pada tahun 2020 menunjukkan kualitas yang cukup baik. Nilai DBI sebesar 0.5827 mengindikasikan bahwa klaster yang dihasilkan terdefinisi dengan baik, dengan jarak antar klaster cukup jelas dan variansi dalam klaster masih dapat diterima.
2. Tahun 2021 (DBI = 0.6639): Pada tahun 2021, kualitas klasterisasi sedikit menurun dibandingkan tahun sebelumnya, dengan nilai DBI sebesar 0.6639. Hal ini menunjukkan adanya sedikit tumpang tindih

antara klaster, sehingga batas antar klaster menjadi kurang tegas. Meskipun demikian, hasil ini masih dapat diterima untuk analisis data penanganan *stunting*.

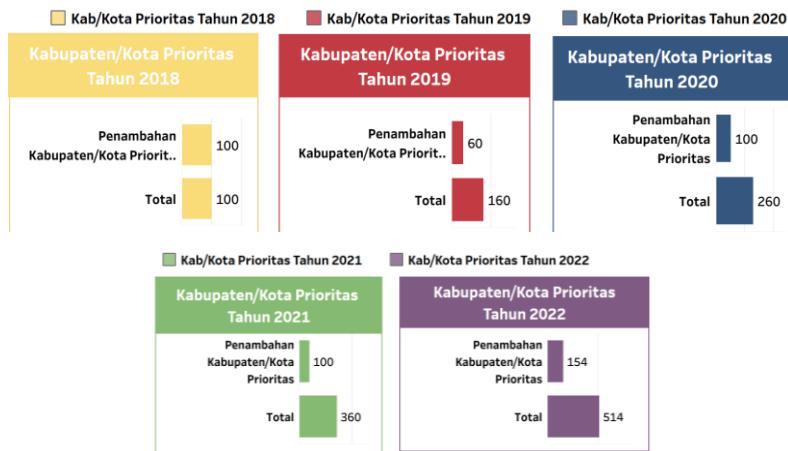
3. Tahun 2022 (DBI = 0.5710): Kualitas klasterisasi pada tahun 2022 kembali meningkat, dengan nilai DBI sebesar 0.5710. Hasil ini menunjukkan bahwa klaster yang dihasilkan lebih terpisah dengan baik, dan jarak antar klaster lebih jelas dibandingkan tahun sebelumnya.

Dari hasil evaluasi tersebut, dapat disimpulkan bahwa algoritma klasterisasi yang digunakan menghasilkan kualitas klaster yang cukup baik secara konsisten selama tiga tahun. Meskipun terdapat sedikit penurunan kualitas pada tahun 2021, hasilnya tetap memberikan pengelompokan wilayah berdasarkan indikator penanganan *stunting*.

#### 4.4.2. Validasi Eksternal

*External Validation* adalah metode evaluasi klasterisasi dengan membandingkan hasil klasterisasi yang dibuat (*output model*) dengan data yang sudah diketahui kebenarannya. Validasi eksternal dilakukan dengan membandingkan hasil klasterisasi yang telah dibuat dengan data pemerintah, yaitu kabupaten/kota prioritas penanganan *stunting*. Proses validasi ini bertujuan untuk memastikan apakah hasil klasterisasi sesuai dengan wilayah-wilayah prioritas yang telah ditetapkan oleh pemerintah seperti terlihat pada Gambar 4.12,

A1	A	B	C	D	E	F	G	H	I
	KD_PROV	KD_KABKOTA	PROVINSI	KABKOTA	kdpov	dkdab	nmprov	nmkab	thn_prior
1									
2	11	1101	ACEH	Simeulue	11	1109	ACEH	Kab. Simeulue	2022
3	11	1102	ACEH	Aceh Singkil	11	1110	ACEH	Kab. Aceh Singkil	2022
4	11	1103	ACEH	Aceh Selatan	11	1101	ACEH	Kab. Aceh Selatan	2022
5	11	1104	ACEH	Aceh Tenggara	11	1102	ACEH	Kab. Aceh Tenggara	2020
6	11	1105	ACEH	Aceh Timur	11	1103	ACEH	Kab. Aceh Timur	2019
7	11	1106	ACEH	Aceh Tengah	11	1104	ACEH	Kab. Aceh Tengah	2018
8	11	1107	ACEH	Aceh Barat	11	1105	ACEH	Kab. Aceh Barat	2022
9	11	1108	ACEH	Aceh Besar	11	1106	ACEH	Kab. Aceh Besar	2021
10	11	1109	ACEH	Pidie	11	1107	ACEH	Kab. Pidie	2018
11	11	1110	ACEH	Bireuen	11	1111	ACEH	Kab. Bireuen	2020
12	11	1111	ACEH	Aceh Utara	11	1108	ACEH	Kab. Aceh Utara	2021
13	11	1112	ACEH	Aceh Barat Daya	11	1112	ACEH	Kab. Aceh Barat Daya	2022
14	11	1113	ACEH	Gayo Lues	11	1113	ACEH	Kab. Gayo Lues	2020
15	11	1114	ACEH	Aceh Tamlang	11	1116	ACEH	Kab. Aceh Tamlang	2021
16	11	1115	ACEH	Nagan Raya	11	1115	ACEH	Kab. Nagan Raya	2020
17	11	1116	ACEH	Aceh Jaya	11	1114	ACEH	Kab. Aceh Jaya	2022
18	11	1117	ACEH	Bener Meriah	11	1117	ACEH	Kab. Bener Meriah	2020
19	11	1118	ACEH	Pidie Jaya	11	1118	ACEH	Kab. Pidie Jaya	2022
20	11	1171	ACEH	Kota Banda Aceh	11	1171	ACEH	Kota Banda Aceh	2022
21	11	1172	ACEH	Kota Sabang	11	1172	ACEH	Kota Sabang	2022
22	11	1173	ACEH	Kota Langsa	11	1174	ACEH	Kota Langsa	2022
23	11	1174	ACEH	Kota Lhokseumawe	11	1173	ACEH	Kota Lhokseumawe	2022
24	11	1175	ACEH	Kota Subulussalam	11	1175	ACEH	Kota Subulussalam	2020
25	12	1201	SUMATERA UTARA	Nias	12	1204	SUMATERA UTARA	Kab. Nias	2020
26	12	1202	SUMATERA UTARA	Mandailing Natal	12	1213	SUMATERA UTARA	Kab. Mandailing Natal	2020
27	12	1203	SUMATERA UTARA	Tapanuli Selatan	12	1203	SUMATERA UTARA	Kab. Tapanuli Selatan	2022
28	12	1204	SUMATERA UTARA	Tapanuli Tengah	12	1201	SUMATERA UTARA	Kab. Tapanuli Tengah	2020
29	12	1205	SUMATERA UTARA	Tapanuli Utara	12	1202	SUMATERA UTARA	Kab. Tapanuli Utara	2021

**Gambar 4.12.** Kabupaten/Kota Prioritas Pemerintah

(Sumber: dasbor.stunting.go.id)

**Tabel 4.12.** Validasi Wilayah Prioritas Sistem Tahun 2020

No	Provinsi	Kab/Kota	Prevalensi	IKPS	Klaster	Label Klaster	Hasil Validasi Sistem dengan Wilayah Prioritas Pemerintah
1	Nusa Tenggara Timur	Timor Tengah Selatan	48.5	57.4	2	Prevalensi Buruk, IKPS Rendah	Sesuai
2	Kalimantan Utara	Nunukan	43.9	66.5	2	Prevalensi Buruk, IKPS Rendah	Sesuai
3	Nusa Tenggara Timur	Timor Tengah Utara	42.5	62.9	2	Prevalensi Buruk, IKPS Rendah	Sesuai
4	Nusa Tenggara Timur	Sabu Raijua	41.1	72.6	2	Prevalensi Buruk, IKPS Rendah	Sesuai
5	Sulawesi Barat	Majene	40.1	76.0	2	Prevalensi Buruk, IKPS Rendah	Sesuai
6	Nusa Tenggara Timur	Sumba Barat Daya	38.3	54.0	2	Prevalensi Buruk, IKPS Rendah	Sesuai
7	Kalimantan Barat	Kapuas Hulu	33.1	57.7	2	Prevalensi Buruk, IKPS Rendah	Sesuai
8	Kepulauan Bangka Belitung	Bangka Selatan	32.7	55.9	2	Prevalensi Buruk, IKPS Rendah	Sesuai
9	Kalimantan Barat	Sintang	31.4	54.8	2	Prevalensi Buruk, IKPS Rendah	Sesuai
10	Aceh	Aceh Timur	29.7	54.1	2	Prevalensi Buruk, IKPS Rendah	Sesuai

**Tabel 4.13.** Validasi Wilayah Prioritas Sistem Tahun 2021

No	Provinsi	Kab/Kota	Prevalensi	IKPS	Klaster	Label Klaster	Hasil Validasi Sistem dengan Wilayah Prioritas Pemerintah
1	Kalimantan Utara	Nunukan	43.9	67.5	2	Prevalensi Buruk, IKPS Stabil	Sesuai
2	Nusa	Timor	40.6	59.2	2	Prevalensi Buruk,	Sesuai

	Tenggara Timur	Tengah Selatan				IKPS Stabil	
3	Sulawesi Barat	Majene	34.3	77.3	2	Prevalensi Buruk, IKPS Stabil	Sesuai
4	Kalimantan Barat	Kapuas Hulu	33.0	64.3	2	Prevalensi Buruk, IKPS Stabil	Sesuai
5	Nusa Tenggara Timur	Sumba Barat	32.2	71.7	2	Prevalensi Buruk, IKPS Stabil	Sesuai
6	Nusa Tenggara Timur	Sabu Raijua	31.4	68.8	2	Prevalensi Buruk, IKPS Stabil	Sesuai
7	Kalimantan Barat	Sintang	31.1	57.2	2	Prevalensi Buruk, IKPS Stabil	Sesuai
8	Nusa Tenggara Timur	Timor Tengah Utara	28.9	70.6	2	Prevalensi Buruk, IKPS Stabil	Sesuai
9	Kalimantan Utara	Bulungan	28.7	65.8	2	Prevalensi Buruk, IKPS Stabil	Sesuai
10	Sulawesi Tenggara	Buton Selatan	28.7	73.9	2	Prevalensi Buruk, IKPS Stabil	Sesuai

**Tabel 4.14.** Validasi Wilayah Prioritas Sistem Tahun 2022

No	Provinsi	Kab/Kota	Prevalensi	IKPS	Klaster	Label Klaster	Hasil Validasi Sistem dengan Wilayah Prioritas Pemerintah
1	Nusa Tenggara Timur	Sumba Barat Daya	44.3	62.0	2	Prevalensi Buruk, IKPS Stabil	Sesuai
2	Nusa Tenggara Barat	Lombok Utara	33.9	79.6	2	Prevalensi Buruk, IKPS Stabil	Sesuai
3	Sulawesi Barat	Majene	32.2	74.4	2	Prevalensi Buruk, IKPS Stabil	Sesuai
4	Nusa Tenggara Timur	Timor Tengah Selatan	32.0	60.1	2	Prevalensi Buruk, IKPS Stabil	Sesuai
5	Kalimantan Barat	Kapuas Hulu	31.2	56.9	2	Prevalensi Buruk, IKPS Stabil	Sesuai
6	Nusa Tenggara Timur	Timor Tengah Utara	31.2	71.8	2	Prevalensi Buruk, IKPS Stabil	Sesuai
7	Kalimantan Barat	Melawi	30.2	58.2	2	Prevalensi Buruk, IKPS Stabil	Sesuai
8	Maluku	Kota Ambon	29.7	56.5	2	Prevalensi Buruk, IKPS Stabil	Sesuai
9	Kalimantan Barat	Sintang	28.6	59.0	2	Prevalensi Buruk, IKPS Stabil	Sesuai
10	Kalimantan Barat	Bengkayang	27.9	64.8	2	Prevalensi Buruk, IKPS Stabil	Sesuai

Berdasarkan tabel validasi wilayah prioritas di atas, hasil klasterisasi menunjukkan bahwa wilayah prioritas 10 teratas untuk setiap tahun dapat diidentifikasi berdasarkan klaster yang memiliki prevalensi buruk dengan nilai IKPS rendah atau stabil. Pada tahun 2020, seluruh wilayah prioritas 10 teratas termasuk dalam Klaster 2, yang ditandai dengan prevalensi *stunting* yang buruk dan nilai IKPS yang rendah. Hal ini menunjukkan bahwa wilayah-wilayah tersebut menghadapi tantangan serius dalam mengatasi *stunting*, baik dari segi kondisi kesehatan, gizi, maupun layanan intervensi lainnya.

Pada tahun 2021, wilayah prioritas 10 teratas masih berada dalam Klaster 2, meskipun nilai IKPS menunjukkan stabilitas dibandingkan dengan tahun sebelumnya. Kondisi ini mengindikasikan adanya sedikit perbaikan dalam dimensi-dimensi yang diukur oleh IKPS, tetapi prevalensi *stunting* tetap berada pada tingkat yang buruk, sehingga wilayah ini tetap menjadi fokus prioritas pemerintah. Demikian pula, pada tahun 2022, wilayah prioritas 10 teratas kembali dikelompokkan dalam Klaster 2, dengan karakteristik prevalensi buruk dan IKPS yang stabil. Meskipun tidak ada penurunan signifikan dalam prevalensi *stunting*, stabilitas nilai IKPS dapat mencerminkan upaya pemerintah yang mulai menunjukkan dampaknya, namun masih perlu peningkatan yang lebih signifikan.

Analisis ini menunjukkan bahwa wilayah prioritas tahun 2020 hingga 2022 tetap konsisten berada dalam klaster yang menunjukkan kondisi buruk. Hal ini menegaskan perlunya intervensi yang lebih efektif dan berkelanjutan di wilayah-wilayah tersebut untuk mengatasi masalah *stunting*.

## BAB 5

### KESIMPULAN DAN SARAN

#### 5.1. Kesimpulan

Berdasarkan hasil penelitian, kesimpulan yang dapat diambil dalam penelitian ini adalah sebagai berikut,

1. Hasil klasterisasi menunjukkan bahwa setiap tahun terbentuk 3 klaster dengan karakteristik yang berbeda. Tahun 2020, Klaster 1 berjumlah 5 Kab/kota (Prevalensi Baik, IKPS Optimal), Klaster 0 berjumlah 73 Kab/kota (Prevalensi Menengah, IKPS Stabil) dan Klaster 2 berjumlah 112 Kab/kota (Prevalensi Buruk, IKPS Rendah). Tahun 2021, Klaster 1 ada 61 Kab/kota (Prevalensi Menengah, IKPS Optimal), Klaster 2 ada 246 Kab/kota (Prevalensi Buruk, IKPS Stabil), Klaster 0 ada 8 Kab/kota (Prevalensi Baik, IKPS Rendah). Tahun 2022, Klaster 0 berjumlah 198 Kab/kota (Prevalensi Menengah, IKPS Optimal), Klaster 2 berjumlah 264 Kab/kota (Prevalensi Buruk, IKPS Stabil), Klaster 1 berjumlah 7 Kab/kota (Prevalensi Baik, IKPS Rendah).
2. Evaluasi klaster menggunakan *Davies-Bouldin Index* (DBI) menunjukkan bahwa kualitas klasterisasi cukup baik dengan nilai DBI sebesar 0.5827 pada tahun 2020, 0.6639 pada tahun 2021, dan 0.5710 pada tahun 2022. Hasil pengujian eksternal tahun prioritas mendominasi oleh klaster 2 untuk setiap tahunnya dan sesuai secara keseluruhan.
3. Dasbor interaktif yang dikembangkan dalam penelitian ini menvisualisasikan hasil klasterisasi, mencakup pemetaan wilayah, perbandingan prevalensi dan IKPS, serta perangkingan wilayah prioritas. Visualisasi ini diharapkan dapat memberikan gambaran yang jelas mengenai wilayah dengan prevalensi *stunting* serta indikator yang perlu ditingkatkan.

## 5.2. Saran

Saran dari penulis untuk penelitian berikutnya yaitu menampilkan seluruh hasil uji coba parameter HDBSCAN, agar dapat terlihat hasil klaster dari parameter yang terbaik. Kemudian memperbanyak jumlah data kabupaten/kota untuk meningkatkan akurasi hasil klasterisasi, sehingga kualitas pengelompokan wilayah dapat lebih optimal. Selain itu, direkomendasikan untuk menggunakan data kabupaten/kota yang mencakup seluruh wilayah di Indonesia secara lengkap dan seimbang setiap tahunnya. Hal ini bertujuan agar visualisasi pada dasbor dapat lebih interaktif, memberikan gambaran yang lebih representatif mengenai kondisi prevalensi *stunting* di setiap daerah.



## DAFTAR PUSTAKA

- Anggraeni, M. R., Yudatama, U., & Maimunah, M. (2023). Clustering Prevalensi Stunting Balita Menggunakan Agglomerative Hierarchical Clustering. *Jurnal Media Informatika Budidarma*, 7(1), 351. <https://doi.org/10.30865/mib.v7i1.5501>
- Badan Pusat Statistik (BPS). (2023). Indeks Khusus Penanganan *Stunting* 2021-2022. *Badan Pusat Statistik*. <https://www.bps.go.id>.
- Badan Pusat Statistik (BPS). (2022). Prevalensi *Stunting* pada Balita di Indonesia 2021. *Badan Pusat Statistik*. <https://www.bps.go.id>.
- Ditjen Bina Pembangunan Daerah, Kementerian Dalam Negeri. (2024). Monitoring Pelaksanaan 8 Aksi Konvergensi Intervensi Penurunan Stunting Terintegrasi. <https://aksi.bangda.kemendagri.go.id/emonev/DashPrev>.
- Fadilah, A., Pangestu, M. N., Lumbanbatu, S., & Defiyanti, S. (2022). Pengelompokan Kabupaten/Kota Di Indonesia Berdasarkan Faktor Penyebab Stunting Pada Balita Menggunakan Algoritma K-Means. *JIKO (Jurnal Informatika Dan Komputer)*, 6(2), 223. <https://doi.org/10.26798/jiko.v6i2.581>
- Faujia, R. A., Setianingsih, E. S., & Pratiwi, H. (2022). Analisis Klaster K-Means Dan Agglomerative Nesting Pada Indikator Stunting Balita Di Indonesia. *Seminar Nasional Official Statistics*, 2022(1), 1249–1258. <https://doi.org/10.34123/semnasoffstat.v2022i1.1511>
- Gare, S., Chel, S., Pantula, P. D., Saxena, A., Mitra, K., Sarkar, R., & Giri, L. (2022). Analytics pipeline for visualization of single cell RNA sequencing data from bronchoalveolar fluid in COVID-19 patients: Assessment of Neuro Fuzzy-C-Means and HDBSCAN. *Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC)*, 2022, 9871686. <https://doi.org/10.1109/EMBC48229.2022.9871686>
- Global Nutrition Report. (2022). *Global Nutrition Report: Action on equity to end malnutrition*. Diakses dari [<https://globalnutritionreport.org>]
- Handayani, F. D., & Rosyida, I. (2023). *Clustering Review Pengguna Aplikasi Zenius pada Layanan Google Play Store Menggunakan Metode DBSCAN*

- dan HDBSCAN. Program Studi Matematika, Universitas Negeri Semarang.
- HDBSCAN Documentation. (n.d.). HDBSCAN. Retrieved January 17, 2025, from <https://hdbSCAN.readthedocs.io/en/latest/index.html>.
- Ghamarian, I., & Marquis, E. A. (2019). Hierarchical density-based cluster analysis framework for atom probe tomography data. *Materials Characterization*, 149, 310-319. <https://doi.org/10.1016/j.matchar.2019.01.022>
- Jannah, P. D. N., & Pramoedyo, H. (2024). Penerapan Density-Based Spatial Clustering of Application with Noise (DBSCAN) untuk mengelompokkan kecamatan di Kabupaten Blitar berdasarkan prevalensi stunting pada anak [Skripsi, Universitas Brawijaya]. *Universitas Brawijaya Repository*.
- Kementerian & Lembaga. (2023). Indeks Khusus Penanganan Stunting (IKPS). Pusat Pembelajaran. <https://Stunting.go.id/buku-indeks-khusus-penanganan-Stunting-IKPS/>.
- Rianti, R., Andarsyah, R., & Awangga, R. M. (2024). Penerapan PCA dan Algoritma Clustering untuk Analisis Mutu Perguruan Tinggi di LLDIKTI Wilayah IV. *Nuansa Informatika*, 18(2), 67–77. <https://doi.org/10.25134/ilkom.v18i2.211>
- Santos, J. A. dos, Syed, T. I., Naldi, M. C., Campello, R. J. G. B., & Sander, J. (2019). Hierarchical Density-Based Clustering Using MapReduce. *IEEE Transactions on Big Data*, 7(1), 102–114. <https://doi.org/10.1109/tbdta.2019.2907624>
- Tan, P.N., Steinbach, M., & Kumar, V. (2020). *Introduction to Data Mining (2nd ed.)*. Pearson Education.
- Wahyuni, N. A., Hayati, M. N., & Rizki, A. (2021). Metode Hierarchical Density-Based Spatial Clustering of Application with Noise ( HDBSCAN ) Pada Wilayah Desa / Kelurahan Tertinggal di Kabupaten Kutai Kartanegara ( Studi Kasus : Data Hasil Pendataan Potensi Desa ( PODES ) Tahun 2018 ) Hierarchical Densit. *Eksponensial*, 12(1), 47–52. <http://jurnal.fmipa.unmul.ac.id/index.php/exponensial/article/view/758>
- World Health Organization (WHO). (2022). *Levels and trends in child malnutrition*. Geneva: WHO. Diakses dari [<https://www.who.int>]

Yulia, N., Saragih, R., & Ambarita, I. (2021). Data Mining Pengelompokan Anak Stunting Berdasarkan Usia , Penyebab dan Pekerjaan Orang Tua Dengan Menggunakan Metode Clustering ( Studi Kasus : Dinas Kesehatan Kabupaten Langkat ). *Seminar Nasional Informatika (SENATIKA)Prosiding SENATIKA 2021*, 295–306.

Yusuf, A. (2022). K-Means clustering based on distance measures: Stunting prevalence clustering in South Kalimantan. *2022 5th International Seminar on Research of Information Technology and Intelligent Systems (ISRITI)*, 706–710. <https://doi.org/10.1109/ISRITI56927.2022.10052925>

Zarlis, M., Oktavia, T., Buaton, R., Ernawan, F., & Andrian, K. (2023). Minimizing the number of stunting prevalence using the Euclid algorithm clustering approach. *2023 International Conference of Computer Science and Information Technology (ICOSNIKOM)*, 1–7. <https://doi.org/10.1109/ICoSNIKOM60230.2023.10364489>