KLASIFIKASI BENCANA KEKERINGAN DI JAWA TIMUR MENGGUNAKAN CITRA SATELIT LANDSAT 8 DENGAN METODE *XGBOOST*

SKRIPSI

KEVIN TULUS RICARDO SILITONGA

201402051

PROGRAM STUDI S1 TEKNOLOGI INFORMASI

FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI

UNIVERSITAS SUMATERA UTARA

MEDAN

2025

KLASIFIKASI BENCANA KEKERINGAN DI JAWA TIMUR MENGGUNAKAN CITRA SATELIT LANDSAT 8 DENGAN METODE *XGBOOST*

SKRIPSI

Diajukan untuk melengkapi tugas dan memenuhi syarat memperoleh ijazah
Sarjana Teknologi Informasi

KEVIN TULUS RICARDO SILITONGA
201402051

PROGRAM STUDI S1 TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA
MEDAN
2025

PERSETUJUAN

Judul	: KLASIFIKASI BENCANA KEKERINGAN DI JAWA TIMUR MENGGUNAKAN CITRA SATELIT LANDSAT 8 DENGAN METODE *XGBOOST*
Kategori	: SKRIPSI
Nama Mahasiswa	: KEVIN TULUS RICARDO SILITONGA
Nomor Induk Mahasiswa	: 201402051
Program Studi	: SARJANA (S-1) TEKNOLOGI INFORMASI
Fakultas	: ILMU KOMPUTER DAN TEKNOLOGI INFORMASI UNIVERSITAS SUMATERA UTARA

Medan, 10 Januari 2025

Komisi Pembimbing :

Pembimbing 2,	Pembimbing 1,
Ivan Jaya S.Si., M.Kom.	Sarah Purnamawati, S.T., M.Sc.
NIP. 198407072015041001	NIP. 198302262010122003

Diketahui/disetujui oleh

Program Studi S1 Teknologi Informasi

Ketua,

Dedy Arisandi, S.T., M.Kom.

NIP. 197908312009121001

PERNYATAAN

KLASIFIKASI BENCANA KEKERINGAN DI JAWA TIMUR MENGGUNAKAN CITRA SATELIT LANDSAT 8 DENGAN METODE *XGBOOST*

SKRIPSI

Saya mengakui bahwa skripsi ini merupakan hasil karya saya sendiri, kecuali beberapa kutipan dan ringkasan yang masing-masing telah disebutkan sumbernya.

Medan, 10 Januari 2025

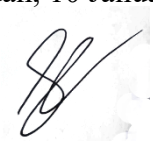

Kevin Tulus Ricardo Silitonga
201402051

UCAPAN TERIMA KASIH

Segala puji dan syukur penulis panjatkan kepada Tuhan Yang Maha Esa atas limpahan rahmat dan karunia-Nya, yang telah menuntun penulis dalam menyelesaikan skripsi berjudul "Klasifikasi Bencana Kekeringan di Jawa Timur Menggunakan Citra Satelit Landsat 8 dengan Metode *XGBoost*." Skripsi ini disusun sebagai salah satu syarat untuk meraih gelar Sarjana Komputer di Program Studi Teknologi Informasi, Universitas Sumatera Utara. Penulis mengucapkan terima kasih yang mendalam kepada semua pihak yang telah memberikan dukungan, bantuan, dan motivasi selama proses penyusunan skripsi ini. Ucapan terima kasih khusus penulis sampaikan kepada dosen pembimbing atas arahan, nasihat, dan waktu berharga yang telah diberikan. Rasa syukur juga penulis tunjukan kepada orang tua dan keluarga tercinta atas doa, kasih sayang, serta semangat. Selain itu, terima kasih kepada teman-teman yang telah memberikan dukungan moral dan inspirasi. Semoga skripsi ini dapat bermanfaat bagi berbagai pihak.

1. Tuhan Yesus Kristus yang senantiasa memberikan kekuatan dan kelancaran kepada penulis selama proses penyusunan hingga tahap akhir penulisan.
2. Keluarga penulis yang tak henti-hentinya memberikan doa, dukungan, dan motivasi sehingga penulis dapat menyelesaikan skripsi ini dengan baik.
3. Ibu Dr. Maya Silvi Lydia, M.Sc selaku Dekan Fasilkom-TI USU.
4. Bapak Dedy Arisandi ST., M.Kom., selaku Ketua Program Studi S1 Teknologi Informasi Universitas Sumatera Utara.
5. Ibu Sarah Purnamawati, S.T., M.Sc., selaku Dosen Pembimbing I dan Bapak Ivan Jaya S.Si., M.Kom., selaku Dosen Pembimbing II yang telah meluangkan waktunya untuk memberikan bimbingan dan dukungan, serta kritik dan saran yang membangun, yang telah membantu penulis dalam menyelesaikan skripsi.
6. Dosen Pengajar di Program Studi S1 Teknologi Informasi Universitas Sumatera Utara.
7. Seluruh staf dan pegawai di Program Studi S1 Teknologi Informasi Universitas Sumatera Utara.
8. Teman-teman angkatan 2020 Teknologi Informasi, Universitas Sumatera Utara, yang tidak dapat penulis ungkapkan satu-satu. Terima kasih telah saling memberi dukungan dan semangat.

9. Teman-teman yang telah bersama sejak awal perkuliahan, yaitu Kelvin Lumbanraja, Stephani Silitonga, Pretty Hutasoit, dan Frans Marbun, yang telah berbagi pengalaman suka dan duka selama masa perkuliahan dan kegiatan kepanitiaan.
10. Teman-teman seperjuangan sekaligus pendukung terbaik dalam penyelesaian skripsi penulis Yeftha El Imani Pardede, Syavira Khairani, Monica Juliana, Retno Wulan Sari, Felix Christian Oshwalt Rumahorbo, dan Vicky Natanael Sinaga.
11. Kakak/Abang Senior di Program Studi S1 Teknologi Informasi yang telah berbagi ilmu dan pengalaman dalam menjalani masa perkuliahan.
12. Semua pihak yang tidak dapat disebutkan satu per satu atas segala bantuan, perhatian, dan doa yang diberikan kepada penulis selama proses penyelesaian skripsi ini. Penulis mengucapkan terima kasih yang sebesar-besarnya.

Medan, 24 Desember 2024

Penulis,

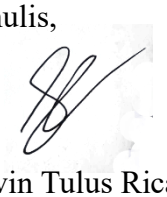

Kevin Tulus Ricardo Silitonga

201402051

ABSTRAK

Bencana kekeringan menyebabkan dampak yang besar seperti berkurangnya air bersih, merusak tanaman pangan dan hancurnya ekosistem lingkungan yang terjadi di area yang sangat luas dalam waktu yang sangat lama. Dalam pemantauan kekeringan saat ini, dibutuhkan waktu yang cukup lama. Biasanya waktu yang digunakan dalam monitoring dilakukan dalam kurun waktu sebulan. Dari permasalahan yang ada, kebutuhan informasi kekeringan kepada masyarakat dan pihak berwenang diperlukan guna mengurangi kerugian dengan mengantisipasi kekeringan dan memitigasi dampak sosial, ekonomi, dan lingkungan yang diakibatkan oleh bencana kekeringan. Sehingga dibutuhkan suatu sistem yang dapat mengklasifikasikan bencana kekeringan dengan cepat dan akurat. Penelitian ini menggunakan algoritma *XGBoost*, yang memiliki kemampuan untuk menangani variabilitas spektral dalam data citra satelit. Data yang digunakan meliputi citra satelit Landsat 8 dengan Band 4, Band 5, dan Band 10 untuk perhitungan indeks vegetasi, serta data SPI dan DEM. Dataset terdiri dari 168 citra raster dari tahun 2014 hingga 2022, yang kemudian dibagi menjadi 80% untuk data pelatihan (*training*) dan 20% untuk data pengujian (*testing*). Model *XGBoost* dilatih dan dievaluasi menggunakan data tersebut untuk mengklasifikasikan citra ke dalam lima kategori tingkat kekeringan: kekeringan ekstrem, kekeringan parah, kekeringan sedang, kekeringan ringan, dan tidak kekeringan Hasil penelitian menunjukkan bahwa model *XGBoost* mencapai akurasi keseluruhan sebesar 89,40%. Nilai *precision*, *recall*, dan *F1 score* yang tinggi untuk setiap kelas mengindikasikan kemampuan model dalam mengidentifikasi berbagai tingkat keparahan kekeringan dengan baik.

Kata kunci: Bencana Kekeringan, Citra Satelit, Landsat 8, *XGBoost*, Pemantauan Lingkungan, Indeks Vegetasi

CLASSIFICATION OF DROUGHT DISASTER IN EAST JAVA USING LANDSAT 8 SATELLITE IMAGERY WITH THE XGBOOST METHOD

ABSTRACT

Drought disasters cause major impacts such as reduced clean water, damage to food crops and the destruction of environmental ecosystems that occur in very large areas for a very long time. In monitoring droughts today, it takes quite a long time. Usually the time used in monitoring is carried out within a month. From the existing problems, the need for drought information to the community and authorities is needed to reduce losses by anticipating drought and mitigating the social, economic and environmental impacts caused by drought disasters. So a system is needed that can classify drought disasters quickly and accurately. This study uses the XGBoost algorithm, which has the ability to handle spectral variability in satellite imagery data. The data used includes Landsat 8 satellite imagery with Band 4, Band 5, and Band 10 for calculating the vegetation index, as well as SPI and DEM data. The dataset consists of 168 raster images from 2014 to 2022, which are then divided into 80% for training data and 20% for testing data. The XGBoost model was trained and evaluated using the data to classify images into five categories of drought severity: extreme drought, severe drought, moderate drought, mild drought, and no drought. The results showed that the XGBoost model achieved an overall accuracy of 89.40%. The high precision, recall, and F1 score values for each class indicate the model's ability to identify various levels of drought severity well.

Keywords: *Drought Disaster, Satellite Imagery, Landsat 8, XGBoost, Environmental Monitoring, Vegetation Index*

DAFTAR ISI

PERSETUJUAN **iii**
PERNYATAAN **iv**
UCAPAN TERIMA KASIH **v**
ABSTRAK **vii**
ABSTRACT **viii**
DAFTAR ISI **ix**
DAFTAR TABEL **xii**
DAFTAR GAMBAR **xiii**
DAFTAR PSEUDOCODE **xv**
BAB 1 PENDAHULUAN **1**
1.1. Latar Belakang **1**
1.2. Rumusan Masalah **3**
1.3. Tujuan Penelitian **4**
1.4. Batasan Masalah **4**
1.5. Manfaat Penelitian **4**
1.6. Metodologi Penelitian **4**
1.7. Sistematika Penulisan **5**
BAB 2 LANDASAN TEORI **7**
2.1. Bencana Kekeringan **7**
2.2. Citra Satelit Landsat 8 **8**
2.3. Algoritma *XGBoost* **11**
2.4. Land Surface Temperatures (LST) dan LST Normalization **13**
2.5. Indeks Vegetasi **14**
2.5.1. Normalized Difference Vegetation Index (NDVI) 14
2.5.2. Soil-Adjusted Vegetation Index (SAVI) 15
2.5.3. Vegetation Condition Index (VCI) 15
2.5.4. Temperature Condition Index (TCI) 16
2.5.5. Vegetation Health Index (VHI) 16
2.6. Standardized Precipitation Index (SPI) **17**
2.7. Digital Elevation Model (DEM) **18**

2.8. Confusion Matrix **19**
2.9. Website **20**
2.10. HTML (HyperText Markup Language) **20**
2.11. Bootstrap **20**
2.12. JavaScript **21**
2.13. Python **21**
2.14. Flask **22**
2.15. Penelitian Terdahulu **23**
2.16. Perbedaan Penelitian **26**
BAB 3 ANALISIS DAN PERANCANGAN SISTEM **28**
3.1. Dataset **28**
3.2. Arsitektur Umum **29**
3.2.1. Pengambilan data citra satelit 31
3.2.2. Pre-Processing citra satelit 32
3.2.3. Perhitungan indeks 36
3.2.4. Data SPI 44
3.2.5. Data DEM 45
3.2.6. Data PDSI 45
3.2.7. XGBoost Algorithm 47
3.2.8. Learned Model 48
3.2.9. Klasifikasi bencana kekeringan 52
3.2.10. Evaluasi 53
3.3. Perancangan Sistem **53**
3.3.1. Desain tampilan halaman depan 54
3.3.2. Desain tampilan testing data 54
3.3.3. Desain tampilan halaman klasifikasi citra 57
BAB 4 IMPLEMENTASI DAN PENGUJIAN SISTEM **61**
4.1. Implementasi Sistem **61**
4.1.1. Spesifikasi perangkat keras dan perangkat lunak 61
4.1.2. Implementasi perancangan antarmuka 61
4.2. Implementasi Model **69**
4.2.1. Hasil pelatihan model 69
4.2.2. Hasil pengujian model 74

4.3. Analisis Hasil **80**
4.3.1. Analisis hasil tidak kekeringan 81
4.3.2. Analisis hasil kekeringan ringan 82
4.3.3. Analisis hasil kekeringan sedang 83
4.3.4. Analisis hasil kekeringan parah 83
4.3.5. Analisis hasil kekeringan ekstrem 84
BAB 5 KESIMPULAN DAN SARAN **86**
5.1. Kesimpulan **86**
5.2. Saran **87**
DAFTAR PUSTAKA **88**

DAFTAR TABEL

Tabel 2. 1 Klasifikasi PDSI 8
Tabel 2. 2 Klasifikasi PDSI yang Digunakan 8
Tabel 2. 3 *Spectral Bands* Landsat 8 10
Tabel 2. 4 Klasifikasi SPI 18
Tabel 2. 5 Penelitian Terdahulu 24
Tabel 3. 1 Dataset Citra Landsat 8 31
Tabel 3. 2 Dataset Citra Landsat 8 (Lanjutan) 32
Tabel 3. 3 Band Landsat 8 Dan Perhitungan Indeks 36
Tabel 3. 4 Band Landsat 8 Dan Perhitungan Indeks (Lanjutan) 37
Tabel 4. 1 Daftar Parameter 69
Tabel 4. 2 Hasil *Bayesian Optimization* 70
Tabel 4. 3 Hasil *Bayesian Optimization* (Lanjutan) 71
Tabel 4. 4 Nilai TP, TN, FP, dan FN 73
Tabel 4. 5 Hasil prediksi benar dan salah 78

DAFTAR GAMBAR

Gambar 2. 1 Satelit Landsat 8 (USGS) 9
Gambar 2. 2 Contoh Citra Satelit 11
Gambar 2. 3 Ilustrasi Model *XGBoost* (Yao et al., 2022) 11
Gambar 2. 4 Gambar DEM Daerah Gunung Bromo 19
Gambar 3. 1 Citra Raster Daerah Penelitian 28
Gambar 3. 2 Arsitektur Umum 30
Gambar 3. 3 Hasil Pre-Processing 36
Gambar 3. 4 Hasil Perhitungan Indeks 44
Gambar 3. 5 Gambar SPI 45
Gambar 3. 6 Gambar DEM 45
Gambar 3. 7 Gambar PDSI 47
Gambar 3. 8 Halaman Depan 54
Gambar 3. 9 Halaman Testing 55
Gambar 3. 10 Halaman Testing (Lanjutan) 55
Gambar 3. 11 Halaman Testing (Lanjutan) 56
Gambar 3. 12 Halaman Klasifikasi Citra 58
Gambar 3. 13 Halaman Klasifikasi Citra (Lanjutan) 58
Gambar 3. 14 Halaman Klasifikasi Citra (Lanjutan) 59
Gambar 4. 1 Tampilan Halaman Depan 62
Gambar 4. 2 Tampilan Halaman Klasifikasi Citra 62
Gambar 4. 3 Tampilan Hasil Prediksi Klasifikasi Citra 63
Gambar 4. 4 Tampilan Hasil Prediksi Klasifikasi Citra (Lanjutan) 64
Gambar 4. 5 Tampilan Hasil Prediksi Klasifikasi Citra (Lanjutan) 65
Gambar 4. 6 Tampilan Halaman Testing 65
Gambar 4. 7 Tampilan Hasil Testing 66
Gambar 4. 8 Tampilan Hasil Testing (Lanjutan) 67
Gambar 4. 9 Tampilan Hasil Testing (Lanjutan) 68
Gambar 4. 10 Tampilan Hasil Testing (Lanjutan) 68
Gambar 4. 11 *Confusion Matrix* 72
Gambar 4. 12 Hasil Preprocessing 76

Gambar 4. 13 Gambar Hasil Klasifikasi 76
Gambar 4. 14 Gambar Perbandingan 80
Gambar 4. 15 Hasil Peta Bencana Kekeringan Tidak Kekeringan 81
Gambar 4. 16 Hasil Peta Bencana Kekeringan Ringan 82
Gambar 4. 17 Hasil Peta Bencana Kekeringan Sedang 83
Gambar 4. 18 Hasil Peta Bencana Kekeringan Parah 84
Gambar 4. 19 Hasil Peta Bencana Kekeringan Ekstrem 85

DAFTAR PSEUDOCODE

Pseudocode 3. 1 *Cropping Raster* 33
Pseudocode 3. 2 Ganti Nilai *Nodata* 34
Pseudocode 3. 3 *Resampling Raster* 35
Pseudocode 3. 4 Indeks *(NDVI, LST, SAVI, VCI, TCI, VHI*, dan LST *Normalization)* 43
Pseudocode 3. 5 Klasifikasi PDSI 47
Pseudocode 3. 6 *Learned Model* 51
Pseudocode 3. 7 Klasifikasi Bencana Kekeringan 53

BAB 1

PENDAHULUAN

1.1. Latar Belakang

Definisi kekeringan secara luas adalah kurangnya curah hujan dalam jangka waktu yang lama, biasanya satu musim atau lebih, yang mengakibatkan kekurangan air untuk beberapa aktivitas, kelompok, atau sektor lingkungan (UNISDR, 2009). Bencana kekeringan dapat terjadi dikarenakan curah hujan yang sangat rendah, periode panjang tanpa hujan, atau kombinasi faktor-faktor seperti tingkat penguapan yang tinggi dan kondisi tanah yang kering. Kekeringan dapat mengakibatkan penurunan drastis dalam ketersediaan air, baik untuk konsumsi manusia, pertanian, industri, maupun keperluan ekologi. Oleh karena itu, identifikasi daerah rentan terhadap kekeringan penting dan menjelaskan mengapa penelitian di Jawa Timur sangat relevan.

Jawa Timur dipilih sebagai lokasi penelitian karena wilayah ini memiliki kerentanan yang tinggi terhadap bencana kekeringan. Berdasarkan data dari Badan Meteorologi, Klimatologi, dan Geofisika (BMKG), Jawa Timur sering mengalami musim kemarau yang panjang dengan curah hujan yang sangat rendah. Kondisi geografis dan iklim di Jawa Timur menjadikannya salah satu daerah yang paling terdampak oleh perubahan iklim, yang menyebabkan fluktuasi signifikan dalam ketersediaan air. Selain itu, sektor pertanian yang menjadi tulang punggung ekonomi di wilayah ini sangat bergantung pada ketersediaan air, sehingga kekeringan memiliki dampak yang sangat merugikan bagi perekonomian dan kesejahteraan masyarakat setempat. Oleh karena itu, penelitian mengenai klasifikasi kekeringan di Jawa Timur menggunakan citra satelit Landsat 8 dan metode *XGBoost* diharapkan dapat memberikan kontribusi signifikan dalam upaya mitigasi dan adaptasi terhadap bencana kekeringan di daerah ini.

Citra satelit merupakan salah satu teknologi paling penting dalam pemantauan dan pemetaan bumi dari jarak jauh. Citra satelit adalah gambar atau rekaman visual dari permukaan Bumi yang diambil oleh satelit buatan manusia yang mengorbit bumi. Citra citra ini dihasilkan oleh sensor optik yang terpasang pada satelit, yang mampu

mendeteksi cahaya yang dipantulkan atau dipancarkan oleh permukaan bumi dalam berbagai panjang gelombang, mulai dari sinar tampak hingga inframerah. Citra-citra satelit bisa digunakan untuk berbagai tujuan, mulai dari pemetaan dan pemantauan lingkungan, analisis perubahan lahan, pemantauan cuaca, hingga keperluan militer dan komersial (Marlina, 2022). Salah satu contoh penggunaan teknologi ini adalah dalam penelitian terkait prediksi kekeringan.

Penelitian sebelumnya yang berjudul Analisis Data Citra Landsat 8 OLI Sebagai Indeks Prediksi Kekeringan Menggunakan *Machine Learning* di Wilayah Kabupaten Boyolali dan Purworejo (Prasetyo et al., 2019). Dengan menggunakan dataset Landsat 8 yang dimasukan ke dalam *Machine Learning* yang menggunakan metode *XGBoost* dan *Random Forest*. Hasil penelitian menunjukkan nilai akurasi 0.8286 dan Nilai Kappa 0.6477 dari metode *XGBoost* dan nilai akurasi 0.6857 dan Nilai Kappa 0.3699 dari metode *Random Forest*.

Penelitian lainnya dengan judul Identifikasi Kekeringan Lahan Kabupaten Lamongan Berdasarkan Citra Satelit (Noraini et al., 2022). Penelitian ini menggunakan dataset Landsat 8 yang diolah menggunakan algoritma NDWI dan NDVI untuk mendapatkan nilai indeks NDDI. Hasil penelitian ini menunjukkan kekeringan lahan di Kabupaten Lamongan didominasi sebesar 62,14% atau 1.097,087 Km2 dengan tingkat klasifikasi kekeringan berat dari seluruh total area.

Pada penelitian Klasifikasi Tutupan Lahan Pada Citra Sentinel-2 Kabupaten Kuningan Dengan NDVI Dan Algoritme *Random Forest* (Marlina, 2022). Citra satelit yang digunakan adalah citra satelit sentinel-2. Klasifikasi tutupan lahan yang diterapkan pada penelitian ini terdiri dari empat kelas yaitu badan air, bangunan, lahan kosong, pertanian, dan vegetasi. Hasil *overall accuracy* pada algoritma *random forest* bernilai 91,39% dan nilai kappa 0,88.

Penelitian lainnya judul *Satellite imagery and machine learning for aridity disaster classification using vegetation indices* (Prasetyo et al., 2020). Dengan menggunakan citra satelit Landsat 8, Penelitian ini mencoba memprediksi bencana kekeringan provinsi Jawa Tengah menggunakan *K-Nearest Neighbour* (K-NN), *Random Forest* (RF), dan *Support Vector Machine* (SVM). Data satelit dilakukan *preprocessing* untuk menghasilkan NDVI, SAVI, VHI, TCI, dan VCI kemudian dibagi 70% *training* data dan 30% testing data. Dari penelitian ini ditemukan hasil akurasi *K-Nearest Neighbour*

sebesar 92.03%, akurasi *Support Vector Machine* sebesar 96% dan *Random Forest* sebesar 91%.

Penelitian sebelumnya yang berjudul *Drought Monitoring using MODIS derived indices and Google Earth Engine Platform* (Aksoy et al., 2019). Dengan menggunakan dataset yang didapat dari MODIS sensor, diolah untuk mendapatkan *Normalized Difference Drought Index* (NDDI), *Vegetation Health Index* (VHI), dan *Normalized Multi-Band Drought Index* (NMDI). Hasil penelitian ini menunjukkan bahwa Ketepatan peta kondisi kekeringan NMDI lebih rendah dibandingkan dengan peta indeks lainnya dan Peta VHI menunjukkan peta kondisi kekeringan yang lebih baik dibandingkan dengan VCI.

Penelitian terdahulu lainnya yang berjudul Penerapan Metode *Extreme Gradient Boosting* (*XGBoost*) pada Klasifikasi Nasabah Kartu Kredit (Yulianti et al., 2022). Penelitian ini bertujuan untuk menggunakan metode *XGBoost* dalam mengelompokkan nasabah kartu kredit yang mengalami keterlambatan pembayaran. Hasil dari penelitian ini menunjukkan bahwa melakukan *hyperparameter tuning* pada algoritma dapat meningkatkan performa *XGBoost* dalam mengklasifikasikan nasabah kartu kredit dengan akurasi sebesar 80,039%, presisi sebesar 81,338% dan nilai *recall* sebesar 96,854%.

Berdasarkan latar belakang dan penelitian terdahulu, maka penulis melakukan penelitian yang berjudul "Klasifikasi Bencana Kekeringan di Jawa Timur Menggunakan Citra Satelit Landsat 8 dengan Metode *XGBoost*".

1.2. Rumusan Masalah

Bencana kekeringan menyebabkan dampak yang besar seperti berkurangnya air bersih, merusak tanaman pangan dan hancurnya ekosistem lingkungan yang terjadi di area yang sangat luas dalam waktu yang sangat lama. Dalam pemantauan kekeringan saat ini, dibutuhkan waktu yang cukup lama. Biasanya waktu yang digunakan dalam monitoring dilakukan dalam kurun waktu sebulan. Dari permasalahan yang ada, kebutuhan informasi kekeringan kepada masyarakat dan pihak berwenang diperlukan guna mengurangi kerugian dengan mengantisipasi kekeringan dan memitigasi dampak sosial, ekonomi, dan lingkungan yang diakibatkan oleh bencana kekeringan. Sehingga dibutuhkan suatu sistem yang dapat mengklasifikasikan bencana kekeringan dengan cepat dan akurat.

1.3. Tujuan Penelitian

Tujuan penelitian ini adalah mengklasifikasi bencana kekeringan dengan metode *XGBoost* pada citra satelit Landsat 8.

1.4. Batasan Masalah

Batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Daerah penelitian dilakukan di wilayah Provinsi Jawa Timur pada WRS Path 118 dan WRS Row 65.
2. Kelas bencana kekeringan yang diklasifikasikan sejumlah 5 yaitu, Kekeringan ekstrem, Kekeringan parah, Kekeringan sedang, Kekeringan ringan, dan Tidak kekeringan.
3. Keluaran yang dihasilkan berupa gambar peta dengan klasifikasi bencana kekeringan.

1.5. Manfaat Penelitian

Manfaat dari penelitian ini adalah:

1. Membantu dalam pemantauan dan deteksi dini bencana kekeringan.
2. Membantu dalam mengurangi risiko bencana dengan memiliki pemahaman yang lebih baik tentang wilayah-wilayah yang rentan terhadap kekeringan melalui klasifikasi citra satelit.
3. Mengetahui performa *XGBoost* dalam melakukan klasifikasi bencana kekeringan pada citra satelit.

1.6. Metodologi Penelitian

Tahapan-tahapan yang dilakukan dalam penelitian ini yaitu :

1. Studi Literatur

   Tahap pertama merupakan proses pengumpulan data dan referensi melalui jurnal, skripsi, buku, artikel, dan berbagi sumber lainnya mengenai bencana kekeringan, penggunaan citra satelit dan metode *machine learning XGBoost*.
2. Analisis Permasalahan

   Tahap berikutnya melakukan analisis dari informasi yang telah dikumpulkan untuk memahami konsep penggunaan metode *XGBoost* yang hendak diterapkan ke dalam penelitian untuk mengklasifikasikan bencana kekeringan dengan citra satelit.
3. Perancangan Sistem

Pada tahap ini, dilakukan perancangan sistem untuk membangun sebuah sistem yang dapat mengklasifikasikan bencana kekeringan menggunakan citra satelit Landsat 8 dengan metode *XGBoost*. Perancangan sistem meliputi arsitektur sistem, mulai dari pengumpulan data, pengolahan data, pembuatan model, hingga pengujian model.

4. Implementasi

   Sistem yang telah dirancang kemudian diimplementasikan untuk mengklasifikasikan bencana kekeringan pada citra satelit Landsat 8. Implementasi ini melibatkan penggunaan model *XGBoost* untuk mengklasifikasikan citra baru.

5. Pengujian

   Pengujian dilakukan untuk memastikan sistem yang telah dibangun dapat berfungsi dengan baik dan memberikan hasil yang akurat dalam mengklasifikasikan bencana kekeringan.

6. Penyusunan Laporan

   Tahap akhir adalah penyusunan laporan yang berisi seluruh proses penelitian, mulai dari perancangan sistem, implementasi, hingga hasil pengujian.

1.7. Sistematika Penulisan

Sistematikan penulisan yang dilakukan pada penelitian ini dibagi menjadi 5 (lima) bagian, yaitu.

Bab 1: Pendahuluan

Bab ini berisi penjelasan mengenai latar belakang, rumusan masalah, tujuan penelitian, batasan masalah, manfaat peneletian, metologi penelitian, dan sistematika penulisan.

Bab 2: Landasan Teori

Bab ini menyajikan landasan teori yang mendukung penelitian, termasuk penjelasan mengenai bencana kekeringan, klasifikasi kekeringan, teknologi penginderaan jauh (citra satelit Landsat 8), dan metode klasifikasi *XGBoost*. Selain itu, bab ini juga menyajikan hasil penelitian terdahulu yang relevan sebagai referensi.

Bab 3: Analisis dan Perancangan Sistem

Bab ini menguraikan analisis mendalam terhadap permasalahan yang telah diidentifikasi. Selanjutnya, bab ini menjelaskan perancangan sistem klasifikasi

kekeringan berbasis *XGBoost* secara rinci, termasuk arsitektur sistem dan alur prosesnya.

Bab 4: Implementasi dan Pengujian Sistem

Bab ini menjelaskan proses implementasi sistem yang telah dirancang, termasuk pengumpulan data, preprocessing data, pelatihan model, dan pengujian model. Hasil pengujian dan evaluasi kinerja sistem akan disajikan secara detail.

Bab 5: Kesimpulan dan Saran

Bab ini menyimpulkan temuan-temuan penting yang diperoleh dari penelitian, menjawab pertanyaan penelitian yang diajukan, dan memberikan saran untuk penelitian lebih lanjut

BAB 2

LANDASAN TEORI

2.1. Bencana Kekeringan

Kekeringan adalah suatu fenomena alam yang ditandai dengan kekurangan pasokan air secara signifikan dalam jangka waktu yang lama akibat curah hujan yang rendah atau tidak ada sama sekali (UNISDR, 2009). Kekeringan dapat dipengaruhi oleh berbagai faktor, seperti kondisi iklim, aktivitas manusia, dan karakteristik geografis suatu wilayah. Secara umum, kekeringan dapat dikategorikan menjadi empat jenis: meteorologis, hidrologis, agronomis, dan sosioekonomi. Kekeringan meteorologis terjadi akibat curah hujan yang jauh di bawah rata-rata, sedangkan kekeringan hidrologis berkaitan dengan menurunnya debit air sungai atau tingkat muka air tanah. Kekeringan agronomis berdampak langsung pada sektor pertanian, di mana kebutuhan air tanaman tidak tercukupi, sementara kekeringan sosioekonomi melibatkan dampak luas terhadap kehidupan masyarakat, seperti kekurangan pangan dan air bersih.

Bencana kekeringan sering kali terjadi akibat pola musim kemarau yang panjang serta variabilitas iklim seperti El Niño. Daerah-daerah dengan curah hujan rendah dan topografi tertentu, seperti dataran tinggi atau kawasan semi-arid, cenderung lebih rentan terhadap kekeringan. Selain itu, faktor antropogenik seperti penggundulan hutan, pengelolaan sumber daya air yang buruk, dan peningkatan kebutuhan air akibat pertumbuhan populasi turut memperburuk kondisi kekeringan (Haile et al., 2020).

Salah satu metode yang umum digunakan untuk mengukur kondisi kekeringan adalah *Palmer Drought Severity Index* (PDSI). PDSI merupakan indeks berbasis meteorologis yang dirancang untuk mengukur intensitas, durasi, dan luasnya kekeringan dengan mempertimbangkan keseimbangan antara curah hujan, evapotranspirasi, dan kelembapan tanah. PDSI menghitung anomali kelembapan tanah secara terstandarisasi, sehingga memberikan gambaran yang lebih komprehensif tentang kondisi kekeringan dibandingkan metode sederhana berbasis curah hujan saja (Y. Liu et al., 2016). Indeks ini sangat berguna dalam memantau kekeringan

meteorologis dan agronomis, karena mempertimbangkan kebutuhan air tanah dan ketersediaan air di permukaan. Pada umumnya PDSI diklasifikasikan ulang menjadi sembilan kategori seperti pada tabel 2.1. Dalam penelitian ini akan menggunakan klasifikasi yang ada pada tabel 2.2.

Tabel 2. 1 Klasifikasi PDSI

Nilai PDSI	Kategori PDSI
4.00 ke atas	Basah Ekstrem
3.00 sampai 3.99	Basah Parah
2.00 sampai 2.99	Basah Sedang
1.00 sampai 1.99	Sedikit Basah
-1.00 sampai 0.99	Normal
-1.00 sampai -1.99	Kekeringan Ringan
-2.00 sampai -2.99	Kekeringan Sedang
-3.00 sampai -3.99	Kekeringan Parah
-4.00 ke bawah	Kekeringan Ekstrem

Tabel 2. 2 Klasifikasi PDSI yang Digunakan

Nilai PDSI	Kategori PDSI
-1.00 ke atas	Normal
-1.00 sampai -1.99	Kekeringan Ringan
-2.00 sampai -2.99	Kekeringan Sedang
-3.00 sampai -3.99	Kekeringan Parah
-4.00 ke bawah	Kekeringan Ekstrem

2.2. Citra Satelit Landsat 8

Gambar adalah representasi visual atau foto dari kondisi permukaan bumi yang dihasilkan melalui penginderaan spektrum elektromagnetik. Citra satelit merupakan gambaran permukaan bumi atau planet lain yang direkam oleh satelit pengamat milik pemerintah atau perusahaan dari berbagai negara. Gambar-gambar ini dihasilkan oleh sensor yang dipasang pada satelit yang mengorbit ratusan kilometer di atas permukaan bumi. Citra satelit memiliki berbagai manfaat dalam bidang seperti meteorologi, oseanografi, perikanan, pertanian, konservasi keanekaragaman hayati, kehutanan, geologi, kartografi, pendidikan, dan intelijen. Dalam penginderaan jauh, objek atau area

yang dipelajari dapat mencakup permukaan bumi, atmosfer, atau bahkan planet lain di luar angkasa (Lillesand & Kiefer, 1979). Dengan memanfaatkan citra satelit, perencanaan mitigasi bencana kekeringan dapat dilakukan secara lebih efektif, memungkinkan identifikasi daerah rawan, pemantauan perkembangan kekeringan, dan perancangan strategi pengelolaan sumber daya air yang berkelanjutan.

Penelitian ini akan menggunakan citra dari satelit Landsat 8 dimana satelit ini membawa dua sensor utama, yaitu *Operational Land Imager* (OLI) dan *Thermal Infrared Sensor* (TIRS). Sensor OLI memiliki delapan saluran spektral yang mencakup cahaya tampak dan inframerah dekat dengan resolusi spasial 30 meter untuk saluran panchromatic dan 15 meter untuk saluran multispektral. Sensor TIRS, di sisi lain, dirancang khusus untuk mengukur suhu permukaan Bumi dalam saluran inframerah jauh dengan resolusi spasial 100 meter (Prasetyo et al., 2019).

Gambar 2. 1 Satelit Landsat 8 (USGS)

Landsat 8 merupakan salah satu satelit penginderaan jauh yang paling populer dan banyak digunakan dalam berbagai aplikasi, terutama karena kemampuannya menyediakan citra berkualitas tinggi secara gratis dalam jangka waktu yang panjang. Dibandingkan dengan satelit lainnya, Landsat 8 memiliki beberapa keunggulan signifikan. Salah satu kelebihannya adalah adanya dua sensor canggih, yaitu Operational Land Imager (OLI) dan Thermal Infrared Sensor (TIRS), yang tidak dimiliki oleh Sentinel-2 (Benzougagh et al., 2022). Keberadaan TIRS memungkinkan Landsat 8 untuk merekam Land Surface Temperature (LST), yang merupakan parameter penting dalam analisis bencana kekeringan.

Selain itu, Landsat 8 juga unggul dibandingkan satelit MODIS dalam hal resolusi spasial. Landsat 8 mampu memberikan resolusi 30 meter untuk kebanyakan bandnya, sementara MODIS hanya menawarkan resolusi 250 meter untuk 2 band, 500 meter untuk 5 band, dan 1 kilometer untuk 29 band lainnya (Samet AKSOY et al., 2019).

Dengan kombinasi resolusi tinggi, cakupan spektral yang luas, dan kemampuan untuk merekam LST, Landsat 8 menjadi pilihan yang sangat andal dan efektif untuk klasifikasi bencana kekeringan dibandingkan citra satelit lainnya.

Tabel 2. 3 *Spectral Bands* Landsat 8

Band	Nama Band	Panjang Gelombang (micrometers)	Resolusi Spasial (meters)
1	Coastal Aerosol	433 - 453	30
2	Blue	458 - 523	30
3	Green	543 - 578	30
4	Red	650 - 680	30
5	Near Infrared (NIR)	698 - 713	30
6	Shortwave Infrared (SWIR) 1	733 - 748	30
7	Shortwave Infrared (SWIR) 2	773 - 793	30
8	Panchromatic	785 - 899	15
9	Cirrus	935 - 955	30
10	Thermal Infrared (TIRS) 1	1360 - 1390	100 (resampled menjadi 30)
11	Thermal Infrared (TIRS) 2	2100 - 2280	100 (resampled menjadi 30)

Penelitian ini menggunakan citra satelit Landsat 8 dengan resolusi spasial asli 30 meter yang telah diubah (resampled) menjadi 1000 meter. Band yang digunakan meliputi Band 4 (Red), Band 5 (Near Infrared), dan Band 10 (Thermal Infrared 1). Pemilihan band-band tersebut didasarkan pada kebutuhannya dalam menghitung berbagai indeks spasial, seperti NDVI, LST, SAVI, VCI, TCI, VHI, dan LST *Normalization*. Resolusi spasial 1000 meter dipilih untuk menyesuaikan dengan resolusi data lain yang digunakan dalam penelitian ini, seperti data *Standardized Precipitation Index* (SPI).

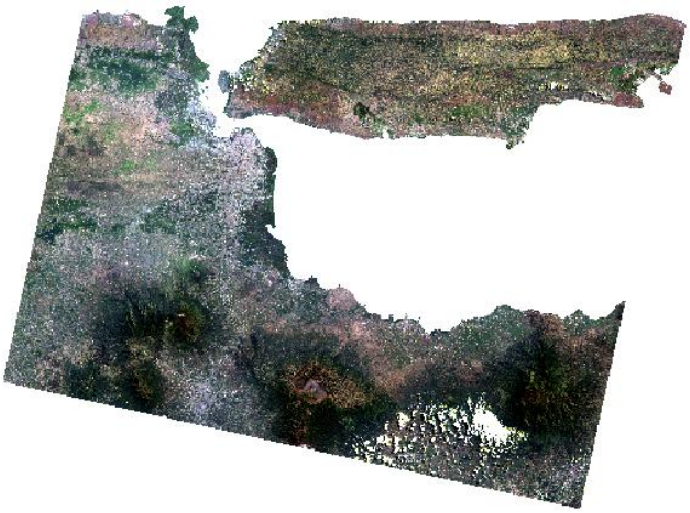

Gambar 2. 2 Contoh Citra Satelit

2.3. Algoritma *XGBoost*

XGBoost, singkatan dari eXtreme Gradient Boosting, adalah algoritma pembelajaran mesin yang kuat dan efisien yang sering digunakan untuk tugas-tugas pemodelan prediktif. *XGBoost* awalnya dikembangkan oleh Tianqi Chen pada tahun 2014. *XGBoost* memanfaatkan metode pembelajaran ensemble yang menggabungkan prediksi dari beberapa model untuk meningkatkan performa secara keseluruhan. Pendekatan ini bergantung pada teknik boosting, di mana model-model lemah, yang umumnya berupa pohon keputusan sederhana, digabungkan menjadi model yang lebih kuat (Chen & Guestrin, 2016).

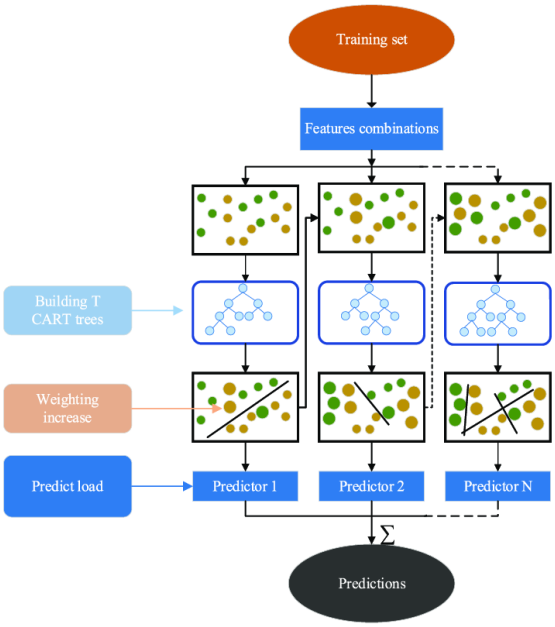

Gambar 2. 3 Ilustrasi Model *XGBoost* (Yao et al., 2022)

Langkah-langkah utama dalam cara kerja *XGBoost* adalah sebagai berikut:

1. Inisialisasi dan Pembentukan Model Dasar: *XGBoost* memulai dengan membuat model dasar yang sederhana, biasanya sebuah pohon keputusan, sebagai titik awal untuk membangun model yang lebih kompleks.
2. Perhitungan Residual: Setelah model dasar dibuat, *XGBoost* menghitung selisih antara prediksi model dasar dengan nilai aktual data. Selisih ini disebut residual dan menjadi target prediksi untuk model berikutnya.
3. Pembuatan Pohon Baru: *XGBoost* kemudian membangun pohon keputusan baru yang fokus pada meminimalkan residual yang telah dihitung sebelumnya. Pohon baru ini akan mempelajari pola dalam data yang belum tertangkap oleh model sebelumnya.
4. Pembaruan Model: Pohon baru yang telah dibuat kemudian ditambahkan ke model yang sudah ada. Bobot setiap pohon akan disesuaikan untuk meminimalkan fungsi kerugian (loss function) secara keseluruhan.
5. Iterasi: Langkah 2-4 diulang secara berulang (iteratif) hingga mencapai kriteria berhenti yang telah ditentukan, seperti jumlah maksimum pohon atau ketika penurunan error sudah sangat kecil.
6. Prediksi: Setelah proses pelatihan selesai, *XGBoost* dapat digunakan untuk melakukan prediksi pada data baru. Prediksi akhir diperoleh dengan menjumlahkan hasil prediksi dari semua pohon dalam model, dengan mempertimbangkan bobot masing-masing pohon.

Adapun kelebihan dari algoritma *XGBoost* dalam Klasifikasi bencana kekeringan adalah :

1. Kemampuan Menangani Data Tidak Seimbang: *XGBoost* dapat menangani dataset yang tidak seimbang dengan efektif, yang sering terjadi pada masalah klasifikasi bencana, di mana data kekeringan mungkin jauh lebih sedikit dibandingkan data non-kekeringan (Rizky et al., 2022).
2. Kemampuan mengatasi *overfitting*: Dengan regularisasi L1 dan L2 yang kuat, *XGBoost* dapat mencegah *overfitting*, yang sangat penting dalam klasifikasi bencana untuk memastikan model tidak terlalu spesifik terhadap data latih yang terbatas (Yulianti et al., 2022).
3. Kecepatan dan Efisiensi: *XGBoost* sangat cepat dalam pelatihan model karena menggunakan teknik seperti *parallelization* dan optimasi berbasis *hardware*, yang

mempercepat proses pelatihan, terutama pada dataset besar seperti citra satelit (Chen & Guestrin, 2016).

4. Skalabilitas: *XGBoost* sangat skalabel, yang berarti dapat menangani dataset besar, seperti citra satelit dalam resolusi tinggi atau data yang mencakup banyak wilayah geospasial (Yulianti et al., 2022).
5. Fleksibilitas dalam Menangani Fitur Kompleks: *XGBoost* mampu menangani berbagai jenis fitur, termasuk data spasial dari citra satelit, serta data numerik atau kategorial, yang membuatnya cocok untuk masalah klasifikasi berbasis data geospasial (Chen & Guestrin, 2016).

2.4. Land Surface Temperatures (LST) dan LST Normalization

Land Surface Temperature (LST) adalah suhu permukaan bumi yang diukur dari energi termal yang dipancarkan oleh permukaan tanah dan objek di atasnya. LST merupakan parameter penting dalam studi lingkungan karena mencerminkan interaksi antara atmosfer, vegetasi, dan tanah. Data LST dapat diperoleh melalui penginderaan jauh menggunakan sensor termal, seperti yang terdapat pada satelit Landsat (Band 10 dan 11 untuk Landsat 8). Informasi ini sering digunakan untuk memahami dinamika lingkungan, termasuk perubahan iklim, urbanisasi, dan siklus hidrologi (Avdan & Jovanovska, 2016). Dalam konteks bencana kekeringan, LST dapat menjadi indikator kondisi panas ekstrem dan kekeringan yang memengaruhi vegetasi, kelembapan tanah, serta kebutuhan air.

$$\mathrm{LST} = \mathrm{TIRS} * 0.00341802 + 149) - 273.15 \qquad (2.1)$$

Dengan :

LST = Nilai Land Surface Temperature (°C)

TIRS = Nilai spectral Thermal Infrared 1 (Band 10)

LST *Normalization* adalah proses normalisasi data LST untuk menghilangkan pengaruh variasi skala yang disebabkan oleh perbedaan spasial dan temporal (Mohamadi et al., 2019). Normalisasi ini bertujuan untuk membuat data LST lebih terstandarisasi sehingga dapat digunakan bersama dengan indeks lainnya dalam analisis kekeringan. Teknik normalisasi biasanya melibatkan konversi nilai LST aktual ke dalam skala relatif, seperti rentang nilai antara 0 hingga 1, atau melalui pendekatan statistik seperti z-score. Normalisasi LST sangat berguna dalam mengintegrasikan data dari berbagai

wilayah atau waktu, sehingga memudahkan perbandingan antar wilayah yang memiliki karakteristik topografi atau iklim berbeda.

$$\mathrm{LSTn} = \frac{\mathrm{LST} - \mathrm{LST_min}}{\mathrm{LST_max} - \mathrm{LST_min}} \tag{2.2}$$

Dengan :

LSTn = Nilai LST *Normalization*

LST = Nilai Land Surface Temperature (°C)

LST_min = Nilai LST terendah dalam dataset (°C)

LST_max = Nilai LST tertinggi dalam dataset (°C)

Dalam konteks bencana kekeringan, LST dan LST *Normalization* memainkan peran penting dalam memetakan wilayah yang terdampak kekeringan secara spasial dan temporal. Peningkatan suhu permukaan yang terdeteksi melalui LST sering dikaitkan dengan penurunan kelembapan tanah dan stress vegetasi, yang merupakan tanda-tanda utama kekeringan. Dengan normalisasi LST, analisis menjadi lebih akurat dalam mengidentifikasi wilayah dengan risiko kekeringan tinggi. Kombinasi LST dengan indeks vegetasi, seperti NDVI atau VHI, memungkinkan pengklasifikasian tingkat keparahan kekeringan, membantu pengelola sumber daya air dan perencana wilayah dalam merancang strategi mitigasi yang tepat (Karnieli et al., 2010).

2.5. Indeks Vegetasi

Indeks Vegetasi adalah metrik yang digunakan untuk menggambarkan kondisi dan kesehatan vegetasi berdasarkan data penginderaan jauh. Indeks ini biasanya dihitung menggunakan kombinasi nilai reflektansi spektral pada band merah (red) dan inframerah-dekat (near-infrared), yang mencerminkan tingkat fotosintesis dan biomassa vegetasi. Indeks vegetasi sangat penting dalam studi lingkungan untuk memantau perubahan vegetasi, identifikasi stres tanaman, dan analisis dampak kekeringan (Li et al., 2013). Dalam konteks bencana kekeringan, indeks vegetasi digunakan untuk mendeteksi area yang terdampak kekeringan dengan mengukur respons vegetasi terhadap ketersediaan air.

2.5.1. Normalized Difference Vegetation Index (NDVI)

Normalized Difference Vegetation Index (NDVI) adalah indeks vegetasi yang paling umum digunakan, dihitung dari rasio antara perbedaan dan jumlah nilai reflektansi pada band near-infrared (NIR) dan red (Karnieli et al., 2010). NDVI memberikan nilai antara

-1 hingga 1, di mana nilai mendekati 1 menunjukkan vegetasi sehat, sedangkan nilai mendekati -1 mencerminkan area tanpa vegetasi, seperti tanah kosong atau air. Dalam analisis kekeringan, NDVI membantu memantau tingkat stres vegetasi yang disebabkan oleh kekurangan air.

$$\mathrm{NDVI} = \frac{\mathrm{NIR} - \mathrm{RED}}{\mathrm{NIR} + \mathrm{RED}} \tag{2.3}$$

Dengan :

NDVI = Nilai Normalized Difference Vegetation Index

NIR = Nilai spectral Near Infrared (Band 5)

RED = Nilai spectral Red (Band 4)

2.5.2. *Soil-Adjusted Vegetation Index* (SAVI)

Soil-Adjusted Vegetation Index (SAVI) adalah pengembangan dari NDVI yang menambahkan faktor koreksi untuk mengurangi efek latar belakang tanah, terutama di area dengan tutupan vegetasi rendah (Hutete A.R., 1988). SAVI dihitung dengan memasukkan nilai koreksi yang disebut L dalam rumusnya, sehingga lebih akurat untuk daerah semi-arid atau kering. Penggunaan SAVI dalam analisis kekeringan memungkinkan pengukuran kesehatan vegetasi yang lebih baik, bahkan pada wilayah dengan tingkat kelembapan tanah yang rendah.

$$\mathrm{SAVI} = \frac{\mathrm{NIR} - \mathrm{RED}}{\mathrm{NIR} + \mathrm{RED} + \mathrm{L}} * (1 + \mathrm{L}) \tag{2.4}$$

Dengan :

SAVI = Nilai Soil-Adjusted Vegetation Index

NIR = Nilai spectral Near Infrared (Band 5)

RED = Nilai spectral Red (Band 4)

L = Nilai faktor koreksi kecerahan tanah (umumnya bernilai 0,5)

2.5.3. Vegetation Condition Index (VCI)

Vegetation Condition Index (VCI) adalah indeks yang mengukur kondisi vegetasi berdasarkan deviasi NDVI dari nilai minimum dan maksimum historis. VCI digunakan untuk memantau perubahan kondisi vegetasi dalam konteks waktu dan memberikan gambaran tentang tingkat stres tanaman akibat kekeringan (W. T. Liu & Kogan, 1996). Dalam analisis kekeringan, VCI membantu mendeteksi area yang mengalami degradasi vegetasi parah akibat kurangnya curah hujan.

$$\mathrm{VCI} = \frac{\mathrm{NDVI} - \mathrm{NDVI_min}}{\mathrm{NDVI_max} - \mathrm{NDVI_min}} * 100 \qquad (2.5)$$

Dengan :

VCI = Nilai Vegetation Condition Index

NDVI = Nilai Normalized Difference Vegetation Index (°C)

NDVI_min = Nilai NDVI terendah dalam dataset (°C)

NDVI_max = Nilai NDVI tertinggi dalam dataset (°C)

2.5.4. *Temperature Condition Index* (TCI)

Temperature Condition Index (TCI) mengukur kondisi suhu berdasarkan deviasi suhu permukaan tanah (LST) dari nilai minimum dan maksimum historis. TCI memberikan informasi tentang tingkat panas yang dialami vegetasi, yang sering kali berkaitan dengan stres akibat kekeringan (Kogan, 1995). Dalam kombinasi dengan VCI, TCI membantu memahami pengaruh gabungan kekeringan dan suhu tinggi terhadap kesehatan tanaman.

$$\mathrm{TCI} = \frac{\mathrm{LST_max} - \mathrm{LST_min}}{\mathrm{LST} - \mathrm{LST_min}} * 100 \qquad (2.6)$$

Dengan :

TCI = Nilai Temperature Condition Index

LST = Nilai Normalized Difference Vegetation Index (°C)

LST_min = Nilai LST terendah dalam dataset (°C)

LST_max = Nilai LST tertinggi dalam dataset (°C)

2.5.5. *Vegetation Health Index* (VHI)

Vegetation Health Index (VHI) adalah kombinasi dari VCI dan TCI, yang dirancang untuk memberikan gambaran menyeluruh tentang kondisi vegetasi dalam kaitannya dengan stres lingkungan. VHI mempertimbangkan pengaruh gabungan dari kekeringan dan suhu panas, sehingga sangat efektif dalam memetakan tingkat keparahan kekeringan (Kogan, 1990). Dengan menggunakan VHI, wilayah yang paling rentan terhadap dampak kekeringan dapat diidentifikasi dengan lebih baik, membantu pengambilan keputusan dalam mitigasi dan adaptasi terhadap bencana kekeringan.

$$\mathrm{VHI} = \mathrm{a} * \mathrm{VCI} + (1 - \mathrm{a}) * \mathrm{TCI} \qquad (2.7)$$

Dengan :

VHI = Nilai Vegetation Health Index

VCI = Nilai Vegetation Condition Index

TCI = Nilai Temperature Condition Index

a = Koefisien yang menentukan kontribusi kedua indeks

2.6. Standardized Precipitation Index (SPI)

Standardized Precipitation Index (SPI) adalah indeks statistik yang dirancang untuk mengevaluasi anomali curah hujan dalam periode tertentu dan menjadi alat utama dalam pemantauan kekeringan. Dikembangkan oleh McKee et al. (1993), SPI menghitung deviasi curah hujan aktual dari rata-rata historisnya yang dinyatakan dalam bentuk nilai z-score. Proses perhitungan SPI melibatkan penyesuaian data curah hujan terhadap distribusi probabilitas, seperti distribusi gamma, dan konversi ke distribusi normal standar. Nilai SPI yang positif menunjukkan kondisi basah, sedangkan nilai negatif menunjukkan kondisi kering. Dalam konteks bencana kekeringan, SPI sangat bermanfaat untuk menentukan tingkat keparahan kekeringan, dari kategori ringan hingga ekstrem, yang membantu pemahaman tentang durasi dan dampak kekeringan terhadap suatu wilayah.

SPI memiliki peran penting dalam analisis bencana kekeringan, khususnya di daerah yang bergantung pada pertanian dan sumber daya air, seperti wilayah Jawa Timur. Dengan menggunakan SPI, pengelola dapat mengidentifikasi awal kekeringan dan membuat keputusan berdasarkan data untuk mengelola risiko serta menyusun strategi mitigasi, seperti pengelolaan irigasi yang efisien atau distribusi sumber daya air. Keunggulan SPI terletak pada kemampuannya untuk menganalisis kekeringan dalam berbagai skala waktu, sehingga memungkinkan pemantauan kekeringan meteorologis jangka pendek maupun kekeringan hidrologis jangka panjang (European Comission, 2020). Namun, untuk analisis yang lebih komprehensif, penggunaan SPI perlu dilengkapi dengan data tambahan seperti kelembapan tanah dan tingkat evaporasi, karena faktor-faktor ini juga berkontribusi signifikan terhadap dampak kekeringan. European Drought Observatory (EDO) membagi nilai SPI menjadi tujuh kelompok berdasarkan tingkat kekeringan atau kelembabannya. Tabel 2.4 menunjukkan bagaimana nilai SPI ini dibagi menjadi kategori dari sangat kering hingga sangat basah.

Tabel 2. 4 Klasifikasi SPI

Nilai SPI	Kategori SPI
2.0 < SPI <= MAX	Basah Ekstrem
1.5 < SPI <= 2.0	Basah Parah
1.0 < SPI <= 1.5	Basah Sedang
-1.0 < SPI <= 1.0	Normal
-1.5 < SPI <= -1.0	Kekeringan Sedang
-2.0 < SPI <= -1.5	Kekeringan Parah
MIN <= SPI <= -2.0	Kekeringan Ekstrem

2.7. Digital Elevation Model (DEM)

Digital Elevation Model (DEM) adalah representasi digital dari permukaan topografi bumi dalam bentuk grid atau raster, di mana setiap piksel menyimpan informasi ketinggian di lokasi tertentu. DEM sering digunakan dalam berbagai analisis spasial, seperti pemetaan, perencanaan wilayah, dan pengelolaan sumber daya alam. Data DEM dapat diperoleh dari berbagai sumber, seperti citra satelit (misalnya, SRTM dan ASTER), survei LiDAR, atau pengukuran lapangan. DEM memungkinkan analisis morfologi lahan, seperti kemiringan, aspek, dan model aliran air, yang berguna dalam memahami karakteristik geografis suatu wilayah (Guth et al., 2021). Dengan resolusi yang memadai, DEM dapat memberikan gambaran rinci tentang variasi topografi yang memengaruhi proses hidrologis.

Dalam konteks bencana kekeringan, DEM memiliki peran penting dalam analisis distribusi air dan pengelolaan sumber daya air di daerah rawan kekeringan. Topografi yang diwakili oleh DEM dapat digunakan untuk memodelkan aliran air permukaan, menentukan lokasi penyimpanan air, serta mengidentifikasi area yang rentan terhadap kekeringan akibat rendahnya kemampuan penangkapan air (Zhang & Montgomery, 1994). Selain itu, DEM memungkinkan simulasi pola curah hujan dan *runoff*, yang dapat membantu pengelola sumber daya air dalam merancang strategi mitigasi bencana kekeringan, seperti pembangunan embung, bendungan kecil, atau irigasi berbasis gravitasi. Dengan demikian, integrasi DEM dalam analisis kekeringan memberikan wawasan yang lebih baik untuk mendukung pengambilan keputusan berbasis data.

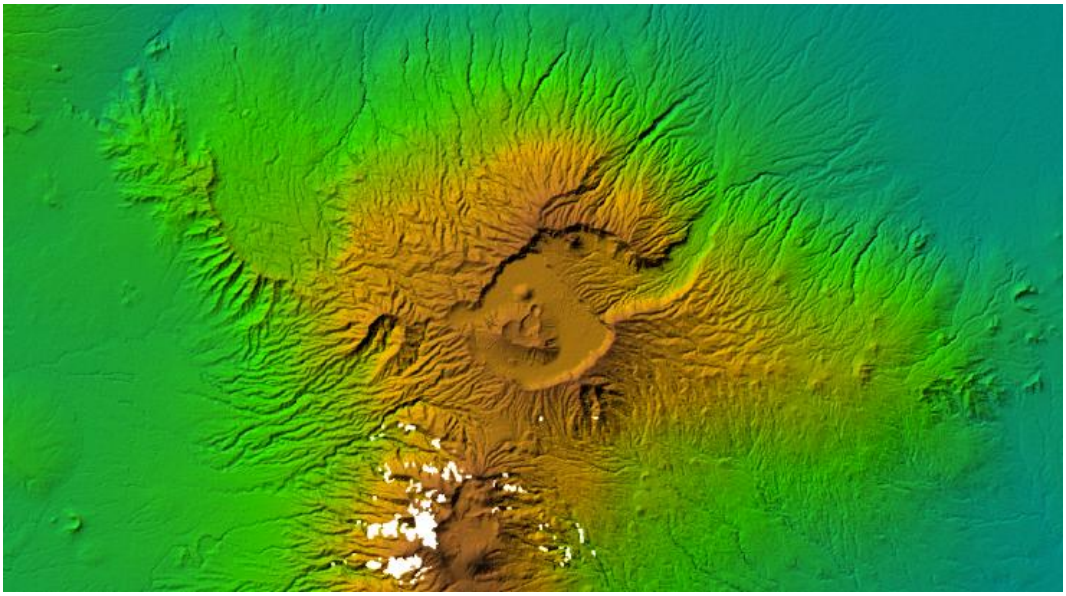

Gambar 2. 4 Gambar DEM Daerah Gunung Bromo

2.8. Confusion Matrix

Confusion Matrix adalah alat yang sering digunakan dalam machine learning dan statistik untuk menilai performa model klasifikasi. Matriks ini membandingkan hasil prediksi model dengan nilai sebenarnya. Komponen utama dari *Confusion Matrix* meliputi:

1. *True Positive* (TP): Kasus yang benar-benar positif dan berhasil diprediksi sebagai positif oleh model.
2. *True Negative* (TN): Kasus yang benar-benar negatif dan diprediksi sebagai negatif oleh model.
3. *False Positive* (FP): Kasus yang sebenarnya negatif, tetapi diprediksi positif oleh model.
4. *False Negative* (FN): Kasus yang sebenarnya positif, tetapi diprediksi negatif oleh model.

Confusion Matrix sangat efektif dalam mengevaluasi kinerja model klasifikasi untuk analisis tutupan lahan menggunakan citra satelit. Model seperti *XGBoost*, misalnya, dapat digunakan untuk mengklasifikasikan berbagai tingkat bencana kekeringan. Dengan memanfaatkan *Confusion Matrix*, kita dapat memahami sejauh mana model tersebut mampu mengidentifikasi setiap kelas kekeringan dengan baik. Matriks ini memungkinkan evaluasi yang lebih mendalam serta membantu meningkatkan akurasi model melalui teknik seperti augmentasi data dan tuning parameter (Markoulidakis & Markoulidakis, 2024). Selain itu, *Confusion Matrix*

memungkinkan perhitungan berbagai metrik kinerja seperti akurasi, presisi, *recall*, dan *F1-score*.

$$Akurasi = \frac{True\ Positives + True\ Negatives}{Total\ Population} \tag{2.4}$$

$$Precision = \frac{True\ Positives}{True\ Positives + False\ Positives} \tag{2.5}$$

$$Recall = \frac{True\ Positives}{True\ Positives + False\ Negatives} \tag{2.6}$$

$$F1_{ham} = 2\ x\ \frac{Precision\ x\ Recall}{Precision + Recall} \tag{2.7}$$

2.9. Website

Situs web adalah kumpulan halaman web yang saling terhubung dan dapat diakses melalui jaringan internet. Setiap halaman web dapat menyajikan berbagai jenis informasi, seperti teks, gambar, video, dan konten lainnya. Dalam proses pengembangannya, situs web memanfaatkan teknologi seperti HTML, CSS, dan JavaScript untuk menciptakan interaksi yang dinamis dan menampilkan konten dengan baik. Pembuatan dan desain situs web membutuhkan pemahaman mengenai struktur halaman serta cara elemen-elemen tersebut bekerja secara bersama-sama untuk memberikan pengalaman pengguna yang maksimal (Sharma, 2018).

2.10. HTML (HyperText Markup Language)

HTML (*HyperText Markup Language*) merupakan bahasa markup standar yang digunakan untuk merancang dan mengatur konten pada halaman web. Dengan HTML, pengembang dapat menentukan kerangka dasar halaman web menggunakan elemen-elemen seperti *heading*, paragraf, tautan, gambar, dan formulir. Setiap elemen dalam HTML ditentukan melalui *tag*, yang memandu browser dalam menampilkan konten sesuai dengan desain yang diinginkan (Sharma, 2018).

2.11. Bootstrap

Bootstrap merupakan *framework front-end* yang banyak digunakan untuk mengembangkan website yang responsif dan *mobile-first*. Bootstrap menawarkan berbagai komponen CSS dan JavaScript yang siap digunakan, termasuk sistem *grid*, navigasi, tombol, dan modal. Dengan menggunakan Bootstrap, pengembang dapat dengan cepat membuat *layout* responsif tanpa harus menulis banyak kode CSS dari

awal. *Framework* ini juga mendukung berbagai browser dan perangkat, memastikan tampilan yang konsisten di berbagai platform (Santoso, 2019).

2.12. JavaScript

JavaScript adalah bahasa pemrograman yang digunakan untuk membuat halaman web menjadi lebih interaktif. Dengan JavaScript, pengembang dapat menambahkan berbagai fitur dinamis pada situs web, seperti validasi formulir, animasi, dan manipulasi DOM. Bekerja secara terpadu dengan HTML dan CSS, JavaScript meningkatkan pengalaman pengguna dengan memungkinkan interaksi yang lebih responsif dan kaya fitur. Selain itu, JavaScript juga dapat digunakan di sisi server melalui lingkungan *runtime* seperti Node.js, memungkinkan pengembangan aplikasi web *full-stack* menggunakan satu bahasa pemrograman (Flanagan, 2020).

Keunggulan utama JavaScript mencakup kemampuannya untuk meningkatkan pengalaman pengguna melalui elemen interaktif seperti menu *dropdown*, *slider* gambar, dan efek animasi. Bahasa ini juga sangat kompatibel dengan berbagai browser dan platform, menjadikannya alat yang fleksibel dan serbaguna dalam pengembangan web. JavaScript memungkinkan pengembang dengan mudah mengimplementasikan fitur-fitur canggih, seperti *drag-and-drop*, *carousel*, dan modal *popup*, yang semuanya meningkatkan kegunaan serta daya tarik visual sebuah situs web (Brown, 2016).

2.13. Python

Python adalah bahasa pemrograman yang terkenal karena sintaksisnya yang sederhana dan mudah dipahami, membuatnya cocok untuk pemula maupun pengembang berpengalaman. Python banyak digunakan dalam berbagai bidang seperti pengembangan web, data science, machine learning, dan otomatisasi tugas. Dalam pengembangan web, Python dapat diintegrasikan dengan *framework* seperti Django dan Flask untuk menciptakan aplikasi web yang andal dan skalabel. Keunggulan Python meliputi ekosistem pustaka yang luas serta komunitas yang aktif, menjadikannya salah satu bahasa pemrograman yang paling diminati oleh para pengembang (Zelle, 2010).

Python juga unggul dalam pengolahan data, dengan pustaka seperti Pandas, NumPy, dan SciPy yang mempermudah manipulasi data, analisis statistik, dan komputasi ilmiah. Menurut Wes Mckinney (2018), Python menjadi pilihan utama untuk analisis data karena kemampuannya dalam menangani dataset besar dan kompleks secara efisien. Python telah membantu perusahaan dalam pengambilan keputusan berbasis data yang

lebih akurat. Harris et al. (2020) menambahkan bahwa Python sangat efektif untuk mengolah data skala besar dan kompleks, dengan pustaka seperti NumPy yang menawarkan performa tinggi untuk pemrosesan *array*, mendukung berbagai aplikasi ilmiah dan teknik. Kemampuannya ini telah memperkuat pengambilan keputusan berbasis analisis data yang mendalam dan tepat waktu.

Selain itu, Python juga banyak digunakan dalam pengolahan citra satelit. Dengan pustaka seperti Rasterio, GDAL, dan OpenCV, Python memungkinkan analisis data citra satelit secara efisien. Penelitian menunjukkan bahwa Python dapat diaplikasikan dalam berbagai tugas penginderaan jauh, seperti klasifikasi tutupan lahan, deteksi perubahan, dan pemantauan lingkungan. Kemampuan Python untuk menangani data besar dengan presisi dan kecepatan menjadikannya alat yang sangat andal dalam pengolahan data citra satelit, menjadikannya pilihan utama untuk aplikasi penginderaan jauh (Gorelick et al., 2017).

2.14. Flask

Flask adalah kerangka kerja web ringan (*microframework*) yang ditulis menggunakan Python. Flask dirancang untuk memberikan fleksibilitas tinggi kepada pengembang dengan menyediakan kerangka kerja yang sederhana namun mudah diperluas. Flask mendukung berbagai ekstensi untuk menambahkan fitur seperti autentikasi, ORM (*Object-Relational Mapping*), dan pengelolaan formulir. Kelebihan utama Flask meliputi kemudahan penggunaan dan kemampuan untuk membuat prototipe dengan cepat, menjadikannya pilihan ideal untuk pengembangan aplikasi web kecil hingga menengah (Idris et al., 2021).

Dari segi performa, Flask dan Python bekerja sangat baik bersama-sama, memberikan kinerja optimal untuk aplikasi web. Kombinasi ini memungkinkan pengembang menciptakan aplikasi yang efisien dan responsif. Flask menyediakan sistem routing yang cepat dan mudah digunakan, serta mendukung berbagai alat pengembangan yang canggih. Sementara itu, Python menawarkan ekosistem pustaka yang kaya untuk pengolahan data, manipulasi string, dan perhitungan matematis. Menurut Grinberg (2018), penerapan Flask bersama Python dapat mempercepat proses pengembangan sekaligus meningkatkan performa aplikasi web secara keseluruhan. Idris et al. (2021) juga menyoroti kemampuan Flask dalam menangani permintaan HTTP dan integrasinya dengan pustaka Python lainnya, menjadikannya solusi yang cepat dan ringan bagi pengembang yang membutuhkan efisiensi dan keandalan.

2.15. Penelitian Terdahulu

Penelitian sebelumnya yang berjudul Analisis Data Citra Landsat 8 OLI Sebagai Indeks Prediksi Kekeringan Menggunakan Machine Learning di Wilayah Kabupaten Boyolali dan Purworejo (Prasetyo et al., 2019). Dengan menggunakan dataset Landsat 8 yang dimasukan ke dalam Machine Learning yang menggunakan metode *XGBoost* dan Random Forest. Hasil penelitian menunjukkan nilai akurasi 0.8286 dan Nilai Kappa 0.6477 dari metode *XGBoost* dan nilai akurasi 0.6857 dan Nilai Kappa 0.3699 dari metode Random Forest.

Penelitian lainnya dengan judul Identifikasi Kekeringan Lahan Kabupaten Lamongan Berdasarkan Citra Satelit (Noraini et al., 2022). Penelitian ini menggunakan dataset Landsat 8 yang diolah menggunakan algoritma NDWI dan NDVI untuk mendapatkan nilai indeks NDDI. Hasil penelitian ini menunjukkan kekeringan lahan di Kabupaten Lamongan didominasi sebesar 62,14% atau 1.097,087 Km2 dengan tingkat klasifikasi kekeringan berat dari seluruh total area.

Pada penelitian Klasifikasi Tutupan Lahan Pada Citra Sentinel-2 Kabupaten Kuningan Dengan NDVI Dan Algoritme Random Forest (Marlina, 2022). Citra satelit yang digunakan adalah citra satelit sentinel-2. Klasifikasi tutupan lahan yang diterapkan pada penelitian ini terdiri dari empat kelas yaitu badan air, bangunan, lahan kosong, pertanian, dan vegetasi. Hasil *overall accuracy* pada algoritma random forest bernilai 91,39% dan nilai kappa 0,88.

Penelitian lainnya judul Satellite imagery and machine learning for aridity disaster classification using vegetation indices (Prasetyo et al., 2020). Dengan menggunakan citra satelit Landsat 8, Penelitian ini mencoba memprediksi bencana kekeringan provinsi Jawa Tengah menggunakan *K-Nearest Neighbour* (K-NN), *Random Forest* (RF), dan *Support Vector Machine* (SVM). Data satelit dilakukan *preprocessing* untuk menghasilkan NDVI, SAVI, VHI, TCI, dan VCI kemudian dibagi 70% *training* data dan 30% testing data. Dari penelitian ini ditemukan hasil akurasi K-*Nearest Neighbour* sebesar 92.03%, akurasi *Support Vector Machine* sebesar 96% dan *Random Forest* sebesar 91%.

Penelitian sebelumnya yang berjudul Drought Monitoring using MODIS derived indices and Google Earth Engine Platform (Aksoy et al., 2019). Dengan menggunakan dataset yang didapat dari MODIS sensor, diolah untuk mendapatkan *Normalized Difference Drought Index* (NDDI), *Vegetation Health Index* (VHI), dan

Normalized Multi-Band Drought Index (NMDI). Hasil penelitian ini menunjukkan bahwa Ketepatan peta kondisi kekeringan NMDI lebih rendah dibandingkan dengan peta indeks lainnya dan Peta VHI menunjukkan peta kondisi kekeringan yang lebih baik dibandingkan dengan VCI.

Penelitian terdahulu lainnya yang berjudul Penerapan Metode *Extreme Gradient Boosting* (*XGBoost*) pada Klasifikasi Nasabah Kartu Kredit (Yulianti et al., 2022). Penelitian ini bertujuan untuk menggunakan metode *XGBoost* dalam mengelompokkan nasabah kartu kredit yang mengalami keterlambatan pembayaran. Hasil dari penelitian ini menunjukkan bahwa melakukan *hyperparameter tuning* pada algoritma dapat meningkatkan performa *XGBoost* dalam mengklasifikasikan nasabah kartu kredit dengan akurasi sebesar 80,039%, presisi sebesar 81,338% dan nilai *recall* sebesar 96,854%. Ringkasan peneliti terdahulu dapat dilihat pada tabel 2.5 berikut ini.

Tabel 2. 5 Penelitian Terdahulu

No	Penulis	Tahun	Metode	Keterangan
1.	Prasetyo, *et. al.*	2019	*XGBoost* dan *Random Forest*	Memprediksi risiko bencana kekeringan menggunakan metode *XGBoost* dan1 *Random Forest* dan dataset dari satelit Landsat 8. Hasil penelitian menunjukan nilai akurasi 0.8286 dari metode *XGBoost* dan nilai akurasi 0.6857 dari metode *Random Forest*.
2.	Noraini, *et. al.*	2022	*Normalized Difference Index Water, Normalized Difference Index Vegetation* dan *Normalized Difference*	Mengidentifikasi lahan kekeringan menggunakan dataset satelit Landsat 8. Dataset diolah untuk mendapatkan NDWI, NDVI, NDDI. Hasil penelitian ini menunjukkan kekeringan lahan di Kabupaten Lamongan didominasi sebesar 62,14% atau 1.097,087 Km2 dengan tingkat klasifikasi

Tabel 2. 5 Penelitian Terdahulu

No	Penulis	Tahun	Metode	Keterangan
			Drought Indeks	kekeringan berat dari seluruh total area.
3.	Dwi Marlina.	2022	*Random Forest*	Penelitian ini melakukan klasifikasi tutupan lahan menggunakan citra satelit Landsat 8. Dengan menggunakan Algoritma *Random Forest*, data di bagi ke dalam empat klasifikasi. Hasil overall accuracy pada algoritma *random forest* bernilai 91,39% dan nilai kappa 0,88.
4.	Prasetyo, *et. al.*	2020	*K-Nearest Neighbor, Random Forest, Support Vector Machine*	Memprediksi bencana kekeringan provinsi Jawa Tengah menggunakan *K-Nearest Neighbour* (*K-NN*), *Random Forest* (RF), dan Support Vector Machine (SVM). Data satelit di *preprocessing* kemudian dibagi 70% *training* data dan 30% testing data. Dari penelitian ini ditemukan hasil akurasi *K-Nearest Neighbour* sebesar 92.03%, akurasi *Support Vector Machine* sebesar 96% dan Random Forest sebesar 91%.
5.	Aksoy, *et. al.*	2019	*Normalized Difference Drought Index, Vegetation Health Index*	Penelitian ini memonitor kondisi kekeringan yang terjadi di Turki dalam periode dua puluh tahun menggunakan citra satelit MODIS. Data citra satelit MODIS diolah untuk mendapatkan NDDI, VHI

Tabel 2. 5 Penelitian Terdahulu

No	Penulis	Tahun	Metode	Keterangan
			dan *Normalized Multi-Band Drought Index*	dan NMDI. Hasil penelitian ini menunjukkan bahwa Ketepatan peta kondisi kekeringan NMDI lebih rendah dibandingkan dengan peta indeks lainnya dan Peta VHI menunjukkan peta kondisi kekeringan yang lebih baik dibandingkan dengan VCI.
6.	Yulianti, *et. al.*	2022	*XGBoost*	Penelitian ini bertujuan untuk menggunakan metode *XGBoost* dalam mengelompokkan nasabah kartu kredit yang mengalami keterlambatan pembayaran. Hasil dari penelitian ini menunjukkan bahwa melakukan *hyperparameter tuning* pada algoritma dapat meningkatkan performa *XGBoost* dalam mengklasifikasikan nasabah kartu kredit dengan akurasi sebesar 80,039%, presisi sebesar 81,338% dan nilai *recall* sebesar 96,854%.

2.16. Perbedaan Penelitian

Penelitian ini memiliki beberapa perbedaan dibandingkan dengan penelitian sebelumnya. Penelitian ini mengklasifikasikan citra ke dalam lima kategori, yaitu kekeringan ekstrem, kekeringan parah, kekeringan sedang, kekeringan ringan, dan tidak kekeringan. Wilayah penelitian yang digunakan adalah Jawa Timur dengan cakupan citra pada WRS *path* 118 dan *row* 65. Penelitian ini memanfaatkan data Landsat 8 dengan tiga band yang memiliki resolusi spasial 30 meter, yaitu Band 4 (*Red*), Band 5 (*Near Infrared*), dan Band 10 (*Thermal Infrared* 1). Ketiga band ini akan digunakan

untuk menghitung berbagai indeks, termasuk NDVI, LST, SAVI, VCI, TCI, VHI, serta normalisasi LST untuk kebutuhan klasifikasi bencana kekeringan. Selain itu, penelitian ini juga melibatkan data tambahan berupa *Standardized Precipitation Index* (SPI) dan *Digital Elevation Model* (DEM).

Berbeda dengan penelitian sebelumnya, Prasetyo et al. (2019) hanya memanfaatkan indeks NDVI, VHI, TCI, dan VCI, sedangkan Samet AKSOY et al., (2019) menggunakan indeks NDDI, VHI, dan NMDI. Penelitian ini akan menggunakan total 168 citra raster dari tahun 2014 hingga 2022, yang akan dibagi dengan proporsi 80% untuk data pelatihan (*training*) dan 20% untuk data pengujian (*testing*).

BAB 3

ANALISIS DAN PERANCANGAN SISTEM

3.1. Dataset

Penelitian ini memanfaatkan data citra raster berformat (.tif) yang diperoleh melalui Google Earth Engine. Lokasi penelitian difokuskan pada wilayah Provinsi Jawa Timur yang termasuk dalam WRS *Path* 118 dan *Row* 65. Citra yang digunakan berasal dari satelit Landsat 8 Level 2, Collection 2, Tier 1, yang dapat diakses melalui USGS atau Google Earth Engine. Data raster yang digunakan mencakup periode 2014–2022 dengan persyaratan tingkat tutupan awan maksimal 20%. Hal ini dilakukan untuk memastikan jumlah data yang memadai sambil tetap menjaga kualitas citra. Data ini menggunakan sistem koordinat EPSG 4326, yang merupakan referensi untuk sistem WGS84 (*World Geodetic System 1984*). Sistem koordinat ini dirancang untuk merepresentasikan posisi di permukaan bumi secara akurat, sehingga memungkinkan pengukuran dan analisis lokasi geografis dengan presisi tinggi.

Citra yang digunakan dalam penelitian ini terdiri dari tiga band yang diambil dari 11 band pada citra satelit Landsat 8, yaitu Band 4 (*Red*), Band 5 (*Near Infrared*), dan Band 10 (*Thermal Infrared* 1). Ketiga band ini akan diubah resolusi spasialnya melalui proses *downsampling* dari 30 meter menjadi 1000 meter.

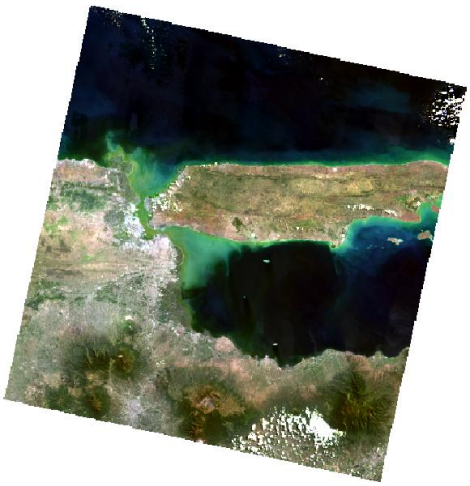

Gambar 3. 1 Citra Raster Daerah Penelitian

Data SPI dalam penelitian ini diperoleh dari dataset berbasis CHIRPS (*Climate Hazards Group InfraRed Precipitation with Station*), yang diakses melalui platform Climate Engine. SPI-CHIRPS memiliki resolusi spasial 0.05° x 0.05° (sekitar 5 km x 5 km di dekat khatulistiwa), menjadikannya salah satu dataset dengan resolusi spasial tertinggi untuk analisis presipitasi berbasis SPI. Data SPI-CHIRPS ini diambil dalam rentang waktu 2014–2022, konsisten dengan data lain yang digunakan dalam studi.

Data Digital Elevation Model (DEM) diperoleh dari kumpulan citra topografi hasil misi *Shuttle Radar Topography Mission* (SRTM) yang diunduh melalui situs resmi USGS Earth Explorer dalam format raster. Citra-citra DEM ini mencakup berbagai *tile* yang meliputi wilayah Jawa Timur, dan seluruh *tile* digabungkan menjadi satu citra mosaik untuk menghasilkan representasi topografi yang utuh. Dengan resolusi spasial 30 meter, yang merupakan salah satu resolusi tertinggi untuk data DEM dengan cakupan global.

Sementara itu, data PDSI (*Palmer Drought Severity Index*) diambil dari produk data TerraClimate, yang menyediakan data iklim global dengan resolusi spasial tinggi. Data ini mencakup periode 2014–2022 dan juga diunduh dalam format NetCDF. Resolusi spasial data PDSI dari TerraClimate adalah 4 km, yang merupakan salah satu resolusi tertinggi yang tersedia untuk analisis kekeringan.

3.2. Arsitektur Umum

Tahap pertama dalam penelitian ini adalah pengambilan data yang meliputi citra Landsat 8, data *Standardized Precipitation Index* (SPI), data *Digital Elevation Model* (DEM), dan *data Palmer Drought Severity Index* (PDSI). Data yang diperoleh akan masuk tahap *pre-processing.* Untuk citra Landsat 8, dilakukan *cropping*, mengubah nilai *nodata*, dan *resampling*. Data SPI dan PDSI diekstrak menjadi format GeoTIFF, *filtering date*, dan *resampling*. Sementara itu, data DEM dilakukan *merge* raster diikuti dengan *resampling*. Setelah tahap *preprocessing*, dilakukan penghitungan indeks dari citra Landsat 8. Indeks yang dihitung mencakup NDVI, LST, SAVI, VCI, TCI, VHI, serta LST *normalization*. Hasil dari *preprocessing* dan penghitungan indeks ini kemudian digabungkan dan dibagi menjadi dua subset, yaitu data *training* yang digunakan untuk melatih model dan data *testing* untuk menguji performa model.

Pada tahap berikutnya, algoritma *XGBoost* digunakan untuk melatih model menggunakan data *training*. Model yang telah dilatih kemudian diuji dengan data *testing* untuk mengevaluasi akurasi dan kemampuan prediksi. Selanjutnya, model akan

melakukan klasifikasi kepada citra raster untuk mengklasifikasikan tingkat kekeringan yang dibagi menjadi lima kategori, yaitu kekeringan ekstrem, kekeringan parah, kekeringan sedang, kekeringan ringan, dan tidak kekeringan. Gambaran umum mengenai arsitektur penelitian ini disajikan pada Gambar 3.2.

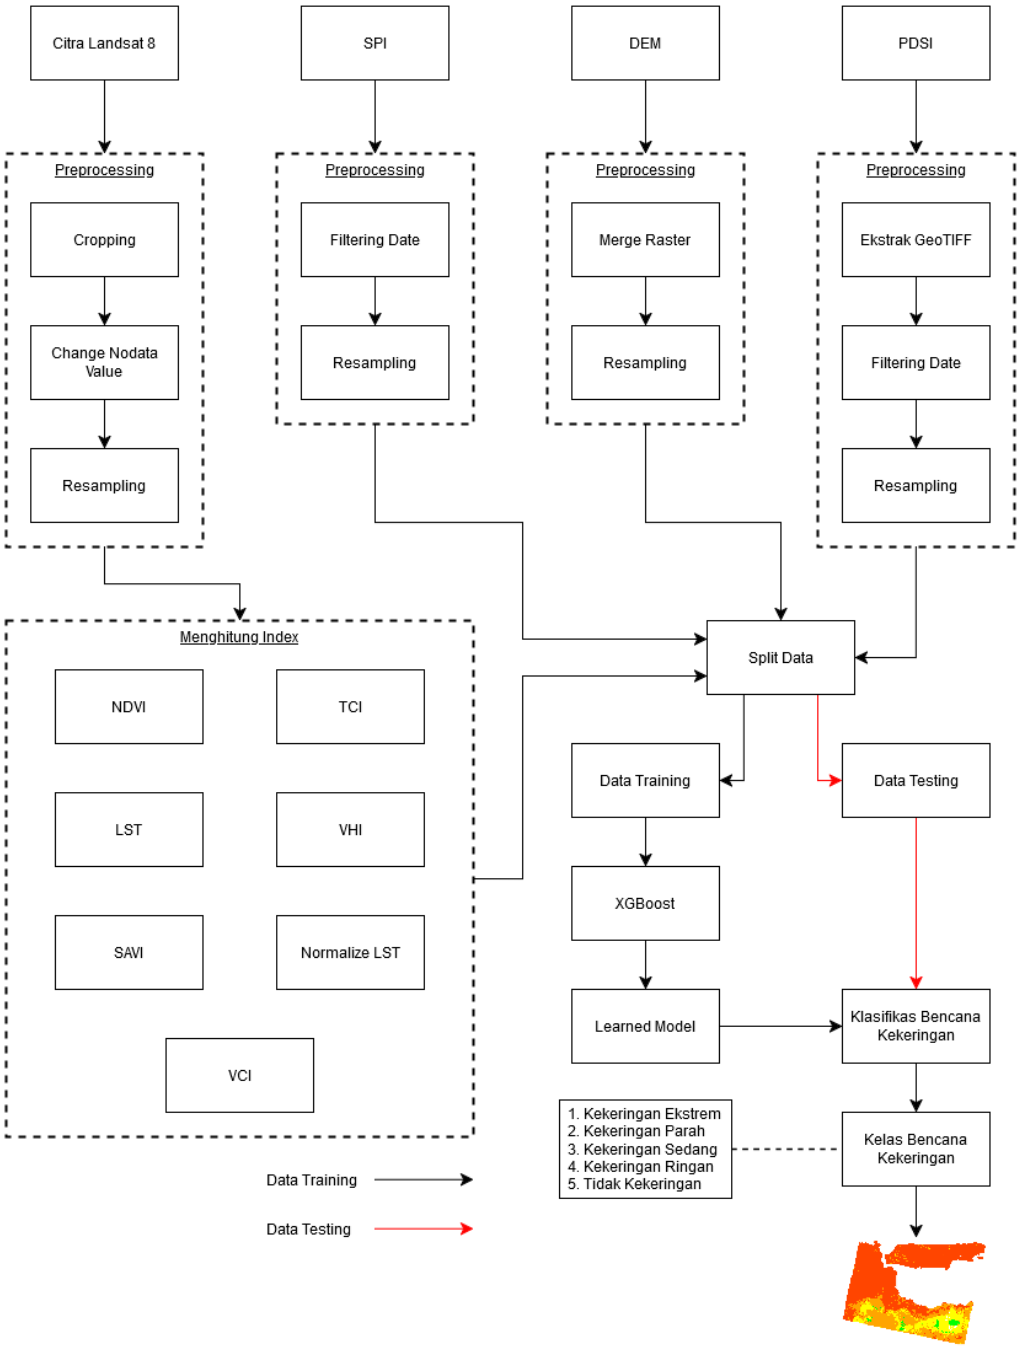

Gambar 3. 2 Arsitektur Umum

3.2.1. Pengambilan data citra satelit

Tahap awal penelitian ini melibatkan pengambilan data citra satelit berupa gambar raster beresolusi tinggi yang diunduh dari Google Earth Engine (https://code.earthengine.google.com/). Data yang digunakan adalah citra dari satelit Landsat 8 Level 2, Collection 2, Tier 1, dengan resolusi spasial 30 meter yang kemudian diambil dalam skala 1000 meter untuk menyelaraskan resolusi dengan data SPI, PDSI, dan DEM. Wilayah yang dipilih untuk pengambilan data adalah Provinsi Jawa Timur, yang mencakup WRS *Path* 118 dan *Row* 65. Data diambil untuk periode 2014–2022 dengan kriteria tingkat tutupan awan maksimal 20% agar tetap menjaga kualitas citra.

Tabel 3. 1 Dataset Citra Landsat 8

No	Tahun	Bulan
1	2014	3
2	2014	6
3	2014	7
4	2014	8
5	2014	9
6	2014	10
7	2014	11
8	2015	3
9	2015	5
10	2015	6
11	2015	7
12	2015	8
13	2015	9
14	2015	10
15	2015	11
16	2016	5
17	2016	6
18	2016	7
19	2016	8
20	2016	9
21	2017	5
22	2017	6
23	2017	7
24	2017	8
25	2017	9
26	2017	10
27	2018	4
28	2018	5
29	2018	6

Tabel 3. 2 Dataset Citra Landsat 8 (Lanjutan)

No	Tahun	Bulan
30	2018	7
31	2018	8
32	2018	9
33	2018	10
34	2019	5
35	2019	6
36	2019	7
37	2019	8
38	2019	9
39	2019	10
40	2019	11
41	2020	3
42	2020	4
43	2020	7
44	2020	8
45	2020	9
46	2020	10
47	2021	3
48	2021	4
49	2021	5
50	2021	9
51	2021	11
52	2022	4
53	2022	5
54	2022	7
55	2022	8
56	2022	9

3.2.2. Pre-Processing citra satelit

Tahap ini dilakukan untuk mempersiapkan data citra satelit agar siap digunakan dalam analisis klasifikasi kekeringan. Data yang telah diunduh akan melalui beberapa langkah *preprocessing*, sebagaimana dijelaskan berikut ini.

a) Cropping

Pada tahap *cropping*, citra akan dipotong berdasarkan *shapefile* batas administratif Provinsi Jawa Timur. Proses ini bertujuan untuk memisahkan wilayah penelitian dari wilayah provinsi lain dan perairan lautan yang tidak relevan dengan penelitian. Hal ini penting untuk menjaga akurasi hasil analisis, mengingat wilayah perairan

tidak relevan dalam klasifikasi bencana kekeringan. Berikut merupakan *pseudocode* dari proses c*ropping* yang dilakukan seperti pada *pseudocode* 3.1

```
FUNCTION cropRaster(raster, shapefile):
    # Baca data raster
    open raster AS raster_data

    # Baca data shapefile
    open shapefile AS shape_data

    # Pastikan koordinat shapefile sesuai dengan raster
    IF shape_data.CRS != raster_data.CRS:
        transform shape_data TO raster_data.CRS

    # Ekstrak geometri dari shapefile
    geometries = shape_data.geometries

    # Lakukan cropping raster menggunakan geometri shapefile
    cropped_raster, transform = MASK raster_data WITH geometries

    # Simpan hasil cropping ke file baru
    save cropped_raster WITH transform TO "cropped_raster.tif"

    RETURN "cropped_raster.tif"
END FUNCTION
```

Pseudocode 3. 1 *Cropping Raster*

b) Mengubah Nilai Nodata

Setelah *cropping*, dilakukan perubahan nilai *nodata* (nilai piksel yang tidak valid) yang menjadi nilai -9999. Pengubahan ini dilakukan untuk memastikan perhitungan indeks yang benar. Nilai -9999 dipilih karena secara umum digunakan sebagai representasi nilai *nodata* dalam pemrosesan data geospasial. Berikut merupakan *pseudocode* dari proses mengubah nilai *nodata* yang dilakukan seperti pada *pseudocode* 3.2

```
FUNCTION setNoDataValue(raster, new_nodata):
    # Buka file raster
    open raster AS raster_data

    # Ambil metadata raster
    metadata = raster_data.metadata

    # Baca semua data raster
    raster_array = raster_data.read()

    # Periksa nilai NoData saat ini
    current_nodata = metadata.nodata

    # Ganti nilai NoData lama dengan nilai baru
    raster_array[raster_array == current_nodata] = new_nodata

    # Perbarui metadata dengan nilai NoData baru
    metadata.nodata = new_nodata

    # Simpan raster dengan nilai NoData baru
    save raster_array WITH metadata TO "new_nodata_raster.tif"

    RETURN "new_nodata_raster.tif"
END FUNCTION
```

Pseudocode 3. 2 Ganti Nilai *Nodata*

c) Resampling

Tahap terakhir dalam *preprocessing* adalah *resampling*. Proses ini bertujuan untuk memastikan bahwa semua data citra memiliki resolusi, bentuk dan koordinat spasial yang seragam, sehingga dapat digabungkan dengan data SPI, PDSI, dan DEM. Berikut merupakan *pseudocode* dari proses mengubah nilai *resampling* yang dilakukan seperti pada *pseudocode* 3.3

```
FUNCTION resampleRaster(input_raster, reference_raster, resampling_method):
    # Buka file raster masukan
    open input_raster AS source_raster

    # Buka file raster referensi
    open reference_raster AS ref_raster

    # Ambil transformasi, dimensi, dan CRS dari raster referensi
    ref_transform = ref_raster.transform
    ref_width = ref_raster.width
    ref_height = ref_raster.height
    ref_crs = ref_raster.crs

    # Periksa jika CRS input raster sama dengan referensi
    IF source_raster.crs != ref_crs:
        # Transformasikan CRS raster masukan agar sesuai dengan referensi
        reproject source_raster TO ref_crs

    # Resample raster masukan ke dimensi dan resolusi raster referensi
    resampled_raster = RESAMPLE source_raster USING resampling_method TO ref_transform, ref_width, ref_height

    # Simpan hasil raster yang di-resample ke file baru
    save resampled_raster TO "resampled_raster.tif"

    RETURN "resampled_raster.tif"
END FUNCTION
```

Pseudocode 3. 3 *Resampling Raster*

(a) Band 4

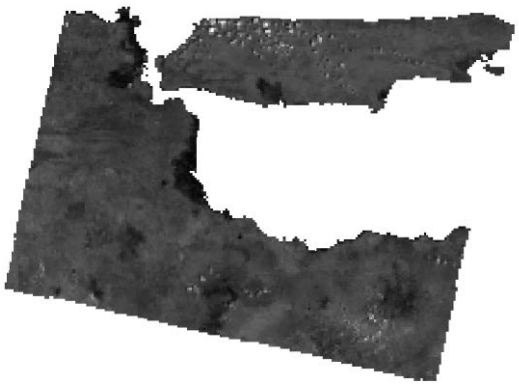

(b) Band 5

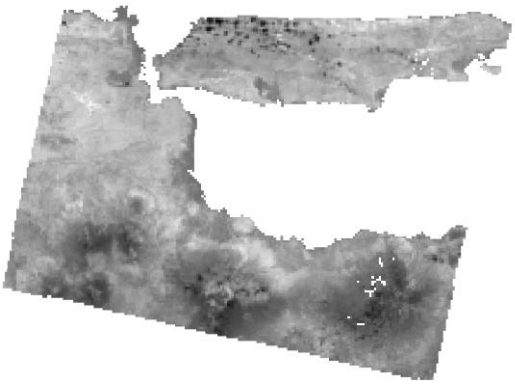

(c) Band 10

Gambar 3. 3 Hasil Pre-Processing

3.2.3. Perhitungan indeks

Setelah data Landsat 8 melalui tahap *preprocessing*, langkah selanjutnya adalah menghitung berbagai indeks, yaitu NDVI, LST, SAVI, VCI, TCI, VHI, dan LST *Normalization*. Proses perhitungan dilakukan pada setiap piksel dalam citra satelit dengan menggunakan band yang relevan. Rumus yang digunakan dalam perhitungan indeks telah dijelaskan secara rinci pada Bab 2. Indeks yang dihasilkan akan memberikan informasi tambahan yang signifikan bagi model klasifikasi, sehingga model dapat menentukan kategori kekeringan dengan lebih akurat dan komprehensif.

Tabel 3. 3 Band Landsat 8 Dan Perhitungan Indeks

No	Band 4	Band 5	Band 10	NDVI	LST	SAVI
1	0,019863	0,282433	43259	0,86859	23,8601	0,49091
2	0,85039	0,87074	40303	0,01182	13,7565	0,01374
3	0,07852	0,047693	46459	-0,2443	34,7978	-0,0738
4	0,117433	0,387318	46566	0,53469	35,1635	0,40291

5	0,014583	0,252403	42910	0,89076	22,6672	0,46511
6	0,064193	0,33196	47045	0,67592	36,8008	0,4482
7	0,089135	0,337047	46582	0,5817	35,2182	0,40151
8	0,012273	0,40709	43495	0,94147	24,6668	0,64417
9	0,13407	0,1949	51774	0,18491	52,9646	0,11007
10	0,736155	0,7801	41835	0,02898	18,9929	0,03269

Tabel 3. 4 Band Landsat 8 Dan Perhitungan Indeks (Lanjutan)

No	**VCI**	**TCI**	**VHI**	**LST *Normalization***
1	93,8534	74,2307	84,04201325	0,257693314
2	21,5965	100	60,7982526	0
3	0	46,3342	23,16711708	0,536657658
4	65,6935	45,4014	55,5474629	0,545985529
5	95,7234	77,2731	86,49825067	0,227268765
6	77,6043	41,2257	59,41500792	0,587743004
7	69,6585	45,262	57,46021223	0,54738035
8	100	72,1733	86,0866533	0,278266934
9	36,1941	0	18,09705158	1
10	23,0436	86,6446	54,84411001	0,13355418

Berikut adalah detail perhitungan indeks yang dilakukan dengan rumus NDVI, LST, SAVI, VCI, TCI, VHI, dan LST *Normalization*.

a) Baris 1

NDVI = (Band 5 - Band 4) / (Band 5 + Band 4) = (0,2824 - 0,0199) / (0,2824 + 0,0199) = 0,8686

LST = Band 10 * 0,00341802 + 149 – 273 = 43259 * 0,00341802 + 149 – 273 = 23,8601

SAVI = ((1 + 0,5) * (Band 5 - Band 4)) / (Band 5 + Band 4 + 0,5) = ((1 + 0,5) * (0,2824 - 0,0199)) / (0,2824 + 0,0199 + 0,5) = 0,4909

VCI = (NDVI - NDVImin) / (NDVImax - NDVImin) * 100 = (0,8686 - -0,2443) / (0,9415 - -0,2443) * 100 = 93,8534

TCI = (LSTmax - LST) / (LSTmax - LSTmin) * 100 = (52,9646 - 23,8601) / (52,9646 - 13,7565) * 100 = 74,2307

VHI = 0.5 * VCI + 0.5 * TCI = 0,5 * 93,8534 + 0,5 * 74,2307 = 84,0420

LST *Normalization* = (LST - LSTmin) / (LSTmax - LSTmin) = (23,8601 - 13,7565) / (52,9646 - 13,7565) = 0,2577

b) Baris 2

NDVI = (Band 5 - Band 4) / (Band 5 + Band 4) = (0,8707 - 0,8504) / (0,8707 + 0,8504) = 0,0118

LST = Band 10 * 0,00341802 + 149 – 273 = 40303 * 0,00341802 + 149 – 273 = 13,7565

SAVI = ((1 + 0,5) * (Band 5 - Band 4)) / (Band 5 + Band 4 + 0,5) = ((1 + 0,5) * (0,8707 - 0,8504)) / (0,8707 + 0,8504 + 0,5) = 0,0137

VCI = (NDVI - NDVImin) / (NDVImax - NDVImin) * 100 = (0,0118 - -0,2443) / (0,9415 - -0,2443) * 100 = 21,5965

TCI = (LSTmax - LST) / (LSTmax - LSTmin) * 100 = (52,9646 - 13,7565) / (52,9646 - 13,7565) * 100 = 100,0000

VHI = 0.5 * VCI + 0.5 * TCI = 0,5 * 21,5965 + 0,5 * 100,0000 = 60,7983

LST *Normalization* = (LST - LSTmin) / (LSTmax - LSTmin) = (13,7565 - 13,7565) / (52,9646 - 13,7565) = 0,0000

c) Baris 3

NDVI = (Band 5 - Band 4) / (Band 5 + Band 4) = (0,0477 - 0,0785) / (0,0477 + 0,0785) = -0,2443

LST = Band 10 * 0,00341802 + 149 – 273 = 46459 * 0,00341802 + 149 – 273 = 34,7978

SAVI = ((1 + 0,5) * (Band 5 - Band 4)) / (Band 5 + Band 4 + 0,5) = ((1 + 0,5) * (0,0477 - 0,0785)) / (0,0477 + 0,0785 + 0,5) = -0,0738

VCI = (NDVI - NDVImin) / (NDVImax - NDVImin) * 100 = (-0,2443 - -0,2443) / (0,9415 - -0,2443) * 100 = 0,0000

TCI = (LSTmax - LST) / (LSTmax - LSTmin) * 100 = (52,9646 - 34,7978) / (52,9646 - 13,7565) * 100 = 46,3342

VHI = 0.5 * VCI + 0.5 * TCI = 0,5 * 0,0000 + 0,5 * 46,3342 = 23,1671

LST *Normalization* = (LST - LSTmin) / (LSTmax - LSTmin) = (34,7978 - 13,7565) / (52,9646 - 13,7565) = 0,5367

d) Baris 4

NDVI = (Band 5 - Band 4) / (Band 5 + Band 4) = (0,3873 - 0,1174) / (0,3873 + 0,1174) = 0,5347

LST = Band 10 * 0,00341802 + 149 – 273 = 46566 * 0,00341802 + 149 – 273 = 35,1635

SAVI = ((1 + 0,5) * (Band 5 - Band 4)) / (Band 5 + Band 4 + 0,5) = ((1 + 0,5) * (0,3873 - 0,1174)) / (0,3873 + 0,1174 + 0,5) = 0,4029

VCI = (NDVI - NDVImin) / (NDVImax - NDVImin) * 100 = (0,5347 - -0,2443) / (0,9415 - -0,2443) * 100 = 65,6935

TCI = (LSTmax - LST) / (LSTmax - LSTmin) * 100 = (52,9646 - 35,1635) / (52,9646 - 13,7565) * 100 = 45,4014

VHI = 0.5 * VCI + 0.5 * TCI = 0,5 * 65,6935 + 0,5 * 45,4014 = 55,5475

LST *Normalization* = (LST - LSTmin) / (LSTmax - LSTmin) = (35,1635 - 13,7565) / (52,9646 - 13,7565) = 0,5460

e) Baris 5

NDVI = (Band 5 - Band 4) / (Band 5 + Band 4) = (0,2524 - 0,0146) / (0,2524 + 0,0146) = 0,8908

LST = Band 10 * 0,00341802 + 149 – 273 = 42910 * 0,00341802 + 149 – 273 = 22,6672

SAVI = ((1 + 0,5) * (Band 5 - Band 4)) / (Band 5 + Band 4 + 0,5) = ((1 + 0,5) * (0,2524 - 0,0146)) / (0,2524 + 0,0146 + 0,5) = 0,4651

VCI = (NDVI - NDVImin) / (NDVImax - NDVImin) * 100 = (0,8908 - -0,2443) / (0,9415 - -0,2443) * 100 = 95,7234

TCI = (LSTmax - LST) / (LSTmax - LSTmin) * 100 = (52,9646 - 22,6672) / (52,9646 - 13,7565) * 100 = 77,2731

VHI = 0.5 * VCI + 0.5 * TCI = 0,5 * 95,7234 + 0,5 * 77,2731 = 86,4983

LST *Normalization* = (LST - LSTmin) / (LSTmax - LSTmin) = (22,6672 - 13,7565) / (52,9646 - 13,7565) = 0,2273

f) Baris 6

NDVI = (Band 5 - Band 4) / (Band 5 + Band 4) = (0,3320 - 0,0642) / (0,3320 + 0,0642) = 0,6759

LST = Band 10 * 0,00341802 + 149 – 273 = 47045 * 0,00341802 + 149 – 273 = 36,8008

SAVI = ((1 + 0,5) * (Band 5 - Band 4)) / (Band 5 + Band 4 + 0,5) = ((1 + 0,5) * (0,3320 - 0,0642)) / (0,3320 + 0,0642 + 0,5) = 0,4482

VCI = (NDVI - NDVImin) / (NDVImax - NDVImin) * 100 = (0,6759 - -0,2443) / (0,9415 - -0,2443) * 100 = 77,6043

TCI = (LSTmax - LST) / (LSTmax - LSTmin) * 100 = (52,9646 - 36,8008) / (52,9646 - 13,7565) * 100 = 41,2257

VHI = 0.5 * VCI + 0.5 * TCI = 0,5 * 77,6043 + 0,5 * 41,2257 = 59,4150

LST *Normalization* = (LST - LSTmin) / (LSTmax - LSTmin) = (36,8008 - 13,7565) / (52,9646 - 13,7565) = 0,5877

g) Baris 7

NDVI = (Band 5 - Band 4) / (Band 5 + Band 4) = (0,3370 - 0,0891) / (0,3370 + 0,0891) = 0,5817

LST = Band 10 * 0,00341802 + 149 – 273 = 46582 * 0,00341802 + 149 – 273 = 35,2182

SAVI = ((1 + 0,5) * (Band 5 - Band 4)) / (Band 5 + Band 4 + 0,5) = ((1 + 0,5) * (0,3370 - 0,0891)) / (0,3370 + 0,0891 + 0,5) = 0,4015

VCI = (NDVI - NDVImin) / (NDVImax - NDVImin) * 100 = (0,5817 - -0,2443) / (0,9415 - -0,2443) * 100 = 69,6585

TCI = (LSTmax - LST) / (LSTmax - LSTmin) * 100 = (52,9646 - 35,2182) / (52,9646 - 13,7565) * 100 = 45,2620

VHI = 0.5 * VCI + 0.5 * TCI = 0,5 * 69,6585 + 0,5 * 45,2620 = 57,4602

LST *Normalization* = (LST - LSTmin) / (LSTmax - LSTmin) = (35,2182 - 13,7565) / (52,9646 - 13,7565) = 0,5474

h) Baris 8

NDVI = (Band 5 - Band 4) / (Band 5 + Band 4) = (0,4071 - 0,0123) / (0,4071 + 0,0123) = 0,9415

LST = Band 10 * 0,00341802 + 149 – 273 = 43495 * 0,00341802 + 149 – 273 = 24,6668

SAVI = ((1 + 0,5) * (Band 5 - Band 4)) / (Band 5 + Band 4 + 0,5) = ((1 + 0,5) * (0,4071 - 0,0123)) / (0,4071 + 0,0123 + 0,5) = 0,6442

VCI = (NDVI - NDVImin) / (NDVImax - NDVImin) * 100 = (0,9415 - -0,2443) / (0,9415 - -0,2443) * 100 = 100,0000

TCI = (LSTmax - LST) / (LSTmax - LSTmin) * 100 = (52,9646 - 24,6668) / (52,9646 - 13,7565) * 100 = 72,1733

VHI = 0.5 * VCI + 0.5 * TCI = 0,5 * 100,0000 + 0,5 * 72,1733 = 86,0867

LST *Normalization* = (LST - LSTmin) / (LSTmax - LSTmin) = (24,6668 - 13,7565) / (52,9646 - 13,7565) = 0,2783

i) Baris 9

NDVI = (Band 5 - Band 4) / (Band 5 + Band 4) = (0,1949 - 0,1341) / (0,1949 + 0,1341) = 0,1849

LST = Band 10 * 0,00341802 + 149 – 273 = 51774 * 0,00341802 + 149 – 273 = 52,9646

SAVI = ((1 + 0,5) * (Band 5 - Band 4)) / (Band 5 + Band 4 + 0,5) = ((1 + 0,5) * (0,1949 - 0,1341)) / (0,1949 + 0,1341 + 0,5) = 0,1101

VCI = (NDVI - NDVImin) / (NDVImax - NDVImin) * 100 = (0,1849 - -0,2443) / (0,9415 - -0,2443) * 100 = 36,1941

TCI = (LSTmax - LST) / (LSTmax - LSTmin) * 100 = (52,9646 - 52,9646) / (52,9646 - 13,7565) * 100 = 0,0000

VHI = 0.5 * VCI + 0.5 * TCI = 0,5 * 36,1941 + 0,5 * 0,0000 = 18,0971

LST *Normalization* = (LST - LSTmin) / (LSTmax - LSTmin) = (52,9646 - 13,7565) / (52,9646 - 13,7565) = 1,0000

j) Baris 10

NDVI = (Band 5 - Band 4) / (Band 5 + Band 4) = (0,7801 - 0,7362) / (0,7801 + 0,7362) = 0,0290

LST = Band 10 * 0,00341802 + 149 – 273 = 41835 * 0,00341802 + 149 – 273 = 18,9929

SAVI = ((1 + 0,5) * (Band 5 - Band 4)) / (Band 5 + Band 4 + 0,5) = ((1 + 0,5) * (0,7801 - 0,7362)) / (0,7801 + 0,7362 + 0,5) = 0,0327

VCI = (NDVI - NDVImin) / (NDVImax - NDVImin) * 100 = (0,0290 - -0,2443) / (0,9415 - -0,2443) * 100 = 23,0436

TCI = (LSTmax - LST) / (LSTmax - LSTmin) * 100 = (52,9646 - 18,9929) / (52,9646 - 13,7565) * 100 = 86,6446

VHI = 0.5 * VCI + 0.5 * TCI = 0,5 * 23,0436 + 0,5 * 86,6446 = 54,8441

LST *Normalization* = (LST - LSTmin) / (LSTmax - LSTmin) = (18,9929 - 13,7565) / (52,9646 - 13,7565) = 0,1336

Berikut merupakan *pseudocode* dari proses indeks (NDVI, LST, SAVI, VCI, TCI, VHI, dan LST *Normalization*) yang dilakukan seperti pada *pseudocode* 3.4

```
FUNCTION calculate_NDVI(band_5, band_4):
   // Rumus Normalized Difference Vegetation Index (NDVI)
   ndvi = (band_5 - band_4) / (band_5 + band_4)
   RETURN ndvi
END FUNCTION

FUNCTION calculate_LST(band_10, emissivity):
   // Rumus Land Surface Temperature (LST)
   lst = band_10 * 0.00341802 + 149 - 273.15
   RETURN lst
END FUNCTION

FUNCTION calculate_SAVI(band_5, band_4, L):
   // Rumus Soil Adjusted Vegetation Index (SAVI)
   savi = ((band_5 - band_4) / (band_5 + band_4 + L)) * (1 + L)
   RETURN savi
END FUNCTION

FUNCTION calculate_VCI(ndvi, ndvi_min, ndvi_max):
   // Rumus Vegetation Condition Index (VCI)
   vci = ((ndvi - ndvi_min) / (ndvi_max - ndvi_min)) * 100
   RETURN vci
END FUNCTION

FUNCTION calculate_TCI(lst, lst_min, lst_max):
   // Rumus Temperature Condition Index (TCI)
   tci = ((lst_max - lst) / (lst_max - lst_min)) * 100
   RETURN tci
END FUNCTION

FUNCTION calculate_VHI(vci, tci, alpha, beta):
```

```
    // Rumus Vegetation Health Index (VHI)
    vhi = (alpha * vci) + (beta * tci)
    RETURN vhi
END FUNCTION

FUNCTION normalize_LST(lst, lst_min, lst_max):
    // Rumus Normalisasi LST
    normalized_lst = (lst - lst_min) / (lst_max - lst_min)
    RETURN normalized_lst
END FUNCTION
```

Pseudocode 3. 4 Indeks *(NDVI, LST, SAVI, VCI, TCI, VHI*, dan LST *Normalization)*

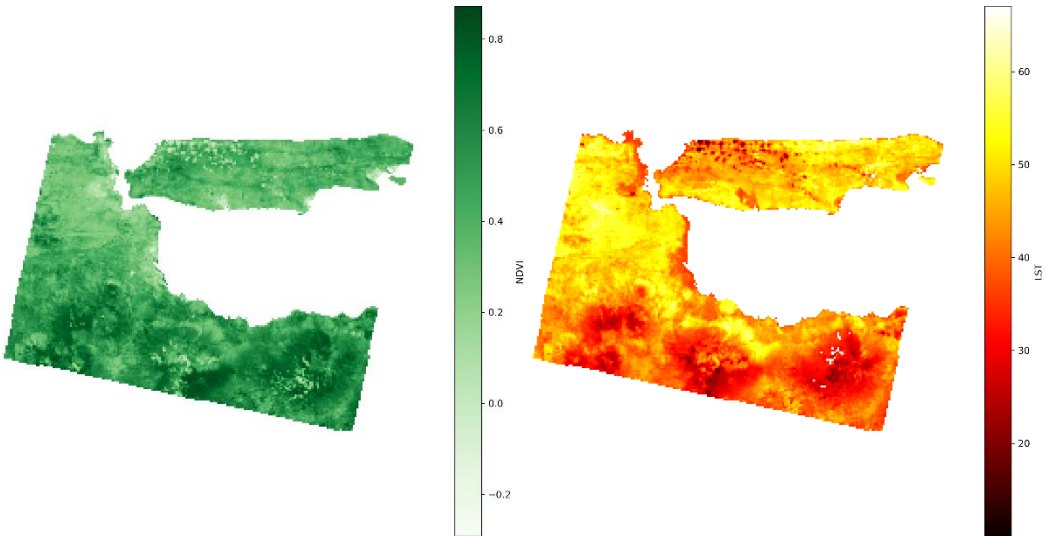

(a) NDVI

(b) LST

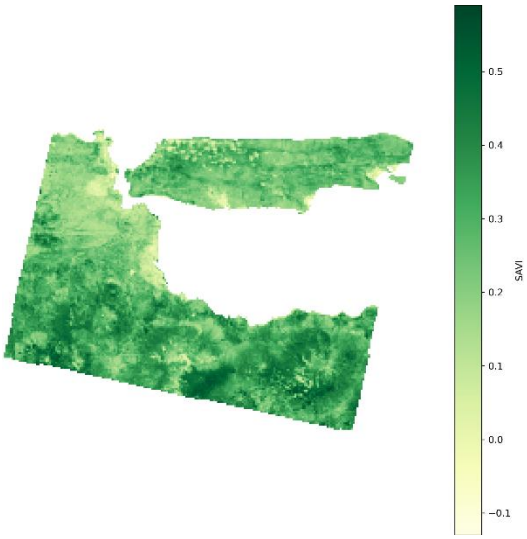

(c) SAVI

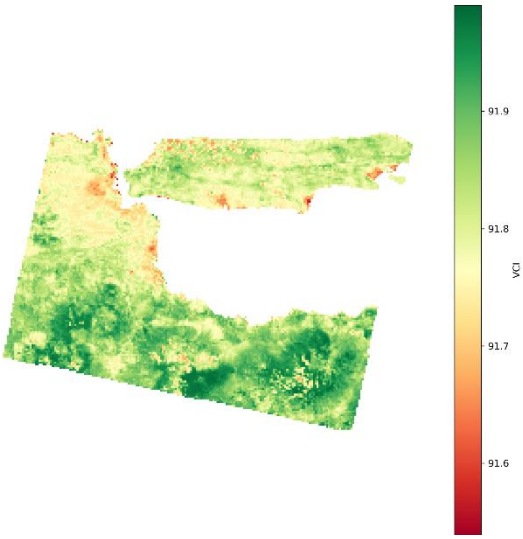

(d) VCI

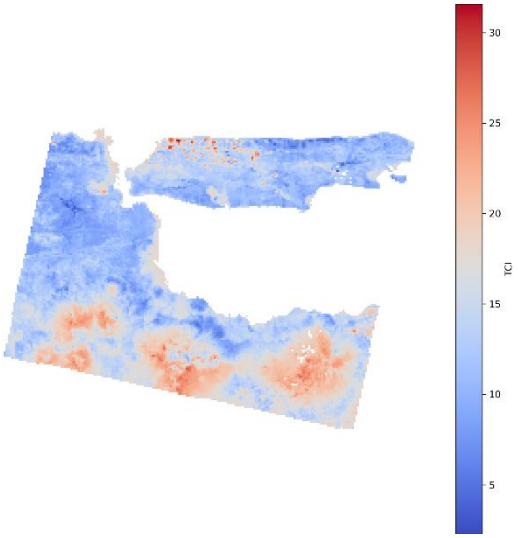

(e) TCI

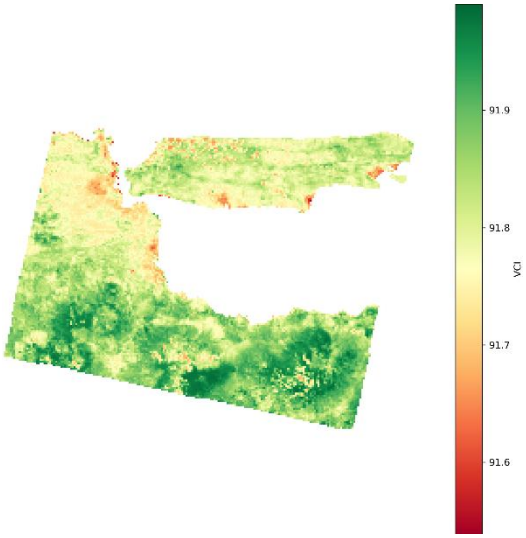

(f) VHI

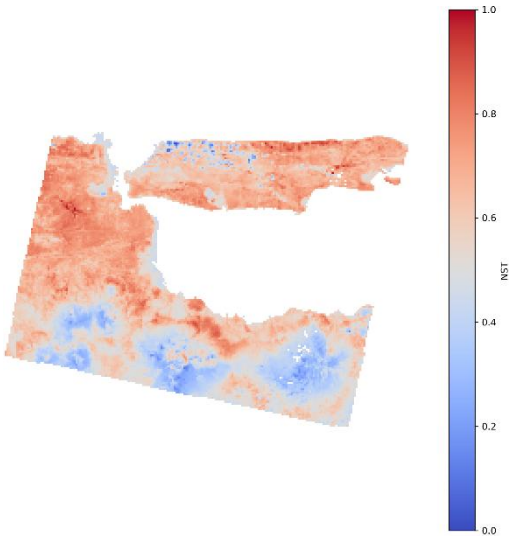

(g) LST *Normalization*

Gambar 3. 4 Hasil Perhitungan Indeks

3.2.4. Data SPI

Data SPI yang digunakan dalam penelitian ini berasal dari dataset berbasis SPI-CHIRPS yang diakses melalui platform Climate Engine. Dataset ini mencakup periode bulanan dari tahun 2014 hingga 2022 dengan resolusi spasial 0.05° x 0.05° (sekitar 5 km). Tahap awal dalam pengolahan data adalah *filtering date* untuk memastikan bahwa data yang digunakan sesuai dengan rentang waktu penelitian. Setelah itu, dilakukan *resampling* untuk menyelaraskan resolusi, bentuk dan koordinat spasial SPI dengan data lainnya.

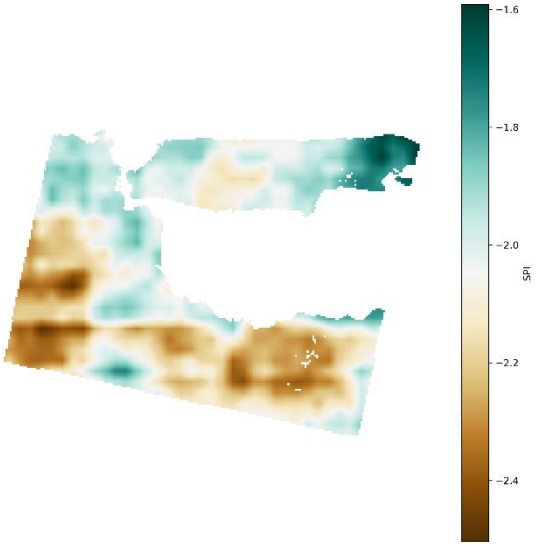

Gambar 3. 5 Gambar SPI

3.2.5. Data DEM

Dataset DEM yang digunakan berasal dari SRTM (*Shuttle Radar Topography Mission*) dengan resolusi asli 30 meter dan diunduh dari situs resmi USGS dalam format *GeoTIFF*. Langkah pertama dalam pengolahan data DEM adalah menggabungkan (*merge*) beberapa citra DEM yang mencakup wilayah Jawa Timur menjadi satu citra utuh. Setelah penggabungan selesai, citra DEM *diresampling* untuk menyesuaikan resolusi, bentuk dan koordinat spasial data.

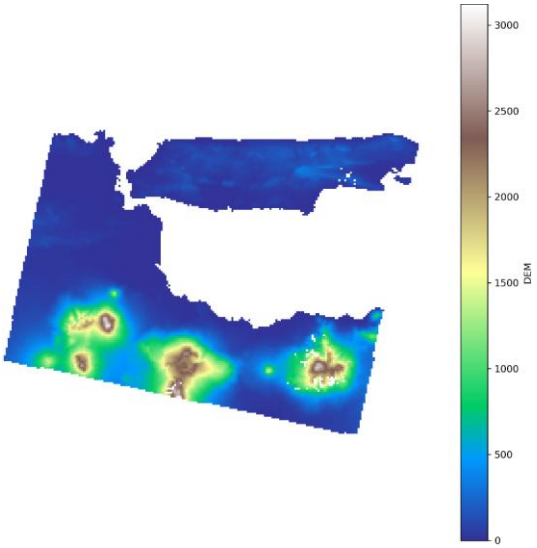

Gambar 3. 6 Gambar DEM

3.2.6. Data PDSI

Data Palmer Drought Severity Index (PDSI) diperoleh dari dataset TerraClimate, yang memiliki resolusi spasial asli 1/24 derajat (~4 km). Data ini mencakup periode bulanan dari tahun 2014 hingga 2022 dan diunduh dalam format *NetCDF*. Langkah awal adalah

mengonversi data PDSI dari format *NetCDF* ke *GeoTIFF* menggunakan Python untuk mempermudah analisis geospasial. Setelah konversi, dilakukan *filtering date* untuk menyesuaikan cakupan temporal PDSI dengan periode penelitian, yaitu dari Januari 2014 hingga Desember 2022. Proses ini penting untuk memastikan keselarasan temporal antara PDSI dan dataset lainnya. Tahap akhir adalah *resampling* data PDSI untuk menyesuaikan resolusi spasial menjadi 1000 meter. Penyesuaian ini memungkinkan integrasi data dengan Landsat 8, SPI, dan DEM.

Setelah proses *resampling*, data PDSI dibagi menjadi beberapa kategori kekeringan berdasarkan nilai PDSI, yaitu:

- Jika PDSI ≤ -4, maka dikategorikan sebagai Kekeringan Ekstrem.
- Jika -4 < PDSI ≤ -3, maka dikategorikan sebagai Kekeringan Parah.
- Jika -3 < PDSI ≤ -2, maka dikategorikan sebagai Kekeringan Sedang.
- Jika -2 < PDSI ≤ -1, maka dikategorikan sebagai Kekeringan Ringan.
- Jika PDSI > -1, maka dikategorikan sebagai Tidak ada kekeringan (Normal).

Berikut merupakan *pseudocode* dari proses klasifikasi PDSI yang dilakukan seperti pada *pseudocode* 3.5

```
FUNCTION classifyPDSIRaster(pdsi_raster):
    # Buka file raster PDSI
    open pdsi_raster AS raster_data

    # Baca data raster ke dalam array
    pdsi_array = raster_data.read()

    # Buat array kosong untuk menyimpan hasil klasifikasi
    classified_array =
CREATE_EMPTY_ARRAY_WITH_SAME_DIMENSIONS(pdsi_array)

    # Iterasi setiap piksel dalam array PDSI
    FOR each value IN pdsi_array:
        IF value <= -4:
            classified_value = 0  # Kekeringan Ekstrem
        ELSE IF -4 < value <= -3:
            classified_value = 1  # Kekeringan Parah
```

```
        ELSE IF -3 < value <= -2:
            classified_value = 2  # Kekeringan Sedang
        ELSE IF -2 < value <= -1:
            classified_value = 3  # Kekeringan Ringan
        ELSE:
            classified_value = 4  # Tidak ada kekeringan (Normal)

        # Simpan nilai klasifikasi ke array hasil
        INSERT classified_value INTO classified_array AT current_position
    END FOR

    # Perbarui metadata raster dengan informasi klasifikasi
    metadata = raster_data.metadata
    metadata.description = "PDSI Classification"

    # Simpan hasil klasifikasi ke file baru
    save classified_array WITH metadata TO "classified_pdsi_raster.tif"

    RETURN "classified_pdsi_raster.tif"
END FUNCTION
```

Pseudocode 3. 5 Klasifikasi PDSI

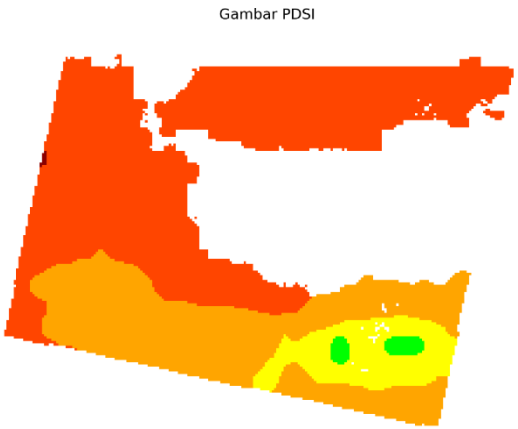

Gambar 3. 7 Gambar PDSI

3.2.7. XGBoost Algorithm

Pada penelitian ini, digunakan berbagai data raster yang meliputi indeks (NDVI, LST, SAVI, VCI, TCI, VHI, dan LST *Normalization*), SPI, DEM, dan PDSI. Data raster (.tif)

ini merupakan gambar berbentuk grid, di mana setiap piksel memiliki nilai yang mencerminkan informasi spesifik sesuai jenisnya. Selanjutnya, data raster tersebut diubah dari format dua dimensi menjadi satu dimensi (*flattened*), dengan data PDSI digunakan sebagai label untuk kategori kekeringan. Hal ini kemudian membentuk dataset yang digunakan untuk pelatihan model.

Setelah dataset pelatihan terbentuk, model *XGBoost* akan digunakan untuk melakukan klasifikasi terhadap piksel yang ada pada dataset. Proses dimulai dengan membangun pohon keputusan pertama yang bertujuan untuk meminimalkan kesalahan prediksi. Setelah pohon pertama selesai, *XGBoost* menghitung residual (kesalahan) antara prediksi dan nilai aktual, yang kemudian digunakan untuk membangun pohon berikutnya. Setiap pohon baru berfokus untuk memperbaiki kesalahan yang dibuat oleh pohon sebelumnya, menggunakan teknik optimasi *gradient descent* untuk meminimalkan fungsi *loss*. Algoritma ini bertujuan untuk meminimalkan kesalahan keseluruhan secara efisien dengan memperbaiki model pada setiap langkah iterasi. Pada setiap iterasi, pohon-pohon keputusan yang baru dilatih dengan mempertimbangkan residual dari model sebelumnya, dan hasil prediksi dari setiap pohon digabungkan untuk menghasilkan prediksi akhir.

Untuk mengoptimalkan model *XGBoost*, teknik *Bayesian optimization* digunakan untuk mencari kombinasi *hyperparameter* terbaik. Parameter yang dioptimalkan dalam proses ini meliputi *learning_rate, max_depth, n_estimators, gamma, subsample, colsample_bytree, dan min_child_weight*. *Bayesian optimization* memungkinkan pencarian ruang *hyperparameter* secara lebih efisien dibandingkan pencarian acak, dengan memodelkan fungsi objektif dan memilih kombinasi parameter berdasarkan hasil sebelumnya untuk meningkatkan kinerja model.

Dengan menggunakan teknik ini, model dapat di-*tuning* untuk mendapatkan nilai parameter yang memaksimalkan kinerja prediktif pada data testing. Setelah menemukan set parameter terbaik, model yang teroptimasi dapat digunakan untuk mengklasifikasikan piksel pada citra raster, memberikan hasil klasifikasi yang lebih akurat berdasarkan data yang sudah dilabeli.

3.2.8. Learned Model

Setelah model *XGBoost* dilatih dengan data pelatihan, model yang dihasilkan dapat dianggap sebagai model yang dipelajari (*learned model*). Model ini terdiri dari serangkaian pohon keputusan yang dibangun secara bertahap. Setiap pohon baru

dibangun untuk mengoreksi kesalahan yang dibuat oleh pohon sebelumnya, dengan tujuan untuk mengurangi error model secara keseluruhan. Prediksi akhir adalah hasil dari kombinasi prediksi setiap pohon yang dioptimalkan untuk meminimalkan *loss function*, model *XGBoost* mampu menghasilkan prediksi pada piksel lainnya. model disimpan dengan nama *XGBoost*_klasifikasi_kekeringan.json. Penyimpanan model ini memungkinkan kita untuk memanfaatkan hasil pelatihan yang telah dilakukan tanpa perlu melatih model dari awal setiap kali kita ingin melakukan prediksi.

```
FUNCTION trainAndOptimizeXGBoost(train_data, test_data, columns):
    # Inisialisasi data train, test, dan validation
    X_train = SELECT features FROM train_data EXCLUDING last column
    y_train = SELECT labels FROM train_data LAST column
    X_test = SELECT features FROM test_data EXCLUDING last column
    y_test = SELECT labels FROM test_data LAST column

    # Definisikan ruang hyperparameter untuk Bayesian Optimization
    param_space = {
        'learning_rate': {'type': 'float', 'min': 0.01, 'max': 0.3, 'log': True},
        'max_depth': {'type': 'int', 'min': 4, 'max': 15},
        'n_estimators': {'type': 'int', 'min': 100, 'max': 500},
        'gamma': {'type': 'float', 'min': 0.1, 'max': 10, 'log': True},
        'subsample': {'type': 'float', 'min': 0.5, 'max': 1},
        'colsample_bytree': {'type': 'float', 'min': 0.5, 'max': 1},
        'min_child_weight': {'type': 'int', 'min': 1, 'max': 10}
    }

    # Inisialisasi Bayesian Optimization
    bayesian_optimizer = INITIALIZE BayesianOptimizer:
        param_space = param_space
        objective_function = TRAIN_XGBoost_MODEL
        n_trials = 50
        random_state = 42

    # Definisikan fungsi objektif untuk optimasi
```

```
FUNCTION TRAIN_XGBoost_MODEL(hyperparameters):
    # Ekstrak hyperparameter dari ruang pencarian
    learning_rate = hyperparameters['learning_rate']
    max_depth = hyperparameters['max_depth']
    n_estimators = hyperparameters['n_estimators']
    gamma = hyperparameters['gamma']
    subsample = hyperparameters['subsample']
    colsample_bytree = hyperparameters['colsample_bytree']
    min_child_weight = hyperparameters['min_child_weight']

    # Buat model XGBoost dengan hyperparameter yang diusulkan
    model = XGBoostClassifier:
        learning_rate = learning_rate
        max_depth = max_depth
        n_estimators = n_estimators
        gamma = gamma
        subsample = subsample
        colsample_bytree = colsample_bytree
        min_child_weight = min_child_weight
        random_state = 42

    # Latih model pada data pelatihan
    model.FIT(X_train, y_train)

    # Test model dengan data test
    y_pred = model.PREDICT(X_test)
    test_accuracy = CALCULATE accuracy_score(y_test, y_pred)

    # Bayesian Optimization akan memaksimalkan akurasi validasi
    RETURN test_accuracy
END FUNCTION

# Jalankan optimasi Bayesian
```

```
        bayesian_optimizer.OPTIMIZE()

        # Ambil hyperparameter terbaik
        best_params = bayesian_optimizer.BEST_PARAMETERS

        # Buat model final menggunakan hyperparameter terbaik
        best_model = XGBoostClassifier:
            learning_rate = best_params['learning_rate']
            max_depth = best_params['max_depth']
            n_estimators = best_params['n_estimators']
            gamma = best_params['gamma']
            subsample = best_params['subsample']
            colsample_bytree = best_params['colsample_bytree']
            min_child_weight = best_params['min_child_weight']
            random_state = 42

        # Latih model terbaik pada data pelatihan
        best_model.FIT(X_train, y_train)

        # Evaluasi akurasi pada data pengujian
        y_test_pred = best_model.PREDICT(X_test)
        test_accuracy = CALCULATE accuracy_score(y_test, y_test_pred)
        PRINT 'Testing overall accuracy XGBoost: ' + test_accuracy

        # Evaluasi akurasi pada data validasi
        y_validation_pred = best_model.PREDICT(X_validation)
        validation_accuracy = CALCULATE accuracy_score(y_validation,
y_validation_pred)
        PRINT 'Validation overall accuracy XGBoost: ' + validation_accuracy

        RETURN best_model, best_params, test_accuracy, validation_accuracy
    END FUNCTION
```

Pseudocode 3. 6 *Learned Model*

3.2.9. Klasifikasi bencana kekeringan

Dari model *XGBoost* yang telah dilatih, langkah selanjutnya adalah memprediksi setiap piksel pada citra raster untuk mengklasifikasikan tingkat kekeringan. Hasil prediksi ditampilkan dalam bentuk peta klasifikasi kekeringan dengan kategori yang diwakili oleh warna tertentu: coklat untuk Kekeringan Ekstrem, merah untuk Kekeringan Parah, jingga untuk Kekeringan Sedang, kuning untuk Kekeringan Ringan, dan hijau untuk Tidak ada kekeringan (Normal).

```
FUNCTION startClassification(input_folder, model_json, ref_tif):
    # Tentukan urutan data yang diharapkan
    expected_order = ["NDVI", "LST", "SAVI", "VCI", "TCI", "VHI", "SPI", "DEM", "NST"]

    # Langkah 1: Membaca data raster dalam urutan yang ditentukan
    raster_stack, nodata_mask = CALL readRastersWithNoData(input_folder, expected_order)

    # Langkah 2: Merapikan data untuk prediksi
    raster_shape = GET SHAPE of raster_stack  # Simpan dimensi asli raster untuk pemrosesan selanjutnya
    raster_flat = RESHAPE raster_stack INTO 2D array (rows, features)  # Flatten raster

    # Langkah 3: Muat model XGBoost yang sudah dilatih
    model = INITIALIZE XGBClassifier()
    model.LOAD_MODEL(model_json)

    # Langkah 4: Prediksi menggunakan model
    predictions_flat = model.PREDICT(raster_flat)

    # Langkah 5: Ubah hasil prediksi ke dimensi raster asli
    predictions = RESHAPE predictions_flat INTO original raster dimensions (height, width)
```

```
    # Langkah 6: Atur nilai NoData pada hasil prediksi
    SET predictions[nodata_mask] TO NaN

    # Langkah 7: Simpan hasil prediksi sebagai raster baru
    WITH rasterio.OPEN(ref_tif) AS src:
      meta = src.META  # Salin metadata dari raster input

    # Update metadata untuk file output
    UPDATE meta WITH:
      count = 1
      dtype = 'float32'
      nodata = NaN

    # Menyimpan hasil prediksi ke dalam file raster output
    WITH rasterio.OPEN('Peta_Kekeringan.tif', 'w', **meta) AS dst:
      WRITE predictions TO dst

    RETURN "Klasifikasi berhasil dan peta prediksi kekeringan telah disimpan."
  END FUNCTION
```

Pseudocode 3. 7 Klasifikasi Bencana Kekeringan

3.2.10. Evaluasi

Setelah model *XGBoost* selesai dilatih, langkah berikutnya adalah mengevaluasi performanya menggunakan *confusion matrix*. Matriks ini menunjukkan jumlah prediksi yang benar dan salah untuk setiap kategori, memberikan gambaran tentang jenis kesalahan yang dilakukan oleh model. Dengan menganalisis *confusion matrix*, berbagai metrik evaluasi seperti akurasi, presisi, *recall*, dan *F1-score* dapat dihitung. Metrik-metrik ini memberikan wawasan mendalam tentang kemampuan model dalam mengklasifikasikan kategori secara akurat.

3.3. Perancangan Sistem

Tahap ini menjelaskan desain antarmuka sistem untuk klasifikasi bencana kekeringan. Sistem dikembangkan dalam bentuk aplikasi berbasis web, memungkinkan pengguna untuk memilih area yang akan dianalisis. Setelah area dipilih, sistem akan menghasilkan peta dengan kategori kekeringan yang telah terklasifikasi.

3.3.1. Desain tampilan halaman depan

Desain tampilan halaman depan sistem berisi informasi utama tentang judul penelitian, nama peneliti, serta navigasi untuk mengakses fitur-fitur sistem. *Navigation bar* memudahkan pengguna untuk berpindah antara halaman testing dan halaman klasifikasi citra. Ilustrasi rancangan halaman depan sistem dapat dilihat pada gambar 3.3.

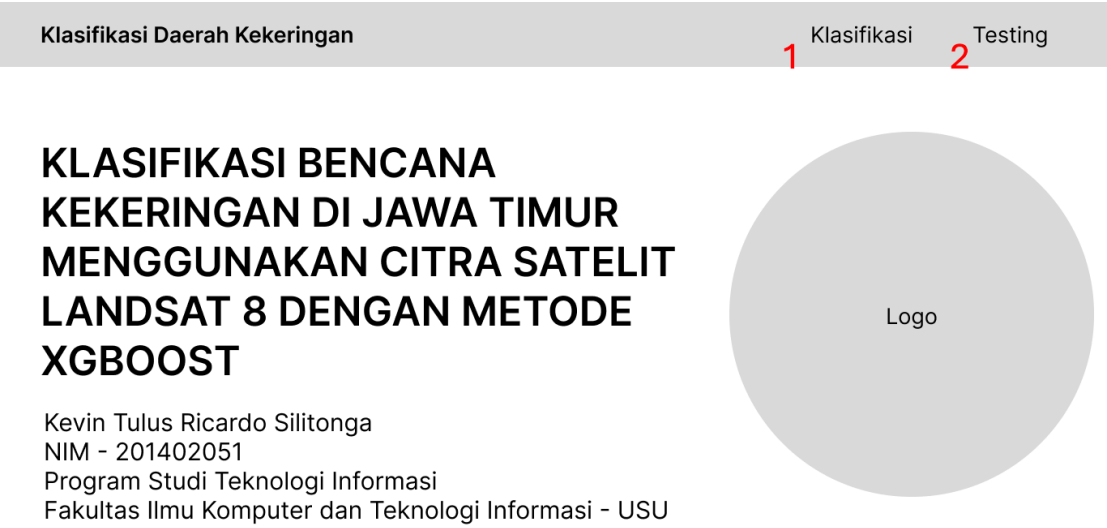

Gambar 3. 8 Halaman Depan

Keterangan:

1. Label 1 Mengarahkan pengguna ke halaman klasifikasi citra, di mana pengguna dapat memilih area analisis untuk menghasilkan peta klasifikasi.
2. Label 2 Mengarahkan pengguna ke halaman testing, tempat pengguna dapat menguji performa model menggunakan data uji.

3.3.2. Desain tampilan testing data

Halaman ini menyediakan fitur *input* untuk menentukan lokasi WRS berdasarkan *path* dan *row*, serta memilih bulan dan tahun citra yang akan diklasifikasikan. Citra Landsat 8 akan diunduh sesuai dengan *input* pengguna dan ditampilkan langsung pada halaman ini. Setelah itu, proses pengujian model akan dilakukan, dan hasilnya akan disajikan pada halaman yang sama. Rancangan antarmuka halaman testing data pada aplikasi web dapat dilihat pada Gambar 3.4, 3.5, dan 3.6.

Gambar 3. 9 Halaman Testing

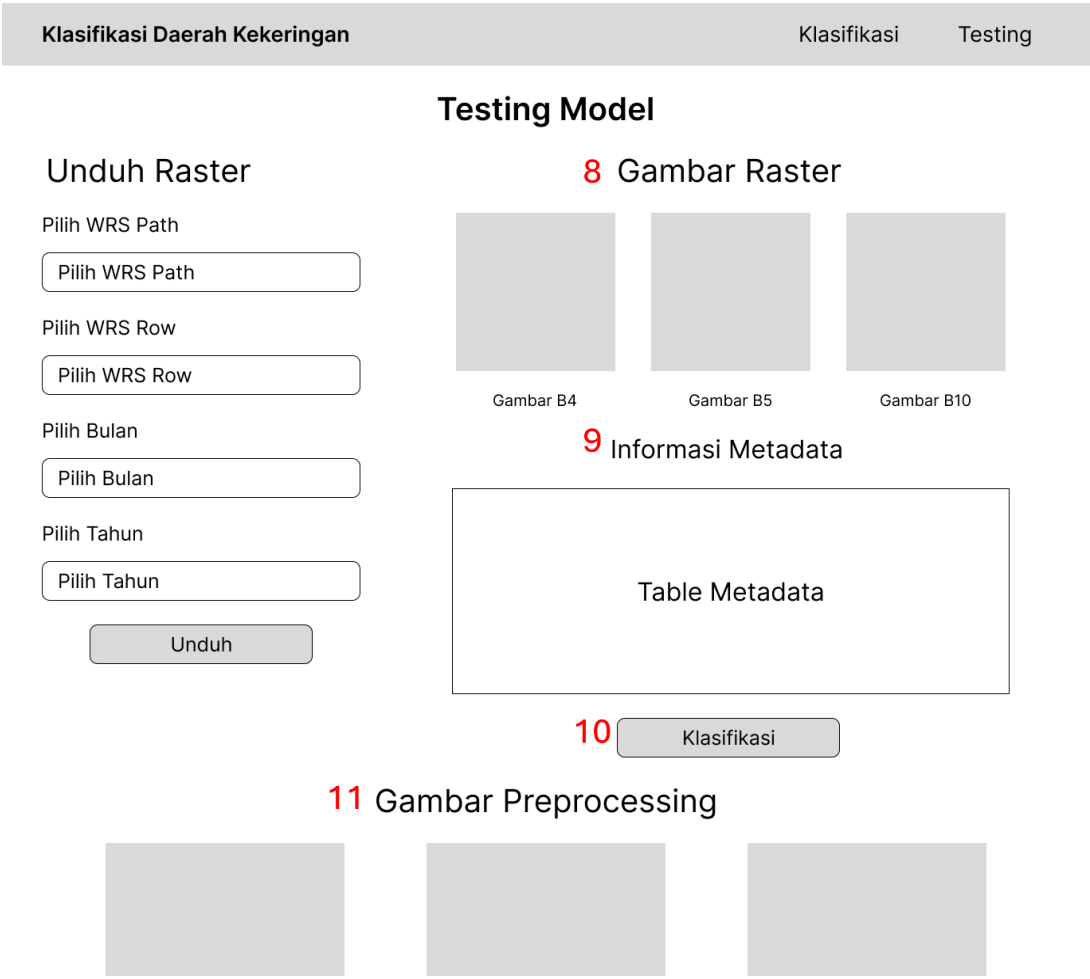

Gambar 3. 10 Halaman Testing (Lanjutan)

Gambar 3. 11 Halaman Testing (Lanjutan)

Keterangan:

1. Label 1 digunakan untuk memasukkan WRS *path*, yaitu posisi *path* citra yang akan diklasifikasikan.
2. Label 2 digunakan untuk memasukkan WRS *row*, yaitu posisi *row* citra yang akan diklasifikasikan.
3. Label 3 berfungsi sebagai *input* untuk tahun pengambilan citra yang akan diklasifikasikan.
4. Label 4 digunakan untuk menentukan bulan pengambilan citra yang akan diklasifikasikan.
5. Label 5 adalah tombol untuk mengunduh citra Landsat 8 berdasarkan *input* yang telah ditentukan sebelumnya.
6. Label 6 menampilkan peta yang memuat informasi WRS *path* dan *row* di wilayah Provinsi Jawa Timur.
7. Label 7 menyediakan panduan bagi pengguna untuk memilih citra yang sesuai dengan kebutuhan.
8. Label 8 menampilkan citra Landsat 8 yang telah berhasil diunduh.
9. Label 9 menampilkan tabel yang berisi *metadata* dari citra raster yang diunduh.
10. Label 10 adalah tombol untuk memulai proses klasifikasi bencana kekeringan menggunakan citra yang telah diunduh.
11. Label 11 menampilkan gambar dari masing-masing indeks yang digunakan dalam proses klasifikasi.
12. Label 12 memuat gambar PDSI yang digunakan sebagai data *ground truth* untuk pengujian model.
13. Label 13 menampilkan hasil klasifikasi bencana kekeringan dalam bentuk citra raster.
14. Label 14 menunjukkan persentase setiap kategori bencana kekeringan yang telah diklasifikasikan.
15. Label 15 menampilkan *validation report* dan *confusion matrix* dari hasil testing model.

3.3.3. Desain tampilan halaman klasifikasi citra

Halaman klasifikasi citra berfungsi sebagai antarmuka untuk menerima *input* dari pengguna. Halaman ini menyediakan fitur *input* WRS untuk menentukan lokasi berdasarkan *path* dan *row*, serta memilih bulan dan tahun citra yang akan

diklasifikasikan. Citra Landsat 8 akan diunduh sesuai dengan *input* pengguna dan ditampilkan langsung di halaman ini. Model yang telah dilatih kemudian digunakan untuk melakukan klasifikasi bencana kekeringan pada citra raster yang diunduh berdasarkan *input* tersebut. Desain antarmuka halaman klasifikasi citra pada aplikasi web ditampilkan pada Gambar 3.7, 3.8, dan 3.9.

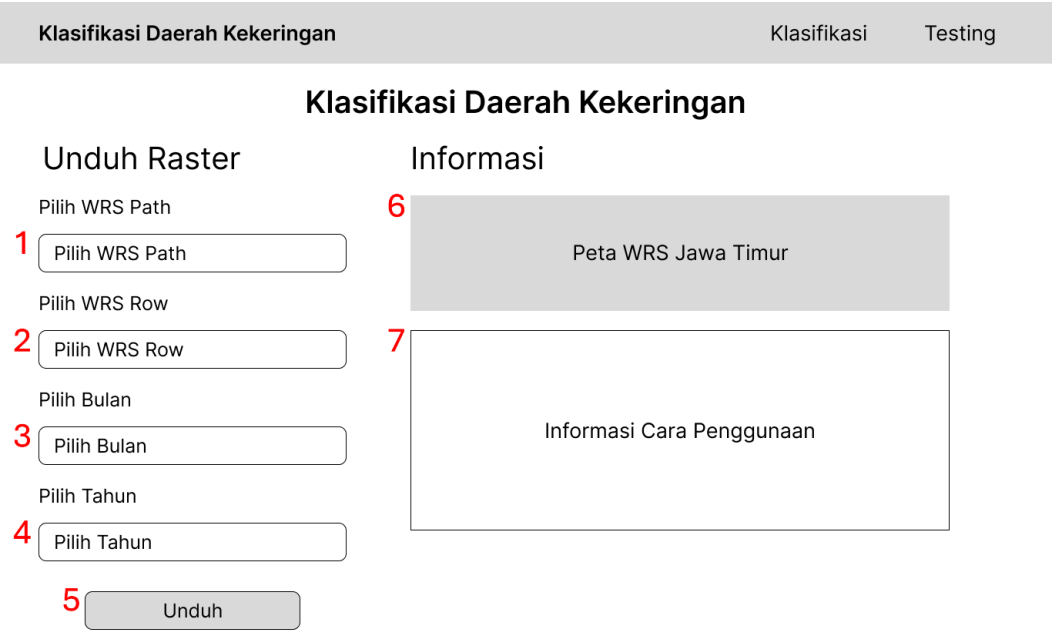

Gambar 3. 12 Halaman Klasifikasi Citra

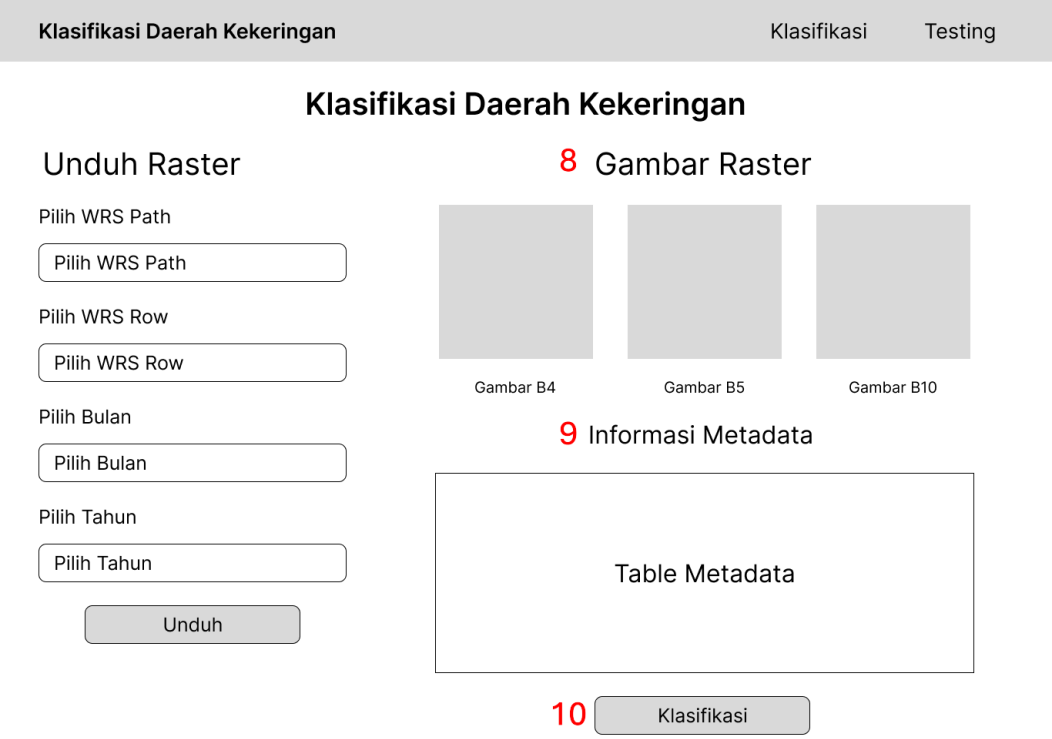

Gambar 3. 13 Halaman Klasifikasi Citra (Lanjutan)

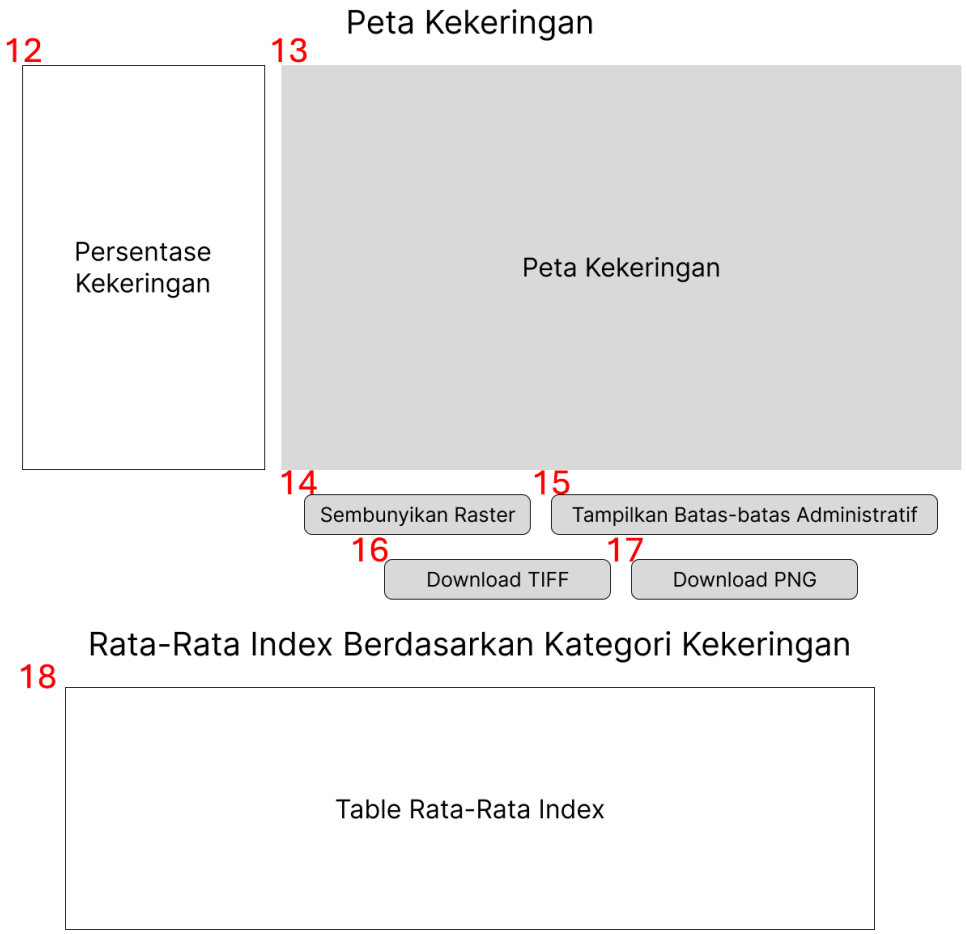

Gambar 3. 14 Halaman Klasifikasi Citra (Lanjutan)

Keterangan:

1. Label 1 digunakan untuk memasukkan WRS *path*, yaitu posisi *path* citra yang akan diklasifikasikan.
2. Label 2 digunakan untuk memasukkan WRS *row*, yaitu posisi *row* citra yang akan diklasifikasikan.
3. Label 3 berfungsi sebagai *input* untuk tahun pengambilan citra yang akan diklasifikasikan.
4. Label 4 digunakan untuk menentukan bulan pengambilan citra yang akan diklasifikasikan.
5. Label 5 adalah tombol untuk mengunduh citra Landsat 8 berdasarkan *input* yang telah ditentukan sebelumnya.
6. Label 6 menampilkan peta yang memuat informasi WRS *path* dan *row* di wilayah Provinsi Jawa Timur.
7. Label 7 menyediakan panduan bagi pengguna untuk memilih citra yang sesuai dengan kebutuhan.

8. Label 8 menampilkan citra Landsat 8 yang telah berhasil diunduh.
9. Label 9 menampilkan tabel yang berisi *metadata* dari citra raster yang diunduh.
10. Label 10 adalah tombol untuk memulai proses klasifikasi bencana kekeringan menggunakan citra yang telah diunduh.
11. Label 11 menampilkan gambar dari masing-masing indeks yang digunakan dalam proses klasifikasi.
12. Label 12 menunjukkan persentase setiap kategori bencana kekeringan yang telah diklasifikasikan.
13. Label 13 menampilkan raster hasil klasifikasi bencana kekeringan dalam bentuk *map*.
14. Label 14 adalah tombol untuk menampilkan atau menyembunyikan raster hasil klasifikasi dari *map*.
15. Label 15 adalah tombol untuk menampilkan atau menyembunyikan batas-batas administratif Provinsi Jawa Timur.
16. Label 16 berfungsi sebagai tombol untuk mengunduh hasil klasifikasi dalam format GeoTIFF (.tif).
17. Label 17 berfungsi sebagai tombol untuk mengunduh hasil klasifikasi dalam format gambar (.png).
18. Label 18 menampilkan tabel yang berisi rata-rata nilai indeks dari setiap kategori bencana kekeringan.

BAB 4

IMPLEMENTASI DAN PENGUJIAN SISTEM

4.1. Implementasi Sistem

4.1.1. Spesifikasi perangkat keras dan perangkat lunak

Spesifikasi perangkat keras yang dipakai untuk pengimplementasian sistem pada penelitian ini adalah sebagai berikut:

1. Processor : AMD Ryzen 3 4300U with Radeon Graphics (4 CPUs) @ 2.70 GHz
2. Memory : 12 GB RAM
3. *SSD* : 512 GB

Berikut adalah spesifikasi perangkat lunak yang dipakai untuk pengimplementasian sistem pada penelitian ini:

1. Sistem Operasi : Windows 11
2. Microsoft Visual Studio Code
3. Python Versi 3.12.7.
4. *Library* yang digunakan ee, geemap, rasterio, fiona, numpy, pandas, matplotlib, seaborn, scikit-learn, *XGBoost*, optuna, flask.

4.1.2. Implementasi perancangan antarmuka

Dari perancangan yang dilakukan pada bab 3, maka berikut ini merupakan implementasi dari rancangan tersebut.

a) Halaman Klasifikasi

   Halaman klasifikasi merupakan antarmuka awal yang akan dilihat oleh pengguna saat mengakses aplikasi. Bagian atas halaman menampilkan informasi berupa judul penelitian dan identitas penulis.

Gambar 4. 1 Tampilan Halaman Depan

Di sisi kiri, terdapat kolom *input* untuk menentukan *path* dan *row* WRS, serta memilih bulan dan tahun. Berdasarkan *input* ini, citra raster akan diunduh dari Google Earth Engine. Sementara itu, di sisi kanan terdapat peta pembagian WRS wilayah Jawa Timur, dilengkapi dengan panduan untuk membantu pengguna memilih area yang akan diklasifikasikan. Tampilan *input* halaman ini dapat dilihat pada Gambar 4.2.

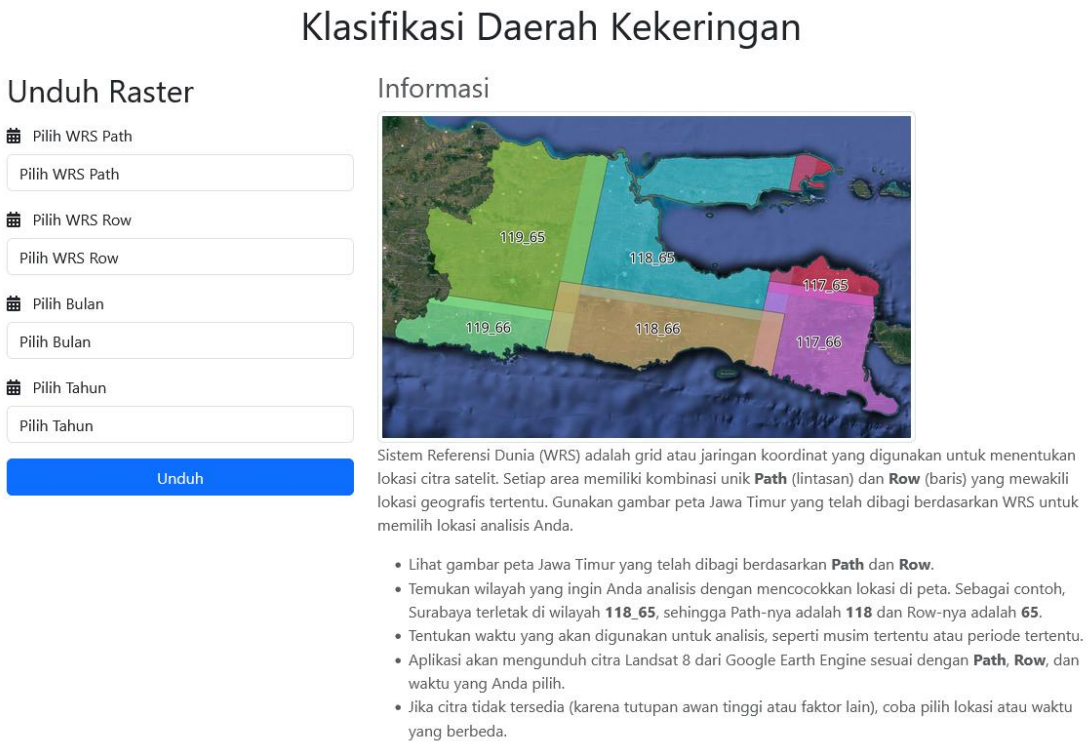

Gambar 4. 2 Tampilan Halaman Klasifikasi Citra

Setelah citra diunduh, citra tersebut beserta *metadata* terkait akan ditampilkan pada halaman ini. Pengguna dapat melanjutkan dengan menekan tombol klasifikasi untuk memulai proses analisis. Hasil klasifikasi akan ditampilkan dalam bentuk peta pada halaman ini, lengkap dengan data pendukungnya. Visualisasi hasil prediksi dapat dilihat pada Gambar 4.3, 4.4, dan 4.5.

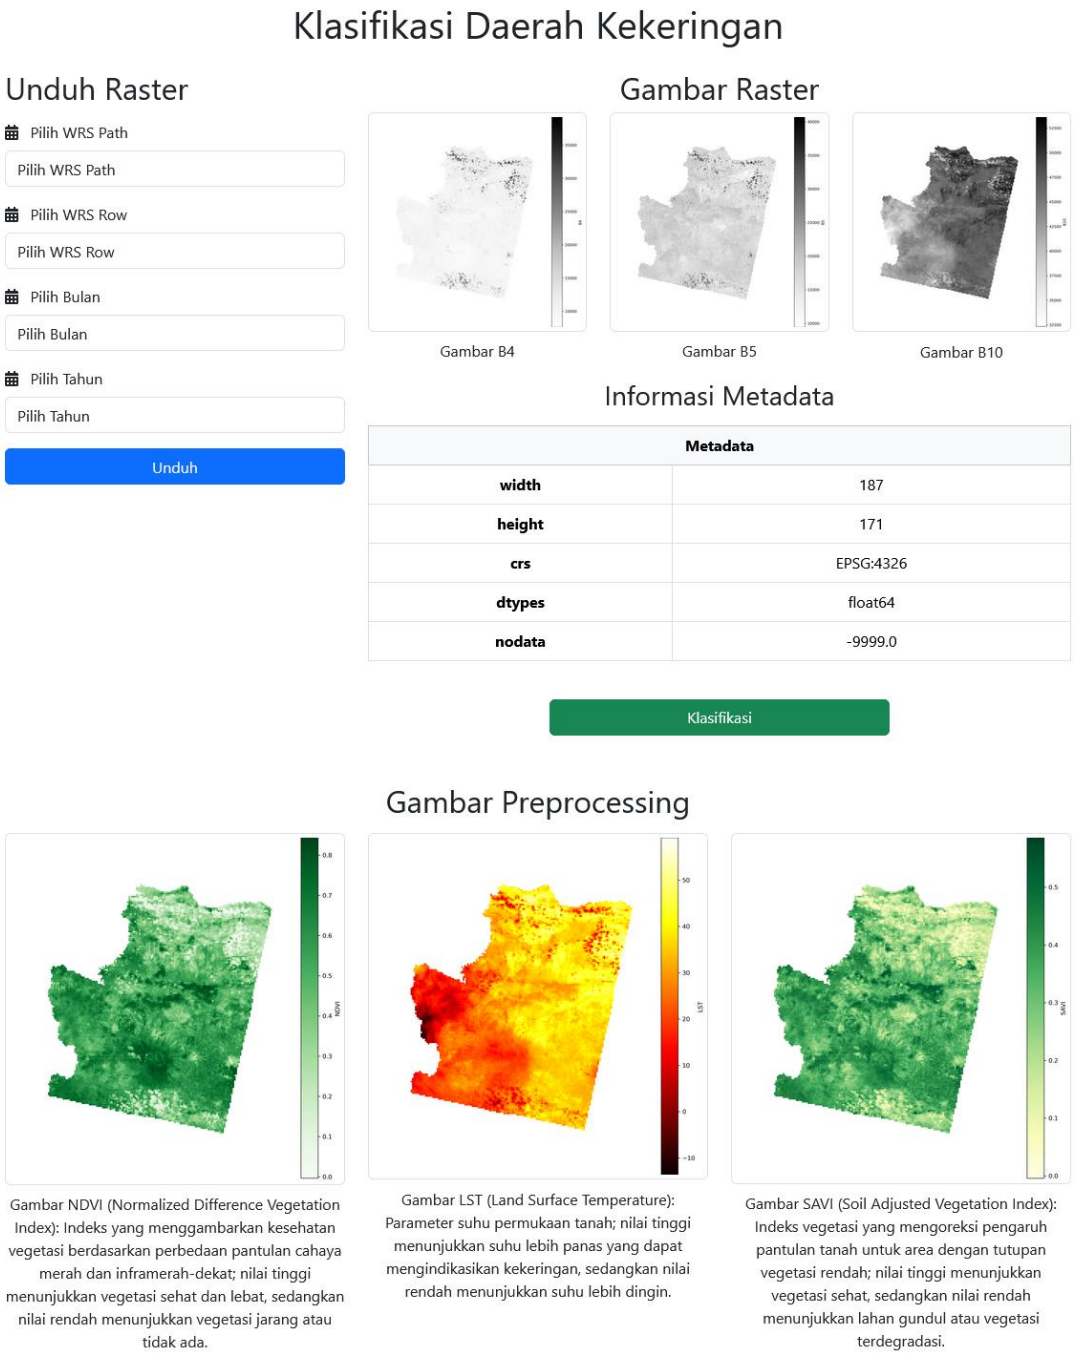

Gambar 4. 3 Tampilan Hasil Prediksi Klasifikasi Citra

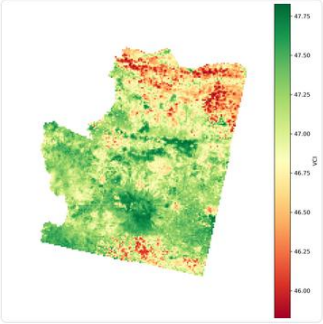

Gambar VCI (Vegetation Condition Index): Indeks yang membandingkan NDVI saat ini dengan nilai maksimum dan minimum historisnya; nilai tinggi menunjukkan kondisi vegetasi baik, sedangkan nilai rendah menunjukkan stres pada vegetasi akibat kekeringan.

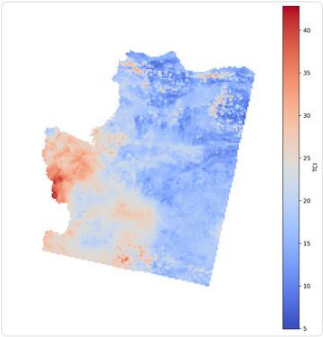

Gambar TCI (Temperature Condition Index): Indeks yang membandingkan suhu saat ini dengan nilai maksimum dan minimum historisnya; nilai tinggi menunjukkan suhu lebih dingin dan kondisi lebih baik, sedangkan nilai rendah menunjukkan suhu tinggi dan kondisi yang lebih kering.

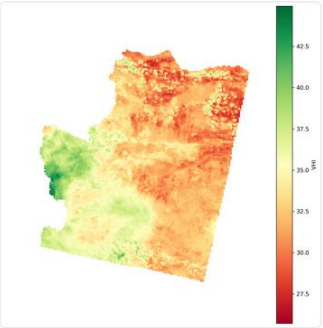

Gambar VHI (Vegetation Health Index): Indeks gabungan dari VCI dan TCI untuk menilai kesehatan vegetasi; nilai tinggi menunjukkan vegetasi dalam kondisi baik, sedangkan nilai rendah menunjukkan vegetasi tertekan akibat kekeringan.

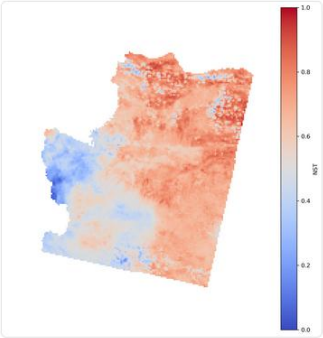

Gambar Normalize LST: Normalisasi suhu untuk mengurangi variabilitas; nilai tinggi menunjukkan suhu lebih tinggi dari rata-rata normal, sedangkan nilai rendah menunjukkan suhu lebih rendah dari rata-rata normal.

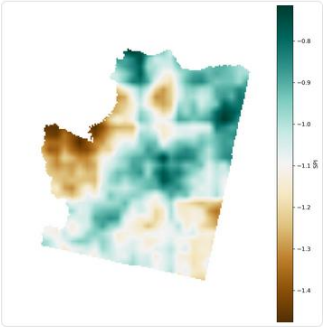

Gambar SPI (Standardized Precipitation Index): Indeks yang mengevaluasi tingkat kekeringan berdasarkan curah hujan; nilai tinggi menunjukkan curah hujan melimpah (basah), sedangkan nilai rendah menunjukkan defisit curah hujan (kekeringan).

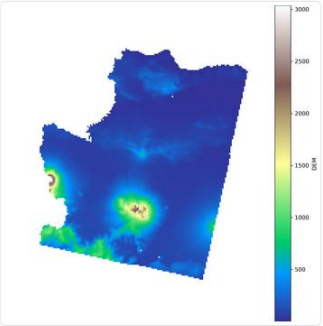

Gambar DEM (Digital Elevation Model): Representasi topografi permukaan bumi; nilai tinggi menunjukkan elevasi yang lebih tinggi seperti perbukitan atau pegunungan, sedangkan nilai rendah menunjukkan daerah dataran rendah yang lebih rentan terhadap kekeringan.

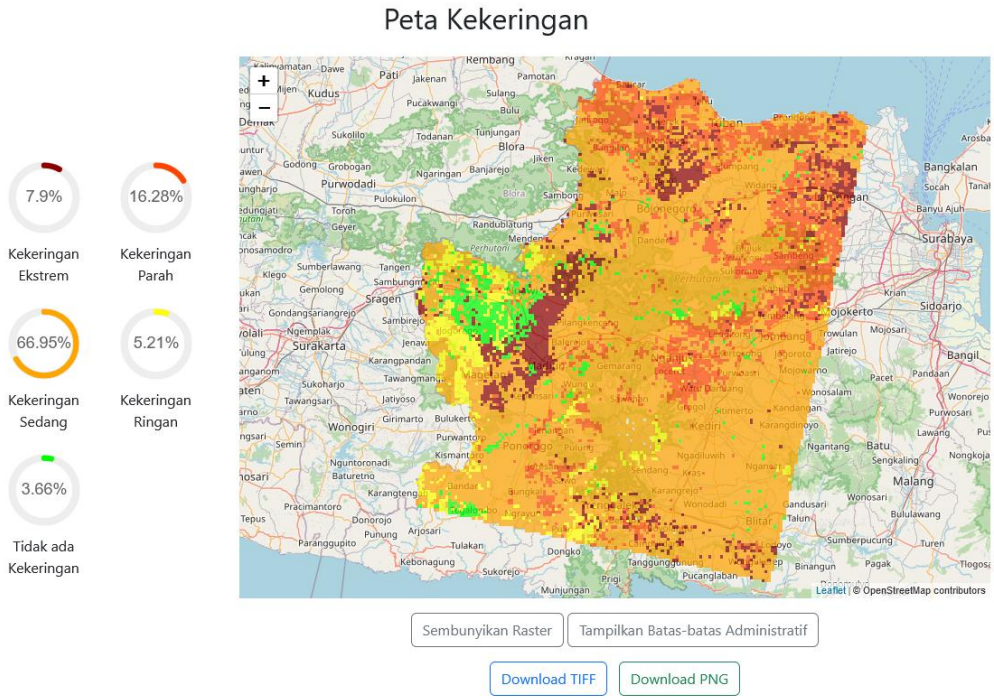

Gambar 4. 4 Tampilan Hasil Prediksi Klasifikasi Citra (Lanjutan)

Rata-Rata Index Berdasarkan Kategori Kekeringan

Kategori Kekeringan	NDVI	LST	SAVI	VCI	TCI	VHI	NST	SPI	DEM (Meter)
Kekeringan Ekstrem	0.4	32.04	0.26	46.79	19.08	32.93	0.63	-1.11	107.43 Meter
Kekeringan Parah	0.37	36.13	0.23	46.7	16.94	31.82	0.68	-0.93	98.29 Meter
Kekeringan Sedang	0.55	31.27	0.34	47.13	19.48	33.3	0.62	-1.06	222.88 Meter
Kekeringan Ringan	0.59	14.91	0.38	47.22	28.01	37.61	0.39	-1.2	433.42 Meter
Tidak ada Kekeringan	0.66	17.37	0.42	47.4	26.73	37.06	0.43	-1.2	131.69 Meter

Gambar 4. 5 Tampilan Hasil Prediksi Klasifikasi Citra (Lanjutan)

b) Tampilan Halaman Testing Data

Halaman testing data dirancang untuk menguji model yang telah dikembangkan. Bagian atas halaman ini menampilkan informasi mengenai judul penelitian dan identitas penulis. Proses pengunduhan citra pada halaman ini serupa dengan yang ada di halaman klasifikasi.

Di sisi kiri, terdapat kolom *input* untuk menentukan *path* dan *row* WRS, serta memilih bulan dan tahun. Berdasarkan *input* tersebut, citra raster akan diunduh dari Google Earth Engine. Di sisi kanan, tersedia peta pembagian WRS wilayah Jawa Timur yang dilengkapi dengan panduan untuk membantu pengguna memilih area yang akan diuji. Tampilan *input* halaman ini dapat dilihat pada Gambar 4.5.

Testing Model

Unduh Raster

Pilih WRS Path

Pilih WRS Path

Pilih WRS Row

Pilih WRS Row

Pilih Bulan

Pilih Bulan

Pilih Tahun

Pilih Tahun

Unduh

Informasi

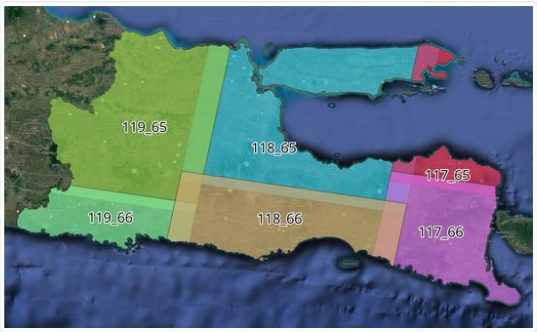

Sistem Referensi Dunia (WRS) adalah grid atau jaringan koordinat yang digunakan untuk menentukan lokasi citra satelit. Setiap area memiliki kombinasi unik **Path** (lintasan) dan **Row** (baris) yang mewakili lokasi geografis tertentu. Gunakan gambar peta Jawa Timur yang telah dibagi berdasarkan WRS untuk memilih lokasi analisis Anda.

- Lihat gambar peta Jawa Timur yang telah dibagi berdasarkan **Path** dan **Row**.
- Temukan wilayah yang ingin Anda analisis dengan mencocokkan lokasi di peta. Sebagai contoh, Surabaya terletak di wilayah **118_65**, sehingga Path-nya adalah **118** dan Row-nya adalah **65**.
- Tentukan waktu yang akan digunakan untuk analisis, seperti musim tertentu atau periode tertentu.
- Aplikasi akan mengunduh citra Landsat 8 dari Google Earth Engine sesuai dengan **Path**, **Row**, dan waktu yang Anda pilih.
- Jika citra tidak tersedia (karena tutupan awan tinggi atau faktor lain), coba pilih lokasi atau waktu yang berbeda.

Gambar 4. 6 Tampilan Halaman Testing

Setelah citra berhasil diunduh, citra tersebut beserta *metadata* terkait akan ditampilkan di halaman ini. Pengguna dapat melanjutkan dengan menekan tombol klasifikasi untuk memulai proses pengujian model. Hasil pengujian berupa gambar *ground truth*, hasil klasifikasi, serta evaluasi performa model akan ditampilkan secara lengkap. Tampilan hasil testing dapat dilihat pada Gambar 4.6, 4.7, 4.8, 4.9, dan 4.10.

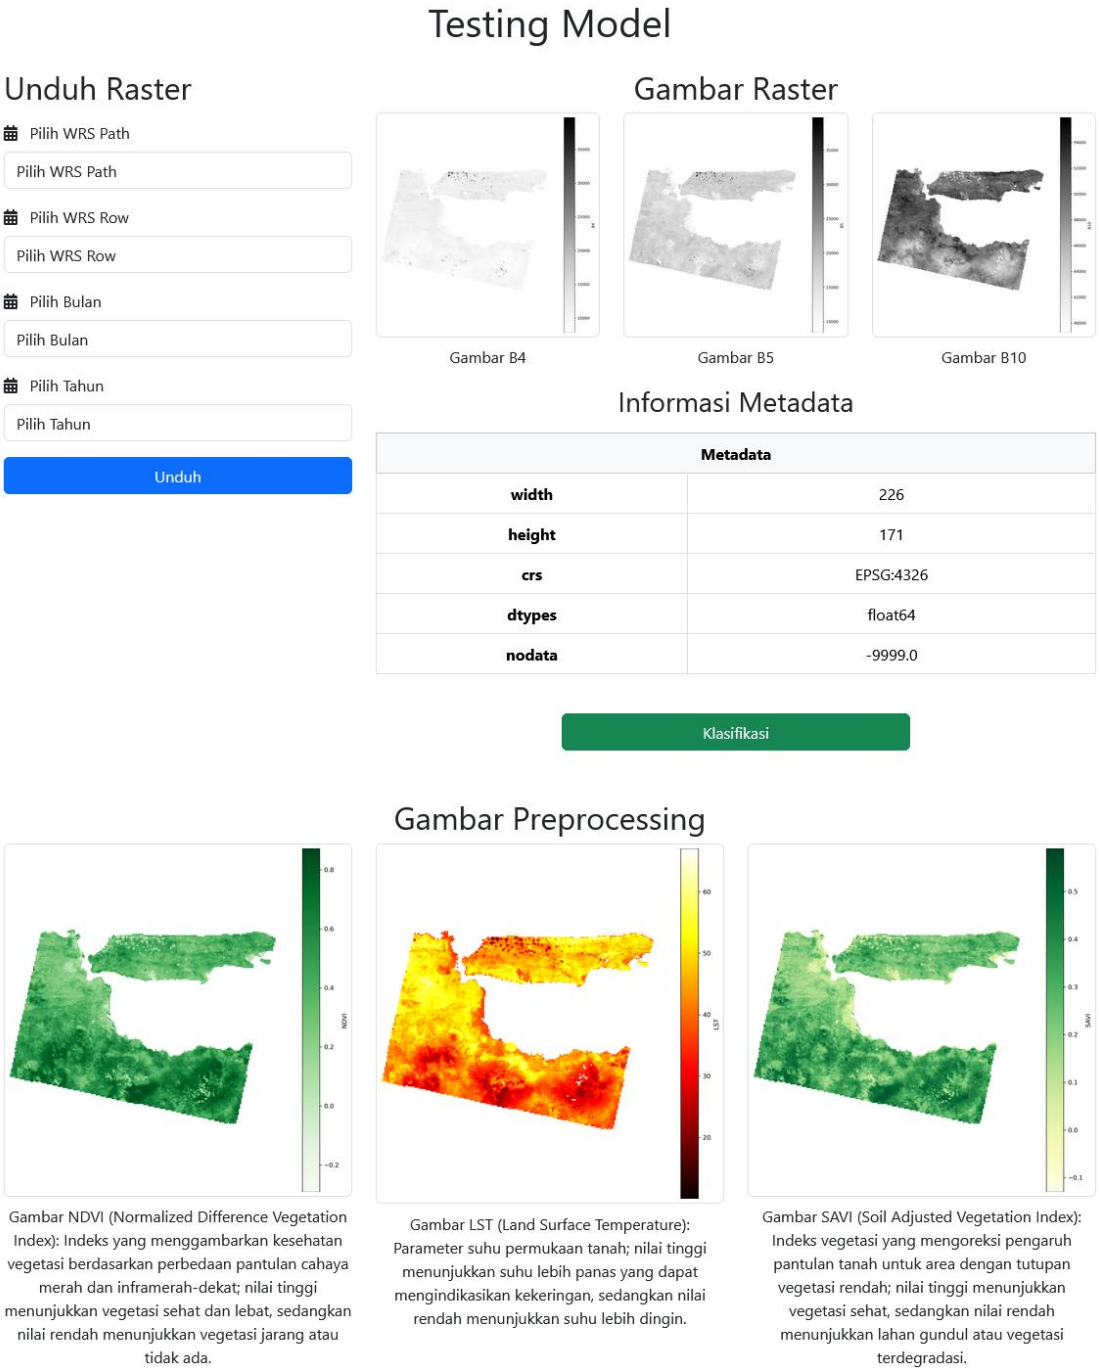

Gambar 4. 7 Tampilan Hasil Testing

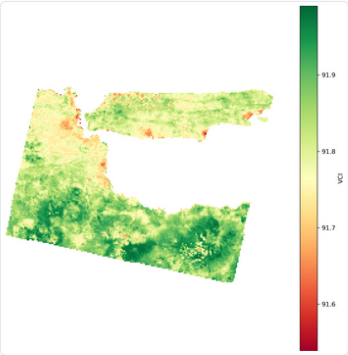

Gambar VCI (Vegetation Condition Index): Indeks yang membandingkan NDVI saat ini dengan nilai maksimum dan minimum historisnya; nilai tinggi menunjukkan kondisi vegetasi baik, sedangkan nilai rendah menunjukkan stres pada vegetasi akibat kekeringan.

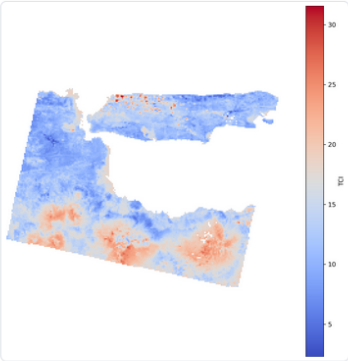

Gambar TCI (Temperature Condition Index): Indeks yang membandingkan suhu saat ini dengan nilai maksimum dan minimum historisnya; nilai tinggi menunjukkan suhu lebih dingin dan kondisi lebih baik, sedangkan nilai rendah menunjukkan suhu tinggi dan kondisi yang lebih kering.

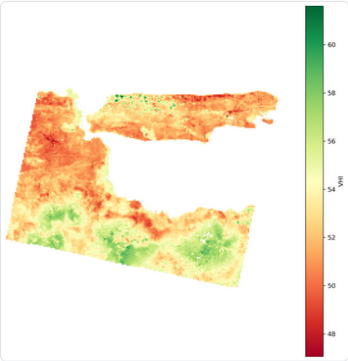

Gambar VHI (Vegetation Health Index): Indeks gabungan dari VCI dan TCI untuk menilai kesehatan vegetasi; nilai tinggi menunjukkan vegetasi dalam kondisi baik, sedangkan nilai rendah menunjukkan vegetasi tertekan akibat kekeringan.

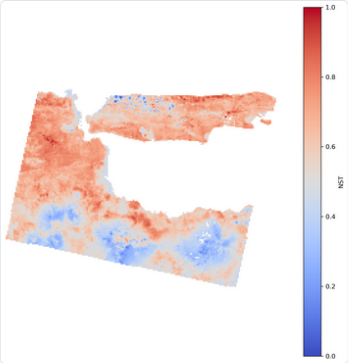

Gambar Normalize LST: Normalisasi suhu untuk mengurangi variabilitas; nilai tinggi menunjukkan suhu lebih tinggi dari rata-rata normal, sedangkan nilai rendah menunjukkan suhu lebih rendah dari rata-rata normal.

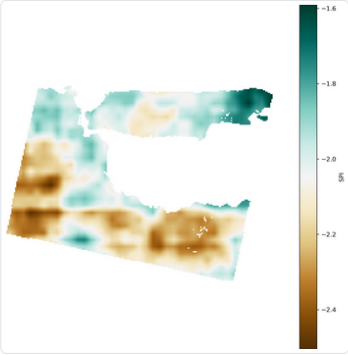

Gambar SPI (Standardized Precipitation Index): Indeks yang mengevaluasi tingkat kekeringan berdasarkan curah hujan; nilai tinggi menunjukkan curah hujan melimpah (basah), sedangkan nilai rendah menunjukkan defisit curah hujan (kekeringan).

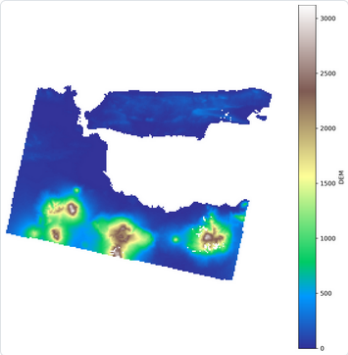

Gambar DEM (Digital Elevation Model): Representasi topografi permukaan bumi; nilai tinggi menunjukkan elevasi yang lebih tinggi seperti perbukitan atau pegunungan, sedangkan nilai rendah menunjukkan daerah dataran rendah yang lebih rentan terhadap kekeringan.

Gambar Klasifikasi

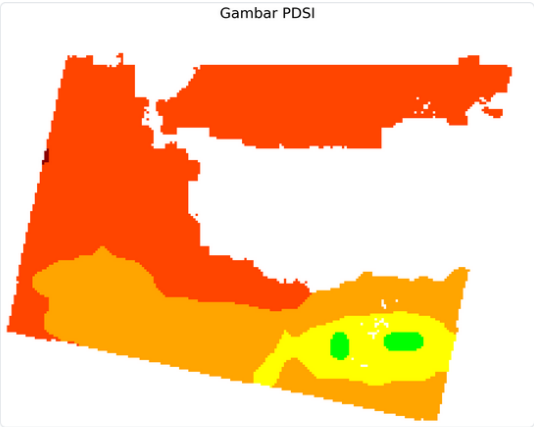

Gambar PDSI

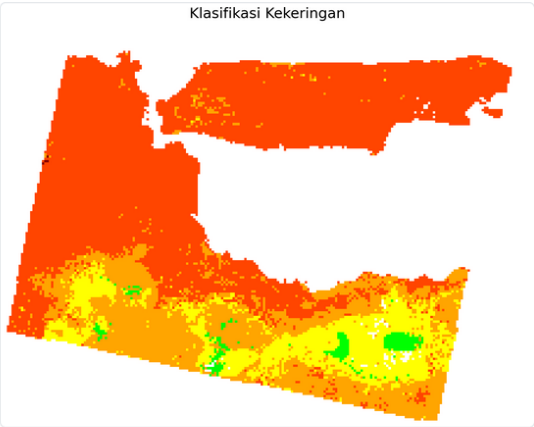

Gambar Klasifikasi

Gambar 4. 8 Tampilan Hasil Testing (Lanjutan)

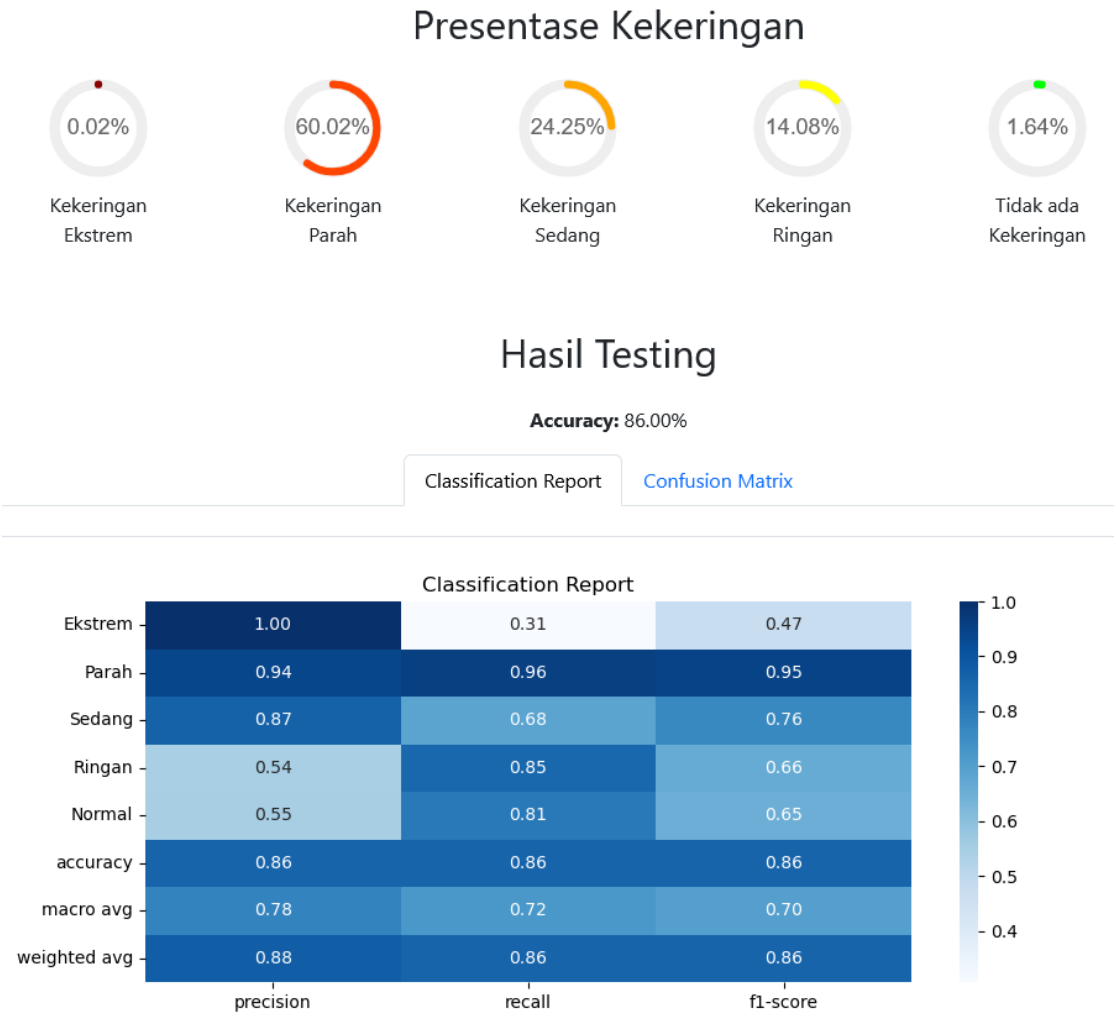

Gambar 4. 9 Tampilan Hasil Testing (Lanjutan)

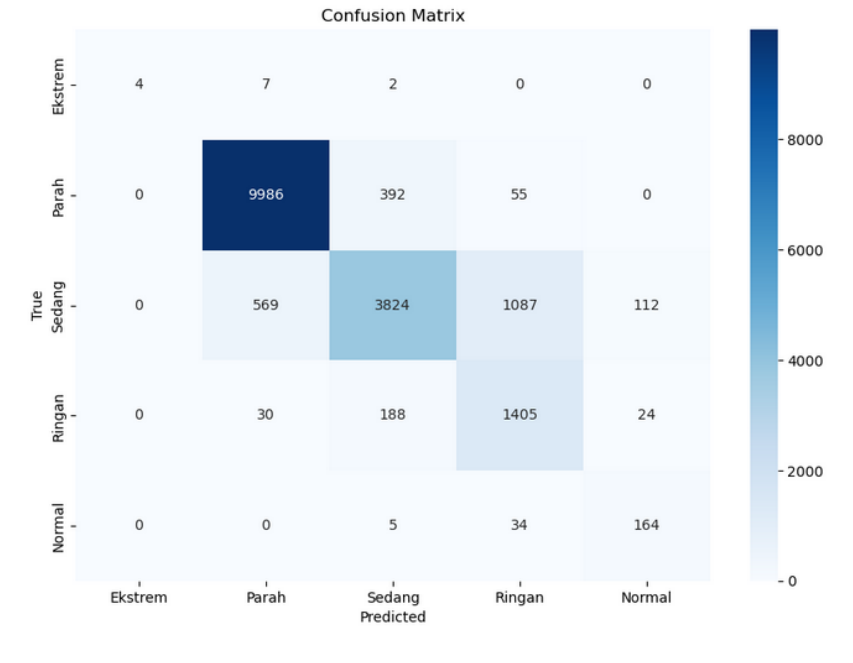

Gambar 4. 10 Tampilan Hasil Testing (Lanjutan)

4.2. Implementasi Model

4.2.1. Hasil pelatihan model

Bab ini menyajikan hasil penelitian yang diperoleh dari penerapan model *XGBoost* untuk analisis data citra raster. Agar model *XGBoost* dapat bekerja secara optimal, digunakan metode *Bayesian optimization* dalam penyesuaian *hyperparameter. Bayesian optimization* merupakan teknik pencarian *hyperparameter* yang memanfaatkan model *probabilistik* untuk mengevaluasi kombinasi parameter pada ruang *hyperparameter* tertentu. Metode ini memungkinkan pencarian parameter yang optimal secara efisien dengan mengeksplorasi ruang parameter yang lebih luas dalam waktu yang lebih singkat dibandingkan pendekatan konvensional seperti *GridSearchCV* (Bergstra & Bengio, 2012). Parameter yang disesuaikan melalui metode ini mencakup:

Tabel 4. 1 Daftar Parameter

Parameter	Type	Value	Logarithmic Scale
learning_rate	float	0.01 – 0.3	True
max_depth	int	4 – 15	False
n_estimators	int	100 – 500	False
gamma	float	0.1 – 10	True
subsample	float	0.5 – 1	False
colsample_bytree	float	0.5 – 1	False
min_child_weight	int	1 – 10	False

Melalui parameter pada tabel 4.1, dilakukan kombinasi untuk menentukan *best parameters* yang dapat dilihat pada Tabel 4.2 dan 4.3 sebagai berikut

Tabel 4. 2 Hasil *Bayesian Optimization*

No	colsample_bytree	gamma	learning_rate	max_depth	min_child_weight	n_estimators	subsample	accuracy
1	0.733896636	2.116598338	0.070766773	12	6	338	0.577753843	0.831959465
2	0.796251378	0.566196262	0.013216515	13	10	131	0.791322277	0.782438652
3	0.694472623	0.149311492	0.145127303	6	9	391	0.640828404	0.754839089
4	0.942350232	0.622854121	0.130324778	7	5	154	0.50806675	0.74024871
5	0.934428695	6.59349237	0.021104495	15	8	141	0.956714849	0.823588923
6	0.635949865	0.186974912	0.013400687	6	4	319	0.529692804	0.642375488
7	0.857067738	0.126886698	0.041188054	10	5	142	0.98074327	0.757202487
8	0.577355913	7.637959889	0.04350869	8	5	334	0.574284074	0.730978424
9	0.990340762	0.501213434	0.013460761	15	6	170	0.779875004	0.827789586
10	0.875215852	0.330844325	0.267335003	8	8	181	0.90898688	0.806713506
11	0.743458395	2.178348479	0.084993544	11	1	473	0.667780412	0.824499859
12	0.508452171	2.43072743	0.025815481	15	7	244	0.792510064	0.817068239
13	0.793523183	1.610116364	0.068910403	12	3	243	0.717375299	0.836974515
14	0.789879976	2.014152298	0.067992648	12	2	252	0.692225086	0.833344761
15	0.817418658	1.292963809	0.099914765	13	2	241	0.70893476	0.858169535
16	0.854037816	1.154155102	0.143900951	13	3	240	0.857969893	0.860337033
17	0.878345551	1.050076664	0.299393093	4	1	203	0.843047008	0.698902538
18	0.848755718	4.438343531	0.16801597	13	3	387	0.898204508	0.830609152
19	0.673662827	0.873625827	0.104821139	14	3	278	0.848326306	0.869920758
20	0.670132398	3.930877676	0.20680523	14	3	288	0.854493783	0.842223245
21	0.603997606	0.292389876	0.110132935	10	4	396	0.862468195	0.836852777
22	0.693217122	0.998997706	0.119211071	13	2	278	0.743994463	0.865108606
23	0.708910321	0.868129937	0.190393925	14	2	283	0.829220795	0.874387287
24	0.693940221	0.698204425	0.209000932	14	2	285	0.75491744	0.881830101
25	0.564321895	0.395806339	0.20588006	14	1	356	0.765143934	0.887484625

Tabel 4. 3 Hasil *Bayesian Optimization* (Lanjutan)

No	colsample_bytree	gamma	learning_rate	max_depth	min_child_weight	n_estimators	subsample	accuracy
26	0.535459298	0.243962645	0.200580142	14	1	366	0.765809573	0.88405497
27	0.505529523	0.255089806	0.237574263	11	1	441	0.756733043	0.870397916
28	0.551771971	0.100098333	0.209736406	15	1	358	0.633130657	0.88436981
29	0.544774326	0.101997581	0.168545614	15	1	361	0.662237559	0.884831575
30	0.582851756	0.103845289	0.167569934	15	1	424	0.624453877	0.892503873
31	0.600728273	0.408230885	0.083506756	11	1	433	0.607132265	0.849652067
32	0.560515836	0.107260079	0.258565052	15	1	357	0.62486069	0.891728667
33	0.631833144	0.100334389	0.16470565	15	2	426	0.568011058	0.890777151
34	0.64134062	0.182813826	0.266335702	15	2	433	0.565971993	0.890375555
35	0.635437675	0.171944471	0.288633257	15	4	487	0.56203312	0.890265011
36	0.631054739	0.137590765	0.253260301	13	2	427	0.604896198	0.887837246
37	0.601294316	0.186469079	0.152368747	15	10	459	0.54126747	0.888009358
38	0.649521069	0.131265992	0.138901524	12	2	410	0.59685645	0.874956797
39	0.586806717	0.220229957	0.054903493	4	4	497	0.509620823	0.656687409
40	0.522432317	0.15685734	0.240341262	14	6	450	0.552630783	0.881583826
41	0.616157404	0.117940151	0.168480278	9	3	411	0.625456247	0.836333641
42	0.652768626	0.180372552	0.295586186	15	4	496	0.569697784	0.89026781
43	0.723218076	0.19631917	0.25271199	15	2	472	0.583559728	0.893828999
44	0.718902867	0.120200373	0.247117758	15	2	469	0.520088936	0.892911065
45	0.768150664	0.116864644	0.125444451	14	9	463	0.514719577	0.886552699
46	0.778016078	0.280123552	0.214122723	15	9	319	0.692798078	0.894040291
47	0.721046479	0.142407298	0.025858583	15	2	472	0.530759835	0.871118549
48	0.755749961	0.101027524	0.1777596	15	1	109	0.592575899	0.880296481
49	0.569515216	0.219473667	0.236979415	12	5	414	0.663382495	0.883179015
50	0.664708196	0.146674672	0.144872712	5	7	315	0.646335588	0.7092013

Berdasarkan Tabel 4.2 dan 4.3, kombinasi parameter terbaik dengan skor tertinggi yang ditemukan adalah sebagai berikut: *learning_rate* sebesar 0.21412272292448714, *max_depth* sebesar 15, *n_estimators* sebanyak 319, *gamma* sebesar 0.280123551653284, *subsample* sebesar 0.6927980782054145, *colsample_bytree* sebesar 0.7780160775823342, dan *min_child_weight* sebesar 9. Dengan kombinasi parameter ini, model berhasil mencapai akurasi rata-rata sebesar 89.40%. Hal ini menunjukkan bahwa model mampu mengklasifikasikan bencana kekeringan dengan tingkat akurasi 89.40%. *Confusion matrix* yang dihasilkan dari kombinasi parameter tersebut ditampilkan sebagai berikut.

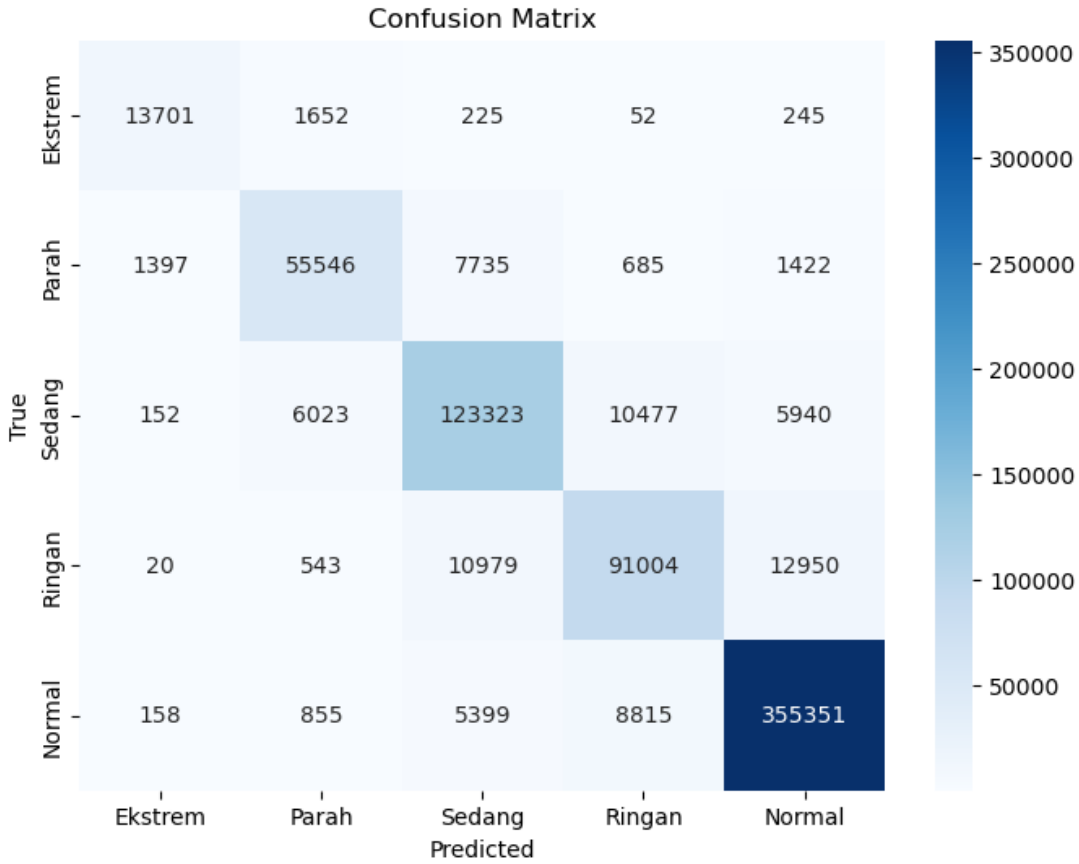

Gambar 4. 11 *Confusion Matrix*

Gambar 4.11 di atas menunjukkan hasil klasifikasi bencana kekeringan menggunakan metode *XGBoost*. Matriks ini menggambarkan performa model dalam mengklasifikasikan lima kategori kekeringan: kekeringan ekstrem, kekeringan parah, kekeringan sedang, kekeringan ringan, dan tidak kekeringan. Hasil terbaik terlihat pada kategori Normal, dengan 353,351 sampel diklasifikasikan dengan akurat, diikuti oleh kategori Sedang sebanyak 123,323 sampel. Hal ini menunjukkan bahwa model bekerja sangat baik dalam mengidentifikasi kondisi tanpa kekeringan dan tingkat kekeringan

sedang, yang mungkin merupakan kategori dengan jumlah data lebih banyak dalam dataset.

Namun, terdapat beberapa kesalahan dalam klasifikasi, terutama di kategori Ekstrem dan Parah, di mana model sering kali salah mengelompokkan sampel ke tingkat kekeringan yang lebih ringan. Contohnya, 1,652 sampel yang seharusnya termasuk kategori Ekstrem diklasifikasikan sebagai Parah, dan 7,735 sampel yang seharusnya Parah diklasifikasikan sebagai Sedang.

Secara keseluruhan, performa model menunjukkan akurasi yang tinggi untuk kategori dominan, tetapi memerlukan perbaikan untuk kategori dengan jumlah sampel lebih sedikit. Model tampaknya bias terhadap kategori dengan lebih banyak data, seperti Normal dan Sedang, yang terlihat dari dominasi jumlah prediksi benar di kategori ini. Penjelasan ini menggambarkan performa model dalam klasifikasi bencana kekeringan menggunakan citra satelit Landsat 8.

Tabel 4. 4 Nilai TP, TN, FP, dan FN

Label	TP	TN	FP	FN
Kekeringan Ekstrem	13701	697047	1727	2174
Kekeringan Parah	55546	625090	9073	11239
Kekeringan Sedang	123323	530695	24338	22592
Kekeringan Ringan	91004	565423	20029	24492
Tidak Kekeringan	355351	309813	20557	15227

Dengan demikian, selanjutnya dapat dilakukan perhitungan nilai *accuracy, precision, recall,* dan *f1- score* yang merupakan metode evaluasi dari *confussion matrix*. Berikut merupakan perhitungannya.

a) Kekeringan Ekstrem

$$Precision = \frac{TP}{TP+FP} \text{ x } 100\% = \frac{13701}{13701 + 1727} \text{ x } 100\% = 88.9\%$$

$$Recall = \frac{TP}{TP+FN} \text{ x } 100\% = \frac{13701}{13701 + 2174} \text{ x } 100\% = 86.4\%$$

$$F1\text{-}score = \frac{2\ x\ precision\ x\ recall}{precision + recall} \text{ x } 100\% = \frac{2\ x\ 0.889\ x\ 0.864}{0.889 + 0.864} \text{ x } 100\% = 87.4\%$$

b) Kekeringan Parah

$$Precision = \frac{TP}{TP+FP} \text{ x } 100\% = \frac{55546}{55546 + 1727} \text{ x } 100\% = 86.0\%$$

$$Recall = \frac{TP}{TP+FN} \text{ x } 100\% = \frac{55546}{55546 + 2174} \text{ x } 100\% = 83.1\%$$

$$F1\text{-}score = \frac{2\ x\ precision\ x\ recall}{precision + recall} \text{ x } 100\% = \frac{2\ x\ 0.860\ x\ 0.831}{0.860 + 0.831} \text{ x } 100\% = 84.5\%$$

c) Kekeringan Sedang

$$Precision = \frac{TP}{TP+FP} \text{ x } 100\% = \frac{123323}{123323 + 24338} \text{ x } 100\% = 83.4\%$$

$$Recall = \frac{TP}{TP+FN} \text{ x } 100\% = \frac{123323}{123323 + 22592} \text{ x } 100\% = 84.6\%$$

$$F1\text{-}score = \frac{2\ x\ precision\ x\ recall}{precision + recall} \text{ x } 100\% = \frac{2\ x\ 0.834\ x\ 0.846}{0.834 + 0.846} \text{ x } 100\% = 83.9\%$$

d) Kekeringan Ringan

$$Precision = \frac{TP}{TP+FP} \text{ x } 100\% = \frac{91004}{91004 + 20029} \text{ x } 100\% = 81.9\%$$

$$Recall = \frac{TP}{TP+FN} \text{ x } 100\% = \frac{91004}{91004 + 24492} \text{ x } 100\% = 78.9\%$$

$$F1\text{-}score = \frac{2\ x\ precision\ x\ recall}{precision + recall} \text{ x } 100\% = \frac{2\ x\ 0.819\ x\ 0.789}{0.819 + 0.789} \text{ x } 100\% = 80.4\%$$

e) Tidak Kekeringan

$$Precision = \frac{TP}{TP+FP} \text{ x } 100\% = \frac{355351}{355351 + 20557} \text{ x } 100\% = 94.6\%$$

$$Recall = \frac{TP}{TP+FN} \text{ x } 100\% = \frac{355351}{355351 + 15227} \text{ x } 100\% = 95.8\%$$

$$F1\text{-}score = \frac{2\ x\ precision\ x\ recall}{precision + recall} \text{ x } 100\% = \frac{2\ x\ 0.946\ x\ 0.958}{0.946 + 0.958} \text{ x } 100\% = 95.2\%$$

f) Accuracy

$$Accuracy = \frac{TP}{Total} \text{ x } 100\% = \frac{638925}{714649} = 89.40\%$$

4.2.2. Hasil pengujian model

Dalam penelitian ini, penulis memanfaatkan model *XGBoost* untuk mengklasifikasikan tingkat bencana kekeringan menggunakan citra satelit Landsat 8. Hasil klasifikasi divisualisasikan dalam bentuk peta yang menggambarkan distribusi bencana kekeringan di wilayah studi. Klasifikasi ini terdiri dari lima kategori kekeringan: kekeringan ekstrem, kekeringan parah, kekeringan sedang, kekeringan ringan, dan kondisi tanpa kekeringan. Setiap kategori direpresentasikan dengan warna tertentu pada peta, yaitu coklat untuk kekeringan ekstrem, merah untuk kekeringan parah, jingga untuk kekeringan sedang, kuning untuk kekeringan ringan, dan hijau untuk kondisi tanpa kekeringan. Gambar 4.12 menunjukkan hasil dari preprocessing, sedangkan Gambar 4.13 merupakan peta hasil klasifikasi bencana kekeringan yang diperoleh dari model yang telah dilatih dan diuji menggunakan data raster.

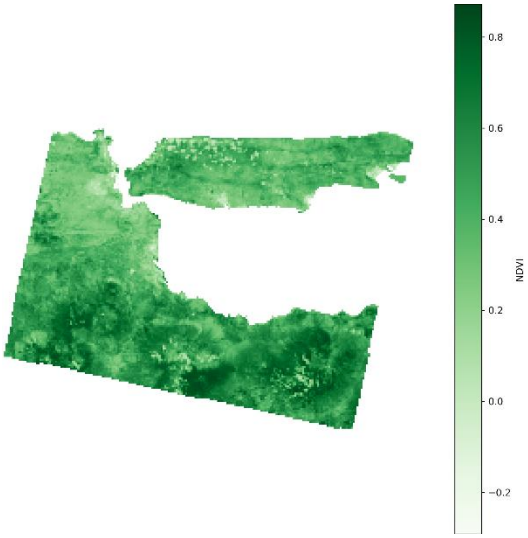

(a) NDVI

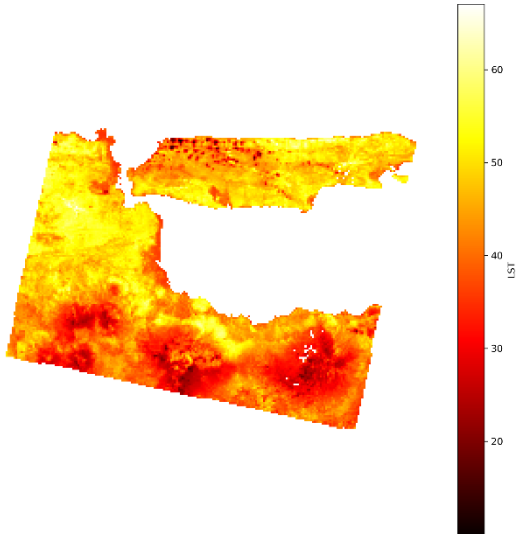

(b) LST

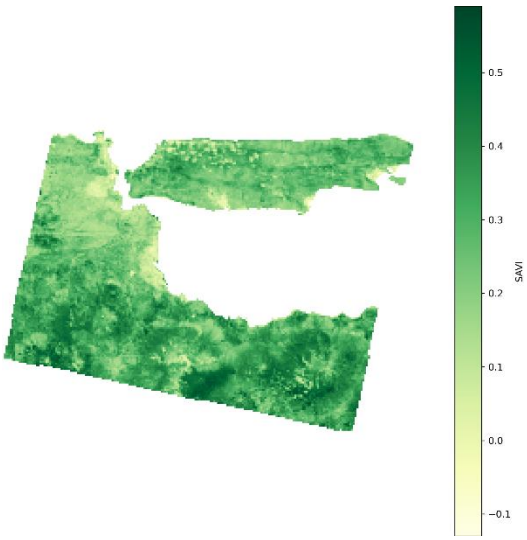

(c) SAVI

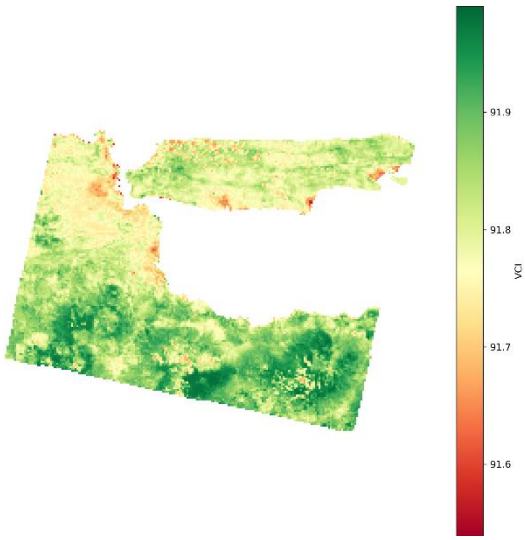

(d) VCI

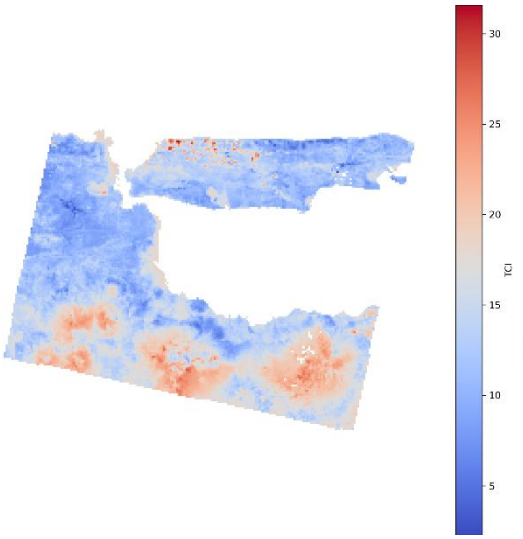

(e) TCI

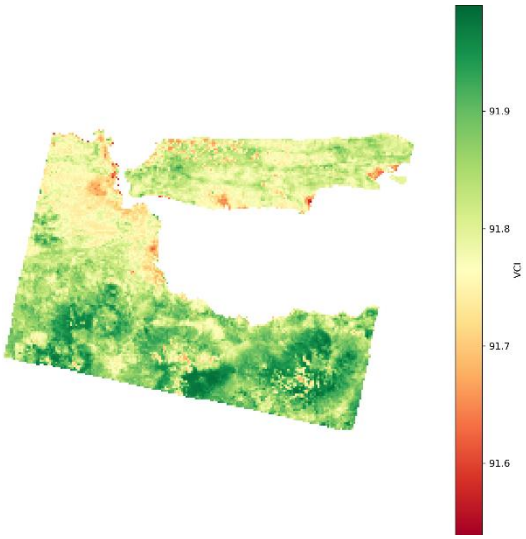

(f) VHI

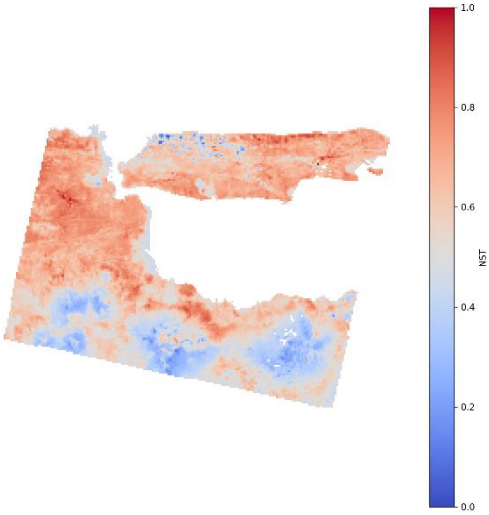

(g) LST Normalization

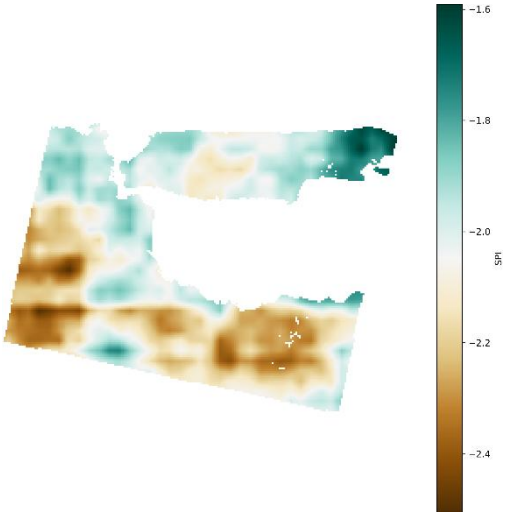

(h) SPI

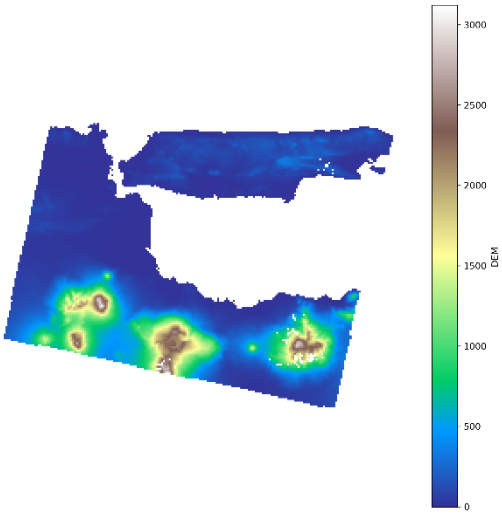

(i) DEM

Gambar 4. 12 Hasil Preprocessing

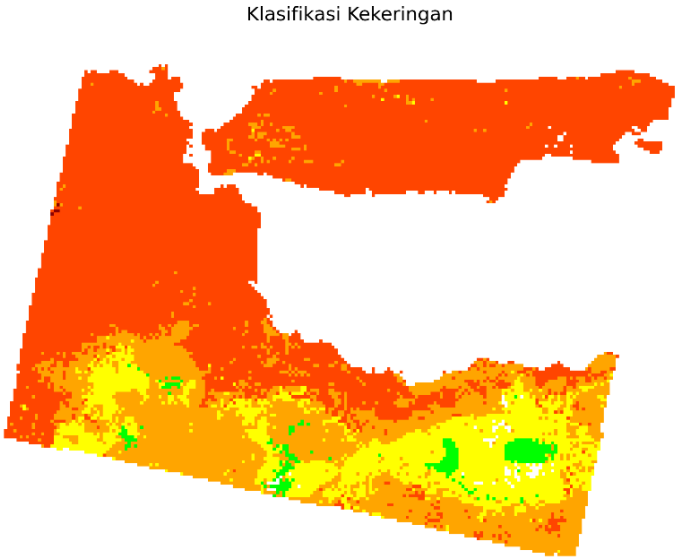

Gambar 4. 13 Gambar Hasil Klasifikasi

Peta hasil klasifikasi bencana kekeringan menggunakan model *XGBoost* menunjukkan distribusi berbagai jenis bencana kekeringan di wilayah studi. Berdasarkan hasil klasifikasi, berikut adalah penjelasan mengenai setiap kelas bencana kekeringan yang diidentifikasi dalam peta:

a. Tidak kekeringan (hijau)

   Area berwarna hijau pada peta menunjukkan wilayah yang tidak mengalami kekeringan, mencakup 1,64% dari total area penelitian. Lokasi ini tersebar di beberapa bagian wilayah studi, terutama di daerah yang kemungkinan merupakan kawasan pegunungan.

b. Kekeringan ringan (kuning)

   Area berwarna kuning mengindikasikan wilayah dengan kekeringan ringan, yang mencakup 14,08% dari total area. Kelas ini menjadi salah satu yang dominan, terdistribusi di bagian bawah peta, termasuk wilayah kehutanan dan pegunungan.

c. Kekeringan sedang (jingga)

   Area berwarna jingga merepresentasikan kekeringan tingkat sedang, yang mencakup 24,25% dari total wilayah studi. Kekeringan sedang umumnya ditemukan di sekitar kawasan perbukitan tinggi dan daerah kehutanan.

d. Kekeringan parah (merah)

   Area berwarna merah menunjukkan wilayah dengan kekeringan parah, yang mencakup 60,02% dari total area. Wilayah ini tersebar luas, termasuk daerah dataran rendah dan kawasan perkotaan.

e. Kekeringan ekstrem (coklat)

   Area berwarna coklat menunjukkan wilayah dengan kekeringan ekstrem, mencakup hanya 0,02% dari total area. Wilayah ini sangat kecil dan hanya terdiri dari beberapa piksel pada peta.

Hasil klasifikasi ini menunjukkan dominasi kekeringan parah di wilayah studi, diikuti oleh kekeringan sedang dan kekeringan ringan. Distribusi persentase ini memberikan gambaran jelas mengenai proporsi dan penyebaran setiap kelas kekeringan, yang dapat menjadi dasar untuk analisis lebih lanjut dan pengembangan strategi mitigasi dampak kekeringan.

Tabel 4. 5 Hasil prediksi benar dan salah

Gambar Piksel	Predicted Output	Actual Output
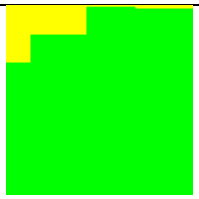	Tidak kekeringan	Tidak kekeringan
	Tidak kekeringan	Tidak kekeringan
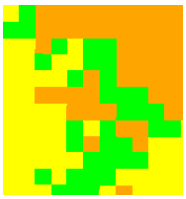	Tidak kekeringan	Kekeringan sedang
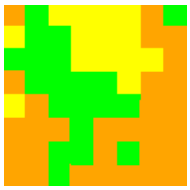	Tidak kekeringan	Kekeringan sedang
	Kekeringan ringan	Kekeringan ringan
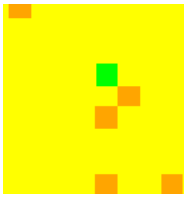	Kekeringan ringan	Kekeringan ringan
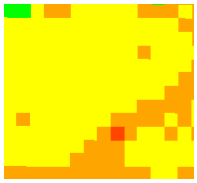	Kekeringan ringan	Kekeringan sedang
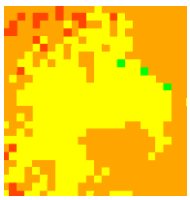	Kekeringan ringan	Kekeringan sedang

	Kekeringan sedang	Kekeringan sedang
	Kekeringan sedang	Kekeringan sedang
	Kekeringan sedang	Kekeringan parah
	Kekeringan sedang	Kekeringan parah
	Kekeringan parah	Kekeringan parah
	Kekeringan parah	Kekeringan parah
	Kekeringan parah	Kekeringan sedang
	Kekeringan parah	Kekeringan ekstrem
	Kekeringan ekstrem	Kekeringan ekstrem

4.3. Analisis Hasil

Untuk menganalisis hasil klasifikasi secara mendalam, penulis membandingkan dua jenis visualisasi utama: citra raster PDSI sebagai target klasifikasi, dan citra hasil klasifikasi yang telah diberi *colormap* (cmap). Citra raster PDSI berfungsi sebagai acuan, sedangkan citra hasil klasifikasi dengan cmap memberikan representasi yang lebih terorganisir mengenai berbagai jenis bencana kekeringan di wilayah studi. Tujuan analisis ini adalah untuk menilai tingkat akurasi model klasifikasi sekaligus memahami pola distribusi spasial dari setiap kelas bencana kekeringan. Melalui perbandingan kedua visualisasi tersebut, diharapkan dapat diidentifikasi area dengan klasifikasi yang akurat serta area yang memerlukan peningkatan lebih lanjut. Gambar 4.14 menunjukkan citra PDSI bersama dengan peta hasil klasifikasi bencana kekeringan yang diperoleh dari model yang telah dilatih dan diuji menggunakan data raster.

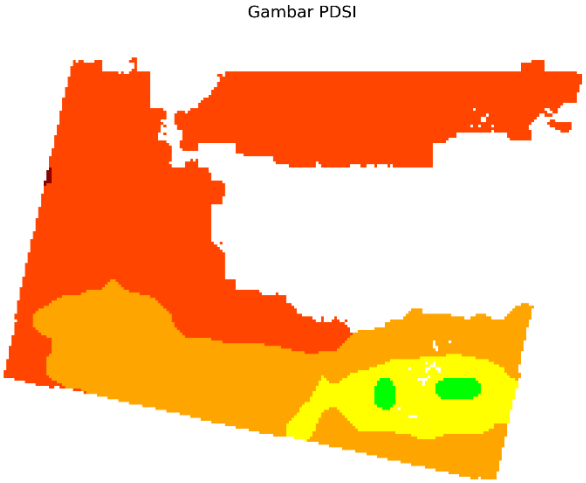

(a) Gambar PDSI

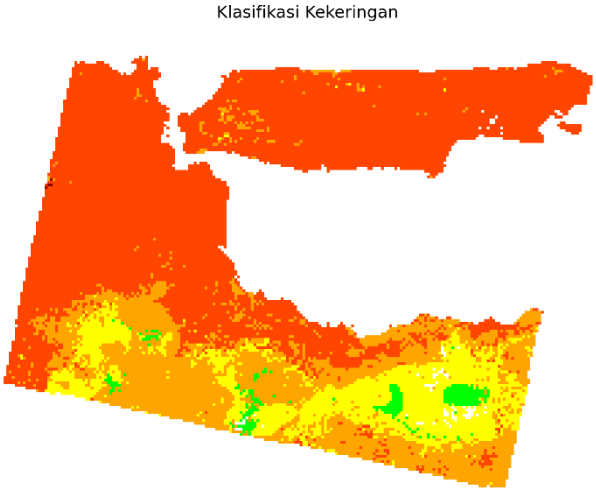

(b) Gambar Hasil Klasifikasi

Gambar 4. 14 Gambar Perbandingan

4.3.1. Analisis hasil tidak kekeringan

Hasil klasifikasi untuk kelas tidak kekeringan dibandingkan dengan citra raster PDSI untuk menilai ketepatan dan akurasi model dalam mendeteksi wilayah yang tidak mengalami kekeringan.

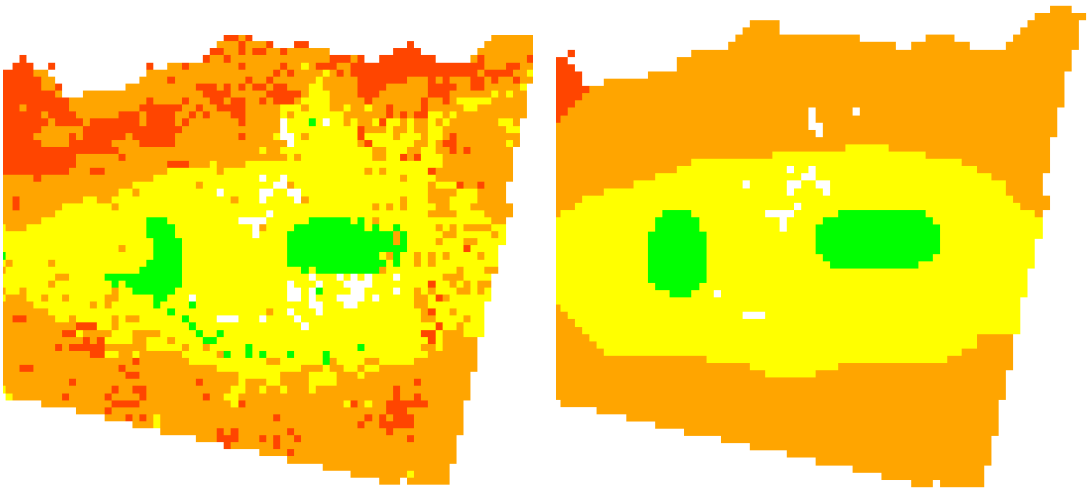

(a) Hasil Klasifikasi Tidak Kekeringan (b) Citra Raster PDSI

Gambar 4. 15 Hasil Peta Bencana Kekeringan Tidak Kekeringan

Pada Gambar 4.15 di atas, panel (a) menampilkan hasil klasifikasi kekeringan menggunakan model *XGBoost*, sedangkan panel (b) menunjukkan citra raster PDSI. Area berwarna hijau merepresentasikan wilayah yang diidentifikasi sebagai tidak kekeringan baik oleh model maupun oleh citra PDSI.

Hasil klasifikasi menunjukkan bahwa model *XGBoost* memiliki performa yang cukup baik dalam mengenali kelas tidak kekeringan (Normal), meskipun masih terdapat keterbatasan. *Precision* untuk kelas ini tercatat sebesar 0.55, yang berarti hanya 55% dari prediksi model yang menyatakan "tidak kekeringan" benar-benar sesuai dengan kondisi sebenarnya. Namun, nilai *recall* yang mencapai 0.81 menunjukkan bahwa sebagian besar area "tidak kekeringan" berhasil diidentifikasi oleh model. Nilai *F1-score* sebesar 0.65 merepresentasikan keseimbangan antara *precision* dan *recall*, meskipun *precision* yang rendah menjadi faktor utama yang mempengaruhi performa model dalam kelas ini.

Kemampuan model *XGBoost* dalam mengenali kelas "tidak kekeringan" didukung oleh pemanfaatan fitur-fitur seperti NDVI, LST, SAVI, VCI, TCI, VHI, SPI, dan DEM. Indeks vegetasi seperti NDVI dan SAVI membantu membedakan area tidak kekeringan melalui nilai vegetasi yang tinggi, sementara parameter suhu seperti LST dan LST

Normalization memberikan informasi penting terkait kondisi panas permukaan yang lebih stabil di area "tidak kekeringan". Selain itu, penggunaan SPI sebagai indikator curah hujan dan DEM untuk topografi mendukung deteksi area tanpa kekeringan dengan lebih akurat. Namun, nilai *precision* yang rendah menunjukkan adanya kesalahan prediksi, kemungkinan disebabkan oleh kemiripan fitur dengan kelas lainnya seperti Ringan atau Sedang.

4.3.2. Analisis hasil kekeringan ringan

Hasil klasifikasi untuk kelas kekeringan ringan dibandingkan dengan citra raster PDSI untuk menilai ketepatan dan akurasi model dalam mendeteksi wilayah yang mengalami kekeringan ringan. Area berwarna kuning merepresentasikan wilayah yang diidentifikasi sebagai kekeringan ringan baik oleh model maupun oleh citra PDSI.

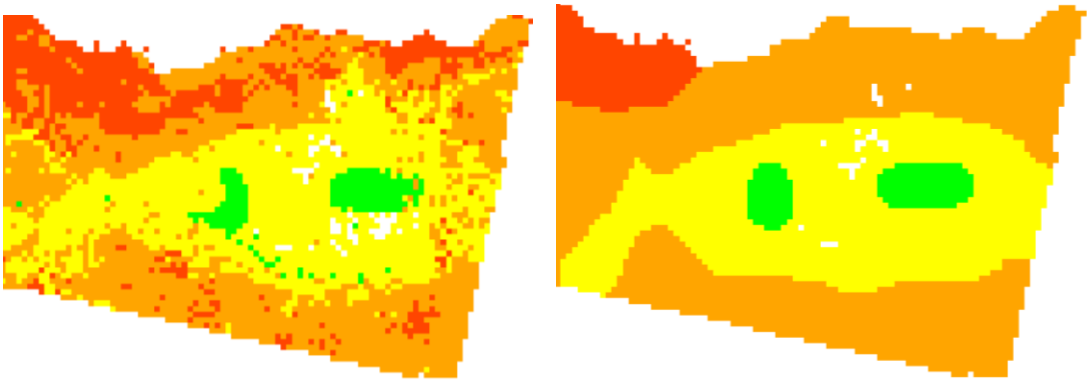

(a) Hasil Klasifikasi Kekeringan Ringan (b) Citra Raster PDSI

Gambar 4. 16 Hasil Peta Bencana Kekeringan Ringan

Hasil klasifikasi untuk kategori kekeringan ringan menunjukkan performa model *XGBoost* yang cukup baik dalam mendeteksi area kekeringan ringan, meskipun terdapat beberapa kelemahan. Nilai *recall* sebesar 0.85 mengindikasikan bahwa model mampu mengenali sebagian besar area yang benar-benar termasuk dalam kategori Ringan. Namun, nilai *precision* yang lebih rendah, yaitu 0.54, menunjukkan bahwa terdapat kesalahan prediksi di mana area dari kelas lain sering diklasifikasikan sebagai Ringan. Nilai *F1-score* sebesar 0.66 mencerminkan ketidakseimbangan antara *precision* dan *recall* dalam performa model pada kategori ini.

Kemampuan model untuk mengenali kategori kekeringan ringan dipengaruhi oleh kompleksitas distribusi spasial kekeringan ringan, yang mungkin memiliki karakteristik mirip dengan kelas Sedang atau Normal. Penggunaan fitur-fitur seperti NDVI, LST, VCI, dan SPI membantu model dalam membedakan tingkat kekeringan, namun tumpang tindih nilai antar kelas membuat klasifikasi menjadi lebih sulit.

4.3.3. Analisis hasil kekeringan sedang

kekeringan sedang ditandai dengan warna jingga pada hasil klasifikasi menunjukkan area yang dikenali sebagai kekeringan sedang oleh model.

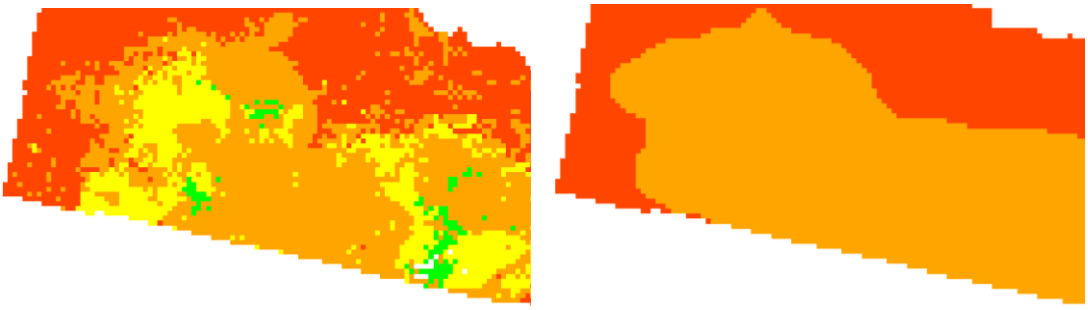

(a) Hasil Klasifikasi Kekeringan Sedang (b) Citra Raster PDSI

Gambar 4. 17 Hasil Peta Bencana Kekeringan Sedang

Hasil klasifikasi untuk kategori Sedang menunjukkan performa model *XGBoost* yang cukup baik dengan beberapa area perbaikan. Nilai *precision* sebesar 0.87 menunjukkan bahwa sebagian besar area yang diprediksi sebagai Sedang memang benar-benar termasuk dalam kategori tersebut. Namun, *recall* yang lebih rendah (0.68) mengindikasikan bahwa model tidak sepenuhnya dapat menangkap semua area yang sebenarnya termasuk dalam kategori Sedang, sehingga ada sebagian area yang tidak terdeteksi dengan baik. Nilai *F1-score* yang mencapai 0.76 mencerminkan adanya keseimbangan yang cukup baik antara *precision* dan *recall*, meskipun masih ada ruang untuk perbaikan.

Kemampuan model untuk mengenali kategori Sedang didukung oleh fitur-fitur yang relevan seperti SAVI, VCI, dan SPI, yang memberikan informasi tentang kelembaban dan kondisi vegetasi yang mendukung dalam membedakan tingkat kekeringan. Namun, perbedaan yang tidak terlalu jelas antara kategori Sedang dan kategori lain seperti Ringan atau Parah membuat klasifikasi menjadi lebih menantang, yang tercermin dalam nilai recall yang lebih rendah.

4.3.4. Analisis hasil kekeringan parah

kekeringan parah ditandai dengan warna jingga pada hasil klasifikasi menunjukkan area yang dikenali sebagai kekeringan parah oleh model.

(a) Hasil Klasifikasi Kekeringan

(b) Citra Raster PDSI

Gambar 4. 18 Hasil Peta Bencana Kekeringan Parah

Hasil klasifikasi untuk kategori Parah menunjukkan performa yang sangat baik dari model *XGBoost* dalam mendeteksi area kekeringan parah. Nilai *precision* yang tinggi (0.94) mengindikasikan bahwa sebagian besar area yang diprediksi sebagai Parah memang benar-benar termasuk dalam kategori tersebut, dengan sedikit kesalahan prediksi. Selain itu, nilai *recall* yang sangat baik (0.96) menunjukkan bahwa model mampu menangkap hampir semua area yang sebenarnya berada dalam kategori Parah, dengan tingkat deteksi yang sangat tinggi. *F1-score* yang mencapai 0.95 menandakan keseimbangan yang sangat baik antara *precision* dan *recall* pada kategori ini.

Kemampuan model untuk mengenali kategori Parah sangat didukung oleh indeks spektral seperti VCI, NDVI, dan SAVI, yang memberikan informasi mendalam tentang kondisi vegetasi dan kelembaban yang relevan dengan tingkat kekeringan parah. Indeks-indeks ini sangat berguna dalam membedakan daerah dengan kekeringan yang parah, karena mereka sensitif terhadap perubahan drastis dalam vegetasi dan suhu permukaan tanah. Penggunaan fitur-fitur ini membantu model untuk lebih akurat dalam mengklasifikasikan area dengan kondisi kekeringan parah, yang tercermin dalam tingginya nilai *precision*, *recall*, dan *F1-score* pada kategori ini.

4.3.5. Analisis hasil kekeringan ekstrem

kekeringan ekstrem ditandai dengan warna jingga pada hasil klasifikasi menunjukkan area yang dikenali sebagai kekeringan ekstrem oleh model.

(a) Hasil Klasifikasi Kekeringan Ekstrem (b) Citra Raster PDSI

Gambar 4. 19 Hasil Peta Bencana Kekeringan Ekstrem

Hasil klasifikasi untuk kategori Ekstrem menunjukkan bahwa model *XGBoost* memiliki kemampuan yang sangat baik dalam mendeteksi area dengan kekeringan ekstrem, meskipun ada beberapa tantangan. Nilai *precision* yang sempurna (1.00) mengindikasikan bahwa setiap area yang diprediksi sebagai Ekstrem benar-benar sesuai dengan kategori tersebut, tanpa adanya kesalahan prediksi. Namun, *recall* yang relatif rendah (0.31) menunjukkan bahwa model kesulitan dalam menangkap sebagian besar area yang sebenarnya termasuk dalam kategori Ekstrem, mengakibatkan banyak area ekstrem yang tidak terdeteksi. Nilai *F1-score* yang lebih rendah (0.47) mencerminkan ketidakseimbangan antara *precision* dan *recall*, di mana meskipun prediksi yang benar sangat akurat, namun ketidakmampuan model untuk mendeteksi banyak area ekstrem membuat hasil keseluruhan tidak seimbang.

Kemampuan model untuk mengenali kategori Ekstrem dipengaruhi oleh distribusi spasial yang sangat terbatas dan jarangnya kejadian kekeringan ekstrem dalam data, yang menyebabkan kesulitan dalam pengenalan model. Tantangan utamanya adalah kurangnya data yang cukup representatif untuk kategori ini.

BAB 5

KESIMPULAN DAN SARAN

5.1.Kesimpulan

Kesimpulan dari penelitian klasifikasi tutupan lahan menggunakan citra satelit resolusi tinggi dengan metode *XGBoost* adalah sebagai berikut:

1. Hasil klasifikasi menunjukkan bahwa model *XGBoost* menunjukkan performa yang sangat baik dalam mengenali berbagai kategori bencana kekeringan, dengan tingkat akurasi keseluruhan mencapai 89,4%. Angka ini menunjukkan kemampuan model dalam memetakan area dengan berbagai tingkat kekeringan dengan cukup tepat, mengindikasikan bahwa model *XGBoost* efektif dalam mengklasifikasikan bencana kekeringan berdasarkan data citra satelit.
2. Dalam penelitian ini, citra raster yang digunakan untuk klasifikasi diperoleh dari Band 4, Band 5, dan Band 10 pada citra satelit Landsat 8. Pemilihan band-band ini didasarkan pada peranannya dalam perhitungan beberapa indeks yang relevan untuk klasifikasi bencana kekeringan. Band 4 (red), Band 5 (near infrared), dan Band 10 (thermal infrared 1) masing-masing menyimpan informasi yang sangat berguna untuk analisis vegetasi, kelembapan tanah, dan suhu permukaan, yang merupakan parameter kunci dalam mendeteksi dan mengklasifikasikan bencana kekeringan.
3. Perhitungan berbagai indeks spektral dari data citra raster, seperti NDVI, LST, SAVI, VCI, TCI, VHI, dan LST *Normalization*, memberikan informasi yang sangat penting dalam mengidentifikasi kondisi kekeringan. NDVI dan SAVI memberikan gambaran tentang kesehatan dan distribusi vegetasi, sedangkan LST dan LST *Normalization* memberi indikasi suhu permukaan yang dapat menunjukkan tingkat kekeringan. Indeks seperti VCI, TCI, dan VHI menggambarkan kelembapan tanah dan kondisi vegetasi yang berkaitan langsung dengan bencana kekeringan. Kombinasi dari berbagai indeks ini memberikan gambaran yang komprehensif tentang keadaan lingkungan, yang sangat mendukung model *XGBoost* dalam melakukan klasifikasi dengan akurasi tinggi.

4. Penggunaan *Standardized Precipitation Index* (SPI) dalam klasifikasi bencana kekeringan terbukti sangat membantu dalam meningkatkan kemampuan model dalam mengidentifikasi area dengan kondisi kekeringan. SPI efektif dalam mendeteksi tingkat kekeringan berdasarkan perbandingan curah hujan aktual dengan rata-rata historisnya, memberikan indikasi yang jelas mengenai kondisi kelembaban tanah dan kekeringan meteorologis. Dengan memasukkan SPI sebagai fitur dalam model, dapat diperoleh informasi yang lebih akurat terkait kondisi kekeringan, terutama untuk mendeteksi wilayah yang menghadapi kekeringan ekstrem atau parah.
5. Penggunaan *Digital Elevation Model* (DEM) berkontribusi dalam klasifikasi bencana kekeringan dengan memberikan informasi tentang elevasi permukaan tanah. DEM membantu model dalam memetakan daerah yang mungkin lebih rentan terhadap kekeringan berdasarkan topografi, seperti wilayah dataran rendah yang lebih cepat mengalami kekeringan dibandingkan daerah yang lebih tinggi. DEM dapat memperbaiki klasifikasi dengan memberi wawasan tentang drainase permukaan dan potensi akumulasi air.

5.2.Saran

Saran yang dapat diberikan oleh peneliti selanjutnya adalah:

1. Menggunakan indeks kekeringan tambahan, seperti *Normalized Multi-band Drought Index* (NMDI) atau *Standardized Precipitation Evapotranspiration Index* (SPEI). Indeks ini dapat memberikan wawasan lebih dalam tentang kondisi tanah dan atmosfer yang memengaruhi tingkat kekeringan, melengkapi indeks yang sudah digunakan seperti SPI dan VHI.
2. Menggunakan data sosial-ekonomi, seperti distribusi populasi atau pola penggunaan lahan, untuk mengevaluasi dampak kekeringan secara holistik dan mendukung pengambilan keputusan yang lebih baik.
3. Penelitian dapat menambahkan parameter topografi lain seperti *slope*, *curvature*, atau *aspect*, yang dapat membantu memahami bagaimana kekeringan dipengaruhi oleh karakteristik geografis lokal selain DEM yang sudah digunakan.

DAFTAR PUSTAKA

Aksoy, S., Gorucu, O., & Sertel, E. (2019). 2019 the Eighth International Conference on Agro-Geoinformatics : July 16-19, Istanbul, Turkey. *8th International Conference on Agro-Geoinformatics (Agro-Geoinformatics)*, 1–6.

Avdan, U., & Jovanovska, G. (2016). Algorithm for automated mapping of land surface temperature using LANDSAT 8 satellite data. *Journal of Sensors*, *2016*. https://doi.org/10.1155/2016/1480307

Brown, E. (2016). *Learning JavaScript: Add Sparkle and Life to Your Web Pages*.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, *13-17-Augu*, 785–794. https://doi.org/10.1145/2939672.2939785

European Comission. (2020). Standardized Precipitation Index (SPI). *Copernicus European Drought Observatory (EDO)*, 1–5. https://edo.jrc.ec.europa.eu/

Flanagan, D. (2020). *JavaScript: The Definitive Guide: The Definitive Guide*. https://books.google.de/books/about/JavaScript_The_Definitive_Guide.html?id=2weL0iAfrEMC&pgis=1

Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., & Moore, R. (2017). Google Earth Engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*, *202*(2016), 18–27. https://doi.org/10.1016/j.rse.2017.06.031

Grinberg, M. (2018). Flask Web Development: Developing Web Applications with Python - Miguel Grinberg - Google Books. In *Google Books*.

Guth, P. L., Van Niekerk, A., Grohmann, C. H., Muller, J. P., Hawker, L., Florinsky, I. V., Gesch, D., Reuter, H. I., Herrera-Cruz, V., Riazanoff, S., López-Vázquez, C., Carabajal, C. C., Albinet, C., & Strobl, P. (2021). Digital elevation models: Terminology and definitions. *Remote Sensing*, *13*(18), 1–19. https://doi.org/10.3390/rs13183581

Haile, G. G., Tang, Q., Li, W., Liu, X., & Zhang, X. (2020). Drought: Progress in broadening its understanding. *Wiley Interdisciplinary Reviews: Water*, *7*(2), 1–25. https://doi.org/10.1002/WAT2.1407

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., … Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, *585*(7825), 357–362. https://doi.org/10.1038/s41586-020-2649-2

Hutete A.R. (1988). A Soil-Adjusted Vegetation Index (SAVI). *Remote Sensing of Environment*, *25*(1), 395–309.

Idris, N., Mohd Foozy, C. F., & Shamala, P. (2021). A Generic Review of Web Technology: DJango and Flask. *International Journal of Advanced Science Computing and Engineering*, *2*(1), 34–40. https://doi.org/10.62527/ijasce.2.1.29

Karnieli, A., Agam, N., Pinker, R. T., Anderson, M., Imhoff, M. L., Gutman, G. G., Panov, N., & Goldberg, A. (2010). Use of NDVI and land surface temperature for drought assessment: Merits and limitations. *Journal of Climate*, *23*(3), 618–633. https://doi.org/10.1175/2009JCLI2900.1

Kogan, F. N. (1990). Remote sensing of weather impacts on vegetation in non-homogeneous areas. *International Journal of Remote Sensing*, *11*(8), 1405–1419. https://doi.org/10.1080/01431169008955102

Kogan, F. N. (1995). Application of vegetation index and brightness temperature for drought detection. *Advances in Space Research*, *15*(11), 91–100. https://doi.org/10.1016/0273-1177(95)00079-T

Li, P., Jiang, L., & Feng, Z. (2013). Cross-comparison of vegetation indices derived from landsat-7 enhanced thematic mapper plus (ETM+) and landsat-8 operational land imager (OLI) sensors. *Remote Sensing*, *6*(1), 310–329. https://doi.org/10.3390/rs6010310

Lillesand, T. M., & Kiefer, R. W. (1979). Remote sensing and image interpretation. In *Remote sensing and image interpretation.* (Vol. 7, Issue 2). https://doi.org/10.2307/634969

Liu, W. T., & Kogan, F. N. (1996). Monitoring regional drought using the vegetation condition index. *International Journal of Remote Sensing*, *17*(14), 2761–2782. https://doi.org/10.1080/01431169608949106

Liu, Y., Ren, L., Ma, M., Yang, X., Yuan, F., & Jiang, S. (2016). An insight into the Palmer drought mechanism based indices: comprehensive comparison of their strengths and limitations. *Stochastic Environmental Research and Risk*

Assessment, *30*(1), 119–136. https://doi.org/10.1007/s00477-015-1042-4

Markoulidakis, I., & Markoulidakis, G. (2024). Probabilistic Confusion Matrix: A Novel Method for Machine Learning Algorithm Generalized Performance Analysis. *Technologies*, *12*(7). https://doi.org/10.3390/technologies12070113

Marlina, D. (2022). Klasifikasi Tutupan Lahan pada Citra Sentinel-2 Kabupaten Kuningan dengan NDVI dan Algoritme Random Forest. *STRING (Satuan Tulisan Riset Dan Inovasi Teknologi)*, *7*(1), 41. https://doi.org/10.30998/string.v7i1.12948

McKee, T. B., Nolan, J., & Kleist, J. (1993). The relationship of drought frequency and duration to time scales. *Preprints, Eighth Conf. on Applied Climatology, Amer. Meteor, Soc.*, *January*, 179–184.

Mckinney, W. (2018). *Python for Data Analysis Data Wrangling with Pandas, NumPy, and IPython SECOND EDITION*. http://oreilly.com/catalog/errata.csp?isbn=9781491957660

Mohamadi, B., Chen, S., Balz, T., & Gulshad, K. (2019). Normalized Method for Land Surface Temperature. *Sensors*, 1–19.

Noraini, A., Tjahjadi, M. E., & Sudiasa, I. N. (2022). Identifikasi Kekeringan Lahan Kabupaten Lamongan Berdasarkan Citra Satelit. *Buletin Poltanesa*, *23*(1), 335–340. https://doi.org/10.51967/tanesa.v23i1.958

Prasetyo, S. Y. J., Christianto, Y. B., & Hartomo, K. D. (2019). Analisis Data Citra Landsat 8 OLI Sebagai Indeks Prediksi Kekeringan Menggunakan Machine Learning di Wilayah Kabupaten Boyolali dan Purworejo. *Indonesian Journal of Modeling and Computing*, *2*(2), 25–36. https://ejournal.uksw.edu/icm/article/view/2954

Prasetyo, S. Y. J., Hartomo, K. D., Paseleng, M. C., Chandra, D. W., & Winarko, E. (2020). Satellite imagery and machine learning for aridity disaster classification using vegetation indices. *Bulletin of Electrical Engineering and Informatics*, *9*(3), 1149–1158. https://doi.org/10.11591/eei.v9i3.1916

Rizky, P. S., Hirzi, R. H., & Hidayaturrohman, U. (2022). Perbandingan Metode LightGBM dan XGBoost dalam Menangani Data dengan Kelas Tidak Seimbang. *J Statistika: Jurnal Ilmiah Teori Dan Aplikasi Statistika*, *15*(2), 228–236. https://doi.org/10.36456/jstat.vol15.no2.a5548

Santoso, M. F. (2019). Teknik Responsive Web Design Bootstrap 4 Serta Penerapannya Dalam Rancang Bangun Layout Web. *Jurnal Pilar Nusa Mandiri*, *15*(1), 61–68.

https://doi.org/10.33480/pilar.v15i1.101

Sharma, A. (2018). Introduction to HTML (Hyper Text Markup Language) - A Review Paper. *International Journal of Science and Research (IJSR)*, *7*(5), 2017–2019. https://doi.org/10.21275/ART20182355

UNISDR, & United Nations secretariat of the International Strategy for Disaster Reduction (UNISDR). (2009). *Drought Risk Reduction Framework and Practices: Contributing to the Implementation of the Hyogo Framework for Action.* 2013. http://www.unisdr.org/preventionweb/files/11541_DroughtRiskReduction2009library.pdf

Yao, X., Fu, X., & Zong, C. (2022). Short-Term Load Forecasting Method Based on Feature Preference Strategy and LightGBM-XGboost. *IEEE Access*, *10*(July), 75257–75268. https://doi.org/10.1109/ACCESS.2022.3192011

Yulianti, S. E. H., Soesanto, O., & Sukmawaty, Y. (2022). Penerapan Metode Extreme Gradient Boosting (XGBOOST) pada Klasifikasi Nasabah Kartu Kredit. *Journal of Mathematics: Theory and Applications*, *4*(1), 21–26. https://doi.org/10.31605/jomta.v4i1.1792

Zelle, J. (2010). Python programming: an introduction to computer science. *Beedle & Associates, Inc*, 1–406. http://www.amazon.com/dp/1887902996%5Cnhttp://books.google.com/books?hl=en&lr=&id=aJQILlLxRmAC&oi=fnd&pg=PR9&dq=Python+Programming+:+An+Introduction+to+Computer+Science&ots=CA3HCFXd2G&sig=Crj7m-MK2J_gpNGLRNYQc6pvSYA

Zhang, W., & Montgomery, D. R. (1994). Digital elevation model grid size, landscape representation, and hydrologic simulations. *Water Resources Research*, *30*(4), 1019–1028. https://doi.org/10.1029/93WR03553

Universitas Sumatera Utara
Fakultas Ilmu Komputer Dan Teknologi Informasi

Alamat
Jalan Universitas No. 9
Kampus USU, Medan
20155

Email:
fasilkomti@usu.ac.id
Telepon: (061)
8213793

KEPUTUSAN
DEKAN FAKULTAS ILMU KOMPUTER
DAN TEKNOLOGI INFORMASI
NOMOR : 158/UN5.2.14.D/SK/HK.07/2025

DEKAN FAKULTAS ILMU KOMPUTER
DAN TEKNOLOGI INFORMASI UNIVERSITAS SUMATERA UTARA

Membaca : Surat Permohonan Mahasiswa Fasilkom-TI USU tanggal 08 Januari 2025 perihal permohonan ujian skripsi:

Nama	:	KEVIN TULUS SILITONGA
NIM	:	201402051
Program Studi	:	Sarjana (S-1) Teknologi Informasi
Judul Skripsi	:	Klasifikasi Bencana Kekeringan di Jawa Timur Menggunakan Citra Satelit Landsat 8 dengan Metode Xgboost

Memperhatikan : Bahwa Mahasiswa tersebut telah memenuhi kewajiban untuk ikut dalam pelaksanaan Meja Hijau Skripsi Mahasiswa pada Program Studi Sarjana (S-1) Teknologi Informasi Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Sumatera Utara TA 2024/2025.

Menimbang : Bahwa permohonan tersebut diatas dapat disetujui dan perlu ditetapkan dengan surat keputusan

Mengingat :
1. Undang-undang Nomor 20 Tahun 2003 tentang Sistem Pendidikan Nasional.
2. Peraturan Pemerintah Nomor 17 tahun 2010 tentang pengelolaan dan penyelenggara pendidikan.
3. Keputusan Rektor USU Nomor 03/UN5.1.R/SK/SPB/2021 tentang Peraturan Akademik Program Sarjana Universitas Sumatera Utara.
4. Surat Keputusan Rektor USU Nomor 1876/UN5.1.R/SK/SDM/2021 tentang pengangkatan Dekan Fasilkom-TI USU Periode 2021-2026

MEMUTUSKAN

Menetapkan :

Pertama : Membentuk dan mengangkat Tim Penguji Skripsi mahasiswa sebagai berikut:

Ketua	:	Ainul Hizriadi S.Kom., M.Sc NIP: 198510272017061001
Sekretaris	:	Fanindia Purnamasari S.TI., M.IT NIP: 198908172019032023
Anggota Penguji	:	Sarah Purnamawati S.T., M.Sc NIP: 198302262010122003
Anggota Penguji	:	Ivan Jaya S.Si., M.Kom. NIP: 198407072015041001
Moderator	:	-
Panitera	:	-

Kedua : Segala biaya yang diperlukan untuk pelaksanaan kegiatan ini dibebankan pada Dana Penerimaan Bukan Pajak (PNPB) Fasilkom-TI USU Tahun 2025.

Ketiga : Keputusan ini berlaku sejak tanggal ditetapkan dengan ketentuan bahwa segala sesuatunya akan diperbaiki sebagaimana mestinya apabila dikemudian hari terdapat kekeliruan dalam surat keputusan ini.

Medan, 10 Januari 2025
Ditandatangani secara elektronik oleh:
Dekan

Maya Silvi Lydia
NIP 197401272002122001

Tembusan :
1. Ketua Program Studi Sarjana (S-1) Teknologi Informasi
2. Yang bersangkutan

Dokumen ini menggunakan sertifikat elektronik yang diterbitkan oleh Balai Sertifikat Elektronik (BSrE) Badan Siber dan Sandi Negara